R 语言统计分析学习笔记

杨志宏[①]

二〇一七年二月十二日

[①]西北民族大学新闻传播学院副教授，Email：yangjh@yeah.net。

目录

第 1 章 R 语言概述 **1**

1.1 R 语言介绍 1

1.1.1 R 语言简史 2

1.1.2 R 语言特点 2

1.2 R 下载与安装 2

1.2.1 RStudio 的下载与安装 3

1.2.2 扩展包的安装 3

1.2.3 R 界面介绍 3

1.3 学习资源 3

1.3.1 R 语言的帮助系统 3

1.3.2 在线学习资源 4

第 2 章 R 语言语法基础 **5**

2.1 对象 5

2.1.1 对象的基本类型 5

2.1.2 对象的属性 7

2.1.3 特殊的组合对象 7

2.2 运算及表达式 8

2.2.1 简单表达式 8

2.3 流程控制 9

2.3.1 if 9

2.3.2 循环 10

2.4 函数 10

2.4.1 函数调用 10

第 3 章 数据的导入与导出 **13**

3.1 在 R 中录入数据 13

3.2 在 Excel 中录入数据 13

3.3 导入外部数据 14

3.3.1 导入 txt 文件 14

3.3.2 导入 csv 文件 15

3.3.3 导入 Excel 文件 16
3.3.4 导入 SPSS 文件 17
3.4 导出数据 17

第 4 章 数据清理 19
4.1 数据合并 19
4.1.1 文本文件的合并 19
4.1.2 Excel 格式的数据文件合并 20
4.2 数据初步清理 20
4.2.1 删除空白数据 20
4.2.2 删除重复数据 20
4.3 逻辑一致性检查 20
4.4 重新编码与变量生成 20
4.5 数据变换 20

第 1 章　R 语言概述

随着互联网的快速发展，各个行业都积累了海量的数据，这些数据中蕴含着宝贵的线索和知识，如何分析这些数据，使之为人们所用，已成为有着广泛需求的问题。一般来说，数据分析是一个获取数据、清理数据、统计分析及解释发现的过程，详见图1-1：

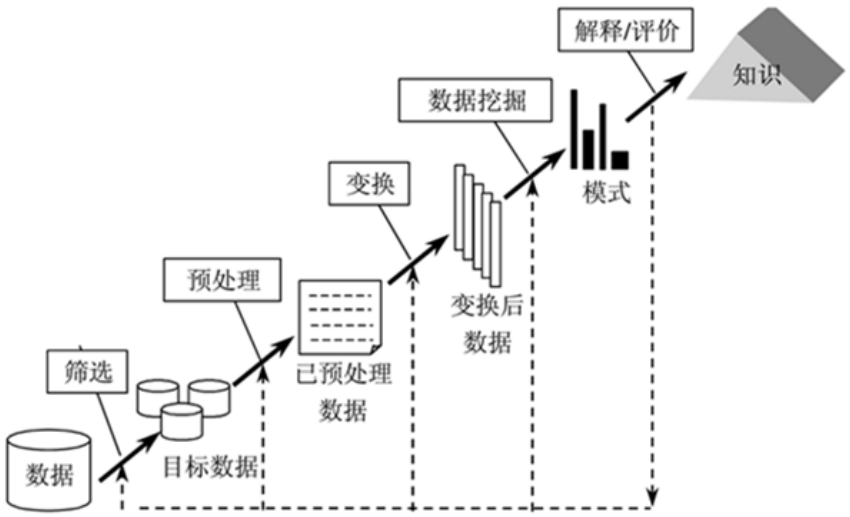


图 1-1　数据分析流程

R 语言不同于其他软件，能在数据分析的全程中灵活发挥作用，因而在竞争激烈的统计分析工具中受到人们的青睐。

1.1　R 语言介绍

R 是一套完整的数据处理、统计分析和绘制图形的软件系统。与其说 R 是一个统计软件，还不如说 R 是一种统计计算的环境。R 语言提供了大量的统计程序，使用者只需提供数据和必要的参数，便可进行简单或者复杂的统计分析。R 语言的思想是，它提供一些集成的统计工具，还提供了各种统计计算函数，从而使得使用者能够灵活地进行数据分析，甚至创造出符合需要的新的统计计算方法。

1.1.1 R 语言简史

R 之所以被称为“R”，其实是一个互联网式的幽默。Bechker 和 Chambers 在 20 世纪 80 年代早期为他们新发明的语言起名为 S。这种语言后来发展成一个商用的版本 S-PLUS，并被世界范围的统计学家广为使用。新西兰奥克兰大学的 Ross Ihaka 和 Robert Gentleman 为了教学需要，写了一个 S 的简化版。这两位先生的名字都以 R 开头，好吧，他们的这个统计编程语言就叫 R 了。

在 1995 年，Ross 和 Robert 按照 GPL 规则公开了 R 语言的源代码，这与当时风行一时的 Linux 系统开源运动不谋而合。R 很快给那些需要在 Linux 上进行统计计算的人带去了福音，而这些使用者当中，又有高手不断贡献内容，R 语言逐渐从小众工具慢慢渗透到主流用户之中。

随着 R 的发展，R 已经实现了从学界到业界的跨越，而且势头越来越猛，可以预见的是，R 的应用场景将日益广阔。而这一切，得益于 R 的开源。

1.1.2 R 语言特点

R 语言是一个数据操作、计算和可视化的工具整合包，相对于其他统计软件，其特色在于：

1. 有效的数据处理和保存机制。
2. 一系列连贯而完整的数据分析中间工具。
3. 一种完善、简洁和高效的程序设计语言。
4. R 语言具有丰富的统计方法，大多数人使用 R 语言是因为其强大的统计功能。
5. R 语言是开源免费软件。这意味着一些志愿者会提供针对特定行业需求的扩展包。
6. R 语言的学习资源非常丰富，在线文档齐全。

1.2 R 下载与安装

R 提供了主要平台（Linux、Mac OS X、Windows）的发行版本，用户可从官方网站或者镜像站点下载其最新版本。镜像站点有很多，中国有清华大学、兰州大学、中国科技大学和厦门大学提供的镜像站点。你可以选择离你最近的站点，从而加快下载速度。

目前 R 最新的版本是 3.3.2。在 windows 系统安装 R 后，在开始菜单中就可找到 R 的图标。

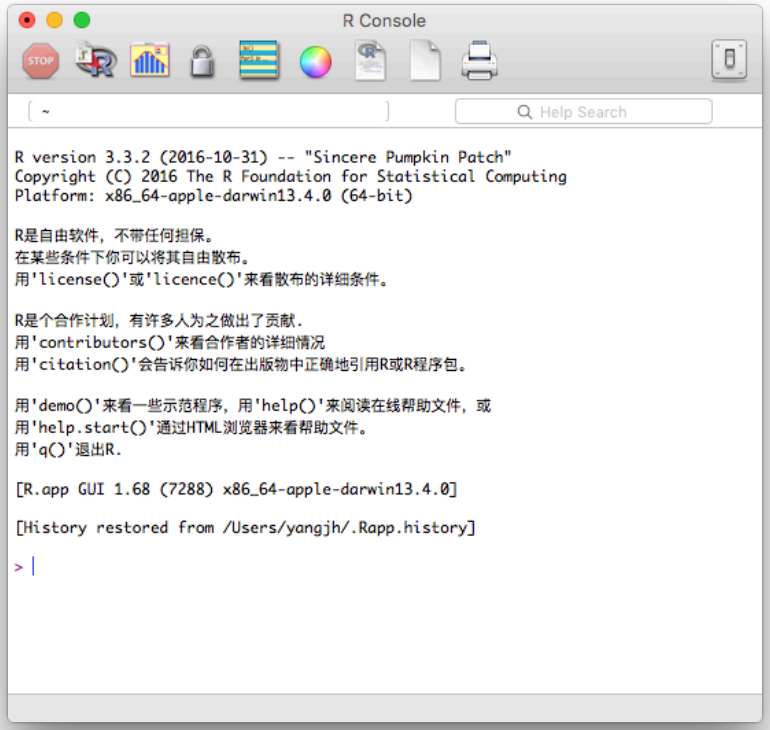


图 1-2 R 控制台

1.2.1 RStudio 的下载与安装

1.2.2 扩展包的安装

1.2.3 R 界面介绍

R 启动后，首先看到的是 R 的控制台（R Console），R 的主要命令都在这里执行。

在控制台中，我们可以交互式地使用 R，即键入相应内容，控制台会给出对应内容。

一个简单的例子

1.3 学习资源

1.3.1 R 语言的帮助系统

R 语言提供了强大的内置帮助系统，例如为了知道平均数函数 mean 的用法，可以使用如下命令：

```
>help(mean)
```

除此之外，我们还可以使用 example 来获得范例：

```
>example(mean)
```

1.3.2 在线学习资源

1. An Introduction to R R 语言官方介绍
2. R Language Definition R 语言官方语法手册
3. R 语言与统计分析
4. 慕课网 R 语言视频教程
5. 非常棒的 R 入门交互教程

参考文献

第 2 章　R 语言语法基础

任何一门编程语言，都会定义自己的规则，其中变量、运算和控制是编程语言最基本的要素，在这一章节，我们将学习 R 语言在变量定义和类型、数据运算和流程控制三个方面的基础知识。

2.1　对象

每种编程语言都提供访问存储在内存中数据的方式，不同于其他编程语言，R 并不能直接访问内存数据，但是提供了“对象”的机制来结构化内存中的数据，通过对象来访问数据。这是 R 语言非常不同于其他语言的地方。

2.1.1　对象的基本类型

向量

向量是由相同基本类型元素组成的序列，相当于一维数组，可视为含有数据的连续单元格。单元格中的数据可以通多索引操作符来获取，比如 x[5]。R 语言中有六种基本的向量类型：逻辑型（logical）、整型（integer）、实数（real）、复数（complex）、字符串（string）和原型（raw）。在 R 语言中，整型和实数之间的区别并不是十分重要。[1] 使用大写字母 L 可以创建整型数据：

```
> 1L
[1]
```

如果我们要创建一个由 5 个数值组成的向量 x，这 5 个值分别是 1，3，5，7，9。R 中的命令是：

```
x = c(1,3,5,7,9)
```

这里的函数 c() 可以有任意多个参数，而它输出的值则是一个把这些参数首尾相连形成的一个向量。

R 语言的赋值符号除了“=”之外，还有“->”和“<-”，建议使用“<-”作为赋值符号。

除此之外，我们还可以使用 vector 函数来创建向量：

```
x <- vector("real", length = 10)
```

上述语句将创建一个长度为 10，各个元素为实数的空向量。

可以使用 typeof 或者 class 函数得到 R 中对象的类型。

```
> typeof(x)
[1] "double"
```

矩阵

矩阵是将数据用行和列排列的长方形表格，它是二维的数组，其单元格必须是相同的数据类型。通常用列表示不同的变量，用行来表示各个对象。可以使用 matrix 函数创建矩阵：

```
> matrix(2, nrow = 2, ncol = 3)
     [,1] [,2] [,3]
[1,]    2    2    2
[2,]    2    2    2
```

上述语句将创建一个 2 行 3 列，元素全部都是 2 的矩阵。

数组

数组与矩阵类似，但是维度可以大于 2。使用 array 函数创建数组：

```
> array(1:24,dim = c(2,3,4))
, , 1

     [,1] [,2] [,3]
[1,]    1    3    5
[2,]    2    4    6

, , 2

     [,1] [,2] [,3]
[1,]    7    9   11
[2,]    8   10   12

, , 3

     [,1] [,2] [,3]
[1,]   13   15   17
[2,]   14   16   18
```

```
, , 4

     [,1] [,2] [,3]
[1,]   19   21   23
[2,]   20   22   24
```

上述的语句将创建一个用 1-24 之间数字填充的三维数组。

列表

列表是另外一种数据存储形式，列表中的元素可以是 R 对象中的任何一种。也就是说，列表用于组织多种类型的数据。比如不同班级、不同性别的学生成绩之类的数据。

使用 list 函数创建列表：

```
> x = c(1,1,2,2,3,3,4,4)
> y = c('男',"女",'男',"女",'男',"女",'男',"女")
> z = c(80,85,89,88,80,85,89,88)
> totalScore = list(class=x, sex=y,score=z)
> totalScore
$class
[1] 1 1 2 2 3 3 4 4

$sex
[1] "男" "女" "男" "女" "男" "女" "男" "女"

$score
[1] 80 85 89 88 80 85 89 88
```

2.1.2 对象的属性

对象的常用属性有名称（name）、维度（dimensions）、类型（class）、长度（length）。

2.1.3 特殊的组合对象

因子

因子（factor）是用来处理分类数据的，比如性别这个变量就有男和女两个类别。使用 factor 函数来创建因子：

```
> y = c('男',"女",'男',"女",'男',"女",'男',"女")
> f = factor(y)
> f
[1] 男 女 男 女 男 女 男 女
```

```
Levels: 男 女
```

上述语句根据 y 向量值的情况，创建了一个包含有两个值的因子 f。

数据框

数据框（data frame）主要用来存储表格数据，可以视为各个元素长度相同的列表，每个元素代表一列数据，元素的长度就是行数，既然是列表，当然其元素类型可以不同。数据框是进行数据分析是最主要的数据结构类型。

2.2 运算及表达式

在编程语言中，所有的表达式有应该有个值。我们先从简单的表达式开始学习。

2.2.1 简单表达式

常数

在控制台中直接键入数字，就是常数：

```
> 1
[1] 1
```

变量名

当一个变量被创建时，必须给它一个名字，这个名字叫做 symbol，symbol 也是对象，在 R 语言中，所有的东西都是对象。

```
y = 4
```

在这个例子中，y 是个 symbol，它的值是 4。

操作符

R 语言有一系列运算符：

```
- Minus, can be unary or binary
+ Plus, can be unary or binary
! Unary not
~ Tilde, used for model formulae, can be either unary or binary
? Help
: Sequence, binary (in model formulae: interaction)
```

```
* Multiplication, binary
/ Division, binary
^ Exponentiation, binary
%x% Special binary operators, x can be replaced by any valid name
%%  Modulus, binary
%/% Integer divide, binary
%*% Matrix product, binary
%o% Outer product, binary
%x% Kronecker product, binary
%in%  Matching operator, binary (in model formulae: nesting)
< Less than, binary
> Greater than, binary
==  Equal to, binary
>=  Greater than or equal to, binary
<=  Less than or equal to, binary
& And, binary, vectorized
&&  And, binary, not vectorized
| Or, binary, vectorized
||  Or, binary, not vectorized
<-  Left assignment, binary
->  Right assignment, binary
$ List subset, binary
```

2.3 流程控制

2.3.1 if

if else 语句可以根据不同条件允许不同的语句块:

```
if ( statement1 )
    statement2
else
    statement3
```

当然，也可以嵌套:

```
if ( statement1 ) {
    statement2
} else if ( statement3 ) {
    statement4
} else if ( statement5 ) {
    statement6
} else
    statement8
```

2.3.2 循环

for

for 循环语法：

```
for ( name in vector )
   statement1
```

while

```
while ( statement1 ) statement2
```

2.4 函数

除了 R 自带的函数之外，用户可以自己根据需要创建函数，语法如下：

```
function ( arglist ) body
```

比如，我们编写一个没有参数的函数：

```
> welcome = function() print("Welcome to using R")
> welcome
function() print("Welcome to using R")
> welcome()
[1] "Welcome to using R"
```

从上面的代码运行结果可以看出，函数的定义使用 function 关键字，调用时要用括号。

还可以在定义函数的时候设置参数：

```
> welcome = function(name) print(paste("Welcome to using R!,", name))
> welcome('Yang')
[1] "Welcome to using R!, Yang"
```

上述函数中 paste 函数用来连接字符串，详细用法可以参看手册。

2.4.1 函数调用

在 R 中，大多数表达式都和函数调用有关。函数通过函数名和其必要的参数值进行调用：

```
> mean(c(1,2,3))
[1] 2
```

参考文献

[1] CRAN. R Language Definition[EB/OL]. 2017. https://cran.r-project.org/doc/manuals/r-release/R-lang.html.

第 3 章　数据的导入与导出

相对于数据统计而言，数据的录入或者导入工作虽然简单，但非常繁琐和耗时。

3.1　在 R 中录入数据

在 R 中，我们可以使用 edit 命令用电子表格的形式编辑、录入数据，但要求编辑的数据已经存在或已被定义。[1] 例如：

```
elements <- data.frame()
elements <- edit(elements)
```

命令运行后，会启动 R 电子表格对话框，可以进行交互编辑，如图3-1：

编辑完成后，关闭窗口会自动保存数据并传回到 R。这种方式虽然看似简单，但其功能较弱，并不建议使用这种方式录入大量数据。

3.2　在 Excel 中录入数据

与在 SPSS 和 R 中录入数据相比，在 Excel 软件中录入数据，有一些要求：

1. 所有的数据应该在一个表中。
2. 变量名称应该在表的第一行。
3. 变量名中不能有特殊字符、空格。
4. 不能有空行。
5. 在原始数据中应该有问卷编号或者 id 这样的变量，方便数据清理。
6. 除非必须，否则都应使用数字代表选项，比如，用 1 代表男性，0 代表女性。
7. 缺失值不要填入任何内容，留空即可。
8. 日期使用“月/日/年”格式。
9. 不要忘记定时存盘及备份数据，重要数据一定要有网络备份。

在遵守以上规则的同时，我们还可以利用 Excel 的一些特性，高质量的完成数据录入工作：

1. 避免在 Excel 中使用排序功能，以免混乱数据。若需排序，则一定要全部数据排序。

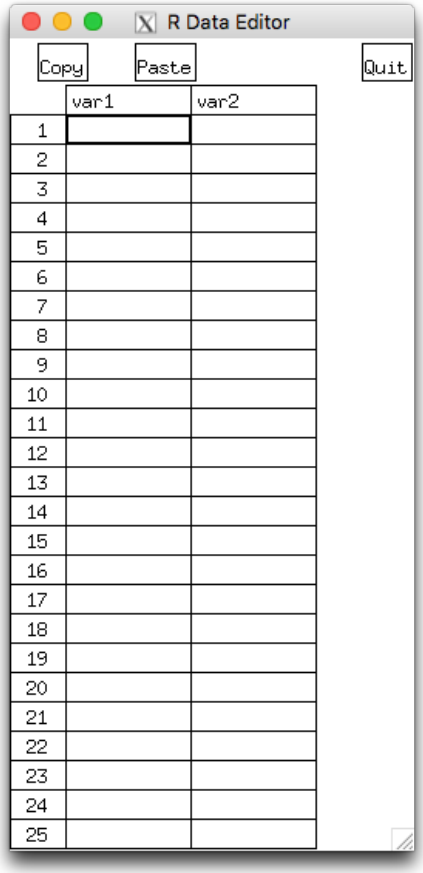


图 3-1 R 数据编辑界面

2. ID 的值可以通过拖动自动生成。
3. 可通过设置数据的有效性，来防止输入错误。参见图3-2。
4. 数据输入的过程中难免会出错误，为最大限度的降低录入数据时的错误，我们最好确保同一份问卷由不同的录入人员分别录入。Excel 可以方便得对比，以发现不同录入人员在同一值上的区别。将不同人员录入的表，分别放在 sheet1 和 sheet2 中，然后在 sheet3 中，输入公式 `=IF(sheet1!A1=sheet2!A1,1,0)`，将其自动填充到所有有效区域，即可方便得看出录入的不同地方。

3.3 导入外部数据

以下介绍如何导入常见格式的外部文件。

3.3.1 导入 txt 文件

有时候，我们需要导入 txt 格式的文件，R 对.txt 格式的文件有一些要求：

1. 首行应该为变量名称。
2. 变量、值之间应该用符号隔开，这些符号常见的有空格、分号等等。
3. 中文以 utf 格式存储。



图 3-2 Excel 数据验证设置

4. 缺失值以 NA 表示。

只要格式符号要求，就可以使用 read.table 导入到 R 中：

```
> recodes = read.table("/Users/yangjh/document/works/ci/收益率.txt",
   header = T,fileEncoding = "UTF-16")
> class(recodes)
[1] "data.frame"
> recodes
     买入日期 股票名称 买入数量 买入价格 实际卖出价格
1   2014/12/3 中信证券      300    19.63        25.35
2   2014/12/3 民生银行     1000     8.49        10.41
3   2014/12/5 深圳能源      700    10.16        11.70
4   2014/12/5 中国平安      100    62.40        63.20
```

read.table 函数导入后以数据框的结构存储数据，必须要指定文件存放路径及名称，header 参数为真，将以第一行的数据为变量名称。如果文件中有中文，还要指定文件的编码方式。

3.3.2 导入 csv 文件

和 txt 文件类似，导入 csv 文件也需要 csv 文件本身符合如下规则：

1. 首行应该为变量名称。
2. 变量、值之间应该用符号隔开。
3. 中文以 utf 格式存储。[①]
4. 缺失值以 NA 表示。

可以使用 read.table 或者 read.csv 函数，read.csv 函数其实就是 read.table 函数。

```
> recodes = read.csv("/Users/yangjh/document/works/ci/收益率/复利计算
   .csv",header = T,fileEncoding = "UTF-8")
> recodes
          本金 追加本金 收益率          资产
1     300,000          20%    JP¥ 360,000
2     360,000   20,000 20%    JP¥ 456,000
3     456,000   20,000 20%    JP¥ 571,200
4     571,200   20,000 20%    JP¥ 709,440
```

3.3.3 导入 Excel 文件

若要在 R 中使用 Excel 的数据，有很多种办法，可以将其转换为 txt 或者 csv 文件，也可以使用扩展包来直接获取 Excel 的内容，用来读取 Excel 文件的扩展包较多，常用 openxlsx 扩展包：

```
> install.packages('openxlsx')
> library(openxlsx)
> demo <- read.xlsx("/Users/yangjh/document/works/ci/收益率.xlsx")
> demo
       本金 追加本金 收益率     资产
1    300000       NA    0.2   360000
2    360000    20000    0.2   456000
3    456000    20000    0.2   571200
4    571200    20000    0.2   709440
5    709440    20000    0.2   875328
6    875328    20000    0.2  1074394
```

使用这种方法，避免了 csv 文件的导出及中文编码的转换问题，并且数值及时间等内容更符合使用习惯。

其中 install.packages('openxlsx') 安装好之后，以后再导入 Excel 文件就无需执行。

另外，还可以在 Excel 中将文件打开，观察数据结构后将其复制到剪切板，然后一样可以使用 read.table('clipboard') 导入到 R 里。

[①]在 OS X 中，Excel 存储 csv 格式时，无法指定编码方式，可通过苹果 Numbers 导出为 utf 编码的 csv 文件。

3.3.4 导入 SPSS 文件

导入 SPSS 文件和导入 Excel 文件类似，可以将其转为 csv 格式或用剪切板的方式。当然，也可以使用扩展包直接打开，考虑到中文编码问题，我们建议使用 haven 扩展包：

```
install.packages('haven')
library(haven)
read_sav("mtcars.sav")
```

3.4 导出数据

导出数据大多采用 csv 格式，white.table 函数可以完成需求。

```
> write.table(data, "/Users/yangjh/Downloads/数据/80222-80231.csv",
   fileEncoding = "UTF-8")
```

参考文献

[1] Andrie de Vries, Joris Meys. How to Enter Data into the R Text Editor - dummies[EB/OL]. 2017. http://www.dummies.com/programming/r/how-to-enter-data-into-the-r-text-editor/.

第 4 章　数据清理

数据清洗，是整个数据分析过程中不可缺少的一个环节，其结果质量直接关系到模型效果和最终结论。在实际操作中，数据清洗通常会占据分析过程的大部分时间。通常而言，数据清理工作主要包含如下内容：



图 4-1　数据清理路径

4.1　数据合并

通常情况下，我们的数据录入工作往往由多人完成，需要进行数据的合并工作。

4.1.1　文本文件的合并

如果数据文件格式为 txt 或者 csv，就先采用 read.table 函数分别读入文件：

```
> data1 <- read.table('/Users/yangjh/document/works/www/LearningR/
   Data/收益率1.txt', header = T, fileEncoding = 'UTF-16')
> data2 <- read.table('/Users/yangjh/document/works/www/LearningR/
   Data/收益率2.txt', header = T, fileEncoding = 'UTF-16')
```

```
> data1
   买入日期 股票名称 买入数量 买入价格 实际卖出价格 卖出利润
1 2014/12/3 中信证券      300    19.63        25.35     1716
2 2014/12/3 民生银行     1000     8.49        10.41     1921
3 2014/12/5 深圳能源      700    10.16        11.70     1078
4 2014/12/5 中国平安      100    62.40        63.20       80
> data2
    买入日期 股票名称 买入数量 买入价格 实际卖出价格 卖出利润
1 2014/12/24 瀚蓝环境      300    14.86        14.92       18
2 2014/12/25 海油工程     1400    11.13        14.68     4970
3 2014/12/29 海油工程      400    11.18        14.68     1400
4  2015/1/13 福耀玻璃     1000    13.05        13.27      220
5  2015/1/14 浦发银行     1000    15.42        17.01     1590
> data <- rbind(data1,data2)
> data
    买入日期 股票名称 买入数量 买入价格 实际卖出价格 卖出利润
1  2014/12/3 中信证券      300    19.63        25.35     1716
2  2014/12/3 民生银行     1000     8.49        10.41     1921
3  2014/12/5 深圳能源      700    10.16        11.70     1078
4  2014/12/5 中国平安      100    62.40        63.20       80
5 2014/12/24 瀚蓝环境      300    14.86        14.92       18
6 2014/12/25 海油工程     1400    11.13        14.68     4970
7 2014/12/29 海油工程      400    11.18        14.68     1400
8  2015/1/13 福耀玻璃     1000    13.05        13.27      220
9  2015/1/14 浦发银行     1000    15.42        17.01     1590
```

利用 rbind 或者 cbind 函数，能够按照行或者列合并向量、矩阵和数据框。

4.1.2 Excel 格式的数据文件合并

4.2 数据初步清理

4.2.1 删除空白数据

4.2.2 删除重复数据

4.3 逻辑一致性检查

4.4 重新编码与变量生成

4.5 数据变换

参考文献

[1] CRAN. R Language Definition[EB/OL]. 2017. https://cran.r-project.org/doc/manuals/r-release/R-lang.html.

[2] Andrie de Vries, Joris Meys. How to Enter Data into the R Text Editor - dummies[EB/OL]. 2017. http://www.dummies.com/programming/r/how-to-enter-data-into-the-r-text-editor/.