# Introduction to Linear Algebra

6th Edition

麻省理工学院数学教材

清华大学数学基础教学中心翻译

# 线性代数

（原书第6版·中文版）

[美] 吉尔伯特·斯特朗（Gilbert Strang）◎著
麻省理工学院

刘余 黄眸辉 杨晶◎译
清华大学

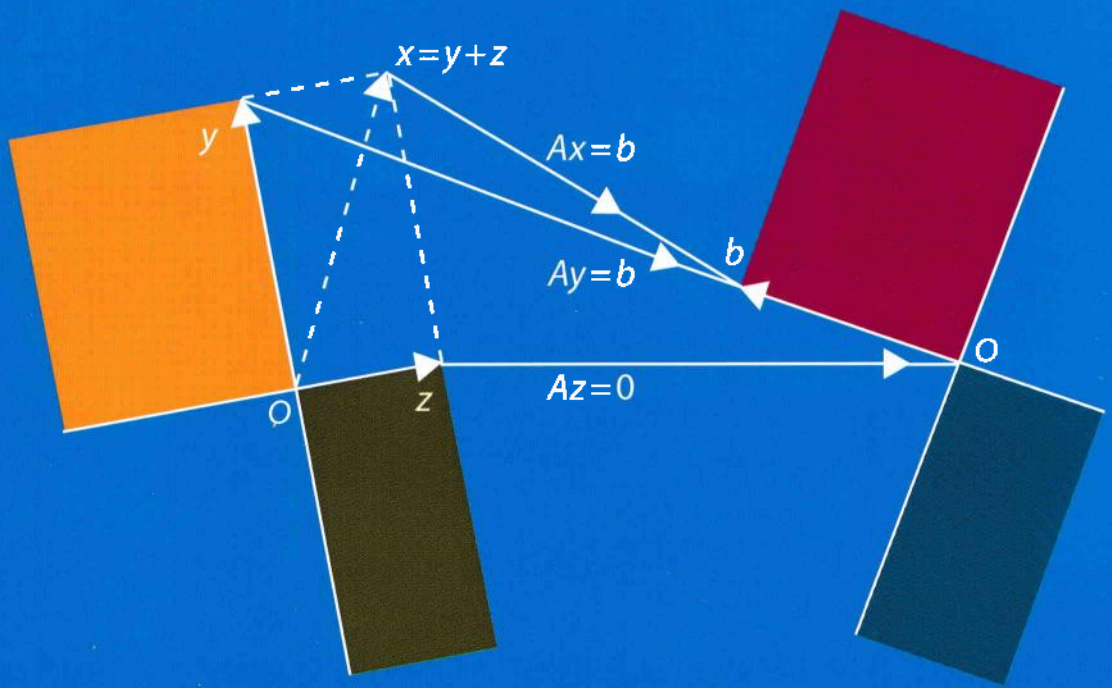


数字资源库

练习题库 教学课件

清华大学出版社

## 作|者|简|介

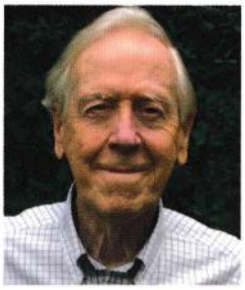

**吉尔伯特·斯特朗**
（Gilbert Strang）

麻省理工学院数学系教授，美国国家科学院院士，享有盛誉的数学家、教育家。在麻省理工学院执教60余年，担任“线性代数导论”“计算科学与工程”等公开课程主讲人，相关视频公开课程全球累计播放量达数千万次。曾担任美国数学联合政策委员会主席、美国国家数学委员会主席、美国国家科学基金会数学顾问小组主席、国际工业与应用数学理事会理事、阿贝尔奖委员会委员等重要学术职务。作为全球数学界的著名学者，他在有限元理论、变分法、小波分析和线性代数等领域成就斐然，出版数学教材和学术专著10余部，对现代数学及其教育发展影响深远。

数|字|资|源|库

- 练习题库
- 教学课件

说明：本书配套英文原版题库（含习题解答）、教学课件，扫描上方二维码即可获取。

Introduction to
# Linear Algebra
6th Edition

## 五种矩阵分解

$A=CR$

- $C$ 矩阵 $A$ 的前 $r$ 个线性无关的列向量
- $R$ 用 $C$ 的列向量线性组合构成 $A$ 的列向量

$A=LU$

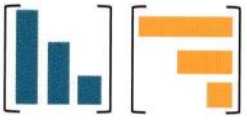

- $L$ 对角线元素均为 1 的下三角矩阵
- $U$ 对角线元素均为非零的上三角矩阵

$A=QR$

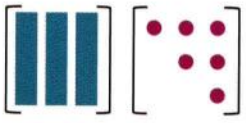

- $Q$ 列向量是两两正交的单位向量
- $R$ 上三角矩阵，用 $Q$ 的单位正交的列向量线性组合构成 $A$ 的列向量

$S=Q\Lambda Q^{\mathrm{T}}$
$SQ=Q\Lambda$

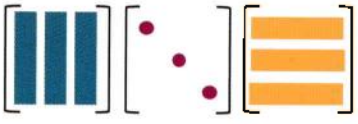

- $Q$ $Q$ 的列向量是 $S$ 的单位正交的特征向量
- $\Lambda$ 对角矩阵，对角元为 $S$ 的实特征值

$A=U\Sigma V^{\mathrm{T}}$
$AV=U\Sigma$

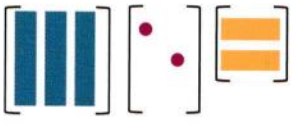

- $U$ 单位正交左奇异向量（由 $A$ 产生）
- $\Sigma$ 对角矩阵，其对角元为 $A$ 的正奇异值
- $V$ 单位正交的右奇异向量（作为 $A$ 的输入）

文泉云盘
防盗码

水木书荟
www.shuimushuhui.com
图书详情　教学资源
会议资讯　图书出版

图 书 资 源
书 圈

上架建议：人工智能/数学基础
ISBN 978-7-302-71165-0
9 787302 711650 >
定价：138.00元

## 译|者|简|介

**刘余**

本科毕业于北京大学数学科学学院，博士毕业于中国科学院数学与系统科学研究院，代数数论专业，重点研究椭圆曲线的算术理论。后在清华大学丘成桐数学科学中心先后做博士后和助理教授；现任清华大学数学基础教学中心讲师，“线性代数”课程团队骨干教师，多次教授“线性代数”课程，深受学生喜爱。

**黄晔辉**

本硕博连读毕业于清华大学数学科学系，现任清华大学数学基础教学中心副教授，“线性代数”课程团队骨干教师。主要研究领域为可积系统。曾出版教材《工程数学基础》、专著《孤立子系统的可积形变及应用》。

**杨晶**

本硕博连读毕业于清华大学数学科学系，现任清华大学数学基础教学中心教授，“线性代数”课程团队负责人。多年来在清华大学讲授代数类课程（“线性代数”“抽象代数”等），深受学生喜爱。所讲授的“简明线性代数”课程获评国家级一流本科课程，北京高校优质本科课程。个人曾获北京市青年教学名师，北京市高等教育教学成果奖二等奖，清华大学新百年教学成就奖等教学荣誉。

MASSACHUSETTS INSTITUTE OF TECHNOLOGY
CAMBRIDGE MA 02139

Best wishes in all your work!

Gilbert Strang

GILBERT STRANG
March 2026

DEPARTMENT OF MATHEMATICS ROOM 2-240

# 线性代数

## （原书第6版·中文版）

[美] 吉尔伯特·斯特朗（Gilbert Strang）◎著
刘余 黄晔辉 杨晶◎译

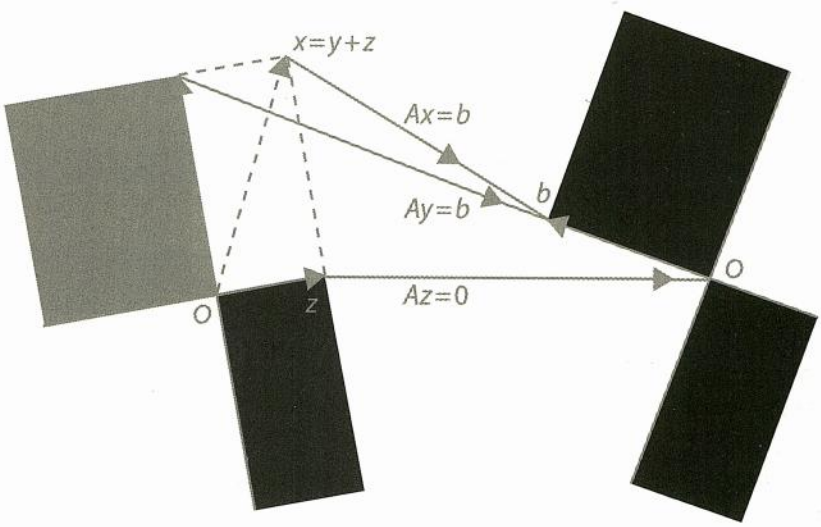


清華大學出版社
北京

北京市版权局著作权合同登记号　图字：01-2025-3515

## 内 容 简 介

本书由麻省理工学院（MIT）科学计算和信号处理领域教授 Gilbert Strang 所著，以线性方程组为核心框架，将抽象概念（如向量空间、特征值）与实际应用（如网络图、机器学习）相结合，被 MIT 等 600 余所高校采用. 2022 年修订后推出了第 6 版. 修订后的第 6 版修改了对线性代数应用的阐述，从传统应用领域转向了更与时俱进的最优化问题以及机器学习；力图把线性代数的理论和时代前沿相连通.

本书概念清晰，层次合理，实用性强，可以作为普通高等学校“线性代数”课程的本科生入门教材，也可以作为对线性代数的实际应用感兴趣的工程师的案头参考资料.

Original English language title: Introduction to Linear Algebra (Sixth Edition) by Gilbert Strang, copyright © 2023.
ISBN: 9781733146678
All Rights Reserved.

本书简体中文版由 Wellesley-Cambridge Press 授权清华大学出版社出版发行。

**版权所有，侵权必究。举报：010-62782989，beiqinquan@tup.tsinghua.edu.cn。**

**图书在版编目（CIP）数据**

线性代数：原书第 6 版 /（美）吉尔伯特•斯特朗（Gilbert Strang）著；刘余，黄晔辉，杨晶译. -- 北京：清华大学出版社，2026. 3. -- ISBN 978-7-302-71165-0

Ⅰ. O151.2

中国国家版本馆 CIP 数据核字第 2026FY7935 号

**责任编辑：**崔　彤
**封面设计：**李召霞
**责任校对：**时翠兰
**责任印制：**宋　林

**出版发行：**清华大学出版社
网　　址：https://www.tup.com.cn，https://www.wqxuetang.com
地　　址：北京清华大学学研大厦 A 座　　邮　　编：100084
社 总 机：010-83470000　　邮　　购：010-62786544
投稿与读者服务：010-62776969，c-service@tup.tsinghua.edu.cn
质量反馈：010-62772015，zhiliang@tup.tsinghua.edu.cn
配套资源下载：https://www.tup.com.cn，010-83470236

**印 装 者：**三河市天利华印刷装订有限公司
**经　　销：**全国新华书店
**开　　本：**210mm×260mm　　**印　　张：**27　　**字　　数：**728 千字
**版　　次：**2026 年 3 月第 1 版　　**印　　次：**2026 年 3 月第 1 次印刷
**定　　价：**138.00 元

产品编号：108794-01

# 译者序

## TRANSLATOR'S FOREWORD

尊敬的读者朋友们，当你们翻开这本《线性代数》（原书第 6 版）时，展现在眼前的不仅是一本经典的线性代数的入门教材，更是一位卓越教育家毕生教学智慧的结晶. 作为麻省理工学院（MIT）的资深教授，Gilbert Strang 教授自 1961 年始，从事教职凡六十余年，除了在学术研究领域的成就，亦深耕线性代数教育领域. Strang 教授以其深邃的学科洞见、独特的教学视角和充满人文关怀的叙述方式，将线性代数这一现代科学与工程的基石，转化为一场启迪思维的探索之旅.

线性代数是数学领域中极具生命力与实用性的学科之一. 从图像处理的奇异值分解到经济模型的优化分析，再到人工智能的神经网络，线性代数的语言与方法早已渗透现代科技的每个角落. 然而，许多初学者在面对抽象的定义与符号时，往往感到迷茫. Strang 教授以其特有的教学艺术，在严谨性与直观性之间架起了一座桥梁. 他善于用几何的图景为代数概念赋予鲜活的生命力，用工程师的实用思维诠释数学定理的价值，用真实的案例揭示理论演进的脉络.

原书第 6 版大体上延续了前作的框架，同时与时俱进地融入数据科学、机器学习等新兴领域的前沿应用. 例如，矩阵分解（如奇异值分解）与最小二乘法的讨论更加贴近实际问题的需求；关于向量空间与线性变换的阐述始终以“理解结构”，即矩阵的四个基本子空间为核心，而非止步于计算技巧；新增的章节与习题进一步强化了线性代数与数值计算、优化理论的交叉融合. Strang 教授尤其注重培养读者的“数学直觉”：他通过精心设计的图示、类比和开放式问题，引导读者从多个角度观察概念的本质，逐步建立起独立解决复杂问题的信心.

本书提及了丰富的实际应用案例，并将理论与应用融会贯通. 同时，译者在清华大学多年的教学中发现，母语为中文的学生，在使用英文数学教材学习时，花费了相当的精力在语言上. 所以翻译的目的是为中文读者减少语言上的负担，从而更加聚焦数学知识点本身. 这些是促成译者翻译本书的根本动力，希望能借助 Strang 教授的“他山之玉”，来琢磨众多对线性代数有着重要需求的读者. 译者在翻译时，力求复刻 Strang 教授清新优雅的文笔、层层递进的讲解，以及贯穿始终的“应用驱动理论”的哲学，但有怠于笔力，终有诸多不及，恳请读者谅解指正，不胜感激.

此外，中文读者和原书所面对的对象在教育背景和教育体系以及文化根基上都有诸多不同，因此译者也试图尽量弥合其中的缝隙. 所做的努力包括语言叙述习惯的调整，增加一些注记，等等；但仅有这些是远远不够的，也请读者对此予以一定的理解. 译者对于一些阅读方式上的不同之处，在此举一些例子. 比如，书中有时对二阶或者三阶方阵的例子进行了详细说明，但是对于一般的 $n$ 阶方阵并没有详细论证（例如 2.2 节）；有的课后习题给的提示过于详细，甚至详细到了给出了完备的证明（例如习题 1.2 中的第 20 题）. 译者认为 Strang 教授的意图在于让读者领会数学的实质，而非陷入严密的逻辑中无法自拔. 所以，译者也建议读者在“理解实质”和“严密逻辑”之间根据自己的实际情况做好平衡，如仍感有所不足，可辅以其他教材.

本书既是一本教材，也是一份邀请函——邀请工程师以数学家的眼光重新审视实际问题，也邀请数学家以工程师的务实精神考察实际问题. 无论你是初次接触线性代数的本科生，还是希望深化理论理解的科研工作者；无论你专注于计算机视觉与自然语言处理，还是金融建模或物理仿真，本书都将对你有一定的帮助.

谨以此序，献给所有使用线性代数、探索线性代数的读者.

译者

2026 年 1 月于清华园

# 前言

## PREFACE

我们从两个列向量 $\boldsymbol{a}_1$ 和 $\boldsymbol{a}_2$ 开始. 设它们各有三个分量，则分别对应了三维空间中的两个点. 为了把它们在图中画出来，还需要一个中心点，即对应于零向量的原点：

$$\boldsymbol{a}_1=\begin{bmatrix}2\\3\\1\end{bmatrix},\qquad \boldsymbol{a}_2=\begin{bmatrix}1\\4\\2\end{bmatrix},\quad \text{零向量}\,\mathbf{0}=\begin{bmatrix}0\\0\\0\end{bmatrix}$$

下图将向量呈现在二维平面上，此外我们也会有利用透视原理进行三维向量的画图练习. 下图标出了 $\boldsymbol{a}_1$、$\boldsymbol{a}_2$、$2\boldsymbol{a}_1$ 以及向量之和 $\boldsymbol{a}_1+\boldsymbol{a}_2$.

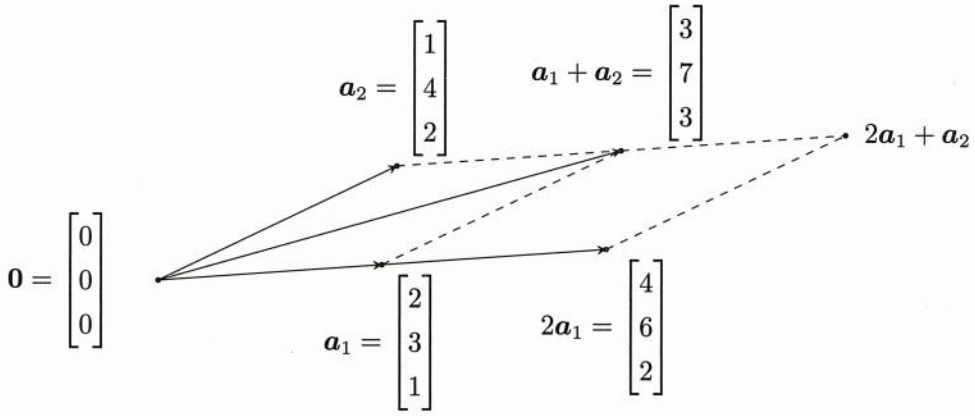


上图展示了两类基本操作：向量加法 $\boldsymbol{a}_1+\boldsymbol{a}_2$，以及数 2 与向量的乘法. 再将这两种操作结合就产生了“线性组合” $2\boldsymbol{a}_1+\boldsymbol{a}_2$：

$$\text{线性组合}=c\boldsymbol{a}_1+d\boldsymbol{a}_2,\quad \forall c,d\in\mathbb{R}$$

上述数值 $c$ 和 $d$ 也可以是负数. 在这种情况下，$c\boldsymbol{a}_1$ 和 $d\boldsymbol{a}_2$ 将会改变为与 $\boldsymbol{a}_1$ 和 $\boldsymbol{a}_2$ 相反的方向：从右指向左. 同样非常重要的是，$c$ 和 $d$ 可以为分数. 下图是一张包含更多线性组合的示意图. 我们最终想要的是所有的形如 $c\boldsymbol{a}_1+d\boldsymbol{a}_2$ 的向量.

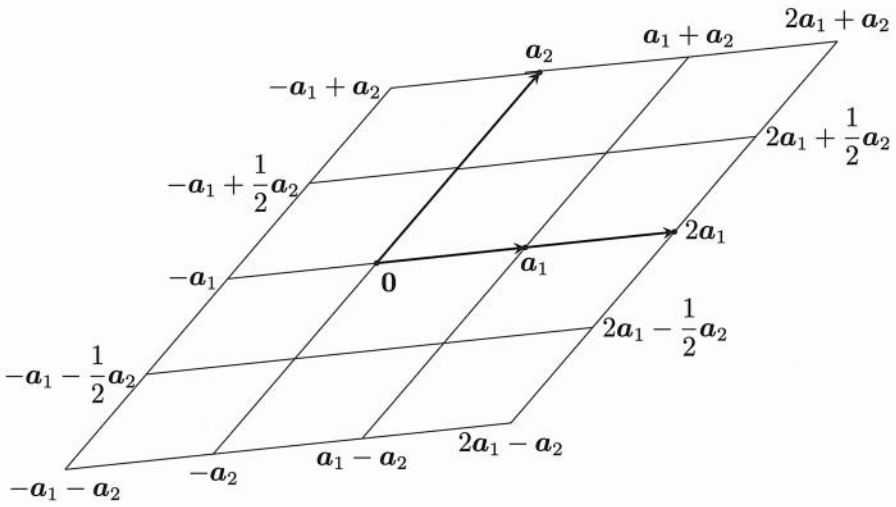


全体线性组合$c\boldsymbol{a}_1+d\boldsymbol{a}_2$填满了一整个平面——这是一个非常重要的事实. 它是三维空间中包含了无限多点的一个平面. 将系数 $c$ 和 $d$ 取更多的值，例如分数和小数，当 $c,d$ 取遍 $\mathbb{R}$，$c\boldsymbol{a}_1+d\boldsymbol{a}_2$ 可以填满整个平面. 而平面上的任意一点都可以表示为 $\boldsymbol{a}_1$ 和 $\boldsymbol{a}_2$ 的线性组合.

现在我们来讨论线性代数中的一个基本概念：矩阵. 矩阵 $\boldsymbol{A}$ 包含 $n$ 个列向量 $\boldsymbol{a}_1,\boldsymbol{a}_2,\cdots,\boldsymbol{a}_n$. 在下面的示例中，我们给出的矩阵只有两个列向量 $\boldsymbol{a}_1$ 和 $\boldsymbol{a}_2$，它们是三维空间中的向量，即该矩阵有 3 行 2 列：

3 行2 列矩阵
$m=3$ 行
$n=2$ 列

$$\boldsymbol{A}=\begin{bmatrix}\boldsymbol{a}_1 & \boldsymbol{a}_2\end{bmatrix}=\begin{bmatrix}2 & 1\\ 3 & 4\\ 1 & 2\end{bmatrix}$$

这两列的线性组合生成了三维空间中的一个平面，该平面有一个自然的名称，称为矩阵的列空间. 一般地，对于任何矩阵 $\boldsymbol{A}$，$\boldsymbol{A}$ 的列空间由它的列向量的线性组合的全体构成.

到目前为止，我们介绍了四个基本概念，均出现在第 1 章.

（1）三维空间中的列向量$\boldsymbol{a}_1$ 和 $\boldsymbol{a}_2$.

（2）三维列向量的线性组合$c\boldsymbol{a}_1+d\boldsymbol{a}_2$.

（3）矩阵$\boldsymbol{A}$ 包含列向量 $\boldsymbol{a}_1$ 和 $\boldsymbol{a}_2$.

（4）矩阵的列空间= 列向量的线性组合的全体 = 一个平面.

接下来，在矩阵 $\boldsymbol{A}$ 中添加两列新的三维列向量，得到：

$$\boldsymbol{A}=\begin{bmatrix}2 & 1 & 3 & 0\\ 3 & 4 & 7 & 0\\ 1 & 2 & 3 & -1\end{bmatrix}$$

线性代数的一个阶段性目标是理解每个矩阵的列空间. 我们尝试解释这个例子：

- 第 1 列和第 2 列可生成与之前相同的平面（因为有相同的 $\boldsymbol{a}_1$ 和 $\boldsymbol{a}_2$）；
- 第 3 列并没有提供新的信息，因为 $\boldsymbol{a}_3$ 属于上述平面：$\boldsymbol{a}_3=\boldsymbol{a}_1+\boldsymbol{a}_2$；
- 第 4 列不在平面上：加上 $c_4\boldsymbol{a}_4$ 会提升或降低平面.

实际上，该矩阵的列空间是整个三维空间，即它包括三维空间中的所有点！

从上述讨论可以看到如何逐列地、从左到右地进行操作. 每一列可以独立于前几列（称线性无关），或者也可表示为前几列的线性组合. 为了产生三维空间中的每个点，需要三个线性无关的列向量.

### 矩阵乘积 $A = CR$

使用“线性组合”和“线性无关列”这两个词可以很好地描述上述 3 行 4 列的矩阵 $\boldsymbol{A}$. 其中，第 3 列是一个线性组合：列 1 + 列 2. 而第 1、2、4 列是线性无关的. 要用线性无关的第 1、2、4 列线性组合出零向量，唯一的方法是把这三列全用系数零来乘.

至此，第 1 章的一个关键思想已经呼之欲出. 矩阵乘法是记录我们所知信息的完美方式. 从 $\boldsymbol{A}$ 的四列中，我们挑选出线性无关列 $\boldsymbol{a}_1, \boldsymbol{a}_2, \boldsymbol{a}_4$，并以它们为列组成一个矩阵 $\boldsymbol{C}$. 下面等式不难发现：以矩阵 $\boldsymbol{R}$ 的每一列的元素作为组合系数，乘到矩阵 $\boldsymbol{C}$ 的三个列 $\boldsymbol{a}_1, \boldsymbol{a}_2, \boldsymbol{a}_4$ 上，所得的线性组合，正好是 $\boldsymbol{A}$ 对应的列. $\boldsymbol{A}$ 等于 $\boldsymbol{C}$ 乘以 $\boldsymbol{R}$：

$$\boldsymbol{A} = \begin{bmatrix} 2 & 1 & \mathbf{3} & 0 \\ 3 & 4 & \mathbf{7} & 0 \\ 1 & 2 & \mathbf{3} & -1 \end{bmatrix} = \begin{bmatrix} \mathbf{2} & \mathbf{1} & 0 \\ \mathbf{3} & \mathbf{4} & 0 \\ \mathbf{1} & \mathbf{2} & -1 \end{bmatrix} \begin{bmatrix} 1 & 0 & \mathbf{1} & 0 \\ 0 & 1 & \mathbf{1} & 0 \\ 0 & 0 & \mathbf{0} & 1 \end{bmatrix} = \boldsymbol{CR}$$

其中，$\boldsymbol{A}$ 的第 3 列依赖于其第 1 列和第 2 列，而 $\boldsymbol{R}$ 的第 3 列显示了是如何依赖的：将矩阵 $\boldsymbol{C}$ 的线性无关的第 1 列和第 2 列相加，即可得到 $\boldsymbol{A}$ 的第 3 列，即 $\boldsymbol{a}_3 = \boldsymbol{a}_1 + \boldsymbol{a}_2 = \begin{bmatrix} \mathbf{3} \\ \mathbf{7} \\ \mathbf{3} \end{bmatrix}$.

**矩阵乘法的解释：$CR$ 的第 $j$ 列等于 $C$ 乘以 $R$ 的第 $j$ 列.**

本书的第 1.3 节将用两种方式介绍矩阵乘以向量的概念. 然后第 1.4 节将介绍矩阵乘以矩阵的概念. 这是线性代数中关键的操作与运算. 同样重要的是，看待矩阵乘法的方式不止一种.

正常来说，前言的目的是告诉读者整本书的架构和计划. 本书主要分为两部分：前 7 章涵盖了大多数线性代数课程的内容. 第 8~10 章为选学章节，将介绍线性代数在目前比较活跃的学科中的应用，例如：深度学习.

## 0.1 四个基本子空间

如前所述，本课程从矩阵 $\boldsymbol{A}$ 的列向量开始切入. 接下来有两个关键步骤：第一步是取出矩阵列向量的所有线性组合 $c\boldsymbol{a}_1 + d\boldsymbol{a}_2 + e\boldsymbol{a}_3 + f\boldsymbol{a}_4$，从而得到 $\boldsymbol{A}$ 的列空间；第二步是将矩阵分解为 $\boldsymbol{C}$ 乘以 $\boldsymbol{R}$，其中矩阵 $\boldsymbol{C}$ 由 $\boldsymbol{A}$ 的一组完整的线性无关列组成.

这仅仅是本书的前言，读者可能还没有练习过求解矩阵的列空间（对于 $\boldsymbol{C}$ 和 $\boldsymbol{R}$ 的练习可能更少）. 但是它们是本课程正确的“打开方式”. 每个矩阵都有四个基本空间. 与 $\boldsymbol{A}$ 的列空间并列的是行空间——矩阵的行向量的线性组合的全体. 当我们取出矩阵 $n$ 个列的所有线性组合，以及 $m$ 个行的所有线性组合时，这些组合所得向量分别填满了“列空间”与“行空间”.

再加上另外两个子空间，就得到以下的全局示意图. 假设行空间是三维空间中的一个平面，那么在三维图像中有一个特殊的方向，即与行空间（平面）垂直的那个方向. 沿着该方向可画出一条过原点的垂线，这条垂线就是矩阵的零空间. 我们将看到寻找零空间中的向量（垂直于矩阵所有的行），等价于求解 $\boldsymbol{Ax}=\boldsymbol{0}$——本课程中最基本的线性方程组.

如果垂直于矩阵所有行的向量很重要，那么垂直于矩阵所有列的向量没有理由不重要. 图 0.1 是矩阵的四个基本子空间的示意图.

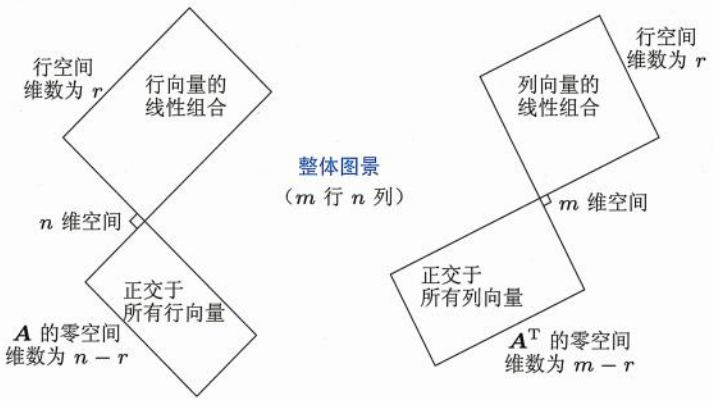


图 0.1 四个基本子空间（关于 $m$ 行 $n$ 列的矩阵，有 $r$ 个线性无关列）

这幅四个子空间的示意图出自第 3 章. 空间正交的概念会出现在第 4 章. 而第 7 章将介绍如何求出四个子空间的一组特殊“基向量”，那将是线性代数基本定理的最终部分. 所谓**线性代数基本定理**给出了一个令人惊叹的结论：对于任何矩阵（无论是方形还是一般矩形），其线性无关的列数总是等于其线性无关的行数.

## 0.2 五种矩阵分解

矩阵分解是线性代数的基本思想之一. 矩阵所具有的特殊属性，总是可以通过乘法分解的方式体现出来. 这一重要思想将会以直接且有用的方式在之后一章又一章地不断呈现.

随着读者学习的深入，从实用性的角度考虑，正交矩阵将越来越重要. 因为正交矩阵的列是相互正交的单位向量，是如此完美！例如：

$$2\text{行}2\text{列正交矩阵}=\begin{bmatrix}\cos\theta & -\sin\theta\\ \sin\theta & \cos\theta\end{bmatrix}：\text{围绕原点逆时针旋转}\,\theta\,\text{角度}$$

以下五种重要的矩阵分解分别来自第 1、2、4、6、7 章：

第 1 章 $\boldsymbol{A}=\boldsymbol{CR}$ $=\boldsymbol{R}$ 通过对 $\boldsymbol{C}$ 中线性无关列的线性组合，重构出 $\boldsymbol{A}$ 的全部列向量

第 2 章 $\boldsymbol{A}=\boldsymbol{LU}$ $=$ 下三角矩阵$\boldsymbol{L}$乘以上三角矩阵$\boldsymbol{U}$

第 4 章 $\boldsymbol{A}=\boldsymbol{QR}$ $=$ 正交矩阵$\boldsymbol{Q}$乘以上三角矩阵$\boldsymbol{R}$

第 6 章 $\boldsymbol{S}=\boldsymbol{Q\Lambda Q}^{\mathrm{T}}$ $=$ (正交矩阵$\boldsymbol{Q}$)(包含特征值的$\boldsymbol{\Lambda}$) (正交矩阵$\boldsymbol{Q}^{\mathrm{T}}$)

第 7 章 $\boldsymbol{A}=\boldsymbol{U\Sigma V}^{\mathrm{T}}$ $=$ (正交矩阵$\boldsymbol{U}$)(包含奇异值的$\boldsymbol{\Sigma}$) (正交矩阵$\boldsymbol{V}^{\mathrm{T}}$)

请读者特别注意最后一种分解——奇异值分解（SVD）. 它适用于任何矩阵 $\boldsymbol{A}$，其因子 $\boldsymbol{U}$ 和 $\boldsymbol{V}$ 的列各自均为相互正交的单位列向量. 并且，乘以 $\boldsymbol{U}$ 或 $\boldsymbol{V}$ 后，向量的长度保持不变——因此该运算不会产生放缩. 而 $\boldsymbol{\Sigma}$ 是一个以“奇异值”（均为正数）为主对角元的矩阵. 对学习了第 6 章特征值和特征向量的读者，请务必继续阅读并学习第 7.1 节的奇异值.

## 0.3 深度学习

要想理解线性代数的真实意义，必须了解其应用. 当然，线性代数并非万能. 原因是现今应用数学的主导方向都要求系统不能完全是线性的！其中典型的代表是“深度学习”. 它是解决“如何从数据中学习（一个基本而重要的科学问题）”的一种极其成功的方法. 在许多情况下，数据以矩阵形式出现. 我们的目标是深入矩阵内部，寻找变量之间的联系. 传统的处理方法是求解矩阵方程或微分方程组，这要求我们知道从输入量到输出量的系统运作规则. 有别于上述传统方法，深度学习成功地构建了一类具有两种输入 $\boldsymbol{x}$ 和 $\boldsymbol{v}$ 的函数 $\boldsymbol{F}(\boldsymbol{x},\boldsymbol{v})$，其中

- 向量 $\boldsymbol{v}$ 描述了训练数据的特征.
- 矩阵 $\boldsymbol{x}$ 为这些特征分配权重.
- 函数 $\boldsymbol{F}(\boldsymbol{x},\boldsymbol{v})$ 逼近于训练数据 $\boldsymbol{v}$ 的正确输出量.
- 当 $\boldsymbol{v}$ 变为测试数据时，$\boldsymbol{F}(\boldsymbol{x},\boldsymbol{v})$ 仍然接近正确的输出.

这一成功部分归结于学习函数 $\boldsymbol{F}$ 的形式. 它会涉及大量数据，于是，仅要求 $\boldsymbol{F}$ 是线性函数将完全不够. 一般，我们首选的 $\boldsymbol{F}$ 是分段线性的，从而达成简洁性和通用性的统一.

## 0.4 本书中的应用和网站上的应用

对于学过线性代数课程的读者，我们希望这本书对您仍然有用. 所以有必要介绍线性代数的更多应用. 我们既可以用矩阵来表示数据，又可以用矩阵的运算来操作数据. 希望读者能通过对矩阵的特征值、特征向量、奇异值和奇异向量等内容的学习与理解从而实现“洞察矩阵”. 此外，每一类应用中都会有相应的特殊矩阵——以下是四个例子：

- 马尔可夫矩阵 $\boldsymbol{M}$：每一列是一组概率，总和为 1.
- 关联矩阵 $\boldsymbol{A}$：对于一组节点相关的图和网络，矩阵 $\boldsymbol{A}$ 描述了节点之间的连接（边）.
- 变换矩阵 $\boldsymbol{F}$：傅里叶矩阵揭示了数据中的频率.
- 协方差矩阵 $\boldsymbol{C}$：方差是关于随机变量的关键信息. 协方差体现了变量之间的依赖关系.

本书的第 6 版包含了上述应用以及其他更多的内容. 对于深度学习中矩阵权重的关键计算，第 9 章介绍了优化的思想. 这是线性代数与微积分的交汇点：对于多变量函数 $F(\boldsymbol{x})$，在其最小值点处偏导数均为零，从而得到相关的矩阵方程.

---

第 5 版中的几个章节在本版中删减了，但并不是它们不重要. 这些章节仅仅是放到网站上了. 链接详见本书数字资源。该网站包括新版的几个章节的样本和所有课后习题的参考解答. 下述第 5 版中的章节（以及更多部分）从书中转存到线上网站中：

- 傅里叶级数
- 范数和条件数

- 迭代方法与预条件子
- 密码学中的线性代数

---

在课程正式开始之前，这里有一些线性代数相关的小问题：

1. 假设纸上有长度分别为 $r$, $s$ 和 $t$ 的三条线段，这些长度需要满足什么条件，才能使其组成一个三角形（在此问题中，三条线的方向可以调整）?

2. 假设三条线段 $\boldsymbol{u}$, $\boldsymbol{v}$, $\boldsymbol{w}$ 的方向是固定且不同的，并且可以将这些线段伸缩为 $a\boldsymbol{u}$, $b\boldsymbol{v}$, $c\boldsymbol{w}$，其中 $a$, $b$, $c$ 可以取任意数. 是否总能用这三个向量 $a\boldsymbol{u}$，$b\boldsymbol{v}$，$c\boldsymbol{w}$ 组成一个封闭的三角形?

3. 线性代数不局限于平面！假设在三维空间中有四条不同方向的线段 $\boldsymbol{u}$, $\boldsymbol{v}$, $\boldsymbol{w}$; $\boldsymbol{z}$，则是否总能选择不为零的数 $a$, $b$, $c$, $d$，使得 $a\boldsymbol{u}+b\boldsymbol{v}+c\boldsymbol{w}+d\boldsymbol{z}=\boldsymbol{0}$ 成立?

---

感谢 Wellesley 出版社的 Ashley C. Fernandes，协助完成了本书的排版、网站的维护，以及向热心读者提供优质教材等工作.

Gilbert Strang

# 目录

CONTENTS


第 1 章 向量和矩阵 …… 1

1.1 向量及其线性组合 …… 2

1.1.1 线性组合 $cv + dw$ …… 3

1.1.2 求解二元方程组 …… 4

1.1.3 消元法会失效吗 …… 4

1.1.4 三维向量的情形 …… 5

1.1.5 如何知道这是一个平面？ …… 6

习题 1.1 …… 6

1.2 点积、长度和角度 …… 9

1.2.1 垂直向量 …… 11

1.2.2 向量之间的夹角 …… 13

1.2.3 三维空间中的平面 …… 15

习题 1.2 …… 16

1.3 矩阵和它们的列空间 …… 19

1.3.1 $\boldsymbol{A}$ 的列空间 …… 22

1.3.2 秩 1 矩阵 …… 24

习题 1.3 …… 25

1.4 矩阵乘法 $\boldsymbol{AB}$ 和 $\boldsymbol{CR}$ …… 28

1.4.1 通常来说 $\boldsymbol{AB} \neq \boldsymbol{BA}$ …… 30

1.4.2 $(\boldsymbol{AB})\boldsymbol{C} = \boldsymbol{A}(\boldsymbol{BC})$ …… 30

1.4.3 回顾矩阵乘法 $\boldsymbol{AB}$ …… 31

1.4.4 秩 1 矩阵和 $\boldsymbol{A} = \boldsymbol{CR}$ …… 31

1.4.5 $\boldsymbol{C}$ 由 $\boldsymbol{A}$ 的前 $r$ 个线性无关的列组成 …… 32

1.4.6 矩阵乘积 $\boldsymbol{CR}$ …… 32

1.4.7 如何找出矩阵 $\boldsymbol{R}$ …… 34

1.4.8 $\boldsymbol{A}$ 的列乘以 $\boldsymbol{B}$ 的行，$\boldsymbol{C}$ 的列乘以 $\boldsymbol{R}$ 的行 …… 35

习题 1.4 …… 37

1.5 谈谈第 1 章 …… 39

第 2 章 解线性方程组 $\boldsymbol{Ax} = \boldsymbol{b}$ …… 41

2.1 消元法和回代 …… 42

2.1.1 回代解法 $Ux=c$ ····· 43
2.1.2 把 $A$ 转化成 $U$，$b$ 转化成 $c$ ····· 44
2.1.3 消元法失效的情况 ····· 44
2.1.4 线性相关或线性无关的列向量 ····· 45
2.1.5 行向量和列向量的图示 ····· 46
2.1.6 消元和置换的例子 ····· 46
习题 2.1 ····· 47
2.2 初等矩阵和逆矩阵 ····· 50
2.2.1 和逆矩阵有关的事实 ····· 51
2.2.2 矩阵乘积 $AB$ 的逆 ····· 53
2.2.3 $L$ 是 $E$ 的逆 ····· 55
习题 2.2 ····· 55
2.3 矩阵运算和 $LU$ 分解 ····· 58
2.3.1 消元法的计算复杂度 ····· 59
2.3.2 证明 $LU$ 分解 ····· 60
2.3.3 伟大的 $A=LU$ 分解 ····· 60
2.3.4 $A=LU$ 的第二种证明：将列乘以行 ····· 61
2.3.5 不包含行对换的消元法 ····· 62
习题 2.3 ····· 62
2.4 置换与转置 ····· 65
2.4.1 置换 ····· 65
2.4.2 置换矩阵的性质 ····· 66
2.4.3 $PA=LU$ 分解：$P$ 导致行交换 ····· 66
2.4.4 选取“部分主元”以减少舍入误差 ····· 67
2.4.5 $PAQ$：$P$ 对 $A$ 做行交换，$Q$ 对 $A$ 做列交换 ····· 67
2.4.6 $A$ 的转置 ····· 68
2.4.7 内积的意义 ····· 69
2.4.8 对称矩阵 ····· 70
2.4.9 对称乘积 $A^{\mathrm{T}}A$、$AA^{\mathrm{T}}$ 和 $LDL^{\mathrm{T}}$ 分解 ····· 71
习题 2.4 ····· 72
2.5 导数和有限差分矩阵 ····· 75
2.5.1 公式的逆向推导：由差值求导数 ····· 76
2.5.2 二阶差分矩阵 $K$、$T$、$B$ ····· 77
2.5.3 矩阵 $K$ 的性质 ····· 78
2.5.4 一端自由一端固定的矩阵 $T_n$ ····· 80
2.5.5 两端自由的矩阵 $B$ 是奇异的 ····· 80
习题 2.5 ····· 81
2.6 谈谈第 2 章 ····· 83

第 3 章 矩阵的四个基本子空间 …… 85
3.1 线性空间及其子空间 …… 86
3.1.1 线性空间的例子 …… 86
3.1.2 线性空间的子空间 …… 87
3.1.3 $\boldsymbol{A}$ 的列空间 …… 88
3.1.4 $\boldsymbol{A}$ 的行空间 …… 89
3.1.5 $\boldsymbol{A}$ 的列向量张成了线性空间 $C(\boldsymbol{A})$ …… 89
习题 3.1 …… 90
3.2 通过消元法 $\boldsymbol{A}=\boldsymbol{CR}$ 计算零空间 …… 93
3.2.1 利用消元法将 $\boldsymbol{A}$ 转化成 $\mathbf{rref}(\boldsymbol{A})$：最简行阶梯形矩阵 …… 95
3.2.2 逐列消元：从 $\boldsymbol{A}$ 到 $\boldsymbol{R}_0$ 的步骤 …… 96
3.2.3 矩阵分解 $\boldsymbol{A}=\boldsymbol{CR}$ 和零空间 …… 97
3.2.4 消元法的终章：分块消元 …… 100
习题 3.2 …… 101
3.3 方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 的解集 …… 105
3.3.1 方程组的特解 $\boldsymbol{x}_p$：$\boldsymbol{Ax}_p=\boldsymbol{b}$ …… 106
3.3.2 行满秩和解集 …… 108
习题 3.3 …… 112
3.4 线性无关性、基、维数 …… 117
3.4.1 线性无关 …… 117
3.4.2 张成子空间的向量组 …… 120
3.4.3 线性空间的基 …… 120
3.4.4 矩阵空间和函数空间的基 …… 124
习题 3.4 …… 126
3.5 四个基本子空间的维数 …… 131
3.5.1 $\boldsymbol{R}_0$ 的四个子空间 …… 132
3.5.2 $\boldsymbol{A}$ 的四个子空间 …… 134
3.5.3 秩 2 矩阵 = 秩 1 矩阵 + 秩 1 矩阵 …… 138
习题 3.5 …… 139
3.6 谈谈第 3 章：消元法的全局理解 …… 142

第 4 章 正交性 …… 145
4.1 向量和子空间的正交性 …… 146
习题 4.1 …… 150
4.2 向直线和子空间作正交投影 …… 153
4.2.1 正交投影到直线 …… 155
4.2.2 正交投影到子空间 …… 157

习题 4.2……162
4.3 最小二乘法……165
4.3.1 误差最小化……166
4.3.2 最小二乘法的全局图景……168
4.3.3 直线拟合……169
4.3.4 当 $\boldsymbol{A}$ 列向量线性相关时求解 $\hat{\boldsymbol{x}}$……171
4.3.5 抛物线拟合……172
习题 4.3……174
4.4 正交矩阵和格拉姆-施密特正交化……178
4.4.1 用单位正交基来作正交投影：用 $\boldsymbol{Q}$ 代替 $\boldsymbol{A}$……181
4.4.2 格拉姆-施密特正交化……182
4.4.3 $\boldsymbol{QR}$ 分解……184
习题 4.4……188
4.5 矩阵的广义逆……192
4.5.1 $m \times n$ 矩阵 $\boldsymbol{A}$ 的广义逆 $\boldsymbol{A}^{+}(n \times m$ 矩阵)……193
4.5.2 $\boldsymbol{A}$ 的重要作用是把行空间映射成列空间……196
4.5.3 $\boldsymbol{A}=\boldsymbol{CR}$ 的广义逆 $\boldsymbol{A}^{+}=\boldsymbol{R}^{+}\boldsymbol{C}^{+}$……196
4.5.4 广义逆的例子——$\boldsymbol{A}$ 是图的关联矩阵……197
习题 4.5……199
4.6 谈谈第 4 章：正交性的巨大成功……199

第 5 章 行列式……201
5.1 三阶方阵的行列式和代数余子式……201
5.1.1 三阶方阵的行列式……202
5.1.2 代数余子式和 $\boldsymbol{A}^{-1}$ 的公式……204
5.1.3 三对角矩阵……205
习题 5.1……206
5.2 行列式的计算和使用……208
5.2.1 证明式 (5.10)～式 (5.13)……209
5.2.2 克莱姆法则解方程组 $\boldsymbol{Ax}=\boldsymbol{b}$……210
5.2.3 行列式的完全展开式：$n!$ 项……211
习题 5.2……212
5.3 行列式与面积和体积……214
习题 5.3……217

第 6 章 特征值和特征向量……219
6.1 初识特征值 $\boldsymbol{Ax}=\lambda\boldsymbol{x}$……219
6.1.1 特征方程：$\det(\boldsymbol{A}-\lambda\boldsymbol{I})=0$……223

6.1.2 行列式和迹 ……225
6.1.3 虚数特征值 ……226
6.1.4 $\boldsymbol{AB}$ 和 $\boldsymbol{A}+\boldsymbol{B}$ 的特征值 ……227
6.1.5 MATLAB 中的 Eigshow 函数 ……230
习题 6.1 ……231
6.2 矩阵的对角化 ……235
6.2.1 相似矩阵：特征值相同 ……239
6.2.2 斐波那契数列 ……241
6.2.3 矩阵方幂 $\boldsymbol{A}^k$ ……242
6.2.4 不可对角化的矩阵（选讲） ……243
习题 6.2 ……246
6.3 对称正定矩阵 ……251
6.3.1 快速证明：正交的特征向量和实特征值 ……251
6.3.2 正定矩阵 ……252
6.3.3 顺序主子式判据和主元判据 ……254
6.3.4 正定矩阵和极小值问题 ……257
6.3.5 半正定矩阵 ……258
6.3.6 椭圆 $ax^2+2bxy+cy^2=1$ ……259
6.3.7 最优化和机器学习 ……260
6.3.8 实对称矩阵都可以正交对角化 ……261
习题 6.3 ……262
6.4 复数、复向量和复矩阵 ……267
6.4.1 复向量：长度 $\|\boldsymbol{v}\|$ 和内积 $\bar{\boldsymbol{v}}^{\mathrm{T}}\boldsymbol{w}$ ……269
6.4.2 复矩阵 $\boldsymbol{A}$ 及其共轭转置 $\bar{\boldsymbol{A}}^{\mathrm{T}}$ ……269
6.4.3 复矩阵 $\boldsymbol{A}$ 的四个基本子空间 ……269
6.4.4 $\bar{\boldsymbol{S}}^{\mathrm{T}}=\boldsymbol{S}$：实特征值和酉正交的特征向量 ……270
6.4.5 置换矩阵 $\boldsymbol{P}$ 的复特征值和特征向量 ……270
6.4.6 所有循环矩阵 $\boldsymbol{C}$ 有相同的傅里叶特征向量 ……272
6.4.7 快速傅里叶变换 ……272
6.4.8 循环矩阵相乘 $\boldsymbol{CD}=\boldsymbol{DC}$ ……273
6.4.9 信号处理中的卷积 ……274
习题 6.4 ……274
6.5 解线性微分方程 ……275
6.5.1 $\mathrm{d}\boldsymbol{u}/\mathrm{d}t=\boldsymbol{Au}$ 的解 ……276
6.5.2 二阶微分方程 ……278
6.5.3 差分方程 ……280
6.5.4 二阶方阵的稳定性 ……282

6.5.5 矩阵的指数函数……282
习题 6.5……286
6.6 用 $QR$ 计算特征值……290
6.7 谈谈微分方程……292

第 7 章 奇异值分解……293
7.1 奇异值和奇异向量……293
7.1.1 奇异值分解的几何意义……294
7.1.2 奇异值分解的完整型……295
7.1.3 奇异值分解的简化型……296
7.1.4 奇异值分解的证明……296
7.1.5 $AB$ 和 $BA$：相同的非零特征值……298
7.1.6 $2\times 2$ 矩阵的奇异向量……299
7.1.7 第一个奇异向量 $v_1$……299
7.1.8 计算特征值和奇异值……300
习题 7.1……301
7.2 通过线性代数来做图像处理……303
7.2.1 对角矩阵的奇异值……304
7.2.2 利用奇异值分解进行图像压缩……305
习题 7.2……306
7.3 主成分分析……307
7.3.1 埃克哈特-扬定理……308
7.3.2 通过奇异值分解进行主成分分析……309
7.3.3 主成分分析背后的几何意义……309
7.3.4 埃克哈特-扬定理的几何意义……310
7.3.5 主成分分析背后的统计学原理……310
7.3.6 主成分分析背后的线性代数……311
习题 7.3……312

第 8 章 线性映射……313
8.1 线性映射的概念……313
8.1.1 直线到直线，三角形到三角形……315
8.1.2 微积分中的线性映射……316
8.1.3 映射的例子（多数是线性的）……317
习题 8.1……319
8.2 线性映射的矩阵……322
8.2.1 基变换：矩阵 $B$……323
8.2.2 构造线性映射 $T$ 的矩阵……324
8.2.3 矩阵乘积 $AB$ 与映射复合 $TS$ 相对应……326

8.2.4 选择最好的基……326
习题 8.2……328
8.3 寻找好的基……331
8.3.1 若尔当标准形……333
8.3.2 函数空间的基……335
8.3.3 函数空间的正交基……336
8.3.4 勒让德多项式和切比雪夫多项式……336
习题 8.3……337

第 9 章 最优化中的线性代数……339
9.1 多变量函数的最小化问题……339
9.1.1 梯度下降 = 最速下降……341
9.1.2 $n=1$ 时一元函数 $f(x)$ 的一阶导数……341
9.1.3 梯度向量 $\nabla F$ 的几何意义……344
9.1.4 一个重要的“之字形”示例……345
9.1.5 动量与重球的路径……346
9.1.6 二次模型……347
习题 9.1……348
9.2 反向传播和随机梯度下降……349
9.2.1 多变量链式法则……350
9.2.2 随机梯度下降……350
9.2.3 普通最小二乘的 SGD……351
9.2.4 反向传播的核心思想……351
9.2.5 Keras 与 TensorFlow 中的反向传播……353
9.2.6 $\boldsymbol{Av}+\boldsymbol{b}$ 的导数……353
9.2.7 隐藏层的偏导数……354
9.2.8 偏导数 $\partial \boldsymbol{w}/\partial \boldsymbol{A}_1$ 的细节……354
习题 9.2……355
9.3 约束条件、拉格朗日乘子与最小范数……356
9.3.1 拉格朗日乘数法——成本函数的偏导数……357
9.3.2 极大值的极小值 = 极小值的极大值……359
9.3.3 二次规划：一般情形……360
9.3.4 不等式约束……361
9.3.5 科学与工程中的对偶问题……362
习题 9.3……363
9.4 线性规划、博弈论和对偶……364
9.4.1 线性规划……364
9.4.2 在线示例……365
9.4.3 最大流-最小割……365

9.4.4 二人博弈……366
9.4.5 半定规划……368
习题 9.4……368

第 10 章 数据学习……370
10.1 分段线性学习函数……371
10.1.1 深度神经网络的构建……373
10.1.2 $F_k$ 是 $\boldsymbol{v}_{k-1}$ 的分段线性函数……373
10.1.3 一个中间层（$L=2$）的情况……374
10.1.4 学习函数 $F(\boldsymbol{v})$ 的图像……375
10.1.5 计算学习函数图像的平坦分块个数：一个中间层的情形……376
10.1.6 计算学习函数图像的平坦分块个数：更多中间层的情形……377
10.1.7 移除……378
习题 10.1……378
10.2 发明和实验……379
10.2.1 泛化与双重下降……380
10.2.2 卷积神经网络：权重共享……381
10.2.3 最大池化……381
10.2.4 深度学习领域的四大重要成就……382
习题 10.2……382
10.3 均值、方差和协方差……383
10.3.1 方差……384
10.3.2 连续概率分布……385
10.3.3 $p(x)$ 的均值和方差……386
10.3.4 正态分布：钟形曲线……387
10.3.5 均值和方差：投掷 $N$ 次硬币，以及 $N \to \infty$ 的渐进行为……388
10.3.6 协方差矩阵和联合概率……390
10.3.7 协方差矩阵 $\boldsymbol{V}$ 的半正定性……392
10.3.8 $\boldsymbol{Z}=\boldsymbol{AX}$ 的协方差矩阵……393
10.3.9 相关性 $\rho$……394
习题 10.3……394
10.4 深度学习的成功引发的思考……395

附录 A……397

# 第 1 章

CHAPTER 1

# 向量和矩阵

向量 $\boldsymbol{v}$ 与矩阵 $\boldsymbol{A}$ 是线性代数讨论的基本对象，对它们可以做加法和减法，并且在合适的情形下还可以做乘法. 如下的二维向量 $\boldsymbol{v}$ 有两个分量 $v_1=2$ 和 $v_2=4$，而 $\boldsymbol{w}$ 也是一个二维向量，于是

$$\boldsymbol{v}=\begin{bmatrix}v_1\\v_2\end{bmatrix}=\begin{bmatrix}2\\4\end{bmatrix}\qquad \boldsymbol{w}=\begin{bmatrix}w_1\\w_2\end{bmatrix}=\begin{bmatrix}1\\3\end{bmatrix}\qquad \boldsymbol{v}+\boldsymbol{w}=\begin{bmatrix}3\\7\end{bmatrix}$$

向量$\boldsymbol{v}$ 与 $\boldsymbol{w}$ 的线性组合是形如 $c\boldsymbol{v}+d\boldsymbol{w}$ 的向量，其中 $c$、$d$ 是两个数，且

$$\text{线性组合 } c\begin{bmatrix}2\\4\end{bmatrix}+d\begin{bmatrix}1\\3\end{bmatrix}=\begin{bmatrix}2c+1d\\4c+3d\end{bmatrix} \text{ 的全体填满了整个 } xy \text{ 平面.}$$

向量 $\boldsymbol{w}$ 的 长度为 $\|\boldsymbol{w}\|=\sqrt{10}$，即 $w_1^2+w_2^2=1+9$ 的平方根. 向量 $\boldsymbol{v}$ 与 $\boldsymbol{w}$ 的点积为

$$\boldsymbol{v}\cdot\boldsymbol{w}=v_1w_1+v_2w_2=(2)(1)+(4)(3)=14.$$

在 1.2 节中，我们还将利用点积 $\boldsymbol{v}\cdot\boldsymbol{w}$ 来研究两个向量之间的夹角.

本章的一个重点是在 1.3 节中介绍的矩阵. 下述的矩阵 $\boldsymbol{A}$ 包含两个列向量，这两个向量各自包含两个分量，由此组成一个 $2\times 2$ 的矩阵：

$$\boldsymbol{A}=\begin{bmatrix}\boldsymbol{v} & \boldsymbol{w}\end{bmatrix}=\begin{bmatrix}2 & 1\\4 & 3\end{bmatrix}.$$

当一个矩阵乘以一个（列）向量时，实际上就是矩阵各列的线性组合 $c\boldsymbol{v}+d\boldsymbol{w}$：

$$\boldsymbol{A}\begin{bmatrix}c\\d\end{bmatrix}=\begin{bmatrix}2 & 1\\4 & 3\end{bmatrix}\begin{bmatrix}c\\d\end{bmatrix}=\begin{bmatrix}2c+1d\\4c+3d\end{bmatrix}=c\boldsymbol{v}+d\boldsymbol{w}.$$

对任意 $c$ 与 $d$ 组成的向量 $\boldsymbol{x}=\begin{bmatrix}c\\d\end{bmatrix}$，我们可将矩阵 $\boldsymbol{A}$ 各列的线性组合表示为 $\boldsymbol{A}\boldsymbol{x}$，这些线性组合的全体称为 矩阵 $\boldsymbol{A}$ 的列空间. 上述矩阵 $\boldsymbol{A}=\begin{bmatrix}2 & 1\\4 & 3\end{bmatrix}$ 的列空间是一个平面.

我们考虑另一个矩阵 $\boldsymbol{B}$，它由三个列向量 $\boldsymbol{v}$、$\boldsymbol{w}$、$\boldsymbol{z}$ 构成，其中 $\boldsymbol{z}$ 是 $\boldsymbol{v}$ 与 $\boldsymbol{w}$ 的线性组合. 于是矩阵 $\boldsymbol{B}$ 的列空间仍然是 $xy$ 平面. 向量 $\boldsymbol{v}$ 与 $\boldsymbol{w}$线性无关，但 $\boldsymbol{v}$、$\boldsymbol{w}$、$\boldsymbol{z}$线性相关. 例如，取

$\boldsymbol{B}=\begin{bmatrix}\boldsymbol{v} & \boldsymbol{w} & \boldsymbol{z}\end{bmatrix}=\begin{bmatrix}2 & 1 & 3\\ 4 & 3 & 7\end{bmatrix}$，则下述线性组合可以产生零向量：

$$\boldsymbol{B}\begin{bmatrix}1\\ 1\\ -1\end{bmatrix}=\boldsymbol{v}+\boldsymbol{w}-\boldsymbol{z}=\begin{bmatrix}2\\ 4\end{bmatrix}+\begin{bmatrix}1\\ 3\end{bmatrix}-\begin{bmatrix}3\\ 7\end{bmatrix}=\begin{bmatrix}0\\ 0\end{bmatrix}.$$

我们最终的目标是希望读者理解： **乘积矩阵 $\boldsymbol{AB}=\boldsymbol{A}$ 乘以 $\boldsymbol{B}$ 的每一列.**

## 1.1 向量及其线性组合

（1）$2\boldsymbol{v}-3\boldsymbol{w}$ 是 $\boldsymbol{v}$、$\boldsymbol{w}$ 的线性组合；对一般的 $c$、$d$，有线性组合 $c\boldsymbol{v}+d\boldsymbol{w}$.

（2）若 $\boldsymbol{v}=\begin{bmatrix}4\\ 1\end{bmatrix},\boldsymbol{w}=\begin{bmatrix}2\\ -1\end{bmatrix}$，那么

$$2\boldsymbol{v}-3\boldsymbol{w}=2\begin{bmatrix}4\\ 1\end{bmatrix}-3\begin{bmatrix}2\\ -1\end{bmatrix}=\begin{bmatrix}2\\ 5\end{bmatrix}.$$

（3）当 $c$、$d$ 取遍所有实数时，线性组合 $c\begin{bmatrix}4\\ 1\end{bmatrix}+d\begin{bmatrix}2\\ -1\end{bmatrix}$ 可以填满整个 $xy$ 平面，它可以取到每个向量 $\begin{bmatrix}x\\ y\end{bmatrix}$.

（4）当 $c$、$d$ 取遍所有实数时，线性组合 $c\begin{bmatrix}1\\ 1\\ 2\end{bmatrix}+d\begin{bmatrix}0\\ 0\\ 4\end{bmatrix}$ 可以填满 $xyz$ 空间中的一个平面，但 $\begin{bmatrix}1\\ 2\\ 3\end{bmatrix}$ 不在这个平面上.

微积分最初讨论的是变量 $x$ 与函数 $f(x)$. 而线性代数最初讨论向量 $\boldsymbol{v}$、$\boldsymbol{w}$ 及其线性组合 $c\boldsymbol{v}+d\boldsymbol{w}$. 不论是二维还是更高维的情形，向量 $\boldsymbol{v}$ 与 $\boldsymbol{w}$ 的线性组合仅由以下两种基本运算构成.

- 用一个数乘以向量 $\boldsymbol{v}$（称为**数乘**），如：$3\boldsymbol{v}=3\begin{bmatrix}2\\ 1\end{bmatrix}=\begin{bmatrix}6\\ 3\end{bmatrix}$；
- 对相同维数的向量 $\boldsymbol{v}$ 与 $\boldsymbol{w}$ 作**加法**，如：$\boldsymbol{v}+\boldsymbol{w}=\begin{bmatrix}2\\ 1\end{bmatrix}+\begin{bmatrix}4\\ 3\end{bmatrix}=\begin{bmatrix}6\\ 4\end{bmatrix}$.

上述两种运算合起来就可得到向量 $\boldsymbol{v}$ 与 $\boldsymbol{w}$ 的**线性组合**，如：取组合系数 $c=5$，$d=-2$，有

$$5\boldsymbol{v}-2\boldsymbol{w}=5\begin{bmatrix}2\\1\end{bmatrix}-2\begin{bmatrix}4\\3\end{bmatrix}=\begin{bmatrix}10\\5\end{bmatrix}-\begin{bmatrix}8\\6\end{bmatrix}=\begin{bmatrix}2\\-1\end{bmatrix}.$$

关于向量的线性组合，有以下两个关键的问题.

（1）描述 $\boldsymbol{v}$ 与 $\boldsymbol{w}$ 的全体线性组合 $c\boldsymbol{v}+d\boldsymbol{w}$，它们填满一个平面还是一条直线？

（2）寻找数 $c$ 与 $d$，使得以之为系数的线性组合得到一个指定的向量，如：$c\boldsymbol{v}+d\boldsymbol{w}=\begin{bmatrix}2\\0\end{bmatrix}$.

在本节我们能回答上述两个问题. 但线性代数所讨论的不仅仅限于二维空间中的两个向量. 只要我们保持线性（加法与数乘），上述问题同样适用于更高维与更多个向量的情形. 向量的分量可以从两个变为 $m$ 个，向量的数量也可从 2 变成 $n$，即 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_n$，$m$ 维空间中的这 $n$ 个向量将组成一个 $m\times n$ 矩阵 $\boldsymbol{A}$：

$m$行
$n$列　　$\boldsymbol{A}=\begin{bmatrix}\boldsymbol{v}_1 & \boldsymbol{v}_2 & \cdots & \boldsymbol{v}_n\end{bmatrix}$
$m\times n$矩阵

我们先用矩阵的语言重述上面两个核心问题：

> 描述 $\boldsymbol{A}$ 的列向量的所有线性组合 $\boldsymbol{Ax}=x_1\boldsymbol{v}_1+\cdots+x_n\boldsymbol{v}_n$
> 对给定的 $\boldsymbol{b}$ 找出满足 $\boldsymbol{Ax}=\boldsymbol{b}$ 的所有 $x_1,x_2,\cdots,x_n$

然后重新审视 $m=2$ 与 $n=2$ 的情形.

### 1.1.1　线性组合 $c\boldsymbol{v}+d\boldsymbol{w}$

二维空间中的向量 $\boldsymbol{v}$ 有两个分量，几何上用从原点出发的箭头（有向线段）来表示它，如图 1.1 所示.

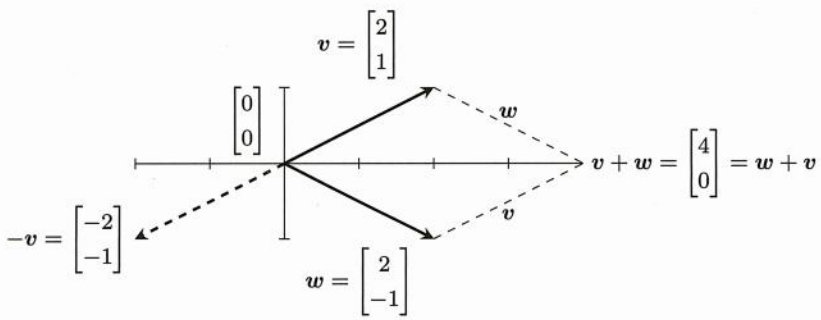


图 1.1　二维空间的向量及其加法

对所有数 $c$，向量 $c\boldsymbol{v}$ 构成 $xy$ 平面中一条无限延长的直线. 若 $\boldsymbol{w}$ 不在上述直线上，则向量 $d\boldsymbol{w}$ 将生成第二条直线. 将上述 $\boldsymbol{v}$ 线与 $\boldsymbol{w}$ 线上所有点组合起来有线性组合 $c\boldsymbol{v}+d\boldsymbol{w}$，可生成整个平面.

在线性组合 $c\boldsymbol{v}+d\boldsymbol{w}$ 中，可取任意的系数 $c$ 与 $d$，下面列出四种特殊的线性组合：

$$\begin{aligned} 1\boldsymbol{v}+1\boldsymbol{w} &= \text{向量之和；}\\ 1\boldsymbol{v}-1\boldsymbol{w} &= \text{向量之差；}\\ 0\boldsymbol{v}+0\boldsymbol{w} &= \text{零向量；}\\ c\boldsymbol{v}+0\boldsymbol{w} &= \text{与 } \boldsymbol{v} \text{ 共线的向量.} \end{aligned}$$

### 1.1.2 求解二元方程组

线性代数通常从几何画图或代数计算开始引入. 几何方面，我们从如何画出 $\boldsymbol{v}+\boldsymbol{w}$ 与 $\boldsymbol{w}+\boldsymbol{v}$ 开始，并说明它们是相等的；另一个重点是画出 $\boldsymbol{v}-\boldsymbol{w}$，从 $\boldsymbol{w}$ 点指向 $\boldsymbol{v}$ 点的向量. 在前言部分，我们还画出了更多线性组合，从而生成了一个平面. 但是，如果要用线性组合的方式表示一个指定的特殊向量，如 $c\boldsymbol{v}+d\boldsymbol{w}=\begin{bmatrix}8\\2\end{bmatrix}$，则用代数计算来求出系数 $c$ 与 $d$ 是更好的方法. 下面用两种方式来描述该问题.

$$\text{解}\quad c\begin{bmatrix}2\\1\end{bmatrix}+d\begin{bmatrix}2\\-1\end{bmatrix}=\begin{bmatrix}8\\2\end{bmatrix}\qquad \text{此即}\quad \begin{cases}2c+2d=8\\ c-d=2\end{cases}$$

求解方法是简单而严谨的：可以对某个方程乘以非零倍数，也可以用一个方程减去另一个方程. 根据经验，求解的关键在于让方程组的左边产生尽量多的零. 对上述具体方程组，一个零就足够了！

$$\begin{cases}2c+2d=8\cdots①\\ c-d=2\cdots②\end{cases}\xrightarrow{\text{方程①}\times 1/2}\begin{cases}c+d=4\cdots③\\ c-d=2\cdots④\end{cases}\xrightarrow{\text{方程④}-\text{方程③}}\begin{cases}c+d=4\\ 0c-2d=-2\end{cases}$$

由第二个方程解得 $d=1$，代回第一个方程解得 $c=3$. 从而

$$3\begin{bmatrix}2\\1\end{bmatrix}+1\begin{bmatrix}2\\-1\end{bmatrix}=\begin{bmatrix}8\\2\end{bmatrix},\quad \text{化成矩阵形式}\quad \begin{bmatrix}2&2\\1&-1\end{bmatrix}\begin{bmatrix}3\\1\end{bmatrix}=\begin{bmatrix}8\\2\end{bmatrix}.$$

若点 $\boldsymbol{v}$、点 $\boldsymbol{w}$ 与原点 $\mathbf{0}$ 三点不共线，则方程组有唯一的一组解 $c, d$，并且向量 $\boldsymbol{v}$ 与 $\boldsymbol{w}$ 的全体线性组合恰为 $xy$ 平面，此时向量 $\boldsymbol{v}$ 与 $\boldsymbol{w}$ 是“线性无关”的，对应的 $2\times 2$ 矩阵 $\boldsymbol{A}=\begin{bmatrix}\boldsymbol{v} & \boldsymbol{w}\end{bmatrix}$ 是“可逆矩阵”.

### 1.1.3 消元法会失效吗

当方程组无解时消元法求解的过程就会失效. 失效的情况会在向量$\boldsymbol{v}$ 与 $\boldsymbol{w}$ 位于同一条过原点的直线时发生. 此时两个向量不是线性无关的.

原因也很明显：此时，$\boldsymbol{v}$ 与 $\boldsymbol{w}$ 的所有线性组合均落在同一条直线上，若目标向量 $\boldsymbol{b}$ 落在该直线外，则方程 $c\boldsymbol{v}+d\boldsymbol{w}=\boldsymbol{b}$ 就无解了.

**例 1.1**

$$\boldsymbol{v}=\begin{bmatrix}1\\2\end{bmatrix}\quad \boldsymbol{w}=\begin{bmatrix}3\\6\end{bmatrix}\quad \boldsymbol{b}=\begin{bmatrix}1\\0\end{bmatrix}\quad \text{考虑}\quad \begin{cases}1c+3d=1\\ 2c+6d=0.\end{cases}$$

以下先说明这两个方程无公共解. 为使用消元法消去第二个方程中的系数 2，先将第一个方程乘以 2，得到 $2c+6d=2$. 用第二个方程 $2c+6d=0$ 减去上式，结果为 $\mathbf{0=-2}$，这是不可能的. 在此过程中，我们消去 $c$ 的同时，$d$ 也被消去了.

由于 $\boldsymbol{v}$ 与 $\boldsymbol{w}$ 共线，它们的线性组合的全体构成一条直线而非平面. 当 $\boldsymbol{b}$ 不落在该直线上时，不存在 $\boldsymbol{v}$ 与 $\boldsymbol{w}$ 的线性组合等于 $\boldsymbol{b}$. 因为 $\boldsymbol{w}=3\boldsymbol{v}$，初始向量 $\boldsymbol{v}$ 与 $\boldsymbol{w}$ “**线性相关**”.

相反，两个线性无关的二维向量 $\boldsymbol{v}$ 与 $\boldsymbol{w}$ 能生成平面中的任意向量 $\boldsymbol{b}$. 于是对应的方程组必有解：

$$\begin{array}{l}\text{2个方程}\\ \text{2个未知数}\end{array} \qquad c\boldsymbol{v}+d\boldsymbol{w}=\boldsymbol{b} \qquad \begin{cases} cv_1+dw_1 = b_1 \\ cv_2+dw_2 = b_2 \end{cases}$$

小结：若 $\boldsymbol{v}$ 与 $\boldsymbol{w}$ 不共线，则线性组合 $c\boldsymbol{v}+d\boldsymbol{w}$ 可填满整个 $xy$ 平面.

**重点**：这里举另一个例子，其中的消元法似乎遇到了麻烦，但我们能轻易解决，从而让求解过程继续. 考虑方程组

$$c\begin{bmatrix}0\\1\end{bmatrix}+d\begin{bmatrix}2\\3\end{bmatrix}=\begin{bmatrix}2\\7\end{bmatrix} \quad \text{或} \quad \begin{cases} 0+2d=2 \\ c+3d=7 \end{cases}$$

上式中的 0 看上去有点麻烦，但我们可以 **对换两个方程**，从而先求出 $d$，再求出 $c$：

$$\begin{cases} c+3d=7 \\ 0+2d=2 \end{cases} \quad \text{可解得} \quad d=1, c=4$$

### 1.1.4 三维向量的情形

假设 $\boldsymbol{v}$ 与 $\boldsymbol{w}$ 的分量都从两个变成三个，从而成为三维空间（也将记作 $\mathbb{R}^3$）中的向量. 我们同样可将它们看作从原点指向空间中对应点的箭头（有向线段），类似地可得 $\boldsymbol{v}$ 与 $\boldsymbol{w}$ 的线性组合，如：

$$\boldsymbol{v}=\begin{bmatrix}2\\3\\1\end{bmatrix}, \quad \boldsymbol{w}=\begin{bmatrix}1\\1\\0\end{bmatrix}, \quad \boldsymbol{v}+\boldsymbol{w}=\begin{bmatrix}3\\4\\1\end{bmatrix}, \quad c\boldsymbol{v}+d\boldsymbol{w}=\begin{bmatrix}2c+d\\3c+d\\c+0\end{bmatrix}.$$

但也有不同之处！$\boldsymbol{v}$ 与 $\boldsymbol{w}$ 的线性组合不能生成整个三维空间. 如果只有两个向量，它们的线性组合最多只能生成一个二维平面. 这并非由线性相关造成，仅仅是因为没有足够的向量.

若想生成三维空间，需要 3 个线性无关的向量. 下述 $\boldsymbol{i}$、$\boldsymbol{j}$、$\boldsymbol{k}$ 是最简单的线性无关的 3 个三维向量：

$$\boldsymbol{i}=\begin{bmatrix}1\\0\\0\end{bmatrix}, \quad \boldsymbol{j}=\begin{bmatrix}0\\1\\0\end{bmatrix}, \quad \boldsymbol{k}=\begin{bmatrix}0\\0\\1\end{bmatrix}, \quad c\boldsymbol{i}+d\boldsymbol{j}+e\boldsymbol{k}=\begin{bmatrix}c\\d\\e\end{bmatrix} \tag{1.1}$$

这里 $\boldsymbol{i}$、$\boldsymbol{j}$、$\boldsymbol{k}$ 分别是与三维空间 $\mathbb{R}^3$ 中的 $x$ 轴、$y$ 轴、$z$ 轴同向的向量. 我们很容易就能将 $\mathbb{R}^3$ 中任意向量写成 $\boldsymbol{i}$、$\boldsymbol{j}$、$\boldsymbol{k}$ 的线性组合：

$$\text{向量形式}\quad \boldsymbol{v}=\begin{bmatrix}v_1\\v_2\\v_3\end{bmatrix}=v_1\boldsymbol{i}+v_2\boldsymbol{j}+v_3\boldsymbol{k}$$

$$\text{矩阵形式}\quad \begin{bmatrix}1&0&0\\0&1&0\\0&0&1\end{bmatrix}\begin{bmatrix}v_1\\v_2\\v_3\end{bmatrix}=\begin{bmatrix}v_1\\v_2\\v_3\end{bmatrix}$$

上式中主对角元均为 1 的对角矩阵是 $3\times 3$单位矩阵 $\boldsymbol{I}$. 任何向量左乘单位矩阵 $\boldsymbol{I}$ 均保持不变，即 $\boldsymbol{Iv}=\boldsymbol{v}$ 对所有 $\boldsymbol{v}$ 成立.

注意：不能把一个二维向量 $\boldsymbol{v}$ 与一个三维向量 $\boldsymbol{w}$ 做线性组合，它们不在同一空间中.

### 1.1.5 如何知道这是一个平面?

假设 $\boldsymbol{v}$ 与 $\boldsymbol{w}$ 是线性无关的三维非零向量，则它们是不同方向的向量：$\boldsymbol{w}$ 不能表示为 $c\boldsymbol{v}$ 的形式. 因此，它们的线性组合生成了三维空间中的一个平面. 下面尝试说明该集合的几何形态是平坦的.

考虑任意两个线性组合 $c\boldsymbol{v}+d\boldsymbol{w}$ 与 $C\boldsymbol{v}+D\boldsymbol{w}$，它们连线的中点为 $\boldsymbol{h}=\frac{1}{2}(c+C)\boldsymbol{v}+\frac{1}{2}(d+D)\boldsymbol{w}$，也是 $\boldsymbol{v}$ 与 $\boldsymbol{w}$ 的线性组合. 因此该集合有一个与平面相同的性质：集合中任意两点连线的中点仍属于该集合. 于是，全体线性组合构成的集合是平坦的.

上述理由似乎不太充分，仅依靠一个与平面相同性质的直觉就得到了结论，这甚至有点让人震惊. 我们将在 1.2节给出另一个证明.

## 习题 1.1

1. $a$、$b$、$c$、$d$ 满足何种条件时，向量 $\begin{bmatrix}c\\d\end{bmatrix}$ 是 $\begin{bmatrix}a\\b\end{bmatrix}$ 的 $m$ 倍？我们从方程 $c=ma, d=mb$ 出发，把 $m$ 消去，就可以得到仅和 $a$、$b$、$c$、$d$ 有关的方程. 可以假设这些数均非零.

2. 如何用向量 $\boldsymbol{u}$、$\boldsymbol{v}$、$\boldsymbol{w}$ 表示从 $(0,0)$ 到 $(5,0)$ 再到 $(0,12)$，最终回到 $(0,0)$ 的三角形？$\boldsymbol{u}+\boldsymbol{v}+\boldsymbol{w}$ 等于什么？$\boldsymbol{u}$、$\boldsymbol{v}$、$\boldsymbol{w}$ 的长度分别是多少？提示：向量 $\boldsymbol{u}=\begin{bmatrix}u_1&u_2\end{bmatrix}^{\mathrm{T}}$ 的长度的平方是 $\|\boldsymbol{u}\|^2=u_1^2+u_2^2$.

**习题 3~10 是关于向量的加法和线性组合的问题.**

3. 从几何上（用 $\mathbb{R}^3$ 中的直线、平面或整个 $\mathbb{R}^3$）描述下列各组向量的线性组合的全体：

(a) $\begin{bmatrix}1\\2\\3\end{bmatrix}$ 和 $\begin{bmatrix}3\\6\\9\end{bmatrix}$　　(b) $\begin{bmatrix}1\\0\\0\end{bmatrix}$ 和 $\begin{bmatrix}0\\2\\3\end{bmatrix}$　　(c) $\begin{bmatrix}2\\0\\0\end{bmatrix}$ 和 $\begin{bmatrix}0\\2\\2\end{bmatrix}$ 和 $\begin{bmatrix}2\\2\\3\end{bmatrix}$

4. 在同一个 $xy$ 坐标平面内，画出 $\boldsymbol{v}=\begin{bmatrix}4\\1\end{bmatrix}$，$\boldsymbol{w}=\begin{bmatrix}-2\\2\end{bmatrix}$，$\boldsymbol{v}+\boldsymbol{w}$，以及 $\boldsymbol{v}-\boldsymbol{w}$.

5. 已知 $\boldsymbol{v}+\boldsymbol{w}=\begin{bmatrix}5\\1\end{bmatrix}$ 和 $\boldsymbol{v}-\boldsymbol{w}=\begin{bmatrix}1\\5\end{bmatrix}$，求向量 $\boldsymbol{v}$、$\boldsymbol{w}$，并在图上把它们画出来.

6. 已知 $\boldsymbol{v}=\begin{bmatrix}2\\1\end{bmatrix}, \boldsymbol{w}=\begin{bmatrix}1\\2\end{bmatrix}$，求 $3\boldsymbol{v}+\boldsymbol{w}$ 和 $c\boldsymbol{v}+d\boldsymbol{w}$.

7. 已知 $\boldsymbol{u}=\begin{bmatrix}1\\2\\3\end{bmatrix}$，$\boldsymbol{v}=\begin{bmatrix}-3\\1\\-2\end{bmatrix}$，$\boldsymbol{u}=\begin{bmatrix}2\\-3\\-1\end{bmatrix}$，计算 $\boldsymbol{u}+\boldsymbol{v}+\boldsymbol{w}$ 和 $2\boldsymbol{u}+2\boldsymbol{v}+\boldsymbol{w}$. 判断：$\boldsymbol{u}$、$\boldsymbol{v}$、$\boldsymbol{w}$ 是否共面？

提示：这 3 个向量共面，事实上可以找到 $c$、$d$ 使得 $\boldsymbol{w}=c\boldsymbol{u}+d\boldsymbol{v}$.

8. 向量 $\boldsymbol{v}=\begin{bmatrix}1 & -2 & 1\end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{w}=\begin{bmatrix}0 & 1 & -1\end{bmatrix}^{\mathrm{T}}$ 的任意线性组合的分量之和是_____. 求出满足 $c\boldsymbol{v}+d\boldsymbol{w}=\begin{bmatrix}3 & 3 & -6\end{bmatrix}^{\mathrm{T}}$ 的 $c$、$d$；思考一下：如果把 $\begin{bmatrix}3 & 3 & -6\end{bmatrix}^{\mathrm{T}}$ 换成 $\begin{bmatrix}3 & 3 & 6\end{bmatrix}^{\mathrm{T}}$，还能找到 $c$、$d$ 满足 $c\boldsymbol{v}+d\boldsymbol{w}=\begin{bmatrix}3 & 3 & 6\end{bmatrix}^{\mathrm{T}}$ 吗？为什么？

9. 在 $xy$ 平面上，标出这 9 个线性组合：$\left\{c\begin{bmatrix}2\\1\end{bmatrix}+d\begin{bmatrix}0\\1\end{bmatrix} : c,d\in\{0,1,2\}\right\}$.

10. (难)$a$、$b$、$c$ 满足什么条件时 $\boldsymbol{u}=\begin{bmatrix}1 & 1 & 0\end{bmatrix}^{\mathrm{T}}$、$\boldsymbol{v}=\begin{bmatrix}0 & 1 & 1\end{bmatrix}^{\mathrm{T}}$、$\boldsymbol{w}=\begin{bmatrix}a & b & c\end{bmatrix}^{\mathrm{T}}$ 线性相关？什么条件下它们线性无关？

11. 如果一个平行四边形有 3 个顶点是 $\begin{bmatrix}1 & 1\end{bmatrix}^{\mathrm{T}}$、$\begin{bmatrix}4 & 2\end{bmatrix}^{\mathrm{T}}$、$\begin{bmatrix}1 & 3\end{bmatrix}^{\mathrm{T}}$，那么第 4 个顶点坐标是什么？注意，有 3 种可能；请画出这 3 个平行四边形.

**习题 12~15 是关于图 1.2 中立方体或者钟表盘中的特殊向量的问题.**

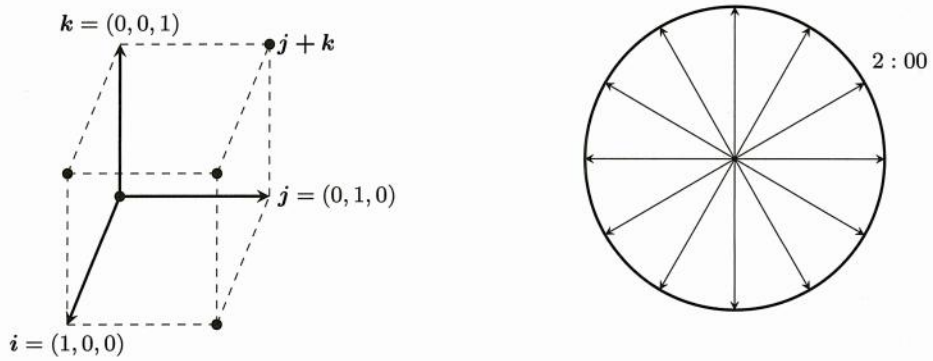


(a) 由 $\boldsymbol{i}$、$\boldsymbol{j}$、$\boldsymbol{k}$ 构成的单位立方体　　(b) 钟表盘的十二个单位向量

图 1.2　习题 12~15 的示意图

12. 这个立方体的四个顶点是 $(0,0,0)$、$(1,0,0)$、$(0,1,0)$、$(0,0,1)$. 其他四个顶点坐标是什么？找出这个立方体的中心点的坐标. 该立方体 6 个面的中心点的坐标是_____. 这个立方体有

几条边？

13. 在 $xyz$-坐标空间中，由 $\boldsymbol{i}=\begin{bmatrix}1 & 0 & 0\end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{i}+\boldsymbol{j}=\begin{bmatrix}1 & 1 & 0\end{bmatrix}^{\mathrm{T}}$ 的所有线性组合构成的平面是哪个？请在图中画出来.

14.（a）从圆的中心点指向 1:00，2:00，$\cdots$，12:00 的 12 个单位向量的和 $\boldsymbol{V}$ 是多少？

（b）如果我们把指向 2:00 的向量移除，解释为何剩下的 11 个向量的和是指向 8:00 的单位向量.

（c）指向 2:00 的单位向量是 $\boldsymbol{v}=\begin{bmatrix}\cos\theta & \sin\theta\end{bmatrix}^{\mathrm{T}}$，求出 $\theta$.

15. 假设 12 个单位向量起点从中心点处的原点改为钟表底部的 6:00，终点依然是表盘上的 12 个整时刻点；例如，指向 12:00 的向量是原先的两倍，其坐标表示为 $\begin{bmatrix}0 & 2\end{bmatrix}^{\mathrm{T}}$. 那么新的 12 个向量的和是_____.

16. 请举出 3 个向量 $\boldsymbol{u}$、$\boldsymbol{v}$、$\boldsymbol{w}$，使得它们的线性组合 $c\boldsymbol{u}+d\boldsymbol{v}+e\boldsymbol{w}$ 仅充满一条直线. 再在 $\mathbb{R}^3$ 中举出 3 个向量 $\boldsymbol{u}$、$\boldsymbol{v}$、$\boldsymbol{w}$，使得它们的线性组合 $c\boldsymbol{u}+d\boldsymbol{v}+e\boldsymbol{w}$ 仅充满一个平面.

17. 求出合适的 $c$、$d$ 使得线性组合 $c\begin{bmatrix}1\\2\end{bmatrix}+d\begin{bmatrix}3\\1\end{bmatrix}=\begin{bmatrix}14\\8\end{bmatrix}$. 我们把这个问题转化为关于线性组合的系数 $c$、$d$ 的两个方程.

**习题 18~19 进一步探讨了 $v, w$ 的线性组合.**

18. 图 1.3(a) 中表示了 $\frac{1}{2}\boldsymbol{v}+\frac{1}{2}\boldsymbol{w}$. 请在图 1.3(a) 中标出 $\frac{3}{4}\boldsymbol{v}+\frac{1}{4}\boldsymbol{w}$、$\frac{1}{4}\boldsymbol{v}+\frac{1}{4}\boldsymbol{w}$ 和 $\boldsymbol{v}+\boldsymbol{w}$. 画出集合 $\{c\boldsymbol{v}+d\boldsymbol{w}:c+d=1\}$; 这是一条直线.

19. 接着上一题，把 $c$、$d$ 限制到 $[0,1]$，画出集合 $\{c\boldsymbol{v}+d\boldsymbol{w}:0\leqslant c,d\leqslant 1\}$. 如果只限定 $c$、$d\geqslant 0$，那么 $\{c\boldsymbol{v}+d\boldsymbol{w}:c,d\geqslant 0\}$ 是一个“锥形”.

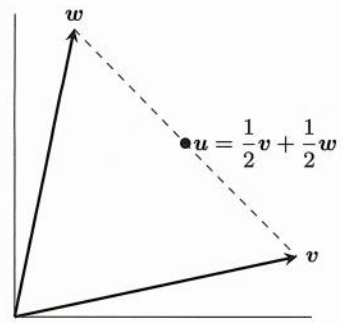


(a) 习题 18 ~ 19，平面上的向量

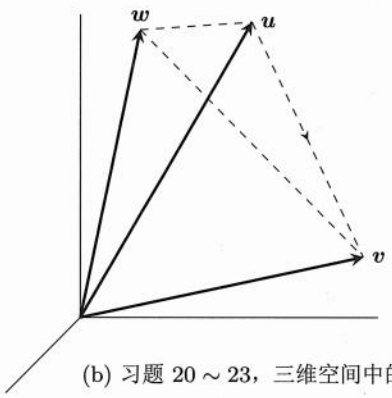


(b) 习题 20 ~ 23，三维空间中的向量

图 1.3 向量的线性组合

**习题 20~23 探讨三维空间中 $u, v, w$ 的线性组合**

20. 在图 1.3(b) 中标出 $\frac{1}{2}\boldsymbol{u}+\frac{1}{3}\boldsymbol{v}+\frac{1}{3}\boldsymbol{w}$ 和 $\frac{1}{2}\boldsymbol{u}+\frac{1}{2}\boldsymbol{w}$. 对 $c$、$d$、$e$ 加以何种条件，能使 $c\boldsymbol{u}+d\boldsymbol{v}+e\boldsymbol{w}$ 填满图 1.3 中虚线三角形. 首先需要注意到，$c$、$d$、$e$ 必须大于或等于 0.

21. 图 1.3 中虚线三角形由 $\boldsymbol{v}-\boldsymbol{u}$、$\boldsymbol{w}-\boldsymbol{v}$ 和 $\boldsymbol{u}-\boldsymbol{w}$ 给定；这三个向量的和是_____. 在平面内，用三角形首尾相连求向量之和的方法，求出 $\begin{bmatrix}3 & 1\end{bmatrix}^{\mathrm{T}}+\begin{bmatrix}-1 & 1\end{bmatrix}^{\mathrm{T}}+\begin{bmatrix}-2 & -2\end{bmatrix}^{\mathrm{T}}$.

22. 画出锥体：$\{c\boldsymbol{u}+d\boldsymbol{v}+e\boldsymbol{w}:c,d,e\geqslant 0,c+d+e\leqslant 1\}$；标出 $\frac{1}{2}(\boldsymbol{u}+\boldsymbol{v}+\boldsymbol{w})$ 相对于这个锥体的大致位置，它在锥体内部还是外部？

23. 如果考虑 $\boldsymbol{u}$、$\boldsymbol{v}$、$\boldsymbol{w}$ 的所有线性组合，是否存在不能表示成 $c\boldsymbol{u}+d\boldsymbol{v}+e\boldsymbol{w}$ 形式的向量？当 $\boldsymbol{u}$、$\boldsymbol{v}$、$\boldsymbol{w}$ 处于_____ 时，对该问题的回答发生改变.

## 挑 战 一 下

24. 四维空间中，以 $\left(\pm 1,\pm 1,\pm 1,\pm 1\right)$ 为顶点、边长为 2 的立方体有多少个顶点？体积是多少？有几个三维的面？多少条棱？找出一条棱.

25. 设 $\boldsymbol{u}=\begin{bmatrix}1 & 3\end{bmatrix}^{\mathrm{T}}$，$\boldsymbol{v}=\begin{bmatrix}2 & 7\end{bmatrix}^{\mathrm{T}}$，$\boldsymbol{w}=\begin{bmatrix}1 & 5\end{bmatrix}^{\mathrm{T}}$，用两种不同的线性组合来表达出 $\boldsymbol{b}=\begin{bmatrix}0 & 1\end{bmatrix}^{\mathrm{T}}$. 若我们在平面上任选 3 个向量 $\boldsymbol{u}$、$\boldsymbol{v}$、$\boldsymbol{w}$，是否始终存在两种不同的线性组合来表达 $\boldsymbol{b}=\begin{bmatrix}0 & 1\end{bmatrix}^{\mathrm{T}}$?

26. 向量 $\boldsymbol{v}=\begin{bmatrix}a & b\end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{w}=\begin{bmatrix}c & d\end{bmatrix}^{\mathrm{T}}$ 的所有线性组合能生成整个平面，除非_____. 在 $\mathbb{R}^4$ 中找出 4 个向量 $\boldsymbol{u}$、$\boldsymbol{v}$、$\boldsymbol{w}$、$\boldsymbol{z}$，它们的 4 个分量均不等于零，而且它们的线性组合可以生成整个 $\mathbb{R}^4$.

27. 已知 $\boldsymbol{u}=\begin{bmatrix}2\\-1\\0\end{bmatrix}$，$\boldsymbol{v}=\begin{bmatrix}-1\\2\\-1\end{bmatrix}$，$\boldsymbol{w}=\begin{bmatrix}0\\-1\\2\end{bmatrix}$，$\boldsymbol{b}=\begin{bmatrix}1\\0\\0\end{bmatrix}$. 将线性组合的等式 $c\boldsymbol{u}+d\boldsymbol{v}+e\boldsymbol{w}=\boldsymbol{b}$ 转化成关于 $c$、$d$、$e$ 的 3 个方程. 也可以把它写成矩阵方程 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 的形式. 对此处的 $\boldsymbol{b}$，你能找出 $c$、$d$、$e$ 吗?

## 1.2　点积、长度和角度

（1）$\boldsymbol{v}=\begin{bmatrix}1\\2\end{bmatrix}$ 和 $\boldsymbol{w}=\begin{bmatrix}4\\6\end{bmatrix}$ 的点积是

$$\boldsymbol{v}\cdot\boldsymbol{w}=(1)(4)+(2)(6)=4+12=16.$$

（2）$\boldsymbol{v}=\begin{bmatrix}1 & 3 & 2\end{bmatrix}^{\mathrm{T}}$ 的长度的平方是

$$\|\boldsymbol{v}\|^2=\boldsymbol{v}\cdot\boldsymbol{v}=1+9+4=14.$$

它的 长度是 $\|\boldsymbol{v}\|=\sqrt{14}$.

（3）$\boldsymbol{v}=\begin{bmatrix}1 & 3 & 2\end{bmatrix}^{\mathrm{T}}$ 与 $\boldsymbol{w}=\begin{bmatrix}4 & -4 & 4\end{bmatrix}^{\mathrm{T}}$ 垂直，这是因为 $\boldsymbol{v}\cdot\boldsymbol{w}=0$.

（4）$\boldsymbol{v}=\begin{bmatrix}1\\0\end{bmatrix}$ 和 $\boldsymbol{w}=\begin{bmatrix}1\\1\end{bmatrix}$ 之间的夹角为 $\theta=45°$：

$$\cos\theta=\frac{\boldsymbol{v}\cdot\boldsymbol{w}}{\|\boldsymbol{v}\|\,\|\boldsymbol{w}\|}=\frac{1}{\sqrt{2}}.$$

（5）任意向量 $\boldsymbol{v}$、$\boldsymbol{w}$ 之间的夹角 $\theta$ 满足 $|\cos\theta|\leqslant 1$；同时，有 Schwarz 不等式 $|\boldsymbol{v}\cdot\boldsymbol{w}|\leqslant\|\boldsymbol{v}\|\,\|\boldsymbol{w}\|$ 和三角不等式 $\|\boldsymbol{v}+\boldsymbol{w}\|\leqslant\|\boldsymbol{v}\|+\|\boldsymbol{w}\|$.

向量 $\boldsymbol{v}$ 和 $\boldsymbol{w}$ 之间最为广泛使用的乘法是点积：$\boldsymbol{v}\cdot\boldsymbol{w}$. 把它们的第一个分量相乘得到 $v_1w_1$，再把第二个分量相乘得到 $v_2w_2$，以此类推；然后把这些乘积相加，就得到了 $\boldsymbol{v}\cdot\boldsymbol{w}$. 例如：

$$\boxed{\boldsymbol{v}=\begin{bmatrix}v_1\\v_2\end{bmatrix}\text{ 和 }\boldsymbol{w}=\begin{bmatrix}w_1\\w_2\end{bmatrix}\text{ 的点积为 }\boldsymbol{v}\cdot\boldsymbol{w}=v_1w_1+v_2w_2.}\tag{1.2}$$

若考虑 $n$ 维空间中的向量，$\boldsymbol{v}$、$\boldsymbol{w}$ 都有 $n$ 个分量，那么

$$\boxed{\boldsymbol{v}\cdot\boldsymbol{w}=v_1w_1+v_2w_2+\cdots+v_nw_n=\boldsymbol{w}\cdot\boldsymbol{v}}\tag{1.3}$$

与向量点积相关联的是向量的长度：$\|\boldsymbol{v}\|$，定义为

$$\|\boldsymbol{v}\|=\sqrt{\boldsymbol{v}\cdot\boldsymbol{v}}=\sqrt{v_1^2+\cdots+v_n^2}$$

在二维平面上，这就是勾股定理：若 $a$、$b$ 是直角三角形中的直角边，$c$ 是斜边，那么 $a^2+b^2=c^2$. 当直角边分别为 $a=v_1, b=v_2$ 时，$c^2=\|\boldsymbol{v}\|^2=v_1^2+v_2^2$.

考虑 $n$ 维空间时，从二维开始逐次增加一个维度. 图 1.4表示了二维空间中的向量 $\boldsymbol{v}=\begin{bmatrix}1&2\end{bmatrix}^{\mathrm{T}}$ 和三维空间中的向量 $\boldsymbol{w}=\begin{bmatrix}1&2&3\end{bmatrix}^{\mathrm{T}}$. 直角三角形的两个直角边是 $\begin{bmatrix}1&2&0\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}0&0&3\end{bmatrix}^{\mathrm{T}}$，它们加起来等于 $\boldsymbol{w}$. 前一条边在 $xy$ 平面上，后一条边平行于 $z$ 轴. 对于三维空间中的这个直角三角形，斜边是 $\boldsymbol{w}$，重复使用勾股定理得 $(1^2+2^2)+(3^2)=14=\|\boldsymbol{w}\|^2$.

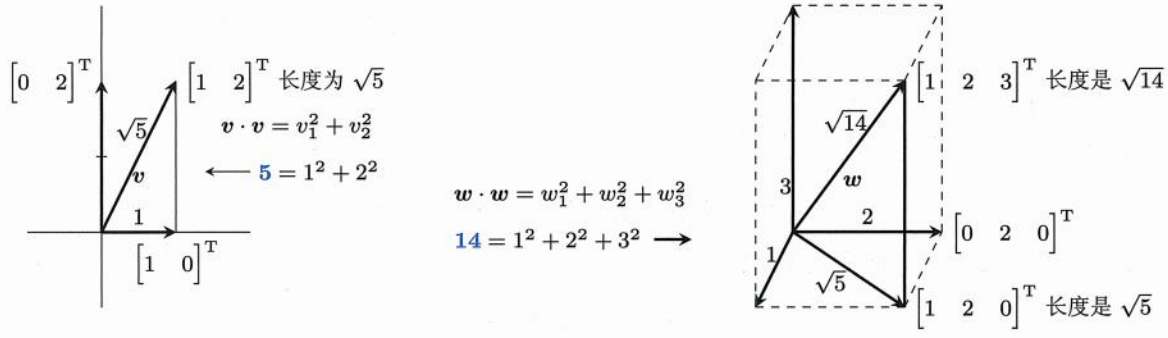


(a) $\boldsymbol{v}=\begin{bmatrix}1&2\end{bmatrix}^{\mathrm{T}}$ 的长度为 $\sqrt{5}$　　(b) $\boldsymbol{w}=\begin{bmatrix}1&2&3\end{bmatrix}^{\mathrm{T}}$ 的长度为 $\sqrt{14}$

图 1.4　二维和三维空间中向量的长度

四维空间中向量的长度是 $\sqrt{v_1^2+v_2^2+v_3^2+v_4^2}$，因此向量 $\begin{bmatrix}1 & 1 & 1 & 1\end{bmatrix}^{\mathrm{T}}$ 的长度为 $\sqrt{1^2+1^2+1^2+1^2}=2$；这是四维空间中单位立方体的对角线的长度. $n$ 维空间中单位立方体的对角线长度为 $\sqrt{n}$.

我们用 单位向量来表示长度为 1 的向量.

> 单位向量的长度为 $\|\boldsymbol{u}\|=1$. 若 $\boldsymbol{v}\neq 0$，则 $\boldsymbol{u}=\dfrac{\boldsymbol{v}}{\|\boldsymbol{v}\|}$ 是单位向量.

**例 1.2**　沿着 $x$ 方向的标准单位向量被记为 $\boldsymbol{i}$. 在 $xy$ 平面上，与 $x$ 轴正向成 $\theta$ 角的单位向量是 $\boldsymbol{u}=\begin{bmatrix}\cos\theta & \sin\theta\end{bmatrix}^{\mathrm{T}}$:

$$\boldsymbol{i}=\begin{bmatrix}1\\0\end{bmatrix} \text{ 和 } \boldsymbol{u}=\begin{bmatrix}\cos\theta\\ \sin\theta\end{bmatrix} \text{ 是单位向量. 注意：} \boldsymbol{i}\cdot\boldsymbol{u}=\cos\theta.$$

$\boldsymbol{u}=\begin{bmatrix}\cos\theta & \sin\theta\end{bmatrix}^{\mathrm{T}}$ 是单位向量，这是因为 $\boldsymbol{u}\cdot\boldsymbol{u}=\cos^2\theta+\sin^2\theta=1$.

在四维空间中，$\boldsymbol{u}=\begin{bmatrix}\frac{1}{2} & \frac{1}{2} & \frac{1}{2} & \frac{1}{2}\end{bmatrix}^{\mathrm{T}}$ 是单位向量. 也可以从任意一个非零向量出发构造单位向量，例如 $\boldsymbol{v}=\begin{bmatrix}1 & 5 & 5 & 7\end{bmatrix}^{\mathrm{T}}$，此时 $\|\boldsymbol{v}\|^2=1+25+25+49=100$，所以 $\boldsymbol{v}$ 的长度是 10，那么 $\boldsymbol{u}=\boldsymbol{v}/10$ 是单位向量.

“单位”这个词总是指在某种测量方式之下的取值是 1. 单位价格是指一个物品的价格，单位立方体指边长是 1 的立方体，单位圆指半径是 1 的圆. 在本书中单位向量指长度是 1 的向量.

### 1.2.1　垂直向量

假设 $\boldsymbol{v}$、$\boldsymbol{w}$ 的夹角是 90°，余弦值是 0，这提供了一种数值上判断向量垂直的方法：$\boldsymbol{v}\cdot\boldsymbol{w}=0$.

> 向量 $\boldsymbol{v}$、$\boldsymbol{w}$ 垂直当且仅当 $\boldsymbol{v}\cdot\boldsymbol{w}=0$，进而 $\|\boldsymbol{v}+\boldsymbol{w}\|^2=\|\boldsymbol{v}\|^2+\|\boldsymbol{w}\|^2$.　(1.4)

这是最重要的特殊情形. 与勾股定理类比：90° 的角推出 $a^2+b^2=c^2$. 很容易就可以从向量的垂直关系 $(\boldsymbol{v}\cdot\boldsymbol{w}=0=\boldsymbol{w}\cdot\boldsymbol{v})$ 导出上述代数关系：

$$\|\boldsymbol{v}+\boldsymbol{w}\|^2=(\boldsymbol{v}+\boldsymbol{w})\cdot(\boldsymbol{v}+\boldsymbol{w})=\boldsymbol{v}\cdot\boldsymbol{v}+\boldsymbol{v}\cdot\boldsymbol{w}+\boldsymbol{w}\cdot\boldsymbol{v}+\boldsymbol{w}\cdot\boldsymbol{w}=\|\boldsymbol{v}\|^2+\|\boldsymbol{w}\|^2. \tag{1.5}$$

中间两项 $\boldsymbol{v}\cdot\boldsymbol{w}=\boldsymbol{w}\cdot\boldsymbol{v}=0$. 值得注意的是，$\|\boldsymbol{v}-\boldsymbol{w}\|^2$ 也等于 $\|\boldsymbol{v}\|^2+\|\boldsymbol{w}\|^2$.

**例 1.3**　• 向量 $\boldsymbol{v}=\begin{bmatrix}1 & 1\end{bmatrix}^{\mathrm{T}}$ 与 $x$ 轴正向成 45° 角.

• 向量 $\boldsymbol{w}=\begin{bmatrix}1 & -1\end{bmatrix}^{\mathrm{T}}$ 与 $x$ 轴正向成 −45° 角.

• 和 $\boldsymbol{v}+\boldsymbol{w}=\begin{bmatrix}2 & 0\end{bmatrix}^{\mathrm{T}}$，差 $\boldsymbol{v}-\boldsymbol{w}=\begin{bmatrix}0 & 2\end{bmatrix}^{\mathrm{T}}$.

因此 $\begin{bmatrix}1 & 1\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}1 & -1\end{bmatrix}^{\mathrm{T}}$ 之间的夹角是 90°. 它们的点积 $\boldsymbol{v}\cdot\boldsymbol{w}=1-1=0$. 这个直角三角形的两条直角边满足 $\|\boldsymbol{v}\|^2=2$ 和 $\|\boldsymbol{w}\|^2=2$，斜边满足 $\|\boldsymbol{v}-\boldsymbol{w}\|^2=\|\boldsymbol{v}+\boldsymbol{w}\|^2=4$.

**例 1.4** 向量 $\boldsymbol{v}=\begin{bmatrix}4\\2\end{bmatrix}$ 和 $\boldsymbol{w}=\begin{bmatrix}-1\\2\end{bmatrix}$ 点积是 0:

$$\begin{bmatrix}4\\2\end{bmatrix}\cdot\begin{bmatrix}-1\\2\end{bmatrix}=-4+4=0.$$

在 $x=-1$（原点的左边）处放一个重为 4 的质点，在 $x=2$ 处放一个重为 2 的质点. 以原点为支点，$x$ 轴看起来就是个跷跷板，此时这个跷跷板恰好是平衡的. 这个平衡性的物理意义是力矩平衡，总力矩是点积：$(4)(-1)+(2)(2)=0$.

这是工程和科学中的典型例子. 质量是 $\begin{bmatrix}w_1 & w_2\end{bmatrix}^{\mathrm{T}}=\begin{bmatrix}4 & 2\end{bmatrix}^{\mathrm{T}}$，与原点的相对位置是 $\begin{bmatrix}v_1 & v_2\end{bmatrix}^{\mathrm{T}}=\begin{bmatrix}-1 & 2\end{bmatrix}^{\mathrm{T}}$. 质量乘以距离，即 $w_1v_1$ 和 $w_2v_2$，就得到了力矩. 跷跷板的平衡条件即 $\boldsymbol{w}\cdot\boldsymbol{v}=w_1v_1+w_2v_2=0$，也即点积为零.

**例 1.5** 考虑单位向量 $\boldsymbol{v}=\begin{bmatrix}1 & 0\end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{u}=\begin{bmatrix}\cos\theta & \sin\theta\end{bmatrix}^{\mathrm{T}}$（见图 1.5），有 $\boldsymbol{v}\cdot\boldsymbol{u}=\cos\theta$. 于是可以把向量的夹角和它们的点积联系起来.

**夹角 $\theta$ 的余弦值** 单位向量之间夹角的余弦值的表达式是容易的:

> 若 $\|\boldsymbol{v}\|=\|\boldsymbol{u}\|=1$，则 $\boldsymbol{v}$ 和 $\boldsymbol{u}$ 夹角 $\theta$ 的余弦值为 $\cos\theta=\boldsymbol{v}\cdot\boldsymbol{u}$.

在数学中，0 永远是一个非常特殊的数值. 对于点积而言，两个向量点积为 0 意味着它们是垂直的，它们之间的夹角是 90°. 最明显的垂直向量的例子是 $x$ 轴的单位向量 $\boldsymbol{i}=\begin{bmatrix}1 & 0\end{bmatrix}^{\mathrm{T}}$ 和 $y$ 轴的单位向量 $\boldsymbol{j}=\begin{bmatrix}0 & 1\end{bmatrix}^{\mathrm{T}}$. 可以看到它们的点积是 0，90° 的余弦值是 0.

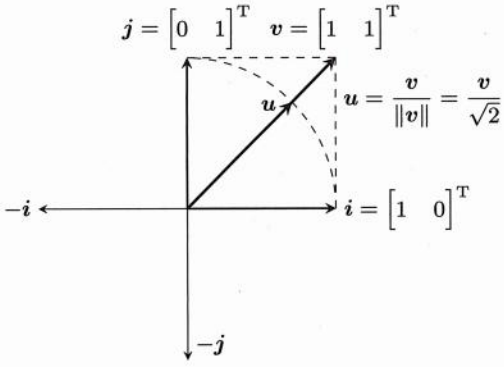


(a) 单位向量 $\boldsymbol{i}$、$\boldsymbol{j}$、$\boldsymbol{u}$

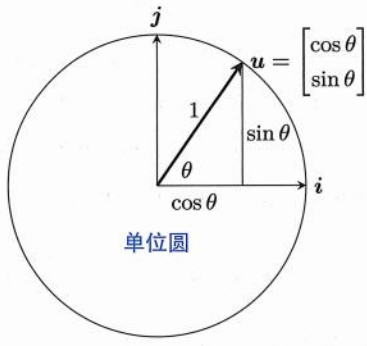


(b) $\boldsymbol{u}$ 与 $\boldsymbol{i}$ 的夹角为 $\theta$

**图 1.5 平面上的单位向量及其夹角**

注：图 1.5(a) 中，$\boldsymbol{v}=\begin{bmatrix}1 & 1\end{bmatrix}^{\mathrm{T}}$ 除以它的长度 $\sqrt{2}$ 得到单位向量 $\boldsymbol{u}$；图 1.5(b) 中，单位向量 $\boldsymbol{u}=\begin{bmatrix}\cos\theta & \sin\theta\end{bmatrix}^{\mathrm{T}}$ 与 $\boldsymbol{i}$ 的夹角为 $\theta$.

**例 1.6**　点积在经济和商业中也很重要. 假设要购买三种物品,它们的单价分别为 $\begin{bmatrix} p_1 & p_2 & p_3 \end{bmatrix}^{\mathrm{T}}$——我们暂且称之为价格向量 $\boldsymbol{p}$. 购买量为 $\boldsymbol{q}=\begin{bmatrix} q_1 & q_2 & q_3 \end{bmatrix}^{\mathrm{T}}$. 以 $p_1$ 的价格买 $q_1$ 件物品，要花费 $q_1p_1$. 那么三种物品的总价就是把 $q_1p_1$、$q_2p_2$、$q_3p_3$ 加起来，恰好就是三维空间中的点积 $\boldsymbol{q}\cdot\boldsymbol{p}$:

$$\text{总价}=q_1p_1+q_2p_2+q_3p_3=\begin{bmatrix} q_1 & q_2 & q_3 \end{bmatrix}^{\mathrm{T}}\cdot\begin{bmatrix} p_1 & p_2 & p_3 \end{bmatrix}^{\mathrm{T}}=\text{点积}.$$

点积为 0 意味着“收支平衡”. 也就是说，买入等于卖出时，$\boldsymbol{q}\cdot\boldsymbol{p}=0$. 那么在三维空间中，$\boldsymbol{p}$ 和 $\boldsymbol{q}$ 是垂直的. 如果我们考虑一个有大量不同种类商品的超市，那么向量的维数就迅速增长了.

电子表格在管理领域是至关重要的，它们计算线性组合和点积. 在显示屏上表示出来就是矩阵运算.

### 1.2.2　向量之间的夹角

我们已经知道了对于垂直的向量 $\boldsymbol{v}$、$\boldsymbol{w}$ 有 $\boldsymbol{v}\cdot\boldsymbol{w}=0$，换句话说，当向量夹角为 90° 时，点积为 0. 接下来把向量的点积和角度联系起来，即可以通过点积把任意两个向量之间的夹角找出来.

**例 1.7**　单位向量 $\boldsymbol{v}=\begin{bmatrix} \cos\alpha & \sin\alpha \end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{w}=\begin{bmatrix} \cos\beta & \sin\beta \end{bmatrix}^{\mathrm{T}}$ 的点积为

$$\boldsymbol{v}\cdot\boldsymbol{w}=\cos\alpha\cos\beta+\sin\alpha\sin\beta=\cos(\beta-\alpha).$$

图 1.6展示了 $\boldsymbol{v}$、$\boldsymbol{w}$ 之间的夹角为 $\beta-\alpha$.

注意到 $\boldsymbol{v}\cdot\boldsymbol{w}=\boldsymbol{w}\cdot\boldsymbol{v}$，因此 $\boldsymbol{v}$ 和 $\boldsymbol{w}$ 的顺序对点积没有影响.

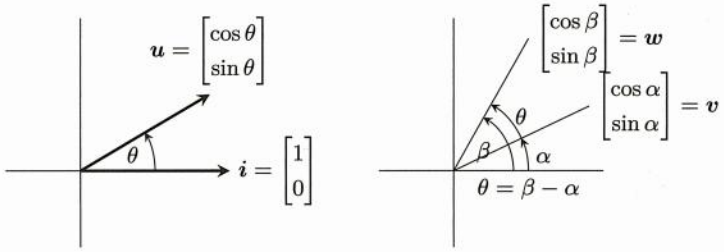


图 1.6　单位向量 $\boldsymbol{u}\cdot\boldsymbol{i}=\cos\theta$

假设 $\boldsymbol{v}\cdot\boldsymbol{w}\neq0$，它可能是正的，也可能是负的. $\boldsymbol{v}\cdot\boldsymbol{w}$ 的正负号对应着夹角是锐角或钝角. 当 $\boldsymbol{v}\cdot\boldsymbol{w}>0$ 时，夹角是锐角；当 $\boldsymbol{v}\cdot\boldsymbol{w}<0$ 时，夹角是钝角. 正负之间的分界线就是和 $\boldsymbol{v}$ 垂直的向量. 如图 1.7所示，$\boldsymbol{w}_2=\begin{bmatrix} 1,-3 \end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{v}=\begin{bmatrix} 3 & 1 \end{bmatrix}^{\mathrm{T}}$ 垂直，它们的点积是 0. 那么当 $\boldsymbol{w}_3$ 越过 90° 角时，$\boldsymbol{v}\cdot\boldsymbol{w}_3<0$，是负数.

**点积反映了夹角 $\theta$.** 再次强调：对于单位向量 $\boldsymbol{u}$ 和 $\boldsymbol{U}$，点积 $\boldsymbol{u}\cdot\boldsymbol{U}$ 是它们夹角的余弦值. 这一点在 $n$ 维空间中也成立.

$\cos\theta$ 在 $[-1,1]$ 上取值，因此单位向量的点积也取值于 $[-1,1]$. $\theta$ 的余弦值，即 $\boldsymbol{u}\cdot\boldsymbol{U}$.

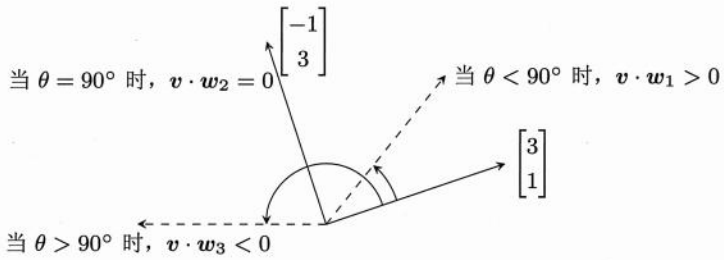


图 1.7　向量点积与夹角的关系示意图

如果 $\boldsymbol{v}$ 和 $\boldsymbol{w}$ 不是单位向量，情况又如何呢？把 $\boldsymbol{v}$、$\boldsymbol{w}$ 除以它们各自的长度，我们得到单位向量 $\boldsymbol{u} = \boldsymbol{v}/\|\boldsymbol{v}\|$ 和 $\boldsymbol{U} = \boldsymbol{w}/\|\boldsymbol{w}\|$. 那么这两个单位向量的点积就给出了余弦值 $\cos\theta$.

$$\boxed{\text{余弦公式：若 } \boldsymbol{v}、\boldsymbol{w} \text{ 是两个非零向量，那么 } \frac{\boldsymbol{v}\cdot\boldsymbol{w}}{\|\boldsymbol{v}\|\,\|\boldsymbol{w}\|} = \cos\theta.} \tag{1.6}$$

无论夹角是多少，$\boldsymbol{v}/\|\boldsymbol{v}\|$ 和 $\boldsymbol{w}/\|\boldsymbol{w}\|$ 的点积都不会大于 1；这就是关于点积的 **Schwarz 不等式**：$|\boldsymbol{v}\cdot\boldsymbol{w}| \leqslant \|\boldsymbol{v}\|\,\|\boldsymbol{w}\|$，或者更准确地说，是 Cauchy-Schwarz-Bunyakowsky 不等式. 这个不等式在法国、德国和俄罗斯等国被独立发现，也可能有其他地方. 这是数学中最重要的不等式.

因为 $|\cos\theta|$ 不超过 1，于是余弦公式(1.6)给出了两个不等式：

| | |
|---|---|
| Schwarz 不等式 | $\|\boldsymbol{v}\cdot\boldsymbol{w}\| \leqslant \|\boldsymbol{v}\|\,\|\boldsymbol{w}\|$ |
| 三角不等式 | $\|\boldsymbol{v}+\boldsymbol{w}\| \leqslant \|\boldsymbol{v}\| + \|\boldsymbol{w}\|$ |

三角不等式是 Schwarz 不等式的直接推论：

$$\|\boldsymbol{v}+\boldsymbol{w}\|^2 = \boldsymbol{v}\cdot\boldsymbol{v} + \boldsymbol{v}\cdot\boldsymbol{w} + \boldsymbol{w}\cdot\boldsymbol{v} + \boldsymbol{w}\cdot\boldsymbol{w} \leqslant \|\boldsymbol{v}\|^2 + 2\|\boldsymbol{v}\|\,\|\boldsymbol{w}\| + \|\boldsymbol{w}\|^2 \tag{1.7}$$

开方就得到 $\|\boldsymbol{v}+\boldsymbol{w}\| \leqslant \|\boldsymbol{v}\| + \|\boldsymbol{w}\|$. 其几何含义是：三角形中，两边之和大于第三边.

**例 1.8**　计算 $\boldsymbol{v} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$ 和 $\boldsymbol{w} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$ 夹角的余弦值 $\cos\theta$，并且验证上述两个不等式.

它们的点积 $\boldsymbol{v}\cdot\boldsymbol{w} = 4$，$\|\boldsymbol{v}\| = \|\boldsymbol{w}\| = \sqrt{5}$，所以 $\|\boldsymbol{v}\|\,\|\boldsymbol{w}\| = 5$.

$$\cos\theta = \frac{\boldsymbol{v}\cdot\boldsymbol{w}}{\|\boldsymbol{v}\|\,\|\boldsymbol{w}\|} = \frac{4}{\sqrt{5}\sqrt{5}} = \frac{4}{5}.$$

此时 Schwarz 不等式是 $\boldsymbol{v}\cdot\boldsymbol{w} = 4 < 5 = \|\boldsymbol{v}\|\,\|\boldsymbol{w}\|$. 还需要验证三角不等式，此时 $\boldsymbol{v}+\boldsymbol{w} = \begin{bmatrix} 3 & 3 \end{bmatrix}^{\mathrm{T}}$，因此 $\|\boldsymbol{v}+\boldsymbol{w}\| = \sqrt{18} \leqslant \sqrt{20} = \|\boldsymbol{v}\| + \|\boldsymbol{w}\|$.

**例 1.9**　向量 $\boldsymbol{v} = \begin{bmatrix} a & b \end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{w} = \begin{bmatrix} b & a \end{bmatrix}^{\mathrm{T}}$ 的点积是 $2ab$，$\|\boldsymbol{v}\| = \|\boldsymbol{w}\| = \sqrt{a^2+b^2}$，由 Schwarz 不等式 $\boldsymbol{v}\cdot\boldsymbol{w} \leqslant \|\boldsymbol{v}\|\,\|\boldsymbol{w}\|$ 可得 $2ab \leqslant a^2 + b^2$.

对任意 $a^2$、$b^2$，它们的 几何平均值 $|ab|$ ⩽ 代数平均值 $\frac{1}{2}(a^2+b^2)$. 也可以不借助 Schwarz 不等式，直接证明：$\frac{1}{2}(a^2+b^2) - ab = \frac{1}{2}(a-b)^2$ 是完全平方，是非负实数，从而几何平均值 ⩽ 代数平均值.

### 1.2.3　三维空间中的平面

设 $\boldsymbol{n}=\begin{bmatrix}n_1 & n_2 & n_3\end{bmatrix}^{\mathrm{T}}$ 是单位向量，考虑 $\mathbb{R}^3$ 中和 $\boldsymbol{n}$ 垂直的向量 $\boldsymbol{w}$ 的全体:

满足 $\boldsymbol{w}\cdot\boldsymbol{n}=0$ 的所有向量 $\boldsymbol{w}$ 一起构成 $\mathbb{R}^3$ 中的一个平面.

我们说这个平面垂直于法向量 $\boldsymbol{n}$. 三维空间中过原点的二维平面满足方程: $n_2w_2+n_2w_2+n_3w_3=0$. 我们通常说的“$xy$ 平面”的法向量沿着 $z$ 轴方向，例如 $\begin{bmatrix}0 & 0 & 1\end{bmatrix}^{\mathrm{T}}$. 所以 $xy$ 平面的方程就是熟知的 $w_3=0$ 或者 $z=0$.

## 例 题 总 结

1.2 A. 对向量 $\boldsymbol{v}=\begin{bmatrix}3 & 4\end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{w}=\begin{bmatrix}4 & 3\end{bmatrix}^{\mathrm{T}}$，验证关于 $\boldsymbol{v}\cdot\boldsymbol{w}$ 的 Schwarz 不等式和关于 $\|\boldsymbol{v}+\boldsymbol{w}\|$ 的三角不等式. 找出 $\boldsymbol{v}$ 和 $\boldsymbol{w}$ 之间夹角的余弦值 $\cos\theta$.

**解**　$\boldsymbol{v}\cdot\boldsymbol{w}=(3)(4)+(4)(3)=24$，$\|\boldsymbol{v}\|=\|\boldsymbol{w}\|=\sqrt{3^2+4^2}=5$. $\boldsymbol{v}+\boldsymbol{w}=\begin{bmatrix}7 & 7\end{bmatrix}^{\mathrm{T}}$，$\|\boldsymbol{v}+\boldsymbol{w}\|=7\sqrt{2}=\sqrt{98}<10$.

| | | |
|---|---|---|
| Schwarz 不等式 | $\lvert\boldsymbol{v}\cdot\boldsymbol{w}\rvert\leqslant\|\boldsymbol{v}\|\,\|\boldsymbol{w}\|$ | 即 $24<25$; |
| 三角不等式 | $\|\boldsymbol{v}+\boldsymbol{w}\|\leqslant\|\boldsymbol{v}\|+\|\boldsymbol{w}\|$ | 即 $7\sqrt{2}<5+5$; |
| 角度的余弦值 | $\cos\theta=\dfrac{24}{25}$. | |

1.2 B. $\boldsymbol{v}$ 和 $\boldsymbol{w}$ 满足什么条件时有等式 $\lvert\boldsymbol{v}\cdot\boldsymbol{w}\rvert=\|\boldsymbol{v}\|\,\|\boldsymbol{w}\|$ 和 $\|\boldsymbol{v}+\boldsymbol{w}\|=\|\boldsymbol{v}\|+\|\boldsymbol{w}\|$?

**解**　当其中一个向量是另一个向量的常数倍时，例如 $\boldsymbol{w}=c\boldsymbol{v}$，它们之间的角度为 0° 或 180°，$\lvert\cos\theta\rvert=1$，因此 $\lvert\boldsymbol{v}\cdot\boldsymbol{w}\rvert=\|\boldsymbol{v}\|\,\|\boldsymbol{w}\|$. 当角度是 0°(例如 $\boldsymbol{w}=2\boldsymbol{v}$) 时，$\|\boldsymbol{v}+\boldsymbol{w}\|=\|\boldsymbol{v}\|+\|\boldsymbol{w}\|$(等式两边都等于 $3\|\boldsymbol{v}\|$). 此时由 $\boldsymbol{v}$、$2\boldsymbol{v}$、$3\boldsymbol{v}$ 组成的三角形退化成重合的线段.

1.2 C. 找出向量 $\boldsymbol{v}=\begin{bmatrix}3 & 4\end{bmatrix}^{\mathrm{T}}$ 方向的单位向量 $\boldsymbol{u}$，并求出和 $\boldsymbol{u}$ 垂直的单位向量 $\boldsymbol{U}$. $\boldsymbol{U}$ 有两种可能.

**解**　$\boldsymbol{u}$ 可由 $\boldsymbol{v}$ 除以它的长度 $\|\boldsymbol{v}\|$ 得到；和 $\boldsymbol{v}$ 垂直的向量可以选取 $\boldsymbol{V}=\begin{bmatrix}-4 & 3\end{bmatrix}^{\mathrm{T}}$ 或者 $\begin{bmatrix}4 & -3\end{bmatrix}^{\mathrm{T}}$，将 $\boldsymbol{V}$ 除以它的长度 $\|\boldsymbol{V}\|=5$ 就可以得到 $\boldsymbol{U}$.

1.2 D. 分析角度余弦值的公式: $\boldsymbol{v}\cdot\boldsymbol{w}=\|\boldsymbol{v}\|\,\|\boldsymbol{w}\|\cos\theta$，这就是余弦定理 $c^2=a^2+b^2-2ab\cos\theta$ 中的 $ab\cos\theta$.

图 1.8 中，$a=\|\boldsymbol{v}\|, b=\|\boldsymbol{w}\|, c=\|\boldsymbol{v}-\boldsymbol{w}\|$，我们只需要将 $\boldsymbol{v}\cdot\boldsymbol{w}=\|\boldsymbol{v}\|\,\|\boldsymbol{w}\|\cos\theta$ 代入式 $\|\boldsymbol{v}-\boldsymbol{w}\|^2=\|\boldsymbol{v}\|^2+\|\boldsymbol{w}\|^2-2\boldsymbol{v}\cdot\boldsymbol{w}$ 中就可以得到余弦定理.

对左边的三角形用勾股定理

$$
\begin{aligned}
c^2 &= (a\sin\theta)^2 + (b - a\cos\theta)^2 \\
&= a^2\sin^2\theta + b^2 - 2ab\cos\theta + a^2\cos^2\theta \\
&= \boldsymbol{a^2 + b^2 - 2ab\cos\theta}
\end{aligned}
$$

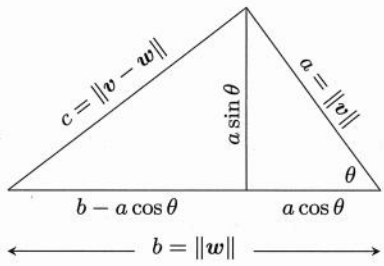


图 1.8 余弦定理

## 习题 1.2

1. 设 $\boldsymbol{u} = \begin{bmatrix} -0.6 & 0.8 \end{bmatrix}^{\mathrm{T}}, \boldsymbol{v} = \begin{bmatrix} 4 & 3 \end{bmatrix}^{\mathrm{T}}, \boldsymbol{w} = \begin{bmatrix} 1 & 2 \end{bmatrix}^{\mathrm{T}}$，计算下列点积：$\boldsymbol{u}\cdot\boldsymbol{v}$、$\boldsymbol{u}\cdot\boldsymbol{w}$、$\boldsymbol{u}\cdot(\boldsymbol{v}+\boldsymbol{w})$ 和 $\boldsymbol{w}\cdot\boldsymbol{v}$.

2. $\boldsymbol{u}$、$\boldsymbol{v}$、$\boldsymbol{w}$ 同习题 1，计算它们的长度 $\|\boldsymbol{u}\|$、$\|\boldsymbol{v}\|$、$\|\boldsymbol{w}\|$. 验证 Schwarz 不等式：$|\boldsymbol{u}\cdot\boldsymbol{v}| \leqslant \|\boldsymbol{u}\|\,\|\boldsymbol{v}\|$ 和 $|\boldsymbol{v}\cdot\boldsymbol{w}| \leqslant \|\boldsymbol{v}\|\cdot\|\boldsymbol{w}\|$.

3. $\boldsymbol{u}$、$\boldsymbol{v}$、$\boldsymbol{w}$ 同习题 1，计算 $\|\boldsymbol{u}\|$、$\|\boldsymbol{v}\|$ 和 $\|\boldsymbol{w}\|$，并计算它们之间夹角的余弦值. 分别找出一个和 $\boldsymbol{w}$ 成 0°、90°、180° 角的向量 $\boldsymbol{a}$、$\boldsymbol{b}$、$\boldsymbol{c}$.

4. 对任意单位向量 $\boldsymbol{v}$、$\boldsymbol{w}$，计算下列各组向量的点积（结果都是明确的数字）：

（1）$\boldsymbol{v}, -\boldsymbol{v}$;

（2）$\boldsymbol{v}+\boldsymbol{w}, \boldsymbol{v}-\boldsymbol{w}$;

（3）$\boldsymbol{v}-2\boldsymbol{w}, \boldsymbol{v}+2\boldsymbol{w}$.

5. 分别求出与 $\boldsymbol{v} = \begin{bmatrix} 1 & 3 \end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{w} = \begin{bmatrix} 2 & 1 & 2 \end{bmatrix}^{\mathrm{T}}$ 同向的单位向量 $\boldsymbol{u}_1$、$\boldsymbol{u}_2$. 分别求出与 $\boldsymbol{u}_1$、$\boldsymbol{u}_2$ 垂直的单位向量 $\boldsymbol{U}_1$、$\boldsymbol{U}_2$.

6.（1）描述垂直于向量 $\boldsymbol{v} = \begin{bmatrix} 2 & -1 \end{bmatrix}^{\mathrm{T}}$ 的所有向量 $\boldsymbol{w} = \begin{bmatrix} w_1 & w_2 \end{bmatrix}^{\mathrm{T}}$.

（2）所有垂直于向量 $\boldsymbol{V} = \begin{bmatrix} 1 & 1 & 1 \end{bmatrix}^{\mathrm{T}}$ 的向量在三维空间的一个_____上.

（3）所有同时垂直于 $\begin{bmatrix} 1 & 1 & 1 \end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix} 1 & 2 & 3 \end{bmatrix}^{\mathrm{T}}$ 的向量在一个_____上.

7. 求出下列各组向量之间的夹角：

（1）$\boldsymbol{v} = \begin{bmatrix} 1 \\ \sqrt{3} \end{bmatrix}, \boldsymbol{w} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$;

（2）$\boldsymbol{v} = \begin{bmatrix} 2 \\ 2 \\ -1 \end{bmatrix}, \boldsymbol{w} = \begin{bmatrix} 2 \\ -1 \\ 2 \end{bmatrix}$;

（3）$\boldsymbol{v} = \begin{bmatrix} 1 \\ \sqrt{3} \end{bmatrix}, \boldsymbol{w} = \begin{bmatrix} -1 \\ -\sqrt{3} \end{bmatrix}$;

（4）$\boldsymbol{v}=\begin{bmatrix}3\\1\end{bmatrix},\boldsymbol{w}=\begin{bmatrix}-1\\-2\end{bmatrix}$.

8. 判断正误，正确请说明理由，错误请给出反例.

（1）若 $\boldsymbol{u}=\begin{bmatrix}1&1&1\end{bmatrix}^{\mathrm{T}}$ 垂直于向量 $\boldsymbol{v}$ 和 $\boldsymbol{w}$，那么 $\boldsymbol{v}$ 和 $\boldsymbol{w}$ 平行.

（2）若 $\boldsymbol{u}$ 和 $\boldsymbol{v}$、$\boldsymbol{w}$ 都垂直，那么 $\boldsymbol{u}$ 和 $\boldsymbol{v}+2\boldsymbol{w}$ 垂直;

（3）若 $\boldsymbol{u}$ 和 $\boldsymbol{v}$ 是互相垂直的单位向量，那么 $\|\boldsymbol{u}-\boldsymbol{v}\|^2=2$.

9. 过点 $(0,0)$ 和点 $(v_1,v_2)$ 的直线斜率是 $v_2/v_1$，过点 $(0,0)$ 和点 $(w_1,w_2)$ 的直线斜率是 $w_2/w_1$. 假设这两个斜率的乘积 $v_2w_2/v_1w_1$ 等于 $-1$. 证明向量 $\boldsymbol{v}=\begin{bmatrix}v_1&v_2\end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{w}=\begin{bmatrix}w_1&w_2\end{bmatrix}^{\mathrm{T}}$ 的点积是 0，从而它们垂直（例如直线 $y=4x$ 和 $y=-\frac{1}{4}x$ 垂直）.

10. 从原点 $(0,0)$ 分别画出过点 $(1,2)$ 和 $(-2,1)$ 的直线，计算它们斜率的乘积. 这两条直线_____.

11. 若 $\boldsymbol{v}\cdot\boldsymbol{w}<0$，你能对 $\boldsymbol{v}$ 和 $\boldsymbol{w}$ 的夹角下什么论断？在三维空间中，画一个向量 $\boldsymbol{v}$（带箭头），并且在图中表示出所有和 $\boldsymbol{v}$ 点积小于 0 的向量 $\boldsymbol{w}$.

12. 给定 $\boldsymbol{v}=\begin{bmatrix}1&1\end{bmatrix}^{\mathrm{T}},\boldsymbol{w}=\begin{bmatrix}1&5\end{bmatrix}^{\mathrm{T}}$，若 $\boldsymbol{w}-c\boldsymbol{v}$ 和 $\boldsymbol{v}$ 垂直，那么 $c$ 是多少？若 $\boldsymbol{v}$、$\boldsymbol{w}$ 是任意给定的两个向量，$c$ 等于多少时，$\boldsymbol{w}-c\boldsymbol{v}$ 和 $\boldsymbol{v}$ 垂直？用关于 $\boldsymbol{v}$、$\boldsymbol{w}$ 的式子来表达这个 $c$.

13. 找出垂直于向量 $\begin{bmatrix}1&1&1&1\end{bmatrix}^{\mathrm{T}}$，并且两两互相垂直的三个非零向量 $\boldsymbol{u}$、$\boldsymbol{v}$、$\boldsymbol{w}$.

14. $x=2$ 和 $y=8$ 的几何平均值是 $\sqrt{xy}=4$，它们的算术平均值不小于几何平均值. $\frac{1}{2}(x+y)=$_____. 事实上，利用 Schwarz 不等式，可以借助 $\boldsymbol{v}=\begin{bmatrix}\sqrt{2}&\sqrt{8}\end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{w}=\begin{bmatrix}\sqrt{8}&\sqrt{2}\end{bmatrix}^{\mathrm{T}}$ 证明该结论. 求出 $\boldsymbol{v}$ 和 $\boldsymbol{w}$ 夹角的余弦值 $\cos\theta$.

15. 九维空间中的向量 $\boldsymbol{v}=\begin{bmatrix}1&1&\cdots&1\end{bmatrix}^{\mathrm{T}}$ 的长度是多少？找出一个和 $\boldsymbol{v}$ 同向的单位向量 $\boldsymbol{u}$，再找出一个和 $\boldsymbol{v}$ 垂直的向量 $\boldsymbol{w}$.

16. 设 $\boldsymbol{i}$、$\boldsymbol{j}$、$\boldsymbol{k}$ 是三维空间三个坐标轴的单位向量，向量 $\boldsymbol{v}=\begin{bmatrix}1&0&-1\end{bmatrix}^{\mathrm{T}}$ 与它们的夹角分别为 $\alpha$、$\beta$、$\theta$，请问：$\cos\alpha$、$\cos\beta$、$\cos\theta$ 是多少？验证：$\cos^2\alpha+\cos^2\beta+\cos^2\theta=1$.

**习题 17~20 是关于三角形的边长和角度的问题.**

17. 向量 $\boldsymbol{v}=\begin{bmatrix}4&2\end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{w}=\begin{bmatrix}-1&2\end{bmatrix}^{\mathrm{T}}$ 是直角三角形的两条直角边. 对这个直角三角形验证勾股定理，即：

$$\|\boldsymbol{v}\|^2+\|\boldsymbol{w}\|^2=\|\boldsymbol{v}+\boldsymbol{w}\|^2.$$

18. 点积满足如下三个运算规律

（1）$\boldsymbol{v}\cdot\boldsymbol{w}=\boldsymbol{w}\cdot\boldsymbol{v}$;

（2）$\boldsymbol{u}\cdot(\boldsymbol{v}+\boldsymbol{w})=\boldsymbol{u}\cdot\boldsymbol{v}+\boldsymbol{u}\cdot\boldsymbol{w}$;

（3）$(c\boldsymbol{v})\cdot\boldsymbol{w}=c(\boldsymbol{v}\cdot\boldsymbol{w})$.

令 $\boldsymbol{u}=\boldsymbol{v}+\boldsymbol{w}$，请只用（1）、（2）证明：$\|\boldsymbol{v}+\boldsymbol{w}\|=\boldsymbol{v}\cdot\boldsymbol{v}+2\boldsymbol{v}\cdot\boldsymbol{w}+\boldsymbol{w}\cdot\boldsymbol{w}$.

19. 余弦定理可以用 $(\boldsymbol{v}-\boldsymbol{w})\cdot(\boldsymbol{v}-\boldsymbol{w})=\boldsymbol{v}\cdot\boldsymbol{v}-2\boldsymbol{v}\cdot\boldsymbol{w}+\boldsymbol{w}\cdot\boldsymbol{w}$ 来证明：

余弦定理　　$\|\boldsymbol{v}-\boldsymbol{w}\|^2=\|\boldsymbol{v}\|^2-2\|\boldsymbol{v}\|\,\|\boldsymbol{w}\|\cos\theta+\|\boldsymbol{w}\|^2.$

画出以 $\boldsymbol{v}$、$\boldsymbol{w}$、$\boldsymbol{v}-\boldsymbol{w}$ 为边的三角形，哪个角是 $\theta$？

20. 三角不等式说的是：$\|\boldsymbol{v}+\boldsymbol{w}\|\leqslant\|\boldsymbol{v}\|+\|\boldsymbol{w}\|$. 第 18 题证明了 $\|\boldsymbol{v}+\boldsymbol{w}\|^2=\|\boldsymbol{v}\|^2+2\boldsymbol{v}\cdot\boldsymbol{w}+\|\boldsymbol{w}\|^2$. 因为 $\boldsymbol{v}\cdot\boldsymbol{w}\leqslant\|\boldsymbol{v}\|\,\|\boldsymbol{w}\|$，所以两边之和不小于第三边：

三角不等式：$\|\boldsymbol{v}+\boldsymbol{w}\|^2\leqslant(\|\boldsymbol{v}\|+\|\boldsymbol{w}\|)^2$ 或者 $\|\boldsymbol{v}+\boldsymbol{w}\|\leqslant\|\boldsymbol{v}\|+\|\boldsymbol{w}\|$.

21. 除了用三角几何的方法，我们还能用代数方法来证明 Schwarz 不等式.

（1）将不等式 $(v_1w_1+v_2w_2)^2\leqslant(v_1^2+v_2^2)(w_1^2+w_2^2)$ 的左右两边完全展开；

（2）不等式右边减去左边，证明这个差等于 $(v_1w_2-v_2w_1)^2$. 这是个完全平方，从而是非负实数，这就证明了原不等式.

22. 对于单位向量 $\boldsymbol{u}=\begin{bmatrix}u_1 & u_2\end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{U}=\begin{bmatrix}U_1 & U_2\end{bmatrix}^{\mathrm{T}}$，用一句话就能证明不等式 $|\boldsymbol{u}\cdot\boldsymbol{U}|\leqslant1$：

$$|\boldsymbol{u}\cdot\boldsymbol{U}|\leqslant|u_1||U_1|+|u_2||U_2|\leqslant\frac{u_1^2+U_1^2}{2}+\frac{u_2^2+U_2^2}{2}=1.$$

23. （1）为什么 $|\cos\theta|$ 始终小于或等于 1？

（2）计算等边三角形内角 $\theta$ 的余弦值.

24. 证明：平行四边形的四条边长的平方和等于两条对角线长度的平方和 (见图 1.9).

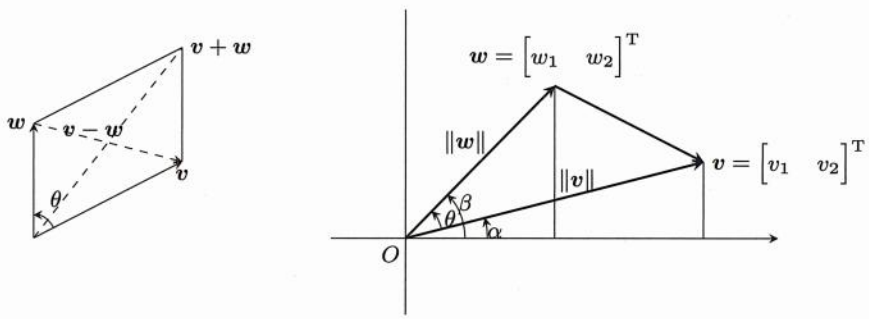


(a) 习题 24　　(b) 习题 25

图 1.9　习题 24 和习题 25

25. 若 $\|\boldsymbol{v}\|=5,\|\boldsymbol{w}\|=3$，那么 $\|\boldsymbol{v}-\boldsymbol{w}\|$ 可能取到的最大值和最小值分别是多少 (见图 1.9)？$\boldsymbol{v}\cdot\boldsymbol{w}$ 可能取到的最大值和最小值分别是多少？

## 挑 战 一 下

26. 在 $xy$-平面上，是否存在 3 个向量，它们之间两两点积都小于 0？三维空间中，你能找出最多几个向量使得其两两点积都小于 0？（平面上不存在两两点积小于 0 的 4 个向量.）

27. 选取合适的正负号，在 $\begin{bmatrix}\pm\frac{1}{2} & \pm\frac{1}{2} & \pm\frac{1}{2} & \pm\frac{1}{2}\end{bmatrix}^{\mathrm{T}}$ 中找出 4 个两两垂直的向量.

28. 在 MATLAB 中，用 $\boldsymbol{v}=\text{randn}(3,1)$ 来随机获取一个单位向量 $\boldsymbol{u}=\boldsymbol{v}/\|\boldsymbol{v}\|$. 用 $\boldsymbol{V}=\text{randn}(3,30)$ 来随机获取 30 个单位向量 $\boldsymbol{U}_j$. 点积的绝对值 $|\boldsymbol{u}\cdot\boldsymbol{U}_j|$ 的平均值是多少？事实上，用概率论的方法可以求出这个平均值是 $\int_0^{\pi}\frac{|\cos\theta|}{\pi}\mathrm{d}\theta=2/\pi$.

29. 在 $xy$ 平面上，4 个向量 $\boldsymbol{v}_1$、$\boldsymbol{v}_2$、$\boldsymbol{v}_3$、$\boldsymbol{v}_4$ 满足什么条件时能构成一个四边形？显然不能是随机的 4 个向量.

## 1.3　矩阵和它们的列空间

（1）$\boldsymbol{A}=\begin{bmatrix}1&2\\3&4\\5&6\end{bmatrix}$ 是 $3\times2$ 矩阵：$m=$ 行数 $=3, n=$ 列数 $=2$，秩为 2.

（2）$\boldsymbol{Ax}$ 的 3 个分量分别是 $\boldsymbol{A}$ 的 3 个行向量和 $\boldsymbol{x}$ 的点积：$\begin{bmatrix}1&2\\3&4\\5&6\end{bmatrix}\begin{bmatrix}7\\8\end{bmatrix}=\begin{bmatrix}1\cdot7+2\cdot8\\3\cdot7+4\cdot8\\5\cdot7+6\cdot8\end{bmatrix}=\begin{bmatrix}23\\53\\83\end{bmatrix}$.

（3）$\boldsymbol{Ax}$ 同时也表示 $\boldsymbol{A}$ 的列向量的线性组合：$\begin{bmatrix}1&2\\3&4\\5&6\end{bmatrix}\begin{bmatrix}7\\8\end{bmatrix}=7\begin{bmatrix}1\\3\\5\end{bmatrix}+8\begin{bmatrix}2\\4\\6\end{bmatrix}$.

（4）$\boldsymbol{A}$ 的列空间是所有的线性组合 $\boldsymbol{Ax}=x_1\boldsymbol{a}_1+x_2\boldsymbol{a}_2$ 的全体.

（5）秩 1 矩阵：非零矩阵 $\boldsymbol{A}$ 的所有列向量（从而所有线性组合 $\boldsymbol{Ax}$）都在一条直线上.

前两节介绍了 $\mathbb{R}^2$、$\mathbb{R}^3$ 以至任意有限维空间 $\mathbb{R}^n$ 中向量的运算：它们的线性组合、点积、长度和角度. 本节我们“图穷匕见”，介绍真正的目标：矩阵. 矩阵就是由 $m$-行 $n$-列共 $mn$ 个数字组成的矩形阵列. 若 $m=n$，称 $\boldsymbol{A}$ 是个方阵. 以下是矩阵的一些例子：

$\begin{bmatrix}1&0&0\\0&1&0\\0&0&1\end{bmatrix}$ 单位矩阵　　$\begin{bmatrix}2&0&0\\0&4&0\\0&0&5\end{bmatrix}$ 对角矩阵　　$\begin{bmatrix}2&1&-3\\0&4&7\\0&0&5\end{bmatrix}$ 上三角矩阵　　$\begin{bmatrix}2&1&-3\\1&4&7\\-3&7&5\end{bmatrix}$ 对称矩阵

我们经常把矩阵 $\boldsymbol{A}$ 视作由列向量 $\boldsymbol{a}_1,\boldsymbol{a}_2,\cdots,\boldsymbol{a}_n$ 排成的行向量；这 $n$ 个列向量都有 $m$ 个分量. 在下面的例子中，每个 $\boldsymbol{a}_i$ 都有 $m=3$ 个分量：

$m=$ 行数 $=3$
$n=$ 列数 $=4$
$\boldsymbol{A}$是$3\times4$矩阵

$$\boldsymbol{A}=\begin{bmatrix}\boldsymbol{a}_1&\boldsymbol{a}_2&\boldsymbol{a}_3&\boldsymbol{a}_4\end{bmatrix}=\begin{bmatrix}-1&1&0&0\\0&-1&1&0\\0&0&-1&1\end{bmatrix}$$

这个矩阵称作“差分矩阵”，因为 $\boldsymbol{Ax}$ 的第 $i$ 个分量为 $x_{i+1}-x_i$（$1\leqslant i\leqslant3$）.

那么一般来说，我们怎么计算 $m\times n$ 矩阵 $\boldsymbol{A}$ 乘以 $n$ 维列向量 $\boldsymbol{x}$（我们也可以把 $\boldsymbol{x}$ 看成 $n\times 1$ 矩阵）？我们可以从两个角度来回答这个问题——从 $\boldsymbol{A}$ 的列出发和从 $\boldsymbol{A}$ 的行出发.

> 从行来看，$\boldsymbol{Ax}$ 的分量是 $\boldsymbol{x}$ 与 $\boldsymbol{A}$ 的相应的行向量的点积
> 从列来看，$\boldsymbol{Ax}$ 是 $\boldsymbol{A}$ 的列向量以 $\boldsymbol{x}$ 的分量为组合系数的线性组合

**从行来看 $\boldsymbol{Ax}$.** 用 $\boldsymbol{A}$ 的每一行来乘列向量 $\boldsymbol{x}$：行向量和列向量相乘的运算和点积吻合！我们来看一下用 $\boldsymbol{A}$ 的第一行来乘:

$$(\boldsymbol{A}\text{的第 1 行})\cdot\boldsymbol{x}=\begin{bmatrix}-1 & 1 & 0 & 0\end{bmatrix}^{\mathrm{T}}\cdot\begin{bmatrix}x_1 & x_2 & x_3 & x_4\end{bmatrix}^{\mathrm{T}}=x_2-x_1.$$

一共需要作 $m\times n$ 次乘法. 特别地，在这里

3 个行向量
做 3 个点积

$$\boldsymbol{Ax}=\begin{bmatrix}-1 & 1 & 0 & 0\\ 0 & -1 & 1 & 0\\ 0 & 0 & -1 & 1\end{bmatrix}\cdot\begin{bmatrix}x_1\\ x_2\\ x_3\\ x_4\end{bmatrix}=\begin{bmatrix}\text{第 1 行}\cdot\boldsymbol{x}\\ \text{第 2 行}\cdot\boldsymbol{x}\\ \text{第 3 行}\cdot\boldsymbol{x}\end{bmatrix}=\begin{bmatrix}x_2-x_1\\ x_3-x_2\\ x_4-x_3\end{bmatrix}\tag{1.8}$$

注意，$\boldsymbol{A}$ 的行向量和 $\boldsymbol{x}$ 有相同个数的分量，这使得我们可以将这些分量逐个乘以 $x_1\sim x_4$ 再相加；否则，$\boldsymbol{Ax}$ 这个乘法是不合法的.

**从列来看 $\boldsymbol{Ax}$.** 矩阵 $\boldsymbol{A}$ 和列向量 $\boldsymbol{x}$ 的乘法是 $\boldsymbol{A}$ 的列向量的线性组合：$\boldsymbol{A}$ 的 $n$ 列分别用 $\boldsymbol{x}$ 的 $n$ 个分量去乘，然后把 $x_1\boldsymbol{a}_1,x_2\boldsymbol{a}_2,\cdots,x_n\boldsymbol{a}_n$ 加起来，就得到了与式(1.8)相同的向量：

$$\boxed{\boldsymbol{Ax}=x_1\boldsymbol{a}_1+x_2\boldsymbol{a}_2+\cdots+x_n\boldsymbol{a}_n}\tag{1.9}$$

这 $n$ 个向量的线性组合正好包含了 $\boldsymbol{x}$ 和 $\boldsymbol{A}$ 的 $m$ 个行向量做点积的所有乘法，但是这是一种更高的观点：我们从向量本身出发，而不从它们的点积出发. 通过下式，我们可以清晰地看到式(1.9)和式(1.8)是吻合的：

列向量的线性组合

$$\boldsymbol{Ax}=x_1\begin{bmatrix}-1\\ 0\\ 0\end{bmatrix}+x_2\begin{bmatrix}1\\ -1\\ 0\end{bmatrix}+x_3\begin{bmatrix}0\\ 1\\ -1\end{bmatrix}+x_4\begin{bmatrix}0\\ 0\\ 1\end{bmatrix}=\begin{bmatrix}x_2-x_1\\ x_3-x_2\\ x_4-x_3\end{bmatrix}\tag{1.10}$$

我们比较梳理一下这两种看法，以及各种使用场景下两种看法的优劣之处. 假设已知 $\boldsymbol{A}$ 和 $\boldsymbol{x}$ 的每个分量的具体数值，如果需要 **计算$\boldsymbol{Ax}$** 是多少，我们倾向于使用点积；如果想要从理论上理解 $\boldsymbol{Ax}$，那么我们倾向于从列向量的角度出发，简而言之，“$\boldsymbol{Ax}$ 是 $\boldsymbol{A}$ 的列向量的线性组合”.

事实上，我们的目标远比理解 $\boldsymbol{A}$ 中列向量的单个线性组合 $\boldsymbol{Ax}$ 要宏大，我们真实的目标是 $\boldsymbol{A}$ 列向量的线性组合的全体. 对此，用图 1.10 来示意一下这两者之间的区别：一是单个的线性组合 $2\boldsymbol{a}_1+\boldsymbol{a}_2$，二是考虑所有的线性组合 $x_1\boldsymbol{a}_1+x_2\boldsymbol{a}_2$（$x_1,x_2$ 是变化的）.

与矩阵乘以列向量相关的几个重要的概念是：**线性相关性、线性无关性和列空间.**

这是整个理论的关键点. 我们之所以思考这个问题，是因为矩阵 $\boldsymbol{A}$ 中的列向量未必每一个都有新的贡献，换句话说，可能其中的某些列向量已经包含在前几列的线性组合中. 例 1.10中 $\boldsymbol{A}$ 的 3 列给了 3 个“新”的方向，它们是线性无关的.

(a) $\boldsymbol{a}_1$、$\boldsymbol{a}_2$ 的一个线性组合　　(b) $\boldsymbol{a}_1$、$\boldsymbol{a}_2$ 的所有线性组合构成了整个平面

图 1.10　向量的线性组合

**例 1.10**

线性无关的列向量　　$\boldsymbol{A}_1=\begin{bmatrix}1&0&0\\2&4&0\\3&5&6\end{bmatrix}$　　每一列都给了一个新方向<br>它们的线性组合是整个 $\mathbb{R}^3$

我们来仔细思考一下为什么 $\mathbb{R}^3$ 中的任意向量 $\begin{bmatrix}b_1&b_2&b_3\end{bmatrix}^{\mathrm{T}}$ 都是 $\boldsymbol{A}_1$ 的列向量的线性组合. 通过选取合适的 $x_1$ 能够使第一列 $x_1\begin{bmatrix}1&2&3\end{bmatrix}^{\mathrm{T}}$ 的第一个分量得到任意的 $b_1$；因为 $x_2\begin{bmatrix}0&4&5\end{bmatrix}^{\mathrm{T}}$ 和 $b_1$ 无关，因此对任意 $b_2$，我们选取合适的 $x_2$ 满足要求；最后，因为 $x_3\begin{bmatrix}0&0&6\end{bmatrix}^{\mathrm{T}}$ 和 $b_1$、$b_2$ 都无关，因此可以取合适的 $x_3$ 满足要求. 也就是说，我们可以选到合适的 $x_1$、$x_2$、$x_3$ 使得 $\boldsymbol{A}_1\boldsymbol{x}=\boldsymbol{b}$.

线性无关性的含义是：仅有 $\boldsymbol{x}=\begin{bmatrix}0&0&0\end{bmatrix}^{\mathrm{T}}$ 使得 $\boldsymbol{A}\boldsymbol{x}=\begin{bmatrix}0&0&0\end{bmatrix}^{\mathrm{T}}$. 如果 $\boldsymbol{A}$ 的每一个列向量都不是它之前的列向量的线性组合，那么 $\boldsymbol{A}$ 的列向量是线性无关的. 线性无关性非常重要!

**例 1.11**

线性相关的列向量　　$\boldsymbol{A}_2=\begin{bmatrix}1&2&3\\1&4&5\\6&0&6\end{bmatrix}$　　第 1 列 + 第 2 列 = 第 3 列<br>它们的线性组合不是整个 $\mathbb{R}^3$　　$\begin{aligned}1+2&=3\\1+4&=5\\6+0&=6\end{aligned}$

与线性无关相对的就是线性相关，$\boldsymbol{A}_2$ 的列向量是线性相关的. 第 3 列在第 1 列和第 2 列生成的平面上，因此第 3 列并没有提供什么新信息.

我们习惯从左到右来判断线性无关性. 第 1 列 $\begin{bmatrix}1&1&6\end{bmatrix}^{\mathrm{T}}$ 毫无疑问是线性无关的；第 2 列不是第 1 列的常数倍，$\begin{bmatrix}2&4&0\end{bmatrix}^{\mathrm{T}}$ 给出了一个新的方向. 但是，第 3 列是第 1 列和第 2 列的和，因此第 3 列 $\begin{bmatrix}3&5&6\end{bmatrix}^{\mathrm{T}}$ 和前两列 $\begin{bmatrix}1&1&6\end{bmatrix}^{\mathrm{T}}$、$\begin{bmatrix}2&4&0\end{bmatrix}^{\mathrm{T}}$ 并不是线性无关的. 矩阵 $\boldsymbol{A}_2$ 只有两个线性无关的列向量.

如果从右到左来判断线性无关性，我们可以看到第 3 列和第 2 列线性无关，但是第 1 列是第 3 列和第 2 列的线性组合. 无论用哪种方法我们都可以知道这三个列向量其实是在一个平面上：两

个线性无关的向量在 $\mathbb{R}^3$ 中张成一个平面 $S$.

平面 $S$ 称为 $A_2$ 的列空间：平面 = 列向量的线性组合的全体.

例 1.11中列向量的线性相关性：$\boxed{\text{第 1 列} + \text{第 2 列} - \text{第 3 列} = \begin{bmatrix}0 & 0 & 0\end{bmatrix}^{\mathrm{T}}}$

例 1.12

$$\boldsymbol{A}_3 = \begin{bmatrix}1 & 3 & 4\\ 2 & 6 & 8\\ 5 & 15 & 20\end{bmatrix}$$

第 2 列 = 第 1 列 ×3
第 3 列 = 第 1 列 ×4
任意两列都是线性相关的

这个例子非常重要，因为这是一个极端情形. $\boldsymbol{A}_3$ 的列向量都在三维空间中的同一条直线上. 这条直线由向量 $\begin{bmatrix}1 & 2 & 5\end{bmatrix}^{\mathrm{T}}$ 的所有倍数组成，即 $L = \left\{\begin{bmatrix}c & 2c & 5c\end{bmatrix}^{\mathrm{T}} : c \in \mathbb{R}\right\}$. 注意：$c = 0$ 时我们得到的是原点 $\begin{bmatrix}0 & 0 & 0\end{bmatrix}^{\mathrm{T}}$. 三维空间中的直线 $L$ 就是矩阵 $A_3$ 的列空间. 这条直线包含了所有 $\boldsymbol{A}_3\boldsymbol{x}$；并且当 $\boldsymbol{x}$ 遍历 $\mathbb{R}^3$ 中所有的向量时，$\boldsymbol{A}_3\boldsymbol{x}$ 就取遍了 $\boldsymbol{A}_3$ 的列空间中的所有元素. 这是非零的列空间中最简单的例子了.

$\boxed{\text{列空间 } C(A) \text{ 包含所有的 } A\boldsymbol{x}\text{：}A \text{ 的列向量的所有线性组合.}}$

### 1.3.1 $A$ 的列空间

向量空间是线性代数的核心对象；兵马未动，粮草先行，在进行严格的理论学习之前，我们从具体的例子开始，这可以给我们关于“线性代数是什么”的基本直觉. 回顾一下，矩阵的列向量的所有线性组合构成了它的列空间，但是实际上我们只需要考虑线性无关的列向量的线性组合；因此，从第 1 列开始，从左到右地确定线性无关的列向量. 考察两个例子：

$$\boldsymbol{A}_4 = \begin{bmatrix}1 & 1 & 1 & 1\\ 0 & 1 & 1 & 1\\ 0 & 0 & 1 & 1\\ 0 & 0 & 0 & 1\end{bmatrix} \qquad \boldsymbol{A}_5 = \begin{bmatrix}1 & 1 & 0 & 0\\ 0 & 1 & 1 & 0\\ 0 & 0 & 1 & 1\\ 1 & 0 & 0 & 1\end{bmatrix}$$

$\boldsymbol{A}_4$ 有 4 个线性无关的列向量，例如第 4 列不是前 3 列的线性组合；它没有线性相关的列向量组. 要构造像 $\boldsymbol{A}_4$ 那样的列向量线性无关的上三角矩阵，我们只需要让主对角线非零即可. 在这个例子中，主对角线元素全都是 1.

$\boldsymbol{A}_5$ 这个例子就不那么容易了. 它的前 3 个列向量是线性无关的，最大的问题是要判断第 4 列是否是前 3 列的线性组合. 为了得到第 4 列中的分量 1，我们从第 1 列开始分析.

为了消掉第一个分量中的 1，要用第 1 列减去第 2 列；那么只需要加上第 3 列，就能把第 2 个分量也消掉. 此时对比一下，正好和第 4 列一样，于是就得到了关于 $\boldsymbol{A}_5$ 的列向量的线性相关性：

$$\text{第 4 列} = \text{第 1 列} - \text{第 2 列} + \text{第 3 列} \tag{1.11}$$

接下来，我们想要“可视化”矩阵的列空间；换句话说，想要直观地了解这 4 个向量的所有线性组合. “可视化”之所以加引号，是因为某种程度上这是做不到的；比方说，我们几乎不可能画

出一个四维空间中的图像，如果你非觉得你能画出来，那么恭喜你，基本上就是画错了. 尽管如此，我们还是不想放弃这方面的努力；对此，我们从 $\boldsymbol{A}_4$ 这个例子出发.

先问自己一个问题，你能“看出来”为什么 $\mathcal{C}(\boldsymbol{A}_4)$ 是整个空间 $\mathbb{R}^4$ 吗？从纯代数的角度，我们可以看到 $\mathbb{R}^4$ 中的任意向量 $\boldsymbol{v}$ 都是 $\boldsymbol{A}_4$ 的列向量的线性组合：

$$\boldsymbol{v}=\begin{bmatrix}v_1\\v_2\\v_3\\v_4\end{bmatrix}=(v_1-v_2)\begin{bmatrix}1\\0\\0\\0\end{bmatrix}+(v_2-v_3)\begin{bmatrix}1\\1\\0\\0\end{bmatrix}+(v_3-v_4)\begin{bmatrix}1\\1\\1\\0\end{bmatrix}+v_4\begin{bmatrix}1\\1\\1\\1\end{bmatrix} \tag{1.12}$$

这说明：任意向量 $\boldsymbol{v}\in\mathbb{R}^4$ 都在 $\boldsymbol{A}_4$ 的列空间中. 事实上，我们解出了线性方程组 $\boldsymbol{A}_4\boldsymbol{x}=\boldsymbol{v}$.

> 用术语“张成”(或“生成”) 来表示一族向量的线性组合的全体.
> $\boldsymbol{A}$ 的列向量（无论是否线性无关）张成了 $\boldsymbol{A}$ 的列空间.

我们可以从几何上看待 $\boldsymbol{A}_4$ 的列空间. 它的第 1 列 $\begin{bmatrix}1&0&0&0\end{bmatrix}^{\mathrm{T}}$ 贡献了 $\mathbb{R}^4$ 中的一条直线，这条直线是 $\left\{\begin{bmatrix}c_1&0&0&0\end{bmatrix}^{\mathrm{T}}:c_1\in\mathbb{R}\right\}$. 第 2 列贡献了另一条直线，这条直线是 $\left\{\begin{bmatrix}c_2&c_2&0&0\end{bmatrix}^{\mathrm{T}}:c_2\in\mathbb{R}\right\}$. 任取 $c_1$、$c_2$，把 $\begin{bmatrix}c_1&0&0&0\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}c_2&c_2&0&0\end{bmatrix}^{\mathrm{T}}$ 加起来，就得到了一个 $\mathbb{R}^4$ 中的一个二维平面. 这个平面是由 $\boldsymbol{A}_4$ 的前两列 张成的平面.

刚考虑了前两列，这仅仅是“开胃小菜”. 线性代数的一个重要原则就是“继续前进，不要停止”. 剩下来的两列给了 $\mathbb{R}^4$ 中两个额外的方向，这 4 列是线性无关的. 最终，由式(1.12)可知：$\mathbb{R}^4$ 中任意元素都是 $\boldsymbol{A}_4$ 中列向量的线性组合. 所以 $\boldsymbol{A}_4$ 的列空间就是整个 $\mathbb{R}^4$.

当我们用同样的方法去处理 $\boldsymbol{A}_5$ 时，对前 3 列的处理运行良好，但是第 4 列是前 3 列的线性组合，所以前 3 列给出了 $\mathbb{R}^4$ 中的一个 三维子空间，而第 4 列恰好在这个子空间中.

这个三维子空间就是 $\boldsymbol{A}_5$ 的整个列空间 $\mathcal{C}(\boldsymbol{A}_5)$. 只有对 $\boldsymbol{v}\in\mathcal{C}(\boldsymbol{A}_5)$，方程组 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{v}$ 才有解. 矩阵 $\boldsymbol{A}_5$ 只有 3 个线性无关的列向量.

我们始终用 $\mathcal{C}(\boldsymbol{A})$ 来表示 $\boldsymbol{A}$ 的列空间. 如果 $\boldsymbol{A}$ 有 $m$ 行，它的列向量都是 $\mathbb{R}^m$ 中的元素. 它的列空间可能是整个 $\mathbb{R}^m$ 也可能不是. 对于 $m=3$，下面给出了 $\mathcal{C}(\boldsymbol{A})\subseteq\mathbb{R}^3$ 的所有 4 种可能性：

| | | |
|---|---|---|
| 1. | 整个 $\mathbb{R}^3$ | $\boldsymbol{A}$ 有 3 个线性无关的列向量 |
| 2. | $\mathbb{R}^3$ 中过原点 $(0,0,0)$ 的平面 | $\boldsymbol{A}$ 只有 2 个线性无关的列向量 |
| 3. | $\mathbb{R}^3$ 中过原点 $(0,0,0)$ 的直线 | $\boldsymbol{A}$ 只有 1 个线性无关的列向量 |
| 4. | $\mathbb{R}^3$ 中的单点：$(0,0,0)$ | $\boldsymbol{A}$ 是零矩阵 |

对应于这 4 种情况，我们分别举一个简单的例子：

$\begin{bmatrix}1&0&0\\0&1&0\\0&0&1\end{bmatrix}$ $\mathcal{C}(\boldsymbol{A})=\mathbb{R}^3=xyz$空间　　$\begin{bmatrix}1&0&0\\0&1&0\\0&0&0\end{bmatrix}$ $\mathcal{C}(\boldsymbol{A})=xy$平面　　$\begin{bmatrix}1&0&0\\0&0&0\\0&0&0\end{bmatrix}$ $\mathcal{C}(\boldsymbol{A})=x$轴　　$\begin{bmatrix}0&0&0\\0&0&0\\0&0&0\end{bmatrix}$ $\mathcal{C}(\boldsymbol{A})=\{(0,0,0)\}$

**作者按.** “列空间”这个术语在第 5 版的第 1 章中并未出现，因为我原来的想法是“空间”这个概念这么早就出现无法体现它的重要性. 但是我现在认为，要充分理解这么重要的概念，就必须尽早出现、大量重复. 当然了，在我们最初接触这个概念时，多研究一些例子远比讲述定义更为有效. 不仅在数学中如此，生活亦如此.

接下来，我要提一系列问题，来帮助我们更好地理解矩阵 $\boldsymbol{A}$. 1.4 节将会给出这些问题完整的解答或关键之处.

（1）$\boldsymbol{A}$ 有多少个线性无关的列向量？这个个数 $r$ 称作 $\boldsymbol{A}$ 的秩.

（2）能不能找出最靠前的 $r$ 个线性无关的列向量？它们组成列空间的一组基.

（3）这 $r$ 个向量组成的“基”如何表达出剩余的 $n-r$ 个列向量？

（4）能否把任意 $m\times n$ 矩阵 $\boldsymbol{A}$ 写成一个 $m\times r$ 矩阵 $\boldsymbol{C}$ 和一个 $r\times n$ 矩阵 $R$ 的乘积：$\boldsymbol{A}=\boldsymbol{CR}$?

（5）（令人震惊的事实!）$\boldsymbol{R}$ 的 $r$ 个行向量构成了 $\boldsymbol{A}$ 的行空间的一组基.

1.4 节我们将要解释，如何把矩阵 $\boldsymbol{C}$ 和 $\boldsymbol{R}$ 乘起来得到 $\boldsymbol{A}=\boldsymbol{CR}$. $\boldsymbol{C}$ 由 $\boldsymbol{A}$ 的一些列向量组成；但是 $\boldsymbol{R}$ 的行向量并不能一眼就从 $\boldsymbol{A}$ 直接看出来.

### 1.3.2 秩 1 矩阵

我们来研究一下构建矩阵的基本模块. 开宗明义，**任意秩为 $r$ 的矩阵都可以写成 $r$ 个秩 1 矩阵的和.** 秩 1 矩阵的列向量同处一条直线，这条过原点 $(0,0,0)$ 的直线就是该秩 1 矩阵的列空间.

**例 1.13** $\boldsymbol{A}_6=\begin{bmatrix}1&3&-2\\4&12&-8\\2&6&-4\end{bmatrix}$ 是秩 1 矩阵，所有列向量都有相同的方向. 设第 1 列为 $\boldsymbol{a}_1=\begin{bmatrix}1&4&2\end{bmatrix}^{\mathrm{T}}$，它的第 2、3 列分别是 $3\boldsymbol{a}_1$、$-2\boldsymbol{a}_1$. 列空间 $C(\boldsymbol{A}_6)=\left\{c\boldsymbol{a}_1=\begin{bmatrix}c&4c&2c\end{bmatrix}^{\mathrm{T}}:c\in\mathbb{R}\right\}$ 是一条直线.

如果你已经注意到并仔细观察了 $\boldsymbol{A}_6$ 的行向量，那么你还会发现关于秩 1 矩阵 $\boldsymbol{A}$ 的一个精妙的事实. **$m\times n$ 矩阵 $\boldsymbol{A}$ 的所有行向量都是某一行的倍数. 当 $\boldsymbol{A}$ 的列空间是 $\mathbb{R}^m$ 中的一条直线时，它的行空间是 $\mathbb{R}^n$ 中的一条直线.** 矩阵 $\boldsymbol{A}_6$ 的行向量都是_____ 的倍数.

$\boldsymbol{A}_6$ 这样的矩阵提出了一个基本的问题：为什么一个矩阵的所有列向量方向都相同时，所有的行向量方向也相同？要寻找这个问题的答案，我们还是从简单的例子开始，比如说 $2\times 2$ 矩阵. 假设第 2 列是第 1 列的 $m$ 倍：

$$\boldsymbol{A}=\begin{bmatrix}a&ma\\b&mb\end{bmatrix}\text{，它的第 2 行是第 1 行的倍数吗？}$$

当然是！它的第 2 行 $\begin{bmatrix}b&mb\end{bmatrix}^{\mathrm{T}}$ 是第 1 行 $\begin{bmatrix}a&ma\end{bmatrix}^{\mathrm{T}}$ 的 $\dfrac{b}{a}$ 倍. 如果它的列秩是 1，那么行秩也是 1. 为了完备性，我们还需要考虑 $a=0$ 的情形，此时，第 1 行 $=\begin{bmatrix}0&0\end{bmatrix}^{\mathrm{T}}=0\cdot$ 第 2 行.

$2\times 2$ 矩阵的情形已经完整解决了，接下来看一下 $3\times 3$ 矩阵的情形. 设 $a\neq 0$，

$$\boldsymbol{A}=\begin{bmatrix} a & ma & pa \\ b & mb & pb \\ c & mc & pc \end{bmatrix}\quad \begin{array}{l} \text{第 2 列 } = m\times \text{ 第 1 列} \\ \text{第 3 列 } = p\times \text{ 第 1 列} \\ \text{第 2(3) 行 } = \dfrac{b}{a}\left(\dfrac{c}{a}\right)\times \text{ 第 1 行} \end{array}$$

这个矩阵只有一个线性无关的列向量. $\boldsymbol{A}$ 的行向量呢，它的第 2 行是否为第 1 行的倍数呢？是的！它的第 3 行是否为第 1 行的倍数呢？是的！因此*列秩是 1 则行秩也是 1* 的规律对于 $3\times 3$ 矩阵也成立.

从秩 1 矩阵推广至一般矩阵，我们可以进行这样的猜测：**对任意矩阵，行秩都等于列秩.** 若 $\boldsymbol{A}$ 有 $r$ 个线性无关的列向量，那么它就有 $r$ 个线性无关的行向量. 这是多么精妙！

我坚信，这是线性代数中第一个重大的定理. 但是限于知识储备，目前我们只知道这对于秩 1 矩阵是成立的. 在 1.4 节中，我们将要学习矩阵乘法，并且最终把我们引向光明的彼岸：理解对任意矩阵都有“行秩 = 列秩”.

## 习题 1.3

本节我们学习了列空间，但是我们还没有涉及如何系统地计算一组列向量的线性相关性或者线性无关性. 所以本节的习题中所有矩阵都是分量为具体数字的低阶矩阵.

1. 描述下列矩阵的列空间：它是整个 $\mathbb{R}^3$，还是其中的一个平面、一条直线或者单点?

$$\boldsymbol{A}_1=\begin{bmatrix} 2 & 2 \\ 1 & 1 \\ 5 & 6 \end{bmatrix}\quad \boldsymbol{A}_2=\begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 1 \end{bmatrix}\quad \boldsymbol{A}_3=\begin{bmatrix} 1 & 5 \\ 2 & 10 \\ 1 & 5 \end{bmatrix}\quad \boldsymbol{A}_4=\begin{bmatrix} 0 & 0 \\ 0 & 0 \\ 0 & 0 \end{bmatrix}$$

2. 用下列矩阵的列向量线性组合出 $\begin{bmatrix} 0 & 0 & 0 \end{bmatrix}^{\mathrm{T}}$，并说明它们的列空间是一个平面. 注意：平凡的线性组合（线性组合的系数都是 0）是不允许的.

哪一列是它前面列的线性组合?

$$\boldsymbol{A}_1=\begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}\qquad \boldsymbol{A}_2=\begin{bmatrix} 1 & 4 & 7 \\ 2 & 5 & 8 \\ 3 & 6 & 9 \end{bmatrix}$$

3. 描述矩阵 $\boldsymbol{B}$、$\boldsymbol{C}$ 的列空间.

$$\boldsymbol{B}=\begin{bmatrix} 1 & 2 \\ 2 & 1 \\ 3 & 3 \end{bmatrix}\quad \boldsymbol{C}=\begin{bmatrix} \boldsymbol{B} & -\boldsymbol{B} \end{bmatrix}\ (3\text{ 行 }4\text{ 列})$$

4. 用点积（例如 $\boldsymbol{A}$ 的行向量 $\cdot\boldsymbol{x}$）来计算 $\boldsymbol{Ax}$、$\boldsymbol{By}$、$\boldsymbol{Cz}$：

$$\boldsymbol{Ax}=\begin{bmatrix} 2 & 1 & 2 \\ 4 & 2 & 4 \\ 0 & 1 & 1 \end{bmatrix}\begin{bmatrix} 1 \\ 2 \\ 5 \end{bmatrix}\qquad \boldsymbol{By}=\begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 1 \end{bmatrix}\begin{bmatrix} 4 \\ 4 \\ 10 \end{bmatrix}\qquad \boldsymbol{Cz}=\begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}\begin{bmatrix} z_1 \\ z_2 \\ z_3 \end{bmatrix}$$

5. 记号同第 4 题，用列向量线性组合的方法，重新计算 $\boldsymbol{Ax}$、$\boldsymbol{By}$、$\boldsymbol{Cz}$，例如：$\boldsymbol{Ax}=$ 1(第 1 列) + 2(第 2 列) + 5(第 3 列).

6. $\boldsymbol{A}$、$\boldsymbol{B}$ 同第 4 题，$\boldsymbol{A}$ 有几个线性无关的列向量？$\boldsymbol{B}$ 有几个线性无关的列向量？$\boldsymbol{A}+\boldsymbol{B}$ 有几个线性无关的列向量？

7. 你能否找到都恰有两个线性无关的列向量的两个矩阵 $\boldsymbol{A}$、$\boldsymbol{B}$，使得 $\boldsymbol{A}+\boldsymbol{B}$

（1）恰有 1 个线性无关的列向量;

（2）没有线性无关的列向量;

（3）恰有 4 个线性无关的列向量.

8. 矩阵的列空间由它的列向量的所有线性组合组成. 作为 $\mathbb{R}^3$ 的子空间，刻画矩阵 $\boldsymbol{A}$、$\boldsymbol{B}$、$\boldsymbol{C}$ 的列空间

$$\boldsymbol{A}=\begin{bmatrix}1&0&0\\0&1&0\\0&0&1\end{bmatrix}\qquad \boldsymbol{B}=\begin{bmatrix}2&4\\1&2\\2&4\end{bmatrix}\qquad \boldsymbol{C}=\begin{bmatrix}1&0&1&2\\0&2&2&4\\0&2&2&4\end{bmatrix}$$

9. 找出一个 $3\times 3$ 矩阵 $\boldsymbol{A}$ 满足：它的所有 9 个元素都属于 $\{1,2\}$ 且 3 个列向量线性无关. 当 $\boldsymbol{A}$ 的 3 个列向量线性无关时，它的 9 个元素中至多有几个 1?

10. 假设 $\boldsymbol{A}$、$\boldsymbol{B}$ 都是秩 1 矩阵，请在它们的空余位置处填上正确的数字.

$$\boldsymbol{A}=\begin{bmatrix}3&\\5&15\end{bmatrix}\qquad \boldsymbol{B}=\begin{bmatrix}1&2&-5\\4&&\end{bmatrix}$$

$\boldsymbol{A}$、$\boldsymbol{B}$ 的列空间分别是什么？它们的行空间分别是什么？

11. 设 $\boldsymbol{A}$ 是一个 $5\times 2$ 矩阵，两个列向量是 $\boldsymbol{a}_1$、$\boldsymbol{a}_2$. 增加一列，我们得到 $5\times 3$ 矩阵 $\boldsymbol{B}$. 当下列条件中的哪一个成立时，$\boldsymbol{A}$、$\boldsymbol{B}$ 有相同的列空间？

（1）新增的列是零向量.

（2）新增的列是 $\begin{bmatrix}1&1&1&1&1\end{bmatrix}^{\mathrm{T}}$.

（3）新增的列是 $\boldsymbol{a}_2-\boldsymbol{a}_1$.

12. 本习题的目的是理解

方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 的解存在当且仅当 $\boldsymbol{b}$ 属于 $\boldsymbol{A}$ 的列空间.

事实上，解方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 无非是把 $\boldsymbol{b}$ 表达成 $\boldsymbol{A}$ 的列向量的线性组合. 当 $\boldsymbol{b}$ 分别等于 $\begin{bmatrix}4\\6\end{bmatrix}$、$\begin{bmatrix}-2\\-2\end{bmatrix}$、$\begin{bmatrix}1\\1\end{bmatrix}$ 时，方程组 $\begin{bmatrix}1&3\\2&4\end{bmatrix}\boldsymbol{x}=\boldsymbol{b}$ 的解是什么？

13. 构造两个 $3\times 3$ 矩阵 $\boldsymbol{A}$、$\boldsymbol{B}$，使得它们的列空间同时都是与向量 $\begin{bmatrix}1&1&1\end{bmatrix}^{\mathrm{T}}$ 垂直的向量构成的平面. 通常来说，$\boldsymbol{A}+\boldsymbol{B}$ 的列空间是什么？

14. 当 $q$ 满足什么条件时，以下矩阵 $\boldsymbol{A}$ 恰有两个线性无关的列向量？

$$\boldsymbol{A}=\begin{bmatrix}1&0&2\\3&1&9\\5&0&q\end{bmatrix}\qquad \boldsymbol{A}=\begin{bmatrix}1&4&7\\2&5&8\\3&6&q\end{bmatrix}\qquad \boldsymbol{A}=\begin{bmatrix}1&1&2\\2&2&4\\0&0&q\end{bmatrix}$$

15. 假设 $\boldsymbol{Ax}=\boldsymbol{b}$，如果我们把 $\boldsymbol{b}$ 添加到 $\boldsymbol{A}$ 的右边得到新的矩阵 $\boldsymbol{B}$，请说明为什么 $\boldsymbol{B}$ 的秩 $r$（线性无关的列向量的个数）和 $\boldsymbol{A}$ 的秩相同.

16. 判断正误，正确请简述理由，错误请举出反例.

（1）若两个 $5\times 2$ 矩阵 $\boldsymbol{A}$、$\boldsymbol{B}$ 的列向量分别都线性无关，则 $\boldsymbol{A}+\boldsymbol{B}$ 的列向量也线性无关.

（2）若一个 $m\times n$ 矩阵有 $n$ 个线性无关的列向量，那么 $m\geqslant n$.

（3）随机的 $3\times 3$ 矩阵几乎一定有 3 个线性无关的列向量.[①]

17. 若 $\boldsymbol{A}$、$\boldsymbol{B}$ 都是秩 1 矩阵，那么 $\boldsymbol{A}+\boldsymbol{B}$ 的秩有哪几种可能？对每种可能的情形分别举一例. $\boldsymbol{A}+\boldsymbol{B}$ 的秩可能是 4 吗？

18. 我们把列向量 $\boldsymbol{s}_1=\begin{bmatrix}1\\1\\1\end{bmatrix}$、$\boldsymbol{s}_2=\begin{bmatrix}0\\1\\1\end{bmatrix}$、$\boldsymbol{s}_3=\begin{bmatrix}0\\0\\1\end{bmatrix}$ 排在一起构成矩阵 $\boldsymbol{S}$. 设 $3\boldsymbol{s}_1+4\boldsymbol{s}_2+5\boldsymbol{s}_3=\boldsymbol{b}$. 那么我们可以把 $\boldsymbol{b}$ 写成矩阵和列向量的乘法：$\boldsymbol{b}=\boldsymbol{Sx}$，其中 $\boldsymbol{x}=\begin{bmatrix}3\\4\\5\end{bmatrix}$. 请计算 $\boldsymbol{S}$ 的行向量和 $\boldsymbol{x}$ 的点积.

19. 若 $a$、$b$、$c$、$d$ 是 4 个非零实数，且向量 $\begin{bmatrix}a & b\end{bmatrix}^{\mathrm{T}}$ 是 $\begin{bmatrix}c & d\end{bmatrix}^{\mathrm{T}}$ 的倍数，证明：$\begin{bmatrix}a & c\end{bmatrix}^{\mathrm{T}}$ 是 $\begin{bmatrix}b & d\end{bmatrix}^{\mathrm{T}}$ 的倍数.

这也是令人吃惊的事实：两个列向量共线. 我们也可以先用具体的数字举例观察，来看一下 $a$、$b$、$c$、$d$ 是怎么联系起来的. 这个题目说明了如下事实

$$\text{若}\begin{bmatrix}a & b\\c & d\end{bmatrix}\text{的行向量线性相关，那么它的列向量也线性相关.}$$

20. 设 $\boldsymbol{S}$ 是 3 阶求和矩阵[②]，解下列方程 $\boldsymbol{Sy}=\boldsymbol{b}$:

$$\begin{bmatrix}1&0&0\\1&1&0\\1&1&1\end{bmatrix}\begin{bmatrix}y_1\\y_2\\y_3\end{bmatrix}=\begin{bmatrix}1\\1\\1\end{bmatrix}\quad\text{和}\quad\begin{bmatrix}1&0&0\\1&1&0\\1&1&1\end{bmatrix}\begin{bmatrix}y_1\\y_2\\y_3\end{bmatrix}=\begin{bmatrix}1\\4\\9\end{bmatrix}$$

前 3 个奇数的和是_____，前 10 个奇数的和是_____.

21. $\boldsymbol{S}$ 是求和矩阵，解线性方程组 $\boldsymbol{Sy}=\boldsymbol{c}$，即用 $c_1$、$c_2$、$c_3$ 来表示 $y_1$、$y_2$、$y_3$:

$$\boldsymbol{Sy}=\boldsymbol{c}\qquad\begin{bmatrix}1&0&0\\1&1&0\\1&1&1\end{bmatrix}\begin{bmatrix}y_1\\y_2\\y_3\end{bmatrix}=\begin{bmatrix}c_1\\c_2\\c_3\end{bmatrix}$$

我们把 $\boldsymbol{y}$ 写成矩阵 $\boldsymbol{A}$ 和向量 $\boldsymbol{c}$ 相乘；那么 $\boldsymbol{A}$ 是 $\boldsymbol{S}$ 的“逆矩阵” $\boldsymbol{S}^{-1}$. $\boldsymbol{S}$ 的列向量是线性相关的还是无关的？

---

① 译者注：“几乎一定”的意思是“以概率 1 成立”.

② 译者注：$n$ 阶求和矩阵 $\boldsymbol{S}$ 是指下三角元素全是 1 的下三角矩阵；它之所以被称作“求和矩阵”是因为 $\boldsymbol{Sx}$ 的第 $k$ 个分量是 $\boldsymbol{x}$ 的前 $k$ 个分量之和.

22. 下面的 3 阶方阵 $\boldsymbol{A}$ 的行向量线性相关，那么线性代数的理论告诉我们它的列向量也线性相关. 请找一个非零向量 $\boldsymbol{x}$ 使之符合方程 $\boldsymbol{Ax}=\boldsymbol{0}$:

$$\boldsymbol{A}=\begin{bmatrix}1 & 2 & 3\\ 3 & 5 & 6\\ 4 & 7 & 8\end{bmatrix}$$

第 1 行 + 第 2 行 = 第 3 行

$\boldsymbol{A}$ 只有两个线性无关的行向量

因此只有两个线性无关的列向量

23. 求 $c$ 使得下列矩阵的列向量线性相关；进而把零向量表示成它们列向量的一个非平凡的线性组合.

$$\begin{bmatrix}1 & 1 & 0\\ 3 & 2 & 1\\ 7 & 4 & c\end{bmatrix}\qquad\begin{bmatrix}1 & 0 & c\\ 1 & 1 & 0\\ 0 & 1 & 1\end{bmatrix}\qquad\begin{bmatrix}c & c & c\\ 2 & 1 & 5\\ 3 & 3 & 6\end{bmatrix}\qquad\begin{bmatrix}c & 1\\ 4 & c\end{bmatrix}$$

24. 设 $\boldsymbol{A}=\begin{bmatrix}\boldsymbol{a}_1 & \boldsymbol{a}_2 & \boldsymbol{a}_3\end{bmatrix}=\begin{bmatrix}\boldsymbol{r}_1\\ \boldsymbol{r}_2\\ \boldsymbol{r}_3\end{bmatrix}$，若它的列向量的一个非平凡线性组合是零向量：$\boldsymbol{Ax}=\boldsymbol{0}$，那么 $\boldsymbol{A}$ 的每一行和 $\boldsymbol{x}$ 的点积都是 0:

$$\text{若}\begin{bmatrix}\boldsymbol{a}_1 & \boldsymbol{a}_2 & \boldsymbol{a}_3\end{bmatrix}\begin{bmatrix}x_1\\ x_2\\ x_3\end{bmatrix}=\begin{bmatrix}0\\ 0\\ 0\end{bmatrix}\quad\text{则}\begin{bmatrix}\boldsymbol{r}_1\cdot\boldsymbol{x}\\ \boldsymbol{r}_2\cdot\boldsymbol{x}\\ \boldsymbol{r}_3\cdot\boldsymbol{x}\end{bmatrix}=\begin{bmatrix}0\\ 0\\ 0\end{bmatrix}$$

$\boldsymbol{A}$ 的三个行向量在同一个平面内；为什么这个平面和 $\boldsymbol{x}$ 垂直？

## 1.4 矩阵乘法 $AB$ 和 $CR$

（1）矩阵 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 可以相乘的前提是矩阵 $\boldsymbol{A}$ 的列数等于矩阵 $\boldsymbol{B}$ 的行数.
（2）矩阵 $\boldsymbol{AB}$ 的第 $i$ 行、第 $j$ 列元素是（$\boldsymbol{A}$ 的第 $i$ 行）·（$\boldsymbol{B}$ 的第 $j$ 列）.
（3）按列来看，$\boldsymbol{AB}$ 的第 $j$ 列为 $\boldsymbol{A}$ 乘以 $\boldsymbol{B}$ 的第 $j$ 列.
（4）通常来说，$\boldsymbol{AB}\neq\boldsymbol{BA}$，但始终有 $(\boldsymbol{AB})\boldsymbol{C}=\boldsymbol{A}(\boldsymbol{BC})$.
（5）若 $\boldsymbol{A}$ 恰好有 $r$ 个线性无关的列向量，它们组成 $m\times r$ 矩阵 $\boldsymbol{C}$，那么存在 $r\times n$ 矩阵 $\boldsymbol{R}$ 使得 $\boldsymbol{A}=\boldsymbol{CR}$.

在前面的章节中，我们已经知道如何做矩阵 $\boldsymbol{A}$ 和列向量 $\boldsymbol{x}$ 或者 $\boldsymbol{b}$ 的乘积. 本节中考虑矩阵与矩阵的乘积：矩阵 $\boldsymbol{A}$ 乘以矩阵 $\boldsymbol{B}$. 这个新的运算基于矩阵与向量的乘积：将 $\boldsymbol{A}$ 乘以 $\boldsymbol{B}$ 的每一列就得到了 $\boldsymbol{AB}$ 的每一列；因此若 $\boldsymbol{B}$ 有 $p$ 列，则 $\boldsymbol{AB}$ 也有 $p$ 列

$\boldsymbol{AB}$ 的第 $j$ 列等于 $\boldsymbol{A}$ 乘以 $\boldsymbol{B}$ 的第 $j$ 列

若 $\boldsymbol{B}=\begin{bmatrix}\boldsymbol{b}_1 & \cdots & \boldsymbol{b}_p\end{bmatrix}$，则 $\boldsymbol{AB}=\begin{bmatrix}\boldsymbol{Ab}_1 & \cdots & \boldsymbol{Ab}_p\end{bmatrix}$ (1.13)

下面是一个简单的例子. 设 $\boldsymbol{B}$ 为 $2\times 2$ “对换矩阵”. 那么 $\boldsymbol{B}$ 有两列 $\boldsymbol{b}_1$ 和 $\boldsymbol{b}_2$. 将 $\boldsymbol{A}$ 乘以每一列就可得到 $\boldsymbol{AB}$ 的每一列.

$$\boldsymbol{Ab}_1=\begin{bmatrix}1&2\\3&4\end{bmatrix}\begin{bmatrix}0\\1\end{bmatrix}=\begin{bmatrix}2\\4\end{bmatrix},\qquad \boldsymbol{Ab}_2=\begin{bmatrix}1&2\\3&4\end{bmatrix}\begin{bmatrix}1\\0\end{bmatrix}=\begin{bmatrix}1\\3\end{bmatrix},\qquad \boldsymbol{AB}=\begin{bmatrix}1&2\\3&4\end{bmatrix}\begin{bmatrix}0&1\\1&0\end{bmatrix}=\begin{bmatrix}2&1\\4&3\end{bmatrix}$$

对这个矩阵 $\boldsymbol{B}$，$\boldsymbol{AB}$ 的运算效果是将 $\boldsymbol{A}$ 的两列互换了位置.

再例如，我们拿同一个矩阵 $\boldsymbol{A}$ 乘以另一个不同的 $2\times 2$ 矩阵 $\boldsymbol{B}$:

$$\begin{bmatrix}1&2\\3&4\end{bmatrix}\begin{bmatrix}5&6\\7&8\end{bmatrix}\text{ 的第一列为 }\boldsymbol{Ab}_1=\begin{bmatrix}1&2\\3&4\end{bmatrix}\begin{bmatrix}5\\7\end{bmatrix},\text{ 第 2 列为 }\boldsymbol{Ab}_2=\begin{bmatrix}1&2\\3&4\end{bmatrix}\begin{bmatrix}6\\8\end{bmatrix}$$

矩阵乘法的一个关键点是如何计算. 我们知道可以通过行或者列两种方式来计算 $\boldsymbol{Ab}_1$，比如可以用 $\boldsymbol{b}_1$ 和 $\boldsymbol{A}$ 的每一行作点积：

行向量的角度
点积

$$\boldsymbol{Ab}_1=\begin{bmatrix}1&2\\3&4\end{bmatrix}\begin{bmatrix}5\\7\end{bmatrix}=\begin{bmatrix}\text{第 1 行}\cdot\boldsymbol{b}_1\\\text{第 2 行}\cdot\boldsymbol{b}_1\end{bmatrix}=\begin{bmatrix}1\cdot 5+2\cdot 7\\3\cdot 5+4\cdot 7\end{bmatrix}=\begin{bmatrix}19\\43\end{bmatrix}\tag{1.14}$$

还可以通过 $\boldsymbol{A}$ 的列向量的线性组合来计算 $\boldsymbol{Ab}_1$. 得到的结果是一样的：

列向量的角度
线性组合

$$\boldsymbol{Ab}_1=\begin{bmatrix}1&2\\3&4\end{bmatrix}\begin{bmatrix}5\\7\end{bmatrix}=5\begin{bmatrix}1\\3\end{bmatrix}+7\begin{bmatrix}2\\4\end{bmatrix}=\begin{bmatrix}5\\15\end{bmatrix}+\begin{bmatrix}14\\28\end{bmatrix}=\begin{bmatrix}19\\43\end{bmatrix}\tag{1.15}$$

虽然这两种方法都进行了 4 次乘法运算，但是多数人还是会选择利用行来计算，即 **利用 $\boldsymbol{A}$ 的每一行和 $B$ 的每一列作点积来计算 $\boldsymbol{AB}$**. 当 $\boldsymbol{A}$ 有 2 行而 $\boldsymbol{B}$ 有 2 列时，需要 4 次点积.

当 $\boldsymbol{A}$ 是 $m\times n$ 矩阵，$\boldsymbol{B}$ 是 $n\times p$ 矩阵时，$\boldsymbol{AB}$ 是 $m\times p$ 矩阵. 那么我们需要作 $mp$ 次点积.

行向量
$\boldsymbol{A}$ 的行

$$\boldsymbol{AB}=\begin{bmatrix}\text{第 1 行}\cdot\text{第 1 列}&\text{第 1 行}\cdot\text{第 2 列}\\\text{第 2 行}\cdot\text{第 1 列}&\text{第 2 行}\cdot\text{第 2 列}\end{bmatrix}=\begin{bmatrix}19&22\\43&50\end{bmatrix}\tag{1.16}$$

现在我们通过列，也就是 $\boldsymbol{A}$ 的列向量的线性组合来计算 $\boldsymbol{AB}$. 这是对向量作整体的操作，从而得到 $\boldsymbol{AB}$ 的每一列. 式(1.15)给出了第一列，用 $\boldsymbol{A}$ 乘以 $\boldsymbol{b}_2$ 就可以得到 $\boldsymbol{AB}$ 的第二列为 $\begin{bmatrix}22\\50\end{bmatrix}$:

列向量的线性组合
来计算$\boldsymbol{Ab}_2$

$$\boldsymbol{Ab}_2=\begin{bmatrix}1&2\\3&4\end{bmatrix}\begin{bmatrix}6\\8\end{bmatrix}=6\begin{bmatrix}1\\3\end{bmatrix}+8\begin{bmatrix}2\\4\end{bmatrix}=\begin{bmatrix}6\\18\end{bmatrix}+\begin{bmatrix}16\\32\end{bmatrix}=\begin{bmatrix}22\\50\end{bmatrix}\tag{1.17}$$

式(1.15)和式(1.17)给出的 $\boldsymbol{AB}$ 的两列和式(1.16)给出的是一致的. 这两种方法都用了 8 次乘法运算，只是顺序不一样. 注意，我们忽略了加法运算. 我们可以计算一下 $m\times n$ 矩阵 $\boldsymbol{A}$ 乘以 $n\times p$ 矩阵 $\boldsymbol{B}$ 所需的乘法的运算量. 再次提醒: $\boldsymbol{AB}$ 是 $m\times p$ 矩阵.

（行向量的角度） $\boldsymbol{AB}$ 需要 $mp$ 次点积运算，每次点积需要运算 $n$ 次乘法，共需 $mnp$ 次乘法运算；
（列向量的角度） $\boldsymbol{AB}$ 有 $p$ 列, 每一列需要 $mn$ 次乘法运算，共需 $mnp$ 次乘法运算.

实际的计算速度和矩阵的存储方式有关. 通常矩阵会按列进行存储. 一般情况下调用大块的矩阵会比一个个单独的数要快. 在大型运算中, 利用 BLAS3(第三级基本线性代数子程序) 进行矩阵-矩阵操作是最佳的.

至此，我们已经讨论了从 (行)·(列)（点积）以及 (矩阵)(列) 两个角度来理解 $\boldsymbol{AB}$. 另外还有两种方法 (行)(矩阵) 以及 (列)(行). 这四种方法也都需要 $mnp$ 次乘法运算，只是运算次序不同.

如果 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 都为 $2\times 2$ 矩阵，那么需要 $n^3=8$ 次运算来得到 $\boldsymbol{AB}$.[①]

### 1.4.1 通常来说 $\boldsymbol{AB}\neq\boldsymbol{BA}$

对 $\boldsymbol{B}=\begin{bmatrix}0&1\\1&0\end{bmatrix}$，$\boldsymbol{AB}$为互换 $\boldsymbol{A}$ 的两列得到的矩阵，而 $\boldsymbol{BA}$ 是互换了 $\boldsymbol{A}$ 的两行得到的矩阵!

$$\boldsymbol{AB}=\begin{bmatrix}2&1\\4&3\end{bmatrix}\qquad\boldsymbol{BA}=\begin{bmatrix}0&1\\1&0\end{bmatrix}\begin{bmatrix}1&2\\3&4\end{bmatrix}=\begin{bmatrix}3&4\\1&2\end{bmatrix}\tag{1.18}$$

这个简单的例子就说明了，通常矩阵的乘积运算不是可交换的: $\boldsymbol{BA}\neq\boldsymbol{AB}$. 在 $\boldsymbol{A}$ 的左边乘 $\boldsymbol{B}$ 是对 $\boldsymbol{A}$ 的行进行操作，而在右边乘 $\boldsymbol{B}$ 是对 $\boldsymbol{A}$ 的列进行操作.

问题. 为什么将对换矩阵平方得到单位矩阵：$\boldsymbol{B}^2=\begin{bmatrix}0&1\\1&0\end{bmatrix}\begin{bmatrix}0&1\\1&0\end{bmatrix}=\boldsymbol{I}$?

### 1.4.2 $(\boldsymbol{AB})\boldsymbol{C}=\boldsymbol{A}(\boldsymbol{BC})$

矩阵乘法的结合律成立. 结合律非常有用，若非万不得已，我们都希望保留这个运算规则. 我们可以先计算 $\boldsymbol{AB}$，也可以先计算 $\boldsymbol{BC}$.

这里 $\boldsymbol{A}$、$\boldsymbol{B}$、$\boldsymbol{C}$ 的顺序是保持不变的, 所以它们的大小应该满足矩阵乘法的运算要求：

$\boldsymbol{A}$ 为 $m\times n$ 矩阵，$\boldsymbol{B}$ 为 $n\times p$ 矩阵，$\boldsymbol{C}$ 为 $p\times q$ 矩阵，$\boldsymbol{AB}$ 为 $m\times p$ 矩阵，$(\boldsymbol{AB})\boldsymbol{C}$ 为 $m\times q$ 矩阵.

我们可以用对换矩阵 $\boldsymbol{B}$ 对矩阵 $\boldsymbol{A}$ 的行和列的影响来检验结合律：

$$(\boldsymbol{BA})\boldsymbol{B}=\left(\begin{bmatrix}0&1\\1&0\end{bmatrix}\begin{bmatrix}1&2\\3&4\end{bmatrix}\right)\begin{bmatrix}0&1\\1&0\end{bmatrix}=\begin{bmatrix}3&4\\1&2\end{bmatrix}\begin{bmatrix}0&1\\1&0\end{bmatrix}=\begin{bmatrix}4&3\\2&1\end{bmatrix}$$

$$\boldsymbol{B}(\boldsymbol{AB})=\begin{bmatrix}0&1\\1&0\end{bmatrix}\left(\begin{bmatrix}1&2\\3&4\end{bmatrix}\begin{bmatrix}0&1\\1&0\end{bmatrix}\right)=\begin{bmatrix}0&1\\1&0\end{bmatrix}\begin{bmatrix}2&1\\4&3\end{bmatrix}=\begin{bmatrix}4&3\\2&1\end{bmatrix}$$

这就是说，对 $\boldsymbol{A}$，无论是先作行变换再作列变换，还是先作列变换再作行变换，结果是不变的.

特别需要说明，当 $\boldsymbol{C}$ 仅仅是一个列向量 $\boldsymbol{x}$ 时，$(\boldsymbol{AB})\boldsymbol{C}=\boldsymbol{A}(\boldsymbol{BC})$ 的意义. 如果 $\boldsymbol{x}$ 只在第 $j$ 个分量是 1，其他分量是 0，根据结合律有 $(\boldsymbol{AB})\boldsymbol{x}=\boldsymbol{A}(\boldsymbol{Bx})$. 这就告诉了我们应该如何计算矩阵的乘法：等式左边为 $\boldsymbol{AB}$ 的第 $j$ 列，等式右边为 $\boldsymbol{A}$ 乘以 $\boldsymbol{B}$ 的第 $j$ 列. 所以这一等式正是前面式(1.13)给出的矩阵乘法的定义.

现在，我们总结关于 $\boldsymbol{ABC}$ 以及 $\boldsymbol{A}$ 乘以 $\boldsymbol{B}+\boldsymbol{C}$ 的重要的运算规则:

$$\text{结合律}\quad(\boldsymbol{AB})\boldsymbol{C}=\boldsymbol{A}(\boldsymbol{BC})\qquad\text{分配律}\quad\boldsymbol{A}(\boldsymbol{B}+\boldsymbol{C})=\boldsymbol{AB}+\boldsymbol{AC}\tag{1.19}$$

① 作者注：Strassen 发现对于 $2\times 2$ 矩阵的情况，7 次乘法运算就已经足够得到 $\boldsymbol{AB}$，代价是额外的 1 次加法. 对于 $n\times n$ 矩阵，乘法的计算量为 $n^c$, 其中 $c=\log_2 7$, 而不是通常认为的 $c=\log_2 8=3$. 现在 $c$ 可以降得更低. 当然 $c$ 不可能小于 2, 因为 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 都有 $n^2$ 个元素. 寻找最小的 $c$ 仍然是一个非常难的公开问题.

### 1.4.3　回顾矩阵乘法 $AB$

| | | |
|---|---|---|
| 点积 | ($\boldsymbol{A}$ 的第 $i$ 行)· ($\boldsymbol{B}$ 的第 $j$ 列)= $(\boldsymbol{AB})_{ij}$ | = $\boldsymbol{AB}$ 的第 $i$ 行, 第 $j$ 列位置的分量 |
| 列的线性组合 | (矩阵 $\boldsymbol{A}$)($\boldsymbol{B}$ 的第 $j$ 列 $\boldsymbol{b}_j$) | = $\boldsymbol{AB}$ 的第 $j$ 列 |

从每一个分量的角度来看，$mp$ 次点积运算可以得到 $m \times p$ 矩阵 $\boldsymbol{AB}$.

从列向量的角度来看（从某种程度而言，这是更高的观点），$p$ 个线性组合 $\boldsymbol{Ab}_j$ 即 $\boldsymbol{AB}$ 的 $p$ 个列向量.

在具体手算时, 我会选择行的方式来计算 $\boldsymbol{AB}$. 但是当我在脑海中构建矩阵乘法时，我会通过列的线性组合来理解：$\boldsymbol{AB}$ 的列 $\boldsymbol{Ab}_j$ 为 $\boldsymbol{A}$ 的列的线性组合.

### 1.4.4　秩 1 矩阵和 $A = CR$

秩为 1 的矩阵的所有列都在一条线上. 这条线正是 $\boldsymbol{A}$ 的列空间. 1.3 节中的例子给出了一个重要的事实: 所有的行也在一条线上. 换句话说，$\boldsymbol{A}$ 的所有列都在一个方向上, $\boldsymbol{A}$ 的所有行也都在一个方向上. 下面是这种极端情况的一个新例子: 秩 $r = 1$.

例 1.14

$$\boldsymbol{A} = \begin{bmatrix} 1 & 2 & 10 & 100 \\ 3 & 6 & 30 & 300 \\ 2 & 4 & 20 & 200 \end{bmatrix} \quad \begin{array}{l} \text{秩 1 矩阵} \\ = \text{1 个线性无关的列} \\ \text{1 个线性无关的行!} \end{array}$$

所有列向量是 $\begin{bmatrix} 1 & 3 & 2 \end{bmatrix}^{\mathrm{T}}$ 的倍数，而所有行向量都是 $\begin{bmatrix} 1 & 2 & 10 & 100 \end{bmatrix}$ 的倍数. 当矩阵仅有一个线性无关的列向量时，也仅有一个线性无关的行向量. 这种现象是什么原因呢？另外一个例子是: 元素全是 1 的矩阵 =(分量全是 1 的列向量) 乘以（分量全是 1 的行向量）.

我们思考问题的方法就是矩阵乘法. 将 $\boldsymbol{A}$ 分解为 $\boldsymbol{C}$ 乘以 $\boldsymbol{R}$. 在上面这个特殊的例子中, $\boldsymbol{C}$ 只有一列, $\boldsymbol{R}$ 只有一行. $\boldsymbol{CR}$ = (3 × 1矩阵)(1 × 4矩阵).

$$\text{秩} = 1 \qquad \boldsymbol{A} = \begin{bmatrix} 1 & 2 & 10 & 100 \\ 3 & 6 & 30 & 300 \\ 2 & 4 & 20 & 200 \end{bmatrix} = \begin{bmatrix} 1 \\ 3 \\ 2 \end{bmatrix} \begin{bmatrix} 1 & 2 & 10 & 100 \end{bmatrix} = \boldsymbol{CR} \tag{1.20}$$

点积运算 ($\boldsymbol{C}$的行) · ($\boldsymbol{R}$的列) 是由像 $1 \cdot 1$ 这样的简单运算组成的. 最后一个运算是 $2 \cdot 100$. 对细长条的 $\boldsymbol{C}$ 和 $\boldsymbol{R}$ 逐分量做乘法，经过 12 次简单运算就得到了矩阵 $\boldsymbol{A}$ 的 12 个数.

$\boldsymbol{A}$ 的行向量是分别用 1、3、2 乘以 $\boldsymbol{R}$ 的行 $\begin{bmatrix} 1 & 2 & 10 & 100 \end{bmatrix}$. 这个特殊的分解把 $\boldsymbol{A}$ 写成列向量乘以行向量的形式，那么结论就呼之欲出了：

> 如果 $\boldsymbol{A}$ 的列空间是一条线，那么 $\boldsymbol{A}$ 的行空间也是一条线.

在讨论完 $\boldsymbol{C}$ 仅有一列、$\boldsymbol{R}$ 仅有一行的情况后，接下来我们将要讨论 $\boldsymbol{C}$ 有 $r$ 列时如何找到有 $r$ 行的矩阵 $\boldsymbol{R}$，使得 $\boldsymbol{A} = \boldsymbol{CR}$. 这里的 $r$ 实际上就是 $\boldsymbol{A}$ 的秩.

### 1.4.5 $C$ 由 $A$ 的前 $r$ 个线性无关的列组成

假设我们从左到右逐个寻找 $\boldsymbol{A}$ 的线性无关的列向量：

> 如果 $\boldsymbol{A}$ 的第 1 列非零，那么把它放入 $\boldsymbol{C}$；
> 如果 $\boldsymbol{A}$ 的第 2 列不是第 1 列的倍数，那么把它放入 $\boldsymbol{C}$；
> 如果 $\boldsymbol{A}$ 的第 3 列不是第 1 列和第 2 列的线性组合，那么把它放入 $\boldsymbol{C}$，以此类推.

最后 $\boldsymbol{C}$ 会包括 $\boldsymbol{A}$ 的 $r$ 个列向量. $r$ 是 $A$ 和 $C$ 的秩. $\boldsymbol{A}$ 的 $n$ 个列向量可能是线性相关的，但是 $\boldsymbol{C}$ 的 $r$ 列一定是 线性无关的.

列线性无关 $\quad$ $\boldsymbol{C}$的每一列都不是它前面列向量的线性组合
$\boldsymbol{Cx}=\boldsymbol{0}$只有零解

$\boldsymbol{A}$ 的列向量均可以由 $\boldsymbol{C}$ 的 $r$ 列线性表出.

$\boldsymbol{Cx}=0$ 表示 $x_1(\boldsymbol{C}$的第 1 列$)+x_2(\boldsymbol{C}$的第 2 列$)+\cdots=$零向量$\boldsymbol{0}$. 当 $\boldsymbol{C}$ 的列向量线性无关时，$\boldsymbol{Cx}=0$ 只有零解；否则假设 $x_j\neq 0$ 且 $x_\ell=0(\forall \ell>j)$，将 $\boldsymbol{Cx}=\boldsymbol{0}$ 除以 $x_j$，则 $\boldsymbol{C}$ 的第 $j$ 列就可以表示为前面的列向量的线性组合，和我们的条件矛盾；因此 $\boldsymbol{C}$ 的列向量总是线性无关的.

**例 1.15** 若 $\boldsymbol{A}=\begin{bmatrix}2&6&4\\4&12&8\\1&3&5\end{bmatrix}$，按照我们的构造方法，$\boldsymbol{C}=\begin{bmatrix}2&4\\4&8\\1&5\end{bmatrix}$，秩 $r=2$.

$\boldsymbol{A}$ 的第 1 列和第 3 列构成了 $\boldsymbol{C}$. 第 2 列是第 1 列的 3 倍：它们不是线性无关的，因此不在 $\boldsymbol{C}$ 中.

### 1.4.6 矩阵乘积 $CR$

$R$ 的作用是告诉我们如何由 $C$ 生成 $A$ 的各列，即 $\boldsymbol{A}=\boldsymbol{CR}$. 在下面的例子中，$\boldsymbol{A}$ 的第 1 列就是 $\boldsymbol{C}$ 的第 1 列，那么 $\boldsymbol{R}$ 的第 1 列是 $\begin{bmatrix}1&0\end{bmatrix}^{\mathrm{T}}$. $\boldsymbol{A}$ 的第 3 列就是 $\boldsymbol{C}$ 的第 2 列，所以 $R$ 的第 3 列是 $\begin{bmatrix}0&1\end{bmatrix}^{\mathrm{T}}$.

注意，$\boldsymbol{I}$ 在 $\boldsymbol{R}$ 中
秩$r=2$

$$\boldsymbol{A}=\boldsymbol{CR} \quad \text{为} \quad \begin{bmatrix}2&6&4\\4&12&8\\1&3&5\end{bmatrix}=\begin{bmatrix}2&4\\4&8\\1&5\end{bmatrix}\begin{bmatrix}1&?&0\\0&?&1\end{bmatrix} \tag{1.21}$$

$\boldsymbol{C}$ 由 $\boldsymbol{A}$ 的两列构成，所以 $\boldsymbol{R}$ 的一部分其实就是单位矩阵. 剩下的问题是如何得到 $\boldsymbol{A}$ 的第 2 列，它并不在 $\boldsymbol{C}$ 里. 事实上，第 2 列是第 1 列的 3 倍，所以 $\boldsymbol{R}$ 的第 2 列为 3 和 0.

$\boldsymbol{A}$是$m\times n$矩阵
$\boldsymbol{C}$是$m\times r$矩阵
$\boldsymbol{R}$是$r\times n$矩阵

$$\boldsymbol{A}=\boldsymbol{CR} \quad \text{为} \quad \begin{bmatrix}2&6&4\\4&12&8\\1&3&5\end{bmatrix}=\begin{bmatrix}2&4\\4&8\\1&5\end{bmatrix}\begin{bmatrix}1&3&0\\0&0&1\end{bmatrix} \tag{1.22}$$

这是 $\boldsymbol{A}=\boldsymbol{CR}$ 的典型例子. 我们回顾一下 $\boldsymbol{C}$ 和 $\boldsymbol{R}$ 的描述.

（1）$\boldsymbol{C}$ 包括了 $\boldsymbol{A}$ 一组**线性无关的 $r$ 个列向量**（从左到右地选取）.

（2）$\boldsymbol{R}=\begin{bmatrix}\boldsymbol{I} & \boldsymbol{F}\end{bmatrix}$ 包括了 **单位阵 $\boldsymbol{I}$**；此处并不是说单位阵作为一个整体是 $\boldsymbol{R}$ 的一部分，而是说单位阵的每一列分布在 $\boldsymbol{C}$ 的对应的与 $\boldsymbol{A}$ 相同的 $r$ 列上.[①]

（3）$\boldsymbol{A}$ 余下的 **线性相关的那些列为$\boldsymbol{CF}$**, 即 $\boldsymbol{C}$ 中列向量的线性组合.

矩阵 $\boldsymbol{F}$ 为 $\boldsymbol{R}=\begin{bmatrix}\boldsymbol{I} & \boldsymbol{F}\end{bmatrix}$ 的除 $\boldsymbol{I}$ 外的另外 $n-r$ 列. $\boldsymbol{A}=\boldsymbol{CR}$ 即

$$\boldsymbol{A}=\boldsymbol{C}\begin{bmatrix}\boldsymbol{I} & \boldsymbol{F}\end{bmatrix}=\begin{bmatrix}\boldsymbol{C} & \boldsymbol{CF}\end{bmatrix}=\begin{bmatrix}A\text{线性无关的列} & \boldsymbol{A}\text{的线性相关的列}\end{bmatrix}$$

(在列向量的某个正确的排序下相等)

$\boldsymbol{C}$ 和 $\boldsymbol{A}$ 的 **列空间相同**，$\boldsymbol{R}$ 和 $\boldsymbol{A}$ 的**行空间相同**.

**例 1.16**

$$\begin{matrix}\boldsymbol{A}=\boldsymbol{CR}\\ \text{秩}=2\end{matrix}\qquad \begin{bmatrix}1&2&3\\4&5&6\\7&8&9\end{bmatrix}=\begin{bmatrix}1&2\\4&5\\7&8\end{bmatrix}\begin{bmatrix}1&0&-1\\0&1&2\end{bmatrix} \tag{1.23}$$

这里 $\boldsymbol{F}=\begin{bmatrix}-1\\2\end{bmatrix}$.

当 $\boldsymbol{A}$ 的某一列被选入 $\boldsymbol{C}$ 时，$\boldsymbol{I}$ 的相应的列会出现在 $\boldsymbol{R}$ 的对应位置上.

| $\boldsymbol{A}$ 的第 $j$ 列 $=\boldsymbol{C}$ 乘以（$\boldsymbol{R}$ 的第 $j$ 列）.　　$\boldsymbol{A}$ 的第 $i$ 行 $=$（$\boldsymbol{C}$ 的第 $i$ 行）乘以 $\boldsymbol{R}$. |
|---|

如果 $\boldsymbol{A}$ 的全体列向量是线性无关的，那么 $\boldsymbol{C}=\boldsymbol{A}$, $\boldsymbol{R}$ 是哪个矩阵？ **答案：$\boldsymbol{R}=\boldsymbol{I}$.**

第 1 章我们通过寻找 $\boldsymbol{A}$ 的线性无关的列来构造 $\boldsymbol{C}$, 然后再来求 $\boldsymbol{R}$. 在第 3 章中我们将先构造 $\boldsymbol{R}$. 考察例子

$$\boldsymbol{A}=\begin{bmatrix}1&2&3&4\\1&2&4&5\end{bmatrix}=\begin{bmatrix}1&3\\1&4\end{bmatrix}\begin{bmatrix}1&2&0&1\\0&0&1&1\end{bmatrix}=\boldsymbol{CR}\qquad \text{秩}r=2$$

在这个例子中 $\boldsymbol{A}$ 的第 3 列是 $\boldsymbol{C}$ 中的第 2 个列向量. 所以 $\boldsymbol{R}$ 的第 3 列为 $\begin{bmatrix}0\\1\end{bmatrix}$. $\boldsymbol{R}$ 告诉我们如何从 $\boldsymbol{C}$ 来得到 $\boldsymbol{A}$.

下面我们给一个 $\boldsymbol{A}$ 的行秩等于 $\boldsymbol{A}$ 的列秩的非正式的证明.

（1）$\boldsymbol{C}$ 的 $r$ 列是线性无关的 (从 $\boldsymbol{A}$ 中选出)；

（2）$\boldsymbol{A}$ 的每一列都是 $\boldsymbol{C}$ 的 $r$ 列的线性组合 ($\boldsymbol{A}=\boldsymbol{CR}$)；

（3）$\boldsymbol{R}$ 的 $r$ 行是线性无关的 (它们包括了 $r\times r$ 单位阵 $\boldsymbol{I}$)；

（4）$\boldsymbol{A}$ 的每一行是 $\boldsymbol{R}$ 的 $r$ 行的线性组合（按照行向量来看 $\boldsymbol{A}=\boldsymbol{CR}$）.

① 译者注：意思是，若 $\boldsymbol{A}$ 的第 $i$ 列在 $\boldsymbol{C}$ 中，那么 $\boldsymbol{R}$ 的第 $i$ 列就是单位阵 $\boldsymbol{I}$ 的某一列.

### 1.4.7 如何找出矩阵 $R$

到现在为止我们还不知道该如何找出满足 $A=CR$ 的矩阵 $R$.

**例 1.17** 设 $A=\begin{bmatrix}1&3&4\\2&4&2\\3&7&6\end{bmatrix}$. 如果已知 $A$ 的第 3 列是第 1 列和第 2 列的线性组合，即

$$x\begin{bmatrix}1\\3\\2\end{bmatrix}+y\begin{bmatrix}3\\4\\7\end{bmatrix}=\begin{bmatrix}4\\2\\6\end{bmatrix}. \tag{1.24}$$

那么具体的线性表出的系数 $x$ 和 $y$ 实际上就可以构成 $R$ 的第 3 列.

但是即使对小尺寸的矩阵，我们也不能很快看出 $x$ 和 $y$ 是什么. 所以我们也无法快速判断矩阵 $A$ 的秩是 2 还是 3. 但是理应有一个便捷的方法来得到 $x$ 和 $y$.

这个方法是消元法. 这是第 2 章讨论方阵和第 3 章讨论任意矩阵的重要算法. 我们先针对例 1.17中的矩阵做一下简单的介绍.

该方法的思路是通过“行变换”来简化 $A$. 这将使我们更容易得到 $x$ 和 $y$. 我们希望消去 $A$ 的第 1 列中的 2 和 3. 我们可以让 $A$ 的第 2 行减去 2 倍的第 1 行，让 $A$ 的第 3 行减去 3 倍的第 1 行. 这时矩阵 $A$ 变为 $B$.

$$B=\begin{bmatrix}1&3&4\\0&-2&-6\\0&-2&-6\end{bmatrix}\qquad x\begin{bmatrix}1\\0\\0\end{bmatrix}+y\begin{bmatrix}3\\-2\\-2\end{bmatrix}\overset{?}{=}\begin{bmatrix}4\\-6\\-6\end{bmatrix} \tag{1.25}$$

这么做是合理的. 将一个方程减去另一个方程得到一个新的方程. 新方程为 $-2y=-6$，所以我们得到 $y=3$. 进而由第一个方程得到 $x=-5$. 所以原方程式 (1.17) 的解为 $-5,3$:

$$\begin{matrix}x=-5\\y=+3\end{matrix}\qquad -5\begin{bmatrix}1\\3\\2\end{bmatrix}+3\begin{bmatrix}3\\4\\7\end{bmatrix}=\begin{bmatrix}4\\2\\6\end{bmatrix}\qquad A\text{的第 3 列与前两列是相关的}$$

所以 $-5,3$ 就是我们需要的 $R$ 的第 3 列. 矩阵的秩为 $r=2$:

$$A=\begin{bmatrix}1&3&4\\2&4&2\\3&7&6\end{bmatrix}=\begin{bmatrix}1&3\\2&4\\3&7\end{bmatrix}\begin{bmatrix}1&0&-5\\0&1&3\end{bmatrix}=CR \tag{1.26}$$

观察这个例子我们还能得到更多结论. 从 $A$ 经过消元得到 $B$ 的过程称为初等行变换. 我们还可以进一步将 $B$ 转化为更简单的矩阵 $U$，方法是将 $B$ 的第 3 行减去第 2 行，从而使第 3 行成为零行向量:

$$A\longrightarrow B=\begin{bmatrix}1&3&4\\0&-2&-6\\0&-2&-6\end{bmatrix}\longrightarrow U=\begin{bmatrix}1&3&4\\0&-2&-6\\0&0&0\end{bmatrix}\qquad \text{是上三角阵} \tag{1.27}$$

零行向量是行秩为 2 的明显的信号. 在第 2 章我们的讨论就到 $\boldsymbol{U}$ 为止，第 3 章中还将进一步化简 $\boldsymbol{U}$ 以得到含有更多 0 的矩阵. 例如，这里我们可以得到 $\boldsymbol{R}_0$ 和 $\boldsymbol{R}$:

$$\boldsymbol{U}=\begin{bmatrix}1&3&4\\0&-2&-6\\0&0&0\end{bmatrix}\longrightarrow\begin{bmatrix}1&3&4\\0&1&3\\0&0&0\end{bmatrix}\longrightarrow\begin{bmatrix}1&0&-5\\0&1&3\\0&0&0\end{bmatrix}=\boldsymbol{R}_0$$

- $\boldsymbol{R}_0$ 的所有行向量是 $\boldsymbol{A}$ 的行向量的线性组合;
- $\boldsymbol{R}_0$ 中的零行说明 $\boldsymbol{A}$ 的秩是 $r=2$;
- $\boldsymbol{R}_0$ 中一个 $2\times 2$ 子矩阵是单位阵说明 $\boldsymbol{A}$ 的第 1 列和第 2 列是线性无关的 (即构成 $\boldsymbol{C}$);
- 将 $\boldsymbol{R}_0$ 中的零行删去我们就得到了分解式 $\boldsymbol{A}=\boldsymbol{CR}$ 中所需的 $\boldsymbol{R}$;
- 第 3 章中的消元法将给出系统得到 $\boldsymbol{R}$ 的方法.

从 $\boldsymbol{A}=\boldsymbol{CR}$ 解读的关键事实

$\boldsymbol{C}$ 的 $r$ 列构成了 $\boldsymbol{A}$ 的列空间的一组基: 维数为 $r$.
$\boldsymbol{R}$ 的 $r$ 行构成了 $\boldsymbol{A}$ 的行空间的一组基: 维数为 $r$.

关于“基”以及“维数”的详细定义将在 3.4节中给出.

- 第 1 章我们根据矩阵 $\boldsymbol{A}$ 的线性无关的列得到 $\boldsymbol{C}$.
- 第 3 章我们从矩阵 $\boldsymbol{A}$ 的行出发, 通过它们的线性组合得到 $\boldsymbol{R}$.

我们多次强调 $\boldsymbol{CR}$ 是因为这两个矩阵都很重要. $\boldsymbol{C}$ 包含了 $\boldsymbol{A}$ 的 $r$ 个线性无关的列向量，$\boldsymbol{R}$ 告诉我们如何从这些列向量线性组合出 $\boldsymbol{A}$ 的所有列向量. ($\boldsymbol{R}$ 包含一个 $r$ 阶单位阵作为它的子矩阵，因为 $\boldsymbol{A}$ 相应的 $r$ 列已经在 $\boldsymbol{C}$ 中了.) 第 3 章将直接从 $\boldsymbol{A}$ 出发通过消元法得到 $\boldsymbol{R}$, 该方法在计算数学中有广泛的应用.

$\boldsymbol{A}=\boldsymbol{CR}$ 将是我们求解线性方程 $\boldsymbol{Ax}=\boldsymbol{b}$ 这个基本问题的关键.

### 1.4.8　$A$ 的列乘以 $B$ 的行，$C$ 的列乘以 $R$ 的行

在本章结束之前, 我想要再补充一段. 我们还有另外一种方法来计算矩阵的乘法 (和之前的 $\boldsymbol{AB}$ 以及 $\boldsymbol{CR}$ 一样). 这种方法并不那么广泛使用，但是很有效. 这个新的方法就是用 $\boldsymbol{A}$ 的列乘以 $\boldsymbol{B}$ 的行.

$$\boldsymbol{AB}=\begin{bmatrix}|&&|\\\boldsymbol{a}_1&\cdots&\boldsymbol{a}_n\\|&&|\end{bmatrix}\begin{bmatrix}--&\boldsymbol{b}_1^{\mathrm{T}}&--\\&\vdots&\\--&\boldsymbol{b}_n^{\mathrm{T}}&--\end{bmatrix}=\boldsymbol{a}_1\boldsymbol{b}_1^{\mathrm{T}}+\boldsymbol{a}_2\boldsymbol{b}_2^{\mathrm{T}}+\cdots+\boldsymbol{a}_n\boldsymbol{b}_n^{\mathrm{T}}\tag{1.28}$$

列向量$\boldsymbol{a}_k$　　行向量$\boldsymbol{b}_k^{\mathrm{T}}$　　将列向量$\boldsymbol{a}_k$和行向量$\boldsymbol{b}_k^{\mathrm{T}}$相乘，再相加

这些矩阵 $\boldsymbol{a}_k\boldsymbol{b}_k^{\mathrm{T}}$ 称为外积. 我们发现它们的秩都是 1：列乘以行. 它们和点积完全不一样 ( 行乘以列). 如果 $\boldsymbol{A}$ 是 $m\times n$ 矩阵而 $\boldsymbol{B}$ 是 $n\times p$ 矩阵，那么这样的 $\boldsymbol{A}$ 的列乘以 $\boldsymbol{B}$ 的行后相加得到的结果与 $\boldsymbol{A}$ 的行和 $\boldsymbol{B}$ 的列的点积运算得到的结果是完全一样的.

不同的计算 $\boldsymbol{AB}$ 的方法都需要 $mnp$ 次基本的数乘, 只是顺序完全不同!

| | | |
|---|---|---|
| (行)·(列) | $mp$ 次点积运算, 每次点积需 $n$ 次乘法 | 合计 $mnp$ 次 |
| (列)(行) | $n$ 个秩为 1 的矩阵, 每个 $mp$ 次乘法 | 合计 $mnp$ 次 |

列 × 行

$$\begin{bmatrix}1&4\\2&5\\3&6\end{bmatrix}\begin{bmatrix}7&8&9\\10&11&12\end{bmatrix}=\begin{bmatrix}1\\2\\3\end{bmatrix}\begin{bmatrix}7&8&9\end{bmatrix}+\begin{bmatrix}4\\5\\6\end{bmatrix}\begin{bmatrix}10&11&12\end{bmatrix}$$

秩 1 矩阵 + 秩 1 矩阵

$$=\begin{bmatrix}7&8&9\\14&16&18\\21&24&27\end{bmatrix}+\begin{bmatrix}40&44&48\\50&55&60\\60&66&72\end{bmatrix}=\begin{bmatrix}47&52&57\\64&71&78\\81&90&99\end{bmatrix}=\boldsymbol{AB}$$

这个例子的计算量是 $mnp=(3)(2)(3)=18$. 在第二行的开始可以看到 18 次乘法运算 (在两个 $3\times3$ 矩阵里). 然后 9 次加法给出了正确的 $\boldsymbol{AB}$. $\boldsymbol{AB}$ 的秩为 2，只有两个线性无关的列，不是三个；只有两个线性无关的行，不是三个. 下一章我们会换一种方式描述，即：$\boldsymbol{AB}$ 没有逆矩阵，它不是可逆矩阵. 在第 5 章中我们会再换一种方式描述，即 $\boldsymbol{AB}$ 的行列式是 0.

### 关于矩阵 $R$ 的注记

分解式 $\boldsymbol{A}=\boldsymbol{CR}$ 中的矩阵 $\boldsymbol{R}$ 是线性代数中的一个著名的矩阵! 它本质上是 $\boldsymbol{A}$ 的“**最简行阶梯型矩阵**”. MATLAB 中用 **rref**($\boldsymbol{A}$) 来表示，其包含 $m-r$ 个零行. 我们把包含零行的矩阵记作 $\boldsymbol{R}_0$.

分解 $\boldsymbol{A}=\boldsymbol{CR}$ 是线性代数中的重要一步. 课后习题会重点关注 $\boldsymbol{R}$ 的构造. $\boldsymbol{R}$ 包含了一个 $r$ 阶单位阵. $\boldsymbol{C}$ 乘以 $\boldsymbol{R}$ 的每一列可以得到相应的 $\boldsymbol{A}$ 的每一列. **我们将在第 3 章引入$\boldsymbol{R}_0$.**

**例 1.18**

$$\boldsymbol{A}=\begin{bmatrix}\boldsymbol{a}_1&\boldsymbol{a}_2&3\boldsymbol{a}_1+4\boldsymbol{a}_2\end{bmatrix}=\begin{bmatrix}\boldsymbol{a}_1&\boldsymbol{a}_2\end{bmatrix}\begin{bmatrix}1&0&3\\0&1&4\end{bmatrix}=\boldsymbol{CR}.$$

这里的 $\boldsymbol{a}_1$ 和 $\boldsymbol{a}_2$ 是 $\boldsymbol{A}$ 的线性无关的列. 第 3 列是 $\boldsymbol{a}_1$ 和 $\boldsymbol{a}_2$ 的线性组合. 因此它在第 1 列和第 2 列张成的平面里. 所有的矩阵 $\boldsymbol{A}$、$\boldsymbol{C}$、$\boldsymbol{R}$ 的秩都为 $r=2$.

也可以尝试用新的（**列 × 行**）方法来快速计算例 1.18中的 $\boldsymbol{CR}$:

$\boldsymbol{C}$ 的列乘以 $\boldsymbol{R}$ 的行

$$\boldsymbol{CR}=\boldsymbol{a}_1\begin{bmatrix}1&0&3\end{bmatrix}+\boldsymbol{a}_2\begin{bmatrix}0&1&4\end{bmatrix}=\begin{bmatrix}\boldsymbol{a}_1&\boldsymbol{a}_2&3\boldsymbol{a}_1+4\boldsymbol{a}_2\end{bmatrix}=\boldsymbol{A}$$

---

$(3\times2\text{矩阵})(2\times4\text{矩阵})=(3\times4\text{矩阵})$ — **四种计算 $\boldsymbol{AB}=\boldsymbol{C}$ 的方法**

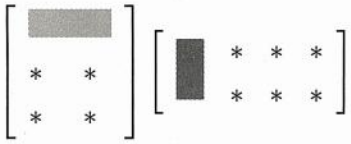

($\boldsymbol{A}$的第 $i$ 行)·($\boldsymbol{B}$的第 $k$ 列) = $\boldsymbol{C}$的分量$\boldsymbol{C}_{ik}$

$i=1,2,3;k=1,2,3,4$ 共 12 个数

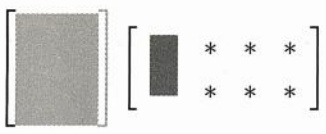

$\boldsymbol{A}\times$($\boldsymbol{B}$的第 $k$ 列) = $\boldsymbol{C}$的第 $k$ 列

$k=1,2,3,4$ 共 4 列

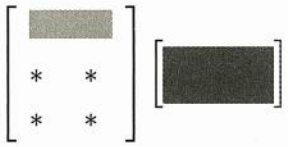

($\boldsymbol{A}$的第 $i$ 行) $\times \boldsymbol{B}$ $=$ $\boldsymbol{C}$的第 $i$ 行

$i=1,2,3$　　共 3 行

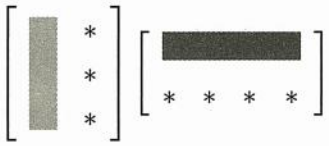

($\boldsymbol{A}$的第 $j$ 列) $\cdot$ ($\boldsymbol{B}$的第 $j$ 行) $=$ 秩 1 矩阵

$j=1,2$　　共 2 个矩阵

从上往下，分别是从点积、列运算、行运算、列乘以行四种角度来看待矩阵乘法.

## 习题 1.4

1. 当 $\boldsymbol{A}$ 是 $m\times n$ 矩阵，$\boldsymbol{B}$ 是 $n\times p$ 矩阵时，复习并默写从四种角度理解矩阵乘法 $\boldsymbol{AB}=\boldsymbol{C}$ 的表格. 在计算 $\boldsymbol{AB}$ 的过程中，有多少点积运算、多少行、多少列以及多少秩为 1 的矩阵？请说明：在这四种情形里总的乘法计算量都是 $mnp$.

2. 如果 $\boldsymbol{A}=\begin{bmatrix}\boldsymbol{a} & \boldsymbol{a} & \boldsymbol{a}\end{bmatrix}$ 的所有列为同一个非零向量 $\boldsymbol{a}$，那么 $\boldsymbol{C}$ 和 $\boldsymbol{R}$ 是什么？

3. 利用点积来计算下列矩阵乘法:

$$(1)\ \begin{bmatrix}1&0&0\\1&1&0\\1&1&1\end{bmatrix}\begin{bmatrix}1&0&0\\-1&1&0\\1&-1&1\end{bmatrix}\qquad (2)\ \begin{bmatrix}1&2&3\end{bmatrix}\begin{bmatrix}4\\5\\6\end{bmatrix}\qquad (3)\ \begin{bmatrix}4\\5\\6\end{bmatrix}\begin{bmatrix}1&2&3\end{bmatrix}$$

4. 验证结合律 $(\boldsymbol{AB})\boldsymbol{C}=\boldsymbol{A}(\boldsymbol{BC})$.

$$(1)\ \begin{bmatrix}1&1\end{bmatrix}\begin{bmatrix}1\\1\end{bmatrix}\begin{bmatrix}1&1&1\end{bmatrix}\qquad (2)\ \begin{bmatrix}1&2\\0&1\end{bmatrix}\begin{bmatrix}1&3\\0&1\end{bmatrix}\begin{bmatrix}1&4\\0&1\end{bmatrix}$$

5. 为什么 7 行 4 列的矩阵 $\boldsymbol{A}$ 中不存在 5 个线性无关的行？这并不是一个无用的问题.

6. 从左到右判断矩阵 $\boldsymbol{A}$ 的每一列是否该放入矩阵 $\boldsymbol{C}$，注意：判断标准是该列是否为前面列的线性组合：

$$\boldsymbol{A}=\begin{bmatrix}2&-2&1&6&0\\1&-1&0&2&0\\3&-3&0&6&1\end{bmatrix}\qquad \boldsymbol{C}=\begin{bmatrix}2&&\\1&&\\3&&\end{bmatrix}$$

7. 给出习题 6 中的 $\boldsymbol{R}$ 使得 $\boldsymbol{A}=\boldsymbol{CR}$. 如果 $\boldsymbol{C}$ 有 $r$ 列，那么 $\boldsymbol{R}$ 有 $r$ 行. $\boldsymbol{R}$ 的 5 列说明如何从 $\boldsymbol{C}$ 得到 $\boldsymbol{A}$ 的 5 列.

8. 给定上三角矩阵

$$\boldsymbol{A}=\begin{bmatrix}2&2&2\\0&4&4\\0&0&6\end{bmatrix}\qquad \boldsymbol{B}=\begin{bmatrix}2&2&2\\0&0&4\\0&0&6\end{bmatrix}$$

$\boldsymbol{A}$ 有 3 个线性无关的列向量. 那么 $\boldsymbol{C}$ 和 $\boldsymbol{A}$ 有相同的 3 列. 哪个 $3\times 3$ 矩阵 $\boldsymbol{R}$ 满足 $\boldsymbol{A}=\boldsymbol{CR}$? 当我们对矩阵 $\boldsymbol{B}$ 考虑这样的分解，有什么不一样的地方?

9. 假设 $\boldsymbol{A}$ 是一个随机的 $4\times 4$ 矩阵. $\boldsymbol{A}$ 的列向量“线性无关”的概率是 1. 此时分解式 $\boldsymbol{A}=\boldsymbol{CR}$ 中的 $\boldsymbol{C}$ 和 $\boldsymbol{R}$ 分别是什么?

注：随机矩阵理论是线性代数应用的重要组成部分, 尤其是对于非常大的矩阵，此时即便只是计算矩阵乘法 $\boldsymbol{AB}$，其计算量都会非常的大. “概率为 1”是说随机选择两个矩阵，它们不同的概率是 1. 但实际上它们也可能会一样! 习题 10 是这种类型的另一个例子.

10. 假设 $\boldsymbol{A}$ 是一个随机的 $4\times 5$ 矩阵，在概率为 1 的意义下，$\boldsymbol{A}=\boldsymbol{CR}$ 的 $\boldsymbol{C}$ 和 $\boldsymbol{R}$ 分别是什么? 特别地，从左到右，$\boldsymbol{A}$ 的哪一列和前面的列是线性无关的?

11. 给出一个秩 $r=2$ 的 $4\times 4$ 矩阵 $\boldsymbol{A}$ 的例子，然后将 $\boldsymbol{A}$ 分解为 $\boldsymbol{CR}=(4\times 2\text{矩阵})(2\times 4\text{矩阵})$.

12. 给定矩阵

$$\boldsymbol{A}_1=\begin{bmatrix}1&2&3\\1&3&4\end{bmatrix},\quad \boldsymbol{A}_2=\begin{bmatrix}0&1&2&3\\0&1&3&5\end{bmatrix},\quad \boldsymbol{A}_3=\begin{bmatrix}2&1&3\\6&3&9\end{bmatrix},\quad \boldsymbol{A}_4=\begin{bmatrix}1&0&0&4\\0&2&2&0\end{bmatrix}$$

对它们作 $\boldsymbol{CR}$ 分解，即：把它们写成 $\boldsymbol{CR}=(m\times r\text{矩阵})(r\times n\text{矩阵})$ 的形式，其中 $r$ 是待分解矩阵的秩.

13. 已知 $\boldsymbol{C}=\begin{bmatrix}1\\3\end{bmatrix}$, $\boldsymbol{R}=\begin{bmatrix}2&4\end{bmatrix}$，计算 $\boldsymbol{CR}$、$\boldsymbol{RC}$、$\boldsymbol{CRC}$、$\boldsymbol{RCR}$.

14. 按照给定的条件，把这些 $2\times 2$ 矩阵的空缺处补充完整：

| | | | |
|---|---|---|---|
| $\begin{bmatrix}3&6\\5&\end{bmatrix}$ | $\begin{bmatrix}6&7\\7&\end{bmatrix}$ | $\begin{bmatrix}2&\\3&6\end{bmatrix}$ | $\begin{bmatrix}3&4\\&-3\end{bmatrix}$ |
| 秩为 1 | 正交阵 | 秩为 2 | $\boldsymbol{A}^2=\boldsymbol{I}$ |

15. 假设 $\boldsymbol{A}=\boldsymbol{CR}$，其中 $\boldsymbol{C}$ 的列线性无关，$\boldsymbol{R}$ 的行线性无关. 由 $\boldsymbol{A}=\boldsymbol{CR}=(m\times r\text{矩阵})(r\times n\text{矩阵})$，解释下面这些论证的逻辑推理为什么是成立的.

（1）$\boldsymbol{A}$ 的每一列是 $\boldsymbol{C}$ 的列的线性组合.

（2）$\boldsymbol{A}$ 的每一行是 $\boldsymbol{R}$ 的行的线性组合. $\boldsymbol{A}$ 的第一行如何由 $\boldsymbol{R}$ 的行线性组合出来?

（3）$\boldsymbol{C}$ 的列的数量等于 $\boldsymbol{R}$ 的行的数量.

（4）行秩等于列秩. $\boldsymbol{A}$ 的线性无关的列向量的个数等于 $\boldsymbol{A}$ 的线性无关的行向量的个数.

16.（1）当 $\boldsymbol{x}$ 取遍所有列向量时，向量 $\boldsymbol{ABx}$ 生成了 $\boldsymbol{AB}$ 的列空间. 证明：向量 $\boldsymbol{ABx}$ 属于 $\boldsymbol{A}$ 的列空间.（换句话说：是否存在 $\boldsymbol{y}$ 使得 $\boldsymbol{ABx}=\boldsymbol{Ay}$?）由此我们断言：$\boldsymbol{A}$ 的列空间包含了 $\boldsymbol{AB}$ 的列空间.

（2）构造两个非零矩阵 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 使得 $\boldsymbol{AB}$ 的列空间仅包含零向量. 这是列空间可能取到的最小值.

17. 判断正误，并简述理由:

（1）如果 $3\times 3$ 矩阵 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 的秩都为 1, 那么 $\boldsymbol{AB}$ 的秩一定等于 1.

（2）如果 $3\times 3$ 矩阵 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 的秩都为 3, 那么 $\boldsymbol{AB}$ 的秩一定等于 3.

（3）假设对任意 $2\times 2$ 矩阵 $\boldsymbol{B}$，都有 $\boldsymbol{AB}=\boldsymbol{BA}$. 那么存在常数 $c$ 使得 $\boldsymbol{A}=\begin{bmatrix}c&0\\0&c\end{bmatrix}=c\boldsymbol{I}$. 换

言之，只有 $\boldsymbol{A}=c\boldsymbol{I}$ 才能和所有矩阵 $\boldsymbol{B}$ 可交换.

18. 本节提到了结合律 $(\boldsymbol{AB})\boldsymbol{C}=\boldsymbol{A}(\boldsymbol{BC})$ 的一个特例：

$$\boldsymbol{A}=\boldsymbol{C}=\text{对换矩阵}\begin{bmatrix}0&1\\1&0\end{bmatrix},\qquad \boldsymbol{B}=\begin{bmatrix}1&2\\3&4\end{bmatrix}.$$

（1）首先计算 $\boldsymbol{AB}$（交换行），然后计算 $\boldsymbol{BC}$（交换列）.

（2）现在计算双重替换：$(\boldsymbol{AB})\boldsymbol{C}$（先交换行）和 $\boldsymbol{A}(\boldsymbol{BC})$（先交换列）. 验证这两种计算得到的是相同的 $\boldsymbol{ABC}$.

19. 请按式(1.28)的方法计算 $\boldsymbol{AB}$ 和 $\boldsymbol{BA}$：

$$\boldsymbol{AB}=\begin{bmatrix}1&0&0\\1&1&0\\1&1&1\end{bmatrix}\begin{bmatrix}1&1&1\\0&1&1\\0&0&1\end{bmatrix}\qquad \boldsymbol{BA}=\begin{bmatrix}1&1&1\\0&1&1\\0&0&1\end{bmatrix}\begin{bmatrix}1&0&0\\1&1&0\\1&1&1\end{bmatrix}$$

20. 若 $\boldsymbol{A}$、$\boldsymbol{B}$、$\boldsymbol{C}$ 分别是 $4\times3$、$3\times2$、$2\times1$ 矩阵，那么用 $(\boldsymbol{AB})\boldsymbol{C}$ 和 $\boldsymbol{A}(\boldsymbol{BC})$ 这两种顺序来计算 $\boldsymbol{ABC}$ 的计算量分别是多少？提示：这两种计算方法的计算量是不一样的.

## 1.5　谈谈第 1 章

大多数教科书都不会设置独立的篇幅以供作者直抒胸臆. 但是编写一本新教科书需要做出很多决定. 我的选择是直入主题，讨论线性无关性和秩. 前人有很多很好的经验，并且经过了时间的沉淀，所以何不开门见山呢？当我考虑具体的写作时，两个问题对我有重大的影响.

是什么让这个课题显得很容易？所有的方程都是线性的.

是什么让这个课题变得很困难？有无数的未知、想法和方程.

书中的例子都是低阶矩阵. 但是在工程实践上并非如此，例如当我们想要测量一个发动机的温度，我们需要对很多位置进行温度信息的采集，因为发动机在实际工作状态下温度分布并不遵循简单的规律. 这就有成百上千个位置变元.

我坚信矩阵是解决问题的关键！方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 是允许容纳任意有限多个变元的完美形态，线性就建立在符号 $\boldsymbol{Ax}$ 和 $\boldsymbol{A}(\boldsymbol{x}+\boldsymbol{y})=\boldsymbol{Ax}+\boldsymbol{Ay}$ 这条运算法则上. $m$ 个方程 $\boldsymbol{Ax}=\boldsymbol{b}$ 中的每一个都代表一个平坦的（超）平面：

$$\begin{aligned}&2x+5y-4z=6 && \text{三维空间中的平面}\\&2x+5y-4z+7w=9 && \text{四维空间中的三维平面（超平面）}\end{aligned}$$

线性似乎触手可及，显而易见；但是当我们试图想象在 11 维空间的 10 个超平面是如何相交的，问题陡然严肃起来. 我们当然希望它们交于一条直线：维数大略等于 $11-10=1$. 我们再拿第 11 个超平面来相交时，预计交出来一个点：这相当于解包含 11 个未知数的 11 个方程. 那么一本合格的教科书和符号系统，理应使得诸如此类的“数数”能够简洁明了.

对于一个 $m\times n$ 矩阵 $\boldsymbol{A}$，我们有一些先验的期待：

- 若 $m<n$，那么 $m$ 个方程的方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 大概率有很多解；
- 若 $m=n$，那么 $m$ 个方程的方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 大概率仅有唯一解；

- 若 $m > n$，那么 $m$ 个方程的方程组 $\boldsymbol{Ax} = \boldsymbol{b}$ 大概率没有解，因为相比于未知数的个数，方程太多了.

但是这种直白的想法略显幼稚，因而不该是我们的目标. 注意到，若 $\boldsymbol{A}$ 的某列是它之前列的线性组合，那么这一列并没有提供新的信息. 换句话说，某个方程仅仅是前面一些方程的组合. 因此，从行向量或者列向量的线性无关性导出的不变量——秩 $r$——才真正衡量了问题的复杂度. 这也正是分解式 $\boldsymbol{A} = \boldsymbol{CR} = (m \times r\text{矩阵})(r \times n\text{矩阵})$ 的优美之处，这三个矩阵的秩都是 $r$.

再次提醒：$\boldsymbol{A}$ 中的某些列在 $\boldsymbol{C}$ 中意味着 $\boldsymbol{R}$ 的某些列构成的子矩阵恰为单位阵.

我们再对伟大的结合律 $(\boldsymbol{AB})\boldsymbol{C} = \boldsymbol{A}(\boldsymbol{BC})$ 多说两句. 当 $\boldsymbol{C}$ 只有 1 列时，换言之 $\boldsymbol{C} = \boldsymbol{c} = \begin{bmatrix} c_1 \\ \vdots \\ c_n \end{bmatrix}$ 是个列向量，那么

- 若 $\boldsymbol{AB}$ 的列向量是 $\boldsymbol{Ab}_1, \boldsymbol{Ab}_2, \cdots, \boldsymbol{Ab}_n$，那么 $(\boldsymbol{AB})\boldsymbol{c} = c_1\boldsymbol{Ab}_1 + c_2\boldsymbol{Ab}_2 + \cdots + c_n\boldsymbol{Ab}_n$.
- $\boldsymbol{Bc}$ 只有一列：$c_1\boldsymbol{b}_1 + c_2\boldsymbol{b}_2 + \cdots + c_n\boldsymbol{b}_n$，那么 $\boldsymbol{A}(\boldsymbol{Bc}) = \boldsymbol{A}(c_1\boldsymbol{b}_1 + c_2\boldsymbol{b}_2 + \cdots + c_n\boldsymbol{b}_n)$.

线性性质告诉我们这两个求和式相等，这就证明了 $(\boldsymbol{AB})\boldsymbol{c} = \boldsymbol{A}(\boldsymbol{Bc})$. 那么对任意 $\boldsymbol{C}$，对 $\boldsymbol{C}$ 的每一列，我们都有这个事实，因此 $(\boldsymbol{AB})\boldsymbol{C} = \boldsymbol{A}(\boldsymbol{BC})$.

最后，需要重点强调的是：当我们写 $\boldsymbol{Ax}$、$\boldsymbol{AB}$、$\boldsymbol{CR}$ 时，我们内心想表达的是 $\boldsymbol{A}$ 或 $\boldsymbol{C}$ 的列向量的线性组合，而不是在和行向量作点积!

# 第 2 章

CHAPTER 2

# 解线性方程组 $Ax = b$

本章讨论的矩阵是 $n$ 阶方阵，即 $n \times n$ 矩阵. **$Ax = b$ 实际上是 $n$ 个方程**（$\boldsymbol{A}$ 的每一行都对应一个方程）. 这些方程都含有 $n$ 个未知数，即列向量 $\boldsymbol{x}$ 的 $n$ 个分量. 方程组 $\boldsymbol{Ax} = \boldsymbol{b}$ 虽然并不是对每个 $\boldsymbol{b}$ 都有解，但大概率有解. 在这种情况下，$\boldsymbol{A}$ 有逆矩阵 $\boldsymbol{A}^{-1}$，其满足 $\boldsymbol{A}^{-1}\boldsymbol{A} = \boldsymbol{I}$ 以及 $\boldsymbol{AA}^{-1} = \boldsymbol{I}$，将 $\boldsymbol{Ax} = \boldsymbol{b}$ 左乘 $\boldsymbol{A}^{-1}$，那么形式上可得 $\boldsymbol{x} = \boldsymbol{A}^{-1}\boldsymbol{b}$.

本章的目标是找到解 $\boldsymbol{x}$. 但是，**请不要计算 $\boldsymbol{A}^{-1}$**.（即使求出 $\boldsymbol{A}^{-1}$ 后，对每个 $\boldsymbol{b}$ 可以统一解方程组 $\boldsymbol{Ax} = \boldsymbol{b}$.）相反地，在 $\boldsymbol{A}$ 的列向量线性无关的前提下，我们逐列研究 $\boldsymbol{A}$ 的列向量. 最终 $\boldsymbol{Ax} = \boldsymbol{b}$ 转化为一个**上三角方程组 $\boldsymbol{Ux} = \boldsymbol{c}$**，这样 $\boldsymbol{x}$ 就很容易求解了，如图 2.1 所示. 一旦中途进行不下去，那么必然是假设条件不成立，我们将暂停，对方程组作更细致的探讨.

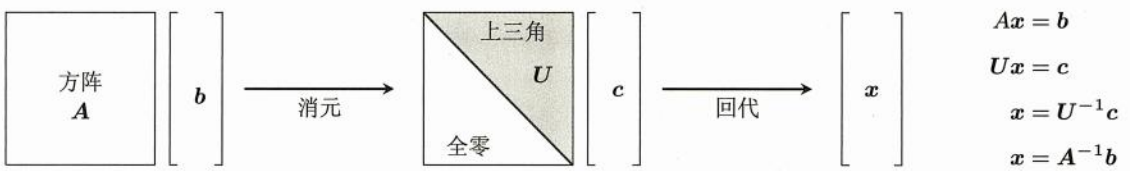


图 2.1　消元法的步骤

这一思想来源于几千年前的中国. 每一步“消元”在矩阵中产生一个零元素. 方阵 $\boldsymbol{A}$ 慢慢转化为上三角阵 $\boldsymbol{U}$. 有时需要交换两行. 这并不意外，相反地，完全是意料之内的事，这是在对 $\boldsymbol{A}$ 进行化简的过程中自然发生的.

为了描述这些步骤，矩阵是不可或缺的. 这正是线性代数的核心！简单的初等矩阵 $\boldsymbol{E}_{ij}$ 会让被其作用的矩阵第 $i$ 行第 $j$ 列的位置（$i > j$）变成零. 总的来说，存在矩阵 $\boldsymbol{E}$ 使得 $\boldsymbol{EA} = \boldsymbol{U}$. 在矩阵 $\boldsymbol{U}$ 的左边乘以 $\boldsymbol{E}$ 的逆矩阵 $\boldsymbol{L} = \boldsymbol{E}^{-1}$，则可以返回到 $\boldsymbol{A}$. 本章最重要的矩阵有：

| | | |
|---|---|---|
| 系数矩阵 $\boldsymbol{A}$ | 上三角矩阵 $\boldsymbol{U}$ | 下三角矩阵 $\boldsymbol{L}$ |
| 初等矩阵 $\boldsymbol{E}_{ij}$ | 总体初等矩阵 $\boldsymbol{E}$ | 逆矩阵 $\boldsymbol{A}^{-1}$ |
| 置换矩阵 $\boldsymbol{P}$ | 转置矩阵 $\boldsymbol{A}^{\mathrm{T}}$ | 对称矩阵 $\boldsymbol{S} = \boldsymbol{S}^{\mathrm{T}}$ |

我们的目标是解释从 $\boldsymbol{A}$ 到 $\boldsymbol{EA} = \boldsymbol{U}$，再到 $\boldsymbol{A} = \boldsymbol{E}^{-1}\boldsymbol{U}$，最后到 $\boldsymbol{x}$ 的所有步骤. 如果失败了，意味着方程组 $\boldsymbol{Ax} = \boldsymbol{b}$ 对于大多数 $\boldsymbol{b}$ 来说无解. 每个计算机系统都有代码来寻找这个上三角矩阵 $\boldsymbol{U}$ 和方程组的解 $\boldsymbol{x}$. 这些代码很常用以至于消元法在所有科学计算中都占据了很大的计算成本.

## 2.1 消元法[①]和回代

（1）消元法将第 $i$ 行减去第 $j$ 行的 $\ell_{ij}$ 倍，使第 $i$ 行出现一个零.
（2）$\boldsymbol{Ax}=\boldsymbol{b}$ 转化为 $\boldsymbol{Ux}=\boldsymbol{c}$（或者 $\boldsymbol{Ax}=\boldsymbol{b}$ 被证明无解）.
（3）因为 $\boldsymbol{U}$ 是上三角矩阵，$\boldsymbol{Ux}=\boldsymbol{c}$ 可通过回代来求解.

本章给出了一个系统的方法来求解 $n$ 个方程、$n$ 个未知数的方程组 $\boldsymbol{Ax}=\boldsymbol{b}$. $n$ 阶方阵 $\boldsymbol{A}$ 和 $n\times 1$ 列向量 $\boldsymbol{b}$ 是已知的. 有可能不存在满足方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 的向量 $\boldsymbol{x}=\begin{bmatrix}x_1 & x_2 & \cdots & x_n\end{bmatrix}^{\mathrm{T}}$，有可能只有唯一解，也可能存在无穷多解. 我们的目标是判断这三种可能的情况并求出所有解. 首先我们来分析 $n=2$ 的情形.

（1）**$\boldsymbol{Ax}=\boldsymbol{b}$ 只有唯一解**. 在此情形下，$\boldsymbol{A}$ 的列向量线性无关. $\boldsymbol{A}$ 的秩为 2. $\boldsymbol{Ax}=\boldsymbol{0}$ 只有零解 $\boldsymbol{x}=\boldsymbol{0}$. **$\boldsymbol{A}$ 有逆矩阵 $\boldsymbol{A}^{-1}$.** 此例只有唯一解 $(x,y)=(1,1)$，列向量 $\begin{bmatrix}2 & 4\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}3 & 2\end{bmatrix}^{\mathrm{T}}$ 线性无关.

$$\begin{cases}2x+3y=5\\4x+2y=6\end{cases}\qquad \boldsymbol{A}=\begin{bmatrix}2 & 3\\4 & 2\end{bmatrix}$$

（2）**$\boldsymbol{Ax}=\boldsymbol{b}$ 无解**. 在此情形下，$\boldsymbol{b}$ 不是 $\boldsymbol{A}$ 列向量的线性组合. $\boldsymbol{A}$ 的秩为 1. 此例无解，列向量 $\begin{bmatrix}2 & 4\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}3 & 6\end{bmatrix}^{\mathrm{T}}$ 线性无关.

$$\begin{cases}2x+3y=6\\4x+6y=15\end{cases}\qquad \boldsymbol{A}=\begin{bmatrix}2 & 3\\4 & 6\end{bmatrix}$$

将第二行减去第一行的 2 倍得到 $0=3$，矛盾，所以原方程组无解.

（3）**$\boldsymbol{AX}=\boldsymbol{0}$ 有无穷多解**，在此情形下，$\boldsymbol{A}$ 的列向量不是线性无关的，或者说，$\boldsymbol{A}$ 的列向量线性相关，这使得有无穷多种方式把 $\boldsymbol{A}$ 的列向量线性组合成零向量. 若 $\boldsymbol{Ax}=\boldsymbol{b}$ 有解，则所有 $\boldsymbol{x}+\alpha\boldsymbol{X}$ 仍是解. 对任意 $\alpha$，

$$\boldsymbol{A}(\boldsymbol{x}+\alpha\boldsymbol{X})=\boldsymbol{Ax}+\alpha\boldsymbol{AX}=\boldsymbol{b}+\boldsymbol{0}=\boldsymbol{b}. \tag{2.1}$$

此例有无穷多解，$\boldsymbol{A}$ 的列向量线性相关，且 $\boldsymbol{b}\in C(\boldsymbol{A})$

$$\begin{cases}2x+3y=6\\4x+6y=12\end{cases}\qquad \boldsymbol{A}=\begin{bmatrix}2 & 3\\4 & 6\end{bmatrix}$$

$\boldsymbol{x}=\begin{bmatrix}0 & 2\end{bmatrix}^{\mathrm{T}}$ 是 $\boldsymbol{Ax}=\boldsymbol{b}$ 的解，$\boldsymbol{X}=\begin{bmatrix}3 & 2\end{bmatrix}^{\mathrm{T}}$ 是 $\boldsymbol{Ax}=\boldsymbol{0}$ 的解. $2\boldsymbol{X}=\begin{bmatrix}6 & -4\end{bmatrix}^{\mathrm{T}}$ 也是 $\boldsymbol{Ax}=\boldsymbol{0}$ 的解.

① 译者注：我们通常说的消元法应该是初等行变换的同义语，它包括倍加、倍乘和行对换三种初等行变换. 但是本书的消元法大抵只是指代倍加变换这一种. 建议读者不要太严格地计较这些术语的使用，多体会其中的内涵. 正所谓“只可意会，不可言传”.

事实上，任意 $\alpha X$ 加上特解 $\begin{bmatrix}0 & 2\end{bmatrix}^{\mathrm{T}}$ 都是 $Ax=b$ 的解，所以它的解集是直线：

$$\left\{x+\alpha X=\begin{bmatrix}3\alpha\\2-2\alpha\end{bmatrix}:\alpha\in\mathbb{R}\right\}$$

本章将从解方程组 $Ux=c$ 开始，这种方程组有唯一解，且非常容易求解. 然后说明如何从 $Ax=b$ 导出 $Ux=c$. 如果过程中出现困难，有可能作行对换能解决；如果行对换还是无法解决，那么 $A$ 可能没有逆矩阵，于是它的列向量线性相关（见第（2）、（3）种情形）.

### 2.1.1　回代解法 $Ux=c$

本章将介绍一种系统的方法判断方程组解的情况属于上述哪一种，即何时方程组有唯一解、何时无解、何时有无穷多解. 这个系统的方法称作消元法. 它把 $A$ 变得简单，但是不能改变方程组的解，这就意味着，对 $A$ 作变换的同时，也要对 $b$ 作对应的变换，并且这些变换都必须是可逆的操作. 再强调一遍：消元法保持方程组的解不变！既不少一个，也不多一个，必须正好.

我们先看一下最理想的情形. 消元产生一个上三角矩阵 $U$（$U$ 是 upper triagular 的首字母，所以用它来代表上三角矩阵），比如我们假设某个方程组 $Ax=b$ 可以通过消元法变成：

对 $Ax=b$ 使用消元法（见下文）
得到 $Ux=c$
利用回代法，很容易求出解 $x$

$$Ux=c:\quad\begin{bmatrix}2&3&4\\0&5&6\\0&0&7\end{bmatrix}\begin{bmatrix}x_1\\x_2\\x_3\end{bmatrix}=\begin{bmatrix}19\\17\\14\end{bmatrix}$$

矩阵 $U$ 对角线的左下方的元素全为 0. 更重要的是：$U$ 的对角线上的“主元” $2,5,7$ 非零. 然后我们就可以从下到上来求解方程组：求出 $x_3$，然后 $x_2$，最后 $x_1$.

| | |
|---|---|
| 求解最后一个方程 | 最后一方程是 $7x_3=14$，由此得知 $x_3=2$. |
| 向上回代 | 第二个方程为 $5x_2+6\cdot(2)=17$，由此可得 $x_2=1$. |
| 继续回代 | 第一个方程为 $2x_1+3\cdot(1)+4\cdot(2)=19$，由此可得 $x_1=4$ |
| 结论 | $Ux=c$ 的唯一解是 $\boxed{x=\begin{bmatrix}4&1&2\end{bmatrix}^{\mathrm{T}}}$. |
| 注意 | 在解 $x_1$、$x_2$、$x_3$ 的过程中，我们需要除以主元 2、5、7. |

这些主元通常并不在初始的 $A$ 的对角线上 (我们看不到). 主元 2、5、7 出现在经过“消元”得到下三角全为零的 $U$ 中. 从 $A$ 到 $U$ 的过程是关键的一步，所以需要给出充分的解释！在此之前，我们先给出回代的最后一步，然后再解释消元的原理.

$$\text{方程组}Ax=b\longrightarrow\text{消元得到}Ux=c\longrightarrow\text{回代求解}x=U^{-1}c=A^{-1}b$$

注：我们不允许 0 成为主元. 因为类似 $0x_1=2$、$0x_2=5$、$0x_3=8$ 这样的方程无解. 当主元位置（$U$ 的对角线）出现 0 时，回代法就失效了. $A$ 的列向量线性无关的一个判定法则就是 $U$ 有 $n$ 个非零主元（必要时，需要经过一些行对换）.

每一个列向量组线性无关（列满秩）的方阵 $A$ 都可以化为对角线非零的上三角阵 $U$. 这就是我们接下来要讨论的. 我们可能需要调整方程组 $Ax=b$ 中方程的顺序. 我们先讨论通常的把 $A$ 转化成 $U$ 的过程，然后讨论如何通过回代法求出 $Ax=b$ 的解.

### 2.1.2 把 $A$ 转化成 $U$，$b$ 转化成 $c$

首先，依然以无须作行对换的例子开始，如下面的 $\boldsymbol{A}$，这是列满秩矩阵. 左乘初等矩阵 $\boldsymbol{E}_{21}$、$\boldsymbol{E}_{31}$、$\boldsymbol{E}_{32}$，$\boldsymbol{A}$ 和 $\boldsymbol{b}$ 则分别化为 $\boldsymbol{U}$ 和 $\boldsymbol{c}$. 初始矩阵是 $\boldsymbol{A}$，第一个主元是 2，等号右边是 $\boldsymbol{b}$.

$$\boldsymbol{A}=\begin{bmatrix}2&3&4\\4&11&14\\2&8&17\end{bmatrix}\qquad \boldsymbol{b}=\begin{bmatrix}19\\55\\50\end{bmatrix} \tag{2.2}$$

初等行变换 $\boldsymbol{E}_{21}$ 将第二个方程减去第一个方程的 2 倍，第 2 行第 1 列就化为 0 了：

$$\boldsymbol{E}_{21}=\begin{bmatrix}1&0&0\\-2&1&0\\0&0&1\end{bmatrix}\qquad \boldsymbol{E}_{21}\boldsymbol{A}=\begin{bmatrix}2&3&4\\0&5&6\\2&8&17\end{bmatrix}\qquad \boldsymbol{E}_{21}\boldsymbol{b}=\begin{bmatrix}19\\17\\50\end{bmatrix} \tag{2.3}$$

第一列产生了一个我们需要的 0. 当然，第二个方程也变了. 要得到第一列另一个 0，则需要用行变换 $\boldsymbol{E}_{31}$ 将第三行减去第一行. 如此，第一列的消元工作就处理完了：

$$\boldsymbol{E}_{31}=\begin{bmatrix}1&0&0\\0&1&0\\-1&0&1\end{bmatrix}\qquad \boldsymbol{E}_{31}\boldsymbol{E}_{21}\boldsymbol{A}=\begin{bmatrix}2&3&4\\0&5&6\\0&5&13\end{bmatrix}\qquad \boldsymbol{E}_{31}\boldsymbol{E}_{21}\boldsymbol{b}=\begin{bmatrix}19\\17\\31\end{bmatrix} \tag{2.4}$$

现在我们来看第二行第二列（第二个主元）. 主元为对角线中的 5. 为了消去下面的 5，可以将第三行减去第二行：

$$\boldsymbol{E}_{32}=\begin{bmatrix}1&0&0\\0&1&0\\0&-1&1\end{bmatrix}\qquad \boldsymbol{U}=\begin{bmatrix}2&3&4\\0&5&6\\0&0&7\end{bmatrix}\qquad \boldsymbol{c}=\begin{bmatrix}19\\17\\14\end{bmatrix} \tag{2.5}$$

最终得到上三角矩阵 $\boldsymbol{U}$：$\boldsymbol{E}_{32}\boldsymbol{E}_{31}\boldsymbol{E}_{21}\boldsymbol{A}=\boldsymbol{U}$. 前面已知 $\boldsymbol{x}=\begin{bmatrix}4&1&2\end{bmatrix}^{\mathrm{T}}$ 是 $\boldsymbol{U}\boldsymbol{x}=\boldsymbol{c}$ 的解，同时它也是 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 的解. 由于 $\boldsymbol{U}$ 的对角元为 2、5、7，回代成立. $\boldsymbol{U}$ 的列向量线性无关（因此 $\boldsymbol{A}$ 的列向量也线性无关）. 矩阵 $\boldsymbol{A}$ 和 $\boldsymbol{U}$ 都列满秩.

当没有行对换时，我们可以将消元法总结如下：

> 利用第一个方程将第一列中第一个主元下方的元素化为零.
> 利用新的第二个方程将第二列中第二个主元下方的元素化为零.
> 继续操作第 3 列. 预期的结果是上三角矩阵 $\boldsymbol{U}$.

对 $\boldsymbol{A}$ 进行消元得到 $\boldsymbol{U}$ 的步骤也要同步地用于等号右边的 $\boldsymbol{b}$，把 $\boldsymbol{b}$ 化为新的向量 $\boldsymbol{c}$. 新的方程组 $\boldsymbol{U}\boldsymbol{x}=\boldsymbol{c}$（其等价于原方程 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$）可以通过回代进行求解：$\boldsymbol{x}=\begin{bmatrix}4&1&2\end{bmatrix}^{\mathrm{T}}$.

### 2.1.3 消元法失效的情况

消元法可能失效——0 可能出现在主元的位置，下面的行减去 0 并不能使其消去. 如下就是一个例子：

第一列消元之后
第二个主元位置是0

$$A=\begin{bmatrix}2&3&4\\4&\mathbf{6}&\mathbf{14}\\2&\mathbf{8}&\mathbf{17}\end{bmatrix}\longrightarrow\begin{bmatrix}2&3&4\\0&\mathbf{0}&\mathbf{6}\\0&\mathbf{5}&\mathbf{13}\end{bmatrix}=B$$

解决问题的办法也很简单：**将有 0 的第二行和有 5 的第三行交换.** 那么第二个主元为 **5**，然后我们可以利用该主元对第二列进行消元. 在用置换矩阵 $P$ 进行对换后，消元得到 $U$ 的步骤和之前一样.

成功的行对换

$$PB=\begin{bmatrix}1&0&0\\0&0&1\\0&1&0\end{bmatrix}\begin{bmatrix}2&3&4\\0&\mathbf{0}&\mathbf{6}\\0&\mathbf{5}&\mathbf{13}\end{bmatrix}=\begin{bmatrix}2&3&4\\0&\mathbf{5}&\mathbf{13}\\0&\mathbf{0}&\mathbf{6}\end{bmatrix}$$

在这个例子中，只需要行对换就能理顺消元的步骤，最终得到有非零主元 2、5、6 的上三角矩阵 $U$. 在更一般的情况下，我们需要处理更多的列与行才能得到 $U$.

**注意！** 之前的行对换取得了成功，这正是我们期望的结果——每个主元都非零（主元 2、5、6 都在对角线上）. 但是对另一个略有不同的矩阵 $A^*$，问题有点棘手：**第二列没有主元.**

列向量线性相关
$U^*$ 不可逆
$A^*$ 不可逆

$$A^*=\begin{bmatrix}2&3&4\\4&\mathbf{6}&14\\2&\mathbf{3}&17\end{bmatrix}\longrightarrow\begin{bmatrix}2&3&4\\0&\mathbf{0}&6\\0&\mathbf{0}&13\end{bmatrix}=U^*\tag{2.6}$$

在这种情况下消元不能处理第二列——第二个主元不存在. 这很“悲催”地反映了 $A^*$ 不列满秩这个事实. $U^*$ 的第二列和第一列方向相同，$A^*$ 的第二列和第一列方向也相同.

从中可以看到消元法可以系统地判定列向量的线性相关性：主元中会出现 0. 那么方程组 $A^*X=0$ 存在非零解. $U^*$ 的列向量不是线性无关的.

在这个例子中，第二列是第一列的 $\frac{3}{2}$ 倍，向量 $X=\begin{bmatrix}3&-2&0\end{bmatrix}^{\mathrm{T}}$. 方程组 $A^*x=b$ 可能有解，也可能无解，这依赖于 $b$. 事实上，无解的概率是 1.

### 2.1.4　线性相关或线性无关的列向量

$A^*$ 看起来是个消元失败的案例：没有第二个主元. 但实际上它仍是成功的，因为我们知道：它的列是线性相关的. 寻找上三角矩阵 $U$ 或者 $U^*$ 的美妙之处在于：对角线元素告诉了我们所有的信息.

**上三角矩阵 $U$ 列满秩，当且仅当它的主对角线上没有零元.**

此时（主元均非零的方阵）$U$ 的列向量线性无关，它的各行也线性无关. 因为消元法直接把 $A$ 变为上三角矩阵 $U$，这些事实直接观察即可明了.

那么为何 $U^*$ 的对角线上出现 0 会导致它的列线性相关呢？

$$U^*=\begin{bmatrix}*&*&*&*\\0&*&*&*\\0&0&\mathbf{0}&*\\0&0&0&*\end{bmatrix}=\begin{matrix}\text{对角线有零元的上三角矩阵}\\\text{该矩阵奇异（不列满秩，没有逆矩阵）}\\\text{前三列线性相关}\\\text{后两行线性相关}\end{matrix}$$

### 2.1.5 行向量和列向量的图示

图 2.2 展示了 $\boldsymbol{Ax}=\boldsymbol{b}$ 的三种情况：无解、无穷多解或者唯一解. 可以从两个角度看待. 首先我们从 $\boldsymbol{A}$ 的行向量出发来画出两个方程的示意图. 如果两条直线不相交，那就意味着方程组无解.

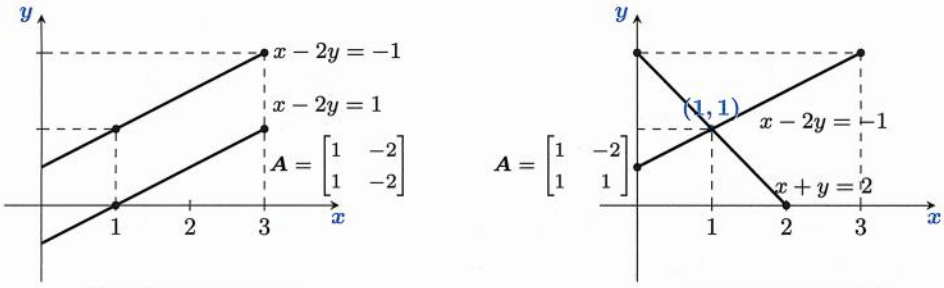


(a) 平面上的平行直线　　(b) 平面上的相交直线

图 2.2　平面上的直线相交与方程组的解

注：图 2.2(a) 两条直线平行意味着方程组**无解**，两条直线重合意味着方程组有**无穷多解**；图 2.2(b) 直线相交意味着方程组有**唯一解**，交点即方程组的解.

如果我们有关于 $x$、$y$、$z$ 的三个方程，那么两条直线会变为三个平面. 三个平面在三维空间中交于一个点. 行示意图难以画出. 列示意图在三维或更高维空间中表现更好.

列示意图仅仅表示列向量：$\boldsymbol{A}$ 的各列和向量 $\boldsymbol{b}$. 我们不必去寻找不同向量的交点. 解方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 无非是用 $\boldsymbol{A}$ 的列向量线性组合出 $\boldsymbol{b}$. 列示意图如图 2.3 所示.

如果 $\boldsymbol{A}$ 的各列（$n$ 维空间中的 $n$ 个向量）线性无关，那么 $\boldsymbol{A}$ 的列空间将包括 $\mathbb{R}^n$ 中的所有向量；并且任意 $\boldsymbol{b}$ 都是唯一的线性组合 $\boldsymbol{Ax}$，消元法可以找出这个 $\boldsymbol{x}$.

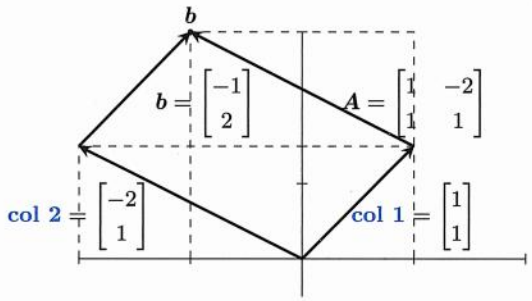


**A**列向量线性相关

第 1 列 + 第 2 列 = **b**

解为：$x_1=1, x_2=1$

用列向量组合出**b**

底部的点是(0, 0)

图 2.3　列示意图：$b$ 是 $A$ 列向量的线性组合 $Ax$

### 2.1.6 消元和置换的例子

本章接下来的任务是利用矩阵来表述整个消元流程. 倍加矩阵 $\boldsymbol{E}$ 左乘在 $\boldsymbol{Ax}=\boldsymbol{b}$ 的等号两边. 如果 0 出现在主元的位置，就用置换矩阵 $\boldsymbol{P}$ 交换两行. 最后的结果将包括一个上三角阵 $\boldsymbol{U}$ 和等号右边新的列向量 $\boldsymbol{c}$，然后通过回代法求解 $\boldsymbol{Ux}=\boldsymbol{c}$.

实际上可以借助 MATLAB ($\boldsymbol{x}=\boldsymbol{A}\backslash\boldsymbol{b}$) 来进行这个操作，但是手动运算一些例子会更有助于理解，理解用消元法得到 $\boldsymbol{Ux}=\boldsymbol{c}$ 的详细步骤，进而求解 $\boldsymbol{x}$. 在此多给一些不同类型的例子，帮助理解.

$$\boldsymbol{A}=\begin{bmatrix}2&4&-2\\4&9&-3\\-2&-3&7\end{bmatrix}\xrightarrow{\boldsymbol{E}_{21}}\begin{bmatrix}2&4&-2\\0&1&1\\-2&-3&7\end{bmatrix}\xrightarrow{\boldsymbol{E}_{31}}\begin{bmatrix}2&4&-2\\0&1&1\\0&1&5\end{bmatrix}\xrightarrow{\boldsymbol{E}_{32}}\begin{bmatrix}2&4&-2\\0&1&1\\0&0&4\end{bmatrix}=\boldsymbol{U}$$

倍加矩阵 $\boldsymbol{E}_{21}$、$\boldsymbol{E}_{31}$、$\boldsymbol{E}_{32}$ 让 $(2,1)$、$(3,1)$、$(3,2)$ 处的元素变为 0. 这几个倍加矩阵在相应位置处的分量分别是 $-2$、$+1$ 和 $-1$. 同样的矩阵 $\boldsymbol{E}_{21}$、$\boldsymbol{E}_{31}$、$\boldsymbol{E}_{32}$ 必须左乘于 $\boldsymbol{b}$ 以确保方程组的解不变.

$$\boldsymbol{b}=\begin{bmatrix}2\\8\\10\end{bmatrix}\longrightarrow\boldsymbol{E}_{21}\boldsymbol{b}=\begin{bmatrix}2\\4\\10\end{bmatrix}\longrightarrow\boldsymbol{E}_{31}\boldsymbol{E}_{21}\boldsymbol{b}=\begin{bmatrix}2\\4\\12\end{bmatrix}\longrightarrow\boldsymbol{E}_{32}\boldsymbol{E}_{31}\boldsymbol{E}_{21}\boldsymbol{b}=\boldsymbol{E}\boldsymbol{b}=\boldsymbol{c}=\begin{bmatrix}2\\4\\8\end{bmatrix}.$$

有一个简单的方法可以同时对矩阵 $\boldsymbol{A}$ 和列向量 $\boldsymbol{b}$ 进行操作——将 $\boldsymbol{b}$ 作为额外的一列添加在 $\boldsymbol{A}$ 最右边. 矩阵 $\begin{bmatrix}\boldsymbol{A}&\boldsymbol{b}\end{bmatrix}$ 称为增广矩阵.

$$\begin{bmatrix}\boldsymbol{A}&\boldsymbol{b}\end{bmatrix}=\begin{bmatrix}2&4&-2&2\\4&9&-3&8\\-2&-3&7&10\end{bmatrix}\xrightarrow{\boldsymbol{E}}\begin{bmatrix}2&4&-2&2\\0&1&1&4\\0&0&4&8\end{bmatrix}=\begin{bmatrix}\boldsymbol{U}&\boldsymbol{c}\end{bmatrix}.\tag{2.7}$$

下面这个例子需要置换矩阵 $\boldsymbol{P}$，用 $\boldsymbol{P}$ 交换方程的位置以确保主元非零. 该矩阵 $\boldsymbol{A}$ 要用 $\boldsymbol{P}$ 来处理第二列.

交换第二、三两行　$$\boldsymbol{A}=\begin{bmatrix}1&1&1\\2&2&3\\0&4&5\end{bmatrix}\xrightarrow{\boldsymbol{E}}\begin{bmatrix}1&1&1\\0&0&1\\0&4&5\end{bmatrix}\xrightarrow{\boldsymbol{P}}\begin{bmatrix}1&1&1\\0&4&5\\0&0&1\end{bmatrix}=\boldsymbol{U}.$$

置换矩阵 $\boldsymbol{P}_{23}$ 交换第二、三两行来避免出现 0 作为主元的情况. 我们也可以在一开始就交换二、三两行，但这时 $\boldsymbol{E}_{21}$ 和 $\boldsymbol{E}_{31}$ 需要交换位置.

最终，$\boldsymbol{A}$ 的矩阵消元实际上可以用 $\boldsymbol{PA}=\boldsymbol{LU}$ 来描述，所有倍加矩阵 $\boldsymbol{E}$ 都移动到右边. $\boldsymbol{E}_{32}$、$\boldsymbol{E}_{31}$、$\boldsymbol{E}_{21}$ 中的每个矩阵都取了逆矩阵. 这些矩阵的逆按顺序相乘为 $\boldsymbol{L}=\boldsymbol{E}_{21}^{-1}\boldsymbol{E}_{31}^{-1}\boldsymbol{E}_{32}^{-1}$. 打包整理之后即为 $\boldsymbol{PA}=\boldsymbol{LU}$. 当然，最常发生的情况是并不需要置换矩阵即可通过消元来得到 $\boldsymbol{A}=\boldsymbol{LU}$：这是 2.2节的最佳公式.

2.4节将继续讨论 $n$ 个行向量所有可能的置换. 一共有 $n!$ 个置换矩阵 $\boldsymbol{P}$，包括没做任何置换的单位阵 $\boldsymbol{P}=\boldsymbol{I}$.

## 习题 2.1

问题 1 ~ 10 都是关于 $2\times2$ 矩阵的消元.

1. 对于方程组 $\begin{cases}2x+3y=11\\10x+9y=11\end{cases}$，第二个方程需要减去第一个方程的多少倍来实现消元？写出消元后得到的上三角矩阵，并圈出两个主元. 最后用回代法解出 $x$ 和 $y$（检验结果是否正确）.

2. 对第 1 题的方程组，如果第一个方程加上第二个方程，以下哪些会变化：行示意图中的直线、列示意图中的向量、系数矩阵、方程组的解？

3. 对于方程组 $\begin{cases}2x-4y=6\\-x+5y=0\end{cases}$，第二个方程需要减去第一个方程的多少倍来实现消元？此时得到一个系数矩阵是上三角矩阵的方程组，求解该方程组. 如果方程右边的列向量变为 $\begin{bmatrix}-6 & 0\end{bmatrix}^{\mathrm{T}}$，新的解是什么？

4. 对于方程组 $\begin{cases}ax+by=f\\cx+dy=g\end{cases}$，第二个方程需要减去第一个方程的多少倍来消去 $c$？第一个主元是 $a$(假设其非零)，那么消元法给出的第二个主元如何表示？$y$ 等于什么？第二个主元在 $ad=bc$ 的时候消失了：此时系数矩阵是奇异矩阵.

5. 在下面的方程组中画横线的部分分别填上合适的数字，使得方程组分别无解、有无穷多解. 在有无穷多解时，写两个不相同的解.

奇异方程组　　$3x+2y=10,\quad 6x+4y=_____.$

6. 对方程组 $\begin{cases}2x+by=16\\4x+8y=g\end{cases}$，选择合适的系数 $b$ 使得系数矩阵是奇异矩阵；然后再选择合适的 $g$，使得该方程组可解. 对上述的 $b$ 和 $g$，求方程组两个不同的解.

7. 对于方程组 $\begin{cases}ax+3y=-3\\4x+6y=6\end{cases}$，$a$ 取什么值的时候消元法会①永远失效②暂时失效？当消元法暂时失效时，通过行对换来求出 $x$ 和 $y$.

8. 对于方程组 $\begin{cases}kx+3y=6\\3x+ky=-6\end{cases}$，$k$ 的哪三个取值会使消元法失效？其中哪一个可以通过行对换来解决？对于 $k$ 的这三个取值，方程组解的数量是 0、1 还是 $\infty$？画出这 3 种情况的行示意图.

9. 对方程组 $\begin{cases}3x-2y=b_1\\6x-4y=b_2\end{cases}$，$b_1$ 和 $b_2$ 满足什么关系时该方程组有解？有解时有多少解？分别画出 $\boldsymbol{b}=\begin{bmatrix}1 & 2\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}1 & 0\end{bmatrix}^{\mathrm{T}}$ 时的列示意图.

10. 画出直线 $x+y=5$ 和 $x+2y=6$ 的示意图，通过消元法得到 $y=_____$. $c$ 取何值时，直线 $5x-4y=c$ 经过上述方程组的解？

问题 11~20 考虑 $3\times 3$ 矩阵的消元法 (以及可能的失败的情况).

11.（推荐）一个线性方程组不会恰好有两个不同的解.

（1）如果 $\begin{bmatrix}x & y & z\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}X & Y & Z\end{bmatrix}^{\mathrm{T}}$ 是两个解，那么你能写出第三个解吗？

（2）如果 25 个平面交于两点，那么它们还在哪些点相交？

12. 通过行变换将下面两个方程组化成系数矩阵是上三角矩阵的方程组，然后解出 $x$、$y$、$z$.

$$\begin{cases} 2x+3y+\ z=8 \\ 4x+7y+5z=20 \\ \quad -2y+2z=0 \end{cases} \qquad \begin{cases} 2x-3y\quad\ =3 \\ 4x-5y+\ z=7 \\ 2x-\ y-3z=5 \end{cases}$$

13. $d$ 取何值时，我们对下面的方程组消元需要做行对换？此时，若系数矩阵非奇异，那么消元所得的上三角矩阵是什么？$d$ 取何值时系数矩阵奇异 (不存在第三个主元)？

$$\begin{cases} 2x+5y+z=0 \\ 4x+dy+z=2 \\ \quad y-z=3 \end{cases}$$

14. $b$ 取何值时，我们对下面的方程组消元需要做行对换？$b$ 取何值时会缺少主元？在系数矩阵奇异的情况下，求一个非零解 $x$、$y$、$z$.

$$\begin{cases} x+by\quad\ =0 \\ x-2y\ -z=0 \\ \quad y\ +z=0 \end{cases}$$

15.（1）构造一个 3 个未知数 3 个方程的线性方程组，使其需要通过两次行对换才能将系数矩阵上三角化.

（2）构造一个需要行对换且不满秩的矩阵.

16. 以下面的方程组为例，探讨：如果方程组第 1 行和第 2 行相同，该如何进行消元（允许行对换)？如果第 1 列和第 2 列相同，哪一个主元缺失了？

两行相同
$$\begin{cases} 2x-y+z=0 \\ 2x+2y+z=0 \\ 4x+y+z=2 \end{cases} \qquad \text{两列相同} \begin{cases} 2x+2y+z=0 \\ 4x+4y+z=0 \\ 6x+6y+z=2 \end{cases}$$

17. 构造一个 3 个未知数 3 个方程的方程组，使其等号左边 9 个系数均不相同，但是经过消元第 2 行和第 3 行都化为 0. 以你的方程组为例，若等号右边 $\boldsymbol{b}=\begin{bmatrix}1 & 10 & 100\end{bmatrix}^{\mathrm{T}}$，则方程组有多少解？若 $\boldsymbol{b}=\begin{bmatrix}0 & 0 & 0\end{bmatrix}^{\mathrm{T}}$，则方程组有多少解？

18. $q$ 取何值时，下面方程组的系数矩阵奇异？在此前提下，$t$ 取何值时方程组有无穷多解？此时，找出满足 $z=1$ 的解.

$$\begin{cases} x+4y-2z=1 \\ x+7y-6z=6 \\ \quad 3x+qz=t \end{cases}$$

19. $a$ 取哪两个值时，对矩阵 $\boldsymbol{A}=\begin{bmatrix}a & 2\\ a & a\end{bmatrix}$ 消元会失效？

20. 设 $\boldsymbol{A}=\begin{bmatrix} a & 2 & 3 \\ a & a & 4 \\ a & a & a \end{bmatrix}$，$a$ 取哪三个值会导致对 $\boldsymbol{A}$ 消元得不到三个主元？

提示：$a$ 有三个取值使得 $\boldsymbol{A}$ 是奇异的.

21. 对于矩阵 $\begin{bmatrix} a & b \\ c & d \end{bmatrix}$，若其行向量各元素之和为 4 和 8，其列向量各元素之和为 2 和 $s$，那么下述四个方程构成的方程组仅当 $s=$ _____ 时有解. 找到两个这样的矩阵. 写出关于 $\boldsymbol{x}=\begin{bmatrix} a & b & c & d \end{bmatrix}^{\mathrm{T}}$ 的方程组 $\boldsymbol{Ax}=\boldsymbol{b}$，并且使得 $\boldsymbol{A}$ 可以通过消元法上三角化.

$$\text{矩阵}\begin{bmatrix} a & b \\ c & d \end{bmatrix} \qquad \begin{matrix} 4\text{ 个未知数} & a+b=4 & a+c=2 \\ 4\text{ 个方程} & c+d=8 & b+d=s \end{matrix}$$

22. 将 MATLAB 命令 $\boldsymbol{A}(2,:)=\cdots$ 补充完整，实现以下目标：如果给定 $3\times 3$ 矩阵 $\boldsymbol{A}$，则该命令将第 2 行减去第 1 行的 3 倍来得到新的第 2 行.

23. 做一个实验：通过 MATLAB 命令计算 $[\boldsymbol{L},\boldsymbol{U}]=\mathbf{lu}(\mathbf{rand}(3))$ 来观察三个主元的平均值，其中 $(\mathbf{rand}(3))$ 是元素随机取 0、1 值的 $3\times 3$ 矩阵. $\boldsymbol{U}(1,1)$ 的平均值会比 $\frac{1}{2}$ 大，原因是 **lu** 会把最大的主元放在第 1 列.

24. 基本设定同上一题，若 $5\times 5$ 矩阵 $\boldsymbol{A}$ 的右下角元素 $\boldsymbol{A}(5,5)=11$ 而它最后一个主元是 $\boldsymbol{U}(5,5)=4$，那么 $\boldsymbol{A}(5,5)$ 改成什么值时，矩阵会成为奇异矩阵？

25. 假设 $\boldsymbol{A}$ 到 $\boldsymbol{U}$ 的消元过程不需要行对换，那么 $\boldsymbol{U}$ 的第 $j$ 行是 $\boldsymbol{A}$ 的哪些行的线性组合？如果 $\boldsymbol{Ax}=\boldsymbol{0}$，那么 $\boldsymbol{Ux}=\boldsymbol{0}$ 吗？如果 $\boldsymbol{Ax}=\boldsymbol{b}$，那么 $\boldsymbol{Ux}=\boldsymbol{b}$ 吗？如果 $\boldsymbol{A}$ 是下三角阵，那么上三角阵 $\boldsymbol{U}$ 是什么？

26. 考虑关于 100 个未知数 $\boldsymbol{x}=\begin{bmatrix} x_1 & x_2 & \cdots & x_{100} \end{bmatrix}^{\mathrm{T}}$、100 个方程的方程组 $\boldsymbol{Ax}=\boldsymbol{0}$. 假设消元法将第 100 个方程化为 $0=0$，即系数矩阵是“奇异”的.

（1）方程组 $\boldsymbol{Ax}=\boldsymbol{0}$ 有无穷多解，这说明 $\boldsymbol{A}$ 的 100 个列向量的某个线性组合是_____.

（2）构造一个每个元素均非零的、奇异的 $100\times 100$ 矩阵.

（3）请用文字、行示意图、列示意图这三种方法来描述你构造的方程组 $\boldsymbol{Ax}=\boldsymbol{0}$.

## 2.2 初等矩阵和逆矩阵

（1）将初等矩阵 $\boldsymbol{E}_{21},\boldsymbol{E}_{31},\cdots,\boldsymbol{E}_{n1}$ 左乘于 $\boldsymbol{A}$，然后 $\boldsymbol{E}_{32},\boldsymbol{E}_{42},\cdots,\boldsymbol{E}_{n2}$，以此类推，最终 $\boldsymbol{A}$ 化为 $\boldsymbol{EA}=\boldsymbol{U}$.

（2）反过来，$\boldsymbol{E}$ 的逆矩阵左乘于 $\boldsymbol{U}$ 可以得到 $\boldsymbol{A}=\boldsymbol{E}^{-1}\boldsymbol{U}$，这就是 $\boldsymbol{A}=\boldsymbol{LU}$.

（3）$\boldsymbol{A}^{-1}\boldsymbol{A}=\boldsymbol{I}$，所以 $(\boldsymbol{LU})^{-1}=\boldsymbol{U}^{-1}\boldsymbol{L}^{-1}$. 那么 $\boldsymbol{Ax}=\boldsymbol{b}$ 可变为 $\boldsymbol{x}=\boldsymbol{A}^{-1}\boldsymbol{b}=\boldsymbol{U}^{-1}\boldsymbol{L}^{-1}\boldsymbol{b}$.

消元法的所有步骤都可以用矩阵乘法来表示，这些步骤的逆也可以通过矩阵乘法来实现. 如果只是针对 $3\times 3$ 矩阵我们可以直接写出详细步骤；但在实际应用中，矩阵是更好的表示方法.

**基本的消元步骤是将第 $i$ 行减去第 $j$ 行的 $\ell_{ij}$ 倍.** 在消元法中，我们总是说“减去”，尽管有的时候实际上是加，比方说，如果第一个主元是 $a_{11}=3$ 而 $a_{21}=-3$，我们只需要将第二行加上第一个行来得到 0. 但是我们还是说“减去”：将第 2 行减去第 1 行的 $\ell_{21}=-1$ 倍可以得到同一个结果. 类似地，相反的步骤是加法，这一点将在式(2.17)和式(2.18)中体现.

下面这个矩阵是将单位阵的第 3 行减去第 1 行的 2 倍，第 1 行和第 2 行保持不变：

倍加矩阵 $E_{ij}=E_{31}$
第 3 行，第 1 列，倍数为 2

$$\boldsymbol{E}_{31}=\begin{bmatrix}1&0&0\\0&1&0\\-2&0&1\end{bmatrix}$$

对于 3 阶方阵，如果不需要行置换，那么 3 个倍加矩阵 $\boldsymbol{E}_{21}$、$\boldsymbol{E}_{31}$ 和 $\boldsymbol{E}_{32}$ 就能把左下角三个元素全化为零，得到上三角阵 $\boldsymbol{U}$：

$$\boxed{\boldsymbol{E}=\boldsymbol{E}_{32}\boldsymbol{E}_{31}\boldsymbol{E}_{21}\qquad \boldsymbol{E}\boldsymbol{A}=\boldsymbol{U}\text{是上三角矩阵.}} \tag{2.8}$$

$\ell_{32}$ 的选择会受到之前 $\ell_{21}$ 和 $\ell_{31}$ 的影响. 我们减去的是 $\boldsymbol{U}$ 的第 2 行 (并不是原来的 $\boldsymbol{A}$ 的第 2 行) 的 $\ell_{32}$ 倍. 这个 $\boldsymbol{E}_{32}$ 才使得 $\boldsymbol{U}$ 的第 3 行第 2 列为 0. $\boldsymbol{E}_{32}$ 是 $3\times 3$ 矩阵消元的最后一步.

**例 2.1**　设 $\boldsymbol{A}=\begin{bmatrix}3&1&0\\-3&1&1\\6&8&4\end{bmatrix}$，先将 $\boldsymbol{E}_{21}$ 左乘于 $\boldsymbol{A}$，再左乘 $\boldsymbol{E}_{31}$，使矩阵的第 2 行和第 3 行减去了第 1 行的相应倍数:

$$\boldsymbol{E}_{31}\boldsymbol{E}_{21}\boldsymbol{A}=\begin{bmatrix}1&0&0\\0&1&0\\-2&0&1\end{bmatrix}\begin{bmatrix}1&0&0\\1&1&0\\0&0&1\end{bmatrix}\begin{bmatrix}3&1&0\\-3&1&1\\6&8&4\end{bmatrix}=\begin{bmatrix}3&1&0\\0&2&1\\0&6&4\end{bmatrix}\qquad \text{第一列产生 2 个 0} \tag{2.9}$$

要在第 2 列中产生 0，$\boldsymbol{E}_{32}$ 将第 3 行减去新矩阵的第 2 行的 $\ell_{32}=3$ 倍:

$$(\boldsymbol{E}_{32})(\boldsymbol{E}_{31}\boldsymbol{E}_{21}\boldsymbol{A})=\begin{bmatrix}1&0&0\\0&1&0\\0&-3&0\end{bmatrix}\begin{bmatrix}3&1&0\\0&2&1\\0&6&4\end{bmatrix}=\begin{bmatrix}3&1&0\\0&2&1\\0&0&1\end{bmatrix}\qquad \boldsymbol{U}\text{ 对角线下方都是 0.} \tag{2.10}$$

再次提醒，$\boldsymbol{E}_{32}$ 使第 3 行减去了 $\begin{bmatrix}0&2&1\end{bmatrix}$ 的 3 倍而不是最初的 $\boldsymbol{A}$ 的第 2 行的 3 倍. 因此，主元 3、2、1 在 $U$ 的对角线上：对角线下方都是 0.

每个 $\boldsymbol{E}_{ij}$ 的逆将第 $j$ 行的 $\ell_{ij}$ 倍重新加到第 $i$ 行上去. 所有的逆过程都完成之后，相当于左乘它们的乘积 $\boldsymbol{E}=\boldsymbol{E}_{32}\boldsymbol{E}_{31}\boldsymbol{E}_{21}$ 的逆. $\boldsymbol{E}$ 的逆记为 $\boldsymbol{L}$.

### 2.2.1　和逆矩阵有关的事实

假设 $\boldsymbol{A}$ 是方阵，我们想要寻找相同大小的“逆矩阵” $\boldsymbol{A}^{-1}$ 使得 $\boldsymbol{A}^{-1}\boldsymbol{A}=\boldsymbol{I}$. 不管 $\boldsymbol{A}$ 进行了什么操作，$\boldsymbol{A}^{-1}$ 都反向而行. 它们的乘积是单位阵，对向量没有做任何操作，所以对任意向量 $\boldsymbol{x}$，

$\boldsymbol{A}^{-1}\boldsymbol{A}\boldsymbol{x}=\boldsymbol{x}$ 都成立. 但是 $\boldsymbol{A}^{-1}$ 并不总是存在.

$n\times n$ 矩阵 $\boldsymbol{A}$ 需要 $n$ 个列向量线性无关来保证它可逆，这才有 $\boldsymbol{A}^{-1}\boldsymbol{A}=\boldsymbol{I}$.

矩阵的主要作用之一是乘以向量. 将 $\boldsymbol{A}^{-1}$ 左乘 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 得到 $\boldsymbol{A}^{-1}\boldsymbol{A}\boldsymbol{x}=\boldsymbol{A}^{-1}\boldsymbol{b}$，即 $\boldsymbol{x}=\boldsymbol{A}^{-1}\boldsymbol{b}$. $\boldsymbol{A}^{-1}\boldsymbol{A}$ 可以类比地看作先乘了一个倍数，再把这个倍数除掉. 而数只要非零就可逆，矩阵的情况更复杂也更有趣. 矩阵 $\boldsymbol{A}^{-1}$ 叫作“$\boldsymbol{A}$ 的逆”.

**定义 2.1** 矩阵 $\boldsymbol{A}$**可逆**，如果存在一个矩阵 $\boldsymbol{A}^{-1}$ 是矩阵 $\boldsymbol{A}$ 的“逆运算”：

$$\text{双边逆}\qquad \boldsymbol{A}^{-1}\boldsymbol{A}=\boldsymbol{A}\boldsymbol{A}^{-1}=\boldsymbol{I}. \tag{2.11}$$

**不是所有的矩阵都具有逆.** 关于方阵 $\boldsymbol{A}$ 的第一个问题正是：$\boldsymbol{A}$ 是否可逆？若可逆，则它的列向量必须线性无关. 但我们并不用真的去计算 $\boldsymbol{A}^{-1}$. 我们基本上从来不计算它！下面是关于 $\boldsymbol{A}^{-1}$ 的 7 个注释.

**注释 1** 矩阵的逆矩阵存在当且仅当消元法能产生 $n$ 个非零主元(允许行对换). 通过消元法即可求解 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$，并不需要明确求出矩阵 $\boldsymbol{A}^{-1}$.

**注释 2** 矩阵 $\boldsymbol{A}$ 的逆矩阵如果存在，则唯一. 事实上，假设 $\boldsymbol{B}\boldsymbol{A}=\boldsymbol{I}$ 以及 $\boldsymbol{A}\boldsymbol{C}=\boldsymbol{I}$. 那么根据矩阵乘法的结合律可以得到 $\boldsymbol{B}=\boldsymbol{C}$:

$$\boldsymbol{B}(\boldsymbol{A}\boldsymbol{C})=(\boldsymbol{B}\boldsymbol{A})\boldsymbol{C}\Longrightarrow \boldsymbol{B}\boldsymbol{I}=\boldsymbol{I}\boldsymbol{C},\quad \text{即}\quad \boldsymbol{B}=\boldsymbol{C}. \tag{2.12}$$

这证明了左逆 $\boldsymbol{B}$(从 $\boldsymbol{A}$ 的左边乘) 和右逆 $\boldsymbol{C}$(从 $\boldsymbol{A}$ 的右边乘使得 $\boldsymbol{A}\boldsymbol{C}=\boldsymbol{I}$) 必须是同一个矩阵.

**注释 3** 如果 $\boldsymbol{A}$ 可逆，那么 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 恰好有唯一解 $\boldsymbol{x}=\boldsymbol{A}^{-1}\boldsymbol{b}$:

$$\boxed{\text{将 } \boldsymbol{A}\boldsymbol{x}=\boldsymbol{b} \text{ 左乘 } \boldsymbol{A}^{-1},\ \text{则 } \boldsymbol{x}=\boldsymbol{A}^{-1}\boldsymbol{A}\boldsymbol{x}=\boldsymbol{A}^{-1}\boldsymbol{b}.}$$

**注释 4 (重要)** 假设存在非零列向量 $\boldsymbol{x}$ 使得 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$，那么 $\boldsymbol{A}$ 的列向量线性相关. 矩阵 $\boldsymbol{A}$ 的逆矩阵不存在. 没有矩阵可以将 $\boldsymbol{0}$ 变为 $\boldsymbol{x}$:

$$\text{若 } \boldsymbol{A} \text{ 可逆，则 } \boldsymbol{A}\boldsymbol{x}=\boldsymbol{0} \text{ 只有唯一解 } \boldsymbol{x}=\boldsymbol{A}^{-1}\boldsymbol{0}=\boldsymbol{0}.$$

**注释 5** 方阵可逆当且仅当它的列向量线性无关.

**注释 6** $2\times 2$ 矩阵 $\begin{bmatrix}a & b\\ c & d\end{bmatrix}$ 可逆当且仅当 $ad-bc\neq 0$.

$$\boxed{2\times 2 \text{ 矩阵的逆矩阵}\qquad \begin{bmatrix}a & b\\ c & d\end{bmatrix}^{-1}=\frac{1}{ad-bc}\begin{bmatrix}d & -b\\ -c & a\end{bmatrix}} \tag{2.13}$$

$ad-bc$ 称作矩阵 $\boldsymbol{A}$ 的行列式. $\boldsymbol{A}$ 可逆当且仅当其行列式非零；在第 5 章可知此结论对任意阶数的方阵都成立，并不限于 2 阶方阵. 在行列式引入之前，我们一般通过存在 $n$ 个非零主元来判定矩阵的可逆性.

**注释 7** 如果上三角矩阵的对角元 $d_i$ 都非零，则其逆矩阵存在:

如果 $\boldsymbol{A}=\begin{bmatrix} d_1 & \cdots & \cdots & \cdot \\ 0 & \ddots & \cdots & \vdots \\ \vdots & \ddots & \ddots & \vdots \\ 0 & \cdots & 0 & d_n \end{bmatrix}$，那么 $\boldsymbol{A}^{-1}=\begin{bmatrix} d_1^{-1} & \cdots & \cdots & \cdot \\ 0 & \ddots & \cdots & \vdots \\ \vdots & \ddots & \ddots & \vdots \\ 0 & \cdots & 0 & d_n^{-1} \end{bmatrix}$.

**例 2.2**　$2\times 2$ 矩阵 $\boldsymbol{A}=\begin{bmatrix} 1 & 2 \\ 1 & 2 \end{bmatrix}$ 不可逆. 因为 $ad=bc$，所以不满足注释 6 的条件. 因为 $\boldsymbol{Ax}=\boldsymbol{0}$ 有非零解 $\boldsymbol{x}=\begin{bmatrix} 2 & -1 \end{bmatrix}^{\mathrm{T}}$，所以它不满足注释 4 的条件. 因为它只有一个主元. 不满足注释 1 的条件，它的列向量线性相关.

消元法将矩阵 $\boldsymbol{A}$ 的第二行化为 0, 所以没有第二个主元.

**例 2.3**　下面 6 个矩阵依次为 $\boldsymbol{A}$、$\boldsymbol{B}$、$\boldsymbol{C}$、$\boldsymbol{D}$、$\boldsymbol{S}$、$\boldsymbol{T}$:

$$\begin{bmatrix} 4 & 3 \\ 8 & 6 \end{bmatrix} \quad \begin{bmatrix} 4 & 3 \\ 8 & 7 \end{bmatrix} \quad \begin{bmatrix} 6 & 6 \\ 6 & 0 \end{bmatrix} \quad \begin{bmatrix} 6 & 6 \\ 6 & 6 \end{bmatrix} \quad \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 1 \end{bmatrix} \quad \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 0 \\ 1 & 1 & 1 \end{bmatrix}$$

其中有三个矩阵可逆, 三个是奇异的. 找到其中的可逆阵. 给出矩阵不可逆的理由 (行列式为 0, 缺少主元, $\boldsymbol{Ax}=\boldsymbol{0}$ 有非零解).

**解**　三个可逆矩阵为 $\boldsymbol{B}$、$\boldsymbol{C}$、$\boldsymbol{S}$:

$$\boldsymbol{B}^{-1}=\frac{1}{4}\begin{bmatrix} 7 & -3 \\ -8 & 4 \end{bmatrix}, \qquad \boldsymbol{C}^{-1}=\frac{1}{36}\begin{bmatrix} 0 & 6 \\ 6 & -6 \end{bmatrix}, \qquad \boldsymbol{S}^{-1}=\begin{bmatrix} 1 & 0 & 0 \\ -1 & 1 & 0 \\ 0 & -1 & 1 \end{bmatrix}$$

$\boldsymbol{A}$ 不可逆因为它的行列式为 $4\cdot 6-3\cdot 8=24-24=0$. $\boldsymbol{D}$ 不可逆因为它只有一个主元; 第二行减去第一行为 0. $\boldsymbol{T}$ 有两个相同的列 (第二列减去第一列等于 0). 换句话说, $\boldsymbol{Tx}=\boldsymbol{0}$ 有非零解 $\boldsymbol{x}=\begin{bmatrix} -1 & 1 & 0 \end{bmatrix}^{\mathrm{T}}$. 它们都不可逆.

### 2.2.2　矩阵乘积 $AB$ 的逆

对两个非零数 $a$ 和 $b$, $a+b$ 可能可逆也可能不可逆. $a=3$ 和 $b=-3$ 有逆 $\frac{1}{3}$ 和 $-\frac{1}{3}$. 它们的和 $a+b=0$ 不可逆. 但是它们的乘积 $ab=-9$ 有逆，逆为 $\frac{1}{3}$ 乘 $-\frac{1}{3}$.

对矩阵 $\boldsymbol{A}$ 和 $\boldsymbol{B}$, 情况是类似的. 它们的乘积 $\boldsymbol{AB}$ 可逆当且仅当 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 都是可逆的 (而且阶数相同). 重点是 $\boldsymbol{A}^{-1}$ 和 $\boldsymbol{B}^{-1}$ 相乘的顺序是反过来的:

如果 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 是阶数相同的可逆矩阵，那么 $\boldsymbol{AB}$ 的逆矩阵为 $\boldsymbol{B}^{-1}\boldsymbol{A}^{-1}$:

$$(\boldsymbol{AB})^{-1}=\boldsymbol{B}^{-1}\boldsymbol{A}^{-1} \qquad (\boldsymbol{AB})\left(\boldsymbol{B}^{-1}\boldsymbol{A}^{-1}\right)=\boldsymbol{AIA}^{-1}=\boldsymbol{AA}^{-1}=\boldsymbol{I} \tag{2.14}$$

我们利用结合律，移动括号的位置，先计算 $\boldsymbol{B}\boldsymbol{B}^{-1}$. 类似可得 $\boldsymbol{B}^{-1}\boldsymbol{A}^{-1}$ 乘以 $\boldsymbol{A}\boldsymbol{B}$ 等于 $\boldsymbol{I}$.

$\boldsymbol{B}^{-1}\boldsymbol{A}^{-1}$ 反映了一个基本的数学规则: 逆总是反序的. 这是一个基本常识: 如果你先穿袜子后穿鞋, 那么你先脱的会是什么呢？类似的规则对于三个或更多矩阵相乘也是成立的:

$$\text{逆序} \qquad (\boldsymbol{A}\boldsymbol{B}\boldsymbol{C})^{-1} = \boldsymbol{C}^{-1}\boldsymbol{B}^{-1}\boldsymbol{A}^{-1} \tag{2.15}$$

**例 2.4 (倍加矩阵的逆)** 如果 $\boldsymbol{E}$ 是将第二行减去第一行的 5 倍，那么 $\boldsymbol{E}^{-1}$ 就是将第二行加上第一行的 5 倍:

$\boldsymbol{E}$ 减
则 $\boldsymbol{E}^{-1}$ 加

$$\boldsymbol{E} = \begin{bmatrix} 1 & 0 & 0 \\ -5 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \qquad \boldsymbol{E}^{-1} = \begin{bmatrix} 1 & 0 & 0 \\ 5 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

$\boldsymbol{E}\boldsymbol{E}^{-1}$ 和 $\boldsymbol{E}^{-1}\boldsymbol{E}$ 的结果都是 $\boldsymbol{I}$. 我们将第二行加上和减去了第一行的 5 倍. 如果 $\boldsymbol{A}$、$\boldsymbol{C}$ 都是方阵，且 $\boldsymbol{A}\boldsymbol{C} = \boldsymbol{I}$，那么同样有 $\boldsymbol{C}\boldsymbol{A} = \boldsymbol{I}$.

对方阵而言，其左（右）逆也是其右（左）逆.

**例 2.5** 设 $\boldsymbol{F}$ 也是倍加矩阵，它将第三行减去第二行的 4 倍，$\boldsymbol{F}^{-1}$ 会把它加回去:

$$\boldsymbol{F} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -4 & 1 \end{bmatrix}, \quad \text{则} \quad \boldsymbol{F}^{-1} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 4 & 1 \end{bmatrix}.$$

现在将 $\boldsymbol{F}$ 乘以例 2.4中的 $\boldsymbol{E}$ 得到 $\boldsymbol{F}\boldsymbol{E}$. 同样将 $\boldsymbol{E}^{-1}$ 乘以 $\boldsymbol{F}^{-1}$ 得到 $(\boldsymbol{F}\boldsymbol{E})^{-1}$. 注意 $\boldsymbol{F}\boldsymbol{E}$ 和 $\boldsymbol{E}^{-1}\boldsymbol{F}^{-1}$ 的顺序!

$$\boldsymbol{F}\boldsymbol{E} = \begin{bmatrix} 1 & 0 & 0 \\ -5 & 1 & 0 \\ 20 & -4 & 1 \end{bmatrix} \quad \text{的逆是} \quad \boldsymbol{E}^{-1}\boldsymbol{F}^{-1} = \begin{bmatrix} 1 & 0 & 0 \\ 5 & 1 & 0 \\ 0 & 4 & 1 \end{bmatrix}. \tag{2.16}$$

结果是“漂亮”而正确的. 乘积 $\boldsymbol{F}\boldsymbol{E}$ 里有“20”，但是它的逆没有. $\boldsymbol{E}$ 将第二行减去第一行的 5 倍. 然后 $\boldsymbol{F}$ 将第三行减去新的第二行 (增加了第一行) 的 4 倍. 按这个顺序，第三行实际上加上了第一行的 20 倍.

在 $\boldsymbol{E}^{-1}\boldsymbol{F}^{-1}$ 中并没有这样的变化. 首先 $\boldsymbol{F}^{-1}$ 将第三行加上第二行的 4 倍，然后 $\boldsymbol{E}^{-1}$ 将第二行加上第一行的 5 倍. 这里并没有“20”，因为第三行没有发生变化. 按照 $\boldsymbol{E}^{-1}\boldsymbol{F}^{-1}$ 的顺序，第三行并没受到第一行的影响.

这也是我们为什么要考虑 $\boldsymbol{A} = \boldsymbol{L}\boldsymbol{U}$, 以实现从上三角阵 $\boldsymbol{U}$ 到 $\boldsymbol{A}$ 的转化. 倍数完美地落在下三角阵 $\boldsymbol{L}$ 的对应的位置: 见式(2.18).

消元的顺序是 $\boldsymbol{F}\boldsymbol{E}$，逆的顺序是 $\boldsymbol{L} = \boldsymbol{E}^{-1}\boldsymbol{F}^{-1}$.
倍数 5 和 4 处于 $\boldsymbol{L}$ 对角线的下方.

### 2.2.3　$L$ 是 $E$ 的逆

$\boldsymbol{E}$ 是所有初等矩阵 $\boldsymbol{E}_{ij}$ 的乘积，它将 $\boldsymbol{A}$ 转化为上三角阵 $\boldsymbol{EA}=\boldsymbol{U}$；这里我们假设没有行对换 ($\boldsymbol{P}=\boldsymbol{I}$). 因为我们并没有一个好的公式来计算这些初等矩阵 $\boldsymbol{E}_{ij}$ 的乘积，求 $\boldsymbol{E}$ 是困难的. 但是当我们将 $\boldsymbol{E}_{ij}^{-1}$ 乘起来，逆矩阵 $\boldsymbol{E}^{-1}$ 变得非常漂亮. 牢记，这些乘积要用相反的顺序.

当 $n=3$ 时，乘积 $\boldsymbol{E}=\boldsymbol{E}_{32}\boldsymbol{E}_{31}\boldsymbol{E}_{21}$ 的复杂性体现在左下角:

$$\boldsymbol{E}=\begin{bmatrix}1&&\\0&1&\\0&-\ell_{32}&1\end{bmatrix}\begin{bmatrix}1&&\\0&1&\\-\ell_{31}&0&1\end{bmatrix}\begin{bmatrix}1&&\\-\ell_{21}&1&\\0&0&1\end{bmatrix}=\begin{bmatrix}1&&\\-\ell_{21}&1&\\(\ell_{32}\ell_{21}-\ell_{31})&-\ell_{32}&1\end{bmatrix}\tag{2.17}$$

反过来是非常好的顺序，因为可以看到在 $\boldsymbol{E}^{-1}=\boldsymbol{L}$ 中并没有这样的混合项:

$$\boldsymbol{E}^{-1}=\begin{bmatrix}1&&\\\ell_{21}&1&\\0&0&1\end{bmatrix}\begin{bmatrix}1&&\\0&1&\\\ell_{31}&0&1\end{bmatrix}\begin{bmatrix}1&&\\0&1&\\0&\ell_{32}&1\end{bmatrix}=\begin{bmatrix}1&&\\\ell_{21}&1&\\\ell_{31}&\ell_{32}&1\end{bmatrix}=\boldsymbol{L}\tag{2.18}$$

所有的倍数 $\ell_{ij}$ 都在 $\boldsymbol{L}$ 中的正确的位置上. 下一节我们将证明这件事对任意阶的矩阵也都是对的. 消元法 $\boldsymbol{EA}=\boldsymbol{U}$ 将成为 $LU$ 分解 $\boldsymbol{A}=\boldsymbol{LU}$.

式(2.18)是本章的重点：每一个 $\ell_{ij}$ 都在 $\boldsymbol{E}^{-1}=\boldsymbol{L}$ 中有属于它的位置.

## 习题 2.2

0. 如果交换可逆矩阵 $\boldsymbol{A}$ 的第一列和第二列, $\boldsymbol{A}^{-1}$ 有什么变化？

问题 1 ~ 11 和初等矩阵相关.

1. 写出下列初等行变换对应的 $3\times3$ 初等矩阵：

(1) $\boldsymbol{E}_{21}$ 将第 2 行减去第 1 行的 5 倍.

(2) $\boldsymbol{E}_{32}$ 将第 3 行减去第 2 行的 $-7$ 倍.

(3) $\boldsymbol{P}$ 先交换第 1 行和第 2 行, 然后交换第 2 行和第 3 行.

2. 在第 1 题中, 对 $\boldsymbol{b}=\begin{bmatrix}1&0&0\end{bmatrix}^{\mathrm{T}}$ 先作用 $\boldsymbol{E}_{21}$ 再作用 $\boldsymbol{E}_{32}$ 得到向量 $\boldsymbol{E}_{32}\boldsymbol{E}_{21}\boldsymbol{b}=$_____. 先作用 $\boldsymbol{E}_{32}$ 再作用 $\boldsymbol{E}_{21}$ 得到向量 $\boldsymbol{E}_{21}\boldsymbol{E}_{32}\boldsymbol{b}=$_____. 当 $\boldsymbol{E}_{32}$ 先作用时, 第_____ 行对第_____ 行没有影响.

3. 哪三个初等矩阵 $\boldsymbol{E}_{21}$、$\boldsymbol{E}_{31}$、$\boldsymbol{E}_{32}$ 将 $\boldsymbol{A}$ 化为三角阵 $\boldsymbol{U}$？

$$\boldsymbol{A}=\begin{bmatrix}1&1&0\\4&6&1\\-2&2&0\end{bmatrix}\qquad\text{以及}\qquad\boldsymbol{E}_{32}\boldsymbol{E}_{31}\boldsymbol{E}_{21}\boldsymbol{A}=\boldsymbol{EA}=\boldsymbol{U}.$$

将这些矩阵乘起来得到初等变换矩阵 $\boldsymbol{E}$. $\boldsymbol{E}^{-1}=\boldsymbol{L}$ 等于什么？

4. 将 $\boldsymbol{b}=\begin{bmatrix}1&0&0\end{bmatrix}^{\mathrm{T}}$ 添加到习题 3 中的矩阵 $\boldsymbol{A}$ 的最右边作为第四列得到增广矩阵 $\begin{bmatrix}\boldsymbol{A}&\boldsymbol{b}\end{bmatrix}$. 对这个增广矩阵作初等变换，求解方程组 $\boldsymbol{Ax}=\boldsymbol{b}$.

5. 假设 $3\times 3$ 矩阵右下角元素 $a_{33}=7$ 以及第三个主元为 5. 如果将 $a_{33}$ 改为 11，第三个主元将变成_____. 如果将 $a_{33}$ 变为_____，将不会有第三个主元.

6. 如果 $\boldsymbol{A}$ 的每一列都是 $\begin{bmatrix}1 & 1 & 1\end{bmatrix}^{\mathrm{T}}$ 的倍数，那么 $\boldsymbol{Ax}$ 总是 $\begin{bmatrix}1 & 1 & 1\end{bmatrix}^{\mathrm{T}}$ 的倍数. 举一个 $3\times 3$ 矩阵的例子. 通过初等行变换可以得到几个主元?

7. 假设 $\boldsymbol{E}$ 将第 3 行减去第 1 行的 7 倍.

（1）上述操作的逆操作是：将第_____ 行_____（加到或者减去）第_____ 行的 7 倍.

（2）实现了上述操作的逆矩阵 $\boldsymbol{E}^{-1}(\boldsymbol{E}^{-1}\boldsymbol{E}=\boldsymbol{I})$ 是什么?

（3）如果先进行逆操作 $\boldsymbol{E}^{-1}$，再进行 $\boldsymbol{E}$，证明 $\boldsymbol{EE}^{-1}=\boldsymbol{I}$.

8. 矩阵 $\boldsymbol{M}=\begin{bmatrix}a & b\\ c & d\end{bmatrix}$ 的行列式为 $\det \boldsymbol{M}=ad-bc$. 将其第 2 行减去第 1 行的 $\ell$ 倍得到新的矩阵 $\boldsymbol{M}^{*}$. 证明：对于任意 $\ell$ 都有 $\det \boldsymbol{M}^{*}=\det \boldsymbol{M}$. 当 $\ell=c/a$ 时，主元的乘积等于行列式的值: $(a)(d-\ell b)=ad-bc$.

9. 本题的矩阵都是 $3\times 3$ 矩阵.

（1）$\boldsymbol{E}_{21}$ 将第 2 行减去第 1 行，然后 $\boldsymbol{P}_{23}$ 交换了第 2 行和第 3 行. 当两步一起操作时 $\boldsymbol{M}=\boldsymbol{P}_{23}\boldsymbol{E}_{21}$ 是什么?

（2）$\boldsymbol{P}_{23}$ 交换了第 2 行和第 3 行，然后 $\boldsymbol{E}_{31}$ 将第 3 行减去第 1 行. 当两步一起操作时 $\boldsymbol{M}=\boldsymbol{E}_{31}\boldsymbol{P}_{23}$ 是什么? 解释一下为什么这两个小题中 $\boldsymbol{M}$ 相同但是 $\boldsymbol{E}$ 不一样

10.（1）左乘哪个矩阵使得第 3 行加上第 1 行同时第 1 行加上第 3 行?

（2）左乘哪个矩阵使得第 3 行加上第 1 行然后使第 1 行加上第 3 行?

11. 构造一个 $3\times 3$ 矩阵，使得 $a_{11}=a_{22}=a_{33}=1$，但是不需要行对换就能通过倍加变换得到两个负的主元（第一个主元是 1）.

12. 对于以下置换矩阵 $\boldsymbol{P}$，请通过试错法（即在矩阵的不同位置放置 1 和 0）求出其逆矩阵 $\boldsymbol{P}^{-1}$:

$$\boldsymbol{P}=\begin{bmatrix}0 & 0 & 1\\ 0 & 1 & 0\\ 1 & 0 & 0\end{bmatrix}\quad \text{以及}\quad \boldsymbol{P}=\begin{bmatrix}0 & 1 & 0\\ 0 & 0 & 1\\ 1 & 0 & 0\end{bmatrix}.$$

13. 求解 $\boldsymbol{A}^{-1}$ 的第一列 $\begin{bmatrix}x & y\end{bmatrix}^{\mathrm{T}}$ 和第二列 $\begin{bmatrix}t & z\end{bmatrix}^{\mathrm{T}}$. 再计算 $\boldsymbol{AA}^{-1}$ 进行检验.

$$\boldsymbol{A}=\begin{bmatrix}10 & 20\\ 20 & 50\end{bmatrix},\qquad \begin{bmatrix}10 & 20\\ 20 & 50\end{bmatrix}\begin{bmatrix}x\\ y\end{bmatrix}=\begin{bmatrix}1\\ 0\end{bmatrix},\qquad \text{以及}\qquad \begin{bmatrix}10 & 20\\ 20 & 50\end{bmatrix}\begin{bmatrix}t\\ z\end{bmatrix}=\begin{bmatrix}0\\ 1\end{bmatrix}.$$

14. 构造一个上三角矩阵 $\boldsymbol{U}$(非对角) 使得 $\boldsymbol{U}^{2}=\boldsymbol{I}$. 那么 $\boldsymbol{U}^{-1}=\boldsymbol{U}$.

15.（1）如果 $\boldsymbol{A}$ 可逆而且 $\boldsymbol{AB}=\boldsymbol{AC}$, 证明 $\boldsymbol{B}=\boldsymbol{C}$.

（2）如果 $\boldsymbol{A}=\begin{bmatrix}1 & 1\\ 1 & 1\end{bmatrix}$，找到两个不同的矩阵 $\boldsymbol{B}$、$\boldsymbol{C}$，使得 $\boldsymbol{AB}=\boldsymbol{AC}$.

16.（推荐）分别从以下 3 个角度证明：如果 $\boldsymbol{A}$ 的第 1 行加上第 2 行等于第 3 行，则 $\boldsymbol{A}$ 不可逆.

（1）解释为什么 $\boldsymbol{Ax}=\begin{bmatrix}0 & 0 & 1\end{bmatrix}^{\mathrm{T}}$ 无解.（提示：将第一个方程加上第二个方程.）

（2）向量 $\begin{bmatrix} b_1 & b_2 & b_3 \end{bmatrix}^{\mathrm{T}}$ 满足什么条件，可以使得方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 有解？

（3）在消元法下，第 3 行变成什么？

17. 分别从以下 2 个角度证明：如果 $\boldsymbol{A}$ 的第 1 列加上第 2 列等于第 3 列，则 $\boldsymbol{A}$ 不可逆.

（1）如果 $\boldsymbol{A}$ 是 $3\times 3$ 矩阵，求 $\boldsymbol{Ax}=\boldsymbol{0}$ 的一个非零解 $\boldsymbol{x}$.

（2）消元法得到的矩阵也满足：第 1 列加上第 2 列等于第 3 列. 说明为什么没有第 3 个主元.

18. 假设 $\boldsymbol{A}$ 可逆，交换它的前两行得到矩阵 $\boldsymbol{B}$. 矩阵 $B$ 可逆吗？如何从 $\boldsymbol{A}^{-1}$ 构造出 $\boldsymbol{B}^{-1}$？

19.（1）构造可逆矩阵 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 使得 $\boldsymbol{A}+\boldsymbol{B}$ 不可逆.

（2）构造奇异矩阵 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 但是 $\boldsymbol{A}+\boldsymbol{B}$ 可逆.

20. 如果 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 是同阶方阵，且乘积 $\boldsymbol{C}=\boldsymbol{AB}$ 可逆，证明：$\boldsymbol{A}$ 可逆. 用 $\boldsymbol{C}^{-1}$ 和 $\boldsymbol{B}$ 来表示 $\boldsymbol{A}^{-1}$.

21. 如果 $\boldsymbol{A}$、$\boldsymbol{B}$、$\boldsymbol{C}$ 是同阶方阵，且乘积 $\boldsymbol{M}=\boldsymbol{ABC}$ 可逆，证明：$\boldsymbol{B}$ 可逆.（事实上，$\boldsymbol{A}$ 和 $\boldsymbol{C}$ 也可逆.）用 $\boldsymbol{M}^{-1}$, $\boldsymbol{A}$ 和 $\boldsymbol{C}$ 来表示 $\boldsymbol{B}^{-1}$.

22. 如果将 $\boldsymbol{A}$ 的第 1 行加到第 2 行得到 $\boldsymbol{B}$，如何从 $\boldsymbol{A}^{-1}$ 得到 $\boldsymbol{B}^{-1}$？

23. 证明：有一列全是零元素的矩阵不可逆.

24. 将 $\begin{bmatrix} a & b \\ c & d \end{bmatrix}$ 与 $\begin{bmatrix} d & -b \\ -c & a \end{bmatrix}$ 相乘. 如果 $ad\neq bc$，这两个矩阵的逆是什么？

25.（1）哪个 $3\times 3$ 初等矩阵 $\boldsymbol{E}$ 实现了如下三步操作：先将第 2 行减去第 1 行，再将第 3 行减去第 1 行, 最后将第 3 行减去第 2 行.

（2）哪个矩阵 $\boldsymbol{L}$ 等同于上述操作的逆操作？先将第 3 行加上第 2 行，再将第 3 行加上第 1 行，最后将第 2 行加上第 1 行.

26. 如果 $\boldsymbol{B}$ 是 $\boldsymbol{A}^2$ 的逆, 证明:$\boldsymbol{AB}$ 是 $\boldsymbol{A}$ 的逆.

27. 证明矩阵 $\boldsymbol{A}=4\boldsymbol{I}(4)-\mathrm{ones}(4,4)$[①]不可逆. 提示：计算 $\boldsymbol{A}\mathrm{ones}(4,1)$.

28. 每个元素均取值 1 或者 0 的 $2\times 2$ 矩阵一共有 16 个，其中有多少个可逆？

29.（高斯-若尔当消元）对 $\begin{bmatrix} \boldsymbol{A} & \boldsymbol{I} \end{bmatrix}$ 消元，把 $\boldsymbol{A}$ 转换为 $\boldsymbol{I}$ 的同时，$\boldsymbol{I}$ 转换为 $\boldsymbol{A}^{-1}$. 对以下两例完成这个操作.

$$\begin{bmatrix} \boldsymbol{A} & \boldsymbol{I} \end{bmatrix}=\begin{bmatrix} 1 & 3 & 1 & 0 \\ 2 & 7 & 0 & 1 \end{bmatrix} \qquad \begin{bmatrix} \boldsymbol{A} & \boldsymbol{I} \end{bmatrix}=\begin{bmatrix} 1 & 4 & 1 & 0 \\ 3 & 9 & 0 & 1 \end{bmatrix}$$

30. 如果 $4\times 4$ 矩阵 $\boldsymbol{A}$ 的每一行都是 0、1、2、3 的某个排列，那么 $\boldsymbol{A}$ 可逆吗？如果 $4\times 4$ 矩阵的每一行都是 0、1、2、$-3$ 的某个排列，那么它可逆吗？

31. 通过对 $\begin{bmatrix} \boldsymbol{A} & \boldsymbol{I} \end{bmatrix}$ 和 $\begin{bmatrix} \boldsymbol{B} & \boldsymbol{I} \end{bmatrix}$ 消元求出 $\boldsymbol{A}^{-1}$ 和 $\boldsymbol{B}^{-1}$（如果存在）：

$$\boldsymbol{A}=\begin{bmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 2 \end{bmatrix} \qquad \boldsymbol{B}=\begin{bmatrix} 2 & -1 & -1 \\ -1 & 2 & -1 \\ -1 & -1 & 2 \end{bmatrix}.$$

32. 对矩阵 $\begin{bmatrix} \boldsymbol{U} & \boldsymbol{I} \end{bmatrix}$ 进行高斯-若尔当消元可得到 $\begin{bmatrix} \boldsymbol{I} & \boldsymbol{U}^{-1} \end{bmatrix}$:

① 译者注：$\mathrm{ones}(m,n)$ 是元素都是 1 的 $m\times n$ 矩阵，称作 $m\times n$ 全 1 矩阵.

如果 $\boldsymbol{U}=\begin{bmatrix}1 & a & b\\ 0 & 1 & c\\ 0 & 0 & 1\end{bmatrix}$，那么 $\boldsymbol{U}^{-1}=\begin{bmatrix}\quad & \quad & \quad\\ \quad & \quad & \quad\\ \quad & \quad & \quad\end{bmatrix}$.

33. 判断正误（正确则简述其理由，错误则给出反例）：设 $\boldsymbol{A}$ 是方阵.

（1）存在某一行全为零的 $4\times 4$ 矩阵不可逆.

（2）对角线下方全为 1 的矩阵可逆.

（3）如果 $\boldsymbol{A}$ 可逆，那么 $\boldsymbol{A}^{-1}$ 和 $\boldsymbol{A}^2$ 也可逆.

34.（推荐）

（1）设 $\boldsymbol{A}=\begin{bmatrix}a & b & b\\ a & a & b\\ a & a & a\end{bmatrix}$，证明：如果 $a\neq 0$ 且 $a\neq b$，则 $\boldsymbol{A}$ 可逆.（提示：找出其主元或者求出 $\boldsymbol{A}^{-1}$.）

（2）设 $\boldsymbol{C}=\begin{bmatrix}2 & c & c\\ c & c & c\\ 8 & 7 & c\end{bmatrix}$，$c$ 取何值时 $\boldsymbol{C}$ 不可逆？

35. 设 $\boldsymbol{A}=\begin{bmatrix}1 & -1 & 1 & -1\\ 0 & 1 & -1 & 1\\ 0 & 0 & 1 & -1\\ 0 & 0 & 0 & 1\end{bmatrix}$，它的逆矩阵比较特别. 请通过对 $\begin{bmatrix}\boldsymbol{A} & \boldsymbol{I}\end{bmatrix}$ 消元求出 $\boldsymbol{A}^{-1}$. 将此结论推广到 $5\times 5$ 的“交替矩阵”并猜测它的逆，并通过矩阵乘法来确认你的猜测是否正确. 求 $\boldsymbol{A}$ 的逆矩阵，解方程组 $\boldsymbol{A}\boldsymbol{x}=\begin{bmatrix}1 & 1 & 1 & 1\end{bmatrix}^{\mathrm{T}}$.

36. 假设 $\boldsymbol{P}$、$\boldsymbol{Q}$、$\boldsymbol{I}$ 有相同的行向量，但是顺序不同，它们都是置换矩阵. 试通过解方程组 $(\boldsymbol{P}-\boldsymbol{Q})\boldsymbol{x}=\boldsymbol{0}$ 证明：$\boldsymbol{P}-\boldsymbol{Q}$ 不可逆.

37. 假设以下分块矩阵的逆矩阵都存在，求出它们的逆矩阵，并验证你的结论：

$$\begin{bmatrix}\boldsymbol{I} & \boldsymbol{0}\\ \boldsymbol{C} & \boldsymbol{I}\end{bmatrix}\qquad\begin{bmatrix}\boldsymbol{A} & \boldsymbol{0}\\ \boldsymbol{C} & \boldsymbol{D}\end{bmatrix}\qquad\begin{bmatrix}\boldsymbol{0} & \boldsymbol{I}\\ \boldsymbol{I} & \boldsymbol{D}\end{bmatrix}$$

38. 如何通过从 $3\times 3$ 矩阵 $\boldsymbol{A}$ 到 $\boldsymbol{U}$ 的初等行变换的过程来判断 $\boldsymbol{A}$ 可逆？

39. 设 $\boldsymbol{u}$、$\boldsymbol{v}$ 都是 $n$ 维列向量，$\boldsymbol{A}=\boldsymbol{I}-\boldsymbol{u}\boldsymbol{v}^{\mathrm{T}}$，令 $\boldsymbol{B}=\boldsymbol{I}+\boldsymbol{u}\boldsymbol{v}^{\mathrm{T}}\left(1-\boldsymbol{v}^{\mathrm{T}}\boldsymbol{u}\right)^{-1}$. 显然，只有当 $\boldsymbol{v}^{\mathrm{T}}\boldsymbol{u}\neq 1$ 时 $\boldsymbol{B}$ 才是良定义的. 证明：如果 $\boldsymbol{v}^{\mathrm{T}}\boldsymbol{u}=1$，则 $\boldsymbol{A}\boldsymbol{u}=\boldsymbol{0}$；如果 $\boldsymbol{v}^{\mathrm{T}}\boldsymbol{u}\neq 1$，则 $\boldsymbol{A}\boldsymbol{B}=\boldsymbol{I}$.

## 2.3 矩阵运算和 $LU$ 分解

（1）从 $\boldsymbol{A}$ 到 $\boldsymbol{U}$ 的消元大概要做 $\frac{1}{3}n^3$ 次乘法和减法.

（2）处理方程等号右边的 $\boldsymbol{b}$ 需要 $n^2$ 次运算：向下得到 $\boldsymbol{U}\boldsymbol{x}=\boldsymbol{c}$，然后回代得到 $\boldsymbol{x}$.

（3）如果不需要行对换，则消元法可以将 $\boldsymbol{A}$ 分解为 $\boldsymbol{L}\boldsymbol{U}$（两个关于 $\boldsymbol{A}=\boldsymbol{L}\boldsymbol{U}$ 分解的证明）.

如何计算 $n\times n$ 矩阵 $\boldsymbol{A}$ 的逆？在回答这个问题之前我们先要问：是不是真的需要知道 $\boldsymbol{A}^{-1}$？方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 的解（我们希望求的）可以由 $\boldsymbol{x}=\boldsymbol{A}^{-1}\boldsymbol{b}$ 给出，但是计算 $\boldsymbol{A}^{-1}$ 以及 $\boldsymbol{A}^{-1}\boldsymbol{b}$ 来求解 $\boldsymbol{x}$ 的效率是非常低的. 所以往往我们并不计算 $\boldsymbol{A}^{-1}$，但是对 $\boldsymbol{A}^{-1}$ 的充分理解是完全有必要的.

关于 $\boldsymbol{A}^{-1}$ 有一个简单的思路. 已知 $\boldsymbol{A}^{-1}$ 满足 $\boldsymbol{AA}^{-1}=\boldsymbol{I}$. 而单位矩阵 $\boldsymbol{I}$ 的 $n$ 列分别是 $\boldsymbol{e}_1,\boldsymbol{e}_2,\cdots,\boldsymbol{e}_n$，所以 $\boldsymbol{AA}^{-1}=\boldsymbol{I}$ 实际上是 $n$ 个方程组 $\boldsymbol{Ax}_1=\boldsymbol{e}_1,\boldsymbol{Ax}_2=\boldsymbol{e}_2,\cdots,\boldsymbol{Ax}_n=\boldsymbol{e}_n$，那么 $\boldsymbol{x}_k$ 就是 $\boldsymbol{A}^{-1}$ 的第 $k$ 列. 如果 $\boldsymbol{A}$ 是 $3\times 3$ 矩阵，那将有 3 个方程组：

$$\boldsymbol{AA}^{-1}=\boldsymbol{I}\qquad \boldsymbol{A}\begin{bmatrix}\boldsymbol{x}_1 & \cdots & \boldsymbol{x}_n\end{bmatrix}=\begin{bmatrix}\boldsymbol{e}_1 & \cdots & \boldsymbol{e}_n\end{bmatrix}\qquad \boldsymbol{A}\begin{bmatrix}\boldsymbol{x}_1 & \boldsymbol{x}_2 & \boldsymbol{x}_3\end{bmatrix}=\begin{bmatrix}1&0&0\\0&1&0\\0&0&1\end{bmatrix}. \tag{2.19}$$

我们需要求解 $n$ 个方程组，而它们的系数矩阵都是 $\boldsymbol{A}$，所以我们可以把它们捆在一起求解，这个方法称为“高斯-若尔当消元”. 与只在 $\boldsymbol{A}$ 右侧增加一列得到增广矩阵 $\begin{bmatrix}\boldsymbol{A} & \boldsymbol{b}\end{bmatrix}$ 不同，我们在 $\boldsymbol{A}$ 右侧增加 $\boldsymbol{I}$，即考虑 $\begin{bmatrix}\boldsymbol{A} & \boldsymbol{I}\end{bmatrix}$. 若消元法把 $\boldsymbol{A}$ 转化成 $\boldsymbol{I}$，则 $\boldsymbol{I}$ 转化成了 $\boldsymbol{A}^{-1}$.

$$\begin{bmatrix}\boldsymbol{A} & \boldsymbol{I}\end{bmatrix}=\left[\begin{array}{ccc|ccc}1&0&0&1&0&0\\-1&1&0&0&1&0\\0&-1&1&0&0&1\end{array}\right]\longrightarrow\left[\begin{array}{ccc|ccc}1&0&0&1&0&0\\0&1&0&1&1&0\\0&-1&1&0&0&1\end{array}\right]$$

$$\begin{array}{c}\text{高斯-若尔当消元}\\ \text{求解}\boldsymbol{AX}=\boldsymbol{I}\Longrightarrow\boldsymbol{X}=\boldsymbol{A}^{-1}\\ \text{比求解}\boldsymbol{Ax}=\boldsymbol{b}\text{ 速度慢}\end{array}\longrightarrow\left[\begin{array}{ccc|ccc}1&0&0&1&0&0\\0&1&0&1&1&0\\0&0&1&1&1&1\end{array}\right]=\begin{bmatrix}\boldsymbol{I} & \boldsymbol{A}^{-1}\end{bmatrix}$$

重点是消元法对 $\boldsymbol{A}$ 只操作一遍，而同样的步骤也要用在方程组等号右边——只不过 $\boldsymbol{AA}^{-1}=\boldsymbol{I}$ 有 $n$ 个右边. 方程组 $\boldsymbol{Ax}_i=\boldsymbol{e}_i$ 的解 $\boldsymbol{x}_i$ 恰好是 $\boldsymbol{A}^{-1}$ 的第 $i$ 列. 高斯-若尔当消元将 $\begin{bmatrix}\boldsymbol{A} & \boldsymbol{I}\end{bmatrix}$ 转化为 $\begin{bmatrix}\boldsymbol{I} & \boldsymbol{A}^{-1}\end{bmatrix}$，因为消元法相当于左乘了 $\boldsymbol{A}^{-1}$.

在这个例子中 $\boldsymbol{A}$ 的作用是在下面的行向量中减去上面的行，而 $\boldsymbol{A}^{-1}$ 的作用是加上. $\boldsymbol{AA}^{-1}=\boldsymbol{I}$ 是线性代数形式的微积分基本定理：对 $f(x)$ 积分再求导等于 $f(x)$.

### 2.3.1　消元法的计算复杂度

一个非常现实的问题是时间复杂度，或者说计算复杂度. 我们可以用计算机解 1000 个方程的方程组. 如果是 100 000 个方程呢？（$\boldsymbol{A}$ 是稠密的还是稀疏的？）科学计算总会遇到如何处理大型方程组的问题，一个三维的问题也可能存在百万量级的未知量. 我们可以等一个晚上，期待睡醒了之后就有一个好的结果，但是等不了 100 年.

将 $\boldsymbol{A}$ 简化为 $\boldsymbol{U}$ 第一步是通过消元法将第 1 列中主元下方的元素都转化为 0. 第 1 行下方的每一个新元素都需要一次乘法和一次减法. 粗略计算，完成这一步需要 $n^2$ 次乘法和 $n^2$ 次减法. 更精细地说，实际的结果应该是 $n^2-n$ 次，因为第 1 行无须处理.

下一步需要处理第 2 列中第二个主元下方的元素. 此时目标矩阵的阶数变为了 $n-1$. 这一步需要 $(n-1)^2$ 次乘法和减法. 每进行一步消元矩阵的阶数会降低 1. 粗略计算，为了得到 $\boldsymbol{U}$ 需要计算 $n^2+(n-1)^2+\cdots+2^2+1^2$ 次乘法和减法.

对上述平方求和，则计算量为 $\frac{1}{3}n\left(n+\frac{1}{2}\right)(n+1)$. 当 $n$ 充分大时，$\frac{1}{2}$ 和 1 并不重要，主项为 $\frac{1}{3}n^3$. 这个结果就像对 $x^2$ 做了积分！$x^2$ 从 0 到 $n$ 的积分是 $\frac{1}{3}n^3$：

**将 $\boldsymbol{A}$ 简化为 $\boldsymbol{U}$ 需要大概 $\frac{1}{3}n^3$ 次乘法和 $\frac{1}{3}n^3$ 次减法.**

那么处理等号右边的 $\boldsymbol{b}$ 的计算量有多大呢？向下计算，我们将 $b_2, b_3, \cdots, b_n$ 减去了 $b_1$ 的某个倍数，这需要 $n-1$ 次. 下一步需要 $n-2$ 次，因为这一步不需要处理 $b_1$. 最后一步向下的消元（从 $\boldsymbol{b}$ 到 $\boldsymbol{c}$）只需要 1 次运算.

现在考虑回代. $x_n$ 需要 1 次计算（除以最后一个主元）. 下一个未知量需要 2 次计算. 为了得到 $x_1$ 我们需要 $n$ 次计算（$n-1$ 次和其他未知量的减法，然后除以第一个主元）. 右侧的从 $\boldsymbol{b}$ 到 $\boldsymbol{c}$ 再到 $\boldsymbol{x}$——向下到最后一行然后向后回到第一行——总的计算量是 $n^2$：

$$[(n-1)+(n-2)+\cdots+1]+[1+2+\cdots+(n-1)+n]=\boldsymbol{n^2}. \tag{2.20}$$

这个求和相对简单，将 $(n-1)$ 与 1 组合，$(n-2)$ 与 2 组合. 这样的组合共有 $n$ 个，每一个都等于 $n$. 所以最后的结果是 $n^2$. 从 $\boldsymbol{b}$ 到 $\boldsymbol{c}$ 再到 $\boldsymbol{x}$ 的计算量远远低于左侧！

**回代　　方程组右边需要 $n^2$ 次的乘法和减法.**

**求解 $\boldsymbol{Ax=b}$ 需要多长时间？**对于一个阶数 $n=1000$ 的随机矩阵，一般计算机只需要 1 秒. 如果 $n$ 乘以 2 那么计算时间会乘以 8.

根据 $n^3$ 性质，矩阵如果扩大 10 倍（到 10000 阶）计算时间将达到 1000 秒. 10 万阶矩阵将使计算时间达到 100 万秒. 如果没有超级计算机这将花费太多时间，但是注意这个矩阵是稠密的. 实际情况中多数大型矩阵是稀疏的（存在非常多的零）. 这样一来 $\boldsymbol{A=LU}$ 将快得多.

### 2.3.2 证明 $LU$ 分解

消元法的矩阵表示一般是 $\boldsymbol{EA=U}$，然后转化为 $\boldsymbol{LU=A}$. 2.2节中的式(2.18)给出了如何将倍数 $\ell_{ij}$ 移动到右边构成 $\boldsymbol{E^{-1}}$——也就是 $\boldsymbol{L}$——的方法.

为什么我们要给一个对任意 $n$ 都成立的证明？原因是：如果我们仅仅观察到某些现象，然后凭借直觉就去相信或者欣赏它，那么这种认知过于肤浅. 只有逻辑上完备的证明，才是真理，才具有说服力. 对于规律的理解，离不开严格的证明.

### 2.3.3 伟大的 $A=LU$ 分解

让我们回顾向下消元、从矩阵 $\boldsymbol{A}$ 开始得到上三角阵 $\boldsymbol{U}$ 的步骤. 暂时不考虑行对换. 每个初等矩阵 $\boldsymbol{E}_{ij}$ 都是下三角矩阵. 这些 $\boldsymbol{E}_{ij}$ 的作用是将第 $j$ 个方程减去第 $i$ 个方程的 $\ell_{ij}$ 倍.

对初等矩阵 $\boldsymbol{E}_{ij}$ 取逆，我们不做减法而改做加法：

$$\boldsymbol{E}_{31}=\begin{bmatrix}1&0&0\\0&1&0\\-\ell_{31}&0&1\end{bmatrix}\qquad \boldsymbol{L}_{31}=\boldsymbol{E}_{31}^{-1}=\begin{bmatrix}1&0&0\\0&1&0\\\ell_{31}&0&1\end{bmatrix}.$$

2.2节中的式(2.17)说明了对 $\boldsymbol{E}_{32}\boldsymbol{E}_{31}\boldsymbol{E}_{21}$ 取逆，则有 $\boldsymbol{L}=\boldsymbol{E}_{21}^{-1}\boldsymbol{E}_{31}^{-1}\boldsymbol{E}_{32}^{-1}$：

$$\boldsymbol{E}^{-1}=\begin{bmatrix}1&0&0\\\ell_{21}&1&0\\0&0&1\end{bmatrix}\begin{bmatrix}1&0&0\\0&1&0\\\ell_{31}&0&1\end{bmatrix}\begin{bmatrix}1&0&0\\0&1&0\\0&\ell_{32}&1\end{bmatrix}=\begin{bmatrix}1&0&0\\\ell_{21}&1&0\\\ell_{31}&\ell_{32}&1\end{bmatrix}=\boldsymbol{L}.$$

所以我们把消元 $\boldsymbol{EA}=\boldsymbol{U}$ 反过来，从 $\boldsymbol{U}$ 得到 $\boldsymbol{A}$，则 $\boldsymbol{A}=\boldsymbol{E}^{-1}\boldsymbol{U}=\boldsymbol{LU}$. 下面我们希望证明这个结论对于任意 $n$ 都是对的. $\boldsymbol{A}=\boldsymbol{LU}$ 是线性代数中最伟大的分解之一.

下面的方法有助于理解为什么 $\boldsymbol{L}$ 的各个位置都只是 $\ell_{ij}$，没有混合项.

**$\boldsymbol{A}=\boldsymbol{LU}$ 的本质：**把主元所在行减到下面各行去的时候，它们还是原来的 $\boldsymbol{A}$ 的行吗？不是，消元改变了行向量. 那它们是 $\boldsymbol{U}$ 的各行吗？是的，因为主元所在的行不会再发生变化. 当计算 $\boldsymbol{U}$ 的第 3 行时，我们减去了 $\boldsymbol{U}$（并不是初始的 $\boldsymbol{A}$ 中的行）前几行的若干倍：

$$\boldsymbol{U}\text{ 的第 3 行}=(\boldsymbol{A}\text{ 的第 3 行})-\ell_{31}(\boldsymbol{U}\text{ 的第 1 行})-\ell_{32}(\boldsymbol{U}\text{ 的第 2 行}).\tag{2.21}$$

将这一等式改写，可以看到我们是用向量 $\begin{bmatrix}\ell_{31}&\ell_{32}&1\end{bmatrix}$ 乘以矩阵 $\boldsymbol{U}$：

$$\boldsymbol{A}\text{ 的第 3 行}=\ell_{31}(\boldsymbol{U}\text{ 的第 1 行})+\ell_{32}(\boldsymbol{U}\text{ 的第 2 行})+(\boldsymbol{U}\text{ 的第 3 行}).\tag{2.22}$$

这恰好就是 $\boldsymbol{A}=\boldsymbol{LU}$ 的第 3 行. $\boldsymbol{L}$ 的第 3 行为 $\ell_{31},\ell_{32},1$. 无论 $\boldsymbol{A}$ 多大. 所有行的变化行为都与之类似，但凡不需要做行对换，我们都能得到 $\boldsymbol{A}=\boldsymbol{LU}$.

### 2.3.4　$\boldsymbol{A}=\boldsymbol{LU}$ 的第二种证明：将列乘以行

下面我给出 $\boldsymbol{A}=\boldsymbol{LU}$ 的另一种证明. 根本思想是递归，具体来说，将消元法看作将 $\boldsymbol{A}$ 减去 $\boldsymbol{L}$ 的一列乘以 $\boldsymbol{U}$ 的一行. 每进行一次，矩阵的阶数减少 1.

消元从主元行，即 $\boldsymbol{A}$ 的第一行开始. 我们将这一主元行乘以 $\ell_{21}$、$\ell_{31}$ 直到 $\ell_{n1}$，然后将 $\boldsymbol{A}$ 的第 2 行、第 3 行直到第 $n$ 行减去第一行相应的倍数，其中 $\ell_{21}=a_{21}/a_{11},\ell_{31}=a_{31}/a_{11},\cdots,\ell_{n1}=a_{n1}/a_{11}$，这些操作得到了第一列中的那些 0.

$$\text{第一步把 }\boldsymbol{A}\text{ 减去 }\begin{bmatrix}1(\text{第 1 行})\\\ell_{21}(\text{第 1 行})\\\vdots\\\ell_{n1}(\text{第 1 行})\end{bmatrix},\text{ 剩下 }\boldsymbol{A}_2=\begin{bmatrix}0&0&\cdots&0\\0&*&\cdots&*\\\vdots&*&\cdots&\\0&*&\cdots&*\end{bmatrix}$$

这一步我们干了什么呢？移除了一个秩 1 矩阵！即列向量 $\boldsymbol{\ell}_1=\begin{bmatrix}1&\ell_{21}&\ell_{31}&\ell_{41}\end{bmatrix}^{\mathrm{T}}$ 乘以 $\boldsymbol{A}$ 的第 1 行——第一个主元行 $\boldsymbol{u}_1$.

现在对于 $\boldsymbol{A}_2$ 我们通过类似的步骤可以得到 $\boldsymbol{A}_3$：

$$\text{第二步把 } \boldsymbol{A}_2 \text{ 减去 } \begin{bmatrix} 0(\boldsymbol{A}_2\text{的第 2 行}) \\ 1(\boldsymbol{A}_2\text{的第 2 行}) \\ \ell_{32}(\boldsymbol{A}_2\text{的第 2 行}) \\ \vdots \\ \ell_{n2}(\boldsymbol{A}_2\text{的第 2 行}) \end{bmatrix}, \text{ 剩下 } \boldsymbol{A}_3 = \begin{bmatrix} 0 & 0 & \cdots & 0 \\ 0 & 0 & \cdots & 0 \\ \vdots & \vdots & * & * \\ 0 & 0 & * & * \end{bmatrix}$$

$\boldsymbol{A}_2$ 的第二行是第二个主元行——$\boldsymbol{U}$ 的第二行 $\boldsymbol{u}_2$. 我们减去了列 $\boldsymbol{\ell}_2 = \begin{bmatrix} 0 & 1 & \ell_{32} & \cdots & \ell_{n2} \end{bmatrix}^{\mathrm{T}}$ 乘以第 2 个主元行. 继续这样的步骤，每一步都减去了 $\boldsymbol{L}$ 的一列 $\boldsymbol{\ell}_j$ 乘以 $\boldsymbol{U}$ 的一个主元行 $\boldsymbol{u}_j$. 现在把这些加到一起：

$$\boldsymbol{A} = \underbrace{\boldsymbol{\ell}_1\boldsymbol{u}_1 + \boldsymbol{\ell}_2\boldsymbol{u}_2 + \cdots + \boldsymbol{\ell}_n\boldsymbol{u}_n}_{\text{列向量乘以行向量}} = \begin{bmatrix} \boldsymbol{\ell}_1 & \cdots & \boldsymbol{\ell}_n \end{bmatrix} \begin{bmatrix} \boldsymbol{u}_1 \\ \cdots \\ \boldsymbol{u}_n \end{bmatrix} = \boldsymbol{LU} \tag{2.23}$$

理解这个等式的关键是理解矩阵乘法，列向量乘以行向量再相加，这就是 $\boldsymbol{L}$ 乘以 $\boldsymbol{U}$. 这在第 1 章的末尾进行过介绍. 在本节的课后习题中将对这种 $\boldsymbol{LU}$ 的形式加以复习——把秩 1 矩阵相加（$\boldsymbol{L}$ 的列乘以 $\boldsymbol{U}$ 的行）.

注意到 $\boldsymbol{U}$ 是上三角矩阵，主元行 $\boldsymbol{u}_k$ 的前 $k-1$ 个元素为 0. $\boldsymbol{L}$ 是下三角矩阵并且主对角线元素为 1，因此列向量 $\boldsymbol{\ell}_k$ 的前 $k-1$ 个元素同样为 0.

### 2.3.5 不包含行对换的消元法

在 2.4 节将考虑包括行对换 $\boldsymbol{P}_{ij}$ 的情况，它们把主元位置的 0 移走. 在这之前，我们先回答一个基本问题：在什么条件下，消元不需要行对换、主元都非零以及 $\boldsymbol{A} = \boldsymbol{LU}$ 成立？

答：$\boldsymbol{A}$ 左上角位置的所有 $k \times k$ 子矩阵都必须可逆（$k = 1, 2, \cdots, n$）. 这样的子矩阵称作 $\boldsymbol{A}$ 的顺序子矩阵.

用分块矩阵来看，消元实际上是把 $\boldsymbol{A}$ 的这些 $k \times k$ 子矩阵作为因子，来消下面的分块. 这些子矩阵 $\boldsymbol{A}_k$ 等于 $\boldsymbol{L}_k\boldsymbol{U}_k$（$\boldsymbol{L}$ 和 $\boldsymbol{U}$ 的 $k$ 阶顺序子矩阵都可逆）.

$$\begin{bmatrix} \boldsymbol{A}_k & * \\ * & * \end{bmatrix} = \begin{bmatrix} \boldsymbol{L}_k & 0 \\ * & * \end{bmatrix} \begin{bmatrix} \boldsymbol{U}_k & * \\ 0 & * \end{bmatrix} \quad \Rightarrow \quad \boldsymbol{A}_k = \boldsymbol{L}_k\boldsymbol{U}_k. \tag{2.24}$$

所以每一个顺序主子阵 $\boldsymbol{A}_k$ 必须可逆，才能保证得到最后的分解式 $\boldsymbol{A} = \boldsymbol{LU}$.

## 习题 2.3

习题 1 ~ 8 计算分解 $\boldsymbol{A} = \boldsymbol{LU}$（包括 $\boldsymbol{A} = \boldsymbol{LDU}$）.

1.（推荐）通过消元法将 $\begin{bmatrix} 1 & 1 \\ 1 & 2 \end{bmatrix} \boldsymbol{x} = \boldsymbol{b}$ 的系数矩阵化为上三角矩阵 $\begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} \boldsymbol{x} = \boldsymbol{c}$：

$$\begin{cases} x+y=5 \\ x+2y=7 \end{cases} \longrightarrow \begin{cases} x+y=5 \\ y=2 \end{cases} \qquad \begin{bmatrix} 1 & 1 & 5 \\ 1 & 2 & 7 \end{bmatrix} \longrightarrow \begin{bmatrix} 1 & 1 & 5 \\ 0 & 1 & 2 \end{bmatrix}$$

首先将第 2 行减去第 1 行的 $\ell_{21}=$ _____ 倍. 逆变换是将第 2 行加上第 1 行的 $\ell_{21}$ 倍. 这一步逆变换对应的矩阵是 $\boldsymbol{L}=$ _____. 将 $\boldsymbol{L}$ 乘以 $\begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}\boldsymbol{x}_1=\begin{bmatrix} 5 \\ 2 \end{bmatrix}$ 得到 _____ = _____. 形式上，$\boldsymbol{L}$ 乘以 $\boldsymbol{Ux}=\boldsymbol{c}$ 得到_____.

2. 写出习题 1 中的方程组 $\boldsymbol{Lc}=\boldsymbol{b}$ 和 $\boldsymbol{Ux}=\boldsymbol{c}$. 验证 $\boldsymbol{c}=\begin{bmatrix} 5 & 2 \end{bmatrix}^{\mathrm{T}}$ 是前一个方程组的解. 求出第二个方程组的解 $\boldsymbol{x}$.

3. 设 $\boldsymbol{A}=\begin{bmatrix} 2 & 1 & 0 \\ 0 & 4 & 2 \\ 6 & 3 & 5 \end{bmatrix}$，求矩阵 $\boldsymbol{E}$ 使得 $\boldsymbol{EA}=\boldsymbol{U}$ 是上三角矩阵. 等号两边同时左乘 $\boldsymbol{E}^{-1}$（令 $\boldsymbol{L}=\boldsymbol{E}^{-1}$）可将 $\boldsymbol{A}$ 分解为 $\boldsymbol{LU}$. 求出 $\boldsymbol{L}$.

4. 设 $\boldsymbol{A}=\begin{bmatrix} 1 & 1 & 1 \\ 2 & 4 & 5 \\ 0 & 4 & 0 \end{bmatrix}$，求初等矩阵 $\boldsymbol{E}_{21}$ 和 $\boldsymbol{E}_{32}$ 使得 $\boldsymbol{E}_{32}\boldsymbol{E}_{21}\boldsymbol{A}=\boldsymbol{U}$ 是上三角矩阵. 等号两边同时左乘 $\boldsymbol{E}_{32}^{-1}$ 和 $\boldsymbol{E}_{21}^{-1}$，则 $\boldsymbol{A}$ 分解为 $\boldsymbol{LU}=\boldsymbol{E}_{32}^{-1}\boldsymbol{E}_{21}^{-1}\boldsymbol{U}$. 求出 $\boldsymbol{L}$.

5. 设 $\boldsymbol{A}=\begin{bmatrix} 1 & 0 & 1 \\ 2 & 2 & 2 \\ 3 & 4 & 5 \end{bmatrix}$，求初等矩阵 $\boldsymbol{E}_{21}$、$\boldsymbol{E}_{31}$ 和 $\boldsymbol{E}_{32}$ 使得 $\boldsymbol{E}_{32}\boldsymbol{E}_{31}\boldsymbol{E}_{21}\boldsymbol{A}=\boldsymbol{U}$ 是上三角矩阵. 等号两边同时左乘 $\boldsymbol{E}_{32}^{-1}$、$\boldsymbol{E}_{31}^{-1}$ 和 $\boldsymbol{E}_{21}^{-1}$，则 $\boldsymbol{A}$ 分解为 $\boldsymbol{LU}$，其中 $\boldsymbol{L}=\boldsymbol{E}_{21}^{-1}\boldsymbol{E}_{31}^{-1}\boldsymbol{E}_{32}^{-1}$. 求出 $\boldsymbol{L}$.

6. 设 $\boldsymbol{A}=\begin{bmatrix} 2 & 4 \\ 4 & 11 \end{bmatrix}$，$\boldsymbol{B}=\begin{bmatrix} 1 & 4 & 0 \\ 4 & 12 & 4 \\ 0 & 4 & 0 \end{bmatrix}$，$\boldsymbol{A}$ 和 $\boldsymbol{B}$ 关于主对角线对称. 求它们的 $\boldsymbol{LDU}$ 分解[①]，并且说明当初始矩阵是对称矩阵时，$\boldsymbol{U}$ 和 $\boldsymbol{L}$ 有什么关系.

7.（推荐）对下面的矩阵 $\boldsymbol{A}$ 作 $\boldsymbol{LU}$ 分解：$\boldsymbol{A}=\boldsymbol{LU}$.

$$A=\begin{bmatrix} a & a & a & a \\ a & b & b & b \\ a & b & c & c \\ a & b & c & d \end{bmatrix}$$

$a$、$b$、$c$、$d$ 满足什么条件时，$\boldsymbol{A}=\boldsymbol{LU}$ 成立且有四个主元？

8. 下面的矩阵 $\boldsymbol{A}$ 不是对称矩阵，请对它作 $\boldsymbol{LU}$ 分解 $\boldsymbol{A}=\boldsymbol{LU}$. 最终你将发现，它和习题 7 中的矩阵有相同的 $\boldsymbol{L}$：

① 译者注：所谓 $\boldsymbol{LDU}$ 分解，其中的 $\boldsymbol{L}$ 和 $\boldsymbol{U}$ 分别是对角线元素都是 1 的下三角矩阵和上三角矩阵，$\boldsymbol{D}$ 是对角矩阵.

$$\boldsymbol{A}=\begin{bmatrix} a & r & r & r \\ a & b & s & s \\ a & b & c & t \\ a & b & c & d \end{bmatrix}$$

$a$、$b$、$c$、$d$、$r$、$s$、$t$ 满足什么条件时，$\boldsymbol{A}=\boldsymbol{LU}$ 成立且有四个主元？

9. 设 $\boldsymbol{L}=\begin{bmatrix} 1 & 0 \\ 4 & 1 \end{bmatrix}, \boldsymbol{U}=\begin{bmatrix} 2 & 4 \\ 0 & 1 \end{bmatrix}, \boldsymbol{b}=\begin{bmatrix} 2 \\ 11 \end{bmatrix}$，求解线性方程组 $\boldsymbol{Lc}=\boldsymbol{b}$ 中的 $\boldsymbol{c}$，然后求解 $\boldsymbol{Ux}=\boldsymbol{c}$ 来得到 $\boldsymbol{x}$.

10. 设 $\boldsymbol{L}=\begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 1 \end{bmatrix}, \boldsymbol{U}=\begin{bmatrix} 1 & 1 & 1 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{bmatrix}, \boldsymbol{b}=\begin{bmatrix} 4 \\ 5 \\ 6 \end{bmatrix}$，求解 $\boldsymbol{Lc}=\boldsymbol{b}$ 中的 $\boldsymbol{c}$，然后求解 $\boldsymbol{Ux}=\boldsymbol{c}$ 来得到 $\boldsymbol{x}$，$\boldsymbol{A}$ 等于什么？

11. 设 $\boldsymbol{L}=\begin{bmatrix} 1 & 0 & 0 \\ \ell_{21} & 1 & 0 \\ \ell_{31} & \ell_{32} & 1 \end{bmatrix}$

（1）对 $\boldsymbol{L}$ 应用通常的消元法，得到什么矩阵？

（2）对 $\boldsymbol{I}$ 用（1）中同样的步骤，得到什么矩阵？

（3）对 $\boldsymbol{LU}$ 用（1）中同样的步骤，得到什么矩阵？

12. 如果 $\boldsymbol{A}=\boldsymbol{LDU}$ 和 $\boldsymbol{A}=\boldsymbol{L_1D_1U_1}$ 都是 $\boldsymbol{A}$ 的 $\boldsymbol{LDU}$ 分解，而且所有的矩阵可逆，证明：$\boldsymbol{L}=\boldsymbol{L}_1, \boldsymbol{D}=\boldsymbol{D}_1, \boldsymbol{U}=\boldsymbol{U}_1$. 这说明在此前提下，矩阵的 $\boldsymbol{LDU}$ 分解是唯一的.

13. 三对角矩阵是指除了主对角线以及两个相邻的次对角线之外的元素都为 0 的矩阵. 求三对角矩阵 $\begin{bmatrix} 1 & 1 & 0 \\ 1 & 2 & 1 \\ 0 & 1 & 2 \end{bmatrix}$ 和 $\begin{bmatrix} a & a & 0 \\ a & a+b & b \\ 0 & b & b+c \end{bmatrix}$ 的 $\boldsymbol{LU}$ 分解和 $\boldsymbol{LDU}$ 分解. 请注意，由于本题两个矩阵都是对角矩阵，其 $\boldsymbol{LDU}$ 分解满足性质 $\boldsymbol{U}=\boldsymbol{L}^{\mathrm{T}}$.

14. 如果下面矩阵 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 在标记为 $x$ 的位置元素非零，哪些零（标记为 0）在对矩阵作 $LU$ 分解后，仍然为 0？

$$\boldsymbol{A}=\begin{bmatrix} x & x & x & x \\ x & x & x & 0 \\ 0 & x & x & x \\ 0 & 0 & x & x \end{bmatrix} \qquad \boldsymbol{B}=\begin{bmatrix} x & x & x & 0 \\ x & x & 0 & x \\ x & 0 & x & x \\ 0 & x & x & x \end{bmatrix}$$

15.（简单但重要）如果不经过行对换对 $\boldsymbol{A}$ 消元，可得其主元 5, 9, 3. 那么它左上角的 $2\times 2$ 顺序主子阵（即去掉 $\boldsymbol{A}$ 的第 3 行和第 3 列剩下的部分）$\boldsymbol{A}_2$ 的主元是什么？

16. 把 $\boldsymbol{A}=\boldsymbol{LU}$ 的第二个证明应用于矩阵 $\boldsymbol{A}=\begin{bmatrix} 1 & 2 & 0 \\ 1 & 5 & 1 \\ 0 & 6 & 4 \end{bmatrix}$，那么哪三个秩为 1 的矩阵被减掉了？

$$\boldsymbol{A}=\begin{bmatrix}1&2&0\\1&5&1\\0&6&4\end{bmatrix}=\boldsymbol{\ell_1u_1}+\boldsymbol{\ell_2u_2}+\boldsymbol{\ell_3u_3}=\boldsymbol{LU}\quad\text{（列向量乘以行向量，再求和）}$$

17. 若 $3\times3$ 下三角矩阵 $\boldsymbol{L}$ 有 6 个元素是 1，请计算 $\boldsymbol{L}^{\mathrm{T}}\boldsymbol{L}$ 和 $\boldsymbol{L}\boldsymbol{L}^{\mathrm{T}}$.

## 2.4　置换与转置

（1）置换矩阵 $\boldsymbol{P}$ 和 $\boldsymbol{I}$ 有相同的行向量（排列顺序不同）. $n$ 个行向量一共有 $n!$ 种不同的排列.
（2）$\boldsymbol{P}$ 乘以 $\boldsymbol{x}$ 的结果是将 $x_1,x_2,\cdots,x_n$ 按新的顺序排列. $\boldsymbol{P}^{\mathrm{T}}=\boldsymbol{P}^{-1}$.
（3）$\boldsymbol{A}$ 的列向量是 $\boldsymbol{A}^{\mathrm{T}}$ 的行向量. $\boldsymbol{Ax}$ 和 $\boldsymbol{AB}$ 的转置是 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{A}^{\mathrm{T}}$ 和 $\boldsymbol{B}^{\mathrm{T}}\boldsymbol{A}^{\mathrm{T}}$.
（4）引入 $\boldsymbol{A}^{\mathrm{T}}$ 的原因是 $\boldsymbol{Ax}\cdot\boldsymbol{y}=\boldsymbol{x}\cdot\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}$：$(\boldsymbol{Ax})^{\mathrm{T}}\boldsymbol{y}=\boldsymbol{x}^{\mathrm{T}}\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}=\boldsymbol{x}^{\mathrm{T}}\left(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}\right)$.
（5）对称矩阵满足 $\boldsymbol{S}^{\mathrm{T}}=\boldsymbol{S}$. $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 和 $\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 总是对称的.

### 2.4.1　置换

置换矩阵在每一行都只有一个 1，每一列也只有一个 1，其余的元素都为 0. 这个矩阵 $\boldsymbol{P}$ 乘以向量，会改变向量中元素排列的顺序：

$\boldsymbol{P}$和$\boldsymbol{I}$行向量相同
$\boldsymbol{Px}=\boldsymbol{x}$的循环变换
排列1, 2, 3变成3, 1, 2

$$\boldsymbol{Px}=\begin{bmatrix}0&0&1\\1&0&0\\0&1&0\end{bmatrix}\begin{bmatrix}x_1\\x_2\\x_3\end{bmatrix}=\begin{bmatrix}x_3\\x_1\\x_2\end{bmatrix}$$

在这个例子中，$\boldsymbol{P}$ 将 $x_1$ 移动到第二个位置. 如果再来一次，$\boldsymbol{P}^2$ 将 $x_1$ 移动到第三个位置，然后 $\boldsymbol{P}^3=\boldsymbol{I}$ 将 $x_1$, $x_2$, $x_3$ 的顺序恢复原状. $\boldsymbol{P}$、$\boldsymbol{P}^2$ 和 $\boldsymbol{I}$ 都是置换阵.

将一副牌洗乱相当于给 $n=52$ 张牌另一个随机的排列. Persi Diaconis 证明一副新牌经过 7 次随机置换可以洗得很好.

3 阶置换矩阵一共有 $3!=6$ 个，4 阶置换矩阵一共有 $4!=24$ 个. 下面是一些特殊的 $4\times4$ 置换矩阵乘以向量 $\boldsymbol{x}$ 的效果：

$\boldsymbol{Px}$ 将顺序反转为 $x_4,\ x_3,\ x_2,\ x_1$
$\boldsymbol{P}^2=\boldsymbol{I}$

$$\begin{bmatrix}0&0&0&1\\0&0&1&0\\0&1&0&0\\1&0&0&0\end{bmatrix}$$

$x_4$ 固定，其余轮换
输入 $x_1,x_2,x_3,x_4$
输出 $x_3,x_1,x_2,x_4$
$\boldsymbol{P}^3=\boldsymbol{I}$

$$\begin{bmatrix}0&0&1&0\\1&0&0&0\\0&1&0&0\\0&0&0&1\end{bmatrix}$$

轮换
输入 $x_1,x_2,x_3,x_4$
输出 $x_4,x_1,x_2,x_3$
$\boldsymbol{P}^4=\boldsymbol{I}$

$$\begin{bmatrix}0&0&0&1\\1&0&0&0\\0&1&0&0\\0&0&1&0\end{bmatrix}$$

偶数指标在奇数指标前面
$x_0,x_2$ 在 $x_1,x_3$ 之前
快速傅里叶变换
指标从 0 到 3，而非 1 到 4

$$\begin{bmatrix}1&0&0&0\\0&0&1&0\\0&1&0&0\\0&0&0&1\end{bmatrix}$$

一半置换矩阵是“奇”置换阵，另一半是“偶”置换阵（各 $\frac{n!}{2}$ 个）. 偶置换阵的意思是需要进行偶数次行对换来将其变为 $\boldsymbol{I}$. 最后一个例子（一次置换）是奇置换阵；第一个例子（交换 1 和 4，2 和 3）是偶置换阵.

$\boldsymbol{P}$ 的行是
$\boldsymbol{P}^{-1}=\boldsymbol{P}^{\mathrm{T}}$ 对应的列
$\boldsymbol{P}^{\mathrm{T}}=$“$\boldsymbol{P}$ 的转置”

$$\boldsymbol{P}^{\mathrm{T}}\boldsymbol{P}=\begin{bmatrix}0&1&0\\0&0&1\\1&0&0\end{bmatrix}\begin{bmatrix}0&0&1\\1&0&0\\0&1&0\end{bmatrix}=\begin{bmatrix}1&&\\&1&\\&&1\end{bmatrix}=\boldsymbol{I}$$

### 2.4.2 置换矩阵的性质

（1）$n$ 个 1 出现在 $\boldsymbol{P}$ 的 $n$ 个不同的行和 $n$ 个不同的列.

（2）$\boldsymbol{P}$ 的列向量两两正交：不同的列点积等于 0.

（3）置换矩阵的乘积仍然是置换矩阵. 置换矩阵的逆矩阵也是置换矩阵.

（4）如果矩阵 $\boldsymbol{A}$ 是可逆的，那么存在一个置换矩阵对 $\boldsymbol{A}$ 的行进行重排，使得对 $\boldsymbol{PA}$ 消元时主元不会出现 0，即 $\boldsymbol{PA}$ 存在 $LU$ 分解：$\boldsymbol{PA}=\boldsymbol{LU}$.

### 2.4.3 $PA=LU$ 分解：$P$ 导致行交换

下面的例子将说明为什么即使在主元的位置出现 0 时，消元法依旧可以成功. 假设从第一个主元 1 开始消元. 经过两次变换我们在第二个主元处得到了 0：

$$\boldsymbol{A}=\begin{bmatrix}1&2&a\\2&4&b\\3&7&c\end{bmatrix}\xrightarrow{E}\begin{bmatrix}1&2&a\\0&0&b-2a\\0&1&c-3a\end{bmatrix}\xrightarrow{P}\begin{bmatrix}1&2&a\\0&1&c-3a\\0&0&b-2a\end{bmatrix}=\boldsymbol{U}$$

尽管出现了 0，矩阵 $\boldsymbol{A}$ 仍然可能是可逆的. 为了继续消元，$\boldsymbol{P}$ 将第二行和第三行做了交换. 这样一来我们就得到了第二个主元 1.

$\boldsymbol{A}$ 可逆当且仅当第三个主元 $b-2a$ 非零. 如果 $b=2a$，那么 $\boldsymbol{A}$ 的第二行等于两倍的第一行，$A$ 就是不可逆的.

也可以先交换第二行和第三行来得到 $\boldsymbol{PA}$，然后 $\boldsymbol{LU}$ 分解为 $\boldsymbol{PA}=\boldsymbol{LU}$. 对 $\boldsymbol{PA}$ 做消元不会出现主元为 0 的情况：

$$\underset{\boldsymbol{P}}{\begin{bmatrix}1&0&0\\0&0&1\\0&1&0\end{bmatrix}}\underset{\boldsymbol{A}}{\begin{bmatrix}1&2&a\\2&4&b\\3&7&c\end{bmatrix}}=\underset{\boldsymbol{PA}}{\begin{bmatrix}1&2&a\\3&7&c\\2&4&b\end{bmatrix}}=\underset{\boldsymbol{L}}{\begin{bmatrix}1&0&0\\3&1&0\\2&0&1\end{bmatrix}}\underset{\boldsymbol{U}}{\begin{bmatrix}1&2&a\\0&1&c-3a\\0&0&b-2a\end{bmatrix}}$$

我们可能会需要多次行对换，那么置换矩阵 $\boldsymbol{P}$ 可以包含所有对换的信息，并且仍然保证有分解式 $\boldsymbol{PA}=\boldsymbol{LU}$. Daniel Drucker 在 $\boldsymbol{A}$ 的右侧添加一列 $\mathbf{1,2,3}$，给出了一个简洁的方法来找出 $\boldsymbol{P}$. 这一列不跟随消元做四则运算，而只随着行对换跟踪原始矩阵的行数. 比如这个例子中的置换矩阵 $\boldsymbol{P}$ 为 $\mathbf{1,3,2}$.

$$\begin{bmatrix}1&2&a&1\\2&4&b&2\\3&7&c&3\end{bmatrix}\longrightarrow\begin{bmatrix}1&2&a&1\\0&\mathbf{0}&b-2a&2\\0&\mathbf{1}&c-3a&3\end{bmatrix}\longrightarrow\begin{bmatrix}1&2&a&1\\0&1&c-3a&3\\0&0&b-2a&2\end{bmatrix}\qquad \text{那么}\boldsymbol{P}_{132}=\begin{bmatrix}\mathbf{1}&0&0\\0&0&\mathbf{1}\\0&\mathbf{1}&0\end{bmatrix}$$

### 2.4.4　选取“部分主元”以减少舍入误差

一个好的消元算法会允许更多的行变换来保证计算的稳定性. **小的主元**[①]**会导致大的误差!** 当主元下方（同一列）有更大的数时，算法不会直接选择小主元. 如果我们通过行对换将更大的数作为主元，算法会更稳定.

在下面这个例子中，第一个主元为 1，但是第一列中有两个更大的数 2 和 3. **算法会选择最大的数 3 作为第一个主元：交换第一行和第三行.** 行的顺序可以通过最后一列 * 来跟踪，再强调一次：它并不是矩阵的一部分，不跟随矩阵作加减乘除，只用来标记行对换：

$$\underset{\boldsymbol{A}}{\begin{bmatrix}1&2&a&1\\2&4&b&2\\3&7&c&3\end{bmatrix}}\xrightarrow{\boldsymbol{P}}\underset{\ast}{\begin{bmatrix}3&7&c&3\\2&4&b&2\\1&2&a&1\end{bmatrix}}\longrightarrow\begin{bmatrix}3&7&c&3\\0&-\frac{2}{3}&b-\frac{2}{3}c&2\\1&2&a-\frac{1}{3}c&1\end{bmatrix}\longrightarrow\underset{\boldsymbol{U}}{\begin{bmatrix}3&7&c&3\\0&-\frac{2}{3}&b-\frac{2}{3}c&2\\0&0&a-\frac{1}{2}b&1\end{bmatrix}}\underset{\ast}{}$$

在这个例子中，$\boldsymbol{P}=\begin{bmatrix}0&0&1\\0&1&0\\1&0&0\end{bmatrix}$ 和 $\boldsymbol{L}=\begin{bmatrix}1&0&0\\\frac{2}{3}&1&0\\\frac{1}{3}&\frac{1}{2}&1\end{bmatrix}$ 使得 $\boldsymbol{PA}=\boldsymbol{LU}$. 当我们选择了合适的主元——使之大于下方所有元素时，$\boldsymbol{L}$ 的所有元素都小于或等于 1.

### 2.4.5　$PAQ$：$P$ 对 $A$ 做行交换，$Q$ 对 $A$ 做列交换

以 $3\times3$ 矩阵 $\boldsymbol{A}$ 为例，$\boldsymbol{P}$ 将原来的行交换顺序，新矩阵的第 1、2、3 行分别是原矩阵的第 2、3、1 行：

$$\boldsymbol{P}=\begin{bmatrix}0&\mathbf{1}&0\\0&0&\mathbf{1}\\\mathbf{1}&0&0\end{bmatrix}\qquad \boldsymbol{PA}=\begin{bmatrix}a_{21}&a_{22}&a_{23}\\a_{31}&a_{32}&a_{33}\\a_{11}&a_{12}&a_{13}\end{bmatrix}\tag{2.25}$$

列还是按原来的顺序排列. 也可以用置换矩阵 $\boldsymbol{Q}$ 将列向量重排，新矩阵的第 1、2、3 列分别是 $\boldsymbol{PA}$ 的第 3、2、1 列. 列交换矩阵 $\boldsymbol{Q}$ 乘在 $\boldsymbol{PA}$ 后形成 $\boldsymbol{PAQ}$：

$$\boldsymbol{Q}=\begin{bmatrix}0&0&\mathbf{1}\\0&\mathbf{1}&0\\\mathbf{1}&0&0\end{bmatrix}\qquad \boldsymbol{PAQ}=\begin{bmatrix}a_{23}&a_{22}&a_{21}\\a_{33}&a_{32}&a_{31}\\a_{13}&a_{12}&a_{11}\end{bmatrix}\tag{2.26}$$

① 译者注：所谓大的主元或者小的主元，是指主元绝对值的大小. 实际操作中，一般愿意让主元是正数，那么出现负主元的时候，将该主元行乘以 $-1$，就变成正数了；在将主元统一成正数的这个意义下，大小就是真实的大小，无须取绝对值.

观察 $\boldsymbol{PAQ}$，可以看到其行指标按 2、3、1 的顺序排，而列指标按 3、2、1 的顺序排. 行有 6 种可能的排列 $\boldsymbol{P}$，列同样有 6 种可能的排列 $\boldsymbol{Q}$，这样一共有 36 种不同的 $\boldsymbol{PAQ}$.

问题：这些是不是 $\boldsymbol{A}$ 的 9 个元素所有可能的排列？当然不是. 9 个位置共有 $9! = 362880$ 种可能的顺序. 而 $\boldsymbol{PAQ}$ 是特殊的，因为指标 1、2、3 在每一行（下标中的第一个数）都是固定的. 同样在每一列（下标中的第二个数）也都不变. 从列空间的角度，$\mathcal{C}(\boldsymbol{PAQ})$ 和 $\mathcal{C}(\boldsymbol{A})$ 相等吗？

### 2.4.6 $A$ 的转置

为了更好地研究 $\boldsymbol{A}$，我们还需要一个矩阵——$\boldsymbol{A}$ 的“**转置**”. 它比逆要简单，记作 $\boldsymbol{A}^{\mathrm{T}}$. $\boldsymbol{A}^{\mathrm{T}}$ 的列就是 $\boldsymbol{A}$ 的行.

若 $\boldsymbol{A}$ 是 $m \times n$ 矩阵，转置 $\boldsymbol{A}^{\mathrm{T}}$ 是 $n \times m$ 矩阵. $2 \times 3$ 矩阵的转置为 $3 \times 2$ 矩阵.

**转置** 如果 $\boldsymbol{A} = \begin{bmatrix} 1 & 2 & 3 \\ 0 & 0 & 4 \end{bmatrix}$，那么 $\boldsymbol{A}^{\mathrm{T}} = \begin{bmatrix} 1 & 0 \\ 2 & 0 \\ 3 & 4 \end{bmatrix}$.

我们可以将 $\boldsymbol{A}$ 的行写入 $\boldsymbol{A}^{\mathrm{T}}$ 的列，也可以将 $\boldsymbol{A}$ 的列写入 $\boldsymbol{A}^{\mathrm{T}}$ 的行. 矩阵沿着主对角线“翻转”了一下. $\boldsymbol{A}^{\mathrm{T}}$ 的第 $i$ 行 $j$ 列的元素和 $\boldsymbol{A}$ 的第 $j$ 行 $i$ 列的元素相同：

**$\boldsymbol{A}$ 的行变为 $\boldsymbol{A}^{\mathrm{T}}$ 的列** $\boxed{\left(\boldsymbol{A}^{\mathrm{T}}\right)_{ij} = \boldsymbol{A}_{ji}}$

下三角矩阵的转置是上三角矩阵. $\boldsymbol{A}^{\mathrm{T}}$ 的转置是 $\boldsymbol{A}$.

注：MATLAB 中 $\boldsymbol{A}^{\mathrm{T}}$ 的记号是 $\boldsymbol{A}'$. 输入 $\begin{bmatrix} 1 & 2 & 3 \end{bmatrix}$ 会得到一个行向量，而列向量是 $\boldsymbol{v} = \begin{bmatrix} 1 & 2 & 3 \end{bmatrix}'$. 再加上第二列 $\boldsymbol{w} = \begin{bmatrix} 4 & 5 & 6 \end{bmatrix}'$ 就可得到矩阵 $\boldsymbol{M} = \begin{bmatrix} \boldsymbol{v} & \boldsymbol{w} \end{bmatrix}$. 快速的输入方法是通过行和转置：$M = \begin{bmatrix} 1 & 2 & 3; & 4 & 5 & 6 \end{bmatrix}'$.

转置的运算规则很直观. 将 $(\boldsymbol{A}+\boldsymbol{B})$ 转置得 $(\boldsymbol{A}+\boldsymbol{B})^{\mathrm{T}}$. 另一方面，也可以分别对 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 转置，再相加得 $\boldsymbol{A}^{\mathrm{T}} + \boldsymbol{B}^{\mathrm{T}}$——两者结果一样.

稍微麻烦一些的是关于乘积 $\boldsymbol{AB}$ 和逆 $\boldsymbol{A}^{-1}$ 的转置：

| | | | |
|---|---|---|---|
| 和 | $\boldsymbol{A}+\boldsymbol{B}$的转置是 | $(\boldsymbol{A}+\boldsymbol{B})^{\mathrm{T}} = \boldsymbol{A}^{\mathrm{T}} + \boldsymbol{B}^{\mathrm{T}}$ | (2.27) |
| 乘积 | $\boldsymbol{AB}$的转置是 | $(\boldsymbol{AB})^{\mathrm{T}} = \boldsymbol{B}^{\mathrm{T}}\boldsymbol{A}^{\mathrm{T}}$ | (2.28) |
| 逆 | $\boldsymbol{A}^{-1}$的转置是 | $(\boldsymbol{A}^{-1})^{\mathrm{T}} = (\boldsymbol{A}^{\mathrm{T}})^{-1}$ | (2.29) |

请注意 $\boldsymbol{B}^{\mathrm{T}}\boldsymbol{A}^{\mathrm{T}}$ 相乘的顺序. 对于矩阵逆来说，这种逆序很容易验证：$\boldsymbol{B}^{-1}\boldsymbol{A}^{-1}$ 乘以 $\boldsymbol{AB}$ 得到 $\boldsymbol{I}$，因为 $\boldsymbol{A}^{-1}\boldsymbol{A} = \boldsymbol{B}^{-1}\boldsymbol{B} = \boldsymbol{I}$. 为了理解 $(\boldsymbol{AB})^{\mathrm{T}} = \boldsymbol{B}^{\mathrm{T}}\boldsymbol{A}^{\mathrm{T}}$，我们先从 $\boldsymbol{B}$ 是一个向量开始，那么需要验证 $(\boldsymbol{Ax})^{\mathrm{T}} = \boldsymbol{x}^{\mathrm{T}}\boldsymbol{A}^{\mathrm{T}}$：

$\boldsymbol{Ax}$ 是 $\boldsymbol{A}$ 的列向量的线性组合，而 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{A}^{\mathrm{T}}$ 是 $\boldsymbol{A}^{\mathrm{T}}$ 的行向量的线性组合.

这是相同向量的相同的线性组合！$\boldsymbol{A}$ 的列就是 $\boldsymbol{A}^{\mathrm{T}}$ 的行. 所以列 $\boldsymbol{Ax}$ 的转置就是行 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{A}^{\mathrm{T}}$，这就证明了 $(\boldsymbol{Ax})^{\mathrm{T}}=\boldsymbol{x}^{\mathrm{T}}\boldsymbol{A}^{\mathrm{T}}$. 进一步, 当 $B$ 是多列的时候，可以证明 $(\boldsymbol{AB})^{\mathrm{T}}=\boldsymbol{B}^{\mathrm{T}}\boldsymbol{A}^{\mathrm{T}}$.

如果 $\boldsymbol{B}$ 有两列 $\boldsymbol{x}_1$ 和 $\boldsymbol{x}_2$，对每一列运用同样的方法. $\boldsymbol{AB}$ 的列是 $\boldsymbol{Ax}_1$ 和 $\boldsymbol{Ax}_2$. 它们的转置 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{A}^{\mathrm{T}}$ 恰好就是 $\boldsymbol{B}^{\mathrm{T}}\boldsymbol{A}^{\mathrm{T}}$ 的行：

$$\text{将}\boldsymbol{AB}=\begin{bmatrix}\boldsymbol{Ax}_1 & \boldsymbol{Ax}_2 & \cdots\end{bmatrix}\text{转置得}\begin{bmatrix}\boldsymbol{x}_1^{\mathrm{T}}\boldsymbol{A}^{\mathrm{T}}\\ \boldsymbol{x}_2^{\mathrm{T}}\boldsymbol{A}^{\mathrm{T}}\\ \vdots\end{bmatrix}\text{，此即}\boldsymbol{B}^{\mathrm{T}}\boldsymbol{A}^{\mathrm{T}}. \tag{2.30}$$

这一点并不复杂，只需要熟悉如何从行向量的角度理解矩阵乘积 $\boldsymbol{B}^{\mathrm{T}}\boldsymbol{A}^{\mathrm{T}}$. 下面举一个 $(\boldsymbol{AB})^{\mathrm{T}}=\boldsymbol{B}^{\mathrm{T}}\boldsymbol{A}^{\mathrm{T}}$ 的例子：

$$\boldsymbol{AB}=\begin{bmatrix}1&0\\1&1\end{bmatrix}\begin{bmatrix}5&0\\4&1\end{bmatrix}=\begin{bmatrix}\mathbf{5}&\mathbf{0}\\\mathbf{9}&\mathbf{1}\end{bmatrix}\qquad \boldsymbol{B}^{\mathrm{T}}\boldsymbol{A}^{\mathrm{T}}=\begin{bmatrix}5&4\\0&1\end{bmatrix}\begin{bmatrix}1&1\\0&1\end{bmatrix}=\begin{bmatrix}\mathbf{5}&\mathbf{9}\\\mathbf{0}&\mathbf{1}\end{bmatrix}$$

矩阵先乘积后转置等于先转置再逆序最后乘积，这一性质可以进一步推广到三个或更多矩阵乘积的情况：

$$(\boldsymbol{ABC})^{\mathrm{T}}=\boldsymbol{C}^{\mathrm{T}}\boldsymbol{B}^{\mathrm{T}}\boldsymbol{A}^{\mathrm{T}}$$

将这一性质与取逆矩阵结合起来，考虑 $\boldsymbol{A}^{-1}\boldsymbol{A}=\boldsymbol{I}$. 等号右边 $\boldsymbol{I}^{\mathrm{T}}=\boldsymbol{I}$. 可以验证 $\left(\boldsymbol{A}^{-1}\right)^{\mathrm{T}}$ 是 $\boldsymbol{A}^{\mathrm{T}}$ 的逆:

逆矩阵的转置　　$\boldsymbol{A}^{-1}\boldsymbol{A}=\boldsymbol{I}$　转置得　$\boldsymbol{A}^{\mathrm{T}}\left(\boldsymbol{A}^{-1}\right)^{\mathrm{T}}=\boldsymbol{I}$ (2.31)

同理，由 $\boldsymbol{AA}^{-1}=\boldsymbol{I}$ 可得 $\left(\boldsymbol{A}^{-1}\right)^{\mathrm{T}}\boldsymbol{A}^{\mathrm{T}}=\boldsymbol{I}$. 可以先求转置后取逆，也可以先求逆后取转置.

特别地：$\boldsymbol{A}^{\mathrm{T}}$ 是可逆的当且仅当 $\boldsymbol{A}$ 是可逆的. $\boldsymbol{A}=\begin{bmatrix}1&0\\6&1\end{bmatrix}$ 的逆是 $\boldsymbol{A}^{-1}=\begin{bmatrix}1&0\\-6&1\end{bmatrix}$. 转置是 $\boldsymbol{A}^{\mathrm{T}}=\begin{bmatrix}1&6\\0&1\end{bmatrix}$.

$\left(\boldsymbol{A}^{-1}\right)^{\mathrm{T}}$ 和 $\left(\boldsymbol{A}^{\mathrm{T}}\right)^{-1}$ 都等于 $\begin{bmatrix}1&-6\\0&1\end{bmatrix}$.

### 2.4.7　内积的意义

$\boldsymbol{x}$ 和 $\boldsymbol{y}$ 的点积（内积）是 $x_iy_i$ 的和. 现在有一个更好的方法来写 $\boldsymbol{x}\cdot\boldsymbol{y}$，用以取代那个看起来略显业余的点——用矩阵乘法 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{y}$ 来表示：

| | | |
|---|---|---|
| $^{\mathrm{T}}$ 在中间 | 点积或内积 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{y}$ | $(1\times n)(n\times 1)=1\times 1$ |
| $^{\mathrm{T}}$ 在后面 | 秩 1 矩阵或外积 $\boldsymbol{xy}^{\mathrm{T}}$ | $(n\times 1)(1\times n)=n\times n$ |

$\boldsymbol{x}^{\mathrm{T}}\boldsymbol{y}$ 是一个数，而 $\boldsymbol{xy}^{\mathrm{T}}$ 是一个矩阵. 量子力学中它们被写成 $\langle\boldsymbol{x}|\boldsymbol{y}\rangle$（内积）和 $|\boldsymbol{x}\rangle\langle\boldsymbol{y}|$（外积）. 这是否暗示着我们的宇宙就是由线性代数统治的？下面是另外三个和内积有关的例子：

| | |
|---|---|
| 力学上 | 功 =(位移)(力)= $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{f}$ |
| 电路上 | 热损失 =(电压差)(电流) = $\boldsymbol{e}^{\mathrm{T}}\boldsymbol{y}$ |
| 经济学上 | 营收 = (数量)(价格) = $\boldsymbol{q}^{\mathrm{T}}\boldsymbol{p}$ |

我们已经很接近应用数学的核心了，还有一点需要强调：内积和 $\boldsymbol{A}$ 的转置有更深刻的联系.

我们把 $\boldsymbol{A}^{\mathrm{T}}$ 定义成 $\boldsymbol{A}$ 沿着主对角线“翻转”了一下，这很不数学. 更好的定义是：$\boldsymbol{A}^{\mathrm{T}}$ 是满足如下关于内积等式的矩阵[①]：对任意 $\boldsymbol{x}$、$\boldsymbol{y}$

$$(\boldsymbol{A}\boldsymbol{x})^{\mathrm{T}}\boldsymbol{y}=\boldsymbol{x}^{\mathrm{T}}\left(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}\right) \qquad \boldsymbol{A}\boldsymbol{x}\text{ 和 }\boldsymbol{y}\text{ 的内积 }=\boldsymbol{x}\text{ 和 }\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}\text{ 的内积.}$$

**例 2.6** 以 $\boldsymbol{A}=\begin{bmatrix}-1 & 1 & 0\\ 0 & -1 & 1\end{bmatrix}$ 为例，$\boldsymbol{x}=\begin{bmatrix}x_1\\ x_2\\ x_3\end{bmatrix}$，$\boldsymbol{y}=\begin{bmatrix}y_1\\ y_2\end{bmatrix}$. $\boldsymbol{A}\boldsymbol{x}$ 和 $\boldsymbol{y}$ 的内积等于 $(x_2-x_1)y_1+(x_3-x_2)y_2$，也等于 $x_1(-y_1)+x_2(y_1-y_2)+x_3(y_3)$. 现在将 $\boldsymbol{x}$ 与 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}$ 作内积.

$$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}=\begin{bmatrix}-1 & 0\\ 1 & -1\\ 0 & 1\end{bmatrix}\begin{bmatrix}y_1\\ y_2\end{bmatrix}=\begin{bmatrix}-y_1\\ y_1-y_2\\ y_2\end{bmatrix} \qquad (\boldsymbol{A}\boldsymbol{x})^{\mathrm{T}}\boldsymbol{y}=\boldsymbol{x}^{\mathrm{T}}\left(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}\right)\text{ 就很明显了.}$$

**例 2.7** 我们是否可以考虑一点点微积分？当然还是从线性代数角度出发.（这是关于函数的线性代数.）将矩阵变为求导：$\boldsymbol{A}=\dfrac{\mathrm{d}}{\mathrm{d}t}$. $\dfrac{\mathrm{d}}{\mathrm{d}t}$ 的转置可以通过 $(\boldsymbol{A}\boldsymbol{x})^{\mathrm{T}}\boldsymbol{y}=\boldsymbol{x}^{\mathrm{T}}\left(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}\right)$ 来定义.

那么首先就要明确此时点积是什么. 点积 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{y}$ 由求和 $x_1y_1+x_2y_2+\cdots+x_ny_n$ 变为了 $\boldsymbol{x}(t)\boldsymbol{y}(t)$ 的积分.

函数 $x(t)$ 和 $y(t)$ 的内积的定义

$$\boldsymbol{x}^{\mathrm{T}}\boldsymbol{y}:=\int_{-\infty}^{+\infty}\boldsymbol{x}(t)\boldsymbol{y}(t)\,\mathrm{d}t \tag{2.32}$$

转置的运算法则 $(\boldsymbol{A}\boldsymbol{x})^{\mathrm{T}}\boldsymbol{y}=\boldsymbol{x}^{\mathrm{T}}\left(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}\right)$

$$\int_{-\infty}^{+\infty}\frac{\mathrm{d}\boldsymbol{x}}{\mathrm{d}t}\boldsymbol{y}(t)\,\mathrm{d}t=\int_{-\infty}^{+\infty}\boldsymbol{x}(t)\left(-\frac{\mathrm{d}\boldsymbol{y}}{\mathrm{d}t}\right)\mathrm{d}t \tag{2.33}$$

我想你应该认出了“分部积分”. 求导运算 $\boldsymbol{A}$ 的对象从第一个函数 $\boldsymbol{x}(t)$ 转移到了第二个函数 $\boldsymbol{y}(t)$，在这个过程中出现了一个负号. 这告诉我们 $\boldsymbol{A}=\dfrac{\mathrm{d}}{\mathrm{d}t}$ 的转置为 $\boldsymbol{A}^{\mathrm{T}}=-\boldsymbol{A}=-\dfrac{\mathrm{d}}{\mathrm{d}t}$.

求导运算是反对称的. 对称矩阵满足 $\boldsymbol{A}^{\mathrm{T}}=\boldsymbol{A}$，而反对称矩阵满足 $\boldsymbol{A}^{\mathrm{T}}=-\boldsymbol{A}$. 某种意义上，例2.6中的 $2\times 3$ 差分矩阵 $\boldsymbol{A}$ 也有类似的性质，$3\times 2$ 矩阵 $\boldsymbol{A}^{\mathrm{T}}$ 可以看作负的差分矩阵. $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}$ 中间的元素是 $y_1-y_2$ 而不是 $y_2-y_1$.

分部积分法不是花里胡哨的奇技淫巧，而是非常重要的方法. 在这里，我们假设 $\boldsymbol{x}(-\infty)$ 和 $\boldsymbol{x}(+\infty)$ 为零来忽略边界条件.

### 2.4.8 对称矩阵

所谓对称矩阵，是指 $\boldsymbol{A}$ 和 $\boldsymbol{A}^{\mathrm{T}}$ 相等的矩阵：$\boldsymbol{A}^{\mathrm{T}}=\boldsymbol{A}$. $\boldsymbol{A}$ 的 $(j,i)$ 元素与关于主对角线对称位置的 $(i,j)$ 元素相同. 鄙人愚见，对称矩阵大概是最重要的矩阵. 我们用 $\boldsymbol{S}$ 来记对称矩阵.

① 译者注：凡事都有代价，这种定义方式虽然更数学，但是是隐式的，或者是间接的，首先无法直接看出 $\boldsymbol{A}^{\mathrm{T}}$ 是什么，其次也需要花篇幅说明其存在性和唯一性.

$\boldsymbol{S}$ 称为对称矩阵，如果 $\boldsymbol{S}^{\mathrm{T}}=\boldsymbol{S}$；等价于：对任意 $i$、$j$，都有 $s_{ji}=s_{ij}$.

例如：

对称矩阵　$$\boldsymbol{S}=\begin{bmatrix}1&2\\2&5\end{bmatrix}=\boldsymbol{S}^{\mathrm{T}},\quad \boldsymbol{D}=\begin{bmatrix}1&0\\0&10\end{bmatrix}=\boldsymbol{D}^{\mathrm{T}}.$$

可逆对称矩阵的逆矩阵仍然是对称矩阵. $\boldsymbol{S}^{-1}$ 的转置为 $(\boldsymbol{S}^{-1})^{\mathrm{T}}=(\boldsymbol{S}^{\mathrm{T}})^{-1}=\boldsymbol{S}^{-1}$. 这说明当 $\boldsymbol{S}$ 可逆时, $\boldsymbol{S}^{-1}$ 是对称的，例如

对称矩阵的逆　$$\boldsymbol{S}^{-1}=\begin{bmatrix}5&-2\\-2&1\end{bmatrix}=(\boldsymbol{S}^{-1})^{\mathrm{T}},\quad \boldsymbol{D}^{-1}=\begin{bmatrix}1&0\\0&0.1\end{bmatrix}=(\boldsymbol{D}^{-1})^{\mathrm{T}}.$$

对任意矩阵 $\boldsymbol{A}$，$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 都是对称矩阵. 接下来我们就要探讨这一类对称矩阵.

### 2.4.9　对称乘积 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$、$\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 和 $\boldsymbol{L}\boldsymbol{D}\boldsymbol{L}^{\mathrm{T}}$ 分解

对任意矩阵 $\boldsymbol{A}$，把 $\boldsymbol{A}^{\mathrm{T}}$ 和 $\boldsymbol{A}$ 相乘，乘积 $\boldsymbol{S}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 是对称矩阵:

$$(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{\mathrm{T}}=\boldsymbol{A}^{\mathrm{T}}\left(\boldsymbol{A}^{\mathrm{T}}\right)^{\mathrm{T}},\ \text{仍然等于}\ \boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}.$$

$\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 也是对称矩阵（$\boldsymbol{A}$ 和 $\boldsymbol{A}^{\mathrm{T}}$ 的形状符合矩阵乘法的要求.）但是 $\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 和 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 是不同的矩阵. 从经验来看，多数非方阵的矩阵 $\boldsymbol{A}$ 的问题最终还是要转化到 $\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 或 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 上解决. 这两个都是方阵.

例 2.8　$\boldsymbol{A}=\begin{bmatrix}-1&1&0\\0&-1&1\end{bmatrix}$, $\boldsymbol{A}^{\mathrm{T}}=\begin{bmatrix}-1&0\\1&-1\\0&1\end{bmatrix}$, 计算 $\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 和 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$.

$$\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}=\begin{bmatrix}2&-1\\-1&2\end{bmatrix},\quad \boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}=\begin{bmatrix}1&-1&0\\-1&2&-1\\0&-1&1\end{bmatrix}$$

$\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 是 $m\times m$ 矩阵，而 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 是 $n\times n$ 矩阵. 它们都是对称矩阵, 而且主对角线元素都是正数 (为什么？) 但是即使 $m=n$，一般来说，$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 和 $\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 也不相等.

对称矩阵的消元　对称性 $\boldsymbol{S}^{\mathrm{T}}=\boldsymbol{S}$ 使消元的效率是普通矩阵的两倍. 我们对矩阵的一半元素进行操作 (加上对角线). 对称性使我们得到 $\boldsymbol{S}=\boldsymbol{L}\boldsymbol{D}\boldsymbol{L}^{\mathrm{T}}$，同时把主元写入对角阵 $D$ 中，使得 $\boldsymbol{U}=\boldsymbol{L}^{\mathrm{T}}$.

$$\begin{bmatrix}1&2\\2&7\end{bmatrix}=\begin{bmatrix}1&0\\2&1\end{bmatrix}\begin{bmatrix}1&2\\0&3\end{bmatrix}$$

$\boldsymbol{L}\boldsymbol{U}$ 分解忽略了 $\boldsymbol{S}$ 的对称性.
将主元 1, 3 从 $\boldsymbol{U}$ 中提出

$$\begin{bmatrix}1&2\\2&7\end{bmatrix}=\begin{bmatrix}1&0\\2&1\end{bmatrix}\begin{bmatrix}1&0\\0&3\end{bmatrix}\begin{bmatrix}1&2\\0&1\end{bmatrix}$$

$\boldsymbol{S}=\boldsymbol{L}\boldsymbol{D}\boldsymbol{L}^{\mathrm{T}}$ 保留了对称性
主元在 $\boldsymbol{D}$ 中，$\boldsymbol{U}$ 是 $\boldsymbol{L}$ 的转置.

**例 2.9** 给定矩阵 $\boldsymbol{A}$，与之关联的一个重要的对称矩阵 $\boldsymbol{S}$ 被称作鞍点矩阵：

分块矩阵
$$\boldsymbol{S}=\begin{bmatrix}\boldsymbol{I} & \boldsymbol{A}\\ \boldsymbol{A}^{\mathrm{T}} & \boldsymbol{0}\end{bmatrix}=\boldsymbol{S}^{\mathrm{T}}$$

$\boldsymbol{S}$ 是 $m+n$ 阶方阵. 通过分块消元法可得分块分解式 $\boldsymbol{S}=\boldsymbol{L}\boldsymbol{D}\boldsymbol{L}^{\mathrm{T}}$.

分块消元
第二行减去 $\boldsymbol{A}^{\mathrm{T}}$(第一行)
$$\boldsymbol{S}=\begin{bmatrix}\boldsymbol{I} & \boldsymbol{A}\\ \boldsymbol{A}^{\mathrm{T}} & \boldsymbol{0}\end{bmatrix}\text{ 化为 }\begin{bmatrix}\boldsymbol{I} & \boldsymbol{A}\\ \boldsymbol{0} & -\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\end{bmatrix}.\text{ 这就是 }\boldsymbol{U}.$$

分块的主元对角阵 $\boldsymbol{D}$ 含有 $\boldsymbol{I}$ 和 $-\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$，$\boldsymbol{L}$ 和 $\boldsymbol{L}^{\mathrm{T}}$ 包含了 $\boldsymbol{A}^{\mathrm{T}}$ 和 $\boldsymbol{A}$:

分块分解
$$\boldsymbol{S}=\boldsymbol{L}\boldsymbol{D}\boldsymbol{L}^{\mathrm{T}}=\begin{bmatrix}\boldsymbol{I} & \boldsymbol{0}\\ \boldsymbol{A}^{\mathrm{T}} & \boldsymbol{I}\end{bmatrix}\begin{bmatrix}\boldsymbol{I} & \boldsymbol{0}\\ \boldsymbol{0} & -\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\end{bmatrix}\begin{bmatrix}\boldsymbol{I} & \boldsymbol{A}\\ \boldsymbol{0} & \boldsymbol{I}\end{bmatrix}.$$

因此

$$\boldsymbol{S}\text{ 可逆}\Longleftrightarrow\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\text{ 可逆}\Longleftrightarrow\text{对任意 }\boldsymbol{x}\neq\boldsymbol{0},\boldsymbol{A}\boldsymbol{x}\neq\boldsymbol{0}.$$

## 习题 2.4

习题 1 ~ 7 关于转置矩阵的性质.

1. 对 $\boldsymbol{A}=\begin{bmatrix}1 & 0\\ 9 & 3\end{bmatrix}$ 和 $\begin{bmatrix}1 & c\\ c & 0\end{bmatrix}$，求 $\boldsymbol{A}^{\mathrm{T}}$、$\boldsymbol{A}^{-1}$、$(\boldsymbol{A}^{-1})^{\mathrm{T}}$ 和 $\left(\boldsymbol{A}^{\mathrm{T}}\right)^{-1}$.

2. 设 $\boldsymbol{A}=\begin{bmatrix}1 & 0\\ 2 & 1\end{bmatrix},\boldsymbol{B}=\begin{bmatrix}1 & 3\\ 0 & 1\end{bmatrix}$，验证：$(\boldsymbol{A}\boldsymbol{B})^{\mathrm{T}}$ 等于 $\boldsymbol{B}^{\mathrm{T}}\boldsymbol{A}^{\mathrm{T}}$，而不等于 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{B}^{\mathrm{T}}$:

$$\boldsymbol{A}=\begin{bmatrix}1 & 0\\ 2 & 1\end{bmatrix},\qquad\boldsymbol{B}=\begin{bmatrix}1 & 3\\ 0 & 1\end{bmatrix},\quad\boldsymbol{A}\boldsymbol{B}=\begin{bmatrix}1 & 3\\ 2 & 7\end{bmatrix}.$$

证明：$\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}\neq\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$. 但是它们都是_____.

3.（1）矩阵 $((\boldsymbol{A}\boldsymbol{B})^{-1})^{\mathrm{T}}$ 和 $(\boldsymbol{A}^{-1})^{\mathrm{T}},(\boldsymbol{B}^{-1})^{\mathrm{T}}$ 的关系是什么？

（2）如果 $\boldsymbol{U}$ 是上三角矩阵，那么 $(\boldsymbol{U}^{-1})^{\mathrm{T}}$ 是_____ 三角矩阵.

4. 证明：存在非零矩阵 $\boldsymbol{A}$ 使得 $\boldsymbol{A}^2=\boldsymbol{0}$，但是不存在非零矩阵 $\boldsymbol{A}$ 使得 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}=\boldsymbol{0}$.

5.（1）计算 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{y}=\begin{bmatrix}0 & 1\end{bmatrix}\begin{bmatrix}1 & 2 & 3\\ 4 & 5 & 6\end{bmatrix}\begin{bmatrix}0\\ 1\\ 0\end{bmatrix}=$_____.

（2）上式等于行向量 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{A}=$_____ 乘以列向量 $\boldsymbol{y}=\begin{bmatrix}0\\ 1\\ 0\end{bmatrix}$.

（3）上式也等于行向量 $\boldsymbol{x}^{\mathrm{T}}=\begin{bmatrix}0 & 1\end{bmatrix}$ 乘以列向量 $\boldsymbol{A}\boldsymbol{y}=$_____.

6. 分块矩阵 $\boldsymbol{M}=\begin{bmatrix}\boldsymbol{A} & \boldsymbol{B}\\ \boldsymbol{C} & \boldsymbol{D}\end{bmatrix}$ 的转置 $\boldsymbol{M}^{\mathrm{T}}=$_____. 如果 $\boldsymbol{A}$、$\boldsymbol{D}$ 是方阵，那么 $\boldsymbol{A}$、$\boldsymbol{B}$、$\boldsymbol{C}$、$\boldsymbol{D}$ 满足什么条件时，分块矩阵 $\boldsymbol{M}$ 是对称的？

7. 判断正误，正确则简述其理由，错误则举反例.

（1）分块矩阵 $\begin{bmatrix}0 & \boldsymbol{A}\\ \boldsymbol{A} & 0\end{bmatrix}$ 是对称的.

（2）如果 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 是对称矩阵，那么它们的乘积 $\boldsymbol{AB}$ 也是对称矩阵.

（3）如果 $\boldsymbol{A}$ 不是对称矩阵，那么 $\boldsymbol{A}^{-1}$ 也不是对称矩阵.

（4）当 $\boldsymbol{A}$、$\boldsymbol{B}$、$\boldsymbol{C}$ 是对称矩阵时，$\boldsymbol{ABC}$ 的转置等于 $\boldsymbol{CBA}$.

问题 8 ~ 15 关于置换矩阵.

8. 为什么 $n$ 阶置换矩阵有 $n!$ 个？

9. 已知当 $\boldsymbol{P}_1$ 和 $\boldsymbol{P}_2$ 是置换矩阵时，$\boldsymbol{P}_1\boldsymbol{P}_2$ 也是置换矩阵，它仍然是 $\boldsymbol{I}$ 的行向量的某种排列. 举出 $\boldsymbol{P}_1\boldsymbol{P}_2\neq\boldsymbol{P}_2\boldsymbol{P}_1$ 和 $\boldsymbol{P}_3\boldsymbol{P}_4=\boldsymbol{P}_4\boldsymbol{P}_3$ 的例子.

10. $(1,2,3,4)$ 的排列有 12 个是“偶”的：它们可以从 (1,2,3,4) 出发做偶数次的对换得到. 没有做对换的 (1, 2, 3, 4) 和做了两次对换的 $(4,3,2,1)$ 就是其中之二. 请列出其余 10 个偶排列. 这种表示方法比写出 $4\times4$ 矩阵简单，仅仅列出了顺序.

11. 如果 $\boldsymbol{P}$ 在反对角线 $(1,n)$ 到 $(n,\ 1)$ 上为 1，描述 $\boldsymbol{PAP}$. 注意 $\boldsymbol{P}=\boldsymbol{P}^{\mathrm{T}}$.

12. 设 $\boldsymbol{P}$ 是置换矩阵，解释 $\boldsymbol{x}$ 和 $\boldsymbol{y}$ 的点积为什么等于 $\boldsymbol{Px}$ 和 $\boldsymbol{Py}$ 的点积. 那么 $(\boldsymbol{Px})^{\mathrm{T}}(\boldsymbol{Py})=\boldsymbol{x}^{\mathrm{T}}\boldsymbol{y}$ 说明对所有的置换矩阵 $\boldsymbol{P}$ 都有 $\boldsymbol{P}^{\mathrm{T}}\boldsymbol{P}=\boldsymbol{I}$. 对 $\boldsymbol{x}=\begin{bmatrix}1 & 2 & 3\end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{y}=\begin{bmatrix}1 & 4 & 2\end{bmatrix}^{\mathrm{T}}$，选择合适的 $\boldsymbol{P}$ 来说明 $\boldsymbol{Px}\cdot\boldsymbol{y}$ 不一定等于 $\boldsymbol{x}\cdot\boldsymbol{Py}$.

13. 设 $\boldsymbol{A}=\begin{bmatrix}0 & 0 & 6\\ 1 & 2 & 3\\ 0 & 4 & 5\end{bmatrix}$，哪个置换矩阵 $\boldsymbol{P}$ 使得 $\boldsymbol{PA}$ 是上三角矩阵？哪两个置换矩阵使 $\boldsymbol{P}_1\boldsymbol{AP}_2$ 是下三角矩阵？在 $\boldsymbol{A}$ 右边乘以 $\boldsymbol{P}_2$ 交换了 $\boldsymbol{A}$ 的_____.

14. 求一个 $3\times3$ 置换矩阵 $\boldsymbol{P}\neq\boldsymbol{I}$ 满足 $\boldsymbol{P}^3=\boldsymbol{I}$. 为什么 $\boldsymbol{P}$ 不是简单地交换两行？求一个 $4\times4$ 置换矩阵 $\widehat{\boldsymbol{P}}$ 使 $\widehat{\boldsymbol{P}}^4\neq I$.

15. 所有的行对换矩阵都是对称的：$\boldsymbol{P}^{\mathrm{T}}=\boldsymbol{P}$. 那么 $\boldsymbol{P}^{\mathrm{T}}\boldsymbol{P}=\boldsymbol{I}$ 变为 $\boldsymbol{P}^2=\boldsymbol{I}$. 其他置换矩阵未必是对称的.

（1）如果 $\boldsymbol{P}$ 将第 1 行换到第 4 行，那么 $\boldsymbol{P}^{\mathrm{T}}$ 将第_____ 行换到第_____ 行. 当 $\boldsymbol{P}^{\mathrm{T}}=\boldsymbol{P}$ 时行交换成对出现，而且没有交叉.

（2）举出一个 $4\times4$ 置换矩阵 $\boldsymbol{P}$ 的例子，其满足 $\boldsymbol{P}^{\mathrm{T}}=\boldsymbol{P}$ 并且把四行都变到了其他行.

问题 16 ~ 18 关于对称矩阵以及它们的分解.

16. 如果 $\boldsymbol{A}=\boldsymbol{A}^{\mathrm{T}},\boldsymbol{B}=\boldsymbol{B}^{\mathrm{T}}$，下面哪些矩阵一定是对称的？

（1）$\boldsymbol{A}^2-\boldsymbol{B}^2$

（2）$(\boldsymbol{A}+\boldsymbol{B})(\boldsymbol{A}-\boldsymbol{B})$

（3）$\boldsymbol{ABA}$

（4）$\boldsymbol{ABAB}$.

17.（1）$\boldsymbol{S}$ 是一个 $5\times5$ 矩阵，它有多少元素可以随意独立选择？

（2）$5\times5$ 矩阵 $\boldsymbol{LDL}^{\mathrm{T}}$ 中可独立选择的元素和（1）相同. 在 $\boldsymbol{L}$ 和 $\boldsymbol{D}$ 中可以随意独立选择多少元素？

（3）如果 $\boldsymbol{A}$ 是反对称矩阵 $(\boldsymbol{A}=-\boldsymbol{A}^{\mathrm{T}})$，在 $\boldsymbol{A}$ 中多少元素可以随意独立选择？

（4）为什么 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 的对角线元素非负？

18. 将以下对称矩阵分解为 $\boldsymbol{S}=\boldsymbol{LDL}^{\mathrm{T}}$，其中主元矩阵 $\boldsymbol{D}$ 是对角矩阵：

$$\boldsymbol{S}=\begin{bmatrix}1&3\\3&2\end{bmatrix},\qquad \boldsymbol{S}=\begin{bmatrix}1&b\\b&c\end{bmatrix},\qquad \boldsymbol{S}=\begin{bmatrix}2&-1&0\\-1&2&-1\\0&-1&2\end{bmatrix}.$$

19. 对以下矩阵 $\boldsymbol{A}$，求它的 $\boldsymbol{PA}=\boldsymbol{LU}$ 分解

$$\boldsymbol{A}=\begin{bmatrix}0&1&1\\1&0&1\\2&3&4\end{bmatrix},\qquad \boldsymbol{A}=\begin{bmatrix}1&2&0\\2&4&1\\1&1&1\end{bmatrix}.$$

20. 构造一个需要 3 次行对换才能完成消元的 $4\times4$ 矩阵 $\boldsymbol{A}$. 这个矩阵的分解因子 $\boldsymbol{P}$、$\boldsymbol{L}$、$\boldsymbol{U}$ 分别是什么？

21. 证明单位矩阵不能写成 3 个（或 5 个）对换的乘积，但是可以写成 2 个（或 4 个）对换的乘积.

22. 如果一个 $4\times4$ 矩阵的每一行都是 0、1、2、3 按某种顺序排列而成，这个矩阵可能是对称矩阵吗？

23. 对 $3\times3$ 矩阵 $\boldsymbol{A}$，证明不能通过重新排列矩阵的行或列得到 $\boldsymbol{A}^{\mathrm{T}}$（注意主对角线上的元素）.

24. 在波士顿、芝加哥、西雅图这三个城市间铺设电缆. 这些城市的电势分别为 $x_{\mathrm{B}}$、$x_{\mathrm{C}}$、$x_{\mathrm{S}}$. 假设城市间存在单位电阻，城市间的电流记为 $\boldsymbol{y}$:

$$\boldsymbol{y}=\boldsymbol{Ax}\qquad \begin{bmatrix}y_{\mathrm{BC}}\\y_{\mathrm{CS}}\\y_{\mathrm{BS}}\end{bmatrix}=\begin{bmatrix}1&-1&0\\0&1&-1\\1&0&-1\end{bmatrix}\begin{bmatrix}x_{\mathrm{B}}\\x_{\mathrm{C}}\\x_{\mathrm{S}}\end{bmatrix}.$$

（1）求这三个城市各自输出的总电流 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}$.

（2）验证 $(\boldsymbol{Ax})^{\mathrm{T}}\boldsymbol{y}$ 和 $\boldsymbol{x}^{\mathrm{T}}\left(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}\right)$ 相等——均为 6 项之和.

25. 若矩阵 $\boldsymbol{P}$ 乘以 $\begin{bmatrix}x&y&z\end{bmatrix}^{\mathrm{T}}$ 后得到 $\begin{bmatrix}z&x&y\end{bmatrix}^{\mathrm{T}}$，则它还是一个旋转矩阵，求 $\boldsymbol{P}$ 和 $\boldsymbol{P}^3$. $\boldsymbol{a}=\begin{bmatrix}1&1&1\end{bmatrix}^{\mathrm{T}}=\boldsymbol{Pa}$，保持不变，所以 $\boldsymbol{a}$ 是旋转轴. 从 $\boldsymbol{v}=\begin{bmatrix}2&3&-5\end{bmatrix}^{\mathrm{T}}$ 到 $\boldsymbol{Pv}=\begin{bmatrix}-5&2&3\end{bmatrix}^{\mathrm{T}}$ 的旋转角度是多少？

26. 下面是一个新的分解式 $\boldsymbol{A}=\boldsymbol{LS}=$ 上三角矩阵乘以对称矩阵：

$$\text{由 }\boldsymbol{A}=\boldsymbol{LDU}\text{，得 }\boldsymbol{A}=\left(\boldsymbol{L}\left(\boldsymbol{U}^{\mathrm{T}}\right)^{-1}\right)\left(\boldsymbol{U}^{\mathrm{T}}\boldsymbol{DU}\right).$$

为什么 $\boldsymbol{L}\left(\boldsymbol{U}^{\mathrm{T}}\right)^{-1}$ 是上三角矩阵？为什么 $\boldsymbol{U}^{\mathrm{T}}\boldsymbol{D}\boldsymbol{U}$ 是对称阵？

27. 在代数中，包含 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 的矩阵群一定包含 $\boldsymbol{A}\boldsymbol{B}$ 和 $\boldsymbol{A}^{-1}$. “群关于乘法封闭且任意元素存在逆元.” 下列哪些集合是群？

（1）主对角线上元素为 1 的全体下三角矩阵；

（2）全体对称矩阵；

（3）全体正定矩阵；

（4）全体对角可逆矩阵；

（5）全体置换矩阵；

（6）全体正交矩阵，即满足 $\boldsymbol{Q}^{\mathrm{T}}=\boldsymbol{Q}^{-1}$ 的矩阵 $\boldsymbol{Q}$ 的全体.

再写出两个矩阵群.

## 挑 战 一 下

28. 计算置换矩阵 $\boldsymbol{P}$ 的幂，为什么有些幂 $\boldsymbol{P}^k$ 等于单位矩阵 $\boldsymbol{I}$？写一个 $5\times 5$ 的置换矩阵 $\boldsymbol{P}$ 使得等于 $\boldsymbol{I}$ 的最低幂次是 $\boldsymbol{P}^6$.

29.（1）任意写一个 $3\times 3$ 矩阵 $\boldsymbol{M}$. 将 $\boldsymbol{M}$ 拆分为 $\boldsymbol{S}+\boldsymbol{A}$ 的形式，其中 $\boldsymbol{S}=\boldsymbol{S}^{\mathrm{T}}$ 是对称矩阵且 $\boldsymbol{A}=-\boldsymbol{A}^{\mathrm{T}}$ 是反对称矩阵.

（2）用 $\boldsymbol{M}$ 和 $\boldsymbol{M}^{\mathrm{T}}$ 把 $\boldsymbol{S}$ 和 $\boldsymbol{A}$ 表示出来.

30. 设 $\boldsymbol{Q}^{\mathrm{T}}=\boldsymbol{Q}^{-1}$，所以 $\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{Q}=\boldsymbol{I}$. 这样的矩阵 $\boldsymbol{Q}$ 称为正交矩阵.

（1）证明 $\boldsymbol{q}_1,\boldsymbol{q}_2,\cdots,\boldsymbol{q}_n$ 是单位向量：$\|\boldsymbol{q}_i\|^2=1$.

（2）证明 $\boldsymbol{Q}$ 的任意两列都正交：$\boldsymbol{q}_1^{\mathrm{T}}\boldsymbol{q}_2=0$.

（3）写一个 $2\times 2$ 正交矩阵的例子，其中左上角元素 $q_{11}=\cos\theta$.

## 2.5　导数和有限差分矩阵

本节的目标是建立微积分与线性代数的联系. 用矩阵来表示导数 (尽可能模拟). 导数告诉我们在一点 $x$ 或者一个时刻 $t$ 的状态：

| | |
|---|---|
| $\dfrac{\mathrm{d}y}{\mathrm{d}x}>0$：$y$ 的图像是向上的 | $\dfrac{\mathrm{d}u}{\mathrm{d}t}>0$：函数 $u$ 递增 |
| $\dfrac{\mathrm{d}^2y}{\mathrm{d}x^2}>0$：$y$ 的图像是下凸的 | $\dfrac{\mathrm{d}^2u}{\mathrm{d}t^2}>0$：增长率 $\dfrac{\mathrm{d}u}{\mathrm{d}t}$ 是递增的 |

要写出关于 $y(x)$ 和 $u(t)$ 比上述更重要的性质可能“强人所难”了. 不过需要说明的是，增加或减少与上凸（加速）或下凸不是一回事儿.

抛物线 $y=x^2$ 的导数为 $\dfrac{\mathrm{d}y}{\mathrm{d}x}=2x$，二阶导数为 $\dfrac{\mathrm{d}^2y}{\mathrm{d}x^2}=2$. 当 $x$ 为负时，其图像向下（递减），当 $x$ 为正时，图像向上. 但是 $y=x^2$ 的图像在任何地方都是下凸的. 它的二阶导数为正（+2），所以它的一阶导数是递增的. 切线斜率的增加使得图像下凸.

之前我们讨论了导数（仅在一个点），现在我们来讨论两点之间的差值：$y$ 在两个点的取值之差或者 $u$ 在两个时刻的取值之差. 两个点为 $x$ 和 $x+h$. 下面是三个重要的陈述.

（1）差值 $\Delta y = y(x+h) - y(x)$ 近似于 $x$ 处的斜率 $\dfrac{\mathrm{d}y}{\mathrm{d}x}$ 的 $h$ 倍.

（2）对 $\Delta y$ 一个更好的近似是加上 $x$ 处的二阶导数 $\dfrac{\mathrm{d}^2y}{\mathrm{d}x^2}$ 的 $\dfrac{1}{2}h^2$ 倍.

（3）$\Delta y$ 的精确值 $y(x+h)-y(x)$ 是 $\dfrac{\mathrm{d}y}{\mathrm{d}x}$ 从 $x$ 到 $x+h$ 的积分.

前两个将变化量 $y(x+h)-y(x)$ 与 $y$ 在某一点的导数联系起来. 一阶导数给出“一阶”近似——不错但不够理想. 把二阶导数 (乘以 $\dfrac{1}{2}h^2$) 再包含进去，我们得到“二阶”近似——这要好得多. 对于 $y=x^2, \dfrac{\mathrm{d}y}{\mathrm{d}x}=2x, \dfrac{\mathrm{d}^2y}{\mathrm{d}x^2}=2$. 精确值 $\Delta y = (x+h)^2 - x^2$ 为 $x^2+2hx+h^2-x^2$.

$$\underset{}{\Delta y =} \quad \underset{\text{一阶}}{2hx} \quad + \quad \underset{\text{二阶}}{h^2} \quad = \quad \underset{\text{切线}}{h\frac{\mathrm{d}y}{\mathrm{d}x}} \quad + \quad \underset{\text{抛物线}}{\frac{1}{2}h^2\frac{\mathrm{d}^2y}{\mathrm{d}x^2}}$$

导数 $\dfrac{\mathrm{d}y}{\mathrm{d}x}$ 乘以步长 $h=\Delta x$. 从图像上看，第一阶近似是用切线去逼近图像. 二阶导数乘以 $\dfrac{1}{2}h^2$ 给出了误差的修正. 二阶近似可看作切抛物线.

对于 $y=x^2$ 这个特殊例子，切线抛物线就是实际的抛物线. 如果我们想要估计切线抛物线带来的误差，可以接着研究函数 $y=x^3$. $y=x^2$ 和 $y=x^3$ 从 $x=1$ 到 $x=1+h=2$ 的图像展示了切线抛物线相较于切线的改进之处.

$y(x+h)-y(x)$ 的包含 $y$ 的所有导数的公式是泰勒级数. 泰勒级数的前两项是 $h$ 乘以 $\dfrac{\mathrm{d}y}{\mathrm{d}x}$ 和 $\dfrac{1}{2}h^2$ 乘以二阶导数 $\dfrac{\mathrm{d}^2y}{\mathrm{d}x^2}$. 下一项是 $\dfrac{1}{6}h^3$ 乘以三阶导数，第 $n$ 项是 $\dfrac{1}{n!}h^n$ 乘以 $n$ 阶导数.

泰勒级数有两种常见的表述. 一是用 $x=0$ 处的导数来预测其他点 $x$ 处的 $y(x)$，二是用点 $x$ 处的导数来预测不同点 $x+h$ 处的 $y(x+h)$.

$y(x)$ 的泰勒级数：
$$y(0)+x\frac{\mathrm{d}y}{\mathrm{d}x}(0)+\frac{1}{2}x^2\frac{\mathrm{d}^2y}{\mathrm{d}x^2}(0)+\cdots+\frac{1}{n!}x^n\frac{\mathrm{d}^ny}{\mathrm{d}x^n}(0)+\cdots$$

$y(x+h)$ 的泰勒级数：
$$y(x)+h\frac{\mathrm{d}y}{\mathrm{d}x}(x)+\frac{1}{2}h^2\frac{\mathrm{d}^2y}{\mathrm{d}x^2}(x)+\cdots+\frac{1}{n!}h^n\frac{\mathrm{d}^ny}{\mathrm{d}x^n}(x)+\cdots$$

它们都是无穷级数! 很多著名的函数，比如 $y(x)=\mathrm{e}^x$，其泰勒级数在每一点收敛. $\mathrm{e}^x$ 是全纯函数. 函数 $y(x)=1/(1-x)$ 的泰勒级数 $1+x+x^2+\cdots$ 只在 $|x|<1$ 时收敛，所以 $1/(1-x)$ 从左边接近 1 时是收敛的，但是 $x=1$ 是一个“奇点”或者称为 $1/(1-x)$ 的“极点”.

### 2.5.1 公式的逆向推导：由差值求导数

我们的出发点仍是通过切线抛物线得到的重要近似：

$$y(x+h) \approx y(x) + h\frac{\mathrm{d}y}{\mathrm{d}x}(x) + \frac{1}{2}h^2\frac{\mathrm{d}^2y}{\mathrm{d}x^2}(x) \tag{2.34}$$

与之前不同，现在我们的问题反过来了. 我们如果知道 $y(x)$ 和 $y(x+h)$, 如何估计 $\dfrac{\mathrm{d}y}{\mathrm{d}x}$ 呢？如果还知道 $y(x-h)$, 又该如何估计 $\dfrac{\mathrm{d}y}{\mathrm{d}x}$（改进版!）以及 $\dfrac{\mathrm{d}^2y}{\mathrm{d}x^2}$ 呢？利用 $y(x-h)$、$y(x)$、$y(x+h)$ 这三个值, 我们可以得到科学计算中最重要的近似值. 我们必须这么做, 而且并不难. 在 $x+h$ 处写出近似式 (2.34), 然后在 $x-h$ 处再写一次 ($h$ 将换成 $-h$)：

$$y(x+h)-y(x)\approx h\frac{\mathrm{d}y}{\mathrm{d}x}+\frac{1}{2}h^2\frac{\mathrm{d}^2y}{\mathrm{d}x^2} \tag{2.35a}$$

$$y(x-h)-y(x)\approx -h\frac{\mathrm{d}y}{\mathrm{d}x}+\frac{1}{2}h^2\frac{\mathrm{d}^2y}{\mathrm{d}x^2} \tag{2.35b}$$

式(2.35a)减式(2.35b)再除以 $2h$，这就得到了 $\dfrac{\mathrm{d}y}{\mathrm{d}x}$ 的一个改进近似值：

$$\boxed{\text{中心差分}\qquad \frac{y(x+h)-y(x-h)}{2h}\approx\frac{\mathrm{d}y}{\mathrm{d}x}} \tag{2.36}$$

式(2.35a)加式(2.35b)再除以 $h^2$，就得到了二阶导数的一个完美估计!

$$\boxed{\text{二阶差分}\qquad \frac{y(x+h)-2y(x)+y(x-h)}{h^2}\approx\frac{\mathrm{d}^2y}{\mathrm{d}x^2}} \tag{2.37}$$

这两个公式为我们接下来迈出的一大步打下了坚实的基础——近似求解微分方程. 许多重要的微分方程是“二阶”的，不仅包含一阶导数，也包含二阶导数, 如:

$$\frac{\mathrm{d}^2y}{\mathrm{d}x^2}+a\frac{\mathrm{d}y}{\mathrm{d}x}+by=f(x) \tag{2.38}$$

在点 $x$ 处，一个很好的有限差分近似是:

$$\boxed{\frac{y(x+h)-2y(x)+y(x-h)}{h^2}+a\frac{y(x+h)-y(x-h)}{2h}+by(x)=f(x)} \tag{2.39}$$

从式(2.38)中的导数到式(2.39)中的差分这一步，使用了式(2.36)和式(2.37)的近似. 可以将式(2.36)与这些非中心差分进行比较，非中心差分只有一阶精度：

$$\boxed{\begin{array}{ll}\text{向前差分} & \dfrac{\mathrm{d}y}{\mathrm{d}x}=\dfrac{y(x+h)-y(x)}{h}+O(h)\text{误差}\\ \text{向后差分} & \dfrac{\mathrm{d}y}{\mathrm{d}x}=\dfrac{y(x)-y(x-h)}{h}+O(h)\text{误差}\end{array}} \tag{2.40}$$

对式(2.40)中的向前差分和向后差分取平均值，就得到了式(2.36)的中心差分. 误差的主项 $O(h)$ 抵消了. 这样一来, 中心差分具有二阶精度.

### 2.5.2　二阶差分矩阵 $K$、$T$、$B$

本节介绍三个重要的二阶差分矩阵 $\boldsymbol{K}$、$\boldsymbol{T}$、$\boldsymbol{B}$. 它们都有式(2.37)在近似 $\dfrac{\mathrm{d}^2y}{\mathrm{d}x^2}$（图形的弯曲程度以及运动的加速度）时所得到的 1、−2、1 系数类型.

这些矩阵中的数字其实统一改变了符号，变成了 $-1$、$2$、$-1$. 现在我们来近似 $-\dfrac{\mathrm{d}^2y}{\mathrm{d}x^2}$. 从一个点的二阶差分近似扩展到许多点的二阶差分, 从而进入矩阵的领地——这一点极为重要.

其中最关键的一步是在 $N$ 个网格点处用 $N$ 个差分方程来近似一个微分方程. 我们通常使用等间距的点 $x_1=h, x_2=2h, \cdots, x_N=Nh$. 间距 $h$ 就是网格宽度. 边界点是 $x_0=0$ 和 $x_{N+1}=1$. 因此 $(N+1)h$ 等于总长度 1. 网格宽度为 $h=1/(N+1)$. $h$ 将出现在一阶差分中, 而 $h^2$ 出现在二阶差分中.

从方程 $-\dfrac{\mathrm{d}^2u}{\mathrm{d}x^2}=f(x)$ 出发. 假设函数边界点 $x=0$ 和 $x=1$ 的值都固定为零. 这意味着 $u(0)=0$ 且 $u(1)=0$. 对于差分方程这些边界条件转化为 $u_0=0$ 和 $u_{N+1}=0$. 未知数 $u_1, u_2, \cdots, u_N$ 将是方程在 $x=0$ 和 $x=1$ 之间的精确解 $u(h), u(2h), \cdots, u(Nh)$ 的近似值.

我们的未知量是向量 $\boldsymbol{U}=\begin{bmatrix}u_1 & \cdots & u_N\end{bmatrix}^{\mathrm{T}}$. 我们需要 $N$ 个差分方程, 每个网格点处一个. 我们打算将这 $N$ 个方程表示为一个矩阵方程. 以下是 $N=4$ 且 $h=\dfrac{1}{5}$ 时的矩阵方程 $(1/h^2)\boldsymbol{KU}=\boldsymbol{F}$:

$$
\begin{array}{l}
-\dfrac{\mathrm{d}^2y}{\mathrm{d}x^2}=f(x) \\
\text{化为}\dfrac{\boldsymbol{KU}}{h^2}=\boldsymbol{F}
\end{array}
\qquad
\frac{1}{h^2}\begin{bmatrix}2&-1&0&0\\-1&2&-1&0\\0&-1&2&-1\\0&0&-1&2\end{bmatrix}\begin{bmatrix}u_1\\u_2\\u_3\\u_4\end{bmatrix}=\begin{bmatrix}f(h)\\f(2h)\\f(3h)\\f(4h)\end{bmatrix}.
$$

式(2.37)表明 $\dfrac{\mathrm{d}^2u}{\mathrm{d}x^2}$ 近似于 $\dfrac{u(x+h)-2u(x)+u(x-h)}{h^2}$. 矩阵 $\boldsymbol{K}$ 在固定边界条件 $u_0=0$ 和 $u_{N+1}=0$下给出了 $-\dfrac{\mathrm{d}^2u}{\mathrm{d}x^2}$ 的一个自然的近似.

关键要点是：$N=4$ 个方程被纳入一个 $N\times N$ 矩阵中. 在行向量乘以列向量的规则下, $\boldsymbol{KU}$ 重现了 $N$ 个差分方程. 第一行乘以 $\boldsymbol{U}$ 得到 $2u_1-u_2$，它是行向量 $\begin{bmatrix}2&-1&0&0\end{bmatrix}$ 与列向量 $\begin{bmatrix}u_1&u_2&u_3&u_4\end{bmatrix}^{\mathrm{T}}$ 的乘积. 对于第一行以及最后一行，矩阵 $\boldsymbol{K}$ 都蕴含了固定的边界条件 $u_0=0$ 和 $u_5=0$. 比较典型的一行是 $\dfrac{(-u_1+2u_2-u_3)}{h^2}=f(h)$.

除以 $h^2$，那么 $\boldsymbol{K}/h^2$ 成为一个二阶差分矩阵，替代了二阶求导 $-\dfrac{\mathrm{d}^2u}{\mathrm{d}x^2}$.

### 2.5.3 矩阵 $K$ 的性质

提出一个问题：*矩阵 $\boldsymbol{K}$ 满足哪些重要的性质？* 当我向我的学生提出这个问题时，通常会得到三个答案，有时是四个. 按照学生们给出答案的顺序来阐述. 以 $N=4$ 时的矩阵 $\boldsymbol{K}_4$ 为例.

固定边界条件的二阶差分矩阵
$$
\boldsymbol{K}_4=\begin{bmatrix}2&-1&0&0\\-1&2&-1&0\\0&-1&2&-1\\0&0&-1&2\end{bmatrix} \tag{2.41}
$$

（1）$\boldsymbol{K}$ 是对称的. 第 $i$ 行第 $j$ 列的元素和第 $j$ 行第 $i$ 列元素相同，因此 $\boldsymbol{K}_{ij}=\boldsymbol{K}_{ji}$，对称的元素位于主对角线的两侧. “$\boldsymbol{K}$ 的转置等于 $\boldsymbol{K}$”，所以矩阵 $\boldsymbol{K}$ 沿对角线对称.

表达对称性最简单的方式是 $\boldsymbol{K}^{\mathrm{T}}=\boldsymbol{K}$. 转置操作将任意矩阵 $\boldsymbol{A}$ 的行变为 $\boldsymbol{A}^{\mathrm{T}}$ 的列. 在我们的例子中，$\boldsymbol{K}^{\mathrm{T}}$ 与 $\boldsymbol{K}$ 相同.

$$\boldsymbol{A}=\begin{bmatrix}1&2\\3&4\\5&6\end{bmatrix}\quad \text{的转置}\quad \boldsymbol{A}^{\mathrm{T}}=\begin{bmatrix}1&3&5\\2&4&6\end{bmatrix},\quad \text{并且}\left(\boldsymbol{A}^{\mathrm{T}}\right)^{\mathrm{T}}=\boldsymbol{A}\quad ,\quad \left(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\right)^{\mathrm{T}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}.$$

（2）$\boldsymbol{K}$ 是“带状矩阵”. $\boldsymbol{K}$ 中的所有非零元素都位于主对角线周围的一个“带”内. 该条带只有三条对角线，所以 $\boldsymbol{K}$ 是一个三对角矩阵. 这意味着 $\boldsymbol{KU}/h^2=\boldsymbol{F}$ 可以快速求解. 消元过程简单且快速.

带很窄的带状矩阵是稀疏的——大部分元素为零. 对于 $N=4$（小矩阵），我们不太能明显看出这一点. 但对于 $N=100$，我们就能清晰地意识到这一点. 在这种情况下，矩阵的 $100^2=10000$ 个元素中，只有 $100+99+99$ 个非零元素：占比还不到 3%. 而且 $N=100$ 远算不上是一个大矩阵.

（3）$\boldsymbol{K}$ 对角线元素都相等. 一条对角线元素为 $-1$，另一条对角线元素为 2，最后一条对角线元素为 $-1$. 该矩阵是“平移不变的”. 这是因为基础的微分方程有常数系数 $-1$. 对 $-\dfrac{\mathrm{d}^2u}{\mathrm{d}x^2}$ 的近似在每个 $x$ 处都有相同的系数 $-1$、2、$-1$. 严格来说，平移不变性在边界处不成立——这始终是个棘手的问题.

对角线是常数的性质立刻让人联想到傅里叶变换. 傅里叶变换整个领域都与对角线是常数的矩阵相关联. 我们也称它们为滤波器或卷积矩阵. 其数学名称是托普利兹矩阵.

矩阵 $\boldsymbol{K}$ 无疑是科学计算中最重要的矩阵之一.

MATLAB 命令 K = toeplitz[2, −1, 0, 0] 从第一行开始构建 $\boldsymbol{K}=\boldsymbol{K}^{\mathrm{T}}$.

至此就完整阐述了 $\boldsymbol{K}$ 的三个直观可见的性质：对称性、稀疏性和平移不变性. 对任意 $n$，矩阵 $\boldsymbol{K}_n$ 都还有第四个同样重要的性质，尽管这个事实并不足够显而易见.

（4）

$$\boxed{\begin{array}{l}\boldsymbol{K}\text{ 可逆}\\ \boldsymbol{K}\text{ 有逆矩阵 }\boldsymbol{K}^{-1}\\ \text{那么 }\boldsymbol{K}^{-1}\boldsymbol{K}=\boldsymbol{K}\boldsymbol{K}^{-1}=\boldsymbol{I}\end{array}\qquad \boldsymbol{K}_4^{-1}=\frac{1}{5}\begin{bmatrix}4&3&2&1\\3&6&4&2\\2&4&6&3\\1&2&3&4\end{bmatrix}} \tag{2.42}$$

逆矩阵 $\boldsymbol{K}^{-1}$ 也是对称的，但不是三对角矩阵. 它是稠密矩阵（实际上没有元素为零）. 在数值计算中我们不需要把 $\boldsymbol{K}^{-1}$ 算出来，但我们确实需要知道逆矩阵存在.

仅从矩阵的外观很难快速判断其是否可逆. 从理论上讲，我们可以计算其行列式（这里行列式的值是 5），因为逆矩阵的公式必须除以行列式的值，所以可逆矩阵的行列式不能为零. 若矩阵行列式不为零，那么就有逆矩阵——但在实际中几乎从不计算行列式或 $\boldsymbol{K}^{-1}$！先求逆矩阵再求出解 $\boldsymbol{K}^{-1}\boldsymbol{F}$ 是一种非常低效的方法.

实际上我们所做的是直接进行消元来求解 $\boldsymbol{KU}=\boldsymbol{F}$. 上三角矩阵主对角线上的非零主元表明 $\boldsymbol{K}$ 是可逆的.

在 MATLAB 中，反斜杠命令 U = K\F 非常快地就能给出解.

（5）再补充一条性质：对称矩阵 $\boldsymbol{K}_n$ 是正定的. 第 6 章将详细解释这个概念. 我们计划将 $\boldsymbol{K}$ 和 $\boldsymbol{T}$（正定）与矩阵 $\boldsymbol{B}$（半正定）进行对比.

一切都源自“正”和“非负”之间的区别：“大于 0”和“大于或等于 0”.

主元
- 可逆矩阵有$n$ 个非零主元
- 正定对称矩阵有$n$ 个正的主元
- 半正定对称矩阵有$n$ 个非负的主元

### 2.5.4 一端自由一端固定的矩阵 $T_n$

在本节结束之前，我们再介绍一下 $\boldsymbol{T}_n$ 和 $\boldsymbol{B}_n$. 它们是 $\boldsymbol{K}_n$ 的变形. 这些变形源于“改变边界条件”. 我们可以设想一根弹性杆，两端固定、仅一端固定或者完全自由. 在我们了解这些矩阵之后，对这个问题的模型进行描述.

二阶差分矩阵 $\boldsymbol{T}_n$ 和 $\boldsymbol{K}_n$ 一样，是对称且三对角的. 但是 $\boldsymbol{T}_n$ 的 $(1,1)$ 位置的元素从 2 变为了 1. 第一行的 $1,-1$ 表示自由边界条件 $\dfrac{\mathrm{d}u}{\mathrm{d}x}=0$，至于为什么我们很快就会明白.

自由-固定边界条件
矩阵仍然正定

$$\boldsymbol{T}_4=\begin{bmatrix}1&-1&0&0\\-1&2&-1&0\\0&-1&2&-1\\0&0&-1&2\end{bmatrix} \tag{2.43}$$

$\boldsymbol{T}$ 已经不是托普利兹矩阵了，因为它的主对角线元素不是常数. 但它的分解比 $\boldsymbol{K}$ 更简单（因为 $\boldsymbol{T}$ 的每个主元都等于 1）.

$$\boldsymbol{T}=\begin{bmatrix}1&&&\\-1&1&&\\0&-1&1&\\0&0&-1&1\end{bmatrix}\begin{bmatrix}1&-1&0&0\\&1&-1&0\\&&1&-1\\&&&1\end{bmatrix}=\boldsymbol{LU} \tag{2.44}$$

$\boldsymbol{T}$ 是由一个向后差分矩阵 $\boldsymbol{L}$ 与其转置 $\boldsymbol{U}=\boldsymbol{L}^{\mathrm{T}}$ 相乘得到的. 注意，$\boldsymbol{U}$ 是负的向前差分矩阵. 这就给出了我们需要的负号，因为 $\boldsymbol{T}$ 是二阶差分矩阵的 $-1$ 倍.

这个负号使得 $\boldsymbol{T}=\boldsymbol{L}\boldsymbol{L}^{\mathrm{T}}$ 是正定矩阵！请注意，$\boldsymbol{L}$、$\boldsymbol{U}$ 以及 $\boldsymbol{T}=\boldsymbol{LU}$ 都有很好的逆矩阵.

$$\boldsymbol{U}^{-1}=\begin{bmatrix}1&1&1&1\\&1&1&1\\&&1&1\\&&&1\end{bmatrix},\quad \boldsymbol{L}^{-1}=\begin{bmatrix}1&&&\\1&1&&\\1&1&1&\\1&1&1&1\end{bmatrix},\quad \boldsymbol{T}^{-1}=\boldsymbol{U}^{-1}\boldsymbol{L}^{-1}=\begin{bmatrix}4&3&2&1\\3&3&2&1\\2&2&2&1\\1&1&1&1\end{bmatrix}. \tag{2.45}$$

### 2.5.5 两端自由的矩阵 $B$ 是奇异的

对一个方阵 $\boldsymbol{B}$，“奇异”是指“不可逆”. 一种判断方法是行列式等于 0. 若 $\boldsymbol{B}$ 可逆，它的逆矩阵需要除以行列式 $D$，所以需要 $D\neq 0$.

另一个更好的判断方法（因为计算 $D$ 不是必需的）是找一个非零向量 $\boldsymbol{x}$ 使得 $\boldsymbol{Bx}=\boldsymbol{0}$.

> 如果 $\boldsymbol{B}$ 乘以一个非零的向量 $\boldsymbol{x}$ 使得 $\boldsymbol{Bx}=\boldsymbol{0}$，那么 $\boldsymbol{B}$ 不能是可逆的.
> $\boldsymbol{B}$ 可逆会导致 $\boldsymbol{B}^{-1}\boldsymbol{Bx}=\boldsymbol{x}$. 但是这表示 $\boldsymbol{B}^{-1}\boldsymbol{0}=\boldsymbol{x}$. 不可能成立.

**例 2.10**　自由-自由矩阵 $\boldsymbol{B}_3$ 在 $(1,1)$ 和 $(3,3)$ 位置是 1（而不是 2）:

$$\boldsymbol{B}_3=\begin{bmatrix}1&-1&0\\-1&2&-1\\0&-1&1\end{bmatrix}\quad 则\quad \boldsymbol{B}_3\boldsymbol{x}=\begin{bmatrix}1&-1&0\\-1&2&-1\\0&-1&1\end{bmatrix}\begin{bmatrix}1\\1\\1\end{bmatrix}=\begin{bmatrix}0\\0\\0\end{bmatrix}. \tag{2.46}$$

全 1 向量 $\boldsymbol{x}=\begin{bmatrix}1&1&1\end{bmatrix}^{\mathrm{T}}$ 是 $\boldsymbol{B}_3\boldsymbol{x}=\boldsymbol{0}$ 的解. 该向量属于 $\boldsymbol{B}_3$ 的零空间. 任意常数向量 $\boldsymbol{x}=\begin{bmatrix}c&c&c\end{bmatrix}^{\mathrm{T}}$ 都属于零空间：$\boldsymbol{B}_3\boldsymbol{x}=\boldsymbol{0}$. 而原因都是 $\boldsymbol{B}_3$ 的各列所有分量相加都等于 0. 这样的矩阵不可能可逆.

为了弄清楚为什么 $\boldsymbol{K}_3$ 和 $\boldsymbol{T}_3$ 可逆而 $\boldsymbol{B}_3$ 是奇异的，我们看几个模型，如图 2.4 所示. 有三个通过弹簧连接的质量块. 差异在于两端（边界处）. 对于 $\boldsymbol{K}_3$，两端是固定的；对于 $\boldsymbol{B}_3$，两端都是自由的；$\boldsymbol{T}_3$ 介于两者之间，顶部是自由的，底部是固定的.

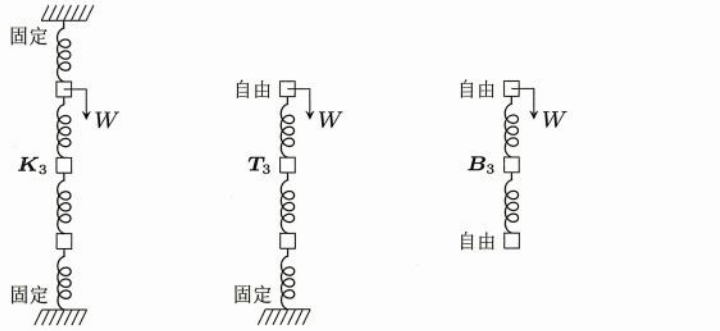


(a) 固定-固定　(b) 自由-固定　(c) 自由-自由（奇异，没有逆）

图 2.4　弹簧系统根据两端是否固定分类

如果在中间的盒子里添加一个重量为 $W$ 的物体，$\boldsymbol{B}_3$ 的弹簧无法做出调整，因为它们缺乏外部支撑. 但 $\boldsymbol{K}_3$ 和 $\boldsymbol{T}_3$ 的弹簧会做出调整以平衡这个重量：

$$\begin{bmatrix}2&-1&0\\-1&2&-1\\0&-1&2\end{bmatrix}\begin{bmatrix}W/2\\W\\W/2\end{bmatrix}=\begin{bmatrix}0\\W\\0\end{bmatrix}\qquad\begin{bmatrix}1&-1&0\\-1&2&-1\\0&-1&2\end{bmatrix}\begin{bmatrix}2W\\2W\\W\end{bmatrix}=\begin{bmatrix}0\\W\\0\end{bmatrix} \tag{2.47}$$

质量和弹簧会引出矩阵. 弹性杆会引出微分方程.

## 习题 2.5

1. 对于函数 $y(x)=x^3$，令 $\Delta y=(x+h)^3-x^3$，求 $\Delta y$ 中关于 $h$ 和 $h^2$ 的一阶项和二阶项. 将 $(x+h)^3$ 展开，证明你的答案与 $h\dfrac{\mathrm{d}y}{\mathrm{d}x}$ 和 $\dfrac{1}{2}h^2\dfrac{\mathrm{d}^2y}{\mathrm{d}x^2}$ 一致.

2. 对于函数 $y=\mathrm{e}^x$，在点 $x=0, y=1$ 处切线的斜率是多少？该切线的方程是什么？

3. 继续考虑 $y=\mathrm{e}^x$，$x=0$ 处的二阶导数是什么？切线抛物线的方程是什么？这是 $\mathrm{e}^h$ 的二阶近似：$y(h)=y(0)+h\dfrac{\mathrm{d}y}{\mathrm{d}x}(0)+\dfrac{1}{2}h^2\dfrac{\mathrm{d}^2y}{\mathrm{d}x^2}(0)$.

4. 求 $y=\mathrm{e}^x$ 在 $x=0$ 的各阶导数. 写出泰勒级数！

$$y(h)=\mathrm{e}^h=y(0)+h\frac{\mathrm{d}y}{\mathrm{d}x}(0)+\cdots+\frac{h^n}{n!}\frac{\mathrm{d}^n y}{\mathrm{d}x^n}(0)+\cdots$$

我相信这是数学中最重要的无穷级数.

5. 对于 $y(x)=\sin x$，近似 $\sin h\approx h$ 的精度阶数是多少？

6. 著名的欧拉公式 $\mathrm{e}^{\mathrm{i}x}=\cos x+\mathrm{i}\sin x$ 可以通过比较泰勒级数得到！$y=\mathrm{e}^{\mathrm{i}x}$ 在 $x=0$ 的各阶导数是什么？

$$\mathrm{e}^{\mathrm{i}x}=1+\mathrm{i}x+\frac{1}{2}(\mathrm{i}x)^2+\frac{1}{6}(\mathrm{i}x)^3+\cdots=\left(1-\frac{1}{2}x^2+\cdots\right)+\mathrm{i}\left(x-\frac{1}{6}x^3+\cdots\right)$$

7. 对于 $y(x)=x^3$ 和 $h=1/10$，计算在 $x=0$ 处 $\dfrac{\mathrm{d}y}{\mathrm{d}x}$ 的这些近似值：

中心差分：$\dfrac{y(h)-y(-h)}{2h}$　　向前差分：$\dfrac{y(h)-y(0)}{h}$　　向后差分：$\dfrac{y(0)-y(-h)}{h}$

8. 我们知道 $y(h)\approx y(0)+h\dfrac{\mathrm{d}y}{\mathrm{d}x}(0)+\dfrac{1}{2}h^2\dfrac{\mathrm{d}^2y}{\mathrm{d}x^2}(0)$，将其代入习题 7 中的三个式子，直到 $h^2$ 这个二阶项. 哪个公式是精确的？另外两个公式的误差是多少？

9. $y=\mathrm{e}^x$ 在 $x=0$ 的导数是 $\dfrac{\mathrm{d}y}{\mathrm{d}x}=1$. 用 $h=1$ 求 $\dfrac{\mathrm{d}y}{\mathrm{d}x}(0)$ 的中心-向前-向后近似值. 哪个最接近 1？

10. 对 $y=\mathrm{e}^x$ 和 $h=1$，$\left(\mathrm{e}-2+\mathrm{e}^{-1}\right)/1^2$ 与 $\mathrm{e}^x$ 在 $x=0$ 处的二阶导数误差有多大？

11. 当一阶差分的系数为 1、−1，二阶差分的系数为 1、−2、1 时，三阶差分中会出现哪四个数？（提示：可以除以 $h^3$ 来近似 $\dfrac{\mathrm{d}^3y}{\mathrm{d}x^3}$. 三阶差分相当少见，但可以在函数 $y=x^3$ 和 $y=x^4$ 上尝试一下.）

12. 中心差分 $\Delta_0$ 的转置是 $-\Delta_0$（反对称）. 这和分部积分中的负号类似，当 $f(x)g(x)$ 在 $\pm\infty$ 处趋于 0 时：

分部积分　　$$\int_{-\infty}^{+\infty}f(x)\frac{\mathrm{d}g}{\mathrm{d}x}\,\mathrm{d}x=-\int_{-\infty}^{+\infty}\frac{\mathrm{d}f}{\mathrm{d}x}g(x)\,\mathrm{d}x.$$

用分部求和验证等式：

$$\sum_{-\infty}^{+\infty}f_i\left(g_{i+1}-g_{i-1}\right)=-\sum_{-\infty}^{+\infty}\left(f_{i+1}-f_{i-1}\right)g_i.$$

13. 证明 $u$ 在四个点处的取值可以在中心处为 $\dfrac{\mathrm{d}u}{\mathrm{d}x}$ 提供四阶精度：

$$\frac{-u_2+8u_1-8u_{-1}+u_{-2}}{12h}=\frac{\mathrm{d}u}{\mathrm{d}x}+bh^4\frac{\mathrm{d}^5u}{\mathrm{d}x^5}+\cdots$$

分别对 $u=x^2$ 和 $u=x^4$ 检验我们的结论.

14. $K_3$ 和 $K_4$ 的逆矩阵分别有因子 $\dfrac{1}{\text{行列式}}=\dfrac{1}{4}$ 和 $\dfrac{1}{5}$:

$$K_3^{-1}=\frac{1}{4}\begin{bmatrix}3&2&1\\2&4&2\\1&2&3\end{bmatrix}\qquad K_4^{-1}=\frac{1}{5}\begin{bmatrix}4&3&2&1\\3&6&4&2\\2&4&6&3\\1&2&3&4\end{bmatrix}.$$

首先请猜测一下 $K_5$ 的行列式. 然后读者也可以挑战一下自我：猜一下 $K_5$ 的逆是什么，然后把 $\det(K_5)$ 和 $K_5^{-1}$ 相乘. 可以借助任何你会的软件.

15. 矩阵 $B$、$T$、$K$ 分别由带 0、1、2 个边界条件的矩阵 $A_0$、$A_1$、$A_2$ 得到.

$$A_0=\begin{bmatrix}1&-1&0&0\\0&1&-1&0\\0&0&-1&1\end{bmatrix}$$

$A_0$是一个向前差分矩阵

$B=A_0^{\mathrm{T}}A_0$是一个二阶差分矩阵

要得到满足 $T=A_1^{\mathrm{T}}A_1$ 的 $A_1$，你会去掉 $A_0$ 的哪一列？要得到满足 $K=A_2^{\mathrm{T}}A_2$ 的 $A_2$，你会接着去掉哪一列？

16. 证明：$D_4D_4^{\mathrm{T}}$ 给出了一个二阶差分，$D_4$ 可逆吗？

$$D_4=\begin{bmatrix}1&-1&0&0\\0&1&-1&0\\0&-1&1&0\\0&0&-1&1\end{bmatrix}\qquad D_4^{\mathrm{T}}=\begin{bmatrix}1&0&0&0\\-1&1&-1&0\\0&-1&1&-1\\0&0&0&1\end{bmatrix}\qquad C_4=D_4D_4^{\mathrm{T}}.$$

17. 求解边界条件为 $u(0)=u(1)=0$ 的二阶微分方程 $-u''=\cos 4\pi x$，利用 $K_4$ 和 $K_8$ 来计算 $u_1,u_2,\cdots,u_n$，然后把它们和 $u(x)$ 画在同一张图上：

$$u_{i+1}-2u_i+u_{i-1}=h^2\cos 4\pi ih,\qquad \text{其中}u_0=u_{n+1}=0.$$

18. 中心一阶差分矩阵可能不可逆！请检验以下两个中心一阶差分矩阵是否可逆：

$$\Delta_3=\begin{bmatrix}0&1&0\\-1&0&1\\0&-1&0\end{bmatrix}\qquad \Delta_4=\begin{bmatrix}0&1&0&0\\-1&0&1&0\\0&-1&0&1\\0&0&-1&0\end{bmatrix}.$$

## 2.6　谈谈第 2 章

我认为第 2 章非常有用且接近实际. 第 2 章主要针对系数矩阵是可逆矩阵的方程组 $Ax=b$ 进行讨论. 了解 $A^{-1}$ 的性质很重要：$(AB)^{-1}=B^{-1}A^{-1}$ 且 $x=A^{-1}b$. 但我们很少计算逆矩阵. 求出 $A^{-1}$ 再与其相乘既费时费事又没有必要.

对于上三角矩阵 $U$，解方程要容易得多. 其主对角线下方的所有元素都为零. 那么 $Ux=c$ 的第 $n$ 个方程就是 $u_{nn}x_n=c_n$，除以 $u_{nn}$ 就得到 $x_n$. 然后上一个方程也很容易：它能求出 $x_{n-1}$. 整个 $Ux=c$ 的问题可以从最后一个方程到第一个方程来求解：这就是所谓的回代法.

很自然地，我们想把方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 转化为 $\boldsymbol{Ux}=\boldsymbol{c}$. 原则上这很容易做到. 对于 $i=2$ 到 $i=n$ 这 $n-2$ 个方程，把第 $i$ 个方程减去第 1 个方程的 $a_{i1}/a_{11}$ 倍. 这样就剩下只含有未知量 $x_2$ 到 $x_n$ 的 $n-1$ 个方程. 对这些方程再重复一遍上述操作，得到含有未知量 $x_3$ 到 $x_n$ 的 $n-2$ 个方程. 经过 $n^3/3$ 次运算后，就得到 $\boldsymbol{Ux}=\boldsymbol{c}$，其中 $\boldsymbol{U}$ 是上三角矩阵——可以进行回代了：$\boldsymbol{x}=\boldsymbol{U}^{-1}\boldsymbol{c}=\boldsymbol{A}^{-1}\boldsymbol{b}$.

$\boldsymbol{A}=\boldsymbol{LU}$ 是美妙的公式，$\boldsymbol{L}$ 是由倍数构成的下三角矩阵（比如第一列中的 $\ell_{i1}=a_{i1}/a_{11}$），$\boldsymbol{U}$ 是消元得到 $\boldsymbol{Ux}=\boldsymbol{c}$ 时出现的上三角矩阵.

唯一不太好的情况是对角元素 $u_{ii}$ 很小甚至为零——在这种情况下，后面的倍数 $\ell_{ij}$ 很大，抑或是无穷大. 我们可以将第 $i$ 个方程与下面的某个方程交换，以使主元尽可能大.

我们接下来不会再过多涉及分解式 $\boldsymbol{A}=\boldsymbol{LU}$ 或 $\boldsymbol{PA}=\boldsymbol{LU}$ 了. 它们所求解的方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 是比较理想的情况，而数学并不总是关于“理想情况”的. 数学的乐趣在于探索，迎接更大的挑战，攀登更高的高峰.

如果 $\boldsymbol{A}$ 不可逆该怎么办？如果 $\boldsymbol{A}$ 不是方阵该怎么办？

如果 $\boldsymbol{A}$ 有很多列和（或）很多行该怎么办？

这些都是实实在在的问题，而本书会给出答案. 我们从第 2 章中收获的是对有用矩阵的认识，在第 3 章将会梳理和拓展一些想法. 下面罗列了第 2 章中涉及的特殊矩阵或者概念：

| | | |
|---|---|---|
| 逆矩阵 | 奇异矩阵 | 有限差分矩阵 |
| 上三角矩阵 $\boldsymbol{U}$ | 下三角矩阵 $\boldsymbol{L}$ | 中心、向前、向后差分 |
| 倍加矩阵 $\boldsymbol{E}$ | 置换矩阵 $\boldsymbol{P}$ | 二阶差分矩阵 |
| 转置矩阵 $\boldsymbol{A}^{\mathrm{T}}$ | 对称矩阵 $\boldsymbol{S}=\boldsymbol{S}^{\mathrm{T}}$ | $\boldsymbol{K}$、$\boldsymbol{T}$、$\boldsymbol{B}$ |
| $LU$ 分解：$\boldsymbol{A}=\boldsymbol{LU}$ | $LDL^{\mathrm{T}}$ 分解：$\boldsymbol{S}=\boldsymbol{LDL}^{\mathrm{T}}$ | 固定端或自由端 |

可逆的 $n$ 阶方阵 $\boldsymbol{A}$ 的列空间是 $\mathbb{R}^n$，行空间也是 $\mathbb{R}^n$. $\boldsymbol{A}$ 的列向量线性无关，$\boldsymbol{A}$ 的行向量也线性无关. 第 3 章将主要目标对准了所有矩阵，并且会引入新的概念.

# 第 3 章

CHAPTER 3

# 矩阵的四个基本子空间

3.1节将从纯代数问题出发：我们如何定义“线性空间”？回顾 $\mathbb{R}^3$ 这个例子，这个集合上最关键的操作是 $\boldsymbol{v}+\boldsymbol{w}$ 和 $c\boldsymbol{v}$；并通过分配律 $c(\boldsymbol{v}+\boldsymbol{w})=c\boldsymbol{v}+c\boldsymbol{w}$ 将两者联系在一起. 那么在一般的线性空间上，我们也必须合理地定义加法 $\boldsymbol{v}+\boldsymbol{w}$ 和数乘 $c\boldsymbol{v}$. 3.1节会给出线性空间关于向量 $\boldsymbol{v}$ 和数 $c$ 之间必须满足的八条公理.

不仅是列向量，$\boldsymbol{v}$、$\boldsymbol{w}$ 甚至可以是矩阵！我们可以把矩阵相加，也可以把函数相加（当然也可以乘以 $c$），从而就有所谓的矩阵空间和函数空间. 在 $\mathbb{R}^n$ 中，如果我们考虑满足 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$ 的所有向量 $\boldsymbol{x}$，它们组成了 $\boldsymbol{A}$ 的零空间. 方程组 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$ 解的线性组合仍然是该方程组的解，因此零空间是线性子空间.

线性代数的理论告诉我们如何去解 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$. 最好的系统性的解法是消元法. 我们把 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$ 简化为 $\boldsymbol{R}\boldsymbol{x}=\boldsymbol{0}$. 那么 $\boldsymbol{A}=\boldsymbol{C}\boldsymbol{R}$ 说明了 $\boldsymbol{A}$ 的每一列如何用 $\boldsymbol{C}$ 的列线性表出，也就是如何用 $\boldsymbol{A}$ 的前 $r$ 个线性无关的列线性表出. 换句话说，某一列是其他列的线性组合！这恰好就是方程组 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$ 的一个解！

最后一个重要的概念是基，所谓的基就是正好能够完美地描述这个线性空间的一组向量. 线性空间中的每一个向量，都可以唯一地用这组基线性表出. $\boldsymbol{A}$ 的 $r$ 个线性无关的列向量是 $\mathcal{C}(\boldsymbol{A})$ 的一组基，由高斯消元法给出的 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$ 的 $n-r$ 个基础解是 $\mathcal{N}(\boldsymbol{A})$ 的一组基，或者称为齐次方程组 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$ 的一个基础解系. $\mathcal{C}(\boldsymbol{A})$ 和 $\mathcal{N}(\boldsymbol{A})$ 维数分别等于 $r$ 和 $n-r$.

第 2 章主要处理了可逆矩阵. 对于可逆矩阵，$\boldsymbol{P}\boldsymbol{A}=\boldsymbol{L}\boldsymbol{U}$ 中的四个矩阵都是满秩的，或者说秩都是 $r=m=n$. $\boldsymbol{A}$ 的行空间和列空间都是整个 $\mathbb{R}^n$，$\boldsymbol{A}$ 和 $\boldsymbol{A}^{\mathrm{T}}$ 的零空间只包含唯一的元素——零向量.

第 3 章将转向更高层次的理论，极有可能它是本书中最重要的一章. 我们要考虑任意的 $m\times n$ 矩阵，显然当 $n>m$ 时方程组 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$ 有非零解. 需要注意的是，$\boldsymbol{A}$ 的零空间和它的列空间、行空间均不相同，它并不来源于 $\boldsymbol{A}$ 的行向量或者列向量，而是来源于方程组 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$ 的解.

本章至关重要的目标是“线性代数基本定理”，它将矩阵的四个子空间联系在一起

$\boldsymbol{A}$ 的列空间、行空间、零空间和 $\boldsymbol{A}^{\mathrm{T}}$ 的零空间

这四个子空间的维数分别是 $r$、$r$、$n-r$、$m-r$. 我们将在 3.5节中完成这个定理的证明. 希望书中的图示能让这个基本定理更加容易理解和记忆.

## 3.1 线性空间及其子空间

（1）子空间的要求：对线性组合 $c\boldsymbol{v}+d\boldsymbol{w}$ 封闭.
（2）$\boldsymbol{A}$ 的行空间是由 $\boldsymbol{A}$ 的行向量张成的子空间；$\boldsymbol{A}$ 的列向量张成了列空间 $\mathcal{C}(\boldsymbol{A})$.
（3）矩阵 $\boldsymbol{M}_1,\boldsymbol{M}_2,\cdots,\boldsymbol{M}_N$ 和函数 $f_1,f_2,\cdots,f_N$ 分别张成矩阵空间和函数空间.

我们从线性空间 $\mathbb{R}^1,\mathbb{R}^2,\cdots$ 开始. $\mathbb{R}^n$ 包含了所有 $n$ 维列向量 $\boldsymbol{v}$，其分量 $v_1,v_2,\cdots,v_n$ 都是实数. 如果我们考虑复数，比如 $v_1=2+3i$，那么相应的空间就是 $\mathbb{C}^1,\mathbb{C}^2,\cdots$. 我们已经学过了 $\mathbb{R}^n$ 中的加法（$\boldsymbol{v}+\boldsymbol{w}$）和数乘（$c\boldsymbol{v}$），由此得出线性空间 $\mathbb{R}^n$ 中的线性组合$c\boldsymbol{v}+d\boldsymbol{w}$.

线性组合这样的操作对任何线性空间都是最基本的操作，它必须满足八条公理，这八条公理将在本节课后习题的一开始严格地叙述——从交换律 $\boldsymbol{v}+\boldsymbol{w}=\boldsymbol{w}+\boldsymbol{v}$ 开始，每一条都很容易验证，但是没有必要逐字逐句地背诵.

然而，我们需要牢记：该线性空间中任意向量 $\boldsymbol{v}$、$\boldsymbol{w}$ 的任意的线性组合 $c\boldsymbol{v}+d\boldsymbol{w}$仍然属于这个线性空间. 于是集合 $\left\{\begin{bmatrix}v_1 & \cdots & v_n\end{bmatrix}^{\mathrm{T}}:v_i\geqslant 0,\forall 1\leqslant i\leqslant n\right\}$不是线性空间. 非齐次线性方程组 $\boldsymbol{A}\boldsymbol{x}=\begin{bmatrix}1 & \cdots & 1\end{bmatrix}^{\mathrm{T}}$ 的解集也不是线性空间. $\mathbb{R}^n$ 中的一条直线不是线性空间，除非它过原点 $(0,0,\cdots,0)$.

如果一条直线经过原点 $\boldsymbol{0}$，那么直线上任意向量乘以任意的实数 $c$ 仍然在这条直线上. 直线上任意两个向量相加，也仍然在这条直线上. $\mathbb{R}^n$ 中过原点的直线启发了我们思考子空间——包含在某个线性空间内的线性空间.

### 3.1.1 线性空间的例子

本书主要考虑的线性空间是 $\mathbb{R}^n$ 和它的子空间，例如直线或者平面. 只包含零向量的单点集 $\{\boldsymbol{0}\}$[①]是它的子空间！任意线性组合 $c\boldsymbol{0}+d\boldsymbol{0}$ 还是等于 $\boldsymbol{0}$，自然是属于 $\{\boldsymbol{0}\}$ 的. $\{\boldsymbol{0}\}$ 是最小的线性空间，它也是可逆矩阵的零空间. 如果方程组 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$ 只有零解 $\boldsymbol{x}=\boldsymbol{0}$，那么 $\boldsymbol{A}$ 的列向量线性无关.

我们很自然就可以接受由矩阵构成的线性空间. 我们用 $\mathbb{R}^{3\times 3}$ 来表示所有 $3\times 3$ 矩阵的全体，对其中的矩阵，我们可以作线性组合 $c\boldsymbol{A}+d\boldsymbol{B}$. 容易验证它满足线性空间的八条公理. 9 个分量都相等的 $3\times 3$ 矩阵的全体就是一个子空间——“由矩阵构成的直线”. 子集合 $\boldsymbol{S}=\{$所有的 3 阶对称矩阵$\}$ 也是 $\mathbb{R}^{3\times 3}$ 的子空间：$\boldsymbol{A}+\boldsymbol{B}$ 也是对称矩阵. 但是，所有三阶可逆矩阵的全体并不是子空间，请读者思考一下为什么.

我们也可以接受由函数构成的线性空间，尽管这并不是那么自然的事情. $\{y=ce^x:c\in\mathbb{R}\}$ 是

① 译者注：在原书中，作者把这个集合记作 $\mathbb{Z}$. 译者以为，一是没必要给它专门的记号，甚至大多数文献都不用严谨的集合符号，而仅仅用 $\boldsymbol{0}$ 就表示这个线性空间；二是 $\mathbb{Z}$ 这个记号公认地用来表示整数集，用来表示别的对象容易引起混淆. 因此译者翻译时不给它专门的符号标记.

函数空间中的“一条直线”. 这条直线包含了微分方程 $\dfrac{\mathrm{d}y}{\mathrm{d}x}=y$ 的所有解. 集合 $\{y=a+bx+cx^2:a,b,c\in\mathbb{R}\}$ 也是函数空间的子空间，它们是微分方程 $\dfrac{\mathrm{d}^3y}{\mathrm{d}x^3}=0$ 的解. 当我们转向函数空间时，考虑的不再是线性方程组 $\boldsymbol{Ax}=\boldsymbol{0}$，而是常微分方程.

从某种意义上，$3\times3$ 矩阵的全体 $\mathbb{R}^{3\times3}$ 可以等同于 $\mathbb{R}^9$，函数空间的子空间 $\{y=a+bx+cx^2:a,b,c\in\mathbb{R}\}$ 也可以等同于 $\mathbb{R}^3$.

矩阵的线性组合在矩阵空间中，函数的线性组合也在相应的线性空间中. 我们这本书几乎只处理通常的列向量，而很少涉及函数这种一般意义上的抽象向量.

需要强调的是，“空间”这个词，我们一般指在 $\mathbb{R}^n$、矩阵空间或者函数空间中由一些元素的所有线性组合的全体构成的子集.

### 3.1.2　线性空间的子空间

有必要提醒读者，在某些场合，矩阵或者函数也可以被视作向量. 但是在绝大部分情形下，我们只需要考虑通常的列向量——它们是有 $n$ 个分量的向量. 但是，请注意，尽管我们考虑的列向量都有 $n$ 个分量，并不是说我们始终考虑 $\mathbb{R}^n$ 这个包含了所有 $n$ 维向量的全集；相反地，我们经常只考虑其中的一部分——在 $\mathbb{R}^n$ 中有很多重要的线性空间，即 $\mathbb{R}^n$ 的线性子空间.

我们从通常的三维空间 $\mathbb{R}^3$ 开始说起. 取一个过原点 $(0,0,0)$ 的平面，此平面是线性空间. 该平面上两个向量相加之和还在这个平面上；该平面上的向量乘以一个倍数，比如 2 倍或者 $-5$ 倍，其结果依然在这个平面上. 三维空间 $\mathbb{R}^3$ 中的平面虽然看上去像 $\mathbb{R}^2$ 一样，但它并不是 $\mathbb{R}^2$：每个向量都有三个分量，属于 $\mathbb{R}^3$. 总而言之，过原点 $(0,0,0)$ 的平面是线性空间 $\mathbb{R}^3$ 的子空间.

这个例子解释了线性代数最基本的想法.

**定义 3.1**　线性空间的子空间是满足如下条件的非空子集 $V$：对任意 $\boldsymbol{v},\boldsymbol{w}\in V$，任意实数 $c$，都有

$$(1)\ \boldsymbol{v}+\boldsymbol{w}\in V\qquad(2)\ c\boldsymbol{v}\in V$$

换言之，子空间在加法 $\boldsymbol{v}+\boldsymbol{w}$ 和数乘 $c\boldsymbol{v}$ 之下是“封闭”的. 因此，我们考虑这两个运算时，不一定非要在整个空间上看，在子空间内即可. 子空间对于减法也是封闭的，这是因为 $-\boldsymbol{w}\in V$，$\boldsymbol{v}$ 和 $-\boldsymbol{w}$ 的和是 $\boldsymbol{v}-\boldsymbol{w}$，因此也属于 $V$. 综上所述，子空间内任意有限个向量的任意线性组合也在这个子空间内，或者简称为：子空间对线性组合封闭.

这两个操作是从整个空间中继承来的，它们自动满足线性空间的八条公理，唯一需要确保的是任意的线性组合 $c\boldsymbol{v}+d\boldsymbol{w}$ 也在这个子空间中.

任意子空间都包含零向量. 例如，$\mathbb{R}^3$ 中的平面如果是子空间，那么一定要过原点 $(0,0,0)$. 我们特意提及这个事实不是说它困难，而是为了表示强调；事实上，由定义可以直接看出来：$V$ 非空，于是我们先任取 $\boldsymbol{v}\in V$，再取 $c=0$，那么 $\boldsymbol{0}=0\boldsymbol{v}\in V$.

不经过原点的平面不符合这个要求，所以不是子空间.

过原点的直线也是子空间. 直线上的向量乘以一个数，比如说 5，或者把直线上的两个向量相加，得到的结果仍在这条直线上. 和平面类似，必须是经过原点 $(0,0,0)$ 的直线才是子空间.

$\mathbb{R}^3$ 的另一个子空间是 $\mathbb{R}^3$ 本身，整个空间显然是子空间. 下面是 $\mathbb{R}^3$ 中所有子空间的分类.

| | |
|---|---|
| （L）过原点的直线 | （$\mathbb{R}^3$）整个空间 |
| （P）过原点的平面 | （$\{\mathbf{0}\}$）只包含零向量的单点集 |

如果只有平面或者直线的一部分，那么子空间必须满足的条件有可能不成立. 我们来看 $\mathbb{R}^2$ 中的一些反例.

**例 3.1** 考虑两个分量均大于或等于 0 的向量 $\begin{bmatrix} x & y \end{bmatrix}^{\mathrm{T}}$ 构成的集合，即第一象限，它是四分之一平面；向量 $\begin{bmatrix} 2 & 3 \end{bmatrix}^{\mathrm{T}}$ 属于这个集合，而 $\begin{bmatrix} -2 & -3 \end{bmatrix}^{\mathrm{T}}$ 不属于. 当我们试图将 $\begin{bmatrix} 2 & 3 \end{bmatrix}^{\mathrm{T}}$ 乘以数 $c=-1$ 时，就发现它不满足定义 3.1中的第 (2) 点要求，因此第一象限不是子空间.

**例 3.2** 相同的结论对所有分量都小于或等于 0 的向量构成的集合也成立：它不是子空间. 我们得到了两个象限，各自均不满足定义 3.1中的第 (2) 点要求；然而，当我们考虑这两个象限的并集时，此时定义 3.1中的第 (2) 点对这个并集成立，它对于数乘是封闭的. 但是它不满足定义 3.1中的第 (1) 点要求，例如向量 $\boldsymbol{v}=\begin{bmatrix} 2 & 3 \end{bmatrix}^{\mathrm{T}}$ 和向量 $\boldsymbol{w}=\begin{bmatrix} -3 & -2 \end{bmatrix}^{\mathrm{T}}$ 的和是 $\begin{bmatrix} -1 & 1 \end{bmatrix}^{\mathrm{T}}$，在这个并集之外，因此这两个象限的并集不是子空间.

子空间的定义 3.1中的两个条件涉及向量加法和数乘，实际上可以合成一个条件——子空间的条件：

包含 $\boldsymbol{v}$ 和 $\boldsymbol{w}$ 的子空间必须包含它们的所有线性组合 $c\boldsymbol{v}+d\boldsymbol{w}$.

**例 3.3** 设线性空间 $M$ 是所有 $2\times 2$ 矩阵构成的线性空间，其中有两个子空间：

（$U$）所有上三角矩阵 $\begin{bmatrix} a & b \\ 0 & d \end{bmatrix}$ 的全体　　（$D$）所有对角矩阵 $\begin{bmatrix} a & 0 \\ 0 & d \end{bmatrix}$ 的全体

$U$ 中任意有限个上三角矩阵相加之和依然是上三角矩阵；对角矩阵相加之和依然是对角矩阵. 所以 $D$ 是 $U$ 的子空间. 取 $a=b=d=0$，可见零矩阵在这几个子空间中. $\{\mathbf{0}\}$ 永远是只包含单个向量的子空间.

单位矩阵的常数倍组成的集合也是 $M$ 的子空间，那些矩阵构成了 $M$ 中的“一条直线”，这条直线同时也在 $U$ 和 $D$ 中.

单位矩阵组成的单点集是子空间吗？当然不是，只有零矩阵组成的单点集才是子空间. 要对线性空间的概念有更好的理解，我们必须在脑海中有足够多的例子，比如说 $M$ 的一些子空间——本节习题 5 中有一些例子.

### 3.1.3 $A$ 的列空间

最重要的子空间自然是那些和矩阵 $\boldsymbol{A}$ 紧密联系的子空间. 求解线性方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 相当于刻画等号右边的向量 $\boldsymbol{b}$——如何把它写成 $\boldsymbol{A}$ 乘以某个列向量 $\boldsymbol{x}$. 这样的 $\boldsymbol{b}$ 组成了 $\boldsymbol{A}$ 的“列空间”.

回忆一下，$\boldsymbol{Ax}$ 是 $\boldsymbol{A}$ 的列向量的线性组合，为了得到所有可能的 $\boldsymbol{b}$，我们需要取遍所有可能的 $\boldsymbol{x}$. 这提示我们从 $\boldsymbol{A}$ 的列向量出发，取遍 $A$ 的列向量的所有线性组合，由此构建出 $A$ 的列空间. 这是从列向量出发得到的线性空间.

**定义 3.2**　$\boldsymbol{A}$ 的列空间是它列向量的线性组合的全体，而这些线性组合就是 $\boldsymbol{Ax}$ 所有可能的取值. 它们填满了列空间 $C(\boldsymbol{A})$.

列空间是整本书最重要的研究对象. 原因在于解线性方程组 $Ax = b$ 等价于把 $b$ 写成 $A$ 的列向量的线性组合. 等号右边的 $\boldsymbol{b}$ 必须属于 $\boldsymbol{A}$ 的列空间，否则 $\boldsymbol{Ax} = \boldsymbol{b}$ 无解.

方程组 $Ax = b$ 有解当且仅当 $b$ 属于 $A$ 的列空间.

$\boldsymbol{b}$ 属于 $C(\boldsymbol{A})$ 时，它是 $\boldsymbol{A}$ 的列向量的线性组合，那么组合系数就是 $\boldsymbol{Ax} = \boldsymbol{b}$ 的解. “空间”这个词意味着要取遍所有线性组合，自然一定有 $\mathbb{R}^m$ 的零向量.

注意，$\boldsymbol{A}$ 的列向量构成的集合本身并不是子空间！由可逆矩阵组成的集合不是矩阵空间的子空间！由奇异矩阵组成的集合也不是矩阵空间的子空间！要构成子空间必须要包含所有的线性组合. 当取遍 $\boldsymbol{A}$ 的列向量的所有线性组合时，$\boldsymbol{A}$ 的列向量“张成”一个子空间.

### 3.1.4　$A$ 的行空间

$A$ 的行空间是 $A^{\mathrm{T}}$ 的列空间，其中 $\boldsymbol{A}^{\mathrm{T}}$ 是 $\boldsymbol{A}$ 的转置，它是 $n \times m$ 矩阵. 这样处理是因为本书的向量默认是列向量，所以我们引入 $\boldsymbol{A}^{\mathrm{T}}$——它的列向量就是 $\boldsymbol{A}$ 的行向量.

$A$ 的行空间是它的转置矩阵 $A^{\mathrm{T}}$ 的列空间 $C(A^{\mathrm{T}})$.

$\boldsymbol{A}$ 的行空间是 $\mathbb{R}^n$ 的子空间，包含了 $\boldsymbol{A}^{\mathrm{T}}$ 的 $m$ 个列向量以及它们的线性组合. $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y} = \boldsymbol{c}$ 有解当且仅当向量 $\boldsymbol{c}$ 属于子空间 $C(\boldsymbol{A}^{\mathrm{T}})$，即 $\boldsymbol{A}$ 的行空间.

第 1 章说明了为什么 $C(\boldsymbol{A})$ 和 $C(\boldsymbol{A}^{\mathrm{T}})$ 都恰好包含了 $r$ 个线性无关的向量，从而 $r = \mathrm{rank}(A) = \mathrm{rank}(A^{\mathrm{T}})$. 我们将在 3.5节中给这个事实一个新的证明.

**例 3.4**　秩 1 矩阵 $\boldsymbol{A} = \boldsymbol{uv}^{\mathrm{T}}$ 的行空间是 $\{c\boldsymbol{v} : c \in \mathbb{R}\}$. 这是因为 $\boldsymbol{A}^{\mathrm{T}} = \boldsymbol{vu}^{\mathrm{T}}$ 的列向量都是 $\boldsymbol{v}$ 的倍数. 向量 $\boldsymbol{v}$ 张成了 $\boldsymbol{A}$ 的行空间，$\boldsymbol{u}$ 张成了 $\boldsymbol{A}$ 的列空间. 这两个线性空间都是过原点的直线.

### 3.1.5　$A$ 的列向量张成了线性空间 $C(A)$

“张成”是一个很有用的新术语. 我们从 $\mathbb{R}^m$ 的子集 $S$ 出发，如果 $S$ 只包含 $N$ 个向量，它显然不是子空间. 但是如果我们把 $S$ 中向量的所有线性组合放在一起，那么我们就得到一个线性空间 $V$. 在这种情况下，集合 $S$ 张成了 $V$. 事实上，$V$ 是包含 $S$ 的最小线性空间（为了得到一个线性空间，我们不得不包含所有的线性组合）.

这其实就是我们处理 $\boldsymbol{A}$ 的列空间时做的事情. $\boldsymbol{A}$ 的 $n$ 个列向量张成了它的列空间 $C(\boldsymbol{A})$——$\boldsymbol{A}$ 的列向量的所有线性组合. 在“张成”的过程中，线性无关性是无须考虑的. 同理，$\boldsymbol{A}^{\mathrm{T}}$ 的 $m$ 个列向量张成了行空间 $C(\boldsymbol{A}^{\mathrm{T}})$.

这里给出一个思考题，证明全体 2 阶可逆矩阵张成了 $\mathbb{R}^{2\times 2}$（2 阶方阵组成的线性空间）.

**例 3.5** 若 $\boldsymbol{A}$ 是 $n \times n$ 可逆矩阵，那么它的列向量张成了 $\mathbb{R}^n$.

三阶可逆矩阵的全体张成了 $\mathbb{R}^{3\times 3}$.

三阶奇异矩阵 (不可逆矩阵) 的全体也张成了 $\mathbb{R}^{3\times 3}$.

当我们考虑零空间 $\mathcal{N}(\boldsymbol{A})$ 时，事情就变得不一样了. 我们从方程组 $\boldsymbol{Ax}=\boldsymbol{0}$ 出发（这是 $m$ 个方程，而非 $n$ 个向量），该齐次方程组的解集是线性子空间：若 $\boldsymbol{Ax}=\boldsymbol{0}, \boldsymbol{Ay}=\boldsymbol{0}$，则 $\boldsymbol{A}(c\boldsymbol{x}+d\boldsymbol{y})=\boldsymbol{0}$. 那么问题来了，我们要如何找出这些解 $\boldsymbol{x}$、$\boldsymbol{y}$ 呢？

再给出一个思考题，什么时候 $\mathbb{R}^5$ 中的 10 个向量可以张成 $\mathbb{R}^5$？虽然并不是任意 10 个向量一定能张成 $\mathbb{R}^5$，但几乎总是可以张成.

## 习题 3.1

**习题 1 ~ 7 是关于线性空间的一般理论. 线性空间中的向量未必是列向量. 在线性空间的定义中，向量加法 $\boldsymbol{x}+\boldsymbol{y}$ 和数乘 $c\boldsymbol{x}$ 需要满足以下八条规则：**

（1）$\boldsymbol{x}+\boldsymbol{y}=\boldsymbol{y}+\boldsymbol{x}$;

（2）$\boldsymbol{x}+(\boldsymbol{y}+\boldsymbol{z})=(\boldsymbol{x}+\boldsymbol{y})+\boldsymbol{z}$;

（3）存在唯一的“零向量” $\boldsymbol{0}$ 满足：对任意 $\boldsymbol{x}$ 都有 $\boldsymbol{x}+\boldsymbol{0}=\boldsymbol{x}$;

（4）对任意 $\boldsymbol{x}$ 存在唯一的向量 $-\boldsymbol{x}$ 使得 $\boldsymbol{x}+(-\boldsymbol{x})=\boldsymbol{0}$;

（5）$1\cdot\boldsymbol{x}=\boldsymbol{x}$;

（6）$(c_1c_2)\boldsymbol{x}=c_1(c_2\boldsymbol{x})$;

（7）$c(\boldsymbol{x}+\boldsymbol{y})=c\boldsymbol{x}+c\boldsymbol{y}$;

（8）$(c_1+c_2)\boldsymbol{x}=c_1\boldsymbol{x}+c_2\boldsymbol{x}$.

第（1）~（4）条规则是关于向量加法的，第（5）~（6）条规则是关于数乘的，第（7）~（8）条是关于向量加法和数乘之间的分配律的.

---

1. 如果定义 $\mathbb{R}^2$ 的加法为 $(x_1,x_2)+(y_1,y_2)=(x_1+y_2,x_2+y_1)$，数乘为通常的数乘 $c\boldsymbol{x}=(cx_1,cx_2)$. 此时，上述八条规则有哪几条不成立？

2. 如果数乘的定义改为 $c\boldsymbol{x}=(cx_1,0)$，而非通常的 $(cx_1,cx_2)$；但加法还是通常的加法：$(x_1,x_2)+(y_1,y_2)=(x_1+y_1,x_2+y_2)$，上述的八条规则有哪几条不成立？

3. （1）考虑 $\mathbb{R}_+=\{x\in\mathbb{R}^1: x>0\}$，哪几条规则不再成立？

（2）对于 $\mathbb{R}_+$，重新定义加法和数乘为：$\boldsymbol{x}+\boldsymbol{y}=xy, c\boldsymbol{x}=x^c$.[①]请验证：在这样定义的运算之下，$\mathbb{R}_+$ 是线性空间. 取 $c=3, x=2, y=1$，验证第（7）条规则（实际上，$\boldsymbol{x}+\boldsymbol{y}=2, c\boldsymbol{x}=8$）. $\mathbb{R}_+$ 中哪一个元素是“零向量”？

4. 矩阵 $\boldsymbol{A}=\begin{bmatrix}2 & -2\\ 2 & -2\end{bmatrix}$ 是 $2\times 2$ 矩阵空间 $M$ 中的向量. 写下这个线性空间中的零向量、$\frac{1}{2}\boldsymbol{A}$ 和 $-\boldsymbol{A}$. 哪些矩阵在包含 $\boldsymbol{A}$ 的最小的线性空间中（由 $\boldsymbol{A}$ 张成的子空间）？

5. $M$ 和第 4 题相同.

---

① 译者注：这里虽然 $\boldsymbol{x}=x, \boldsymbol{y}=y$，但是我们用 $\boldsymbol{x}$、$\boldsymbol{y}$ 来表示向量，用 $x$、$y$ 来表示实数，$xy$、$x^c$ 都是实数中的乘法和幂运算. 所以需要区分的是，同一个对象在不同场合下，运算规则可以不一样.

(1) 写出 $M$ 的一个子空间，其包含 $\boldsymbol{A}=\begin{bmatrix}1&0\\0&0\end{bmatrix}$ 但不包含 $\boldsymbol{B}=\begin{bmatrix}0&0\\0&-1\end{bmatrix}$.

(2) 若 $M$ 的一个子空间包含 (1) 中的矩阵 $\boldsymbol{A}$ 和 $\boldsymbol{B}$，它是否一定包含单位矩阵？

(3) 写出 $M$ 的一个不包含任何非零对角矩阵的子空间.

6. 设 $F$ 是 $(-\infty,+\infty)$ 上所有取值是实数的函数的集合，这是一个线性空间. $\boldsymbol{f}(x)=x^2$ 和 $\boldsymbol{g}(x)=5x$ 是 $F$ 中的两个向量. 线性组合 $3\boldsymbol{f}(x)-4\boldsymbol{g}(x)$ 是函数 $\boldsymbol{h}(x)=$_____.

7. 如果重新定义 $c$ 在 $\boldsymbol{f}(x)$ 上的数乘为 $c(\boldsymbol{f}(x))=\boldsymbol{f}(cx)$，向量加法还是通常的函数相加. 此时，线性空间的八条规则中哪些不再成立？

**习题 8 ~ 15 关于子空间需要满足的条件：$x+y$ 和 $cx$ 属于子空间（进而所有的线性组合 $cx+dy$ 属于子空间）.**

8. 请举出满足以下条件的线性空间的子集，这两个例子表明子空间的两个条件未必都满足.

(1) $\mathbb{R}^2$ 的一个子集 $S$，满足：对任意 $\boldsymbol{x},\boldsymbol{y}\in S$ 都有 $\boldsymbol{x}+\boldsymbol{y}\in S$，但是存在 $\boldsymbol{x}\in S$ 使得 $\frac{1}{2}\boldsymbol{x}\notin S$.

(2) $\mathbb{R}^2$ 的一个子集 $S$(不是两个象限的并集)，满足：对任意 $\boldsymbol{x}\in S, c\in\mathbb{R}$ 都有 $c\boldsymbol{x}\in S$，但是存在 $\boldsymbol{x},\boldsymbol{y}\in S$ 使得 $\boldsymbol{x}+\boldsymbol{y}\notin S$.

9. $\mathbb{R}^3$ 以下的子集中，哪些是子空间？注意，虽然未必都是子空间，但是它们都可以张成子空间.

(1) $\left\{\begin{bmatrix}b_1&b_2&b_3\end{bmatrix}^{\mathrm{T}}:b_1=b_2\right\}$；这是平面.

(2) $\left\{\begin{bmatrix}b_1&b_2&b_3\end{bmatrix}^{\mathrm{T}}:b_1=1\right\}$；这是平面.

(3) $\left\{\begin{bmatrix}b_1&b_2&b_3\end{bmatrix}^{\mathrm{T}}:b_1b_2b_3=0\right\}$.

(4) $\boldsymbol{v}=\begin{bmatrix}1&4&0\end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{w}=\begin{bmatrix}2&2&2\end{bmatrix}^{\mathrm{T}}$ 的线性组合的全体.

(5) $\left\{\begin{bmatrix}b_1&b_2&b_3\end{bmatrix}^{\mathrm{T}}:b_1+b_2+b_3=0\right\}$.

(6) $\left\{\begin{bmatrix}b_1&b_2&b_3\end{bmatrix}^{\mathrm{T}}:b_1\leqslant b_2\leqslant b_3\right\}$.

10. 刻画 $2\times2$ 矩阵空间 $M$ 中包含如下各组矩阵的最小的子空间：

(1) $\begin{bmatrix}1&0\\0&0\end{bmatrix}$ 和 $\begin{bmatrix}0&1\\0&0\end{bmatrix}$　　(2) $\begin{bmatrix}1&1\\0&0\end{bmatrix}$　　(3) $\begin{bmatrix}1&1\\1&1\end{bmatrix}$ 和 $\begin{bmatrix}1&0\\0&1\end{bmatrix}$

11. 设 $P$ 是 $\mathbb{R}^3$ 中由方程 $x+y-2z=4$ 定义的平面. 原点 $(0,0,0)\notin P$! 请在 $P$ 上找两个向量，并且验证它们相加之和不在 $P$ 上.

12. 令 $P_0$ 是平行于上一题中 $P$ 且过原点 $(0,0,0)$ 的平面. $P_0$ 的方程是什么？在 $P_0$ 上找两个向量，验证它们相加之和也在 $P_0$ 上.

13. 设 $P$ 和 $L$ 分别是过原点 $(0,0,0)$ 的平面和直线. 同时包含 $P$ 和 $L$ 的最小线性空间要么是_____，要么是_____.

14. 设 $M$ 是 $n\times n$ 矩阵空间.

(1) 证明：$M$ 中的可逆矩阵构成的子集不是子空间.

（2）证明：当 $n \geqslant 2$ 时，[①]$M$ 中的奇异矩阵构成的子集不是子空间.

15. 判断正误（对每一小题，举一例或一反例以验证加法）. 设 $M$ 是 $n \times n$ 矩阵空间.

（1）$M$ 中的对称矩阵（$\boldsymbol{A}^{\mathrm{T}} = \boldsymbol{A}$）构成的子集是子空间.

（2）$M$ 中的反对称矩阵（$\boldsymbol{A}^{\mathrm{T}} = -\boldsymbol{A}$）构成的子集是子空间.

（3）$M$ 中的非对称矩阵（$\boldsymbol{A}^{\mathrm{T}} \neq \boldsymbol{A}$）构成的子集张成一个子空间.

**习题 16 ~ 26 关于列空间 $C(A)$ 和方程组 $Ax = b$.**

16. 刻画下列矩阵的列空间（直线或是平面）：

$$\boldsymbol{A} = \begin{bmatrix} 1 & 2 \\ 0 & 0 \\ 0 & 0 \end{bmatrix}, \qquad \boldsymbol{B} = \begin{bmatrix} 1 & 0 \\ 0 & 2 \\ 0 & 0 \end{bmatrix}, \qquad \boldsymbol{C} = \begin{bmatrix} 1 & 0 \\ 2 & 0 \\ 0 & 0 \end{bmatrix}$$

17. 当 $b_1$、$b_2$、$b_3$ 分别满足什么条件时，下面两个方程组有解？

（1） $\begin{bmatrix} 2 & 4 & 2 \\ 2 & 8 & 4 \\ -1 & -4 & -2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix}$ （2） $\begin{bmatrix} 1 & 4 \\ 2 & 9 \\ -1 & -4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix}$

18. 设 $\boldsymbol{A} = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}, \boldsymbol{B} = \begin{bmatrix} 1 & 2 \\ 3 & 6 \end{bmatrix}, \boldsymbol{C} = \begin{bmatrix} 1 & 3 \\ 2 & 6 \end{bmatrix}$. 把 $\boldsymbol{A}$ 的第 1 行加到第 2 行可得 $\boldsymbol{B}$，把 $\boldsymbol{A}$ 的第 1 列加到第 2 列可得 $\boldsymbol{C}$. 矩阵_____（$\boldsymbol{B}$ 或者 $\boldsymbol{C}$）的列向量的线性组合也是 $\boldsymbol{A}$ 的列向量的线性组合. 哪两个矩阵有相同的列_____?

19. 当 $b_1$、$b_2$、$b_3$ 分别满足什么条件时，以下方程组有解？（提示：此时向量 $\boldsymbol{b} \in C(\boldsymbol{A})$.）

$$\begin{bmatrix} 1 & 1 & 1 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix} \qquad \begin{bmatrix} 1 & 1 & 1 \\ 0 & 1 & 1 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix} \qquad \begin{bmatrix} 1 & 1 & 1 \\ 0 & 0 & 1 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix}$$

20.（推荐）如果我们给矩阵 $\boldsymbol{A}$ 增加一列 $\boldsymbol{b}$，除非_____，否则列空间严格地变大. 对于列空间变大和不变大两种情形分别举出一个实例. 为什么当列空间不变大时，$\boldsymbol{Ax} = \boldsymbol{b}$ 有解？此时 $\boldsymbol{A}$ 和 $\begin{bmatrix} \boldsymbol{A} & \boldsymbol{b} \end{bmatrix}$ 有相同的列空间.

21. $\boldsymbol{AB}$ 的列向量都是 $\boldsymbol{A}$ 的列向量的线性组合. 这意味着：$\boldsymbol{AB}$ 的列空间包含于（有可能相等）$\boldsymbol{A}$ 的列空间. 请举一例说明 $\boldsymbol{A}$ 的列空间和 $\boldsymbol{AB}$ 的列空间可能不相等.

22. 设方程组 $\boldsymbol{Ax} = \boldsymbol{b}$ 和 $\boldsymbol{Ay} = \boldsymbol{b}^*$ 都有解. 证明：$\boldsymbol{Az} = \boldsymbol{b} + \boldsymbol{b}^*$ 也有解；$\boldsymbol{z}$ 是什么？把这个问题翻译一下：若 $\boldsymbol{b}$、$\boldsymbol{b}^*$ 都属于 $\boldsymbol{A}$ 的列空间 $C(\boldsymbol{A})$，那么 $\boldsymbol{b} + \boldsymbol{b}^*$ 也属于 $C(\boldsymbol{A})$. 这是线性空间必须满足的要求之一.

23. 若 $\boldsymbol{A}$ 是 $5 \times 5$ 可逆矩阵，那么它的列空间是_____. 为什么？

24. 判断正误（正确简述其原因，错误则举反例）

（1）不属于列空间 $C(\boldsymbol{A})$ 的所有向量 $\boldsymbol{b}$ 组成一个线性子空间.

（2）若 $C(\boldsymbol{A})$ 只包含零向量这一个元素，那么 $\boldsymbol{A}$ 是零矩阵.

---

① 译者注：原文没有这个条件. 但是显而易见，若 $n = 1$，则 $M$ 中的奇异矩阵只有 $\mathbf{0}$，这是平凡的子空间.

（3）$2\boldsymbol{A}$ 和 $\boldsymbol{A}$ 有相同的列空间.

（4）$\boldsymbol{A}-\boldsymbol{I}$ 和 $\boldsymbol{A}$ 有相同的列空间（请检验）.

25. 构造一个 $3\times 3$ 矩阵使得其列空间包含向量 $\begin{bmatrix}1 & 1 & 0\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}1 & 0 & 1\end{bmatrix}^{\mathrm{T}}$，但不包含向量 $\begin{bmatrix}1 & 1 & 1\end{bmatrix}^{\mathrm{T}}$. 构造一个 $3\times 3$ 矩阵使得其列空间是一条直线.

26. 若 $\boldsymbol{A}$ 是 $9\times 12$ 矩阵，且对任意 $\boldsymbol{b}$，方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 都有解，那么 $\mathcal{C}(\boldsymbol{A})=$_____.

## 挑 战 一 下

27. 设 $S$ 和 $T$ 是线性空间 $V$ 的两个子空间.

（1）定义：$S+T=\{\boldsymbol{s}+\boldsymbol{t}:\boldsymbol{s}\in S,\boldsymbol{t}\in T\}$. 证明：$S+T$ 对加法和数乘都封闭，且 $S+T$ 满足线性空间所需的八条规则.

（2）若 $S$ 和 $T$ 都是 $\mathbb{R}^m$ 中的直线，$S+T$ 和 $S\cup T$ 有何区别？$S$ 和 $T$ 的并集包含 $S$ 和 $T$ 中的所有向量. 阐述如下断言：$S\cup T$ 张成了 $S+T$.（3.4节将回到“张成”这个术语.）

28. 如果 $S=\mathcal{C}(\boldsymbol{A}),T=\mathcal{C}(\boldsymbol{B})$，那么 $S+T$ 是哪个矩阵 $\boldsymbol{M}$ 的列空间？$\boldsymbol{A}$、$\boldsymbol{B}$、$\boldsymbol{M}$ 的列空间都是 $\mathbb{R}^m$ 中的列向量. 一般来说，$\boldsymbol{A}+\boldsymbol{B}$ 并不是正确答案，$\boldsymbol{M}$ 的列向量应该张成 $S+T$.

29. 证明：矩阵 $\boldsymbol{A}$ 和 $\begin{bmatrix}\boldsymbol{A} & \boldsymbol{AB}\end{bmatrix}$（比 $\boldsymbol{A}$ 多了一些列）有相同的列空间. 试找出一个矩阵 $\boldsymbol{A}$ 满足：$\mathcal{C}(\boldsymbol{A}^2)$ 是 $\mathcal{C}(\boldsymbol{A})$ 的真子集. 另一个重要的事实是：$n\times n$ 矩阵 $\boldsymbol{A}$ 的列空间 $\mathcal{C}(\boldsymbol{A})=\mathbb{R}^n$ 当且仅当 $\boldsymbol{A}$ 是_____.

30. 已知函数 $y=\mathrm{e}^x$ 是二阶微分方程 $\dfrac{\mathrm{d}^2y}{\mathrm{d}x^2}=y$ 的解，再找一个该微分方程与之线性无关的解. 试求微分方程 $\dfrac{\mathrm{d}^2y}{\mathrm{d}x^2}=-y$ 的两个线性无关的解；那么这个维数等于 2 的解空间包含所有线性组合：$y=$_____.

31. 假设 $V$ 和 $W$ 是 $\mathbb{R}^n$ 的两个子空间. 它们的“交集” $V\cap W$ 由同属于两个子空间的向量组成（注意到零向量同时属于 $V$ 和 $W$）. 通过检验子空间的定义来证明：$V\cap W$ 也是 $\mathbb{R}^n$ 的子空间；对 $\boldsymbol{x},\boldsymbol{y}\in V\cap W$，$c\boldsymbol{x}+d\boldsymbol{y}$ 为何属于 $V\cap W$？

## 3.2　通过消元法 $A=CR$ 计算零空间

（1）$\boldsymbol{A}$ 的零空间 $\mathcal{N}(\boldsymbol{A})$ 是 $\mathbb{R}^n$ 的子空间，它包含方程组 $\boldsymbol{Ax}=\boldsymbol{0}$ 的所有解，自然包含 $\boldsymbol{x}=\boldsymbol{0}$.

（2）消元法通过初等行变换把 $\boldsymbol{A}$ 变成 $\boldsymbol{R}_0$ 再变成 $\boldsymbol{R}$，这个过程保持零空间不变：$\mathcal{N}(\boldsymbol{A})=\mathcal{N}(\boldsymbol{R}_0)=\mathcal{N}(\boldsymbol{R})$.

（3）$A$ 的最简行阶梯形矩阵 $R_0=\mathrm{rref}(A)$ 包含 $r$ 阶单位阵 $\boldsymbol{I}_r$，余下的 $n-r$ 列为 $\boldsymbol{F}$.

（4）若第 $j$ 列不能由前 $j-1$ 列线性表出，那么 $\boldsymbol{Ax}=\boldsymbol{0}$ 存在第 $j$ 个分量为 $x_j=1$ 的解.

（5）由 $Ax=0$ 的 $n-r$ 个解构成的基础解系蕴含了 $-F$ 和 $I_r$.

（6）每一个“扁宽形”矩阵（满足 $m<n$ 的 $m\times n$ 矩阵）$\boldsymbol{A}$ 的零空间都包含非零向量，即 $\boldsymbol{Ax}=\boldsymbol{0}$ 有非零解.

本节的目标是求 $\boldsymbol{Ax}=\boldsymbol{0}$ 的解集. 当 $\boldsymbol{A}$ 是可逆矩阵时（在此种情形下，它的秩 $r=n$），$\boldsymbol{A}$ 的列向量线性无关，方程组有唯一解 $\boldsymbol{x}=\boldsymbol{0}$，所以零空间只包含零向量. 一般地，$\boldsymbol{A}$ 只有 $r$（$r$ 是 $\boldsymbol{A}$ 的秩）个线性无关的列向量，其他 $n-r$ 个列向量是这 $r$ 个线性无关的列向量的线性组合. 我们的目标是在 $\boldsymbol{A}$ 的零空间中找出 $n-r$ 个元素——$\boldsymbol{Ax}=\boldsymbol{0}$ 的基础解系.

对于可逆方阵，在第 2 章我们把 $\boldsymbol{A}$ 转化成上三角矩阵 $\boldsymbol{U}$. 对任意尺寸的矩阵，高斯消元法把 $\boldsymbol{Ax}=\boldsymbol{0}$ 转化成了“阶梯型”的 $\boldsymbol{Rx}=\boldsymbol{0}$. 事实上，当 $\boldsymbol{A}$ 是可逆矩阵时，$\boldsymbol{R}=\boldsymbol{I}$，因此此时的消元法不仅仅是把 $\boldsymbol{A}$ 分解成 $\boldsymbol{L}$ 和 $\boldsymbol{U}$ 的乘积，而是分解得更彻底：做初等行变换转化成最简行阶梯形矩阵. 我们从两个例子出发，更直接地看一下整个过程.

**例 3.6**

$$\boldsymbol{R}=\begin{bmatrix}\boldsymbol{I} & \boldsymbol{F}\end{bmatrix}\boldsymbol{P}=\begin{bmatrix}\boldsymbol{1} & \boldsymbol{0} & 3 & 5\\ \boldsymbol{0} & \boldsymbol{1} & 4 & 6\end{bmatrix}\quad \boldsymbol{Rx}=\boldsymbol{0}\quad 即\quad \begin{cases}x_1+3x_2+5x_4=0 & ①\\ x_2+4x_3+6x_4=0 & ②\end{cases}$$

矩阵 $\boldsymbol{R}$ 的秩为 $r=2$，它有 $n=4$ 列，所以我们要找出 $\boldsymbol{Rx}=\boldsymbol{0}$ 的 $n-r=2$ 个线性无关的解. 零空间 $\mathcal{N}(\boldsymbol{R})$ 的维数是 2. 这两个解其实很容易找，我们只需要分别令 $x_3$、$x_4$ 为 0、1 和 1、0.

令 $x_3=\boldsymbol{1},x_4=\boldsymbol{0}$. 根据方程①得 $x_1=\boldsymbol{-3}$. 根据方程②得 $x_2=\boldsymbol{-4}$.

令 $x_3=\boldsymbol{0},x_4=\boldsymbol{1}$. 根据方程①得 $x_1=\boldsymbol{-5}$. 根据方程②得 $x_2=\boldsymbol{-6}$.

于是我们在 $\boldsymbol{R}$ 的零空间中就找到了两个元素 $\boldsymbol{s}_1=\begin{bmatrix}-3 & -4 & 1 & 0\end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{s}_2=\begin{bmatrix}-5 & -6 & 0 & 1\end{bmatrix}^{\mathrm{T}}$，也就是说 $\boldsymbol{Rs}_1=\boldsymbol{0},\boldsymbol{Rs}_2=\boldsymbol{0}$. 这两个向量的任意线性组合也属于 $\boldsymbol{R}$ 的零空间. 我们将会证明 $\boldsymbol{s}_1$、$\boldsymbol{s}_2$ 这两个向量构成了 $\boldsymbol{R}$ 的**零空间的一组基.**

矩阵 $\boldsymbol{R}$ 是很容易处理的，它的前两列是单位矩阵（$\boldsymbol{P}$ 是单位阵 $\boldsymbol{I}$）. $\boldsymbol{R}$ 是“最简行阶梯形矩阵”. 我们再给出一个最简行阶梯形矩阵的例子 $\boldsymbol{R}_0$，它也很简单. 多加一个下标 0 是为了表明该矩阵有零行.

**例 3.7**

$$\boldsymbol{R}_0=\begin{bmatrix}\boldsymbol{I} & \boldsymbol{F}\end{bmatrix}\boldsymbol{P}=\begin{bmatrix}\boldsymbol{1} & 7 & \boldsymbol{0} & 8\\ \boldsymbol{0} & 0 & \boldsymbol{1} & 9\\ \boldsymbol{0} & 0 & \boldsymbol{0} & 0\end{bmatrix}\quad \boldsymbol{R}_0\boldsymbol{x}=\boldsymbol{0}\quad 即\quad \begin{cases}x_1+7x_2+0x_3+8x_4=0 & ①\\ x_3+9x_4=0 & ②\\ 0=0 & ③\end{cases}$$

单位矩阵包含于第 1 列和第 3 列，第 3 行是零行. 这个矩阵也是最简行阶梯形矩阵——我们无法使用高斯消元法把它变得更简单. 单位矩阵中的 1 是它们所在行的第一个非零元. “阶梯型”这个词意思是说这些 1 出现的位置就像台阶一样. 所有的零行都出现在 $\boldsymbol{R}_0$ 的最下面.

要得到基础解系中的元素，我们还是通过对“自由变元”赋以 0、1 的取值——此处，$x_2$、$x_4$ 是自由变元.

令 $x_2=\boldsymbol{1},x_4=\boldsymbol{0}$. 根据方程①得 $x_1=\boldsymbol{-7}$. 根据方程②得 $x_3=\boldsymbol{0}$.

令 $x_2=\boldsymbol{0},x_4=\boldsymbol{1}$. 根据方程①得 $x_1=\boldsymbol{-8}$. 根据方程②得 $x_3=\boldsymbol{-9}$.

于是我们在 $\boldsymbol{R}_0$ 的零空间中找到了两个元素 $\boldsymbol{s}_1=\begin{bmatrix}-7 & 1 & 0 & 0\end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{s}_2=\begin{bmatrix}-8 & 0 & -9 & 1\end{bmatrix}^{\mathrm{T}}$. 我们对自由变元 $x_2$ 和 $x_4$ 分别取值 1、0 和 0、1，然后通过方程组 $\boldsymbol{R}_0\boldsymbol{x}=\boldsymbol{0}$ 解出 $x_1$ 和 $x_3$. 如果非要让单位阵包含于第 1 列和第 2 列，我们需要插入一个置换矩阵 $\boldsymbol{P}$.

---

现在是时候介绍本节的计划了. 任意给定 $m\times n$ 矩阵 $\boldsymbol{A}$，使用消元法（或者说初等行变换）把 $\boldsymbol{A}$ 转化成最简行阶梯形矩阵 $\boldsymbol{R}_0=\mathbf{rref}(\boldsymbol{A})$. 在之前的例子中我们看到最简单的情况是 $\boldsymbol{R}_0=\boldsymbol{R}$，而一般情形下，$\boldsymbol{R}_0$ 可能有零行. 把 $\boldsymbol{R}_0$ 的零行都删掉得没有零行的矩阵 $\boldsymbol{R}$.

| | |
|---|---|
| $r,m,n=2,2,4$ | 简单情形　$\boldsymbol{R}=\begin{bmatrix}\boldsymbol{I} & \boldsymbol{F}\end{bmatrix}$　类似于 $\begin{bmatrix}1 & 0 & 3 & 5\\ 0 & 1 & 4 & 6\end{bmatrix}$ |
| $r,m,n=2,3,4$ | 一般情形　$\boldsymbol{R}_0=\begin{bmatrix}\boldsymbol{I} & \boldsymbol{F}\\ \boldsymbol{0} & \boldsymbol{0}\end{bmatrix}\boldsymbol{P}$　类似于 $\begin{bmatrix}1 & 7 & 0 & 8\\ 0 & 0 & 1 & 9\\ 0 & 0 & 0 & 0\end{bmatrix}$ |

$\boldsymbol{I}$ 和 $\boldsymbol{F}$ 都有 $r$ 行，最简行阶梯形矩阵 $\boldsymbol{R}_0$ 和初始的 $\boldsymbol{A}$ 都有 $m$ 行，所以 $\boldsymbol{R}_0$ 有 $m-r$ 个零行. 如果我们把这些零行全部删掉，就得到 $\boldsymbol{R}=\begin{bmatrix}\boldsymbol{I} & \boldsymbol{F}\end{bmatrix}\boldsymbol{P}$.

总结：在第 2 章，$\boldsymbol{A}$ 是可逆方阵，$\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 最终转化为 $\boldsymbol{U}\boldsymbol{x}=\boldsymbol{c}$（其中 $\boldsymbol{U}$ 是上三角矩阵），再用回代法解出 $\boldsymbol{x}$.

这里考虑的秩为 $r$ 的任意矩阵 $\boldsymbol{A}$. 做初等行变换，直到像第 1 章那样找出 $r\times r$ 单位阵 $\boldsymbol{I}$.（当时我们还不知道完整的消元法，但是至少找出了 $\boldsymbol{A}$ 的前 $r$ 个线性无关的列向量，将之排成了矩阵 $\boldsymbol{C}$）. 现在我们从 $\boldsymbol{A}$ 出发构造出 $\boldsymbol{C}$ 和 $\boldsymbol{R}$.

找新的主元列的关键是：判断每一列是否可以被前面的列线性表出. 在本节中，$\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$ 最终化成了 $\boldsymbol{R}\boldsymbol{x}=\boldsymbol{0}$，从而求出零空间. 在 3.3节，$\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 转化成了 $\boldsymbol{R}\boldsymbol{x}=\boldsymbol{d}$，由此可以找出方程组所有的解. 之前的例子说明，通过消元法得到的 $\boldsymbol{R}$ 已经尽可能地简化了 $\boldsymbol{A}$. 接下来我们也会讲述得到 $\boldsymbol{R}$ 的具体步骤.

附录 A9 总结了 $\mathbf{rref}(\boldsymbol{A})$ 的作用：它是矩阵分解 $\boldsymbol{A}=\boldsymbol{C}\boldsymbol{R}$ 和解方程组 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$ 的关键.

### 3.2.1　利用消元法将 $\boldsymbol{A}$ 转化成 $\mathbf{rref}(\boldsymbol{A})$：最简行阶梯形矩阵

如何作消元法？所谓消元法就是（以任何顺序）作如下三种初等行变换[①].

（1）把某一行的若干倍加到另一行（无论是上面还是下面的行）；

（2）把某一行乘以非零常数倍；

（3）交换两行.

在例 3.6 和例 3.7 中，我们有最简单的 $\boldsymbol{R}$ 和稍微一般一点的 $\boldsymbol{R}_0$. 这里我们给一个 $2\times 4$ 矩阵 $\boldsymbol{A}$，通过消元法可得例 3.6 中的 $\boldsymbol{R}=\begin{bmatrix}\boldsymbol{I} & \boldsymbol{F}\end{bmatrix}$.

---

① 译者注：这三种初等行变换，按顺序依次被称作倍加变换、倍乘变换和对换. 同时提示一下，倍加变换中的倍数可以是任意倍数，而倍乘变换中的倍数一定是非零倍数.

$$A=\begin{bmatrix}1&2&11&17\\3&7&37&57\end{bmatrix}\longrightarrow\begin{bmatrix}1&2&11&17\\0&1&4&6\end{bmatrix}\longrightarrow\begin{bmatrix}1&0&3&5\\0&1&4&6\end{bmatrix}=\boldsymbol{R}$$

从第 1 列开始消元. 用第 2 行减去第 1 行的 3 倍，就得到了中间那个矩阵中的分量 0. 现在第 1 列就完成了（左上角元素 $A_{11}=1$ 是主元，是我们想要的）. 接下来看第 2 列；把新得到的矩阵的第 1 行减去第 2 行的 2 倍，就得到了 $\boldsymbol{R}$ 中第二个分量 0. 至此，$\boldsymbol{R}$ 的前两列恰是 $r\times r$ 单位阵 $\boldsymbol{I}$；因此矩阵 $\boldsymbol{A}$ 的秩是 $r=2$，并且消元的步骤也全部完成了.

现在可以回过头来思考一下，消元法到底是在干什么呢？本例中，消元法把原矩阵前两列构成的可逆矩阵 $\boldsymbol{W}=\begin{bmatrix}1&2\\3&7\end{bmatrix}$ 转化成了单位阵 $\boldsymbol{I}$：

$$\boldsymbol{W}^{-1}\boldsymbol{A}=\boldsymbol{W}^{-1}\begin{bmatrix}\boldsymbol{W}&\boldsymbol{H}\end{bmatrix}=\begin{bmatrix}\boldsymbol{I}&\boldsymbol{W}^{-1}\boldsymbol{H}\end{bmatrix}=\begin{bmatrix}\boldsymbol{I}&\boldsymbol{F}\end{bmatrix}=\boldsymbol{R}.$$

我们必须时刻注意到 $\boldsymbol{A}$ 中的自由列（$\boldsymbol{H}$ 中的列向量）是主元列（$\boldsymbol{W}$ 中的列向量）的线性组合，也就是说存在矩阵 $\boldsymbol{F}$ 使得 $\boldsymbol{H}=\boldsymbol{W}\boldsymbol{F}$. 矩阵 $\boldsymbol{F}$ 包含了如何用主元列线性表出自由列的信息. 这就是对最简行阶梯形矩阵 $\boldsymbol{R}$ 和矩阵 $\boldsymbol{F}$ 的作用的理解!

$$\text{自由列}\quad\boldsymbol{H}=\begin{bmatrix}11&17\\37&57\end{bmatrix}=\boldsymbol{W}\boldsymbol{F}=\begin{bmatrix}1&2\\3&7\end{bmatrix}\begin{bmatrix}3&5\\4&6\end{bmatrix}$$

尽管对 $\boldsymbol{A}$ 进行初等行变换转化成最简行阶梯形矩阵的过程不唯一，有很多种途径可以达成这个目标，但是无论如何对 $\boldsymbol{A}$ 进行初等行变换，最后得到的（没有零行的）最简行阶梯形矩阵始终是 $\boldsymbol{R}$. $\boldsymbol{R}$ 由 $\boldsymbol{A}$ 完全决定，而跟初等行变换的过程无关.

（1）$\boldsymbol{A}$ 的前 $r$ 个线性无关的列向量所在的列和 $\boldsymbol{R}$ 包含单位阵 $\boldsymbol{I}$ 的列相同. 我们可以右乘某个置换矩阵 $\boldsymbol{P}$ 把这些列排在最前面的 $r$ 列.
（2）$\boldsymbol{R}$ 的其他列构成的矩阵 $\boldsymbol{F}$ 可以由式 $\boldsymbol{H}=\boldsymbol{W}\boldsymbol{F}$ 确定. $\boldsymbol{A}$ 的非主元列 $=\boldsymbol{A}$ 的主元列 $\times\boldsymbol{F}$.
（3）$\boldsymbol{R}_0$ 的后 $m-r$ 行都是零行.

**例 3.8** 我们再给一个矩阵 $\boldsymbol{A}$，它的最简行阶梯形矩阵是例 3.7中的 $\boldsymbol{R}_0$. $\boldsymbol{A}$ 和 $\boldsymbol{R}_0$ 都是秩为 2 的 $3\times4$ 矩阵. 下面是具体的例子和消元的过程.

$$A=\begin{bmatrix}1&7&3&35\\2&14&6&70\\2&14&9&97\end{bmatrix}\longrightarrow\begin{bmatrix}1&7&3&35\\0&0&0&0\\0&0&3&27\end{bmatrix}\longrightarrow\begin{bmatrix}1&7&0&8\\0&0&0&0\\0&0&3&27\end{bmatrix}\longrightarrow\begin{bmatrix}1&7&0&8\\0&0&1&9\\0&0&0&0\end{bmatrix}=\boldsymbol{R}_0$$

### 3.2.2 逐列消元：从 $\boldsymbol{A}$ 到 $\boldsymbol{R}_0$ 的步骤

通过前面的例子，我们可以总结出作消元的具体算法. 这是一种递归的方法，从左往右，每次对一列作消元. 对前 $k$ 列作完消元法后，设得到矩阵 $\boldsymbol{B}$. 矩阵 $\boldsymbol{B}$ 的前 $k$ 列是 $\boldsymbol{A}$ 前 $k$ 列的 **rref**. 接下来处理第 $k+1$ 列：把 $\boldsymbol{B}$ 的第 $k+1$ 列分成上下两部分，上半部分记为 $\boldsymbol{u}$，下半部分记为 $\boldsymbol{\ell}$.

$$\boldsymbol{B}\text{ 的前 }k+1\text{ 列为}\quad\begin{bmatrix}\boldsymbol{I}_k&\boldsymbol{F}_k\\0&0\end{bmatrix}\boldsymbol{P}_k\text{ 后面接}\begin{bmatrix}\boldsymbol{u}\\\boldsymbol{\ell}\end{bmatrix}$$ ①

① 译者注：此处的 $\boldsymbol{I}_k$ 表示的并不是 $k$ 阶单位阵，而是对 $\boldsymbol{A}$ 的前 $k$ 列进行消元产生的单位阵.

关键问题是：能否把第 $k+1$ 列处理之后接在 $\boldsymbol{I}_k$ 或者 $\boldsymbol{F}_k$ 之后？

若 $\boldsymbol{\ell}=\boldsymbol{0}$，则第 $k+1$ 列可以由前 $k$ 列线性表出. 于是我们可以把 $\boldsymbol{u}$ 处理之后接在 $\boldsymbol{F}_k$ 之后，得到 $\boldsymbol{F}_{k+1}$，然后接着处理第 $k+2$ 列.

若 $\boldsymbol{\ell}\neq\boldsymbol{0}$，则第 $k+1$ 列不能由前 $k$ 列线性表出. 在 $\boldsymbol{\ell}$ 中找一个非零分量（一般来说，取其中绝对值最大的分量[①]）作为主元，然后把该主元所在的行和 $\boldsymbol{B}$ 的第 $k+1$ 行交换，接着把此时的第 $k+1$ 行的适当的倍数加到其余各行，使得第 $k+1$ 列就只剩下主元是非零元，再通过倍乘把主元化为 1. 于是，我们可以把第 $k+1$ 列接在 $\boldsymbol{I}_k$ 后面得到 $\boldsymbol{I}_{k+1}$. 接下来，我们就可以用同样的方法处理第 $k+2$ 列.

通过消元法我们最终得到 $\boldsymbol{A}$ 的所有主元列——这就是我们所需要的**$\boldsymbol{A}$ 的前 $r$ 个线性无关的列向量**. 这些主元列也是 $\boldsymbol{C}$ 的列向量，并最终导出矩阵分解 $\boldsymbol{A}=\boldsymbol{CR}$ 中 $\boldsymbol{R}$ 所包含的单位阵 $\boldsymbol{I}_{r\times r}$.

---

例 3.8展示了从 $\boldsymbol{A}$ 到最简行阶梯形矩阵 $\boldsymbol{R}_0$ 所允许的三种初等行变换：

（1）把某一行的若干倍加到另一行（**上面行的倍数往下面的行加或者下面行的倍数往上面行加，两者均可**）；

（2）把某一行除以它的第一个非零元把主元化为 1，例如 $\begin{bmatrix}0 & 0 & 3 & 27\end{bmatrix}$ 除以 3；

（3）交换两行（例如把 $\boldsymbol{R}_0$ 的零行移到最下面）.

可以通过不同的初等行变换的步骤来得到最简行阶梯形矩阵 $\boldsymbol{R}_0=\mathbf{rref}(\boldsymbol{A})$；但是必须强调的是，无论通过何种途径，最终的最简行阶梯形矩阵 $\boldsymbol{R}_0=\mathbf{rref}(\boldsymbol{A})$ 是固定不变的. $\boldsymbol{R}_0$ 的每一个部分都由初始的矩阵 $\boldsymbol{A}$ 完全决定.

（1）例 3.8中 $\boldsymbol{R}_0$ 有一个零行，这是因为 $\boldsymbol{A}$ 的秩 $r=2$.

（2）$\boldsymbol{I}$ 在 $\boldsymbol{R}_0$ 的第 1 列和第 3 列，因为这两列是 $\boldsymbol{A}$ 的前两个线性无关的列向量.

（3）$\boldsymbol{F}$ 在 $\boldsymbol{R}$ 的第 2、4 列，它们是 $\boldsymbol{A}$ 的自由列，可以由主元列（第 1、3 列）线性组合出来.

$$\boldsymbol{C}\times\boldsymbol{F}=\begin{bmatrix}1 & 3\\ 2 & 6\\ 2 & 9\end{bmatrix}\begin{bmatrix}7 & 8\\ 0 & 9\end{bmatrix}=\begin{bmatrix}7 & 35\\ 14 & 70\\ 14 & 97\end{bmatrix}=\boldsymbol{A}\text{ 的自由列：第 2、4 列}$$

在第 1 章，我们无法直接看出 $\begin{bmatrix}35 & 70 & 97\end{bmatrix}^{\mathrm{T}}$ 是矩阵 $\boldsymbol{A}$ 的第 1 列和第 3 列的线性组合.

需要始终牢记，矩阵 $\boldsymbol{R}$ 可以求出 $\boldsymbol{A}$ 的零空间；说得更明白一点，那就是解 $\boldsymbol{Ax}=\boldsymbol{0}$ 等价于解 $\boldsymbol{Rx}=\boldsymbol{0}$；因为 $\boldsymbol{R}$ 有一部分是单位矩阵，所以 $\boldsymbol{Rx}=\boldsymbol{0}$ 是容易求解的.

### 3.2.3　矩阵分解 $\boldsymbol{A}=\boldsymbol{CR}$ 和零空间

第 1 章介绍了矩阵分解 $\boldsymbol{A}=\boldsymbol{CR}$，并且举了一些小尺寸矩阵分解的例子. 我们已经了解了主元列的含义，只是苦于没有一个系统的方法找出主元列. 但是现在我们有方法了：对 $\boldsymbol{A}$ 进行初等

① 译者注：在第 2 章已经阐述了主元的选取和计算稳定性的关系，此处再复习一遍. 从理论上来说，取哪个非零元没有区别；但是在计算上，取绝对值最大的元素有助于控制误差，因为作倍加变换时要乘以该主元的倒数.

行变换转化为最简行阶梯形 $\boldsymbol{R}_0$. 那么 $\boldsymbol{A}$ 中和 $\boldsymbol{R}_0$ 中的单位阵所在列相同的那些列向量就是 $\boldsymbol{A}$ 的主元列. 把 $\boldsymbol{R}_0$ 的零行去掉就得到了矩阵分解 $\boldsymbol{A}=\boldsymbol{CR}$ 中所需的 $\boldsymbol{R}$.

回看例 3.8，我们求出了 $\boldsymbol{Ax}=\boldsymbol{0}$ 的两个解 $\boldsymbol{s}_1$ 和 $\boldsymbol{s}_2$——每一个都对应于 $\boldsymbol{F}$ 中的一列.

$$\boldsymbol{Rs}_1=\boldsymbol{0} \qquad \begin{bmatrix}1&7&0&8\\0&0&1&9\end{bmatrix}\begin{bmatrix}\mathbf{-7}\\\mathbf{1}\\\mathbf{0}\\\mathbf{0}\end{bmatrix}=\begin{bmatrix}0\\0\end{bmatrix} \qquad \text{在第 2、4 分量分别放 } \mathbf{1}、\mathbf{0}$$

$$\boldsymbol{Rs}_2=\boldsymbol{0} \qquad \begin{bmatrix}1&7&0&8\\0&0&1&9\end{bmatrix}\begin{bmatrix}\mathbf{-8}\\\mathbf{0}\\\mathbf{-9}\\\mathbf{1}\end{bmatrix}=\begin{bmatrix}0\\0\end{bmatrix} \qquad \text{在第 2、4 分量分别放 } \mathbf{0}、\mathbf{1}$$

通过 $-\boldsymbol{F}$、$\boldsymbol{I}$ 和 $\boldsymbol{P}^{\mathrm{T}}$，$\boldsymbol{s}_1$ 和 $\boldsymbol{s}_2$ 是最容易看出来的解.

$$\begin{bmatrix}\boldsymbol{I} & \boldsymbol{F}\end{bmatrix}\boldsymbol{x}=\boldsymbol{0}\text{的基础解系是}\begin{bmatrix}-\boldsymbol{F}\\\boldsymbol{I}\end{bmatrix}\text{的列向量.}$$

$$\begin{bmatrix}\boldsymbol{I} & \boldsymbol{F}\end{bmatrix}\boldsymbol{Px}=\boldsymbol{0}\text{的基础解系是}\boldsymbol{P}^{\mathrm{T}}\begin{bmatrix}-\boldsymbol{F}\\\boldsymbol{I}\end{bmatrix}\text{的列向量.}$$

第一种情况相对简单，因为置换矩阵 $\boldsymbol{P}=\boldsymbol{I}$；第二种情况成立是因为对任意置换矩阵 $\boldsymbol{P}$ 都有 $\boldsymbol{PP}^{\mathrm{T}}=\boldsymbol{I}$.

$$\boldsymbol{Rx}=\boldsymbol{0} \qquad \begin{bmatrix}\boldsymbol{I} & \boldsymbol{F}\end{bmatrix}\boldsymbol{PP}^{\mathrm{T}}\begin{bmatrix}-\boldsymbol{F}\\\boldsymbol{I}\end{bmatrix}=\begin{bmatrix}\boldsymbol{I} & \boldsymbol{F}\end{bmatrix}\begin{bmatrix}-\boldsymbol{F}\\\boldsymbol{I}\end{bmatrix}=\begin{bmatrix}\boldsymbol{0}\end{bmatrix}$$

**复习总结：** 假设 $\boldsymbol{A}$ 是秩为 $r$ 的 $m\times n$ 矩阵，为了求方程组 $\boldsymbol{Ax}=\boldsymbol{0}$ 的 $n-r$ 个解构成的基础解系，我们先计算 $\boldsymbol{A}$ 的最简行阶梯形矩阵 $\boldsymbol{R}_0$，把 $\boldsymbol{R}_0$ 的 $m-r$ 个零行删掉，得到矩阵 $\boldsymbol{R}=\begin{bmatrix}\boldsymbol{I} & \boldsymbol{F}\end{bmatrix}\boldsymbol{P}$ 和矩阵分解 $\boldsymbol{A}=\boldsymbol{CR}$. 进一步地，$\boldsymbol{Ax}=\boldsymbol{0}$ 的基础解系就是 $\boldsymbol{P}^{\mathrm{T}}\begin{bmatrix}-\boldsymbol{F}\\\boldsymbol{I}\end{bmatrix}$ 的 $n-r$ 个列向量. 详情请见第 3 章末尾的介绍.

**例 3.9** 对 $\boldsymbol{A}$ 作消元可得 $\boldsymbol{R}_0$ 和 $\boldsymbol{R}$. $\boldsymbol{R}$ 揭秘了 $\boldsymbol{A}$ 的零空间.

$$\boldsymbol{A}=\begin{bmatrix}1&2&1\\2&4&5\\3&6&9\end{bmatrix}\longrightarrow\boldsymbol{A}=\begin{bmatrix}1&2&1\\0&0&3\\0&0&6\end{bmatrix}\longrightarrow\boldsymbol{A}=\begin{bmatrix}1&2&0\\0&0&1\\0&0&0\end{bmatrix}=\boldsymbol{R}_0 \quad \text{秩}=2$$

那么 $\boldsymbol{R}=\begin{bmatrix}1&2&0\\0&0&1\end{bmatrix}$，$\boldsymbol{A}$、$\boldsymbol{R}_0$ 和 $\boldsymbol{R}$ 的主元列是第 1 和第 3 列.

要解 $\boldsymbol{Ax}=\boldsymbol{0}$ 和 $\boldsymbol{Rx}=\boldsymbol{0}$，令 $x_2=1$，从而解出 $x_1=-2,x_3=0$. 因此 $\boldsymbol{s}=\begin{bmatrix}-2&1&0\end{bmatrix}^{\mathrm{T}}$ 单个

向量就是基础解系，方程组所有的解均形如 $\boldsymbol{x}=\begin{bmatrix}-2c & c & 0\end{bmatrix}^{\mathrm{T}}(c\in\mathbb{R})$. 矩阵分解 $\boldsymbol{A}=\boldsymbol{CR}$ 为

$$\boldsymbol{A}=\begin{bmatrix}1&2&1\\2&4&5\\3&6&9\end{bmatrix}=\boldsymbol{CR}=\begin{bmatrix}1&1\\2&5\\3&9\end{bmatrix}\begin{bmatrix}1&2&0\\0&0&1\end{bmatrix}=\begin{matrix}\text{（列空间的一组基）}\\\text{在 }\boldsymbol{C}\text{ 中}\end{matrix}\quad\begin{matrix}\text{（行空间的一组基）}\\\text{在 }\boldsymbol{R}\text{ 中}\end{matrix}$$

$\boldsymbol{A}$ 的每一行都可以写成 $\boldsymbol{R}$ 的行向量的线性组合吗？答案是肯定的！我们只需要用矩阵分解 $\boldsymbol{A}=\boldsymbol{CR}$. $\boldsymbol{A}$ 的行向量是 $\boldsymbol{R}$ 的两行以 $\boldsymbol{C}$ 的行向量为系数的线性组合.

对相当一部分矩阵而言，方程组 $\boldsymbol{Ax}=\boldsymbol{0}$ 只有唯一解 $\boldsymbol{x}=\boldsymbol{0}$；$\boldsymbol{A}$ 的列向量线性无关. 零空间 $\mathcal{N}(\boldsymbol{A})$ 只包含零向量：没有所谓的“基础解系”. 能使列向量的线性组合等于零向量的只有平凡的零线性组合（即系数都是零）.

$\mathcal{N}(\boldsymbol{A})=\{\boldsymbol{0}\}$ 的矩阵 $\boldsymbol{A}$ 极其重要，它表明 $\boldsymbol{A}$ 的列向量线性无关. 除了平凡的线性组合，没有其他线性组合能得到零向量. 然而，这种情况在 $n>m$ 时不可能出现，我们无法在 $\mathbb{R}^m$ 中找到 $n$ 个线性无关的列向量.

---

**重点：如果 $\boldsymbol{A}$ 的列数大于行数，即 $n>m$，那么至少有一个自由变元，从而线性方程组 $\boldsymbol{Ax}=\boldsymbol{0}$ 至少有一个非零解.**

> 若方程组 $\boldsymbol{Ax}=\boldsymbol{0}$ 的未知数的个数大于方程个数（$n>m$），则至少有 $n-m$ 个自由变元. $\boldsymbol{Ax}=\boldsymbol{0}$ 一定有非零解，等价地，$\mathcal{N}(\boldsymbol{A})$ 中有非零向量.

矩阵的零空间是线性子空间，“维数”等于自由变元的个数. 子空间的维数是关键的不变量——我们将在 3.5节详细论述.

---

**例 3.10** 给定矩阵 $\boldsymbol{A}=\begin{bmatrix}1&2\\3&8\end{bmatrix},\boldsymbol{B}=\begin{bmatrix}\boldsymbol{A}\\2\boldsymbol{A}\end{bmatrix}=\begin{bmatrix}1&2\\3&8\\2&4\\6&16\end{bmatrix},\boldsymbol{M}=\begin{bmatrix}\boldsymbol{A}&2\boldsymbol{A}\end{bmatrix}=\begin{bmatrix}1&2&2&4\\3&8&6&16\end{bmatrix}$，

求 $\boldsymbol{A}$、$\boldsymbol{B}$、$\boldsymbol{M}$ 的零空间，求方程组 $\boldsymbol{Mx}=\boldsymbol{0}$ 的一个基础解系.

**解** 方程组 $\boldsymbol{Ax}=\boldsymbol{0}$ 只有零解，$\boldsymbol{A}$ 的零空间是 $\{\boldsymbol{0}\}$，只包含 $\mathbb{R}^2$ 的零向量，直接通过消元法求解即可.

$$\boldsymbol{A}=\begin{bmatrix}1&2\\3&8\end{bmatrix}\longrightarrow\begin{bmatrix}1&2\\0&2\end{bmatrix}\longrightarrow\begin{bmatrix}1&0\\0&1\end{bmatrix}=\boldsymbol{R}=\boldsymbol{I}\quad\text{没有自由变元，没有 }\boldsymbol{F}$$

$\boldsymbol{A}$ 是可逆矩阵，$\boldsymbol{Ax}=\boldsymbol{0}$ 没有非零解，它的两列都是主元列.

矩阵 $\boldsymbol{B}$ 是竖长形的，它的零空间也是 $\{\boldsymbol{0}\}$. 方程组 $\boldsymbol{Bx}=\boldsymbol{0}$ 的前两个方程足以推出 $\boldsymbol{x}=\boldsymbol{0}$，后两个方程也迫使 $\boldsymbol{x}=\boldsymbol{0}$. 当我们添加更多的方程（系数矩阵多一些行向量）时，零空间显然不能变大. 额外的行无非是对零空间中的向量 $\boldsymbol{x}$ 加以更多的限制条件.

矩阵 $M$ 是扁宽的形状，它的零空间就不一样了. 它有更多的列，而非更多的行. 此时 $x$ 有 4 个分量，分量多那就是未知数多，未知数多意味着更多的自由度. 消元法说明 $M$ 的前两列是主元列，而 $M$ 的后两列是自由列，没有主元.

$$M=\begin{bmatrix}1&2&2&4\\3&8&6&16\end{bmatrix}\qquad R=\begin{bmatrix}1&0&2&0\\0&1&0&2\end{bmatrix}=\begin{bmatrix}I&F\end{bmatrix}$$

对自由变元 $x_3$、$x_4$，我们分别取值 0 和 1. 先令 $x_3=1$、$x_4=0$，再令 $x_3=0$、$x_4=1$；主元 $x_1$、$x_2$ 就由方程组 $Rx=0$ 决定. 于是就得到了 $M$ 零空间中的两个向量. 它们当然也属于 $R$ 的零空间：初等行变换保持方程组的解不变.

$Mx=0$ 的基础解系

$$R=\begin{bmatrix}1&0&2&0\\0&1&0&2\end{bmatrix}\qquad s_1=\begin{bmatrix}-2\\0\\1\\0\end{bmatrix},\ s_2=\begin{bmatrix}0\\-2\\0\\1\end{bmatrix}$$

$Rs_1=0$　$Rs_2=0$

← 2个　← 主元　← 2个　← 自由变元

### 3.2.4 消元法的终章：分块消元

矩阵语言的特殊价值在于它能够展示整体概况. 到目前为止，我们已经描述了通常情况下具体执行消元法的过程，即一次处理一列. 但是，如果我们对原始矩阵 $A$ 进行分块，那么分块消元可以用以下三个步骤来简化描述. 设 $A$ 的秩是 $r$.

第一步，用两个置换矩阵 $P_C$ 和 $P_R$ 分别交换 $A$ 的列和行，使得 $P_RAP_C$ 左上角的 $r\times r$ 子矩阵是可逆矩阵：

$$P_RAP_C=\begin{bmatrix}W&H\\J&K\end{bmatrix}\qquad C=\begin{bmatrix}W\\J\end{bmatrix}\text{和}B=\begin{bmatrix}W&H\end{bmatrix}\text{的秩都是}r$$

第二步，将前 $r$ 行乘以矩阵 $W^{-1}$，可得 $W^{-1}B=\begin{bmatrix}I&W^{-1}H\end{bmatrix}=\begin{bmatrix}I&F\end{bmatrix}$.

第三步，把 $-J\begin{bmatrix}I&W^{-1}H\end{bmatrix}$ 加到后 $m-r$ 行——$\begin{bmatrix}J&K\end{bmatrix}$，把后 $m-r$ 行消成零行 $\begin{bmatrix}0&0\end{bmatrix}$.

上述三步最终将 $A$ 转化成了它的最简行阶梯形矩阵 $R_0$

$$P_RAP_C=\begin{bmatrix}W&H\\J&K\end{bmatrix}\longrightarrow\begin{bmatrix}I&W^{-1}H\\J&K\end{bmatrix}\longrightarrow\begin{bmatrix}I&W^{-1}H\\0&0\end{bmatrix}=R_0 \tag{3.1}$$

有两点需要加以重点说明，它们是第二步和第三步能够成立的原因.

① $r\times r$ 矩阵 $W$ 是可逆矩阵.　② $A$ 的分块满足 $JW^{-1}H=K$.

（1）对于 $W$ 的可逆性，我们回顾矩阵分解 $A=CR$；只看 $A$ 的 $r$ 个线性无关的行向量，也就是矩阵 $B$，它有矩阵分解 $B=WR$. 因为 $B$ 和 $R$ 的秩都是 $r$ 且 $W$ 是 $r\times r$ 矩阵，那么 $W$ 的秩必须是 $r$，因此 $W$ 是可逆矩阵.

（2）显然中间的矩阵前 $r$ 行 $\begin{bmatrix}I&W^{-1}H\end{bmatrix}$ 线性无关；又因为矩阵的秩是 $r$，后 $m-r$ 行 $\begin{bmatrix}J&K\end{bmatrix}$ 可以由前 $r$ 行线性表出. 这个线性表出的方式由 $J$ 给出：只有 $J$ 能使前 $r$ 列吻合 $JI=J$；而消元让后 $n-r$ 列被消掉，必要条件是 $J(W^{-1}H)=K$.

最终结论：$P_R A P_C = \begin{bmatrix} W \\ J \end{bmatrix} W^{-1} \begin{bmatrix} W & H \end{bmatrix} = C W^{-1} B.$

因为列向量构成的矩阵 $C$ 和行向量构成的矩阵 $B$ 都包含 $W$，所以中间的 $W^{-1}$ 是为了消掉多余的 $W$.

## 习题 3.2

1. 设 $E$ 是可逆矩阵，为什么 $A$ 和 $R = EA$ 的行空间相同？

2. 给定矩阵 $A = \begin{bmatrix} 1 & 2 & 1 \\ 3 & 6 & 3 \\ 4 & 8 & c \end{bmatrix}$ 和 $B = \begin{bmatrix} c & c \\ c & c \end{bmatrix}$，求它们各自的最简行阶梯形矩阵和秩（提示：和 $c$ 有关，需分类讨论）. 主元列分别是哪几列？求方程组 $Ax = 0$ 和 $Bx = 0$ 的基础解系.

3. 给定向量 $s_1 = \begin{bmatrix} -3 \\ 1 \\ 0 \\ 0 \end{bmatrix}$ 和 $s_2 = \begin{bmatrix} -2 \\ 0 \\ -6 \\ 1 \end{bmatrix}$，请构造一个 $2 \times 4$ 最简行阶梯形矩阵 $R$ 使得 $s_1$、$s_2$ 是方程组 $Rx = 0$ 的基础解系（提示：请分析出第 1、3 列是主元列，自由变元是 $x_2$、$x_4$，它们分别取值 1、0 和 0、1 得到 $s_1$ 和 $s_2$）.

请刻画 $\left\{ A \in \mathbb{R}^{2\times 4} : \mathcal{N}(A) \text{ 是 } s_1, s_2 \text{ 张成的子空间} \right\}$.

4. 把下述矩阵 $A$ 和 $B$ 用消元法化成阶梯型矩阵，并且对它们作矩阵分解，分解成 $CR$ 的乘积形式（$C$ 和 $R$ 的要求与正文相同）

（1）　$A = \begin{bmatrix} 1 & 2 & 2 & 4 & 6 \\ 1 & 2 & 3 & 6 & 9 \\ 0 & 0 & 1 & 2 & 3 \end{bmatrix}$　　（2）　$B = \begin{bmatrix} 2 & 4 & 2 \\ 0 & 4 & 4 \\ 0 & 8 & 8 \end{bmatrix}$

5. 矩阵 $A$ 同上一题. 每一个自由变元都对应于 $Rx = 0$ 的一个基础解：令它等于 1 并令其他自由变元等于 0. 找出这些解并解方程组 $Rx = 0$.

6. 判断正误，正确则简述理由，错误则举出反例.

（1）方阵没有自由变元（它的列向量线性无关）；

（2）可逆矩阵没有自由变元；

（3）$m \times n$ 矩阵至多 $n$ 个主元；

（4）$m \times n$ 矩阵至多 $m$ 个主元.

7. $C$ 是 $r \times r$ 可逆矩阵，$A = \begin{bmatrix} C & C \end{bmatrix}$. 把 $A$ 分解成 $CR$ 的形式，并且找出 $Ax = 0$ 的 $r$ 个线性无关的解：它们构成 $A$ 的零空间的一组基.

8. 构造有尽可能多的元素是 1 的 $4 \times 8$ 最简行阶梯形矩阵 $R$，且其自由列（取决于前面的列）是

（1）第 2、4、5、6 列；

（2）第 1、3、6、7、8 列.

9. 设一个 $3\times5$ 矩阵的第 4 列全是 0，那么 $x_4$ 一定是_____ 变元. 对应于这个变元的基础解是向量 $\boldsymbol{x}=$_____.

10. 设一个 $3\times4$ 矩阵的首个列向量和末个列向量相同，那么 _____ 是自由变元. 请找出对应于这个自由变元的基础解.

11. 当一个 $5\times5$ 矩阵有_____ 个主元时，它的零空间只包含 $\boldsymbol{x}=\boldsymbol{0}$. 请解释为什么它的列空间是 $\mathbb{R}^5$.

12. 设一个 $m\times n$ 矩阵有 $r$ 个主元，那么它有_____ 个基础解. 当 $r=$_____ 时，它的零空间只包含 $\boldsymbol{x}=\boldsymbol{0}$. 当 $r=$_____ 时，它的列空间是整个 $\mathbb{R}^m$.

13.（推荐）由方程 $x-3y-z=12$ 和 $x-3y-z=0$ 定义的两个平面平行. 点 $(12,0,0)$ 在前一个平面上，那么这个平面上的所有点形如：

$$\begin{bmatrix}x\\y\\z\end{bmatrix}=\begin{bmatrix}__\\0\\0\end{bmatrix}+y\begin{bmatrix}__\\1\\0\end{bmatrix}+z\begin{bmatrix}__\\0\\1\end{bmatrix}$$

14. 设 $4\times5$ 矩阵 $\boldsymbol{A}$ 有 4 个主元，并且第 1 列 + 第 3 列 + 第 5 列 $=\boldsymbol{0}$. 它的哪一列没有主元？对应的基础解是什么？请写出 $\mathcal{N}(\boldsymbol{A})$.

习题 15 ~ 20 意在构造（如果存在）符合特定条件的矩阵.

15. 构造一个矩阵 $\boldsymbol{A}$ 使得 $\mathcal{N}(\boldsymbol{A})$ 是由 $\begin{bmatrix}2&2&1&0\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}3&1&0&1\end{bmatrix}^{\mathrm{T}}$ 张成的子空间.

16. 构造一个矩阵 $\boldsymbol{A}$ 使得 $\mathcal{N}(\boldsymbol{A})$ 是由 $\begin{bmatrix}4&3&2&1\end{bmatrix}^{\mathrm{T}}$ 张成的子空间. 它的秩是_____.

17. 构造一个矩阵使得其列空间包含 $\begin{bmatrix}1&1&5\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}0&3&1\end{bmatrix}^{\mathrm{T}}$ 且其零空间包含 $\begin{bmatrix}1&1&2\end{bmatrix}^{\mathrm{T}}$.

18. 构造一个矩阵使得其列空间包含 $\begin{bmatrix}1&1&0\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}0&1&1\end{bmatrix}^{\mathrm{T}}$ 且其零空间包含 $\begin{bmatrix}1&0&1\end{bmatrix}^{\mathrm{T}}$.

19. 构造一个零空间和列空间相等的 $2\times2$ 矩阵（这样的矩阵存在）.

20. 为什么不存在零空间和列空间相等的 $3\times3$ 矩阵？

21. 如果 $\boldsymbol{AB}=\boldsymbol{0}$，那么 $\boldsymbol{B}$ 的列空间包含于 $\boldsymbol{A}$ 的_____ 空间. 为什么？

22. 随机选取的 $3\times3$ 矩阵的无零行最简行阶梯形矩阵 $\boldsymbol{R}$ 几乎一定是_____. 若 $\boldsymbol{A}$ 是随机的 $4\times3$ 矩阵，$\boldsymbol{R}$ 几乎一定是什么？

23. 若 $\mathcal{N}(\boldsymbol{A})$ 是 $\boldsymbol{x}=\begin{bmatrix}2&1&0&1\end{bmatrix}^{\mathrm{T}}$ 张成的子空间，那么 $\boldsymbol{R}$ 是什么？它的秩是多少？

24. 若 $\boldsymbol{Rx}=\boldsymbol{0}$ 的基础解系是矩阵 $\boldsymbol{N}$ 的列向量，且 $\boldsymbol{R}$ 是无零行最简行阶梯形矩阵；对下述三种矩阵 $\boldsymbol{N}$，分别求出 $\boldsymbol{R}$.

$$\begin{bmatrix}2&3\\1&0\\0&1\end{bmatrix}\qquad\begin{bmatrix}0\\0\\1\end{bmatrix}\qquad\begin{bmatrix}\\\\\end{bmatrix}$$

（$3\times1$ 空矩阵，即原方程组没有基础解）

25.（1）由 0、1 组成的 $2\times2$ 最简行阶梯形矩阵一共有 5 个，请把它们都写下来.

（2）由 0、1 组成的 $1\times3$ 矩阵一共有 8 个，请把它们都写下来. 这 8 个矩阵是否全是最简行阶梯形矩阵？

26. 如果 $\boldsymbol{A}$ 是可逆 4 阶方阵，那么 $4\times 8$ 矩阵 $\boldsymbol{B}=\begin{bmatrix}\boldsymbol{A} & \boldsymbol{A}\end{bmatrix}$ 的零空间是什么？请说明为什么 $\boldsymbol{A}$ 和 $-\boldsymbol{A}$ 总是有相同的最简行阶梯形矩阵 $\boldsymbol{R}$.

27. 设 $\boldsymbol{C}=\begin{bmatrix}\boldsymbol{A}\\ \boldsymbol{B}\end{bmatrix}$，那么零空间 $\mathcal{N}(\boldsymbol{C})$ 和 $\mathcal{N}(\boldsymbol{A})$、$\mathcal{N}(\boldsymbol{B})$ 有什么关系？

28. 求下列矩阵的最简行阶梯形矩阵:

$$\boldsymbol{A}=\begin{bmatrix}0 & 0 & 0\\ 2 & 4 & 6\end{bmatrix}\quad \boldsymbol{B}=\begin{bmatrix}\boldsymbol{A} & \boldsymbol{A}\\ \boldsymbol{0} & \boldsymbol{A}\end{bmatrix}\quad \boldsymbol{C}=\begin{bmatrix}\boldsymbol{A} & \boldsymbol{A}\\ \boldsymbol{A} & 0\end{bmatrix}$$

29. 假设某个由三个列向量组成的矩阵的主元列是后两列而非前两列，它的无零行最简行阶梯形矩阵 $\boldsymbol{R}$ 是什么？求出它的基础解系.

30. 若 $\boldsymbol{A}$ 有 $r$ 个主元列，为什么 $\boldsymbol{A}^{\mathrm{T}}$ 也有 $r$ 个主元列？请举一个 $3\times 3$ 矩阵的例子说明 $\boldsymbol{A}$ 和 $\boldsymbol{A}^{\mathrm{T}}$ 的主元列不在相同的位置.

31. 下列矩阵都是秩 1 矩阵，假设 $a\neq 0$，把它们补充完整

$$\boldsymbol{A}=\begin{bmatrix}a & b & c\\ d & & \\ g & & \end{bmatrix}\qquad \boldsymbol{B}=\begin{bmatrix} & 9 & \\ 1 & & \\ 2 & 6 & -3\end{bmatrix}\qquad \boldsymbol{M}=\begin{bmatrix}a & b\\ c & \end{bmatrix}$$

32. 若 $\boldsymbol{A}$ 是秩 1 矩阵，那么 $\boldsymbol{R}_0$ 的第二行是_____. 请举一例.

33. 若 $\boldsymbol{A}$ 的秩是 $r$，那么它包含可逆的 $r$ 阶子矩阵 $\boldsymbol{S}$. 事实上，保留矩阵的主元行和主元列，删去其余 $m-r$ 行和 $n-r$ 列，剩下的 $r$ 阶方阵即 $\boldsymbol{A}$ 的 $r$ 阶可逆子矩阵. 请分别找出下列 $\boldsymbol{A}$、$\boldsymbol{B}$、$\boldsymbol{C}$ 的一个 $r$ 阶可逆子矩阵.

$$\boldsymbol{A}=\begin{bmatrix}1 & 2 & 3\\ 1 & 2 & 4\end{bmatrix}\qquad \boldsymbol{B}=\begin{bmatrix}1 & 2 & 3\\ 2 & 4 & 6\end{bmatrix}\qquad \boldsymbol{C}=\begin{bmatrix}0 & 1 & 0\\ 0 & 0 & 0\\ 0 & 0 & 1\end{bmatrix}$$

34. 假设 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 有相同的最简行阶梯形矩阵 $\boldsymbol{R}_0$.

（1）证明：$\boldsymbol{A}$ 和 $\boldsymbol{B}$ 有相同的零空间和相同的行空间.

（2）根据题意，存在矩阵 $\boldsymbol{E}_i(i=1,2)$ 满足 $\boldsymbol{E}_1\boldsymbol{A}=\boldsymbol{R}_0,\boldsymbol{E}_2\boldsymbol{B}=\boldsymbol{R}_0$，那么 $\boldsymbol{A}$ 等于_____ 乘以 $\boldsymbol{B}$.

35. 基尔霍夫电流定律 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}=\boldsymbol{0}$ 说的是每个节点处的流入电流 = 流出电流. 节点 1 处有 $y_3=y_1+y_4$（图 3.1 中箭头表示的是电流方向）. 把 $\boldsymbol{A}^{\mathrm{T}}$ 化为 $\boldsymbol{R}$（3 行），并且找出 $\boldsymbol{A}^{\mathrm{T}}$ 零空间的三个基础解.

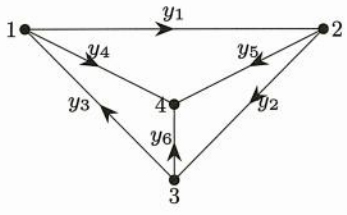


$$\boldsymbol{A}^{\mathrm{T}}=\begin{bmatrix}-1 & 0 & 1 & -1 & 0 & 0\\ 1 & -1 & 0 & 0 & -1 & 0\\ 0 & 1 & -1 & 0 & 0 & 1\\ 0 & 0 & 0 & 1 & 1 & 1\end{bmatrix}$$

图 3.1　有向图和其关联矩阵

36. 给定矩阵 $\boldsymbol{A}$，设 $\boldsymbol{C}$ 是 $\boldsymbol{A}$ 的 $r$ 个主元列，取 $\boldsymbol{C}^{\mathrm{T}}$（$r\times m$ 矩阵）的 $r$ 个主元列，再转置就得到了 $\boldsymbol{A}$ 的一个 $r\times r$ 可逆子矩阵 $\boldsymbol{S}$. 将上述方法应用于矩阵 $\boldsymbol{A}=\begin{bmatrix}1&2&3\\2&4&6\\2&4&7\end{bmatrix}$，找出 $3\times 2$ 矩阵 $\boldsymbol{C}$ 和 $2\times 2$ 可逆子矩阵 $\boldsymbol{S}$.

37. 请证明：$\boldsymbol{AB}$ 的列空间 $\mathcal{C}(\boldsymbol{AB})$ 是 $\boldsymbol{A}$ 的列空间 $\mathcal{C}(\boldsymbol{A})$ 的子空间，并由此导出结论：$\mathrm{rank}(\boldsymbol{AB})\leqslant\mathrm{rank}(\boldsymbol{A})$.

38. 设 $\boldsymbol{B}$ 的第 $j$ 列是前 $j-1$ 列的线性组合. 证明：$\boldsymbol{AB}$ 的第 $j$ 列可以通过相同的系数被 $\boldsymbol{AB}$ 的前 $j-1$ 列线性表出. 这说明 $\boldsymbol{AB}$ 相比于 $\boldsymbol{B}$ 没有新的主元列，由此可以证明 $\mathrm{rank}(\boldsymbol{AB})\leqslant\mathrm{rank}(\boldsymbol{B})$.

39.（重要）设 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 都是 $n$ 阶方阵，并且 $\boldsymbol{AB}=\boldsymbol{I}$. 请基于 $\mathrm{rank}(\boldsymbol{AB})\leqslant\mathrm{rank}(\boldsymbol{A})$ 这个事实来证明 $\mathrm{rank}(\boldsymbol{A})=n$. 从而 $\boldsymbol{A}$ 是可逆矩阵且 $\boldsymbol{B}$ 也是可逆矩阵，证明：$\boldsymbol{BA}=\boldsymbol{I}$（这不是显然的事实）！

40. 如果 $\boldsymbol{A}$ 是 $2\times 3$ 矩阵，$\boldsymbol{B}$ 是 $3\times 2$ 矩阵，满足 $\boldsymbol{AB}=\boldsymbol{I}_2$. 基于习题 38 关于矩阵乘积的秩的不等式，请证明 $\boldsymbol{BA}\neq\boldsymbol{I}_3$. 请举例说明存在满足上述条件的矩阵 $\boldsymbol{A}$ 和 $\boldsymbol{B}$. 一般情形也是成立的：若 $m<n$，矩阵的右逆不是左逆.

41. 对于下述矩阵 $\boldsymbol{A}$、$\boldsymbol{B}$、$\boldsymbol{C}$，它们的零空间矩阵（即由基础解系排成的矩阵）分别是什么？

所有分块都是 $2\times 2$ 矩阵 $\quad\boldsymbol{A}=\begin{bmatrix}\boldsymbol{I}&\boldsymbol{I}\end{bmatrix}\quad\boldsymbol{B}=\begin{bmatrix}\boldsymbol{I}&\boldsymbol{I}\\\boldsymbol{0}&\boldsymbol{0}\end{bmatrix}\quad\boldsymbol{C}=\begin{bmatrix}\boldsymbol{I}&\boldsymbol{I}&\boldsymbol{I}\end{bmatrix}$

42. 设 $\boldsymbol{A}$ 是秩为 $r$ 的 $m\times n$ 矩阵，它的最简行阶梯形矩阵（包含所有零行）是 $\boldsymbol{R}_0$. 令 $\boldsymbol{Z}=(\mathbf{rref}(\boldsymbol{R}_0^{\mathrm{T}}))^{\mathrm{T}}$，它是 $\boldsymbol{R}_0$ 转置的最简行阶梯形矩阵再取转置. 请确定 $\boldsymbol{Z}$ 是什么样的矩阵，即刻画它的尺寸、各个位置的分量等信息.

43.（推荐）设 $\boldsymbol{R}_0=\begin{bmatrix}\boldsymbol{I}&\boldsymbol{F}\\\boldsymbol{0}&\boldsymbol{0}\end{bmatrix}$ 是秩为 $r$ 的 $m\times n$ 矩阵，左上角是单位阵.

（1）这四个分块分别是什么尺寸？用 $m$、$n$、$r$ 来表示.

（2）若 $r=m$，则 $\boldsymbol{R}_0$ 没有零行；请问 $\boldsymbol{R}_0$ 的右逆是什么？也就是说找一个矩阵 $B$ 满足 $\boldsymbol{R}_0\boldsymbol{B}=\boldsymbol{I}$.

（3）若 $r=n$，请问 $\boldsymbol{R}_0$ 的左逆是什么？也就是说找一个矩阵 $\boldsymbol{C}$ 满足 $\boldsymbol{CR}_0=\boldsymbol{I}$，此时 $\boldsymbol{F}$ 和它下面的 $\boldsymbol{0}$ 列都不存在.

（4）$\boldsymbol{R}_0^{\mathrm{T}}$ 的最简行阶梯形矩阵是什么（需要说明它的尺寸）？

（5）$\boldsymbol{R}_0^{\mathrm{T}}\boldsymbol{R}_0$ 的最简行阶梯形矩阵是什么（需要说明它的尺寸）？

44. 假设我们可以类似于做初等行变换那样对矩阵做初等列变换，那么秩为 $r$ 的 $m\times n$ 矩阵 $\boldsymbol{A}$ 的“行-列最简矩阵”是什么？

45. 对矩阵 $\boldsymbol{A}=\begin{bmatrix}1&4&7\\2&5&8\\3&6&9\end{bmatrix}$ 作矩阵分解：$\boldsymbol{A}=\boldsymbol{CR}=\boldsymbol{CW}^{-1}\boldsymbol{B}$.

46. 对于分块矩阵 $\begin{bmatrix} \boldsymbol{W} \\ \boldsymbol{J} \end{bmatrix} \begin{bmatrix} \boldsymbol{W}^{-1} \end{bmatrix} \begin{bmatrix} \boldsymbol{W} & \boldsymbol{H} \end{bmatrix} = \begin{bmatrix} \boldsymbol{W} & \boldsymbol{H} \\ \boldsymbol{J} & \boldsymbol{J}\boldsymbol{W}^{-1}\boldsymbol{H} \end{bmatrix}$，第一行左乘哪个矩阵等于第二行？

## 3.3　方程组 $Ax = b$ 的解集

（1）$\boldsymbol{Ax} = \boldsymbol{b}$ 的解集是：$\boldsymbol{x}$ = 特解$\boldsymbol{x}_p$ + $\boldsymbol{A}$的零空间中所有向量$\boldsymbol{x}_n$.
（2）用消元法把 $\boldsymbol{Ax} = \boldsymbol{b}$ 转化为 $\boldsymbol{R}_0\boldsymbol{x} = \boldsymbol{d}$. 若 $\boldsymbol{d}$ 在 $\boldsymbol{R}_0$ 零行的分量是 0，则方程组有解.
（3）当 $\boldsymbol{R}_0\boldsymbol{x} = \boldsymbol{d}$ 有解时，通过令所有的自由变元为零，可以得到方程组的一个特解.
（4）当 $\boldsymbol{A}$ 的零空间 $\mathcal{N}(\boldsymbol{A}) = \{\boldsymbol{0}\}$ 时，$\boldsymbol{A}$ 列满秩，即秩 $r$ = 列数$n$，此时 $\boldsymbol{A}$ 没有自由变元.
（5）当 $\boldsymbol{A}$ 的行空间 $\mathcal{C}(\boldsymbol{A}) = \mathbb{R}^m$ 时，$\boldsymbol{A}$ 行满秩，即秩 $r$ = 行数$m$，此时 $\boldsymbol{Ax} = \boldsymbol{b}$ 一定有解.

3.2 节完成了对齐次线性方程组 $\boldsymbol{Ax} = \boldsymbol{0}$ 的求解；消元法把这个问题转化成解方程组 $\boldsymbol{R}_0\boldsymbol{x} = \boldsymbol{0}$. 对自由变元赋以特殊值（0 或 1），然后通过回代法就可以确定主元的值. 我们并没有关注方程组等号右边的向量，因为无论如何变都是零向量，而且 $\boldsymbol{R}_0$ 的零行也不会“制造麻烦”.

而当 $\boldsymbol{b} \neq \boldsymbol{0}$ 时，方程组等号左边做的初等行变换在方程组等号右边也必须同步进行. 于是 $\boldsymbol{Ax} = \boldsymbol{b}$ 就转化成有相同解集的更简单的方程组 $\boldsymbol{R}_0\boldsymbol{x} = \boldsymbol{d}$. 从矩阵初等行变换的操作层面上来说，我们只需要把 $\boldsymbol{b}$ 作为额外的一列加到矩阵 $\boldsymbol{A}$ 右边. 我们看一个例子

$$\begin{bmatrix} 1 & 3 & 0 & 2 \\ 0 & 0 & 1 & 4 \\ 1 & 3 & 1 & 6 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} 1 \\ 6 \\ 7 \end{bmatrix} \qquad \text{增广矩阵是} \qquad \begin{bmatrix} 1 & 3 & 0 & 2 & 1 \\ 0 & 0 & 1 & 4 & 6 \\ 1 & 3 & 1 & 6 & 7 \end{bmatrix} = \begin{bmatrix} \boldsymbol{A} & \boldsymbol{b} \end{bmatrix}$$

把向量 $\begin{bmatrix} b_1 & b_2 & b_3 \end{bmatrix}^{\mathrm{T}}$ “增广”在 $\boldsymbol{A}$ 的右侧得到增广矩阵 $\begin{bmatrix} \boldsymbol{A} & \boldsymbol{b} \end{bmatrix}$. 我们对 $\boldsymbol{A}$ 做初等行变换转化成 $\boldsymbol{R}_0$ 时，$\boldsymbol{b}$ 同步转化成了 $\boldsymbol{d}$.

在这个例子里面，把第 3 行减去第 1 行和第 2 行，这导致 $\boldsymbol{R}_0$ 的第 3 行是零行；同样的初等行变换把 $\boldsymbol{b} = \begin{bmatrix} 1 & 6 & 7 \end{bmatrix}^{\mathrm{T}}$ 转化成新向量 $\boldsymbol{d} = \begin{bmatrix} 1 & 6 & 0 \end{bmatrix}^{\mathrm{T}}$：

$$\begin{bmatrix} 1 & 3 & 0 & 2 \\ 0 & 0 & 1 & 4 \\ 0 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} 1 \\ 6 \\ 0 \end{bmatrix} \qquad \text{增广矩阵是} \qquad \begin{bmatrix} 1 & 3 & 0 & 2 & 1 \\ 0 & 0 & 1 & 4 & 6 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix} = \begin{bmatrix} \boldsymbol{R}_0 & \boldsymbol{d} \end{bmatrix}$$

最后一行是极其关键的. 第三行对应的方程是 $0 = 0$，所以方程组才有解. 矩阵 $\boldsymbol{A}$ 的第 1 行加第 2 行等于第 3 行，那么要使 $\boldsymbol{Ax} = \boldsymbol{b}$ 有解，方程右边就必须满足 $b_1 + b_2 = b_3$. 对 $\boldsymbol{b}$ 而言，最重要的性质就是 $1 + 6 = 7$，如此我们才能把第 3 个方程转化成 $0 = 0$. 虽然都是极为简单的事实，但这正是关键之处，要多加体会.

对于一般的 $\boldsymbol{b}=\begin{bmatrix}b_1 & b_2 & b_3\end{bmatrix}^{\mathrm{T}}$，有类似的增广矩阵：

$$\begin{bmatrix}\boldsymbol{A} & \boldsymbol{b}\end{bmatrix}=\begin{bmatrix}1&3&0&2&b_1\\0&0&1&4&b_2\\1&3&1&6&b_3\end{bmatrix}\longrightarrow\begin{bmatrix}1&3&0&2&b_1\\0&0&1&4&b_2\\0&0&0&0&b_3-b_1-b_2\end{bmatrix}=\begin{bmatrix}\boldsymbol{R}_0 & \boldsymbol{d}\end{bmatrix}$$

只有 $b_3-b_1-b_2=0$（或者等价地，$b_1+b_2=b_3$）时第三个方程才是 $0=0$.

### 3.3.1 方程组的特解 $\boldsymbol{x}_p$：$\boldsymbol{Ax}_p=\boldsymbol{b}$

还是看上面的例子. 令所有自由变元都是 0：$x_2=x_4=0$，很容易就得到方程组 $\boldsymbol{Ax}_p=\boldsymbol{b}$ 的一个解. 两个非零方程直接解出主元 $x_1=1$ 和 $x_3=6$. 因此 $\boldsymbol{Ax}=\boldsymbol{b}$（等价地，$\boldsymbol{R}_0\boldsymbol{x}=\boldsymbol{d}$）的一个解是 $\boldsymbol{x}_p=\begin{bmatrix}1&0&6&0\end{bmatrix}^{\mathrm{T}}$. 这个特殊的解是我个人最喜欢的；**自由变元都等于0，由 $\boldsymbol{d}$ 解出主元.**[①]

**方程组要有解，$\boldsymbol{d}$ 在 $\boldsymbol{R}_0$ 零行处的分量必须是 0. 又因为 $\boldsymbol{R}_0$ 的主元列的非零行构成单位阵，$\boldsymbol{x}_{\text{particular}}$ 的主元等于 $\boldsymbol{d}$ 对应位置的分量：**

$$\boldsymbol{R}_0\boldsymbol{x}_p=\begin{bmatrix}\mathbf{1}&3&\mathbf{0}&2\\\mathbf{0}&0&\mathbf{1}&4\\0&0&0&0\end{bmatrix}\begin{bmatrix}\mathbf{1}\\0\\\mathbf{6}\\0\end{bmatrix}=\begin{bmatrix}\mathbf{1}\\\mathbf{6}\\0\end{bmatrix}=\boldsymbol{d}$$

主元 **1, 6**
自由变元 **0, 0**
$\boldsymbol{x}_{\text{particular}}=\begin{bmatrix}1&0&6&0\end{bmatrix}^{\mathrm{T}}$

值得关注的一件事情是如何选取自由变元（例如都取 0）以及如何进一步解出主元. 做初等行变换把系数矩阵转化成 $\boldsymbol{R}_0$ 后，这些步骤都能很快完成. 当自由变元都取 0 时，$\boldsymbol{x}_p$ 中的主元取值已然包含在方程右边的 $\boldsymbol{d}$ 中.

| | |
|---|---|
| 一个 $\boldsymbol{x}_{\text{particular}}$ | $\boldsymbol{Ax}_p=\boldsymbol{b}$的一个特解 |
| 所有 $\boldsymbol{x}_{\text{nullspace}}$ | $\boldsymbol{Ax}_n=\boldsymbol{0}$ 的 $n-r$ 个基础解 |

$\boldsymbol{Ax}=\boldsymbol{b}$ 的一个特解是 $\begin{bmatrix}1&0&6&0\end{bmatrix}^{\mathrm{T}}$. 零空间的 $4-2=2$ 个基础解在 3.2节已经给出，它来自 $\boldsymbol{R}_0$ 的两个自由列，更明确一点，那就是改变自由列中 3（第 2 列）、2 和 4（第 4 列）的符号. **需要再次强调的是，方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 的解集是 $\left\{\boldsymbol{x}_p+\boldsymbol{x}_n:\boldsymbol{x}_n\in\mathcal{N}(\boldsymbol{A})\right\}$.**

解是
一个$\boldsymbol{x}_p$+所有$\boldsymbol{x}_n$
$\boldsymbol{x}_p$是$\boldsymbol{Ax}=\boldsymbol{b}$的特解
$\boldsymbol{x}_n$取遍$\mathcal{N}(\boldsymbol{A})$

$$\boldsymbol{x}=\boldsymbol{x}_p+\boldsymbol{x}_n=\begin{bmatrix}1\\0\\6\\0\end{bmatrix}+x_2\begin{bmatrix}-3\\1\\0\\0\end{bmatrix}+x_4\begin{bmatrix}-2\\0\\-4\\1\end{bmatrix}$$

① 译者注：理论上来说，非齐次方程组的任何一个解都可以扮演“特解”的角色，没有本质的区别. 但是本文的“特解”（particular solution）特指非齐次方程组的自由变元都是 0 的解. 和齐次方程组类比，“基础解”（special solution）特指齐次方程组某个自由变元是 1、其他自由变元是 0 的解. 趁此机会，我们对 complete solution 也作一点注释. 事实上，原文的这个术语含义并不非常明确. 复数形式 complete solutions 一般都指方程组的解的全体，所以译者选择翻译成“解集”；然而其单数形式 complete solution 就不太好说，大多数时候也是指“解集”，但是有的时候并不是，对这些少数情况译者猜测，作者大概是为了表达本节求解的是非齐次方程组，齐次方程组 $\boldsymbol{Ax}=0$ 的解——也就是零空间的元素——只是其中的一部分，并不完整；需要再取一个特解组合起来，才构成非齐次方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 的“完整的”解.

问题：若 $\boldsymbol{A}$ 是可逆方阵，此时 $m=n=r$. 那么 $\boldsymbol{x}_p$ 和 $\boldsymbol{x}_n$ 是什么？

解答：$\boldsymbol{Ax}=\boldsymbol{b}$ 的特解存在且唯一，$\boldsymbol{x}_p=\boldsymbol{A}^{-1}\boldsymbol{b}$. 而 $\boldsymbol{A}$ 可逆，所以没有自由变元，齐次方程组 $\boldsymbol{Ax}=\boldsymbol{0}$ 没有基础解. $\boldsymbol{R}_0$ 没有零行，零空间 $\mathcal{N}(\boldsymbol{A})=\{\boldsymbol{0}\}$. 因此，$\boldsymbol{Ax}=\boldsymbol{b}$ 的解是 $\boldsymbol{x}=\boldsymbol{x}_p+\boldsymbol{x}_n=\boldsymbol{A}^{-1}\boldsymbol{b}+\boldsymbol{0}$.

在第 2 章中，因为 $\boldsymbol{A}$ 是可逆矩阵，所以我们没涉及零空间. $\boldsymbol{A}$ 的最简行阶梯形矩阵是单位阵 $\boldsymbol{I}$，$\begin{bmatrix}\boldsymbol{A} & \boldsymbol{b}\end{bmatrix}$ 转化为 $\begin{bmatrix}\boldsymbol{I} & \boldsymbol{A}^{-1}\boldsymbol{b}\end{bmatrix}$. 因此，$\boldsymbol{Ax}=\boldsymbol{b}$ 即 $\boldsymbol{x}=\boldsymbol{A}^{-1}\boldsymbol{b}=\boldsymbol{d}$. 这是很特殊的情况，从这个角度而言，可逆方阵是性质最好的矩阵.

对于小尺寸的矩阵，把 $\begin{bmatrix}\boldsymbol{A} & \boldsymbol{b}\end{bmatrix}$ 简化为 $\begin{bmatrix}\boldsymbol{R}_0 & \boldsymbol{d}\end{bmatrix}$ 的过程手动计算也完全可行. 对于大矩阵，使用 MATLAB 则是更明智的选择. 在 MATLAB 中，用反斜杠“\”这个命令，即 $\boldsymbol{x}=\boldsymbol{A}\backslash\boldsymbol{b}$，可以求出非齐次方程组的一个特解（未必是我们用上面的方法得到的特解）. 这里我们举一个例子，系数矩阵列满秩，从而其两列都是主元列.

**例 3.11**　矩阵 $\boldsymbol{A}=\begin{bmatrix}1 & 1\\ 1 & 2\\ -2 & -3\end{bmatrix}, \boldsymbol{b}=\begin{bmatrix}b_1\\ b_2\\ b_3\end{bmatrix}$. $(b_1,b_2,b_3)$ 满足什么条件时，$\boldsymbol{Ax}=\boldsymbol{b}$ 有解？

**解**　对增广矩阵 $\begin{bmatrix}\boldsymbol{A} & \boldsymbol{b}\end{bmatrix}$ 作消元法即可. $\begin{bmatrix}\boldsymbol{A} & \boldsymbol{b}\end{bmatrix}$ 的第二行减去第一行，第三行加上第一行的两倍；然后对此时的矩阵，第一行减去第二行，第三行加上第二行，就得到了 $\begin{bmatrix}\boldsymbol{R}_0 & \boldsymbol{d}\end{bmatrix}$：

$$\begin{bmatrix}1 & 1 & b_1\\ 1 & 2 & b_2\\ -2 & -3 & b_3\end{bmatrix}\longrightarrow\begin{bmatrix}1 & 1 & b_1\\ 0 & 1 & b_2-b_1\\ 0 & -1 & b_3+2b_1\end{bmatrix}\longrightarrow\begin{bmatrix}1 & 0 & 2b_1-b_2\\ 0 & 1 & b_2-b_1\\ 0 & 0 & b_3+b_1+b_2\end{bmatrix}=\begin{bmatrix}\boldsymbol{R}_0 & \boldsymbol{d}\end{bmatrix}$$

原方程组有解当且仅当第三个方程为 $0=0$，当且仅当 $b_3+b_1+b_2=0$. 这也是 $\boldsymbol{b}$ 属于 $\boldsymbol{A}$ 的列空间 $\mathcal{C}(\boldsymbol{A})$ 所需要满足的条件. 在此条件下，$\boldsymbol{Ax}=\boldsymbol{b}$ 有解. 我们也可以换个角度思考，注意到 $\boldsymbol{A}$ 的三个行向量加起来等于零向量，所以为了保持行（每一行是一个方程）的一致性，$\boldsymbol{b}$ 的分量加起来也必须等于 0.

因为 $n-r=2-2=0$，所以这个例子没有自由变元，齐次方程组 $\boldsymbol{Ax}=\boldsymbol{0}$ 也没有基础解，它只有唯一的零解 $\boldsymbol{x}_n=\boldsymbol{0}$. $\boldsymbol{Ax}=\boldsymbol{b}$ 和 $\boldsymbol{R}_0\boldsymbol{x}=\boldsymbol{d}$ 的特解就是最终的列向量 $\boldsymbol{d}$ 的前两行：

$$r=n\quad \boldsymbol{Ax}=\boldsymbol{b}\text{的一个解是}\quad \boldsymbol{x}=\boldsymbol{x}_p+\boldsymbol{x}_n=\begin{bmatrix}2b_1-b_2\\ b_2-b_1\end{bmatrix}+\begin{bmatrix}0\\ 0\end{bmatrix}$$

如果 $b_3+b_1+b_2\neq 0$，那么 $\boldsymbol{Ax}=\boldsymbol{b}$ 没有解（$\boldsymbol{x}_p$ 和 $\boldsymbol{x}$ 都不存在）.

这是极其重要、极其典型的一种情况：$\boldsymbol{A}$ 列满秩. 每一列都有主元，秩 $r=n$. 矩阵是竖长形的（$m\geqslant n$）. 当我们用初等行变换把矩阵转化成最简行梯阶型矩阵 $\boldsymbol{R}_0$ 时，它的前 $n$ 行是单位矩阵：

$$\text{列满秩 } r=n\qquad \boldsymbol{R}_0=\begin{bmatrix}\boldsymbol{I}\\ \boldsymbol{0}\end{bmatrix}=\begin{bmatrix}n\times n\text{单位矩阵}\\ m-n\text{个零行}\end{bmatrix}\tag{3.2}$$

列满秩矩阵 $\boldsymbol{A}$ 的列向量线性无关，零空间 $\mathcal{N}(\boldsymbol{A})=\{\boldsymbol{0}\}$.

我们把这类矩阵从各个角度做一个总结.

> 列满秩（$r=n$）矩阵$\boldsymbol{A}$有下述性质：
> （1）$\boldsymbol{A}$的列向量线性无关，所有列都是主元列；没有自由变元.
> （2）$\boldsymbol{A}$的零空间 $\mathcal{N}(\boldsymbol{A})$ 只包含零向量.
> （3）若方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 有解，则它只有唯一解.

只有当 $\boldsymbol{x}=\boldsymbol{0}$ 时，$\boldsymbol{Ax}$ 才等于 $\boldsymbol{0}$. 在不久的将来，上述列表将增加一条：若 $\boldsymbol{A}$ 的秩是 $n$，则 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 是可逆矩阵. 当然，$\boldsymbol{A}$ 可能有很多行.

在这种情况下，$\mathcal{N}(\boldsymbol{A})$ 只有零向量. 方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 只有（如果存在的话）唯一解. $\boldsymbol{R}_0$ 有 $m-n$ 个零行；要使方程组有解，这些零行都必须对应于方程 $0=0$，所以我们需要对 $\boldsymbol{b}$ 提 $m-n$ 个条件，以使 $\boldsymbol{b}$ 属于 $\boldsymbol{A}$ 的列空间. 简而言之，若 $\boldsymbol{A}$ 列满秩，那么方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 要么没有解，要么有唯一解.

### 3.3.2 行满秩和解集

另一种极端情况是行满秩. 此时 $\boldsymbol{Ax}=\boldsymbol{b}$ 要么有唯一解，要么有无穷多解. 矩阵 $\boldsymbol{A}$ 是扁宽形的（$m\leqslant n$）. 若 $r=m$，我们称矩阵 $A$ 是行满秩矩阵. 它的行向量线性无关，每一行都有一个主元.

**例 3.12** 设方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 有 3 个未知数，但是只有 2 个方程：

$$\text{行满秩}\qquad \begin{cases} x+\quad y+z=3 \\ x+\ 2y-z=4 \end{cases}\qquad \text{秩 } r=m=2$$

每个方程都定义了 $xyz$ 空间中的一个平面，这两个平面不平行，相交于一条直线. 这条直线就是我们通过消元法要找的方程组的解集. 特解是该直线上的一个点，把它加上零空间中的向量，得到的向量将沿着这条直线移动，见图 3.2. $\boldsymbol{x}=\boldsymbol{x}_p+$（所有 $\boldsymbol{x}_n$）给出了由方程的解构成的整条直线.

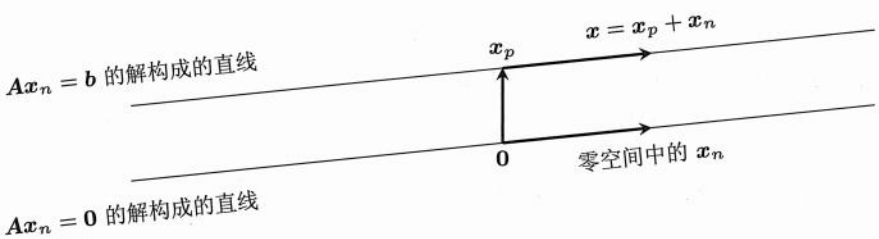


图 3.2 完整解和特解、零解的关系

注：完整解 $\boldsymbol{x}=$ 一个特解 $\boldsymbol{x}_p+$ 所有的零解 $\boldsymbol{x}_n$.

我们通过对增广矩阵 $\begin{bmatrix}\boldsymbol{A} & \boldsymbol{b}\end{bmatrix}$ 作消元法来求解 $\boldsymbol{x}_p$ 和 $\boldsymbol{x}_n$：

$$\begin{bmatrix}1&1&1&3\\1&2&-1&4\end{bmatrix}\longrightarrow\begin{bmatrix}1&1&1&3\\0&1&-2&1\end{bmatrix}\longrightarrow\begin{bmatrix}1&0&3&2\\0&1&-2&1\end{bmatrix}=\begin{bmatrix}\boldsymbol{R} & \boldsymbol{d}\end{bmatrix}$$

令自由变元 $x_3=0$，从 $\boldsymbol{d}$ 直接可得特解 $\begin{bmatrix}2 & 1 & 0\end{bmatrix}^{\mathrm{T}}$. 令 $x_3=1$，由 $\boldsymbol{R}$ 的自由列可以直接得到 $-x_1=3$ 和 $-x_2=-2$，因此零空间的基础解为 $\boldsymbol{s}=\begin{bmatrix}-3 & 2 & 1\end{bmatrix}^{\mathrm{T}}$.

当我们求出 $\boldsymbol{x}_p$ 和 $\boldsymbol{s}$ 之后，再验证一下 $\boldsymbol{A}\boldsymbol{x}_p=\boldsymbol{b}$ 和 $\boldsymbol{A}\boldsymbol{s}=\boldsymbol{0}$，这显然是明智的做法：

$$\begin{aligned} 2+1&=3 \qquad & -3+2+1&=0\\ 2+2&=4 & -3+4-1&=0 \end{aligned}$$

零解 $\boldsymbol{x}_n$ 是 $\boldsymbol{s}$ 的任意常数倍. 那么解集就从 $\boldsymbol{x}_p$ 出发，沿着所有解构成的直线移动. 此处我们再示范一次如何写下解答：

$$\begin{matrix}\text{解集}\\ \text{特解 + 零空间}\end{matrix} \qquad \boldsymbol{x}=\boldsymbol{x}_p+\boldsymbol{x}_n=\begin{bmatrix}2\\1\\0\end{bmatrix}+x_3\begin{bmatrix}-3\\2\\1\end{bmatrix}$$

方程组的解构成的直线在图 3.2 中已经画出来了，虽然我们令 $x_3=0$ 得到特解 $\boldsymbol{x}_p$，然而事实上这条直线上的任意一个点都可以选作特解.

注意：非齐次方程组的特解不能随便乘一个常数：$\boldsymbol{A}(c\boldsymbol{x}_p)=c\boldsymbol{A}\boldsymbol{x}_p=c\boldsymbol{b}$，除非 $c=1$，否则 $c\boldsymbol{b}\neq\boldsymbol{b}$，从而 $c\boldsymbol{x}_p$ 不再是方程组的解.

> 行满秩（$r=m$）矩阵$\boldsymbol{A}$有下述性质：
> （1）$\boldsymbol{A}$所有行都有主元，$\boldsymbol{R}_0$ 没有零行，$\boldsymbol{R}_0=\boldsymbol{R}$.
> （2）对任意$\boldsymbol{b}$, $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$都有解.
> （3）$\boldsymbol{A}$的列空间是整个$\mathbb{R}^m$.
> （4）若$m<n$，则对任意 $\boldsymbol{b}\in\mathbb{R}^m$，方程组$\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$有无穷多解.

在行满秩的情况下，矩阵有 $m$ 个主元，$m$ 个行向量线性无关. 也就是说，$\boldsymbol{A}^{\mathrm{T}}$ 的列向量线性无关，$\boldsymbol{A}^{\mathrm{T}}$ 的零空间只包含零向量.

一般情况下，方程组的解集按照矩阵的秩 $r$ 分类有四种情况：

| | | | | | |
|---|---|---|---|---|---|
| $r=m$ | 且 | $r=n$ | 可逆方阵 | $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ | 有唯一解 |
| $r=m$ | 且 | $r<n$ | 扁宽形矩阵 | $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ | 有无穷多解 |
| $r<m$ | 且 | $r=n$ | 竖长形矩阵 | $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ | 无解或有唯一解 |
| $r<m$ | 且 | $r<n$ | 不满秩 | $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ | 无解或有无穷多解 |

最简行阶梯形矩阵 $\boldsymbol{R}_0$ 和 $\boldsymbol{A}$ 一样是行满秩的. 当主元列在前时，我们把上述四种情况可以表达得更清晰. 要使 $\boldsymbol{R}_0\boldsymbol{x}=\boldsymbol{d}$ 和 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 有解，$\boldsymbol{d}$ 的后 $m-r$ 个分量必须都是 0. 设 $\boldsymbol{F}$ 是 $\boldsymbol{R}_0$ 的自由列，则

| $\boldsymbol{R}_0$ 的四种情形 | $\begin{bmatrix}\boldsymbol{I}\end{bmatrix}$ | $\begin{bmatrix}\boldsymbol{I} & \boldsymbol{F}\end{bmatrix}$ | $\begin{bmatrix}\boldsymbol{I}\\\boldsymbol{0}\end{bmatrix}$ | $\begin{bmatrix}\boldsymbol{I} & \boldsymbol{F}\\\boldsymbol{0} & \boldsymbol{0}\end{bmatrix}$ |
|---|---|---|---|---|
| 秩 | $r=m=n$ | $r=m<n$ | $r=n<m$ | $r<m, r<n$ |

第 1、第 2 种情形行满秩：$r=m$；第 1、第 3 种情形列满秩：$r=n$.

本节在整本书中都相当重要；在结束之前，我们对计算线性代数做一些说明. 线性方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 无疑是最基础的对象. 在实际操作中，为了速度和数值稳定性，消元的步骤会适当地选取和排序（例如选取每一列中绝对值最大的非零数作为主元）. 我们可以在笔记本电脑上解决 1000 阶的系统（允许单精度或双精度下的舍入误差）. 超级计算机能解决规模更大的系统；但无论计算机计算能力有多强，它能精确处理的矩阵的大小是有限制的. 那么，如何突破这一限制呢？

令人惊讶的答案是随机线性代数. 我们对 $\boldsymbol{A}$ 的列向量进行抽样，接受由此产生的误差. 当然实际上我们要处理的矩阵并非完全随机，但是使用这一方法，最终结果却出奇地好. 通常，我们可以把 $\boldsymbol{A}$ 近似地分解成三个矩阵乘积的形式，即 $\boldsymbol{A}\approx\boldsymbol{CUR}$，$\boldsymbol{C}$ 来自对 $\boldsymbol{A}$ 的列向量进行抽样，$\boldsymbol{R}$ 来自 $\boldsymbol{A}$ 的行向量.

较小的矩阵 $\boldsymbol{U}$ 随着抽样计算的进行逐渐地被构建出来. 在大多数情况下，近似解的精确度以极高的概率精确得令人吃惊.

线性代数至今仍然充满活力. 计算的需求（速度和准确性）催生了新的思想. 对于特征值和奇异值来说，也是如此——这在本书的后续部分将会详细论述.

## 例 题 总 结

3.3 A. 本题在一个更高的层面上把消元法（包括主元列和回代法）和列空间-零空间-秩-可解性联系在一起. 令矩阵 $\boldsymbol{A}=\begin{bmatrix}1&2&3&5\\2&4&8&12\\3&6&7&13\end{bmatrix}$，秩为 2.

$$\text{方程组}\boldsymbol{Ax}=\boldsymbol{b}\quad\text{即}\quad\begin{cases}x_1+&2x_2+&3x_3+&5x_4=b_1\\2x_1+&4x_2+&8x_3+&12x_4=b_2\\3x_1+&6x_2+&7x_3+&13x_4=b_3\end{cases}$$

1. 将 $\begin{bmatrix}\boldsymbol{A}&\boldsymbol{b}\end{bmatrix}$ 转化为 $\begin{bmatrix}\boldsymbol{U}&\boldsymbol{c}\end{bmatrix}$，其中 $\boldsymbol{U}$ 是行阶梯形矩阵，那么方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 等价于 $\boldsymbol{Ux}=\boldsymbol{c}$.
2. 当 $b_1$、$b_2$、$b_3$ 满足什么条件时，$\boldsymbol{Ax}=\boldsymbol{b}$ 有解？
3. $\boldsymbol{A}$ 的列空间是 $\boldsymbol{R}^3$ 中哪个平面？
4. $\boldsymbol{A}$ 的零空间是什么？基础解系是 $\boldsymbol{R}^4$ 中哪几个向量？
5. 将 $\begin{bmatrix}\boldsymbol{U}&\boldsymbol{c}\end{bmatrix}$ 转化为 $\begin{bmatrix}\boldsymbol{R}_0&\boldsymbol{d}\end{bmatrix}$；基础解系基于 $\boldsymbol{R}_0$，特解基于 $\boldsymbol{d}$.
6. 求出 $\boldsymbol{Ax}=\begin{bmatrix}0&6&-6\end{bmatrix}^{\mathrm{T}}$ 的一个特解，并写出它的解集.

**解**

1. 消元法所乘的系数分别是 $-2$、$-3$ 和 1：

$$\begin{bmatrix}1&2&3&5&b_1\\2&4&8&12&b_2\\3&6&7&13&b_3\end{bmatrix}\longrightarrow\left[\begin{array}{cccc|c}1&2&3&5&b_1\\0&0&2&2&b_2-2b_1\\0&0&-2&-2&b_3-3b_1\end{array}\right]\longrightarrow\left[\begin{array}{cccc|c}1&2&3&5&b_1\\0&0&2&2&b_2-2b_1\\0&0&0&0&b_3+b_2-5b_1\end{array}\right]$$

2. 上述最后一个矩阵的最后一行说明原方程有解的条件是 $b_3+b_2-5b_1=0$.

3. 第一种刻画：由于 $\boldsymbol{A}$ 的主元列是第 1 和第 3 列，所以列空间是主元列 $\begin{bmatrix}1 & 2 & 3\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}3 & 8 & 7\end{bmatrix}^{\mathrm{T}}$ 的所有线性组合构成的平面.

第二种刻画：$\boldsymbol{A}$ 的列空间包含了所有满足 $b_3+b_2-5b_1=0$ 的向量，这是因为当 $\boldsymbol{b}$ 满足此条件时，$\boldsymbol{Ax}=\boldsymbol{b}$ 有解，而该方程组有解当且仅当 $\boldsymbol{b}\in C(\boldsymbol{A})$. $\boldsymbol{A}$ 的所有列向量都处于方程 $b_3+b_2-5b_1=0$ 决定的平面；这个方程也是第一种刻画中的平面所满足的方程.

4. 为了求得齐次方程组的基础解系，我们分别令自由变元 $x_2=1,x_4=0$ 和 $x_2=0,x_4=1$:

$\boldsymbol{Ax}=\boldsymbol{0}$的基础解系可由
回代$\boldsymbol{Ux}=\boldsymbol{0}$的解得到
或者改变$\boldsymbol{R}$中$\boldsymbol{2,2,1}$的正负号得到

$$\boldsymbol{s}_1=\begin{bmatrix}-2\\1\\0\\0\end{bmatrix}\quad \boldsymbol{s}_2=\begin{bmatrix}-2\\0\\-1\\1\end{bmatrix}$$

零空间 $\mathcal{N}(\boldsymbol{A})=\{c_1\boldsymbol{s}_1+c_2\boldsymbol{s}_2:c_1,c_2\in\mathbb{R}\}$.

5. $\begin{bmatrix}\boldsymbol{U} & \boldsymbol{c}\end{bmatrix}=\begin{bmatrix}1&2&3&5&\boldsymbol{0}\\0&0&2&2&\boldsymbol{6}\\0&0&0&0&\boldsymbol{0}\end{bmatrix}\longrightarrow\begin{bmatrix}\boldsymbol{R}_0 & \boldsymbol{d}\end{bmatrix}=\begin{bmatrix}1&2&0&2&\boldsymbol{-9}\\0&0&1&1&\boldsymbol{3}\\0&0&0&0&\boldsymbol{0}\end{bmatrix}$. 把 $\boldsymbol{U}$ 的第 3 列 $\begin{bmatrix}3\\2\\0\end{bmatrix}$ 做初等行变换变成 $\begin{bmatrix}0\\1\\0\end{bmatrix}$ 就得到了最简行阶梯形矩阵 $\boldsymbol{R}_0$. 同时方程右侧，或者说增广矩阵的最后一列 $\boldsymbol{c}=\begin{bmatrix}0 & 6 & 0\end{bmatrix}^{\mathrm{T}}$ 转化为 $\boldsymbol{d}=\begin{bmatrix}-9 & 3 & 0\end{bmatrix}^{\mathrm{T}}$. 这说明特解$\boldsymbol{x}_p$ 中含有 $-9$ 和 3.

6. $\boldsymbol{x}_p=\begin{bmatrix}\boldsymbol{-9} & 0 & \boldsymbol{3} & 0\end{bmatrix}^{\mathrm{T}}$ 正是通过令自由变元 $x_2=x_4=0$ 得到的特解. $\boldsymbol{Ax}=\begin{bmatrix}0 & 6 & -6\end{bmatrix}^{\mathrm{T}}$ 的解集是 $\left\{\boldsymbol{x}=\boldsymbol{x}_p+\boldsymbol{x}_n=\boldsymbol{x}_p+c_1\boldsymbol{s}_1+c_2\boldsymbol{s}_2:c_1,c_2\in\mathbb{R}\right\}$.

3.3 B. 对于特定的 $\boldsymbol{b}$ 和方程组 $\boldsymbol{Ax}=\boldsymbol{b}$，以及如下四个条件中的每一个，分别能得到关于 $m$、$n$、$r$，甚至 $\boldsymbol{A}$ 和 $\boldsymbol{b}$ 自身的哪些结论？

1. 方程组只有唯一解.

2. $\boldsymbol{Ax}=\boldsymbol{b}$ 的所有解都形如 $\boldsymbol{x}=\begin{bmatrix}2\\1\end{bmatrix}+c\begin{bmatrix}1\\1\end{bmatrix}(c\in\mathbb{R})$.

3. 方程组没有解.

4. $\boldsymbol{Ax}=\boldsymbol{b}$ 的所有解都形如 $\boldsymbol{x}=\begin{bmatrix}1\\1\\0\end{bmatrix}+c\begin{bmatrix}1\\0\\1\end{bmatrix}(c\in\mathbb{R})$.

解　第一种情形，方程组只有唯一解，那么 $\boldsymbol{A}$ 列满秩：$r=n$. $\boldsymbol{A}$ 的零空间只包含零向量，$\boldsymbol{b}$ 属于 $\boldsymbol{A}$ 的列空间.

第二种情形，$\boldsymbol{A}$ 的列数 $n$ 必须是 2（行数 $m$ 没有限制）. 因为 $\begin{bmatrix}1\\1\end{bmatrix}\in\mathcal{N}(\boldsymbol{A})$，$\boldsymbol{A}$ 的第二

列是第一列的 $-1$ 倍，所以 $r=1$，从而显然有 $\boldsymbol{A}\neq\boldsymbol{0}$. 又因为 $\boldsymbol{x}=\begin{bmatrix}2\\1\end{bmatrix}$ 是特解，所以 $\boldsymbol{b}=2\cdot$第一列$+1\cdot$第二列$=$第一列. 我更愿意选取的特解是 $\boldsymbol{x}_p=\begin{bmatrix}1\\0\end{bmatrix}$.

第三种情况，$\boldsymbol{b}$ 不在 $\boldsymbol{A}$ 的列空间中，因此 $\boldsymbol{A}$ 的秩小于 $m$. 显然 $\boldsymbol{b}\neq\boldsymbol{0}$，否则 $\boldsymbol{x}=\boldsymbol{0}$ 是解.

第四种情形，$\boldsymbol{A}$ 的列数 $n$ 必须是 3（行数 $m$ 没有限制）. 因为 $\begin{bmatrix}1\\0\\1\end{bmatrix}\in\mathcal{N}(\boldsymbol{A})$，$\boldsymbol{A}$ 的第三列是第一列的 $-1$ 倍. 同时，$\boldsymbol{A}$ 的秩 $r=3-1=2$，且 $\boldsymbol{b}=$第一列$+$第三列.

3.3 C. 设 $\begin{bmatrix}1&2&1&0\\2&4&4&8\\4&8&6&8\end{bmatrix}$，$\boldsymbol{b}=\begin{bmatrix}4\\2\\10\end{bmatrix}$. 本题意在以此为例，说明如何对增广矩阵 $\begin{bmatrix}\boldsymbol{A}&\boldsymbol{b}\end{bmatrix}$ 做初等行变换来求出方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 的解集.

**解** 方法还是把 $\begin{bmatrix}\boldsymbol{A}&\boldsymbol{b}\end{bmatrix}$ 转化为 $\begin{bmatrix}\boldsymbol{R}_0&\boldsymbol{d}\end{bmatrix}$.

$$\begin{bmatrix}1&2&1&0&4\\2&4&4&8&2\\4&8&6&8&10\end{bmatrix}\longrightarrow\begin{bmatrix}1&2&1&0&4\\0&0&2&8&-6\\0&0&0&0&0\end{bmatrix}\longrightarrow\begin{bmatrix}1&2&0&-4&7\\0&0&1&4&-3\\0&0&0&0&0\end{bmatrix}$$

要得到 $\boldsymbol{x}_n$，分别令自由变元 $x_2$、$x_4$ 为 1、0 和 0、1:

基础解系：$\boldsymbol{s}_1=\begin{bmatrix}-2&1&0&0\end{bmatrix}^{\mathrm{T}}$，$\boldsymbol{s}_2=\begin{bmatrix}4&0&-4&1\end{bmatrix}^{\mathrm{T}}$

特解：$\boldsymbol{x}_p=\begin{bmatrix}7&0&-3&0\end{bmatrix}$

所有方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 的解集是 $\left\{\boldsymbol{x}=\boldsymbol{x}_p+c_1\boldsymbol{s}_1+c_2\boldsymbol{s}_2:c_1,c_2\in\mathbb{R}\right\}$.

$\boldsymbol{A}$ 的行向量满足：$2\cdot$第一行$+$第二行$-$第三行$=\boldsymbol{0}$；对于 $\boldsymbol{b}=\begin{bmatrix}4&2&10\end{bmatrix}^{\mathrm{T}}$，相同系数的线性组合得到 0：$2\cdot4+2-10=0$.

若 $\boldsymbol{A}$ 的行向量的某个线性组合（方程的左边）是零向量，那么方程右边同样系数的组合必须等于 0，否则方程组无解！

我们也可以用另一种方式来描述这个现象. 若 $\boldsymbol{A}$ 的每一个列向量都垂直于 $\boldsymbol{y}=\begin{bmatrix}2&1&-1\end{bmatrix}^{\mathrm{T}}$，那么它们的任意线性组合都必须垂直于 $\boldsymbol{y}$. 若 $\boldsymbol{b}$ 不垂直于 $\boldsymbol{y}$，则 $\boldsymbol{b}$ 不属于 $\boldsymbol{A}$ 的列空间且 $\boldsymbol{Ax}=\boldsymbol{b}$ 没有解.

或者用专业术语再包装一次：若 $\boldsymbol{y}\in\mathcal{N}(\boldsymbol{A}^{\mathrm{T}})$，则对任意 $\boldsymbol{b}\in\mathcal{C}(\boldsymbol{A})$，$\boldsymbol{y}$ 都正交于 $\boldsymbol{b}$.

## 习题 3.3

1.（推荐）按照例题总结 3.3A 中的六个步骤，刻画下述 $\boldsymbol{A}$ 的列空间、零空间和方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 的解集.

$$\boldsymbol{A}=\begin{bmatrix}2&4&6&4\\2&5&7&6\\2&3&5&2\end{bmatrix}\qquad \boldsymbol{b}=\begin{bmatrix}b_1\\b_2\\b_3\end{bmatrix}=\begin{bmatrix}4\\3\\5\end{bmatrix}$$

2. 将例题总结 3.3 A 中的六个步骤应用于下述秩 1 矩阵 $\boldsymbol{A}$：

$$\boldsymbol{A}=\begin{bmatrix}1\\3\\2\end{bmatrix}\begin{bmatrix}2&1&3\end{bmatrix}=\begin{bmatrix}2&1&3\\6&3&9\\4&2&6\end{bmatrix}\qquad \boldsymbol{b}=\begin{bmatrix}b_1\\b_2\\b_3\end{bmatrix}=\begin{bmatrix}10\\30\\20\end{bmatrix}$$

请找出关于 $b_1$、$b_2$、$b_3$ 的两个条件使得 $\boldsymbol{Ax}=\boldsymbol{b}$ 有解. 这两个条件把 $\boldsymbol{b}$ 限定在了_____ 中（一个平面或者一条直线）.（提示：两个平面交于一条直线）

**习题 3 ~ 15 关于 $\boldsymbol{Ax}=\boldsymbol{b}$ 的解. 从最后一列是 $\boldsymbol{b}$ 的增广矩阵出发，按照正文的步骤求解 $\boldsymbol{x}_p$ 和 $\boldsymbol{x}_n$.**

3. 把下列方程组的解写成 $\boldsymbol{x}_p+c\boldsymbol{s}$ 的形式，其中 $\boldsymbol{x}_p$ 是特解，$\boldsymbol{s}$ 是齐次方程组的解.

$$\begin{cases}x+3y=7\\2x+6y=14\end{cases}\qquad\qquad \begin{cases}x+3y+3z=1\\2x+6y+9z=5\\-x-3y+3z=5\end{cases}$$

4. 求下述方程组的解集：$\boldsymbol{x}=\boldsymbol{x}_p+$ 任意$\boldsymbol{x}_n$ （也被称为一般解）.

$$\begin{bmatrix}1&3&1&2\\2&6&4&8\\0&0&2&4\end{bmatrix}\begin{bmatrix}x\\y\\z\\t\end{bmatrix}=\begin{bmatrix}1\\3\\1\end{bmatrix}$$

5. 对下述两个方程组，$b_1$、$b_2$、$b_3$ 各自分别满足什么条件时，方程组有解？

$$\begin{cases}x+2y-2z=b_1\\2x+5y-4z=b_2\\4x+9y-8z=b_3\end{cases}\qquad\qquad \begin{cases}2x+2y=b_1\\4x+4y=b_2\\8x+8y=b_3\end{cases}$$

6. 对下述两个方程组，$b_1$、$b_2$、$b_3$、$b_4$ 各自分别满足什么条件时，方程组有解？在你给定的条件下，求出解集.

$$\begin{bmatrix}1&2\\2&4\\2&5\\3&9\end{bmatrix}\begin{bmatrix}x_1\\x_2\end{bmatrix}=\begin{bmatrix}b_1\\b_2\\b_3\\b_4\end{bmatrix}\qquad\qquad \begin{bmatrix}1&2&3\\2&4&6\\2&5&7\\3&9&12\end{bmatrix}\begin{bmatrix}x_1\\x_2\\x_3\end{bmatrix}=\begin{bmatrix}b_1\\b_2\\b_3\\b_4\end{bmatrix}$$

7. 设 $\boldsymbol{A}=\begin{bmatrix}1&3&1\\3&8&2\\2&4&0\end{bmatrix}$，请通过消元法证明：$\boldsymbol{A}$ 的秩 $\boldsymbol{r=2}$；并且证明：当 $b_3-2b_2+4b_2=0$

时，$\begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix}$ 属于 $\boldsymbol{A}$ 的列空间 $\mathcal{C}(\boldsymbol{A})$. 如何用 $\boldsymbol{A}$ 的行向量线性组合出零向量？

8. 对下列矩阵 $\boldsymbol{A}$，哪些向量 $\begin{bmatrix} b_1 & b_2 & b_3 \end{bmatrix}^{\mathrm{T}}$ 属于 $\boldsymbol{A}$ 的列空间？如何用 $\boldsymbol{A}$ 的行向量线性组合出零向量？

（1）$\boldsymbol{A}=\begin{bmatrix} 1 & 2 & 1 \\ 2 & 6 & 3 \\ 0 & 2 & 5 \end{bmatrix}$　　（2）$\boldsymbol{A}=\begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 4 \\ 2 & 4 & 8 \end{bmatrix}$

9. 对下列方程组，把解写成 $\boldsymbol{x}_p+\boldsymbol{x}_n$ 的形式，求出解集. 注意，它们的系数矩阵都是行满秩矩阵.

（1）$x+y+z=4$　　（2）$\begin{cases} x+y+z=4 \\ x-y+z=4 \end{cases}$

10. 构造一个 $2\times 3$ 矩阵 $\boldsymbol{A}$ 和 $\boldsymbol{b}\in\mathbb{R}^2$，使得方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 满足：

（1）$\boldsymbol{x}_p=\begin{bmatrix} 2 & 4 & 0 \end{bmatrix}^{\mathrm{T}}$ 是一个特解；

（2）齐次方程组 $\boldsymbol{Ax}=\boldsymbol{0}$ 的解 $\boldsymbol{x}_n$ 都是 $\begin{bmatrix} 1 & 1 & 1 \end{bmatrix}^{\mathrm{T}}$ 的常数倍.

11. 请说明：为什么不存在 $1\times 3$ 矩阵 $\boldsymbol{A}$ 和 $\boldsymbol{b}\in\mathbb{R}^1$ 使得 $\boldsymbol{x}_p=\begin{bmatrix} 2 & 4 & 0 \end{bmatrix}^{\mathrm{T}}$ 是方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 的一个特解且 $\mathcal{N}(\boldsymbol{A})=\left\{c\begin{bmatrix} 1 & 1 & 1 \end{bmatrix}^{\mathrm{T}}:c\in\mathbb{R}\right\}$.

12.（1）若 $\boldsymbol{Ax}=\boldsymbol{b}$ 有两个解 $\boldsymbol{x}_1$ 和 $\boldsymbol{x}_2$，试求齐次方程组 $\boldsymbol{Ax}=\boldsymbol{0}$ 的两个解.

（2）接上问，分别求出 $\boldsymbol{Ax}=\boldsymbol{0}$ 和 $\boldsymbol{Ax}=\boldsymbol{b}$ 的另一个解.

13. 说明下述错误论断的错误原因.

（1）方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 的解集由 $\boldsymbol{x}_p$ 和 $\boldsymbol{x}_n$ 的任意线性组合组成.

（2）方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 至多只有一个特解. 当 $\boldsymbol{A}$ 是_____ 时（填写何种特殊矩阵），这个论断是正确的.

（3）令所有自由变元都是 0，得到的解 $\boldsymbol{x}_p$ 是长度最小的解. 举一个 $2\times 2$ 的反例.

（4）若 $\boldsymbol{A}$ 是可逆矩阵，那么零空间是空集.

14. 假设 $\boldsymbol{U}$ 的第五列没有主元，那么 $x_5$ 是_____ 变元. 零向量_____（填“是”或者“不是”）$\boldsymbol{Ax}=\boldsymbol{0}$ 的唯一解. 若 $\boldsymbol{Ax}=\boldsymbol{b}$ 有解，那么它有_____（填“唯一一个”或者“无穷多个”）解.

15. 假设 $\boldsymbol{U}$ 的第三行没有主元，那么这一行是_____（这一行有什么显著的特征?）. 当满足条件_____ 时，方程组 $\boldsymbol{Ux}=\boldsymbol{c}$ 才有解. 方程组 $\boldsymbol{Ax}=\boldsymbol{b}$_____（填“有解”、“无解”或者“可能有解”）.

16. $3\times 5$ 矩阵的秩最大可能是_____. 秩取最大值时，$\boldsymbol{U}$ 和 $\boldsymbol{R}$ 的每一_____（“行”或者“列”）都有主元；方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 的解_____（“一定存在”或者“一定唯一”）；$\boldsymbol{A}$ 的列空间是_____；请举一个例子：$\boldsymbol{A}=$_____.

17. $6\times 4$ 矩阵的秩最大可能是_____. 秩取最大值时，$\boldsymbol{U}$ 和 $\boldsymbol{R}$ 的每一_____（“行”或者“列”）

都有主元；方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 的解_____（“一定存在”或者“一定唯一”）；$\boldsymbol{A}$ 的零空间是_____；请举一个例子：$\boldsymbol{A}=$_____.

18. 用消元法求 $\boldsymbol{A}$ 和 $\boldsymbol{A}^{\mathrm{T}}$ 的秩.

（1）$\boldsymbol{A}=\begin{bmatrix}1 & 4 & 0\\ 2 & 11 & 5\\ -1 & 2 & 10\end{bmatrix}$

（2）$\boldsymbol{A}=\begin{bmatrix}1 & 0 & 1\\ 1 & 1 & 2\\ 1 & 1 & q\end{bmatrix}$，此时矩阵的秩取决于 $q$ 的取值，请分类讨论.

19. 假设方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 有无穷多解，那么对任何 $\boldsymbol{b}'$，方程组 $\boldsymbol{Ax}=\boldsymbol{b}'$ 都不可能只有唯一解，请解释原因. 是否可能存在 $\boldsymbol{b}'$ 使得 $\boldsymbol{Ax}=\boldsymbol{b}'$ 无解？

20. 下列矩阵 $\boldsymbol{A}$、$\boldsymbol{B}$ 的秩是 1 或者 2 或者 3 时，$q$ 取什么值？对各种情况分别论证.

$$\boldsymbol{A}=\begin{bmatrix}6 & 4 & 2\\ -3 & -2 & -1\\ 9 & 6 & q\end{bmatrix}\qquad \boldsymbol{B}=\begin{bmatrix}3 & 1 & 3\\ q & 2 & q\end{bmatrix}$$

21. 针对方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 的解可能的情况，举出矩阵 $\boldsymbol{A}$ 的合适的例子.

（1）对不同的 $\boldsymbol{b}$，方程组要么无解，要么有唯一解；

（2）对任意 $\boldsymbol{b}$，方程组都有无穷多解；

（3）对不同的 $\boldsymbol{b}$，方程组要么无解，要么有无穷多解；

（4）对任意 $\boldsymbol{b}$，方程组都有唯一解.

22. 针对方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 的解可能的情况，矩阵 $\boldsymbol{A}$ 行数 $m$、列数 $n$ 和秩 $r$ 满足什么关系？

（1）存在 $\boldsymbol{b}$ 使得方程组无解；

（2）存在 $\boldsymbol{b}$ 使得方程组无解，也存在 $\boldsymbol{b}$ 使得方程组有唯一解；

（3）对任意 $\boldsymbol{b}$ 方程组都有无穷多解；

（4）对任意 $\boldsymbol{b}$ 方程组都有唯一解.

### 习题 23 ~ 27 关于最简行阶梯形矩阵 $\boldsymbol{R}_0$ 和 $\boldsymbol{R}$.

23. 把下列矩阵的行向量除以该行的主元，再用倍加变换把主元列其他元素都转化为 0，求出最简行阶梯型矩阵 $\boldsymbol{R}_0$ 和无零行的最简行阶梯型矩阵 $\boldsymbol{R}$.

$$\boldsymbol{U}=\begin{bmatrix}2 & 4 & 4\\ 0 & 3 & 6\\ 0 & 0 & 0\end{bmatrix}\qquad \boldsymbol{U}=\begin{bmatrix}2 & 4 & 4\\ 0 & 3 & 6\\ 0 & 0 & 5\end{bmatrix}\qquad \boldsymbol{U}=\begin{bmatrix}0 & 0 & 4\\ 0 & 1 & 0\end{bmatrix}$$

24. 若 $\boldsymbol{A}$ 是上三角矩阵，$\boldsymbol{R}_0=\mathbf{rref}(\boldsymbol{A})$ 何时等于单位阵 $\boldsymbol{I}$？

25. 分别对 $\boldsymbol{Ux}=\boldsymbol{0}$ 和 $\boldsymbol{Ux}=\boldsymbol{c}$ 作消元法，转化成 $\boldsymbol{R}_0\boldsymbol{x}=\boldsymbol{0}$ 和 $\boldsymbol{R}_0\boldsymbol{x}=\boldsymbol{d}$.

$$\begin{bmatrix}\boldsymbol{U} & \boldsymbol{0}\end{bmatrix}=\begin{bmatrix}1 & 2 & 3 & \boldsymbol{0}\\ 0 & 0 & 4 & \boldsymbol{0}\end{bmatrix}\qquad \begin{bmatrix}\boldsymbol{U} & \boldsymbol{c}\end{bmatrix}=\begin{bmatrix}1 & 2 & 3 & \boldsymbol{5}\\ 0 & 0 & 4 & \boldsymbol{8}\end{bmatrix}$$

令 $x_2=1$，解方程组 $\boldsymbol{R}_0\boldsymbol{x}=\boldsymbol{0}$，求出 $\boldsymbol{x}_n$；令 $x_2=0$，解方程组 $\boldsymbol{R}_0\boldsymbol{x}=\boldsymbol{d}$，求出 $\boldsymbol{x}_p$.

26. 把下列方程组 $\boldsymbol{U}\boldsymbol{x}=\boldsymbol{0}$ 和 $\boldsymbol{U}\boldsymbol{x}=\boldsymbol{c}$ 转化为 $\boldsymbol{R}_0\boldsymbol{x}=\boldsymbol{0}$ 和 $\boldsymbol{R}_0\boldsymbol{x}=\boldsymbol{d}$，然后再求解方程组 $\boldsymbol{R}_0\boldsymbol{x}=\boldsymbol{d}$.

$$\begin{bmatrix}\boldsymbol{U} & \boldsymbol{0}\end{bmatrix}=\begin{bmatrix}3&0&6&\mathbf{0}\\0&0&0&\mathbf{0}\\0&0&2&\mathbf{0}\end{bmatrix}\qquad\begin{bmatrix}\boldsymbol{U} & \boldsymbol{c}\end{bmatrix}=\begin{bmatrix}3&0&6&\mathbf{9}\\0&0&0&\mathbf{4}\\0&0&2&\mathbf{5}\end{bmatrix}$$

27. 把方程组 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 转化成为 $\boldsymbol{U}\boldsymbol{x}=\boldsymbol{c}$，并进一步转化为 $\boldsymbol{R}_0\boldsymbol{x}=\boldsymbol{d}$. 由此求出方程组的特解 $\boldsymbol{x}_p$ 和齐次方程组的基础解系.

$$\boldsymbol{A}\boldsymbol{x}=\begin{bmatrix}1&0&2&3\\1&3&2&0\\2&0&4&9\end{bmatrix}\begin{bmatrix}x_1\\x_2\\x_3\\x_4\end{bmatrix}=\begin{bmatrix}2\\5\\10\end{bmatrix}=\boldsymbol{b}$$

28. 找出符合下述条件的矩阵 $\boldsymbol{A}$ 和 $\boldsymbol{B}$；若不存在，则简述其原因.

（1）方程组 $\boldsymbol{A}\boldsymbol{x}=\begin{bmatrix}1\\2\\3\end{bmatrix}$ 有唯一解 $\boldsymbol{x}=\begin{bmatrix}0\\1\end{bmatrix}$；

（2）方程组 $\boldsymbol{B}\boldsymbol{x}=\begin{bmatrix}0\\1\end{bmatrix}$ 有唯一解 $\boldsymbol{x}=\begin{bmatrix}1\\2\\3\end{bmatrix}$.

29. 通过对 $\boldsymbol{A}$ 作 $\boldsymbol{LU}$ 分解来求出方程组 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 的解集.

$$\boldsymbol{A}=\begin{bmatrix}1&3&1\\1&2&3\\2&4&6\\1&1&5\end{bmatrix}\qquad\boldsymbol{b}=\begin{bmatrix}1\\3\\6\\5\end{bmatrix}\quad\text{及}\quad\boldsymbol{b}=\begin{bmatrix}1\\0\\0\\0\end{bmatrix}$$

30. 设方程组 $\boldsymbol{A}\boldsymbol{x}=\begin{bmatrix}1\\3\end{bmatrix}$ 的解集是 $\left\{\begin{bmatrix}1\\0\end{bmatrix}+c\begin{bmatrix}0\\1\end{bmatrix}:c\in\mathbb{R}\right\}$，试求出矩阵 $\boldsymbol{A}$.

31.（推荐）设 $\boldsymbol{A}$ 是 $3\times4$ 矩阵，且方程组 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$ 有唯一的基础解 $\boldsymbol{s}=\begin{bmatrix}2&3&1&0\end{bmatrix}^{\mathrm{T}}$.

（1）$\boldsymbol{A}$ 的秩是多少？$\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$ 的解集是什么？

（2）$\boldsymbol{A}$ 的最简行阶梯形矩阵 $\boldsymbol{R}_0$ 是什么？

（3）对任意的 $\boldsymbol{b}\in\mathbb{R}^3$，方程组 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 是否都有解？为什么？

32. 假设对任意 $\boldsymbol{b}$，方程组 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 和 $\boldsymbol{C}\boldsymbol{x}=\boldsymbol{b}$ 都有相同的解集. 请问是否一定有 $\boldsymbol{A}=\boldsymbol{C}$?

33. 若最简行阶梯形矩阵 $\boldsymbol{R}_0$ 的秩为 $r$，它的列空间是什么？把 $\boldsymbol{R}_0$ 的零行去掉，得到矩阵 $\boldsymbol{R}$，$\boldsymbol{R}$ 的列空间是什么？

## 3.4　线性无关性、基、维数

（1）线性无关的向量组：若线性组合 $c_1\boldsymbol{v}_1+c_2\boldsymbol{v}_2+\cdots+c_k\boldsymbol{v}_k=\boldsymbol{0}$，则所有的系数 $c_1,c_2,\cdots,c_k$ 都等于 0.
（2）若 $S$ 由 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_k$ 的所有线性组合构成，那么我们说 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_k$ 张成了 $S$.
（3）$\boldsymbol{A}$ 的最简行阶梯形矩阵 $\boldsymbol{R}_0=\mathrm{rref}(\boldsymbol{A})$ 包含 $r$ 阶单位阵 $\boldsymbol{I}_r$，余下的 $n-r$ 列为 $\boldsymbol{F}$.
（4）给定 $S$ 中的向量 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_k$，若：①它们线性无关，②它们张成 $S$，则称它们是 $S$ 的一组基.
（5）线性空间 $S$ 的维数定义为它的一组基所包含的向量的个数.

本节的内容非常重要，它研究了子空间“真实”的大小. $m\times n$ 矩阵有 $n$ 个列向量，但是其列空间的真实“维度”却未必是 $n$. $\mathcal{C}(\boldsymbol{A})$ 的维数由线性无关的列向量来衡量. 这里只是简要概括，后面我们会看到，列空间的维数实际上等于矩阵的秩 $r$.

线性无关性适用于任何线性空间中的任何一组向量. 本节关注的绝大部分子空间都是我们已经涉及和了解的——尤其是矩阵 $\boldsymbol{A}$ 的列空间和零空间. 在之前的章节中，我们也学习过并非列向量的“向量”——比如矩阵或者函数，对这些一般意义上的向量，也可以谈线性相关和线性无关. 当然，主要的例子还是列向量.

本节的主要目标是理解基这个概念——张成线性空间的线性无关的向量组.

线性空间中每一个向量都可以唯一地被基线性表出.

我们正处于线性代数的核心地带，如果没有基，一切都无法展开. 本节的四个出发点（包括这些术语名词可以望文生义的缘由）如下：

| | |
|---|---|
| （1）线性无关的向量组 | 没有冗余的向量 |
| （2）张成线性空间 | 向量足够多，能线性表出所有向量 |
| （3）线性空间的基 | 向量不太多，也不太少，“严丝合缝” |
| （4）线性空间的维数 | 线性空间的任意一组基包含的向量的个数 |

### 3.4.1　线性无关

我们可以给线性无关下一个不常规的定义.

**定义 3.3**　若方程组 $\boldsymbol{Ax}=\boldsymbol{0}$ 只有唯一解 $\boldsymbol{x}=\boldsymbol{0}$，则称 $\boldsymbol{A}$ 的列向量线性无关. 等价地，所有的非零线性组合 $\boldsymbol{Ax}$ 都不等于零向量.

也就是说，当 $\boldsymbol{A}$ 的零空间 $\mathcal{N}(\boldsymbol{A})$ 只包含零向量时，它的列向量线性无关. 我们来阐述一下 $\mathbb{R}^3$ 中三个向量的线性无关（和线性相关）性.

（1）如果 $\mathbb{R}^3$ 中三个向量不共面，那么它们线性无关. 图 3.3(a) 显示了除非 $0\boldsymbol{v}_1+0\boldsymbol{v}_2+0\boldsymbol{v}_3$，否则 $\boldsymbol{v}_1$、$\boldsymbol{v}_2$、$\boldsymbol{v}_3$ 其他的线性组合都不是零向量.

（2）如果 $\mathbb{R}^3$ 中三个向量 $\boldsymbol{w}_1$、$\boldsymbol{w}_2$、$\boldsymbol{w}_3$ 共面，则它们线性相关.

(a) 线性无关　　(b) 线性相关

**图 3.3　三维空间中线性无关和线性相关的向量组**

注：图 3.3(a) 中的向量组**线性无关**：只有 $0\boldsymbol{v}_1+0\boldsymbol{v}_2+0\boldsymbol{v}_3$ 才等于 $\boldsymbol{0}$；图 3.3(b) 中的向量组**线性相关**：$\boldsymbol{w}_1-\boldsymbol{w}_2+\boldsymbol{w}_3=\boldsymbol{0}$.

线性无关性不受列向量分量个数的限制，可以对任意 $\mathbb{R}^n$ 中的向量组来谈，比如我们可以问 $\mathbb{R}^{12}$ 中的 7 个向量是否线性无关. 如果线性无关，把它们作为列向量排成 $12\times 7$ 矩阵 $\boldsymbol{A}$ 时，那么 $\boldsymbol{A}$ 的零空间只有零向量 $\boldsymbol{x}=\boldsymbol{0}$. 其中任意一个向量都不能被其余 6 个向量线性表出.

现在，我们换一种等价的说法来描述线性无关性. 这个定义适用于任何线性空间.

**定义 3.4**　如果向量组 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_n$ 线性组合出零向量的方式只有 $0\boldsymbol{v}_1+0\boldsymbol{v}_2+\cdots+0\boldsymbol{v}_n$，则称这个向量组**线性无关**.

当 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_n$ 是矩阵 $\boldsymbol{A}$ 的列向量时，这个定义和定义 3.3一致.

**线性无关**

只有当 $x_1,x_2,\cdots,x_n$ 都是 0 时，才有$x_1\boldsymbol{v}_1+x_2\boldsymbol{v}_2+\cdots+x_n\boldsymbol{v}_n=\boldsymbol{0}$.　　(3.3)

当一个向量组的某个系数不全为零的线性组合能等于零向量时，它们**线性相关**. 对于线性无关性的叙述，我们做一点说明，表面上看是描述问题，其实背后体现了对概念的理解.

正确的说法：这个向量组线性无关；可行的简称：这些向量线性无关；完全错误的说法：这个矩阵线性无关.

一个向量组要么线性相关，要么线性无关，二者必居其一，取决于是否可以用非零的组合系数把它们线性组合出零向量. 因此，关键问题是：如何用这组向量组合出零向量. 我们先考虑 $\mathbb{R}^2$ 中的几个例子.

（1）向量 $\begin{bmatrix}1 & 0\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}1 & 0.00001\end{bmatrix}^{\mathrm{T}}$ 线性无关.

（2）向量 $\begin{bmatrix}1 & 1\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}-1 & -1\end{bmatrix}^{\mathrm{T}}$ 线性相关.

（3）向量 $\begin{bmatrix}1 & 1\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}0 & 0\end{bmatrix}^{\mathrm{T}}$ 线性相关，因为有零向量.

（4）$\mathbb{R}^2$ 中任意三个向量 $\begin{bmatrix}a & b\end{bmatrix}^{\mathrm{T}}$、$\begin{bmatrix}c & d\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}e & f\end{bmatrix}^{\mathrm{T}}$ 都线性相关.

列向量线性相关
零空间有非零向量

令 $x_1=x_2=1$，则 $\begin{bmatrix}1 & -1\\ 1 & -1\end{bmatrix}\begin{bmatrix}x_1\\ x_2\end{bmatrix}=\begin{bmatrix}0\\ 0\end{bmatrix}$

在（4）中，我们断言 $\mathbb{R}^2$ 中任意三个向量都线性相关. 这是因为：由这三个列向量排成的矩阵至少有一个自由变元，因此方程组 $\boldsymbol{Ax}=\boldsymbol{0}$ 有非零解.

现在我们把视线转移到 $\mathbb{R}^3$ 的三个向量. 如果其中一个向量是另一个的倍数，它们显然是线性相关的. 但是一般来说，只考虑其中两个向量是不够的，三个都需要考虑. 按照惯例，我们还是把它们排成矩阵 $\boldsymbol{A}$，并且试着解方程组 $\boldsymbol{Ax}=\boldsymbol{0}$.

**例 3.13**　矩阵 $\boldsymbol{A}=\begin{bmatrix}1 & 0 & 3\\ 2 & 1 & 5\\ 1 & 0 & 3\end{bmatrix}$ 的列向量线性相关，$\boldsymbol{Ax}=\boldsymbol{0}$ 有非零解：

$$\boldsymbol{Ax}=\begin{bmatrix}1 & 0 & 3\\ 2 & 1 & 5\\ 1 & 0 & 3\end{bmatrix}\begin{bmatrix}-3\\ 1\\ 1\end{bmatrix}=-3\begin{bmatrix}1\\ 2\\ 1\end{bmatrix}+1\begin{bmatrix}0\\ 1\\ 0\end{bmatrix}+1\begin{bmatrix}3\\ 5\\ 3\end{bmatrix}=\begin{bmatrix}\boldsymbol{0}\\ \boldsymbol{0}\\ \boldsymbol{0}\end{bmatrix}$$

$\boldsymbol{A}$ 的秩是 2，而列满秩的矩阵需要满足 $r=n=3$. 对方阵而言，线性相关的列向量意味着线性相关的行向量；反之亦然.

问题：如何求出 $\boldsymbol{Ax}=\boldsymbol{0}$ 的解？系统性的方法依然是消元法.

$$\boldsymbol{A}=\begin{bmatrix}1 & 0 & 3\\ 2 & 1 & 5\\ 1 & 0 & 3\end{bmatrix}\longrightarrow\boldsymbol{R}_0=\begin{bmatrix}1 & 0 & 3\\ 0 & 1 & -1\\ 0 & 0 & 0\end{bmatrix},\qquad \text{因此}\boldsymbol{F}=\begin{bmatrix}3\\ -1\end{bmatrix},\boldsymbol{x}=\begin{bmatrix}-3\\ 1\\ 1\end{bmatrix}$$

> 列满秩：矩阵 $\boldsymbol{A}$ 的列向量线性无关，当且仅当它的秩 $r=n$. 进一步地，$\boldsymbol{A}$ 有 $n$ 个主元，且 $\boldsymbol{A}=\boldsymbol{C}$. 零空间只包含 $\boldsymbol{x}=\boldsymbol{0}$.

我们再看一个例子. $\mathbb{R}^5$ 中任意 7 个向量（请注意 $5<7$ 这个事实）都线性相关. 原因如下：如果我们把这 7 个向量排成矩阵 $\boldsymbol{A}$（它是 $5\times 7$ 矩阵），那么 $\boldsymbol{A}$ 的秩小于或等于 5；而每一行最多一个主元，因此 $\boldsymbol{A}$ 至多 5 个主元，从而 $\boldsymbol{Ax}=\boldsymbol{0}$ 至少有 $7-5=2$ 个自由变元，所以有非零解——这说明 $\boldsymbol{A}$ 的列向量线性相关.

> 如果 $n>m$，则 $\mathbb{R}^m$ 中任意 $n$ 个向量都线性相关.

这类矩阵的列数大于行数，它是扁宽形的. 因为 $\boldsymbol{Ax}=\boldsymbol{0}$ 有非零解，所以 $\boldsymbol{A}$ 的列向量当然是线性相关的.

当 $n\leqslant m$ 时，列向量可能线性相关，也可能线性无关. 消元法找出 $r$ 个主元列，这 $r$ 个主元列线性无关，构成了矩阵 $\boldsymbol{C}$.

注：我们还可以这样来描述线性相关——“一个向量组线性相关，当且仅当其中存在可以被其他向量线性表出的向量”. 这种描述听起来很浅显且直接明了，那为什么我们不一开始就采用这种定义呢？相反地，初始定义略为拗口：“除了系数全为零的线性组合，其他线性组合均不等于零向量.”要排除掉零向量被系数全是零的线性组合所表示. 当一个向量被其余向量线性表出时，天然地有一个非零的系数 1.

我们之所以采用原始定义是因为可以避免选取特定的“害群之马”，所有的向量“一视同仁”. 我们直接考察方程组 $\boldsymbol{Ax}=\boldsymbol{0}$，看它有没有非零解；否则就需要对向量组中的向量逐个验证其是否可以被其他向量线性表出.[①]

### 3.4.2 张成子空间的向量组

本书接触的第一个子空间是矩阵的列空间. 设 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_n$ 是矩阵 $\boldsymbol{A}$ 的列向量，那么 $C(\boldsymbol{A})$ 包含了所有线性组合 $x_1\boldsymbol{v}_1+x_2\boldsymbol{v}_2\cdots+x_n\boldsymbol{v}_n$. 列空间由列向量的所有线性组合 $\boldsymbol{Ax}$ 组成. 我们用术语“张成”来指代这个过程.

**矩阵的列向量张成了列空间；它们有可能线性相关.**

**例 3.14** 描述矩阵 $\boldsymbol{A}$ 的列空间和行空间：

$$m=3,\quad n=2 \qquad \boldsymbol{A}=\begin{bmatrix}1&4\\2&7\\3&5\end{bmatrix} \qquad \text{则} \quad \boldsymbol{A}^{\mathrm{T}}=\begin{bmatrix}1&2&3\\4&7&5\end{bmatrix}$$

$\boldsymbol{A}$ 的列空间是 $\mathbb{R}^3$ 的子空间，由 $\boldsymbol{A}$ 的两个列向量张成；$\boldsymbol{A}$ 的行空间由它的三个行向量（或者说 $\boldsymbol{A}^{\mathrm{T}}$ 的列向量）张成，行空间是整个 $\mathbb{R}^2$.

需要提醒的是，对于一般的 $m\times n$ 矩阵，行向量属于 $\mathbb{R}^n$，张成矩阵的行空间；列向量属于 $\mathbb{R}^m$，张成矩阵的列空间. 虽然行空间和列空间维数相同（以后证明），但是它们由不同欧氏空间中的不同向量张成.

更一般地，设 $V$ 是线性空间，$\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_n$ 都属于 $V$.

**定义 3.5** 若 $V$ 由 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_n$ 的所有线性组合构成，则称 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_n$ 张成 $V$，或者称 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_n$ 是 $V$ 的一组生成元.

### 3.4.3 线性空间的基

$\mathbb{R}^3$ 中两个向量即使线性无关，也无法张成整个 $\mathbb{R}^3$；而 4 个向量，即使它们张成 $\mathbb{R}^3$，也不可能线性无关. 因此，最佳状态是能够张成整个线性空间的线性无关的向量，这正是基的含义.

① 译者注：译者愿意称之为“难度守恒定律”. 数学中的问题，其难度是守恒的，如果采用简单直接的定义，那么使用这个定义往往会困难一些；如果采用复杂的定义，那么使用这个定义简单一些. 如果是做题，思考得多一些，技巧性强一些，那么往往计算过程可以容易一些；如果思考得少一些，技巧性弱一些，那么往往计算过程就很复杂.

**定义 3.6**　线性空间的一组基是满足如下条件的向量组：

（1）线性无关；　　（2）能张成整个线性空间.

在线性代数中，这两个性质的组合具有基础性的意义. 一方面，因为基能张成整个空间，所以任意向量 $\boldsymbol{v}$ 都是基的线性组合；另一方面，因为基是线性无关的向量组，所以任意向量用基中的向量线性表出的方式是唯一的：

任意向量 $v$ 都可以被基唯一地线性表出.

线性表出的存在性无须多言，由定义的第 2 点保证，我们简要地证明唯一性.

**证明**　假设 $\boldsymbol{v}=a_1\boldsymbol{v}_1+a_2\boldsymbol{v}_2+\cdots+a_n\boldsymbol{v}_n=b_1\boldsymbol{v}_1+b_2\boldsymbol{v}_2+\cdots+b_n\boldsymbol{v}_n$，那么 $(a_1-b_1)\boldsymbol{v}_1+(a_2-b_2)\boldsymbol{v}_2+\cdots+(a_n-b_n)\boldsymbol{v}_n=\boldsymbol{0}$. 因为 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_n$ 线性无关，所以 $a_i-b_i=0(1\leqslant i\leqslant n)$. 这就说明 $a_i=b_i(1\leqslant i\leqslant n)$，也就是说线性表出的方式只能有一种.

**例 3.15**　$\boldsymbol{I}=\begin{bmatrix}1&0\\0&1\end{bmatrix}$ 的列向量是 $\mathbb{R}^2$ 的“标准基”. 向量 $\boldsymbol{i}=\begin{bmatrix}1\\0\end{bmatrix}$ 和 $\boldsymbol{j}=\begin{bmatrix}0\\1\end{bmatrix}$ 线性无关，且张成 $\mathbb{R}^2$. 几乎所有人都是从这一组基开始认识 $\mathbb{R}^2$，$\boldsymbol{i}$ 表示横坐标，$\boldsymbol{j}$ 表示纵坐标. $n$ 阶单位方阵的列向量是 $\mathbb{R}^n$ 的“标准基”.

事实上一个线性空间的基不仅不唯一，甚至有无穷多组基.

**例 3.16**　（重要）任意 $n$ 阶可逆方阵的列向量都是 $\mathbb{R}^n$ 的基.

可逆矩阵
列向量线性无关
列空间 $=\mathbb{R}^3$

$$\boldsymbol{A}=\begin{bmatrix}1&0&0\\1&1&0\\1&1&1\end{bmatrix}$$

奇异矩阵
列向量线性相关
列空间 $\neq\mathbb{R}^3$

$$\boldsymbol{B}=\begin{bmatrix}1&0&1\\1&1&2\\1&1&2\end{bmatrix}$$

方程组 $\boldsymbol{Ax}=\boldsymbol{0}$ 只有零解 $\boldsymbol{x}=\boldsymbol{A}^{-1}\boldsymbol{0}=\boldsymbol{0}$，因此列向量线性无关. 对任意 $\boldsymbol{b}$，$\boldsymbol{Ax}=\boldsymbol{b}$ 都有解 $\boldsymbol{x}=\boldsymbol{A}^{-1}\boldsymbol{b}$，所以 $\boldsymbol{b}$ 是 $\boldsymbol{A}$ 的列向量的线性组合，也就是说，$\boldsymbol{A}$ 的列向量张成了 $\mathbb{R}^n$. 两方面结合就说明了 $\boldsymbol{A}$ 的列向量是 $\mathbb{R}^n$ 的基. 总结来说：

向量组 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_n$ 是 $\mathbb{R}^n$ 的一组基，当且仅当它们作为列向量排成的矩阵是 $n$ 阶可逆方阵.
从而 $\mathbb{R}^n$ 有无穷多组基.

若列向量线性相关，我们选取其主元列——例如上面矩阵 $\boldsymbol{B}$ 的前两列，这两列线性无关，它们张成了矩阵的列空间.

任意一个线性无关的向量组都可以扩充成一组基.
任意一组生成元都包含一组基.

**例 3.17**　矩阵 $\boldsymbol{A}=\begin{bmatrix}2&4\\3&6\end{bmatrix}$ 不可逆，它的列向量组不是任何子空间的基.

一个主元列
一个主元行

$$\boldsymbol{A}=\begin{bmatrix}2&4\\3&6\end{bmatrix}\text{ 转化为 }\boldsymbol{R}_0=\begin{bmatrix}1&2\\0&0\end{bmatrix}$$

**例 3.18** 找出秩为 2 的矩阵 $\boldsymbol{R}_0=\begin{bmatrix}1&2&0&3\\0&0&1&4\\0&0&0&0\end{bmatrix}$ 的列空间和行空间的一组基.

第一列和第三列是主元列，并且是 $\boldsymbol{R}_0$ 列空间的一组基. 在 $xyz$ 空间 $\mathbb{R}^3$ 中，$\boldsymbol{R}_0$ 的列空间是“$xy$ 平面”. 需要说明的是，它并不是 $\mathbb{R}^2$，而是 $\mathbb{R}^3$ 的子空间. 第二列和第三列也是列空间的一组基. $\boldsymbol{R}_0$ 的哪两列不是列空间的基?

$\boldsymbol{R}_0$ 的行空间是 $\mathbb{R}^4$ 的子空间，最简单的一组基是 $\boldsymbol{R}_0$ 的两个非零行. 零向量永远不能出现在基中.

**问题** 任意给定 $\mathbb{R}^7$ 中 5 个向量，如何找出它们张成的子空间的一组基?

方法一：把它们当成行向量排成矩阵 $\boldsymbol{A}$，用消元法找出阶梯型矩阵 $\boldsymbol{R}$ 的非零行.

方法二：把它们当成列向量排成矩阵 $\boldsymbol{A}$，利用消元法找出主元列；主元所在的（做消元法之前的矩阵 $\boldsymbol{A}$ 的）列向量就是 $\mathcal{C}(\boldsymbol{A})$ 的基.

不同的基是否有相同个数的向量？这个关键的问题有完美的答案：是！线性空间的任意一组基都有相同个数的向量.

线性空间任意一组基所包含的向量个数定义为该空间的“维数”.

换言之，虽然不同的基有不同的向量，但是其中向量的个数是相同的. 这个断言必须给出严格且完整的证明，我们先用数学的语言把要证明的内容复述一遍：

若 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_m$ 和 $\boldsymbol{w}_1,\boldsymbol{w}_2,\cdots,\boldsymbol{w}_n$ 是同一个线性空间的两组基，那么 $m=n$.

**证明** 先用反证法证明 $n>m$ 不成立. 因为 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_m$ 是一组基，那么任意 $\boldsymbol{w}_j$ 都是它们的线性组合. 例如，可以假设 $\boldsymbol{w}_1=a_{11}\boldsymbol{v}_1+a_{21}\boldsymbol{v}_2+\cdots+a_{m1}\boldsymbol{v}_m$. 令 $\boldsymbol{W}=\begin{bmatrix}\boldsymbol{w}_1&\cdots&\boldsymbol{w}_n\end{bmatrix}$，$\boldsymbol{V}=\begin{bmatrix}\boldsymbol{v}_1&\cdots&\boldsymbol{v}_m\end{bmatrix}$，那么 $\boldsymbol{w}_1=\boldsymbol{V}\begin{bmatrix}a_{11}\\\vdots\\a_{m1}\end{bmatrix}$. $\boldsymbol{w}_1,\boldsymbol{w}_2,\cdots,\boldsymbol{w}_n$ 也是 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_m$ 的线性组合，于是

任意 $w_j$ 都是
$v_1,v_2,\cdots,v_n$ 的线性组合

$$\boldsymbol{W}=\begin{bmatrix}\boldsymbol{w}_1&\cdots&\boldsymbol{w}_n\end{bmatrix}=\begin{bmatrix}\boldsymbol{v}_1&\cdots&\boldsymbol{v}_m\end{bmatrix}\begin{bmatrix}a_{11}&\cdots&a_{1n}\\\vdots&&\vdots\\a_{m1}&&a_{mn}\end{bmatrix}=\boldsymbol{V}\boldsymbol{A}$$

虽然我们不知道这些 $a_{ij}$ 具体是多少，但是我们知道 $\boldsymbol{A}$ 是 $m\times n$ 矩阵. 关键点在于：根据反证假设 $n>m$，$\boldsymbol{A}$ 是扁宽形矩阵. 所以 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$ 有非零解.

取 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$ 的非零解 $\boldsymbol{x}_0$，则有 $\boldsymbol{W}\boldsymbol{x}_0=\boldsymbol{V}\boldsymbol{A}\boldsymbol{x}_0=\boldsymbol{0}$. 这说明 $\boldsymbol{w}_1,\boldsymbol{w}_2,\cdots,\boldsymbol{w}_n$ 的某个非零线性组合等于零向量 $\boldsymbol{0}$! 这和 $\boldsymbol{w}_1,\boldsymbol{w}_2,\cdots,\boldsymbol{w}_n$ 是一组基矛盾，因此反证假设 $n>m$ 不成立.

交换这两组基的地位，重复同样的论证就可以证明 $m > n$ 也不成立. 两者相结合就完全证明了 $m = n$.

线性空间的维数定义为其任意一组基的向量个数，所以 $\mathbb{R}^n$ 的维数是 $n$. 尽管已经说明过了，但是我们还是给维数这个关键的量正式地下个定义以示尊重.

**定义 3.7　线性空间的维数是它的任意一组基所包含的向量的个数.**

上述维数的定义和我们的直觉完全吻合. 过向量 $\boldsymbol{v} = \begin{bmatrix} 1 & 5 & 2 \end{bmatrix}^{\mathrm{T}}$ 的直线维数是 1. 这条直线是以 $\boldsymbol{v}$ 为基的子空间. 过原点、垂直于这条直线的平面方程是 $x + 5y + 2z = 0$，维数是 2. 要说明这一点，我们只需要找出它的一组基，看一看这组基有几个向量.

事实上，该平面是矩阵 $\boldsymbol{A} = \begin{bmatrix} 1 & 5 & 2 \end{bmatrix}$ 的零空间，它有两个自由变元，因此方程组 $\boldsymbol{Ax} = \boldsymbol{0}$ 有两个基础解：$\begin{bmatrix} -5 & 1 & 0 \end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix} -2 & 0 & 1 \end{bmatrix}^{\mathrm{T}}$.

一般地，秩为 $r$ 的 $m \times n$ 矩阵的基础解系有 $n - r$ 个基础解，基础解系也是矩阵零空间的一组基，从而零空间的维数是 $n - r$.

线性代数专业术语的说明：“线性空间的秩”、“基的维数”或者“矩阵的基”这些说法都是完全不规范的，没有任何理论意义，要坚决摒弃这一类说法. 我们虽然一定程度上对初学者容易发生的这些混淆予以理解，但是这类混淆更说明了初学者对概念的理解不到位，必须厘清并消除这些混淆. 我想引起误解的根源在于如下事实：矩阵的秩等于其列空间的维数.

| | |
|---|---|
| 行空间的维数是 $r$ | 列空间的维数是 $r$ |
| 零空间的维数是 $n - r$ | $\mathcal{N}(\boldsymbol{A}^{\mathrm{T}})$ 的维数是 $m - r$ |

注：这四个基本子空间的相互关系见图 3.4.

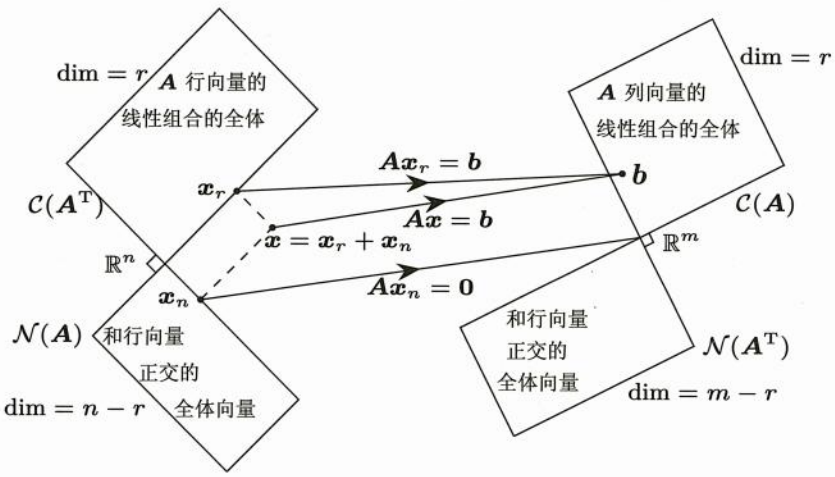


图 3.4　四个基本子空间的整体图景

注：$\boldsymbol{Ax}_r = \boldsymbol{b}$ 属于 $\boldsymbol{A}$ 的列空间；$\boldsymbol{Ax}_n = \boldsymbol{0}$. 方程组 $\boldsymbol{Ax} = \boldsymbol{b}$ 的解集是 $\boldsymbol{x} =$ 一个 $\boldsymbol{x}_r +$ 任意 $\boldsymbol{x}_n$.

### 3.4.4 矩阵空间和函数空间的基

线性无关、基和维数这些概念并不仅限于由列向量组成的线性子空间. 我们也可以问矩阵空间中三个元素 $\boldsymbol{A}_1$、$\boldsymbol{A}_2$、$\boldsymbol{A}_3$ 是否线性相关. 当它们都是 $3\times 4$ 矩阵时，可能存在非零线性组合是零矩阵. 我们也可以问由所有的 $3\times 4$ 矩阵构成的线性空间的维数（维数等于 12，任意一组基都正好包含 12 个矩阵）.

若我们把目光转向微分方程，$\mathrm{d}^2y/\mathrm{d}x^2 = y$ 的解构成一个线性空间，以 $y = \mathrm{e}^x$ 和 $y = \mathrm{e}^{-x}$ 为一组基，从而该方程的解空间维数是 2 （直觉上维数等于 2 来源于微分方程求导的阶最高是 2）.

**矩阵空间** 设 $M$ 是所有 $2\times 2$ 矩阵构成的线性空间，它的维数是 4.

**一组基是** $$\boldsymbol{A}_1, \boldsymbol{A}_2, \boldsymbol{A}_3, \boldsymbol{A}_4 = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}, \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}, \begin{bmatrix} 0 & 0 \\ 1 & 0 \end{bmatrix}, \begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix},$$

这四个向量线性无关. 要验证这一点，并不是考察它们的列向量，而是整个矩阵本身作为一个向量. 另外，$M$ 中任意矩阵都可以由它们线性表出.

$$\boldsymbol{A} = \begin{bmatrix} c_1 & c_2 \\ c_3 & c_4 \end{bmatrix} = c_1\boldsymbol{A}_1 + c_2\boldsymbol{A}_2 + c_3\boldsymbol{A}_3 + c_4\boldsymbol{A}_4.$$

$\boldsymbol{A} = \boldsymbol{0}$ 当且仅当 $c_1 = c_2 = c_3 = c_4 = 0$，这说明 $\boldsymbol{A}_1$、$\boldsymbol{A}_2$、$\boldsymbol{A}_3$、$\boldsymbol{A}_4$ 线性无关.

$M$ 中上三角矩阵的全体是子空间，以 $\boldsymbol{A}_1$、$\boldsymbol{A}_2$、$\boldsymbol{A}_4$ 为一组基，维数是 3. 对角矩阵的全体也是子空间，以 $\boldsymbol{A}_1$、$\boldsymbol{A}_4$ 为一组基. 对称矩阵的全体也是子空间，它的一组基是什么？$\boldsymbol{A}_1$、$\boldsymbol{A}_4$ 和 $\boldsymbol{A}_2 + \boldsymbol{A}_3$!

$n$ 阶方阵的全体构成的线性空间维数是 $n^2$.

$n$ 阶上三角矩阵的全体构成的线性空间维数是 $\dfrac{n(n+1)}{2}$.

$n$ 阶对角矩阵的全体构成的线性空间维数是 $n$.

$n$ 阶对称矩阵的全体构成的线性空间维数是 $\dfrac{n(n+1)}{2}$.（为什么？）

**函数空间** 我们来考虑二阶线性微分方程 $\mathrm{d}^2y/\mathrm{d}x^2 = 0$、$\mathrm{d}^2y/\mathrm{d}x^2 = -y$ 和 $\mathrm{d}^2y/\mathrm{d}x^2 = y$. 在分析学中，这些方程都能显式求解：

| | |
|---|---|
| $y'' = 0$ | 解集是线性函数 $y = cx + d$; |
| $y'' = -y$ | 解集是三角函数的线性组合 $y = c\sin x + d\cos x$; |
| $y'' = y$ | 解集是指数函数的线性组合 $y = ce^x + de^{-x}$. |

$y'' = -y$ 的解空间以 $\sin x$ 和 $\cos x$ 为一组基. $y'' = 0$ 的解空间是二阶求导这个“线性映射”的“零空间”[①]；以 $x$ 和 1 为一组基. 以上三个微分方程的解空间都是二维线性空间，因为它们都是二阶微分方程.

① 译者注：之所以加引号，是因为我们并没有明确指出二阶求导的定义域和值域. 我们也无意严格化这个论述，请读者结合自身的分析学的知识，大概地感受一下这种观点.

方程 $y''=2$ 的解集不是线性空间——方程右边的 $b=2$ 不是 0. $y(x)=x^2$ 是一个特解，解集是 $\left\{y(x)=x^2+(cx+d):c,d\in\mathbb{R}\right\}$. 注意，每一个解仍然是 $\boldsymbol{x}_p+\boldsymbol{x}_n$ 的形式（此处，$\boldsymbol{x}_p$ 是特解 $y=x^2$，$\boldsymbol{x}_n$ 属于零空间，形如 $cx+d$），所以解线性微分方程和解线性方程组有一定的可比性.

为了逻辑的完备性，我们还需要对只包含零向量的线性空间 $\{\boldsymbol{0}\}$ 做一些规定. 它的维数规定为 0，空集是它的基. 我们无论如何都不允许零向量出现在基中，否则线性无关性就丢失了.

本节的关键词是：线性无关、张成、基、维数.

（1）$\boldsymbol{A}$ 的列向量线性无关，当且仅当 $\boldsymbol{x}=\boldsymbol{0}$ 是方程组 $\boldsymbol{Ax}=\boldsymbol{0}$ 的唯一解.

（2）如果向量 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_r$ 的线性组合填满了 $V$，则它们张成线性空间 $V$.

（3）线性空间的基是可以张成该空间的线性无关的向量组. 任意向量都可以唯一地被这组基线性表出.

（4）线性空间的所有基都含有相同个数的向量，基中的向量个数称为线性空间的维数.

（5）矩阵主元所在的列是列空间的一组基，$\mathcal{C}(\boldsymbol{A})$ 的维数等于秩 $r$.

## 例 题 总 结

3.4 A.（重要的例子）假设 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_n$ 是 $\mathbb{R}^n$ 的一组基且 $\boldsymbol{A}$ 是可逆矩阵. 证明：$\boldsymbol{Av}_1,\boldsymbol{Av}_2,\cdots,\boldsymbol{Av}_n$ 也是 $\boldsymbol{R}^n$ 的基.

**解**　用矩阵语言证明. 把向量 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_n$ 作为列向量排成矩阵 $\boldsymbol{V}$，因为它们是一组基，所以 $\boldsymbol{V}$ 是可逆矩阵. 又因为 $\boldsymbol{A}$ 是可逆矩阵，那么 $\boldsymbol{AV}$ 也是可逆矩阵；而 $\boldsymbol{Av}_1,\boldsymbol{Av}_2,\cdots,\boldsymbol{Av}_n$ 是 $\boldsymbol{AV}$ 的列向量，因此它们构成 $\mathbb{R}^n$ 的一组基.

用向量语言证明. 假设 $c_1\boldsymbol{Av}_1+c_2\boldsymbol{Av}_2+\cdots+c_n\boldsymbol{Av}_n=\boldsymbol{0}$，即 $\boldsymbol{A}(c_1\boldsymbol{v}_1+c_2\boldsymbol{v}_2+\cdots+c_n\boldsymbol{v}_n)=\boldsymbol{0}$. 等式两边乘以 $\boldsymbol{A}^{-1}$ 可得 $c_1\boldsymbol{v}_1+c_2\boldsymbol{v}_2+\cdots+c_n\boldsymbol{v}_n=\boldsymbol{0}$. 由 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_n$ 的线性无关性可知 $c_1=c_2=\cdots=c_n=0$，这证明了 $\boldsymbol{Av}_1,\boldsymbol{Av}_2,\cdots,\boldsymbol{Av}_n$ 是线性无关的.

还剩下要证明 $\boldsymbol{Av}_1,\boldsymbol{Av}_2,\cdots,\boldsymbol{Av}_n$ 张成 $\mathbb{R}^n$. 对任意 $\boldsymbol{b}\in\mathbb{R}^n$，因为 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_n$ 是一组基，所以存在 $c_1,c_2,\cdots,c_n$ 使得 $c_1\boldsymbol{v}_1+c_2\boldsymbol{v}_2+\cdots+c_n\boldsymbol{v}_n=\boldsymbol{A}^{-1}\boldsymbol{b}$；等式两边乘以 $\boldsymbol{A}$ 就有 $c_1\boldsymbol{Av}_1+c_2\boldsymbol{Av}_2+\cdots+c_n\boldsymbol{Av}_n=\boldsymbol{b}$.

3.4 B. 给定向量 $\boldsymbol{v}_1=\begin{bmatrix}1&2&0\end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{v}_2=\begin{bmatrix}2&3&0\end{bmatrix}^{\mathrm{T}}$.

（1）它们是否线性无关？

（2）它们是否为某个线性空间 $V$ 的基？

（3）（2）中的线性空间 $V$ 维数是多少？

（4）哪个矩阵 $\boldsymbol{A}$ 以 $V$ 为列空间？

（5）哪个矩阵 $\boldsymbol{B}$ 以 $V$ 为零空间？

（6）向量 $\boldsymbol{v}_3$ 满足何种条件时，$\boldsymbol{v}_1$、$\boldsymbol{v}_2$、$\boldsymbol{v}_3$ 构成 $\mathbb{R}^3$ 的一组基？

**解**

（1）$\boldsymbol{v}_1$ 和 $\boldsymbol{v}_2$ 线性无关，只有 $0\boldsymbol{v}_1+0\boldsymbol{v}_2$ 能线性表出零向量 $\boldsymbol{0}$.

（2）是的. 令 $V$ 是 $\boldsymbol{v}_1$ 和 $\boldsymbol{v}_2$ 张成的子空间，那么 $\boldsymbol{v}_1$ 和 $\boldsymbol{v}_2$ 是 $V$ 的基. 事实上，$V=\left\{\begin{bmatrix}x&y&0\end{bmatrix}^{\mathrm{T}}:x,y\in\mathbb{R}\right\}$.

（3）$V$ 的维数是 2，因为它的基恰好包含两个向量.

（4）$V$ 是 $\boldsymbol{A}$ 的列空间，当且仅当 $\boldsymbol{A}$ 是 $3\times n$ 的秩为 2 的矩阵，且它的列向量都是 $\boldsymbol{v}_1$、$\boldsymbol{v}_2$ 的线性组合. 例如，我们可以取 $\boldsymbol{A}=\begin{bmatrix}\boldsymbol{v}_1 & \boldsymbol{v}_2\end{bmatrix}$.

（5）$V$ 是 $\boldsymbol{B}$ 的零空间，当且仅当 $\boldsymbol{B}$ 是 $m\times 3$ 的秩为 1 的矩阵，且它的行向量都是 $\begin{bmatrix}0 & 0 & 1\end{bmatrix}$ 的倍数. 例如，可以取 $\boldsymbol{B}=\begin{bmatrix}0 & 0 & 1\end{bmatrix}$，此时 $\boldsymbol{B}\boldsymbol{v}_1=\boldsymbol{B}\boldsymbol{v}_2=0$.

（6）若向量 $\boldsymbol{v}_3=\begin{bmatrix}a & b & c\end{bmatrix}^{\mathrm{T}}$ 满足 $c\neq 0$，那么 $\boldsymbol{v}_1$、$\boldsymbol{v}_2$、$\boldsymbol{v}_3$ 都是 $\mathbb{R}^3$ 的一组基.

**基变换** 给定线性无关的向量组 $\boldsymbol{w}_1$、$\boldsymbol{w}_2$、$\boldsymbol{w}_3$，考虑它们的线性组合 $\boldsymbol{v}_1$、$\boldsymbol{v}_2$、$\boldsymbol{v}_3$:

$$\begin{cases}\boldsymbol{v}_1=\boldsymbol{w}_1+\boldsymbol{w}_2\\ \boldsymbol{v}_2=\boldsymbol{w}_1+2\boldsymbol{w}_2+\boldsymbol{w}_3\\ \boldsymbol{v}_3=\boldsymbol{w}_2+c\boldsymbol{w}_3\end{cases}\quad\text{即}\quad\begin{bmatrix}\boldsymbol{v}_1 & \boldsymbol{v}_2 & \boldsymbol{v}_3\end{bmatrix}=\begin{bmatrix}\boldsymbol{w}_1 & \boldsymbol{w}_2 & \boldsymbol{w}_3\end{bmatrix}\begin{bmatrix}1 & 1 & 0\\ 1 & 2 & 1\\ 0 & 1 & c\end{bmatrix}$$

令 $\boldsymbol{V}=\begin{bmatrix}\boldsymbol{v}_1 & \boldsymbol{v}_2 & \boldsymbol{v}_3\end{bmatrix}$，$\boldsymbol{W}=\begin{bmatrix}\boldsymbol{w}_1 & \boldsymbol{w}_2 & \boldsymbol{w}_3\end{bmatrix}$，$\boldsymbol{B}=\begin{bmatrix}1 & 1 & 0\\ 1 & 2 & 1\\ 0 & 1 & c\end{bmatrix}$，则有 $\boldsymbol{V}=\boldsymbol{W}\boldsymbol{B}$. 我们如何通过 $\boldsymbol{B}$ 来判断 $\boldsymbol{V}$ 的列向量是否线性无关？事实上，当 $c\neq 1$ 时，$\boldsymbol{v}_1$、$\boldsymbol{v}_2$、$\boldsymbol{v}_3$ 线性无关；当 $c=1$ 时，$\boldsymbol{v}_1$、$\boldsymbol{v}_2$、$\boldsymbol{v}_3$ 线性相关.

证明 $\boldsymbol{v}_1$、$\boldsymbol{v}_2$、$\boldsymbol{v}_3$ 线性无关当且仅当$\boldsymbol{V}$ 的零空间只有零向量，或者说，方程组 $\boldsymbol{V}\boldsymbol{x}=\boldsymbol{0}$ 只有零解 $\boldsymbol{x}=\boldsymbol{0}$.

当 $c=1$ 时，我们可以通过两种方式来看出线性相关. 第一种，直接观察可知 $\boldsymbol{v}_1+\boldsymbol{v}_3=\boldsymbol{v}_2$，即 $\boldsymbol{v}_1-\boldsymbol{v}_2+\boldsymbol{v}_3=\boldsymbol{0}$，这说明 $\boldsymbol{v}_1$、$\boldsymbol{v}_2$、$\boldsymbol{v}_3$ 线性相关. 第二种，考察 $\boldsymbol{B}$ 的零空间. 如果 $c=1$，那么 $\boldsymbol{x}=\begin{bmatrix}1 & -1 & 1\end{bmatrix}^{\mathrm{T}}$ 满足 $\boldsymbol{B}\boldsymbol{x}=\boldsymbol{0}$，从而 $\boldsymbol{V}\boldsymbol{x}=\boldsymbol{W}\boldsymbol{B}\boldsymbol{x}=\boldsymbol{0}$；同样可以得到 $\boldsymbol{v}_1-\boldsymbol{v}_2+\boldsymbol{v}_3=\boldsymbol{0}$ 以及 $\boldsymbol{v}_1$、$\boldsymbol{v}_2$、$\boldsymbol{v}_3$ 线性相关.

当 $c\neq 1$ 时，$\boldsymbol{B}$ 是可逆矩阵，$\boldsymbol{v}_1$、$\boldsymbol{v}_2$、$\boldsymbol{v}_3$ 线性无关.

更一般地，当 $\boldsymbol{B}$ 是可逆矩阵时，那么 $\boldsymbol{v}_1$，$\boldsymbol{v}_2$，$\boldsymbol{v}_3$ 线性无关当且仅当 $\boldsymbol{w}_1$、$\boldsymbol{w}_2$、$\boldsymbol{w}_3$ 线性无关. 如果这两组向量都是 $\mathbb{R}^3$ 中的向量，它们不仅仅线性无关，还都是 $\mathbb{R}^3$ 的基. 我们可以总结规律：**当两个向量组之间的转移矩阵 $B$ 是可逆矩阵时，一个向量组是基当且仅当另一个向量组也是基.**

## 习题 3.4

习题 1 ~ 10 关于线性相关性和线性无关性.

1. 证明如下向量组 $\boldsymbol{v}_1$、$\boldsymbol{v}_2$、$\boldsymbol{v}_3$、$\boldsymbol{v}_4$ 线性相关，但是 $\boldsymbol{v}_1$、$\boldsymbol{v}_2$、$\boldsymbol{v}_3$ 线性无关

$$\boldsymbol{v}_1=\begin{bmatrix}1\\0\\0\end{bmatrix},\boldsymbol{v}_2=\begin{bmatrix}1\\1\\0\end{bmatrix},\boldsymbol{v}_3=\begin{bmatrix}1\\1\\1\end{bmatrix},\boldsymbol{v}_4=\begin{bmatrix}2\\3\\4\end{bmatrix}$$

可以通过解方程 $c_1\boldsymbol{v}_1+c_2\boldsymbol{v}_2+c_3\boldsymbol{v}_3+c_4\boldsymbol{v}_4=\boldsymbol{0}$ 来说明；或者等价地，把它们作为列向量排成矩阵 $\boldsymbol{A}$，然后解方程组 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$.

2.（推荐）在下面的 6 个向量中，找一个线性无关的向量组，使其包含尽可能多的向量.[①]

$$\boldsymbol{v}_1=\begin{bmatrix}1\\-1\\0\\0\end{bmatrix},\boldsymbol{v}_2=\begin{bmatrix}1\\0\\-1\\0\end{bmatrix},\boldsymbol{v}_3=\begin{bmatrix}1\\0\\0\\-1\end{bmatrix},\boldsymbol{v}_4=\begin{bmatrix}0\\1\\-1\\0\end{bmatrix},\boldsymbol{v}_5=\begin{bmatrix}0\\1\\0\\-1\end{bmatrix},\boldsymbol{v}_6=\begin{bmatrix}0\\0\\1\\-1\end{bmatrix},$$

3. 设矩阵 $\boldsymbol{U}=\begin{bmatrix}a&b&c\\0&d&e\\0&0&f\end{bmatrix}$，证明：如果 $a=0$ 或 $d=0$ 或 $f=0$（三种不同的情况），则 $\boldsymbol{U}$ 的列向量线性相关.

4. 如果上一题中的 $a$、$d$、$f$ 都是非零元，证明 $\boldsymbol{U}\boldsymbol{x}=\boldsymbol{0}$ 只有零解 $\boldsymbol{x}=\boldsymbol{0}$. 这个命题说明了：对角线非零的上三角矩阵的列向量线性无关.

5. 以下两组向量线性相关还是线性无关？

（1）$\begin{bmatrix}1&3&2\end{bmatrix}^{\mathrm{T}},\begin{bmatrix}2&1&3\end{bmatrix}^{\mathrm{T}},\begin{bmatrix}3&2&1\end{bmatrix}^{\mathrm{T}}$

（2）$\begin{bmatrix}1&-3&2\end{bmatrix}^{\mathrm{T}},\begin{bmatrix}2&1&-3\end{bmatrix}^{\mathrm{T}},\begin{bmatrix}-3&2&1\end{bmatrix}^{\mathrm{T}}$

6. 对矩阵 $\boldsymbol{U}$ 和 $\boldsymbol{A}$，分别找出三组由三个列向量构成的线性无关组.

$$\boldsymbol{U}=\begin{bmatrix}2&3&4&1\\0&6&7&0\\0&0&0&9\end{bmatrix},\qquad \boldsymbol{A}=\begin{bmatrix}2&3&4&1\\0&6&7&0\\0&0&0&9\\4&6&8&2\end{bmatrix}$$

7. 如果 $\boldsymbol{w}_1$、$\boldsymbol{w}_2$、$\boldsymbol{w}_3$ 线性无关，求 $\boldsymbol{v}_1=\boldsymbol{w}_2-\boldsymbol{w}_3,\boldsymbol{v}_2=\boldsymbol{w}_1-\boldsymbol{w}_3$ 和 $\boldsymbol{v}_3=\boldsymbol{w}_1-\boldsymbol{w}_2$ 的一个非零的线性组合，使其等于零向量；由此证明 $\boldsymbol{v}_1$、$\boldsymbol{v}_2$、$\boldsymbol{v}_3$ 线性相关. 求矩阵 $\boldsymbol{A}$ 使得 $\begin{bmatrix}\boldsymbol{v}_1&\boldsymbol{v}_2&\boldsymbol{v}_3\end{bmatrix}=\begin{bmatrix}\boldsymbol{w}_1&\boldsymbol{w}_2&\boldsymbol{w}_3\end{bmatrix}\boldsymbol{A}$，请问 $\boldsymbol{A}$ 是否是奇异矩阵？

8. 如果 $\boldsymbol{w}_1$、$\boldsymbol{w}_2$、$\boldsymbol{w}_3$ 线性无关，证明：$\boldsymbol{v}_1=\boldsymbol{w}_2+\boldsymbol{w}_3,\boldsymbol{v}_2=\boldsymbol{w}_1+\boldsymbol{w}_3$ 和 $\boldsymbol{v}_3=\boldsymbol{w}_1+\boldsymbol{w}_2$ 线性无关.

（提示：把 $c_1\boldsymbol{v}_1+c_2\boldsymbol{v}_2+c_3\boldsymbol{v}_3=\boldsymbol{0}$ 写成关于 $\boldsymbol{w}_1$、$\boldsymbol{w}_2$、$\boldsymbol{w}_3$ 的表达式，然后写出关于 $c_1$、$c_2$、$c_3$ 的方程组，解该方程组）

9. 设 $\boldsymbol{v}_1$、$\boldsymbol{v}_2$、$\boldsymbol{v}_3$、$\boldsymbol{v}_4\in\mathbb{R}^3$.

（1）因为_____，所以这四个向量线性相关.

（2）当_____ 时，$\boldsymbol{v}_1$、$\boldsymbol{v}_2$ 线性相关.

（3）因为_____，$\boldsymbol{v}_1$ 和 $\begin{bmatrix}0&0&0\end{bmatrix}^{\mathrm{T}}$ 线性相关.

10. 考虑 $\mathbb{R}^4$ 中的超平面 $x+2y-3z-t=0$，找出这个超平面上两个线性无关的向量；再找出该超平面上三个线性无关的向量. 该超平面上是否有四个线性无关的向量？它是哪个矩阵的零空间？

① 译者注：这就是所谓的“极大”线性无关组.

习题 11 ～ 14 关于用一组向量张成一个空间. 回顾一下，所谓张成，就是取这组向量的所有线性组合.

11. 刻画下列各组向量在 $\mathbb{R}^3$ 中张成的子空间（一条直线或者一个平面）.

（1）向量 $\begin{bmatrix}1 & 1 & -1\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}-1 & -1 & 1\end{bmatrix}^{\mathrm{T}}$

（2）向量 $\begin{bmatrix}0 & 1 & 1\end{bmatrix}^{\mathrm{T}}$，$\begin{bmatrix}1 & 1 & 0\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}0 & 0 & 0\end{bmatrix}^{\mathrm{T}}$

（3）$\mathbb{R}^3$ 中所有向量.

（4）$\mathbb{R}^3$ 中所有分量全是正数的向量.

12. 向量 $\boldsymbol{b}$ 属于 $\boldsymbol{A}$ 的列向量张成的子空间，当且仅当方程组_____ 有解. 对于向量 $\boldsymbol{c}$，当方程组_____ 有解时，向量 $\boldsymbol{c}$ 属于 $\boldsymbol{A}$ 的行空间.

判断正误：如果零向量在矩阵的行空间中，则行向量组线性相关.

13. 设矩阵 $\boldsymbol{A}=\begin{bmatrix}1 & 1 & 0\\ 1 & 3 & 1\\ 3 & 1 & -1\end{bmatrix}$，$\boldsymbol{U}=\begin{bmatrix}1 & 1 & 0\\ 0 & 2 & 1\\ 0 & 0 & 0\end{bmatrix}$. 求下面四个空间的维数. 哪两个空间维数相同？

（1）$\boldsymbol{A}$ 的列空间.

（2）$\boldsymbol{U}$ 的列空间.

（3）$\boldsymbol{A}$ 的行空间.

（4）$\boldsymbol{U}$ 的行空间.

14. $\boldsymbol{v}+\boldsymbol{w}$ 和 $\boldsymbol{v}-\boldsymbol{w}$ 是 $\boldsymbol{v}$ 和 $\boldsymbol{w}$ 的线性组合. 把 $\boldsymbol{v}$、$\boldsymbol{w}$ 写成 $\boldsymbol{v}+\boldsymbol{w}$ 和 $\boldsymbol{v}-\boldsymbol{w}$ 的线性组合. 这两组向量_____（张成或者不张成）相同的线性空间. 满足什么条件时，它们都是同一个线性空间的基？

习题 15 ～ 25 关于基满足的条件.

15. 如果 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_n$ 线性无关，它们张成的线性空间维数等于_____. 这组向量是该线性空间的_____. 如果这组向量是某个 $m\times n$ 矩阵的列向量，那么 $m$_____（大于、小于、大于或等于、小于或等于）$n$；如果 $m=n$，则该矩阵_____.

16. 找出 $\mathbb{R}^4$ 中如下各个子空间的一组基.

（1）各分量都相等的向量的全体组成的子空间.

（2）分量相加等于 0 的向量的全体组成的子空间.

（3）垂直于 $\begin{bmatrix}1 & 1 & 0 & 0\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}1 & 0 & 1 & 1\end{bmatrix}^{\mathrm{T}}$ 的向量的全体组成的子空间.

（4）4 阶单位阵 $\boldsymbol{I}$ 的列空间和零空间.

17. 试给出矩阵 $\boldsymbol{U}=\begin{bmatrix}1 & 0 & 1 & 0 & 1\\ 0 & 1 & 0 & 1 & 0\end{bmatrix}$ 的列空间三组不同的基，再给出它的行空间两组不同的基.

18. 给定 $\mathbb{R}^4$ 中的向量 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_6$.

（1）它们_____（一定、一定不、可能不）张成 $\mathbb{R}^4$.

（2）它们_____（一定、一定不、可能）线性无关.

（3）它们中任意四个向量_____（一定是、一定不是、可能是）$\mathbb{R}^4$ 的一组基.

19. 设 $\boldsymbol{A}$ 是 $m \times n$ 矩阵，如果它的列向量线性无关，那么 $\boldsymbol{A}$ 的秩等于多少？如果它们张成 $\mathbb{R}^m$，$\boldsymbol{A}$ 的秩等于多少？如果它们构成 $\mathbb{R}^m$ 的一组基，你能得到什么结论？矩阵的秩 $r$ 等于它_____的列向量的个数.

20. 试求出 $\mathbb{R}^3$ 中的平面 $x-2y+3z=0$ 的一组基，再找出该平面和 $xy$ 平面的交集的一组基，最后找出垂直于该平面中向量的所有向量构成的子空间的一组基.

21. 设 $5 \times 5$ 矩阵 $\boldsymbol{A}$ 的列向量是 $\mathbb{R}^5$ 的一组基.

（1）因为_____，方程组 $\boldsymbol{Ax}=\boldsymbol{0}$ 只有零解.

（2）因为基_____$\mathbb{R}^5$，对任意 $\boldsymbol{b} \in \mathbb{R}^5$ 方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 都有解.

结论：$\boldsymbol{A}$ 是可逆矩阵，秩是 5，行向量也是 $\mathbb{R}^5$ 的基.

22. 设 $S$ 是 $\mathbb{R}^6$ 的一个 5 维子空间，判断正误（正确请简要说明，错误请举出反例）.

（1）$S$ 的任意一组基都可以增加一个向量扩充成 $\mathbb{R}^6$ 的一组基.

（2）$\mathbb{R}^6$ 的任意一组基都可以减少一个向量缩减成 $S$ 的一组基.

23. 设 $\boldsymbol{A}=\begin{bmatrix}1&3&2\\0&1&1\\1&3&2\end{bmatrix}$，第三行减去第一行可得 $\boldsymbol{U}=\begin{bmatrix}1&3&2\\0&1&1\\0&0&0\end{bmatrix}$. 分别求这两个矩阵列空间、行空间、零空间的一组基. 哪些子空间在消元法之下保持不变？

24. 判断正误（正确请简要说明，错误请举出反例）.

（1）如果一个矩阵的列向量线性相关，那么它的行向量也线性相关.

（2）$2 \times 2$ 矩阵的列空间和行空间相同.

（3）$2 \times 2$ 矩阵的列空间和行空间维数相同.

（4）矩阵的列向量是列空间的一组基.

25. 假设 $\boldsymbol{v}_1, \boldsymbol{v}_2, \cdots, \boldsymbol{v}_k$ 张成 $\mathbb{R}^n$，如何减少一些向量使得剩余向量构成 $\mathbb{R}^n$ 的一组基？假设 $\boldsymbol{v}_1, \boldsymbol{v}_2, \cdots, \boldsymbol{v}_j$ 是 $\mathbb{R}^n$ 中线性无关的向量组，如何增加一些向量使得它们合并起来构成 $\mathbb{R}^n$ 的一组基？

26. 设 $\boldsymbol{A}=\begin{bmatrix}1&2&5&0&5\\0&0&c&2&c\\0&0&0&d&2\end{bmatrix}$，$\boldsymbol{B}=\begin{bmatrix}c&d\\d&c\end{bmatrix}$. 当 $c$、$d$ 满足什么条件时，$\boldsymbol{A}$ 的秩为 2？当 $c$、$d$ 满足什么条件时，$\boldsymbol{B}$ 的秩为 2？

习题 27 ~ 31 关于矩阵空间和矩阵空间中的向量.

27. 找出下列 $3 \times 3$ 矩阵空间的子空间的一组基和维数.

（1）对角矩阵的全体.

（2）对称矩阵的全体（$\boldsymbol{A}^{\mathrm{T}}=\boldsymbol{A}$）.

（3）反对称矩阵的全体（$\boldsymbol{A}^{\mathrm{T}}=-\boldsymbol{A}$）.

28. 试构造 6 个线性无关的 $3 \times 3$ 行阶梯型矩阵 $\boldsymbol{U}_1, \boldsymbol{U}_2, \cdots, \boldsymbol{U}_6$.

29. 考虑 $2 \times 3$ 矩阵，$V_1$ 是其中 3 个列向量的分量相加都等于 0 的全体，$V_2$ 是其中 2 个行向量的分量相加都等于 0 的全体. 请分别求 $V_1$、$V_2$ 的一组基.

30. $3\times 3$ 矩阵空间的下列子集张成的子空间分别是什么？

（1）所有可逆矩阵.

（2）所有秩 1 矩阵.

（3）单位阵.

31. 设 $\boldsymbol{M}_{2\times 3}$ 是 $2\times 3$ 矩阵的全体，$V=\left\{\boldsymbol{A}\in\boldsymbol{M}_{2\times 3}:\begin{bmatrix}2&1&1\end{bmatrix}^{\mathrm{T}}\in\mathcal{N}(\boldsymbol{A})\right\}$，请证明 $V$ 是线性空间，并找出 $V$ 的一组基.

**习题 32 ~ 36 关于函数空间和函数空间中的向量.**

32.（1）求微分方程 $\dfrac{\mathrm{d}y}{\mathrm{d}x}=0$ 的解集.

（2）求微分方程 $\dfrac{\mathrm{d}y}{\mathrm{d}x}=3$ 的一个特解.

（3）求微分方程 $\dfrac{\mathrm{d}y}{\mathrm{d}x}=3$ 的解集.

33. 定义：余弦函数空间 $\boldsymbol{F}_3=\{y(x)=a\cos x+b\cos 2x+\cos 3x:a,b,c\in\mathbb{R}\}$；$V=\{y\in\boldsymbol{F}_3:y(0)=0\}$，试求 $V$ 的一组基.

34. 试求下列微分方程的解集的一组基.

（1）$\dfrac{\mathrm{d}y}{\mathrm{d}x}-2y=0.$

（2）$\dfrac{\mathrm{d}y}{\mathrm{d}x}-\dfrac{y}{x}=0.$

35. 设 $y_1(x)$、$y_2(x)$、$y_3(x)$ 是关于 $x$ 的三个不同函数. 它们张成的子空间的维数可能是 1、2、3. 对每种情况分别举一个例子.

36. 设 $\mathbb{R}[x]_{\leqslant 3}=\left\{p(x)\text{是多项式：}\deg(p(x))\leqslant 3\right\}$，其中 $\deg(p(x))$ 是 $p(x)$ 的次数，请证明 $\mathbb{R}[x]_{\leqslant 3}$ 是线性空间，并找出它的一组基. 设 $V=\left\{p(x)\in\mathbb{R}[x]_{\leqslant 3}:p(1)=0\right\}$，证明 $V$ 是 $\mathbb{R}[x]_{\leqslant 3}$ 的子空间，并找出它的一组基.

37. 分别求 $S=\left\{\begin{bmatrix}a&b&c&d\end{bmatrix}^{\mathrm{T}}:a+c+d=0\right\}$ 和 $T=\left\{\begin{bmatrix}a&b&c&d\end{bmatrix}^{\mathrm{T}}:a+b=0,c=2d\right\}$ 的一组基，再求它们的交集 $S\cap T$ 的维数.

38. 设 $\boldsymbol{A}$ 是秩为 4 的 $5\times 4$ 矩阵，证明 $\boldsymbol{Ax}=\boldsymbol{b}$ 无解，当且仅当 $5\times 5$ 矩阵 $\begin{bmatrix}\boldsymbol{A}&\boldsymbol{b}\end{bmatrix}$ 是可逆矩阵.

39. 分别写出微分方程 $\dfrac{\mathrm{d}^2y}{\mathrm{d}x^2}=y(x)$ 和 $\dfrac{\mathrm{d}^2y}{\mathrm{d}x^2}=-y(x)$ 的解集的一组基.

## 挑 战 一 下

40. 三阶置换矩阵一共有 6 个，把三阶单位阵写成其余 5 个置换矩阵的线性组合；证明除单位阵以外的 5 个三阶置换矩阵线性无关.

事实上，如果我们考虑 $\mathbb{R}^{3\times 3}$ 中满足如下条件的矩阵 $\boldsymbol{A}$ 构成的子集 $S$：$\boldsymbol{A}$ 的三个行向量的分量的和、三个列向量的分量的和都相等. 那么 $S$ 是子空间，并且除单位阵以外的 5 个三阶置换矩

阵是 $S$ 的一组基. 能否证明这个论断?

41. 取 $\boldsymbol{x}=\begin{bmatrix}x_1 & x_2 & x_3 & x_4\end{bmatrix}^{\mathrm{T}}\in\mathbb{R}^4$，把它的分量改变顺序，一共有 24 个向量，例如 $\begin{bmatrix}x_2 & x_1 & x_3 & x_4\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}x_4 & x_3 & x_1 & x_2\end{bmatrix}^{\mathrm{T}}$ 等. 包括 $\boldsymbol{x}$ 本身在内的 24 个向量张成一个子空间，记作 $S$. 请分别举出具体的 $\boldsymbol{x}$ 的例子，使得 $S$ 的维数等于 0、1、3、4.

42. 线性空间的交与和之间的维数满足公式：$\dim(V)+\dim(W)=\dim(V\cap W)+\dim(V+W)$. 试证明之.

[提示：先选取 $V\cap W$ 的一组基 $\boldsymbol{u}_1,\boldsymbol{u}_2,\cdots,\boldsymbol{u}_r$；再添加向量 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_r$ （$\boldsymbol{w}_1,\boldsymbol{w}_2,\cdots,\boldsymbol{w}_t$）扩张成 $V$（$W$）的一组基. 然后证明 $\boldsymbol{u}_1,\boldsymbol{u}_2,\cdots,\boldsymbol{u}_r,\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_s,\boldsymbol{w}_1,\boldsymbol{w}_2,\cdots,\boldsymbol{w}_t$ 线性无关，于是维数公式即 $(r+s)+(r+t)=(r)+(r+s+t)$.]

43. 假设 $\mathbb{R}^n$ 的两个子空间 $V$ 和 $W$ 的维数满足 $\dim(V)+\dim(W)>n$. 证明：存在同时属于 $V$ 和 $W$ 的非零向量.

（提示：分别取 $V$ 和 $W$ 的一组基，把它们作为列向量排成矩阵 $\boldsymbol{A}$，证明 $\boldsymbol{Ax}=\boldsymbol{0}$ 有非零解. 也可以用上一题的结论.）

44. 设 $10\times10$ 矩阵 $\boldsymbol{A}$ 满足 $\boldsymbol{A}^2=\boldsymbol{0}$，即 $\boldsymbol{A}$ 乘以 $\boldsymbol{A}$ 的每个列向量都等于 $\boldsymbol{0}$，那么 $\boldsymbol{A}$ 的列向量包含于_____. 设 $\boldsymbol{A}$ 的秩是 $r$，通过子空间的包含关系可得 $r\leqslant10-r$，因此 $\boldsymbol{r\leqslant5}$.

## 3.5　四个基本子空间的维数

（1）列空间 $\mathcal{C}(\boldsymbol{A})$ 和行空间 $\mathcal{C}(\boldsymbol{A}^{\mathrm{T}})$ 的维数都等于 $\boldsymbol{A}$ 的秩 $r$.
（2）$\boldsymbol{A}$ 的零空间 $\mathcal{N}(\boldsymbol{A})$ 的维数等于 $n-r$，左零空间 $\mathcal{N}(\boldsymbol{A}^{\mathrm{T}})$ 的维数等于 $m-r$.
（3）消元法会改变列空间和左零空间，但是不改变它们的维数.

本章的主要定理把秩和维数联系起来. 矩阵的**秩**是指线性无关的列向量的个数，子空间的**维数**是指它的基所包含的向量的个数. 我们当然可以数主元个数，或者基中向量的个数. 矩阵 $\boldsymbol{A}$ 的秩反映了它四个基本子空间的维数.

四个基本子空间中的两个直接来源于 $\boldsymbol{A}$，另外两个来源于 $\boldsymbol{A}^{\mathrm{T}}$. $\boldsymbol{A}$ 的四个基本子空间和维数见图 3.5.

| | 四个基本子空间 | 维数 |
|---|---|---|
| （1） | 行空间 $\mathcal{C}(\boldsymbol{A}^{\mathrm{T}})\subseteq\mathbb{R}^{\boldsymbol{n}}$ | $\boldsymbol{r}$ |
| （2） | 列空间 $\mathcal{C}(\boldsymbol{A})\subseteq\mathbb{R}^{\boldsymbol{m}}$ | $\boldsymbol{r}$ |
| （3） | 零空间 $\mathcal{N}(\boldsymbol{A})\subseteq\mathbb{R}^{\boldsymbol{n}}$ | $\boldsymbol{n-r}$ |
| （4） | 左零空间 $\mathcal{N}(\boldsymbol{A}^{\mathrm{T}})\subseteq\mathbb{R}^{\boldsymbol{m}}$ | $\boldsymbol{m-r}$ |

我们对 $\mathcal{C}(\boldsymbol{A})$ 和 $\mathcal{N}(\boldsymbol{A})$ 的介绍已经很透彻了，接下来是 $\mathcal{C}(\boldsymbol{A}^{\mathrm{T}})$ 和 $\mathcal{N}(\boldsymbol{A}^{\mathrm{T}})$. 行空间包含了行向量的所有线性组合，$\boldsymbol{A}$ 的行空间即 $\boldsymbol{A}^{\mathrm{T}}$ 的列空间.

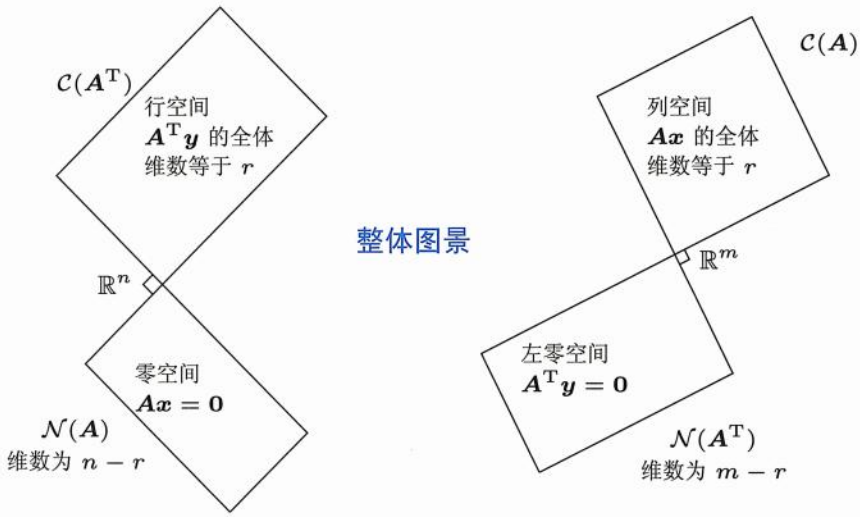


图 3.5 $A$ 的四个基本子空间和维数

要求左零空间，我们只需解方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}=\boldsymbol{0}$——这是 $m$ 个变元 $n$ 个方程的方程组. 在例3.20中，我们可以看到左零空间的应用，同时也是应用数学最伟大的方程之一——**基尔霍夫电流定律**. 电流在电网中流动，不会在节点处堆积，也就是说每个节点处的流入电流都等于流出电流. 设矩阵 $\boldsymbol{A}$ 是从电网抽象出来的图的关联矩阵，它的四个子空间来源于节点、边、环和树这些图论对象. 这些有着具体背景的子空间以一种极致“优雅”的方式相互“缠绵”.

线性代数基本定理的第一部分断言了矩阵四个子空间的维数. 一个引人注目的事实是：**矩阵的行空间和列空间的维数都等于秩 $r$.** 另一个重要的事实是关于两个零空间的：

**$\mathcal{N}(A)$ 和 $\mathcal{N}(A^{\mathrm{T}})$ 的维数分别是$n-r$和$m-r$，正好和上两个空间的维数补足$n$、$m$.**

基本定理的第二部分将要说明如何把这四个基本子空间拼在一起：零空间和行空间正交，左零空间和列空间正交. 这些合在一起才是对方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 完整的理解. 数学不只有计算，还有对计算所展示出来的理论的总结. 坚持这样的过程，因为这才是真正在研究数学、欣赏数学！

### 3.5.1 $R_0$ 的四个子空间

设 $\boldsymbol{A}$ 可以转化为最简行阶梯形矩阵 $\boldsymbol{R}_0$. 对于后者这种特殊矩阵，它的四个基本子空间是容易确定的；所以我们先对最简行阶梯形矩阵来确定四个基本子空间以及维数，然后再研究 $\boldsymbol{R}_0$ 和 $\boldsymbol{A}$ 的四个子空间之间如何互相转化. 关键点是**$A$ 和 $R_0$ 的四个基本子空间的维数分别对应相等.**

而对于 $\boldsymbol{A}$ 和 $\boldsymbol{R}$，四个基本子空间中的其中一个维数是不相等的——$\boldsymbol{R}$ 没有零行，因此 $m$ 的值改变了.

我们还是从具体的例子入手. 先看下面这个 $3\times5$ 最简行阶梯形矩阵 $\boldsymbol{R}_0$ 的四个子空间:

$$\begin{matrix} m=3 \\ n=5 \\ r=2 \end{matrix} \qquad \mathrm{R}_0=\begin{bmatrix} 1 & 3 & 5 & 0 & 7 \\ 0 & 0 & 0 & 1 & 2 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$

主元行是第一、第二行

主元列是第一、第四列

$\boldsymbol{R}_0$ 的秩是 $r=2$（两个主元）. 我们逐个来看它的四个基本子空间.

（1）$\boldsymbol{R}_0$ 的行空间维数等于 2，和秩相同.

原因：前两行是行空间的一组基；虽然行空间由三个行向量的线性组合构成，但是第三行是零行，对行空间没有任何贡献.

主元行——第一、第二行——线性无关，这个事实是显然的. 一般情况下也成立，即任意最简行阶梯形矩阵的主元行都线性无关. 事实上，主元行和主元列的交叉点构成的 $r\times r$ 矩阵是单位阵，所以除了系数全为零的平凡的线性组合，我们不可能用主元行线性组合出零向量，因此 $r$ 个主元行（也就是 $\boldsymbol{R}$ 的行向量）是行空间的一组基.

行空间的维数等于秩 $r$，$\boldsymbol{R}_0$ 的非零行是一组基.

（2）$\boldsymbol{R}_0$ 的列空间维数也等于秩 $r=2$.

原因：主元列——第一、第四列——是列空间的一组基；同样是因为主元列包含 $r\times r$ 单位阵，所以线性无关. 除了系数全为零的平凡的线性组合，我们不可能用主元列线性组合出零向量. 同时主元列能张成列空间，所有自由列都是主元列的线性组合. 事实上，基础解系作系数就给出了这样的线性组合.

$$
\begin{aligned}
&\text{第二列} = \text{第一列}\times 3 && \text{基础解为}\ \begin{bmatrix}-3 & 1 & 0 & 0 & 0\end{bmatrix}^{\mathrm{T}}\\
&\text{第三列} = \text{第一列}\times 5 && \text{基础解为}\ \begin{bmatrix}-5 & 0 & 1 & 0 & 0\end{bmatrix}^{\mathrm{T}}\\
&\text{第五列} = \text{第一列}\times 7 + \text{第四列}\times 2 && \text{基础解为}\ \begin{bmatrix}-7 & 0 & 0 & -2 & 1\end{bmatrix}^{\mathrm{T}}
\end{aligned}
$$

主元列线性无关，并且张成 $C(\boldsymbol{R}_0)$，所以它们是 $C(\boldsymbol{R}_0)$ 的基.

列空间的维数等于秩 $r$，主元列是一组基.

（3）$\boldsymbol{R}_0$ 的零空间的维数等于 $n-r=5-2$. 分别令 3 个自由变元中一个等于 1，其余两个等于 0，就给出 $\boldsymbol{R}_0\boldsymbol{x}=\boldsymbol{0}$ 的三个基础解.

$$
\boldsymbol{s}_2=\begin{bmatrix}-3\\1\\0\\0\\0\end{bmatrix}\quad
\boldsymbol{s}_3=\begin{bmatrix}-5\\0\\1\\0\\0\end{bmatrix}\quad
\boldsymbol{s}_5=\begin{bmatrix}-7\\0\\0\\-2\\1\end{bmatrix}
$$

$\boldsymbol{R}_0\boldsymbol{x}=\boldsymbol{0}$ 的解集是

$$
\left\{\boldsymbol{x}=x_2\boldsymbol{s}_2+x_3\boldsymbol{s}_3+x_5\boldsymbol{s}_5 : x_1,x_3,x_5\in\mathbb{R}\right\}
$$

零空间 $\mathcal{N}(\boldsymbol{A})$ 的维数等于3

原因：每个自由变元都对应于一个基础解. 若方程组有 $n$ 个变元和 $r$ 个主元，则有 $n-r$ 个自由变元以及 $n-r$ 个基础解. 因为 $n-r$ 个基础解的第二、三、五行构成单位阵，因此它们线性无关.

零空间 $\mathcal{N}(\boldsymbol{A})$ 的维数等于 $n-r$，基础解系是一组基.

$\boldsymbol{R}_0^{\mathrm{T}}$ 的零空间（即 $\boldsymbol{R}_0$ 的左零空间）维数等于 $m-r=3-2$.

原因：$\boldsymbol{R}_0$ 有 $r$ 个线性无关的行向量和 $m-r$个零行，因此 $\boldsymbol{R}_0^{\mathrm{T}}$ 有 $r$ 个线性无关的列向量和 $m-r$个零列；所以 $\boldsymbol{y}\in\mathcal{N}(\boldsymbol{R}_0^{\mathrm{T}})$ 的那 $m-r$ 个分量可以非零.

在本例中，$\boldsymbol{R}_0^{\mathrm{T}}$ 只有 $m-r=1$ 个零列，因此 $\boldsymbol{y}$ 可以有 1 个非零分量.

$$\boldsymbol{R}_0^{\mathrm{T}}\boldsymbol{y}=\begin{bmatrix}1&0&0\\3&0&0\\5&0&0\\0&1&0\\7&2&0\end{bmatrix}\begin{bmatrix}y_1\\y_2\\y_3\end{bmatrix}=\begin{bmatrix}0\\0\\0\\0\\0\end{bmatrix},\qquad \text{解为}\quad \boldsymbol{y}=\begin{bmatrix}0\\0\\y_3\end{bmatrix}(y_3\in\mathbb{R}) \tag{3.4}$$

由 $\boldsymbol{R}_0$ 的零行或者 $\boldsymbol{R}_0^{\mathrm{T}}$ 的零列，第四个基本子空间的维数（甚至一组基）就很容易了.

$\boldsymbol{R}_0$ 有 $m-r$ 个零行，它的左零空间维数等于 $m-r$.

为什么我们称之为“左零空间”？对 $\boldsymbol{R}_0^{\mathrm{T}}\boldsymbol{y}=\boldsymbol{0}$ 作转置可得 $\boldsymbol{y}^{\mathrm{T}}\boldsymbol{R}_0=\boldsymbol{0}^{\mathrm{T}}$. 那么 $\boldsymbol{y}^{\mathrm{T}}$ 就是左乘于 $\boldsymbol{R}_0$ 的行向量. 有些线性代数书忽略了第四个子空间，后果是破坏了研究对象的完整性.

> 行空间和零空间是 $\mathbb{R}^n$ 的子空间，维数分别等于 $r$ 和 $n-r$（相加等于 $n$）.
> 列空间和左零空间是 $\mathbb{R}^m$ 的子空间，维数分别等于 $r$ 和 $m-r$（相加等于 $m$）.

我们还有未竟的事业，那就是说明 $\boldsymbol{A}$ 的四个基本子空间和 $\boldsymbol{R}_0$ 的四个基本子空间有相同的维数. 设 $\boldsymbol{A}$ 是一个以 $\boldsymbol{R}_0$ 为最简行阶梯形矩阵的矩阵，例如

$$\boldsymbol{A}=\begin{bmatrix}1&3&5&0&7\\0&0&0&1&2\\1&3&5&1&9\end{bmatrix}$$

和 $\boldsymbol{R}_0$ 有相同的行空间
不同的列空间
但是有相同的维数

### 3.5.2 $A$ 的四个子空间

（1）$\boldsymbol{A}$ 和 $\boldsymbol{R}_0$、$\boldsymbol{R}$ 有相同的行空间，从而有相同的维数和相同的基.

原因：$\boldsymbol{A}$ 的每一行都是 $\boldsymbol{R}_0$ 行向量的线性组合，同时 $\boldsymbol{R}_0$ 的每一行也都是 $\boldsymbol{A}$ 的行向量的线性组合. 消元法改变行向量，但是不改变行空间.

鉴于 $\boldsymbol{A}$ 和 $\boldsymbol{R}_0$ 有相同的行空间，$\boldsymbol{R}_0$ 的前 $r$ 行也是 $\boldsymbol{A}$ 的基. 当然我们也可以选 $\boldsymbol{A}$ 的 $r$ 个合适的行向量作为一组基，但并不总是 $\boldsymbol{A}$ 的前 $r$ 行，因为 $\boldsymbol{A}$ 的前 $r$ 行可能线性相关. 一个“好”的选择是能最终导出 $\boldsymbol{R}_0$ 和 $\boldsymbol{R}$ 的主元行的行向量.[①]

（2）$\boldsymbol{A}$ 的列空间维数等于 $r$，列秩等于行秩.

> 线性无关的列向量的个数 = 线性无关的行向量的个数

错误原因：“$\boldsymbol{A}$ 和 $\boldsymbol{R}_0$ 有相同的列空间”. 这不成立，因为 $\boldsymbol{R}_0$ 的列向量最后面的分量是 0，而往往 $\boldsymbol{A}$ 的列向量最后的分量并不总是零. 所以 $\mathcal{C}(\boldsymbol{A})\neq\mathcal{C}(\boldsymbol{R}_0)$.

① 译者按：译者并不觉得这个选择有优势，既然都得到 $\boldsymbol{R}_0$ 和 $\boldsymbol{R}$ 了，我们有什么理由不直接选 $\boldsymbol{R}_0$ 的非零行作为行向量的一组基，而非要多此一举返回去找对应的 $\boldsymbol{A}$ 的行向量呢？

正确原因：$\boldsymbol{A}$ 和 $\boldsymbol{R}_0$ 的列向量用相同的组合系数作线性组合，得到的向量要么都是零向量，要么都不是零向量. 因此 $\boldsymbol{A}$ 的列向量线性相关，当且仅当 $\boldsymbol{R}_0$ 的列向量线性组关. 也可以从解方程组的角度看:$\boldsymbol{Ax}=\boldsymbol{0}$，当且仅当 $\boldsymbol{R}_0\boldsymbol{x}=\boldsymbol{0}$. 虽然两者的列空间不同，但是它们的维数相同——都等于秩 $r$.

结论：$\boldsymbol{A}$ 的 $r$ 个主元列是列空间 $\mathcal{C}(\boldsymbol{A})$ 的基.

**（3）$\boldsymbol{A}$ 和 $\boldsymbol{R}_0$ 有相同的零空间，从而两者的零空间有相同的维数和基.**

原因：消元法不改变方程组 $\boldsymbol{Ax}=\boldsymbol{0}$ 的解，基础解系是零空间的一组基. 方程组有 $n-r$ 个自由变元，所以零空间的维数是 $n-r$. 这里有一个简单的计数的等式：$\boldsymbol{r+(n-r)=n}$.

（列空间的维数）+（零空间的维数）$=\mathbb{R}^n$的维数

**（4）$\boldsymbol{A}$ 的左零空间**（即 $\boldsymbol{A}^{\mathrm{T}}$ 的零空间）**维数等于$\boldsymbol{m-r}$.**

原因：$\boldsymbol{A}^{\mathrm{T}}$ 与 $\boldsymbol{A}$ 关系紧密是毋庸多言的. 如果每一个 $\boldsymbol{A}$ 的相关子空间的维数都知道，那么 $\boldsymbol{A}^{\mathrm{T}}$ 的自然也知道了. 我们已经证明了 $\boldsymbol{A}^{\mathrm{T}}$ 的列空间维数等于 $r$；由于 $\boldsymbol{A}^{\mathrm{T}}$ 是 $n\times m$ 矩阵，“全空间”已经变成 $\mathbb{R}^m$ 了，对于 $\boldsymbol{A}$ 来说，计数的公式是 $r+(n-r)=n$，**对于 $\boldsymbol{A}^{\mathrm{T}}$ 来说，计数的公式是$\boldsymbol{r+(m-r)=m}$.**

**线性代数基本定理，第一部分**

**矩阵的列空间和行空间的维数都等于$\boldsymbol{r}$.**
**矩阵的零空间和左零空间的维数分别等于$\boldsymbol{n-r}$和$\boldsymbol{m-r}$.**

当我们关注向量构成的线性空间，而非单个的数字或者向量时，就能得到这样“干净”的结论. 以后我们就默认这些事实，当然这些事实在不断地重复中，习惯成自然，也终将变得显然. 但是当你写一个 $11\times 17$ 矩阵，且它的 187 个分量都非零时，我认为大多数人都无法直观地看出来为什么下面的事实成立：

**两个关键事实**

$$\dim\mathcal{C}(\boldsymbol{A})=\dim\mathcal{C}(\boldsymbol{A}^{\mathrm{T}})=\operatorname{rank}(\boldsymbol{A})$$
$$\dim\mathcal{C}(\boldsymbol{A})+\dim\mathcal{N}(\boldsymbol{A})=17$$

任意 $\boldsymbol{b}\in\mathcal{C}(\boldsymbol{A})$，已知存在 $\boldsymbol{x}$ 使得 $\boldsymbol{b}=\boldsymbol{Ax}$；但是在行空间中恰好存在唯一的 $\boldsymbol{x}$ 使得 $\boldsymbol{b}=\boldsymbol{Ax}$.（事实上，如果 $\boldsymbol{y}$ 也属于行空间且 $\boldsymbol{Ay}=\boldsymbol{b}$，那么 $\boldsymbol{A}(\boldsymbol{x}-\boldsymbol{y})=\boldsymbol{0}$，所有 $\boldsymbol{x}-\boldsymbol{y}$ 同时属于零空间和行空间，所以必须有 $\boldsymbol{x}=\boldsymbol{y}$.[①]）

正是零空间启发了我们在第 4.5节中定义的“**$\boldsymbol{A}$的广义逆**”.

**例 3.19**　考虑 $\boldsymbol{A}=\begin{bmatrix}1&2&3\\2&4&6\end{bmatrix}$，$m=2,n=3$. $\boldsymbol{A}$ 的秩是 1.

行空间是过 $\begin{bmatrix}1&2&3\end{bmatrix}^{\mathrm{T}}$ 的直线，零空间是平面 $x_1+2x_2+3x_3=0$. 直线和平面的维数相加：$1+2=3$. 列空间和左零空间是 $\mathbb{R}^2$ 中互相垂直的直线，维数相加：$1+1=2$.

$$\text{列空间}=\text{过}\begin{bmatrix}1\\2\end{bmatrix}\text{的直线}\qquad\text{左零空间}=\text{过}\begin{bmatrix}2\\-1\end{bmatrix}\text{的直线}$$

① 译者注：这里实际上需要证明：$\mathcal{N}(\boldsymbol{A})\cap\mathcal{C}(\boldsymbol{A}^{\mathrm{T}})=\{\boldsymbol{0}\}$，即零空间和行空间只相交于零向量. 我们将在第 4 章中证明.

用左零空间中向量的分量作组合系数，对行向量作线性组合，得到零向量.

**例 3.20** 我们已经用人为编造的方程进行了几乎整整三章了，但是不能永远这么干. 这里有一个五个方程的例子（对图 3.6的每条边都列一个方程）. 该方程组有四个未知数 (每个节点一个未知数). 方程组 $Ax=b$ 的系数矩阵是重要的关联矩阵. 每一行都正好有一个 1 和一个 $-1$.

差分方程组 $Ax=b$
过边 $1,2,3,4,5$
顶点 $1,2,3,4$
$m=5, n=4$

$$\begin{array}{rrrrr} -x_1 & +x_2 & & & =b_1 \\ -x_1 & & +x_3 & & =b_2 \\ & -x_2 & +x_3 & & =b_3 \\ & -x_2 & & +x_4 & =b_4 \\ & & -x_3 & +x_4 & =b_5 \end{array} \tag{3.5}$$

如果你已经理解了矩阵的四个基本子空间（即 $\boldsymbol{A}$ 和 $\boldsymbol{A}^{\mathrm{T}}$ 两者的列空间和零空间），那么你就掌握了线性代数的核心思想.

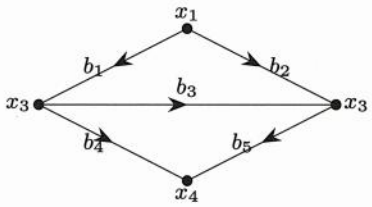


$$\boldsymbol{A}=\begin{bmatrix} -1 & 1 & & \\ -1 & & 1 & \\ & -1 & 1 & \\ & -1 & & 1 \\ & & -1 & 1 \end{bmatrix}$$

图 3.6 4 个顶点、5 条边的图及其关联矩阵

零空间 $\mathcal{N}(\boldsymbol{A})$ 为了求解零空间，我们令 $\boldsymbol{b}=\boldsymbol{0}$. 第一个方程说明 $x_1=x_2$，第二个方程说明 $x_3=x_1$，第四个方程说明 $x_2=x_4$. 因此四个未知数 $x_1$、$x_2$、$x_3$、$x_4$ 取同一个值 $c$，即 $\mathcal{N}(\boldsymbol{A})=\left\{\begin{bmatrix} c & c & c & c \end{bmatrix}^{\mathrm{T}} : c\in\mathbb{R}\right\}$.

该零空间是 $\mathbb{R}^4$ 中的一条直线，基础解 $\boldsymbol{x}=\begin{bmatrix} 1 & 1 & 1 & 1 \end{bmatrix}^{\mathrm{T}}$ 是 $\mathcal{N}(\boldsymbol{A})$ 的一组基；因为基中只有一个向量，所以 $\mathcal{N}(\boldsymbol{A})$ 的维数等于 1. 根据维数公式，$\boldsymbol{A}$ 的秩 $r=4-1=3$. 四个基本子空间的维数就可以从中得出.

列空间 $\mathcal{C}(\boldsymbol{A})$ $\boldsymbol{A}$ 一定有 3 个线性无关的列向量. 快速找到这三列的方法是瞄一眼 $\boldsymbol{A}$ 的前三列；而系统性的方法则是消元法，即找出最简行阶梯形矩阵 $\boldsymbol{R}_0=\mathbf{rref}(\boldsymbol{A})$.

$\boldsymbol{A}$ 的前三列 $\begin{matrix} -1 & 1 & 0 \\ -1 & 0 & 1 \\ 0 & -1 & 1 \\ 0 & -1 & 0 \\ 0 & 0 & -1 \end{matrix}$ $\qquad \boldsymbol{R}_0=$ $\boldsymbol{A}$ 的最简行阶梯型矩阵 $=\begin{bmatrix} 1 & 0 & 0 & -1 \\ 0 & 1 & 0 & -1 \\ 0 & 0 & 1 & -1 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}$

由 $\boldsymbol{R}_0$ 可以再次求出基础解 $\boldsymbol{x}=\begin{bmatrix} 1 & 1 & 1 & 1 \end{bmatrix}^{\mathrm{T}}$. 前三列是主元列，第四列是自由列. 为了得到 $\mathcal{C}(\boldsymbol{A})$ 的基而非 $\mathcal{C}(\boldsymbol{R}_0)$ 的基，我们需要返回去看 $\boldsymbol{A}$ 的前三列，而非 $\boldsymbol{R}_0$ 的前三列. 列空间的维数等于 $r=3$.

行空间 $C(A^{\mathrm{T}})$ 其维数也等于 $r=3$. 但是 $\boldsymbol{A}$ 的前三行满足：第三行 = 第二行 − 第一行，所以线性相关. 作消元时，第三行将成为零行，并与第四行交换. 前三个线性无关的行是第一、二、四行，这三行是行空间的一组基（当然还有其他基）. 因为系数矩阵是图的关联矩阵，行向量的线性相关性和线性无关性其实来源于图的信息：

| | |
|---|---|
| 图的边 1,2,3 形成一个圈 | 矩阵的第 1,2,3 行线性相关 |
| 图的边 1,2,4 形成一个树. 树没圈 | 矩阵的第 1,2,4 行线性无关 |

左零空间 $N(A^{\mathrm{T}})$ 最后我们解方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}=\boldsymbol{0}$，也就是说用行向量线性表出零向量. 已知第三行 = 第一行 − 第二行，所以首先找到解 $\boldsymbol{y}=\begin{bmatrix}1 & -1 & 1 & 0 & 0\end{bmatrix}^{\mathrm{T}}$；这个解来自图上半部分的圈. 那么从图下半部分的圈可得另一个解 $\boldsymbol{y}=\begin{bmatrix}0 & 0 & 1 & -1 & 1\end{bmatrix}^{\mathrm{T}}$：第三行 = 第四行 − 第五行. 这两个解线性无关；又因为 $\dim N(A^{\mathrm{T}})=m-r=5-3=2$，所以它们是左零空间的一组基.

你可能要问，“圈”和“树”是如何进入这个问题中的；如果仅仅从线性代数的角度，自然没有必要. 我们只需要通过消元法解方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}=\boldsymbol{0}$. 那么 $4\times5$ 矩阵 $\boldsymbol{A}^{\mathrm{T}}$ 有三个主元列：第一、第二、第四列，第三列和第五列是自由列，所以 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}=\boldsymbol{0}$ 有两个基础解且 $\dim N(A^{\mathrm{T}})=m-r=5-3=2$. 但是圈和树以一种优美和谐的方式刻画了图的关联矩阵线性相关的行向量和线性无关的行向量.

如果我们把这个图看成电路，方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 给出四个节点之间的电压，那么方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}=\boldsymbol{0}$ 则给出五条边上的电流. 这两个方程就是基尔霍夫电压定律和基尔霍夫电流定律. 虽然这两个定律是电路网络中的规律，但是其背后的思想广泛应用于工程、科学、经济、商业等各个领域. 线性代数把这些规律和矩阵的四个基本子空间紧密联系.

图论是应用离散数学中最重要的模型，几乎所有场合都有图论的身影：道路、管线、血流、大脑、网络和一个国家甚至整个世界的经济. 在这些领域中出现的图都可以用它们关联矩阵 $\boldsymbol{A}$（包括 $\boldsymbol{A}^{\mathrm{T}}$）来研究. 我们把相关的知识点总结如下.

设 $\boldsymbol{A}$ 是某个有 $n$ 个顶点、$m$ 条边的连通图的关联矩阵. $\boldsymbol{A}$ 的行空间和列空间的维数都等于 $r=n-1$. $\boldsymbol{A}$ 和 $\boldsymbol{A}^{\mathrm{T}}$ 的零空间维数分别等于 1 和 $m-n+1$.

| | |
|---|---|
| $N(A)$ | 向量 $\begin{bmatrix}c & c & \cdots & c\end{bmatrix}^{\mathrm{T}}$ $(c\in\mathbb{R})$ 组成了 $\boldsymbol{A}$ 的零空间，维数等于 1. |
| $C(A^{\mathrm{T}})$ | 图的任意一个树的边都给出了 $\boldsymbol{A}$ 的 $r$ 个线性无关的列向量：$r=n-1$. |
| $C(A)$ | 电压定律：所有环路的分量相加等于 0 的向量，维数等于 $n-1$. |
| $N(A^{\mathrm{T}})$ | 电流定律：用环路电流来解方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}=$（流入电流）−（流出电流）$=\boldsymbol{0}$. 图中有 $m-r=m-n+1$ 个线性无关的极小环路[①]. |

对任意平面图，线性代数知识推出了欧拉公式，这是拓扑学中最重要的公式！

$$\text{顶点数}-\text{边数}+\text{极小环路数}=(n)-(m)+(m-n+1)=1$$

① 译者注：此处的极小环路是对原文 small loop 的直译；图论的标准术语应该是“面”，但是“面”和作者 Strang 此处的 small loop 有细微的差异：对于平面图而言，“面”包括图外部无限大的区域（从射影几何或者拓扑的角度看，其实是球面上的图）；根据此处方程组的解释和下面平面图的欧拉公式来理解，small loop 并不包括这个外部区域. 综合上述原因，译者采取了极小环路这个直译. 如果把极小环路改成面，那么欧拉公式更为人所熟知：顶点数 − 边数 + 面数 =2.

### 3.5.3 秩 2 矩阵 = 秩 1 矩阵 + 秩 1 矩阵

秩 1 矩阵都是行向量乘以列向量 $\boldsymbol{u}\boldsymbol{v}^{\mathrm{T}}$ 的形式. 设 $\boldsymbol{A}=\begin{bmatrix}1&0&3\\1&1&7\\4&2&20\end{bmatrix}$，秩为 2. 我们很难直接看出 $\boldsymbol{A}$ 的秩是 2，因此我们需要对 $\boldsymbol{A}$ 做初等行变换转化成最简行阶梯形矩阵 $\boldsymbol{R}_0$. $\boldsymbol{R}_0$ 和 $\boldsymbol{A}$ 有相同的行空间. 忽略零行，我们得到 $\boldsymbol{R}$——它和 $\boldsymbol{A}$ 也有相同的行空间

$$\boldsymbol{A}=\begin{bmatrix}1&0&3\\1&1&7\\4&2&20\end{bmatrix}=\begin{bmatrix}\mathbf{1}&\mathbf{0}\\\mathbf{1}&\mathbf{1}\\\mathbf{4}&\mathbf{2}\end{bmatrix}\begin{bmatrix}\mathbf{1}&\mathbf{0}&\mathbf{3}\\\mathbf{0}&\mathbf{1}&\mathbf{4}\end{bmatrix}=\boldsymbol{C}\boldsymbol{R}$$

我们来看列向量. $\boldsymbol{R}$ 的主元列显然是 $\begin{bmatrix}1&0\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}0&1\end{bmatrix}^{\mathrm{T}}$，那么 $\boldsymbol{A}$ 的主元列也是第一列和第二列：$\boldsymbol{u}_1=\begin{bmatrix}1&1&4\end{bmatrix}^{\mathrm{T}}$，$\boldsymbol{u}_2=\begin{bmatrix}0&1&2\end{bmatrix}^{\mathrm{T}}$. 注意到 $\boldsymbol{C}$ 的列向量就是 $\boldsymbol{u}_1$、$\boldsymbol{u}_2$! 这是因为 $\boldsymbol{R}$ 的前两列是单位阵，因此不改变主元列 $\boldsymbol{u}_1$、$\boldsymbol{u}_2$.

我们把 $\boldsymbol{C}$ 的列向量和 $\boldsymbol{R}$ 的行向量用字母来代替就得到秩 2 矩阵 = 秩 1 矩阵 + 秩 1 矩阵.

$$\text{秩 2 矩阵}\boldsymbol{A}\qquad \boldsymbol{A}=\begin{bmatrix}\boldsymbol{u}_1&\boldsymbol{u}_2&\boldsymbol{u}_3\end{bmatrix}\begin{bmatrix}\boldsymbol{v}_1^{\mathrm{T}}\\\boldsymbol{v}_2^{\mathrm{T}}\\\text{零行}\end{bmatrix}=\boldsymbol{u}_1\boldsymbol{v}_1^{\mathrm{T}}+\boldsymbol{u}_2\boldsymbol{v}_2^{\mathrm{T}}$$

秩为 $r$ 时情况与之类似，我们分别用 $\boldsymbol{C}$ 的列来乘 $\boldsymbol{R}$ 的行，则可得：任何秩为 $r$ 的矩阵都可以写成 $r$ 个秩 1 矩阵的和.

## 例 题 总 结

3.5 A. 将 $5\times 6$ 零矩阵的四个元素改成 1，如何修改能使行空间的维数最小？如何修改能使列空间维数最小？如何修改能使零空间的维数最小？如何修改能使四个基本子空间维数的和最小？

**解** 当四个 1 同处于一行或者同处一列时，矩阵的秩等于 1. 我们还可以把四个 1 摆成一个矩形的四个顶点，即取 $i\neq j$ 并令 $a_{ii}=a_{ij}=a_{ji}=a_{jj}=1$，该矩阵也是秩 1 矩阵. 因为矩阵的行空间和列空间维数始终相等，因此前两个问题的答案相同：最小维数等于 1.

当矩阵的秩等于 4 时，零空间的维数取到可能的最小值 $6-4=2$. 为了让秩等于 4. 我们把这四个 1 分散在四个不同的行和四个不同的列.

四个基本子空间维数的和是不变的：$r+(n-r)+r+(m-r)=m+n$. 所以无论把 1 放在哪儿，四个基本子空间维数的和都等于 11. 即使一个 1 也没有，这个和依然是 11.

如果初始矩阵不是零矩阵，而是分量都是 2 的矩阵，那么问题的答案会如何变化呢？

3.5 B. $\boldsymbol{AB}$ 的行向量都是 $\boldsymbol{B}$ 的行向量的线性组合，所以 $\boldsymbol{AB}$ 的行空间包含于（可能相等）$\boldsymbol{B}$ 的行空间，从而 $\mathrm{rank}(\boldsymbol{AB})\leqslant\mathrm{rank}(\boldsymbol{B})$.

$\boldsymbol{AB}$ 的列向量都是 $\boldsymbol{A}$ 的列向量的线性组合，所以 $\boldsymbol{AB}$ 的列空间包含于（可能相等）$\boldsymbol{B}$ 的列空间，从而 $\mathrm{rank}(\boldsymbol{AB})\leqslant\mathrm{rank}(\boldsymbol{A})$.

$\boldsymbol{A}$ 乘以可逆矩阵$\boldsymbol{B}$，秩不变. 事实上，一方面 $\mathrm{rank}(\boldsymbol{AB}) \leqslant \mathrm{rank}(\boldsymbol{A})$；另一方面 $\mathrm{rank}(\boldsymbol{A}) = \mathrm{rank}((\boldsymbol{AB})\boldsymbol{B}^{-1}) \leqslant \mathrm{rank}(\boldsymbol{AB})$，因此 $\mathrm{rank}(\boldsymbol{A}) = \mathrm{rank}(\boldsymbol{AB})$.

## 习题 3.5

1.（1）若某个 $7 \times 9$ 矩阵秩为 5，它的四个基本子空间的维数是多少？这四个子空间的维数和是多少？

（2）若某个 $3 \times 4$ 矩阵秩为 3，它的列空间和左零空间是什么？

2. 求出矩阵 $\boldsymbol{A} = \begin{bmatrix} 1 & 2 & 4 \\ 2 & 4 & 8 \end{bmatrix}$ 和 $\boldsymbol{B} = \begin{bmatrix} 1 & 2 & 4 \\ 2 & 5 & 8 \end{bmatrix}$ 的四个子空间的基和维数.

3. 求矩阵 $\boldsymbol{A} = \begin{bmatrix} 0 & 1 & 2 & 3 & 4 \\ 0 & 1 & 2 & 4 & 6 \\ 0 & 0 & 0 & 1 & 2 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 0 & 1 & 1 \end{bmatrix} \begin{bmatrix} 0 & 1 & 2 & 3 & 4 \\ 0 & 0 & 0 & 1 & 2 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix}$ 的四个基本子空间的基和维数.

4. 分别构造满足下列性质的矩阵，若不存在，请解释原因.

（1）列空间包含 $\begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}$、$\begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$，行空间包含 $\begin{bmatrix} 1 \\ 2 \end{bmatrix}$、$\begin{bmatrix} 2 \\ 5 \end{bmatrix}$.

（2）列空间的一组基为 $\begin{bmatrix} 1 \\ 1 \\ 3 \end{bmatrix}$，零空间的一组基是 $\begin{bmatrix} 3 \\ 1 \\ 1 \end{bmatrix}$.

（3）零空间的维数 $=1+$ 左零空间的维数.

（4）零空间包含 $\begin{bmatrix} 1 \\ 3 \end{bmatrix}$，列空间包含 $\begin{bmatrix} 3 \\ 1 \end{bmatrix}$.

（5）行空间 $=$ 列空间；零空间 $\neq$ 左零空间.

5. $V \subseteq \mathbb{R}^3$ 是由 $\begin{bmatrix} 1 & 1 & 1 \end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix} 2 & 1 & 0 \end{bmatrix}^{\mathrm{T}}$ 张成的子空间. 试构造一个以 $V$ 为列空间矩阵 $\boldsymbol{A}$，再构造一个以 $V$ 为零空间矩阵 $\boldsymbol{B}$. 计算矩阵乘法 $\boldsymbol{AB}$.

6. 已知 $\boldsymbol{A} = \begin{bmatrix} 0 & 3 & 3 & 3 \\ 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 1 \end{bmatrix}, \boldsymbol{B} = \begin{bmatrix} 1 \\ 4 \\ 5 \end{bmatrix}$，不作消元法，直接求出它们四个基本子空间的维数和基.

7. 设 $\boldsymbol{A}$ 是 $3\times3$ 可逆矩阵，写下 $\boldsymbol{A}$ 的四个基本子空间的一组基，再求出 $3\times6$ 矩阵 $\boldsymbol{B} = \begin{bmatrix} \boldsymbol{A} & \boldsymbol{A} \end{bmatrix}$ 四个基本子空间的一组基（注：$\{\boldsymbol{0}\}$ 的基是空集）.

8. 设 $\boldsymbol{I}$ 是 $3 \times 3$ 单位阵，$\boldsymbol{0}$ 表示 $3 \times 2$ 零矩阵，那么以下三个矩阵 $\boldsymbol{A}$、$\boldsymbol{B}$、$\boldsymbol{C}$ 的四个基本子空间的维数各是多少？

$$\boldsymbol{A} = \begin{bmatrix} \boldsymbol{I} & \boldsymbol{0} \end{bmatrix} \qquad \boldsymbol{B} = \begin{bmatrix} \boldsymbol{I} & \boldsymbol{I} \\ \boldsymbol{0}^{\mathrm{T}} & \boldsymbol{0}^{\mathrm{T}} \end{bmatrix} \qquad \boldsymbol{C} = \begin{bmatrix} \boldsymbol{0} \end{bmatrix}$$

9. 以下两组不同尺寸的矩阵，每一组中两个矩阵的四个基本子空间中有哪几个是相同的？

（1）$\boldsymbol{A}$ 和 $\begin{bmatrix}\boldsymbol{A}\\ \boldsymbol{A}\end{bmatrix}$　　（2）$\begin{bmatrix}\boldsymbol{A}\\ \boldsymbol{A}\end{bmatrix}$ 和 $\begin{bmatrix}\boldsymbol{A} & \boldsymbol{A}\\ \boldsymbol{A} & \boldsymbol{A}\end{bmatrix}$

证明：上述三个矩阵的秩都相等.

10. 若 $3\times 3$ 矩阵的分量随机取值 0 或者 1，那么四个基本子空间的维数最有可能等于多少？如果对 $3\times 5$ 矩阵考虑同样的问题，答案如何？

11.（重要）设 $\boldsymbol{A}$ 是秩为 $r$ 的 $m\times n$ 矩阵. 假设存在 $\boldsymbol{b}$ 使得方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 无解.

（1）$m$、$n$ 和 $r$ 之间满足何种不等式（$<$ 或者 $\leqslant$）？

（2）证明：$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}=\boldsymbol{0}$ 有非零解.

12. 构造一个矩阵，使得其行空间和列空间均以 $\begin{bmatrix}1 & 0 & 1\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}1 & 2 & 0\end{bmatrix}^{\mathrm{T}}$ 为一组基. 为何这两个向量不能同时是某个矩阵的行空间和零空间的基？

13. 判断正误，正确则简述其理由，错误则举反例.

（1）若 $m=n$，则 $\boldsymbol{A}$ 的行空间等于列空间.

（2）矩阵 $\boldsymbol{A}$ 和 $-\boldsymbol{A}$ 的四个基本子空间分别都对应相等.

（3）如果矩阵 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 的四个基本子空间分别都对应相等，则 $\boldsymbol{A}$ 是 $\boldsymbol{B}$ 的常数倍.

14. 对下面矩阵 $\boldsymbol{A}$，不要把它展开计算出来，直接借助乘积式求它的四个基本子空间的一组基.

$$\boldsymbol{A}=\begin{bmatrix}1 & 0 & 0\\ 6 & 1 & 0\\ 9 & 8 & 1\end{bmatrix}\begin{bmatrix}1 & 2 & 3 & 4\\ 0 & 1 & 2 & 3\\ 0 & 0 & 1 & 2\end{bmatrix}$$

15. 把矩阵 $\boldsymbol{A}$ 的前两行对换后得到矩阵 $\boldsymbol{B}$，四个基本子空间中哪几个保持不变？若 $\boldsymbol{v}=\begin{bmatrix}1 & 2 & 3 & 4\end{bmatrix}^{\mathrm{T}}$ 属于 $\boldsymbol{A}$ 的左零空间，请写出 $\boldsymbol{B}$ 的左零空间中的一个非零向量.

16. 说明：为什么 $\boldsymbol{v}=\begin{bmatrix}1 & 0 & -1\end{bmatrix}^{\mathrm{T}}$ 不能既是 $\boldsymbol{A}$ 的行向量，又属于 $\boldsymbol{A}$ 的零空间.

17. 分别描述 $\boldsymbol{A}=\begin{bmatrix}0 & 1 & 0\\ 0 & 0 & 1\\ 0 & 0 & 0\end{bmatrix}$ 和 $\boldsymbol{I}+\boldsymbol{A}=\begin{bmatrix}1 & 1 & 0\\ 0 & 1 & 1\\ 0 & 0 & 1\end{bmatrix}$ 的四个基本子空间.

18. 井字棋游戏[①]结束的局面可以视作 $3\times 3$ 矩阵，其中有 5 个 1 和 4 个 0. 在双方都使用“没有错失必胜招法”的前提下，游戏能否终结于某个秩为 2 的矩阵？

19.（左零空间）我们在矩阵 $\boldsymbol{A}$ 的右侧增加一列 $\boldsymbol{b}$，并转化成阶梯型矩阵：

$$\begin{bmatrix}\boldsymbol{A} & \boldsymbol{b}\end{bmatrix}=\begin{bmatrix}1 & 2 & 3 & b_1\\ 4 & 5 & 6 & b_2\\ 7 & 8 & 9 & b_3\end{bmatrix}\longrightarrow\begin{bmatrix}1 & 2 & 3 & b_1\\ 0 & -3 & -6 & b_2-4b_1\\ 0 & 0 & 0 & b_3-2b_2+b_1\end{bmatrix}$$

① 译者注：井字棋 (tic-tac-toe) 游戏是在 $3\times 3$ 的格子棋盘上进行的一种回合制游戏. 游戏双方选定一种颜色的棋子，例如黑色和白色，由一方先下第一步，然后双方轮流摆放棋子. 任意一方率先在横、竖、斜任意方向的三个棋子连成一条直线即为胜利；若棋盘上的所有格子都已被占用，且没有一方形成连续的三个棋子，则游戏为平局. 比如我们可以把黑棋视作数字 1，白棋视作数字 0，黑棋先下. “没有错失必胜招法”也可以理解为每一步都是最优招法.

$\boldsymbol{A}$ 的行向量的某个线性组合是零向量，请写出一个这样的线性组合（提示：观察右侧的 $b_3-2b_2+b_1$）. $\boldsymbol{A}$ 和 $\boldsymbol{A}^{\mathrm{T}}$ 的零空间中分别有哪些向量？

20.（耐心的考验）请描述：从矩阵 $\boldsymbol{A}$ 做初等行变换到它的最简行阶梯型矩阵 $\boldsymbol{R}_0$ 的过程.

21. 设 $\boldsymbol{A}$ 是两个秩 1 矩阵的和：$\boldsymbol{A}=\boldsymbol{u}\boldsymbol{v}^{\mathrm{T}}+\boldsymbol{w}\boldsymbol{z}^{\mathrm{T}}$.

（1）哪几个向量张成 $\boldsymbol{A}$ 的列空间？

（2）哪几个向量张成 $\boldsymbol{A}$ 的行空间？

（3）如果_____ 或者_____，则 $\boldsymbol{A}$ 的秩严格小于 2.

（4）当 $\boldsymbol{u}=\boldsymbol{z}=\begin{bmatrix}1 & 0 & 0\end{bmatrix}^{\mathrm{T}}$，$\boldsymbol{v}=\boldsymbol{w}=\begin{bmatrix}0 & 0 & 1\end{bmatrix}^{\mathrm{T}}$ 时，计算矩阵 $\boldsymbol{A}$ 和 $\boldsymbol{A}$ 的秩.

22. 构造以 $\begin{bmatrix}1 & 2 & 4\end{bmatrix}^{\mathrm{T}}$、$\begin{bmatrix}2 & 2 & 1\end{bmatrix}^{\mathrm{T}}$ 为列向量的一组基，以 $\begin{bmatrix}1 & 0\end{bmatrix}^{\mathrm{T}}$、$\begin{bmatrix}1 & 1\end{bmatrix}^{\mathrm{T}}$ 为行空间的一组基的矩阵 $\boldsymbol{A}=\boldsymbol{u}\boldsymbol{v}^{\mathrm{T}}+\boldsymbol{w}\boldsymbol{z}^{\mathrm{T}}$，然后把 $\boldsymbol{A}$ 写成 $3\times 2$ 矩阵和 $2\times 2$ 矩阵的乘积.

23. 不把矩阵乘法算出来，直接找出 $\boldsymbol{A}=\begin{bmatrix}1 & 2\\ 4 & 5\\ 2 & 7\end{bmatrix}\begin{bmatrix}3 & 0 & 3\\ 1 & 1 & 2\end{bmatrix}$ 行空间和列空间的一组基. 能否从这些矩阵的形状看出 $\boldsymbol{A}$ 是否为可逆矩阵？

24.（重要）当 $\boldsymbol{d}$ 属于 $\boldsymbol{A}$ 的四个基本子空间中哪一个时，$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}=\boldsymbol{d}$ 有解？当_____ 只包含零向量时，该方程组的解 $\boldsymbol{y}$ 唯一.

25. 判断正误，正确则简述其理由，错误则举出反例.

（1）$\boldsymbol{A}$ 和 $\boldsymbol{A}^{\mathrm{T}}$ 主元个数相等.

（2）$\boldsymbol{A}$ 和 $\boldsymbol{A}^{\mathrm{T}}$ 的左零空间相同.

（3）若 $\boldsymbol{A}$ 的行空间和列空间相同，则 $\boldsymbol{A}^{\mathrm{T}}=\boldsymbol{A}$.

（4）若 $\boldsymbol{A}^{\mathrm{T}}=\boldsymbol{A}$，则 $\boldsymbol{A}$ 的行空间和列空间相同.

26. 给定 $a$、$b$、$c$ 且 $a\neq 0$，那么 $d$ 取什么值时，$\begin{bmatrix}a & b\\ c & d\end{bmatrix}$ 的秩是 1.

## 挑 战 一 下

27. 国际象棋的棋盘是 $8\times 8$ 的正方形，棋子有车（$r$）、马（$h$）、象（$b$）、王后（$q$）、国王（$k$）和兵（$p$）. 考虑“棋盘矩阵”$\boldsymbol{B}$ 和“国象矩阵”$\boldsymbol{C}$

$$\boldsymbol{B}=\begin{bmatrix}1 & 0 & 1 & 0 & 1 & 0 & 1 & 0\\ 0 & 1 & 0 & 1 & 0 & 1 & 0 & 1\\ 1 & 0 & 1 & 0 & 1 & 0 & 1 & 0\\ \cdot & \cdot & \cdot & \cdot & \cdot & \cdot & \cdot & \cdot\\ 0 & 1 & 0 & 1 & 0 & 1 & 0 & 1\end{bmatrix},\qquad \boldsymbol{C}=\begin{bmatrix}r & n & b & q & k & b & n & r\\ p & p & p & p & p & p & p & p\\ & & & 4\text{ 个零行} & & & & \\ p & p & p & p & p & p & p & p\\ r & n & b & q & k & b & n & r\end{bmatrix}$$

其中 $r$、$n$、$b$、$q$、$k$、$p$ 互不相等. 求 $\boldsymbol{B}$ 和 $\boldsymbol{C}$ 的行空间和左零空间的一组基，求 $\boldsymbol{C}$ 零空间的一组基.

28. 若 $\boldsymbol{A}=\boldsymbol{u}\boldsymbol{v}^{\mathrm{T}}$ 是秩为 1 的 $2\times 2$ 矩阵，将图 3.5画一遍，各个空间、维数都根据 $\boldsymbol{A}$ 的实际情况表达出来. 若 $\boldsymbol{B}$ 和 $\boldsymbol{A}$ 有相同的四个基本子空间，那么 $\boldsymbol{B}$ 和 $\boldsymbol{A}$ 有什么关系？

29. 设 $M$ 是所有 $3\times 3$ 矩阵的全体，对任意 $\boldsymbol{X}\in M$，我们都左乘上 $\boldsymbol{A}$，其中

$$\boldsymbol{A}=\begin{bmatrix}1&0&-1\\-1&1&0\\0&-1&1\end{bmatrix}.\qquad \text{注意：}\boldsymbol{A}\begin{bmatrix}1\\1\\1\end{bmatrix}=\begin{bmatrix}0\\0\\0\end{bmatrix}.$$

（1）哪些矩阵 $\boldsymbol{X}$ 满足 $\boldsymbol{AX}=$ 零矩阵？

（2）哪些矩阵可以写成 $\boldsymbol{AX}$ 的形式？

（1）实际上是求 $\boldsymbol{X}\mapsto\boldsymbol{AX}$ 这个映射的“零空间”，（2）是在求它的“列空间”. $M$ 的这两个子空间的维数是多少？它们加起来为什么等于 9?

30. 设 $m\times n$ 矩阵 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 有相同的四个基本子空间，若它们都是最简行阶梯型矩阵：

$$\boldsymbol{A}=\begin{bmatrix}\boldsymbol{I}&\boldsymbol{F}\\\boldsymbol{0}&\boldsymbol{0}\end{bmatrix}\qquad \boldsymbol{B}=\begin{bmatrix}\boldsymbol{I}&\boldsymbol{G}\\\boldsymbol{0}&\boldsymbol{0}\end{bmatrix}$$

那么是否一定有 $\boldsymbol{F}=\boldsymbol{G}$?

31. 写出图 3.7四个顶点、六条边的完全图的关联矩阵，求出该关联矩阵的四个基本子空间和秩.

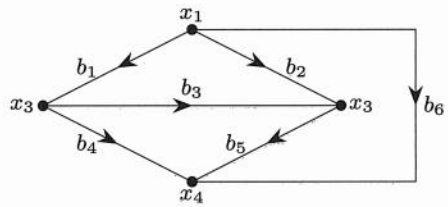


图 3.7　4 个顶点的完全有向图

32.（复习）

（1）$\mathcal{N}(\boldsymbol{AB})$ 和 $\mathcal{N}(\boldsymbol{BA})$ 是否包含于 $\mathcal{N}(\boldsymbol{A})$?

（2）$\mathcal{C}(\boldsymbol{AB})$ 和 $\mathcal{C}(\boldsymbol{BA})$ 是否包含于 $\mathcal{C}(\boldsymbol{A})$?

33. 设 $\boldsymbol{A}$ 是 $m\times n$ 矩阵，$\boldsymbol{B}$ 是 $m\times n$ 矩阵，$\boldsymbol{T}=\begin{bmatrix}\boldsymbol{A}\\\boldsymbol{B}\end{bmatrix}$.

（1）$\boldsymbol{T}$ 的零空间和 $\boldsymbol{A}$、$\boldsymbol{B}$ 的零空间是什么关系？

（2）$\boldsymbol{T}$ 的行空间和 $\boldsymbol{A}$、$\boldsymbol{B}$ 的零空间是什么关系？

34. 设 $\boldsymbol{A}$ 是 $m\times n$ 矩阵，那么 $\boldsymbol{W}=\begin{bmatrix}\boldsymbol{A}&\boldsymbol{A}\end{bmatrix}$ 和 $\boldsymbol{A}$ 的四个基本子空间有什么关系？

35. 若 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 都是 $n\times n$ 矩阵，那么 $\operatorname{rank}\begin{bmatrix}\boldsymbol{A}\\\boldsymbol{B}\end{bmatrix}=\operatorname{rank}\begin{bmatrix}\boldsymbol{A}&\boldsymbol{B}\end{bmatrix}$ 是否一定成立？

## 3.6　谈谈第 3 章：消元法的全局理解

本节我们从向量层面和子空间层面分别谈谈消元法. 鉴于大家已经知道如何从任意一个矩阵 $\boldsymbol{A}$ 出发做初等行变换得到它的最简行阶梯型矩阵，我就不再详细重复这个步骤了. 对于上三角矩阵

$\boldsymbol{U}$，消元法从第一个主元开始，每一次从左往右移动一列，并从上往下移动一行. 直到没有非零行，再转而向上消元可得 $\boldsymbol{R}_0$ 和 $\boldsymbol{R}$. 消元法回答了以下两个问题.

**问题 1　每一列是否是它前面那些列的线性组合？**

若该列是主元列，则答案是否定的；主元列不能被前面的列线性表出. 如果第四列没有主元，那么它可以被第一、二、三列线性表出.

**问题 2　每一行是否是它前面那些行的线性组合？**

若该行有主元，则答案是否定的；主元行不能被上面的行线性表出，且它的第一个非零元 1 来自单位子矩阵. $\boldsymbol{R}_0$ 可能有零行，这导致它的行向量可能线性相关；但是这些零行删掉之后，就得到了 $r \times n$ 行满秩矩阵 $\boldsymbol{R}$.

我觉得令人惊奇的是，竟然只要对矩阵变换一遍就能同时回答这两个问题. 消元法做的是行变换，但结果却揭示了列的信息！$\boldsymbol{R}$ 所包含的单位子矩阵告诉我们矩阵 $\boldsymbol{A}$ 的前 $r$ 个线性无关的列向量；$\boldsymbol{R}$ 的自由列 $\boldsymbol{F}$ 告诉我们这些线性无关的列如何线性组合出 $\boldsymbol{A}$ 的自由列. 如果没有矩阵分解 $\boldsymbol{A}=\boldsymbol{CR}$，这一现象不是那么容易看出来的.

**我们也可以从 $\boldsymbol{R}$ 解出 $\boldsymbol{Ax}=\boldsymbol{0}$ 的基础解系.** 尽管可以通过不同的消元法的步骤得到最简行阶梯形矩阵（以及 $\boldsymbol{R}$），但是最终结果相同. 这是因为基础解系由 $\boldsymbol{A}$ 完全决定，见 3.2节习题之前的公式. $\boldsymbol{R}$ 也揭示了 $\boldsymbol{A}$ 的四个基本子空间其中三个子空间的一组基：

$\boldsymbol{A}$ 的列空间——$\boldsymbol{R}$ 的 $r$ 个主元所在列的 $\boldsymbol{A}$ 的列向量.

$\boldsymbol{A}$ 的行空间——$\boldsymbol{R}$ 的 $r$ 个行向量.

$\boldsymbol{A}$ 的零空间——$\boldsymbol{Rx}=\boldsymbol{0}$ 的基础解系，它们也是 $\boldsymbol{Ax}=\boldsymbol{0}$ 的 $n-r$ 个解.

还剩下左零空间 $\mathcal{N}(\boldsymbol{A}^{\mathrm{T}})$. 我们看一下消元法：$\boldsymbol{EA}=\boldsymbol{R}_0$，$\boldsymbol{R}_0$ 的后 $m-r$ 行是零行，所以 $\boldsymbol{E}$ 的后 $m-r$ 行是左零空间的一组基！为了记录 $\boldsymbol{E}$ 的信息，我们对矩阵 $\begin{bmatrix}\boldsymbol{A} & \boldsymbol{I}\end{bmatrix}$ 做初等行变换，将之转化成 $\begin{bmatrix}\boldsymbol{R}_0 & \boldsymbol{E}\end{bmatrix}$. 否则，$\boldsymbol{E}$ 就被忽略了.

给定两个秩为 $r$ 的矩阵：$m \times r$ 矩阵 $\boldsymbol{B}$ 和 $r \times n$ 矩阵 $\boldsymbol{C}$. 对任意 $r \times r$ 可逆矩阵 $\boldsymbol{M}$，$\boldsymbol{CMB}$ 的四个基本子空间都相同，反之亦然. 言下之意，若矩阵 $\boldsymbol{A}$ 和 $\boldsymbol{CB}$ 有相同的四个基本子空间，则存在可逆矩阵 $\boldsymbol{M}$ 使得 $\boldsymbol{A}=\boldsymbol{CMB}$.

最后提一下，本书是第一本用矩阵分解 $\boldsymbol{A}=\boldsymbol{CR}=\boldsymbol{C}\begin{bmatrix}\boldsymbol{I} & \boldsymbol{F}\end{bmatrix}\boldsymbol{P}$（其中 $\boldsymbol{P}$ 是置换矩阵）来叙述消元法的教材. 从消元法得到 $\boldsymbol{C}$、$\boldsymbol{F}$ 和 $\boldsymbol{P}$ 以及 $\boldsymbol{A}=\begin{bmatrix}\boldsymbol{C} & \boldsymbol{CF}\end{bmatrix}\boldsymbol{P}$.

$$\boldsymbol{A}=\begin{bmatrix}\text{主元列}\boldsymbol{C} & \text{自由列}\boldsymbol{CF}\end{bmatrix}\text{置换矩阵}$$

**回顾：对 $m \times n$ 矩阵 $\boldsymbol{A}$ 做初等行变换**

① 某一行减去另一行的若干倍
② 交换两行
③ 某一行乘以一个非零常数

关键是这三种变换都是可逆的：

① 某一行加上另一行的同样的倍数
② 再次交换两行
③ 某一行除以同一个非零常数

整体来看，对 $\boldsymbol{A}$ 做初等行变换等价于：对 $\boldsymbol{A}$ 左乘一个 $m \times m$ 可逆矩阵 $\boldsymbol{E}$.

零空间不变的原因是：$\boldsymbol{Ax}=\boldsymbol{0} \Rightarrow \boldsymbol{EAx}=\boldsymbol{0}$，且 $\boldsymbol{EAx}=\boldsymbol{0} \Rightarrow \boldsymbol{Ax}=\boldsymbol{E}^{-1}\boldsymbol{EAx}=\boldsymbol{0}$.

$\boldsymbol{A}$ 和 $\boldsymbol{EA}$ 的行向量不一样，但是它们的行空间和零空间相同.

最简行阶梯型矩阵：存在可逆矩阵 $\boldsymbol{E}$ 使得 $\boldsymbol{EA}=\boldsymbol{R}_0=\begin{bmatrix}\boldsymbol{I} & \boldsymbol{F}\\ \boldsymbol{0} & \boldsymbol{0}\end{bmatrix}\boldsymbol{P}=\mathbf{rref}(\boldsymbol{A})$.

其中的单位阵 $\boldsymbol{I}$ 是 $r \times r$ 矩阵，$\boldsymbol{F}$ 是 $r \times (n-r)$ 矩阵，$\boldsymbol{P}$ 是某个 $n$ 阶置换矩阵.

矩阵分解：$\boldsymbol{A}=\boldsymbol{CR}=\begin{bmatrix}\text{前 } r \text{ 个线性无关的列向量}\end{bmatrix}\begin{bmatrix}\boldsymbol{I} & \boldsymbol{F}\end{bmatrix}\boldsymbol{P}$，

$$\boldsymbol{A}=\begin{bmatrix}\boldsymbol{C} & \boldsymbol{CF}\end{bmatrix}\boldsymbol{P}=\begin{bmatrix}\text{主元列} & \text{自由列}\end{bmatrix}\text{置换矩阵}$$

$\boldsymbol{A}$ 的零空间：$\boldsymbol{F}$ 的每一列都给出 $\boldsymbol{Ax}=\boldsymbol{0}$ 的一个基础解：

$$\text{基础解}\qquad \boldsymbol{s}_k=\boldsymbol{P}^{\mathrm{T}}\begin{bmatrix}-\boldsymbol{F}\text{的第 } k \text{ 列}\\ +\boldsymbol{I}_{n-r}\text{的第 } k \text{ 列}\end{bmatrix}$$

这里 $\boldsymbol{I}_{n-r}$ 是 $(n-r)\times(n-r)$ 单位阵. $\boldsymbol{P}^{\mathrm{T}}$ 把 $\boldsymbol{s}_k$ 的每个分量放在正确的位置.

对下面的例子，$\boldsymbol{P}=\boldsymbol{I}$，秩 $r=3$，$\boldsymbol{Ax}=\boldsymbol{0}$ 和 $\boldsymbol{Rx}=\boldsymbol{0}$ 的基础解 $\boldsymbol{s}_1$ 为

$$\boldsymbol{R}=\begin{bmatrix}1 & 0 & 0 & 3\\ 0 & 1 & 0 & 4\\ 0 & 0 & 1 & 5\end{bmatrix}\qquad \boldsymbol{s}_1=\begin{bmatrix}-3\\ -4\\ -5\\ 1\end{bmatrix}\qquad \boldsymbol{Rs}_1=\boldsymbol{0},\qquad \boldsymbol{As}_1=\boldsymbol{CRs}_1=\boldsymbol{0}.$$

# 第 4 章

CHAPTER 4

# 正　交　性

如果向量 $\boldsymbol{v}$ 和 $\boldsymbol{w}$ 的内积等于零，即 $\boldsymbol{v}\cdot\boldsymbol{w}=\boldsymbol{v}^{\mathrm{T}}\boldsymbol{w}=0$，则称它们正交[①]. 本章的主要学习内容如下：

（1）互相正交的子空间：两个子空间中分别任取一个向量都是正交的；

（2）正交基：其中任意两个向量都正交；

（3）正交矩阵：任意两个列向量都正交.

若 $\boldsymbol{v}$ 和 $\boldsymbol{w}$ 正交，它们可以成为直角三角形的直角边，根据勾股定理则有

$$\boxed{\text{正交的向量}\qquad \boldsymbol{v}^{\mathrm{T}}\boldsymbol{w}=0 \text{ 且 } \|\boldsymbol{v}\|^2+\|\boldsymbol{w}\|^2=\|\boldsymbol{v}+\boldsymbol{w}\|^2.}$$

具体来说，斜边长的平方等于 $\|\boldsymbol{v}+\boldsymbol{w}\|^2=(\boldsymbol{v}+\boldsymbol{w})^{\mathrm{T}}(\boldsymbol{v}+\boldsymbol{w})$，于是当 $\boldsymbol{v}^{\mathrm{T}}\boldsymbol{w}=\boldsymbol{w}^{\mathrm{T}}\boldsymbol{v}=0$ 时，$\|\boldsymbol{v}+\boldsymbol{w}\|^2=\boldsymbol{v}^{\mathrm{T}}\boldsymbol{v}+\boldsymbol{w}^{\mathrm{T}}\boldsymbol{w}$.

为了刻画方程组 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 的解集，我们在第 3 章引入了子空间的概念. 矩阵的列空间和零空间是我们首先研究的两个子空间，接着，焦点转向了 $\boldsymbol{A}^{\mathrm{T}}$（$\boldsymbol{A}$ 的转置），它给了我们另外两个子空间. 这四个基本子空间展现了矩阵真正的作用.

我们可以从三个层面去理解矩阵 $\boldsymbol{A}$ 和向量 $\boldsymbol{x}$ 相乘. 第一个层面是数值：即 $\boldsymbol{A}\boldsymbol{x}$ 的每一个分量是多少；第二个层面是向量：$\boldsymbol{A}\boldsymbol{x}$ 是 $\boldsymbol{A}$ 列向量的线性组合；第三个层面是子空间. 但是我认为读者只有在看懂了图 4.1之后才能说真正弄清楚了完整的理论. 四个基本子空间分成两对互相正交的子空间.

$$\boxed{\begin{array}{l}\text{零空间 } \mathcal{N}(\boldsymbol{A}) \text{ 恰好由与行空间 } \mathcal{C}(\boldsymbol{A}^{\mathrm{T}}) \text{ 正交的向量构成.}\\ \text{左零空间 } \mathcal{N}(\boldsymbol{A}^{\mathrm{T}}) \text{ 恰好由与列空间 } \mathcal{C}(\boldsymbol{A}) \text{ 正交的向量构成.}\end{array}}$$

方程组 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$ 的意思即 $\boldsymbol{x}$ 和 $\boldsymbol{A}$ 的每一个行向量都正交；同理，方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}=\boldsymbol{0}$ 意即 $\boldsymbol{y}$ 和 $\boldsymbol{A}$ 的每一个列向量都正交.

本章另一个重要的思想是正交投影：如果 $\boldsymbol{b}\notin\mathcal{C}(\boldsymbol{A})$，我们要在 $\mathcal{C}(\boldsymbol{A})$ 中找出和 $\boldsymbol{b}$ 距离最近的向量 $\boldsymbol{p}$. $\boldsymbol{b}$ 和 $\boldsymbol{p}$ 的差是误差 $\boldsymbol{e}$. 误差项 $\boldsymbol{e}$ 和列空间正交. 最小二乘方程 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$ 可以解出要

① 译者注：在之前的章节，我们有一个类似的术语是“垂直”，如果仅限于两个向量，那么垂直和正交是一样的. 但是当我们谈论子空间时，就容易出现歧义. 例如，在中学阶段的立体几何中我们学习过“三维空间中垂直的两个平面”，但是在线性代数中，三维空间中任意两个平面都不正交；为了防止这一类混淆，译者建议尽量不使用“垂直”这个术语，统一成“正交”. 另外，垂直更倾向于几何上的直观意义，正交相对而言代数的意味更强，在高维的情况下，我们已经很难想象垂直该是什么样子了.

求的 $\boldsymbol{p}=\boldsymbol{A}\hat{\boldsymbol{x}}$ 和误差项 $\boldsymbol{e}$. 当 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 无解时，$\hat{\boldsymbol{x}}$ 是某种意义上的最优选项：$\hat{\boldsymbol{x}}$ 是使得 $\|\boldsymbol{A}\hat{\boldsymbol{x}}-\boldsymbol{b}\|^2$ 取最小值的向量——即最小二乘解.[①]

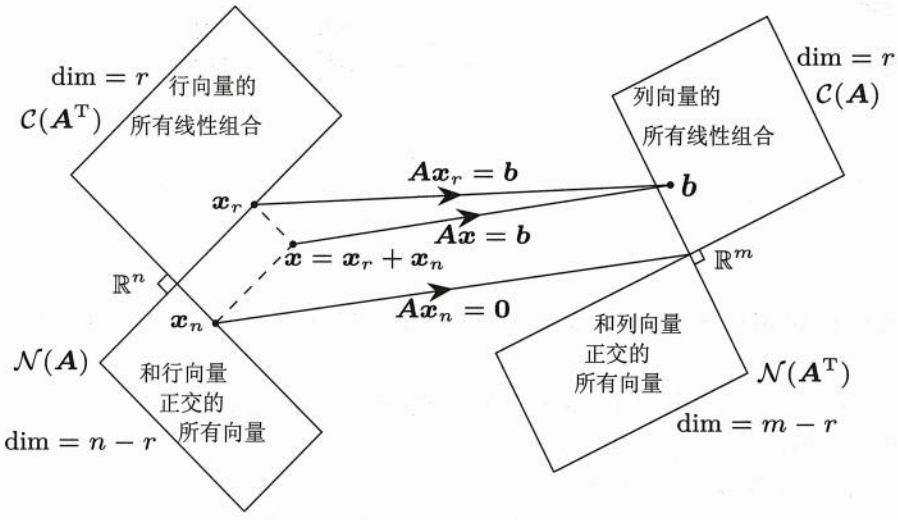


图 4.1 四个基本子空间、方程组的解和最短解

注：$\boldsymbol{A}\boldsymbol{x}_r=\boldsymbol{b}$ 属于列空间，$\boldsymbol{A}\boldsymbol{x}_n=\boldsymbol{0}$，$\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 的解集是 $\boldsymbol{x}$ =唯一的 $\boldsymbol{x}_r$+ 所有 $\boldsymbol{x}_n$，进而 $\|\boldsymbol{x}\|^2=\|\boldsymbol{x}_r\|^2+\|\boldsymbol{x}_n\|^2$ 且 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 的长度最小的解为 $\boldsymbol{x}=\boldsymbol{x}_r$.

如果 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}=\boldsymbol{I}$，那么方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{x}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$ 的解是显然的. 这种情况下，$\boldsymbol{A}$ 的列向量是相互正交的单位向量. 没有那么多巧合正好让 $\boldsymbol{A}$ 满足这个性质，但是我们可以构造. 在 4.4节中，我们将从列向量 $\boldsymbol{a}_1,\boldsymbol{a}_2,\cdots,\boldsymbol{a}_n$ 出发，构造向量 $\boldsymbol{q}_1,\boldsymbol{q}_2,\cdots,\boldsymbol{q}_n$，使得矩阵 $\boldsymbol{Q}=\begin{bmatrix}\boldsymbol{q}_1 & \cdots & \boldsymbol{q}_n\end{bmatrix}$ 满足 $\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{Q}=\boldsymbol{I}$ 以及 $\boldsymbol{Q}\boldsymbol{R}=\boldsymbol{A}$，其中 $\boldsymbol{R}$ 是某个上三角矩阵.

正交矩阵在计算上堪称完美！正交矩阵的乘积还是正交矩阵. 在很多情况下，$\boldsymbol{Q}\boldsymbol{R}$ 分解都优于 $\boldsymbol{L}\boldsymbol{U}$ 分解，其原因也将在本章说明.

## 4.1 向量和子空间的正交性

（1）向量 $\boldsymbol{v}$ 和 $\boldsymbol{w}$ 正交的意思是 $\boldsymbol{v}^{\mathrm{T}}\boldsymbol{w}=0$；如同勾股定理 $a^2+b^2=c^2$，我们有 $\|\boldsymbol{v}\|^2+\|\boldsymbol{w}\|^2=\|\boldsymbol{v}+\boldsymbol{w}\|^2$.

（2）设 $V$、$W$ 是两个线性子空间，若任意 $\boldsymbol{v}\in V$ 和任意 $\boldsymbol{w}\in W$ 都正交，则称 $V$ 和 $W$ 正交.

（3）$\boldsymbol{A}$ 的行空间和零空间正交，列空间和左零空间正交.

（4）（3）中的两对子空间维数满足 $r+(n-r)=n$ 和 $r+(m-r)=m$，这两对子空间互为

① 译者注："二乘"其实就是平方，这个词汇可考的是 square 早期的日文翻译"にじょう"；清末民初引进西方的科学技术时，很多是从日本引进的；很多学术词汇，因为日文和中文有很多共通之处，也是采用了日文的翻译，因此很多翻译和术语就作为历史沿革和学术习惯保留了下来.《九章算术》以及刘徽的注中，已经用了"再乘"、"自乘"等词来表示平方. 至于古代日本在引进中国文化时，有没有吸收"再乘"一词并演化成"二乘"一词，译者没有能力再去考证了.

正交补空间.
(5) $\mathbb{R}^n$ 中 $n$ 个线性无关的向量组张成 $\mathbb{R}^n$. 反之，若 $\mathbb{R}^n$ 中 $n$ 个向量张成 $\mathbb{R}^n$，则它们线性无关.

第 1 章把向量 $\boldsymbol{v}$ 和 $\boldsymbol{w}$ 的点积 $\boldsymbol{v}^{\mathrm{T}}\boldsymbol{w}$ 与它们的夹角相联系. 若角度是 90°，那么 $\boldsymbol{v}^{\mathrm{T}}\boldsymbol{w}=0$，此时向量 $\boldsymbol{v}$、$\boldsymbol{w}$ 和 $\boldsymbol{v}+\boldsymbol{w}$ 构成直角三角形，三条边长 $a$、$b$、$c$ 或者说 $\|\boldsymbol{v}\|$、$\|\boldsymbol{w}\|$、$\|\boldsymbol{v}+\boldsymbol{w}\|$ 满足勾股定理 $a^2+b^2=c^2$:

$$\boxed{\text{正交的向量}\qquad \boldsymbol{v}^{\mathrm{T}}\boldsymbol{w}=0 \text{ 且 } \|\boldsymbol{v}\|^2+\|\boldsymbol{w}\|^2=\|\boldsymbol{v}+\boldsymbol{w}\|^2.}$$

原因在于：

$$\text{等号右边}=(\boldsymbol{v}+\boldsymbol{w})^{\mathrm{T}}(\boldsymbol{v}+\boldsymbol{w})=\boldsymbol{v}^{\mathrm{T}}\boldsymbol{v}+\boldsymbol{w}^{\mathrm{T}}\boldsymbol{w}+\boldsymbol{v}^{\mathrm{T}}\boldsymbol{w}+\boldsymbol{w}^{\mathrm{T}}\boldsymbol{v}=\boldsymbol{v}^{\mathrm{T}}\boldsymbol{v}+\boldsymbol{w}^{\mathrm{T}}\boldsymbol{w}+0+0.$$

不局限于平面，我们可以考虑任意 $\mathbb{R}^n$ 中的向量，用正交这个概念来替换垂直，仍然有直角三角形及勾股定理.

在三维空间中，若一条直线上（一维子空间）的所有向量都正交于某个平面上（二维子空间）的向量，那么该直线和平面正交. 在更高的维数下，我们借助矩阵的行空间和零空间来判断子空间的正交性.

$$\boxed{\text{由方程组 } \boldsymbol{A}\boldsymbol{x}=\boldsymbol{0} \text{ 可知，} \boldsymbol{A} \text{ 的零空间和它的行空间正交.}}$$

$$\boldsymbol{A}=\begin{bmatrix}\text{第 1 行}\\ \vdots \\ \text{第 } m \text{ 行}\end{bmatrix}\begin{bmatrix}\boldsymbol{x}\end{bmatrix}\quad\begin{matrix}\longleftarrow\\ \\ \longleftarrow\end{matrix}\quad\begin{matrix}\text{第 1 行}\cdot\boldsymbol{x}=0\\ \vdots \\ \text{第 } m \text{ 行}\cdot\boldsymbol{x}=0\end{matrix}\tag{4.1}$$

也就是说，每一行和 $\boldsymbol{x}$ 的点积都是 0，从而行向量的任意线性组合和 $\boldsymbol{x}$ 的点积也是 0，所以行空间 $\mathcal{C}(\boldsymbol{A}^{\mathrm{T}})$ 和零空间正交.

为了避免混淆，需要再强调一下我们的约定——所有的向量都是列向量. 因此，当我们说 $\boldsymbol{A}$ 的行向量时，实际上指的是 $\boldsymbol{A}^{\mathrm{T}}$ 的列向量，行空间的元素指的是 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}$. 那么行空间和零空间正交这个事实，我们可以形式地给予证明：

$$\forall \boldsymbol{x}\in\mathcal{N}(\boldsymbol{A}),\forall \boldsymbol{y}\in\mathbb{R}^m,\qquad \boldsymbol{x}^{\mathrm{T}}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y})=(\boldsymbol{A}\boldsymbol{x})^{\mathrm{T}}\boldsymbol{y}=\boldsymbol{0}^{\mathrm{T}}\boldsymbol{y}=0.\tag{4.2}$$

我个人还是更喜欢式(4.1)的论证方式，从中可以直接看到 $\boldsymbol{A}$ 的行向量和 $\boldsymbol{x}$ 点积为 0，并进一步地得到行向量的所有线性组合和 $\boldsymbol{x}$ 点积仍然为 0. 相比而言这种方式比较直观，而式(4.2)就略显严肃和正式，像一个一板一眼的“老古董”.

**重点** 我们还有一对互相正交的子空间：$\boldsymbol{A}$ 的列空间 $\mathcal{C}(\boldsymbol{A})$ 和左零空间 $\mathcal{N}(\boldsymbol{A}^{\mathrm{T}})$，它们是 $\mathbb{R}^m$ 中正交的线性子空间.

要理解这一点，只需要把先前对 $\boldsymbol{A}$ 的说明全部照搬到 $\boldsymbol{A}^{\mathrm{T}}$ 上. $\boldsymbol{A}^{\mathrm{T}}$ 的行空间是 $\boldsymbol{A}$ 的列空间，行空间和零空间的正交性应用于 $\boldsymbol{A}^{\mathrm{T}}$ 即得**列空间 $\mathcal{C}(A)$ 和左零空间 $\mathcal{N}(A^{\mathrm{T}})$ 正交.**

**例 4.1** 设 $\boldsymbol{A}=\begin{bmatrix}1 & -2 & 1\\ 1 & 0 & -1\end{bmatrix}$，$\boldsymbol{x}=\begin{bmatrix}1 & 1 & 1\end{bmatrix}^{\mathrm{T}}$ 是 $\mathcal{N}(\boldsymbol{A})$ 的基，

行空间
零空间

$$\boldsymbol{A}\boldsymbol{x}=\begin{bmatrix}1 & -2 & 1\\ 1 & 0 & -1\end{bmatrix}\begin{bmatrix}1\\1\\1\end{bmatrix}=\begin{bmatrix}0\\0\end{bmatrix}$$

第一个点积：$1-2+1=0$
第二个点积：$1+0-1=0$

注意到 $\mathcal{N}(\boldsymbol{A}^{\mathrm{T}})=\{\boldsymbol{0}\}$，$\boldsymbol{A}$ 的三个列向量（也就是 $\boldsymbol{A}^{\mathrm{T}}$ 的行向量）都和 $\boldsymbol{y}=\boldsymbol{0}\in\mathcal{N}(\boldsymbol{A}^{\mathrm{T}})$ 正交：

列空间
左零空间

$$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}=\begin{bmatrix}1 & 1\\ -2 & 0\\ 1 & -1\end{bmatrix}\begin{bmatrix}0\\0\end{bmatrix}=\begin{bmatrix}0\\0\\0\end{bmatrix}$$

这是一种极端情况：$\mathcal{C}(\boldsymbol{A})=\mathbb{R}^2,\mathcal{N}(\boldsymbol{A}^{\mathrm{T}})=\{\boldsymbol{0}\}$.

行空间和零空间的维数相加：$2+1=3$，这两个子空间合起来应该是整个 $\mathbb{R}^3=\mathbb{R}^n$；列空间和左零空间的维数相加：$2+0=0$，这两个子空间合起来应该是整个 $\mathbb{R}^2=\mathbb{R}^m$.

正交的两个子空间的维数受到严格的限制：

> 设 $V$、$W$ 是 $\mathbb{R}^n$ 中正交的线性子空间，那么 $\dim V+\dim W\leqslant n$.[①]

这看起来是非常自然且非常清楚的，但是也有违背生活经验的地方. 比如说我们环顾所处的房间，看一下墙壁和地面，可以把它们看作 $\mathbb{R}^3$ 中的两个平面，你会觉得它们垂直. 然而**它们不是正交的子空间！维数相加 $2+2>3$.** 因此，存在一些既属于墙面又属于地面的向量，显然，墙面和地面相交处的直线同时属于两个子空间.

有时正交的两个子空间合起来是整个子空间，这样的情况实际上有个专属的名称：**正交补. $V$ 的正交补 $V^{\perp}$ 由所有和 $V$ 正交的向量组成.** 因此，线性代数基本定理中涉及的两对子空间实际上都互为正交补：

正交补

| | |
|---|---|
| 行空间和零空间 | $r+(n-r)=n$ |
| 列空间和左零空间 | $r+(m-r)=m$ |

$\mathbb{R}^n$ 中任意向量 $\boldsymbol{x}$ 都可以写成 $\boldsymbol{x}=\boldsymbol{x}_{\mathrm{row}}+\boldsymbol{x}_{\mathrm{null}}$ 的形式，其中 $\boldsymbol{x}_{\mathrm{row}}$ 属于 $\boldsymbol{A}$ 的行空间，$\boldsymbol{x}_{\mathrm{null}}$ 属于零空间. $\mathbb{R}^m$ 中任意向量 $\boldsymbol{y}$ 都可以写成 $\boldsymbol{y}=\boldsymbol{y}_{\mathrm{col}}+\boldsymbol{y}_{\mathrm{null}}$ 的形式，其中 $\boldsymbol{y}_{\mathrm{col}}$ 属于 $\boldsymbol{A}$ 的列空间，$\boldsymbol{y}_{\mathrm{null}}$ 属于左零空间.

**线性代数基本定理　第 2 部分**

$\mathcal{N}(\boldsymbol{A})$ 是 $\mathcal{C}(\boldsymbol{A}^{\mathrm{T}})$ 在 $\mathbb{R}^n$ 中的正交补空间.

$\mathcal{N}(\boldsymbol{A}^{\mathrm{T}})$ 是 $\mathcal{C}(\boldsymbol{A})$ 在 $\mathbb{R}^m$ 中的正交补空间.

第 1 部分给出了四个基本子空间的维数；第 2 部分给出了它们之间的“角度”——都是 90°. 任意 $\boldsymbol{x}$ 都可以唯一地分解为**行空间分支 $\boldsymbol{x}_r$** 和**零空间分支 $\boldsymbol{x}_n$** 之和；由于 $\boldsymbol{A}\boldsymbol{x}_n=\boldsymbol{0}$，用 $\boldsymbol{A}$ 乘以 $\boldsymbol{x}=\boldsymbol{x}_r+\boldsymbol{x}_n$，则有 $\boldsymbol{A}\boldsymbol{x}_r=\boldsymbol{A}\boldsymbol{x}$，见图 4.1.

① 译者注：此处原文似乎漏了一个知识点，我们做个补充. 若 $V$ 和 $W$ 互相正交，则 $V\cap W=\{\boldsymbol{0}\}$. 设 $\boldsymbol{x}=V\cap W$，则 $\boldsymbol{x}\cdot\boldsymbol{x}=0$，这里我们把第一个 $\boldsymbol{x}$ 视作 $V$ 中的元素，第二个 $\boldsymbol{x}$ 视作 $W$ 中的元素. 设 $\boldsymbol{x}=\begin{bmatrix}x_1 & \cdots & x_n\end{bmatrix}^{\mathrm{T}}$，则 $0=\boldsymbol{x}\cdot\boldsymbol{x}=x_1^2+x_2^2+\cdots+x_n^2$，于是 $x_1=x_2=\cdots=x_n=0$，即 $\boldsymbol{x}=\boldsymbol{0}$.

任意向量 $\boldsymbol{Ax}=\boldsymbol{b}$ 都属于列空间，再乘一次 $\boldsymbol{A}$ 也得不到更多的信息. 不仅如此，列空间中任意向量事实上都只来自行空间中唯一一个向量，即对任意 $\boldsymbol{b}\in\mathcal{C}(\boldsymbol{A})$，存在唯一 $\boldsymbol{x}_r\in\mathcal{C}(\boldsymbol{A}^{\mathrm{T}})$，使得 $\boldsymbol{b}=\boldsymbol{Ax}_r$.

证明 若 $\boldsymbol{Ax}_r=\boldsymbol{Ax}_r'$，则 $\boldsymbol{A}(\boldsymbol{x}_r-\boldsymbol{x}_r')=\boldsymbol{0}$，所以 $\boldsymbol{x}_r-\boldsymbol{x}_r'\in\mathcal{N}(\boldsymbol{A})$. 但是 $\boldsymbol{x}_r-\boldsymbol{x}_r'$ 也属于 $\mathcal{C}(\boldsymbol{A}^{\mathrm{T}})$，所以

$$\boldsymbol{x}_r-\boldsymbol{x}_r'\in\mathcal{C}(\boldsymbol{A}^{\mathrm{T}})\cap\mathcal{N}(\boldsymbol{A})=\{\boldsymbol{0}\}\quad\Longrightarrow\quad\boldsymbol{x}_r=\boldsymbol{x}_r'.$$

如果抛开两个零空间，那么矩阵 $\boldsymbol{A}$ 诱导了从行空间到列空间的可逆映射[①]，在 4.5节中，我们将构造 $\boldsymbol{A}$ 的广义逆 $\boldsymbol{A}^{+}$，它给出了该可逆映射的逆映射. 注意到行空间和列空间都是 $r$ 维线性空间，$\boldsymbol{A}$ 诱导出从行空间到列空间的可逆映射这个事实与 $\boldsymbol{A}$ 中包含 $r\times r$ 的可逆子矩阵是同一个现象的一体两面. 要理解这件事需要对线性映射的一般理论有一定的了解，请读者暂且放下，待以后再来回顾.

例 4.2 任意秩为 $r$ 的矩阵都包含 $r\times r$ 可逆子矩阵. 例如，矩阵 $\boldsymbol{A}=\begin{bmatrix}1&2&3&4&5\\1&2&4&5&6\\1&2&4&5&6\end{bmatrix}$ 的秩是 2，第一行和第二行是主元行，第一列和第三列是主元列，交叉点处的子矩阵 $\begin{bmatrix}1&3\\1&4\end{bmatrix}$ 是可逆矩阵.

证明 （对一般情形的证明）设 $\boldsymbol{A}$ 是秩为 $r$ 的矩阵，$\boldsymbol{C}$ 是 $\boldsymbol{A}$ 的前 $r$ 个线性无关的列向量，那么 $\boldsymbol{C}$ 和 $\boldsymbol{C}^{\mathrm{T}}$ 的秩也都是 $r$. 于是 $\boldsymbol{C}^{\mathrm{T}}$ 有 $r$ 个线性无关的列向量，等价地，$\boldsymbol{C}$ 有 $r$ 个线性无关的行向量. 把 $\boldsymbol{C}$ 前 $r$ 个线性无关的行向量取出来，就是 $\boldsymbol{A}$ 的一个 $r\times r$ 可逆子矩阵.

我们最后再重申一遍：正交的子空间的交集只包含零向量.

线性空间的基指的是张成这个空间的线性无关的向量组. 通常来说，“张成”和“线性无关”这两个性质都需要验证. 但是当向量组中向量的个数等于维数时，两者是等价的，也就是说其中任意一个性质都能推出另一个. 根本原因是任意向量都能被基唯一地线性表出.

> （1）$\mathbb{R}^n$ 中 $n$ 个向量如果线性无关则一定张成 $\mathbb{R}^n$，从而它们构成一组基.
> （2）$\mathbb{R}^n$ 中 $n$ 个向量如果张成 $\mathbb{R}^n$ 则一定线性无关，从而它们构成一组基.

上述论断对于一般的线性空间也是成立的，但是我们暂时只考虑 $\mathbb{R}^n$. 对于 $n\times n$ 矩阵 $\boldsymbol{A}$ 的列向量，我们可以重述上面的事实：

> （1）若 $\boldsymbol{A}$ 的 $n$ 个列向量线性无关，则它们一定张成 $\mathbb{R}^n$，从而对任意 $\boldsymbol{b}\in\mathbb{R}^n$，方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 一定有解.
> （2）若 $\boldsymbol{A}$ 的 $n$ 个列向量张成 $\mathbb{R}^n$，则它们一定线性无关，从而对任意 $\boldsymbol{b}\in\mathbb{R}^n$，方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 一定只有唯一解.
> （3）若方阵 $\boldsymbol{A}$、$\boldsymbol{B}$ 满足 $\boldsymbol{AB}=\boldsymbol{I}$，则 $\boldsymbol{BA}=\boldsymbol{I}$.

① 译者注：事实上这是个线性映射，即对任意 $a,b\in\mathbb{R},\boldsymbol{x},\boldsymbol{y}\in\mathcal{C}(\boldsymbol{A}^{\mathrm{T}})$，都有 $\boldsymbol{A}(a\boldsymbol{x}+b\boldsymbol{y})=a(\boldsymbol{Ax})+b(\boldsymbol{Ay})$.

言下之意，对于系数矩阵是方阵的方程组而言，解的唯一性意味着存在性，存在性也意味着唯一性. 从而系数矩阵$A$ **是可逆矩阵.** 如果没有自由变元，那么方程组的解是唯一的，所以一定有$n$个主元，那么回代法就能解方程组$\boldsymbol{Ax}=\boldsymbol{b}$（即方程组的解存在）. 反之，若对任意$\boldsymbol{b}$，方程组$\boldsymbol{Ax}=\boldsymbol{b}$都有解，那么做消元法不会产生零行，因此方程组有$n$个主元而没有自由变元，$\boldsymbol{A}$的零空间只包含零向量$\boldsymbol{x}=\boldsymbol{0}$（即方程组的解唯一）.

考虑行空间和零空间的基，一共有$r+(n-r)=n$个向量，向量的个数是契合的. 事实上，这$n$个向量线性无关[①]，从而一定张成$\mathbb{R}^n$.

另一方面，任意$\boldsymbol{x}$都等于行空间中某个$\boldsymbol{x}_r$加上零空间中某个$\boldsymbol{x}_n$：$\boldsymbol{x}=\boldsymbol{x}_r+\boldsymbol{x}_n$. 图 4.1中的分解$\boldsymbol{x}=\boldsymbol{x}_r+\boldsymbol{x}_n$告诉我们正交补空间的另一个关键因素——维数相加等于$n$（或者说基的向量个数要契合）.

**例 4.3** 设矩阵$\boldsymbol{A}=\begin{bmatrix}1&2\\3&6\end{bmatrix}$，向量$\boldsymbol{x}=\begin{bmatrix}4\\3\end{bmatrix}$可以分解为$\boldsymbol{x}_r+\boldsymbol{x}_n=\begin{bmatrix}2\\4\end{bmatrix}+\begin{bmatrix}2\\-1\end{bmatrix}$，向量$\begin{bmatrix}2\\4\end{bmatrix}$属于行空间，向量$\begin{bmatrix}2\\-1\end{bmatrix}$属于零空间. 4.2 节我们将通过正交投影矩阵$\boldsymbol{P}$来计算这个分解.

**例 4.4** 设$S$是九维空间$\mathbb{R}^9$中的一个六维线性子空间.

（1）与$S$正交的线性子空间维数可能是多少？ 0、1、2、3

（2）$S$的正交补空间$S^{\perp}$的维数可能是多少？ 3

（3）以$S$为行空间的矩阵$\boldsymbol{A}$的最小尺寸是什么？ $6\times 9$

（4）以$S^{\perp}$为零空间的矩阵$\boldsymbol{B}$的最小尺寸是什么？ $6\times 9$

## 习题 4.1

1. 写出所有的$2\times 3$秩 1 矩阵的形式，对这类矩阵，画出图 4.1，并标出每个基本子空间的基. 哪些向量是正交的？

2. 对秩为 2 的$3\times 2$矩阵，画出图 4.1. 哪个基本子空间是$\{\boldsymbol{0}\}$？对任意$\boldsymbol{x}\in\mathbb{R}^2$，它的零空间分支是$\boldsymbol{x}_n=$_____.

3. 构造符合下列条件的矩阵，如果不存在请说明理由.

（1）列空间包含$\begin{bmatrix}1\\2\\3\end{bmatrix}$和$\begin{bmatrix}2\\-3\\5\end{bmatrix}$，零空间包含$\begin{bmatrix}1\\1\\1\end{bmatrix}$.

（2）行空间包含$\begin{bmatrix}1\\2\\3\end{bmatrix}$和$\begin{bmatrix}2\\-3\\5\end{bmatrix}$，零空间包含$\begin{bmatrix}1\\1\\1\end{bmatrix}$.

---

① 假设$\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_r$是$C(\boldsymbol{A}^{\mathrm{T}})$的基，$\boldsymbol{y}_1,\boldsymbol{y}_2,\cdots,\boldsymbol{y}_{n-r}$是$\mathcal{N}(\boldsymbol{A})$的基，要证它们合在一起线性无关，只需要说明：若$a_1\boldsymbol{x}_1+\cdots+a_r\boldsymbol{x}_r+b_1\boldsymbol{y}_1+\cdots+b_{n-r}\boldsymbol{y}_{n-r}=\boldsymbol{0}$，则$a_1=\cdots=a_r=b_1=\cdots=b_{n-r}=0$. 事实上，向量$a_1\boldsymbol{x}_1+\cdots+a_r\boldsymbol{x}_r=-(b_1\boldsymbol{y}_1+\cdots+b_{n-r}\boldsymbol{y}_{n-r})$属于$C(\boldsymbol{A}^{\mathrm{T}})\cap\mathcal{N}(\boldsymbol{A})$，因此是零向量；再由这两组向量各自都线性无关，所以$a_1=\cdots=a_r=0$，$b_1=\cdots=b_{n-r}=0$.

（3）方程组 $\boldsymbol{A}\boldsymbol{x}=\begin{bmatrix}1\\1\\1\end{bmatrix}$ 有解，且 $\boldsymbol{A}^{\mathrm{T}}\begin{bmatrix}1\\0\\0\end{bmatrix}=\begin{bmatrix}0\\0\\0\end{bmatrix}$.

（4）非零矩阵，且任意行向量和任意列向量都正交.

（5）列向量相加等于零向量，行向量相加得到的向量所有分量都是 1.

4. 若 $\boldsymbol{A}\boldsymbol{B}=\boldsymbol{0}$，那么 $\boldsymbol{B}$ 的列向量都属于 $\boldsymbol{A}$ 的_____. $\boldsymbol{A}$ 的行向量都属于 $\boldsymbol{B}$ 的_____. 若 $\boldsymbol{A}$、$\boldsymbol{B}$ 都是 $3\times3$ 矩阵且 $\boldsymbol{A}\boldsymbol{B}=\boldsymbol{0}$，为何 $\boldsymbol{A}$、$\boldsymbol{B}$ 的秩不能都是 2?

5.（1）若 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 有解且 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}=\boldsymbol{0}$，那么 $(\boldsymbol{y}^{\mathrm{T}}\boldsymbol{x}=0)$ 和 $(\boldsymbol{y}^{\mathrm{T}}\boldsymbol{b}=0)$ 中哪一个成立?

（2）若 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}=\begin{bmatrix}1\\1\\1\end{bmatrix}$ 有解且 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$，那么_____.

6. 所有无解的方程组最终都能归结为矛盾的等式 $0=1$. 对于方程组

$$\begin{cases}x+2y+2z&=&5\\2x+2y+3z&=&5\\3x+4y+5z&=&9\end{cases}$$

找三个数 $c_1$、$c_2$、$c_3$，分别乘以这三个方程后相加得到 $0=1$. 那么，向量 $\boldsymbol{c}=\begin{bmatrix}c_1&c_2&c_3\end{bmatrix}^{\mathrm{T}}$ 实际上属于哪个基本子空间？另外，由于点积 $\boldsymbol{y}^{\mathrm{T}}\boldsymbol{b}=1$，所以原方程组无解.

7. 习题 6 中的现象对于无解的方程组 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 具有一般性：存在 $y_1,y_2,\cdots,y_m$，分别乘以 $m$ 个方程后相加得到方程 $0=1$，这就是所谓的**Fredholm 二择一定理：若 $b\notin C(A)$，则 $b$ 的左零空间分支不为零.** 该定理可以严格地表述为**以下两个方程组有且仅有一个有解：**

$$\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}\qquad\text{以及}\qquad\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}=\boldsymbol{0}\text{且}\boldsymbol{y}^{\mathrm{T}}\boldsymbol{b}=1.$$

对方程组 $\begin{cases}x_1-x_2=1\\x_2-x_3=1\\x_1-x_3=1\end{cases}$，找一组数 $y_1$、$y_2$、$y_3$，分别乘以这三个方程后相加得到 $0=1$. 由此可知该方程组无解.

8. 在图 4.1中，为什么 $\boldsymbol{A}\boldsymbol{x}_r=\boldsymbol{A}\boldsymbol{x}$？如何得知 $\boldsymbol{A}\boldsymbol{x}$ 属于列空间？如果 $\boldsymbol{A}=\begin{bmatrix}1&1\\1&1\end{bmatrix}$ 且 $\boldsymbol{x}=\begin{bmatrix}1\\0\end{bmatrix}$，求 $\boldsymbol{x}_r$.

9. 按照下述提示证明命题：**若 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{x}=0$，则 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$.** 因为 $\boldsymbol{A}\boldsymbol{x}$ 属于 $\boldsymbol{A}^{\mathrm{T}}$ 的零空间，所以它也属于 $\boldsymbol{A}$ 的_____ 空间；这两个空间_____，所以 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$，进而 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 和 $\boldsymbol{A}$ 有相同的零空间. 这是很重要的结论，我们将会多次使用.

10. 设 $\boldsymbol{A}$ 是对称矩阵（$\boldsymbol{A}^{\mathrm{T}}=\boldsymbol{A}$）.

（1）为什么 $\boldsymbol{A}$ 的列空间和零空间正交?

（2）如果 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$ 且 $\boldsymbol{A}\boldsymbol{z}=5\boldsymbol{z}$，那么 $\boldsymbol{x}$ 和 $\boldsymbol{z}$ 各自属于哪个基本子空间？它们是 $\boldsymbol{A}$ 的“特征向量”（见第 6 章）. **实对称矩阵属于不同特征值的特征向量互相正交.**

11. 对矩阵 $\boldsymbol{A}=\begin{bmatrix}1 & 2\\ 3 & 6\end{bmatrix}$ 和 $\boldsymbol{B}=\begin{bmatrix}1 & 0\\ 3 & 0\end{bmatrix}$，画出相应的图 4.1，并正确地标出每个子空间.

12. 对矩阵 $\boldsymbol{A}=\begin{bmatrix}1 & -1\\ 0 & 0\end{bmatrix}$ 画出相应的图 4.1. 对 $\boldsymbol{x}=\begin{bmatrix}2\\ 0\end{bmatrix}$，求 $\boldsymbol{x}_r$ 和 $\boldsymbol{x}_n$.

习题 13 ~ 23 关于正交的线性子空间.

13. 把线性子空间 $V$ 和 $W$ 的一组基作为列向量排成矩阵 $\boldsymbol{V}$ 和 $\boldsymbol{W}$. 请说明：为什么我们可以用 $\boldsymbol{V}^{\mathrm{T}}\boldsymbol{W}=\boldsymbol{0}$ 来判断 $V$ 和 $W$ 正交. 这在形式上和正交的向量（$\boldsymbol{v}^{\mathrm{T}}\boldsymbol{w}=0$）有相似性.

14. 假设子空间 $V$ 和 $W$ 分别表示三维空间中的地面和墙面，因为存在非零向量同时属于这两个子空间（即它们相交的直线），所以它们不正交. $\mathbb{R}^3$ 中任意两个平面 $V$ 和 $W$ 都不正交. 请找出一个非零向量，同时属于下列矩阵 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 的列空间：

$$\boldsymbol{A}=\begin{bmatrix}1 & 2\\ 1 & 3\\ 1 & 2\end{bmatrix}\qquad \boldsymbol{B}=\begin{bmatrix}5 & 4\\ 6 & 3\\ 5 & 1\end{bmatrix}$$

提示：这个向量既可以表示成 $\boldsymbol{A}\boldsymbol{x}$，又可以表示成 $\boldsymbol{B}\hat{\boldsymbol{b}}$，这引导我们考虑矩阵 $\begin{bmatrix}\boldsymbol{A} & \boldsymbol{B}\end{bmatrix}$.

15. 习题 14 可以推广到 $\mathbb{R}^n$ 中 $p$ 维子空间 $V$ 和 $q$ 维子空间 $W$. 关于 $p+q$ 的哪个不等式可以保证 $V\cap W\neq\{\boldsymbol{0}\}$？此时 $V$ 和 $W$ 一定不正交.

16. 证明：任意 $\boldsymbol{y}\in\mathcal{N}(\boldsymbol{A}^{\mathrm{T}})$ 和任意 $\boldsymbol{A}\boldsymbol{x}\in\mathcal{C}(\boldsymbol{A})$ 都正交.

提示：基于 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}=\boldsymbol{0}$，类比式(4.2)论证.

17. 设 $S$ 是 $\mathbb{R}^3$ 的只包含零向量的子空间，$S^{\perp}$ 是什么？若 $S$ 由 $\begin{bmatrix}1 & 1 & 1\end{bmatrix}^{\mathrm{T}}$ 张成，$S^{\perp}$ 是什么？若 $S$ 由 $\begin{bmatrix}1 & 1 & 1\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}1 & 1 & -1\end{bmatrix}^{\mathrm{T}}$ 张成，请写出 $S^{\perp}$ 的一组基.

18. 设 $S$ 只包含向量 $\begin{bmatrix}1 & 5 & 1\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}2 & 2 & 2\end{bmatrix}^{\mathrm{T}}$，显然不是线性空间. 那么 $S^{\perp}$ 是矩阵 $\boldsymbol{A}=$_____ 的零空间. 这个例子说明：即使 $S$ 本身不是子空间，$S^{\perp}$ 仍然是子空间.

19. 设 $L$ 是 $\mathbb{R}^3$ 中的一个一维子空间，即过原点的直线. 它的正交补 $L^{\perp}$ 是垂直于 $L$ 的_____，$(L^{\perp})^{\perp}$ 是垂直于 $L^{\perp}$ 的_____. 事实上，$(L^{\perp})^{\perp}$ 和_____ 相同.

20. 设 $V$ 是整个 $\mathbb{R}^4$，那么 $V^{\perp}$ 只包含向量_____，$(V^{\perp})^{\perp}$ 是_____. 事实上，$(V^{\perp})^{\perp}$ 和_____ 相同.

21. 设 $S$ 由向量 $\begin{bmatrix}1 & 2 & 2 & 3\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}1 & 3 & 3 & 2\end{bmatrix}^{\mathrm{T}}$ 张成. 求两个向量使得它们张成 $S^{\perp}$. 这相当于对哪个矩阵 $\boldsymbol{A}$ 来解方程组 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$？

22. 设 $P=\left\{\begin{bmatrix}x_1 & x_2 & x_3 & x_4\end{bmatrix}^{\mathrm{T}}\in\mathbb{R}^4:x_1+x_2+x_3+x_4=0\right\}$. 请写出 $P^{\perp}$ 的一组基，并构造一个矩阵，其以 $P$ 为零空间.

23. 若 $S\subseteq V$ 是两个子空间，证明：$S^{\perp}\supseteq V^{\perp}$.

习题 24 ~ 28 关于列向量和行向量的正交关系.

24. 设 $\boldsymbol{A}$ 是 $n \times n$ 可逆矩阵，即存在 $\boldsymbol{A}^{-1}$ 使得 $\boldsymbol{A}\boldsymbol{A}^{-1} = \boldsymbol{I}_n$. 那么 $\boldsymbol{A}^{-1}$ 的第一列和 $\boldsymbol{A}$ 的哪些行向量张成的子空间正交?

25. 假设矩阵 $\boldsymbol{A}$ 的列向量是两两正交的单位向量，请计算 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$.

26. 构造一个所有分量均非零，并且列向量两两正交的 $3 \times 3$ 矩阵 $\boldsymbol{A}$. 请计算 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 并说明为什么它是对角矩阵?

27. 直线 $3x + y = b_1$ 和 $6x + 2y = b_2$ 的关系是_____. 若_____ 则它们是同一条直线，此时向量 $\begin{bmatrix} b_1 & b_2 \end{bmatrix}^{\mathrm{T}}$ 和向量_____ 正交. 直线 $3x + y =$ _____ 是某个矩阵的零空间，非零向量_____ 属于该零空间.

28. 请说明以下各论断错误的原因.

(1) 向量 $\begin{bmatrix} 1 & 1 & 1 \end{bmatrix}^{\mathrm{T}}$ 垂直于 $\begin{bmatrix} 1 & 1 & -2 \end{bmatrix}^{\mathrm{T}}$，所以平面 $x + y + z = 0$ 和 $x + y - 2z = 0$ 是互相正交的线性子空间.

(2) $\begin{bmatrix} 1 & 1 & 0 & 0 & 0 \end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix} 0 & 0 & 0 & 1 & 1 \end{bmatrix}^{\mathrm{T}}$ 张成的子空间与 $\begin{bmatrix} 1 & -1 & 0 & 0 & 0 \end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix} 2 & -2 & 3 & 4 & -4 \end{bmatrix}^{\mathrm{T}}$ 张成的子空间正交.

(3) 若两个子空间只交于零向量，那么它们正交.

29. 构造一个矩阵 $\boldsymbol{A}$ 使得向量 $\boldsymbol{v} = \begin{bmatrix} 1 & 2 & 3 \end{bmatrix}^{\mathrm{T}}$ 同时属于它的列空间和行空间. 构造一个矩阵 $\boldsymbol{B}$ 使得向量 $\boldsymbol{v}$ 同时属于它的列空间和零空间. 哪两个基本子空间不能同时包含 $\boldsymbol{v}$?

30. 设 $\boldsymbol{A}$ 是 $3 \times 4$ 矩阵，$\boldsymbol{B}$ 是 $4 \times 5$ 矩阵，且 $\boldsymbol{A}\boldsymbol{B} = \boldsymbol{0}$，于是 $\mathcal{N}(\boldsymbol{A})$ 包含 $\mathcal{C}(\boldsymbol{B})$. 请从 $\mathcal{N}(\boldsymbol{A})$ 和 $\mathcal{C}(\boldsymbol{B})$ 的关系出发证明 $\mathrm{rank}(\boldsymbol{A}) + \mathrm{rank}(\boldsymbol{B}) \leqslant 4$.

31. 假设有台机器，输入命令“$\mathrm{null}(\boldsymbol{A})$”就会输出 $\boldsymbol{A}$ 零空间的一组基，那么输入命令“$\mathrm{null}(\boldsymbol{A}^{\mathrm{T}})$”输出的是 $\boldsymbol{A}$ 的_____ 空间的一组基.

32. 若 $\mathbb{R}^2$ 中的四个向量 $\boldsymbol{r}$、$\boldsymbol{n}$、$\boldsymbol{c}$、$\boldsymbol{l}$ 要分别成为某个 $2 \times 2$ 矩阵 $\boldsymbol{A}$ 的四个基本子空间 $\mathcal{C}(\boldsymbol{A}^{\mathrm{T}})$、$\mathcal{N}(\boldsymbol{A})$、$\mathcal{C}(\boldsymbol{A})$、$\mathcal{N}(\boldsymbol{A}^{\mathrm{T}})$ 的一组基，那么它们需要满足哪些条件?

33. 当 $\mathbb{R}^4$ 中的四组向量 $(\boldsymbol{r}_1, \boldsymbol{r}_2)$、$(\boldsymbol{n}_1, \boldsymbol{n}_2)$、$(\boldsymbol{c}_1, \boldsymbol{c}_2)$、$(\boldsymbol{l}_1, \boldsymbol{l}_2)$ 分别是某个 $4 \times 4$ 矩阵 $\boldsymbol{A}$ 的四个基本子空间 $\mathcal{C}(\boldsymbol{A}^{\mathrm{T}})$、$\mathcal{N}(\boldsymbol{A})$、$\mathcal{C}(\boldsymbol{A})$、$\mathcal{N}(\boldsymbol{A}^{\mathrm{T}})$ 的一组基时，它们满足哪些条件? 请写出一个可能的 $\boldsymbol{A}$.

## 4.2　向直线和子空间作正交投影

(1) 把向量 $\boldsymbol{b}$ 正交投影到过 $\boldsymbol{a}$ 的直线[①]，得到该直线上与 $\boldsymbol{b}$ 距离最近的向量：$\boldsymbol{p} = \dfrac{\boldsymbol{a}^{\mathrm{T}}\boldsymbol{b}}{\boldsymbol{a}^{\mathrm{T}}\boldsymbol{a}}\boldsymbol{a}$.

(2) 误差 $\boldsymbol{e}$ 和 $\boldsymbol{a}$ 正交，$\boldsymbol{b}$、$\boldsymbol{p}$、$\boldsymbol{e}$ 构成直角三角形，于是根据勾股定理得 $\|\boldsymbol{p}\|^2 + \|\boldsymbol{e}\|^2 = \|\boldsymbol{b}\|^2$.

(3) 向量 $\boldsymbol{b}$ 在子空间 $S$ 的正交投影是 $S$ 中与 $\boldsymbol{b}$ 距离最近的向量：$\boldsymbol{b} - \boldsymbol{p}$ 和 $S$ 正交.

① 译者注：更严谨地说，应该是 $\boldsymbol{b}$ 向 $\boldsymbol{a}$ 张成的一维线性子空间作正交投影. 但是原文这种说法，甚至更不严谨地说“把 $\boldsymbol{b}$ 正交投影到 $\boldsymbol{a}$”“$\boldsymbol{b}$ 向 $\boldsymbol{a}$ 作正交投影”等，虽然不严谨，但是描述简洁，也不至于引起混淆，以后我们也会采用这样的叙述.

（4）当 $\boldsymbol{A}$ 列满秩时，$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 是可逆矩阵，原因是：对任意矩阵 $\boldsymbol{A}$ 都有 $\mathcal{N}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})=\mathcal{N}(\boldsymbol{A})$.
（5）若 $\boldsymbol{A}$ 列满秩，$\boldsymbol{b}$ 在列空间 $\mathcal{C}(\boldsymbol{A})$ 的正交投影为向量 $\boldsymbol{p}=\boldsymbol{A}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1}\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$.
（6）若 $\boldsymbol{A}$ 列满秩，则到列空间 $\mathcal{C}(\boldsymbol{A})$ 正交投影的投影矩阵是 $\boxed{\boldsymbol{P}=\boldsymbol{A}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1}\boldsymbol{A}^{\mathrm{T}}}$，该矩阵满足 $\boldsymbol{p}=\boldsymbol{P}\boldsymbol{b}$ 且 $\boldsymbol{P}^2=\boldsymbol{P}=\boldsymbol{P}^{\mathrm{T}}$.

向子空间 $S$ 作正交投影是很直观的：把 $\boldsymbol{b}$ 映射为 $S$ 上离 $\boldsymbol{b}$ 最近的向量 $\boldsymbol{p}$. 误差项 $\boldsymbol{e}=\boldsymbol{b}-\boldsymbol{p}$ 正交于该子空间. 若 $\boldsymbol{A}$ 的全体列向量线性无关，那么 $\boldsymbol{b}$ 在 $\mathcal{C}(\boldsymbol{A})$ 上的正交投影为 $\boldsymbol{p}=\boldsymbol{A}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1}\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$. 投影矩阵 $\boldsymbol{P}=\boldsymbol{A}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1}\boldsymbol{A}^{\mathrm{T}}$是对称矩阵，且满足性质：$\boldsymbol{P}^2=\boldsymbol{P}$——几何含义是投影两次和投影一次一样：$\boldsymbol{p}$ 的正交投影还是 $\boldsymbol{p}$.

对某些性质良好的特殊子空间，你能迅速看出来向它们作正交投影的投影矩阵吗？

（1）向量 $\boldsymbol{b}=\begin{bmatrix}2 & 3 & 4\end{bmatrix}^{\mathrm{T}}$ 在 $z$ 轴和 $xy$ 平面的正交投影分别是什么？

（2）向一条直线和一个平面作正交投影的投影矩阵分别是什么？

$\boldsymbol{b}$ 在一条直线上的正交投影就是 $\boldsymbol{b}$ 在这条直线上的分支[①]；$\boldsymbol{b}$ 在一个平面上的投影就是 $\boldsymbol{b}$ 在这个平面上的分支. 正交投影 $\boldsymbol{p}=\boldsymbol{P}\boldsymbol{b}$.

我们把 $\boldsymbol{b}$ 在 $z$ 轴和 $xy$ 平面的正交投影分别记作 $\boldsymbol{p}_1$ 和 $\boldsymbol{p}_2$. 若 $\boldsymbol{b}=\begin{bmatrix}2 & 3 & 4\end{bmatrix}^{\mathrm{T}}$，那么 $\boldsymbol{p}_1=\begin{bmatrix}0 & 0 & 4\end{bmatrix}^{\mathrm{T}}$，$\boldsymbol{p}_2=\begin{bmatrix}2 & 3 & 0\end{bmatrix}^{\mathrm{T}}$. $\boldsymbol{b}$ 在 $z$ 轴和 $xy$ 平面分解的情况见图 4.2.

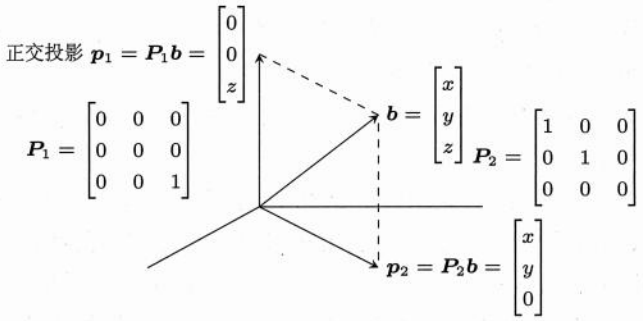


图 4.2　三维向量的正交投影

注：正交投影 $\boldsymbol{p}_1=\boldsymbol{P}_1\boldsymbol{b},\boldsymbol{p}_2=\boldsymbol{P}_2\boldsymbol{b}$，并且 $\boldsymbol{P}_1+\boldsymbol{P}_2=\boldsymbol{I},\boldsymbol{P}_1\boldsymbol{P}_2=\boldsymbol{0}$.

投影矩阵 $\boldsymbol{P}_1$、$\boldsymbol{P}_2$ 都是 $3\times 3$ 矩阵，乘以三维向量 $\boldsymbol{b}$，得到的还是三维向量. 向直线正交投影的投影矩阵秩为 1，向平面正交投影的投影矩阵秩为 2.

| 向 $z$ 轴<br>作正交投影 | $\boldsymbol{P}_1=\begin{bmatrix}0&0&0\\0&0&0\\0&0&1\end{bmatrix}$ | 向 $xy$ 平面<br>作正交投影 | $\boldsymbol{P}_2=\begin{bmatrix}1&0&0\\0&1&0\\0&0&0\end{bmatrix}$ |
|---|---|---|---|

① 译者注：单用“分支”这个词并不严格，只有规定好分解的方式，才能谈分支. 当然我们可以按照子空间和它的正交补空间作分解，作者在本章中使用“分支”这个词表达的意思应当就是如此.

$\boldsymbol{P}_1$ 乘以一个向量的结果是该向量的 $z$ 分支；$\boldsymbol{P}_2$ 乘以一个向量的结果是该向量的 $xy$ 平面分支. 所以用 $\boldsymbol{P}_1$、$\boldsymbol{P}_2$ 左乘于 $\boldsymbol{b}$，分别得到 $\boldsymbol{b}$ 在 $z$ 轴和 $xy$ 平面的正交投影 $\boldsymbol{p}_1$ 和 $\boldsymbol{p}_2$

$$\boldsymbol{p}_1=\boldsymbol{P}_1\boldsymbol{b}=\begin{bmatrix}0&0&0\\0&0&0\\0&0&1\end{bmatrix}\begin{bmatrix}x\\y\\z\end{bmatrix}=\begin{bmatrix}0\\0\\z\end{bmatrix}\qquad \boldsymbol{p}_2=\boldsymbol{P}_2\boldsymbol{b}=\begin{bmatrix}1&0&0\\0&1&0\\0&0&0\end{bmatrix}\begin{bmatrix}x\\y\\z\end{bmatrix}=\begin{bmatrix}x\\y\\0\end{bmatrix}$$

此时，因为 $xy$ 平面和 $z$ 轴是互相正交的子空间，两个正交投影 $\boldsymbol{p}_1$、$\boldsymbol{p}_2$ 是正交的，就像地面和垂直向上的直线那样.

不仅正交，$z$ 轴和 $xy$ 平面还互为正交补：维数相加 $1+2=3$. 任意向量 $\boldsymbol{b}$ 都等于它在这两个空间上的分支的和. 正交投影 $\begin{bmatrix}0&0&z\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}x&y&0\end{bmatrix}^{\mathrm{T}}$ 正好就是 $\boldsymbol{b}$ 的这两个分支：

$$\text{两个正交投影满足}\boldsymbol{p}_1+\boldsymbol{p}_2=\boldsymbol{b}\qquad \text{两个投影矩阵满足}\boldsymbol{P}_1+\boldsymbol{P}_2=\boldsymbol{I},\boldsymbol{P}_1\boldsymbol{P}_2=\boldsymbol{0}\tag{4.3}$$

这太完美了！至少就这个例子而言，我们的目标完美地达成了. 对任意直线、任意平面、$m$ 维空间中的任意 $n$ 维子空间，我们也有同样的期望. 对每个子空间，我们希望找到 $\boldsymbol{b}$ 在其上的正交投影 $\boldsymbol{p}$、投影矩阵 $\boldsymbol{P}$ 满足 $\boldsymbol{p}=\boldsymbol{P}\boldsymbol{b}$. $\mathbb{R}^m$ 中任意子空间都有与之对应的 $m\times m$ 正交投影矩阵.

刻画子空间最好的工具是基. 我们把基中的向量作为列向量排成矩阵 $\boldsymbol{A}$，问题就变成了向 $\boldsymbol{A}$ 的列空间作正交投影. 显然 $z$ 轴是 $3\times 1$ 矩阵 $\boldsymbol{A}_1=\begin{bmatrix}0\\0\\1\end{bmatrix}$ 的列空间，$xy$ 平面是 $\boldsymbol{A}_2=\begin{bmatrix}1&0\\0&1\\0&0\end{bmatrix}$ 的列空间，也是 $\boldsymbol{A}_3=\begin{bmatrix}1&2\\2&3\\0&0\end{bmatrix}$ 的列空间，所以必然有 $\boldsymbol{p}_2=\boldsymbol{p}_3$ 以及 $\boldsymbol{P}_2=\boldsymbol{P}_3$.

现在问题就转化为研究：将向量 $\boldsymbol{b}\in\mathbb{R}^m$ 正交投影到 $m\times n$ 矩阵的列空间. 我们先从一条直线开始（即 $n=1$），此时矩阵 $\boldsymbol{A}$ 就是一个列向量，记作 $\boldsymbol{a}$.

### 4.2.1　正交投影到直线

给定过原点且沿着向量 $\boldsymbol{a}=\begin{bmatrix}a_1&\cdots&a_m\end{bmatrix}^{\mathrm{T}}$ 方向的直线，我们想在这条直线上找到和 $\boldsymbol{b}=\begin{bmatrix}b_1&\cdots&b_m\end{bmatrix}^{\mathrm{T}}$ 距离最近的向量. 问题的关键就在于正交性：误差项 $\boldsymbol{e}=\boldsymbol{b}-\boldsymbol{p}$ 和 $\boldsymbol{a}$ 正交，见图 4.3. 我们用代数方法来计算 $\boldsymbol{p}$.

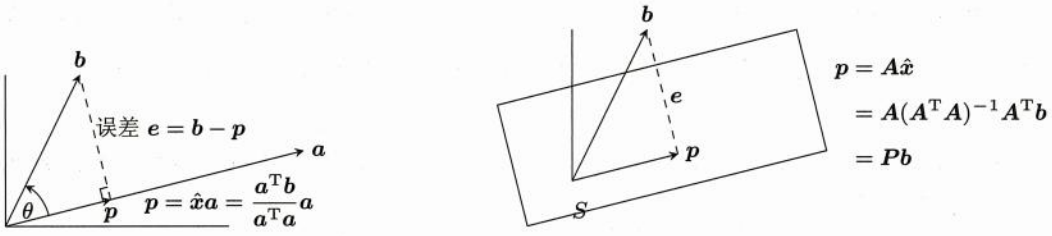


图 4.3　向量 $b$ 到子空间 $S=C(A)$ 的正交投影 $p$

注意到 $\boldsymbol{p}$ 是 $\boldsymbol{a}$ 的倍数，所以可以假设 $\boldsymbol{p}=\hat{\boldsymbol{x}}\boldsymbol{a}$，先计算出 $\hat{\boldsymbol{x}}$ 得到 $\boldsymbol{p}$ 的表达式，再从 $\boldsymbol{p}$ 的表达式中读出投影矩阵 $\boldsymbol{P}$. 这三个步骤对于求投影矩阵具有普适性：

① 求出 $\hat{\boldsymbol{x}}$；　② 求出 $\boldsymbol{p}$；　③ 求出投影矩阵 $\boldsymbol{P}$.

图 4.3中虚线部分 $\boldsymbol{b}-\boldsymbol{p}$ 是误差 $\boldsymbol{e}=\boldsymbol{b}-\hat{\boldsymbol{x}}\boldsymbol{a}$，它正交于 $\boldsymbol{a}$——这个性质完全决定了 $\hat{\boldsymbol{x}}$. 基于这个事实，我们可以列方程：$(\boldsymbol{b}-\hat{\boldsymbol{x}}\boldsymbol{a})\cdot\boldsymbol{a}=0$.

$$\boxed{\begin{array}{l}\boldsymbol{b}\text{向}\boldsymbol{a}\text{作正交投影，误差为}\boldsymbol{e}=\boldsymbol{b}-\hat{\boldsymbol{x}}\boldsymbol{a}\\ \boldsymbol{a}\cdot(\boldsymbol{b}-\hat{\boldsymbol{x}}\boldsymbol{a})=0\text{或}\boldsymbol{a}\cdot\boldsymbol{b}-\hat{\boldsymbol{x}}\boldsymbol{a}\cdot\boldsymbol{a}=0\end{array}\qquad\hat{\boldsymbol{x}}=\frac{\boldsymbol{a}\cdot\boldsymbol{b}}{\boldsymbol{a}\cdot\boldsymbol{a}}=\frac{\boldsymbol{a}^{\mathrm{T}}\boldsymbol{b}}{\boldsymbol{a}^{\mathrm{T}}\boldsymbol{a}}} \tag{4.4}$$

矩阵乘法 $\boldsymbol{a}^{\mathrm{T}}\boldsymbol{b}$ 和内积 $\boldsymbol{a}\cdot\boldsymbol{b}$ 虽然相同，但我们还是采用前一种写法，因为它也适用于一般矩阵. 在高维的情形（不再是投影到直线）时，我们必须引入矩阵（而不再仅仅是单个列向量）. 由 $\hat{\boldsymbol{x}}=\dfrac{\boldsymbol{a}^{\mathrm{T}}\boldsymbol{b}}{\boldsymbol{a}^{\mathrm{T}}\boldsymbol{a}}$ 可知，正交投影为 $\boldsymbol{p}=\hat{\boldsymbol{x}}\boldsymbol{a}$.

$\boldsymbol{b}$ 到 $\boldsymbol{a}$ 的正交投影为 $\boldsymbol{p}=\hat{\boldsymbol{x}}\boldsymbol{a}=\dfrac{\boldsymbol{a}^{\mathrm{T}}\boldsymbol{b}}{\boldsymbol{a}^{\mathrm{T}}\boldsymbol{a}}\boldsymbol{a}$.

第一种特殊情形：若 $\boldsymbol{b}=\boldsymbol{a}$，则 $\hat{\boldsymbol{x}}=1$，$\boldsymbol{a}$ 到过 $\boldsymbol{a}$ 的直线的正交投影是它本身，$\boldsymbol{P}\boldsymbol{a}=\boldsymbol{a}$.

第二种特殊情形：若 $\boldsymbol{b}$ 和 $\boldsymbol{a}$ 正交，则 $\boldsymbol{a}^{\mathrm{T}}\boldsymbol{b}=0$，因此 $\boldsymbol{b}$ 的正交投影为 $\boldsymbol{p}=\boldsymbol{0}$.

**例 4.5**　将 $\boldsymbol{b}=\begin{bmatrix}1\\1\\1\end{bmatrix}$ 正交投影到过 $\boldsymbol{a}=\begin{bmatrix}1\\2\\2\end{bmatrix}$ 的直线上，求出图 4.3中的 $\boldsymbol{p}=\hat{\boldsymbol{x}}\boldsymbol{a}$.

**解**　$\hat{\boldsymbol{x}}$ 等于 $\boldsymbol{a}^{\mathrm{T}}\boldsymbol{b}=5$ 和 $\boldsymbol{a}^{\mathrm{T}}\boldsymbol{a}=9$ 的商，所以 $\boldsymbol{p}=\dfrac{5}{9}\boldsymbol{a}$.

$\boldsymbol{b}$ 和 $\boldsymbol{p}$ 之间的误差项是 $\boldsymbol{e}=\boldsymbol{b}-\boldsymbol{p}$，所以 $\boldsymbol{p}+\boldsymbol{e}=\begin{bmatrix}1&1&1\end{bmatrix}^{\mathrm{T}}$：

$$\boldsymbol{p}=\frac{5}{9}\boldsymbol{a}=\begin{bmatrix}\frac{5}{9}&\frac{10}{9}&\frac{10}{9}\end{bmatrix}^{\mathrm{T}}\qquad\boldsymbol{e}=\boldsymbol{b}-\boldsymbol{p}=\begin{bmatrix}\frac{4}{9}&-\frac{1}{9}&-\frac{1}{9}\end{bmatrix}^{\mathrm{T}}$$

误差项 $\boldsymbol{e}$ 应该和 $\boldsymbol{a}=\begin{bmatrix}1&2&2\end{bmatrix}^{\mathrm{T}}$ 正交：$\boldsymbol{e}^{\mathrm{T}}\boldsymbol{a}=\dfrac{4}{9}-\dfrac{2}{9}-\dfrac{2}{9}=0$.

观察 $\boldsymbol{b}$、$\boldsymbol{p}$、$\boldsymbol{e}$ 构成的直角三角形，斜边 $\boldsymbol{b}$ 分解成两部分：$\boldsymbol{a}$ 方向的 $\boldsymbol{p}$ 和正交于 $\boldsymbol{a}$ 方向的 $\boldsymbol{e}$，那么两条边长分别为 $\|\boldsymbol{p}\|=\|\boldsymbol{b}\|\cos\theta,\|\boldsymbol{e}\|=\|\boldsymbol{b}\|\sin\theta$，这里的 $\theta$ 是通过点积给出来的角度：

$$\boldsymbol{p}=\frac{\boldsymbol{a}^{\mathrm{T}}\boldsymbol{b}}{\boldsymbol{a}^{\mathrm{T}}\boldsymbol{a}}\boldsymbol{a}\quad\text{长度是}\quad\boxed{\|\boldsymbol{p}\|}=\frac{\|\boldsymbol{a}\|\,\|\boldsymbol{b}\|\cos\theta}{\|\boldsymbol{a}\|^{2}}\|\boldsymbol{a}\|=\boxed{\|\boldsymbol{b}\|\cos\theta}. \tag{4.5}$$

计算点积比计算 $\boldsymbol{b}$ 的长度和余弦 $\cos\theta$ 要方便多了. 在本例中，$\|\boldsymbol{b}\|=\sqrt{3},\cos\theta=5/3\sqrt{3}$，都包含了平方根，但是最后的正交投影 $\boldsymbol{p}=\dfrac{5}{9}\boldsymbol{a}$ 并不包含平方根，所以用 $\boldsymbol{a}^{\mathrm{T}}\boldsymbol{b}/\boldsymbol{a}^{\mathrm{T}}\boldsymbol{a}$ 算系数 5/9 是更好的方法.

我们再来看投影矩阵，也就是说要寻找一个矩阵，左乘于 $\boldsymbol{b}$ 可以得到 $\boldsymbol{p}$. 把 $\hat{\boldsymbol{x}}$ 写在 $\boldsymbol{a}$ 的右边就容易看出来这个矩阵了：

$$\boxed{\text{当投影矩阵}\boldsymbol{P}=\frac{\boldsymbol{a}\boldsymbol{a}^{\mathrm{T}}}{\boldsymbol{a}^{\mathrm{T}}\boldsymbol{a}}\text{时，}\boldsymbol{p}=\boldsymbol{a}\hat{\boldsymbol{x}}=\boldsymbol{a}\frac{\boldsymbol{a}^{\mathrm{T}}\boldsymbol{b}}{\boldsymbol{a}^{\mathrm{T}}\boldsymbol{a}}=\boldsymbol{P}\boldsymbol{b}.}$$

$\boldsymbol{P}$ 是列向量乘以行向量，具体地说，用列向量 $\boldsymbol{a}$ 乘以行向量 $\boldsymbol{a}^{\mathrm{T}}$，再整体除以数 $\boldsymbol{a}^{\mathrm{T}}\boldsymbol{a}$. 它是 $m\times m$ 秩 1 矩阵，究其原因，我们向一维子空间——$\boldsymbol{a}$ 张成的子空间作正交投影，这条直线就是 $\boldsymbol{P}$ 的列空间.

例 4.6 求向 $\boldsymbol{a}=\begin{bmatrix}1\\2\\2\end{bmatrix}$ 作正交投影的投影矩阵 $\boldsymbol{P}=\dfrac{\boldsymbol{a}\boldsymbol{a}^{\mathrm{T}}}{\boldsymbol{a}^{\mathrm{T}}\boldsymbol{a}}$.

解 先用列向量 $\boldsymbol{a}$ 乘以行向量 $\boldsymbol{a}^{\mathrm{T}}$，然后除以数 $\boldsymbol{a}^{\mathrm{T}}\boldsymbol{a}=9$:

$$\text{投影矩阵}\qquad \boldsymbol{P}=\frac{\boldsymbol{a}\boldsymbol{a}^{\mathrm{T}}}{\boldsymbol{a}^{\mathrm{T}}\boldsymbol{a}}=\frac{1}{9}\begin{bmatrix}1\\2\\2\end{bmatrix}\begin{bmatrix}1&2&2\end{bmatrix}=\frac{1}{9}\begin{bmatrix}1&2&2\\2&4&4\\2&4&4\end{bmatrix}$$

它把 $\boldsymbol{b}$ 正交投影到直线 $L$，我们用例 4.5中的 $\boldsymbol{b}=\begin{bmatrix}1&1&1\end{bmatrix}^{\mathrm{T}}$ 来验证一下 $\boldsymbol{p}=\boldsymbol{P}\boldsymbol{b}$:

$$\boldsymbol{p}=\boldsymbol{P}\boldsymbol{b}=\frac{1}{9}\begin{bmatrix}1&2&2\\2&4&4\\2&4&4\end{bmatrix}\begin{bmatrix}1\\1\\1\end{bmatrix}=\frac{1}{9}\begin{bmatrix}5\\10\\10\end{bmatrix},\text{误差项}\boldsymbol{e}=\boldsymbol{b}-\boldsymbol{p}=\begin{bmatrix}1\\1\\1\end{bmatrix}-\frac{1}{9}\begin{bmatrix}5\\10\\10\end{bmatrix}=\frac{1}{9}\begin{bmatrix}4\\-1\\-1\end{bmatrix}$$

把 $\boldsymbol{a}$ 改成原来的非零倍数，比如说两倍，矩阵 $\boldsymbol{P}$ 保持不变，它乘以任意向量还是得到该向量在 $L$ 上的正交投影. 把投影矩阵平方有 $\boldsymbol{P}^2=\boldsymbol{P}$. 再投影一次不改变任何东西，所以 $\boldsymbol{P}^2=\boldsymbol{P}$. $\boldsymbol{P}$ 对角线相加得 $\dfrac{1}{9}(1+4+4)=1$，并且 $\boldsymbol{e}^{\mathrm{T}}\boldsymbol{p}=0$.

矩阵 $\boldsymbol{I}-\boldsymbol{P}$ 也应该是投影矩阵，它把向量 $\boldsymbol{b}$ 投影成直角三角形的另一条边——误差 $\boldsymbol{e}$. 若 $\boldsymbol{P}$ 是到某个子空间 $V$ 的正交投影矩阵，那么 $\boldsymbol{I}-\boldsymbol{P}$ 是到 $V$ 的正交补空间 $V^{\perp}$ 的投影矩阵. 所以 $\boldsymbol{I}-\boldsymbol{P}$ 把任意向量投影到和 $\boldsymbol{a}$ 正交的子空间上——或者说 $\boldsymbol{a}$ 的正交补空间.

现在我们把目光从直线上移开，转向 $\mathbb{R}^m$ 中的 $n$ 维子空间. 当然，这需要我们付出更多辛苦的劳动. 式(4.7)~式(4.9)至关重要，读者最好能把这三个公式背下来.

### 4.2.2 正交投影到子空间

给定 $\mathbb{R}^m$ 中线性无关的 $n$ 个向量 $\boldsymbol{a}_1,\boldsymbol{a}_2,\cdots,\boldsymbol{a}_n$.

问题：对任意给定的向量 $\boldsymbol{b}$，找出和它最近的线性组合 $\boldsymbol{p}=\hat{x}_1\boldsymbol{a}_1+\hat{x}_2\boldsymbol{a}_2+\cdots+\hat{x}_n\boldsymbol{a}_n$. 实际上我们在把任意 $\boldsymbol{b}\in\mathbb{R}^m$ 正交投影到 $\boldsymbol{a}_1,\boldsymbol{a}_2,\cdots,\boldsymbol{a}_n$ 张成的线性子空间.

当 $n=1$ 时，只有一个向量 $\boldsymbol{a}_1$，这种情况我们已经处理过了：到直线的正交投影. 这条直线是矩阵 $\boldsymbol{A}=\begin{bmatrix}\boldsymbol{a}_1\end{bmatrix}$ 的列空间.

对于一般的 $n$，我们令 $\boldsymbol{A}=\begin{bmatrix}\boldsymbol{a}_1&\cdots&\boldsymbol{a}_n\end{bmatrix}$. 要求的线性组合 $\boldsymbol{p}=\hat{x}_1\boldsymbol{a}_1+\hat{x}_2\boldsymbol{a}_2+\cdots+\hat{x}_n\boldsymbol{a}_n\in C(\boldsymbol{A})$. 因此，原问题就转化为：找出 $C(\boldsymbol{A})$ 中和 $\boldsymbol{b}$ 距离最近的向量 $\boldsymbol{p}=\boldsymbol{A}\hat{\boldsymbol{x}}$. 符号 $\hat{\boldsymbol{x}}$ 上的“小帽子”

意思是最优解，就是说，$A\hat{x}$ 是集合 $\{Ax : x \in \mathbb{R}^n\}$ 中和 $b$ 距离最近的元素. 当 $n=1$ 时，已知 $\hat{x}=a^{\mathrm{T}}b/a^{\mathrm{T}}b$；当 $n>1$ 时，最优的 $\hat{x}$ 就是我们的目标.

计算到 $n$ 维子空间的正交投影也分成三个步骤（和到直线正交投影类似）：

① 求出向量 $\hat{x}$；　② 正交投影 $p=A\hat{x}$；　③ 正交投影矩阵 $P$.

要达成这些目标，几何上的观察提供了相当重要的提示. 图 4.3中虚线部分的向量从 $b$ 指向了子空间中离它最近的向量 $A\hat{x}$. 误差项 $b-A\hat{x}$ 和子空间正交，于是它和 $a_1, a_2, \cdots, a_n$ 都正交. 这 $n$ 个正交关系给出关于 $\hat{x}$ 的 $n$ 个方程：

$$\begin{cases} a_1^{\mathrm{T}}(b-A\hat{x})=0 \\ \quad\vdots \\ a_n^{\mathrm{T}}(b-A\hat{x})=0 \end{cases} \quad \text{或者} \quad \begin{bmatrix} a_1^{\mathrm{T}} \\ \vdots \\ a_n^{\mathrm{T}} \end{bmatrix} \begin{bmatrix} b-A\hat{x} \end{bmatrix} = \begin{bmatrix} 0 \end{bmatrix} \quad \text{或者} \quad A^{\mathrm{T}}A\hat{x}=A^{\mathrm{T}}b \tag{4.6}$$

以 $a_i^{\mathrm{T}}$ 为行向量的矩阵是 $A^{\mathrm{T}}$，用矩阵乘法来表示这 $n$ 个方程就是 $A^{\mathrm{T}}(b-A\hat{x})=0$.

把 $A^{\mathrm{T}}(b-A\hat{x})=0$ 重写成熟知的形式：$A^{\mathrm{T}}A\hat{x}=A^{\mathrm{T}}b$. 这是关于 $\hat{x}$ 的、以 $A^{\mathrm{T}}A$ 为系数矩阵的方程组. 解该方程组就能求出 $\hat{x}$、$p$ 和 $P$.

以下式(4.7)~式(4.9)是求正交投影的关键步骤.

和 $b$ 距离最近的线性组合 $p=\hat{x}_1a_1+\hat{x}_2a_2+\cdots+\hat{x}_na_n=A\hat{x}$ 由 $\hat{x}$ 给出：

找出满足条件的 $n\times 1$矩阵$\hat{x}$　$A^{\mathrm{T}}(b-A\hat{x})=0$　或者　$A^{\mathrm{T}}A\hat{x}=A^{\mathrm{T}}b$　(4.7)

$A^{\mathrm{T}}A$ 是 $n\times n$ 对称矩阵. 因为 $a_1, a_2, \cdots, a_n$ 线性无关，所以 $A^{\mathrm{T}}A$ 是可逆矩阵，方程组式(4.7)的唯一解是 $\hat{x}=(A^{\mathrm{T}}A)^{-1}A^{\mathrm{T}}b$. $b$ 在子空间上的正交投影是 $p$：

求出 $m\times 1$矩阵$p$　$p=A\hat{x}=A(A^{\mathrm{T}}A)^{-1}A^{\mathrm{T}}b.$　(4.8)

上式给出了左乘于 $b$ 的投影矩阵 $P$，表达式中包含 4 个 $A$：

求出 $m\times m$矩阵$P$　$P=A(A^{\mathrm{T}}A)^{-1}A^{\mathrm{T}}.$　(4.9)

当 $n=1$，即向直线作正交投影时，$A$ 只有一列，$A^{\mathrm{T}}A=a^{\mathrm{T}}a$ 是 $1\times 1$ 矩阵，或者说是一个数：

$n=1$ 时　$\hat{x}=\dfrac{a^{\mathrm{T}}b}{a^{\mathrm{T}}a}$,　$p=a\dfrac{a^{\mathrm{T}}b}{a^{\mathrm{T}}a}$,　$P=\dfrac{aa^{\mathrm{T}}}{a^{\mathrm{T}}a}$.　(4.10)

这三个表达式我们在 4.2.1 节就已经得到了，它们和式(4.7)、式(4.8)、式(4.10)得出的结果完全一样.[①]形式上的不同点不过是 $a^{\mathrm{T}}a$ 被写成了 $A^{\mathrm{T}}A$，若它是非零数，我们可以除以它；若它是可逆矩阵，我们乘以其逆矩阵. $a_1, a_2, \cdots, a_n$ 的线性无关性保证了 $A^{\mathrm{T}}A$ 是可逆的.

解方程组 $A^{\mathrm{T}}(b-A\hat{x})=0$ 是非常重要的一步. 先前我们是从几何（即 $e$ 和 $a_1, a_2, \cdots, a_n$ 都正交）角度列出方程组，当然也可以从代数的角度以一种快速而优雅的方式出发：

（1）正交投影的目标子空间实际上是 $A$ 的列空间 $\mathcal{C}(A)$.

（2）误差 $e=b-A\hat{x}$ 属于 $\mathcal{C}(A)$ 的正交补空间——$\mathcal{N}(A^{\mathrm{T}})$.

① 译者注：在学习到一个一般性的论述时，该如何理解其含义？如何说服自己相信一个陌生的陈述是正确的呢？一个方法就是取特例进行验证；特例往往是我们已经学过的东西，在验证的过程中，一方面，我们可以感受一般论述是在说什么，另一方面，一般论述取特例能成立其实也给出了正确性的证据.

这说明 $\boldsymbol{A}^{\mathrm{T}}(\boldsymbol{b}-\boldsymbol{A}\hat{\boldsymbol{x}})=\boldsymbol{0}$. 当我们考虑正交投影时，左零空间 $\mathcal{N}(\boldsymbol{A}^{\mathrm{T}})$ 很重要，它包含了误差项 $\boldsymbol{e}=\boldsymbol{b}-\boldsymbol{A}\hat{\boldsymbol{x}}$. 向量 $\boldsymbol{b}$ 分解成两部分：正交投影 $\boldsymbol{p}$ 和误差项 $\boldsymbol{e}=\boldsymbol{b}-\boldsymbol{p}$. 正交投影诱导出以 $\boldsymbol{p}$、$\boldsymbol{e}$ 和 $\boldsymbol{b}$ 为三条边的直角三角形.

**例 4.7** 若 $\boldsymbol{A}=\begin{bmatrix}1&0\\1&1\\1&2\end{bmatrix}$, $\boldsymbol{b}=\begin{bmatrix}6\\0\\0\end{bmatrix}$，请求出 $\hat{\boldsymbol{x}}$、$\boldsymbol{p}$ 和 $\boldsymbol{P}$.

**解** 计算方阵 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 和向量 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$

$$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}=\begin{bmatrix}1&1&1\\0&1&2\end{bmatrix}\begin{bmatrix}1&0\\1&1\\1&2\end{bmatrix}=\begin{bmatrix}3&3\\3&5\end{bmatrix},\qquad \boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}=\begin{bmatrix}1&1&1\\0&1&2\end{bmatrix}\begin{bmatrix}6\\0\\0\end{bmatrix}=\begin{bmatrix}6\\0\end{bmatrix}$$

下一步我们通过解方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$ 来求解 $\hat{\boldsymbol{x}}$

$$\text{由}\quad\begin{bmatrix}3&3\\3&5\end{bmatrix}\begin{bmatrix}\hat{x}_1\\\hat{x}_2\end{bmatrix}=\begin{bmatrix}6\\0\end{bmatrix}\qquad\text{可得}\qquad\hat{\boldsymbol{x}}=\begin{bmatrix}\hat{x}_1\\\hat{x}_2\end{bmatrix}=\begin{bmatrix}\mathbf{5}\\\mathbf{-3}\end{bmatrix}\tag{4.11}$$

$\boldsymbol{b}$ 在 $\boldsymbol{A}$ 列空间上的正交投影为 $\boldsymbol{p}=\boldsymbol{A}\hat{\boldsymbol{x}}$

$$\boldsymbol{p}=\mathbf{5}\begin{bmatrix}1\\1\\1\end{bmatrix}\mathbf{-3}\begin{bmatrix}0\\1\\2\end{bmatrix}=\begin{bmatrix}5\\2\\-1\end{bmatrix}.\qquad\text{误差项是}\qquad\boldsymbol{e}=\boldsymbol{b}-\boldsymbol{p}=\begin{bmatrix}1\\-2\\1\end{bmatrix}\tag{4.12}$$

我们从两个侧面，用两种方式验证计算是否正确. 首先，误差 $\boldsymbol{e}=\begin{bmatrix}1&-2&1\end{bmatrix}^{\mathrm{T}}$ 与 $\boldsymbol{A}$ 的列向量 $\begin{bmatrix}1&1&1\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}0&1&2\end{bmatrix}^{\mathrm{T}}$ 都正交. 其次，矩阵 $\boldsymbol{P}$ 乘以 $\boldsymbol{b}=\begin{bmatrix}6&0&0\end{bmatrix}^{\mathrm{T}}$ 会得到正确的 $\boldsymbol{p}=\begin{bmatrix}5&2&-1\end{bmatrix}^{\mathrm{T}}$. 第二种验证方式不仅对特定 $\boldsymbol{b}$ 求出它的正交投影，也求出了投影矩阵 $\boldsymbol{P}$.

投影矩阵 $\boldsymbol{P}=\boldsymbol{A}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1}\boldsymbol{A}^{\mathrm{T}}$，$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 的行列式是 $15-9=6$；它是 $2\times2$ 矩阵，所以逆矩阵很容易求；然后做矩阵乘法：$\boldsymbol{A}$ 乘以 $(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1}$ 乘以 $\boldsymbol{A}^{\mathrm{T}}$，就算出了 $\boldsymbol{P}$

$$(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1}=\frac{1}{6}\begin{bmatrix}5&-3\\-3&3\end{bmatrix}\qquad\text{且}\qquad\boldsymbol{P}=\frac{1}{6}\begin{bmatrix}5&2&-1\\2&2&2\\-1&2&5\end{bmatrix}\tag{4.13}$$

当然，我们最好还是再验算一下等式 $\boldsymbol{P}^2=\boldsymbol{P}$，这也是在检验计算准确性. 这个等式成立的原因我们已经知道了：投影两次和投影一次没有区别.

**提醒** 矩阵 $\boldsymbol{P}$ 的表达式 $\boldsymbol{A}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1}\boldsymbol{A}^{\mathrm{T}}$ 有一定的迷惑性. 有些人会以为 $(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1}=\boldsymbol{A}^{-1}(\boldsymbol{A}^{\mathrm{T}})^{-1}$；一旦如此，把这个谬误代入 $\boldsymbol{P}$ 的表达式就得到 $\boldsymbol{P}=\boldsymbol{A}\boldsymbol{A}^{-1}(\boldsymbol{A}^{\mathrm{T}})^{-1}\boldsymbol{A}^{\mathrm{T}}$. 接着，把能消掉的东西消掉之后，结果居然是 $\boldsymbol{P}=\boldsymbol{I}$. 这显然是错误的，那么问题来了：哪里出错了呢？

**原因在于矩阵 $\boldsymbol{A}$ 不是方阵，没有逆矩阵.** 当 $m>n$ 时，$\boldsymbol{A}^{-1}$ 压根不存在，更别谈把 $(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1}$ 分解成 $\boldsymbol{A}^{-1}(\boldsymbol{A}^{\mathrm{T}})^{-1}$ 了.

根据我的经验，涉及非方阵的普通矩阵 $\boldsymbol{A}$ 的问题往往会导向 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$. 如果 $m\times n$ 矩阵 $\boldsymbol{A}$ 是列满秩——列向量线性无关，那么 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 是可逆矩阵. 所谓“重要的事情说三遍”，尽管 3.5节已经证明过了，但我们还是不厌其烦地再叙述并证明一遍.

**$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 是可逆矩阵，当且仅当 $\boldsymbol{A}$ 的列向量线性无关.**

**证明** $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 是 $n$ 阶方阵. 我们先断言：**$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 和 $\boldsymbol{A}$ 有相同的零空间：$\mathcal{N}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})=\mathcal{N}(\boldsymbol{A})$.** 于是：

$$
\begin{aligned}
&\boldsymbol{A}\text{的列向量线性无关}\\
\Leftrightarrow\ &\mathcal{N}(\boldsymbol{A})=\{\boldsymbol{0}\}\\
\Leftrightarrow\ &\mathcal{N}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})=\{\boldsymbol{0}\}\\
\Leftrightarrow\ &\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\text{列向量线性无关，等价于 }\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\text{ 可逆.}
\end{aligned}
$$

其中第二个“$\Leftrightarrow$”使用了断言. 剩下来只需要验证断言. 首先，对 $\boldsymbol{x}\in\mathcal{N}(\boldsymbol{A})$，即 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$，再左乘 $\boldsymbol{A}^{\mathrm{T}}$ 即有 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$，这说明了 $\mathcal{N}(\boldsymbol{A})\subseteq\mathcal{N}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{x})$.

此外，对 $\boldsymbol{x}\in\mathcal{N}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})$，即 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$，**目标是证明 $\boldsymbol{x}\in\mathcal{N}(\boldsymbol{A})$，即 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$.** 一般来说 $\boldsymbol{A}^{\mathrm{T}}$ 不是方阵，$(\boldsymbol{A}^{\mathrm{T}})^{-1}$ 不存在，所以不能直接乘，但是可以左乘 $\boldsymbol{x}^{\mathrm{T}}$:

$$
\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}\quad\Rightarrow\quad\boldsymbol{x}^{\mathrm{T}}\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{x}=\boldsymbol{x}^{\mathrm{T}}\boldsymbol{0}=0\quad\Rightarrow\quad(\boldsymbol{A}\boldsymbol{x})^{\mathrm{T}}(\boldsymbol{A}\boldsymbol{x})=0\quad\Rightarrow\quad\|\boldsymbol{A}\boldsymbol{x}\|^2=0\qquad(4.14)
$$

也就是说，我们证明了：当 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$ 时，$\boldsymbol{A}\boldsymbol{x}$ 的长度是 0，从而 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$，因此 $\mathcal{N}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{x})\subseteq\mathcal{N}(\boldsymbol{A})$. 综上所述，就有 $\mathcal{N}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})=\mathcal{N}(\boldsymbol{A})$.

总结一下就是说，向量 $\boldsymbol{x}$ 若属于 $\mathcal{N}(\boldsymbol{A})$ 和 $\mathcal{N}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})$ 中的一个，也一定同时属于另一个. $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 的列向量线性相关，则 $\boldsymbol{A}$ 也如此；$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 的列向量线性无关，则 $\boldsymbol{A}$ 也如此. 显然这是非常理想的一种情形：$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 是可逆矩阵.

**若 $\boldsymbol{A}$ 的列向量线性无关，则 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 是对称的可逆方阵.**

再次强调：$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 是 $n\times m$ 矩阵乘以 $m\times n$ 矩阵，所以是 $n\times n$ 矩阵——$n$ 阶方阵. 取转置则有 $(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{\mathrm{T}}=\boldsymbol{A}^{\mathrm{T}}(\boldsymbol{A}^{\mathrm{T}})^{\mathrm{T}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$，因此 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 是对称矩阵. 在 $\boldsymbol{A}$ 列满秩的前提下，我们刚刚证明了 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 可逆. 我们通过具体例子看一下 $\boldsymbol{A}$ 列满秩和不列满秩之间的区别.

$$
\begin{array}{cccc}
\boldsymbol{A}^{\mathrm{T}} & \boldsymbol{A} & \boldsymbol{A}^{\mathrm{T}}\boldsymbol{A} & \\
\begin{bmatrix}1&1&0\\2&2&0\end{bmatrix} & \begin{bmatrix}1&2\\1&2\\0&0\end{bmatrix} & =\begin{bmatrix}2&4\\4&8\end{bmatrix} & \\
\text{列相关} & & \text{不可逆} & \\
\boldsymbol{A}^{\mathrm{T}} & \boldsymbol{A} & \boldsymbol{A}^{\mathrm{T}}\boldsymbol{A} & \\
\begin{bmatrix}1&1&0\\2&2&1\end{bmatrix} & \begin{bmatrix}1&2\\1&2\\0&1\end{bmatrix} & =\begin{bmatrix}2&4\\4&9\end{bmatrix} & \\
\text{列满秩} & & \text{可逆} &
\end{array}
$$

**简短的总结：**为了求正交投影：$\boldsymbol{p}=\hat{x}_1\boldsymbol{a}_1+\hat{x}_2\boldsymbol{a}_2+\cdots+\hat{x}_n\boldsymbol{a}_n$，我们要解方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$. 求出 $\hat{\boldsymbol{x}}$ 之后，正交投影为 $\boldsymbol{p}=\boldsymbol{A}\hat{\boldsymbol{x}}$，误差为 $\boldsymbol{e}=\boldsymbol{b}-\boldsymbol{p}=\boldsymbol{b}-\boldsymbol{A}\hat{\boldsymbol{x}}$. 投影矩阵为 $\boldsymbol{P}=\boldsymbol{A}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1}\boldsymbol{A}^{\mathrm{T}}$，$\boldsymbol{p}=\boldsymbol{P}\boldsymbol{b}$. $\boldsymbol{P}$ 是可逆矩阵当且仅当 $\boldsymbol{P}=\boldsymbol{I}$.

**投影矩阵 $\boldsymbol{P}$ 满足 $\boldsymbol{P}^2=\boldsymbol{P}$. $\boldsymbol{b}$ 到子空间 $C(\boldsymbol{A})$ 的距离是 $\|\boldsymbol{e}\|$.**

## 重点复习

1. 向量 $\boldsymbol{b}$ 到 $\boldsymbol{a}$ 的正交投影是 $\boldsymbol{p}=\boldsymbol{a}\hat{\boldsymbol{x}}=\boldsymbol{a}\left(\boldsymbol{a}^{\mathrm{T}}\boldsymbol{b}/\boldsymbol{a}^{\mathrm{T}}\boldsymbol{a}\right)$.

2. 秩 1 矩阵 $\boldsymbol{P}=\boldsymbol{a}\boldsymbol{a}^{\mathrm{T}}/\boldsymbol{a}^{\mathrm{T}}\boldsymbol{a}$ 是把 $\boldsymbol{b}$ 映到 $\boldsymbol{p}$ 的投影矩阵.

3. 把 $\boldsymbol{b}$ 向一个子空间作正交投影得到的误差 $\boldsymbol{e}=\boldsymbol{b}-\boldsymbol{p}$ 和该子空间正交.

4. 若 $\boldsymbol{A}$ 是列满秩的 $m\times n$ 矩阵，那么方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$ 的解 $\hat{\boldsymbol{x}}$ 给出 $\boldsymbol{b}$ 在 $\mathcal{C}(\boldsymbol{A})$ 上的正交投影 $\boldsymbol{p}=\boldsymbol{A}\hat{\boldsymbol{x}}$.

5. 若 $\boldsymbol{A}$ 是列满秩的 $m\times n$ 矩阵，到 $\boldsymbol{A}$ 列空间的正交投影矩阵为 $\boldsymbol{P}=\boldsymbol{A}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1}\boldsymbol{A}^{\mathrm{T}}$,$\boldsymbol{p}=\boldsymbol{P}\boldsymbol{b}$，并且满足 $\boldsymbol{P}^2=\boldsymbol{P}$,$\boldsymbol{P}^{\mathrm{T}}=\boldsymbol{P}$.

## 例题总结

4.2 A. 设 $\boldsymbol{a}=\begin{bmatrix}2&2&1\end{bmatrix}^{\mathrm{T}}$,$\boldsymbol{a}^*=\begin{bmatrix}1&0&0\end{bmatrix}^{\mathrm{T}}$,$V$ 是 $\boldsymbol{a}$ 和 $\boldsymbol{a}^*$ 张成的平面. 把向量 $\boldsymbol{b}=\begin{bmatrix}3&4&4\end{bmatrix}^{\mathrm{T}}$ 正交投影到 $\boldsymbol{a}$，验证误差 $\boldsymbol{b}-\boldsymbol{p}$ 和 $\boldsymbol{a}$ 正交，再把 $\boldsymbol{b}$ 正交投影到平面 $V$. 验证误差 $\boldsymbol{e}^*=\boldsymbol{b}-\boldsymbol{p}^*$ 不仅和 $\boldsymbol{a}$ 正交，也和 $\boldsymbol{a}^*$ 正交.

求正交投影到 $V$ 的投影矩阵 $\boldsymbol{P}$；并找出一个向量，其到 $V$ 的正交投影是 $\boldsymbol{p}=\boldsymbol{0}$.

**解** $\boldsymbol{b}=\begin{bmatrix}3&4&4\end{bmatrix}^{\mathrm{T}}$ 到 $\boldsymbol{a}=\begin{bmatrix}2&2&1\end{bmatrix}^{\mathrm{T}}$ 的正交投影是 $\boldsymbol{p}=2\boldsymbol{a}$

$$\boldsymbol{p}=\frac{\boldsymbol{a}^{\mathrm{T}}\boldsymbol{b}}{\boldsymbol{a}^{\mathrm{T}}\boldsymbol{a}}\boldsymbol{a}=\frac{18}{9}\begin{bmatrix}2\\2\\1\end{bmatrix}=\begin{bmatrix}4\\4\\2\end{bmatrix}=2\boldsymbol{a}.$$

误差 $\boldsymbol{e}=\boldsymbol{b}-\boldsymbol{p}=\begin{bmatrix}-1&0&2\end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{a}=\begin{bmatrix}2&2&1\end{bmatrix}^{\mathrm{T}}$ 正交，这表明 $\boldsymbol{p}$ 计算正确.

平面 $V$ 是矩阵 $\boldsymbol{A}=\begin{bmatrix}\boldsymbol{a}&\boldsymbol{a}^*\end{bmatrix}$ 的列空间:

$$\boldsymbol{A}=\begin{bmatrix}2&1\\2&0\\1&0\end{bmatrix}\qquad \boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}=\begin{bmatrix}9&2\\2&1\end{bmatrix}\qquad (\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1}=\frac{1}{5}\begin{bmatrix}1&-2\\-2&9\end{bmatrix}\qquad \boldsymbol{P}=\begin{bmatrix}1&0&0\\0&0.8&0.4\\0&0.4&0.2\end{bmatrix}$$

于是 $\boldsymbol{p}^*=\boldsymbol{P}\boldsymbol{b}=\begin{bmatrix}3&4.8&2.4\end{bmatrix}^{\mathrm{T}}$，误差 $\boldsymbol{e}^*=\boldsymbol{b}-\boldsymbol{p}^*=\begin{bmatrix}0&-0.8&1.6\end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{a}$、$\boldsymbol{a}^*$ 都正交. $\boldsymbol{e}^*$ 属于 $\boldsymbol{P}$ 的零空间，它的正交投影是零向量. 我们还要提醒 $\boldsymbol{P}$ 满足 $\boldsymbol{P}^2=\boldsymbol{P}=\boldsymbol{P}^{\mathrm{T}}$.

4.2 B. 某个人测量脉搏，测了三次，分别是每分钟 70 次、80 次和 120 次，那脉搏到底应该是多少呢？“多次测量取平均值”是一个可行的方法；利用线性代数，我们给另一个选择. 假设脉搏每分钟 $x$ 次，上述三次测量给出方程 $\boldsymbol{A}x=\boldsymbol{b}$，其中 $\boldsymbol{A}\begin{bmatrix}1&1&1\end{bmatrix}^{\mathrm{T}}=\boldsymbol{b}=\begin{bmatrix}70&80&120\end{bmatrix}^{\mathrm{T}}$；该方程组显然没有解. 但是 70、80、120 的最佳逼近是_____. 对于这个问题，我们可以从微积分和正交投影两个角度去求解:

（1）$E=(x-70)^2+(x-80)^2+(x-120)^2$ 取最小值时，$\mathrm{d}E/\mathrm{d}x=0$.

（2）把 $\boldsymbol{b}$ 正交投影到 $\boldsymbol{a}$，求得 $\hat{x}=$ 平均值 $=90$.

4.2 C. 假设有一组数据 $b_1, b_2, \cdots, b_{999}$，我们只知道它们的均值 $\hat{x}_{旧}$. 当新测量值 $b_{1000}$ 给定之后，验证：新的均值是 $\hat{x}_{旧}$ 和偏移值 $b_{1000} - \hat{x}_{旧}$ 的线性组合：

$$\hat{x}_{新} = \frac{b_1 + \cdots + b_{1000}}{1000} = \frac{b_1 + \cdots + b_{999}}{999} + \frac{1}{1000}\left(b_{1000} - \frac{b_1 + \cdots + b_{999}}{999}\right)$$

我们称之为以 $\frac{1}{1000}$ 为增益矩阵[①]的 “Kalman 滤子”：$\hat{x}_{新} = \hat{x}_{旧} + \frac{1}{1000}(b_{1000} - \hat{x}_{旧})$.

## 习题 4.2

0. 投影矩阵 $\boldsymbol{P}$ 满足 $\boldsymbol{P}^2 = \boldsymbol{P}$. 额外的关于对称性的要求 $\boldsymbol{P}^{\mathrm{T}} = \boldsymbol{P}$ 保证了 $\boldsymbol{P}$ 是正交投影矩阵. 以下例子可以说明这些术语的含义和区别.

（1）令 $\boldsymbol{P} = \begin{bmatrix} 0 & 1 \\ 0 & 1 \end{bmatrix}$，那么 $\boldsymbol{I} - \boldsymbol{P} = \begin{bmatrix} 1 & -1 \\ 0 & 0 \end{bmatrix}$，请验证 $\boldsymbol{P}^2 = \boldsymbol{P}, (\boldsymbol{I} - \boldsymbol{P})^2 = \boldsymbol{I} - \boldsymbol{P}$.

（2）在 $\boldsymbol{P}$ 和 $\boldsymbol{I} - \boldsymbol{P}$ 的列空间中各找一个非零向量，两者的列空间是否正交？

（3）证明：若 $\boldsymbol{P}^2 = \boldsymbol{P}$ 且 $\boldsymbol{P}^{\mathrm{T}} = \boldsymbol{P}$，那么对任意向量 $\boldsymbol{v}$、$\boldsymbol{w}$、$\boldsymbol{Pv}$ 和 $(\boldsymbol{I} - \boldsymbol{P})\boldsymbol{w}$ 的点积始终为零，$(\boldsymbol{Pv})^{\mathrm{T}}((\boldsymbol{I} - \boldsymbol{P})\boldsymbol{w}) = 0$. 这说明 $\boldsymbol{P}$ 和 $\boldsymbol{I} - \boldsymbol{P}$ 的列空间正交.

总结　要使 $\boldsymbol{p} = \boldsymbol{Pb}$ 和误差项 $\boldsymbol{e} = \boldsymbol{b} - \boldsymbol{p}$ 正交，必须有 $\boldsymbol{P}^2 = \boldsymbol{P} = \boldsymbol{P}^{\mathrm{T}}$.

习题 1 ~ 10 关于到直线的正交投影 $\boldsymbol{p}$，误差 $\boldsymbol{e} = \boldsymbol{b} - \boldsymbol{p}$，以及投影矩阵 $\boldsymbol{P}$.

1. 求 $\boldsymbol{b}$ 到 $\boldsymbol{a}$ 的正交投影，验证 $\boldsymbol{e}$ 和 $\boldsymbol{a}$ 正交：

（1）$\boldsymbol{b} = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix}$，$\boldsymbol{a} = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$；　　（2）$\boldsymbol{b} = \begin{bmatrix} 1 \\ 3 \\ 1 \end{bmatrix}$，$\boldsymbol{a} = \begin{bmatrix} -1 \\ -3 \\ -1 \end{bmatrix}$.

2. 画出 $\boldsymbol{b}$ 到 $\boldsymbol{a}$ 的正交投影，并计算 $\boldsymbol{p} = \hat{x}\boldsymbol{a}$

（1）$\boldsymbol{b} = \begin{bmatrix} \cos\theta \\ \sin\theta \end{bmatrix}$，$\boldsymbol{a} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$；　　（2）$\boldsymbol{b} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$，$\boldsymbol{a} = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$.

3. 对习题 1 中的两个小题，用公式 $\boldsymbol{P} = \boldsymbol{a}\boldsymbol{a}^{\mathrm{T}}/\boldsymbol{a}^{\mathrm{T}}\boldsymbol{a}$ 计算投影矩阵. 在两种情况下，分别验证 $\boldsymbol{P}^2 = \boldsymbol{P}$，再用 $\boldsymbol{Pb}$ 来计算正交投影 $\boldsymbol{p}$.

4. 对习题 2 中的两个小题，分别计算它们的投影矩阵 $\boldsymbol{P}_1$ 和 $\boldsymbol{P}_2$. 等式 $(\boldsymbol{P}_1 + \boldsymbol{P}_2)^2 = \boldsymbol{P}_1 + \boldsymbol{P}_2$ 是否成立？需要说明的是，当两个正交投影矩阵 $\boldsymbol{P}_1$、$\boldsymbol{P}_2$ 满足 $\boldsymbol{P}_1\boldsymbol{P}_2 = \boldsymbol{0}$ 时，等式 $(\boldsymbol{P}_1 + \boldsymbol{P}_2)^2 = \boldsymbol{P}_1 + \boldsymbol{P}_2$ 成立.

5. 利用公式 $\boldsymbol{a}\boldsymbol{a}^{\mathrm{T}}/\boldsymbol{a}^{\mathrm{T}}\boldsymbol{a}$ 分别计算到 $\boldsymbol{a}_1 = \begin{bmatrix} 1 & -2 & 2 \end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{a}_2 = \begin{bmatrix} 2 & 2 & -1 \end{bmatrix}^{\mathrm{T}}$（见图 4.4）的正交投影矩阵 $\boldsymbol{P}_1$、$\boldsymbol{P}_2$；计算 $\boldsymbol{P}_1\boldsymbol{P}_2$，并解释为什么会出现这个结果.

6. 把 $\boldsymbol{b} = \begin{bmatrix} 1 & 0 & 0 \end{bmatrix}^{\mathrm{T}}$ 分别正交投影到第 5 题中两个向量所在的直线，再正交投影到 $\boldsymbol{a}_3 = \begin{bmatrix} 2 & -1 & 2 \end{bmatrix}^{\mathrm{T}}$. 计算这三个正交投影 $\boldsymbol{p}_1$、$\boldsymbol{p}_2$、$\boldsymbol{p}_3$，并把它们相加求出 $\boldsymbol{p}_1 + \boldsymbol{p}_2 + \boldsymbol{p}_3$.

① 译者注：言下之意，此处只是维数等于 1 的情形，所以所谓的“增益矩阵”是一阶的，就是一个数，在高维的情形会成为真正的矩阵.

7. 接第 5 题和第 6 题，计算正交投影到 $\boldsymbol{a}_3$ 的投影矩阵 $\boldsymbol{P}_3$，请验证：$\boldsymbol{P}_1+\boldsymbol{P}_2+\boldsymbol{P}_3=\boldsymbol{I}$.

注：这个等式成立的原因是 $\boldsymbol{a}_1$、$\boldsymbol{a}_2$、$\boldsymbol{a}_3$ 是一组正交基.

8. 把向量 $\boldsymbol{b}=\begin{bmatrix}1 & 1\end{bmatrix}^{\mathrm{T}}$ 分别正交投影到 $\boldsymbol{a}_1=\begin{bmatrix}1 & 0\end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{a}_2=\begin{bmatrix}1 & 2\end{bmatrix}^{\mathrm{T}}$，请画出这两个投影 $\boldsymbol{p}_1$、$\boldsymbol{p}_2$，画出并计算 $\boldsymbol{p}_1+\boldsymbol{p}_2$. 注意：因为 $\boldsymbol{a}_1$、$\boldsymbol{a}_2$ 不是正交基，所以 $\boldsymbol{p}_1+\boldsymbol{p}_2\neq\boldsymbol{b}$.

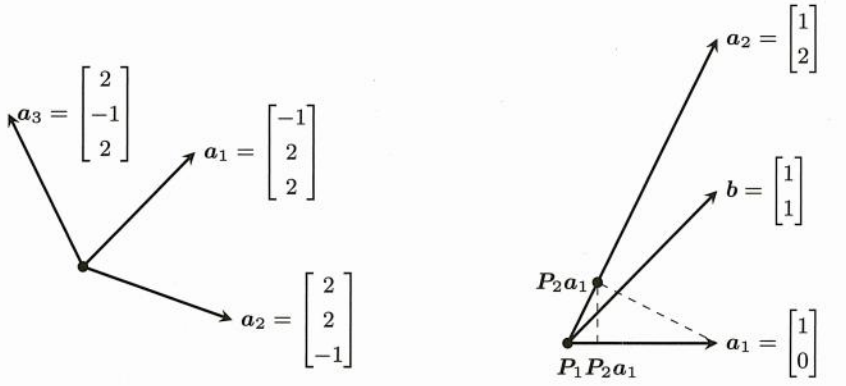


(a) 习题 5 ~ 7：$\boldsymbol{a}_1$、$\boldsymbol{a}_2$、$\boldsymbol{a}_3$ 正交　　(b) 习题 8 ~ 10：$\boldsymbol{a}_1$、$\boldsymbol{a}_2$ 不正交

图 4.4　习题 5 ~ 10 的示意图

9. 第 8 题中，$\boldsymbol{b}$ 到 $\boldsymbol{a}_1$、$\boldsymbol{a}_2$ 张成的平面的正交投影等于 $\boldsymbol{b}$ 自身. 令 $\boldsymbol{A}=\begin{bmatrix}\boldsymbol{a}_1 & \boldsymbol{a}_2\end{bmatrix}$，根据公式 $\boldsymbol{P}=\boldsymbol{A}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1}\boldsymbol{A}^{\mathrm{T}}$ 计算投影矩阵. 提示：$\boldsymbol{A}=\begin{bmatrix}\boldsymbol{a}_1 & \boldsymbol{a}_2\end{bmatrix}=\begin{bmatrix}1 & 1\\0 & 2\end{bmatrix}$ 是可逆矩阵.

10. 把 $\boldsymbol{a}_1=\begin{bmatrix}1 & 0\end{bmatrix}^{\mathrm{T}}$ 正交投影到 $\boldsymbol{a}_2=\begin{bmatrix}1 & 2\end{bmatrix}^{\mathrm{T}}$，再把此投影向量正交投影到 $\boldsymbol{a}_1$. 请画出这两个正交投影，并且计算投影矩阵 $\boldsymbol{P}_1$、$\boldsymbol{P}_2$. 计算矩阵乘法 $\boldsymbol{P}_1\boldsymbol{P}_2$，它是正交投影矩阵吗？

习题 11 ~ 21 关于到子空间的正交投影和投影矩阵.

11. 设 $m\times m$ 矩阵 $\boldsymbol{P}$ 是 $\mathbb{R}^m$ 到子空间 $S$ 的正交投影矩阵，那么 $\boldsymbol{P}$ 的四个基本子空间是什么？

12. 对以下两个小题，通过解方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$ 和 $\boldsymbol{p}=\boldsymbol{A}\hat{\boldsymbol{x}}$ 来计算 $\boldsymbol{b}$ 到 $\boldsymbol{A}$ 列空间的正交投影. 再计算误差 $\boldsymbol{e}=\boldsymbol{b}-\boldsymbol{p}$，验证它和 $\boldsymbol{A}$ 的列向量都正交.

（1）$\boldsymbol{A}=\begin{bmatrix}1 & 1\\0 & 1\\0 & 0\end{bmatrix}$，$\boldsymbol{b}=\begin{bmatrix}2\\3\\4\end{bmatrix}$　　（2）$\boldsymbol{A}=\begin{bmatrix}1 & 1\\1 & 1\\0 & 1\end{bmatrix}$，$\boldsymbol{b}=\begin{bmatrix}4\\4\\6\end{bmatrix}$.

13. 计算上题中两个小题的投影矩阵 $\boldsymbol{P}_1$ 和 $\boldsymbol{P}_2$；验证 $\boldsymbol{P}_1\boldsymbol{b}$ 给出了 (1) 小题中 $\boldsymbol{b}$ 的正交投影 $\boldsymbol{p}_1$；验证 $\boldsymbol{P}_2^2=\boldsymbol{P}_2$.

14.（推荐）设 $\boldsymbol{A}$ 是 $4\times4$ 单位阵的前三列. 把 $\boldsymbol{b}=\begin{bmatrix}1 & 2 & 3 & 4\end{bmatrix}^{\mathrm{T}}$ 正交投影到 $\boldsymbol{A}$ 的列空间，求 $\boldsymbol{b}$ 的投影. 这个正交投影的投影矩阵 $\boldsymbol{P}$ 是什么形状的？请算出 $\boldsymbol{P}$.

15. 假设向量 $\boldsymbol{b}$ 是矩阵 $\boldsymbol{A}$ 第一列的两倍，那么 $\boldsymbol{b}$ 在 $\boldsymbol{A}$ 的列空间的正交投影是什么？该正交投影矩阵是否一定是 $\boldsymbol{I}$？当 $\boldsymbol{A}$ 的列向量是 $\begin{bmatrix}0 & 1 & 2\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}1 & 2 & 0\end{bmatrix}^{\mathrm{T}}$ 时，$\boldsymbol{b}=\begin{bmatrix}0 & 2 & 4\end{bmatrix}^{\mathrm{T}}$，计算 $\boldsymbol{p}$ 和 $\boldsymbol{P}$.

16. 如果 $\boldsymbol{A}$ 变成原来的两倍，那么 $\boldsymbol{P}=(2\boldsymbol{A})(4\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1}(2\boldsymbol{A}^{\mathrm{T}})$，还是等于 $\boldsymbol{A}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1}\boldsymbol{A}^{\mathrm{T}}$. $2\boldsymbol{A}$ 的列空间和_____ 相同. 对于 $\boldsymbol{A}$ 和 $2\boldsymbol{A}$，$\hat{\boldsymbol{x}}$ 是相同的吗？

17. 向量 $\begin{bmatrix}1 & 2 & -1\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}1 & 0 & 1\end{bmatrix}^{\mathrm{T}}$ 的哪个线性组合和 $\boldsymbol{b}=\begin{bmatrix}2 & 1 & 1\end{bmatrix}^{\mathrm{T}}$ 距离最近？

18.（推荐）证明：若 $\boldsymbol{P}^2=\boldsymbol{P}$，则 $(\boldsymbol{I}-\boldsymbol{P})^2=\boldsymbol{I}-\boldsymbol{P}$. 若 $\boldsymbol{P}$ 是到 $\boldsymbol{A}$ 列空间的正交投影矩阵，那么 $\boldsymbol{I}-\boldsymbol{P}$ 是到_____ 的正交投影矩阵.

19.（1）若 $2\times 2$ 矩阵 $\boldsymbol{P}$ 是到 $\begin{bmatrix}1 & 1\end{bmatrix}^{\mathrm{T}}$ 的正交投影矩阵，那么 $\boldsymbol{I}-\boldsymbol{P}$ 是到_____ 的正交投影矩阵.

（2）若 $3\times 3$ 矩阵 $\boldsymbol{P}$ 是到 $\begin{bmatrix}1 & 1 & 1\end{bmatrix}^{\mathrm{T}}$ 的正交投影矩阵，那么 $\boldsymbol{I}-\boldsymbol{P}$ 是到_____ 的正交投影矩阵.

20. 为了计算到平面 $x-y-2z=0$ 的正交投影矩阵，我们在该平面上选取两个合适的列向量，排成矩阵 $\boldsymbol{A}$，那么该平面就是 $\boldsymbol{A}$ 的列空间. 请用 $\boldsymbol{P}=\boldsymbol{A}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1}\boldsymbol{A}^{\mathrm{T}}$ 计算投影矩阵.

21. 还是计算到平面 $x-y-2z=0$ 的正交投影矩阵 $\boldsymbol{P}$. 我们选取正交于该平面的向量 $\boldsymbol{e}$，求出投影矩阵 $\boldsymbol{Q}=\boldsymbol{e}\boldsymbol{e}^{\mathrm{T}}/\boldsymbol{e}^{\mathrm{T}}\boldsymbol{e}$，那么 $\boldsymbol{P}=\boldsymbol{I}-\boldsymbol{Q}$. 请把上述过程和计算详细地写下来.

习题 22 ~ 30 全面梳理性质：正交投影矩阵满足 $\boldsymbol{P}^2=\boldsymbol{P}$ 和 $\boldsymbol{P}^{\mathrm{T}}=\boldsymbol{P}$.

22. 把矩阵 $\boldsymbol{P}=\boldsymbol{A}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1}\boldsymbol{A}^{\mathrm{T}}$ 和它自身相乘，消掉合适的项，证明：$\boldsymbol{P}^2=\boldsymbol{P}$. 由此解释 $\boldsymbol{P}\boldsymbol{b}$ 的正交投影 $\boldsymbol{P}(\boldsymbol{P}\boldsymbol{b})$ 一定等于 $\boldsymbol{P}\boldsymbol{b}$.

23. 计算 $\boldsymbol{P}^{\mathrm{T}}$，证明 $\boldsymbol{P}=\boldsymbol{A}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1}\boldsymbol{A}^{\mathrm{T}}$ 是对称矩阵. 需要注意的是，对称矩阵的逆矩阵也是对称的.

24. 若 $\boldsymbol{A}$ 是可逆方阵，则 $(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1}$ 可以分解成 $\boldsymbol{A}^{-1}(\boldsymbol{A}^{\mathrm{T}})^{-1}$，之前关于它不能分解的提醒失效了. 请基于等式 $\boldsymbol{A}\boldsymbol{A}^{-1}(\boldsymbol{A}^{\mathrm{T}})^{-1}\boldsymbol{A}^{\mathrm{T}}=\boldsymbol{I}$ 说明：当 $\boldsymbol{A}$ 可逆时，$\boldsymbol{P}=\boldsymbol{I}$；这种情况下，误差 $\boldsymbol{e}$ 是什么？

25. $\boldsymbol{A}^{\mathrm{T}}$ 的零空间 $\mathcal{N}(\boldsymbol{A}^{\mathrm{T}})$ 和列空间 $\mathcal{C}(\boldsymbol{A})$_____. 从而当 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}=\boldsymbol{0}$ 时，$\boldsymbol{b}$ 在 $\mathcal{C}(\boldsymbol{A})$ 上的正交投影是 $\boldsymbol{p}=$_____. 验证 $\boldsymbol{A}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1}\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}=\boldsymbol{p}$.

26. $\mathbb{R}^m$ 到某个 $n$ 维子空间 $S$ 的正交投影的投影矩阵 $\boldsymbol{P}$ 的秩 $r=n$. 理由如下：全体投影 $\boldsymbol{P}\boldsymbol{b}$ 填满了子空间 $S$，该子空间 $S$ 是 $\boldsymbol{P}$ 的_____.

27. 若 $m\times m$ 矩阵 $\boldsymbol{A}$ 满足 $\boldsymbol{A}^2=\boldsymbol{A}$ 且它的秩是 $m$，如何证明 $\boldsymbol{A}=\boldsymbol{I}$？

28. 本节结尾处证明了一个重要的事实：若 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$，则 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$. 此处我们再给一个证明. $\boldsymbol{A}\boldsymbol{x}$ 属于_____ 的零空间；而 $\boldsymbol{A}\boldsymbol{x}$ 总是属于_____ 的列空间. 因为 $\boldsymbol{A}\boldsymbol{x}$ 同时属于正交的两个子空间，所以 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$.

29. 设矩阵 $\boldsymbol{P}$ 满足 $\boldsymbol{P}^{\mathrm{T}}=\boldsymbol{P}$ 且 $\boldsymbol{P}^2=\boldsymbol{P}$，证明 $\boldsymbol{P}$ 第 2 个列向量长度的平方等于它第二个对角线元素 $\boldsymbol{P}_{22}$. 再对另一个列向量，说明类似的结果.

30. 设 $\boldsymbol{B}$ 是行满秩矩阵，证明：$\boldsymbol{B}\boldsymbol{B}^{\mathrm{T}}$ 是可逆矩阵.

## 挑 战 一 下

31.（1）求出正交投影到矩阵 $\boldsymbol{A}=\begin{bmatrix}3 & 6 & 6\\ 4 & 8 & 8\end{bmatrix}$ 的列空间的投影矩阵 $\boldsymbol{P}_{\mathcal{C}}$.

（2）求出正交投影到（1）中矩阵 $\boldsymbol{A}$ 的行空间的投影矩阵 $\boldsymbol{P}_{\mathcal{R}}$，它是 $3\times 3$ 矩阵. 计算矩阵 $\boldsymbol{B}=\boldsymbol{P}_{\mathcal{C}}\boldsymbol{A}\boldsymbol{P}_{\mathcal{R}}$. 计算结果令人惊讶，你能解释其中的原因吗？

32. 考虑全空间 $\mathbb{R}^m$，给定向量 $\boldsymbol{b}$ 以及 $\boldsymbol{a}_1,\boldsymbol{a}_2,\cdots,\boldsymbol{a}_n$ 的线性组合 $\boldsymbol{p}$. 如何判断 $\boldsymbol{p}$ 是否为 $\boldsymbol{b}$ 在 $\boldsymbol{a}_1,\boldsymbol{a}_2,\cdots,\boldsymbol{a}_n$ 张成的子空间上的正交投影？

33. 给定矩阵 $\boldsymbol{A}=\begin{bmatrix}1&0\\2&1\\0&1\end{bmatrix}$. 设 $\boldsymbol{P}_1$ 是正交投影到 $\boldsymbol{A}$ 的第一列的投影矩阵，$\boldsymbol{P}_2$ 是到 $\boldsymbol{A}$ 的列空间的正交投影矩阵，计算矩阵乘法 $\boldsymbol{P}_2\boldsymbol{P}_1$. 请思考一下，能否不计算这个矩阵乘法而直接写出结果？

34. 设 $\boldsymbol{P}_1$、$\boldsymbol{P}_2$ 是两个正交投影矩阵，即 $\boldsymbol{P}_i^2=\boldsymbol{P}_i=\boldsymbol{P}_i^{\mathrm{T}}$（$i=1,2$）. 证明：$\boldsymbol{P}_1\boldsymbol{P}_2$ 是正交投影矩阵，当且仅当 $\boldsymbol{P}_1\boldsymbol{P}_2=\boldsymbol{P}_2\boldsymbol{P}_1$.

## 4.3 最小二乘法

（1）方程组 $\boxed{\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}}$ 的解给出了 $\boldsymbol{b}$ 在 $\boldsymbol{A}$ 的列空间上的正交投影 $\boldsymbol{p}=\boldsymbol{A}\hat{\boldsymbol{x}}$.

（2）若方程组 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 无解，那么 $\hat{\boldsymbol{x}}$ 是“最小二乘解”：$\|\boldsymbol{A}\hat{\boldsymbol{x}}-\boldsymbol{b}\|^2=\min\left\{\|\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}\|^2:\boldsymbol{x}\in\mathbb{R}^n\right\}$.

（3）令函数 $E=\|\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}\|^2$ 的偏导数全为零：$\left(\dfrac{\partial E}{\partial x_i}=0\right)$，也能得到最小二乘方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$.

（4）用直线拟合点 $(t_1,b_1),(t_2,b_2),\cdots,(t_m,b_m)$，则系数矩阵 $\boldsymbol{A}$ 的列向量为 $\begin{bmatrix}1&\cdots&1\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}t_1&\cdots&t_m\end{bmatrix}^{\mathrm{T}}$.

（5）在上述情况下，$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 是 $2\times 2$ 矩阵 $\begin{bmatrix}m&\sum\limits_{i=1}^{m}t_i\\\sum\limits_{i=1}^{m}t_i&\sum\limits_{i=1}^{m}t_i^2\end{bmatrix}$，$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}=\begin{bmatrix}\sum\limits_{i=1}^{m}b_i\\\sum\limits_{i=1}^{m}t_ib_i\end{bmatrix}$.

方程组 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 无解的情况时常会发生，通常来讲，原因是方程太多了——方程的个数比未知数的个数多，或者说矩阵 $\boldsymbol{A}$ 的行数大于列数（$m>n$）. $n$ 个列向量张成的子空间不够整个 $\mathbb{R}^m$. 除非所有数据都很匹配，否则 $\boldsymbol{b}$ 基本上都落在 $\boldsymbol{A}$ 的列空间之外. 用消元法来处理，最终导致一个矛盾的方程，然后消元过程就终止了. 如果数据有干扰项，例如来自实验测量的数据，可能会包含测量误差或者噪声，那么我们不能仅仅满足于到消元法终止、方程组无解.

换言之，我们并不能总是期望误差 $\boldsymbol{e}=\boldsymbol{b}-\boldsymbol{A}\boldsymbol{x}$ 最终为零. 当 $\boldsymbol{e}=\boldsymbol{0}$ 时，$\boldsymbol{x}$ 正好是方程组 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 的解. 当 $\boldsymbol{e}$ 尽可能小时，$\|\boldsymbol{b}-\boldsymbol{A}\hat{\boldsymbol{x}}\|^2$ 取到最小值，这个 $\hat{\boldsymbol{x}}$ 就是最小二乘解. 本节的主要目标就是学习如何计算和应用 $\hat{\boldsymbol{x}}$. 这些都是实际应用中经常碰到的问题，我们需要对这个问题作尽可能完善的回答.

4.2 节强调得更多的是正交投影 $\boldsymbol{p}$，本节更关注最小二乘解 $\hat{\boldsymbol{x}}$，两者的关系是 $\boldsymbol{p}=\boldsymbol{A}\hat{\boldsymbol{x}}$. 起着基

础性作用的方程组依然是 $A^{\mathrm{T}}Ax = A^{\mathrm{T}}b$. 此处有一个非正式[①]但是简洁的方法来得到这个“正规方程组”：

**当 $Ax = b$ 无解时，方程两边同时左乘 $A^{\mathrm{T}}$，解方程组 $A^{\mathrm{T}}A\hat{x} = A^{\mathrm{T}}b$.**

**例 4.8** 最小二乘法最常见的使用场景是用直线去拟合 $m$ 个点. 从三个点开始：求与点 $(0,6)$、$(1,0)$、$(2,0)$ 距离最近的直线.[②]

不存在过这三个点的直线 $b = C + Dt$. 事实上，我们要解的是关于 $C$、$D$ 这两个未知数的方程组，但是有三个方程 $n = 2, m = 3$. 对 $t = 0, 1, 2$，对应的 $b$ 的取值是 $6, 0, 0$

$t = 0$　　第一个点在直线 $b = C + Dt$ 上，即 $C + D \cdot 0 = 6$

$t = 1$　　第二个点在直线 $b = C + Dt$ 上，即 $C + D \cdot 1 = 0$

$t = 2$　　第三个点在直线 $b = C + Dt$ 上，即 $C + D \cdot 2 = 0$

写成通常的方程组的形式为 $Ax = b$

$$A = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix} \qquad x = \begin{bmatrix} C \\ D \end{bmatrix} \qquad b = \begin{bmatrix} 6 \\ 0 \\ 0 \end{bmatrix}$$

这个方程组实际上在 4.2节例 4.7中讨论过了，因为 $b = \begin{bmatrix} 6 & 0 & 0 \end{bmatrix}^{\mathrm{T}}$ 不是 $\begin{bmatrix} 1 & 1 & 1 \end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix} 0 & 1 & 2 \end{bmatrix}^{\mathrm{T}}$ 的线性组合，该方程组无解. 我们也计算出了 $\hat{x} = \begin{bmatrix} 5 & -3 \end{bmatrix}^{\mathrm{T}}$，因此**它们是 $C$、$D$ 的最优解，或者说 $b = 5 - 3t$ 是离这三个点最近的直线**. 我们必须通过解释 $A^{\mathrm{T}}A\hat{x} = A^{\mathrm{T}}b$ 成立的原因，建立正交投影和最小二乘法之间的联系.

在实际应用中，采样数据动辄成百上千个，而不是简单的三四个，因此几乎不可能存在经过所有点的直线. 这个例子中的数据 $6, 0, 0$ 有点夸张了，但这只是为了画图方便而故意放大了误差. 具体的请参考示意图 4.5.

### 4.3.1 误差最小化

怎样才能使误差 $e = b - Ax$ 尽量小呢？[③]这是一个很重要的问题，结论却出人意料地“优美”. 我们将用几何方法（误差项 $e$ 和 $A$ 的列空间正交）来找出最佳的 $x$（记作 $\hat{x}$）. 代数上，关键点是方程组 $A^{\mathrm{T}}Ax = A^{\mathrm{T}}b$. 使用多元微积分也可以得到同样的 $\hat{x}$——误差 $\|Ax - b\|^2$ 在 $\hat{x}$ 处的偏导数都是零.

**几何方法** $Ax$ 属于由列向量 $\begin{bmatrix} 1 & 1 & 1 \end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix} 0 & 1 & 2 \end{bmatrix}^{\mathrm{T}}$ 张成的平面，所以我们要在该平面上找出和 $b$ 最近的向量，而这个距离最近的向量是 $b$ 的正交投影 $p$.

① 译者注：之所以称之“非正式”，是因为在“$Ax = b$ 无解”的前提之下，再对它进行操作得出什么结论，逻辑上都是过不去的.

② 译者注：其实此处的距离实际上指的是纵向距离，而非点到直线的距离.

③ 译者注：我们首先明确一点，$e$ 是向量，那么此处所谓的“尽量小”，意思其实是使得 $\|e\|$ 尽量小，或者等价地，使得 $\|e\|^2$ 尽量小. 我们将一直对向量的大小采取这样的约定.

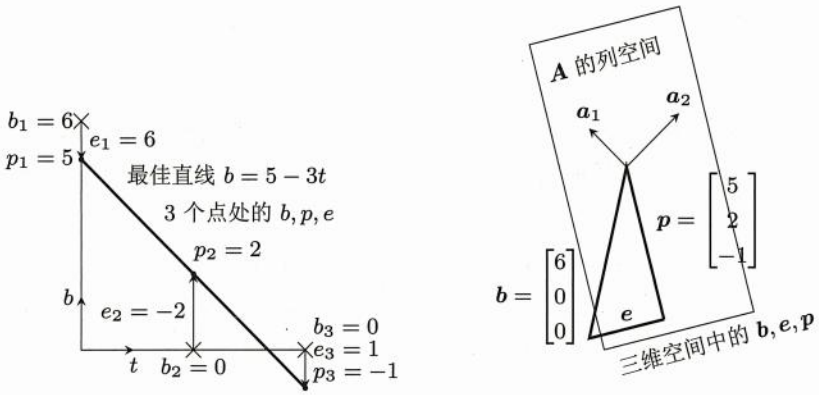


(a) 误差 = 点到直线的纵向距离　　(b) 误差 $\boldsymbol{e} = \begin{bmatrix} 1 & -2 & 1 \end{bmatrix}^{\mathrm{T}} = \boldsymbol{b} - \boldsymbol{p}$

**图 4.5　最优直线和正交投影**

注：两个图片从两个角度描述同一个问题. 该直线在 0,1,2 处的纵坐标是 $\boldsymbol{p} = \begin{bmatrix} 5 & 2 & -1 \end{bmatrix}^{\mathrm{T}}$，三个已知点的纵向误差是 $\boldsymbol{e} = \begin{bmatrix} 1 & -2 & 1 \end{bmatrix}^{\mathrm{T}}$. 由方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{x} = \boldsymbol{A}^{\mathrm{T}}\boldsymbol{x}$ 解得 $\hat{\boldsymbol{x}} = \begin{bmatrix} 5 & -3 \end{bmatrix}$. 结果相同！最优直线是 $b = 5 - 3t$，最近点是 $\boldsymbol{p} = 5\boldsymbol{a}_1 - 3\boldsymbol{a}_2$.

所以最优解 $\hat{\boldsymbol{x}}$ 满足 $\boldsymbol{A}\hat{\boldsymbol{x}} = \boldsymbol{p}$；最小误差是 $\boldsymbol{e} = \boldsymbol{b} - \boldsymbol{p}$，它正交于 $\boldsymbol{A}$ 的列空间. 因为 $\boldsymbol{p}$ 属于 $\boldsymbol{A}$ 的列空间，点 $(0, p_1)$、$(1, p_2)$、$(2, p_3)$ 共线. $\hat{\boldsymbol{x}} = \begin{bmatrix} C & D \end{bmatrix}^{\mathrm{T}}$ 是拟合直线的最优解.

**代数方法**　任意向量 $\boldsymbol{b}$ 都可以分解成两个分支：一是属于 $\boldsymbol{A}$ 列空间的分支 $\boldsymbol{p}$，二是正交于列空间的分支 $\boldsymbol{e}$. 现在我们就有了两个方程组：一是无解的方程组 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$，二是有解的方程组 $\boldsymbol{A}\hat{\boldsymbol{x}} = \boldsymbol{p}$. 后者从前者忽略 $\boldsymbol{e}$ 导出，并且可以通过方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}} = \boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$ 求解.

$$\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b} = \boldsymbol{p} + \boldsymbol{e} \quad \text{无解}; \qquad \boldsymbol{A}\hat{\boldsymbol{x}} = \boldsymbol{p} \quad \text{有解}; \qquad \hat{\boldsymbol{x}} = (\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1}\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}. \tag{4.15}$$

求解 $\boldsymbol{A}\hat{\boldsymbol{x}} = \boldsymbol{p}$ 产生的误差 $\boldsymbol{e}$ 最小：对任意 $\boldsymbol{x}$

$$\|\boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}\|^2 = \|\boldsymbol{A}\boldsymbol{x} - \boldsymbol{p}\|^2 + \|\boldsymbol{e}\|^2. \tag{4.16}$$

这就是直角三角形的勾股定理 $a^2 + b^2 = c^2$. $\boldsymbol{A}\boldsymbol{x} - \boldsymbol{p} \in \mathcal{C}(\boldsymbol{A})$，和左零空间中的向量 $\boldsymbol{e}$ 正交. 在式(4.16)中，令 $\boldsymbol{x} = \hat{\boldsymbol{x}}$，则 $\boldsymbol{A}\boldsymbol{x} - \boldsymbol{p} = \boldsymbol{0}$；余项就是我们无法消除的最小误差 $\boldsymbol{e} = \begin{bmatrix} e_1 & e_2 & e_3 \end{bmatrix}^{\mathrm{T}}$.

注意，所谓“最小误差”，是指误差向量的长度最小，所以

$$\boxed{E = \|\boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}\|^2 \text{ 在最小二乘解 } \hat{\boldsymbol{x}} \text{ 处取到最小值.}}$$

图 4.5(a) 展示了与给定的三个点纵向距离最近的直线，三个点到该直线的纵向距离 $e_1$、$e_2$、$e_3$ 分别是 1、$-2$、1. 这条直线——姑且称之为“最小二乘线”——使得 $E = e_1^2 + e_2^2 + e_3^2$ 取最小值.

图 4.5(b) 在三维空间（$\boldsymbol{b}$、$\boldsymbol{p}$、$\boldsymbol{e}$ 所在的空间）展示了这个问题. 向量 $\boldsymbol{b}$ 不属于 $\boldsymbol{A}$ 的列空间，这是方程组 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$ 无解的原因，进而导致不存在直线过我们给定的三个点. 最小的误差是和 $\mathcal{C}(\boldsymbol{A})$ 正交的向量 $\boldsymbol{e}$，它等于 $\boldsymbol{b} - \boldsymbol{A}\hat{\boldsymbol{x}}$，是三个方程对应误差，也即三个已知点到最小二乘线的纵向距离 $\begin{bmatrix} 1 & -2 & 1 \end{bmatrix}^{\mathrm{T}}$. 图 4.5 的左右两部分背后蕴含的都是最基本的方程组：$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}} = \boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$.

还有一个值得注意的现象——纵向距离 1、$-2$、1 相加为零. 这不是偶然发生的，原因在于

误差项 $\boldsymbol{e}=\begin{bmatrix}e_1 & e_2 & e_3\end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{A}$ 的第一列 $\begin{bmatrix}1 & 1 & 1\end{bmatrix}^{\mathrm{T}}$ 正交，因此点积为零，而两者的点积就是 $e_1+e_2+e_3$.

**微积分方法** 大多数函数的极值都可以用微积分来求解. 极小值点为函数图像的局部最低点，所有方向导数都是零. 具体到我们的问题，要求误差 $\boldsymbol{E}=e_1^2+e_2^2+e_3^2$（三个纵向距离的平方和）的极小值：

$$\boldsymbol{E}=\|\boldsymbol{Ax}-\boldsymbol{b}\|^2=(C+D\cdot 0-6)^2+(C+D\cdot 1)^2+(C+D\cdot 2)^2 \tag{4.17}$$

变元是 $C$ 和 $D$，所以我们考虑两个偏导数——在最小值点处，这两个偏导数取值均为零. 所谓偏导数，就是把函数看成关于其中一个变元的函数，而视其他变元为常数. 下面是 $E$ 的偏导数：

$$\frac{\partial \boldsymbol{E}}{\partial C}=2(C+D\cdot 0-6)\qquad +2(C+D\cdot 1)\qquad +2(C+D\cdot 2)\qquad =0$$

$$\frac{\partial \boldsymbol{E}}{\partial D}=2(C+D\cdot 0-6)(\mathbf{0})\quad +2(C+D\cdot 1)(\mathbf{1})\quad +2(C+D\cdot 2)(\mathbf{2})\quad =0$$

$\partial E/\partial D$ 中额外的因子 **0**、**1**、**2** 由链式法则而来 [例如最后一项 $(C+2D)^2$ 的偏导数等于 2 乘以 $(C+2D)$ 再乘以 2]，但是这三个因子在 $\partial E/\partial C$ 中并没有.

$\|\boldsymbol{Ax}-\boldsymbol{b}\|^2$ 的偏导数中出现的两组因子 $1,1,1$ 和 $0,1,2$ 也不是偶然的，它们是 $\boldsymbol{A}$ 的列向量. 把上述等式的公因子 2 全部消掉，再合并同类项：

$$\begin{aligned}&\text{关于 } C \text{ 的偏导数为 0：}\quad 3C+3D=6\\&\text{关于 } D \text{ 的偏导数为 0：}\quad 3C+5D=0\end{aligned}\qquad \text{注意到 } \boldsymbol{A}^{\mathrm{T}}\boldsymbol{A} \text{ 正好是 } \begin{bmatrix}3 & 3\\3 & 5\end{bmatrix} \tag{4.18}$$

上述关于 $C$、$D$ 的方程组恰好是 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$，$C$、$D$ 的最优解就是 $\hat{\boldsymbol{x}}$ 的分量. 微积分方法得到的方程组和线性代数得到的正规方程组是一样的. 它们是求 $\|\boldsymbol{Ax}-\boldsymbol{b}\|^2=\boldsymbol{x}^{\mathrm{T}}\boldsymbol{A}^{\mathrm{T}}\boldsymbol{Ax}-2\boldsymbol{x}^{\mathrm{T}}\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}+\boldsymbol{b}^{\mathrm{T}}\boldsymbol{b}$ 最小值所需的方程：

> 当 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$ 时，$\|\boldsymbol{Ax}-\boldsymbol{b}\|^2$ 在 $\hat{\boldsymbol{x}}$ 处的偏导数均为零.

直接求解得 $C=5, D=-3$，从而 $b=5-3t$ 是最优直线——它和三个已知点的距离最近. $t$ 分别取值 0、1、2 时，$b$ 分别取值 5、2、$-1$（$\boldsymbol{p}$ 的分量）而非 6、0、0（$\boldsymbol{b}$ 的分量），误差分别是 1、$-2$、1（$\boldsymbol{e}$ 的分量）.

### 4.3.2 最小二乘法的全局图景

本书最重要的图是关于矩阵 $\boldsymbol{A}$ 的四个基本子空间及其相互关系的图. 图 4.1左边的 $\boldsymbol{x}$ 映成右边的 $\boldsymbol{b}=\boldsymbol{Ax}$. 在那个图中，每个 $\boldsymbol{x}$ 都分解为 $\boldsymbol{x}_r+\boldsymbol{x}_n$. 方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 也有不止一个解——无穷多解.

本节，我们考虑的是完全相反的情形：$\boldsymbol{Ax}=\boldsymbol{b}$ 无解. 既然无解，也无从分解 $\boldsymbol{x}$，所以我们转而分解 $\boldsymbol{b}=\boldsymbol{p}+\boldsymbol{e}$. 图 4.6 展示了最小二乘法的全局图景.

注意到此时零空间 $\mathcal{N}(\boldsymbol{A})$ 只包含零向量，$\boldsymbol{A}$ 的列向量线性无关，方程组 $\boldsymbol{Ax}=\boldsymbol{0}$ 只有零解 $\boldsymbol{x}=\boldsymbol{0}$. 那么 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 是可逆矩阵，从而方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{Ax}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$ 完全决定了唯一的最佳向量 $\hat{\boldsymbol{x}}$. 误差项 $\boldsymbol{e}=\boldsymbol{b}-\boldsymbol{p}$ 满足 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{e}=\boldsymbol{0}$.

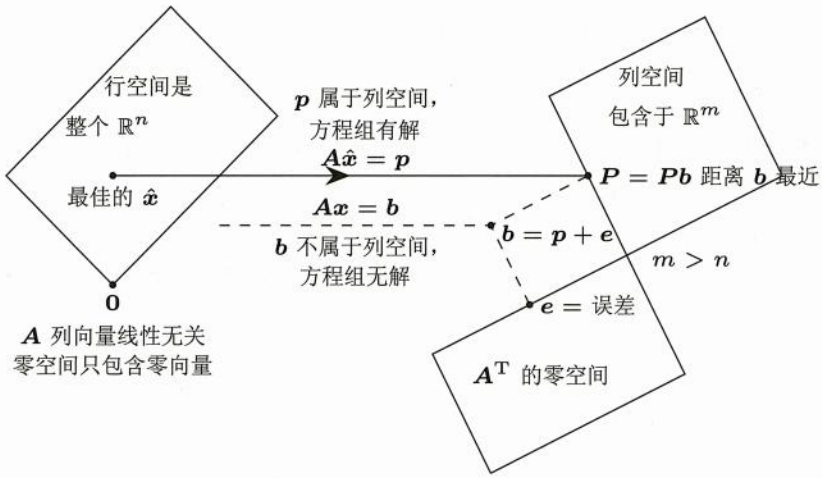


图 4.6　四个基本子空间和最小二乘法

注：$\boldsymbol{p} = \boldsymbol{A}\hat{\boldsymbol{x}}$ 是离 $\boldsymbol{b}$ 最近的向量，此时 $E = \|\boldsymbol{b} - \boldsymbol{A}\boldsymbol{x}\|^2$ 取最小值.

第 7 章将展示完整图景——不仅包含四个基本子空间，而且每个 $\boldsymbol{x}$ 都分解为 $\boldsymbol{x}_r + \boldsymbol{x}_n$，每个 $\boldsymbol{b}$ 都分解为 $\boldsymbol{p} + \boldsymbol{e}$. 最小二乘法中的最优解 $\hat{\boldsymbol{x}}$ 是行空间中的向量 $\hat{\boldsymbol{x}}_r$. 我们暂且不需要控制误差 $\boldsymbol{e}$，也不需要零空间中向量 $\boldsymbol{x}_n$，需要的只是 $\boldsymbol{A}\hat{\boldsymbol{x}} = \boldsymbol{p}$.

### 4.3.3　直线拟合

直线拟合是最小二乘法最直接的应用. 给定 $m > 2$ 个点，两点确定一条直线，点的个数多了，往往就不在一条直线上，但是我们假设它们大体上沿着一条直线分布. 假设在时刻 $t_1, t_2, \cdots, t_m$ 处，$m$ 个点的高度为 $b_1, b_2, \cdots, b_m$.[①]最优直线 $C + Dt$ 一般来说不会经过全部 $m$ 个点，设纵向距离是 $e_1, e_2, \cdots, e_m$，当直线是最小二乘直线时，$E = e_1^2 + e_2^2 + \cdots + e_m^2$ 取最小值.

第一个例子就是图 4.5中三个点的例子. 现在我们允许任意 $m$ 个点（显然 $m$ 可能非常大）. $\hat{\boldsymbol{x}}$ 的两个分量仍然是 $C$ 和 $D$.

当方程组 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$ 有解时，存在过这 $m$ 点的直线. 如前所述，这种情况一般来说不会发生. $C$ 和 $D$ 这两个未知数决定直线的方程，所以系数矩阵 $\boldsymbol{A}$ 只有 $n = 2$ 列. 要拟合 $m$ 个点，我们需要解 $m$ 个方程的方程组（但是只有两个未知数！）：

$$\text{方程组}\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}\text{即} \quad \begin{cases} C + Dt_1 = b_1 \\ C + Dt_2 = b_2 \\ \quad\vdots \\ C + Dt_m = b_m \end{cases} \qquad \text{从而系数矩阵}\boldsymbol{A} = \begin{bmatrix} 1 & t_1 \\ 1 & t_2 \\ \vdots & \vdots \\ 1 & t_m \end{bmatrix} \tag{4.19}$$

列空间太小了，以至于几乎所有的 $\boldsymbol{b}$ 都不属于 $\boldsymbol{A}$ 的列空间. 如果 $\boldsymbol{b}$ 偶然地属于该列空间，这

① 译者注：实际上意思是说 $m$ 个点的横坐标分别是 $t_1, t_2, \cdots, t_m$，纵坐标分别是 $b_1, b_2, \cdots, b_m$. 正文翻译一方面尊重英文原文，另一方面具有实际背景. 例如，做实验采集样本数据，在不同的时间采集数据，因此横坐标就是时间，纵坐标是数据. 更具体一点，比方说做生物实验培养细菌，在不同的时间统计细菌的数量，等等.

些点碰巧在一条直线上，此时 $\boldsymbol{b}=\boldsymbol{p}$，$\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 有解且误差 $\boldsymbol{e}=\begin{bmatrix}0 & \cdots & 0\end{bmatrix}^{\mathrm{T}}$.

**最佳直线 $C+Dt$ 在 $t_1,t_2,\cdots,t_m$ 处的纵坐标是 $p_1,p_2,\cdots,p_m$，纵向误差是 $e_1,e_2,\cdots,e_m$.**

**解方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$ 得 $\hat{\boldsymbol{x}}=\begin{bmatrix}C & D\end{bmatrix}^{\mathrm{T}}$；误差 $e_i=b_i-C-Dt_i$.**

直线拟合实在是太重要了，所以我们选择“一劳永逸”地直接给出方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$ 的两个方程. 除非所有 $t_i$ 都相等（如前所述，在实际应用中是不会发生的），否则 $\boldsymbol{A}$ 的列向量一定线性无关，于是 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 可逆. 总之，把问题归结为最小二乘和解方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$ 是很明智的选择. 用点积来计算矩阵乘法可得

$$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}=\begin{bmatrix}1 & \cdots & 1\\ t_1 & \cdots & t_m\end{bmatrix}\begin{bmatrix}1 & t_1\\ \vdots & \vdots\\ 1 & t_m\end{bmatrix}=\begin{bmatrix}m & \sum_{i=1}^{m}t_i\\ \sum_{i=1}^{m}t_i & \sum_{i=1}^{m}t_i^2\end{bmatrix} \tag{4.20}$$

方程右边是 $2\times 1$ 矩阵 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$：

$$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\begin{bmatrix}C\\ D\end{bmatrix}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}=\begin{bmatrix}1 & \cdots & 1\\ t_1 & \cdots & t_m\end{bmatrix}\begin{bmatrix}b_1\\ \vdots\\ b_m\end{bmatrix}=\begin{bmatrix}\sum b_i\\ \sum t_ib_i\end{bmatrix} \tag{4.21}$$

在实际问题中，这些数据都是已知的. 最优解 $\hat{\boldsymbol{x}}=\begin{bmatrix}C & D\end{bmatrix}^{\mathrm{T}}=(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1}\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$. 当 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$ 时，该直线 $C+Dt$ 最小化了 $e_1^2+e_2^2+\cdots+e_m^2=\|\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}\|^2$ 的取值：

$$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}\qquad\begin{bmatrix}m & \sum t_i\\ \sum t_i & \sum t_i^2\end{bmatrix}\begin{bmatrix}C\\ D\end{bmatrix}=\begin{bmatrix}\sum b_i\\ \sum t_ib_i\end{bmatrix}. \tag{4.22}$$

向量 $\boldsymbol{e}=\boldsymbol{b}-\boldsymbol{p}$ 的各个分量表示给定的 $m$ 个点相对这条直线的纵向误差. 从几何角度看，误差向量 $\boldsymbol{b}-\boldsymbol{A}\hat{\boldsymbol{x}}$ 也称为残差——正交于 $\boldsymbol{A}$ 的列向量；从线性代数角度看，误差向量属于 $\boldsymbol{A}^{\mathrm{T}}$ 的零空间；从微积分的角度看，全误差 $E$ 在 $\hat{\boldsymbol{x}}=\begin{bmatrix}C & D\end{bmatrix}^{\mathrm{T}}$ 处取最小值，即如下的平方和取最小值：

$$E(\boldsymbol{x})=\|\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}\|^2=(C+Dt_1-b_1)^2+(C+Dt_2-b_2)^2+\cdots+(C+Dt_m-b_m)^2.$$

也可以直接令偏导数 $\partial E/\partial C=\partial E/\partial D=0$，同样可得方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$.

最小二乘问题也可以处理多个未知数的问题. 比如说，抛物线拟合的问题有三个系数 $C$、$D$、$E$（见例 4.9）. 一般地，我们可以考虑用 $n$ 个参数来拟合 $m$ 个数据，那么 $n<m$ 且系数矩阵 $\boldsymbol{A}$ 有 $n$ 列. 对 $\|\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}\|^2$ 求偏导数（$n$ 个参数，就有 $n$ 个偏导数，因此有 $n$ 个方程）可得方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$. 平方项的导数是线性的，这也是最小二乘法使用如此广泛的原因之一.

**例 4.9** 如果时间 $t_i$ 的求和是零，那么 $\boldsymbol{A}$ 的两列正交.[①]设 $t=-2,0,2$ 时，$b=1,2,4$，显然时间加起来等于 0. $\boldsymbol{A}$ 的两列点积为 0：$\begin{bmatrix}1 & 1 & 1\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}-2 & 0 & 2\end{bmatrix}^{\mathrm{T}}$ 正交.

① 译者注：读者可能有疑问，时间都是正的，加起来不可能为零. 实际上，我们只需要将坐标系平移，或者说，规定某个时刻的时间为零，在此时刻之前的时间取负值，此时刻之后的时间取正值即可.

$$\begin{cases} C+ & D(-1)=1 \\ C+ & D(0)=2 \\ C+ & D(0)=4 \end{cases} \quad \text{也即} \quad \boldsymbol{A}\boldsymbol{x}=\begin{bmatrix}1&-2\\1&0\\1&2\end{bmatrix}\begin{bmatrix}C\\D\end{bmatrix}=\begin{bmatrix}1\\2\\4\end{bmatrix}$$

如果 $\boldsymbol{A}$ 的列向量互相正交，那么 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 是对角矩阵：

$$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b} \quad \text{为} \quad \begin{bmatrix}3&0\\0&8\end{bmatrix}\begin{bmatrix}C\\D\end{bmatrix}=\begin{bmatrix}7\\6\end{bmatrix} \tag{4.23}$$

此时的要点是，由于 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 是可逆的对角矩阵，它的逆矩阵很容易得出——将对角线元取倒数. 从而易知 $C=\dfrac{7}{3}$，$D=\dfrac{6}{8}$. $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 非对角线元素为零来源于 $\boldsymbol{A}$ 的正交的列向量的点积，对角线元素为 $m=3$，$t_1^2+t_2^2+t_3^2=8$，它和单位矩阵差不多简单.

列向量互相正交实在是太方便了！所以当时间的求和不等于零时，我们不妨都按均值 $\hat{t}=\dfrac{t_1+t_2+\cdots+t_m}{m}$ 平移. 若初始时间是 1、3、5，那么均值是 $\hat{t}=3$；平移之后时间变量记作 $T$，于是 $T_i=t_i-\hat{t}=t_i-3$ 求和为零.

$$\begin{aligned} T_1&=1-3=-2\\ T_2&=3-3=0\\ T_3&=5-3=2 \end{aligned} \qquad \boldsymbol{A}_{\text{新}}=\begin{bmatrix}1&T_1\\1&T_2\\1&T_3\end{bmatrix}, \qquad \boldsymbol{A}_{\text{新}}^{\mathrm{T}}\boldsymbol{A}_{\text{新}}=\begin{bmatrix}3&0\\0&8\end{bmatrix}$$

根据式(4.23)，$C$、$D$ 很容易就看出来了. 但是，最优直线是 $C+DT$，我们还需要代回去用 $t$ 来表示，即 $C+D(t-\hat{t})=C+D(t-3)$. 习题 30 将在一般情形下给出 $C$、$D$ 的表达式.

这个例题非常好地启发我们思考 4.3.4 节中的格拉姆-施密特正交化：尝试着将 $\boldsymbol{A}$ 的列向量转化成两两正交的向量. 此时新的矩阵 $\boldsymbol{A}_{\text{新}}$ 就有这个好性质——$\boldsymbol{A}_{\text{新}}^{\mathrm{T}}\boldsymbol{A}_{\text{新}}$ 是对角矩阵，于是 $\hat{\boldsymbol{x}}_{\text{新}}$ 就很容易求解了.

### 4.3.4 当 $A$ 列向量线性相关时求解 $\hat{x}$

本章从一开始就假设 $\boldsymbol{A}$ 列向量线性无关，那么 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 是可逆矩阵，从 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{x}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$ 可求得 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 的最小二乘解.

如果 $\boldsymbol{A}$ 的列向量线性相关，如何求 $\hat{\boldsymbol{x}}$ 呢？先举个例子看看.

这个例子说的是，在同一时刻 $T$ 有两个测量值 $b_1=3$ 和 $b_2=1$. 不可能有直线 $b=C+Dt$ 同时过这两个点. 当然，可以把 $\boldsymbol{b}=\begin{bmatrix}3&1\end{bmatrix}^{\mathrm{T}}$ 正交投影到 $\boldsymbol{A}$ 列空间中的向量 $\boldsymbol{p}=\begin{bmatrix}2&2\end{bmatrix}^{\mathrm{T}}$. 这样就把无解的方程组 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 转变为有无穷多解的方程组 $\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{p}$. （提醒一下和 $\boldsymbol{A}$ 列向量线性无关时的区别：$\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{p}$ 只有唯一解.）其原因在于 $\boldsymbol{A}$ 的列向量线性相关，$\begin{bmatrix}1&-1\end{bmatrix}^{\mathrm{T}}$ 属于它的零空间.

既然有无穷多解，那么要选哪个 $\hat{\boldsymbol{x}}$ 呢？图 4.7中的所有虚线直线都有相同的纵向距离 1 和 $-1$，所有误差向量 $\begin{bmatrix}1&-1\end{bmatrix}^{\mathrm{T}}=\boldsymbol{e}=\boldsymbol{b}-\boldsymbol{p}$ 都是最小的，所以我们无法从中知道哪条虚线是最佳的.

直觉告诉我应该选择水平方向高度为 2 的直线. 用方程 $b=C+Dt$ 来表示最优直线，那就是 $\hat{x}_1=C=2,\hat{x}_2=D=0$. 如果用 $b=ct+d$ 来表示直线方程又如何呢？问题显然没有任何变化，仅仅是交换了 $C$、$D$ 的地位，此时 $\hat{x}_1=c=0,\hat{x}_2=d=2$. 我想大概是没有其他结果了.

$$\begin{bmatrix}1 & 1\\ 1 & 1\end{bmatrix}\begin{bmatrix}x_1\\ x_2\end{bmatrix}=\begin{bmatrix}3\\ 1\end{bmatrix}=\boldsymbol{b} \qquad \begin{bmatrix}1 & 1\\ 1 & 1\end{bmatrix}\begin{bmatrix}\hat{x}_1\\ \hat{x}_2\end{bmatrix}=\begin{bmatrix}2\\ 2\end{bmatrix}=\boldsymbol{p}$$

$$\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b} \qquad \boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{p}$$

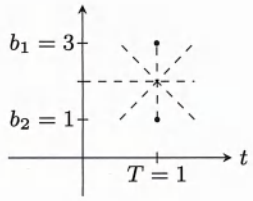


图 4.7 示例

在 4.5节中，$\boldsymbol{A}$ 的“广义逆”给出方程组 $\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{p}$ 的**最短解**. 就我们这个例子而言，最短解是 $\boldsymbol{x}^+=\begin{bmatrix}1 & 1\end{bmatrix}^{\mathrm{T}}$. 注意到特解的零空间分支可以任选，所以我们不妨取零向量，此时 $\boldsymbol{x}^+$ 实际上属于 $\boldsymbol{A}$ 的行空间，长度是 $\sqrt{2}$（而 $\hat{\boldsymbol{x}}=\begin{bmatrix}2 & 0\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}0 & 2\end{bmatrix}^{\mathrm{T}}$ 的长度都是 2.）

如果 $\boldsymbol{A}$ 列向量线性无关，它的广义逆实际上就是它的左逆 $(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1}\boldsymbol{A}^{\mathrm{T}}$. 通过这种表达方式，广义逆看上去就是求 $\hat{\boldsymbol{x}}$ 的最好的方法.

**注：**在有关奇异矩阵的 MATLAB 的实验中，返回结果不是 Inf（无穷大）就是 NaN（非数字）或者 $10^{16}$（很大的、不方便处理的数字）. 每种情况程序都会警告！我认为 Inf、NaN 和 $10^{16}$ 这三种情况分别来自三种方程：$\boldsymbol{0x=b}$、$\boldsymbol{0x=0}$ 和 $\boldsymbol{10^{-16}x=1}$；分别对应于：系数矩阵奇异且方程组无解、系数矩阵奇异且方程组有无穷多解、系数矩阵非奇异但是非常接近奇异导致不好处理.

### 4.3.5 抛物线拟合

在研究自由落体运动时，用直线来拟合小球的运动轨迹显然是不合理的. 比如说向上抛，小球的轨迹先减速上升再加速下降，而直线是单调的，所以直线拟合是不合理的. 虽然小球实际的运动轨迹受客观条件的影响，和时间的关系未必是完美的抛物线，但是根据物理学规律，用抛物线 $b=C+Dt+Et^2$（$b$ 是 $t$ 时刻的高度）来拟合是合理的.

回想当年，伽利略在比萨斜塔上往下扔石头，石头加速往下落. 下落高度中包含一个二次项 $\frac{1}{2}gt^2$（伽利略研究的目的首先是下落高度和石头的质量无关）. 如果没有 $t^2$ 项，我们无法把卫星送入太空轨道. 但是神奇的事情发生了：尽管此处出现了非线性项 $t^2$，$C$、$D$、$E$ 的表现仍然是线性的. 换句话说，用抛物线来拟合给定点的问题仍然是线性代数问题.

**问题** 用抛物线 $C+Dt+Et^2$ 来拟合在 $t_1,t_2,\cdots,t_m$ 时刻高度分别为 $b_1,b_2,\cdots,b_m$ 的点.

**解** 若给定点的个数 $m>3$ 时，则方程有 $m$ 个，而未知数只有 3 个，因此大概率方程组无解（或者说找不到能完美地拟合 $m$ 个点的抛物线）:

$$\begin{cases} C+Dt_1+Et_2^2=b_1\\ \quad\vdots\\ C+Dt_m+Et_m^2=b_m \end{cases} \qquad \begin{array}{l}\text{即方程组}\boldsymbol{Ax}=\boldsymbol{b}\\ \text{系数矩阵}\boldsymbol{A}\text{是 } m\times 3 \text{ 矩阵}\end{array} \qquad \boldsymbol{A}=\begin{bmatrix}1 & t_1 & t_1^2\\ \vdots & \vdots & \vdots\\ 1 & t_m & t_m^2\end{bmatrix} \tag{4.24}$$

**最小二乘法** 最优抛物线 $C+Dt+Et^2$ 的系数 $C$、$D$、$E$ 构成的向量 $\hat{\boldsymbol{x}}=\begin{bmatrix}C & D & E\end{bmatrix}^{\mathrm{T}}$ 是正规方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$ 的解.

你能把这个问题转化为正交投影吗？我们来一起思考. $\boldsymbol{A}$ 列空间的维数是_____. $\boldsymbol{b}$ 在 $C(\boldsymbol{A})$ 上的正交投影是 $\boldsymbol{p}=\boldsymbol{A}\hat{\boldsymbol{x}}$，它是 $\boldsymbol{A}$ 的列向量以 $C$、$D$、$E$ 为组合系数的线性组合. 在时刻 $t_1$ 处的误差是 $e_1=b_1-C-Dt_1-Et_1^2$. 如果用微积分的方法求最小值，那么我们需要对 $e_1^2+e_2^2+\cdots+e_m^2$ 作关于__、__、__ 的偏导数. 当 $\hat{\boldsymbol{x}}=\begin{bmatrix}C & D & E\end{bmatrix}^{\mathrm{T}}$ 满足方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$ 时，这三个偏导数均为零.

傅里叶级数是无穷维线性空间中的最小二乘法——它的目标是逼近函数，而非 $\mathbb{R}^n$ 中的列向量. 此时要最小化的目标函数不再是误差的平方和，而是误差的平方积分.

**例 4.10** 假设抛物线 $b=C+Dt+Et^2$ 在 $t=0,1,2$ 时刻的高度分别为 $b=6,0,0$，换句话说，该抛物线过点 $(0,6)$、$(1,0)$、$(2,0)$，那么可以列出关于 $C$、$D$、$E$ 的方程组

$$\begin{cases} C+D\cdot 0+E\cdot 0^2=6 \\ C+D\cdot 1+E\cdot 1^2=0 \\ C+D\cdot 2+E\cdot 2^2=0 \end{cases} \tag{4.25}$$

用矩阵乘法可以写成 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$，这个方程组有解. 因为三个点给出三个方程，系数矩阵是可逆方阵，它的解是 $\boldsymbol{x}=\begin{bmatrix}C & D & E\end{bmatrix}^{\mathrm{T}}=\begin{bmatrix}6 & -9 & 3\end{bmatrix}^{\mathrm{T}}$. 所以过这三个点的抛物线是 $\boldsymbol{b}=6-9t+3t^2$.

## 例 题 总 结

4.3 A. 假设在 9 个时间点 $t=1,2,\cdots,9$ 的测量值 $b_1,b_2,\cdots,b_9$ 全是 0，但是 $t=10$ 的测量值是 $b=40$，一般来说，这个异常值是要舍弃掉的. 我们暂且先不管这一点，请按照下述三种不同的误差的定义，求出和给定的 10 个点 $(1,0),(2,0),\cdots,(9,0),(10,40)$ **误差最小的水平直线** $y=C$.

（1）最小二乘误差 $E_2=e_1^2+e_2^2+\cdots+e_{10}^2$（从而关于 $C$ 的正规方程是线性方程）;

（2）最小极大绝对值误差：$E_\infty=\max\{|e_i|:1\leqslant i\leqslant 10\}$;

（3）最小总和绝对值误差：$E_1=|e_1|+|e_2|+\cdots+|e_{10}|$.

**解**

（1）用水平直线作最小二乘拟合的最优解是 $C=4$:

$\boldsymbol{A}=\begin{bmatrix}1 & \cdots & 1\end{bmatrix}^{\mathrm{T}}$，$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{a}=10$，$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}=b_1+b_2+\cdots+b_{10}=40$，所以正规方程为 $10C=40$.

（2）根据题意，极大绝对值误差为 $E_\infty=\max\{|C|,|40-C|\}$，$E_\infty$ 取最小值当且仅当 $C=20$，即 0 和 40 的平均值.

（3）根据题意，总和绝对值误差为 $E_1=9|C|+|40-C|$，$E_1$ 取最小值当且仅当 $C=0$.

最小总和绝对值误差来自测量值的中位数（$0,0,\cdots,0,40$ 的中位数是 0）. 很多统计学家认为，像 $b_{10}=40$ 这样的异常值对最小二乘误差的影响太大了，所以有时候他们更倾向于使用总和绝对值误差. 但是求解过程中要处理的方程变成了非线性方程. 各种方法各有利弊，我们要根据实际情况灵活应变.

我们改用直线 $b=C+Dt$ 来对这十个点作最小二乘拟合：

$$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}=\begin{bmatrix}10 & \sum t_i\\ \sum t_i & \sum t_i^2\end{bmatrix}=\begin{bmatrix}10 & 55\\ 55 & 385\end{bmatrix}\qquad \boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}=\begin{bmatrix}\sum b_i\\ \sum t_i b_i\end{bmatrix}=\begin{bmatrix}40\\ 400\end{bmatrix}$$

由方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$ 解得 $C=-8, D=\dfrac{24}{11}$.

如果把 $\boldsymbol{b}=\begin{bmatrix}0 & \cdots & 0 & 40\end{bmatrix}^{\mathrm{T}}$ 乘以 3 倍，然后每个分量都加 30，得到向量 $\boldsymbol{b}_{\text{新}}=\begin{bmatrix}30 & \cdots & 30 & 150\end{bmatrix}^{\mathrm{T}}$ 那么 $C$ 和 $D$ 是怎么变化的？对 $\boldsymbol{b}$ 的这两个调整都是线性的，对 $\boldsymbol{b}$ 乘以 3 的结果是 $C$、$D$ 也都乘以 3；把每个 $b_i$ 都加 30 的结果是 $C$ 也加上 30.

4.3 B. 假设在时刻 $t=-2,-1,0,1,2$ 的测量值分别是 $b=0,0,1,0,0$；在最小二乘的意义下用抛物线 $b=C+Dt+Et^2$ 拟合这五个点.

首先写出关于 $\boldsymbol{x}=\begin{bmatrix}C & D & E\end{bmatrix}^{\mathrm{T}}$ 的五个方程：$A\boldsymbol{x}=\boldsymbol{b}$，其含义是抛物线要过这五个点. 但是往往这样的抛物线不存在，所以该方程组无解. 那么我们解正规方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$.

我预测 $D=0$，这意味着最佳抛物线关于直线 $t=0$ 是对称的，为什么呢？在方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$ 中，第 2 个方程和第 1、3 两个方程是分开的.

**解** 方程组 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 的系数矩阵 $\boldsymbol{A}$ 是长方形的范德蒙矩阵：

$$\begin{aligned}&C+D(-2)+E(-2)^2=0\\ &C+D(-1)+E(-1)^2=0\\ &C+D\ \ (0)+E\ \ (0)^2=1\\ &C+D\ \ (1)+E\ \ (1)^2=0\\ &C+D\ \ (2)+E\ \ (2)^2=0\end{aligned}\qquad \boldsymbol{A}=\begin{bmatrix}1 & -2 & 4\\ 1 & -1 & 1\\ 1 & 0 & 0\\ 1 & 1 & 1\\ 1 & 2 & 4\end{bmatrix}\qquad \boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}=\begin{bmatrix}5 & \mathbf{0} & 10\\ \mathbf{0} & 10 & \mathbf{0}\\ 10 & \mathbf{0} & 34\end{bmatrix}$$

$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 的零元素来源于 $\boldsymbol{A}$ 的第 2 列和第 1 列、第 3 列都正交，这一点可以直接从 $\boldsymbol{A}$ 看出来（因为时间 $-2,-1,0,1,2$ 是对称的）. 最优抛物线 $C+Dt+Et^2$ 中的系数 $C$、$D$、$E$ 可由方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$ 求得，$D$ 和 $C$、$E$ 无关.

$$\begin{bmatrix}5 & 0 & 10\\ 0 & 10 & 0\\ 10 & 0 & 34\end{bmatrix}\begin{bmatrix}C\\ D\\ E\end{bmatrix}=\begin{bmatrix}1\\ 0\\ 0\end{bmatrix}\quad\Rightarrow\quad\begin{cases}C=\dfrac{34}{70}\\ D=0\\ E=-\dfrac{10}{70}\end{cases}$$

## 习题 4.3

**习题 1～11 用四个数据 $\boldsymbol{b}=\begin{bmatrix}0 & 8 & 8 & 20\end{bmatrix}^{\mathrm{T}}$ 来复习关于最小二乘法的关键思想.[①]**

1. 当 $t=0,1,3,4$ 时，$b=0,8,8,20$，列出并求解正规方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$. 求出图 4.8(a) 中最优直线在四个时刻处的纵坐标 $p_i(1\leqslant i\leqslant 4)$ 和误差 $e_i(1\leqslant i\leqslant 4)$. $E=e_1^2+e_2^2+e_3^2+e_4^2$ 的最小值是多少？

① 习题 1～11 中提到的给定的四个点是指 $(0,0)$、$(1,8)$、$(2,8)$、$(3,20)$.

2.（在给定的时刻，$C+Dt$ 纵坐标是 $p$）当 $t=0,1,3,4$ 时，$b=0,8,8,20$，列出方程组 $\boldsymbol{Ax}=\boldsymbol{b}$，该方程组无解. 把测量值改为 $p=1,5,13,17$，求解方程组 $\boldsymbol{A\hat{x}}=\boldsymbol{p}$.

3. 验算：$\boldsymbol{e}=\boldsymbol{b}-\boldsymbol{p}=\begin{bmatrix}-1 & 3 & -5 & 3\end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{A}$ 的列向量都正交. $\boldsymbol{b}$ 到 $\boldsymbol{A}$ 列空间的最短距离 $\|\boldsymbol{e}\|$ 是多少？

4.（用微积分的方法）把 $E=\|\boldsymbol{Ax}-\boldsymbol{b}\|^2$ 写成四个平方之和——最后一项是 $(C+4D-20)^2$. 求偏导可得方程组 $\partial E/\partial C=0$，$\partial E/\partial D=0$. 消掉公因子 2 后，可得正规方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A\hat{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$.

5. 对给定的四个点，求水平方向的最佳拟合直线 $y=C$. “恰好能拟合”意即该直线过全部四个点，也就是要解方程组 $C=0, C=8, C=8, C=20$. 该方程组无解；$4\times 1$ 系数矩阵 $\boldsymbol{A}$ 是什么？解正规方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A\hat{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$，在图 4.8(a) 中画出纵坐标为 $\hat{\boldsymbol{x}}=C$ 的水平直线和四个误差，并在图 4.8(b) 中画出误差向量 $\boldsymbol{e}$.

6. 把 $\boldsymbol{b}=\begin{bmatrix}0 & 8 & 8 & 20\end{bmatrix}^{\mathrm{T}}$ 正交投影 $\boldsymbol{a}=\begin{bmatrix}1 & 1 & 1 & 1\end{bmatrix}^{\mathrm{T}}$. 请计算 $\hat{x}=\boldsymbol{a}^{\mathrm{T}}\boldsymbol{b}/\boldsymbol{a}^{\mathrm{T}}\boldsymbol{a}$ 以及投影 $\boldsymbol{p}=\hat{x}\boldsymbol{a}$，验证 $\boldsymbol{e}=\boldsymbol{b}-\boldsymbol{p}$ 和 $\boldsymbol{a}$ 正交，再求出 $\boldsymbol{b}$ 到过 $\boldsymbol{a}$ 的直线的最短距离 $\|\boldsymbol{e}\|$.

7. 对给定的四个点，求过原点的最佳拟合直线 $b=Dt$. “恰好能拟合”的意思是该直线过全部四个点，也就是要解方程组 $D\cdot 0=0, D\cdot 1=8, D\cdot 3=8, D\cdot 4=20$. 该方程组无解；求 $4\times 1$ 系数矩阵 $\boldsymbol{A}$，并且解正规方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A\hat{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$，在图 4.8(a) 中画出这个最佳拟合直线 $b=Dt$ 和四个误差，并在图 4.8(b) 中画出误差向量 $\boldsymbol{e}$.

8. 把 $\boldsymbol{b}=\begin{bmatrix}0 & 8 & 8 & 20\end{bmatrix}^{\mathrm{T}}$ 投影到过 $\boldsymbol{a}=\begin{bmatrix}0 & 1 & 3 & 4\end{bmatrix}^{\mathrm{T}}$ 的直线. 求 $\hat{x}=D$ 使得 $\boldsymbol{p}=\hat{x}\boldsymbol{a}$ 是 $\boldsymbol{b}$ 的正交投影. 习题 $5\sim 6$ 中最佳的 $C$ 和习题 $7\sim 8$ 中最佳的 $D$ 和习题 $1\sim 4$ 中最佳的 $(C,D)$ 并不一致. 这是因为 $\begin{bmatrix}1 & 1 & 1 & 1\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}0 & 1 & 3 & 4\end{bmatrix}^{\mathrm{T}}$ _____ 正交.

9. 用抛物线 $b=C+Dt+Et^2$ 拟合给定的四个点，写出关于未知数 $\boldsymbol{x}=\begin{bmatrix}C & D & E\end{bmatrix}^{\mathrm{T}}$ 的四个方程 $\boldsymbol{Ax}=\boldsymbol{b}$. 列出正规方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A\hat{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$（暂不要求求解）. 若在图 4.8(a) 用抛物线拟合四个点，那么请在图 4.8(b) 中画出对应的示意图.

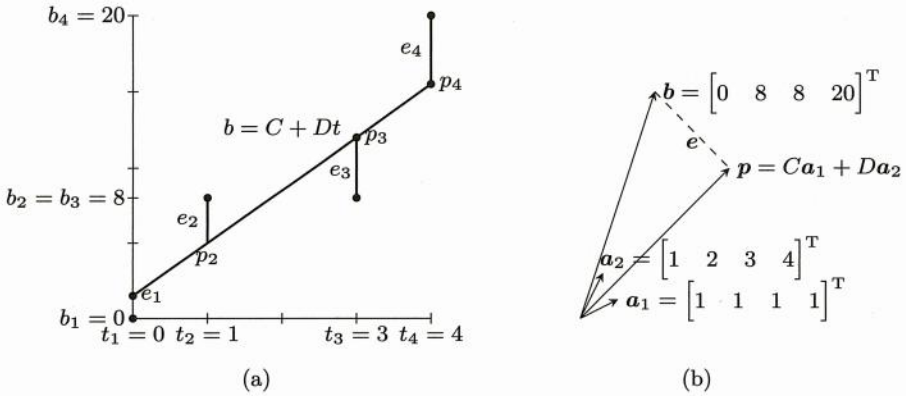


图 4.8　习题 $1\sim 11$的示意图

注：对应于 $\mathbb{R}^4$ 中的向量 $C\boldsymbol{a}_1+D\boldsymbol{a}_2$ 的最优直线 $C+Dt$.

10. 用三次曲线 $b = C + Dt + Et^2 + Ft^3$ 拟合给定的四个点，写出四个方程构成的方程组 $\boldsymbol{Ax} = \boldsymbol{b}$，并利用消元法求解. 此时图 4.8(a) 中，这条三次曲线恰好过这四个点，那么 $\boldsymbol{p}$ 和 $\boldsymbol{e}$ 分别是什么？

11. 四个测量时刻的均值是 $\hat{t} = \frac{1}{4}(0+1+3+4) = 2$，四个测量值的均值是 $\hat{b} = \frac{1}{4}(0+8+8+20) = 9$.

（1）验证：最佳拟合直线过中心点 $(\hat{t}, \hat{b}) = (2, 9)$.

（2）解释如何从 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}} = \boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$ 的第一个方程得到 $C + D\hat{t} = \hat{b}$.

**习题 12 ~ 16 介绍统计学的基本想法——这也是最小二乘法的基础.**

12.（推荐）本题把 $\boldsymbol{b} = \begin{bmatrix} b_1 & \cdots & b_m \end{bmatrix}^{\mathrm{T}}$ 正交投影到 $\boldsymbol{a} = \begin{bmatrix} 1 & \cdots & 1 \end{bmatrix}^{\mathrm{T}}$. 我们解 1 个未知数、$m$ 个方程的方程组 $\boldsymbol{a}x = \boldsymbol{b}$.

（1）通过解方程组 $\boldsymbol{a}^{\mathrm{T}}\boldsymbol{a}\hat{x} = \boldsymbol{a}^{\mathrm{T}}\boldsymbol{b}$ 来证明 $\hat{x}$ 是 $\boldsymbol{b}$ 分量的平均值.

（2）求 $\boldsymbol{e} = \boldsymbol{b} - \boldsymbol{a}\hat{x}$，以及方差 $\|\boldsymbol{e}\|^2$ 和标准差 $\|\boldsymbol{e}\|$.

（3）水平直线 $\hat{\boldsymbol{b}} = 3$ 是距离 $\boldsymbol{b} = \begin{bmatrix} 1 & 2 & 6 \end{bmatrix}^{\mathrm{T}}$ 最近的直线. 验证 $\boldsymbol{p} = \begin{bmatrix} 3 & 3 & 3 \end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{e}$ 正交，请求出 $3 \times 3$ 正交投影矩阵 $\boldsymbol{P}$.

13. 最小二乘法隐含的第一个假设：$\boldsymbol{Ax} = \boldsymbol{b}$ -（均值为零的噪声$\boldsymbol{e}$）. 将误差 $\boldsymbol{e} = \boldsymbol{b} - \boldsymbol{Ax}$ 左边乘上 $(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1}\boldsymbol{A}^{\mathrm{T}}$，那么等式右边等于 $\hat{\boldsymbol{x}} - \boldsymbol{x}$. 从而误差估计 $\hat{\boldsymbol{x}} - \boldsymbol{x}$ 的均值也是零，估计值 $\hat{\boldsymbol{x}}$ 是无偏的.

14. 最小二乘法隐含的第二个假设：$m$ 个误差 $e_i$ 互相独立，方差为 $\sigma^2$，所以 $(\boldsymbol{b}-\boldsymbol{Ax})(\boldsymbol{b}-\boldsymbol{Ax})^{\mathrm{T}}$ 的均值是 $\sigma^2\boldsymbol{I}$；将 $(\boldsymbol{b}-\boldsymbol{Ax})(\boldsymbol{b}-\boldsymbol{Ax})^{\mathrm{T}}$ 左乘和右乘 $\boldsymbol{A}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1}$，证明：$(\hat{\boldsymbol{x}}-\boldsymbol{x})(\hat{\boldsymbol{x}}-\boldsymbol{x})^{\mathrm{T}}$ 的均值是 $\sigma^2(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1}$. 这恰好是 10.2 节中的**协方差矩阵 $\boldsymbol{W}$.**

15. 假设医生对某个病人测了四次心率，分别是 $b_1$、$b_2$、$b_3$、$b_4$，那么方程组 $x = b_1, x = b_2, x = b_3, x = b_4$ 的最优解是 $b_1, b_2, b_3, b_4$ 的均值 $\hat{x}$，矩阵 $\boldsymbol{A}$ 是分量全为 1 的列向量. 习题 14 预计误差 $(\hat{x} - x)^2$ 为 $\sigma^2(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1} =$ _____. 通过取均值，方差从 $\sigma^2$ 降低至 $\sigma^2/4$.

16. 如果我们已知 9 个数 $b_1, b_2, \cdots, b_9$ 的均值 $\hat{x}_9$，那么再给第 10 个数 $b_{10}$ 的时候，你有什么方法可以快速知道 10 个数的均值吗？二乘递归算法可以避免计算 10 个数的和. 用哪个数字乘以 $\hat{x}_9$ 可得 $\hat{x}_{10}$？

$$\text{参考例题 4.2C：}\ \hat{x}_{10} = \frac{1}{10}b_{10} + \underline{\qquad}\hat{x}_9 = \frac{1}{10}(b_1 + \cdots + b_{10}).$$

**习题 17 ~ 24 给出更多关于 $\hat{\boldsymbol{x}}$、$\boldsymbol{p}$ 和 $\boldsymbol{e}$ 的习题.**

17. 写下直线 $b = C + Dt$ 过点 $(-1, 7)$、$(1, 7)$、$(2, 21)$ 所满足的三个方程，求最小二乘解 $\hat{\boldsymbol{x}} = \begin{bmatrix} C & D \end{bmatrix}^{\mathrm{T}}$，并在图中画出最优直线.

18. 求出习题 17 中的正交投影 $\boldsymbol{p} = \boldsymbol{A}\hat{\boldsymbol{x}}$，这给出了最佳直线在 $t = -1, 1, 2$ 处的纵坐标. 证明：误差向量 $\boldsymbol{e} = \begin{bmatrix} 2 & -6 & 4 \end{bmatrix}^{\mathrm{T}}$. 说明为什么 $\boldsymbol{Pe} = \boldsymbol{0}$.

19. 假设将习题 18 中 $t = -1, 1, 2$ 时的测量值改为误差 $2, -6, 4$，对于新的测量值，求最小二乘意义下的最优直线和 $\hat{\boldsymbol{x}}$. 结合几何直观，对结果作一些说明：$\boldsymbol{b} = \begin{bmatrix} 2 & -6 & 4 \end{bmatrix}^{\mathrm{T}}$ 和_____ 正交，所以正交投影 $\boldsymbol{p} = \boldsymbol{0}$.

20. 假设 $t=-1,1,2$ 时的测量值分别是 $\boldsymbol{b}=\begin{bmatrix}5 & 13 & 17\end{bmatrix}^{\mathrm{T}}$ 的三个分量，求最小二乘意义下的最优直线，计算 $\hat{\boldsymbol{x}}$ 和 $\boldsymbol{e}$. 此时误差 $\boldsymbol{e}=\boldsymbol{0}$，因为 $\boldsymbol{b}$ 是_____.

21. 系数矩阵的四个基本子空间中，哪一个子空间包含误差向量 $\boldsymbol{e}$？哪一个子空间包含 $\boldsymbol{p}$？哪一个子空间包含 $\hat{\boldsymbol{x}}$？$\boldsymbol{A}$ 的零空间是什么？

22. 在时刻 $t=-2,-1,0,1,2$ 时测量值是 $b=4,2,-1,0,0$，求最小二乘意义下的最优拟合直线 $b=C+Dt$.

23. 误差向量 $\boldsymbol{e}$ 和 $\boldsymbol{b}$、$\boldsymbol{p}$、$\hat{\boldsymbol{x}}$ 正交吗？证明：$\|\boldsymbol{e}\|^2=\boldsymbol{e}^{\mathrm{T}}\boldsymbol{b}$. 后者等于 $\boldsymbol{b}^{\mathrm{T}}\boldsymbol{b}-\boldsymbol{p}^{\mathrm{T}}\boldsymbol{b}$；$\|\boldsymbol{e}\|^2$ 是全误差 $E$ 的最小值.

24. 函数 $\|\boldsymbol{A}\boldsymbol{x}\|^2$ 关于 $x_1,x_2,\cdots,x_n$ 的偏导数组成向量 $2\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{x}$，$2\boldsymbol{b}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{x}$ 的偏导数组成向量 $2\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$. 所以满足条件_____ 时，$\|\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}\|^2$ 的偏导数全为零.

## 挑 战 一 下

25. 对 $(t_1,b_1)$、$(t_2,b_2)$、$(t_3,b_3)$ 提什么条件可以使得它们共线？利用列空间可以给一个回答：列向量 $\begin{bmatrix}b_1 & b_2 & b_3\end{bmatrix}^{\mathrm{T}}$ 是 $\begin{bmatrix}1 & 1 & 1\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}t_1 & t_2 & t_3\end{bmatrix}^{\mathrm{T}}$ 的线性组合. 请尝试给出一个关于 $t_1$、$t_2$、$t_3$、$b_1$、$b_2$、$b_3$ 的方程. 写不出也不必着急，因为我很快就要告诉你们如何思考这个题.

26. 找在正方形的四个顶点 $(1,0)$、$(0,1)$、$(-1,0)$、$(0,-1)$ 处分别取值 0、1、3、4 的最优拟合平面.[①]设平面方程是 $C+Dx+Ey=b$，根据已知的四个点可以列出关于 $C$、$D$、$E$ 的方程组 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$，其中 $\boldsymbol{x}=\begin{bmatrix}C & D & E\end{bmatrix}^{\mathrm{T}}$. 系数矩阵 $\boldsymbol{A}$ 是什么？在正方形的中心点 $(0,0)$ 处，证明 $C+Dx+Ey=b_1$、$b_2$、$b_3$、$b_4$ 的均值.

27.（直线之间的距离）$\left\{P=\begin{bmatrix}x & x & x\end{bmatrix}^{\mathrm{T}}:x\in\mathbb{R}\right\}$ 和 $\left\{Q=\begin{bmatrix}y & 3y & -1\end{bmatrix}^{\mathrm{T}}:y\in\mathbb{R}\right\}$ 是 $\mathbb{R}^3$ 中的两条不相交的直线，求 $\|P-Q\|^2$ 的最小值以及此时 $x$、$y$ 的取值；当 $\|P-Q\|^2$ 取最小值时 $P$、$Q$ 的连线和_____ 正交.

28. 假设 $\boldsymbol{A}$ 的列向量线性相关，正交投影到 $\boldsymbol{A}$ 列空间的投影矩阵是 $\boldsymbol{P}$. 因为 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 不可逆，所以公式 $\boldsymbol{P}=\boldsymbol{A}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1}\boldsymbol{A}^{\mathrm{T}}$ 失效. 能否找一个矩阵 $\boldsymbol{B}$ 使得 $\boldsymbol{P}=\boldsymbol{B}(\boldsymbol{B}^{\mathrm{T}}\boldsymbol{B})^{-1}\boldsymbol{B}^{\mathrm{T}}$.

29. 通常，给定 $\mathbb{R}^n$ 中的 $n$ 个点 $\boldsymbol{x}=\boldsymbol{0},\boldsymbol{a}_1,\cdots,\boldsymbol{a}_{n-1}$，恰好存在唯一超平面过这 $n$ 个给定点. 例如，$n=3$ 时，在 $\mathbb{R}^3$ 中，除非_____，则存在唯一一个平面包含 $\boldsymbol{0}$、$\boldsymbol{a}_1$、$\boldsymbol{a}_2$. 如何判断 $\mathbb{R}^n$ 中是否存在唯一一个超平面过给定的 $n$ 个点？

30. 例 4.9中，我们平移时间，使得它们相加之和为零；事实上，只需要把每一个时间都减去它们的平均值 $\hat{t}=(t_1+\cdots+t_m)/m$ 即可：$T_i=t_i-\hat{t}$；这些 $T_i$ 相加为零. 于是列向量 $\begin{bmatrix}1 & \cdots & 1\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}T_1 & \cdots & T_m\end{bmatrix}^{\mathrm{T}}$ 正交，$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 是对角矩阵，对角线元素是 $m$ 和 $T_1^2+T_2^2+\cdots+T_m^2$. 证明：最优的 $C$、$D$ 由下述公式直接给出：

$$\boldsymbol{T}=\boldsymbol{t}-\hat{\boldsymbol{t}}\qquad C=\frac{b_1+\cdots+b_m}{m}\qquad D=\frac{b_1T_1+\cdots+b_mT_m}{T_1^2+\cdots+T_m^2}.$$

① 译者注：这是在三维空间中用平面拟合，其含义是找一个平面，它和给定的点在 $z$ 轴方向的距离的平方和最小.

最优直线为 $b=C+DT$ 或者 $b=C+D(t-\hat{t})$. 平移时间使得 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 变成对角矩阵的方法是格拉姆-施密特正交化的例子：先把 $\boldsymbol{A}$ 的列向量转化为两两正交的向量. 这是 4.4节的主题.

## 要点回顾

1. $\|\boldsymbol{Ax}-\boldsymbol{b}\|^2=\boldsymbol{x}^{\mathrm{T}}\boldsymbol{A}^{\mathrm{T}}\boldsymbol{Ax}-2\boldsymbol{x}^{\mathrm{T}}\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}+\boldsymbol{b}^{\mathrm{T}}\boldsymbol{b}$ 在最小二乘解 $\hat{\boldsymbol{x}}$ 处取最小值；$\|\boldsymbol{Ax}-\boldsymbol{b}\|^2$ 也是 $m$ 个误差项 $e_1,e_2,\cdots,e_m^2$ 的平方和 $E$.

2. 最优解 $\hat{\boldsymbol{x}}$ 可以通过正规方程 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$ 求解，此时 $E$ 取最小值.

3. 用直线 $b=C+Dt$ 在最小二乘的意义下拟合 $m$ 个点，可以通过正规方程求解 $C$、$D$.

4. 最优直线在 $m$ 个点处的纵坐标为 $\boldsymbol{p}=\begin{bmatrix}p_1 & \cdots & p_m\end{bmatrix}$，和采样点的竖直距离是误差 $\boldsymbol{e}=\begin{bmatrix}e_1 & \cdots & e_m\end{bmatrix}^{\mathrm{T}}$. 关键方程组是 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{e}=\boldsymbol{0}$.

5. 设 $n<m$，如果要用 $n$ 个函数的组合拟合 $m$ 个点，那么 $m$ 个方程构成的方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 通常无解. 方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{Ax}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$（$n$ 个方程）给出了最小二乘解，即使得均方误差（Mean Square Error，MSE）最小的函数组合.

## 4.4 正交矩阵和格拉姆-施密特正交化

（1）若向量 $\boldsymbol{q}_1,\boldsymbol{q}_2,\cdots,\boldsymbol{q}_n$ 满足

$$\boldsymbol{q}_i^{\mathrm{T}}\boldsymbol{q}_j=\begin{cases}0 & i\neq j\\ 1 & i=j\end{cases}$$

我们称 $\boldsymbol{q}_1,\boldsymbol{q}_2,\cdots,\boldsymbol{q}_n$ 单位正交；此时矩阵 $\boldsymbol{Q}=\begin{bmatrix}\boldsymbol{q}_1 & \cdots & \boldsymbol{q}_n\end{bmatrix}$ 满足 $\boxed{\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{Q}=\boldsymbol{I}}$.

（2）进一步地，若 $\boldsymbol{Q}$ 还是方阵，则 $\boldsymbol{QQ}^{\mathrm{T}}=\boldsymbol{I}$ 且 $\boxed{\boldsymbol{Q}^{\mathrm{T}}=\boldsymbol{Q}^{-1}}$. 这样的矩阵称作“正交矩阵”.

（3）方程组 $\boldsymbol{Qx}=\boldsymbol{b}$ 的最小二乘解是 $\hat{\boldsymbol{x}}=\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{b}$. $\boldsymbol{b}$ 到 $\boldsymbol{Q}$ 列空间的正交投影是 $\boldsymbol{p}=\boldsymbol{QQ}^{\mathrm{T}}\boldsymbol{b}=\boldsymbol{Pb}$.

（4）格拉姆-施密特正交化算法把线性无关的向量组 $\boldsymbol{a}_1,\boldsymbol{a}_2,\cdots,\boldsymbol{a}_n$ 转化为标准正交的向量组 $\boldsymbol{q}_1,\boldsymbol{q}_2,\cdots,\boldsymbol{q}_n$. 第一步是令 $\boldsymbol{q}_1=\boldsymbol{a}_1/\|\boldsymbol{a}_1\|$.

（5）$\boldsymbol{a}_i$ 到 $\boldsymbol{a}_1,\boldsymbol{a}_2,\cdots,\boldsymbol{a}_{i-1}$ 张成的子空间的正交投影是 $\boldsymbol{p}_i=(\boldsymbol{a}_i^{\mathrm{T}}\boldsymbol{q}_1)\boldsymbol{q}_1+(\boldsymbol{a}_i^{\mathrm{T}}\boldsymbol{q}_2)\boldsymbol{q}_2+\cdots+(\boldsymbol{a}_i^{\mathrm{T}}\boldsymbol{q}_{i-1})\boldsymbol{q}_{i-1}$. $\boldsymbol{q}_i$ 等于 $\boldsymbol{a}_i-\boldsymbol{p}_i$ 的单位化，即：$\boldsymbol{q}_i=\dfrac{\boldsymbol{a}_i-\boldsymbol{p}_i}{\|\boldsymbol{a}_i-\boldsymbol{p}_i\|}$.

（6）每一个 $\boldsymbol{a}_i$ 是 $\boldsymbol{a}_1,\boldsymbol{a}_2,\cdots,\boldsymbol{q}_i$ 的线性组合，从而 $\boldsymbol{A}=\boldsymbol{QR}$：列向量单位正交的矩阵 $\boldsymbol{Q}$ 乘以上三角矩阵 $\boldsymbol{R}$.

本节有两个主要目标：为什么和怎么做. 为了达成前一个目标，我们需要理解矩阵 $\boldsymbol{A}$ 的列向量正交的好处：正交的向量点积为零，所以 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 是对角矩阵. 那么正规方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$ 和 $\boldsymbol{b}$ 的正交投影 $\boldsymbol{p}=\boldsymbol{A}\hat{\boldsymbol{x}}$ 就很容易解了. 后一个目标是构造这些正交的向量 $\boldsymbol{q}_1,\boldsymbol{q}_2,\cdots,\boldsymbol{q}_n$. 我们可以看到格拉姆-施密特正交化方法如何从初始的向量 $\boldsymbol{a}_1,\boldsymbol{a}_2,\cdots,\boldsymbol{a}_n$ 线性组合出 $\boldsymbol{q}_1,\boldsymbol{q}_2,\cdots,\boldsymbol{q}_n$. $\boldsymbol{A}$ 的列向量 $\boldsymbol{a}_1,\boldsymbol{a}_2,\cdots,\boldsymbol{a}_n$ 未必正交，而新的矩阵 $\boldsymbol{Q}$ 的列向量 $\boldsymbol{q}_1,\boldsymbol{q}_2,\cdots,\boldsymbol{q}_n$ 单位正交.

基是张成线性空间的线性无关的向量组. 基中向量的夹角，除了 0° 和 180°，可以是任意角度. 但是我们遇到的坐标系，坐标轴几乎都是互相正交的，以至于在我们的印象中，坐标轴天然就该是正交的. 正交的坐标轴让几何图像和具体计算都变得更简单.

若向量 $\boldsymbol{q}_1, \boldsymbol{q}_2, \cdots, \boldsymbol{q}_n$ 两两之间点积为零，我们称它们是正交向量组. 更明确地说，当 $i \neq j$ 时，$\boldsymbol{q}_i^{\mathrm{T}} \boldsymbol{q}_j = 0$. 把正交向量组的每个向量都除以自身的长度，就得到了单位正交向量组. 每个向量的长度都是 1，于是这组基被称为标准正交基.

**定义 4.1**　若 $n$ 个向量 $\boldsymbol{q}_1, \boldsymbol{q}_2, \cdots, \boldsymbol{q}_n$ 满足

$$\boldsymbol{q}_i^{\mathrm{T}} \boldsymbol{q}_j = \begin{cases} 0 & i \neq j \quad \text{正交向量} \\ 1 & i = j \quad \text{单位向量：} \ \|q_i\| = 1 \end{cases}$$

则称它们为标准正交向量组.

若 $\boldsymbol{Q}$ 的列向量是标准正交向量组，则 $\boldsymbol{Q}^{\mathrm{T}} \boldsymbol{Q} = \boldsymbol{I}$；该等式无非用矩阵乘法的语言把 $\boldsymbol{q}_1, \boldsymbol{q}_2, \cdots, \boldsymbol{q}_n$ 单位正交重新包装了一遍. 也是因为等式 $\boldsymbol{Q}^{\mathrm{T}} \boldsymbol{Q} = \boldsymbol{I}$，$\boldsymbol{Q}$ 相比于一般矩阵更容易处理. 需要说明的是，$\boldsymbol{Q}$ 的列向量标准正交，则天然地必须满足 $m \geqslant n$. 若 $m > n$，则 $\boldsymbol{Q}$ 不是方阵，于是 $\boldsymbol{Q}\boldsymbol{Q}^{\mathrm{T}} \neq \boldsymbol{I}$.

$\boldsymbol{Q}$ 的列向量是标准正交向量组时，$\boldsymbol{Q}^{\mathrm{T}} \boldsymbol{Q} = \boldsymbol{I}$ 可以如下说明：

$$\boldsymbol{Q}^{\mathrm{T}} \boldsymbol{Q} = \begin{bmatrix} \boldsymbol{q}_1^{\mathrm{T}} \\ \boldsymbol{q}_2^{\mathrm{T}} \\ \vdots \\ \boldsymbol{q}_n^{\mathrm{T}} \end{bmatrix} \begin{bmatrix} \boldsymbol{q}_1 & \boldsymbol{q}_2 & \cdots & \boldsymbol{q}_n \end{bmatrix} = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix} = \boldsymbol{I} \tag{4.26}$$

$\boldsymbol{Q}^{\mathrm{T}}$ 的第 $i$ 行和 $\boldsymbol{Q}$ 第 $j$ 列的乘积恰好是点积 $\boldsymbol{q}_i^{\mathrm{T}} \boldsymbol{q}_j$. 由正交性，非对角线（等价地说，$i \neq j$）上的点积是 0；对角线（等价地说，$i = j$）元素为 $\boldsymbol{q}_i^{\mathrm{T}} \boldsymbol{q}_i = \|\boldsymbol{q}_i\|^2 = 1$. 一般来说，$\boldsymbol{Q}$ 不是方阵（$m > n$），偶尔会有 $m = n$.

**若 $\boldsymbol{Q}$ 是方阵，则 $\boldsymbol{Q}^{\mathrm{T}} \boldsymbol{Q} = \boldsymbol{I}$ 意味着 $\boldsymbol{Q}^{\mathrm{T}} = \boldsymbol{Q}^{-1}$：$\boldsymbol{Q}$ 的转置 $= \boldsymbol{Q}$ 的逆矩阵.**

如果 $\boldsymbol{Q}$ 列向量只是互相正交（未必是单位向量），我们称 $\boldsymbol{Q}$ 是列正交矩阵；依然根据点积可知，$\boldsymbol{Q}^{\mathrm{T}} \boldsymbol{Q}$ 是对角矩阵（未必是单位矩阵）. 对角矩阵也很易于计算，难度和单位矩阵 $\boldsymbol{I}$ 相差无几. 由此可见，最重要的性质是正交性，在此基础上进一步生成单位向量是非常容易的.

注意，纵然 $\boldsymbol{Q}$ 不是方阵，依然有 $\boldsymbol{Q}^{\mathrm{T}} \boldsymbol{Q} = \boldsymbol{I}$，$\boldsymbol{Q}^{\mathrm{T}}$ 只是 $\boldsymbol{Q}$ 的左逆. 如果 $\boldsymbol{Q}$ 是方阵，$\boldsymbol{Q}\boldsymbol{Q}^{\mathrm{T}} = \boldsymbol{I}$ 也成立，那么 $\boldsymbol{Q}^{\mathrm{T}}$ 是 $\boldsymbol{Q}$ 的双边逆. 此时我们可以发现，$\boldsymbol{Q}$ 的行向量和它的列向量一样，也是单位正交的向量. $\boldsymbol{Q}$ 的逆矩阵是它的转置 $\boldsymbol{Q}^{\mathrm{T}}$. 若 $\boldsymbol{Q}$ 是方阵，我们称 $\boldsymbol{Q}$ 是正交矩阵.[①]

接下来，我们给出三类具体的正交矩阵——旋转、置换和反射. 这些都是非常重要的矩阵！说明它们是正交矩阵最快的方法还是验证 $\boldsymbol{Q}^{\mathrm{T}} \boldsymbol{Q} = \boldsymbol{I}$.

**例 4.11 (旋转)**　$\boldsymbol{Q} = \begin{bmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{bmatrix}$ 把平面上任意向量都逆时针旋转了 $\theta$ 角：

① 作者注：事实上，“标准正交矩阵”可能是更好的称呼，但是并没有被使用. 在本书中，只要矩阵的列向量单位正交，我们就把它记作 $\boldsymbol{Q}$. 但是我们只有在它是方阵的时候，才称它为正交矩阵.

$$\boldsymbol{Q}=\begin{bmatrix}\cos\theta & -\sin\theta\\ \sin\theta & \cos\theta\end{bmatrix},\qquad \boldsymbol{Q}^{\mathrm{T}}=\boldsymbol{Q}^{-1}=\begin{bmatrix}\cos\theta & \sin\theta\\ -\sin\theta & \cos\theta\end{bmatrix}.$$

计算两列的点积可知 $\boldsymbol{Q}$ 的列向量正交. 因为 $\sin^2\theta+\cos^2\theta=1$，所有 $\boldsymbol{Q}$ 的列向量都是单位向量，从而 $\boldsymbol{Q}$ 的两列构成 $\mathbb{R}^2$ 的标准正交基.

$\mathbb{R}^2$ 的标准基（即 $x$ 轴和 $y$ 轴正向的单位向量）$\boldsymbol{i}$、$\boldsymbol{j}$ 在 $\boldsymbol{Q}$ 的作用下逆时针旋转了 $\theta$ 角，见图 4.9(a). 再顺时针旋转 $\theta$ 角就回到原位，或者说 $\boldsymbol{Q}^{-1}$ 就是逆时针旋转 $-\theta$ 角. 注意到 $\cos(-\theta)=\cos\theta$，$\sin(-\theta)=-\sin\theta$，所以 $\boldsymbol{Q}^{-1}$ 和 $\boldsymbol{Q}^{\mathrm{T}}$ 相等，于是 $\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{Q}=\boldsymbol{Q}\boldsymbol{Q}^{\mathrm{T}}=\boldsymbol{I}$.

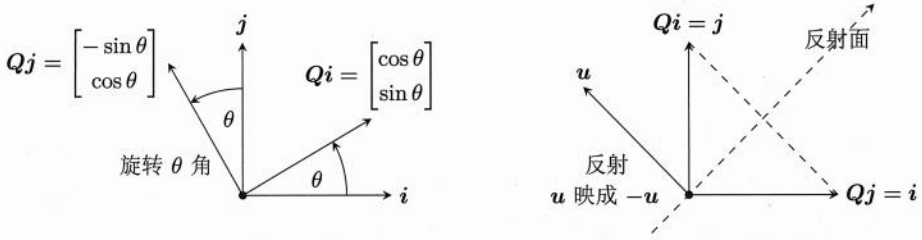


(a) 旋转矩阵 $\boldsymbol{Q}=\begin{bmatrix}c & -s\\ s & c\end{bmatrix}$　　(b) 反射矩阵 $\boldsymbol{Q}=\begin{bmatrix}0 & 1\\ 1 & 0\end{bmatrix}$

图 4.9　二阶正交矩阵

**例 4.12 (置换)**　置换矩阵交换坐标的顺序，例如 $\begin{bmatrix}x & y & z\end{bmatrix}^{\mathrm{T}}$ 变成 $\begin{bmatrix}y & z & x\end{bmatrix}^{\mathrm{T}}$，$\begin{bmatrix}x & y\end{bmatrix}^{\mathrm{T}}$ 变成 $\begin{bmatrix}y & x\end{bmatrix}^{\mathrm{T}}$:

$$\begin{bmatrix}0&1&0\\0&0&1\\1&0&0\end{bmatrix}\begin{bmatrix}x\\y\\z\end{bmatrix}=\begin{bmatrix}y\\z\\x\end{bmatrix},\qquad \begin{bmatrix}0&1\\1&0\end{bmatrix}\begin{bmatrix}x\\y\end{bmatrix}=\begin{bmatrix}y\\x\end{bmatrix}.$$

这些矩阵 $\boldsymbol{Q}$ 的列向量都是单位向量（长度等于 1 是显而易见的事实）. 列向量两两正交也是明显的（分量中的非零元 1 处于不同的位置）. 置换矩阵的逆和它的转置相同：$\boldsymbol{Q}^{-1}=\boldsymbol{Q}^{\mathrm{T}}$. 该逆矩阵把坐标变回原来的顺序.

逆 = 转置:
$$\begin{bmatrix}0&1&0\\0&0&1\\1&0&0\end{bmatrix}\begin{bmatrix}y\\z\\x\end{bmatrix}=\begin{bmatrix}x\\y\\z\end{bmatrix},\qquad \begin{bmatrix}0&1\\1&0\end{bmatrix}\begin{bmatrix}y\\x\end{bmatrix}=\begin{bmatrix}x\\y\end{bmatrix}.$$

任意置换矩阵都是正交矩阵.

**例 4.13 (反射)**　设 $\boldsymbol{u}$ 是单位向量，令 $\boldsymbol{Q}=\boldsymbol{I}-2\boldsymbol{u}\boldsymbol{u}^{\mathrm{T}}$. 需要注意到，$\boldsymbol{u}\boldsymbol{u}^{\mathrm{T}}$ 是矩阵而 $\boldsymbol{u}^{\mathrm{T}}\boldsymbol{u}=\|\boldsymbol{u}\|^2=1$. 那么 $\boldsymbol{Q}^{\mathrm{T}}=\boldsymbol{Q}^{-1}=\boldsymbol{Q}$:

$$\boxed{\boldsymbol{Q}^{\mathrm{T}}=\boldsymbol{I}-2\boldsymbol{u}\boldsymbol{u}^{\mathrm{T}}=\boldsymbol{Q}}\qquad \boldsymbol{Q}^{\mathrm{T}}\boldsymbol{Q}=\boldsymbol{I}-4\boldsymbol{u}\boldsymbol{u}^{\mathrm{T}}+4\boldsymbol{u}\boldsymbol{u}^{\mathrm{T}}\boldsymbol{u}\boldsymbol{u}^{\mathrm{T}}=\boldsymbol{I}.\tag{4.27}$$

最后一个等号是因为 $\boldsymbol{u}\boldsymbol{u}^{\mathrm{T}}\boldsymbol{u}\boldsymbol{u}^{\mathrm{T}}$ 中间两项乘积 $\boldsymbol{u}^{\mathrm{T}}\boldsymbol{u}=1$. 反射矩阵 $\boldsymbol{Q}=\boldsymbol{I}-2\boldsymbol{u}\boldsymbol{u}^{\mathrm{T}}$ 是对称的正交矩阵. 平方可得: $\boldsymbol{Q}^2=\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{Q}=\boldsymbol{I}$. 这个等式的含义可以用生活的实际类比: 沿着某个镜子反射两次就回到初始状态了, 也可以类比于 $(-1)^2=1$.

参照图 4.9(b), 我们选取 $\boldsymbol{u}=\begin{bmatrix}-\dfrac{1}{\sqrt{2}} & \dfrac{1}{\sqrt{2}}\end{bmatrix}^{\mathrm{T}}$. 先算出 $2\boldsymbol{u}\boldsymbol{u}^{\mathrm{T}}$, 再用 $\boldsymbol{I}$ 减去它, 就得到反射矩阵 $\boldsymbol{Q}$:

反射矩阵 $$\boldsymbol{Q}=\boldsymbol{I}-2\begin{bmatrix}0.5 & -0.5\\ -0.5 & 0.5\end{bmatrix}=\begin{bmatrix}0 & 1\\ 1 & 0\end{bmatrix} \quad \text{以及} \quad \begin{bmatrix}0 & 1\\ 1 & 0\end{bmatrix}\begin{bmatrix}x\\ y\end{bmatrix}=\begin{bmatrix}y\\ x\end{bmatrix}.$$

这个映射把 $(x,y)$ 映成 $(y,x)$, 像 $(3,3)$ 这样的点处在反射轴上, 所以被 $\boldsymbol{Q}$ 作用之后固定不变.

旋转保持向量的长度和向量之间的夹角, 反射、置换亦然. 任意正交矩阵 $\boldsymbol{Q}$ 都有这个性质——保持向量的长度和向量之间的夹角.

证明 因为

$$(\boldsymbol{Q}\boldsymbol{x})^{\mathrm{T}}(\boldsymbol{Q}\boldsymbol{x})=\boldsymbol{x}^{\mathrm{T}}\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{Q}\boldsymbol{x}=\boldsymbol{x}^{\mathrm{T}}\boldsymbol{I}\boldsymbol{x}=\boldsymbol{x}^{\mathrm{T}}\boldsymbol{x},$$

所以 $\|\boldsymbol{Q}\boldsymbol{x}\|^2=\|\boldsymbol{x}\|^2$, 于是 $\|\boldsymbol{Q}\boldsymbol{x}\|=\|\boldsymbol{x}\|$. $\boldsymbol{Q}$ 也保持点积:

$$(\boldsymbol{Q}\boldsymbol{x})^{\mathrm{T}}(\boldsymbol{Q}\boldsymbol{y})=\boldsymbol{x}^{\mathrm{T}}\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{Q}\boldsymbol{y}=\boldsymbol{x}^{\mathrm{T}}\boldsymbol{I}\boldsymbol{y}=\boldsymbol{x}^{\mathrm{T}}\boldsymbol{y}.$$

注: 事实上, 可以把条件放宽为 $\boldsymbol{Q}$ 的列向量单位正交, 即 $\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{Q}=\boldsymbol{I}$, 那么 $\boldsymbol{Q}$ 就保持点积和长度:

$$\boxed{\text{对任意 } \boldsymbol{x} \text{ 都有 } \|\boldsymbol{Q}\boldsymbol{x}\|=\|\boldsymbol{x}\|;\ \text{对任意 } \boldsymbol{x}、\boldsymbol{y} \text{ 都有 } (\boldsymbol{Q}\boldsymbol{x})^{\mathrm{T}}(\boldsymbol{Q}\boldsymbol{y})=\boldsymbol{x}^{\mathrm{T}}\boldsymbol{y}.} \tag{4.28}$$

证明和之前完全一样.

### 4.4.1 用单位正交基来作正交投影: 用 $Q$ 代替 $A$

正交矩阵在计算上的表现是相当优秀的——列向量的长度限定住之后, 矩阵的元素不会变得特别大. 任何具有计算稳定的代码都尽可能多地使用正交矩阵.

当我们考虑向子空间作正交投影时, 任何公式都涉及形如 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 的矩阵乘法. $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 的分量是它的列向量 $\boldsymbol{a}_1,\boldsymbol{a}_2,\cdots,\boldsymbol{a}_n$, 也是子空间的基的点积 $\boldsymbol{a}_i^{\mathrm{T}}\boldsymbol{a}_j$.

假设这组基是标准正交基, $\boldsymbol{a}_i$ 就改记作 $\boldsymbol{q}_i$, $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 简化成 $\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{Q}=\boldsymbol{I}$, 并且进一步地可以简化 $\hat{\boldsymbol{x}}$、$\boldsymbol{p}$ 和 $\boldsymbol{P}$:

$$\hat{\boldsymbol{x}}=\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{b} \qquad \boldsymbol{p}=\boldsymbol{Q}\hat{\boldsymbol{x}} \qquad \boldsymbol{P}=\boldsymbol{Q}\boldsymbol{Q}^{\mathrm{T}} \tag{4.29}$$

方程组 $\boldsymbol{Q}\boldsymbol{x}=\boldsymbol{b}$ 的最小二乘解是 $\hat{\boldsymbol{x}}=\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{b}$. 投影矩阵是 $\boldsymbol{Q}\boldsymbol{Q}^{\mathrm{T}}$. 没必要再放什么逆矩阵了, 这正是标准正交基的作用. 最优解 $\hat{\boldsymbol{x}}=\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{b}$ 的分量恰好是 $\boldsymbol{q}_1,\boldsymbol{q}_2,\cdots,\boldsymbol{q}_n$ 和 $\boldsymbol{b}$ 的点积, 而每一个点积又恰好是到一维子空间的正交投影![①]$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 有时被称作“耦合矩阵”或者“关联矩阵”, 此时等于 $\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{Q}=\boldsymbol{I}$: 耦合消失了. 当 $\boldsymbol{A}$ 是列向量单位正交的矩阵 $\boldsymbol{Q}$ 时, $\boldsymbol{p}=\boldsymbol{Q}\hat{\boldsymbol{x}}=\boldsymbol{Q}\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{b}$:

① 译者注: $\boldsymbol{b}$ 到过 $\boldsymbol{q}_i$ 的直线的正交投影为 $\boldsymbol{q}_i^{\mathrm{T}}\boldsymbol{b}/\boldsymbol{q}_i^{\mathrm{T}}\boldsymbol{q}_i=\boldsymbol{q}_i^{\mathrm{T}}\boldsymbol{b}$.

$$\text{到 } \boldsymbol{q}_i \text{ 的正交投影} \qquad \boldsymbol{p}=\begin{bmatrix}\boldsymbol{q}_1 & \cdots & \boldsymbol{q}_n\end{bmatrix}\begin{bmatrix}\boldsymbol{q}_1^{\mathrm{T}}\boldsymbol{b}\\ \vdots \\ \boldsymbol{q}_n^{\mathrm{T}}\boldsymbol{b}\end{bmatrix}=\boldsymbol{q}_1(\boldsymbol{q}_1^{\mathrm{T}}\boldsymbol{b})+\cdots+\boldsymbol{q}_n(\boldsymbol{q}_n^{\mathrm{T}}\boldsymbol{b}) \tag{4.30}$$

**重要的特例** 若 $m=n$，则 $\boldsymbol{Q}$ 是方阵，此时 $\boldsymbol{Q}$ 的列空间是整个 $\mathbb{R}^n$. 于是 $\boldsymbol{Q}^{\mathrm{T}}=\boldsymbol{Q}^{-1}$，且 $\hat{\boldsymbol{x}}=\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{b}=\boldsymbol{Q}^{-1}\boldsymbol{b}$ 是精确解. $\boldsymbol{b}$ 到全空间的正交投影是它自身，从而 $\boldsymbol{p}=\boldsymbol{b}$ 且 $\boldsymbol{P}=\boldsymbol{Q}\boldsymbol{Q}^{\mathrm{T}}=\boldsymbol{I}$.

或许很多人会觉得，到全空间的正交投影其实是恒同映射，那有什么研究价值呢？注意到 $\boldsymbol{p}=\boldsymbol{b}$，式(4.30)告诉我们 $\boldsymbol{b}$ 是它到 $n$ 个一维子空间的正交投影的和. 若 $\boldsymbol{q}_1,\boldsymbol{q}_2,\cdots,\boldsymbol{q}_n$ 是全空间的标准正交基，则 $\boldsymbol{Q}$ 是方阵，等式 $\boldsymbol{b}=\boldsymbol{Q}\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{b}$ 表明$\boldsymbol{b}$ 等于其在各 $\boldsymbol{q}_i$ 方向上的分支的总和:

$$\boldsymbol{b}=\boldsymbol{q}_1(\boldsymbol{q}_1^{\mathrm{T}}\boldsymbol{b})+\boldsymbol{q}_2(\boldsymbol{q}_2^{\mathrm{T}}\boldsymbol{b})+\cdots+\boldsymbol{q}_n(\boldsymbol{q}_n^{\mathrm{T}}\boldsymbol{b}) \tag{4.31}$$

**变换** $\boldsymbol{Q}\boldsymbol{Q}^{\mathrm{T}}=\boldsymbol{I}$ 是傅里叶变换甚至现代应用数学中所有伟大“变换”的基础. 它们把一个向量 $\boldsymbol{b}$ 或者函数 $f(x)$ 拆分成互相正交的分支；把这些分支相加，就是所谓的“逆变换”. 通过逆变换，拆分出来的分支又重新合成 $\boldsymbol{b}$ 或者 $f(x)$.

**例 4.14** 下面的矩阵 $\boldsymbol{Q}$ 的列向量 $\boldsymbol{q}_1$、$\boldsymbol{q}_2$、$\boldsymbol{q}_3$ 单位正交:

$$m=n=3 \qquad \boldsymbol{Q}=\frac{1}{3}\begin{bmatrix}-1 & 2 & 2\\ 2 & -1 & 2\\ 2 & 2 & -1\end{bmatrix} \qquad \boldsymbol{Q}^{\mathrm{T}}\boldsymbol{Q}=\boldsymbol{Q}\boldsymbol{Q}^{\mathrm{T}}=\boldsymbol{I}.$$

设 $\boldsymbol{b}=\begin{bmatrix}0 & 0 & 1\end{bmatrix}^{\mathrm{T}}$ 到 $\boldsymbol{q}_1$、$\boldsymbol{q}_2$、$\boldsymbol{q}_3$ 的正交投影分别是 $\boldsymbol{p}_1$、$\boldsymbol{p}_2$、$\boldsymbol{p}_3$，则

$$\boldsymbol{p}_1=\boldsymbol{q}_1(\boldsymbol{q}_1^{\mathrm{T}}\boldsymbol{b})=\frac{2}{3}\boldsymbol{q}_1 \qquad \boldsymbol{p}_2=\boldsymbol{q}_2(\boldsymbol{q}_2^{\mathrm{T}}\boldsymbol{b})=\frac{2}{3}\boldsymbol{q}_2 \qquad \boldsymbol{p}_3=\boldsymbol{q}_3(\boldsymbol{q}_3^{\mathrm{T}}\boldsymbol{b})=-\frac{1}{3}\boldsymbol{q}_3$$

$\boldsymbol{p}_1+\boldsymbol{p}_2$ 是 $\boldsymbol{b}$ 在 $\boldsymbol{q}_1$、$\boldsymbol{q}_2$ 张成的平面上的正交投影. 三个投影相加是 $\boldsymbol{b}$ 在全空间的正交投影，即 $\boldsymbol{b}=\boldsymbol{p}_1+\boldsymbol{p}_2+\boldsymbol{p}_3$. 验算一下:

$$\text{重构}\boldsymbol{b}=\boldsymbol{p}_1+\boldsymbol{p}_2+\boldsymbol{p}_3 \qquad \frac{2}{3}\boldsymbol{q}_1+\frac{2}{3}\boldsymbol{q}_2-\frac{1}{3}\boldsymbol{q}_3=\frac{1}{9}\begin{bmatrix}-2+4-2\\ 4-2-2\\ 4+1+1\end{bmatrix}=\begin{bmatrix}0\\ 0\\ 1\end{bmatrix}=\boldsymbol{b}.$$

### 4.4.2 格拉姆-施密特正交化

本节多次强调，正交性有很多好处. 正交投影和最小二乘法总是涉及形如 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 的矩阵，如果该矩阵是 $\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{Q}=\boldsymbol{I}$，那么对该矩阵取逆这个问题就不存在了. 到各个一维子空间的正交投影互不干扰，所以最优的 $\hat{\boldsymbol{x}}$ 等于 $\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{b}$（也就是 $n$ 个单独的点积而已）. 尽管有这么大的优点，我们不能忘记前提条件：“如果列向量单位正交”. **接下来介绍“格拉姆-施密特方法”，用以构造单位正交的向量组.**

遵循由易到难、由特殊到一般的原则，我们从**线性无关**的三个向量 $\boldsymbol{a}$、$\boldsymbol{b}$、$\boldsymbol{c}$ 开始，目标是构造相互正交的向量 $\boldsymbol{\alpha}$，$\boldsymbol{\beta}$，$\boldsymbol{\gamma}$，然后（根据我们的步骤实际上是最后一步）再把 $\boldsymbol{\alpha}$，$\boldsymbol{\beta}$，$\boldsymbol{\gamma}$ 分别除以各自的长度，那么就得到了单位正交的向量组 $\boldsymbol{q}_1=\boldsymbol{\alpha}/\|\boldsymbol{\alpha}\|,\boldsymbol{q}_2=\boldsymbol{\beta}/\|\boldsymbol{\beta}\|,\boldsymbol{q}_3=\boldsymbol{\gamma}/\|\boldsymbol{\gamma}\|$.

**格拉姆-施密特方法** 第一步什么也不干，直接令 $\boldsymbol{\alpha}=\boldsymbol{a}$. 第二步构造和 $\boldsymbol{\alpha}$ 正交的向量 $\boldsymbol{\beta}$，此时需要引入 $\boldsymbol{b}$，把 $\boldsymbol{b}$ 减去它到 $\boldsymbol{\alpha}$ 的正交投影，两者之差与 $\boldsymbol{\alpha}$ 正交，我们令之为 $\boldsymbol{\beta}$:

正交化的第一步、第二步
构造和 $\boldsymbol{\alpha}$ 正交的 $\boldsymbol{\beta}$

$$\boxed{\boldsymbol{\beta}=\boldsymbol{b}-\frac{\boldsymbol{\alpha}^{\mathrm{T}}\boldsymbol{b}}{\boldsymbol{\alpha}^{\mathrm{T}}\boldsymbol{\alpha}}\boldsymbol{\alpha}.} \tag{4.32}$$

$\boldsymbol{\alpha}$ 和 $\boldsymbol{\beta}$ 的正交性参考图 4.10. 式(4.32)左右两边同时左乘 $\boldsymbol{\alpha}^{\mathrm{T}}$ 可知：$\boldsymbol{\alpha}^{\mathrm{T}}\boldsymbol{\beta}=\boldsymbol{\alpha}^{\mathrm{T}}\boldsymbol{b}-\boldsymbol{\alpha}^{\mathrm{T}}\boldsymbol{b}=0$. 事实上，$\boldsymbol{\beta}$ 就是作正交投影时的误差项，自然和 $\boldsymbol{\alpha}$ 是正交的. 注意到式(4.32)中的 $\boldsymbol{\beta}$ 不是零向量，否则 $\boldsymbol{a}$、$\boldsymbol{b}$ 线性相关，于是 $\boldsymbol{\alpha}$、$\boldsymbol{\beta}$ 就构造完成了.

第三步构造 $\boldsymbol{\gamma}$. 我们从 $\boldsymbol{c}$ 出发，由于它不是 $\boldsymbol{a}$、$\boldsymbol{b}$ 线性组合，因此也不是 $\boldsymbol{\alpha}$、$\boldsymbol{\beta}$ 的线性组合. 当然，$\boldsymbol{c}$ 很有可能不和 $\boldsymbol{\alpha}$、$\boldsymbol{\beta}$ 正交，但是没关系，我们还是作正交投影，把 $\boldsymbol{c}$ 减去它在 $\boldsymbol{\alpha}$、$\boldsymbol{\beta}$ 方向上的正交投影，剩下的部分 $\boldsymbol{\gamma}$ 和 $\boldsymbol{\alpha}$、$\boldsymbol{\beta}$ 正交：

正交化的第三步
构造和 $\boldsymbol{\alpha}$、$\boldsymbol{\beta}$ 正交的 $\boldsymbol{\gamma}$

$$\boxed{\boldsymbol{\gamma}=\boldsymbol{c}-\frac{\boldsymbol{\alpha}^{\mathrm{T}}\boldsymbol{c}}{\boldsymbol{\alpha}^{\mathrm{T}}\boldsymbol{\alpha}}\boldsymbol{\alpha}-\frac{\boldsymbol{\beta}^{\mathrm{T}}\boldsymbol{c}}{\boldsymbol{\beta}^{\mathrm{T}}\boldsymbol{\beta}}\boldsymbol{\beta}.} \tag{4.33}$$

这个例子充分体现了格拉姆-施密特正交化的核心思想. 本质是归纳法，**把每一个向量减去它到之前已经构造出来的方向上的正交投影.** 格拉姆-施密特的构造每一步都在重复这一过程.[①]如果还有第四个向量 $\boldsymbol{d}$，把它减去在 $\boldsymbol{\alpha}$、$\boldsymbol{\beta}$、$\boldsymbol{\gamma}$ 三个方向上的正交投影就得到了 $\boldsymbol{\delta}$. 我们初步处理完了所有向量之后，把所得的正交向量组 $\boldsymbol{\alpha}$、$\boldsymbol{\beta}$、$\boldsymbol{\gamma}$、$\boldsymbol{\delta}$ 都除以各自的长度，最终得到单位正交的向量组 $\boldsymbol{q}_1$、$\boldsymbol{q}_2$、$\boldsymbol{q}_3$、$\boldsymbol{q}_4$.

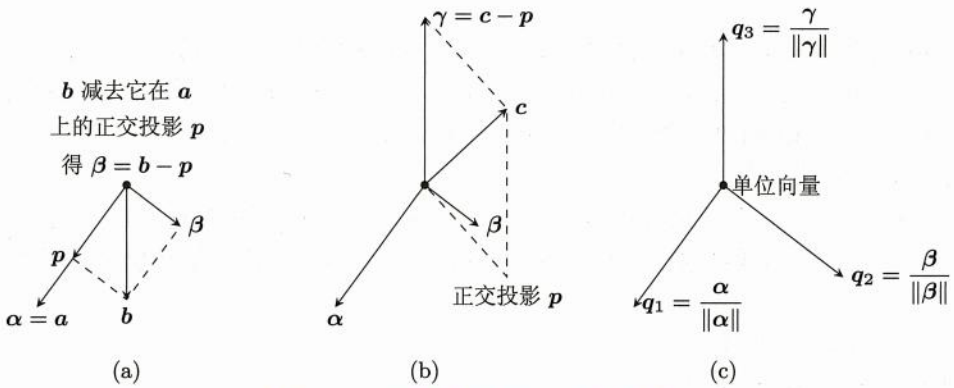


图 4.10　格拉姆-施密特正交化的步骤

注：图 4.10(a) 把 $\boldsymbol{b}$ 正交投影到过 $\boldsymbol{a}$ 的直线得到 $\boldsymbol{\beta}=\boldsymbol{b}-\boldsymbol{p}$；图 4.10(b) 把 $\boldsymbol{c}$ 正交投影到过 $\boldsymbol{\alpha}$、$\boldsymbol{\beta}$ 的平面得到 $\boldsymbol{\gamma}=\boldsymbol{c}-\boldsymbol{p}$；图 4.10(c) 把 $\boldsymbol{\alpha}$、$\boldsymbol{\beta}$、$\boldsymbol{\gamma}$ 除以各自的长度得到单位向量.

**格拉姆-施密特正交化的例题.** 给定如下线性无关但不正交的向量组 $\boldsymbol{a}$、$\boldsymbol{b}$、$\boldsymbol{c}$:

$$\boldsymbol{a}=\begin{bmatrix}1\\-1\\0\end{bmatrix},\qquad \boldsymbol{b}=\begin{bmatrix}2\\0\\-2\end{bmatrix},\qquad \boldsymbol{c}=\begin{bmatrix}3\\-3\\3\end{bmatrix}.$$

① 作者按：我认为格拉姆有这个想法，但我不确定施密特在这个想法中扮演的角色.

那么 $\boldsymbol{\alpha}=\boldsymbol{a},\boldsymbol{\alpha}^{\mathrm{T}}\boldsymbol{\alpha}=2,\boldsymbol{\alpha}^{\mathrm{T}}\boldsymbol{b}=2$. 把 $\boldsymbol{b}$ 减去它在 $\boldsymbol{\alpha}$ 方向的正交投影：

$$\text{第一步}\qquad \boldsymbol{\beta}=\boldsymbol{b}-\frac{\boldsymbol{\alpha}^{\mathrm{T}}\boldsymbol{b}}{\boldsymbol{\alpha}^{\mathrm{T}}\boldsymbol{\alpha}}\cdot\boldsymbol{\alpha}=\boldsymbol{b}-\frac{2}{2}\boldsymbol{\alpha}=\begin{bmatrix}1\\1\\-2\end{bmatrix}$$

检验：$\boldsymbol{\alpha}^{\mathrm{T}}\boldsymbol{\beta}=1\cdot1+(-1)\cdot1+0\cdot(-2)=0$，再把 $\boldsymbol{c}$ 减去它在 $\boldsymbol{\alpha}$、$\boldsymbol{\beta}$ 方向上的正交投影得到 $\boldsymbol{\gamma}$：

$$\text{第二步}\qquad \boldsymbol{\gamma}=\boldsymbol{c}-\frac{\boldsymbol{\alpha}^{\mathrm{T}}\boldsymbol{c}}{\boldsymbol{\alpha}^{\mathrm{T}}\boldsymbol{\alpha}}\boldsymbol{\alpha}-\frac{\boldsymbol{\beta}^{\mathrm{T}}\boldsymbol{c}}{\boldsymbol{\beta}^{\mathrm{T}}\boldsymbol{\beta}}\boldsymbol{\beta}=\boldsymbol{c}-\frac{6}{2}\boldsymbol{\alpha}-\frac{6}{6}\boldsymbol{\beta}=\begin{bmatrix}1\\1\\1\end{bmatrix}$$

检验 $\boldsymbol{\gamma}$ 和 $\boldsymbol{\alpha}$、$\boldsymbol{\beta}$ 正交的具体过程就留给读者. 最后，我们把 $\boldsymbol{\alpha}$、$\boldsymbol{\beta}$、$\boldsymbol{\gamma}$ 除以各自的长度 $\sqrt{2}$、$\sqrt{6}$、$\sqrt{3}$ 以得到单位正交向量组 $\boldsymbol{q}_1$、$\boldsymbol{q}_2$、$\boldsymbol{q}_3$：

$$\boldsymbol{q}_1=\frac{1}{\sqrt{2}}\begin{bmatrix}1\\-1\\0\end{bmatrix},\qquad \boldsymbol{q}_2=\frac{1}{\sqrt{6}}\begin{bmatrix}1\\1\\-2\end{bmatrix},\qquad \boldsymbol{q}_3=\frac{1}{\sqrt{3}}\begin{bmatrix}1\\1\\1\end{bmatrix}.$$

$\boldsymbol{\alpha}$、$\boldsymbol{\beta}$、$\boldsymbol{\gamma}$ 通常包含分数，而 $\boldsymbol{q}_1$、$\boldsymbol{q}_2$、$\boldsymbol{q}_3$ 几乎一定包含平方根. 这是为了得到单位正交向量组（也就是 $\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{Q}=\boldsymbol{I}$）必要的代价.

### 4.4.3 $QR$ 分解

设矩阵 $\boldsymbol{A}$ 的列向量 $\boldsymbol{a}$、$\boldsymbol{b}$、$\boldsymbol{c}$ 线性无关；作格拉姆-施密特正交化，得到 $\boldsymbol{q}_1$、$\boldsymbol{q}_2$、$\boldsymbol{q}_3$，排成矩阵 $\boldsymbol{Q}$. 如何把 $\boldsymbol{A}$ 和 $\boldsymbol{Q}$ 联系起来呢？因为 $\boldsymbol{a}$、$\boldsymbol{b}$、$\boldsymbol{c}$ 都是 $\boldsymbol{q}_1$、$\boldsymbol{q}_2$、$\boldsymbol{q}_3$ 的线性组合（反之亦然），那么一定存在联系 $\boldsymbol{A}$ 和 $\boldsymbol{Q}$ 的第三个矩阵，该矩阵即分解式$\boldsymbol{A}=\boldsymbol{QR}$ 中的上三角矩阵 $\boldsymbol{R}$（注意，它不是第 1 章中的行满秩矩阵 $R$）.

回顾格拉姆-施密特正交化的详细步骤. 第一步 $\boldsymbol{q}_1=\boldsymbol{a}/\|\boldsymbol{a}\|$（和其他向量无关）. 第二步即式(4.32)，$\boldsymbol{b}$ 是 $\boldsymbol{\alpha}$ 和 $\boldsymbol{\beta}$ 的线性组合，$\boldsymbol{\gamma}$ 和 $\boldsymbol{q}_3$ 并没有涉及，这一点恰恰是格拉姆-施密特正交化的关键：

（1）向量 $\boldsymbol{a}$、$\boldsymbol{\alpha}$、$\boldsymbol{q}_1$ 共线；

（2）向量组 $\boldsymbol{a},\boldsymbol{b}$、$\boldsymbol{\alpha},\boldsymbol{\beta}$ 和 $\boldsymbol{q}_1,\boldsymbol{q}_2$ 共面；

（3）向量组 $\boldsymbol{a},\boldsymbol{b},\boldsymbol{c}$、$\boldsymbol{\alpha},\boldsymbol{\beta},\boldsymbol{\gamma}$ 和 $\boldsymbol{q}_1,\boldsymbol{q}_2,\boldsymbol{q}_3$ 在同一个三维线性子空间上.

在每一步，$\boldsymbol{a}_1,\boldsymbol{a}_2,\cdots,\boldsymbol{a}_k$ 都是 $\boldsymbol{q}_1,\boldsymbol{q}_2,\cdots,\boldsymbol{q}_k$ 的线性组合，不涉及其他 $\boldsymbol{q}_j$，所以矩阵 $\boldsymbol{R}$ 是上三角矩阵，且 $\boldsymbol{A}=\boldsymbol{QR}$.

$$\begin{bmatrix}\boldsymbol{a} & \boldsymbol{b} & \boldsymbol{c}\end{bmatrix}=\begin{bmatrix}\boldsymbol{q}_1 & \boldsymbol{q}_2 & \boldsymbol{q}_3\end{bmatrix}\begin{bmatrix}\boldsymbol{q}_1^{\mathrm{T}}\boldsymbol{a} & \boldsymbol{q}_1^{\mathrm{T}}\boldsymbol{b} & \boldsymbol{q}_1^{\mathrm{T}}\boldsymbol{c}\\ & \boldsymbol{q}_2^{\mathrm{T}}\boldsymbol{b} & \boldsymbol{q}_2^{\mathrm{T}}\boldsymbol{c}\\ & & \boldsymbol{q}_3^{\mathrm{T}}\boldsymbol{c}\end{bmatrix}\qquad \text{或者}\qquad \boldsymbol{A}=\boldsymbol{QR}.\tag{4.34}$$

一言以蔽之，$\boldsymbol{A}=\boldsymbol{QR}$ 就是格拉姆-施密特正交化的矩阵形式. 式(4.34)左右两边同时左乘 $\boldsymbol{Q}^{\mathrm{T}}$ 即有 $\boldsymbol{R}=\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{A}$.

**格拉姆-施密特**　从线性无关的向量组 $\boldsymbol{a}_1, \boldsymbol{a}_2, \cdots, \boldsymbol{a}_n$ 开始，格拉姆-施密特构造了单位正交向量组 $\boldsymbol{q}_1, \boldsymbol{q}_2, \cdots, \boldsymbol{q}_n$. 以这两组向量排成的矩阵满足 $\boldsymbol{A} = \boldsymbol{QR}$. 同时，每个 $\boldsymbol{q}_j$ 都正交于 $\boldsymbol{a}_i (i < j)$，所以 $\boldsymbol{R} = \boldsymbol{Q}^{\mathrm{T}}\boldsymbol{A}$ 是上三角矩阵.

继续之前的例子. $\boldsymbol{R} = \boldsymbol{Q}^{\mathrm{T}}\boldsymbol{A}$ 的第 $i$、$j$ 分量是 $\boldsymbol{Q}^{\mathrm{T}}$ 的第 $i$ 行乘以 $\boldsymbol{A}$ 的第 $j$ 列，也即点积 $\boldsymbol{q}_i^{\mathrm{T}}\boldsymbol{a}_j$，于是 $\boldsymbol{A} = \boldsymbol{QR}$:

$$\boldsymbol{A} = \begin{bmatrix} 1 & 2 & 3 \\ -1 & 0 & -3 \\ 0 & -2 & 3 \end{bmatrix} = \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{6} & 1/\sqrt{3} \\ -1/\sqrt{2} & 1/\sqrt{6} & 1/\sqrt{3} \\ 0 & -2/\sqrt{6} & 1/\sqrt{3} \end{bmatrix} \begin{bmatrix} \sqrt{2} & \sqrt{2} & \sqrt{18} \\ 0 & \sqrt{6} & -\sqrt{6} \\ 0 & 0 & \sqrt{3} \end{bmatrix} = \boldsymbol{QR}.$$

再仔细观察一下 $\boldsymbol{Q}$ 和 $\boldsymbol{R}$. $\boldsymbol{\alpha}$、$\boldsymbol{\beta}$、$\boldsymbol{\gamma}$ 的长度 $\sqrt{2}$、$\sqrt{6}$、$\sqrt{3}$ 是 $\boldsymbol{R}$ 的对角线元素. $\boldsymbol{Q}$ 的列向量单位正交. 这么多平方根让 $\boldsymbol{QR}$ 分解看起来比 $\boldsymbol{LU}$ 分解复杂多了，但是眼见未必为实，具体到实际计算就未必那么复杂. 这两种分解在线性代数的计算中都起着绝对核心的作用.

列满秩的 $m \times n$ 矩阵 $\boldsymbol{A}$ 都可以分解为 $\boldsymbol{A} = \boldsymbol{QR}$，其中 $\boldsymbol{Q}$ 是 $m \times n$ 矩阵，其列向量单位正交；$\boldsymbol{R}$ 是对角线元素都是正数的上三角矩阵. 路走远了总该回头看看——我们不能忘了 $\boldsymbol{QR}$ 分解在最小二乘中的作用：

$$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A} = (\boldsymbol{QR})^{\mathrm{T}}(\boldsymbol{QR}) = \boldsymbol{R}^{\mathrm{T}}\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{QR} = \boldsymbol{R}^{\mathrm{T}}\boldsymbol{R},$$

那么 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}} = \boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$ 就简化为

$$\boldsymbol{R}^{\mathrm{T}}\boldsymbol{R}\hat{\boldsymbol{x}} = \boldsymbol{R}^{\mathrm{T}}\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{b}, \qquad \text{进而} \boldsymbol{R}\hat{\boldsymbol{x}} = \boldsymbol{Q}^{\mathrm{T}}\boldsymbol{b}.$$

由于 $\boldsymbol{R}$ 是上三角矩阵，求解这样的方程组就很容易了. 总结一下：

最小二乘　$\boldsymbol{R}^{\mathrm{T}}\boldsymbol{R}\hat{\boldsymbol{x}} = \boldsymbol{R}^{\mathrm{T}}\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{b}$　等价地　$\boldsymbol{R}\hat{\boldsymbol{x}} = \boldsymbol{Q}^{\mathrm{T}}\boldsymbol{b}$　等价地　$\hat{\boldsymbol{x}} = \boldsymbol{R}^{-1}\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{b}$.　(4.35)

不同于求解 $\boldsymbol{Ax} = \boldsymbol{b}$ 这个无解的方程组，用回代法解 $\boldsymbol{R}\hat{\boldsymbol{x}} = \boldsymbol{Q}^{\mathrm{T}}\boldsymbol{b}$ 就很快了. 格拉姆-施密特正交化用于构造列正交矩阵 $\boldsymbol{Q}$、上三角矩阵 $\boldsymbol{R}$ 和分解式 $\boldsymbol{A} = \boldsymbol{QR}$. 实际的计算量是 $mn^2$ 次乘法. 下面我们用 MATLAB 的记号来写格拉姆-施密特正交化的伪代码.

```
for j = 1 : n                          % n 步的改进格拉姆-施密特算法
  v = A(:, j);                         % 令 v 为初始矩阵 A 的第 j 列
  for i = 1 : j − 1                    % Q 的第 1 列到第 j − 1 列 q_1, q_2, ..., q_{j−1} 已完成构造
    R(i, j) = Q(:, i)' * v;            % 计算 R_{i,j} = q_i^T a_j，即 q_i^T v
    v = v − R(i, j) * Q(:, i);         % 减去 q_i 方向的正交投影 (q_i^T v) q_i
  end                                  % v 和 q_1, q_2, ..., q_{j−1} 都正交
  R(j, j) = norm(v);                   % R 的对角线元素 R_{jj} 是 v 的长度
  Q(:, j) = v/R(j, j);                 % v 除以自身的长度得到 q_j
end                                    % 用循环 "j = 1 : n" 生成所有 q_j
```

这段伪代码是循环语句. 其中第 4、5 行表示把 $\boldsymbol{v}=\boldsymbol{a}_j$ 减去它在 $\boldsymbol{q}_1,\boldsymbol{q}_2,\cdots,\boldsymbol{q}_{j-1}$ 方向上的正交投影；最后一行单位化 $\boldsymbol{v}$（除以 $r_{jj}=\|\boldsymbol{v}\|$），从而得到单位向量 $\boldsymbol{q}_j$. 总而言之，这段伪代码从 $j=1$、$j=2$ 一直到 $j=n$，循环执行下述算式：

$$r_{kj}=\sum_{i=1}^{m}q_{ik}v_{ij},\qquad v_{ij}=v_{ij}-q_{ik}r_{kj},\qquad r_{jj}=\left(\sum_{i=1}^{m}v_{ij}^2\right)^{1/2},\qquad q_{ij}=\frac{v_{ij}}{r_{jj}} \tag{4.36}$$

例如，从 $\boldsymbol{a},\boldsymbol{b},\boldsymbol{c}=\boldsymbol{a}_1,\boldsymbol{a}_2,\boldsymbol{a}_3$ 开始，这段代码先构造 $\boldsymbol{q}_1$，然后是 $\boldsymbol{\beta}$ 和 $\boldsymbol{q}_2$，最后是 $\boldsymbol{\gamma}$ 和 $\boldsymbol{q}_3$:

$$\begin{aligned}&\boldsymbol{q}_1=\boldsymbol{a}_1/\|\boldsymbol{a}_1\|\\&\boldsymbol{\beta}=\boldsymbol{a}_2-(\boldsymbol{q}_1^{\mathrm{T}}\boldsymbol{a}_2)\boldsymbol{q}_1\quad \boldsymbol{q}_2=\boldsymbol{\beta}/\|\boldsymbol{\beta}\|\\&\boldsymbol{\gamma}^*=\boldsymbol{a}_3-(\boldsymbol{q}_1^{\mathrm{T}}\boldsymbol{a}_3)\boldsymbol{q}_1\quad \boldsymbol{\gamma}=\boldsymbol{\gamma}^*-(\boldsymbol{q}_2^{\mathrm{T}}\boldsymbol{\gamma}^*)\boldsymbol{q}_2\quad \boldsymbol{q}_3=\boldsymbol{\gamma}/\|\boldsymbol{\gamma}\|\end{aligned}$$

式(4.36)中，每次只减去一个方向的正交投影，例如 $\boldsymbol{\gamma}^*$ 和 $\boldsymbol{\gamma}$. 正是因此，该算法才称作**改进的格拉姆-施密特正交化算法**. 这个算法相比于式(4.33)，误差累计更小，计算稳定性表现更好.

若要反解 $\boldsymbol{A}$ 的第 $j$ 列，我们只需要把伪代码的最后一步和中间一步反过来：

$$\boldsymbol{R}(j,j)\boldsymbol{q}_j=(\boldsymbol{v}-\text{它的正交投影})=\boldsymbol{A}\text{的第 }j\text{ 列}-\sum_{i=1}^{j-1}\boldsymbol{R}(i,j)\boldsymbol{q}_i \tag{4.37}$$

**把等式右边的求和项移到等式左边，即可得到分解式 $\boldsymbol{QR}=\boldsymbol{A}$ 中的第 $j$ 列.**

**注：**诸如 LAPACK、MATLAT、Julia 和 Python 等优秀的计算软件或者系统，未必使用上述格拉姆-施密特代码，因为现在已经发展出了更好的方法——我们可以用“豪斯霍尔德反射”作用在 $\boldsymbol{A}$ 上来构造上三角矩阵 $\boldsymbol{R}$. 类似于 $\boldsymbol{LU}$ 分解中用消元法构造上三角矩阵 $U$，这种算法每次只处理 $\boldsymbol{A}$ 的一列.

如果 $\boldsymbol{A}$ 是三对角矩阵，“豪斯霍尔德反射”甚至可以简化到用 $2\times 2$ 旋转矩阵. 其结果始终是 $\boldsymbol{A}=\boldsymbol{QR}$ 的形式，MATLAB 中正交化 $\boldsymbol{A}$ 的命令是 $[\boldsymbol{Q},\boldsymbol{R}]=\mathrm{qr}(\boldsymbol{A})$. 即便新方法有诸多优点，格拉姆-施密特算法依然是容易理解的优秀算法. 我们也需要认识到，最稳定的代码永远在新的步骤中寻找并使用**最大的向量 $\boldsymbol{a}_j$.**[①]

## 要 点 回 顾

1. 若矩阵 $\boldsymbol{Q}$ 的列向量 $\boldsymbol{q}_1,\boldsymbol{q}_2,\cdots,\boldsymbol{q}_n$ 是单位正交向量组，那么 $\boldsymbol{q}_i^{\mathrm{T}}\boldsymbol{q}_j=0(i\neq j)$ 且 $\boldsymbol{q}_i^{\mathrm{T}}\boldsymbol{q}_i=1(1\leqslant i\leqslant n)$. 用矩阵乘法来描述就是 $\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{Q}=\boldsymbol{I}$.

2. 若 $\boldsymbol{Q}$ 还是方阵（此时 $\boldsymbol{Q}$ 称作正交矩阵），则 $\boldsymbol{Q}^{\mathrm{T}}=\boldsymbol{Q}^{-1}$：**转置 = 逆.**

3. $\boldsymbol{Qx}$ 的长度和 $\boldsymbol{x}$ 相同：$\|\boldsymbol{Qx}\|=\|\boldsymbol{x}\|$.

4. 到 $\boldsymbol{q}_1,\boldsymbol{q}_2,\cdots,\boldsymbol{q}_n$ 张成的子空间——$\boldsymbol{Q}$ 的列空间——的正交投影矩阵是 $\boldsymbol{P}=\boldsymbol{QQ}^{\mathrm{T}}$.

5. 如果 $\boldsymbol{Q}$ 是方阵，则 $\boldsymbol{P}=\boldsymbol{QQ}^{\mathrm{T}}=\boldsymbol{I}$，且任意 $\boldsymbol{b}$ 都有分解式：$\boldsymbol{b}=\boldsymbol{q}_1(\boldsymbol{a}_1^{\mathrm{T}}\boldsymbol{b})+\boldsymbol{q}_2(\boldsymbol{a}_2^{\mathrm{T}}\boldsymbol{b})+\cdots+\boldsymbol{q}_n(\boldsymbol{q}_n^{\mathrm{T}}\boldsymbol{b})$.

① 译者注：类比 $\boldsymbol{LU}$ 分解，我们选取主元也是倾向于选择绝对值最大的主元.

6. 格拉姆-施密特正交化可以从线性无关的向量组出发构造出单位正交的向量组. 用矩阵乘法来描述即 $\boldsymbol{A}=\boldsymbol{Q}\boldsymbol{R}$，其中 $\boldsymbol{Q}$ 满足 $\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{Q}=\boldsymbol{I}$，$\boldsymbol{R}$ 是对角线为正数的上三角矩阵.

## 例 题 总 结

4.4 A. 把 1 和 $-1$ 填入 $\boldsymbol{H}_4$ 的后两列，使其四个列向量两两正交. 这样的矩阵称作“阿达玛矩阵”.[①]你能否把 $\boldsymbol{H}_4$ 转化为正交矩阵 $\boldsymbol{Q}_4$?

$$\boldsymbol{H}_2=\begin{bmatrix}1 & 1\\ 1 & -1\end{bmatrix},\qquad \boldsymbol{H}_4=\begin{bmatrix}1 & 1 & * & *\\ 1 & -1 & * & *\\ 1 & 1 & * & *\\ 1 & -1 & * & *\end{bmatrix},\qquad \boldsymbol{Q}_4=\begin{bmatrix} & & & \\ & & & \\ & & & \\ & & & \end{bmatrix}$$

分块矩阵 $\boldsymbol{H}_8=\begin{bmatrix}\boldsymbol{H}_4 & \boldsymbol{H}_4\\ \boldsymbol{H}_4 & -\boldsymbol{H}_4\end{bmatrix}$ 的各个分量也都是 $\pm1$，$\boldsymbol{H}_8^{\mathrm{T}}\boldsymbol{H}_8$ 等于什么?

向量 $\boldsymbol{b}=\begin{bmatrix}6 & 0 & 0 & 2\end{bmatrix}^{\mathrm{T}}$ 到 $\boldsymbol{H}_4$ 第一个列向量的正交投影是 $\boldsymbol{p}_1=\begin{bmatrix}2 & 2 & 2 & 2\end{bmatrix}^{\mathrm{T}}$，到第二个列向量的正交投影是 $\boldsymbol{p}_2=\begin{bmatrix}1 & -1 & 1 & -1\end{bmatrix}^{\mathrm{T}}$. 那 $\boldsymbol{b}$ 到前两个列向量张成的二维子空间的正交投影是什么?

解　$\boldsymbol{H}_4$ 可以从 $\boldsymbol{H}_2$ 构造，如同 $\boldsymbol{H}_8$ 从 $\boldsymbol{H}_4$ 构造一样:

$$\boldsymbol{H}_4=\begin{bmatrix}\boldsymbol{H}_2 & \boldsymbol{H}_2\\ \boldsymbol{H}_2 & -\boldsymbol{H}_2\end{bmatrix}=\begin{bmatrix}1 & 1 & 1 & 1\\ 1 & -1 & 1 & -1\\ 1 & 1 & -1 & -1\\ 1 & -1 & -1 & 1\end{bmatrix}\qquad \text{列向量两两正交.}$$

因为 $\boldsymbol{H}_4$ 的列向量长度都是 2，所有 $\boldsymbol{Q}_4=\dfrac{1}{2}\boldsymbol{H}_4$ 的列向量是两两正交的单位向量，从而是正交矩阵. $5\times5$ 的阿达玛矩阵是不存在的，因为两个列向量的点积是 5 个 $\pm1$ 的和，一定是奇数，不可能等于 0.

$$\boldsymbol{H}_8^{\mathrm{T}}\boldsymbol{H}_8=\begin{bmatrix}\boldsymbol{H}_4^{\mathrm{T}} & \boldsymbol{H}_4^{\mathrm{T}}\\ \boldsymbol{H}_4^{\mathrm{T}} & -\boldsymbol{H}_4^{\mathrm{T}}\end{bmatrix}\begin{bmatrix}\boldsymbol{H}_4 & \boldsymbol{H}_4\\ \boldsymbol{H}_4 & -\boldsymbol{H}_4\end{bmatrix}=\begin{bmatrix}2\boldsymbol{H}_4^{\mathrm{T}}\boldsymbol{H}_4 & \boldsymbol{0}\\ \boldsymbol{0} & 2\boldsymbol{H}_4^{\mathrm{T}}\boldsymbol{H}_4\end{bmatrix}=\begin{bmatrix}8\boldsymbol{I} & \boldsymbol{0}\\ \boldsymbol{0} & 8\boldsymbol{I}\end{bmatrix}$$

$\boldsymbol{H}_8$ 的列向量长度都是 $\sqrt{8}$，所以 $\boldsymbol{Q}_8=\dfrac{1}{\sqrt{8}}\boldsymbol{H}_8$ 是正交矩阵.

4.4 B. 矩阵的列向量两两正交的关键作用是什么?

解　若 $\boldsymbol{Q}$ 是这样的矩阵，那么 $\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{Q}$ 是对角矩阵，从而它的逆矩阵很容易求. 此外，还是因为列向量正交，往列空间作正交投影只需要计算到每个列向量的投影然后相加.

① 译者注：如果 $n$ 阶方阵 $\boldsymbol{H}_n$ 所有元素都是 $\pm1$ 且 $\boldsymbol{H}_n^{\mathrm{T}}\boldsymbol{H}_n=n\boldsymbol{I}$，那么就称 $\boldsymbol{H}_n$ 是阿达玛矩阵.

## 正交矩阵 $Q$ 和正交投影 $P$

| $A$ 的列向量是 $\mathbb{R}^m$ 中 $n$ 个线性无关的向量 | $Q$ 的列向量是 $\mathbb{R}^m$ 中 $n$ 个两两正交的向量 |
|---|---|
| $A=\begin{bmatrix}a_1 & \cdots & a_n\end{bmatrix}$ | $Q=\begin{bmatrix}q_1 & \cdots & q_n\end{bmatrix}$ |
| $A^{\mathrm{T}}A$ 对称且可逆 | $Q^{\mathrm{T}}Q=I$ |
| 到列空间的正交投影矩阵 $P$ | $Pb$ 是和 $b$ 距离最近的向量 |
| $P=A(A^{\mathrm{T}}A)^{-1}A^{\mathrm{T}}$ | $P=QQ^{\mathrm{T}}$ |
| $Ax=b$ 的最小二乘解 | $Qx=b$ 的最小二乘解 |
| $A^{\mathrm{T}}A\hat{x}=A^{\mathrm{T}}b$ | $\hat{x}=Q^{\mathrm{T}}b$ |
| 格拉姆-施密特正交化 $A=QR$ | $a_1,a_2,\cdots,a_n$ 线性无关，$q_1,q_2,\cdots,q_n$ 两两正交 |
| $\begin{bmatrix}a_1 & \cdots & a_n\end{bmatrix}=\begin{bmatrix}q_1 & \cdots & q_n\end{bmatrix}\begin{bmatrix}r_{11} & r_{12} & \cdots & r_{1n}\\ 0 & r_{22} & \cdots & r_{2n}\\ \vdots & \vdots & \ddots & \vdots\\ 0 & \cdots & 0 & r_{nn}\end{bmatrix}$ | |
| $A=QR$ 的广义逆 $A^{+}=R^{+}Q^{+}=R^{-1}Q^{+}$ | $Q$ 的广义逆 $Q^{+}=Q^{\mathrm{T}}$ |
| $A=CR$ 的广义逆见 4.5节 | $A^{+}=R^{+}C^{+}=R^{\mathrm{T}}(C^{\mathrm{T}}AR^{\mathrm{T}})^{-1}C^{\mathrm{T}}$ |

### 习题 4.4

习题 1 ～ 25 关于正交的向量组和正交矩阵.

1. 以下各组向量是何种向量组？单位正交向量组、正交向量组、线性无关的向量组？

（1）$\begin{bmatrix}1\\0\end{bmatrix}$ 和 $\begin{bmatrix}-1\\1\end{bmatrix}$　　（2）$\begin{bmatrix}0.6\\0.8\end{bmatrix}$ 和 $\begin{bmatrix}0.4\\-0.3\end{bmatrix}$　　（3）$\begin{bmatrix}\cos\theta\\\sin\theta\end{bmatrix}$ 和 $\begin{bmatrix}-\sin\theta\\\cos\theta\end{bmatrix}$

2. 向量 $\begin{bmatrix}2 & 2 & -1\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}-1 & 2 & 2\end{bmatrix}^{\mathrm{T}}$ 正交. 它们除以各自的长度得到单位正交向量组 $q_1$、$q_2$. 排成矩阵 $Q=\begin{bmatrix}q_1 & q_2\end{bmatrix}$，计算矩阵乘法 $Q^{\mathrm{T}}Q$ 和 $QQ^{\mathrm{T}}$.

3.（1）若 $A$ 是列向量长度都等于 4 的列正交矩阵，$A^{\mathrm{T}}A$ 等于什么？

（2）若 $A$ 是列向量是长度分别等于 1、2、3 的列正交矩阵，$A^{\mathrm{T}}A$ 等于什么？

4. 分别举出符合下列各个条件的例子.

（1）矩阵 $Q$ 的列向量是单位正交向量组，但是 $Q^{\mathrm{T}}Q\neq I$.

（2）两个线性相关的正交向量.

（3）$\mathbb{R}^3$ 的一组标准正交基，且其中一个向量是 $q_1=\dfrac{1}{\sqrt{1}}\begin{bmatrix}1 & 1 & 1\end{bmatrix}^{\mathrm{T}}$.

5. 求平面 $x+y+2z=0$ 上的两个正交向量，并把它们单位化.

6. 若 $\boldsymbol{Q}_1$、$\boldsymbol{Q}_2$ 都是正交矩阵，证明：$\boldsymbol{Q}_1\boldsymbol{Q}_2$ 也是正交矩阵（利用正交矩阵的定义：$\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{Q}=\boldsymbol{I}$）.

7. 若 $\boldsymbol{Q}$ 的列向量单位正交，那么 $\boldsymbol{Q}\boldsymbol{x}=\boldsymbol{b}$ 的最小二乘解 $\hat{\boldsymbol{x}}$ 是什么？

8. 若 $\boldsymbol{q}_1$ 和 $\boldsymbol{q}_2$ 是 $\mathbb{R}^5$ 中正交的单位向量，对任意给定向量 $\boldsymbol{b}$，线性组合 _____$\boldsymbol{q}_1$ + _____$\boldsymbol{q}_2$ 和 $\boldsymbol{b}$ 距离最近.

9.（1）设 $\boldsymbol{Q}$ 以 $\boldsymbol{q}_1=\begin{bmatrix}0.8 & 0.6 & 0\end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{q}_2=\begin{bmatrix}-0.6 & 0.8 & 0\end{bmatrix}^{\mathrm{T}}$ 为列向量，计算 $\boldsymbol{P}=\boldsymbol{Q}\boldsymbol{Q}^{\mathrm{T}}$ 并验证 $\boldsymbol{P}^2=\boldsymbol{P}$.

（2）若 $\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{Q}=\boldsymbol{I}$，证明：$(\boldsymbol{Q}\boldsymbol{Q}^{\mathrm{T}})^2=\boldsymbol{Q}\boldsymbol{Q}^{\mathrm{T}}$. 由此继续证明：$\boldsymbol{P}=\boldsymbol{Q}\boldsymbol{Q}^{\mathrm{T}}$ 是正交投影到 $\boldsymbol{Q}$ 列空间的投影矩阵.

10. 本题将要从两个角度分别证明：单位正交向量组线性无关.

（1）从向量的角度证明. 设 $c_1\boldsymbol{q}_1+c_2\boldsymbol{q}_2+c_3\boldsymbol{q}_3=\boldsymbol{0}$，等式两边和哪个向量作点积可得 $c_1=0$？同理可证 $c_2=c_3=0$，由此得 $\boldsymbol{q}$ 线性无关.

（2）从矩阵的角度证明，设 $\boldsymbol{Q}\boldsymbol{x}=\boldsymbol{b}$，证明：$\boldsymbol{x}=\boldsymbol{0}$. 注意：$\boldsymbol{Q}$ 可能不是方阵，而是竖长形矩阵，所以 $\boldsymbol{Q}^{-1}$ 未必存在，但是可以利用 $\boldsymbol{Q}^{\mathrm{T}}$.

11.（1）格拉姆-施密特正交化：求 $\boldsymbol{a}=\begin{bmatrix}1 & 3 & 4 & 5 & 7\end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{b}=\begin{bmatrix}-6 & 6 & 8 & 0 & 8\end{bmatrix}^{\mathrm{T}}$ 张成的子空间的一组标准正交基 $\boldsymbol{q}_1$、$\boldsymbol{q}_2$.

（2）该平面上哪个向量和 $\begin{bmatrix}1 & 0 & 0 & 0 & 0\end{bmatrix}^{\mathrm{T}}$ 距离最近？

12. 若 $\boldsymbol{a}_1$、$\boldsymbol{a}_2$、$\boldsymbol{a}_3$ 是 $\mathbb{R}^3$ 的一组正交基，任意 $\boldsymbol{b}\in\mathbb{R}^3$ 都可以由这组基线性表出

$$\boldsymbol{b}=x_1\boldsymbol{a}_1+x_2\boldsymbol{a}_2+x_3\boldsymbol{a}_3,\qquad \text{或者写成}\qquad \boldsymbol{b}=\begin{bmatrix}\boldsymbol{a}_1 & \boldsymbol{a}_2 & \boldsymbol{a}_3\end{bmatrix}\begin{bmatrix}x_1\\x_2\\x_3\end{bmatrix},$$

证明：$x_1=\dfrac{\boldsymbol{a}_1^{\mathrm{T}}\boldsymbol{b}}{\boldsymbol{a}_1^{\mathrm{T}}\boldsymbol{a}_1}$.

13. 将 $\boldsymbol{b}=\begin{bmatrix}4\\0\end{bmatrix}$ 减去 $\boldsymbol{a}=\begin{bmatrix}1\\1\end{bmatrix}$ 的多少倍所得之差 $\boldsymbol{\beta}$ 与 $\boldsymbol{a}$ 正交？简要地画个示意图，表示出 $\boldsymbol{a},\boldsymbol{b}$ 和 $\boldsymbol{\beta}$.

14. 对上一题的 $\boldsymbol{a}$、$\boldsymbol{b}$ 使用完整的格拉姆-施密特正交化，计算 $\boldsymbol{q}_1=\boldsymbol{a}/\|\boldsymbol{a}\|$ 和 $\boldsymbol{q}_2=\boldsymbol{\beta}/\|\boldsymbol{\beta}\|$，并且写出 $\boldsymbol{Q}\boldsymbol{R}$ 分解：

$$\begin{bmatrix}1 & 4\\1 & 0\end{bmatrix}=\begin{bmatrix}\boldsymbol{q}_1 & \boldsymbol{q}_2\end{bmatrix}\begin{bmatrix}\|\boldsymbol{a}\| & ?\\0 & \|\boldsymbol{B}\|\end{bmatrix}.$$

15.（1）求 $\mathbb{R}^3$ 的一组标准正交基 $\boldsymbol{q}_1$、$\boldsymbol{q}_2$、$\boldsymbol{q}_3$，并且 $\boldsymbol{q}_1$、$\boldsymbol{q}_2$ 张成矩阵 $\boldsymbol{A}=\begin{bmatrix}1 & 1\\2 & -1\\-2 & 4\end{bmatrix}$ 的列空间.

（2）矩阵 $\boldsymbol{A}$ 四个基本子空间中的哪一个包含向量 $\boldsymbol{q}_3$？

（3）求方程组 $\boldsymbol{A}\boldsymbol{x}=\begin{bmatrix}1 & 2 & 7\end{bmatrix}^{\mathrm{T}}$ 的最小二乘解.

16. 向量 $\boldsymbol{a}=\begin{bmatrix}4 & 5 & 2 & 2\end{bmatrix}^{\mathrm{T}}$ 张成的直线上，哪个向量距离 $\boldsymbol{b}=\begin{bmatrix}1 & 2 & 0 & 0\end{bmatrix}^{\mathrm{T}}$ 最近？求 $\boldsymbol{a}$、$\boldsymbol{b}$ 所在平面上的两个单位正交的向量 $\boldsymbol{q}_1$、$\boldsymbol{q}_2$.

17. 对下述向量 $\boldsymbol{a}$、$\boldsymbol{b}$，求 $\boldsymbol{b}$ 到 $\boldsymbol{a}$ 的正交投影.

$$\boldsymbol{a}=\begin{bmatrix}1\\1\\1\end{bmatrix},\qquad \boldsymbol{b}=\begin{bmatrix}1\\3\\5\end{bmatrix},\qquad \boldsymbol{p}=?,\qquad \boldsymbol{e}=\boldsymbol{b}-\boldsymbol{p}=?$$

求单位正交向量组 $\boldsymbol{q}_1=\boldsymbol{a}/\|\boldsymbol{a}\|,\boldsymbol{q}_2=\boldsymbol{e}/\|\boldsymbol{e}\|$.

18.（推荐）对下列 $\boldsymbol{a}$、$\boldsymbol{b}$、$\boldsymbol{c}$ 使用格拉姆-施密特正交化，求正交向量组 $\boldsymbol{\alpha}$、$\boldsymbol{\beta}$、$\boldsymbol{\gamma}$.

$$\boldsymbol{a}=\begin{bmatrix}1\\-1\\0\\0\end{bmatrix},\qquad \boldsymbol{b}=\begin{bmatrix}0\\1\\-1\\0\end{bmatrix},\qquad \boldsymbol{a}=\begin{bmatrix}0\\0\\1\\-1\end{bmatrix}.$$

$\boldsymbol{\alpha}$、$\boldsymbol{\beta}$、$\boldsymbol{\gamma}$ 和 $\boldsymbol{a}$、$\boldsymbol{b}$、$\boldsymbol{c}$ 这两组向量都是 $\boldsymbol{d}=\begin{bmatrix}1 & 1 & 1 & 1\end{bmatrix}^{\mathrm{T}}$ 的正交补空间的基.

19. 如果 $\boldsymbol{A}=\boldsymbol{QR}$，则 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}=\boldsymbol{R}^{\mathrm{T}}\boldsymbol{R}=$_____ 三角矩阵乘以_____ 三角矩阵. 对 $\boldsymbol{A}$ 作格拉姆-施密特正交化对应于对 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 作消元法. $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 的主元是 $\boldsymbol{R}$ 的对角元的平方. 对下述矩阵 $\boldsymbol{A}$ 作格拉姆-施密特正交化，求 $\boldsymbol{Q}$ 和 $\boldsymbol{R}$.

$$\boldsymbol{A}=\begin{bmatrix}-1 & 1\\2 & 1\\2 & 4\end{bmatrix},\qquad \boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}=\begin{bmatrix}9 & 9\\9 & 18\end{bmatrix}=\begin{bmatrix}1 & 0\\1 & 1\end{bmatrix}\begin{bmatrix}9 & \\ & 9\end{bmatrix}\begin{bmatrix}1 & 1\\0 & 1\end{bmatrix}$$

20. 判断正误（错误给出反例；正确请简述理由，同时也举一例）.

（1）若 $\boldsymbol{Q}$ 是正交矩阵，则 $\boldsymbol{Q}^{-1}$ 也是正交矩阵.

（2）若 $3\times 2$ 矩阵 $\boldsymbol{Q}$ 的列向量单位正交，则 $\|\boldsymbol{Qx}\|=\|\boldsymbol{x}\|$ 对任意 $\boldsymbol{x}\in\mathbb{R}^2$ 均成立.

21. 对下面的矩阵 $\boldsymbol{A}$ 和向量 $\boldsymbol{b}$，求 $\boldsymbol{A}$ 列空间的一组标准正交基，以及 $\boldsymbol{b}$ 在 $\mathcal{C}(\boldsymbol{A})$ 上的正交投影.

$$\boldsymbol{A}=\begin{bmatrix}1 & -2\\1 & 0\\1 & 1\\1 & 3\end{bmatrix},\qquad \boldsymbol{b}=\begin{bmatrix}-4\\-3\\3\\0\end{bmatrix}$$

22. 对下面的向量组 $\boldsymbol{a}$、$\boldsymbol{b}$、$\boldsymbol{c}$，用格拉姆-施密特正交化求正交向量组 $\boldsymbol{\alpha}$、$\boldsymbol{\beta}$、$\boldsymbol{\gamma}$.

$$\boldsymbol{a}=\begin{bmatrix}1\\1\\2\end{bmatrix},\qquad \boldsymbol{b}=\begin{bmatrix}1\\-2\\0\end{bmatrix},\qquad \boldsymbol{c}=\begin{bmatrix}1\\0\\4\end{bmatrix}.$$

23. 求矩阵 $\boldsymbol{A}$ 列空间的一组标准正交基，并对它作 $\boldsymbol{QR}$ 分解

$$\boldsymbol{A}=\begin{bmatrix}1 & 2 & 4\\ 0 & 0 & 5\\ 0 & 3 & 6\end{bmatrix}.$$

24.（1）设 $S$ 是方程组 $x_1+x_2+x_3-x_4=0$ 的解空间，那么 $S\subseteq\mathbb{R}^4$，求 $S$ 的一组基.

（2）求 $S$ 的正交补空间 $S^{\perp}$ 的一组基.

（3）设 $\boldsymbol{b}=\begin{bmatrix}1 & 1 & 1 & 1\end{bmatrix}^{\mathrm{T}}$，求 $\boldsymbol{b}_1\in S,\boldsymbol{b}_2\in S^{\perp}$ 使得 $\boldsymbol{b}=\boldsymbol{b}_1+\boldsymbol{b}_2$.

25. 若 $ad-bc>0$，那么 $\boldsymbol{A}=\boldsymbol{QR}$ 的分解式为

$$\begin{bmatrix}a & b\\ c & d\end{bmatrix}=\frac{\begin{bmatrix}a & -c\\ c & a\end{bmatrix}}{\sqrt{a^2+c^2}}\frac{\begin{bmatrix}a^2+c^2 & ab+cd\\ 0 & ad-bc\end{bmatrix}}{\sqrt{a^2+c^2}}.$$

当 $a$、$b$、$c$、$d$ 分别取值 2、1、1、1 和 1、1、1、1 时，写出分解式 $\boldsymbol{A}=\boldsymbol{QR}$. 当 $\boldsymbol{A}$ 的列向量线性相关时，格拉姆-施密特正交化会中断，$\boldsymbol{R}$ 的哪些元素是 0?

习题 26 ~ 29 关于式(4.36)、格拉姆-施密特正交化以及 $\boldsymbol{QR}$ 分解的代码.

26. 证明：$\boldsymbol{\gamma}$（由 $\boldsymbol{\gamma}^*$ 执行一步式(4.36)的计算得到）和式(4.33)得到的向量 $\boldsymbol{\gamma}$ 相同.

27. 式(4.33)把 $\boldsymbol{c}$ 减去它在 $\boldsymbol{\alpha}$ 和 $\boldsymbol{\beta}$ 方向的分支. 为什么不直接减去它在 $\boldsymbol{a}$ 和 $\boldsymbol{b}$ 方向的分支呢?

28. 请分析式(4.36)中的 $mn^2$ 次乘法是如何使用的.

29. 将 MATLAB 中的 qr 命令应用于向量组 $\boldsymbol{a}=\begin{bmatrix}2 & 2 & -1\end{bmatrix}^{\mathrm{T}}$、$\boldsymbol{b}=\begin{bmatrix}0 & -3 & -3\end{bmatrix}^{\mathrm{T}}$、$\boldsymbol{c}=\begin{bmatrix}1 & 0 & 0\end{bmatrix}^{\mathrm{T}}$，求出向量组 $\boldsymbol{q}_1$、$\boldsymbol{q}_2$、$\boldsymbol{q}_3$.

习题 30 ~ 34 关于特殊的正交矩阵.

30. 如下小波矩阵 $\boldsymbol{W}$ 的列向量是前四个小波[①]：

$$\boldsymbol{W}=\frac{1}{2}\begin{bmatrix}1 & 1 & \sqrt{2} & 0\\ 1 & 1 & -\sqrt{2} & 0\\ 1 & -1 & 0 & \sqrt{2}\\ 1 & -1 & 0 & -\sqrt{2}\end{bmatrix}$$

$\boldsymbol{W}$ 的列向量有何特殊之处？求逆矩阵 $\boldsymbol{W}^{-1}$.

31. $c$ 等于多少时，如下矩阵 $\boldsymbol{Q}$ 是正交矩阵？

$$\boldsymbol{Q}=c\begin{bmatrix}1 & -1 & -1 & -1\\ -1 & 1 & -1 & -1\\ -1 & -1 & 1 & -1\\ -1 & -1 & -1 & 1\end{bmatrix}.$$

① 译者注：小波分析在信号处理中有广泛的应用；它和傅里叶分析的区别在于，傅里叶变换假设分析的信号是平稳的，也就是说频率不变；小波分析中的小波在时间上仅存在于某一个范围当中，通过对小波的平移及缩放，最终分析出原型中的频率成分；局部范围的信号也就是小波顾名思义的来源. 此处的小波矩阵 $\boldsymbol{W}$ 实际上是应用最为广泛的 Haar 小波矩阵.

求 $\boldsymbol{b}=\begin{bmatrix}1 & 1 & 1 & 1\end{bmatrix}^{\mathrm{T}}$ 到 $\boldsymbol{Q}$ 的第一个列的正交投影，再求 $\boldsymbol{b}$ 到 $\boldsymbol{Q}$ 前两列张成的平面的正交投影.

32. 若 $\boldsymbol{u}$ 是单位向量，$\boldsymbol{Q}=\boldsymbol{I}-2\boldsymbol{u}\boldsymbol{u}^{\mathrm{T}}$ 是反射矩阵（见例 4.13）. 若 $\boldsymbol{u}_1=\begin{bmatrix}0 & 1\end{bmatrix}^{\mathrm{T}}$，求 $\boldsymbol{Q}_1=\boldsymbol{I}-2\boldsymbol{u}_1\boldsymbol{u}_1^{\mathrm{T}}$；若 $\boldsymbol{u}_2=\begin{bmatrix}0 & \sqrt{2}/2 & \sqrt{2}/2\end{bmatrix}^{\mathrm{T}}$，求 $\boldsymbol{Q}_2=\boldsymbol{I}-2\boldsymbol{u}_2\boldsymbol{u}_2^{\mathrm{T}}$. 分别画出 $\boldsymbol{Q}_1$ 乘向量 $\begin{bmatrix}1 & 2\end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{Q}_2$ 乘向量 $\begin{bmatrix}1 & 1 & 1\end{bmatrix}^{\mathrm{T}}$ 的示意图.

33. 求出所有下三角的正交矩阵.

34. 当 $\boldsymbol{u}^{\mathrm{T}}\boldsymbol{u}=1$ 时，$\boldsymbol{Q}=\boldsymbol{I}-2\boldsymbol{u}\boldsymbol{u}^{\mathrm{T}}$ 是反射矩阵. 反射两次保持任何向量不变，因此 $\boldsymbol{Q}^2=\boldsymbol{I}$.

（1）证明：$\boldsymbol{Q}\boldsymbol{u}=-\boldsymbol{u}$. 反射面和 $\boldsymbol{u}$ 正交.

（2）若 $\boldsymbol{u}^{\mathrm{T}}\boldsymbol{v}=0$，$\boldsymbol{Q}\boldsymbol{v}$ 等于什么？反射面由满足 $\boldsymbol{u}^{\mathrm{T}}\boldsymbol{v}=0$ 的 $\boldsymbol{v}$ 构成，因此反射矩阵保持反射面不动.

## 挑 战 一 下

35. 用 MATLAB 命令作分解：$[\boldsymbol{Q},\boldsymbol{R}]=\mathrm{qr}(\boldsymbol{A})$，其中 $\boldsymbol{A}=\mathrm{eye}(4)-\mathrm{diag}([1\quad 1\quad 1],-1)$. 这个命令实际上在正交化 $\boldsymbol{A}$ 的列向量 $\begin{bmatrix}1 & -1 & 0 & 0\end{bmatrix}^{\mathrm{T}}$、$\begin{bmatrix}0 & 1 & -1 & 0\end{bmatrix}^{\mathrm{T}}$、$\begin{bmatrix}0 & 0 & 1 & -1\end{bmatrix}^{\mathrm{T}}$、$\begin{bmatrix}0 & 0 & 0 & 1\end{bmatrix}^{\mathrm{T}}$. 能否把 $\boldsymbol{Q}$ 的列向量乘以某个倍数，使得分量是更为整齐的整数？

36. 若 $\boldsymbol{A}$ 是 $m\times n$ 的列满秩矩阵，那么 MATLAB 命令 $\mathrm{qr}(\boldsymbol{A})$ 构造了正交矩阵 $\boldsymbol{Q}$ 和行阶梯形矩阵 $\boldsymbol{R}$:

$$\text{分解式为}(m\times m)(m\times n)\qquad \boldsymbol{A}=\begin{bmatrix}\boldsymbol{Q}_1 & \boldsymbol{Q}_2\end{bmatrix}\begin{bmatrix}\boldsymbol{R}\\ \boldsymbol{0}\end{bmatrix}.$$

$m\times n$ 矩阵 $\boldsymbol{Q}_1$ 的列向量是哪一个基本子空间的标准正交基？$\boldsymbol{Q}_2$ 的列向量是哪一个基本子空间的标准正交基？

37. 设 $\boldsymbol{Q}$ 是 $m\times n$ 列正交矩阵，我们知道 $\boldsymbol{P}=\boldsymbol{Q}\boldsymbol{Q}^{\mathrm{T}}$ 是到 $\boldsymbol{Q}$ 列空间的正交投影矩阵. 增加一个列向量 $\boldsymbol{a}$，令 $\boldsymbol{A}=\begin{bmatrix}\boldsymbol{Q} & \boldsymbol{a}\end{bmatrix}$. 根据格拉姆-施密特正交化，由 $\boldsymbol{a}$ 得到的向量 $\boldsymbol{q}$ 是什么？把 $\boldsymbol{a}$ 减去_____，再除以_____ 即得 $\boldsymbol{q}$.

## 4.5 矩阵的广义逆

| 秩 | $r=m=n=2$ | $r=m<n=3$ | $r=n<m=3$ |
|---|---|---|---|
| | $\boldsymbol{I}=\begin{bmatrix}1 & 0\\ 0 & 1\end{bmatrix}$ | $\boldsymbol{I}_L=\begin{bmatrix}1 & 0 & 0\\ 0 & 1 & 0\end{bmatrix}$ | $\boldsymbol{I}_R=\begin{bmatrix}1 & 0\\ 0 & 1\\ 0 & 0\end{bmatrix}$ |
| | $\boldsymbol{I}=\boldsymbol{I}$ 的逆 | $\boldsymbol{I}_L=\boldsymbol{I}_R$ 的左逆 | $(\boldsymbol{I}_L)(\boldsymbol{I}_R)=\boldsymbol{I}$ |
| | $(\boldsymbol{I})(\boldsymbol{I})=\boldsymbol{I}$ | $\boldsymbol{I}_R=\boldsymbol{I}_L$ 的右逆 | $(\boldsymbol{I}_R)(\boldsymbol{I}_L)\neq\boldsymbol{I}$ |

只有第一个矩阵 $\boldsymbol{I}$ 才是真的可逆矩阵，$\boldsymbol{I}_L$ 和 $\boldsymbol{I}_R$ 都只有单边逆，并不是可逆矩阵. 任意矩阵 $\boldsymbol{A}$ 都存在广义逆 $\boldsymbol{A}^+$. 这个广义逆既关乎左逆，也关乎右逆. 我们先开门见山地总结罗列关于单边逆的知识.

| | |
|---|---|
| $\boldsymbol{A}$ 有左逆，则 $\boldsymbol{A}^+\boldsymbol{A}=\boldsymbol{I}$ | $\boldsymbol{A}$ 有右逆，则 $\boldsymbol{A}\boldsymbol{A}^+=\boldsymbol{I}$ |
| $\boldsymbol{A}$ 列向量线性无关 | $\boldsymbol{A}$ 行向量线性无关 |
| $\boldsymbol{A}$ 是竖长形矩阵：rank　$r=n$ | $\boldsymbol{A}$ 是扁宽形矩阵：rank　$r=m$ |
| 方程组 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 要么无解，要么有唯一解 | 方程组 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 要么有唯一解，要么有无穷多解 |
| 零空间 $\mathcal{N}(\boldsymbol{A})=\{\boldsymbol{0}\}$ | 左零空间 $\mathcal{N}(\boldsymbol{A}^{\mathrm{T}})=\{\boldsymbol{0}\}$ |
| $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 是 $n\times n$可逆矩阵 | $\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 是 $m\times m$可逆矩阵 |
| $\boldsymbol{A}$ 的左逆为 $\boldsymbol{A}^+=(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1}\boldsymbol{A}^{\mathrm{T}}$ | $\boldsymbol{A}$ 的右逆为 $\boldsymbol{A}^+=\boldsymbol{A}^{\mathrm{T}}(\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}})^{-1}$ |

左侧那列，即 $\boldsymbol{A}^+\boldsymbol{A}=\boldsymbol{I}$，刻画了最小二乘法涉及的矩阵. 秩 $r=n<m$，$m$ 个方程的方程组 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 可能无解，其原因是方程太多了. 那么 $\hat{\boldsymbol{x}}=\boldsymbol{A}^+\boldsymbol{b}$ 是方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$ 的解，且误差项 $\boldsymbol{e}=\boldsymbol{b}-\boldsymbol{A}\hat{\boldsymbol{x}}$ 取到最小值，这就是所谓的最小二乘解.

右侧那列，即 $\boldsymbol{A}\boldsymbol{A}^+=\boldsymbol{I}$，刻画了相反的问题. 此时矩阵的秩 $r=m<n$ 且方程组 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 有无穷多解. 此时，$\boldsymbol{x}^+=\boldsymbol{A}^+\boldsymbol{b}$ 是方程组 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$长度最短的解. 它属于 $\boldsymbol{A}$ 的行空间，且其他任意解都形如 $\boldsymbol{x}=\boldsymbol{x}^++\boldsymbol{x}_n$，其中 $\boldsymbol{x}_n\in\mathcal{N}(\boldsymbol{A})$，而正是 $\boldsymbol{x}_n$ 这项让 $\boldsymbol{x}$ 长度变大.

若 $\boldsymbol{A}$ 不属于这两种情况，也就是说 $r<m$ 且 $r<n$ 时，你对结果有怎样的期待？此时左逆和右逆都不存在. 但是，$\boldsymbol{A}$ 的广义逆 $\boldsymbol{A}^+$（接下来会介绍）给出向量 $\boldsymbol{x}^+=\boldsymbol{A}^+\boldsymbol{b}$，该向量满足：$\|\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}\|^2$ 在 $\boldsymbol{x}=\boldsymbol{x}^+$ 处取最小值. 同时，任意向量 $\boldsymbol{x}=\boldsymbol{x}^++\boldsymbol{x}_n(\boldsymbol{x}_n\in\mathcal{N}(\boldsymbol{A}))$ 都给出相同的误差项，而 $\boldsymbol{x}^+$ 是其中长度最小的. 简而言之，

$$\boldsymbol{x}^+ \text{ 是方程组 } \boldsymbol{A}\boldsymbol{x}=\boldsymbol{b} \text{ 的最短最小二乘解.}$$

严格地，也可以如下表述. 令

$$d=\min\left\{\|\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}\|^2:\boldsymbol{x}\in\mathbb{R}^n\right\},\quad S=\{\boldsymbol{x}\in\mathbb{R}^n:\|\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}\|^2=d\},$$

则

$$\boldsymbol{x}^+\in S \text{ 且对任意 } \boldsymbol{x}\in S \text{ 均有 } \|\boldsymbol{x}^+\|\leqslant\|\boldsymbol{x}\|.$$

根本原因是 $\boldsymbol{x}^+$ 的零空间分支是 $\boldsymbol{0}$. 若 $\boldsymbol{A}$ 的列向量线性无关，相关的内容已经学习得很充分了；而当 $\boldsymbol{A}$ 的列向量线性相关时，必须引入 $\boldsymbol{A}^+$. 本节在教学和学生自学时，并不是必需的内容，可以随机应变. 但是把这块内容安排在这里，整体编排是很合适的. 我们可以用矩阵的四个基本子空间来解释广义逆 $\boldsymbol{A}^+$，实际计算时也可以借助满秩分解 $\boldsymbol{A}=\boldsymbol{C}\boldsymbol{R}$、$\boldsymbol{Q}\boldsymbol{R}$ 分解 $\boldsymbol{A}=\boldsymbol{Q}\boldsymbol{R}$ 又或者 SVD 分解.

### 4.5.1　$m\times n$ 矩阵 $\boldsymbol{A}$ 的广义逆 $\boldsymbol{A}^+$（$n\times m$ 矩阵）

任意 $\boldsymbol{y}\in\mathbb{R}^m$ 可以分解为正交的两部分之和 $\boldsymbol{y}=\boldsymbol{b}+\boldsymbol{z}$，其中 $\boldsymbol{b}\in\mathcal{C}(\mathrm{A}),\boldsymbol{z}\in\mathcal{N}(\mathrm{A}^{\mathrm{T}}):\boldsymbol{A}^{\mathrm{T}}\boldsymbol{z}=\boldsymbol{0}$ 且 $\boldsymbol{A}^+\boldsymbol{z}=\boldsymbol{0}$.

$\boldsymbol{A}$ 行空间中存在唯一一个向量 $\boldsymbol{x}$ 满足 $\boldsymbol{Ax}=\boldsymbol{b}$；这一步也可逆：$\boldsymbol{A}^{+}\boldsymbol{b}=\boldsymbol{x}$.

$$\boxed{\boldsymbol{A}\text{ 的广义逆 }\boldsymbol{A}^{+}\text{ 满足：}\boldsymbol{A}^{+}\boldsymbol{b}=\boldsymbol{x}\quad\boldsymbol{A}^{+}\boldsymbol{z}=\boldsymbol{0}\quad\boldsymbol{A}^{+}\boldsymbol{y}=\boldsymbol{A}^{+}\boldsymbol{b}+\boldsymbol{A}^{+}\boldsymbol{z}=\boldsymbol{x}}$$

借助四个基本子空间（见图 4.11），我们可以画出 $\boldsymbol{A}^{+}$ 的整体图景. 注意到：$\boldsymbol{A}^{+}$ 和 $\boldsymbol{A}^{\mathrm{T}}$ 的四个基本子空间均相同，而两者区别在于 $\boldsymbol{A}^{+}\boldsymbol{A}$ 把 $\boldsymbol{A}$ 行空间中的向量 $\boldsymbol{x}$ 映到自身. 事实上，$\boldsymbol{A}^{+}\boldsymbol{A}$ 是 $\mathbb{R}^{n}$ 到 $\boldsymbol{A}$ 的行空间的正交投影矩阵 $\boldsymbol{P}_{\text{行}}$（$n\times n$ 矩阵）. 对称地，$\boldsymbol{AA}^{+}$ 是 $\mathbb{R}^{m}$ 到 $\boldsymbol{A}$ 的列空间的正交投影矩阵 $\boldsymbol{P}_{\text{列}}$（$m\times m$ 矩阵）. 当 $\boldsymbol{A}$ 可逆时，$\boldsymbol{A}^{+}$ 也可逆，$\boldsymbol{A}^{+}$ 可以视作从 $\boldsymbol{A}$ 的列空间到 $\boldsymbol{A}$ 的行空间的线性映射.

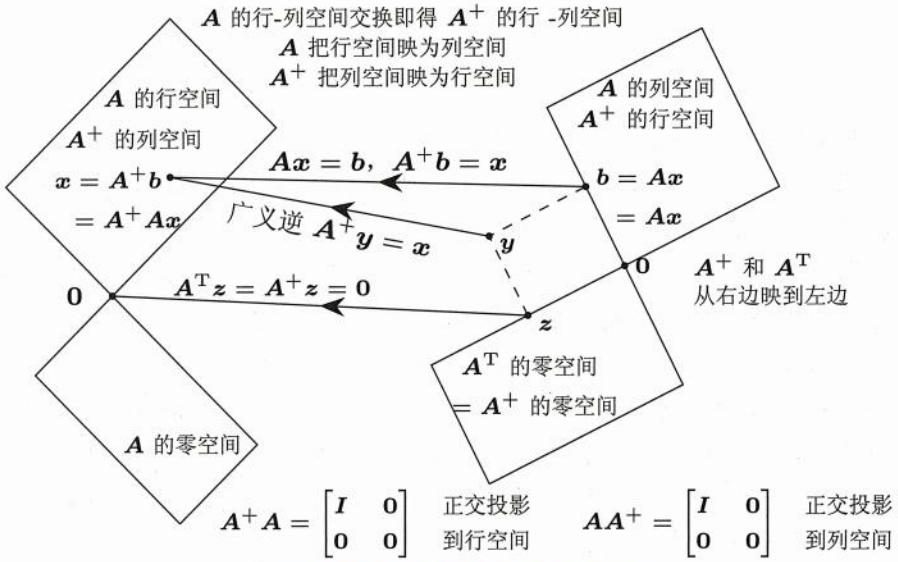


图 4.11 四个基本子空间和广义逆

注：$\boldsymbol{A}$ 列空间中的向量 $\boldsymbol{b}=\boldsymbol{Ax}$ 反解出行空间中的向量 $\boldsymbol{x}=\boldsymbol{A}^{+}\boldsymbol{b}$.

对任意 $\boldsymbol{y}$ 和分解式 $\boldsymbol{y}=\boldsymbol{b}+\boldsymbol{z}(\boldsymbol{b}\in\mathcal{C}(\boldsymbol{A}),\boldsymbol{z}\in\mathcal{N}(\boldsymbol{A}^{\mathrm{T}}))$，因为 $\boldsymbol{A}^{+}\boldsymbol{z}=\boldsymbol{0}$，所以都可以反解出 $\boldsymbol{x}=\boldsymbol{A}^{+}\boldsymbol{b}$，从而 $(\boldsymbol{A}^{+}\boldsymbol{A})^{2}=\boldsymbol{A}^{+}\boldsymbol{A}$.

Moore 提出了广义逆，随后 Penrose（2020 年诺贝尔物理学奖获得者）再次提出 $\boldsymbol{A}^{+}$. 基于广义逆 $\boldsymbol{A}^{+}$，我们可以构造出到 $\boldsymbol{A}$ 的行空间和列空间的正交投影矩阵 $\boldsymbol{P}_{\text{行}}$ 和 $\boldsymbol{P}_{\text{列}}$：

$$\boxed{\boldsymbol{P}_{\text{行}}=\boldsymbol{A}^{+}\boldsymbol{A}=(\boldsymbol{A}^{+}\boldsymbol{A})^{2}=(\boldsymbol{A}^{+}\boldsymbol{A})^{\mathrm{T}},\qquad\boldsymbol{P}_{\text{列}}=\boldsymbol{AA}^{+}=(\boldsymbol{AA}^{+})^{2}=(\boldsymbol{AA}^{+})^{\mathrm{T}}.}$$

这些性质对我们用满秩分解 $\boldsymbol{A}=\boldsymbol{CR}$ 或者 $\boldsymbol{QR}$ 分解 $\boldsymbol{A}=\boldsymbol{QR}$ 计算 $\boldsymbol{A}^{+}$ 相当有用.

**例 4.15** 设 $\boldsymbol{A}=\begin{bmatrix}2&0\\0&0\end{bmatrix},\boldsymbol{y}=\begin{bmatrix}y_1\\0\end{bmatrix}+\begin{bmatrix}0\\y_2\end{bmatrix}=\boldsymbol{b}+\boldsymbol{z}.$

$$\boldsymbol{b}=\begin{bmatrix}y_1\\0\end{bmatrix}\text{ 属于 }\boldsymbol{A}\text{ 的列空间}\qquad\boldsymbol{Ax}=\boldsymbol{b}\text{ 即 }\begin{bmatrix}2&0\\0&0\end{bmatrix}\begin{bmatrix}y_1/2\\0\end{bmatrix}=\begin{bmatrix}y_1\\0\end{bmatrix}$$

$$\boldsymbol{z}=\begin{bmatrix}0\\y_2\end{bmatrix}\text{ 属于 }\boldsymbol{A}^{\mathrm{T}}\text{ 的零空间}\qquad\boldsymbol{A}^{\mathrm{T}}\boldsymbol{z}=\boldsymbol{0}\text{ 即 }\begin{bmatrix}2&0\\0&0\end{bmatrix}\begin{bmatrix}0\\y_2\end{bmatrix}=\begin{bmatrix}0\\0\end{bmatrix}$$

$\boldsymbol{A}^{+}\boldsymbol{y}=\boldsymbol{A}^{+}\boldsymbol{b}+\boldsymbol{A}^{+}\boldsymbol{z}=\boldsymbol{x}+\boldsymbol{0}=\begin{bmatrix}y_1/2\\0\end{bmatrix}$. 于是 $\boldsymbol{A}^{+}=\begin{bmatrix}1/2&0\\0&0\end{bmatrix}$，且 $\boldsymbol{A}^{+}\boldsymbol{A}=\begin{bmatrix}1&0\\0&0\end{bmatrix}$.

这个例子可以推广到任意对角矩阵 $\boldsymbol{D}$，这是简单而又非常有用的情形：①

$$\boldsymbol{D}=\begin{bmatrix}2&0&0\\0&3&0\\0&0&0\end{bmatrix}\text{ 的广义逆为 }\boldsymbol{D}^{+}=\begin{bmatrix}1/2&0&0\\0&1/3&0\\0&0&0\end{bmatrix}.$$

非零对角元的取倒数，零对角元不能取倒数，那就不变，还是令其为 0. 若 $\boldsymbol{D}$ 有更多的零行（零列），那么 $\boldsymbol{D}^{+}$ 有更多的零列（零行）.②

结论还可以进一步推广，从对角矩阵 $\boldsymbol{D}$ 推广到任意矩阵 $\boldsymbol{A}=\boldsymbol{BDC}$，其中 $\boldsymbol{B}$、$\boldsymbol{C}$ 都是可逆矩阵. 此时 $\boldsymbol{A}^{+}=\boldsymbol{C}^{-1}\boldsymbol{D}^{+}\boldsymbol{B}^{-1}$. 我们可以对 $\boldsymbol{B}$ 和 $\boldsymbol{C}$ 取逆，但是不能对 $\boldsymbol{D}$ 中零元素取逆. 若 $\boldsymbol{D}$ 是可逆矩阵，$\boldsymbol{A}$ 也可逆，于是可以对 $\boldsymbol{A}$ 取逆矩阵；把取逆的表达式和广义逆的公式作对比，可以发现 $\boldsymbol{A}^{+}$ 取代了 $\boldsymbol{A}^{-1}$，$\boldsymbol{D}^{+}$ 取代了 $\boldsymbol{D}^{-1}$.③

$\boldsymbol{A}=\begin{bmatrix}1\\1\end{bmatrix}$ 的广义逆是它的左逆 $\boldsymbol{A}^{+}=\frac{1}{2}\begin{bmatrix}1&1\end{bmatrix}$.

$\boldsymbol{A}=\begin{bmatrix}1&1\end{bmatrix}$ 的广义逆是它的右逆 $\boldsymbol{A}^{+}=\frac{1}{2}\begin{bmatrix}1\\1\end{bmatrix}$.

很多矩阵 $\boldsymbol{A}$ 都没有满足 $\boldsymbol{AA}^{-1}=\boldsymbol{A}^{-1}\boldsymbol{A}=\boldsymbol{I}$ 的逆矩阵 $\boldsymbol{A}^{-1}$. 逆矩阵是行向量和列向量都线性无关的方阵的专属. 若 $\boldsymbol{A}$ 可逆，则 $\boldsymbol{A}$ 和 $\boldsymbol{A}^{\mathrm{T}}$ 的零空间都只包含零向量.

本章前几节处理了列满秩的竖长形矩阵（$m>n$）. 矩阵的秩 $r=n$. 零空间 $\mathcal{N}(\boldsymbol{A})$ 只包含零向量. $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 是 $n\times n$ 可逆矩阵. 在这种情况下，$\boldsymbol{A}^{+}=(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1}\boldsymbol{A}^{\mathrm{T}}$ 是 $\boldsymbol{A}$ 的左逆.

$$\boldsymbol{A}^{+}\boldsymbol{A}=(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1}\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}=\boldsymbol{I},\text{ 但是}\boldsymbol{AA}^{+}\neq\boldsymbol{I}. \tag{4.38}$$

另一种情形是行满秩的扁宽形矩阵，$\boldsymbol{A}$ 的秩 $r=m$，左零空间 $\mathcal{N}(\boldsymbol{A}^{\mathrm{T}})$ 只包含零向量. $\boldsymbol{AA}^{\mathrm{T}}$ 是 $m\times m$ 可逆矩阵. 在这种情况下，$\boldsymbol{A}^{+}=\boldsymbol{A}^{\mathrm{T}}(\boldsymbol{AA}^{\mathrm{T}})^{-1}$ 是 $\boldsymbol{A}$ 的右逆.

$$\boldsymbol{AA}^{+}=\boldsymbol{AA}^{\mathrm{T}}(\boldsymbol{AA}^{\mathrm{T}})^{-1}=\boldsymbol{I},\text{ 但是}\boldsymbol{A}^{+}\boldsymbol{A}\neq\boldsymbol{I}. \tag{4.39}$$

---

① 译者注：对于非方阵，情况也类似，例如 $\boldsymbol{A}=\begin{bmatrix}2&0\\0&0\\0&0\end{bmatrix}$ 的广义逆为 $\begin{bmatrix}1/2&0&0\\0&0&0\end{bmatrix}$.

② 译者注：如果给对角矩阵增加零行或者零列，那就不是方阵了. 译者觉得有必要说明把这类矩阵也称作“对角矩阵”的原因和背后的含义. 若 $m>n$ 且 $\boldsymbol{D}$ 是 $n$ 阶方阵，则 $m\times n$ 矩阵 $\boldsymbol{A}=\begin{bmatrix}\boldsymbol{D}\\\boldsymbol{0}_{(m-n)\times n}\end{bmatrix}$ 也被称作对角矩阵，而 $\boldsymbol{A}^{+}=\begin{bmatrix}\boldsymbol{D}^{+}&\boldsymbol{0}_{n\times(n-m)}\end{bmatrix}$. 类似地，若 $m<n$ 且 $\boldsymbol{D}$ 是 $m$ 阶对角方阵，则 $m\times n$ 矩阵 $\boldsymbol{A}=\begin{bmatrix}\boldsymbol{D}&\boldsymbol{0}_{m\times(n-m)}\end{bmatrix}$ 也被称作对角矩阵，而 $\boldsymbol{A}^{+}=\begin{bmatrix}\boldsymbol{D}^{+}\\\boldsymbol{0}_{(n-m)\times m}\end{bmatrix}$.

③ 译者注：这一段原作者论述疑似有误，以下面的列向量 $\boldsymbol{A}=\begin{bmatrix}1\\1\end{bmatrix}$ 为例，那么 $\boldsymbol{A}=\begin{bmatrix}1&0\\1&1\end{bmatrix}\begin{bmatrix}1\\0\end{bmatrix}$. 如果此处的论述正确，则 $\boldsymbol{A}^{+}=\begin{bmatrix}1\\0\end{bmatrix}^{+}\begin{bmatrix}1&0\\1&1\end{bmatrix}^{-1}=\begin{bmatrix}1&0\end{bmatrix}\begin{bmatrix}1&0\\-1&1\end{bmatrix}=\begin{bmatrix}1&0\end{bmatrix}$，该结论是错误的. 当 $\boldsymbol{B}$、$\boldsymbol{C}$ 都是正交矩阵时，结论成立，这是用 SVD 分解求广义逆的方法.

### 4.5.2 $A$ 的重要作用是把行空间映射成列空间

这里我们介绍矩阵的行空间和列空间的一个重点. 我们知道这两个空间有相同的维数 $r$（矩阵的秩），显然这不是全部. 我想我们至少还应该知道：如果 $\boldsymbol{x}$ 和 $\boldsymbol{y}$ 是行空间中两个不同的向量，则 $\boldsymbol{Ax} \neq \boldsymbol{Ay}$. 而且，对任意向量 $\boldsymbol{b} \in \mathcal{C}(\boldsymbol{A})$，都存在唯一一个向量 $\boldsymbol{x} \in \mathcal{C}(\boldsymbol{A}^{\mathrm{T}})$ 使得 $\boldsymbol{b} = \boldsymbol{Ax}$，事实上，该向量是 $\boldsymbol{x} = \boldsymbol{A}^{+}\boldsymbol{b}$.

证明是容易的. 存在性实际上已经证明过了：对任意 $\boldsymbol{b} \in \mathcal{C}(\boldsymbol{A})$，都存在 $\boldsymbol{x} \in \mathbb{R}^n$ 使得 $\boldsymbol{b} = \boldsymbol{Ax}$；$\boldsymbol{x}$ 可以分解为 $\boldsymbol{x} = \boldsymbol{x}_r + \boldsymbol{x}_n$，其中 $\boldsymbol{x}_r \in \mathcal{C}(\boldsymbol{A}^{\mathrm{T}}), \boldsymbol{x}_n \in \mathcal{N}(\boldsymbol{A})$，则 $\boldsymbol{b} = \boldsymbol{Ax}_r$. 还需要验证唯一性. 假设 $\boldsymbol{Ax} = \boldsymbol{Ay} = \boldsymbol{b}$，则 $\boldsymbol{A}(\boldsymbol{x} - \boldsymbol{y}) = \boldsymbol{0}$，即 $\boldsymbol{x} - \boldsymbol{y} \in \mathcal{N}(\boldsymbol{A})$；而 $\boldsymbol{x} - \boldsymbol{y}$ 又属于 $\mathcal{C}(\boldsymbol{A}^{\mathrm{T}})$，我们知道 $\mathcal{N}(\boldsymbol{A})$ 和 $\mathcal{C}(\boldsymbol{A}^{\mathrm{T}})$ 正交，所以 $\boldsymbol{x} - \boldsymbol{y} = \boldsymbol{0}$.

也可以从另一个角度解释这个想法. 假设 $\boldsymbol{x}_1, \boldsymbol{x}_2, \cdots, \boldsymbol{x}_r$ 是 $\boldsymbol{A}$ 行空间的一组基，那么 $\boldsymbol{Ax}_1, \boldsymbol{Ax}_2, \cdots, \boldsymbol{Ax}_r$ 是列空间的一组基. 这得益于两个空间维数都是 $r$——这是第 1 章的重要事实. 同样是第 1 章中学习的满秩分解 $\boldsymbol{A} = \boldsymbol{CR}$（在第 3 章通过消元法证明），现在将发挥作用，帮助我们求出 $\boldsymbol{A}$ 的广义逆 $\boldsymbol{A}^{+}$：

> 矩阵 $\boldsymbol{C}$ 是由 $\boldsymbol{A}$ 的前 $r$ 个线性无关的列向量组成的列满秩矩阵，$\boldsymbol{R}$ 是行向量线性无关的 $r \times n$ 矩阵，可以通过 $\boldsymbol{A}$ 的最简行阶梯形矩阵得到. 于是 $\boldsymbol{A} = \boldsymbol{CR}$，求广义逆可得 $\boldsymbol{A}^{+} = \boldsymbol{R}^{+}\boldsymbol{C}^{+}$.

### 4.5.3 $A = CR$ 的广义逆 $A^{+} = R^{+}C^{+}$

[①] 此时，我们使用 $\boldsymbol{C}$ 和 $\boldsymbol{R}$ 的单边逆. 再次强调，$\boldsymbol{C}$ 有 $r$ 个线性无关的列向量，$\boldsymbol{R}$ 有 $r$ 个线性无关的行向量. 因此，$\boldsymbol{C}^{\mathrm{T}}\boldsymbol{C}$ 和 $\boldsymbol{RR}^{\mathrm{T}}$ 是可逆的 $r$ 阶方阵. $\boldsymbol{C}$ 和 $\boldsymbol{R}$ 的广义逆就是它们的单边逆：$\boldsymbol{C}^{+}\boldsymbol{C} = \boldsymbol{I}, \boldsymbol{RR}^{+} = \boldsymbol{I}$.

$$\boldsymbol{C}^{+} = (\boldsymbol{C}^{\mathrm{T}}\boldsymbol{C})^{-1}\boldsymbol{C}^{\mathrm{T}} \qquad \boldsymbol{R}^{+} = \boldsymbol{R}^{\mathrm{T}}(\boldsymbol{RR}^{\mathrm{T}})^{-1} \tag{4.40}$$

幸运的是，$\boldsymbol{C}$ 的左逆和 $\boldsymbol{R}$ 的右逆以 $\boldsymbol{R}^{+}\boldsymbol{C}^{+}$ 的顺序组合在一起，正确地拼凑出 $\boldsymbol{A} = \boldsymbol{CR}$ 的广义逆. 这是关键事实！请参见习题 10.

$$\begin{aligned} \text{广义逆} \quad \boldsymbol{A}^{+} &= \boldsymbol{R}^{+}\boldsymbol{C}^{+} \\ &= \boldsymbol{R}^{\mathrm{T}}(\boldsymbol{RR}^{\mathrm{T}})^{-1}(\boldsymbol{C}^{\mathrm{T}}\boldsymbol{C})^{-1}\boldsymbol{C}^{\mathrm{T}} \\ &= \boldsymbol{R}^{\mathrm{T}}(\boldsymbol{C}^{\mathrm{T}}\boldsymbol{CRR}^{\mathrm{T}})^{-1}\boldsymbol{C}^{\mathrm{T}} \\ &= \boldsymbol{R}^{\mathrm{T}}(\boldsymbol{C}^{\mathrm{T}}\boldsymbol{AR}^{\mathrm{T}})^{-1}\boldsymbol{C}^{\mathrm{T}} \end{aligned} \tag{4.41}$$

我觉得有必要为这些相互契合的事实给出简略的证明. 证明要点也多次提过，当 $\boldsymbol{C}$ 的列向量线性无关且 $\boldsymbol{R}$ 的行向量线性无关时，$\boldsymbol{C}^{\mathrm{T}}\boldsymbol{C}$ 和 $\boldsymbol{RR}^{\mathrm{T}}$ 是可逆的.

① 译者注：广义逆对于满秩分解有乘性，但这并不意味着广义逆对矩阵乘法有类似于可逆矩阵取逆那样的乘性，换言之，若 $\boldsymbol{A} = \boldsymbol{BC}$，那么 $\boldsymbol{A}^{+} = \boldsymbol{C}^{+}\boldsymbol{B}^{+}$ 一般来说是不成立的.

注：此处，我们基于矩阵的四个基本子空间来解释广义逆 $\boldsymbol{A}^+$，但是 Moore 和 Penrose 用的是另一种方法. Penrose 用矩阵 $\boldsymbol{A}^+$ 必须满足的性质完全刻画 $\boldsymbol{A}^+$——这些条件可以完全确定矩阵 $\boldsymbol{A}^+$，并且和我们给出的广义逆相同.

$$\boldsymbol{A}\boldsymbol{A}^+\boldsymbol{A}=\boldsymbol{A} \qquad \boldsymbol{A}^+\boldsymbol{A}\boldsymbol{A}^+=\boldsymbol{A}^+ \qquad (\boldsymbol{A}^+\boldsymbol{A})^{\mathrm{T}}=\boldsymbol{A}^+\boldsymbol{A} \qquad (\boldsymbol{A}\boldsymbol{A}^+)^{\mathrm{T}}=\boldsymbol{A}\boldsymbol{A}^+ \tag{4.42}$$

由这些刻画性质也可以得知，$\boldsymbol{A}^+\boldsymbol{A}$ 和 $\boldsymbol{A}\boldsymbol{A}^+$ 分别是全空间到 $\boldsymbol{A}$ 的行空间和列空间的正交投影矩阵.

注：线性代数相当一部分精力要花在针对一些特殊性质而选择合适的基. 相对而言，正交性是非常好的性质：基中的向量两两正交. 第 7 章的主要结论就是对任意矩阵 $\boldsymbol{A}$ 构造著名的“奇异向量”，它们是行空间的标准正交基 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_r$，同时使得 $\boldsymbol{A}\boldsymbol{v}_1,\boldsymbol{A}\boldsymbol{v}_2,\cdots,\boldsymbol{A}\boldsymbol{v}_r$ 是列空间的标准正交基——这是数学之美在线性代数中的完美体现!

无论是从满秩分解 $\boldsymbol{A}^+=\boldsymbol{C}\boldsymbol{R}$，还是 $\boldsymbol{Q}\boldsymbol{R}$ 分解 $\boldsymbol{A}=\boldsymbol{Q}\boldsymbol{R}$，抑或是 SVD 分解 $\boldsymbol{A}=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\mathrm{T}}$，我们都得到相同的广义逆.

### 4.5.4　广义逆的例子——$A$ 是图的关联矩阵

3.5 节中提到的 $m\times n$ 关联矩阵，行对应于图的边，列对应于图的顶点. 第 $i$ 行有两个非零值，$-1$ 和 1，表示第 $i$ 条边的出发节点和到达节点. 流量（电流、水流等）可以顺着箭头方向流动，也可以逆着箭头方向流动，所谓的出发和到达仅仅是在每条边上设定了一个方向，将之规定为正. 矩阵 $\boldsymbol{A}$（见图 4.12）有 $m=5$ 行 $n=4$ 列，前三列线性无关，所以我们有满秩分解：

$$\boldsymbol{A}=\boldsymbol{C}\boldsymbol{R}=\begin{bmatrix}-1&1&0\\-1&0&1\\0&-1&1\\-1&0&0\\0&-1&0\end{bmatrix}\begin{bmatrix}\mathbf{1}&0&0&\mathbf{-1}\\0&\mathbf{1}&0&\mathbf{-1}\\0&0&\mathbf{1}&\mathbf{-1}\end{bmatrix} \tag{4.43}$$

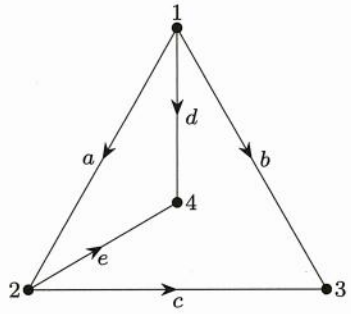


$$\boldsymbol{A}=\begin{bmatrix}-1&1&0&0\\-1&0&1&0\\0&-1&1&0\\-1&0&0&1\\0&-1&0&1\end{bmatrix}\quad\begin{matrix}\text{边 } a\\ b\\ c\\ d\\ e\end{matrix}$$

$\boldsymbol{A}$ 的第 4 列 $=-1$(第 2 列 + 第 3 列 + 第 4 列)

所以 $\boldsymbol{R}$ 的第 4 列为 $\begin{bmatrix}-1&-1&-1\end{bmatrix}^{\mathrm{T}}$

图 4.12　4 个顶点 5 条边的图及其关联矩阵

在继续讨论之前，我们先回顾关于线性方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 的一些基本事实. 若 $\boldsymbol{b}$ 属于 $\boldsymbol{A}$ 的列空间，则方程组有解. 长度最小的解 $\boldsymbol{x}_0$ 是唯一一个属于 $\boldsymbol{A}$ 的行空间的解（从而 $\boldsymbol{x}_0$ 是行向量的线性组合）. 任意解都形如 $\boldsymbol{x}=\boldsymbol{x}_0+\boldsymbol{x}_n$，其中 $\boldsymbol{x}_n\in\mathcal{N}(\boldsymbol{A})$，此时 $\|\boldsymbol{x}\|^2=\|\boldsymbol{x}_0\|^2+\|\boldsymbol{x}_n\|^2\geqslant\|\boldsymbol{x}_0\|^2$.

任意矩阵 $\boldsymbol{A}$ 的行空间和列空间维数都等于秩 $r$，把它视作从行空间到列空间的线性映射，则该映射是可逆映射.

$$\boldsymbol{x}_0\text{属于 }\boldsymbol{A}\text{ 的行空间}\xrightarrow{\boldsymbol{Ax}_0=\boldsymbol{b}_0}\xleftarrow{\boldsymbol{A}^+\boldsymbol{b}_0=\boldsymbol{x}_0}\boldsymbol{b}_0\text{属于 }\boldsymbol{A}\text{ 的列空间}$$

$$\boldsymbol{x}_n\text{属于 }\boldsymbol{A}\text{ 的零空间}\xrightarrow[\boldsymbol{Ax}_n=\boldsymbol{0}]{}\xleftarrow[\boldsymbol{A}^+\boldsymbol{b}_n=\boldsymbol{0}]{}\boldsymbol{b}_n\text{属于 }\boldsymbol{A}\text{ 的左零空间}$$

如何计算 $\boldsymbol{A}^+$ 呢？最为推荐的方法是借助奇异值分解（SVD）：若 $\boldsymbol{A}=\boldsymbol{U\Sigma V}^{\mathrm{T}}$ 则 $\boldsymbol{A}^+=\boldsymbol{V\Sigma U}^{\mathrm{T}}$，这里 $\boldsymbol{U}$ 和 $\boldsymbol{V}$ 都是正交矩阵，$\boldsymbol{U}^{-1}=\boldsymbol{U}^{\mathrm{T}}=\boldsymbol{U}^+,\boldsymbol{V}^{-1}=\boldsymbol{V}^{\mathrm{T}}=\boldsymbol{V}^+$. $m\times n$ 对角矩阵 $\boldsymbol{\Sigma}$ 的广义逆是 $n\times m$ 矩阵 $\boldsymbol{\Sigma}^+$（把 $\boldsymbol{\Sigma}$ 中的 $\sigma_i>0$ 改成 $1/\sigma_i$ 再转置即得 $\boldsymbol{\Sigma}^+$）. $\boldsymbol{\Sigma}$ 对角元中的零在 $\boldsymbol{\Sigma}^+$ 中还是零.

当 $\boldsymbol{A}$ 是元素都是整数的低阶矩阵时，用满秩分解 $\boldsymbol{A}=\boldsymbol{CR}$ 来计算 $\boldsymbol{A}^+$ 也是个好选择. 分解式 $\boldsymbol{A}^+=\boldsymbol{R}^+\boldsymbol{C}^+$ 会产生分数但是不会产生无理数（SVD 分解会产生无理数）.

$$\boldsymbol{A}=\boldsymbol{CR}\text{的广义逆}\qquad\boldsymbol{A}^+=\boldsymbol{R}^{\mathrm{T}}(\boldsymbol{C}^{\mathrm{T}}\boldsymbol{AR}^{\mathrm{T}})^{-1}\boldsymbol{C}^{\mathrm{T}}\tag{4.44}$$

$\boldsymbol{A}^+$ 和 $\boldsymbol{A}^{\mathrm{T}}$ 有相同的行空间和相同的列空间. 而区别在于：$\boldsymbol{A}^+\boldsymbol{A}$ 是到行空间的正交投影矩阵. 式(4.42)中 Penrose 的四个条件可以直接验证，由式(4.44)，也可如下证明 $(\boldsymbol{A}^+\boldsymbol{A})^2=\boldsymbol{A}^+\boldsymbol{A}$：

$$\boxed{(\boldsymbol{A}^+\boldsymbol{A})^2=\boldsymbol{R}^{\mathrm{T}}(\boldsymbol{C}^{\mathrm{T}}\boldsymbol{AR}^{\mathrm{T}})^{-1}\boldsymbol{C}^{\mathrm{T}}\boldsymbol{AR}^{\mathrm{T}}(\boldsymbol{C}^{\mathrm{T}}\boldsymbol{AR}^{\mathrm{T}})^{-1}\boldsymbol{C}^{\mathrm{T}}\boldsymbol{A}=\boldsymbol{A}^+\boldsymbol{A}}\tag{4.45}$$

同理可证 $(\boldsymbol{AA}^+)^2=\boldsymbol{AA}^+$. 若 $\boldsymbol{A}$ 是可逆矩阵，则 $\boldsymbol{A}^+=\boldsymbol{A}^{-1}$. 对于上面提及的图的关联矩阵，我们可以精确计算式(4.32)中的 $\boldsymbol{A}^+$：

$$\boldsymbol{C}^{\mathrm{T}}\boldsymbol{AR}^{\mathrm{T}}=\begin{bmatrix}4&0&0\\0&4&0\\-1&-1&2\end{bmatrix},\qquad\boldsymbol{A}^+=\frac{1}{8}\begin{bmatrix}-2&-2&0&-2&0\\2&0&-2&0&-2\\0&3&3&-1&-1\\0&-1&-1&3&3\end{bmatrix}\tag{4.46}$$

$\boldsymbol{A}^{\mathrm{T}}$ 的四个基本子空间和 $\boldsymbol{A}^+$ 的四个基本子空间完全一样. 事实上，由式(4.32)可直接验证两者有相同的零空间和列空间，由正交性可知两者行空间也一样.

| | | |
|---|---|---|
| $\boldsymbol{A}$ 的所有行相加等于零 | $\longrightarrow$ | $\boldsymbol{A}^+$ 的所有行相加等于零 |
| $\boldsymbol{A}$ 的第 2 行 = 第 1 行 + 第 3 行 | $\longrightarrow$ | $\boldsymbol{A}^+$ 的第 2 列 = 第 1 列 + 第 3 列 |
| $\boldsymbol{A}$ 的第 1 行 = 第 4 行 − 第 5 行 | $\longrightarrow$ | $\boldsymbol{A}^+$ 的第 1 列 = 第 4 列 − 第 5 列 |

方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}=\boldsymbol{0}$ 是基尔霍夫电流定律（每个节点处的流入等于流出）. 这是电路理论和计算工程学中的一个重要方程.

## 习题 4.5

1. 求下面三个矩阵的广义逆.

$$\boldsymbol{A}_1=\begin{bmatrix}1 & 1\\ 1 & 1\end{bmatrix}\qquad \boldsymbol{A}_2=\begin{bmatrix}2 & 0\\ 0 & 4\\ 0 & 0\end{bmatrix}\qquad \boldsymbol{A}_3=\begin{bmatrix}2 & 0 & 0\\ 0 & 4 & 0\end{bmatrix}$$

2. 设 $\boldsymbol{A}$ 是秩 1 矩阵，则存在列向量 $\boldsymbol{a}$、$\boldsymbol{b}$ 使得 $\boldsymbol{A}=\boldsymbol{a}\boldsymbol{b}^{\mathrm{T}}$. 证明：$\boldsymbol{A}^{+}=\boldsymbol{b}\boldsymbol{a}^{\mathrm{T}}/(\boldsymbol{b}^{\mathrm{T}}\boldsymbol{b})(\boldsymbol{a}^{\mathrm{T}}\boldsymbol{a})$，并验证它符合式(4.42)中 Penrose 的四个条件.

3. 证明：如果 $\boldsymbol{A}$ 增加一个零行，那么 $\boldsymbol{A}^{+}$ 将增加一个零列.

提示：在矩阵 $\boldsymbol{A}$ 中添加一个零行和在 $\boldsymbol{A}^{+}$ 中添加一个零列后，Penrose 的四个条件是否仍然正确?

4. 设矩阵 $\boldsymbol{A}=\begin{bmatrix}1 & 0 & 0\\ 0 & 1 & 0\end{bmatrix}$，求 $\boldsymbol{A}$ 的行空间 $C(\boldsymbol{A}^{\mathrm{T}})$ 和列空间 $C(\boldsymbol{A})$；求 $\boldsymbol{A}^{+}$，验证它和 $\boldsymbol{A}^{\mathrm{T}}$ 有相同的四个基本子空间.

5. 设 $\boldsymbol{A}=\begin{bmatrix}0 & 0 & 2\\ 1 & 0 & 0\end{bmatrix}$，求 $\boldsymbol{A}$ 和 $\boldsymbol{A}^{\mathrm{T}}$ 的广义逆. 说明 $(\boldsymbol{A}^{\mathrm{T}})^{+}=(\boldsymbol{A}^{+})^{\mathrm{T}}$ 成立的原因.

6. 若 $\boldsymbol{P}$ 是正交投影矩阵（$\boldsymbol{P}^{\mathrm{T}}=\boldsymbol{P}=\boldsymbol{P}^{2}$），证明：$\boldsymbol{P}^{+}=\boldsymbol{P}$ 满足式(4.42)中 Penrose 的四个条件.

7. 设 $\boldsymbol{A}$ 有满秩分解 $\boldsymbol{A}=\boldsymbol{C}\boldsymbol{R}$，式(4.45)证明了 $(\boldsymbol{A}^{+}\boldsymbol{A})^{2}=\boldsymbol{A}^{+}\boldsymbol{A}$. 请类似地证明：$(\boldsymbol{A}\boldsymbol{A}^{+})^{2}=\boldsymbol{A}\boldsymbol{A}^{+}$.

8. 设 $\boldsymbol{A}$ 有满秩分解 $\boldsymbol{A}=\boldsymbol{C}\boldsymbol{R}$，通过和 $\boldsymbol{A}^{+}=\boldsymbol{R}^{\mathrm{T}}(\boldsymbol{C}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{R}^{\mathrm{T}})^{-1}\boldsymbol{C}^{\mathrm{T}}$ 作矩阵乘法，证明：$\boldsymbol{A}^{+}\boldsymbol{A}$ 和 $\boldsymbol{A}\boldsymbol{A}^{+}$ 都是对称矩阵. 结合 $(\boldsymbol{A}^{+}\boldsymbol{A})^{2}=\boldsymbol{A}^{+}\boldsymbol{A}$ 以及习题 7，说明$\boldsymbol{A}^{+}\boldsymbol{A}$ 和 $\boldsymbol{A}\boldsymbol{A}^{+}$ 都是正交投影矩阵.

9. 假设我们删去图 4.12 中节点 4 和该节点处两条流入的边（只留下外围的三角形）. 写下此时图的邻接矩阵 $\boldsymbol{A}$，求 $\boldsymbol{A}^{+}$. 对 $\boldsymbol{A}$ 作满秩分解 $\boldsymbol{A}=\boldsymbol{C}\boldsymbol{R}$ 并用式(4.44)重新计算 $\boldsymbol{A}^{+}$.

10. 对 $\boldsymbol{A}=\begin{bmatrix}1 & 0\end{bmatrix}$ 和 $\boldsymbol{B}=\begin{bmatrix}1\\ 1\end{bmatrix}$，证明：$(\boldsymbol{A}\boldsymbol{B})^{+}\neq\boldsymbol{B}^{+}\boldsymbol{A}^{+}$，但是 $(\boldsymbol{B}\boldsymbol{A})^{+}=\boldsymbol{A}^{+}\boldsymbol{B}^{+}$.

本题启发我们，分解式 $(\boldsymbol{A}\boldsymbol{B})^{+}=\boldsymbol{B}^{+}\boldsymbol{A}^{+}$ 成立的条件是：前一个因子 $\boldsymbol{A}$ 列满秩且后一个因子 $\boldsymbol{B}$ 行满秩.

11. 为什么 $\boldsymbol{A}^{+}$ 的广义逆等于 $\boldsymbol{A}$? 即证明：$(\boldsymbol{A}^{+})^{+}=\boldsymbol{A}$.

## 4.6　谈谈第 4 章：正交性的巨大成功

如果回顾这本书截至目前所有的线性代数内容，正交向量和正交矩阵已经毫无争议地赢得其首要的地位. 它们的胜利可以说是实至名归，甚至一直可以追溯到关于长度和点积的第 1 章. 我们一起回顾它们的取胜之道，并补充一些新的信息.

若 $\boldsymbol{Q}$ 是列正交矩阵，则

（1）$\boldsymbol{Qx}$ 和 $\boldsymbol{x}$ 的长度相等：$(\boldsymbol{Qx})^{\mathrm{T}}(\boldsymbol{Qx})=\boldsymbol{x}^{\mathrm{T}}\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{Qx}=\boldsymbol{x}^{\mathrm{T}}\boldsymbol{x}=\|\boldsymbol{x}\|^2$.

（2）$\boldsymbol{Qx}$ 和 $\boldsymbol{Qy}$ 的点积等于 $\boldsymbol{x}$ 和 $\boldsymbol{y}$ 的点积：$(\boldsymbol{Qx})^{\mathrm{T}}(\boldsymbol{Qy})=\boldsymbol{x}^{\mathrm{T}}\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{Qy}=\boldsymbol{x}^{\mathrm{T}}\boldsymbol{y}$.

（3）若 $\boldsymbol{Q}$ 是 $m\times n$ 矩阵，那么到 $\boldsymbol{Q}$ 的列空间的正交投影矩阵是 $\boldsymbol{P}=\boldsymbol{QQ}^{\mathrm{T}}=(\boldsymbol{QQ}^{\mathrm{T}})^2$.

（4）方程组 $\boldsymbol{Qx}=\boldsymbol{b}$ 的最小二乘解是 $\hat{\boldsymbol{x}}=\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{b}=\boldsymbol{Q}^{+}\boldsymbol{b}$，其中 $\boldsymbol{Q}^{+}$ 是 $\boldsymbol{Q}$ 的广义逆. 如果 $\boldsymbol{Q}$ 还是方阵，那么 $\boldsymbol{Q}^{\mathrm{T}}=\boldsymbol{Q}^{-1}$. 更多内容见第 5~7 章.

（5）任意有限多个正交矩阵的乘积还是正交矩阵：若 $\boldsymbol{Q}_1,\boldsymbol{Q}_2,\cdots,\boldsymbol{Q}_N$ 都是正交矩阵，则 $\boldsymbol{Q}_1\boldsymbol{Q}_2\cdots\boldsymbol{Q}_N$ 也是正交矩阵. 特别地，正交矩阵 $\boldsymbol{Q}$ 的 $N$ 次幂 $\boldsymbol{Q}^N$ 也是正交矩阵. 正交矩阵行列式的绝对值等于 1.

（6）若 $\boldsymbol{S}$ 是 $n$ 阶实对称矩阵，则可选取 $\boldsymbol{S}$ 的一组特征向量作为 $\mathbb{R}^n$ 的标准正交基.

（7）任意矩阵的奇异向量都单位正交.

以上陈述了一些重要的事实. 正交矩阵的成功之处和长度的平方 $\|\boldsymbol{x}\|^2=\boldsymbol{x}^{\mathrm{T}}\boldsymbol{x}$ 紧密相连. 在最小二乘法中，对 $\|\boldsymbol{Ax}-\boldsymbol{b}\|^2$ 求偏导也可以引出实对称矩阵 $\boldsymbol{S}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$. 于是 $\boldsymbol{S}$ 可以被正交矩阵对角化（我们将在第 6 章引入特征向量）.

任意矩阵 $\boldsymbol{A}$ 都可以由两个正交矩阵 $\boldsymbol{Q}_1$ 和 $\boldsymbol{Q}_2$ 对角化（详情请见第 7 章的奇异值分解）. 最后我们再提两个矩阵分解：$\boldsymbol{A}=\boldsymbol{QR}$ 和 $\boldsymbol{A}=\boldsymbol{QS}$.

（8）任意可逆矩阵 $A$ 都可以写成正交矩阵 $Q$ 和上三角矩阵 $R$ 的乘积，例如

$$\boldsymbol{A}=\begin{bmatrix}3&0\\4&5\end{bmatrix}=\frac{1}{5}\begin{bmatrix}3&-4\\4&3\end{bmatrix}\begin{bmatrix}5&4\\0&3\end{bmatrix}=\boldsymbol{QR}.$$

（9）任意可逆矩阵 $A$ 都可以写成正交矩阵 $Q$ 和对称矩阵 $S$ 的乘积，例如

$$\boldsymbol{A}=\begin{bmatrix}3&0\\4&5\end{bmatrix}=\frac{1}{\sqrt{5}}\begin{bmatrix}2&-1\\1&2\end{bmatrix}\sqrt{5}\begin{bmatrix}2&1\\1&2\end{bmatrix}=\boldsymbol{QS}.$$

# 第 5 章

CHAPTER 5

# 行 列 式

方阵的行列式是一个令人惊叹的数值对象. 如果方阵 $\boldsymbol{A}$ 的行列式（记作 $\det \boldsymbol{A}$）等于 0，则它的列向量线性相关，且 $\boldsymbol{A}$ 不可逆. 如果 $\boldsymbol{A}$ 的行列式不为 0，那么求 $A$ 的逆矩阵 $A^{-1}$ 的公式包含行列式的倒数. 5.2节将介绍如何计算三阶方阵的行列式、用于计算 $\det \boldsymbol{A}$ 和逆矩阵的“代数余子式公式”以及逆矩阵.

矩阵 $\boldsymbol{A}$ 的行列式 $\det \boldsymbol{A}$ 有三种常用的计算公式. 一是通过消元法，有矩阵分解：$\boldsymbol{PA}=\boldsymbol{LU}$. 由于 $\det \boldsymbol{L}$ 始终等于 1，$\det \boldsymbol{P}$ 等于 1 或 $-1$，因此上三角矩阵 $U$ 中主元的乘积给出 $\det \boldsymbol{A}$ 或 $-\det \boldsymbol{A}$（正负号取决于 $\boldsymbol{P}$ 的行列式）. 这通常是最快的方法. 第二种计算公式使用 $n-1$ 阶子方阵的行列式，即 $\boldsymbol{A}$ 的“代数余子式”. 它们为 $\boldsymbol{A}^{-1}$ 提供了最佳的理论公式. $\boldsymbol{A}^{-1}$ 的第 $(i,j)$ 项是 $\boldsymbol{A}$ 的第 $(j,i)$ 个代数余子式除以 $\det \boldsymbol{A}$. 第三种计算公式是行列式的完全展开式. 计算 $\det A$ 的完全展开式包含 $n!$ 项，每一项都对应于矩阵中一条从上到下的路径. 每条路径从每一行和每一列中选择一个元素，并将路径上的 $n$ 个元素相乘. 如果路径的列数的排列是奇置换，则再乘以 $-1$. 一个三阶方阵有 6 条路径，完全展开式包含 6 项——对应于 6 种 $3\times 3$ 置换矩阵.

5.2节从一些重要性质开始，如 $\det \boldsymbol{AB}=(\det \boldsymbol{A})(\det \boldsymbol{B})$. 为了证明这一重要事实，我们从能决定行列式的三个简单性质开始. 从这三个性质出发，可以推导出其他所有内容——包括用于求解线性方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 的著名的克莱姆法则.

5.3节转向几何：$n$ 维空间中平行多面体的体积. 矩阵 $\boldsymbol{E}$ 的列向量给出了从原点出发的 $n$ 条边. 多面体的体积是 $|\det \boldsymbol{E}|$. 这将几何与线性代数联系起来.

本章稍不留神就满是公式！用 $n$ 阶方阵乘以 $n$ 维空间中一个立体图形内部的所有点，会产生另一个立体图形. 立方体变为平行多面体，圆变为椭圆，球体变为椭球体. 目标体积与原始体积的比值始终是 $|\det A|$. 如果行列式不是那么难以计算，它能够告诉我们关于方阵的所有信息.

## 5.1 三阶方阵的行列式和代数余子式

（1）$\boldsymbol{A}=\begin{bmatrix} a & b \\ c & d \end{bmatrix}$ 的行列式是 $ad-bc$. 奇异矩阵 $\begin{bmatrix} a & 2a \\ c & 2c \end{bmatrix}$ 的行列式是 0.

（2）矩阵交换两行改变行列式的正负号：$\boldsymbol{PA}=\begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}\begin{bmatrix} a & b \\ c & d \end{bmatrix}=\begin{bmatrix} c & d \\ a & b \end{bmatrix}$，行列式为

$\det \boldsymbol{PA} = bc - ad = -\det \boldsymbol{A}$.

（3）$\begin{bmatrix} xa+yA & xb+yB \\ c & d \end{bmatrix}$ 的行列式为 $x(ad-bc)+y(Ad-Bc)$. 行列式关于第一行是线性的.

（4）式(5.1)中，三阶方阵的行列式共 $3! = 6$ 项. 利用式(5.4)中的代数余子式，也可以重排成三组. 式(5.7)构造 $\boldsymbol{A}^{-1}$ 时这些代数余子式都要除以 $\det(\boldsymbol{A})$.

行列式能推导出形式上非常优美的公式，但它们往往并不适用于实际计算. 本节将重点关注三阶方阵，以了解行列式是如何构造出逆矩阵 $\boldsymbol{A}^{-1}$ 的（在第 1~4 章中并未出现关于 $\boldsymbol{A}^{-1}$ 的公式）. 首先来看看二阶方阵：

$$\det\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = 1 \qquad \det\begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} = -1 \qquad \det\begin{bmatrix} a & b \\ c & d \end{bmatrix} = ad - bc \qquad \det\begin{bmatrix} c & d \\ a & b \end{bmatrix} = bc - ad$$

这几个例子蕴含了行列式重要的规则. **交换矩阵的两行（或两列）时，行列式的符号会反转.** 这一规则是决定任意方阵行列式的关键. 当矩阵的行列式为零时，该矩阵没有逆矩阵.

对二阶方阵而言，$\det \boldsymbol{A} = 0$ 意味着 $a/c = b/d$，也就是说两列成比例. 对 $n$ 阶方阵而言，$\det \boldsymbol{A} = 0$ **意味着 $\boldsymbol{A}$ 的列向量线性相关.** 那么列向量的某个非零线性组合等于零向量：存在 $\boldsymbol{x} \neq \boldsymbol{0}$ 使得 $\boldsymbol{Ax} = \boldsymbol{0}$.

在定义行列式之后，我们将进一步探讨这些性质以及其他更多性质.

### 5.1.1 三阶方阵的行列式

二阶方阵的行列式是容易的：$ad - bc$，四阶方阵的行列式就难了，最好用消元法算（有计算机更佳）. 三阶方阵的行列式有 $3! = 6$ 项，手算也不算麻烦，所以可以展开讲一讲.

置换矩阵的行列式等于 1 或 $-1$. 置换矩阵都可以从单位矩阵（行列式等于 1）经过若干行对换（每次对换行列式改变一次正负号）得到. 这样我们就迅速得到了 6 个置换矩阵的行列式

$$\det = \underset{+1}{\begin{bmatrix} 1 & & \\ & 1 & \\ & & 1 \end{bmatrix}} \quad \underset{-1}{\begin{bmatrix} & 1 & \\ 1 & & \\ & & 1 \end{bmatrix}} \quad \underset{+1}{\begin{bmatrix} & 1 & \\ & & 1 \\ 1 & & \end{bmatrix}} \quad \underset{-1}{\begin{bmatrix} & & 1 \\ & 1 & \\ 1 & & \end{bmatrix}} \quad \underset{+1}{\begin{bmatrix} & & 1 \\ 1 & & \\ & 1 & \end{bmatrix}} \quad \underset{-1}{\begin{bmatrix} 1 & & \\ & & 1 \\ & 1 & \end{bmatrix}}$$

如果你交换矩阵 $\boldsymbol{A}$ 的两行，比如第 1 行和第 2 行，**那么行列式改变正负号**. 这个规则适用于所有行列式：行对换令行列式乘以 $-1$.

如果把矩阵的某一行乘以一个倍数，那么行列式也将乘以相同的倍数. 假设矩阵的 3 行分别是 $abc$、$pqr$、$xyz$，那么我们有

$$\det = \underset{+aqz}{\begin{bmatrix} a & & \\ & q & \\ & & z \end{bmatrix}} \quad \underset{-bpz}{\begin{bmatrix} & b & \\ p & & \\ & & z \end{bmatrix}} \quad \underset{+brx}{\begin{bmatrix} & b & \\ & & r \\ x & & \end{bmatrix}} \quad \underset{-cqx}{\begin{bmatrix} & & c \\ & q & \\ x & & \end{bmatrix}} \quad \underset{+cpy}{\begin{bmatrix} & & c \\ p & & \\ & y & \end{bmatrix}} \quad \underset{-ary}{\begin{bmatrix} a & & \\ & & r \\ & y & \end{bmatrix}}$$

后面我们要使用最强力的性质. 矩阵 $A$ 的行列式对于它每一个单独的行都是线性的. 如上式所示，我们把这 6 项加起来. 为了方便记忆每一项的正负号，遵循图 5.1中箭头方向即可.

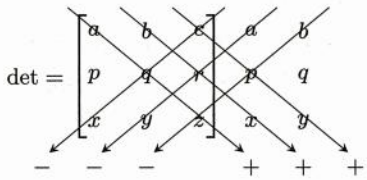


把这 6 个单项组合起来：

$$\det \boldsymbol{A} = +aqz + brx + cpy - ary - pbz - cqx. \tag{5.1}$$

图 5.1　三阶方阵的行列式

注意：这 6 项中每一项都包含来自矩阵每一行的一个元素，也包含来自每一列的一个元素. 因为有 6 个 $3\times 3$ 的置换矩阵，所以在 $\det \boldsymbol{A}$ 中有 $6 = 3!$ 项. 四阶方阵的行列式有 $4! = 4\times 3\times 2\times 1 = 24$ 项.

下面通过 1、2、3、4 阶矩阵的例子来进一步说明. 可能你会觉得有点突然，但是实际上可以快速心算出它们的行列式. 我最喜欢的矩阵是主对角线元素都是 2，对角线上方和下方的次对角线全是 $-1$ 的矩阵.[①]以下是 $n = 1, 2, 3$ 的情形：

$$\boldsymbol{A}_1 = \begin{bmatrix} 2 \end{bmatrix} \qquad \boldsymbol{A}_2 = \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix} \qquad \boldsymbol{A}_3 = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$$

$$\det \boldsymbol{A}_1 = 2 \qquad \det \boldsymbol{A}_2 = 4 - 1 = 3 \qquad \det \boldsymbol{A}_3 = 8 - 2 - 2 = 4$$

$\det \boldsymbol{A}_3 = 4$ 的 6 项具体是哪 6 项呢？对角元给出 $(2)(2)(2) = 8$，其他五项是

$$\begin{bmatrix} 2 & & \\ & & -1 \\ & -1 & \end{bmatrix} \quad \begin{bmatrix} & -1 & \\ -1 & & \\ & & 2 \end{bmatrix} \quad \begin{bmatrix} & -1 & \\ & & -1 \\ 0 & & \end{bmatrix} \quad \begin{bmatrix} & & 0 \\ -1 & & \\ & -1 & \end{bmatrix} \quad \begin{bmatrix} & & 0 \\ & 2 & \\ 0 & & \end{bmatrix}$$

行列式的值分别为 $-2, -2, 0, 0, 0$

所以这 6 项加起来等于 $\det \boldsymbol{A}_3 = 8 - 2 - 2 = 4$. 请注意这个模式：$n! = 3! = 6$ 项中每一项都从每一行每一列取一个元素出来相乘. 这些数字中的任何一个为零时，整项就为零. 当矩阵中有许多零时，计算 $\det \boldsymbol{A}$（即矩阵 $\boldsymbol{A}$ 的行列式）会容易得多.[②]

现在，我们来看行列式有 24 项的 4 阶方阵 $\boldsymbol{A}_4$. 这儿有一个关键的简化步骤，对整个行列式的构造都有重要的启发意义. 4 阶方阵的行列式实际上来源于三阶方阵的行列式！

$$\boldsymbol{A}_4 = \left[\begin{array}{c|ccc} 2 & -1 & & \\ \hline -1 & 2 & -1 & \\ & -1 & 2 & -1 \\ & & -1 & 2 \end{array}\right] \qquad \det \boldsymbol{A}_4 = 2 \det \begin{bmatrix} 2 & -1 & \\ -1 & 2 & -1 \\ & -1 & 2 \end{bmatrix} - (-1) \det \begin{bmatrix} -1 & -1 & 0 \\ 0 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$$

这些来自第 2、3、4 行的三阶方阵的行列式是第 1 行中元素 2 和 $-1$ 的代数余子式. (5.2)

① 译者注：这个矩阵也是“老朋友”了，就是差分矩阵.

② 译者注：通过各种变换，把矩阵中的元素尽量多地变成零，这是计算行列式非常重要的方法，俗称“打洞”.

注意：在矩阵 $\boldsymbol{A}$ 的第一行中，2 与来自其他行的 $3\times 3$ 子矩阵的行列式相乘. 因为行列式的每一项在每一行和每一列都各取一个数字！2 来自第 1 行第 1 列，因此 2 乘以由第 2、3、4 行和第 2、3、4 列构成的 $3\times 3$ 子矩阵的行列式. 该子矩阵是 $\boldsymbol{A}_3$，行列式值为 4.

式(5.2)中的最后一个 $3\times 3$ 子矩阵也来自 $\boldsymbol{A}$ 的第 2、3、4 行. 蓝色的 $-1$ 来自第 1 行第 2 列，因此三阶方阵必须使用第 1、3、4 列. 该矩阵行列式的值为 $-3$（请验证这一点）. 最终 $\boldsymbol{A}_4$ 整体的行列式值为 $8-3=5$.

关于由第 1、3、4 列构成的最后一个三阶方阵，还有一件事需要了解. 在式(5.2)中，它和 $\boldsymbol{A}_4$ 第 1 行第 2 列的 $-1$ 相乘；但该项还有一个神秘的 $-1$！那个负号是从哪里来的呢？它之所以存在，是因为第 1 行第 2 列是一个“负号位置”. $1+2$ 是一个奇数！对于二阶方阵，符号已经确定好了：

$$\det\begin{bmatrix} a & b \\ c & d \end{bmatrix} = \det\begin{bmatrix} a & \\ & d \end{bmatrix} + \det\begin{bmatrix} & b \\ c & \end{bmatrix} = a \text{ 乘以 } d \text{ 减去 } b \text{ 乘以 } c. \tag{5.3}$$

至此 $\boldsymbol{A}_1$、$\boldsymbol{A}_2$、$\boldsymbol{A}_3$、$\boldsymbol{A}_4$ 的行列式就全算出来了，分别是 2、3、4、5. 你也可以猜测，$\det \boldsymbol{A}_5 = 6$. 和计算 $\boldsymbol{A}_4$ 的想法类似，我们有 $\det \boldsymbol{A}_5 = 2\det \boldsymbol{A}_4 - \det \boldsymbol{A}_3 = 2(5) - 4 = 6$. 稍后解释这一点.

### 5.1.2 代数余子式和 $A^{-1}$ 的公式

对于三阶方阵的行列式中类似于 $aqz$ 的 6 项，我们可以用行列式的“代数余子式公式”来解释，并且进一步解释逆矩阵的“代数余子式公式”. 基本思路是将三阶方阵的行列式约化到二阶方阵的行列式. 在行列式 $\det \boldsymbol{A}$ 的 6 项中，以第 1 行的 $a$、$b$ 和 $c$ 开头的项分别都有两项：

$3\times 3$矩阵的行列式
代数余子式公式

$$\boxed{\det \boldsymbol{A} = a(qz - ry) + b(rx - pz) + c(py - qx)} \tag{5.4}$$

这个式子把第一行的 $a$、$b$、$c$ 从它们的“代数余子式”中分离出来. 每个代数余子式都是二阶方阵的行列式. (1,1) 位置处 $a$ 的代数余子式是第 2、3 行和第 2、3 列的交叉点构成的子矩阵的行列式，这样每一行每一列都只使用一次. 注意到 $b$ 在 (1,2) 位置，代数余子式是 $rx-pz$. 元素都来自第 2、3 行和第 1、3 列，但是实际上这个子矩阵的行列式是 $pz-rx$. 代数余子式 $C_{12}$ 改变正负号的次数是 $1+2$ 次，$1+2$ 是奇数，最终效果就是变成 $-1$ 倍. 是时候给代数余子式 $C_{ij}$ 下严格的定义，并且指定它的正负号的规则——$(-1)^{i+j}$.

$$\boxed{\begin{array}{l} \text{对 } 1\leqslant i,j\leqslant n\text{，设 } \boldsymbol{A}_{ij} \text{ 是删掉 } \boldsymbol{A} \text{ 的第 } i \text{ 行和第 } j \text{ 列剩下的 } (n-1) \text{ 阶方阵，令} \\ \qquad\qquad C_{ij} := (-1)^{i+j} \det \boldsymbol{A}_{ij} \\ \text{则按照第 } i \text{ 行展开的代数余子式公式为} \\ \qquad\qquad \det \boldsymbol{A} = a_{i1}C_{i1} + a_{i2}C_{i2} + \cdots + a_{in}C_{in} \end{array}} \tag{5.5}$$

关键点：代数余子式 $C_{ij}$ 无非就是把 $\det \boldsymbol{A}$ 中以 $a_{ij}$ 为因子的项全都放在一起而已. 因此二阶方阵 $\begin{bmatrix} a & b \\ c & d \end{bmatrix}$ 的代数余子式即 $1\times 1$ 行列式 $d$、$c$、$b$、$a$ 乘以相应的 $(-1)^{i+j}$.

$$\boldsymbol{A} = \begin{bmatrix} a & b \\ c & d \end{bmatrix} \text{ 的代数余子式组成矩阵 } \boldsymbol{C} = \begin{bmatrix} d & -c \\ -b & a \end{bmatrix}$$

如果你的注意力足够好，把$\boldsymbol{A}$ 乘以 $\boldsymbol{C}^{\mathrm{T}}$（注意，不是 $\boldsymbol{C}$），结果是 $\det \boldsymbol{A}$ 乘以 $\boldsymbol{I}$：

$$\boldsymbol{A}\boldsymbol{C}^{\mathrm{T}}=\begin{bmatrix} ad-bc & 0 \\ 0 & ad-bc \end{bmatrix}=\begin{bmatrix} \det \boldsymbol{A} & 0 \\ 0 & \det \boldsymbol{A} \end{bmatrix}=(\det \boldsymbol{A})\boldsymbol{I}. \tag{5.6}$$

当 $\det \boldsymbol{A}\neq 0$ 时，上式除以 $\det \boldsymbol{A}$，代数余子式给出逆矩阵 $\boldsymbol{A}^{-1}$ 的第一个也是最优美的公式：

逆矩阵公式

$$\boldsymbol{A}^{-1}=\frac{1}{\det \boldsymbol{A}}\boldsymbol{C}^{\mathrm{T}} \tag{5.7}$$

这个公式也解释了为什么可逆矩阵的行列式不为零. 我们要用矩阵 $\boldsymbol{C}^{\mathrm{T}}$ 除以行列式 $\det \boldsymbol{A}$ 的值. 逆矩阵 $\boldsymbol{A}^{-1}$ 中的每一个元素都是两个行列式的商（其中，$\boldsymbol{C}^{\mathrm{T}}$ 中的元素是 $n-1$ 阶方阵的行列式，而 $\det \boldsymbol{A}$ 是 $n$ 阶方阵的行列式）.

下面的例子中 $\boldsymbol{A}$ 的行列式为 1，所以 $\boldsymbol{A}^{-1}$ 恰好等于 $\boldsymbol{C}^{\mathrm{T}}$——即伴随矩阵. 注意计算 $C_{32}$ 时要去掉 $\boldsymbol{A}$ 的第 3 行和第 2 列，对剩下的二阶方阵求行列式，其行列式值为 1. 由于 $(-1)^{2+3}=-1$，于是代数余子式等于 $(-1)\cdot 1=-1$. $C_{32}$ 位于 $\boldsymbol{C}^{\mathrm{T}}$ 的第 2 行、第 3 列.

$\boldsymbol{A}^{-1}$ 的例子
行列式 $=1$
$\boldsymbol{C}^{\mathrm{T}}$ 的元素都是代数余子式

$$\boldsymbol{A}^{-1}=\begin{bmatrix} 1 & 1 & 1 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{bmatrix}^{-1}=\begin{bmatrix} 1 & -1 & 0 \\ 0 & 1 & -1 \\ 0 & 0 & 1 \end{bmatrix}=\frac{\boldsymbol{C}^{\mathrm{T}}}{1} \tag{5.8}$$

代数余子式 [式(5.5)] 告诉我们，$\boldsymbol{A}\boldsymbol{C}^{\mathrm{T}}$ 的对角线元素总是等于矩阵 $\boldsymbol{A}$ 的行列式. 本节习题 18 将解释为什么 $\boldsymbol{A}\boldsymbol{C}^{\mathrm{T}}$ 的非对角线元素总是零. 这些数实际上是有两行相等的矩阵的行列式，因此自动为零.

一个典型的代数余子式 $C_{31}$ 会去掉第 3 行和第 1 列. 在 $3\times 3$ 矩阵的示例中，留下的是一个 $2\times 2$ 矩阵，其元素全为 1，行列式等于 0. 这是 $\boldsymbol{A}^{-1}$ 第 1 行第 3 列位置上的加粗的 0. 如果矩阵换成 $2\boldsymbol{A}$，行列式会乘以 $2^3=8$，$\boldsymbol{C}$ 中的所有代数余子式都会乘以 $2^2=4$. 从而 $(2\boldsymbol{A})^{-1}=\dfrac{4\boldsymbol{C}^{\mathrm{T}}}{8\det \boldsymbol{A}}=\dfrac{\boldsymbol{A}^{-1}}{2}$，完美！

### 5.1.3　三对角矩阵

行列式的代数余子式公式将 $n$ 阶矩阵的行列式转化为 $n-1$ 阶矩阵的行列式. 三对角矩阵是一个很好的例子，因为第 1 行只有两个非零元素. 你还记得我最喜欢哪个矩阵吗？没错，主对角线元素都是 2、次对角线都是 $-1$ 的方阵，这样的 $n$ 阶方阵记为 $\boldsymbol{A}_n$. 它的行列式只关乎第 1 行的两个代数余子式——而它们最终又可以转化成 $\boldsymbol{A}_{n-1}$ 和 $\boldsymbol{A}_{n-2}$. 让我们看看这是怎么发生的.

$$\det\begin{bmatrix} \mathbf{2} & \mathbf{-1} & 0 & \cdots & 0 \\ -1 & 2 & -1 & \cdots & 0 \\ 0 & -1 & 2 & \ddots & \vdots \\ \vdots & \ddots & \ddots & \ddots & \vdots \\ 0 & \cdots & \cdots & -1 & 2 \end{bmatrix}=\mathbf{2}(-1)^{1+1}\det\begin{bmatrix} 2 & -1 & \cdots & 0 \\ -1 & 2 & \ddots & \vdots \\ \vdots & \ddots & \ddots & \vdots \\ 0 & \cdots & -1 & 2 \end{bmatrix}\mathbf{-1}(-1)^{1+2}\det\begin{bmatrix} -1 & -1 & \cdots & 0 \\ 0 & 2 & \ddots & \vdots \\ \vdots & \ddots & \ddots & \vdots \\ 0 & \cdots & -1 & 2 \end{bmatrix}$$

等号右边第一项是 $2\det \boldsymbol{A}_{n-1}$. 第二项首先有来自 $\boldsymbol{A}_n$ 第 $(1,2)$ 位置处的元素 $-1$，代数余子式的符号 $(-1)^{i+j}=(-1)^{1+2}=-1$. 这个代数余子式本身又有来自左上角元素的 $-1$，所以一共是 3 个

$-1$ 相乘；该代数余子式的代数余子式是 $n-2$ 阶方阵的行列式. 这个 $n-2$ 阶方阵是什么呢？恰好是 $\boldsymbol{A}_{n-2}$！

$$\det \boldsymbol{A}_n = 2\det \boldsymbol{A}_{n-1} - \det \boldsymbol{A}_{n-2}. \tag{5.9}$$

先前已经直接计算出 $n=1$、2、3、4 时，$\det \boldsymbol{A}_n$ 分别等于 2、3、4、5，可以验证它们都满足式(5.9)，例如 $\det \boldsymbol{A}_4 = 5 = 2(4) - 3$. 通过递推式(5.9)可知：对任意 $n$，$\det \boldsymbol{A}_n = n+1$. 易知它满足递推式：$n+1 = 2(n) - (n-1)$.

当矩阵有很多元素等于零时，代数余子式公式最有用，因为此时有非零贡献的代数余子式比较少. 不仅如此，这些代数余子式本身也有很多零元素. 对一个充斥着非零元素的稠密矩阵，代数余子式公式用起来就不那么顺手了，那么我们就需要寻找一个更好的求行列式的方法. 这个方法重新引入了消元法，以产生易于计算的下三角矩阵 $\boldsymbol{L}$ 和上三角矩阵 $\boldsymbol{U}$ 的行列式.

## 习题 5.1

习题 1～5 关于行列式的计算法则

1. 若四阶方阵 $\boldsymbol{A}$ 的行列式 $\det(\boldsymbol{A}) = \frac{1}{2}$，请计算 $\det(2\boldsymbol{A})$、$\det(-\boldsymbol{A})$、$\det(\boldsymbol{A}^2)$ 和 $\det(\boldsymbol{A}^{-1})$.[①]

2. 若三阶方阵 $\boldsymbol{A}$ 的行列式 $\det(\boldsymbol{A}) = -1$，请计算 $\det\left(\frac{1}{2}\boldsymbol{A}\right)$、$\det(-\boldsymbol{A})$、$\det(\boldsymbol{A}^2)$ 和 $\det(\boldsymbol{A}^{-1})$. 如果 $\det \boldsymbol{A} = 0$，那么对同样的四个行列式，你有什么结论？

3. 判断正误，正确则简述其理由，错误则举反例.

（1）$\boldsymbol{I} + \boldsymbol{A}$ 的行列式是 $1 + \det \boldsymbol{A}$.

（2）$4\boldsymbol{A}$ 的行列式是 $4\det \boldsymbol{A}$.

（3）$\boldsymbol{AB} - \boldsymbol{BA}$ 的行列式是 0. 对 $\boldsymbol{A} = \begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix}$ 试举一例或反例.

4. 交换矩阵的两行改变行列式的正负号. 用行对换说明如下的反对角矩阵 $\boldsymbol{J}_3$ 和 $\boldsymbol{J}_4$ 的行列式为 $\det \boldsymbol{J}_3 = -1, \det \boldsymbol{J}_4 = 1$.

$$\det \boldsymbol{J}_3 = \det \begin{bmatrix} 0 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \end{bmatrix} = -1 \qquad \text{但是} \qquad \det \boldsymbol{J}_4 = \det \begin{bmatrix} 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 \end{bmatrix} = 1.$$

5. 对于 $n=5$、6、7，计算将反对角矩阵 $\boldsymbol{J}_n$ 通过行对换变换为单位矩阵 $\boldsymbol{I}_n$ 所需的对换次数. 探索 $\det \boldsymbol{J}_n$ 的规律，并预测 $\boldsymbol{J}_{101}$ 的行列式是 $+1$ 还是 $-1$.

6. 对下列矩阵 $\boldsymbol{A}$、$\boldsymbol{B}$、$\boldsymbol{C}$，写出式(5.1)中像 $+aqz$（对角元）和 $-cqx$（反对角元）那样的 6 项，并把 6 项组合起来求出 $\boldsymbol{A}$、$\boldsymbol{B}$、$\boldsymbol{C}$ 的行列式

$$\boldsymbol{A} = \begin{bmatrix} 1 & -1 & 0 \\ -1 & 1 & -1 \\ 0 & -1 & 1 \end{bmatrix} \qquad \boldsymbol{B} = \begin{bmatrix} 2 & 1 & 4 \\ 4 & 2 & 8 \\ 6 & 3 & 12 \end{bmatrix} \qquad \boldsymbol{C} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}$$

① 译者注：相对于本书第 5 版，作者在正文内容上做出了较大的调整，但是习题并没有作相应的调整，比如说本题中要求计算 $\det(\boldsymbol{A}^2)$，本节没有讲述相应的知识：$\det(\boldsymbol{AB}) = \det \boldsymbol{A} \det \boldsymbol{B}$，仅在这一章前面部分简单提及.

7. 如果我们把三阶方阵 $\begin{bmatrix} a & b & c \\ p & q & r \\ x & y & z \end{bmatrix}$ 的第一行加到第二行，此时第二行是 $\begin{bmatrix} p+a & q+b & r+c \end{bmatrix}$. 通过式(5.1)证明：行列式没有变化. 此处我们可以给两行相加行列式不变这个规律提供另一种证法：

$$\det \begin{bmatrix} \text{第一行} \\ \text{第一行 + 第二行} \\ \text{第三行} \end{bmatrix} = \det \begin{bmatrix} \text{第一行} \\ \text{第一行} \\ \text{第三行} \end{bmatrix} + \det \begin{bmatrix} \text{第一行} \\ \text{第二行} \\ \text{第三行} \end{bmatrix} = 0 + \det \begin{bmatrix} \text{第一行} \\ \text{第二行} \\ \text{第三行} \end{bmatrix}$$

8. 设 $\boldsymbol{A}$ 是三阶方阵，证明：$\det \boldsymbol{A}^{\mathrm{T}} = \det \boldsymbol{A}$.

提示：证明这两个方阵有相同的像 $brx$ 那样的 6 项；这也直接说明对于置换矩阵，$\det \boldsymbol{P}^{\mathrm{T}} = \det \boldsymbol{P}$.

9. 以下各矩阵的行列式分别是多少？是 0、1、2 还是 3?

$$\boldsymbol{A} = \begin{bmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix} \qquad \boldsymbol{B} = \begin{bmatrix} 0 & 1 & 1 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix} \qquad \boldsymbol{C} = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix} \qquad \boldsymbol{D} = \begin{bmatrix} 1 & 1 & 1 \\ 0 & 1 & 0 \\ 1 & 1 & 1 \end{bmatrix}$$

10. 若 $\boldsymbol{A}$ 的每一行所有分量相加等于 0，通过方程组 $\boldsymbol{Ax} = \boldsymbol{0}$ 的解的情况证明：$\det \boldsymbol{A} = 0$. 若 $\boldsymbol{A}$ 的每一行所有分量相加等于 1，证明：$\det(\boldsymbol{A} - \boldsymbol{I}) = 0$；这能说明 $\det \boldsymbol{A} = 1$ 吗？

11. 设 $\boldsymbol{P}_1$、$\boldsymbol{P}_2$ 是置换矩阵，证明：$\det(\boldsymbol{P}_1\boldsymbol{P}_2) = \det(\boldsymbol{P}_1)\det(\boldsymbol{P}_2)$. 若 $\boldsymbol{P}_1$、$\boldsymbol{P}_2$ 分别通过 2 次和 3 次行对换变成单位阵，为什么 $\boldsymbol{P}_1\boldsymbol{P}_2$ 经过 $2+3$ 次行对换可以变成单位阵？那么行列式的等式 $\det(\boldsymbol{P}_1\boldsymbol{P}_2) = \det(\boldsymbol{P}_1)\det(\boldsymbol{P}_2)$ 即 $(-1)^5 = (-1)^2(-1)^3$.

12. 解释：为什么 $5 \times 5$ 置换矩阵的行列式恰好有一半等于 1. 满足这个性质的置换矩阵称为偶置换矩阵.

13. 求下述秩 1 矩阵 $\boldsymbol{A}$ 和反对称矩阵 $\boldsymbol{B}$ 的行列式：

$$\boldsymbol{A} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \begin{bmatrix} 1 & -4 & 5 \end{bmatrix} \qquad \boldsymbol{B} = \begin{bmatrix} 0 & 1 & 3 \\ -1 & 0 & 4 \\ -3 & -4 & 0 \end{bmatrix}$$

14. 设 $\boldsymbol{A}$ 是 $n$ 阶方阵. 若 $n \geqslant 2$ 且 $\boldsymbol{A}$ 的第 $(i,j)$ 位置元素是 $ij$，证明：$\det(\boldsymbol{A}) = 0$. 若 $n \geqslant 3$ 且 $\boldsymbol{A}$ 的第 $(i,j)$ 位置元素是 $i+j$，证明：$\det(\boldsymbol{A}) = 0$.

15. 在四阶方阵 $\boldsymbol{A}$ 中，至少放多少个零，能确保 $\det(\boldsymbol{A}) = 0$？试构造一个矩阵 $\boldsymbol{A}$，$\det(\boldsymbol{A}) \neq 0$，且非零元的个数是可能的最大值.

16. 设 $\boldsymbol{A}$ 是方阵，如果它所有代数余子式都等于零，为什么 $\boldsymbol{A}$ 不可逆？如果 $\boldsymbol{A}$ 的所有代数余子式都非零，那么 $\boldsymbol{A}$ 是否一定可逆？

17. 本题关于有两行相等的矩阵的代数余子式公式. 设 $\boldsymbol{A}$ 是 3 阶方阵，且前两行均为 $\begin{bmatrix} a & b & c \end{bmatrix}$. 把 $\det(\boldsymbol{A})$ 表达式中的 6 项全部写下来，说明 $\det(\boldsymbol{A}) = 0$.

18. 为什么有两行相等的方阵 $\boldsymbol{A}$ 一定是奇异矩阵？此断言说明 $\det \boldsymbol{A} = 0$. 如果我们把某一行的代数余子式分别和另一行的元素相乘再相加，那么实际上我们是在计算有两行相等的矩阵 $\boldsymbol{A}^*$ 的行列式 $\det \boldsymbol{A}^*$. 于是 $\det \boldsymbol{A}^* = 0$. 这个事实说明了 $\boldsymbol{AC}^{\mathrm{T}}$ 的非对角线元素都是 0.

19. 请基于代数余子式公式 $\boldsymbol{A}\boldsymbol{C}^{\mathrm{T}}=(\det \boldsymbol{A})\boldsymbol{I}$，证明：$\det \boldsymbol{C}=(\det \boldsymbol{A})^{n-1}$.

20. 假设 $\det \boldsymbol{A}=1$ 且我们已知 $\boldsymbol{A}$ 的所有代数余子式，可以求出 $\boldsymbol{A}$ 吗？如何求？

## 5.2 行列式的计算和使用

（1）常用结论：$\det \boldsymbol{A}^{\mathrm{T}}=\det \boldsymbol{A}$，$\det \boldsymbol{A}\boldsymbol{B}=(\det \boldsymbol{A})(\det \boldsymbol{B})$；$\boldsymbol{Q}$ 是正交矩阵时，$|\det \boldsymbol{Q}|=1$.

（2）倍加矩阵 $\boldsymbol{E}$ 行列式为 1：$\det \boldsymbol{E}=1$，所以 $\det \boldsymbol{E}\boldsymbol{A}=\det \boldsymbol{A}$.

（3）克莱姆法则把 $\boldsymbol{x}=\boldsymbol{A}^{-1}\boldsymbol{b}$ 表示成行列式的商（这是很慢的算法）.

（4）设 $\boldsymbol{A}$ 有 $\boldsymbol{L}\boldsymbol{U}$ 分解：$\boldsymbol{A}=\boldsymbol{L}\boldsymbol{U}$，则 $\det \boldsymbol{A}$ 等于 $\boldsymbol{U}$ 中主元的乘积. 一般地，$\det \boldsymbol{A}$ 与其主元的乘积只相差正负号.

（5）$n$ 阶方阵 $\boldsymbol{A}$ 的行列式 $\det \boldsymbol{A}$ 的大公式有 $n!$ 项，分别对应于 $n!$ 个置换矩阵（当 $n>3$ 时，是很慢的算法.）

方阵的行列式能告诉我们很多信息. 首先，可逆矩阵 $\boldsymbol{A}$ 的行列式非零：$\det \boldsymbol{A}\neq 0$，奇异矩阵的行列式等于零. 当我们讨论特征值 $\lambda$ 和特征向量 $\boldsymbol{x}$ 时，意即 $\boldsymbol{A}\boldsymbol{x}=\lambda \boldsymbol{x}$，则将特征值方程写成 $(\boldsymbol{A}-\lambda \boldsymbol{I})\boldsymbol{x}=\boldsymbol{0}$. 这意味着 $\boldsymbol{A}-\lambda \boldsymbol{I}$ 是奇异矩阵，其行列式 $\det(\boldsymbol{A}-\lambda \boldsymbol{I})=0$. 于是我们得到一个关于 $\lambda$ 的方程.

总体来说，这些公式对于低阶矩阵和特殊矩阵都很有用. 行列式的性质可以使相关公式更加简化. 例如，如果矩阵是上（下）三角矩阵或对角矩阵，行列式只是对角线上元素的乘积：

上（下）三角矩阵
对角矩阵

$$\det\begin{bmatrix} a & b & c \\ & q & r \\ & & z \end{bmatrix}=\det\begin{bmatrix} a & & \\ b & q & \\ c & r & z \end{bmatrix}=\det\begin{bmatrix} a & & \\ & q & \\ & & z \end{bmatrix}=aqz \tag{5.10}$$

方阵取转置，行列式值不变：

矩阵转置

$$\det(\boldsymbol{A}^{\mathrm{T}})=\det(\boldsymbol{A}) \tag{5.11}$$

方阵乘积的行列式等于行列式的乘积：

矩阵相乘

$$\det(\boldsymbol{A}\boldsymbol{B})=(\det \boldsymbol{A})(\det \boldsymbol{B}) \tag{5.12}$$

从代数上证明这个等式略显复杂，我们将给式(5.12)一个简单的几何证明.

矩阵相加然后取行列式，并不等于先取行列式然后再相加. 例如，考虑 $\boldsymbol{I}+\boldsymbol{I}$，其行列式等于 $2^n$，而不是 2. 利用式(5.11)和式(5.12)，还可以得到两个推论：

正交矩阵 $\boldsymbol{Q}$ 的行列式等于 1 或 $-1$.

这是因为 $\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{Q}=\boldsymbol{I}$，那么 $(\det \boldsymbol{Q})^2=(\det \boldsymbol{Q}^{\mathrm{T}})(\det \boldsymbol{Q})=1$，从而 $\det \boldsymbol{Q}=\pm 1$.

$$\boxed{\text{可逆矩阵 } \boldsymbol{A} \text{ 的行列式 } \det \boldsymbol{A}=\pm\text{（主元的乘积）.}} \tag{5.13}$$

如果 $\boldsymbol{A}=\boldsymbol{L}\boldsymbol{U}$，那么 $\det \boldsymbol{A}=(\det \boldsymbol{L})(\det \boldsymbol{U})=\det \boldsymbol{U}$. 上三角矩阵 $\boldsymbol{U}$ 的行列式等于主元的乘积.

如果 $\boldsymbol{PA}=\boldsymbol{LU}$（需要做行对换），$\boldsymbol{P}$ 是置换矩阵，$\det \boldsymbol{P}=1$ 或 $-1$. 此时 $\det \boldsymbol{A}$ 和主元的乘积可能相等，也可能相差 $-1$ 倍.

$\boldsymbol{U}$ 的对角元，也就是主元的乘积 $U_{11}U_{22}\cdots U_{nn}$ 几乎反映了 $\boldsymbol{A}$ 的行列式. 几乎所有的计算线性代数的系统，计算行列式的方法都是消元法. 在第 2 章中，求矩阵 $\boldsymbol{U}$ 的时间代价是 $n^3/3$ 次乘法.

### 5.2.1　证明式 (5.10)~式 (5.13)

在证明式(5.10)~ 式(5.13)之前，我们先从行列式的三个简单性质出发.

（1）$n$阶单位方阵的行列式为1：$\det \boldsymbol{I}_n=1$.

（2）交换 $\boldsymbol{A}$ 的两行得到 $\boldsymbol{B}$，则 $\det \boldsymbol{B}=-\det \boldsymbol{A}$.

（3）若 $\boldsymbol{A}$ 的第一行是线性组合 $c\boldsymbol{v}+d\boldsymbol{w}$，则 $\boldsymbol{A}$ 的行列式也可以拆成两个行列式的组合：

$$\det\begin{bmatrix} c\boldsymbol{v}+d\boldsymbol{w} \\ \text{第二行} \\ \vdots \\ \text{第 } n \text{ 行}\end{bmatrix}=c\det\begin{bmatrix} \boldsymbol{v} \\ \text{第二行} \\ \vdots \\ \text{第 } n \text{ 行}\end{bmatrix}+d\det\begin{bmatrix} \boldsymbol{w} \\ \text{第二行} \\ \vdots \\ \text{第 } n \text{ 行}\end{bmatrix} \tag{5.14}$$

换言之，性质（3）是说“行列式关于第一行是线性的”. 结合性质（2），实际上行列式关于每个单独的行向量都是线性的. 我们可以先交换两行，拆成线性组合再做一次行对换，所以第一行并没有什么特殊之处.

性质（2）还有个简单的推论：**若方阵 $\boldsymbol{A}$ 有两行相等，那么它的行列式为零.** 这是因为：交换这两行，矩阵没变，因此行列式不变；但是性质（2）又说明行列式要改变符号，两者结合即 $\det \boldsymbol{A}=-\det \boldsymbol{A}$，所以 $\det \boldsymbol{A}=0$.

性质（3）告诉我们：把矩阵的某一行减去另一行的若干倍，行列式的值不变. 例如：

$$\det\begin{bmatrix} \text{第一行} \\ \text{第二行}-d\text{第一行} \\ \vdots \\ \text{第 } n \text{ 行}\end{bmatrix}=\det\begin{bmatrix} \text{第一行} \\ \text{第二行} \\ \vdots \\ \text{第 } n \text{ 行}\end{bmatrix}-d\det\begin{bmatrix} \text{第一行} \\ \text{第一行} \\ \vdots \\ \text{第 } n \text{ 行}\end{bmatrix}=\det \boldsymbol{A} \tag{5.15}$$

第一个等号是将其他行固定，行列式关于第二行的线性性. 这再次说明我们从原始矩阵 $\boldsymbol{A}$ 通过倍加变换得到上三角矩阵 $\boldsymbol{U}$ 的过程，并不会改变行列式的值. 因此，**消元（在不进行行对换的情况下）是简化矩阵 $\boldsymbol{A}$ 及其行列式的好方法.**

不涉及行对换　$\boxed{\det \boldsymbol{A}=\det \boldsymbol{U}=U_{11}U_{22}\cdots U_{nn}=\text{主元的乘积.}}$ (5.16)

现在我们来证明 $\det(\boldsymbol{AB})=(\det \boldsymbol{A})(\det \boldsymbol{B})$. 假设 $\det \boldsymbol{B}\neq 0$，实际上，我们先证明 $D(\boldsymbol{A})=\dfrac{\det(\boldsymbol{AB})}{\det \boldsymbol{B}}$ 也满足性质（1）、（2）、（3），那么 $D(\boldsymbol{A})$ 就和 $\det \boldsymbol{A}$ 相等[①]. 以下我们验证 $D(\boldsymbol{A})$ 的确满足性质（1）、（2）、（3）.

① 译者注：我们还需要证明存在唯一的以方阵为变量的实值函数满足性质（1）、（2）、（3），否则无法断言 $D(\boldsymbol{A})=\det \boldsymbol{A}$. 当然，这一论断是正确的.

（1）取 $\boldsymbol{A}=\boldsymbol{I}$，则 $D(\boldsymbol{I})=\det \boldsymbol{B}/\det \boldsymbol{B}=1$.

（2）交换矩阵的两行等价于在矩阵左边乘以某个对换矩阵，因此交换 $\boldsymbol{A}$ 的两行这个操作也导致交换了 $\boldsymbol{AB}$ 的两行，所以 $D(\boldsymbol{AB})$ 也改变了符号.

（3）把 $\boldsymbol{A}$ 的第一行乘以 $c$，则 $\boldsymbol{AB}$ 的第一行也乘以了 $c$，所以 $D(\boldsymbol{A})$ 的值也乘以了 $c$. 若 $\boldsymbol{A}$ 的第一行是 $\boldsymbol{v}+\boldsymbol{w}$，则 $\boldsymbol{AB}$ 的第一行是 $\boldsymbol{vB}+\boldsymbol{wB}$. 用式(5.14)把 $\det(\boldsymbol{AB})$ 写成两个行列式相加，于是 $D(\boldsymbol{A})$ 也拆成了相应的两项的和.

由此可知，$\det(\boldsymbol{AB})/\det \boldsymbol{B}=\det \boldsymbol{A}$.

如果 $\det \boldsymbol{B}=0$，那么 $\boldsymbol{B}$ 不可逆，$\boldsymbol{AB}$ 也不可逆，所以 $\det(\boldsymbol{AB})=0=(\det \boldsymbol{A})(\det \boldsymbol{B})$.

### 5.2.2 克莱姆法则解方程组 $\boldsymbol{Ax}=\boldsymbol{b}$

设 $\boldsymbol{A}$ 可逆，有一个非常巧妙的方法能给出方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 的解 $\boldsymbol{x}$ 的第一个分量. 将单位矩阵 $\boldsymbol{I}$ 的第一列替换为 $\boldsymbol{x}$，这个下三角矩阵 $\boldsymbol{M}_1$ 的行列式为 $x_1$. 将其左乘 $\boldsymbol{A}$ 时，第一列变为 $\boldsymbol{Ax}$，即 $\boldsymbol{b}$. 其他列直接从 $\boldsymbol{A}$ 中移植过来.

关键思想 $\boldsymbol{AM}_1=\boldsymbol{B}_1$

$$\boldsymbol{A}\begin{bmatrix} \boldsymbol{x_1} & 0 & 0 \\ \boldsymbol{x_2} & 1 & 0 \\ \boldsymbol{x_3} & 0 & 1 \end{bmatrix}=\begin{bmatrix} \boldsymbol{b_1} & a_{12} & a_{13} \\ \boldsymbol{b_2} & a_{22} & a_{23} \\ \boldsymbol{b_3} & a_{32} & a_{33} \end{bmatrix}=\boldsymbol{B}_1 \tag{5.17}$$

这个等式也很容易验证，例如用分块矩阵的乘法，每次用 $\boldsymbol{A}$ 乘以 $\boldsymbol{M}_1$ 的一列. 对式(5.17)取行列式，利用式(5.12)得

$$\boxed{(\det \boldsymbol{A})(x_1)=\det \boldsymbol{B}_1 \quad \text{或者} \quad x_1=\det \boldsymbol{B}_1/\det \boldsymbol{A}.} \tag{5.18}$$

这是克莱姆法则关于 $\boldsymbol{x}$ 的第一个分量的公式. 把 $\boldsymbol{A}$ 的第一列换成 $\boldsymbol{b}$ 得到矩阵 $\boldsymbol{B}_1$，$x_1$ 是 $\det \boldsymbol{B}_1$ 和 $\det \boldsymbol{A}$ 的商. 要得到 $x_2$，方法类似，把 $\boldsymbol{x}$ 和 $\boldsymbol{b}$ 分别替换 $\boldsymbol{I}$ 和 $\boldsymbol{A}$ 的第二列：

$$\boldsymbol{AM}_2=\boldsymbol{B}_2 \qquad \begin{bmatrix} \boldsymbol{a}_1 & \boldsymbol{a}_2 & \boldsymbol{a}_3 \end{bmatrix}\begin{bmatrix} 1 & x_1 & 0 \\ 0 & x_2 & 0 \\ 0 & x_2 & 1 \end{bmatrix}=\begin{bmatrix} \boldsymbol{a}_1 & \boldsymbol{b} & \boldsymbol{a}_3 \end{bmatrix}=\boldsymbol{B}_2 \tag{5.19}$$

取行列式有 $(\det \boldsymbol{A}_2)(x_2)=\det \boldsymbol{B}_2$，于是 $x_2=(\det \boldsymbol{B}_2)/(\det \boldsymbol{A})$.

**例 5.1** 解方程组 $\begin{cases} \boldsymbol{3}x_1+\boldsymbol{4}x_2=\boldsymbol{2} \\ \boldsymbol{5}x_1+\boldsymbol{6}x_2=\boldsymbol{4} \end{cases}$ 需要计算三个行列式：

用 $\begin{bmatrix} 2 \\ 4 \end{bmatrix}$ 替换 $\boldsymbol{A}$ 的列向量 $\quad \det \boldsymbol{A}=\begin{vmatrix} 3 & 4 \\ 5 & 6 \end{vmatrix}=-2 \quad \det \boldsymbol{B}_1=\begin{vmatrix} \boldsymbol{2} & 4 \\ \boldsymbol{4} & 6 \end{vmatrix}=-4 \quad \det \boldsymbol{B}_2=\begin{vmatrix} 3 & \boldsymbol{2} \\ 5 & \boldsymbol{4} \end{vmatrix}=2$

利用克莱姆法则：

$$\boldsymbol{x}=\boldsymbol{A}^{-1}\boldsymbol{B} \qquad x_1=\frac{-4}{-2}=2 \quad x_2=\frac{2}{-2} \qquad \text{检验} \begin{bmatrix} 3 & 4 \\ 5 & 6 \end{bmatrix}\begin{bmatrix} \boldsymbol{2} \\ \boldsymbol{-1} \end{bmatrix}=\begin{bmatrix} 2 \\ 4 \end{bmatrix}$$

以上我们通过三阶方阵介绍了克莱姆法则的基本想法，该想法可以适用于任意 $n$ 阶可逆方阵.

**克莱姆法则** 假设 $\det \boldsymbol{A} \neq 0$，我们可以通过行列式来求解方程组 $\boldsymbol{Ax} = \boldsymbol{b}$:

$$x_1 = \frac{\det \boldsymbol{B}_1}{\det \boldsymbol{A}} \qquad x_2 = \frac{\det \boldsymbol{B}_2}{\det \boldsymbol{A}} \qquad \cdots \qquad x_n = \frac{\det \boldsymbol{B}_n}{\det \boldsymbol{A}} \tag{5.20}$$

其中 $\boldsymbol{B}_j$ 是把 $\boldsymbol{A}$ 的第 $j$ 列替换成 $\boldsymbol{b}$ 得到的方阵.

用克莱姆法求解 $n$ 阶方程组需要计算 $n+1$ 个 $n$ 阶行列式（包括矩阵 $\boldsymbol{A}$ 和 $n$ 个不同的矩阵 $\boldsymbol{B}_j (1 \leqslant j \leqslant n)$ 的行列式）. 更令人头皮发麻的是包含所有排列的行列式“大公式”，每个行列式都是 $n!$ 项之和，总共会有 $(n+1)!$ 项. 用这种方式来解方程简直是疯狂之举. 虽然不适合计算，但归根结底，我们最终还是得到了一个求解 $\boldsymbol{Ax} = \boldsymbol{b}$ 的精确公式.

**例 5.2**　克莱姆法则在处理数字时效率太低，但在处理字母时却非常适用. 对 $n = 2$，通过求解 $\boldsymbol{AA}^{-1} = \boldsymbol{A}\begin{bmatrix} \boldsymbol{x} & \boldsymbol{y} \end{bmatrix} = \boldsymbol{I}$ 来找到 $\boldsymbol{A}^{-1}$ 的两列 $\boldsymbol{x}$ 和 $\boldsymbol{y}$.

$$\boldsymbol{Ax} = \begin{bmatrix} a & b \\ c & d \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} \mathbf{1} \\ \mathbf{0} \end{bmatrix} \qquad \boldsymbol{Ay} = \begin{bmatrix} a & b \\ c & d \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \begin{bmatrix} \mathbf{0} \\ \mathbf{1} \end{bmatrix}$$

这两个方程组有相同的系数矩阵 $\boldsymbol{A}$，要用克莱姆法则解 $x_1$、$x_2$、$y_1$、$y_2$，我们需要计算 5 个行列式:

$$\det \boldsymbol{A} = \begin{vmatrix} a & b \\ c & d \end{vmatrix} \quad \text{和} \quad \begin{vmatrix} \mathbf{1} & b \\ \mathbf{0} & d \end{vmatrix} \quad \begin{vmatrix} a & \mathbf{1} \\ c & \mathbf{0} \end{vmatrix} \quad \begin{vmatrix} \mathbf{0} & b \\ \mathbf{1} & d \end{vmatrix} \quad \begin{vmatrix} a & \mathbf{0} \\ c & \mathbf{1} \end{vmatrix}$$

后 4 个行列式分别为 $d$、$-c$、$-b$、$a$（恰好是代数余子式！），于是

$$x_1 = \frac{d}{\det \boldsymbol{A}}, \quad x_2 = \frac{-c}{\det \boldsymbol{A}}, \quad y_1 = \frac{-b}{\det \boldsymbol{A}}, \quad y_2 = \frac{a}{\det \boldsymbol{A}}, \quad \text{以及} \boldsymbol{A}^{-1} = \frac{1}{ad - bc} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix}$$

$\boldsymbol{A}^{-1}$ 每一项差不多都是 $\boldsymbol{A}$ 的代数余子式. 当 $\boldsymbol{Ax} = \boldsymbol{b}$ 的右侧是单位矩阵 $\boldsymbol{I}$ 的一列时，如 $\boldsymbol{AA}^{-1} = \boldsymbol{I}$ 那样，克莱姆法则中每个 $\boldsymbol{B}_j$ 的行列式就是 $\boldsymbol{A}$ 的一个代数余子式.

$n = 3$ 时你可以看到这些余子式. 我们通过求解 $\boldsymbol{Ax} = \begin{bmatrix} 1 & 0 & 0 \end{bmatrix}^{\mathrm{T}}$ 来找出 $\boldsymbol{A}^{-1}$ 的第一列:

$B_j$ 的行列式都是 $A$ 的代数余子式

$$\begin{vmatrix} \mathbf{1} & a_{12} & a_{13} \\ \mathbf{0} & a_{22} & a_{23} \\ \mathbf{0} & a_{32} & a_{33} \end{vmatrix} \quad \begin{vmatrix} a_{11} & \mathbf{1} & a_{13} \\ a_{21} & \mathbf{0} & a_{23} \\ a_{31} & \mathbf{0} & a_{33} \end{vmatrix} \quad \begin{vmatrix} a_{11} & a_{11} & \mathbf{1} \\ a_{21} & a_{22} & \mathbf{0} \\ a_{31} & a_{32} & \mathbf{0} \end{vmatrix}$$

$\boldsymbol{B}_1$ 的行列式就是余子式 $C_{11} = a_{22}a_{33} - a_{23}a_{32}$. 注意到在 $\det \boldsymbol{B}_2 = -(a_{21}a_{33} - a_{23}a_{31})$ 中出现了负号，这个负号是必要的、正确的. 对应于 $\det \boldsymbol{B}_2$ 的代数余子式 $C_{12}$ 会出现在 $\boldsymbol{A}^{-1}$ 的第一列中，用 $\det \boldsymbol{A}$ 去除这些行列式，由此计算出的 $\boldsymbol{A}^{-1}$ 与之前的结果相同.

$\boldsymbol{A}^{-1}$ 的公式

$$(\boldsymbol{A}^{-1})_{ij} = \frac{C_{ji}}{\det \boldsymbol{A}}, \qquad \boldsymbol{A}^{-1} = \frac{\boldsymbol{C}^{\mathrm{T}}}{\det \boldsymbol{A}} \tag{5.21}$$

### 5.2.3　行列式的完全展开式：$n!$ 项

到目前为止，我们已经找到两个计算 $\det \boldsymbol{A}$（$\boldsymbol{A}$ 的行列式）的公式. 一个是**代数余子式公式**，它将 $\det \boldsymbol{A}$ 简化为阶数更小的行列式的组合（当 $\boldsymbol{A}$ 是三对角矩阵或者有大量的零时，这个方法效

果很好）. 第二个是主元公式，它来自消元法和分解式 $\boldsymbol{PA}=\boldsymbol{LU}$. 这个方法效果也很好，因为 $\boldsymbol{L}$ 和 $\boldsymbol{U}$ 分别是下三角矩阵和上三角，且 $\det \boldsymbol{P}=\pm 1$. 完全展开式并不优秀，因为它包含了 $\det \boldsymbol{A}$ 中的所有 $n!$ 项，项数实在太多了.

每个 $n$ 阶置换矩阵 $\boldsymbol{P}$（有 $n!$ 个这样的 $\boldsymbol{P}$）都在完全展开式中产生一项 $D_{\boldsymbol{P}}$. 每个矩阵 $\boldsymbol{P}$ 都有 $n$ 个 1：每行和每列各有唯一一个非零元 1. 我们乘以 $\boldsymbol{A}$ 在这些位置上的数 $a_{1\alpha}a_{2\beta}\cdots a_{n\omega}$，来找出它们对 $\boldsymbol{A}$ 的行列式的贡献 $D_{\boldsymbol{P}}$. $D_{\boldsymbol{P}}$ 也包含因子 $\det \boldsymbol{P}=\pm 1$，这代表了偶置换或奇置换. 现在将所有像 $ad$ 或者 $aqz$ 这样的项 $D_{\boldsymbol{P}}$ 加起来.

**完全展开式** $\det \boldsymbol{A}=$ 所有 $D_{\boldsymbol{P}}$ 的和 $=$ 来自 $n!$ 个置换矩阵 $\boldsymbol{P}$ 的 $n!$ 项之和. (5.22)

$n=2$ 时，完全展开式正是 $ad-bc$（2 个置换矩阵分别给出 $D_{\boldsymbol{P}}=ad$ 和 $-bc$）. $n=3$ 时有 $3!=6$ 个置换，因此式(5.22)中有 6 项：

$$\det \boldsymbol{A}=\det\begin{bmatrix} a & b & c \\ p & q & r \\ x & y & z \end{bmatrix}=aqz+brx+cpy-ary-bpz-cqx.$$

## 习题 5.2

1. 若 $\det \boldsymbol{A}=2$，$\det(\boldsymbol{A}^{-1})$、$\det(\boldsymbol{A}^{n})$ 和 $\det(\boldsymbol{A}^{\mathrm{T}})$ 分别等于多少？

2. 计算下列矩阵的行列式. 它们的列向量线性无关吗？

$$\boldsymbol{A}=\begin{bmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \\ 0 & 1 & 1 \end{bmatrix} \qquad \boldsymbol{B}=\begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix} \qquad \boldsymbol{C}=\begin{bmatrix} \boldsymbol{A} & 0 \\ 0 & \boldsymbol{A} \end{bmatrix} \qquad \boldsymbol{D}=\begin{bmatrix} \boldsymbol{A} & 0 \\ 0 & \boldsymbol{B} \end{bmatrix}$$

3. 证明：无论 $x$ 取何值，$\det \boldsymbol{A}$ 都等于 0.

$$\boldsymbol{A}=\begin{bmatrix} x & x & x \\ 0 & 0 & x \\ 0 & 0 & x \end{bmatrix}$$

第一行的代数余子式是什么？

$\boldsymbol{A}$ 的秩是多少？

$\det \boldsymbol{A}$ 中的 6 项分别是什么？

4.（1）令 $D_n=\det(\boldsymbol{A}^{n})$. 若 $\boldsymbol{A}$ 的所有元素绝对值都小于 1，当 $n$ 趋于正无穷时，$D_n$ 是否可能趋于无穷？

（2）令 $D_n=\det(\boldsymbol{A}^{n})$. 若 $\boldsymbol{A}$ 的所有元素绝对值都大于 1，当 $n$ 趋于正无穷时，$D_n$ 是否可能趋于零？

**习题 5 ~ 9 关于用克莱姆法则求 $\boldsymbol{x}=\boldsymbol{A}^{-1}\boldsymbol{b}$.**

5. 用克莱姆法则 $x_j=\det \boldsymbol{B}_j/\det \boldsymbol{A}$ 解线性方程组

（1）$\begin{cases} 2x_1+5x_2=1 \\ x_1+4x_2=2 \end{cases}$

（2）$\begin{cases} 2x_1 \quad +x_2 \quad\quad\quad =1 \\ x_1 \quad +2x_2 \quad +x_3 \quad =0 \\ \quad\quad\quad x_2 \quad +2x_3 \quad =0 \end{cases}$

6. 设下面两个方程组的系数矩阵都可逆，请通过克莱姆法则解出未知数 $y$. 简便起见，（2）中方程组的系数矩阵行列式记作 $D$.

(1) $\begin{cases} ax+by=1 \\ cx+dy=2 \end{cases}$　　(2) $\begin{cases} ax+by+cz=1 \\ dx+ey+fz=0 \\ gx+hy+iz=0 \end{cases}$

7. 当系数矩阵行列式 $\det \boldsymbol{A}=0$ 时，克莱姆法则就失效了. 方程组（1）无解而方程组（2）有无穷多解. 对下面（1）（2）两种情形，商 $x_j=\det \boldsymbol{B}_j/\det \boldsymbol{A}$ 分别是什么？[①]

(1) $\begin{cases} 2x_1+3x_2=1 \\ 4x_1+6x_2=1 \end{cases}$ (平行直线)　　(2) $\begin{cases} 2x_1+3x_2=1 \\ 4x_1+6x_2=2 \end{cases}$ (同一条直线)

8. *克莱姆法则的快速证明*. 矩阵转置不改变行列式的值，所以行列式关于第一列也是线性的；若矩阵有两列相同，则行列式值为零. 把 $\boldsymbol{b}=\boldsymbol{A}\boldsymbol{x}=x_1\boldsymbol{a}_1+x_2\boldsymbol{a}_2+x_3\boldsymbol{a}_3$ 替换 $\boldsymbol{A}$ 的第一列得到矩阵 $\boldsymbol{B}_1$ 和克莱姆法则 $x_1=\det \boldsymbol{B}_1/\det \boldsymbol{A}$：

$$\begin{vmatrix} \boldsymbol{b} & \boldsymbol{a}_2 & \boldsymbol{a}_3 \end{vmatrix} = \begin{vmatrix} x_1\boldsymbol{a}_1+x_2\boldsymbol{a}_2+x_3\boldsymbol{a}_3 & \boldsymbol{a}_2 & \boldsymbol{a}_3 \end{vmatrix} = x_1 \begin{vmatrix} \boldsymbol{a}_1 & \boldsymbol{a}_2 & \boldsymbol{a}_3 \end{vmatrix} = x_1 \det \boldsymbol{A}.$$

第二个等号为什么成立？

9. 若 $\boldsymbol{A}$ 可逆，$\boldsymbol{b}$ 等于 $\boldsymbol{A}$ 的第一列，请用克莱姆法则求解该方程组. 克莱姆法则涉及哪些行列式？

10. 设 $\boldsymbol{E}_n$ 是以 1、1、1 为对角线元素的 $n$ 阶三对角矩阵的行列式. 请用按第 1 行展开的代数余子式公式证明：$\boldsymbol{E}_n=\boldsymbol{E}_{n-1}-\boldsymbol{E}_{n-2}$. 易知 $\boldsymbol{E}_1=1, \boldsymbol{E}_2=0$，计算 $\boldsymbol{E}_3, \boldsymbol{E}_4, \cdots, \boldsymbol{E}_8$. 探索其中的规律，$\boldsymbol{E}_{100}$ 是多少？

$$\boldsymbol{E}_1=\begin{bmatrix}1\end{bmatrix}, \quad \boldsymbol{E}_2=\begin{vmatrix}1 & 1\\ 1 & 1\end{vmatrix} \quad \boldsymbol{E}_3=\begin{vmatrix}1 & 1 & 0\\ 1 & 1 & 1\\ 0 & 1 & 1\end{vmatrix} \quad \boldsymbol{E}_4=\begin{vmatrix}1 & 1 & 0 & 0\\ 1 & 1 & 1 & 0\\ 0 & 1 & 1 & 1\\ 0 & 0 & 1 & 1\end{vmatrix}$$

11. 把 $1, 2, \cdots, 9$ 填入 $3\times 3$ 矩阵，行列式可能的最大值是多少？要让我来做这个题，我肯定用计算机来算，这个问题并不容易.

12. 判断正误：$\det(\boldsymbol{ABC})=(\det \boldsymbol{A})(\det \boldsymbol{B})(\det \boldsymbol{C})$.

13. 做消元法，把 $\boldsymbol{A}$ 化成上三角矩阵 $\boldsymbol{U}$，请通过主元乘积来计算 $\det \boldsymbol{A}$.

$$\boldsymbol{A}=\begin{bmatrix}1 & 1 & 1\\ 1 & 2 & 2\\ 1 & 2 & 3\end{bmatrix} \qquad \boldsymbol{A}=\begin{bmatrix}1 & 2 & 3\\ 2 & 2 & 3\\ 3 & 3 & 3\end{bmatrix}$$

14. 做消元法，把矩阵化成上三角矩阵 $\boldsymbol{U}$，请通过主元乘积来计算行列式.

$$\det\begin{bmatrix}1 & 2 & 3 & 0\\ 2 & 6 & 6 & 1\\ -1 & 0 & 0 & 3\end{bmatrix} \qquad \det\begin{bmatrix}1 & -1 & 0 & 0\\ -1 & 2 & -1 & 0\\ 0 & -1 & 2 & -1\\ 0 & 0 & -1 & 2\end{bmatrix}$$

---

① 译者注：读者可能疑惑，$\det \boldsymbol{A}$ 都等于零了，怎么做除数呢？这里我们可以使用微积分的思想，假设系数矩阵为 $A(t)=\begin{bmatrix}2+t & 3\\ 4 & 6+t\end{bmatrix}$，于是可以得出 $x_j(t)=\det \boldsymbol{B}_j(t)/\det \boldsymbol{A}(t)$，考虑 $t\to 0$ 时，$x_j(t)$ 的极限行为.

15. 用初等行变换计算下列行列式：

$$\det\begin{bmatrix}101 & 201 & 301\\ 102 & 202 & 302\\ 103 & 203 & 303\end{bmatrix} \qquad \det\begin{bmatrix}1 & a & a^2\\ 1 & b & b^2\\ 1 & c & c^2\end{bmatrix} = (b-a)(c-a)(c-b)$$

“范德蒙行列式”

16. 对四阶矩阵的行列式，请确定分别对应于行列式的完全展开式中下述三项的置换矩阵 $\boldsymbol{P}$ 的行列式是 $+1$ 还是 $-1$:

$$\pm a_{12}a_{21}a_{34}a_{43} \qquad \pm a_{13}a_{22}a_{31}a_{44} \qquad \pm a_{11}a_{22}a_{34}a_{43}$$

17.（1）若 $\boldsymbol{A}$ 是三阶方阵，$a_{11}=a_{22}=a_{33}=0$. 那么 $\det \boldsymbol{A}$ 的完全展开式的 6 项中，有几项是 0?

（2）若 $\boldsymbol{A}$ 是四阶方阵，$a_{11}=a_{22}=a_{33}=a_{44}=0$. 那么 $\det \boldsymbol{A}$ 的完全展开式的 24 项中，有几项是 0?

18. 行列式的完全展开式有 $n!$ 项. 但如果矩阵 $\boldsymbol{A}$ 的某个元素为零，则 $(n-1)!$ 项会消失. 如果 $\boldsymbol{A}$ 只有三条对角线非零（即除了对角线、对角线上下方两条次对角线外都是零），那么还剩下多少项？

当 $n=1$、2、3、4 时，三对角矩阵 $\boldsymbol{A}$ 的行列式的完全展开式分别有 1、2、3、5 项非零. 这些都是斐波那契数列中的数！请说明为什么一个满足题意的五阶方阵的行列式有 $5+3=8$ 项非零（又是斐波那契数!）.

提示：利用 $a_{11}$ 和 $a_{12}$ 的代数余子式来证明.

19. 如果 $\boldsymbol{A}$ 是四阶方阵，那么 $\boldsymbol{A}$ 的行列式的完全展开式有 24 项. 在 $\det(\boldsymbol{A})$ 中，包含 $a_{13}$ 和 $a_{22}$ 的项分别有多少个？

写下 $\det(\boldsymbol{A})$ 的全部 24 项是一个挑战，所以把 24 项都写下来然后数其中包含 $a_{13}$ 和 $a_{22}$ 的项是个笨方法，不建议采用.

## 5.3 行列式与面积和体积

（1）$\mathbb{R}^2$ 上的平行四边形以点 $(0,0)$ 为起点，其两边分别为 $\boldsymbol{e}_1=\begin{bmatrix}a & b\end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{e}_2=\begin{bmatrix}c & d\end{bmatrix}^{\mathrm{T}}$.

（2）平行四边形的面积 = 矩阵 $\boldsymbol{E}$ 行列式的绝对值 $=|ad-bc|$，其中 $\boldsymbol{E}=\begin{bmatrix}\boldsymbol{e}_1 & \boldsymbol{e}_2\end{bmatrix}$.

（3）$\mathbb{R}^3$ 上的平行多面体以点 $(0,0,0)$ 为起点，以三个向量 $\boldsymbol{e}_1$、$\boldsymbol{e}_2$、$\boldsymbol{e}_3$ 为三条边.

（4）平行多面体的体积 $=\left|\det\begin{bmatrix}\boldsymbol{e}_1 & \boldsymbol{e}_2 & \boldsymbol{e}_3\end{bmatrix}\right|$.

行列式给出了面积和体积的公式，非常优美. 这些区域的边是线段，但它们并非正方形. 一个典型的区域是平行四边形——或者平行四边形的一半，即三角形. 那么问题来了：怎么求面积呢？对于三角形，其面积为 $\frac{1}{2}bh$：底的一半乘以高. 平行四边形包含两个等面积的三角形，所以 $\frac{1}{2}$ 就不需要了. 因此，平行四边形的面积 = 底乘以高.

这些公式很容易记住，但它们不适用于我们的问题，因为我们没有给出底和高. 我们只知道顶点的位置. 对于三角形，假设顶点为 $(0,0)$、$(a,b)$ 和 $(c,d)$. 对于（面积是三角形的两倍）平行四边形，

第四个顶点将是 $(a+c, b+d)$（见图 5.2）. 若已知 $a$、$b$、$c$、$d$，平行四边形面积是多少？可以取下面那条边为底，长度为 $\sqrt{a^2+b^2}$. 为了找到高，从点 $(c,d)$ 作一条垂直于底边的直线，这条垂线的长度 $h$ 会涉及更多关于平方根的运算. 但是面积本身并不包含平方根！它有一个优美的公式 $|ad-bc|$！当 $a=d=1$、$b=c=0$（即一个正方形）时，结果非常简单，可以直接看出来符合我们的公式.

$$\boxed{\text{平行四边形的面积} = |\text{矩阵的行列式}| = \pm\begin{vmatrix} a & c \\ b & d \end{vmatrix} = |ad-bc|} \tag{5.23}$$

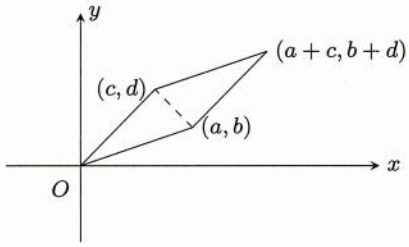


图 5.2　平面上的平行四边形

我们的目标是通过线性代数找到该公式，它不包含平方根或负体积. 后者好处理，取绝对值 $|ad-bc|$ 就可以避免面积出现负值.

我们还有一个更困难的目标，研究三维空间中的平行多面体[①]，并最终扩展到 $n$ 维空间. 设三维空间中平行多面体的一个顶点是 $(0,0,0)$，从它出发的三条边连接了点 $(a,b,c)$、$(p,q,r)$ 和 $(x,y,z)$.（每一面都是一个平行四边形，它看起来会有些斜.）遵循面积公式(5.23)的启示，我们可以得出正确的体积公式：

$$\boxed{\text{平行多面体的体积} = |\text{矩阵的行列式}| = \pm\begin{vmatrix} a & p & x \\ b & q & y \\ c & r & z \end{vmatrix}} \tag{5.24}$$

我们仍然首先在平面上尝试. 这种情况，我们使用点平面几何. 图 5.3展示了如何添加一些小部件把平行四边形增大成矩形. 把矩形面积减去这 6 个小块的面积就能得到平行四边形面积的正确公式 $\boldsymbol{ad-bc}$（不包含平方根）. 虽然这幅图看起来不太优雅，但在二维空间上，即平面上，它相当成功.

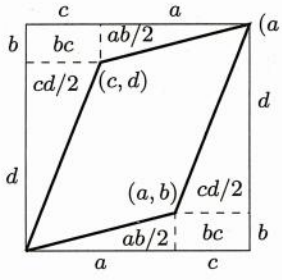


$(a+c, b+d) =$ 矩形的底和高

平行四边形的面积

= 矩形面积 −6 小块的面积

$= (a+c)(b+d) - 2bc - ab - cd$

$= ad - bc$

图 5.3　增加 6 小块，把平行四边形扩张成长方形

① 译者注：给定 $n$ 维空间中的 $n$ 个向量 $\boldsymbol{e}_1, \boldsymbol{e}_2, \cdots, \boldsymbol{e}_n$，它们围成的平行多面体定义为

$$\{\lambda_1\boldsymbol{e}_1 + \lambda_2\boldsymbol{e}_2 + \cdots + \lambda_n\boldsymbol{e}_n : 0 \leqslant \lambda_1, \lambda_2, \cdots, \lambda_n \leqslant 1\}.$$

在三维空间中，是否可能构建类似的结构？参照图 5.3，我原以为可以通过添加一些简单部分，把平行六面体补充成长方体. 但是实际上并不容易，而且我们有更好的方法：使用线性代数.

在处理这个问题的过程中，我逐渐有了一些数学方法论上的体会. 多引入一些代数，那么所需的几何就会减少一些. 很多时候，线性代数的问题都可以归结为矩阵分解. 我们将从中寻找解决问题的思路.

$n$ 维空间中，从原点出发的 $n$ 条边 $\boldsymbol{e}_1, \boldsymbol{e}_2, \cdots, \boldsymbol{e}_n$ 确定了一个平行多面体. 在二维空间，平行四边形有两个向量 $\boldsymbol{e}_1 = \begin{bmatrix} a & b \end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{e}_2 = \begin{bmatrix} c & d \end{bmatrix}^{\mathrm{T}}$. 这些向量 $\boldsymbol{e}$ 给出了平行多面体的两个顶点（在二维情况下是两个顶点，在 $n$ 维情况下则是 $n$ 个顶点）. 在二维图中，第四个顶点是 $\boldsymbol{e}_1 + \boldsymbol{e}_2$. 在 $n$ 维空间，平行多面体的其他顶点则是向量 $\boldsymbol{e}_1, \boldsymbol{e}_2, \cdots, \boldsymbol{e}_n$ 中一部分的和. 这个平行多面体完全由 $n$ 条边构成的矩阵 $\boldsymbol{E}$ 决定：

$$\text{边构成的矩阵} \quad \boldsymbol{E}_2 = \begin{bmatrix} a & c \\ b & d \end{bmatrix} \qquad \boldsymbol{E}_n = \begin{bmatrix} \boldsymbol{e}_1 & \cdots & \boldsymbol{e}_n \end{bmatrix} \quad \text{列向量} = \text{边}$$

我们的目标是证明平行多面体的体积等于 $|\det \boldsymbol{E}|$. 为了达成这一目标，我们可以借助第 2 章、第 4 章、第 7 章中的三种矩阵分解，任意一种都能成功. 第三种矩阵分解就是所谓的奇异值分解（SVD）：

| | |
|---|---|
| 下三角矩阵乘以上三角矩阵 | $\boldsymbol{E} = \boldsymbol{L}\boldsymbol{U}_1$ |
| 正交矩阵乘以上三角矩阵 | $\boldsymbol{E} = \boldsymbol{Q}\boldsymbol{R}$ |
| 正交矩阵—对角矩阵—正交矩阵 | $\boldsymbol{E} = \boldsymbol{U}_2\boldsymbol{\Sigma}\boldsymbol{V}^{\mathrm{T}}$ |

由于 $\boldsymbol{E}$ 是 $n$ 阶方阵，上述三个分解式中所有矩阵也都是 $n$ 阶方阵. $\boldsymbol{L}$ 的对角元都是 1，所以它的行列式也是 1. 正交矩阵的行列式等于 1 或者 $-1$，从而

$$\det \boldsymbol{L} = |\det \boldsymbol{Q}| = |\det \boldsymbol{U}_2| = |\det \boldsymbol{V}| = 1.$$

毫无疑问，这个等式来源于行列式的乘性 $\det(\boldsymbol{A}\boldsymbol{B}) = (\det \boldsymbol{A})(\det \boldsymbol{B})$. 根据这三种矩阵分解：

$$\text{平行多面体的体积} = |\det \boldsymbol{E}| = |\det \boldsymbol{U}_1| = |\det \boldsymbol{R}| = |\det \boldsymbol{\Sigma}| \tag{5.25}$$

其中本质的难点在于如何把平行多面体的体积和等式中任意一个行列式联系起来，也就是如何把几何和线性代数联系起来. 要研究这个问题，我们从正交矩阵的几何开始.

核心的要点是 $\mathbb{R}^n$ 中任意区域中的所有点被正交矩阵 $\boldsymbol{Q}$ 乘了之后得到的新区域与原区域体积相同. 我们首先来理解这个论断，再用矩阵分解 $\boldsymbol{E} = \boldsymbol{Q}\boldsymbol{R}$ 去研究一般情形.

用一般的矩阵去乘，线段还是线段，但是长度会变化；如果是区域，那么体积也会变化.

用正交矩阵 $\boldsymbol{Q}$ 去乘：$\boldsymbol{x}^{\mathrm{T}}\boldsymbol{x} = (\boldsymbol{Q}\boldsymbol{x})^{\mathrm{T}}(\boldsymbol{Q}\boldsymbol{x}), \boldsymbol{x}^{\mathrm{T}}\boldsymbol{y} = (\boldsymbol{Q}\boldsymbol{x})^{\mathrm{T}}(\boldsymbol{Q}\boldsymbol{y})$.

平行多面体的边长、夹角、形状以及体积等几何性质在正交矩阵的作用下保持不变. 对于不规则的区域，这一结论也同样成立，因为我们可以将其划分为许多小立方体以及一些薄的不规则部分，这些薄的不规则部分的总体积可以任意小；而小立方体的体积在 $\boldsymbol{Q}$ 的作用下保持不变. 弄清楚这一点，就可以知道 $\boldsymbol{R}$ 和 $\boldsymbol{E} = \boldsymbol{Q}\boldsymbol{R}$ 两者的列向量围成的平行多面体体积相同.

$\boldsymbol{R}$ 是上三角矩阵，它的列向量围成的平行多面体体积可以直接计算. 二阶方阵的 $\boldsymbol{E} = \boldsymbol{Q}\boldsymbol{R}$，那么 $\boldsymbol{R}$ 列向量在平面上围出一个平行四边形，底和高分别是 $\boldsymbol{R}$ 的对角元 $u$ 和 $w$.

二阶上三角矩阵对应的平行四边形及其面积如图 5.4所示.

$$\boldsymbol{R}=\begin{bmatrix} u & v \\ 0 & w \end{bmatrix}$$

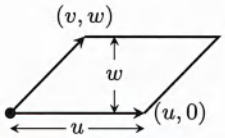


底 $=u$，高 $=w$

$|\text{面积}| = |u \cdot w| = |\det \boldsymbol{R}|$

图 5.4　二阶上三角矩阵对应的平行四边形及其面积

高维情形类似，其中的关键事实是矩阵 $\boldsymbol{R}$ 的主对角线是平行多面体在每个新维度上的高度. **$\boldsymbol{R}$ 的对角元相乘即得平行多面体的体积，同时也是上三角矩阵 $\boldsymbol{R}$ 的行列式.** 由于 $|\det \boldsymbol{Q}| = 1$ 且 $|\det \boldsymbol{E}| = |\det \boldsymbol{R}|$，我们就证明了：$n$ 阶方阵 $\boldsymbol{E}$ 的列向量在 $\mathbb{R}^n$ 上围成的平行多面体体积为 $|\det \boldsymbol{E}|$.

注：奇异值分解 $\boldsymbol{E} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\mathrm{T}}$ 涉及两个正交矩阵 $\boldsymbol{U}$ 和 $\boldsymbol{V}$，于是 $|\det \boldsymbol{E}| = |\det \boldsymbol{\Sigma}|$. 而 $\boldsymbol{\Sigma}$ 是对角矩阵，它的列向量围成的平行多面体是 $\mathbb{R}^n$ 中标准的“长方体”. 奇异值分解 $\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\mathrm{T}}$ 貌似比 $\boldsymbol{Q}\boldsymbol{R}$ 分解要简单，因为 $\boldsymbol{R}$ 的列向量围成的平行多面体是“斜”的.

简单或者复杂并不是我们选择时要考虑的唯一因素，几何背景对于我们理解代数也是至关重要的. $\boldsymbol{R}$ 的对角元的几何含义非常清晰：各个维度上的高. 奇异值分解的几何意义将在第 7 章中介绍. 对于 $n$ 维空间中的平行多面体，奇异值的几何含义不那么清晰；奇异值的几何含义在于椭圆，$\boldsymbol{\Sigma}$ 给出了椭圆各个轴的长度，而不是平行多面体的边长. 对于一个各边都是线段的平行多面体，$\det \boldsymbol{E} = \boldsymbol{Q}\boldsymbol{R}$ 直接给出导出平行多面体的体积 $= |\det \boldsymbol{R}|$.

几何体所有点乘以 $\boldsymbol{E}$，得到的新几何体体积都是原几何体体积的 $|\det \boldsymbol{E}|$ 倍.

## 习题 5.3

1. 设 $(0,0,0)$、$(1,0,0)$、$(0,1,0)$、$(0,0,1)$ 是 $\mathbb{R}^3$ 中立方体的四个顶点. 哪个矩阵 $\boldsymbol{E}$ 的列向量围成了这个立方体？若一个平行多面体由从原点出发的三个向量 $\boldsymbol{e}_1$、$\boldsymbol{e}_2$、$\boldsymbol{e}_3$ 围成，请写出它的 8 个顶点.

2. 设 $\boldsymbol{e}_1$、$\boldsymbol{e}_2$、$\boldsymbol{e}_3$ 是 $\mathbb{R}^3$ 中三个两两正交的单位向量. 从原点出发，它们围成的平行多面体是什么形状？计算该平行多面体的体积.

3. 若 $\mathbb{R}^3$ 中某平行多面体连接某个顶点的三条边长是 $\|\boldsymbol{e}_1\| = 1, \|\boldsymbol{e}_2\| = 2, \|\boldsymbol{e}_3\| = 3$. 猜一猜这样的平行多面体体积最大可能是多少？什么时候能取到最大值？

4. 设 $n$ 阶方阵 $\boldsymbol{E}$ 的列向量是 $\boldsymbol{e}_1, \boldsymbol{e}_2, \cdots, \boldsymbol{e}_n$. 那么习题 3 实际上证明：

$$|\det \boldsymbol{E}| \leqslant \text{边长的乘积} = \|\boldsymbol{e}_1\| \, \|\boldsymbol{e}_2\| \cdots \|\boldsymbol{e}_n\| .$$

提示：利用矩阵分解 $\boldsymbol{E} = \boldsymbol{Q}\boldsymbol{R}$，证明 $\boldsymbol{R}$ 的对角元满足 $R_{ii} \leqslant \|\boldsymbol{e}_i\|$.

5.（1）求以 $\boldsymbol{v} = \begin{bmatrix} 3 & 2 \end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{w} = \begin{bmatrix} 1 & 4 \end{bmatrix}^{\mathrm{T}}$ 为两条边的平行四边形的面积.

（2）$\boldsymbol{v}$、$\boldsymbol{w}$ 如上，画出以 $\boldsymbol{v}$、$\boldsymbol{w}$、$\boldsymbol{v}+\boldsymbol{w}$ 为边的三角形，并求它的面积.

（3）$\boldsymbol{v}$、$\boldsymbol{w}$ 如上，画出以 $\boldsymbol{v}$、$\boldsymbol{w}$、$\boldsymbol{w}-\boldsymbol{v}$ 为边的三角形，并求它的面积.

6.（1）设三角形的三个顶点坐标是 $(2,1)$、$(3,4)$ 和 $(0,5)$，求它的面积.

（2）在上一小题中增加顶点 $(-1,0)$，成为一个四边形（不是平行四边形），求该四边形的面积.

7. 下述阿达玛矩阵 $\boldsymbol{H}$ 是列正交矩阵，列向量围成的平行多面体是超立方体！计算 $|\det \boldsymbol{H}|$，它也是 $\mathbb{R}^4$ 中边长为 2 的超立方体的体积.

$$\boldsymbol{H}=\begin{bmatrix}1 & 1 & 1 & 1\\ 1 & 1 & -1 & -1\\ 1 & -1 & -1 & 1\\ 1 & -1 & 1 & -1\end{bmatrix}$$

8. $n$ 维空间中的立方体有多少个顶点？多少条边？多少个 $(n-1)$ 维面？$\mathbb{R}^n$ 中以 $2\boldsymbol{I}$ 的列向量为边的立方体体积是_____.

超立方体计算机在顶点处设有并行处理器，并通过边相互连接.

9. 以 $(0,0)$、$(1,0)$、$(0,1)$ 为顶点的三角形面积是 $\frac{1}{2}$. $\mathbb{R}^3$ 中以 $(0,0,0)$、$(1,0,0)$、$(0,1,0)$、$(0,0,1)$ 为顶点的四面体体积是_____. $\mathbb{R}^4$ 中以 $(0,0,0,0)$ 和 $\boldsymbol{I}$ 的列向量为顶点的锥体[①]体积是多少？

10. 若平行多面体的边构成的子矩阵是正交矩阵，则它的体积是_____.

若平行多面体的边构成的矩阵是奇异矩阵，则它的体积是_____.

若 $n$ 阶方阵 $\boldsymbol{E}$ 的列向量围成的平行多面体体积是 $V$，则 $2\boldsymbol{E}$ 的列向量围成的平行多面体体积是_____.

11. 分别画出矩阵 $\begin{bmatrix}2 & 1\\ 3 & 4\end{bmatrix}$ 和 $\begin{bmatrix}2 & 3\\ 1 & 4\end{bmatrix}$ 围成的平行四边形. 你能否说明为什么这两个平行四边形面积相等？

12. 将矩阵 $\begin{bmatrix}u & v\\ 0 & w\end{bmatrix}$ 转置，则两个矩阵行列式相等，并且两个矩阵的列向量围成的平行四边形面积相等. 请在 $\mathbb{R}^2$ 上画出这两个平行四边形，并分别计算面积.

13. 在 $\mathbb{R}^2$ 上画出以原点为顶点，向量 $\begin{bmatrix}a & b\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}c & d\end{bmatrix}^{\mathrm{T}}$ 围成的平行四边形 $P$，则有

$$\text{面积}=\left|\det\begin{bmatrix}a & c\\ b & d\end{bmatrix}\right|=\left|\det\begin{bmatrix}a & 0\\ 0 & d\end{bmatrix}+\det\begin{bmatrix}0 & c\\ b & 0\end{bmatrix}\right|$$

你能看出如何从边长为 $a$ 和 $d$ 的矩形以及边长为 $b$ 和 $c$ 的矩形构造出平行四边形 $P$ 吗？

14. 设 5 阶方阵 $\boldsymbol{A}$ 的 25 个元素分别是 5 个 1 和 20 个 2，$\det(\boldsymbol{A})$ 能取到的最大值是多少？

15. 设 2 阶方阵 $\boldsymbol{E}=\begin{bmatrix}\boldsymbol{e}_1 & \boldsymbol{e}_2\end{bmatrix}$. 证明 $|\det \boldsymbol{E}|\leqslant\|\boldsymbol{e}_1\|\cdot\|\boldsymbol{e}_2\|$. 这是二阶方阵的 Hadamar 不等式. 这是习题 4 当 $n=2$ 时的简单情形，可以从它开始探索一般情形时的解题思路. 由本题也可推知平行四边形的面积小于或等于相邻边长的乘积.

---

① $n$ 维空间中，以原点和 $\boldsymbol{e}_1,\boldsymbol{e}_2,\cdots,\boldsymbol{e}_n$ 为顶点的锥体是 $\left\{\sum_{i=1}^{n}\lambda_i\boldsymbol{e}_i:\lambda_1,\lambda_2,\cdots,\lambda_n\geqslant 0\text{且}\sum_{i=1}^{n}\lambda_i\leqslant 1\right\}$.

# 第 6 章

CHAPTER 6

# 特征值和特征向量

特征值和特征向量提供了关于方阵的新信息，远比它的秩或列空间更为深刻. 我们寻找被 $\boldsymbol{A}$ 相乘时方向不变的特征向量 $\boldsymbol{x}$. 此时有$\boldsymbol{Ax}=\lambda\boldsymbol{x}$[①]，其中$\lambda$ 为特征值（可以称 $\lambda$ 为拉伸因子）. 再乘一次得 $\boldsymbol{A}^2\boldsymbol{x}=\lambda^2\boldsymbol{x}$. 当然可以一直推导，得到 $\boldsymbol{A}^{100}\boldsymbol{x}=\lambda^{100}\boldsymbol{x}$. 我们还可以将两个或多个特征向量进行组合，若 $\boldsymbol{Ax}_1=\lambda_1\boldsymbol{x}_1,\boldsymbol{Ax}_2=\lambda_2\boldsymbol{x}_2$，那么

$$\boldsymbol{A}(\boldsymbol{x}_1+\boldsymbol{x}_2)=\lambda_1\boldsymbol{x}_1+\lambda_2\boldsymbol{x}_2 \qquad \boldsymbol{A}^2(c_1\boldsymbol{x}_1+c_2\boldsymbol{x}_2)=c_1\lambda_1^2\boldsymbol{x}_1+c_2\lambda_2^2\boldsymbol{x}_2$$

当我们将给定向量拆分为特征向量时，每个特征向量都会在其自身的方向上伸缩.

特征值是 $\boldsymbol{A}^n\boldsymbol{x}=\lambda^n\boldsymbol{x}$ 中的增长因子. 若所有 $|\lambda_i|<1$，则 $\boldsymbol{A}^n$ 最终将收敛于零矩阵；若所有 $|\lambda_i|>1$，则 $\boldsymbol{A}^n$ 会指数级膨胀. 若 $\lambda=1$，则对任意 $n$，$\lambda^n\boldsymbol{x}$ 都等于 $\boldsymbol{x}$，保持不变（此时 $\boldsymbol{x}$ 是 $\boldsymbol{A}$ 作用下的稳定状态）. 对于一个国家、一家公司或一个家庭的经济状况而言，$\lambda$ 的大小是一个至关重要的数字.

矩阵的性质体现在其特征值 $\lambda$ 和特征向量 $\boldsymbol{x}$ 中. 对称矩阵[②]$\boldsymbol{S}$ 有一族两两正交的特征向量，且其所有特征值都是实数. 线性代数中最强的矩阵是特征值全都是正实数的对称矩阵. 这些“正定矩阵”蕴含着像能量函数 $f(\boldsymbol{x})=\frac{1}{2}\boldsymbol{x}^{\mathrm{T}}\boldsymbol{Sx}$ 等函数的最小值点. 和一元微积分对比，函数 $f(x)$ 取得最小值时，$\mathrm{d}^2f/\mathrm{d}x^2>0$，因而正定矩阵是该判别条件的 $n$ 维形式.

本章结束于求解线性微分方程 $\mathrm{d}\boldsymbol{u}/\,\mathrm{d}t=\boldsymbol{Au}$. 解不再形如 $\boldsymbol{u}_n=\lambda^n\boldsymbol{x}$，而是 $\boldsymbol{u}(t)=\mathrm{e}^{\lambda t}\boldsymbol{x}$——函数是指数形式而不是幂形式. 通解是 $\boldsymbol{u}(t)=\mathrm{e}^{\boldsymbol{A}t}\boldsymbol{u}(0)$. 对于有常系数矩阵 $\boldsymbol{A}$ 的线性微分方程，用特征向量来求解是很精妙的方法.

6.4节讲述了复数矩阵的知识，包括著名的傅里叶矩阵.

## 6.1 初识特征值 $A\boldsymbol{x}=\lambda\boldsymbol{x}$

（1）若 $\boxed{\boldsymbol{Ax}=\lambda\boldsymbol{x}}$ 且 $\boldsymbol{x}\neq\boldsymbol{0}$，则 $\boldsymbol{x}$ 是 $\boldsymbol{A}$ 的特征向量，$\lambda$ 是 $\boldsymbol{A}$ 的特征值.

（2）在（1）的前提下，对任意 $n\geqslant 1$ 都有 $\boxed{\boldsymbol{A}^n\boldsymbol{x}=\lambda^n\boldsymbol{x}}$，而且 $(\boldsymbol{A}+c\boldsymbol{I})\boldsymbol{x}=(\lambda+c)\boldsymbol{x}$. 如果

① 译者注：因为特征值和特征向量不是两个各自独立的对象，如果 $\boldsymbol{x}\neq 0$ 且 $\boldsymbol{Ax}=\lambda\boldsymbol{x}$，我们通常称 $\boldsymbol{x}$ 是属于特征值 $\lambda$ 的特征向量，有时也称 $(\lambda,\boldsymbol{x})$ 是特征对.

② 译者注：需要强调的是，本章的对称矩阵如果不是在 6.4 节或者有特别说明，都是指实对称矩阵，矩阵的每个元素都是实数.

$\boldsymbol{A}$ 可逆，则 $\lambda \neq 0$ 且 $\boldsymbol{A}^{-1}\boldsymbol{x} = \lambda^{-1}\boldsymbol{x}$.

（3）$(\boldsymbol{A} - \lambda \boldsymbol{I})\boldsymbol{x} = \boldsymbol{0}(\boldsymbol{x} \neq \boldsymbol{0}) \Rightarrow \det(\boldsymbol{A} - \lambda \boldsymbol{I}) = 0$，由此得到一个关于 $\lambda$ 的 $n$ 次多项式方程.

（4）若 $\lambda_1, \lambda_2, \cdots, \lambda_n$ 是方程 $\det(\boldsymbol{A} - \lambda \boldsymbol{I}) = 0$ 的 $n$ 个根，则

$$\lambda_1 \lambda_2 \cdots \lambda_n = \det \boldsymbol{A}, \lambda_1 + \lambda_2 + \cdots + \lambda_n = a_{11} + a_{22} + \cdots + a_{nn}(\text{即对角元的和}).$$

（5）投影矩阵的特征值只有 $\lambda = 1, 0$. 旋转矩阵的特征值是 $\lambda = \mathrm{e}^{\mathrm{i}\theta}$、$\mathrm{e}^{-\mathrm{i}\theta}$，都是复数.

从本章开始线性代数进入了新篇章. 先前都是研究静态的线性方程组 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$. 现在则转入动态的内容. 时间被引入了这个框架中——微分方程 $\mathrm{d}\boldsymbol{u}/\mathrm{d}t = \boldsymbol{A}\boldsymbol{u}$ 中的连续时间，或在递归式 $\boldsymbol{u}_{k+1} = \boldsymbol{A}\boldsymbol{u}_k$ 中表现为离散的时间 $k = 1, 2, 3, \cdots$. 这些方程并不是通过消元法来求解的.

解决问题的关键在于把高维的问题转化成一维的问题. 我们的目标是找到被矩阵 $\boldsymbol{A}$ 相乘后方向不变的“特征向量” $\boldsymbol{x}$. 例如，微分方程的解 $\boldsymbol{u}(t)$（或者差分方程的解 $\boldsymbol{u}_k$）与向量 $\boldsymbol{x}$ 方向相同，只需求出（随时间变化的）其关于 $\boldsymbol{x}$ 倍数即可：这是一维的问题.

矩阵幂 $\boldsymbol{A}, \boldsymbol{A}^2, \boldsymbol{A}^3, \cdots$ 是一个良好的模型. 假设需要计算 $\boldsymbol{A}^{100}$，它的列向量会非常接近特征向量 $\boldsymbol{x} = \begin{bmatrix} 0.6 & 0.4 \end{bmatrix}^{\mathrm{T}}$：

$$\boldsymbol{A} = \begin{bmatrix} 0.8 & 0.3 \\ 0.2 & 0.7 \end{bmatrix} \quad \boldsymbol{A}^2 = \begin{bmatrix} 0.70 & 0.45 \\ 0.30 & 0.55 \end{bmatrix} \quad \boldsymbol{A}^3 = \begin{bmatrix} 0.650 & 0.525 \\ 0.350 & 0.475 \end{bmatrix} \quad \boldsymbol{A}^{100} \approx \begin{bmatrix} 0.6000 & 0.6000 \\ 0.4000 & 0.4000 \end{bmatrix}$$

我们通过 $\boldsymbol{A}$ 的特征值 1 和 1/2 来求 $\boldsymbol{A}^{100}$，而不是直接地连续乘 100 次. 特征值和特征向量是深入了解矩阵本质核心的新方法.

在解释特征值之前，我们先解释特征向量. 几乎所有的向量被矩阵 $A$ 左乘，方向都会改变. 然而，某些特殊的向量 $\boldsymbol{x}$ 与 $\boldsymbol{A}\boldsymbol{x}$ 的方向相同[①]，这就是“特征向量”. 我们不妨假设特征向量 $\boldsymbol{x}$ 被 $\boldsymbol{A}$ 左乘，得到的向量 $\boldsymbol{A}\boldsymbol{x}$ 是原向量 $\boldsymbol{x}$ 的 $\lambda$ 倍.

**基本方程是 $\boldsymbol{A}\boldsymbol{x} = \lambda \boldsymbol{x}$. 其中的常数 $\lambda$ 是 $\boldsymbol{A}$ 的特征值.**

特征值 $\lambda$ 告诉我们，这个特殊的向量 $\boldsymbol{x}$ 被矩阵 $\boldsymbol{A}$ 左乘后，它是被拉伸、压缩还是反向. 我们有可能求出 $\lambda = 2$ 或 $1/2$ 或 $-1$，甚至可能为 0！$\boldsymbol{A}\boldsymbol{x} = 0\boldsymbol{x}$ 意味着特征向量 $\boldsymbol{x}$ 属于 $\boldsymbol{A}$ 零空间.

如果 $\boldsymbol{A}$ 是单位矩阵，那么所有向量都满足 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{x}$. 于是所有向量都是单位矩阵 $\boldsymbol{I}$ 的特征向量，所有特征值 $\lambda$ 都是 $\lambda = 1$. 这种情况并不常见. 大多数二阶方阵有两个特征向量方向和两个特征值. 我们将证明特征值 $\lambda$ 满足 $\det(\boldsymbol{A} - \lambda \boldsymbol{I}) = 0$.

本节将解释如何计算特征向量 $\boldsymbol{x}$ 和特征值 $\lambda$. 对于二阶方阵，其实只需要知道二阶方阵的行列式是 $\boldsymbol{ad - bc}$，我们早就可以学习这一部分内容了. 例 6.1用 $\det(\boldsymbol{A} - \lambda \boldsymbol{I}) = 0$ 求出了上面提到的矩阵 $\boldsymbol{A}$ 的特征值 $\lambda = 1$ 和 $\lambda = 1/2$.

**例 6.1** 对于矩阵 $\boldsymbol{A} = \begin{bmatrix} 0.8 & 0.3 \\ 0.2 & 0.7 \end{bmatrix}$ 有

① 译者注：$\boldsymbol{A}\boldsymbol{x}$ 和 $\boldsymbol{x}$ 方向相同并不完全是直观意义上的相同，而是指共线，或者说线性相关.

$$\det(\boldsymbol{A}-\lambda\boldsymbol{I})=\det\begin{bmatrix}0.8-\lambda & -0.3\\ 0.2 & 0.7-\lambda\end{bmatrix}=\lambda^2-\frac{3}{2}\lambda+\frac{1}{2}=(\lambda-1)\left(\lambda-\frac{1}{2}\right)$$

两个关键系数是 $\boldsymbol{A}$ 的对角元之和 $0.8+0.7=3/2$ 以及 $\boldsymbol{A}$ 的行列式 $0.8\cdot0.7-0.3\cdot0.2=1/2$. 把二次多项式分解因式，求出两个特征值 $\lambda=1$ 和 $\lambda=1/2$. 这说明 $\boldsymbol{A}-\boldsymbol{I}$ 和 $\boldsymbol{A}-\frac{1}{2}\boldsymbol{I}$ 不可逆（行列式是 0）. 特征向量 $\boldsymbol{x}_1$ 和 $\boldsymbol{x}_2$ 分别属于 $\boldsymbol{A}-\boldsymbol{I}$ 和 $\boldsymbol{A}-\frac{1}{2}\boldsymbol{I}$ 的零空间：

$(\boldsymbol{A}-\boldsymbol{I})\boldsymbol{x}_1=\boldsymbol{0}$ 即 $\boldsymbol{A}\boldsymbol{x}_1=\boldsymbol{x}_1$. 第一个特征向量是 $\boldsymbol{x}_1=\begin{bmatrix}0.6 & 0.4\end{bmatrix}^{\mathrm{T}}$.

$\left(\boldsymbol{A}-\frac{1}{2}\boldsymbol{I}\right)\boldsymbol{x}_2=\boldsymbol{0}$ 即 $\boldsymbol{A}\boldsymbol{x}_2=\frac{1}{2}\boldsymbol{x}_2$. 第二个特征向量是 $\boldsymbol{x}_2=\begin{bmatrix}0.5 & -0.5\end{bmatrix}^{\mathrm{T}}$.

也就是说

$$\boldsymbol{x}_1=\begin{bmatrix}0.6\\0.4\end{bmatrix}\quad\text{满足}\quad\boldsymbol{A}\boldsymbol{x}_1=\begin{bmatrix}0.8 & 0.3\\0.2 & 0.7\end{bmatrix}\begin{bmatrix}0.6\\0.4\end{bmatrix}=\begin{bmatrix}0.6\\0.4\end{bmatrix}\qquad(\boldsymbol{A}\boldsymbol{x}_1=\boldsymbol{x}_1\text{ 意味着 }\lambda_1=1)$$

$$\boldsymbol{x}_2=\begin{bmatrix}1\\-1\end{bmatrix}\quad\text{满足}\quad\boldsymbol{A}\boldsymbol{x}_2=\begin{bmatrix}0.8 & 0.3\\0.2 & 0.7\end{bmatrix}\begin{bmatrix}1\\-1\end{bmatrix}=\begin{bmatrix}0.5\\-0.5\end{bmatrix}\qquad\left(\boldsymbol{A}\boldsymbol{x}_2=\frac{1}{2}\boldsymbol{x}_2\text{ 意味着 }\lambda_2=\frac{1}{2}\right)$$

由 $\boldsymbol{A}\boldsymbol{x}_1=\boldsymbol{x}_1$ 可得 $\boldsymbol{A}^2\boldsymbol{x}_1=\boldsymbol{A}\boldsymbol{x}_1=\boldsymbol{x}_1$，并且对 $\boldsymbol{A}$ 的任意方幂都有 $\boldsymbol{A}^n\boldsymbol{x}_1=\boldsymbol{x}_1$. 而 $\boldsymbol{A}\boldsymbol{x}_2=\frac{1}{2}\boldsymbol{x}_2$，再乘一次可知 $\boldsymbol{A}^2\boldsymbol{x}_2=\left(\frac{1}{2}\right)^2\boldsymbol{x}_2$.

$\boldsymbol{A}$ 的特征向量也是 $\boldsymbol{A}^2$ 的特征向量，但是特征值是原特征值的平方.

该结论之所以成立，是因为特征向量 $\boldsymbol{x}_1$ 和 $\boldsymbol{x}_2$ 在 $\boldsymbol{A}^2$ 的作用下也保持在它们各自的方向上. $\boldsymbol{A}^{100}$ 的特征值是 $1^{100}$ 和 $\left(\frac{1}{2}\right)^{100}$，后者几乎等于零.

对任意 $n\geqslant1$，$\boldsymbol{A}$ 的特征向量都是 $\boldsymbol{A}^n$ 的特征向量，并且 $\boldsymbol{A}^n\boldsymbol{x}=\lambda^n\boldsymbol{x}$.

其他向量如果不是特征向量，那么左乘 $\boldsymbol{A}$ 之后方向会改变. 但是其他向量都是 $\boldsymbol{x}_1$ 和 $\boldsymbol{x}_2$ 的线性组合，例如 $\boldsymbol{A}$ 的第一个列向量 $\begin{bmatrix}0.8 & 0.2\end{bmatrix}^{\mathrm{T}}=\begin{bmatrix}0.6 & 0.4\end{bmatrix}^{\mathrm{T}}+\begin{bmatrix}0.2 & -0.2\end{bmatrix}^{\mathrm{T}}$.

$\boldsymbol{A}$ 的第一列（见图 6.1）分解成特征向量的线性组合

$$\begin{bmatrix}0.8\\0.2\end{bmatrix}=\begin{bmatrix}0.6\\0.4\end{bmatrix}+\begin{bmatrix}0.2\\-0.2\end{bmatrix}=\boldsymbol{x}_1+0.2\boldsymbol{x}_2\tag{6.1}$$

用 $\lambda_i$ 乘以 $\boldsymbol{x}_i$ 得到 $\boldsymbol{A}^2$ 的第一列　$\boldsymbol{A}\begin{bmatrix}0.8\\0.2\end{bmatrix}=\boldsymbol{x}_1+\frac{1}{2}(0.2\boldsymbol{x}_2)=\begin{bmatrix}0.6\\0.4\end{bmatrix}+\begin{bmatrix}0.1\\-0.1\end{bmatrix}=\begin{bmatrix}0.7\\0.3\end{bmatrix}$　(6.2)

用 $\boldsymbol{A}$ 乘特征向量等同于用特征值乘特征向量. 因为 $\lambda_1=1$，那么每一次 $\boldsymbol{x}_1$ 都不变. 而 $\boldsymbol{x}_2$ 改变，每一次都要乘一个 $1/2$：

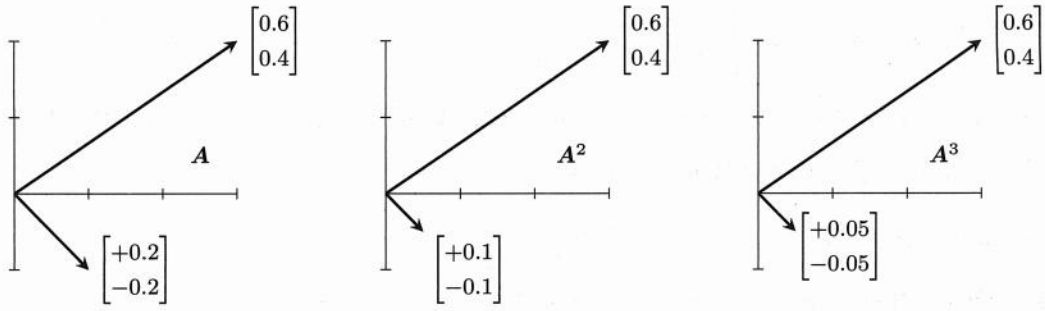


图 6.1 $A$、$A^2$、$A^3$ 的第一列

注：$A$、$A^2$、$A^3$ 的第一列分别是 $\begin{bmatrix}0.8\\0.2\end{bmatrix}$、$\begin{bmatrix}0.7\\0.3\end{bmatrix}$、$\begin{bmatrix}0.65\\0.35\end{bmatrix}$，当 $n$ 趋于无穷时，$A^n$ 的第一列趋于 $\begin{bmatrix}0.6\\0.4\end{bmatrix}$.

$A^{100}$的第一列

$$\boxed{\boldsymbol{A}^{99}\begin{bmatrix}0.8\\0.2\end{bmatrix}=\boldsymbol{x}_1+(0.2)\left(\frac{1}{2}\right)^{99}\boldsymbol{x}_2=\begin{bmatrix}0.6\\0.4\end{bmatrix}+\begin{bmatrix}\text{很小的向量}\end{bmatrix}} \tag{6.3}$$

此即 $\boldsymbol{A}^{100}$ 的第一列. 我们原先写作 0.6000 的数字并不严格，忽略了 0.2 乘以 $\left(\frac{1}{2}\right)^{99}$ 这个在小数点后 30 位才出现的数.

特征向量 $\boldsymbol{x}_1$ 是“稳态”，在迭代之下保持不变（因为它对应的特征值 $\lambda_1=1$）. 特征向量 $\boldsymbol{x}_2$ 是“衰减态”，多次迭代之后，它几乎会消失（因为它对应的特征值 $\lambda_2=0.5$）. 幂次 $n$ 越高，$\boldsymbol{A}^n$ 的列向量就越接近稳态.

有这种特殊性质的矩阵 $\boldsymbol{A}$ 称作**马尔可夫矩阵**. 最大的特征值是 $\lambda=1$. $\boldsymbol{x}_1=\begin{bmatrix}0.6 & 0.4\end{bmatrix}^{\mathrm{T}}$ 是属于特征值 $\lambda=1$ 的特征向量，并且 $\boldsymbol{x}_1$ 是 $\boldsymbol{A}$ 的稳态——$\boldsymbol{A}^k$ 的所有列都会趋近于 $\boldsymbol{x}_1$. 参见附录 A8. 一个规模巨大的马尔可夫矩阵是谷歌超快速网页搜索算法的关键.

**投影矩阵 $\boldsymbol{P}$ 把列空间投影到其自身（$\boldsymbol{Px}=\boldsymbol{x}$），** 把零空间投影到零向量（$\boldsymbol{Px}=0\boldsymbol{x}$）（见图 6.2(a)）. 所以 $\boldsymbol{P}$ 的特征值是 $\lambda=1$ 和 $\lambda=0$.

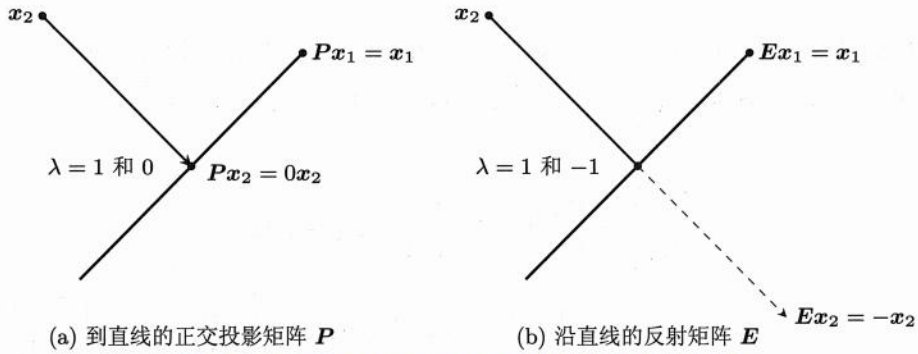


(a) 到直线的正交投影矩阵 $\boldsymbol{P}$　　(b) 沿直线的反射矩阵 $\boldsymbol{E}$

图 6.2 正交投影矩阵和反射矩阵的特征值和特征向量

注：投影矩阵特征值是 1 和 0，对换矩阵 $\boldsymbol{E}$ 特征值是 1 和 −1. 一般的向量被矩阵乘了之后会改变方向，而特征向量的方向不改变.

**例 6.2**　投影矩阵 $\boldsymbol{P}=\begin{bmatrix}0.5 & 0.5\\ 0.5 & 0.5\end{bmatrix}$ 的特征值是 $\lambda=1$ 和 $\lambda=0$. $\boldsymbol{x}_1=\begin{bmatrix}1 & 1\end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{x}_2=\begin{bmatrix}1 & -1\end{bmatrix}^{\mathrm{T}}$ 分别是属于这两个特征值的特征向量：$\boldsymbol{P}\boldsymbol{x}_1=\boldsymbol{x}_1$（稳态），$\boldsymbol{P}\boldsymbol{x}_2=\boldsymbol{0}$（零空间）. $\boldsymbol{P}$ 是奇异马尔可夫矩阵（有特征值 $\lambda=0$）的例子. 然而最重要的是，$\boldsymbol{P}$ 是对称矩阵，这使得它有两个正交的特征向量.

（1）马尔可夫矩阵：$\boldsymbol{P}$ 的每一列分量之和均等于 1，所以 $\lambda=1$ 是特征值.

（2）$\boldsymbol{P}$ 是奇异矩阵：$\lambda=0$ 是特征值.

（3）$\boldsymbol{P}=\boldsymbol{P}^{\mathrm{T}}$ 是对称矩阵：有正交的特征向量 $\begin{bmatrix}1 & 1\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}1 & -1\end{bmatrix}^{\mathrm{T}}$.

投影矩阵的特征值只有 1 和 0. 属于 $\lambda=1$ 的特征向量（即 $\boldsymbol{P}\boldsymbol{x}=\boldsymbol{x}$）和零向量的并集构成了列空间. 对应 $\lambda=0$ 的特征向量（即 $\boldsymbol{P}\boldsymbol{x}=0\boldsymbol{x}$）和零向量的并集构成了零空间. 零空间被投影到零向量，列空间投影到其自身. 投影保持列空间中向量不动，同时让零空间消失了.

各部分逐个投影　$\boldsymbol{v}=\begin{bmatrix}1\\ -1\end{bmatrix}+\begin{bmatrix}2\\ 2\end{bmatrix}=\begin{bmatrix}3\\ 1\end{bmatrix}$　投影为　$\boldsymbol{P}\boldsymbol{v}=\begin{bmatrix}0\\ 0\end{bmatrix}+\begin{bmatrix}2\\ 2\end{bmatrix}$

投影矩阵的特征值是 $\lambda=0$ 和 $\lambda=1$. 置换矩阵的特征值满足 $|\lambda|=1$. 下面的例子 $\boldsymbol{E}$ 是反射，同时也是置换. $\boldsymbol{E}$ 的特征值也很特殊.

**例 6.3**　对换矩阵 $\boldsymbol{E}=\begin{bmatrix}0 & 1\\ 1 & 0\end{bmatrix}$ 的特征值是 1 和 $-1$（见图 6.2(b)）.

特征向量 $\begin{bmatrix}1 & 1\end{bmatrix}^{\mathrm{T}}$ 被 $\boldsymbol{E}$ 左乘保持不变，而 $\begin{bmatrix}1 & -1\end{bmatrix}^{\mathrm{T}}$ 被 $\boldsymbol{E}$ 左乘方向相反. 这个例子说明所有元素均非负的矩阵仍然可以有负特征值！注意到 $\boldsymbol{E}=2\boldsymbol{P}-\boldsymbol{I}$，所以 $\boldsymbol{E}$ 和 $\boldsymbol{P}$ 有相同的特征向量：

$$\boldsymbol{E}=2\boldsymbol{P}-\boldsymbol{I}\qquad \begin{bmatrix}0 & 1\\ 1 & 0\end{bmatrix}=2\begin{bmatrix}0.5 & 0.5\\ 0.5 & 0.5\end{bmatrix}-\begin{bmatrix}1 & 0\\ 0 & 1\end{bmatrix} \tag{6.4}$$

任意矩阵加减单位阵 $\boldsymbol{I}$，则每个特征值相应地加减 1. 但是特征向量不变.

### 6.1.1　特征方程：$\det(\boldsymbol{A}-\lambda\boldsymbol{I})=0$

通过几何方法，我们找出了投影矩阵的特征值 $\lambda$ 和特征向量 $\boldsymbol{x}$：$\boldsymbol{P}\boldsymbol{x}=\boldsymbol{x}$ 和 $\boldsymbol{P}\boldsymbol{x}=\boldsymbol{0}$. 但是一般的方阵可没有这么强的几何背景，所以我们必须用行列式和线性代数的知识来解决问题. 几乎所有的特征值、特征向量有关的应用都要从解方程（组）$\det(\boldsymbol{A}-\lambda\boldsymbol{I})=0$ 和 $\boldsymbol{A}\boldsymbol{x}=\lambda\boldsymbol{x}$ 开始——这也是关键的计算路径.

简单地移项可知 $\boldsymbol{A}\boldsymbol{x}=\lambda\boldsymbol{x}$ 等价于 $(\boldsymbol{A}-\lambda\boldsymbol{I})\boldsymbol{x}=\boldsymbol{0}$. 这说明矩阵 $\boldsymbol{A}-\lambda\boldsymbol{I}$ 和特征向量 $\boldsymbol{x}$ 相乘，结果是零向量. 也就是说属于 $\lambda$ 的全体特征向量（和零向量）组成了 $\boldsymbol{A}-\lambda\boldsymbol{I}$ 的零空间. 一旦我们求得一个特征值 $\lambda$，那么通过解线性方程组 $(\boldsymbol{A}-\lambda\boldsymbol{I})\boldsymbol{x}=\boldsymbol{0}$，就能求出属于 $\lambda$ 的所有特征向量.

先考虑特征值. 如果方程组 $(\boldsymbol{A}-\lambda\boldsymbol{I})\boldsymbol{x}=\boldsymbol{0}$ 有非零解，则 $\boldsymbol{A}-\lambda\boldsymbol{I}$ 不可逆，$\boldsymbol{A}-\lambda\boldsymbol{I}$ 的行列式等于 0. 这是判定 $\lambda$ 是否为特征值 $\lambda$ 的方法：

**特征值** 数 $\lambda$ 是 $\boldsymbol{A}$ 的特征值，当且仅当 $\boldsymbol{A}-\lambda\boldsymbol{I}$ 是奇异矩阵.

**$\boldsymbol{A}$ 的特征方程** $\boxed{\det(\boldsymbol{A}-\lambda\boldsymbol{I})=0.}$ (6.5)

“特征多项式” $\det(\boldsymbol{A}-\lambda\boldsymbol{I})$ 的变量是 $\lambda$，和 $\boldsymbol{x}$ 无关. 根据行列式大公式，$\det(\boldsymbol{A}-\lambda\boldsymbol{I})$ 是关于 $\lambda$ 的多项式；而 $\lambda$ 只出现在对角线上，同样根据行列式大公式，关于 $\lambda$ 的最高项是 $(-\lambda)^n$，也就是说，$\det(\boldsymbol{A}-\lambda\boldsymbol{I})$ 是关于 $\lambda$ 的 $n$ 次多项式. 所以方程式(6.5)有 $n$ 个根 $\lambda_1,\lambda_2,\cdots,\lambda_n$[①]，即 $\boldsymbol{A}$ 有 $n$ 个特征值.

**$n$ 阶方阵都有 $n$ 个特征值（特征值可能有重数）.** 每个特征值 $\lambda$ 都有属于它的特征向量 $\boldsymbol{x}$：解方程组 $\boldsymbol{A}\boldsymbol{x}=\lambda\boldsymbol{x}$ 或者 $(\boldsymbol{A}-\lambda\boldsymbol{I})\boldsymbol{x}=\boldsymbol{0}$ 就可以找到特征向量.

**例 6.4** 求奇异矩阵 $\boldsymbol{A}=\begin{bmatrix}1&2\\2&4\end{bmatrix}$ 的特征值和特征向量.

$\lambda=0$ 是奇异矩阵 $\boldsymbol{A}$ 的特征值，方程组 $\boldsymbol{A}\boldsymbol{x}=0\boldsymbol{x}$ 有非零解，这些非零解是属于特征值 $\lambda$ 的特征向量. 但只找出一个特征值是不够的，只有解方程 $\det(\boldsymbol{A}-\lambda\boldsymbol{I})=0$ 才能求出所有特征值和特征向量. 先用 $\boldsymbol{A}$ 减去 $\lambda\boldsymbol{I}$：

**对角元减去 $\lambda$** $$\boldsymbol{A}-\lambda\boldsymbol{I}=\begin{bmatrix}1-\lambda&2\\2&4-\lambda\end{bmatrix} \tag{6.6}$$

二阶方阵 $\begin{bmatrix}a&b\\c&d\end{bmatrix}$ 的行列式是 $ad-bc$，对矩阵 $\boldsymbol{A}-\lambda\boldsymbol{I}$ 而言，它的“$ad$”部分是 $(1-\lambda)(4-\lambda)=\lambda^2-5\lambda+4$；“$bc$”部分是 $2\cdot2$，不含 $\lambda$：

$$\det\begin{bmatrix}1-\lambda&2\\2&4-\lambda\end{bmatrix}=(1-\lambda)(4-\lambda)-(2)(2)=\lambda^2-5\lambda \tag{6.7}$$

令行列式为零：$\lambda^2-5\lambda=0$，两个解为 $\lambda=0$（如前所述，正因为 $\boldsymbol{A}$ 是奇异的）和 $\lambda=5$：

$$\boxed{\det(\boldsymbol{A}-\lambda\boldsymbol{I})=\lambda^2-5\lambda=0 \qquad \text{解得} \qquad \lambda_1=0,\lambda_2=5.}$$

现在来求特征向量. 分别对 $\lambda_1=0$ 和 $\lambda_2=5$ 解线性方程组 $(\boldsymbol{A}-\lambda\boldsymbol{I})\boldsymbol{x}=\boldsymbol{0}$：

$(\boldsymbol{A}-0\boldsymbol{I})\boldsymbol{x}=\begin{bmatrix}1&2\\2&4\end{bmatrix}\begin{bmatrix}y\\z\end{bmatrix}=\begin{bmatrix}0\\0\end{bmatrix}$，由此解得 $\boxed{\begin{bmatrix}y\\z\end{bmatrix}=\begin{bmatrix}2\\-1\end{bmatrix}}$ 是属于 $\boldsymbol{\lambda_1=0}$ 的特征向量.

$(\boldsymbol{A}-5\boldsymbol{I})\boldsymbol{x}=\begin{bmatrix}-4&2\\2&-1\end{bmatrix}\begin{bmatrix}y\\z\end{bmatrix}=\begin{bmatrix}0\\0\end{bmatrix}$，由此解得 $\boxed{\begin{bmatrix}y\\z\end{bmatrix}=\begin{bmatrix}1\\2\end{bmatrix}}$ 是属于 $\boldsymbol{\lambda_2=5}$ 的特征向量.

因为 0 和 5 都是特征值，所以矩阵 $\boldsymbol{A}-0\boldsymbol{I}$ 和 $\boldsymbol{A}-5\boldsymbol{I}$ 都是奇异矩阵. 特征向量 $\begin{bmatrix}2&-1\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}1&2\end{bmatrix}^{\mathrm{T}}$ 分别属于它俩的零空间：方程组 $(\boldsymbol{A}-\lambda\boldsymbol{I})\boldsymbol{x}=0$ 即 $\boldsymbol{A}\boldsymbol{x}=\lambda\boldsymbol{x}$.

① 译者注：这是代数基本定理的直接推论. 代数基本定理的陈述是：任意 $n\geqslant1$ 次复系数多项式都恰好有 $n$ 个根. 此处，根的个数要计算重数，例如 $(x-1)^2$，有两个相同的根 1；1 是 2 重根，计个数的时候要计两次.

需要强调的是，$\lambda=0$ 并没有什么特殊之处. 和其它数一样，0 可能是特征值，也可能不是. 若 $\boldsymbol{A}$ 是奇异矩阵，属于特征值 $\lambda=0$ 的特征向量（和零向量的并集）构成 $\boldsymbol{A}$ 的零空间：$\boldsymbol{Ax}=0\boldsymbol{x}=\boldsymbol{0}$. 若 $\boldsymbol{A}$ 是可逆矩阵，则 0 不是特征值.

在例 6.4 中，矩阵 $\boldsymbol{A}-5\boldsymbol{I}$ 是奇异矩阵，5 是另一个特征值.

至此，我们可以总结求 $n$ 阶方阵特征值的一般步骤：

> （1）计算 $\boldsymbol{A}$ 的特征多项式——行列式 $\det(\boldsymbol{A}-\lambda\boldsymbol{I})$. $\boldsymbol{A}-\lambda\boldsymbol{I}$ 无非是把 $\boldsymbol{A}$ 的对角元减去 $\lambda$，因此 $\det(\boldsymbol{A}-\lambda\boldsymbol{I})$ 是关于 $\lambda$ 的 $n$ 次多项式，首项是 $\lambda^n$ 或者 $-\lambda^n$.
> （2）求特征多项式的根：$\det(\boldsymbol{A}-\lambda\boldsymbol{I})=0$. 这 $n$ 个根即 $\boldsymbol{A}$ 的 $n$ 个特征值；对每个特征值 $\lambda$，矩阵 $\boldsymbol{A}-\lambda\boldsymbol{I}$ 都是奇异矩阵.
> （3）对每一个特征值 $\lambda$，求解线性方程组 $(\boldsymbol{A}-\lambda\boldsymbol{I})\boldsymbol{x}=\boldsymbol{0}$，得到属于 $\lambda$ 的所有特征向量.

二阶方阵的特征向量也有一些数值上的巧合. 如果 $\boldsymbol{A}-\lambda\boldsymbol{I}$ 是奇异矩阵，那么它的行向量都是某个行向量 $\begin{bmatrix}a & b\end{bmatrix}$ 的倍数，于是特征向量就是 $\begin{bmatrix}b & -a\end{bmatrix}^{\mathrm{T}}$ 的倍数. 在例 6.4 中

$\lambda=0$ 时，$\boldsymbol{A}-0\boldsymbol{I}$ 的两行都是 $\begin{bmatrix}1 & 2\end{bmatrix}$ 的倍数，特征向量是 $\begin{bmatrix}-2 & 1\end{bmatrix}^{\mathrm{T}}$ 的倍数.

$\lambda=5$ 时，$\boldsymbol{A}-5\boldsymbol{I}$ 的两行都是 $\begin{bmatrix}-4 & 2\end{bmatrix}$ 的倍数，特征向量是 $\begin{bmatrix}2 & 4\end{bmatrix}^{\mathrm{T}}$ 的倍数.

先前我们把属于特征值 $\lambda=5$ 的特征向量取成了 $\begin{bmatrix}1 & 2\end{bmatrix}^{\mathrm{T}}$，它和 $\begin{bmatrix}2 & 4\end{bmatrix}^{\mathrm{T}}$ 两者均可，后者无非是前者的 2 倍，与某个特征向量共线的向量都是特征向量，这条直线上的向量没有哪一个（除了零向量）比其他的更好. 用 MATLAB 求特征向量时，命令 eig(A) 输出的特征向量是已经除以了长度之后的向量，也就是说该命令的返回值是单位特征向量.

最后提醒一下，有些二阶方阵可能只有一个线性无关的特征向量，或者说特征向量只分布在一条直线上. 而二阶方阵都有两个特征值，所以上述那种特殊情况只有在两个特征值相等的时候才有可能发生. 当然并不是说两个特征值相等，特征向量就一定只分布在一条直线上，例如单位阵 $\boldsymbol{I}$，任意向量都是它的特征向量. 线性无关的特征向量不够多，我们就不能找出由特征向量构成的一组基，那么就存在向量不能被特征向量线性表出. 如果用下一节的语言来叙述，那就是：*若不存在 $n$ 个线性无关的特征向量，则方阵不可以对角化.*

### 6.1.2　行列式和迹

如果把 $\boldsymbol{A}$ 的某一行加到另一行上，或者交换两行，特征值通常会发生变化. 消元法并不保持特征值不变. 假设有 $LU$ 分解 $\boldsymbol{A}=\boldsymbol{LU}$，上三角矩阵 $\boldsymbol{U}$ 的特征值就是其对角线元素——$\boldsymbol{U}$ 的主元. 但它们并不是矩阵 $\boldsymbol{A}$ 的特征值！下面的例子说明，把矩阵的第一行的倍数加到第二行时，特征值发生改变：

$$\boldsymbol{U}=\begin{bmatrix}1 & 3\\ 0 & 0\end{bmatrix}\quad \text{特征值是}\lambda=0\text{和}\lambda=1;\qquad \boldsymbol{A}=\begin{bmatrix}1 & 3\\ 2 & 6\end{bmatrix}\quad \text{特征值是}\lambda=0\text{和}\lambda=7.$$

特征值 $\lambda_1$ 与 $\lambda_2$ 的和与乘积可以直接从矩阵得到，不需要求出它们然后再求和或者求积. 对矩

阵 $\boldsymbol{A}=\begin{bmatrix}1 & 3\\ 2 & 6\end{bmatrix}$，特征值之和是 0 加 7，与主对角元之和（也就是迹，等于 1 加 6）相等. 特征值之积是 0 乘以 7，与行列式（为 0）相等. 这些检验快速而有效.

> 设 $\boldsymbol{A}$ 是 $n$ 阶方阵. $\lambda_1,\ \lambda_2,\ \cdots,\ \lambda_n$ 是它的 $n$ 个特征值，则
>
> （1）$\lambda_1,\lambda_2,\cdots,\lambda_n$ 相乘等于行列式：$\lambda_1\lambda_2\cdots\lambda_n=\det\boldsymbol{A}$；
>
> （2）$\lambda_1,\lambda_2,\cdots,\lambda_n$ 相加等于对角元相加：$\lambda_1+\lambda_2+\cdots+\lambda_n=a_{11}+a_{22}+\cdots+a_{nn}$；对角元之和也被称作 $\boldsymbol{A}$ 的迹，记作 $\mathrm{Tr}(\boldsymbol{A})$.

这个结论非常有用，习题 16 ~ 17 将给出证明，下一节将再次验证. 但是这个结论并不能丝毫消减计算特征值的痛苦，只不过我们可以用它来检验计算是否正确. 要计算特征值 $\lambda$，还是得老老实实地回到解方程 $\det(\boldsymbol{A}-\lambda\boldsymbol{I})=0$.

对于二阶方阵，迹和行列式的确能完全确定两个特征值，所以很重要. 下面三个矩阵的迹都是 3，行列式都是 2，所以它们特征值都是 1 和 2：

$$\begin{bmatrix}1 & 9\\ 0 & 2\end{bmatrix}\qquad\begin{bmatrix}3 & 1\\ -2 & 0\end{bmatrix}\qquad\begin{bmatrix}7 & -3\\ 10 & -4\end{bmatrix}\tag{6.8}$$

第一个矩阵是上三角矩阵，是最容易看出特征值的矩阵之一. 为什么该矩阵的特征值是其对角元 1、2?

### 6.1.3 虚数特征值

有个不太坏的坏消息：特征值可能不是实数.

> **例 6.5** $\boldsymbol{Q}=\begin{bmatrix}0 & -1\\ 1 & 0\end{bmatrix}$ 是逆时针旋转 90° 的旋转矩阵. 它没有实特征向量. 它的特征值是 $\lambda_1=\mathrm{i}$ 和 $\lambda_2=-\mathrm{i}$. 于是 $\lambda_1+\lambda_2=$ 迹 $=0$，$\lambda_1\lambda_2=$ 行列式 $=1$.

除了 $\boldsymbol{x}=\boldsymbol{0}$，任何向量 $\boldsymbol{x}$ 在逆时针旋转 90° 后都无法和 $\boldsymbol{x}$ 方向相同，所以 $\boldsymbol{Q}$ 没有实特征向量. 解决这个问题的方法就是引入虚数.

要理解 $\mathrm{i}=\sqrt{-1}$ 的作用，只需要注意到 $\boldsymbol{Q}^2=-\boldsymbol{I}$. $\boldsymbol{Q}$ 的作用是逆时针旋转 90°，$\boldsymbol{Q}^2$ 的作用就是逆时针旋转 180°，任何向量都被转至反向；所以 $\boldsymbol{Q}^2$ 的两个特征值是 $-1$ 和 $-1$（显然 $-\boldsymbol{I}\boldsymbol{x}=-\boldsymbol{x}$）. 若 $\lambda$ 是 $\boldsymbol{Q}$ 的特征值，那么 $\lambda^2$ 是 $\boldsymbol{Q}^2$ 的特征值，所以 $\boldsymbol{\lambda^2=-1}$. 这说明逆时针旋转 90° 的旋转矩阵的特征值是 $+\mathrm{i}$ 或者 $-\mathrm{i}$.

这两个特征值也可以像往常那样通过解方程 $\det(\boldsymbol{Q}-\lambda\boldsymbol{I})=0$ 得到. $\boldsymbol{Q}$ 的特征方程是 $\lambda^2+1=0$，两个根是 $\mathrm{i}$ 和 $-\mathrm{i}$. 虚数 $\mathrm{i}$ 和 $-\mathrm{i}$ 也出现在特征向量的分量中：

复特征向量
$$\begin{bmatrix}0 & -1\\ 1 & 0\end{bmatrix}\begin{bmatrix}\mathbf{1}\\ \mathbf{i}\end{bmatrix}=-\mathbf{i}\begin{bmatrix}\mathbf{1}\\ \mathbf{i}\end{bmatrix}\qquad\begin{bmatrix}0 & -1\\ 1 & 0\end{bmatrix}\begin{bmatrix}\mathbf{i}\\ \mathbf{1}\end{bmatrix}=\mathbf{i}\begin{bmatrix}\mathbf{i}\\ \mathbf{1}\end{bmatrix}$$

从某种意义上说，我们可以把上式理解为复向量 $\boldsymbol{x}_1=\begin{bmatrix}1 & \mathrm{i}\end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{x}_2=\begin{bmatrix}\mathrm{i} & 1\end{bmatrix}^{\mathrm{T}}$ 在复二维空间中逆时针旋转 90°后，方向不变. 不要问我复二维空间中这个旋转是怎么转的.[①]这个例子的另一个重要意义在于说明实矩阵也经常有复特征值和复特征向量. 此外，i 和 $-\mathrm{i}$ 这两个特殊的特征值也反映了 $\boldsymbol{Q}$ 这个有特殊性质的矩阵的两个特殊性质：

（1）正交矩阵的特征值 $\lambda$ 的模长是 1：$|\lambda|=1$.

（2）反对称矩阵的特征值是纯虚数（即实部为零）.

我们可以把对称矩阵（$\boldsymbol{S}^{\mathrm{T}}=\boldsymbol{S}$）与实数作类比，反对称矩阵（$\boldsymbol{A}^{\mathrm{T}}=-\boldsymbol{A}$）与纯虚数作类比，正交矩阵（$\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{Q}=\boldsymbol{I}$）与模长为一的复数（$|\lambda|=1$）作类比. 具体到矩阵 $\boldsymbol{S}$、$\boldsymbol{A}$、$\boldsymbol{Q}$ 的特征值上，这些类比就不仅是类比，更是可以证明的事实.

这几类特殊矩阵的特征向量某种意义上说都是正交的. 可能你会有疑问，对于旋转矩阵 $\boldsymbol{Q}$，特征向量 $\begin{bmatrix}\mathrm{i} & 1\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}1 & \mathrm{i}\end{bmatrix}^{\mathrm{T}}$ 的点积是 $\mathrm{i}\cdot 1+1\cdot\mathrm{i}=2\mathrm{i}\neq 0$，明明不正交，那我为什么还要说它们正交呢？其实原因在于复向量的点积和实向量的点积定义有区别，这导致正交的定义也不相同，详情请见 6.4节.

### 6.1.4　$AB$ 和 $A+B$ 的特征值

设 $\boldsymbol{A}$、$\boldsymbol{B}$ 都是 $n$ 阶方阵，让你猜 $\boldsymbol{AB}$ 的特征值时，第一反应可能是 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 各自特征值的乘积：若 $\lambda$、$\beta$ 分别是 $\boldsymbol{A}$、$\boldsymbol{B}$ 的特征值，

$$\text{伪证}\qquad \boldsymbol{ABx}=\boldsymbol{A}\beta\boldsymbol{x}=\beta\boldsymbol{Ax}=\beta\lambda\boldsymbol{x} \tag{6.9}$$

看起来很有道理的样子，可惜这一切都是幻想. 只有当 $\boldsymbol{x}$ 同时是 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 的特征向量时，这个证明才是正确的. 问题就出在想当然地认为 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 有公共的特征向量. 显然这并不成立，$\boldsymbol{A}$ 的特征向量一般不是 $\boldsymbol{B}$ 的特征向量. 下面的例子中，$\boldsymbol{A}$ 和 $\boldsymbol{B}$ 所有特征值都是 0，但是 1 是 $\boldsymbol{AB}$ 和 $\boldsymbol{A}+\boldsymbol{B}$ 的特征值：

$$\boldsymbol{A}=\begin{bmatrix}0 & 1\\ 0 & 0\end{bmatrix}\qquad \boldsymbol{B}=\begin{bmatrix}0 & 0\\ 1 & 0\end{bmatrix},\quad \text{则}\quad \boldsymbol{AB}=\begin{bmatrix}1 & 0\\ 0 & 0\end{bmatrix}\qquad \boldsymbol{A}+\boldsymbol{B}=\begin{bmatrix}0 & 1\\ 1 & 0\end{bmatrix}.$$

同样的道理也说明 $\boldsymbol{A}+\boldsymbol{B}$ 的特征值一般不是二者特征值之和. 以上述 $\boldsymbol{A}$、$\boldsymbol{B}$ 为例，虽然它们特征值都是 0，但是 $\boldsymbol{A}+\boldsymbol{B}$ 的特征值是 1 和 $-1$（不过至少 $\boldsymbol{A}+\boldsymbol{B}$ 的迹是 0）.

错误的证明多多少少也能提示我们一些正确的东西. 假设 $\boldsymbol{x}$ 确实是 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 共同的特征向量，那么我们确实有 $\boldsymbol{ABx}=\lambda\beta\boldsymbol{x}$ 和 $\boldsymbol{BAx}=\lambda\beta\boldsymbol{x}$. 当 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 有 $n$ 个线性无关的公共特征向量时，我们可以将特征值相乘，并且等式 $\boldsymbol{AB}=\boldsymbol{BA}$ 成立. 这一点在量子力学中至关重要——此处不得不提一下线性代数的这一应用：

$$\boxed{\boldsymbol{A}\text{ 和 }\boldsymbol{B}\text{ 有 }n\text{ 个线性无关的公共特征向量，当且仅当 }\boldsymbol{AB}=\boldsymbol{BA}.}\ [②]$$

---

① 译者注：作者说，不要问；译者说，我也不敢问；读者也不要来问译者，译者也不会转.

② 译者注：这个结论是错误的，缺少前提条件. 正确的叙述应该是：设 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 各自都有 $n$ 个线性无关的特征向量，则

$$\boldsymbol{A}\text{ 和 }\boldsymbol{B}\text{ 有 }n\text{ 个线性无关的公共特征向量，当且仅当 }\boldsymbol{AB}=\boldsymbol{BA}.$$

与原叙述作对比就看出差别了：仅由交换性 $\boldsymbol{AB}=\boldsymbol{BA}$，是无法推知 $\boldsymbol{A}$、$\boldsymbol{B}$ 的可对角化的.

**海森堡不确定性原理：**在量子力学中，位置矩阵 $\boldsymbol{P}$ 和动量矩阵 $\boldsymbol{Q}$ 不可交换（它们是无限矩阵）. 事实上，$\boldsymbol{QP}-\boldsymbol{PQ}=\boldsymbol{I}$. 要同时满足 $\boldsymbol{Px}=\boldsymbol{0}$ 和 $\boldsymbol{Qx}=\boldsymbol{0}$，则必须有 $\boldsymbol{x}=\boldsymbol{Ix}=\boldsymbol{0}$. 如果我们能精确地知道位置，我们就无法同时精确地知道动量. 习题 36 推导出了海森堡不确定性原理：$\|\boldsymbol{Px}\|\,\|\boldsymbol{Qx}\|\geqslant\frac{1}{2}\|\boldsymbol{x}\|^2$.

## 要点回顾

（1）$\boldsymbol{Ax}=\lambda\boldsymbol{x}$ 说明特征向量 $\boldsymbol{x}$ 被 $\boldsymbol{A}$ 左乘之后方向不变.

（2）$\boldsymbol{Ax}=\lambda\boldsymbol{x}$ 也说明 $\det(\boldsymbol{A}-\lambda\boldsymbol{I})=0$. 特征方程的 $n$ 个解即 $\boldsymbol{A}$ 的 $n$ 个特征值.

（3）特征值之和等于 $\boldsymbol{A}$ 对角元之和（即 $\boldsymbol{A}$ 的迹）. 特征值之积等于 $\boldsymbol{A}$ 的行列式.

（4）投影矩阵 $\boldsymbol{P}$ 的特征值是 1、0；对换矩阵 $\boldsymbol{E}$ 的特征值是 1、−1；逆时针旋转 90° 的旋转矩阵 $\boldsymbol{Q}$ 的特征值是 i、−i. 0 是奇异矩阵的特征值；上（下）三角矩阵的特征值是其对角元.

（5）矩阵的特殊性质诱导出特征值和特征向量的特殊性质. 这是第6章的主题之一.

## 例题总结

6.1 A. 设 $\boldsymbol{A}=\begin{bmatrix}2&-1\\-1&2\end{bmatrix}$，求 $\boldsymbol{A}$、$\boldsymbol{A}^2$、$\boldsymbol{A}^{-1}$ 和 $\boldsymbol{A}+4\boldsymbol{I}$ 的特征值与特征向量. 验证：$\lambda_1+\lambda_2=4=\mathrm{Tr}(\boldsymbol{A}),\lambda_1\lambda_2=3=\det\boldsymbol{A}$.

**解** 先计算特征方程 $\det(\boldsymbol{A}-\lambda\boldsymbol{I})=0$:

$$\boldsymbol{A}=\begin{bmatrix}2&-1\\-1&2\end{bmatrix},\qquad \det(\boldsymbol{A}-\lambda\boldsymbol{I})=\begin{vmatrix}2-\lambda&-1\\-1&2-\lambda\end{vmatrix}=\lambda^2-4\lambda+3=0.$$

因式分解得 $(\lambda-1)(\lambda-3)=0$，所以 $\boldsymbol{A}$ 的特征值是 $\lambda_1=1,\lambda_2=3$. 于是迹 $\mathrm{Tr}(\boldsymbol{A})=2+2=1+3=\lambda_1+\lambda_2$，行列式 $\det\boldsymbol{A}=2\cdot2-(-1)\cdot(-1)=3=\lambda_1\cdot\lambda_2$.

对 $\lambda=\lambda_1,\lambda_2$，分别解线性方程组 $(\boldsymbol{A}-\lambda\boldsymbol{I})\boldsymbol{x}=\boldsymbol{0}$ 即可求得特征向量:

$$\boldsymbol{\lambda=\lambda_1=1}\quad(\boldsymbol{A}-\boldsymbol{I})\boldsymbol{x}=\begin{bmatrix}1&-1\\-1&1\end{bmatrix}\begin{bmatrix}x\\y\end{bmatrix}=\begin{bmatrix}0\\0\end{bmatrix}\qquad\text{由此得特征向量 }\boldsymbol{x}_1=\begin{bmatrix}1\\1\end{bmatrix}$$

$$\boldsymbol{\lambda=\lambda_2=3}\quad(\boldsymbol{A}-3\boldsymbol{I})\boldsymbol{x}=\begin{bmatrix}-1&-1\\-1&-1\end{bmatrix}\begin{bmatrix}x\\y\end{bmatrix}=\begin{bmatrix}0\\0\end{bmatrix}\qquad\text{由此得特征向量 }\boldsymbol{x}_2=\begin{bmatrix}1\\-1\end{bmatrix}$$

$\boldsymbol{A}^2$、$\boldsymbol{A}^{-1}$ 以及 $\boldsymbol{A}+4\boldsymbol{I}$ 和 $\boldsymbol{A}$ 有相同的特征向量，它们的特征值分别是 $\lambda^2$、$\lambda^{-1}$ 和 $\lambda+4$:

| | |
|---|---|
| $\boldsymbol{A}^2$ 的特征值是 | $1^2=1$ 和 $3^2=9$ |
| $\boldsymbol{A}^{-1}$ 的特征值是 | $1^{-1}=1$ 和 $3^{-1}=\frac{1}{3}$ |
| $\boldsymbol{A}+4\boldsymbol{I}$ 的特征值是 | $1+4=5$ 和 $3+4=7$ |

注　我们对 $\boldsymbol{A}$ 做一些注释，实际上也是在预告后面章节的内容. $\boldsymbol{A}$ 有两个正交的特征向量（原因是 $\boldsymbol{A}$ 是对称矩阵，详见 6.3 节）. 由于 $\lambda_1 \neq \lambda_2$，$\boldsymbol{A}$ 可以对角化，相似于对角线元素是特征值 1 和 3 的对角矩阵（详见 6.2 节）. 因为 $\boldsymbol{A}^{\mathrm{T}} = \boldsymbol{A}$ 且特征值都是正数，所以 $\boldsymbol{A}$ 是正定矩阵（详见 6.3 节）.

6.1 B. 对任意矩阵 $\boldsymbol{A}$，我们如何估计特征值的模长？Gershgorin 给了我们答案.

任意特征值都位于某个对角元 $a_{ii}$“附近”. 稍微具体一点，特征值 $\lambda$“位于 $a_{ii}$ 附近”的意思是

$$|a_{ii} - \lambda| \leqslant \sum_{j \neq i} |a_{ij}| =: R_i$$

即 $\lambda$ 和 $a_{ii}$ 的距离不超过第 $i$ 行其他元素模长之和. 在复平面上，考虑以 $a_{ii}$ 为圆心，$R_i$ 为半径的圆盘 $C_i := \{z \in \mathbb{C} : |a_{ii} - z| \leqslant R_i\}$（$i = 1, 2, \cdots, n$）. 这些圆盘称作Gershgorin 圆盘.

$\boldsymbol{A}$ 的任意特征值都属于 $C_1, C_2, \cdots, C_n$ 中某个圆盘，即存在 $1 \leqslant i \leqslant n$ 使得 $|a_{ii} - \lambda| \leqslant R_i$. 原因也不复杂. 若 $\lambda$ 是特征值，$\boldsymbol{A} - \lambda \boldsymbol{I}$ 不可逆，于是 $\boldsymbol{A} - \lambda \boldsymbol{I}$ 不能是对角占优矩阵[①]；从而一定存在某个对角元 $a_{ii} - \lambda$ 不大于 $R_i$，即第 $i$ 行其他元素模长 $|a_{ij}| (j \neq i)$ 之和.

设 $\boldsymbol{A} = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$，$\boldsymbol{A}$ 的特征值 $\lambda$ 一定属于其中一个或者两个 Gershgorin 圆盘：圆心在 $a$ 和 $d$ 处的两个圆盘，半径分别是 $R_1 = |b|$ 和 $R_2 = |c|$.

$$\text{第一个圆盘：} |\lambda - a| \leqslant |b| \qquad \text{第二个圆盘：} |\lambda - d| \leqslant |c|$$

此处 $\lambda$ 都是复数，所以这两个圆盘都是复平面上的圆盘.

6.1 C. 求下述三阶对称矩阵 $\boldsymbol{S}$ 的特征值和特征向量

对称矩阵
奇异矩阵
迹 $1 + 2 + 1 = 4$

$$\boldsymbol{S} = \begin{bmatrix} 1 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 1 \end{bmatrix}$$

解　由于矩阵 $\boldsymbol{S}$ 的三个行向量分量之和都是零，所以向量 $\boldsymbol{x} = \begin{bmatrix} 1 & 1 & 1 \end{bmatrix}^{\mathrm{T}}$ 满足 $\boldsymbol{S}\boldsymbol{x} = \boldsymbol{0}$，这说明 $\lambda = 0$ 是 $\boldsymbol{S}$ 的特征值，$\boldsymbol{x} = \begin{bmatrix} 1 & 1 & 1 \end{bmatrix}^{\mathrm{T}}$ 是属于 $\lambda = 0$ 的特征向量. 要求其他两个特征值 $\lambda_2$ 和 $\lambda_3$，则需要计算三阶方阵的行列式：

$$\det(\boldsymbol{S} - \lambda \boldsymbol{I}) = \begin{vmatrix} 1-\lambda & -1 & 0 \\ -1 & 2-\lambda & -1 \\ 0 & -1 & 1-\lambda \end{vmatrix} = (1-\lambda)(2-\lambda)(1-\lambda) - 2(1-\lambda) = \boldsymbol{(1-\lambda)(-\lambda)(3-\lambda).}$$

---

① 译者注：所谓“对角占优矩阵”，是指对角线元素占统治地位的矩阵. 严格地说，设 $\boldsymbol{A} = [a_{ij}]_{1 \leqslant i, j \leqslant n}$ 是 $n$ 阶方阵，如果对任意 $1 \leqslant i \leqslant n$ 都满足

$$|a_{ii}| > \sum_{j \neq i} |a_{ij}|$$

即对角元的绝对值大于它所在的行其他元素的绝对值之和，则称 $\boldsymbol{A}$ 是对角占优矩阵. 对角占优矩阵的零空间只包含零向量，从而是可逆矩阵；证明如下：假设非零向量 $\boldsymbol{x} = [x_1 \ \ x_2 \ \ \cdots \ \ x_n]^{\mathrm{T}}$ 满足 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{0}$，设 $|x_i| = \max\{|x_1|, |x_2|, \cdots, |x_n|\} > 0$，根据 $a_{i1}x_1 + a_{i2}x_2 + \cdots + a_{in}x_n = 0$ 知

$$|a_{ii}| = \left| \sum_{j \neq i} \frac{x_j}{x_i} a_{ij} \right| \leqslant \sum_{j \neq i} \left| \frac{x_j}{x_i} \right| |a_{ij}| \leqslant \sum_{j \neq i} |a_{ij}|,$$

与 $\boldsymbol{A}$ 对角占优矛盾.

于是方程 $\det(\boldsymbol{S}-\lambda\boldsymbol{I})=0$ 的三个解是 0、1、3，也是 $\boldsymbol{S}$ 的特征值. 每个特征值都有特征向量（或者说特征向量张成的线性空间）：

$$\boldsymbol{x}_1=\begin{bmatrix}1\\1\\1\end{bmatrix},\quad \boldsymbol{S}\boldsymbol{x}_1=0\boldsymbol{x}_1 \qquad \boldsymbol{x}_2=\begin{bmatrix}1\\0\\-1\end{bmatrix},\quad \boldsymbol{S}\boldsymbol{x}_2=1\boldsymbol{x}_2 \qquad \boldsymbol{x}_3=\begin{bmatrix}1\\-2\\1\end{bmatrix},\quad \boldsymbol{S}\boldsymbol{x}_3=3\boldsymbol{x}_3.$$

再次指出，因为 $\boldsymbol{S}$ 是对称矩阵，它有三个两两正交的特征向量.

虽然我们很幸运地求出了这个例子中 $\boldsymbol{S}$ 的特征值 $\lambda=0,1,3$；但是对于更大的矩阵，我建议永远不要使用行列式，直接用 MATLAB 的 eig(A) 命令. 完整的命令 [X, E] = eig(A) 输出矩阵 $\boldsymbol{X}$，$\boldsymbol{X}$ 的列向量是 $\boldsymbol{A}$ 的单位特征向量.

### 6.1.5 MATLAB 中的 Eigshow 函数

MATLAB 有一个演示 $2\times 2$ 矩阵的特征值的功能（只需输入 eigshow）.[①]它从单位向量 $\boldsymbol{x}=\begin{bmatrix}1 & 0\end{bmatrix}^{\mathrm{T}}$ 开始，用鼠标让这个向量在单位圆上移动. 同时，屏幕上会以彩色显示并移动向量 $\boldsymbol{A}\boldsymbol{x}$. $\boldsymbol{A}\boldsymbol{x}$ 可能位于 $\boldsymbol{x}$ 的前方，也可能位于 $\boldsymbol{x}$ 的后方；有时 $\boldsymbol{A}\boldsymbol{x}$ 与 $\boldsymbol{x}$ 平行.

在平行的那一刻，$\boldsymbol{A}\boldsymbol{x}=\lambda\boldsymbol{x}$（如图 6.3(b) 中 $\boldsymbol{x}_1$ 和 $\boldsymbol{x}_2$ 所示）.

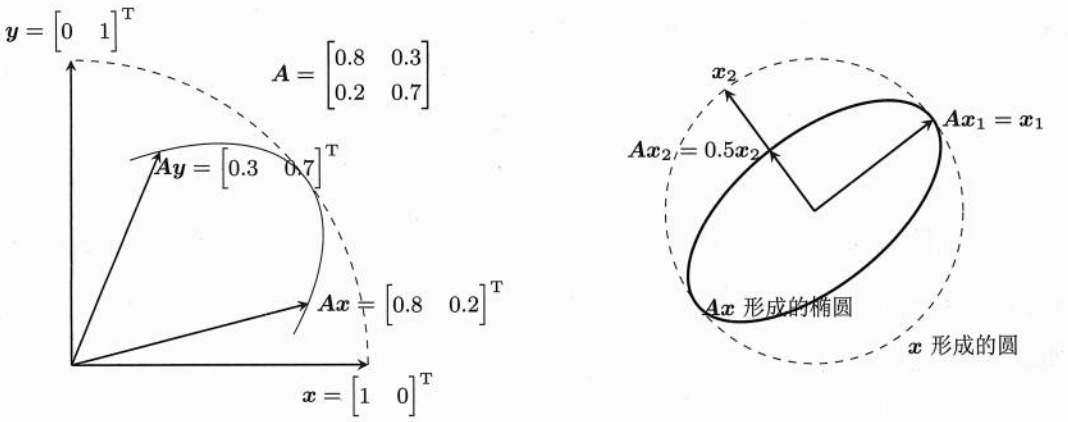


(a) 不是特征向量　　(b) $\boldsymbol{x}$ 和 $\boldsymbol{A}\boldsymbol{x}$ 共线，则它是特征向量

图 6.3　特征向量的动态演示

注：图 (a) 中 $\boldsymbol{x}$、$\boldsymbol{y}$ 不是特征值；图 (b) 中 $\boldsymbol{A}\boldsymbol{x}$ 与 $\boldsymbol{x}$ 共线时，$\boldsymbol{x}$ 是特征向量.

当向量 $\boldsymbol{A}\boldsymbol{x}$ 与单位向量 $\boldsymbol{x}$ 平行时，特征值 $\lambda$ 即为 $\boldsymbol{A}\boldsymbol{x}$ 的长度. 该功能对矩阵 $\boldsymbol{A}$ 提供了三种内置选项，分别展示了三种可能性：0 个、1 个或 2 个实向量 $\boldsymbol{x}$ 使得 $\boldsymbol{A}\boldsymbol{x}$ 与 $\boldsymbol{x}$ 平行.

椭圆的轴是 7.1节中讨论的奇异向量.

① 译者注：最新版本的 MATLAB 似乎已经取消了这个函数，请使用旧版本或者参照原作者英文网站.

## 习题 6.1

1. 本章以矩阵 $\boldsymbol{A}$ 的幂为例开始：

$$\boldsymbol{A}=\begin{bmatrix}0.8 & 0.3\\ 0.2 & 0.7\end{bmatrix}\qquad \boldsymbol{A}^2=\begin{bmatrix}0.70 & 0.45\\ 0.30 & 0.55\end{bmatrix}\qquad \boldsymbol{A}^\infty=\begin{bmatrix}0.6 & 0.6\\ 0.4 & 0.4\end{bmatrix}$$

求这些矩阵的特征值. $\boldsymbol{A}$ 的任意幂都有相同的特征向量. 对换矩阵 $\boldsymbol{A}$ 的两行，请说明行对换改变矩阵的特征值.

2. 求下面两个矩阵的特征值和特征向量：

$$\boldsymbol{A}=\begin{bmatrix}1 & 4\\ 2 & 3\end{bmatrix}\qquad \boldsymbol{A}+\boldsymbol{I}=\begin{bmatrix}2 & 4\\ 2 & 4\end{bmatrix}.$$

$\boldsymbol{A}+\boldsymbol{I}$ 的特征向量和 $\boldsymbol{A}$ 的特征向量_____；特征值是 $\boldsymbol{A}$ 的特征值_____.

3. 计算矩阵 $\boldsymbol{A}$ 和 $\boldsymbol{A}^{-1}$ 的特征值和特征向量，并且用迹检验计算是否正确.

$$\boldsymbol{A}=\begin{bmatrix}0 & 2\\ 1 & 1\end{bmatrix}\qquad \boldsymbol{A}^{-1}=\begin{bmatrix}-1/2 & 1\\ 1/2 & 0\end{bmatrix}.$$

$\boldsymbol{A}^{-1}$ 和 $\boldsymbol{A}$ 的特征向量_____. 若 $\boldsymbol{A}$ 可逆，特征值是 $\lambda_1$、$\lambda_2$，那么 $\boldsymbol{A}^{-1}$ 的特征值是_____.

4. 计算矩阵 $\boldsymbol{A}$ 和 $\boldsymbol{A}^2$ 的特征值和特征向量：

$$\boldsymbol{A}=\begin{bmatrix}-1 & 3\\ 2 & 0\end{bmatrix}\qquad \boldsymbol{A}^2=\begin{bmatrix}7 & -3\\ -2 & 6\end{bmatrix}.$$

$\boldsymbol{A}^2$ 和 $\boldsymbol{A}$ 有相同的_____. 若 $\boldsymbol{A}$ 的特征值是 $\lambda_1$、$\lambda_2$，那么 $\boldsymbol{A}^2$ 的特征值是_____. 在本题中，你有几种方法说明 $\lambda_1^2+\lambda_2^2=13$?

5. 求矩阵 $\boldsymbol{A}$、$\boldsymbol{B}$ 和 $\boldsymbol{A}+\boldsymbol{B}$ 的特征矩阵（上（下）三角矩阵的特征值易知）：

$$\boldsymbol{A}=\begin{bmatrix}3 & 0\\ 1 & 1\end{bmatrix}\qquad \boldsymbol{B}=\begin{bmatrix}1 & 1\\ 0 & 3\end{bmatrix}\qquad \boldsymbol{A}+\boldsymbol{B}=\begin{bmatrix}4 & 1\\ 1 & 4\end{bmatrix}.$$

$\boldsymbol{A}+\boldsymbol{B}$ 的特征值_____（“等于”或者“不等于”）$\boldsymbol{A}$ 与 $\boldsymbol{B}$ 的特征值的和.

6. 求矩阵 $\boldsymbol{A}$、$\boldsymbol{B}$、$\boldsymbol{AB}$ 和 $\boldsymbol{BA}$ 的特征值：

$$\boldsymbol{A}=\begin{bmatrix}1 & 0\\ 1 & 1\end{bmatrix}\qquad \boldsymbol{B}=\begin{bmatrix}1 & 2\\ 0 & 1\end{bmatrix}\qquad \boldsymbol{AB}=\begin{bmatrix}1 & 2\\ 1 & 3\end{bmatrix}\qquad \boldsymbol{BA}=\begin{bmatrix}3 & 2\\ 1 & 1\end{bmatrix}.$$

（1）$\boldsymbol{AB}$ 的特征值是否等于 $\boldsymbol{A}$ 与 $\boldsymbol{B}$ 的特征值的乘积?

（2）$\boldsymbol{AB}$ 的特征值是否等于 $\boldsymbol{BA}$ 的特征值?

7. 假设对 $\boldsymbol{A}$ 作消元法得到分解式 $\boldsymbol{A}=\boldsymbol{LU}$. $\boldsymbol{U}$ 的特征值是它的对角元，它们是 $\boldsymbol{A}$ 的_____. $\boldsymbol{L}$ 的特征值是它的对角元，它们都是_____. $\boldsymbol{A}$ 的特征值和_____ 不同.

8.（1）如果已知 $\boldsymbol{x}$ 是方阵 $\boldsymbol{A}$ 的特征向量，求特征值的方法是_____.

（2）如果已知 $\lambda$ 是方阵 $\boldsymbol{A}$ 的特征值，求特征向量的方法是_____.

9. 设 $\lambda$ 是 $\boldsymbol{A}$ 的特征值，$\boldsymbol{x}$ 是属于 $\lambda$ 的特征向量. 为了证明下述论断（1）（2）（3），需要对方程组 $\boldsymbol{Ax}=\lambda\boldsymbol{x}$ 作怎样的变形?

（1）类似于习题 4，$\lambda^2$ 是 $\boldsymbol{A}^2$ 的特征值.

（2）类似于习题 3，$\lambda^{-1}$ 是 $\boldsymbol{A}^{-1}$ 的特征值.

（3）类似于习题 2，$\lambda+1$ 是 $\boldsymbol{A}+\boldsymbol{I}$ 的特征值.

10. 求马尔可夫矩阵 $\boldsymbol{A}$ 和 $\boldsymbol{A}^\infty$ 的特征值和特征向量. 据此说明为什么 $\boldsymbol{A}^{100}$ 和 $\boldsymbol{A}^\infty$ 非常接近.

$$\boldsymbol{A}=\begin{bmatrix}0.6 & 0.2\\ 0.4 & 0.8\end{bmatrix} \qquad \boldsymbol{A}^\infty=\begin{bmatrix}1/3 & 1/3\\ 2/3 & 2/3\end{bmatrix}=\boldsymbol{A}^n\text{的极限}$$

11. 设二阶方阵 $\boldsymbol{A}$ 有两个不同的特征值 $\lambda_1$、$\lambda_2$、$\boldsymbol{x}_1,\boldsymbol{x}_2$ 分别是属于这两个特征值的特征向量. 一个奇怪的现象：$\boldsymbol{A}-\lambda_1\boldsymbol{I}$ 的列向量都是 $\boldsymbol{x}_2$ 的倍数，你知道为什么吗？

12. 下述矩阵 $\boldsymbol{P}$ 是投影矩阵，我们已知它的特征值是 1 和 0. 求 $\boldsymbol{P}$ 的三个特征向量：[①]

投影矩阵

$$\boldsymbol{P}=\begin{bmatrix}0.2 & 0.4 & 0\\ 0.4 & 0.8 & 0\\ 0 & 0 & 1\end{bmatrix}$$

若两个特征向量属于同一个特征值 $\lambda$，它们的线性组合（若非零向量）也是特征向量. 求 $\boldsymbol{P}$ 的一个分量都不等于零的特征向量.

13. 设 $\boldsymbol{u}=\begin{bmatrix}\frac{1}{6} & \frac{1}{6} & \frac{3}{6} & \frac{5}{6}\end{bmatrix}^{\mathrm{T}}$ 是单位向量，$\boldsymbol{P}=\boldsymbol{u}\boldsymbol{u}^{\mathrm{T}}$ 是秩 1 矩阵；注意到有 $\boldsymbol{u}^{\mathrm{T}}\boldsymbol{u}=1$，$\boldsymbol{P}^2=\boldsymbol{P}$.

（1）因为 $(\boldsymbol{u}\boldsymbol{u}^{\mathrm{T}})\boldsymbol{u}=\boldsymbol{u}(____)$，所以 $\boldsymbol{P}\boldsymbol{u}=\boldsymbol{u}$，从而 $\lambda=1$ 是 $\boldsymbol{P}$ 的特征值.

（2）若 $\boldsymbol{v}$ 和 $\boldsymbol{u}$ 正交，证明：$\boldsymbol{P}\boldsymbol{v}=\boldsymbol{0}$，从而 $\lambda=0$ 是 $\boldsymbol{P}$ 的特征值.

（3）求 $\boldsymbol{P}$ 属于特征值 $\lambda=0$ 的三个线性无关的特征向量.

14. 对旋转矩阵 $\boldsymbol{Q}$，解二次多项式方程 $\det(\boldsymbol{Q}-\lambda\boldsymbol{I})=0$ 求出其特征值 $\lambda=\cos\theta\pm\mathrm{i}\sin\theta$：

$$\boldsymbol{Q}=\begin{bmatrix}\cos\theta & -\sin\theta\\ \sin\theta & \cos\theta\end{bmatrix}$$

$xy$ 平面上逆时针旋转 $\theta$ 角，没有实数特征值.

解线性方程组 $(\boldsymbol{Q}-\lambda\boldsymbol{I})\boldsymbol{x}=\boldsymbol{0}$，求 $\boldsymbol{Q}$ 的特征向量. 提醒：$\mathrm{i}^2=-1$.

15. 任意置换矩阵都保持 $\boldsymbol{x}=\begin{bmatrix}1 & \cdots & 1\end{bmatrix}^{\mathrm{T}}$ 不动，所以 $\lambda=1$ 是置换矩阵的特征值. 解方程组 $\det(\boldsymbol{P}-\lambda\boldsymbol{I})=0$，求下述置换矩阵的另外两个特征值（可能等于 1，也可能是复数）：

$$\boldsymbol{P}=\begin{bmatrix}0 & 1 & 0\\ 0 & 0 & 1\\ 1 & 0 & 0\end{bmatrix} \qquad \boldsymbol{P}=\begin{bmatrix}0 & 0 & 1\\ 0 & 1 & 0\\ 1 & 0 & 0\end{bmatrix}$$

所有特征值模长都是 1：$|\lambda|=1$

16. **方阵的行列式等于其特征值的乘积.** 证明如下：根据代数基本定理，特征多项式 $\det(\boldsymbol{A}-\lambda\boldsymbol{I})$ 总是可以分解成 1 次因子的乘积：

$$\det(\boldsymbol{A}-\lambda\boldsymbol{I})=(\lambda_1-\lambda)(\lambda_2-\lambda)\cdots(\lambda_n-\lambda).$$

等式两边同时取 $\lambda=0$，则 $\det\boldsymbol{A}=$ _____.

17. 方阵对角元之和（即方阵的迹）等于其特征值之和. 例如：

$$\boldsymbol{A}=\begin{bmatrix}a & b\\ c & d\end{bmatrix} \qquad \det(\boldsymbol{A}-\lambda\boldsymbol{I})=\lambda^2-(a+d)\lambda+(ad-bc)=0$$

① 译者注：这道题的本意应该是求三个线性无关的特征向量. 否则任取一个特征向量 $\boldsymbol{x}$，那么 $2\boldsymbol{x}$、$3\boldsymbol{x}$ 也都是特征向量.

则 $\boldsymbol{A}$ 的特征值是 $\lambda_1=\dfrac{(a+d)+\sqrt{\quad}}{2}$ 和 $\lambda_2=$_____. 它们的和是_____. 若 $\boldsymbol{A}$ 的特征值是 $\lambda_1=3,\lambda_2=4$，则 $\det(\boldsymbol{A}-\lambda\boldsymbol{I})=$_____.

18. 如果二阶方阵 $\boldsymbol{A}$ 的特征值是 $\lambda_1=4,\lambda_2=5$，那么 $\det(\boldsymbol{A}-\lambda\boldsymbol{I})=(\lambda-4)(\lambda-5)=\lambda^2-9\lambda+20$. 请构造三个以 4 和 5 为特征值的二阶方阵. 这样的矩阵迹等于 9，行列式等于 20.

19. 已知三阶方阵 $\boldsymbol{B}$ 的特征值是 0、1、2. 据此，下述四项中有三项可以给出明确的解答，请找出这三项，并给出答案.

（1）$\boldsymbol{B}$ 的秩；

（2）$\boldsymbol{B}^{\mathrm{T}}\boldsymbol{B}$ 的行列式；

（3）$\boldsymbol{B}^{\mathrm{T}}\boldsymbol{B}$ 的特征值；

（4）$(\boldsymbol{B}^2+\boldsymbol{I})^{-1}$ 的特征值.

20. 把 $\boldsymbol{A}$ 和 $\boldsymbol{C}$ 的最后一行补充完整，使得它们的特征值分别是 4、7 和 1、2、3：

友阵　　$\boldsymbol{A}=\begin{bmatrix}0&1*&*\end{bmatrix}$　　$\boldsymbol{C}=\begin{bmatrix}0&1&0\\0&0&1*&*&*\end{bmatrix}$

21. $\boldsymbol{A}$ 和 $\boldsymbol{A}^{\mathrm{T}}$ 的特征值相同[①]. 因为_____，所以有 $\det(\boldsymbol{A}-\lambda\boldsymbol{I})=\det(\boldsymbol{A}^{\mathrm{T}}-\lambda\boldsymbol{I})$，这个等式说明 $\boldsymbol{A}$ 和 $\boldsymbol{A}^{\mathrm{T}}$ 的特征多项式相等，而特征值就是特征多项式的根，这就证明了开始的论断. 虽然 $\boldsymbol{A}$ 和 $\boldsymbol{A}^{\mathrm{T}}$ 的特征值相同，但是未必有相同的特征向量，请举反例说明.

22. 设 $\boldsymbol{M}$ 是三阶马尔可夫矩阵：所有分量都是正实数，且每个列向量所有分量的和都是 1. 证明：$\boldsymbol{M}^{\mathrm{T}}\begin{bmatrix}1\\1\\1\end{bmatrix}=\begin{bmatrix}1\\1\\1\end{bmatrix}$. 根据习题 21 可知 $\lambda=1$ 是 $\boldsymbol{M}$ 的特征值. 不仅如此，如果 $\boldsymbol{M}$ 还是迹为 $\dfrac{1}{2}$ 的奇异矩阵，你能求出它所有的特征值吗？

23. 构造三个有二重特征值 $\lambda_1=\lambda_2=0$ 的二阶方阵. 满足此条件的矩阵 $\boldsymbol{A}$ 迹和行列式都是 0，但是 $\boldsymbol{A}$ 可能不是零矩阵. 证明：$\boldsymbol{A}^2=\boldsymbol{0}$.

24. 下述矩阵 $\boldsymbol{A}$ 是秩 1 矩阵，求 $\boldsymbol{A}$ 的三个特征值和三个线性无关的特征向量：

$$\boldsymbol{A}=\begin{bmatrix}1\\2\\1\end{bmatrix}\begin{bmatrix}2&1&1\end{bmatrix}=\begin{bmatrix}2&1&2\\4&2&4\\2&1&2\end{bmatrix}$$

25. 设 $n$ 阶方阵 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 有相同的特征值 $\lambda_1,\lambda_2,\cdots,\lambda_n$ 和 $n$ 个公共的线性无关的特征向量 $\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_n$，且 $\boldsymbol{A}\boldsymbol{x}_i=\boldsymbol{B}\boldsymbol{x}_i=\lambda_i\boldsymbol{x}_i(1\leqslant i\leqslant n)$.[②]证明：$\boldsymbol{A}=\boldsymbol{B}$. 提示：任意向量 $\boldsymbol{x}$ 都是 $\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_n$ 的线性组合，那么 $\boldsymbol{A}\boldsymbol{x}$ 和 $\boldsymbol{B}\boldsymbol{x}$ 有什么关系？

---

① 译者注：设 $\boldsymbol{A}$、$\boldsymbol{B}$ 都是 $n$ 阶方阵，那么它们都有 $n$ 个特征值. 我们说它们的特征值相同，意思是可以把二者的特征值分别排列成 $\lambda_1,\lambda_2,\cdots,\lambda_n$ 和 $\mu_1,\mu_2,\cdots,\mu_n$ 使得 $\lambda_1=\mu_1,\lambda_2=\mu_2,\cdots,\lambda_n=\mu_n$. 也可以换个说法，特征值、每个特征值的重数都相同.

② 译者注：原题没有后一个条件，那是不正确的. 反例如：$\boldsymbol{A}=\begin{bmatrix}3&-1\\-1&3\end{bmatrix},\boldsymbol{B}=\begin{bmatrix}3&1\\1&3\end{bmatrix}$，它们的特征值都是 2、4，$\boldsymbol{x}_1=\begin{bmatrix}1&1\end{bmatrix}^{\mathrm{T}},\boldsymbol{x}_2=\begin{bmatrix}1&-1\end{bmatrix}^{\mathrm{T}}$ 也都是 $\boldsymbol{A}$、$\boldsymbol{B}$ 的特征向量，但是 $\boldsymbol{A}\boldsymbol{x}_1=2\boldsymbol{x}_1,\boldsymbol{A}\boldsymbol{x}_2=4\boldsymbol{x}_2$，而 $\boldsymbol{B}\boldsymbol{x}_1=4\boldsymbol{x}_1,\boldsymbol{B}\boldsymbol{x}_2=2\boldsymbol{x}_2$. 从这道题也可以看出来特征对 $(\lambda,\boldsymbol{x})$ 这个概念的优势.

26. 设 $\boldsymbol{B}$、$\boldsymbol{C}$、$\boldsymbol{D}$ 都是二阶方阵，$\boldsymbol{B}$ 的特征值是 1、2，$\boldsymbol{C}$ 的特征值是 3、4，$\boldsymbol{D}$ 的特征值是 5、7，求分块矩阵 $\boldsymbol{A}$ 的特征值：

$$\boldsymbol{B}=\begin{bmatrix}0&1\\-2&3\end{bmatrix},\quad \boldsymbol{C}=\begin{bmatrix}3&0\\0&4\end{bmatrix},\quad \boldsymbol{D}=\begin{bmatrix}6&1\\1&6\end{bmatrix},\qquad \boldsymbol{A}=\begin{bmatrix}\boldsymbol{B}&\boldsymbol{C}\\\boldsymbol{0}&\boldsymbol{D}\end{bmatrix}=\begin{bmatrix}0&1&3&0\\-2&3&0&4\\0&0&6&1\\0&0&1&6\end{bmatrix}$$

27. 求四阶方阵 $\boldsymbol{A}$ 和 $\boldsymbol{C}$ 的秩和特征值：

$$\boldsymbol{A}=\begin{bmatrix}1&1&1&1\\1&1&1&1\\1&1&1&1\\1&1&1&1\end{bmatrix}\qquad \boldsymbol{C}=\begin{bmatrix}1&0&1&0\\0&1&0&1\\1&0&1&0\\0&1&0&1\end{bmatrix}$$

28. $\boldsymbol{A}$ 和习题 27 相同，求 $\boldsymbol{B}=\boldsymbol{A}-\boldsymbol{I}$ 和 $\boldsymbol{C}=\boldsymbol{I}-\boldsymbol{A}$ 的特征值和行列式：

$$\boldsymbol{B}=\boldsymbol{A}-\boldsymbol{I}=\begin{bmatrix}0&1&1&1\\1&0&1&1\\1&1&0&1\\1&1&1&0\end{bmatrix},\quad \boldsymbol{C}=\boldsymbol{I}-\boldsymbol{A}=\begin{bmatrix}0&-1&-1&-1\\-1&0&-1&-1\\-1&-1&0&-1\\-1&-1&-1&0\end{bmatrix}$$

29.（复习）求矩阵 $\boldsymbol{A}$、$\boldsymbol{B}$、$\boldsymbol{C}$ 的特征值

$$\boldsymbol{A}=\begin{bmatrix}1&2&3\\0&4&5\\0&0&6\end{bmatrix}\qquad \boldsymbol{B}=\begin{bmatrix}0&0&1\\0&2&0\\3&0&0\end{bmatrix}\qquad \boldsymbol{C}=\begin{bmatrix}2&2&2\\2&2&2\\2&2&2\end{bmatrix}$$

30. 若 $a+b=c+d$，证明：$\begin{bmatrix}1\\1\end{bmatrix}$ 是矩阵 $\boldsymbol{A}=\begin{bmatrix}a&b\\c&d\end{bmatrix}$ 的特征向量；求 $\boldsymbol{A}$ 所有的特征值.

31. 交换矩阵的前两行，再交换前两列，矩阵的特征值不变. 对下面的矩阵 $\boldsymbol{A}$ 和 $\boldsymbol{B}$，分别求它们属于特征值 $\lambda=11$ 的特征向量. 因为 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 都是秩 1 矩阵，所以 $\lambda_2=\lambda_3=0$.

$$\boldsymbol{A}=\begin{bmatrix}1&2&1\\3&6&3\\4&8&4\end{bmatrix}\qquad \boldsymbol{B}=\boldsymbol{P}\boldsymbol{A}\boldsymbol{P}^{\mathrm{T}}=\begin{bmatrix}6&3&3\\2&1&1\\8&4&4\end{bmatrix}$$

32. 假设三阶方阵 $\boldsymbol{A}$ 的特征值是 0、3、5，线性无关的向量 $\boldsymbol{u}$、$\boldsymbol{v}$、$\boldsymbol{w}$ 分别是属于这三个特征值的特征向量.

（1）请分别给出 $\boldsymbol{A}$ 的零空间和列空间的一组基.

（2）先给出方程组 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{v}+\boldsymbol{w}$ 的一个特解；再求该方程组的解集.

（3）断言：$\boldsymbol{A}\boldsymbol{x}=\boldsymbol{u}$ 无解. 否则，向量_____ 将属于 $\boldsymbol{A}$ 的列空间.

## 挑 战 一 下

33. 设 $\boldsymbol{A}=\boldsymbol{u}\boldsymbol{v}^{\mathrm{T}}$ 是二阶秩 1 方阵，证明：$\boldsymbol{u}$ 是 $\boldsymbol{A}$ 的特征向量. 求 $\boldsymbol{A}$ 的两个特征值 $\lambda_1$、$\lambda_2$. 验证：$\lambda_1+\lambda_2$ 等于 $\boldsymbol{A}$ 的迹 $u_1v_1+u_2v_2$.

34. 设 $\boldsymbol{P}$ 是下述四阶置换矩阵，通过特征方程 $\det(\boldsymbol{P}-\lambda\boldsymbol{I})=0$ 求它的特征值. 哪些向量被 $\boldsymbol{P}$ 左乘之后不变？这些向量是属于特征值 $\lambda=1$ 的特征向量. 你能再求出 $\boldsymbol{P}$ 的三个特征向量吗？[①]

$$\boldsymbol{P}=\begin{bmatrix}0&0&0&1\\1&0&0&0\\0&1&0&0\\0&0&1&0\end{bmatrix}$$

35. 我们知道，三阶置换矩阵共有 6 个. 这 6 个置换矩阵的行列式有哪些可能的取值？主元有哪些可能的取值？迹有哪些可能的取值？它们的特征值有 4 个可能的取值，是哪 4 个？请参考习题 15.

36.（Heisenberg 不确定原理）若 $\boldsymbol{A}$、$\boldsymbol{B}$ 都是有限阶方阵，那么等式 $\boldsymbol{AB}-\boldsymbol{BA}=\boldsymbol{I}$ 不可能成立. 思考一下为什么？但是对于无限阶[②]方阵则有可能成立. 假设 $\boldsymbol{A}$、$\boldsymbol{B}$ 都是无限阶方阵，$\boldsymbol{A}=\boldsymbol{A}^{\mathrm{T}},\boldsymbol{B}=-\boldsymbol{B}^{\mathrm{T}}$ 且 $\boldsymbol{AB}-\boldsymbol{BA}=\boldsymbol{I}$. 那么对于任意 $\boldsymbol{x}$：

$$\boldsymbol{x}^{\mathrm{T}}\boldsymbol{x}=\boldsymbol{x}^{\mathrm{T}}\boldsymbol{ABx}-\boldsymbol{x}^{\mathrm{T}}\boldsymbol{BAx}\leqslant 2\|\boldsymbol{Ax}\|\,\|\boldsymbol{Bx}\|.$$

请利用 Schwartz 不等式 $|\boldsymbol{u}^{\mathrm{T}}\boldsymbol{v}|\leqslant\|\boldsymbol{u}\|\,\|\boldsymbol{v}\|$ 说明上面不等号成立的原因. Heisenberg 不等式说明 $\dfrac{\|\boldsymbol{Ax}\|}{\|\boldsymbol{x}\|}$ 和 $\dfrac{\|\boldsymbol{Bx}\|}{\|\boldsymbol{x}\|}$ 的乘积不小于 $\dfrac{1}{2}$. 物理含义是：我们不可能使得位置误差和动量误差都很小，或者说，不能同时精确地测出位置和动量.

37. 找一个 $2\times 2$ 旋转矩阵 $\boldsymbol{A}$，满足 $\boldsymbol{A}\neq\boldsymbol{I}$ 但是 $\boldsymbol{A}^3=\boldsymbol{I}$. $\boldsymbol{A}$ 的特征值 $\lambda$ 满足 $\lambda^3=1$，所以可能是 $\mathrm{e}^{\frac{2\pi\mathrm{i}}{3}}$ 和 $\mathrm{e}^{-\frac{2\pi\mathrm{i}}{3}}$. $\boldsymbol{A}$ 的行列式和迹是多少？

38.（1）求矩阵 $\boldsymbol{A}=\begin{bmatrix}0.4&1-c\\0.6&c\end{bmatrix}$ 的特征值和特征向量. 注意：结果依赖于参数 $c$.

（2）证明：当 $c=1.6$ 时，$\boldsymbol{A}$ 的特征向量只分布在一条直线上.

（3）当 $c=0.8$ 时，$\boldsymbol{A}$ 是马尔可夫矩阵. 那么 $\boldsymbol{A}^n$ 最终将收敛于哪个矩阵 $\boldsymbol{A}^{\infty}$？

## 6.2　矩阵的对角化

（1）设 $\boldsymbol{\Lambda}=\mathrm{diag}(\lambda_1,\lambda_2,\cdots,\lambda_n)$ 是对角矩阵，且 $\boldsymbol{AX}=\boldsymbol{X\Lambda}$，那么该等式的第 $k$ 列即 $\boldsymbol{Ax}_k=\lambda_k\boldsymbol{x}_k$. $\boldsymbol{\Lambda}$ 称作特征值矩阵.

（2）若 $\boldsymbol{X}$ 的列向量线性无关，则 $\boldsymbol{X}$ 对角化 $\boldsymbol{A}$：$\boxed{\boldsymbol{A}=\boldsymbol{X\Lambda X^{-1}}\text{ 且 }\boldsymbol{A}^k=\boldsymbol{X\Lambda}^k\boldsymbol{X}^{-1}.}$

① 译者注：见第 12 题注. 原题的本意应该是：$\boldsymbol{P}$ 有四个特征值，再求分别属于其他三个特征值的特征向量.

② 译者注：我们没有定义过无限阶方阵，下面的讨论也无法遵循严格的数学范式；因此在处理这个习题的时候，把无限阶矩阵假装当作有限阶矩阵那样处理，建立一些数学直觉就算是成功了.

（3）方程 $\boldsymbol{u}_{k+1}=\boldsymbol{A}\boldsymbol{u}_k$ 可以递归求解：

$$\boldsymbol{u}_k=\boldsymbol{A}^k\boldsymbol{u}_0=\boldsymbol{X}\boldsymbol{\Lambda}^k\boldsymbol{X}^{-1}\boldsymbol{u}_0=\boxed{c_1\lambda_1^k\boldsymbol{x}_1+c_2\lambda_2^k\boldsymbol{x}_2+\cdots+c_n\lambda_n^k\boldsymbol{x}_n}.$$

（4）若 $\boldsymbol{A}$ 有 $n$ 个不相等的特征值，则特征矩阵 $\boldsymbol{X}$ 可逆且 $\boldsymbol{A}$ 可以对角化.

若 $\boldsymbol{A}$ 有相同的特征值，则 $\boldsymbol{A}$ 可能没有充分多的线性无关的特征向量，$\boldsymbol{X}$ 不可逆.

（5）若存在可逆矩阵 $\boldsymbol{B}$ 使得 $\boldsymbol{C}=\boldsymbol{B}^{-1}\boldsymbol{A}\boldsymbol{B}$，则称方阵 $\boldsymbol{C}$ 和 $\boldsymbol{A}$ 相似. 相似的矩阵有相同的特征值.

当 $\boldsymbol{x}$ 是 $\boldsymbol{A}$ 的特征向量时，$\boldsymbol{x}$ 被 $\boldsymbol{A}$ 左乘等同于数乘 $\lambda$：$\boldsymbol{A}\boldsymbol{x}=\lambda\boldsymbol{x}$. 如果矩阵乘法能转化成矩阵乘以其特征向量，所有的困难都将迎刃而解. 特征值的全体将以对角矩阵的形式出现，而对角矩阵的相乘等价于对角元分别相乘，这显然是容易的. 以计算矩阵的高次幂为例，有 $\boldsymbol{A}^{100}=\boldsymbol{X}\boldsymbol{\Lambda}^{100}\boldsymbol{X}^{-1}$.

本节的主旨非常明确. **如果我们恰当地使用特征向量，矩阵 $\boldsymbol{A}$ 会变成对角矩阵 $\boldsymbol{\Lambda}$.** 这是我们核心思想的矩阵表述. 我们马上从一个例子开始，计算虽然简单，但是能够说明本质的内容. 稍后再解释等式 $\boldsymbol{A}\boldsymbol{X}=\boldsymbol{X}\boldsymbol{\Lambda}$ 的含义.

**对角化** 假设 $n$ 阶方阵 $\boldsymbol{A}$ 有 $n$ 个线性无关的特征向量 $\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_n$. 把它们作为列向量排成可逆矩阵 $\boldsymbol{X}$，称作 $\boldsymbol{A}$ 的**特征向量矩阵**. 那么 $\boldsymbol{X}^{-1}\boldsymbol{A}\boldsymbol{X}$ 是对角**特征值矩阵** $\boldsymbol{\Lambda}$.

特征向量矩阵 $\boldsymbol{X}$
特征值矩阵 $\boldsymbol{\Lambda}$

$$\boldsymbol{X}^{-1}\boldsymbol{A}\boldsymbol{X}=\boldsymbol{\Lambda}=\begin{bmatrix}\lambda_1 & & \\ & \ddots & \\ & & \lambda_n\end{bmatrix} \tag{6.10}$$

这样的矩阵 $\boldsymbol{A}$ 是“可对角化”的. 因为小写希腊字母 $\lambda$ 用来表示特征值，所以我们用大写希腊字母 $\boldsymbol{\Lambda}$ 来表示特征值矩阵，它是对角矩阵，对角元是特征值.

**例 6.6** $\boldsymbol{A}=\begin{bmatrix}2 & 4\\ 0 & 6\end{bmatrix}$ 是上三角矩阵，所以特征值是其对角元 $\lambda_1=2,\lambda_2=6$.

特征向量 $\begin{bmatrix}1\\0\end{bmatrix},\begin{bmatrix}1\\1\end{bmatrix}$ 排成 $\boldsymbol{X}$

$$\underset{\boldsymbol{X}^{-1}}{\begin{bmatrix}1 & -1\\ 0 & 1\end{bmatrix}}\ \underset{\boldsymbol{A}}{\begin{bmatrix}2 & 4\\ 0 & 6\end{bmatrix}}\ \underset{\boldsymbol{X}}{\begin{bmatrix}1 & 1\\ 0 & 1\end{bmatrix}}=\underset{\boldsymbol{\Lambda}}{\begin{bmatrix}2 & 0\\ 0 & 6\end{bmatrix}}$$

等价地说，$\boldsymbol{A}=\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1}$，于是 $\boldsymbol{A}^2=\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1}\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1}$，即 $\boldsymbol{A}^2=\boldsymbol{X}\boldsymbol{\Lambda}^2\boldsymbol{X}^{-1}$.

**$\boldsymbol{A}^2$ 和 $\boldsymbol{A}$ 有相同的特征向量矩阵 $\boldsymbol{X}$，特征值是 $\boldsymbol{A}$ 特征值的平方，即 $\boldsymbol{\Lambda}^2$ 的对角元 4 和 36.**

**为什么写成 $\boldsymbol{A}\boldsymbol{X}=\boldsymbol{X}\boldsymbol{\Lambda}$ 的形式？** $\boldsymbol{X}$ 的列向量是 $\boldsymbol{A}$ 的特征向量，所以 $\boldsymbol{A}\boldsymbol{X}$ 的每一列都是 $\boldsymbol{A}$ 乘以它的特征向量. $\boldsymbol{A}\boldsymbol{X}$ 的第一列是 $\boldsymbol{A}\boldsymbol{x}_1$，等于 $\lambda\boldsymbol{x}_1$. 同理，$\boldsymbol{A}\boldsymbol{X}$ 等同于把 $\boldsymbol{X}$ 的每一列都乘以特征值：

$\boldsymbol{A}\boldsymbol{X}$

$$\boldsymbol{A}\boldsymbol{X}=\boldsymbol{A}\begin{bmatrix}\boldsymbol{x}_1 & \cdots & \boldsymbol{x}_n\end{bmatrix}=\begin{bmatrix}\lambda_1\boldsymbol{x}_1 & \cdots & \lambda_n\boldsymbol{x}_n\end{bmatrix}.$$

等式右边分解为 $\boldsymbol{X}\boldsymbol{\Lambda}$（不是 $\boldsymbol{\Lambda}\boldsymbol{X}$，这是将 $\boldsymbol{X}$ 的每一行乘以特征值）：

$\boldsymbol{X}\boldsymbol{\Lambda}$

$$\begin{bmatrix}\lambda_1\boldsymbol{x}_1 & \cdots & \lambda_n\boldsymbol{x}_n\end{bmatrix}=\begin{bmatrix}\boldsymbol{x}_1 & \cdots & \boldsymbol{x}_n\end{bmatrix}\begin{bmatrix}\lambda_1 & & \\ & \ddots & \\ & & \lambda_n\end{bmatrix}=\boldsymbol{X}\boldsymbol{\Lambda}.$$

请务必注意矩阵相乘的正确顺序！一定要让特征值乘以 $\boldsymbol{X}$ 的列向量. 至此矩阵对角化就完成了，我们可以把 $\boldsymbol{AX}=\boldsymbol{X\Lambda}$ 写成两种形式：

$$\boxed{\boldsymbol{AX}=\boldsymbol{X\Lambda} \quad \text{等价于} \quad \boldsymbol{X}^{-1}\boldsymbol{AX}=\boldsymbol{\Lambda} \quad \text{或} \quad \boldsymbol{A}=\boldsymbol{X\Lambda X}^{-1}.} \tag{6.11}$$

因为我们假设 $\boldsymbol{X}$ 的列向量（即 $\boldsymbol{A}$ 的特征向量）线性无关，所以 $\boldsymbol{X}$ 可逆. 如果不存在 $n$ 个线性无关的特征向量，则 $\boldsymbol{A}$ 不能被对角化.

$\boldsymbol{A}$ 和 $\boldsymbol{\Lambda}$ 有相同的特征值：$\lambda_1,\lambda_2,\cdots,\lambda_n$，但是二者的特征向量不一样. 特征向量 $\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_n$ 的任务是对角化 $\boldsymbol{A}$，由它们组成的矩阵 $\boldsymbol{X}$ 使得 $\boldsymbol{A}=\boldsymbol{X\Lambda X}^{-1}$. 你很快就会明白这么处理的简单之处、重要性以及意义. 考虑矩阵的 $k$ 次幂，由 $\boldsymbol{X}^{-1}\boldsymbol{X}=\boldsymbol{I}$ 可得：$\boldsymbol{A}^k=\boldsymbol{X\Lambda}^k\boldsymbol{X}^{-1}$：

$$\boldsymbol{A}^k=(\boldsymbol{X\Lambda X}^{-1})(\boldsymbol{X\Lambda X}^{-1})\cdots(\boldsymbol{X\Lambda X}^{-1})=\boldsymbol{X\Lambda}^k\boldsymbol{X}^{-1}$$

比如说例 6.6：

$$\begin{bmatrix}2&4\\0&6\end{bmatrix}^k=\begin{bmatrix}1&1\\0&1\end{bmatrix}\begin{bmatrix}2^k&\\&6^k\end{bmatrix}\begin{bmatrix}1&-1\\0&1\end{bmatrix}=\begin{bmatrix}2^k&6^k-2^k\\0&6^k\end{bmatrix}=\boldsymbol{A}^k$$

$k=1$ 时，$\boldsymbol{A}^k=\boldsymbol{A}$ 无须多言；$k=0$ 时，$\boldsymbol{A}^k=\boldsymbol{I}$（$\lambda^0=1$）；$k=-1$ 时，$\boldsymbol{A}^k=\boldsymbol{A}^{-1}$. 我们验算一下 $k=2$. 一方面根据上式：

$$\boldsymbol{A}^2=\begin{bmatrix}2^2&6^2-2^2\\0&6^2\end{bmatrix}=\begin{bmatrix}4&42\\0&36\end{bmatrix};$$

另一方面，直接计算矩阵乘法：

$$\boldsymbol{A}^2=\begin{bmatrix}2&4\\0&6\end{bmatrix}\begin{bmatrix}2&4\\0&6\end{bmatrix}=\begin{bmatrix}2\cdot2+4\cdot0&2\cdot4+4\cdot6\\0\cdot2+6\cdot0&0\cdot4+6\cdot6\end{bmatrix}=\begin{bmatrix}4&42\\0&36\end{bmatrix}$$

二者吻合.

在进一步阐述 $\boldsymbol{\Lambda}$ 之前，我们作四个注释：

**注释 1**　若 $n$ 阶方阵有 $n$ 个不同的特征值（比如 2 和 6），那么分属 $n$ 个特征值的 $n$ 个特征向量线性无关，特征向量矩阵 $\boldsymbol{X}$ 可逆. 从而，只有单重特征值的方阵都可以对角化.

**注释 2**　特征向量乘以任何非零常数还是特征向量：$\boldsymbol{A}(c\boldsymbol{x})=\lambda(c\boldsymbol{x})$ 仍然成立. 在例 6.6 中，我们可以将 $\boldsymbol{x}=\begin{bmatrix}1&1\end{bmatrix}^{\mathrm{T}}$ 除以 $\sqrt{2}$ 以得到单位特征向量.

MATLAB 以及几乎所有其他代码产生的特征向量长度都是 1.

**注释 3**　特征值矩阵中特征值的顺序需要和特征向量矩阵中特征向量的顺序对应. 比如说，我们交换例 6.6 中 $\boldsymbol{\Lambda}$ 对角元 2、6 的位置，那么 $\boldsymbol{X}$ 的列向量 $\begin{bmatrix}1&1\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}1&0\end{bmatrix}^{\mathrm{T}}$ 也要交换位置：

$$\boldsymbol{X}_{\text{新}}^{-1}\boldsymbol{A}\boldsymbol{X}_{\text{新}}=\boldsymbol{\Lambda}_{\text{新}} \qquad \begin{bmatrix}0&1\\1&-1\end{bmatrix}\begin{bmatrix}2&4\\0&6\end{bmatrix}\begin{bmatrix}1&1\\1&0\end{bmatrix}=\begin{bmatrix}\mathbf{6}&4\\0&\mathbf{2}\end{bmatrix}$$

要将 $\boldsymbol{A}$ 对角化，必须使用特征向量矩阵. 假设 $\boldsymbol{X}^{-1}\boldsymbol{AX}=\boldsymbol{\Lambda}$，则 $\boldsymbol{AX}=\boldsymbol{X\Lambda}$. 若 $\boldsymbol{X}$ 的第一列是 $\boldsymbol{x}$，那么 $\boldsymbol{AX}$ 和 $\boldsymbol{X\Lambda}$ 的第一列分别是 $\boldsymbol{Ax}$ 和 $\lambda_1\boldsymbol{x}$，而它们相等，所以 $\boldsymbol{x}$ 必须是特征向量.

**注释 4 (针对多重特征值的再次提醒)** 有些矩阵，线性无关的特征向量不够多，这导致该矩阵无法对角化. 这里有一些例子:

$$\text{不可对角化} \qquad \boldsymbol{A}=\begin{bmatrix}1 & -1\\ 1 & -1\end{bmatrix} \quad \text{和} \quad \boldsymbol{B}=\begin{bmatrix}0 & 1\\ 0 & 0\end{bmatrix}.$$

它们的特征值都是 0 和 0. $\lambda=0$ 这个数字本身并无特殊之处，问题在于重复. 第一个矩阵的所有特征向量都是 $\begin{bmatrix}1 & 1\end{bmatrix}^{\mathrm{T}}$ 的倍数:

$$\text{特征向量分布在一条直线上} \qquad \boldsymbol{A}\boldsymbol{x}=0\boldsymbol{x} \text{ 即 } \begin{bmatrix}1 & -1\\ 1 & -1\end{bmatrix}\boldsymbol{x}=\begin{bmatrix}0\\ 0\end{bmatrix}, \text{ 解得 } \boldsymbol{x}=c\begin{bmatrix}1\\ 1\end{bmatrix}.$$

$\boldsymbol{A}$ 没有两个线性无关的特征向量，所以 $\boldsymbol{A}$ 不可对角化.

这两个矩阵是检验任何有关特征向量的陈述的好例子. 在许多判断题中，不可对角化的矩阵会导致论断出错.

请务必记住，可逆性与可对角化之间没有必然的联系:

(1) 与可逆性相关的是特征值（可逆则 $\lambda\neq 0$）;

(2) 与对角化相关的是特征向量（$n$ 个线性无关的特征向量）.

由于对任意特征值 $\lambda$，$\boldsymbol{A}-\lambda\boldsymbol{I}$ 是奇异矩阵，所以任何特征值都至少有一个属于它的特征向量! 如果解方程组 $(\boldsymbol{A}-\lambda\boldsymbol{I})\boldsymbol{x}=0$ 发现只有零解 $\boldsymbol{x}=0$，那么 $\lambda$ 一定不是特征值，需要检查在解方程 $\det(\boldsymbol{A}-\lambda\boldsymbol{I})=0$ 时是否出现了错误.

还有一个已经陈述但是尚未证明的重要事实：**属于不同特征值的特征向量线性无关. 若 $\boldsymbol{A}$ 有 $n$ 个不同的特征值，则 $\boldsymbol{A}$ 可以对角化.**

在承认前半段陈述的情况下，后半段已经很清晰，并且实际上已经证明了. 我们先用严格的数学语言重新叙述前半段陈述.

**命题 6.1** 设 $\boldsymbol{A}$ 是 $n$ 阶方阵，$\lambda_1,\lambda_2,\cdots,\lambda_k$ 是 $\boldsymbol{A}$ 的 $k$ 个两两不等的特征值，$\boldsymbol{x}_i(1\leqslant i\leqslant k)$ 是属于 $\lambda_i$ 的特征向量，则 $\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_k$ 线性无关.

**证明** $k=2$ 时，假设 $c_1\boldsymbol{x}_1+c_2\boldsymbol{x}_2=\boldsymbol{0}$，左乘 $\boldsymbol{A}$ 得 $c_1\lambda_1\boldsymbol{x}_1+c_2\lambda_2\boldsymbol{x}_2=\boldsymbol{0}$；乘以 $\lambda_2$ 得 $c_1\lambda_2\boldsymbol{x}_1+c_2\lambda_2\boldsymbol{x}_2=\boldsymbol{0}$. 两式相减得

$$(\lambda_1-\lambda_2)c_1\boldsymbol{x}_1=\boldsymbol{0}.$$

因为 $\lambda_1\neq\lambda_2$ 且 $\boldsymbol{x}_1\neq 0$，上式推出 $c_1=0$；类似地，$c_2=0$. 也就是说，只有 $c_1=c_2=0$ 才使得线性组合 $c_1\boldsymbol{x}_1+c_2\boldsymbol{x}_2=\boldsymbol{0}$，所以 $\boldsymbol{x}_1$ 和 $\boldsymbol{x}_2$ 线性无关.

这个证明可以推广到任意的 $k$. 假设 $c_1\boldsymbol{x}_1+c_2\boldsymbol{x}_2+\cdots+c_k\boldsymbol{x}_k=\boldsymbol{0}$，这个式子分别左乘 $\boldsymbol{A}$、乘以 $\lambda_k$，这两个式子 $\boldsymbol{x}_k$ 的系数都是 $c_k\lambda_k$；两者相减就把 $\boldsymbol{x}_k$ 消掉，得到关于 $\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_{k-1}$ 的等式:

$$c_1(\lambda_1-\lambda_k)\boldsymbol{x}_1+c_2(\lambda_2-\lambda_k)\boldsymbol{x}_2+\cdots+c_{k-1}(\lambda_{k-1}-\lambda_k)\boldsymbol{x}_{k-1}=\boldsymbol{0}.$$

再左乘 $\boldsymbol{A}$、乘以 $\lambda_{k-1}$，消掉 $\boldsymbol{x}_{k-1}$. 一步一步，最后只剩下 $\boldsymbol{x}_1$:

$$(\lambda_1-\lambda_2)\cdots(\lambda_1-\lambda_k)c_1\boldsymbol{x}_k=0 \quad\Longrightarrow\quad c_1=0. \tag{6.12}$$

同理，$c_2=0,c_3=0,\cdots,c_k=0$. 这说明 $\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_k$ 线性无关.

这样我们就证明了：属于不同特征值的特征向量线性无关.[①]若 $n$ 阶方阵有 $n$ 个不同的特征值，就有 $n$ 个线性无关的特征向量，它们排成的可逆矩阵 $\boldsymbol{X}$ 就可以将 $\boldsymbol{A}$ 对角化.

**例 6.7**　$\boldsymbol{A}$ 的幂　上一节提到的马尔可夫矩阵 $\boldsymbol{A}=\begin{bmatrix}0.8 & 0.3\\ 0.2 & 0.7\end{bmatrix}$ 的特征值是 $\lambda_1=1,\lambda_2=0.5$，于是 $\boldsymbol{A}=\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1}$，其中 $\boldsymbol{X}$、$\boldsymbol{\Lambda}$ 分别是 $\boldsymbol{A}$ 的特征向量矩阵和特征值矩阵：

马尔可夫矩阵的例子
$$\boldsymbol{A}=\begin{bmatrix}0.8 & 0.3\\ 0.2 & 0.7\end{bmatrix}=\begin{bmatrix}0.6 & 1\\ 0.4 & -1\end{bmatrix}\begin{bmatrix}1 & 0\\ 0 & 0.5\end{bmatrix}\begin{bmatrix}1 & 1\\ 0.4 & -0.6\end{bmatrix}=\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1}.$$

特征向量 $\begin{bmatrix}0.6 & 0.4\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}1 & -1\end{bmatrix}^{\mathrm{T}}$ 组成可逆矩阵 $\boldsymbol{X}$，它们同时也是 $\boldsymbol{A}^2$ 的特征向量. 下式可以看出 $\boldsymbol{X}$ 将 $\boldsymbol{A}^2$ 对角化成特征值矩阵 $\boldsymbol{\Lambda}^2$

$\boldsymbol{A}^2$ 有相同的特征向量矩阵 $\boldsymbol{X}$
$$\boxed{\boldsymbol{A}^2}=\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1}\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1}=\boxed{\boldsymbol{X}\boldsymbol{\Lambda}^2\boldsymbol{X}^{-1}.}\tag{6.13}$$

继续迭代，直接可以看出 $\boldsymbol{A}^k$ 的高次幂最终趋于“稳定状态”：

$\boldsymbol{A}$ 的高次幂
$$\boldsymbol{A}^k=\boldsymbol{X}\boldsymbol{\Lambda}^k\boldsymbol{X}^{-1}=\begin{bmatrix}0.6 & 1\\ 0.4 & -1\end{bmatrix}\begin{bmatrix}1^k & 0\\ 0 & 0.5^k\end{bmatrix}\begin{bmatrix}1 & 1\\ 0.4 & -0.6\end{bmatrix}$$

$k$ 充分大时，$0.5^k$ 极限是 0，由此得 $\boldsymbol{A}^\infty$ 的极限：

$k\to\infty$
$$\boldsymbol{A}^\infty=\begin{bmatrix}0.6 & 1\\ 0.4 & -1\end{bmatrix}\begin{bmatrix}1 & 0\\ 0 & 0\end{bmatrix}\begin{bmatrix}1 & 1\\ 0.4 & -0.6\end{bmatrix}=\begin{bmatrix}\mathbf{0.6} & \mathbf{0.6}\\ \mathbf{0.4} & \mathbf{0.4}\end{bmatrix}$$

极限矩阵的两列都是特征向量 $\boldsymbol{x}_1$，$\boldsymbol{A}^\infty$ 在本章一开始就引入了，此处因为计算 $\boldsymbol{A}$ 的高次幂（例如 $\boldsymbol{A}^{100}=\boldsymbol{X}\boldsymbol{\Lambda}^{100}\boldsymbol{X}^{-1}$）再次出现.

| 问题：$\boldsymbol{A}^k$ 何时趋于零矩阵？ | 回答：所有特征值的绝对值均小于 1：$\lvert\lambda\rvert<1$. |
|---|---|

### 6.2.1　相似矩阵：特征值相同

固定特征值矩阵 $\boldsymbol{\Lambda}$，改变特征向量矩阵 $\boldsymbol{X}$ 时，我们得到了一系列不同的矩阵 $\boldsymbol{A}=\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1}$，这些矩阵的特征值相同，都是 $\boldsymbol{\Lambda}$ 的对角元. 所有这些矩阵 $\boldsymbol{A}$（有相同的特征值矩阵）都是相似的.

相似的概念可以推广到任意矩阵（无论其是否可以对角化）. 固定一个矩阵 $\boldsymbol{C}$（不一定是对角矩阵），观察形如 $\boldsymbol{A}=\boldsymbol{B}\boldsymbol{C}\boldsymbol{B}^{-1}$ 的矩阵，其中 $\boldsymbol{B}$ 可以是任意可逆矩阵. 矩阵 $\boldsymbol{A}$ 和 $\boldsymbol{C}$ 都相似.

我们用字母 $\boldsymbol{C}$ 代替 $\boldsymbol{\Lambda}$，是因为此处并不限定 $\boldsymbol{C}$ 一定是对角矩阵；用字母 $\boldsymbol{B}$ 代替 $\boldsymbol{X}$，是因为 $\boldsymbol{B}$ 的列向量也可能不是特征向量. 唯一的要求是 $\boldsymbol{B}$ 必须可逆——矩阵 $\boldsymbol{A}$ 和 $\boldsymbol{C}$ 相似的最重要的必要条件是共享同样的 $n$ 个特征值.

所有形如 $\boldsymbol{B}\boldsymbol{C}\boldsymbol{B}^{-1}$ 的矩阵都相似，它们的 $n$ 个特征值都和 $\boldsymbol{C}$ 相同.

① 译者注：译者认为更简洁的论证方式是用归纳法，虽然证明思想并没有本质区别.

**证明** 设 $\lambda$ 是 $\boldsymbol{C}$ 的特征值，$\boldsymbol{x}\neq\boldsymbol{0}$ 是属于 $\lambda$ 的特征值：$\boldsymbol{Cx}=\lambda\boldsymbol{x}$. 那么 $\boldsymbol{Bx}$ 是 $\boldsymbol{BCB}^{-1}$ 的属于特征值 $\lambda$ 的特征向量：

相似矩阵有相同的特征值

$$(\boldsymbol{BCB}^{-1})(\boldsymbol{Bx})=\boldsymbol{BCx}=\boldsymbol{B}\lambda\boldsymbol{x}=\lambda(\boldsymbol{Bx})^{①} \tag{6.14}$$

当 $\boldsymbol{B}$ 跑遍所有可逆矩阵，任意固定矩阵 $\boldsymbol{C}$ 都生成一族相似矩阵 $\boldsymbol{BCB}^{-1}$. 若 $\boldsymbol{C}$ 是单位矩阵，这“族”矩阵只有唯一一个成员——$\boldsymbol{BIB}^{-1}=\boldsymbol{I}$. 在特征值全部都是 1 的矩阵中，单位矩阵是唯一的可对角化矩阵.

对于有二重特征值 1，但是只有一个线性无关的特征向量的二阶方阵，相似的矩阵族会更大. 这样的矩阵里，最简单的是 Jordan 形矩阵（详见附录 A5）. 该族矩阵可以用两个不全为零的变量 $r$ 和 $s$ 来参数化，其行列式总是 1，迹总是 2.

Jordan 形矩阵 $\boldsymbol{C}=\begin{bmatrix}1&1\\0&1\end{bmatrix}$ $\qquad \boldsymbol{A}=\boldsymbol{BCB}^{-1}=\begin{bmatrix}1-rs&r^2\\-s^2&1+rs\end{bmatrix}$.② (6.15)

下面的例子很重要，我们取两个不同的特征值 $\lambda=1,0$. 此时整个相似矩阵族都可以对角化，均以 $\boldsymbol{\Lambda}=\begin{bmatrix}1&0\\0&0\end{bmatrix}$ 为特征值矩阵. 通过这种方式，我们得到了以 1 和 0 为特征值的所有矩阵. 它们的迹都是 1，特征值都是 0.

下列矩阵都相似 $\qquad \boldsymbol{\Lambda}=\begin{bmatrix}1&0\\0&0\end{bmatrix}$ $\begin{bmatrix}1&1\\0&0\end{bmatrix}$ $\begin{bmatrix}0.5&0.5\\0.5&0.5\end{bmatrix}$ 以及任何 $\dfrac{\boldsymbol{xy}^{\mathrm{T}}}{\boldsymbol{x}^{\mathrm{T}}\boldsymbol{y}}$ ③

任意满足等式 $\boldsymbol{A}^2=\boldsymbol{A}$ 的二阶非零奇异矩阵都属于该矩阵族. $\boldsymbol{B}=\boldsymbol{I}$ 时，$\boldsymbol{A}=\boldsymbol{\Lambda}$.

---

**命题 6.2** 若 $\boldsymbol{A}$ 是 $m\times n$ 矩阵，$\boldsymbol{B}$ 是 $n\times m$ 矩阵，则 $\boldsymbol{AB}$ 和 $\boldsymbol{BA}$ 有相同的非零特征值.

**证明** 注意到分块矩阵的恒等式：

$$\begin{bmatrix}\boldsymbol{I}&-\boldsymbol{A}\\\boldsymbol{0}&\boldsymbol{I}\end{bmatrix}\begin{bmatrix}\boldsymbol{AB}&\boldsymbol{0}\\\boldsymbol{B}&\boldsymbol{0}\end{bmatrix}\begin{bmatrix}\boldsymbol{I}&\boldsymbol{A}\\\boldsymbol{0}&\boldsymbol{I}\end{bmatrix}=\begin{bmatrix}\boldsymbol{0}&\boldsymbol{0}\\\boldsymbol{B}&\boldsymbol{BA}\end{bmatrix} \qquad \begin{bmatrix}m\times m&m\times n\\n\times m&n\times n\end{bmatrix}$$

左侧的第一、第三个矩阵互为逆矩阵，右侧表示的是分块矩阵的大小. 等式 $\boldsymbol{D}^{-1}\boldsymbol{ED}=\boldsymbol{F}$ 说明矩阵 $\boldsymbol{E}$ 和 $\boldsymbol{F}$ 相似，它们有相同的 $m+n$ 个特征值.

$\begin{bmatrix}\boldsymbol{AB}&\boldsymbol{0}\\\boldsymbol{B}&\boldsymbol{0}\end{bmatrix}$ 的特征值是：$\boldsymbol{AB}$ 的 $m$ 个特征值以及 $n$ 个零 $\qquad$ $\begin{bmatrix}\boldsymbol{AB}&\boldsymbol{0}\\\boldsymbol{B}&\boldsymbol{0}\end{bmatrix}$ 的特征值是：$\boldsymbol{BA}$ 的 $n$ 个特征值以及 $m$ 个零

所以 $\boldsymbol{AB}$ 和 $\boldsymbol{BA}$ 除了 $|n-m|$ 个零，其他特征值都相同.

---

① 译者注：这个证明是不完备的，如果有重特征值，该证明没有说明特征值的重数也相等. 通常，可以用特征多项式给一个完备的证明：

$$\det(\boldsymbol{BCB}^{-1}-\lambda\boldsymbol{I})=\det(\boldsymbol{B}(\boldsymbol{C}-\lambda\boldsymbol{I})\boldsymbol{B}^{-1})=\det(\boldsymbol{C}-\lambda\boldsymbol{I}).$$

② 译者注：此处可取 $\boldsymbol{B}=\begin{bmatrix}r&-s\\s&r\end{bmatrix}$ 且 $r^2+s^2=1$，这样的矩阵是正交矩阵. 对任意二阶可逆矩阵 $\boldsymbol{B}$，作 $\boldsymbol{QR}$ 分解：$\boldsymbol{B}=\boldsymbol{QR}$，那么 $\boldsymbol{Q}$ 形如 $\begin{bmatrix}r&-s\\s&r\end{bmatrix}$ 且 $r^2+s^2=1$，$\boldsymbol{R}$ 形如 $\begin{bmatrix}1&a\\0&1\end{bmatrix}$；直接验算 $\boldsymbol{RCR}^{-1}=\boldsymbol{C}$，所以 $\boldsymbol{BCB}^{-1}=\boldsymbol{QCQ}^{-1}$.

③ 译者注：此处要求 $x$、$y$ 不正交. 若 $x$ 和 $y$ 正交，则该矩阵不可对角化，不相似于 $\boldsymbol{\Lambda}$.

### 6.2.2　斐波那契数列

我们再举一个著名的例子——斐波那契数列，其中蕴含的特征值说明了斐波那契数列的增长速度. 所谓的斐波那契数列 $\{F_k : k \geqslant 0\}$ 是由条件：$F_0 = 0, F_1 = 1, F_{k+2} = F_{k+1} + F_k$ 确定的数列；每个斐波那契数都是前两个斐波那契数之和.

数列：$\boxed{0,1,1,2,3,5,8,13,\cdots}$，由初始的两项和递推式 $\boxed{F_{k+2} = F_{k+1} + F_k}$ 确定.

这些数字在各种场合频繁出现. 比方说，植物和树木以螺旋模式生长，梨树每 3 圈有 8 个生长点，而柳树大概是每 5 圈有 13 个生长点. 最典型的是丹尼尔 • 奥康奈尔的一株向日葵，它在 144 个螺旋圈中有 233 颗种子，是斐波那契数列中的 $F_{12}$ 和 $F_{13}$！有别于这些实际的例子，我们处理的是更为基础的纯数学问题.

求斐波那契数 $F_{100}$. 最朴实无华而枯燥的办法当然是用递推式 $F_{k+2} = F_{k+1} + F_k$ 不停地加，例如把 $F_6 = 8$ 和 $F_7 = 13$ 相加得 $F_8 = 21$. 耐心点总能算出 $F_{100}$. 老实往往是愚钝的别名，机智的我们，必须明白线性代数有更好的处理方法.

问题的关键是矩阵方程：$\boldsymbol{u}_{k+1} = \boldsymbol{A}\boldsymbol{u}_k$，其中：

$$\text{令}\quad \boxed{\boldsymbol{u}_k = \begin{bmatrix} F_{k+1} \\ F_k \end{bmatrix}},\ \text{递推式}\quad \begin{cases} F_{k+2} = F_{k+1} + F_k \\ F_{k+1} = F_{k+1} \end{cases}\quad \text{推出}\quad \boxed{\boldsymbol{u}_{k+1} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix} \boldsymbol{u}_k = \boldsymbol{A}\boldsymbol{u}_k} \tag{6.16}$$

事实上这一步先把 $F_{k+1}$ 和 $F_k$ 组合成列向量 $\boldsymbol{u}_k$，再把关于数的二阶递推式改写成了关于向量的一阶递推式，递推关系由矩阵 $\boldsymbol{A} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix}$ 给出. 每一步递推都乘以 $\boldsymbol{A}$，100 步以后即有 $\boldsymbol{u}_{100} = \boldsymbol{A}^{100}\boldsymbol{u}_0$:

$$\boldsymbol{u}_0 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \boldsymbol{u}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \boldsymbol{u}_2 = \begin{bmatrix} 2 \\ 1 \end{bmatrix}, \boldsymbol{u}_3 = \begin{bmatrix} 3 \\ 2 \end{bmatrix}, \cdots, \boldsymbol{u}_{100} = \begin{bmatrix} F_{101} \\ F_{100} \end{bmatrix}$$

$\boldsymbol{A}$ 的特征值对于求高次幂来说恰到好处！

第一步　$\boldsymbol{A}$ 的对角元减去 $\lambda$:

$$\boldsymbol{A} - \lambda\boldsymbol{I} = \begin{bmatrix} 1-\lambda & 1 \\ 1 & -\lambda \end{bmatrix} \quad \Longrightarrow \quad \det(\boldsymbol{A} - \lambda\boldsymbol{I}) = \boldsymbol{\lambda^2 - \lambda - 1} \qquad \begin{cases} a = +1 \\ b = -1 \\ c = -1 \end{cases}$$

由求根公式 $\dfrac{-b \pm \sqrt{b^2 - 4ac}}{2a}$ 解二次方程 $\lambda^2 - \lambda - 1 = 0$:

$$\text{、}\quad \boldsymbol{A}\text{ 的特征值}\qquad \boxed{\lambda_1 = \frac{1+\sqrt{5}}{2} \approx 1.618}\quad \text{以及}\quad \boxed{\lambda_2 = \frac{1-\sqrt{5}}{2} \approx -0.618}$$

解线性方程组 $(\boldsymbol{A} - \lambda\boldsymbol{I})\boldsymbol{x} = \boldsymbol{0}$ 得特征向量 $\boldsymbol{x}_1 = \begin{bmatrix} \lambda_1 & 1 \end{bmatrix}^{\mathrm{T}}, \boldsymbol{x}_2 = \begin{bmatrix} \lambda_2 & 1 \end{bmatrix}^{\mathrm{T}}$.

**第二步** 把初始向量 $\boldsymbol{u}_0=\begin{bmatrix}F_1 & F_0\end{bmatrix}^{\mathrm{T}}=\begin{bmatrix}1 & 0\end{bmatrix}^{\mathrm{T}}$ 写成特征向量的线性组合：

$$\begin{bmatrix}1\\0\end{bmatrix}=\frac{1}{\lambda_1-\lambda_2}\left(\begin{bmatrix}\lambda_1\\1\end{bmatrix}-\begin{bmatrix}\lambda_2\\1\end{bmatrix}\right)\qquad \text{或者}\qquad \boldsymbol{u}_0=\frac{\boldsymbol{x}_1-\boldsymbol{x}_2}{\lambda_1-\lambda_2}. \tag{6.17}$$

**第三步** 用 $\boldsymbol{A}^{100}$ 乘以 $\boldsymbol{u}_0$ 来计算 $\boldsymbol{u}_{100}$. 因为 $\boldsymbol{x}_1$、$\boldsymbol{x}_2$ 被 $\boldsymbol{A}$ 左乘互不干扰，左乘 100 次之后，只需分别乘以常数 $\lambda_1^{100}$ 和 $\lambda_2^{100}$ 即可：

$$\boxed{\boldsymbol{u}_{100}=\boldsymbol{A}^{100}\boldsymbol{u}_0=\frac{\boldsymbol{A}^{100}\boldsymbol{x}_1-\boldsymbol{A}^{100}\boldsymbol{x}_2}{\lambda_1-\lambda_2}=\frac{\lambda_1^{100}\boldsymbol{x}_1-\lambda_2^{100}\boldsymbol{x}_2}{\lambda_1-\lambda_2}} \tag{6.18}$$

目标对象 $F_{100}$ 是 $\boldsymbol{u}_{100}$ 的第二个分量；$\boldsymbol{x}_1$ 和 $\boldsymbol{x}_2$ 的第二个分量是 1，$\lambda_1-\lambda_2=\sqrt{5}$，并且 $\lambda_2^{100}\approx 0$，所以

$$\text{第 100 个斐波那契数}=\frac{\lambda_1^{100}-\lambda_2^{100}}{\lambda_1-\lambda_2}=\text{最接近}\frac{1}{\sqrt{5}}\left(\frac{1+\sqrt{5}}{2}\right)^{100}\text{的整数}. \tag{6.19}$$

$F_k$ 都是正整数，比值 $F_{101}/F_{100}$ 必然非常接近 $F_{k+1}/F_k$ 的极限 $\dfrac{1+\sqrt{5}}{2}$. 古希腊人将这个数称为“黄金分割”，通常来说，长宽比为 1.618∶1 的矩形看起来特别符合大多数人的审美.

### 6.2.3 矩阵方幂 $A^k$

斐波那契数列是差分方程 $\boldsymbol{u}_{k+1}=\boldsymbol{A}\boldsymbol{u}_k$ 的典型例子. 每一步都左乘 $\boldsymbol{A}$，其解为 $\boldsymbol{u}_k=\boldsymbol{A}^k\boldsymbol{u}_0$. 我们该弄清楚如何将矩阵对角化，由此在三个步骤内快速计算 $\boldsymbol{A}^k$，并找到 $\boldsymbol{u}_k$.

特征向量矩阵 $\boldsymbol{X}$ 可以将 $\boldsymbol{A}$ 分解为 $\boldsymbol{A}=\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1}$. 这是对矩阵的一种分解，类似于 $\boldsymbol{A}=\boldsymbol{L}\boldsymbol{U}$ 或 $\boldsymbol{A}=\boldsymbol{Q}\boldsymbol{R}$. 这种新的分解非常适合计算幂次，因为所有中间项 $\boldsymbol{X}^{-1}$ 乘以 $\boldsymbol{X}$ 都会得到单位矩阵 $\boldsymbol{I}$：

$$\boldsymbol{A}\text{ 的幂次}\qquad \boldsymbol{A}^k\boldsymbol{u}_0=(\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1})\cdots(\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1})\boldsymbol{u}_0=\boldsymbol{X}\boldsymbol{\Lambda}^k\boldsymbol{X}^{-1}\boldsymbol{u}_0.$$

斐波那契数列的例子展示了如何通过三个步骤计算 $\boldsymbol{X}\boldsymbol{\Lambda}^k\boldsymbol{X}^{-1}\boldsymbol{u}_0$，展示了特征值在计算 $\boldsymbol{u}_k$ 中的作用. 我们把一般方法总结如下：

（1）把 $\boldsymbol{u}_0$ 分解成特征向量的线性组合

$\boldsymbol{u}_0=\boldsymbol{X}\boldsymbol{c}=c_1\boldsymbol{x}_1+c_2\boldsymbol{x}_2+\cdots+c_n\boldsymbol{x}_n$. 这一步计算出 $\boldsymbol{X}^{-1}\boldsymbol{u}_0=\boldsymbol{c}$.

（2）每个特征向量 $\boldsymbol{x}_i$ 都乘以 $\lambda_i^k$. 这一步计算出 $\boldsymbol{\Lambda}^k\boldsymbol{X}^{-1}\boldsymbol{u}_0$.

（3）把各 $c_i\lambda_i^k\boldsymbol{x}_i$ 相加. 这一步计算出 $\boldsymbol{X}\boldsymbol{\Lambda}^k\boldsymbol{X}^{-1}\boldsymbol{u}_0=\boldsymbol{A}^k\boldsymbol{u}_0=\boldsymbol{u}_k$.

$$\boldsymbol{u}_{k+1}=\boldsymbol{A}\boldsymbol{u}_k\text{ 的解是}\qquad \boxed{\boldsymbol{u}_k=\boldsymbol{A}^k\boldsymbol{u}_0=c_1\lambda_1^k\boldsymbol{x}_1+c_2\lambda_2^k\boldsymbol{x}_2+\cdots+c_n\lambda_n^k\boldsymbol{x}_n} \tag{6.20}$$

用矩阵语言描述，上述步骤无非是把表达式 $\boldsymbol{A}^k=(\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1})^k=\boldsymbol{X}\boldsymbol{\Lambda}^k\boldsymbol{X}^{-1}$ 做成分解动作：$\boldsymbol{X}$、$\boldsymbol{\Lambda}^k$ 和 $\boldsymbol{X}^{-1}$ 按顺序相乘. 第一步，矩阵 $\boldsymbol{X}$ 中的特征向量确定线性组合 $\boldsymbol{u}_0=c_1\boldsymbol{x}_1+c_2\boldsymbol{x}_2+\cdots+c_n\boldsymbol{x}_n$ 中的组合系数 $\boldsymbol{c}$：

$$\text{第一步}\qquad \boldsymbol{u}_0=\begin{bmatrix}\boldsymbol{x}_1 & \cdots & \boldsymbol{x}_n\end{bmatrix}\begin{bmatrix}c_1\\ \vdots\\ c_n\end{bmatrix}.\qquad \text{也即}\quad \boxed{\boldsymbol{u}_0=\boldsymbol{X}\boldsymbol{c}.} \tag{6.21}$$

因为 $\boldsymbol{X}$ 可逆，线性组合的系数 $\boldsymbol{c}=\boldsymbol{X}^{-1}\boldsymbol{u}_0$. 第二步，用 $\boldsymbol{\Lambda}^k$ 乘 $\boldsymbol{c}$，最后一步是 $\boldsymbol{X}$、$\boldsymbol{\Lambda}^k$ 和 $\boldsymbol{X}^{-1}\boldsymbol{u}_0$ 的乘积：

$$\boldsymbol{A}^k\boldsymbol{u}=\boldsymbol{X}\boldsymbol{\Lambda}^k\boldsymbol{X}^{-1}\boldsymbol{u}_0=\boldsymbol{X}\boldsymbol{\Lambda}^k\boldsymbol{c}=\begin{bmatrix}\boldsymbol{x}_1 & \cdots & \boldsymbol{x}_n\end{bmatrix}\begin{bmatrix}\lambda_1^k & & \\ & \ddots & \\ & & \lambda_n^k\end{bmatrix}\begin{bmatrix}c_1\\ \vdots\\ c_n\end{bmatrix} \tag{6.22}$$

稍微干点体力活，就可以求出递推式 $\boldsymbol{u}_{k+1}=\boldsymbol{A}\boldsymbol{u}_k$ 的解：$\boldsymbol{u}_k=c_1\lambda_1^k\boldsymbol{x}_1+c_2\lambda_2^k\boldsymbol{x}_2+\cdots+c_n\lambda_n^k\boldsymbol{x}_n$.

**例 6.8**　给定初始向量 $\boldsymbol{u}_0=\begin{bmatrix}1\\0\end{bmatrix}$，$\boldsymbol{A}=\begin{bmatrix}1&2\\1&0\end{bmatrix}$，求 $\boldsymbol{A}^k\boldsymbol{u}_0$.

类似于斐波那契数列，这等价于求递推式 $F_{k+2}=F_{k+1}+2F_k, F_0=0, F_1=1$ 的通项. 前几项是 0、1、1、3，增长速度比斐波那契数列更快，因为 $\lambda_1=2$ 是 $\boldsymbol{A}$ 的特征值，比 $(1+\sqrt{5})/2$ 大.

$$\boldsymbol{A}=\begin{bmatrix}1&2\\1&0\end{bmatrix},\qquad \lambda_1=2,\boldsymbol{x}_1=\begin{bmatrix}2\\1\end{bmatrix};\qquad \lambda_2=-1,\boldsymbol{x}_2=\begin{bmatrix}1\\-1\end{bmatrix}.$$

遵循前面提及的三步可以求出 $\boldsymbol{u}_k=\boldsymbol{A}^k\boldsymbol{u}_0$：$\boldsymbol{u}_0=c_1\boldsymbol{x}_1+c_2\boldsymbol{x}_2, \boldsymbol{u}_k=c_1\lambda_1^k\boldsymbol{x}_1+c_2\lambda_2^k\boldsymbol{x}_2$.

**第一步** $\boldsymbol{u}_0=\begin{bmatrix}1\\0\end{bmatrix}=\frac{1}{3}\begin{bmatrix}2\\1\end{bmatrix}+\frac{1}{3}\begin{bmatrix}1\\-1\end{bmatrix}$，所以 $c_1=c_2=\frac{1}{3}$.

**第二步** 把上一步 $\boldsymbol{u}_0$ 的分解式的两部分分别乘以 $\lambda_1^k=2^k$ 和 $\lambda_2^k=(-1)^k$.

**第三步** 把 $c_1\lambda_1^k\boldsymbol{x}_1$ 和 $c_2\lambda_2^k\boldsymbol{x}_2$ 相加得到 $\boldsymbol{u}_k$:

$$\boldsymbol{u}_k=\boldsymbol{A}^k\boldsymbol{u}_0 \qquad\qquad \boldsymbol{u}_k=\frac{1}{3}2^k\begin{bmatrix}2\\1\end{bmatrix}+\frac{1}{3}(-1)^k\begin{bmatrix}1\\-1\end{bmatrix}=\begin{bmatrix}F_{k+1}\\F_k\end{bmatrix}$$

所以通项公式是 $F_k=\dfrac{2^k-(-1)^k}{3}$，从而 $F_{100}\approx\dfrac{2^{100}}{3}$.

这些数值例子背后蕴含着一个基本思想：充分发挥特征向量的作用. 这是 6.5节中联系线性代数和微分方程的关键：$\lambda^k$ 将变为 $\mathrm{e}^{\lambda t}$；在第 8 章将会再次介绍同样的思想——把函数用“特征函数”展开. 最典型的例子是傅里叶级数，整个理论以求导这个线性映射的特征向量 $\mathrm{e}^{\mathrm{i}kx}$ 为基础构建.

### 6.2.4　不可对角化的矩阵（选讲）

假设 $\lambda$ 是矩阵 $\boldsymbol{A}$ 的特征值，我们从两个角度理解这一概念.

（1）**特征向量**（几何角度）存在非零向量满足 $\boldsymbol{A}\boldsymbol{x}=\lambda\boldsymbol{x}$.

（2）**特征值**（代数方法）矩阵 $\boldsymbol{A}-\lambda\boldsymbol{I}$ 行列式为零.

对大多数矩阵的特征值 $\lambda$，属于该特征值的特征向量分布在一条直线上，且 $\det(\boldsymbol{A}-\lambda\boldsymbol{I})$ 不包含重因子. 例外情况也不少见，特征值可能**重复**出现. 根据理解特征值的两种角度，我们可以定义出两种重数——几何重数（GM）和代数重数（AM）.

（1）几何重数：属于 $\lambda$ 的线性无关的特征向量的个数，即 $\mathcal{N}(\boldsymbol{A}-\lambda\boldsymbol{I})$ 的维数.

（2）代数重数：关于 $\lambda$ 的多项式，即特征方程 $\det(\boldsymbol{A}-\lambda\boldsymbol{I})=0$ 的根的重数.

所以几何重数是某种意义上“特征向量的重数”. 特征值 $\lambda$ 根据其重数，分为单重特征值或多重特征值；[①]大多数特征值的重数 $M=1$（即单重特征值）. 对于每个特征值，总有不等式：几何重数 GM $\leqslant$ 代数重数 AM. 若 $\lambda=4$ 是 $\det(\boldsymbol{A}-\lambda\boldsymbol{I})=0$ 的 3 重根，那么代数重数等于 3，几何重数可能是 1、2 或者 3.

下面的矩阵 $\boldsymbol{A}$ 是不可对角化矩阵的典型例子，其特征值 $\lambda=0$ 是特征多项式的 2 重根，所以代数重数是 2（AM $=2$），但只有一个线性无关的特征向量，所以几何重数是 1（GM $=1$）.

AM $=2$
GM $=1$

$$\boldsymbol{A}=\begin{bmatrix}0&1\\0&0\end{bmatrix} \qquad \det(\boldsymbol{A}-\lambda\boldsymbol{I})=\begin{vmatrix}-\lambda&1\\0&-\lambda\end{vmatrix}=\lambda^2$$

$\lambda=0,0$是 2 重根

1 个线性无关的特征向量 $\begin{bmatrix}1\\0\end{bmatrix}$

因为 0 是 $\lambda^2=0$ 的 2 重根，代数重数 AM $=2$. 我们本来期望能有两个线性无关的特征向量，但是它只有一个线性无关的特征向量 $\boldsymbol{x}=\begin{bmatrix}1&0\end{bmatrix}^{\mathrm{T}}$，几何重数 GM $=1$. 线性无关的特征向量不足导致几何重数小于代数重数，这是 $\boldsymbol{A}$ 不能被对角化的根本原因.

以下三个矩阵，线性无关的特征向量个数都不够：

$$\boldsymbol{A}=\begin{bmatrix}5&1\\0&5\end{bmatrix} \qquad \boldsymbol{A}=\begin{bmatrix}6&-1\\1&4\end{bmatrix} \qquad \boldsymbol{A}=\begin{bmatrix}7&2\\-2&3\end{bmatrix}$$

特征多项式都是 $\det(\boldsymbol{A}-\lambda\boldsymbol{I})=(\lambda-5)^2$，因此特征值均为 $\lambda=5$，代数重数 AM $=2$，迹 $5+5=10$，行列式 $=5\times5=25$. 但是 $\boldsymbol{A}-5\boldsymbol{I}$ 的秩都是 1，进而几何重数 GM $=1$，特征向量都分布在一条直线上. 总之，这三个矩阵都不可对角化.

## 要点回顾

（1）若 $\boldsymbol{A}$ 有 $n$ 个线性无关的特征向量 $\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_n$，把它们作为列向量排成矩阵 $\boldsymbol{X}$，则

$$\boldsymbol{A}\text{ 可以被 }\boldsymbol{X}\text{ 对角化：}\boldsymbol{X}^{-1}\boldsymbol{A}\boldsymbol{X}=\boldsymbol{\Lambda}\text{ 和 }\boldsymbol{A}=\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1}.$$

（2）$\boldsymbol{A}$ 的 $k$ 次幂 $\boldsymbol{A}^k=\boldsymbol{X}\boldsymbol{\Lambda}^k\boldsymbol{X}^{-1}$，它和 $\boldsymbol{A}$ 有相同的特征向量矩阵 $\boldsymbol{X}$.

（3）$\boldsymbol{A}^k$ 的特征值是 $\boldsymbol{\Lambda}^k$ 的对角元 $\lambda_1^k,\lambda_2^k,\cdots,\lambda_n^k$.

（4）给定初始值 $\boldsymbol{u}_0$，递推式 $\boldsymbol{u}_{k+1}=\boldsymbol{A}\boldsymbol{u}_k$ 的解是 $\boldsymbol{u}_k=\boldsymbol{A}^k\boldsymbol{u}_0=\boldsymbol{X}\boldsymbol{\Lambda}^k\boldsymbol{X}^{-1}\boldsymbol{u}_0$：

若有分解式 $\boldsymbol{u}_0=c_1\boldsymbol{x}_1+c_2\boldsymbol{x}_2+\cdots+c_n\boldsymbol{x}_n$，则 $\boldsymbol{u}_k=c_1\lambda_1^k\boldsymbol{x}_1+c_2\lambda_2^k\boldsymbol{x}_2+\cdots+c_n\lambda_n^k\boldsymbol{x}_n$

（5）若 $\boldsymbol{A}$ 的每个特征值都有足够多的特征向量，具体来说就是每个特征值的代数重数和几何重数都相等，则 $\boldsymbol{A}$ 可以对角化.[②]

① 译者注：由于重数有两个角度，而且代数重数和几何重数有时会不一样，所以我们提到“重数”，严格一点需要说明是哪种重数，不然容易混淆. 但是在本书中，如果不加说明，作者往往指的都是代数重数. 遇到相关情况，读者直接按照代数重数理解即可. 我们也可以从中看出，作者内心认同的特征值的定义是指特征多项式的根.

② 译者注：每个特征值的代数重数和几何重数都相等，实际上是矩阵可以对角化的充要条件.

## 例 题 总 结

6.2 A. 卢卡斯数和斐波那契数类似，通过同一个递推式 $L_{k+2}=L_{k+1}+L_k$ 定义，区别在于初始值不同：卢卡斯数的初始值是 $L_1=1, L_2=3$；那么后续几项是 4、7、11、18. 证明第 100 个卢卡斯数 $L_{100}=\lambda_1^{100}+\lambda_2^{100}$，其中 $\lambda_1=\dfrac{1+\sqrt{5}}{2}, \lambda_2=\dfrac{1-\sqrt{5}}{2}$.

解　如果仅仅是证明这个问题，用数学归纳法显然更直接更快速. 但是我们的目的是熟悉线性代数的方法，所以还要利用特征值和特征向量的知识练习一遍.

令 $\boldsymbol{u}_k=\begin{bmatrix}L_{k+1}\\L_k\end{bmatrix}$，因为卢卡斯数和斐波那契数列有一样递推式 $L_{k+2}=L_{k+1}+L_k$，所以 $\boldsymbol{u}_{k+1}=\boldsymbol{A}\boldsymbol{u}_k$，二阶递推式就转化成了一阶递推式：

$$\boldsymbol{u}_k=\begin{bmatrix}L_{k+1}\\L_k\end{bmatrix}\quad\text{由递推式}\begin{cases}L_{k+2}=L_{k+1}+L_k\\L_{k+1}=L_{k+1}\end{cases}\quad\text{可得}\quad\boldsymbol{u}_{k+1}=\begin{bmatrix}1&1\\1&0\end{bmatrix}\boldsymbol{u}_k$$

$\boldsymbol{A}$ 的特征值和特征向量依然从特征方程 $\lambda^2=\lambda+1$ 求得

$$\lambda_1=\frac{1+\sqrt{5}}{2},\quad \boldsymbol{x}_1=\begin{bmatrix}\lambda_1\\1\end{bmatrix}\qquad\qquad \lambda_2=\frac{1-\sqrt{5}}{2},\quad \boldsymbol{x}_2=\begin{bmatrix}\lambda_2\\1\end{bmatrix}$$

再解 $c_1\boldsymbol{x}_1+c_2\boldsymbol{x}_2=\boldsymbol{u}_1=\begin{bmatrix}3\\1\end{bmatrix}$，得 $c_1=\lambda_1$，以及 $c_2=\lambda_2$. 为防止错误，检验如下：

$$\lambda_1\boldsymbol{x}_1+\lambda_2\boldsymbol{x}_2=\begin{bmatrix}\lambda_1^2+\lambda_2^2\\\lambda_1+\lambda_2\end{bmatrix}=\begin{bmatrix}\boldsymbol{A}^2\text{的迹}\\\boldsymbol{A}\text{的迹}\end{bmatrix}=\begin{bmatrix}3\\1\end{bmatrix}=\boldsymbol{u}_1.$$

而 $\boldsymbol{u}_{100}=\boldsymbol{A}^{99}\boldsymbol{u}_1=\begin{bmatrix}L_{101}\\L_{100}\end{bmatrix}$. $\boldsymbol{x}_1$ 和 $\boldsymbol{x}_2$ 的第二个分量都是 1，$\boldsymbol{u}_{100}$ 的第二个分量就是我们要求的答案：

卢卡斯数　　$$L_{100}=c_1\lambda_1^{99}+c_2\lambda_2^{99}=\lambda_1^{100}+\lambda_2^{100}.$$

卢卡斯数的初始值比斐波那契数大，所以每一个卢卡斯数都比斐波那契数大，最终两者比值大约是 $\sqrt{5}$，即 $\dfrac{L_k}{F_k}\approx\sqrt{5}$.

6.2 B. 求四阶方阵 $\boldsymbol{A}$ 的逆矩阵、特征值和行列式：

$$\boldsymbol{A}=5\boldsymbol{I}-\mathbf{ones}(4)=\begin{bmatrix}4&-1&-1&-1\\-1&4&-1&-1\\-1&-1&4&-1\\-1&-1&-1&4\end{bmatrix}$$

并且用正交矩阵 $\boldsymbol{Q}$ 将 $\boldsymbol{A}$ 对角化：$\boldsymbol{Q}^{-1}\boldsymbol{A}\boldsymbol{Q}=\boldsymbol{\Lambda}$.

**解** 四阶全 1 矩阵[①]的特征值是什么？该矩阵秩是 1，所以有三个零特征值 $\lambda=0,0,0$. 迹是 4，所以第四个特征值是 $\lambda=4$. 由于 $\boldsymbol{A}$ 是将 $5\boldsymbol{I}$ 减去该全 1 矩阵得到，所以：

把 5,5,5,5 减去 4,0,0,0，由此得 $\boldsymbol{A}$ 的特征值是 1,5,5,5.

$\boldsymbol{A}$ 的行列式等于其四个特征值的乘积，因此 $\det\boldsymbol{A}=125$. 属于特征值 $\lambda=1$ 的特征向量是 $\boldsymbol{x}=\begin{bmatrix}c & c & c & c\end{bmatrix}^{\mathrm{T}}(c\neq 0)$，比如 $\begin{bmatrix}1 & 1 & 1 & 1\end{bmatrix}^{\mathrm{T}}$；又因为 $\boldsymbol{A}$ 对称，所以其他特征向量和 $\boldsymbol{x}$ 正交（详见 6.3 节）. 最好的特征向量矩阵 $\boldsymbol{Q}$ 是对称正交阿达玛矩阵 $\boldsymbol{H}$：

正交特征向量矩阵
$$\boldsymbol{Q}=\boldsymbol{H}=\frac{1}{2}\begin{bmatrix}1 & 1 & 1 & 1\\ 1 & -1 & 1 & -1\\ 1 & 1 & -1 & -1\\ 1 & -1 & -1 & 1\end{bmatrix}=\boldsymbol{H}^{\mathrm{T}}=\boldsymbol{H}^{-1}.$$

$\boldsymbol{A}^{-1}$ 的特征值是 1、$\frac{1}{5}$、$\frac{1}{5}$、$\frac{1}{5}$，特征向量和 $\boldsymbol{A}$ 相同，所以 $\boldsymbol{A}^{-1}=\boldsymbol{H}\boldsymbol{\Lambda}^{-1}\boldsymbol{H}^{-1}$，计算结果是出人意料得简洁：

$$\boldsymbol{A}^{-1}=\frac{1}{5}(\boldsymbol{I}+\mathbf{ones}(4))=\frac{1}{5}\begin{bmatrix}2 & 1 & 1 & 1\\ 1 & 2 & 1 & 1\\ 1 & 1 & 2 & 1\\ 1 & 1 & 1 & 2\end{bmatrix}$$

$\boldsymbol{A}=5\boldsymbol{I}-\mathbf{ones}(4)$ 是对 $5\boldsymbol{I}$ 作了个秩 1 扰动得到的，$\boldsymbol{A}^{-1}$ 是对 $\boldsymbol{I}/5$ 作了个秩 1 扰动得到的.

在一个包含 5 个顶点的完全图中，$\boldsymbol{A}$ 的行列式值 125 用于计算“生成树”（即触及所有顶点的树）. 树没有圈（关于图和树的概念，请参阅 3.5 节）.

在包含 6 个顶点的图中，矩阵 $6\boldsymbol{I}-\mathbf{ones}(5)$ 有五个特征值，分别为 1、6、6、6、6.

## 习题 6.2

1.（1）将下列两个矩阵对角化：$\boldsymbol{A}=\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1}$

$$\boldsymbol{A}=\begin{bmatrix}1 & 2\\ 0 & 3\end{bmatrix}\qquad\qquad \boldsymbol{A}=\begin{bmatrix}1 & 1\\ 3 & 3\end{bmatrix}$$

（2）如果 $\boldsymbol{A}=\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1}$，则 $\boldsymbol{A}^3=(\quad)(\quad)(\quad)$；进一步地，若 $\boldsymbol{A}$ 还是可逆矩阵，则 $\boldsymbol{A}^{-1}=(\quad)(\quad)(\quad)$.

2. 若方阵 $\boldsymbol{A}$ 的特征值为 $\lambda_1=2,\lambda_2=5$，$\boldsymbol{x}_1=\begin{bmatrix}1\\0\end{bmatrix}$ 是属于 $\lambda_1$ 的特征向量，$\boldsymbol{x}_2=\begin{bmatrix}1\\1\end{bmatrix}$ 是属于 $\lambda_2=5$ 的特征向量；请利用 $\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1}$ 求出 $\boldsymbol{A}$.

注：满足条件的矩阵是唯一的.

3. 假设 $\boldsymbol{A}=\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1}$. $\boldsymbol{A}+2\boldsymbol{I}$ 的特征值矩阵是什么？它的特征向量矩阵是什么？验证：$\boldsymbol{A}+2\boldsymbol{I}=(\quad)(\quad)(\quad)$.

① 译者注：所谓全 1 矩阵，即所有元素都是 1 的矩阵.

4. 选择正确论断：如果 $\boldsymbol{A}$ 的特征向量排成的方阵 $\boldsymbol{X}$ 列满秩，则

（1）$\boldsymbol{A}$ 可逆　　（2）$\boldsymbol{A}$ 可以被对角化　　（3）$\boldsymbol{X}$ 可逆　　（4）$\boldsymbol{X}$ 可以被对角化

5. 若 $\boldsymbol{I}$ 的列向量都是 $\boldsymbol{A}$ 的特征向量，那么 $\boldsymbol{A}$ 是_____ 矩阵. 若特征向量矩阵 $\boldsymbol{X}$ 是上（下）三角矩阵，则 $\boldsymbol{X}^{-1}$ 也是上（下）三角矩阵，证明：$\boldsymbol{A}$ 也是上（下）三角矩阵.

6. 请描述能将 $\boldsymbol{A}=\begin{bmatrix}4 & 0\\ 1 & 2\end{bmatrix}$ 对角化的所有矩阵（提示：找出 $\boldsymbol{A}$ 的所有特征向量），再描述能将 $\boldsymbol{A}^{-1}$ 对角化的所有矩阵.

7. 若 $\begin{bmatrix}1\\ 1\end{bmatrix}$ 和 $\begin{bmatrix}-1\\ 1\end{bmatrix}$ 是方阵 $\boldsymbol{A}$ 的特征向量，求 $\boldsymbol{A}$ 的一般形式.

习题 8 ~ 10 关于斐波那契数和 Gibonacci 数[①].

8. 把 $\boldsymbol{X}^{-1}$ 补充完整，完成斐波那契矩阵的对角化

$$\begin{bmatrix}1 & 1\\ 1 & 0\end{bmatrix}=\begin{bmatrix}\lambda_1 & \lambda_2\\ 1 & 1\end{bmatrix}\begin{bmatrix}\lambda_1 & 0\\ 0 & \lambda_2\end{bmatrix}\begin{bmatrix}\quad & \quad\\ \quad & \quad\end{bmatrix}$$

计算 $\boldsymbol{X}\boldsymbol{\Lambda}^k\boldsymbol{X}^{-1}\begin{bmatrix}1\\ 0\end{bmatrix}$，其第二个分量即第 $k$ 个斐波那契数 $F_k=\dfrac{\lambda_1^k-\lambda_2^k}{\lambda_1-\lambda_2}$.

9. 设 $G_{k+2}$ 是前两项 $G_{k+1}$ 和 $G_k$ 的平均值：

$$\begin{cases}G_{k+2}=\dfrac{1}{2}G_{k+1}+\dfrac{1}{2}G_k\\ G_{k+1}=G_{k+1}\end{cases}\quad\text{即}\quad\begin{bmatrix}G_{k+2}\\ G_{k+1}\end{bmatrix}=\boldsymbol{A}\begin{bmatrix}G_{k+1}\\ G_k\end{bmatrix}.$$

（1）写出 $\boldsymbol{A}$ 并求 $\boldsymbol{A}$ 的特征值和特征向量.

（2）求 $\boldsymbol{A}^n=\boldsymbol{X}\boldsymbol{\Lambda}^n\boldsymbol{X}^{-1}$ 当 $n\to+\infty$ 时的极限.

（3）若 $G_0=0,G_1=1$，证明：$G_k$ 最终趋于 $2/3$.

10. 证明：当 $n$ 是 3 的倍数时，第 $n$ 个斐波那契数 $F_n$ 是偶数.[②]

习题 11 ~ 14 关于可对角化.

11. 选择正确论断：如果 $\boldsymbol{A}$ 的特征值是 2、2、5，那么它一定：

（1）可逆　　（2）可对角化　　（3）不可对角化

12. 选择正确论断：如果二阶方阵 $\boldsymbol{A}$ 的特征向量都是 $\begin{bmatrix}1 & 4\end{bmatrix}^{\mathrm{T}}$ 的倍数，那么它一定：

（1）不可逆　　（2）有多重特征值　　（3）不可对角化成 $\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1}$

13. 已知下列矩阵的行列式都是 25，请把它们补充完整.

① 译者注：Gibonacci 数是作者仿照斐波那契 (Fibonacci) 数生造的词，指习题 9 中的数列 $G_k$，并不是人名、通用名词或者其他专有名词.

② 译者注：译者其实不太清楚这个问题如何用相似对角化解决，规律倒是很容易找. 众所周知，找规律的严格说法是数学归纳法.

（1）$\boldsymbol{A}=\begin{bmatrix}8 & \\ & 2\end{bmatrix}$　　（2）$\boldsymbol{A}=\begin{bmatrix}9 & 4\\ & 1\end{bmatrix}$　　（3）$\boldsymbol{A}=\begin{bmatrix}10 & 5\\ -5 & \end{bmatrix}$

验证 $\lambda=5$ 均是 2 重特征值——因为它们的迹是 10，从而 $\det(\boldsymbol{A}-\lambda\boldsymbol{I})=(\lambda-5)^2$. 求这些矩阵的特征向量；证明：它们都没有两个线性无关的特征向量，因此都不可对角化.

14. 设 $\boldsymbol{A}=\begin{bmatrix}3 & 1\\ 0 & 3\end{bmatrix}$，因为 $\boldsymbol{A}-3\boldsymbol{I}$ 的秩等于_____，所以 $\boldsymbol{A}$ 不可对角化. 若要改变 $\boldsymbol{A}$ 的一个元素令其可以被对角化，应该改变哪个元素？

习题 15 ~ 19 关于矩阵的方幂.

15. 当 $k\to+\infty$ 时，$\boldsymbol{A}^k$ 趋于零矩阵，当且仅当 $\boldsymbol{A}$ 的所有特征值 $\lambda$ 的绝对值小于_____.

下面两个矩阵中哪一个矩阵的 $k$ 幂趋于零矩阵？

$$\boldsymbol{A}_1=\begin{bmatrix}0.6 & 0.9\\ 0.4 & 0.1\end{bmatrix}\qquad \boldsymbol{A}_2=\begin{bmatrix}0.6 & 0.9\\ 0.1 & 0.6\end{bmatrix}$$

16.（推荐）将习题 15 中的 $\boldsymbol{A}_1$ 对角化：即求 $\boldsymbol{A}_1$ 的特征向量矩阵 $\boldsymbol{X}$，特征值矩阵 $\boldsymbol{\Lambda}$，满足 $\boldsymbol{A}_1=\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1}$. 那么当 $k\to+\infty$ 时，$\boldsymbol{\Lambda}^k$ 的极限是什么？$\boldsymbol{X}\boldsymbol{\Lambda}^k\boldsymbol{X}^{-1}$ 的极限是什么？观察 $\boldsymbol{X}\boldsymbol{\Lambda}^k\boldsymbol{X}^{-1}$ 的极限矩阵的列向量，你发现_____.

17.（推荐）将习题 15 中的 $\boldsymbol{A}_2$ 对角化：即求 $\boldsymbol{A}_2$ 的特征向量矩阵 $\boldsymbol{X}$，特征值矩阵 $\boldsymbol{\Lambda}$，满足 $\boldsymbol{A}_2=\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1}$. 对下列各个列向量 $\boldsymbol{u}_0$，计算 $\boldsymbol{A}_2^{10}\boldsymbol{u}_0$：

$$\boldsymbol{u}_0=\begin{bmatrix}3\\ 1\end{bmatrix}\qquad \boldsymbol{u}_0=\begin{bmatrix}3\\ -1\end{bmatrix}\qquad \boldsymbol{u}_0=\begin{bmatrix}6\\ 0\end{bmatrix}.$$

18. 设 $\boldsymbol{A}=\begin{bmatrix}2 & -1\\ -1 & 2\end{bmatrix}$，将其对角化，据此证明：$\boldsymbol{A}^k=\frac{1}{2}\begin{bmatrix}1+3^k & 1-3^k\\ 1-3^k & 1+3^k\end{bmatrix}$.

19. 设 $\boldsymbol{B}=\begin{bmatrix}5 & 1\\ 0 & 4\end{bmatrix}$，将其对角化，据此证明：$\boldsymbol{B}^k=\begin{bmatrix}5^k & 5^k-4^k\\ 0 & 4^k\end{bmatrix}$.

20. 设 $\boldsymbol{A}=\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1}$，取行列式可证：$\det\boldsymbol{A}=\det\boldsymbol{\Lambda}=\lambda_1\lambda_2\cdots\lambda_n$. 只有当 $\boldsymbol{A}$_____ 时，这个快速证明成立.

21. 设 $\boldsymbol{X}=\begin{bmatrix}a & b\\ c & d\end{bmatrix},\boldsymbol{Y}=\begin{bmatrix}q & r\\ s & t\end{bmatrix}$，直接计算 $\boldsymbol{X}\boldsymbol{Y}$ 和 $\boldsymbol{Y}\boldsymbol{X}$ 对角元之和，证明：$\mathrm{Tr}(\boldsymbol{X}\boldsymbol{Y})=\mathrm{Tr}(\boldsymbol{Y}\boldsymbol{X})$.

令 $\boldsymbol{Y}=\boldsymbol{\Lambda}\boldsymbol{X}^{-1}$，则 $\mathrm{Tr}(\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1})=\mathrm{Tr}(\boldsymbol{\Lambda})$. 这说明 $\boldsymbol{A}$ 的迹等于 $\boldsymbol{\Lambda}$ 的迹，也等于特征值之和. 因为 $\boldsymbol{A}\boldsymbol{B}-\boldsymbol{B}\boldsymbol{A}$ 的迹是_____，所以等式 $\boldsymbol{A}\boldsymbol{B}-\boldsymbol{B}\boldsymbol{A}=\boldsymbol{I}$ 不可能成立.

22. 设 $\boldsymbol{A}=\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1}$，请将分块矩阵 $\boldsymbol{B}=\begin{bmatrix}\boldsymbol{A} & \boldsymbol{0}\\ \boldsymbol{0} & 2\boldsymbol{A}\end{bmatrix}$ 对角化. 求 $\boldsymbol{B}$ 的特征值矩阵和特征向量矩阵（都用分块矩阵来表示）.

23. 考虑被同一个特征向量矩阵 $\boldsymbol{X}$ 对角化的 $4\times4$ 矩阵 $\boldsymbol{A}$ 的全体. 证明：这些矩阵构成子空间（提示：验证这些矩阵的线性组合都可以被 $\boldsymbol{X}$ 对角化）.

若 $\boldsymbol{X}=\boldsymbol{I}$，该子空间是什么？维数是多少？

24. 设 $n$ 阶方阵 $\boldsymbol{A}$ 满足 $\boldsymbol{A}^2=\boldsymbol{A}$，根据矩阵乘法的含义，等号左边表示用 $\boldsymbol{A}$ 乘以它的每一列. $\boldsymbol{A}$ 的四个基本子空间中的哪一个子空间包含了属于特征值 $\lambda=1$ 的特征向量？哪一个子空间包含了属于特征值 $\lambda=0$ 的特征向量？基于这四个基本子空间的维数证明：$\boldsymbol{A}$ 有 $n$ 个线性无关的特征向量，从而满足等式 $\boldsymbol{A}^2=\boldsymbol{A}$ 的矩阵都可对角化.

25.（推荐）设 $\boldsymbol{A}$ 是 $n$ 阶方阵，$\boldsymbol{A}\boldsymbol{x}=\lambda\boldsymbol{x}$. 若 $\lambda=0$，则 $\boldsymbol{x}$ 属于 $\boldsymbol{A}$ 的零空间；若 $\lambda\neq 0$，则 $\boldsymbol{x}$ 属于 $\boldsymbol{A}$ 的列空间. 零空间和列空间的维数相加：$(n-r)+r=n$. 为什么并不是所有 $n$ 阶方阵都有 $n$ 个线性无关的特征向量呢？

26. 设 $\boldsymbol{A}=\begin{bmatrix}5&4\\4&5\end{bmatrix},\boldsymbol{B}=\begin{bmatrix}4&5\\5&4\end{bmatrix}$，$\boldsymbol{A}$ 的特征值是 1 和 9，$\boldsymbol{B}$ 的特征值是 $-1$ 和 9. 若方阵 $\boldsymbol{C}$ 满足 $\boldsymbol{C}^2=\boldsymbol{A}$，则称 $\boldsymbol{C}$ 是 $\boldsymbol{A}$ 的平方根；矩阵的平方根不唯一，甚至可能有无穷多.

设 $\boldsymbol{X}$ 将 $\boldsymbol{A}$ 对角化：$\boldsymbol{A}=\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1}$，求对角矩阵 $\boldsymbol{\Lambda}$ 的一个平方根，再求 $\boldsymbol{A}$ 的一个平方根. 为什么 $\boldsymbol{B}$ 的平方根不可能是实矩阵？

27. 若可对角化矩阵 $\boldsymbol{A}$ 和 $\boldsymbol{B}$[①]有相同的特征值，并且属于每个特征值的线性无关的特征向量也相同，则它们的_____ 分解式相同，所以 $\boldsymbol{A}=\boldsymbol{B}$.

28. 设可逆矩阵 $\boldsymbol{X}$ 同时将 $\boldsymbol{A}$、$\boldsymbol{B}$ 对角化，即存在对角矩阵 $\boldsymbol{\Lambda}_1$、$\boldsymbol{\Lambda}_2$ 使得 $\boldsymbol{A}=\boldsymbol{X}\boldsymbol{\Lambda}_1\boldsymbol{X}^{-1},\boldsymbol{B}=\boldsymbol{X}\boldsymbol{\Lambda}_2\boldsymbol{X}^{-1}$. 证明：$\boldsymbol{A}\boldsymbol{B}=\boldsymbol{B}\boldsymbol{A}$.

29.（1）设 $\boldsymbol{A}=\begin{bmatrix}a&b\\0&d\end{bmatrix}$，$\boldsymbol{A}-\lambda\boldsymbol{I}$ 的行列式是 $(\lambda-a)(\lambda-d)$. 验证“凯莱-哈密尔顿定理”：

$$(\boldsymbol{A}-a\boldsymbol{I})(\boldsymbol{A}-d\boldsymbol{I})=\text{零矩阵}.$$

（2）对斐波那契矩阵 $\boldsymbol{A}=\begin{bmatrix}1&1\\1&0\end{bmatrix}$ 验证“凯莱-哈密尔顿定理”：$\boldsymbol{A}$ 的特征多项式 $\det(\boldsymbol{A}-\lambda\boldsymbol{I})=\lambda^2-\lambda-1$. 证明：等式 $\boldsymbol{A}^2-\boldsymbol{A}-\boldsymbol{I}=\boldsymbol{0}$ 成立.

30. 设 $n$ 阶方阵 $\boldsymbol{A}$ 可对角化 $\boldsymbol{A}=\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1}$，特征值是 $\lambda_1,\lambda_2,\cdots,\lambda_n$. 把这个分解式代入乘积

$$(\boldsymbol{A}-\lambda_1\boldsymbol{I})(\boldsymbol{A}-\lambda_2\boldsymbol{I})\cdots(\boldsymbol{A}-\lambda_n\boldsymbol{I}),$$

证明：该乘积最终等于零矩阵.

事实上，我们把 $\boldsymbol{A}$ 代入它的特征多项式 $p(\lambda)=\det(\boldsymbol{A}-\lambda\boldsymbol{I})$.[②] “凯莱-哈密尔顿定理”断言：$p(\boldsymbol{A})=$ 零矩阵. 该定理不要求 $\boldsymbol{A}$ 可对角化与否，对任意方阵都成立.

31. 设 $\boldsymbol{A}=\begin{bmatrix}1&0\\0&2\end{bmatrix}$，若 $\boldsymbol{A}\boldsymbol{B}=\boldsymbol{B}\boldsymbol{A}$，证明：$\boldsymbol{B}=\begin{bmatrix}a&b\\c&d\end{bmatrix}$ 也是对角矩阵. $\boldsymbol{B}$ 和 $\boldsymbol{A}$ 有相同的特征_____，但是特征_____ 不同. 满足条件的矩阵 $\boldsymbol{B}$ 构成 $2\times 2$ 矩阵空间的一个二维子空间.

提示：等式 $\boldsymbol{A}\boldsymbol{B}-\boldsymbol{B}\boldsymbol{A}=\boldsymbol{0}$ 实际上给出了关于未知数 $a$、$b$、$c$、$d$ 的四个方程，求出系数矩阵的秩.

---

① 译者注：原题没有可对角化这个条件，此时有反例. 对任意 $a\neq 0$，矩阵 $\begin{bmatrix}1&a\\0&1\end{bmatrix}$ 都有相同的二重特征值 1 和特征向量 $\begin{bmatrix}1\\0\end{bmatrix}$.

② 译者注：这里把 $\boldsymbol{A}$ 代入 $p(\lambda)$，并不是要计算 $p(\boldsymbol{A})=\det(\boldsymbol{A}-\boldsymbol{A}\boldsymbol{I})$，正确的代入方式是 $p(\lambda)=a_n+a_{n-1}\lambda\cdots+a_1\lambda^{n-1}+(-1)^n\lambda^n$，代入 $\boldsymbol{A}$ 得 $p(\boldsymbol{A})=a_n\boldsymbol{I}+a_{n-1}\boldsymbol{A}+\cdots+a_1\boldsymbol{A}^{n-1}+(-1)^n\boldsymbol{A}^n$.

32. 矩阵的特征值决定了它取高次幂时的表现. 若 $\boldsymbol{A}$ 的所有特征值都满足 $|\lambda|>1$，则 $\boldsymbol{A}^k$ 将快速膨胀；若 $\boldsymbol{A}$ 的所有特征值都满足 $|\lambda|<1$，则 $\boldsymbol{A}^k$ 将快速趋于零矩阵. 彼得·拉克斯在他的《线性代数》（*Linear Algebra*）一书中给出了以下引人注目的例子：

$$\boldsymbol{A}=\begin{bmatrix}3&2\\1&4\end{bmatrix}\quad \boldsymbol{B}=\begin{bmatrix}3&2\\-5&-3\end{bmatrix}\quad \boldsymbol{C}=\begin{bmatrix}5&7\\-3&-4\end{bmatrix}\quad \boldsymbol{D}=\begin{bmatrix}5&6.9\\-3&-4\end{bmatrix}$$

$$\|\boldsymbol{A}^{1024}\|>10^{700}\quad \boldsymbol{B}^{1024}=\boldsymbol{I}\quad \boldsymbol{C}^{1024}=-\boldsymbol{C}\quad \|\boldsymbol{D}^{1024}\|<10^{-78}$$

证明：$\boldsymbol{B}^4=\boldsymbol{I},\boldsymbol{C}^3=-\boldsymbol{I}$.

## 挑 战 一 下

33. 逆时针旋转 $\theta$ 角，旋转 $n$ 次的总效果是逆时针旋转 $n\theta$ 角，用矩阵乘法表达这个事实，即：

$$\text{对 }\boldsymbol{A}=\begin{bmatrix}\cos\theta&-\sin\theta\\\sin\theta&\cos\theta\end{bmatrix}\text{，我们有 }\boldsymbol{A}^n=\begin{bmatrix}\cos\theta&-\sin\theta\\\sin\theta&\cos\theta\end{bmatrix}^n=\begin{bmatrix}\cos n\theta&-\sin n\theta\\\sin n\theta&\cos n\theta\end{bmatrix}.$$

请把 $\boldsymbol{A}$ 对角化成 $\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1}$，再证明上述等式.

提示：$\boldsymbol{X}$ 的列向量（$\boldsymbol{A}$ 的特征向量）可以取 $\begin{bmatrix}1&\mathrm{i}\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}\mathrm{i}&1\end{bmatrix}^{\mathrm{T}}$. 并使用欧拉公式：$\mathrm{e}^{\mathrm{i}\theta}=\cos\theta+\mathrm{i}\sin\theta$.

34. 设 $\boldsymbol{A}$ 可对角化：$\boldsymbol{A}=\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1}$；取转置得 $\boldsymbol{A}^{\mathrm{T}}=(\boldsymbol{X}^{-1})^{\mathrm{T}}\boldsymbol{\Lambda}\boldsymbol{X}^{\mathrm{T}}$，那么 $(\boldsymbol{X}^{-1})^{\mathrm{T}}$ 的列向量都是 $\boldsymbol{A}^{\mathrm{T}}$ 的特征向量：$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}=\lambda\boldsymbol{y}$. 因为 $\boldsymbol{y}^{\mathrm{T}}\boldsymbol{A}=\lambda\boldsymbol{y}^{\mathrm{T}}$，通常它们也被称为$\boldsymbol{A}$ 的左特征向量. 你能否通过矩阵乘法得到 $\boldsymbol{A}$ 如下分解式：

秩1矩阵之和　　$\boldsymbol{A}=\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1}=\lambda_1\boldsymbol{x}_1\boldsymbol{y}_1^{\mathrm{T}}+\lambda_2\boldsymbol{x}_2\boldsymbol{y}_2^{\mathrm{T}}+\cdots+\lambda_n\boldsymbol{x}_n\boldsymbol{y}_n^{\mathrm{T}}.$

35. 方阵 $\boldsymbol{A}=\mathbf{eye}(n)+\mathbf{ones}(n)$ 的逆矩阵形如 $\boldsymbol{A}^{-1}=\mathbf{eye}(n)+C\cdot\mathbf{ones}(n)$. 利用等式 $\boldsymbol{A}\boldsymbol{A}^{-1}=\boldsymbol{I}$，求出待定常数 $C$（依赖于 $n$）.

36. 设 $\boldsymbol{A}_1$、$\boldsymbol{A}_2$ 都是可逆矩阵. 找一个矩阵 $\boldsymbol{B}$ 满足 $\boldsymbol{A}_2\boldsymbol{A}_1=\boldsymbol{B}(\boldsymbol{A}_1\boldsymbol{A}_2)\boldsymbol{B}^{-1}$. 进而 $\boldsymbol{A}_2\boldsymbol{A}_1$ 和 $\boldsymbol{A}_1\boldsymbol{A}_2$ 相似，所以有相同的特征值. 若 $\boldsymbol{A}_1$、$\boldsymbol{A}_2$ 不一定都可逆，请问 $\boldsymbol{A}_2\boldsymbol{A}_1$ 和 $\boldsymbol{A}_1\boldsymbol{A}_2$ 是否仍然相似？

37. 何时矩阵 $\boldsymbol{A}$ 相似于它的特征值矩阵 $\boldsymbol{\Lambda}$？

$\boldsymbol{A}$ 和 $\boldsymbol{\Lambda}$ 有相同的特征值，但是相似性要求存在矩阵 $\boldsymbol{B}$ 使得 $\boldsymbol{A}=\boldsymbol{B}\boldsymbol{\Lambda}\boldsymbol{B}^{-1}$，那么 $\boldsymbol{B}$ 是_____矩阵，$\boldsymbol{A}$ 有 $n$ 个线性无关的_____.

38.（Pavel Grinfeld 提供）不作具体的细节计算，你能否通过观察找出下述矩阵 $\boldsymbol{A}$ 的特征值？你能否求出 $\boldsymbol{A}^{2023}$？

$$\boldsymbol{A}=\begin{bmatrix}110&55&-164\\42&21&-62\\88&44&-131\end{bmatrix}$$

## 6.3　对称正定矩阵

（1）对称矩阵的特征值都是实数，并且有 $n$ 个两两正交的单位特征向量.
（2）对称矩阵 $\boldsymbol{S}$ 可以被正交矩阵 $\boldsymbol{Q}$ 对角化.
（3A）若对称矩阵 $\boldsymbol{S}$ 是正定矩阵，则其所有特征值 $\lambda>0$，所有主元 $>0$，所有顺序主子式 $>0$.
（3B）对称矩阵 $\boldsymbol{S}$ 的正定型可由能量来检验，即对任意 $\boldsymbol{x}\neq\boldsymbol{0}$，必须有 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}>0$. 此时存在列满秩矩阵 $\boldsymbol{A}$ 使得 $\boldsymbol{S}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$.
（4）半正定矩阵即将上述严格大于零改为大于或等于零，即允许 $\lambda=0$、主元 $=0$、行列式 $=0$、能量 $=0$，在矩阵分解 $\boldsymbol{S}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 中，对 $\boldsymbol{A}$ 也不作要求.

对称矩阵[①] $\boldsymbol{S}=\boldsymbol{S}^{\mathrm{T}}$ 完全值得我们花费一节的篇幅专门讨论. 通过观察其特征值和特征向量就可以明白它们为何如此特别：

（1）对称矩阵 $S$ 的 $n$ 个特征值都是实数.

（2）存在 $n$ 个两两正交的特征向量.

单位矩阵 $\boldsymbol{S}=\boldsymbol{I}$ 是一个极端情况. 所有特征值都是 $\lambda=1$，每个非零向量 $\boldsymbol{x}$ 都是特征向量：$\boldsymbol{I}\boldsymbol{x}=1\boldsymbol{x}$. 这也解释了为什么性质（2）只断言存在性而没有断言唯一性. 多重特征值——如 $\lambda_1=\lambda_2=1$——使得特征向量有多种选择. 我们先选择互相正交的特征向量，再伸缩合适的倍数成为单位向量（长度为 1）. 那么，这些特征向量 $\boldsymbol{q}_1,\boldsymbol{q}_2,\cdots,\boldsymbol{q}_n$ 不仅正交，而且还是单位正交. 换言之，特征向量矩阵 $\boldsymbol{Q}$ 是正交矩阵，满足 $\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{Q}=\boldsymbol{I}$.

$$\boldsymbol{q}_i^{\mathrm{T}}\boldsymbol{q}_j=\begin{cases}0 & i\neq j\\ 1 & i=j\end{cases}\qquad \text{则}\qquad \begin{bmatrix}\boldsymbol{q}_1^{\mathrm{T}}\\ \vdots\\ \boldsymbol{q}_n^{\mathrm{T}}\end{bmatrix}\begin{bmatrix}\boldsymbol{q}_1 & \cdots & \boldsymbol{q}_n\end{bmatrix}=\begin{bmatrix}1 & 0 & \cdots & 0\\ 0 & 1 & \cdots & 0\\ \vdots & \ddots & \ddots & \vdots\\ 0 & \cdots & 0 & 1\end{bmatrix}$$

为了强调 $\boldsymbol{S}$ 的特征向量矩阵是正交矩阵，我们用 $\boldsymbol{Q}$ 来代替先前惯用的符号 $\boldsymbol{X}$. 此时 $\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{Q}=\boldsymbol{I},\boldsymbol{Q}^{\mathrm{T}}=\boldsymbol{Q}^{-1}$. 于是通常的对角化分解式 $\boldsymbol{A}=\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1}$ 也改写成 $\boldsymbol{S}=\boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\mathrm{T}}$.

**谱分解定理**　任意实对称矩阵都可以正交相似对角化. 即：若 $\boldsymbol{S}$ 是实对称矩阵，则存在正交矩阵 $\boldsymbol{Q}$ 和对角矩阵 $\boldsymbol{\Lambda}$ 使得 $\boldsymbol{S}=\boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\mathrm{T}}$.

反之亦然，可正交对角化的矩阵一定是对称矩阵：对 $\boldsymbol{S}=\boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\mathrm{T}}$ 取转置得 $\boldsymbol{S}^{\mathrm{T}}=(\boldsymbol{Q}^{\mathrm{T}})^{\mathrm{T}}\boldsymbol{\Lambda}^{\mathrm{T}}\boldsymbol{Q}^{\mathrm{T}}=\boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\mathrm{T}}=\boldsymbol{S}$.

### 6.3.1　快速证明：正交的特征向量和实特征值

首先假设对称矩阵 $\boldsymbol{S}$ 有非零特征值和零特征值：$\boldsymbol{S}\boldsymbol{x}=\lambda\boldsymbol{x}(\lambda\neq0)$，$\boldsymbol{S}\boldsymbol{y}=0\boldsymbol{y}$. 那么 $\boldsymbol{x}$ 属于 $\boldsymbol{S}$

① 译者注：若非特殊说明，本节的对称矩阵都是实对称矩阵；复数矩阵将在 6.4 节讲述.

的列空间（$\boldsymbol{x}=\frac{1}{\lambda}\boldsymbol{S}\boldsymbol{x}$ 是 $\boldsymbol{S}$ 的列向量的线性组合），$\boldsymbol{y}$ 属于 $\boldsymbol{S}$ 的零空间. 注意到 $\boldsymbol{S}$ 是对称矩阵，所以它的列空间和行空间相同！此外，因为行空间和零空间是正交的，这就证明了**特征向量 $\boldsymbol{x}$ 和 $\boldsymbol{y}$ 正交.**

第二个特征值也非零怎么办呢？假设 $S\boldsymbol{y}=\alpha\boldsymbol{y}(\alpha\neq\lambda,0)$，我们考虑 $\boldsymbol{S}'=S-\alpha\boldsymbol{I}$，于是 $\boldsymbol{S}'\boldsymbol{x}=(\lambda-\alpha)\boldsymbol{x},\boldsymbol{S}'\boldsymbol{y}=0\boldsymbol{y}$. 这就可以归结到前一种情况了：$\boldsymbol{S}'$ 是对称矩阵，$\boldsymbol{x}$ 属于 $\boldsymbol{S}'$ 的列空间，$\boldsymbol{y}$ 属于 $\boldsymbol{S}'$ 的零空间，所以 $\boldsymbol{y}^{\mathrm{T}}\boldsymbol{x}=0$. 总而言之，实对称矩阵属于不同特征值的特征向量是正交的.

但是，上述证明还有个前提：$\boldsymbol{S}$ 的特征值都是实数，特征向量也是实向量. 为此，我们引入复数. 设 $\lambda\in\mathbb{C},\boldsymbol{0}\neq\boldsymbol{x}\in\mathbb{C}^n$ 满足 $\boldsymbol{S}\boldsymbol{x}=\lambda\boldsymbol{x}$；等式两边同时左乘 $\bar{\boldsymbol{x}}^{\mathrm{T}}$：$\bar{\boldsymbol{x}}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}=\lambda\bar{\boldsymbol{x}}^{\mathrm{T}}\boldsymbol{x}$，一旦我们知道 $\bar{\boldsymbol{x}}^{\mathrm{T}}\boldsymbol{x}$ 和 $\bar{\boldsymbol{x}}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}$ 都是实数，那么**$\lambda$ 也是实数.**

我们把复数和复矩阵的内容留到 6.4 节再介绍. 复数的运算规则固然重要，但正定矩阵实在是太美妙了！而且正定矩阵与线性代数中的许多概念紧密相连，理应优先讲解.

### 6.3.2 正定矩阵

依然设 $\boldsymbol{S}$ 是实对称矩阵：$\boldsymbol{S}=\boldsymbol{S}^{\mathrm{T}}$. 那么 $\boldsymbol{S}$ 的所有特征值都是实数. 某些实对称矩阵（并非全部）有另一个重要性质——正定，正是这个性质使得 $\boldsymbol{S}$ 成为应用数学的核心对象.

#### 1. 判据 1——定义

**如果一个实对称矩阵的特征值都大于（大于或等于）零，则称其为（半）正定矩阵.**

计算特征值实在不是个轻松的活儿，所以我们希望在不计算特征值的情况下，考查特征值是否大于零. 在下述五个例子之后，将给出关于正定矩阵的另外四个判据.

（1）$\boldsymbol{S}=\begin{bmatrix}2&0\\0&6\end{bmatrix}$ 是正定矩阵，特征值是 2 和 6，都大于零.

（2）$\boldsymbol{S}=\boldsymbol{Q}\begin{bmatrix}2&0\\0&6\end{bmatrix}\boldsymbol{Q}^{\mathrm{T}}$，若 $\boldsymbol{Q}^{\mathrm{T}}=\boldsymbol{Q}^{-1}$，则 $\boldsymbol{S}$ 的特征值是 2 和 6，它是正定矩阵.

（3）$\boldsymbol{S}=\boldsymbol{C}\begin{bmatrix}2&0\\0&6\end{bmatrix}\boldsymbol{C}^{\mathrm{T}}$，若 $\boldsymbol{C}$ 是可逆矩阵，则 $\boldsymbol{S}$ 是正定矩阵（能量判据）.

（4）$\boldsymbol{S}=\begin{bmatrix}a&b\\b&c\end{bmatrix}$，若 $\boldsymbol{a>0}$ 且 $\boldsymbol{ac>b^2}$，则 $\boldsymbol{S}$ 是正定矩阵（顺序主子式判据）.

（5）$\boldsymbol{S}=\begin{bmatrix}2&0\\0&0\end{bmatrix}$ 是半正定矩阵，特征值都 $\boldsymbol{\geqslant 0}$，并没有都严格 $>0$.

对下面的三个例子检查判据 1，结论分别是：不符合、符合、符合. 但是用后文其他四个判据可能会更快给出结论.

$$\boldsymbol{S}=\begin{bmatrix}1&2\\2&1\end{bmatrix}\qquad \boldsymbol{S}=\boldsymbol{v}\boldsymbol{v}^{\mathrm{T}}(\text{秩 1 矩阵})\qquad \boldsymbol{S}=\begin{bmatrix}2&1&0\\1&2&1\\0&1&2\end{bmatrix}$$

$$\lambda=3,-1\qquad \lambda=\|\boldsymbol{v}\|^2,0\qquad \lambda=2,2-\sqrt{2},2+\sqrt{2}$$

### 2. 判据 2：基于能量的定义

作者个人认为接下来的观点是关于正定矩阵的最重要观点. 这种新方法并不直接涉及特征值，但它却是对特征值 $\lambda>0$ 的完美的判据. 由此可见，判据 2——能量[①]判据——是正定矩阵的一个非常优秀的定义.

$$\boxed{\text{如果对任意非零向量 } \boldsymbol{x}\text{，均有 } \boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}>0\text{，则 } \boldsymbol{S} \text{ 是正定矩阵.}} \tag{6.23}$$

显然单位矩阵 $\boldsymbol{S}=\boldsymbol{I}$ 是正定的：所有特征值 $\lambda=1$；当 $\boldsymbol{x}\neq\boldsymbol{0}$ 时，能量 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{I}\boldsymbol{x}=\boldsymbol{x}^{\mathrm{T}}\boldsymbol{x}>0$. 接下来我们展示一个 $2\times2$ 矩阵的能量；设 $\boldsymbol{x}=\begin{bmatrix}x_1 & x_2\end{bmatrix}^{\mathrm{T}}$：

能量

$$\boxed{\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}=\begin{bmatrix}x_1 & x_2\end{bmatrix}\begin{bmatrix}2 & 4\\ 4 & 9\end{bmatrix}\begin{bmatrix}x_1\\ x_2\end{bmatrix}=2x_1^2+8x_1x_2+9x_2^2}$$

当 $\boldsymbol{x}=\begin{bmatrix}x_1 & x_2\end{bmatrix}^{\mathrm{T}}\neq\boldsymbol{0}$ 时，该表达式是否一定是正的？是的！该表达式是两个完全平方之和：

$$\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}=2x_1^2+8x_1x_2+9x_2^2=2(x_1+2x_2)^2+x_2^2=\text{能量为正}$$

判据 1 和判据 2 是不是吻合呢？答案是肯定的！为此，一方面需要说明特征值全都大于零的对称矩阵，其能量也都大于零；另一方面需要说明能量都大于零的对称矩阵，其特征值也都大于零.

首先我们建立能量为正 $\boxed{\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}>0}$ 和特征值为正 $\boxed{\lambda>0}$ 之间的联系：

$$\text{如果 } \boldsymbol{x}\neq\boldsymbol{0} \text{ 是特征向量 } \boldsymbol{S}\boldsymbol{x}=\lambda\boldsymbol{x}\text{，则 } \boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}=\lambda\boldsymbol{x}^{\mathrm{T}}\boldsymbol{x}.\ \lambda>0 \text{ 当且仅当 } \boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}>0.$$

这说明了能量都大于零的实对称矩阵，其特征值也都大于零. 反之，我们的证明却不完善，因此暂且只说明了单个特征向量的能量大于零. 当然，情况如我们期待的那般理想：若任意特征向量的能量都大于零，则所有向量的能量都大于零：

$$\text{若 } \boldsymbol{S} \text{ 的任意特征向量 } \boldsymbol{x} \text{ 均满足 } \boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}>0\text{，则对任意非零向量 } \boldsymbol{x}\text{，均有 } \boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}>0.$$

事实上，由于 $\boldsymbol{S}$ 是实对称矩阵，一定可以正交对角化，所以可以取 $\boldsymbol{S}$ 的单位正交特征向量组 $\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_n$，而任意 $\boldsymbol{x}$ 都是特征向量的线性组合 $\boldsymbol{x}=c_1\boldsymbol{x}_1+c_2\boldsymbol{x}_2+\cdots+c_n\boldsymbol{x}_n$. 我们接下来说明 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}$ 是正的能量 $\lambda_k\boldsymbol{x}_k^{\mathrm{T}}\boldsymbol{x}_k$ 的正系数组合：

$$\begin{aligned}\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}&=(c_1\boldsymbol{x}_1^{\mathrm{T}}+c_2\boldsymbol{x}_2^{\mathrm{T}}+\cdots+c_n\boldsymbol{x}_n^{\mathrm{T}})\boldsymbol{S}(c_1\boldsymbol{x}_1+c_2\boldsymbol{x}_2+\cdots+c_n\boldsymbol{x}_n)\\&=(c_1\boldsymbol{x}_1^{\mathrm{T}}+c_2\boldsymbol{x}_2^{\mathrm{T}}+\cdots+c_n\boldsymbol{x}_n^{\mathrm{T}})(c_1\lambda_1\boldsymbol{x}_1+c_2\lambda_2\boldsymbol{x}_2+\cdots+c_n\lambda_n\boldsymbol{x}_n)\\&=c_1^2\lambda_1\boldsymbol{x}_1^{\mathrm{T}}\boldsymbol{x}_1+c_2^2\lambda_2\boldsymbol{x}_2^{\mathrm{T}}\boldsymbol{x}_2+\cdots+c_n^2\lambda_n\boldsymbol{x}_n^{\mathrm{T}}\boldsymbol{x}_n\\&>0\end{aligned}$$

第三个等号源自 $\boldsymbol{S}$ 的特征向量的正交性：$\boldsymbol{x}_i^{\mathrm{T}}\boldsymbol{x}_j=0$. 最后的大于号是因为每一个特征值均大于零 $\lambda_i>0$.

我们看一个在缺乏特征值和特征向量的信息的情况下能量判据的应用：

---

① 译者注：读者可能疑惑，为何 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}$ 称作能量？这需要一些物理背景，比如说最简单的情况，设 $\boldsymbol{S}=m$ 表示质点的质量，$\boldsymbol{x}$ 表示该质点的速度，那么 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}$ 几乎就是动能（相差 $\frac{1}{2}$）. 当然也可以考查其他物理系统和系统的能量. 总而言之，能量这个词确实来源于其在物理中的应用.

若 $S_1$ 和 $S_2$ 都是正定的实对称矩阵，则 $S_1+S_2$ 也正定.

$S_1+S_2$ 的特征值、特征向量很难从 $S_1$ 和 $S_2$ 的特征值、特征向量导出，但是能量仅仅是两者的能量相加：

$$x^{\mathrm{T}}(S_1+S_2)x = x^{\mathrm{T}}S_1x + x^{\mathrm{T}}S_2x > 0+0=0.$$

### 3. 另外三个等价判据

到目前为止，关于正定矩阵我们已经有了两个判据：正特征值和正能量. 由能量判据可以推出另外三个有用的判据（可能还有其他判据，但暂时我们只介绍这三个）：

判据 3. 存在列满秩矩阵 $A$ 使得 $S=A^{\mathrm{T}}A$.
判据 4. $S$ 的顺序主子式[①] $D_1, D_2, \cdots, D_n$ 都大于 0.
判据 5. $S$ 的主元都大于 0.

先看判据 3. 首先 $S=A^{\mathrm{T}}A$ 是对称矩阵：$S^{\mathrm{T}}=(A^{\mathrm{T}}A)^{\mathrm{T}}=A^{\mathrm{T}}(A^{\mathrm{T}})^{\mathrm{T}}=A^{\mathrm{T}}A=S$. 为什么判据 3 一定要求 $A$ 列满秩呢？我们对 $A^{\mathrm{T}}A$ 使用判据 2：

$$S=A^{\mathrm{T}}A \qquad \text{能量} = x^{\mathrm{T}}Sx = x^{\mathrm{T}}A^{\mathrm{T}}Ax = (Ax)^{\mathrm{T}}(Ax) = \|Ax\|^2. \tag{6.24}$$

所以能量等于向量 $Ax$ 长度的平方. 若 $Ax\neq 0$，那么能量都大于 0. 要保证 $x\neq 0$ 时，$Ax\neq 0$，$A$ 必须列满秩.

若 $A$ 是 $2\times 3$ 矩阵，列向量线性相关，那么 $S=A^{\mathrm{T}}A$ 的秩小于 3. 现举一例，$\mathrm{rank}(S)=2$:

$$S=A^{\mathrm{T}}A=\begin{bmatrix}1&1\\1&2\\1&3\end{bmatrix}\begin{bmatrix}1&1&1\\1&2&3\end{bmatrix}=\begin{bmatrix}2&3&4\\3&5&7\\4&7&10\end{bmatrix}$$

$S$ 不是正定矩阵，只是半正定矩阵：$x^{\mathrm{T}}Sx=\|Ax\|^2\geqslant 0$.

此矩阵 $A$ 满足：第 1 列 + 第 3 列 =2· 第 2 列，那么 $x=\begin{bmatrix}1&-2&1\end{bmatrix}^{\mathrm{T}}$ 能量为 0. $x$ 也是 $A^{\mathrm{T}}A$ 的属于特征值 $\lambda=0$ 的特征向量. 因为 $x$ 的能量 $x^{\mathrm{T}}Sx=0$，所以 $S=A^{\mathrm{T}}A$ 不正定.

式(6.24)说明，对任意 $A$，$S=A^{\mathrm{T}}A$ 至少是半正定的：$x^{\mathrm{T}}Sx=\|Ax\|^2\geqslant 0$. “半定”允许矩阵 $S$ 的能量、特征值、顺序主子式、主元等为零，不允许小于零.

## 6.3.3 顺序主子式判据和主元判据

对小尺寸的矩阵，顺序主子式判据是最快的判断方法. 以 $4\times 4$ 二阶差分矩阵为例，它是对称矩阵，四个顺序主子阵 $D_1$、$D_2$、$D_3$、$D_4$ 标明如下：

判据 4

$$\begin{bmatrix}\boxed{2}&\boxed{-1}&&\\\boxed{-1}&\boxed{2}&\boxed{-1}&\\&\boxed{-1}&\boxed{2}&\boxed{-1}\\&&\boxed{-1}&\boxed{2}\end{bmatrix}$$

第 1 个顺序主子式 $\det D_1=2>0$
第 2 个顺序主子式 $\det D_2=3>0$
第 3 个顺序主子式 $\det D_3=4>0$
第 4 个顺序主子式 $\det D_4=5>0$

① 译者注：对于 $n$ 阶方阵 $A=\left[a_{ij}\right]_{\substack{1\leqslant i\leqslant n\\1\leqslant j\leqslant n}}$，当 $1\leqslant k\leqslant n$ 时，矩阵 $\left[a_{ij}\right]_{\substack{1\leqslant i\leqslant k\\1\leqslant j\leqslant k}}$ 称作 $A$ 的第 $k$ 个顺序主子阵，它的行列式称作 $A$ 的第 $k$ 个顺序主子式. 我们也有主子阵和主子式，主子阵是 $A$ 的子方阵，且对角线元素均是 $A$ 的对角线元素；主子式就是主子阵的行列式.

这就看出 $\boldsymbol{S}$ 符合顺序主子式判据！$\boldsymbol{S}$ 是正定矩阵，能量 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}$ 都是正的，特征值也是正的.

顺序主子式与主元（消元后对角线上的数字）密切相关. 在上面 $4\times 4$ 差分矩阵的例子中，第一个主元是 2；把第 1 行的 $\frac{1}{2}$ 倍加到第 2 行，第二个主元是 $\frac{3}{2}$；把新的第 2 行的 $\frac{2}{3}$ 倍加到第 3 行，得到第三个主元 $\frac{4}{3}$. 这三个分数 $\frac{2}{1}$、$\frac{3}{2}$、$\frac{4}{3}$ 都是顺序主子式的比值！第四个主元 $\frac{5}{4}$ 也是如此.

第 $k$ 个主元是第 $k$ 个顺序主子式和第 $k-1$ 个顺序主子式的比值 $\dfrac{D_k}{D_{k-1}}$.

作为这个命题的直接推论：实对称矩阵符合判据 4 当且仅当它符合判据 5！所有主元都大于零.

判据 4　所有顺序主子式都大于零.　　判据 5　所有主元都大于零.

判据 4、判据 5 与判据 3（$\boldsymbol{S}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$）的联系是直接的. 事实上，对 $\boldsymbol{S}$ 进行消元操作会给出 $\boldsymbol{A}$ 的一种重要的选取方式. 记住，消元等价于 $LU$ 分解（$\boldsymbol{S}=\boldsymbol{L}\boldsymbol{U}$）. 到目前为止，$\boldsymbol{L}$ 的对角元都是 1，而 $\boldsymbol{U}$ 的对角元是主元. 但是，对于对称矩阵，我们可以将 $\boldsymbol{S}$ 对称地分解为 $\boldsymbol{L}\boldsymbol{D}\boldsymbol{L}^{\mathrm{T}}$.

以 $3\times 3$ 差分矩阵 $\boldsymbol{S}$ 为例，它的 $LU$ 分解是

$$\begin{bmatrix}2&-1&0\\-1&2&-1\\0&-1&2\end{bmatrix}=\begin{bmatrix}1&&\\-\frac{1}{2}&1&\\0&-\frac{2}{3}&1\end{bmatrix}\begin{bmatrix}2&-1&0\\&\frac{3}{2}&-1\\&&\frac{4}{3}\end{bmatrix}\tag{6.25}$$

为了使用判据 5，把主元提出来，放在对角矩阵 $\boldsymbol{D}$ 的对角元，得到 $\boldsymbol{S}=\boldsymbol{L}\boldsymbol{D}\boldsymbol{L}^{\mathrm{T}}$：

$$\begin{bmatrix}2&-1&0\\-1&2&-1\\0&-1&2\end{bmatrix}=\begin{bmatrix}1&&\\-\frac{1}{2}&1&\\0&-\frac{2}{3}&1\end{bmatrix}\begin{bmatrix}2&&\\&\frac{3}{2}&\\&&\frac{4}{3}\end{bmatrix}\begin{bmatrix}1&-\frac{1}{2}&0\\&1&-\frac{2}{3}\\&&1\end{bmatrix}\tag{6.26}$$

为了使用判据 3，把主元拆出来分给 $\boldsymbol{A}^{\mathrm{T}}$ 和 $\boldsymbol{A}$：

$$\begin{bmatrix}2&-1&0\\-1&2&-1\\0&-1&2\end{bmatrix}=\begin{bmatrix}\sqrt{2}&&\\-\sqrt{\frac{1}{2}}&\sqrt{\frac{3}{2}}&\\0&-\sqrt{\frac{2}{3}}&\sqrt{\frac{4}{3}}\end{bmatrix}\begin{bmatrix}\sqrt{2}&-\sqrt{\frac{1}{2}}&0\\&\sqrt{\frac{3}{2}}&-\sqrt{\frac{2}{3}}\\&&\sqrt{\frac{4}{3}}\end{bmatrix}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\tag{6.27}$$

很抱歉，出现了这么多根号，我也不想这样，但是现实就是让人如此无奈. 取 $\boldsymbol{A}=\sqrt{\boldsymbol{D}}\boldsymbol{L}^{\mathrm{T}}$，完美地达成了我们的目标——$\boldsymbol{S}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$：

消元法把正定的实对称矩阵 $S$ 分解为 $S=A^{\mathrm{T}}A$，其中 $A$ 是上三角矩阵.

式(6.27)是所谓的“Cholesky”分解：$\boldsymbol{S}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$，且 $\boldsymbol{A}$ 的对角元是主元的平方根.

要对正定矩阵 $\boldsymbol{S}$ 使用判据 3，我们必须找出至少一个 $\boldsymbol{A}$. $\boldsymbol{A}$ 的选取不唯一，比如说，我们上文至少提出了两种方案：对称矩阵和上三角矩阵.

（1）设 $\boldsymbol{S}$ 的正交对角化分解为 $S=\boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\mathrm{T}}$，那么取特征值矩阵的平方根 $\sqrt{\boldsymbol{\Lambda}}$，令 $\boldsymbol{A}=\boldsymbol{Q}\sqrt{\boldsymbol{\Lambda}}\boldsymbol{Q}^{\mathrm{T}}=\boldsymbol{A}^{\mathrm{T}}$，即有 $\boldsymbol{S}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$.

（2）设 $\boldsymbol{S}$ 的 $LU$ 分解为 $\boldsymbol{S}=\boldsymbol{L}\boldsymbol{U}=\boldsymbol{L}\boldsymbol{D}\boldsymbol{L}^{\mathrm{T}}$，其中 $\boldsymbol{D}$ 的对角元是主元（都大于零），令 $\boldsymbol{A}=\sqrt{\boldsymbol{D}}\boldsymbol{L}$，即有 $\boldsymbol{S}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$.

**总结** 关于实对称矩阵 $\boldsymbol{S}=\boldsymbol{S}^{\mathrm{T}}$ 的 5 个判据涉及线性代数 5 个不同的主题——主元、行列式、特征值、$\boldsymbol{S}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 和能量. 每个判据本身都能给出完整的解答：正定、半正定或者都不是. 能量为正 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}>0$ 是 $\boldsymbol{S}$ 正定最好的定义，它和其他定义都有直接的联系.

$\boldsymbol{S}$ 是 2 阶对称正定矩阵时，下面是它的四个判据的具体形式

$$\boldsymbol{S}=\begin{bmatrix}a & b\\ b & c\end{bmatrix}$$

顺序主子式 $a>0, ac-b^2>0$　　主元 $a>0, (ac-b^2)/a>0$

特征值 $\lambda_1>0, \lambda_2>0$　　能量 $ax^2+2bxy+cy^2>0$

正交矩阵和对称矩阵的特征值在复平面上的分布如图 6.4所示.

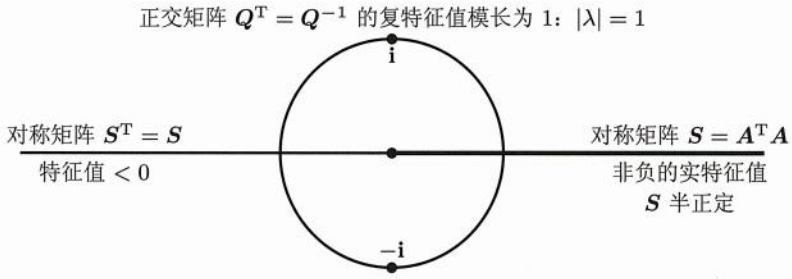


图 6.4　正交矩阵和对称矩阵的特征值在复平面上的分布

下面我们来看两个例子，以对比正定矩阵和半正定矩阵的相似点和不同点.

$\boldsymbol{S}=\begin{bmatrix}9 & 3\\ 3 & 3\end{bmatrix}$ 正定矩阵

顺序主子式：9 和 18

主元：9 和 2（矩阵可逆）

能量：$E(x,y)=9x^2+6xy+3y^2=(3x+y)^2+2y^2$

迹 $=12$，行列式 $=18$，特征方程：$\lambda^2-12\lambda+18=0$

特征值：$\lambda_1=6+3\sqrt{2}, \lambda_2=6-3\sqrt{2}$

特征向量：$\begin{bmatrix}1\\ \sqrt{2}-1\end{bmatrix}, \begin{bmatrix}-1\\ \sqrt{2}+1\end{bmatrix}$

$$\boldsymbol{S}=\boldsymbol{L}\boldsymbol{D}\boldsymbol{L}^{\mathrm{T}}=\begin{bmatrix}1 & 0\\ \frac{1}{3} & 1\end{bmatrix}\begin{bmatrix}9 & 0\\ 0 & 2\end{bmatrix}\begin{bmatrix}1 & \frac{1}{3}\\ 0 & 1\end{bmatrix}$$

$$=\begin{bmatrix}3 & 0\\ 1 & \sqrt{2}\end{bmatrix}\begin{bmatrix}3 & 1\\ 0 & \sqrt{2}\end{bmatrix}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$$

$\boldsymbol{T}=\begin{bmatrix}9 & 3\\ 3 & 1\end{bmatrix}$ 半正定矩阵

顺序主子式：9 和 0

主元：9 和 0（矩阵不可逆）

能量：$E(x,y)=9x^2+6xy+y^2=(3x+y)^2\geqslant 0$

迹 $=10$，行列式 $=0$，特征方程：$\lambda^2-10\lambda=0$

特征值：$\lambda_1=10, \lambda_2=0$

特征向量：$\begin{bmatrix}3\\ 1\end{bmatrix}, \begin{bmatrix}-1\\ 3\end{bmatrix}$

$$\boldsymbol{S}=\boldsymbol{L}\boldsymbol{D}\boldsymbol{L}^{\mathrm{T}}=\begin{bmatrix}1 & 0\\ \frac{1}{3} & 1\end{bmatrix}\begin{bmatrix}9 & 0\\ 0 & 0\end{bmatrix}\begin{bmatrix}1 & \frac{1}{3}\\ 0 & 1\end{bmatrix}$$

$$=\begin{bmatrix}3 & 0\\ 1 & 0\end{bmatrix}\begin{bmatrix}3 & 1\\ 0 & 0\end{bmatrix}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$$

能量函数 $E(x,y)$是严格下凸函数，它的图像 $z=E(x,y)$ 形状像一个碗，如图 6.5 所示. 截面 $E=1$ 是椭圆，椭圆的长短轴即 $\boldsymbol{S}$ 的特征向量.

能量函数 $E(x,y)$ 是下凸函数，它的图像 $z=E(x,y)$ 形状像一个山谷，如图 6.6 所示. 截面 $E=1$ 是两条直线 $3x+y=\pm 1$，直线上的非零向量和与直线正交的非零向量即 $\boldsymbol{T}$ 的特征向量.

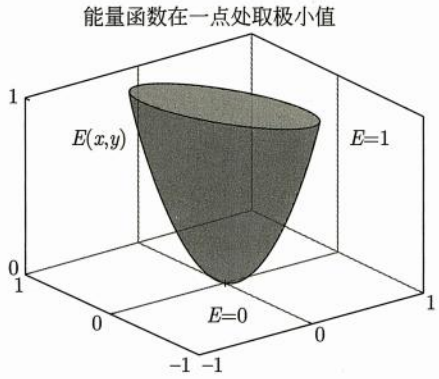


图 6.5　碗状图像

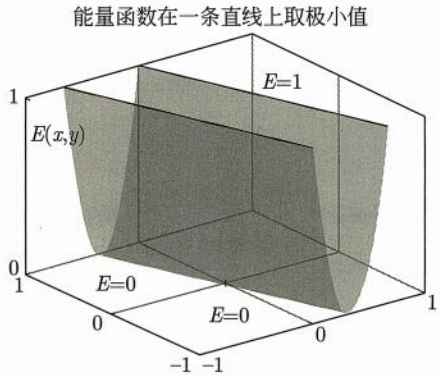


图 6.6　山谷状图像

### 6.3.4　正定矩阵和极小值问题

本节讨论能量函数 $E$，它是关于向量 $\boldsymbol{x}$ 的函数. 例如：设 $\boldsymbol{S}=\begin{bmatrix}5 & 4\\ 4 & 5\end{bmatrix}$.

$$\text{能量}\quad E=\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}\qquad \begin{bmatrix}x & y\end{bmatrix}\begin{bmatrix}5 & 4\\ 4 & 5\end{bmatrix}\begin{bmatrix}x\\ y\end{bmatrix}=5x^2+8xy+5y^2.$$

能量函数 $E(\boldsymbol{x})=E(x,y)$ 的图像是开口向上的碗，如图 6.7 所示. 当 $x=y=0$ 时，碗底部的点能量 $E=0$. 这将微积分中的极小值问题与线性代数中的正定矩阵联系起来.

对于极小最优化问题，函数 $f(x)$ 严格下凸——图像呈碗状向上弯曲. 二阶导数（偏导数）矩阵[①]在所有点处都是正定的. 当我们考虑三维或更高维数的问题时，函数图像已然无法画出，但线性代数能够提炼出二阶导数矩阵 $\boldsymbol{S}$ 的关键性质.

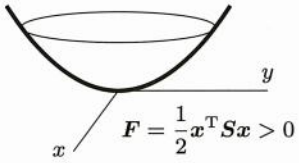


图 6.7　开口向上的碗

能量 $\dfrac{1}{2}\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}$ 的各二阶偏导数实际就是 $\boldsymbol{S}$ 的元素.

① 译者注：所谓二阶导数（偏导数）矩阵，实际上有一个专有名词，叫海森（Hessian）矩阵.

一元函数 $f(x)$ 在点 $x_0$ 处取最小值的判断方法是熟知的：

在$x_0$处取极小值　　导数为零 $\left.\dfrac{\mathrm{d}f}{\mathrm{d}x}\right|_{x=x_0}=0$　　二阶导数为正 $\left.\dfrac{\mathrm{d}^2f}{\mathrm{d}x^2}\right|_{x=x_0}>0.$

而二元函数 $f(x,y)$ 的二阶导数构成矩阵，极小值点处该矩阵正定！

在$(x_0,y_0)$处取极小值　导数为零 $\left.\dfrac{\partial f}{\partial x}\right|_{\substack{x=x_0\\y=y_0}}=\left.\dfrac{\partial f}{\partial y}\right|_{\substack{x=x_0\\y=y_0}}=0$　$\boldsymbol{S}=\begin{bmatrix}\dfrac{\partial^2 f}{\partial x^2} & \dfrac{\partial^2 f}{\partial x\partial y}\\ \dfrac{\partial^2 f}{\partial x\partial y} & \dfrac{\partial^2 f}{\partial y^2}\end{bmatrix}$ 在$(x_0,y_0)$处正定.

因为在 $(x_0,y_0)$ 处 $\partial f/\partial x=\partial f/\partial y=0$，所以 $z=f(x,y)$ 的图像在这点是平的. 又因为二阶导数矩阵 $\boldsymbol{S}$ 正定，所以函数图像向上开口；因此函数 $f(x,y)$ 在这一点取极小值. 三元函数甚至更多变元的情形类似.

**例 6.9**　显然 $E=x^2+y^2$ 在 $x=y=0$ 处取最小值. 函数 $f=\mathrm{e}^{x^2+y^2}$ 情况如何？

$$\begin{aligned}\partial f/\partial x&=2x\mathrm{e}^{x^2+y^2}\\ \partial f/\partial y&=2y\mathrm{e}^{x^2+y^2}\end{aligned}\qquad \boldsymbol{S}=\begin{bmatrix}f_{xx} & f_{xy}\\ f_{yx} & f_{yy}\end{bmatrix}=\begin{bmatrix}2+4x^2 & 4xy\\ 4xy & 2+4y^2\end{bmatrix}\mathrm{e}^{x^2+y^2}$$

$\boldsymbol{S}$ 在任意点处都是正定的！$f(x,y)$ 是严格下凸函数.

### 6.3.5　半正定矩阵

有的矩阵会处在正定性的临界处：行列式为零，最小的特征值是 $\lambda=0$，在这个特征向量上的能量为 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}=0$. 这些临界状态的矩阵是“半正定”的. 以下是两个（不可逆）半正定矩阵的例子：

$$\boldsymbol{S}=\begin{bmatrix}1 & 2\\ 2 & 4\end{bmatrix}\quad 和\quad \boldsymbol{T}=\begin{bmatrix}2 & -1 & -1\\ -1 & 2 & -1\\ -1 & -1 & 2\end{bmatrix}\qquad 都是半正定矩阵，且不正定.$$

$\boldsymbol{S}$ 的特征值是 5 和 0，迹是 $1+4=5$，两个顺序主子式是 1 和 0. $\boldsymbol{S}$ 的秩是 1，把它分解成 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 的形式，则 $\boldsymbol{A}$ 不是列满秩矩阵：

$\boldsymbol{A}$ 的列向量线性相关
$\boldsymbol{S}$ 半正定

$$\begin{bmatrix}1 & 2\\ 2 & 4\end{bmatrix}=\begin{bmatrix}1 & 0\\ 2 & 0\end{bmatrix}\begin{bmatrix}1 & 2\\ 0 & 0\end{bmatrix}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}.$$

$\boldsymbol{S}$ 右下角的元素 4 变大哪怕一点点，都将成为正定矩阵.

循环矩阵 $\boldsymbol{T}$ 的行列式也是零. 特征向量 $\boldsymbol{x}$ 属于特征值 0：$\boldsymbol{T}\boldsymbol{x}=\boldsymbol{0}$，从而能量 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{T}\boldsymbol{x}=0$. 其他方向的向量 $\boldsymbol{x}$ 的能量都大于零.

二阶差分分解为一阶差分的叠加
列向量相加得零向量

$$\begin{bmatrix}2 & -1 & -1\\ -1 & 2 & -1\\ -1 & -1 & 2\end{bmatrix}=\begin{bmatrix}1 & -1 & 0\\ 0 & 1 & -1\\ -1 & 0 & 1\end{bmatrix}\begin{bmatrix}1 & 0 & -1\\ -1 & 1 & 0\\ 0 & -1 & 1\end{bmatrix}$$

半正定矩阵的特征值都大于或等于 0：$\lambda \geqslant 0$，所以 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x} \geqslant 0$. 这个较弱的不等式（$\geqslant$ 而非 $>$）包含了正定矩阵 $\boldsymbol{S}$ 以及临界状态处的奇异矩阵[①].

如果 $\boldsymbol{S}$ 是半正定矩阵，那么任意矩阵 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{A}$ 也是半正定矩阵：

若对任意 $\boldsymbol{x}$ 都有 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x} \geqslant 0$，那么对任意 $\boldsymbol{x}$ 也都有 $(\boldsymbol{A}\boldsymbol{x})^{\mathrm{T}}\boldsymbol{S}(\boldsymbol{A}\boldsymbol{x}) \geqslant 0$.

我们也可以类比地判定 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{A}$ 何时是正定矩阵. 首先必须确保 $\boldsymbol{x} \neq \boldsymbol{0}$ 时 $\boldsymbol{A}\boldsymbol{x}$ 也不是零向量，这才可能有 $(\boldsymbol{A}\boldsymbol{x})^{\mathrm{T}}\boldsymbol{S}(\boldsymbol{A}\boldsymbol{x})$ 不为零.

若对任意 $\boldsymbol{x} \neq \boldsymbol{0}$ 都有 $\boldsymbol{A}\boldsymbol{x} \neq \boldsymbol{0}$ 和 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x} > 0$，则 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{A}$ 是正定矩阵.

毫无疑问应该采用能量判据来证明. 对任意 $\boldsymbol{x} \neq \boldsymbol{0}$，$\boldsymbol{A}\boldsymbol{x} \neq \boldsymbol{0}$，所以在向量 $\boldsymbol{A}\boldsymbol{x}$ 处的能量是正的：$(\boldsymbol{A}\boldsymbol{x})^{\mathrm{T}}\boldsymbol{S}(\boldsymbol{A}\boldsymbol{x}) > 0$. 我们称矩阵 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{A}$ 和 $\boldsymbol{S}$**合同**.[②]

矩阵合同 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{A}$ 在应用数学中有非常重要的意义，我们希望它是正定的（而不仅仅是半正定的）. 这样，在工程中，方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{A}\boldsymbol{x} = f$ 就可以求解了.

在合同关系下，矩阵有被称作**惯性指数**的不变量：

若对称矩阵 $\boldsymbol{S} = \boldsymbol{S}^{\mathrm{T}}$ 有 $p$ 个正特征值、$q$ 个负特征值和 $r$ 个零特征值，那么当 $\boldsymbol{A}$ 可逆时，$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{A}$ 也有 $p$ 个正特征值、$q$ 个负特征值和 $r$ 个零特征值.

$p$、$q$、$r$ 分别被称作正惯性指数、负惯性指数和零惯性指数. 合同的矩阵有相同的惯性指数.

### 6.3.6　椭圆 $ax^2 + 2bxy + cy^2 = 1$

本节的内容是椭圆 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x} = 1$. 虽然它的中心点是 $(0,0)$，但它并不是标准状态的椭圆，而是倾斜的，见图 6.8(a). 将其旋转使得椭圆长短轴处于坐标轴（$X$ 轴和 $Y$ 轴）上，参考图 6.8(b). 这两幅图展示了 $\boldsymbol{\Lambda}$ 的对角元和 $\boldsymbol{Q}$ 的列向量（即 $\boldsymbol{S}$ 的特征值和特征向量）背后的几何意义. 特征向量所在的直线其实就是椭圆轴所在直线.

倾斜椭圆的方程是 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x} = 1$，标准椭圆方程是 $\boldsymbol{X}^{\mathrm{T}}\boldsymbol{\Lambda}\boldsymbol{X} = 1$，坐标变换为 $\boldsymbol{X} = \boldsymbol{Q}^{\mathrm{T}}\boldsymbol{x}$.

**例 6.10**　求倾斜的椭圆 $5x^2 + 8xy + 5y^2 = 1$ 的长短轴.

**解**　把方程用矩阵乘法改写：

$$\begin{bmatrix} x & y \end{bmatrix} \begin{bmatrix} 5 & 4 \\ 4 & 5 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = 1, \qquad \boldsymbol{S} = \begin{bmatrix} 5 & 4 \\ 4 & 5 \end{bmatrix}$$

$\boldsymbol{S}$ 的特征向量是 $\begin{bmatrix} 1 \\ 1 \end{bmatrix}$ 和 $\begin{bmatrix} 1 \\ -1 \end{bmatrix}$. 模长都是 $\sqrt{2}$，所以 $\boldsymbol{Q} = \dfrac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$

① 译者注：言下之意，正定矩阵都是半正定矩阵；而只有可逆的半正定矩阵才是正定矩阵. 笼统地说，限制条件越弱，能涵盖的对象越多；限制条件越强，能涵盖的对象越少.

② 译者注：作者原本的论述并不要求 $\boldsymbol{A}$ 和 $\boldsymbol{S}$ 是同阶方阵. 但是习惯上合同关系是对于同阶方阵来谈的，原则上来讲，合同关系也是一种等价关系，等价关系的要求迫使 $\boldsymbol{A}$ 应该是可逆矩阵. 所以应该这样定义：对于给定的 $n$ 阶方阵 $\boldsymbol{S}_1$ 和 $\boldsymbol{S}_2$，如果存在 $n$ 阶可逆矩阵 $\boldsymbol{A}$ 使得 $\boldsymbol{S}_1 = \boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}_1\boldsymbol{A}$，我们称 $\boldsymbol{S}_1$ 和 $\boldsymbol{S}_2$ 是合同的.

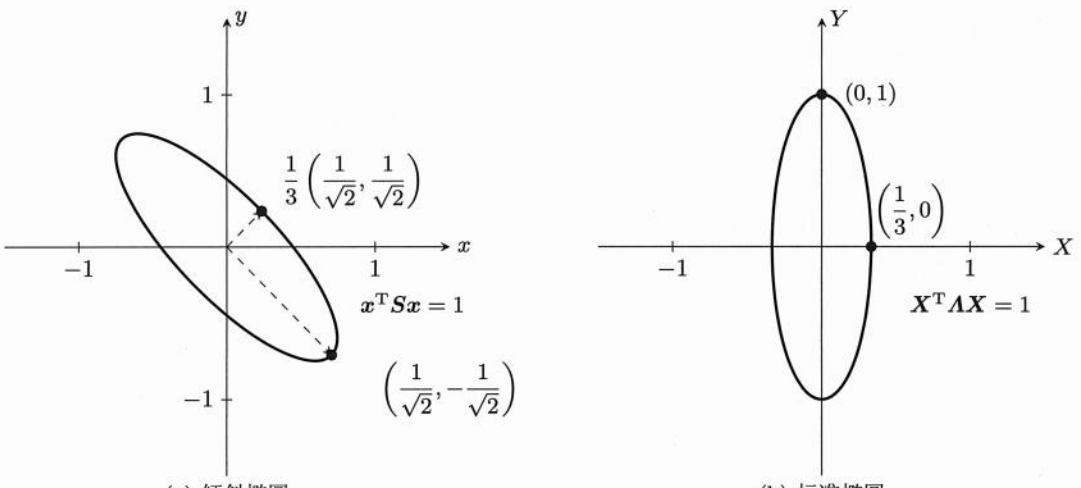


**图 6.8　倾斜与标准椭圆**

注：图 (a) 为 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}=5x^2+8xy+5y^2=1$ 的椭圆；图 (b) 经过坐标变换使得椭圆长短轴和坐标轴重合，椭圆方程变成 $9X^2+Y^2=1$.

$\boldsymbol{Q}$ 是特征向量矩阵　特征值是 9 和 1

$$\begin{bmatrix}5&4\\4&5\end{bmatrix}=\frac{1}{\sqrt{2}}\begin{bmatrix}1&1\\1&-1\end{bmatrix}\begin{bmatrix}9&0\\0&1\end{bmatrix}\frac{1}{\sqrt{2}}\begin{bmatrix}1&1\\1&-1\end{bmatrix}$$

代入椭圆方程得：$\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}=(\boldsymbol{x}^{\mathrm{T}}\boldsymbol{Q})\boldsymbol{\Lambda}(\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{x})$

$\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}=$ 平方和

$$5x^2+8xy+5y^2=9\cdot\left(\frac{x+y}{\sqrt{2}}\right)^2+1\cdot\left(\frac{x-y}{\sqrt{2}}\right)^2 \tag{6.28}$$

系数是特征值 9 和 1，也是 $\boldsymbol{\Lambda}$ 的对角元. 平方和来自特征向量 $\boldsymbol{q}_1=\frac{1}{\sqrt{2}}\begin{bmatrix}1\\1\end{bmatrix},\boldsymbol{q}_1=\frac{1}{\sqrt{2}}\begin{bmatrix}1\\-1\end{bmatrix}$. 倾斜椭圆的对称轴和 $\boldsymbol{S}$ 的特征向量所在直线重合，这也就解释了为什么谱分解 $\boldsymbol{S}=\boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\mathrm{T}}$ 也被称为“主轴定理”——它给出了椭圆两个轴的信息，不仅指出了轴的方向（由特征向量给出），还给出了轴的长度（由特征值给出）.

为了全面地理解这一点，我们用大写字母来表示将椭圆标准化后的新坐标：

$$\frac{x+y}{\sqrt{2}}=X,\qquad\frac{x-y}{\sqrt{2}}=Y\qquad 9X^2+Y^2=1.$$

$X^2$ 的最大值是 $1/9$，短轴的端点是 $(X,Y)=(\pm1/3,0)$. 在 $xy$ 坐标系中，椭圆对称轴的方向是 $\boldsymbol{S}$ 的特征向量；在 $XY$ 坐标系中，椭圆轴的方向是 $\boldsymbol{\Lambda}$ 的特征向量——坐标轴. 所有信息都在谱分解 $\boldsymbol{S}=\boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\mathrm{T}}$ 中了.

注：较大的特征值 $\lambda_1=9$ 给出的是短轴，半短轴长是 $1/\sqrt{\lambda_1}=1/3$. 较小的特征值 $\lambda_2=1$ 给出的是长轴，半长轴是 $1/\sqrt{\lambda_2}=1$.

### 6.3.7　最优化和机器学习

本节将解释如何用梯度下降法求函数 $f(\boldsymbol{x})$ 的最小值. 所谓梯度下降法是这样一种迭代：每一

步迭代均从当前点 $\boldsymbol{x}_k$ 沿着最陡峭的方向走到 $\boldsymbol{x}_{k+1}$. 但是，随着不断下降，这个最陡峭的方向会发生变化，最终到达微积分与线性代数的交汇处——最小值点 $\boldsymbol{x}^*$.

| | |
|---|---|
| 微积分 | $f$ 在 $\boldsymbol{x}^*$ 点处所有偏导数都是 0：$\dfrac{\partial f}{\partial x_i}=0$ |
| 线性代数 | 二阶偏导数 $\dfrac{\partial^2 f}{\partial x_i \partial x_j}$ 构成的矩阵 $\boldsymbol{S}$ 是正定矩阵. |

如果矩阵 $\boldsymbol{S}$ 在所有点 $\boldsymbol{x}=(x_1,x_2,\cdots,x_n)$ 处都是正定的（或半正定的），那么函数 $f(\boldsymbol{x})$ 是下凸函数. 如果 $\boldsymbol{S}$ 的特征值都大于某个正数 $\delta$，那么 $f(\boldsymbol{x})$ 是严格下凸函数；于是函数只有一个最小值，所以是最适合优化的函数. 该最小值可以用梯度下降法找出来. 详情请参阅第 9 章.

机器学习会产生包含成千上万变量的“损失函数”，这些函数作用是衡量误差，而我们正致力于将误差最小化. 但是变量太多了，计算所有二阶导数几乎是不可能的；所以我们转变思路，用一阶导数来确定移动的方向——误差下降最快的方向（即最陡方向）. 然后我们在新的方向上迈出下降的一步. 这是最小二乘法、神经网络和深度学习中的核心计算.

深度学习取得巨大成功的关键在于学习函数 $F(\boldsymbol{x},\boldsymbol{v})$ 的特殊形式，将在第 10 章中描述. “训练数据”包含在向量 $\boldsymbol{v}$ 中，决定训练数据重要性的权重包含在 $\boldsymbol{x}$ 中. 如果训练得当，$F$ 可以识别出它从未见过的新数据 $\boldsymbol{V}$.

### 6.3.8　实对称矩阵都可以正交对角化

我们将以实对称矩阵的谱分解 $\boldsymbol{S}=\boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\mathrm{T}}$ 来作为本节的结尾. 任意实对称矩阵 $\boldsymbol{S}$ 都可以被正交矩阵相似对角化.

$n$ 阶方阵 $\boldsymbol{A}$ 如果没有重特征值，一定存在 $n$ 个线性无关的特征向量，那么 $\boldsymbol{A}$ 可以相似对角化. 我们之前也讨论过，重特征值有时会导致没有足够多的线性无关的特征向量，这种情况对于非对称矩阵时有发生，但是对称矩阵则永远不会：实对称矩阵 $\boldsymbol{S}=\boldsymbol{S}^{\mathrm{T}}$ 始终都有充分多的能将之对角化的特征向量.

我们可以基于Schur 定理证明这个事实. Schur 定理说的是：对任意方阵 $\boldsymbol{A}$，都存在正交矩阵 $\boldsymbol{Q}$ 和上三角矩阵 $\boldsymbol{T}$ 使得 $\boldsymbol{A}=\boldsymbol{Q}\boldsymbol{T}\boldsymbol{Q}^{-1}=\boldsymbol{Q}\boldsymbol{T}\boldsymbol{Q}^{\mathrm{T}}$. 若 $\boldsymbol{A}$ 是对称矩阵，那么 $\boldsymbol{T}=\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{Q}$ 也是对称矩阵. 对称的上三角矩阵只能是对角矩阵.

通过 Schur 定理，我们就找出了所需的对角矩阵. 这里我们再提醒一个事实：若 $\boldsymbol{A}$ 可以相似对角化 $\boldsymbol{A}=\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1}$，那么 $\boldsymbol{T}$ 可以从这个等式导出. 事实上，利用 4.4 节 Gram-Schmidt 正交化，把 $\boldsymbol{X}$ 分解为 $\boldsymbol{X}=\boldsymbol{Q}\boldsymbol{R}$，其中 $\boldsymbol{Q}$ 是正交矩阵，$\boldsymbol{R}$ 是上三角矩阵. 那么

$$\boldsymbol{A}=\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1}=\boldsymbol{Q}\boldsymbol{R}\boldsymbol{\Lambda}\boldsymbol{R}^{-1}\boldsymbol{Q}^{-1}=\boldsymbol{Q}\boldsymbol{T}\boldsymbol{Q}^{-1},\qquad \text{其中}\boldsymbol{T}=\boldsymbol{R}\boldsymbol{\Lambda}\boldsymbol{R}^{-1}.$$

## 例 题 总 结

6.3A. 判断下列实对称矩阵 $\boldsymbol{S}$ 和 $\boldsymbol{T}$ 正定与否.

$$\boldsymbol{S}=\begin{bmatrix}2&-1&0\\-1&2&-1\\0&-1&2\end{bmatrix}\qquad \boldsymbol{T}=\begin{bmatrix}2&-1&c\\-1&2&-1\\c&-1&2\end{bmatrix}$$

**解** $\boldsymbol{S}$ 的主元是 2、$\frac{3}{2}$、$\frac{4}{3}$，都是正数. 它的顺序主子式分别是 2、3、4，都是正数. 它的特征值是 $2-\sqrt{2}$、2、$2+\sqrt{2}$，都是正数. 至此，我们已经说明 $\boldsymbol{S}$ 符合三个不同判据的条件，任何一个判据都可以说明 $\boldsymbol{S}$ 是正定矩阵.

根据上述特征值，我们令 $\boldsymbol{A}=\boldsymbol{Q}\sqrt{\boldsymbol{\Lambda}}\boldsymbol{Q}^{\mathrm{T}}$，$\boldsymbol{A}$ 也是可逆对称矩阵，且 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}=\boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\mathrm{T}}=\boldsymbol{S}$. 这也说明了以 $-1$、2、$-1$ 为三条对角线的三对角矩阵 $\boldsymbol{S}$ 是正定矩阵. 当然，对分解式 $\boldsymbol{S}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 中的 $\boldsymbol{A}$ 我们还有其他选择，以下从三个不同的角度，举三个例子：

| | 重新配方 |
|---|---|
| $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}=2x_1^2-2x_1x_2+2x_2^2-2x_2x_3+2x_3^2$ | |
| $\|\boldsymbol{A}_1\boldsymbol{x}\|^2=x_1^2+(x_2-x_1)^2+(x_3-x_2)^2+x_3^2$ | $\boldsymbol{S}=\boldsymbol{A}_1^{\mathrm{T}}\boldsymbol{A}_1$ |
| $\|\boldsymbol{A}_2\boldsymbol{x}\|^2=2(x_1-\frac{1}{2}x_2)^2+\frac{3}{2}(x_2-\frac{2}{3}x_3)^2+\frac{4}{3}x_3^2$ | $\boldsymbol{S}=\boldsymbol{L}\boldsymbol{D}\boldsymbol{L}^{\mathrm{T}}=\boldsymbol{A}_2^{\mathrm{T}}\boldsymbol{A}_2$ |
| $\|\boldsymbol{A}_2\boldsymbol{x}\|^2=\lambda_1(\boldsymbol{q}_1^{\mathrm{T}}\boldsymbol{x})^2+\lambda_2(\boldsymbol{q}_2^{\mathrm{T}}\boldsymbol{x})^2+\lambda_3(\boldsymbol{q}_3^{\mathrm{T}}\boldsymbol{x})^2$ | $\boldsymbol{S}=\boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\mathrm{T}}=\boldsymbol{A}_3^{\mathrm{T}}\boldsymbol{A}_3$ |

对于 $\boldsymbol{T}$，我们先通过行列式给出其正定的必要条件：

$$\det\boldsymbol{T}=(1+c)(4-2c)\quad\text{必须大于零.}$$

当 $c=-1$ 和 $c=2$ 时，$\det\boldsymbol{T}=0$. 当 $-1<c<2$ 时，$\det\boldsymbol{T}>0$，而 $\boldsymbol{T}$ 前两个顺序主子式和 $\boldsymbol{S}$ 相同，根据顺序主子式判据可知 $\boldsymbol{T}$ 是正定的. 当 $c=0$ 时，矩阵 $\boldsymbol{T}$ 就是 $\boldsymbol{S}$，它在 $-1$ 和 2 之间，正定得那一个叫稳当.

## 习题 6.3

1. 假设 $\boldsymbol{S}=\boldsymbol{S}^{\mathrm{T}}$. 什么情况下 $\boldsymbol{ASB}$ 也是对称矩阵，并且和 $\boldsymbol{S}$ 有相同的特征值？

（1）对 $\boldsymbol{ASB}$ 取转置可以看出当 $\boldsymbol{B}=$_____ 时 $\boldsymbol{ASB}$ 也是正定的.

（2）当 $\boldsymbol{B}=$_____ 时，$\boldsymbol{ASB}$ 和 $\boldsymbol{S}$ 相似（从而有相同的特征值）.

结合（1）（2）两方面，相似于 $\boldsymbol{S}$ 的对称矩阵形如 (___)$\boldsymbol{S}$(___).

2. 求下列矩阵 $\boldsymbol{S}$ 和 $\boldsymbol{T}$ 的特征值和特征向量，并把它们分解成 $\boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\mathrm{T}}$ 的形式，其中 $\boldsymbol{Q}$ 是正交矩阵，$\boldsymbol{\Lambda}$ 是对角矩阵：

$$\boldsymbol{S}=\begin{bmatrix}2&2&2\\2&0&0\\2&0&0\end{bmatrix}\qquad\boldsymbol{T}=\begin{bmatrix}1&0&2\\0&-1&-2\\2&-2&0\end{bmatrix}$$

3. 找出所有能将矩阵 $\boldsymbol{S}=\begin{bmatrix}9&12\\12&16\end{bmatrix}$ 对角化的正交矩阵.

4.（1）对称矩阵 $\begin{bmatrix}1&b\\b&1\end{bmatrix}$ 何时有负特征值？

（2）当（1）中的矩阵有负特征值时，证明：该矩阵有主元是负数.

（3）证明：（1）中矩阵的两个特征值不能都是负数.

5. 若 $\boldsymbol{C}$ 是对称矩阵，证明 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{C}\boldsymbol{A}$ 也对称（提示：取转置）. 若 $\boldsymbol{A}$ 是 $6\times3$ 矩阵，那么 $\boldsymbol{C}$ 和 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{C}\boldsymbol{A}$ 分别是几阶方阵？

6. 求一个能将 $\boldsymbol{S}=\begin{bmatrix}-2 & 6\\ 6 & 7\end{bmatrix}$ 对角化的正交矩阵 $\boldsymbol{Q}$，对角化之后的矩阵 $\boldsymbol{\Lambda}$ 是什么？

如果 $\boldsymbol{A}^3=\boldsymbol{0}$，那么 $\boldsymbol{A}$ 的特征值一定是_____. 举一个满足这个条件的非零矩阵 $\boldsymbol{A}$ 的例子. 但是，当 $\boldsymbol{A}$ 是对称矩阵时，利用 $\boldsymbol{A}$ 的对角化，证明 $\boldsymbol{A}$ 是零矩阵.

7. 对下面的矩阵 $\boldsymbol{S}$、$\boldsymbol{T}$ 作谱分解 $\boldsymbol{Q\Lambda Q}^{\mathrm{T}}$，并写成 $\lambda_1\boldsymbol{x}_1\boldsymbol{x}_1^{\mathrm{T}}+\lambda_2\boldsymbol{x}_2\boldsymbol{x}_2^{\mathrm{T}}$：

$$\boldsymbol{S}=\begin{bmatrix}3 & 1\\ 1 & 3\end{bmatrix}\qquad \boldsymbol{T}=\begin{bmatrix}9 & 12\\ 12 & 16\end{bmatrix}\qquad (\text{要求 } \|\boldsymbol{x}_1\|=\|\boldsymbol{x}_2\|=1)$$

8. 任意二阶对称矩阵都可以写成 $\lambda_1\boldsymbol{x}_1\boldsymbol{x}_1^{\mathrm{T}}+\lambda_2\boldsymbol{x}_2\boldsymbol{x}_2^{\mathrm{T}}=\lambda_1\boldsymbol{P}_1+\lambda_2\boldsymbol{P}_2$ 的形式. 设 $\boldsymbol{Q}=\begin{bmatrix}\boldsymbol{x}_1 & \boldsymbol{x}_2\end{bmatrix}$，那么 $\boldsymbol{Q}$ 是正交矩阵. 证明：$\boldsymbol{P}_1+\boldsymbol{P}_2=\boldsymbol{x}_1\boldsymbol{x}_1^{\mathrm{T}}+\boldsymbol{x}_2\boldsymbol{x}_2^{\mathrm{T}}=\boldsymbol{I}$. 为什么 $\boldsymbol{P}_1\boldsymbol{P}_2=\boldsymbol{0}$？

9. $\boldsymbol{A}=\begin{bmatrix}0 & b\\ -b & 0\end{bmatrix}$ 的特征值是什么？构造一个 $4\times 4$ 反对称矩阵 $\boldsymbol{B}$（$\boldsymbol{B}^{\mathrm{T}}=-\boldsymbol{B}$），并且验证其特征值都是纯虚数.

10.（推荐）令 $\boldsymbol{M}=\dfrac{1}{\sqrt{3}}\begin{bmatrix}0 & 1 & 1 & 1\\ -1 & 0 & -1 & 1\\ -1 & 1 & 0 & -1\\ -1 & -1 & 1 & 0\end{bmatrix}$，那么 $\boldsymbol{M}$ 是反对称的_____ 矩阵. 它的所有特征值 $\lambda$ 都是纯虚数，并且 $|\lambda|=1$. 因为对任意向量 $\boldsymbol{x}$，都有 $\|\boldsymbol{Mx}\|=\|\boldsymbol{x}\|$，所以对特征向量 $\boldsymbol{x}$ 都有 $\|\lambda\boldsymbol{x}\|=\|\boldsymbol{x}\|$. 请根据 $\boldsymbol{M}$ 的迹，求出 $\boldsymbol{M}$ 的四个特征值.

11. 令 $\boldsymbol{A}=\begin{bmatrix}\mathrm{i} & 1\\ 1 & -\mathrm{i}\end{bmatrix}$，那么 $\boldsymbol{A}$ 是对称的复矩阵（不是实矩阵）. 证明 $\boldsymbol{A}$ 的特征向量分布在一条直线上. 因此 $\boldsymbol{A}$ 不可对角化. 由此可见，对于复矩阵，对称性 $\boldsymbol{A}^{\mathrm{T}}=\boldsymbol{A}$ 并不是很特殊的性质. 真正的好性质是 $\overline{\boldsymbol{A}}^{\mathrm{T}}=\boldsymbol{A}$，此时 $\boldsymbol{A}$ 的特征值都是实数，且存在足够多的两两正交的特征向量.

12. 求下列矩阵 $\boldsymbol{S}$ 的特征向量矩阵 $\boldsymbol{Q}$ 和 $\boldsymbol{B}$ 的特征向量矩阵 $\boldsymbol{X}$. 当 $d=1$ 时，$\lambda=1$ 是 $\boldsymbol{B}$ 的二重特征值，证明：此时 $\boldsymbol{X}$ 仍然是可逆矩阵. 能否取到合适的特征向量使得 $\boldsymbol{X}$ 是正交矩阵？

$$\boldsymbol{S}=\begin{bmatrix}0 & d & 0\\ d & 0 & 0\\ 0 & 0 & 1\end{bmatrix},\qquad \boldsymbol{B}=\begin{bmatrix}-d & 0 & 1\\ 0 & 1 & 0\\ 0 & 0 & d\end{bmatrix}\qquad \text{特征值都是}\lambda=1,d,-d.$$

13. 写一个满足 $\overline{\boldsymbol{S}}^{\mathrm{T}}=\boldsymbol{S}$（满足这个条件的复方阵称作埃米特矩阵）的二阶复方阵 $\boldsymbol{S}$，求 $\boldsymbol{S}$ 的特征值 $\lambda_1$、$\lambda_2$，验证分别属于这两个特征值的特征向量 $\boldsymbol{x}_1$、$\boldsymbol{x}_2$ 满足 $\overline{\boldsymbol{x}}_1^{\mathrm{T}}\boldsymbol{x}_2=0$（这就是所谓的“复正交性”）.

14. 判断正误，正确请简述其理由，错误则给出反例：

（1）有 $n$ 个实特征值和 $n$ 个实特征向量的矩阵一定是对称矩阵.

（2）有 $n$ 个实特征值和 $n$ 个单位正交的实特征向量的矩阵一定是对称矩阵.

（3）可逆对称矩阵的逆矩阵也是对称矩阵.

（4）实对称矩阵的特征向量矩阵 $\boldsymbol{Q}$ 是对称矩阵.

（5）正定矩阵的对角元都是正数.

15. 若方阵 $\boldsymbol{A}$ 满足 $\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$，那么 $\boldsymbol{A}$ 和 $\boldsymbol{A}^{\mathrm{T}}$ 有相同的特征向量（承认这个事实，此处无须证明）. 由特征多项式可知 $\boldsymbol{A}$ 和 $\boldsymbol{A}^{\mathrm{T}}$ 有相同的特征值. 请找出下面论述中的漏洞：$\boldsymbol{A}$ 和 $\boldsymbol{A}^{\mathrm{T}}$ 有相同的特征向量矩阵和特征值矩阵，所以 $\boldsymbol{A}=\boldsymbol{A}^{\mathrm{T}}$.

16. 令 $\boldsymbol{A}=\begin{bmatrix}0&0&1\\0&1&0\\1&0&0\end{bmatrix}$，$\boldsymbol{B}=\frac{1}{3}\begin{bmatrix}1&1&1\\1&1&1\\1&1&1\end{bmatrix}$. 它们是否为可逆矩阵、正交矩阵、投影矩阵、置换矩阵、可对角化矩阵？它们各有以下分解中哪几个：$LU$、$\boldsymbol{Q}\boldsymbol{R}$、$\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1}$、$\boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\mathrm{T}}$？

17. 设 $\boldsymbol{A}=\begin{bmatrix}2&b\\1&0\end{bmatrix}$，$b$ 取何值时，$\boldsymbol{A}$ 可以被正交对角化？$b$ 取何值时，$\boldsymbol{A}$ 可以被相似对角化？$b$ 取何值时，$\boldsymbol{A}$ 是奇异矩阵？

18. 写出所有的二阶对称正交矩阵. 这些矩阵的特征值有哪几种可能性？

19. 矩阵 $\boldsymbol{A}=\begin{bmatrix}1&10^{-15}\\0&1+10^{-15}\end{bmatrix}$ 几乎是对称矩阵. $\begin{bmatrix}1\\0\end{bmatrix}$ 是它的特征向量，求一个与之线性无关的特征向量，这两个特征向量之间的夹角是多少？

20. 设 $\lambda_{\max}$ 是实对称矩阵 $\boldsymbol{S}$ 最大的特征值，证明：$\boldsymbol{S}$ 的所有对角元都小于或等于 $\lambda_{\max}$.

我们不妨从左上角的 $a_{11}$ 开始，若 $\boldsymbol{S}=\boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\mathrm{T}}$，那么 $a_{11}$ 可以怎么表示？为什么 $a_{11}\leqslant\lambda_{\max}$？

21. 设 $\boldsymbol{A}$ 是反对称的实矩阵 $\boldsymbol{A}^{\mathrm{T}}=-\boldsymbol{A}$，解释如下关于 $\boldsymbol{A}$ 的事实：

（1）对任意实向量 $\boldsymbol{x}$ 都有 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{x}=0$；

（2）$\boldsymbol{A}$ 的特征值都是纯虚数；

（3）$\boldsymbol{A}$ 的行列式是非负实数.

提示：要说明(1)，可以展开 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{x}$，看看哪些项可以消掉；或者注意到等式 $\boldsymbol{x}^{\mathrm{T}}(\boldsymbol{A}\boldsymbol{x})=-(\boldsymbol{A}\boldsymbol{x})^{\mathrm{T}}\boldsymbol{x}$. 要说明(2)，注意到 $\boldsymbol{A}\boldsymbol{z}=\lambda\boldsymbol{z}$ 推出 $\bar{\boldsymbol{z}}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{z}=\lambda\bar{\boldsymbol{z}}^{\mathrm{T}}\boldsymbol{z}=\lambda\|\boldsymbol{z}\|^2$.(1)可以说明 $\bar{\boldsymbol{z}}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{z}=(\boldsymbol{x}-\mathrm{i}\boldsymbol{y})^{\mathrm{T}}\boldsymbol{A}(\boldsymbol{x}+\mathrm{i}\boldsymbol{y})$ 实部为零.（3）可由（2）推出.

22. 若 $\boldsymbol{S}$ 是实对称矩阵，且所有特征值都是 2. 证明：$\boldsymbol{S}=2\boldsymbol{I}$.

提示：$\boldsymbol{S}$ 是实对称矩阵推出分解式 $\boldsymbol{S}=\boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\mathrm{T}}$，$\boldsymbol{\Lambda}$ 是什么？

23. 如果实对称矩阵 $\boldsymbol{S}$ 是正交矩阵，$\boldsymbol{S}$ 有哪些可能？证明：$\boldsymbol{S}^2=\boldsymbol{I}$. 特征向量有哪些可能的取值？正交对角化 $\boldsymbol{S}=\boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\mathrm{T}}$ 中 $\boldsymbol{\Lambda}$ 可能是什么矩阵？

习题 24 ~ 49 关于正定矩阵的判据.

24. 假设二阶方阵 $\boldsymbol{S}=\begin{bmatrix}a&b\\b&c\end{bmatrix}$ 满足：$a>0, ac-b^2>0$.

（1）因为特征值的乘积 $\lambda_1\lambda_2=$_____，所以 $\lambda_1$ 和 $\lambda_2$ 同为正数或者同为负数.

（2）又因为 $\lambda_1+\lambda_2=$_____，所以 $\lambda_1>0, \lambda_2>0$.

25. 以下四个矩阵 $\boldsymbol{S}_1$、$\boldsymbol{S}_2$、$\boldsymbol{S}_3$、$\boldsymbol{S}_4$ 中，哪几个矩阵的特征值都是正数？不把特征值算出来，你能作出判定吗？找一个向量 $\boldsymbol{x}$ 使得 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}_1\boldsymbol{x}<0$，由此说明 $\boldsymbol{S}_1$ 不是正定矩阵.

$$\boldsymbol{S}_1=\begin{bmatrix}5&6\\6&7\end{bmatrix}\quad \boldsymbol{S}_2=\begin{bmatrix}-1&-2\\-2&-5\end{bmatrix}\quad \boldsymbol{S}_3=\begin{bmatrix}1&10\\10&100\end{bmatrix}\quad \boldsymbol{S}_4=\begin{bmatrix}1&10\\10&101\end{bmatrix}.$$

26. $b$、$c$ 取何值时下列各矩阵是正定矩阵？把它们分解成 $\boldsymbol{LDL}^{\mathrm{T}}$ 的形式.

$$\boldsymbol{S}=\begin{bmatrix}1 & b\\ b & 9\end{bmatrix}\qquad \boldsymbol{S}=\begin{bmatrix}2 & 4\\ 4 & c\end{bmatrix}\qquad \boldsymbol{S}=\begin{bmatrix}c & b\\ b & c\end{bmatrix}$$

27. 把 $f(x,y)=x^2+4xy+3y^2$ 配方成两个平方的差，求一个使得 $f(x,y)<0$ 的点 $(x,y)$. 说明：虽然 $f(x,y)$ 的系数都是正实数，但是 $(0,0)$ 点不是它的极小值点.

28. 点 $(0,0)$ 是函数 $f(x,y)=2xy$ 的鞍点，而非极小值点. 求对称矩阵 $\boldsymbol{S}$ 使得 $\begin{bmatrix}x & y\end{bmatrix}\boldsymbol{S}\begin{bmatrix}x\\ y\end{bmatrix}=2xy$；它的特征值是多少？

29. 对下列各个矩阵 $\boldsymbol{A}$，判断 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 是否是正定矩阵. 提示：$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 正定，当且仅当 $\boldsymbol{A}$ 列满秩.

$$(1)\ \boldsymbol{A}=\begin{bmatrix}1 & 2\\ 0 & 3\end{bmatrix}\qquad (2)\ \boldsymbol{A}=\begin{bmatrix}1 & 1\\ 1 & 2\\ 2 & 1\end{bmatrix}\qquad (3)\ \boldsymbol{A}=\begin{bmatrix}1 & 1 & 2\\ 1 & 2 & 1\end{bmatrix}$$

30. 求对应以下二次型的三阶对称方阵 $\boldsymbol{S}$ 和 $\boldsymbol{T}$：

$\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}=2(x_1^2+x_2^2+x_3^2-x_1x_2-x_2x_3)$. 为什么 $\boldsymbol{S}$ 是正定矩阵？

$\boldsymbol{x}^{\mathrm{T}}\boldsymbol{T}\boldsymbol{x}=2(x_1^2+x_2^2+x_3^2-x_1x_2-x_1x_3-x_2x_3)$. 为什么 $\boldsymbol{T}$ 是半正定矩阵？

31. 计算 $\boldsymbol{S}$ 的三个顺序主子式，判定 $\boldsymbol{S}$ 是正定矩阵. 验证：它们的比值给出了来源于消元法的第二、第三个主元.

主元 = 顺序主子式的比值

$$\boldsymbol{S}=\begin{bmatrix}2 & 2 & 0\\ 2 & 5 & 3\\ 0 & 3 & 8\end{bmatrix}$$

32. $c$、$d$ 取何值时，矩阵 $\boldsymbol{S}$ 和 $\boldsymbol{T}$ 是正定矩阵？请用顺序主子式来判定.

$$\boldsymbol{S}=\begin{bmatrix}c & 1 & 1\\ 1 & c & 1\\ 1 & 1 & c\end{bmatrix}\qquad \boldsymbol{T}=\begin{bmatrix}1 & 2 & 3\\ 2 & d & 4\\ 3 & 4 & 5\end{bmatrix}$$

33. 求一个满足：$a>0, c>0, a+c>2b$ 且有负特征值的二阶方阵 $\begin{bmatrix}a & b\\ b & c\end{bmatrix}$.

34. 证明：若 $\boldsymbol{S}$ 是正定矩阵，则 $\boldsymbol{S}^{-1}$ 也是正定矩阵.

最佳证明：因为_____，所以 $\boldsymbol{S}^{-1}$ 的特征值都是正数. 还有其他判断方法吗？

35. 正定矩阵的对角元不能是零或者负数；请证明：若不然，则不符合能量判据 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}>0$. 例如：

$$(x_1,x_2,x_3)=(\quad,\quad,\quad)\text{时，}\begin{bmatrix}x_1 & x_2 & x_3\end{bmatrix}\begin{bmatrix}4 & 1 & 1\\ 1 & 0 & 2\\ 1 & 2 & 5\end{bmatrix}\begin{bmatrix}x_1\\ x_2\\ x_3\end{bmatrix}\text{ 不是正数.}$$

36. 实对称矩阵的对角元 $s_{jj}$ 不能小于所有特征值. 若不然，$S-s_{jj}\boldsymbol{I}$ 的特征值都_____，从而是正定矩阵. 但是它的对角元有_____ 元素.

37. 简要说明以下论断成立的原因.

（1）正定矩阵都可逆.

（2）唯一的正定投影矩阵是单位阵.

（3）对角元都是正实数的对角矩阵是正定矩阵.

（4）行列式大于零的实对称矩阵可能不是正定矩阵.

38. $s$、$t$ 取何值时，$\boldsymbol{S}$ 和 $\boldsymbol{T}$ 的所有特征值都大于零？

$$\boldsymbol{S}=\begin{bmatrix} s & -4 & -4 \\ -4 & s & -4 \\ -4 & -4 & s \end{bmatrix} \qquad \boldsymbol{T}=\begin{bmatrix} t & 3 & 0 \\ 3 & t & 4 \\ 0 & 4 & t \end{bmatrix}.$$

39. 对以下对称矩阵 $\boldsymbol{S}$，作正交对角化 $\boldsymbol{S}=\boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\mathrm{T}}$，并求 $\boldsymbol{S}$ 的一个对称正定的平方根：$\boldsymbol{Q}\sqrt{\boldsymbol{\Lambda}}\boldsymbol{Q}^{\mathrm{T}}$. 验证该平方根也给出了矩阵分解 $\boldsymbol{S}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$：

$$\boldsymbol{S}=\begin{bmatrix} 5 & 4 \\ 4 & 5 \end{bmatrix} \qquad \boldsymbol{S}=\begin{bmatrix} 10 & 6 \\ 6 & 10 \end{bmatrix}.$$

40. 画出倾斜椭圆 $x^2+xy+y^2=1$ 的图像，写出其对应的实对称矩阵 $\boldsymbol{S}$，求出 $\boldsymbol{S}$ 的特征值和该椭圆长短轴的半轴长.

41. 若对角矩阵 $\boldsymbol{D}$ 的主元都是正数，那么矩阵分解 $\boldsymbol{S}=\boldsymbol{L}\boldsymbol{D}\boldsymbol{L}^{\mathrm{T}}$ 可以改写成 $\boldsymbol{L}\sqrt{\boldsymbol{D}}\sqrt{\boldsymbol{D}}\boldsymbol{L}^{\mathrm{T}}$（对主元开方得 $\boldsymbol{D}=\sqrt{\boldsymbol{D}}\sqrt{\boldsymbol{D}}$）. 令 $\boldsymbol{C}=\sqrt{\boldsymbol{D}}\boldsymbol{L}^{\mathrm{T}}$，则有 $\boldsymbol{S}$ 的Cholesky 分解$\boldsymbol{S}=\boldsymbol{C}^{\mathrm{T}}\boldsymbol{C}$（可以看作 $LU$ 分解的对称化）.

若 $\boldsymbol{C}=\begin{bmatrix} 3 & 1 \\ 0 & 2 \end{bmatrix}$，求 $\boldsymbol{S}$. 若 $\boldsymbol{S}=\begin{bmatrix} 4 & 8 \\ 8 & 25 \end{bmatrix}$，求 $\boldsymbol{C}$.

42. 在 Cholesky 分解 $\boldsymbol{S}=\boldsymbol{C}^{\mathrm{T}}\boldsymbol{C}$（$\boldsymbol{C}=\sqrt{\boldsymbol{D}}\boldsymbol{L}^{\mathrm{T}}$）中，主元的平方根是 $\boldsymbol{C}$ 的对角元. 对下列矩阵，求出相应的 $\boldsymbol{C}$（上三角矩阵）

$$\boldsymbol{S}=\begin{bmatrix} 9 & 0 & 0 \\ 0 & 1 & 2 \\ 0 & 2 & 8 \end{bmatrix} \qquad \boldsymbol{S}=\begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 2 \\ 1 & 2 & 7 \end{bmatrix}$$

43. 不展开计算 $\boldsymbol{S}=\begin{bmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{bmatrix}\begin{bmatrix} 2 & 0 \\ 0 & 5 \end{bmatrix}\begin{bmatrix} \cos\theta & \sin\theta \\ -\sin\theta & \cos\theta \end{bmatrix}$，回答下列问题：

（1）$\boldsymbol{S}$ 的行列式是多少？

（2）$\boldsymbol{S}$ 的特征值是多少？

（3）$\boldsymbol{S}$ 的特征向量是什么？

（4）$\boldsymbol{S}$ 为什么是实对称正定矩阵？

44. 函数 $z=x^2+y^2$ 的图像是开口向上的碗，$z=x^2-y^2$ 图像是马鞍面，$z=-x^2-y^2$ 是开口向下的碗. 你能否提一个关于 $a$、$b$、$c$ 的条件，来判定 $z=ax^2+2bxy+cy^2$ 在点 $(x,y)=(0.0)$ 附近是马鞍面？

45. 考虑函数 $z=4x^2+12xy+cy^2$，$c$ 取何值时它的图像是碗？$c$ 取何值时它的图像是马鞍面？当 $c$ 取值于前两种情况的分界线时，请刻画函数图像.

46. 设 $\boldsymbol{S}$、$\boldsymbol{T}$ 都是实对称正定矩阵，$\boldsymbol{ST}$ 有可能不是对称矩阵. 但是我们断言：$\boldsymbol{ST}$ 的实特征值都大于零. 请证明这个断言（提示：设 $\boldsymbol{STx}=\lambda\boldsymbol{x}$，等式两边同时和 $\boldsymbol{Tx}$ 作点积）.

47. 设 $\boldsymbol{C}$ 是正定矩阵（等价地，对任意 $\boldsymbol{y}\neq 0$ 都有 $\boldsymbol{y}^{\mathrm{T}}\boldsymbol{Cy}>0$），$\boldsymbol{A}$ 是列满秩矩阵（等价地，对任意 $\boldsymbol{x}\neq 0$，都有 $\boldsymbol{Ax}\neq 0$）. 请通过能量判据证明：$S=A^{\mathrm{T}}CA$ 是正定矩阵. 这是工程实践中关键的矩阵类型.

48.（非常推荐）设 $\boldsymbol{S}$ 是对称正定矩阵，特征值从大到小排列：$\lambda_1\geqslant\lambda_2\geqslant\cdots\geqslant\lambda_n>0$.

（1）矩阵 $\lambda_1\boldsymbol{I}-\boldsymbol{S}$ 的特征值是什么？是否是半正定矩阵？

（2）你能否从（1）推导出：对任意 $\boldsymbol{x}$，不等式 $\lambda_1\boldsymbol{x}^{\mathrm{T}}\boldsymbol{x}\geqslant\boldsymbol{x}^{\mathrm{T}}\boldsymbol{Sx}$？

（3）请下结论：$\dfrac{\boldsymbol{x}^{\mathrm{T}}\boldsymbol{Sx}}{\boldsymbol{x}^{\mathrm{T}}\boldsymbol{x}}$ 的最大值是_____.

49. $a$、$c$ 满足什么条件时，$\boldsymbol{S}=\begin{bmatrix}a & a & a\\ a & a+c & a-c\\ a & a-c & a+c\end{bmatrix}$ 是正定矩阵？$a$、$c$ 满足什么条件时，$\boldsymbol{S}$ 是半正定矩阵？注意：正定矩阵也是半正定矩阵.

提示：5 种判据都可以试一下. 能量 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{Sx}=a(x_1+x_2+x_3)^2+c(x_2-x_3)^2$.

## 6.4　复数、复向量和复矩阵

引进复数的一个原因是解方程：$x^2=-1$，其中一个解记作 $x=\mathrm{i}$. 有了 i 之后，任意的实系数二次多项式方程 $ax^2+bx+c=0$ 都有两个复数解 $x_1$、$x_2$. 紧接着，求解多项式方程向前迈进了一大步. 考虑 $n$ 次复系数多项式：$c_0x^n+c_1x^{n-1}+\cdots+c_n=0$，其中 $c_j=a_j+b_j\mathrm{i}$ $(0\leqslant j\leqslant n)$. 代数基本定理断言：复数域上的任意 $n$ 次多项式方程都恰好有 $n$ 个根 $x_1,x_2,\cdots,x_n$. 该定理首先由高斯（数学史上最伟大的数学家之一）证明.

**例 6.11**　方程 $ax^2+bx+c=0$ 的根是 $x=\dfrac{-b\pm\sqrt{b^2-4ac}}{2a}=\dfrac{-b\pm\mathrm{i}\sqrt{4ac-b^2}}{2a}$. 该方程始终有两个根，两个实数根或者一对共轭的复数根（$b^2=4ac$ 时，根是二重根）. 3 次或者 4 次多项式方程也有求根公式，但是太复杂了，所以一般不使用. 但是次数 $n\geqslant 5$ 时，不存在用四则运算和开方表示的求根公式.

我们先简单介绍一下复数，复数域为 $\mathbb{C}=\{a+\mathrm{i}b:a,b\in\mathbb{R}\}$，以下列举一些涉及复数的加法、乘法和除法的概念和运算规律：

（1）$z_1+z_2=(a+\mathrm{i}b)+(x+\mathrm{i}y)=(a+x)+\mathrm{i}(b+y)$；

（2）$z_1z_2=(a+\mathrm{i}b)(x+\mathrm{i}y)=(ax-by)+\mathrm{i}(bx+ay)$，这里需要注意的是：$(\mathrm{i}b)(\mathrm{i}y)=-by$.

（3）$\bar{z}=\overline{x+\mathrm{i}y}=x-\mathrm{i}y$，称作 $z=x+\mathrm{i}y$ 的共轭.

（4）$|z|^2=z\cdot\bar{z}=(x+\mathrm{i}y)(x-\mathrm{i}y)=x^2+y^2=r^2$.

(5) $\dfrac{z_1}{z_2}=\dfrac{a+\mathrm{i}b}{x+\mathrm{i}y}=\dfrac{(a+\mathrm{i}b)(x-\mathrm{i}y)}{(x+\mathrm{i}y)(x-\mathrm{i}y)}=\dfrac{(ax+by)+\mathrm{i}(bx-ay)}{x^2+y^2}$.

给一个非零复数 $z$，你可能会觉得 $\dfrac{1}{z}$ 有点怪怪的，为什么呢？因为它并非直接形如 $a+\mathrm{i}b\ (a,b\in\mathbb{R})$ 这种形式，所以更好的写法可能是 $\dfrac{1}{z}=\dfrac{\bar{z}}{|z|^2}$.

利用 Euler 公式 $\boxed{\mathrm{e}^{\mathrm{i}\theta}=\cos\theta+\mathrm{i}\sin\theta}$，复数还有极坐标形式 $\boxed{z=|z|\mathrm{e}^{\mathrm{i}\theta}=r\mathrm{e}^{\mathrm{i}\theta}}$（见图 6.9）. 比较两种表达方式：$x+\mathrm{i}y=r\mathrm{e}^{\mathrm{i}\theta}=r\cos\theta+\mathrm{i}r\sin\theta$，可以看出 $x=r\cos\theta, y=r\sin\theta$. 极坐标形式对于复数的乘法来说表现堪称完美：辐角 $\theta$ 相加、模长 $r$ 相乘：

$$z_1z_2=|z_1||z_2|\mathrm{e}^{\mathrm{i}(\theta_1+\theta_2)}\qquad z^n=r^n\mathrm{e}^{\mathrm{i}n\theta}\qquad \frac{z_1}{z_2}=\frac{|z_1|}{|z_2|}\mathrm{e}^{\mathrm{i}(\theta_1-\theta_2)}$$

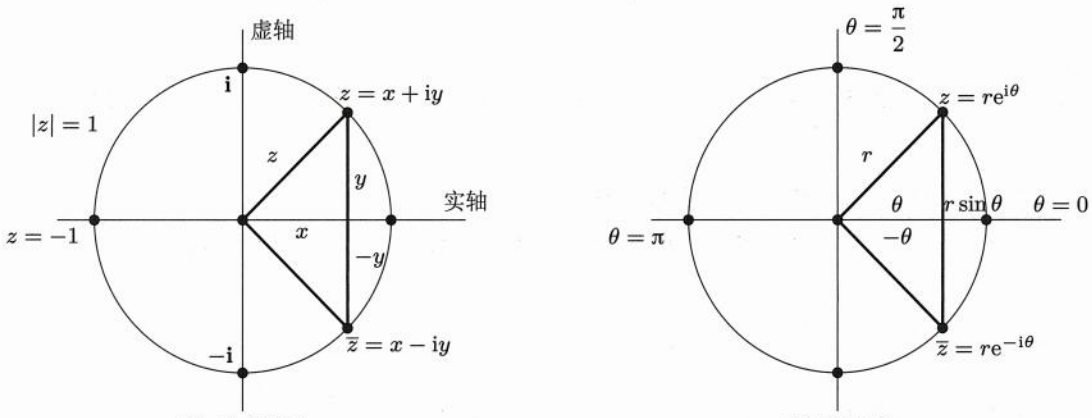


图 6.9 复平面的欧式坐标和极坐标

接下来介绍复向量和复矩阵. 最重要的复矩阵是傅里叶矩阵，我们将详细讲解.

最终的着眼点是 $n$ 阶实方阵的特征值. $\boldsymbol{A}-\lambda\boldsymbol{I}$ 的行列式是关于 $\lambda$ 的 $n$ 次多项式 $P(\lambda)$. 例如，$\boldsymbol{A}$ 是 2 阶方阵时，$P(\lambda)=\lambda^2-(\mathrm{Tr}\boldsymbol{A})\lambda+(\det\boldsymbol{A})$. $\boldsymbol{A}$ 是实矩阵，则 $P(\lambda)$ 的系数都是实数. 我们熟知实系数多项式可能有非实数的复数根，比如 $\lambda^2+1=0$，它的根是 $\lambda=+\mathrm{i},-\mathrm{i}$. 实系数多项式的根有一个不容忽视的事实：

**实系数多项式 $P(\lambda)$ 的非实数根以共轭复数 $\lambda=a\pm b\mathrm{i}$ 的形式成对出现.**

比如：$(\lambda-1)^2+1=0$ 的根是 $\lambda=1+\mathrm{i},1-\mathrm{i}$. 一般的二次方程 $ax^2+bx+c=0$ 的根中出现了 $\pm\sqrt{b^2-4ac}$. 如果 $b^2-4ac<0$，那么这两个平方根是共轭的. 一般来说，

**若 $P(\lambda)=a_n\lambda^n+\cdots+a_0$ 是实系数多项式且 $P(x+\mathrm{i}y)=a_n(x+\mathrm{i}y)^n+\cdots+a_0=0$，则 $P(x-\mathrm{i}y)=0$.**

若 $\boldsymbol{A}$ 是实矩阵，$\boldsymbol{v}$ 是属于特征值 $\lambda$ 的特征向量，那么 $\bar{\boldsymbol{v}}$ 也是属于特征值 $\bar{\lambda}$ 的特征向量. 原因在于：对 $\boldsymbol{A}\boldsymbol{v}=\lambda\boldsymbol{v}$ 取共轭，就有 $\boldsymbol{A}\bar{\boldsymbol{v}}=\bar{\lambda}\bar{\boldsymbol{v}}$.

### 6.4.1　复向量：长度 $\|v\|$ 和内积 $\bar{v}^{\mathrm{T}}w$

长度 $\|\boldsymbol{v}\|^2=\overline{\boldsymbol{v}}^{\mathrm{T}}\boldsymbol{v}=|v_1|^2+|v_2|^2+\cdots+|v_n|^2\geqslant 0$　　注意：是 $\overline{\boldsymbol{v}}^{\mathrm{T}}\boldsymbol{v}$，而不是 $\boldsymbol{v}^{\mathrm{T}}\boldsymbol{v}$.

内积 $=\overline{\boldsymbol{v}}^{\mathrm{T}}\boldsymbol{w}=\overline{v}_1w_1+\overline{v}_2w_2+\cdots+\overline{v}_nw_n$　　注意：是 $\overline{\boldsymbol{v}}^{\mathrm{T}}\boldsymbol{w}$，而不是 $\boldsymbol{v}^{\mathrm{T}}\boldsymbol{w}$.

$\boldsymbol{v}=\begin{bmatrix}1 & \mathrm{i}\end{bmatrix}^{\mathrm{T}}$ 的长度是 $\|\boldsymbol{v}\|=\sqrt{2}$，$\boldsymbol{w}=\begin{bmatrix}1+\mathrm{i} & 0\end{bmatrix}^{\mathrm{T}}$ 的长度也是 $\|\boldsymbol{w}\|=\sqrt{2}$.

### 6.4.2　复矩阵 $A$ 及其共轭转置 $\overline{A}^{\mathrm{T}}$

类似于点积，实矩阵的转置若要推广到复矩阵，也要增加取共轭的操作，例如 $\boldsymbol{A}^{\mathrm{T}}$、$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 和 $\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 要改成 $\overline{\boldsymbol{A}}^{\mathrm{T}}$、$\overline{\boldsymbol{A}}^{\mathrm{T}}\boldsymbol{A}$ 和 $\boldsymbol{A}\overline{\boldsymbol{A}}^{\mathrm{T}}$. 同样地，正交矩阵的定义式 $\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{Q}=\boldsymbol{I}$ 也要修正为 $\overline{\boldsymbol{Q}}^{\mathrm{T}}\boldsymbol{Q}=\boldsymbol{I}$. 言下之意，我们仅仅考虑复矩阵的转置是不够的，转置的同时，要把矩阵中的每一个元素 $x+\mathrm{i}y$ 都改成它的共轭 $x-\mathrm{i}y$. 现今的计算机软件对复矩阵一般都自动地做共轭转置，而不只是转置.

| | |
|---|---|
| 实对称矩阵：$\boldsymbol{S}^{\mathrm{T}}=\boldsymbol{S}$ | 复埃米特矩阵：$\overline{\boldsymbol{S}}^{\mathrm{T}}=\boldsymbol{S}$ |
| 存在正交特征向量矩阵 | 特征值都是实数 |
| 实正交矩阵：$\boldsymbol{Q}^{\mathrm{T}}=\boldsymbol{Q}^{-1}$ | 复酉矩阵$\overline{\boldsymbol{Q}}^{\mathrm{T}}=\boldsymbol{Q}^{-1}$ |
| 存在酉正交特征向量矩阵 | 特征值模长都是 1：$\lvert\lambda\rvert=1(\lambda=\mathrm{e}^{\mathrm{i}\theta})$ |

如果 $\lambda$ 是 $\boldsymbol{A}$ 的特征值，则 $\overline{\lambda}$ 是 $\overline{\boldsymbol{A}}^{\mathrm{T}}$ 的特征值. 埃米特矩阵 $\overline{\boldsymbol{A}}^{\mathrm{T}}\boldsymbol{A}$ 和 $\boldsymbol{A}\overline{\boldsymbol{A}}^{\mathrm{T}}$ 的特征值都是大于或等于 0 的实数：某种意义上，也可以理解为“半正定矩阵”. $n$ 阶埃米特矩阵 $\boldsymbol{S}=\overline{\boldsymbol{S}}^{\mathrm{T}}$ 有 $n$ 个两两酉正交的特征向量：$\overline{\boldsymbol{x}}^{\mathrm{T}}\boldsymbol{y}=0$. 以 $\boldsymbol{S}=\overline{\boldsymbol{S}}^{\mathrm{T}}=\begin{bmatrix}2 & 3-3\mathrm{i}\\ 3+3\mathrm{i} & 5\end{bmatrix}$ 为例，$\boldsymbol{S}$ 是典型的埃米特矩阵，两个特征值 $\lambda=8$ 和 $\lambda=-1$ 都是实数，$\boldsymbol{x}=\begin{bmatrix}1\\ 1+\mathrm{i}\end{bmatrix}$ 和 $\boldsymbol{y}=\begin{bmatrix}1-\mathrm{i}\\ -1\end{bmatrix}$ 是分别属于这两个特征值的复特征向量，它们酉正交：

$$\overline{\boldsymbol{x}}^{\mathrm{T}}\boldsymbol{y}=(\overline{1})(1-\mathrm{i})+(\overline{1+\mathrm{i}})(-1)=0.$$

### 6.4.3　复矩阵 $A$ 的四个基本子空间

设 $\boldsymbol{A}$ 是复矩阵，它的列向量张成了列空间 $\mathcal{C}(\boldsymbol{A})$，方程组 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{0}$ 的解集是零空间 $\mathcal{N}(\boldsymbol{A})$. 我们当然希望在复 $n$ 维空间 $\mathbb{C}^n$ 中，$\mathcal{C}(\boldsymbol{A}^{\mathrm{T}})$ 和 $\mathcal{N}(\boldsymbol{A})$、$\mathcal{C}(\boldsymbol{A})$ 和 $\mathcal{N}(\boldsymbol{A}^{\mathrm{T}})$ 这两对子空间仍然互相正交. 但是，复向量的正交性定义是 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{y}=0$；因此，考虑复矩阵，我们必须重新定义四个基本子空间其中两个：行空间 $\mathcal{C}(\boldsymbol{A}^{\mathrm{T}})$ 修改为 $\mathcal{C}(\overline{\boldsymbol{A}}^{\mathrm{T}})$，$\mathcal{N}(\boldsymbol{A}^{\mathrm{T}})$ 修改为 $\mathcal{N}(\overline{\boldsymbol{A}}^{\mathrm{T}})$.

对这些对象做了修正之后，行空间 $\mathcal{C}(\overline{\boldsymbol{A}}^{\mathrm{T}})$ 和零空间 $\mathcal{N}(\boldsymbol{A})$ 酉正交；当然列空间 $\mathcal{C}(\boldsymbol{A})$ 和左零空间 $\mathcal{N}(\overline{\boldsymbol{A}}^{\mathrm{T}})$ 也酉正交. 矩阵的秩 $r$ 和这些子空间的维数不变.

把 $\boldsymbol{A}^{\mathrm{T}}$ 修改为 $\overline{\boldsymbol{A}}^{\mathrm{T}}$ 后，复矩阵也完美地契合了我们已知的线性代数理论.

现在我们考虑函数空间，对其赋以复内积——类比于复向量的内积（$\bar{x}_k y_k$ 之和），函数 $x(t)$、$y(t)$ 的复内积是 $\bar{x}(t)y(t)$ 的积分. 函数空间最重要的一组基是 $\{e^{inx} : -\infty < n < +\infty\}$，它们是所谓的“Hilbert 空间的傅里叶基”——完备正交基；$e^{ink}$ 和 $e^{ikx}$ 的内积是零：

$$k \neq n \quad \text{时，} \qquad \int_0^{2\pi} e^{ikx} e^{-inx}\,dx = \int_0^{2\pi} e^{i(k-n)x}\,dx = \left.\frac{e^{i(k-n)x}}{i(k-n)}\right|_{x=0}^{x=2\pi} = 0$$

### 6.4.4 $\overline{S}^{\mathrm{T}} = S$：实特征值和酉正交的特征向量

现在我们可以完成 6.3 节预告的重要目标：证明实对称矩阵 $\boldsymbol{S} = \boldsymbol{S}^{\mathrm{T}}$ 的特征值都是实数. 这个结论对复埃米特矩阵 $\boldsymbol{S} = \overline{\boldsymbol{S}}^{\mathrm{T}}$ 也成立，埃米特矩阵的特征值也是实数.

**证明** 设 $\boldsymbol{Sx} = \lambda \boldsymbol{x}$，则 $\overline{\boldsymbol{x}}^{\mathrm{T}}\boldsymbol{Sx} = \lambda \overline{\boldsymbol{x}}^{\mathrm{T}}\boldsymbol{x}$. $\overline{\boldsymbol{x}}^{\mathrm{T}}\boldsymbol{x} = \|\boldsymbol{x}\|^2$ 是正实数；因为 $\overline{\overline{\boldsymbol{x}}^{\mathrm{T}}\boldsymbol{Sx}}^{\mathrm{T}} = \overline{\boldsymbol{x}}^{\mathrm{T}}\overline{\boldsymbol{S}}^{\mathrm{T}}\boldsymbol{x} = \boldsymbol{x}^{\mathrm{T}}\boldsymbol{Sx}$，所以 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{Sx}$ 是实数. 因此，比值

$$\lambda = \frac{\overline{\boldsymbol{x}}^{\mathrm{T}}\boldsymbol{Sx}}{\overline{\boldsymbol{x}}^{\mathrm{T}}\boldsymbol{x}} \qquad \text{是实数.} \tag{6.29}$$

式(6.29)中的比值 $\dfrac{\overline{\boldsymbol{x}}^{\mathrm{T}}\boldsymbol{Sx}}{\overline{\boldsymbol{x}}^{\mathrm{T}}\boldsymbol{x}}$ 称作“**Rayleigh 商**”，其最大值是 $\boldsymbol{S}$ 的最大特征值 $\lambda_{\max}$. Rayleigh 商取最大值的向量 $\boldsymbol{x}$ 是属于 $\lambda_{\max}$ 的特征向量：$\boldsymbol{Sx} = \lambda_{\max}\boldsymbol{x}$. Rayleigh 商的最小值是 $\boldsymbol{S}$ 的最小特征值 $\lambda_{\min}$. $\boldsymbol{S}$ 的中间特征值是式(6.29)中的比值的“鞍点”：在相应点处式(6.29)的一阶导数为零，二阶导数有混合符号.

最后，我们说明 $\boldsymbol{S}$ 有正交的特征向量矩阵，从而 $\boldsymbol{S} = \boldsymbol{Q\Lambda Q}^{-1} = \boldsymbol{Q\Lambda}\overline{\boldsymbol{Q}}^{\mathrm{T}}$. 这需要两步，先得到一个上三角矩阵 $\boldsymbol{T}$，然后得到一个对角矩阵 $\boldsymbol{\Lambda}$.

（1）Schur 定理说明，每个方阵都可以表示成 $\boldsymbol{QT}\overline{\boldsymbol{Q}}^{\mathrm{T}}$ 的形式，其中 $\boldsymbol{T}$ 是上三角矩阵.

（2）如果 $\boldsymbol{S} = \overline{\boldsymbol{S}}^{\mathrm{T}}$，那么 $\boldsymbol{T}$ 是对角矩阵 $\boldsymbol{\Lambda}$（同时也是 $\boldsymbol{S}$ 的特征值矩阵）且 $\boldsymbol{S} = \boldsymbol{Q\Lambda}\overline{\boldsymbol{Q}}^{\mathrm{T}}$.

第（2）点的证明见课后习题.

### 6.4.5 置换矩阵 $P$ 的复特征值和特征向量

下面的置换矩阵 $\boldsymbol{P}$[①]是一个重要的实矩阵. 设 $\lambda$ 是 $\boldsymbol{P}$ 的复特征值，$\boldsymbol{x}$ 是属于 $\lambda$ 的特征向量：

$$\boldsymbol{P} = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 \end{bmatrix}, \qquad \boldsymbol{Px} = \lambda \boldsymbol{x} \quad \text{即} \quad \begin{bmatrix} x_2 \\ x_3 \\ x_4 \\ x_1 \end{bmatrix} = \lambda \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} \tag{6.30}$$

为了求 $\lambda$ 和 $\boldsymbol{x}$，我们从 $x_1$ 开始考虑. 令 $x_1 = 1$，于是 $x_2 = \lambda x_1 = \lambda, x_3 = \lambda x_2 = \lambda^2, x_4 = \lambda x_3 = \lambda^3$，此时最后一个方程 $x_1 = \lambda x_4$ 推出 $1 = \lambda^4$. 该方程有四个解，这四个解就是 $\boldsymbol{P}$ 的特征值，模长都是 1：$|\lambda| = 1$.

$$\det(\boldsymbol{P} - \lambda \boldsymbol{I}) = \lambda^4 - 1, \quad \boldsymbol{P} \text{ 的特征值是 } \lambda = 1, i, (i^2 = -1), (i^3 = -i).$$

① 译者注：作者此处本意应该是特殊的置换矩阵——循环置换，而不是一般的置换矩阵. $n$ 阶置换矩阵未必以 $n$ 阶傅里叶矩阵为特征向量矩阵.

四个特征值相加等于 0，也是 $\boldsymbol{P}$ 的迹；特征多项式的纯虚根 i 和 $-\mathrm{i}$ 是一对共轭的根，完全不出所料. 我们可以选取一个特殊的矩阵作为 $\boldsymbol{P}$ 的特征向量矩阵——傅里叶矩阵 $\boldsymbol{F}=\begin{bmatrix}1&1&1&1\\1&\mathrm{i}&\mathrm{i}^2&\mathrm{i}^3\\1&\mathrm{i}^2&\mathrm{i}^4&\mathrm{i}^6\\1&\mathrm{i}^3&\mathrm{i}^6&\mathrm{i}^9\end{bmatrix}$：

$$\boldsymbol{PF}=\begin{bmatrix}0&1&0&0\\0&0&1&0\\0&0&0&1\\1&0&0&1\end{bmatrix}\begin{bmatrix}1&1&1&1\\1&\mathrm{i}&\mathrm{i}^2&\mathrm{i}^3\\1&\mathrm{i}^2&\mathrm{i}^4&\mathrm{i}^6\\1&\mathrm{i}^3&\mathrm{i}^6&\mathrm{i}^9\end{bmatrix}=\begin{bmatrix}1&1&1&1\\1&\mathrm{i}&\mathrm{i}^2&\mathrm{i}^3\\1&\mathrm{i}^2&\mathrm{i}^4&\mathrm{i}^6\\1&\mathrm{i}^3&\mathrm{i}^6&\mathrm{i}^9\end{bmatrix}\begin{bmatrix}1&&&\\&\mathrm{i}&&\\&&\mathrm{i}^2&\\&&&\mathrm{i}^3\end{bmatrix}=\boldsymbol{F\Lambda}\tag{6.31}$$

更一般地，如果 $\boldsymbol{P}$ 是类似的 $N$ 阶矩阵，那么 $\boldsymbol{P}^N=\boldsymbol{I}$，同理可知它的特征值 $\lambda$ 满足 $\lambda^N=1$. $\boldsymbol{P}$ 的 $N$ 个特征值在单位圆上平均分布，是复数 $\omega=\mathrm{e}^{2\pi\mathrm{i}/N}$ 的幂次，辐角都是 $\dfrac{360^\circ}{N}$（角度制）或者 $\dfrac{2\pi}{N}$（弧度制）的倍数：

$$\lambda^N=1\text{ 的解是 }\lambda=\omega,\omega^2,\cdots,\omega^{N-1},1,\text{ 其中 }\omega=\mathrm{e}^{2\pi\mathrm{i}/N}.\tag{6.32}$$

在复平面上，第一个特征值是 $\mathrm{e}^{\mathrm{i}\theta}=\cos\theta+\mathrm{i}\sin\theta$，其中辐角 $\theta=2\pi/N$；其他特征值的辐角分别是：$2\theta,3\theta,\cdots,N\theta$. 由于 $\theta=2\pi/N$，最后一个特征值的辐角是 $N\theta=2\pi$，所以最后一个特征值是 $\mathrm{e}^{2\pi\mathrm{i}}=\cos2\pi+\mathrm{i}\sin2\pi=1$. 傅里叶矩阵 $\boldsymbol{F}_8$ 是 8 阶方阵，列向量都是置换矩阵 $\boldsymbol{P}_8$ 的特征向量. 如果我们按照工程师的习惯，从 0 到 7 来标记行和列（即从 0 开始），那么置换矩阵 $\boldsymbol{P}_8$ 的特征值（见图 6.10）$\lambda_k=\omega^k$ 就是 $\lambda_0$ 到 $\lambda_7$. 傅里叶矩阵 $\boldsymbol{F}_N$（即 $N$ 阶循环置换矩阵 $\boldsymbol{P}_N$ 的特征向量矩阵）在第 $j$ 行、第 $k$ 列的元素是 $\omega^{jk}$.

$\boldsymbol{F}_N$ 的列向量是 $\boldsymbol{P}_N$ 的特征向量，互相酉正交：$\overline{\boldsymbol{F}}_N^{\mathrm{T}}\boldsymbol{F}_N=N\boldsymbol{I}$.

**证明**　[证法 1.] 置换矩阵 $\boldsymbol{P}_N$ 是正交矩阵，所以它属于不同特征值的特征向量两两正交.

**证明**　[证法 2.] 这些向量 $\boldsymbol{q}_j$ 都是复向量，所以验证正交性即验证 $j\neq k$ 时 $\overline{\boldsymbol{q}}_j^{\mathrm{T}}\boldsymbol{q}_k=0$:

$$\boldsymbol{P}_8=\begin{bmatrix}0&1&&&&&&\\&0&1&&&&&\\&&0&1&&&&\\&&&0&1&&&\\&&&&0&1&&\\&&&&&0&1&\\&&&&&&0&1\\1&&&&&&&0\end{bmatrix}$$

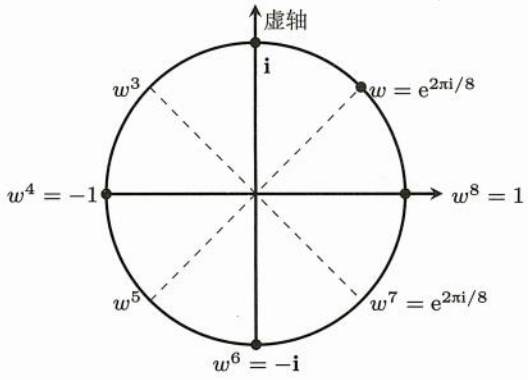


图 6.10　$\boldsymbol{P}_8$ 的特征值

注：$\boldsymbol{P}_8$ 的特征值是 $\omega=\mathrm{e}^{2\pi/8}$ 的 8 个方幂，这 8 个数两两抵消，总和为零.

$$\begin{bmatrix} 1 \\ \overline{\omega}^{j} \\ \cdots \\ \overline{\omega}^{(N-1)j} \end{bmatrix} \cdot \begin{bmatrix} 1 \\ \omega^{k} \\ \cdots \\ \omega^{(N-1)k} \end{bmatrix} = 1 + a + \cdots + a^{N-1} = \frac{a^N - 1}{a - 1}$$

这里 $a = \overline{\omega}^{j}\omega^{k}$. 若 $j = k$，则 $a = 1$，所以 $\boldsymbol{F}_N$ 的每一个列向量和自身的内积（即长度的平方）都是 $N$. 若 $j \neq k$，则 $a \neq 1$ 且 $a^N = \overline{\omega}^{Nj}\omega^{Nk} = 1$，所以上述求和式为零. 这就说明傅里叶矩阵 $\boldsymbol{F}_N$ 是列正交矩阵.

### 6.4.6 所有循环矩阵 $C$ 有相同的傅里叶特征向量

$\boldsymbol{P}$ 同 6.4.5 节. 设 $\boldsymbol{P}\boldsymbol{x} = \lambda\boldsymbol{x}$，那么 $\boldsymbol{P}^2\boldsymbol{x} = \lambda^2\boldsymbol{x}$，这说明 $\boldsymbol{P}$ 的特征向量也是 $\boldsymbol{P}^2$ 的特征向量. 等式两边再左乘 $\boldsymbol{P}$ 得 $\boldsymbol{P}^3\boldsymbol{x} = \lambda^3\boldsymbol{x}$，所以 $\boldsymbol{x}$ 也是 $\boldsymbol{P}^3$ 的特征向量. 对傅里叶矩阵 $\boldsymbol{F}$ 的列向量 $\boldsymbol{x}$ 和任意正整数 $n$，都有 $\boldsymbol{P}^n\boldsymbol{x} = \lambda^n\boldsymbol{x}$.

不仅如此，$\boldsymbol{P}$ 的多项式 $\boldsymbol{C} = c_0\boldsymbol{I} + c_1\boldsymbol{P} + c_2\boldsymbol{P}^2 + c_3\boldsymbol{P}^3$ 都以 $\boldsymbol{x}$ 为特征向量：$\boldsymbol{C}\boldsymbol{x} = (c_0 + c_1\lambda + c_2\lambda^2 + c_3\lambda^3)\boldsymbol{x}$. 这样的矩阵 $\boldsymbol{C}$ 称作循环矩阵:

$$\boldsymbol{C} = \begin{bmatrix} c_0 & c_1 & c_2 & c_3 \\ c_3 & c_0 & c_1 & c_2 \\ c_2 & c_3 & c_0 & c_1 \\ c_1 & c_2 & c_3 & c_0 \end{bmatrix}, \quad \boldsymbol{C}\boldsymbol{x} = \begin{bmatrix} c_0 & c_1 & c_2 & c_3 \\ c_3 & c_0 & c_1 & c_2 \\ c_2 & c_3 & c_0 & c_1 \\ c_1 & c_2 & c_3 & c_0 \end{bmatrix} \begin{bmatrix} 1 \\ \mathrm{i} \\ \mathrm{i}^2 \\ \mathrm{i}^3 \end{bmatrix} = (c_0 + c_1\mathrm{i} + c_2\mathrm{i}^2 + c_3\mathrm{i}^3) \begin{bmatrix} 1 \\ \mathrm{i} \\ \mathrm{i}^2 \\ \mathrm{i}^3 \end{bmatrix} \tag{6.33}$$

$\boldsymbol{C}$ 的具体形式如上，顾名思义，“循环矩阵”指的是 $\boldsymbol{C}$ 内部的元素呈现一种循环的形式. 主对角线是 $c_0\boldsymbol{I}$，主对角线上方的是 $c_1\boldsymbol{P}$，那一条对角线环绕到矩阵的左下角；上三角部分的元素都会绕到下三角部分.[①] $\boldsymbol{x} = \begin{bmatrix} 1 & \mathrm{i} & \mathrm{i}^2 & \mathrm{i}^3 \end{bmatrix}^{\mathrm{T}}$ 是 $\boldsymbol{P}$ 的特征向量：$\boldsymbol{P}\boldsymbol{x} = \lambda\boldsymbol{x} = \mathrm{i}\boldsymbol{x}$，同时也是 $\boldsymbol{C}$ 的特征向量. 事实上，傅里叶矩阵 $\boldsymbol{F}$ 的列向量都是 $\boldsymbol{P}$ 的特征向量，也是 $\boldsymbol{C}$ 的特征向量.

总而言之，所有的循环矩阵 $\boldsymbol{C}$ 有公共的特征向量——傅里叶矩阵 $\boldsymbol{F}$ 的列向量，也就是说，$\boldsymbol{C}\boldsymbol{F} = \boldsymbol{F}\boldsymbol{\Lambda}$，其中 $\boldsymbol{\Lambda}$ 是对角矩阵. 所有循环矩阵被傅里叶矩阵 $\boldsymbol{F}$ 同时对角化，特征值矩阵 $\boldsymbol{\Lambda}$ 由 $\boldsymbol{C}$ 的所有特征值构成，这四个特征值即 $c_0 + c_1\lambda + c_2\lambda^2 + c_3\lambda^3$ 在 $\lambda = 1, \mathrm{i}, \mathrm{i}^2, \mathrm{i}^3$ 时的四个取值.

### 6.4.7 快速傅里叶变换

向量 $\boldsymbol{x}$ 的离散傅里叶变换（DFT）是向量 $\overline{\boldsymbol{F}}\boldsymbol{x}$. 当信号为 $\boldsymbol{x}$ 时，在频域空间中，它被表示为 $\overline{\boldsymbol{F}}\boldsymbol{x}$. 这一步使用了快速傅里叶变换（FFT），也是现代实现信号处理的快速乘法的关键.

FFT 的关键在于对 $\boldsymbol{F}_N$ 进行矩阵分解. 设 $N = 2n$ 是偶数，则其可以分解成三个矩阵的乘积，中间的因子包含两个 $\boldsymbol{F}_n$，计算量几乎减半了——因为第一个因子只包含对角子块，而第三个因子仅仅是一个置换. 以下是 FFT 中的一个步骤：

三个因子

$$\boldsymbol{F}_N = \begin{bmatrix} \boldsymbol{I} & \boldsymbol{B} \\ \boldsymbol{I} & -\boldsymbol{B} \end{bmatrix} \begin{bmatrix} \boldsymbol{F}_n & \\ & \boldsymbol{F}_n \end{bmatrix} \boldsymbol{P}_N \tag{6.34}$$

① 译者注：作者的这种描述简直是佶屈聱牙，“循环矩阵”的循环很好懂，观察每一行和下一行之间元素的排布，一眼就能看出来；看两眼都是对这种明显事实的不尊重.

其中，$\boldsymbol{B}$ 是对角矩阵，对角元是 $1,\omega_n,\omega_n^2,\cdots,\omega_n^{n-1}$（$\omega_n=\mathrm{e}^{\mathrm{i}\frac{2\pi}{n}}$）；$\boldsymbol{P}_N$ 是 $(1,1),(2,3),\cdots,(n,N-1)$，$(n+1,2),(n+2,4)\cdots,(N,N)$ 位置是 1、其余位置是 0 的转置矩阵. 最简单的例子是 $N=4$：[①]

$$\begin{bmatrix}1&1&1&1\\1&\mathrm{i}&\mathrm{i}^2&\mathrm{i}^3\\1&\mathrm{i}^2&\mathrm{i}^4&\mathrm{i}^6\\1&\mathrm{i}^3&\mathrm{i}^6&\mathrm{i}^9\end{bmatrix}=\begin{bmatrix}1&0&1&0\\0&1&0&\mathrm{i}\\1&0&-1&0\\0&1&0&-\mathrm{i}\end{bmatrix}\begin{bmatrix}1&-1&0&0\\1&-1&0&0\\0&0&1&-1\\0&0&1&-1\end{bmatrix}\begin{bmatrix}1&0&0&0\\0&0&1&0\\0&1&0&0\\0&0&0&1\end{bmatrix}\tag{6.35}$$

$\boldsymbol{F}_4$ 的分解式中有两个 $\boldsymbol{F}_2$ 和两个 $\boldsymbol{B}_2$. 我们以 $\boldsymbol{F}_{1024}\boldsymbol{x}$ 为例说明快速傅里叶变换是如何起作用的. 正常的矩阵和向量相乘，需要做 $(1024)^2$ 次数字的乘法——已经超过一百万次了. 式(6.34)中的第一个因子从 $\boldsymbol{B}$ 出发，只需要 $N$ 次乘法. 第三个因子只是在置换，没有乘法运算. 中间包含 $\boldsymbol{F}_{512}$ 的因子可以再被简化为四个 $\boldsymbol{F}_{256}$，然后再简化为 8 个 $\boldsymbol{F}_{128}$，逐步递归.

最终，需要计算的是一些对角矩阵 $\boldsymbol{B}$——因为 $1024=2^{10}$，一共 10 个矩阵. 快速傅里叶变换大约需要 $1024\times 10=N\log_2 N$ 次复数乘法，而不是 $N^2$ 次.

$N=1024$ 时，原先的一百多万次乘法减少了接近 99%. 实际应用中，可能需要调整 $\boldsymbol{F}$ 和 $\boldsymbol{x}$，把 $N$ 取为 2 的幂. 维基百科对乘法和加法的次数进行了更仔细的计算. 快速傅里叶变换有许多变种——这源于 $\boldsymbol{F}$ 内部具有的特殊且优美的形式.

### 6.4.8　循环矩阵相乘 $\boldsymbol{CD}=\boldsymbol{DC}$

把 $\boldsymbol{C}=2\boldsymbol{I}+\boldsymbol{P}+3\boldsymbol{P}^3$ 和 $\boldsymbol{D}=3\boldsymbol{I}+\boldsymbol{P}+\boldsymbol{P}^2+4\boldsymbol{P}^3$ 相乘，其难度大约相当于三年级计算 $c=3012$ 和 $d=4113$ 相乘. 其中的区别是从十进制变成了 $\boldsymbol{P}^4=\boldsymbol{I}$:

| | | | | | | |
|---|---|---|---|---|---|---|
| | | | 3 | 0 | 1 | 2 |
| | | | 4 | 1 | 1 | 3 |
| | | | 9 | 0 | 3 | 6 |
| | | 3 | 0 | 1 | 2 | |
| | 3 | 0 | 1 | 2 | | |
| 12 | 0 | 4 | 8 | | | |
| **12** | **3** | **7** | **18** | **3** | **5** | **6** |

$$\begin{aligned}\boldsymbol{CD}&=6\boldsymbol{I}+5\boldsymbol{P}+3\boldsymbol{P}^2+18\boldsymbol{P}^3+7\boldsymbol{P}^4+3\boldsymbol{P}^5+12\boldsymbol{P}^6\\&=(6+7)\boldsymbol{I}+(5+3)\boldsymbol{P}+(3+12)\boldsymbol{P}^2+18\boldsymbol{P}^3\\&=13\boldsymbol{I}+(5+3)\boldsymbol{P}+(3+12)\boldsymbol{P}^2+18\boldsymbol{P}^3\end{aligned}$$

矩阵乘法 $\boldsymbol{CD}=$ 卷积 $c\circledast d$

这里有两个值得注意的点：一是为了和右侧作对比，左侧的 18 并没有按照十进制的规则进位；二是我们把 $\boldsymbol{P}^4$、$\boldsymbol{P}^5$、$\boldsymbol{P}^6$ 分别替换成了 $\boldsymbol{I}$、$\boldsymbol{P}$、$\boldsymbol{P}^2$. 这种“向量乘法”被称作循环卷积：

$$\boxed{c\circledast d=(2,1,0,3)\circledast(3,1,1,4)=(13,8,15,18)=d\circledast c}\tag{6.36}$$

如果利用 $\boldsymbol{P}^4=\boldsymbol{I}$ 计算 $\boldsymbol{DC}$，那么会得到相同的结果.

如果 $\boldsymbol{P}$ 已经明确了，那就没有必要一直重复写 $\boldsymbol{P}$；循环矩阵 $\boldsymbol{CD}=\boldsymbol{DC}$ 用 $\boldsymbol{P}$ 的幂次展开的系数是 13、8、15、18.

① 译者注：有读者要“抬杠”了，明明最简单的例子是 $N=2$；但是 $N=2$ 的情况太简单了，没办法说明问题，所以是个无效的例子.

$$\boldsymbol{CD}=\begin{bmatrix}\mathbf{2}&\mathbf{1}&\mathbf{0}&\mathbf{3}\\3&2&1&0\\0&3&2&1\\1&0&3&2\end{bmatrix}\begin{bmatrix}\mathbf{3}&\mathbf{1}&\mathbf{1}&\mathbf{4}\\4&3&1&1\\1&4&3&1\\1&1&4&3\end{bmatrix}=\begin{bmatrix}\mathbf{13}&\mathbf{8}&\mathbf{15}&\mathbf{18}\\18&13&8&15\\15&18&13&8\\8&15&18&13\end{bmatrix}=\boldsymbol{DC}\tag{6.37}$$

通常的卷积是 $c*d=(2,1,0,3)*(3,1,1,4)=(6,5,3,18,7,3,12)$，相当于把 $c$、$d$ 两个 3 次多项式（4 个系数）相乘，其结果是 6 次多项式（7 个系数）. 那么利用 $\boldsymbol{P}^4=\boldsymbol{I}$，$c*d$ 就变成了 $c\circledast d$.

### 6.4.9 信号处理中的卷积

给定循环矩阵 $\boldsymbol{C}$，设 $\boldsymbol{c}^{\mathrm{T}}$ 是它的第一行，$\lambda_0,\lambda_1,\cdots,\lambda_{N-1}$ 是它的特征值. 对 $\boldsymbol{C}$ 作相似对角化，有 $\boldsymbol{CF}=\boldsymbol{F\Lambda}$，该等式左边第 1 行第 $k$ 列元素为 $c_0+c_1\omega^k+\cdots+c_{N-1}\omega^{k(N-1)}$，右边第一行第 $k$ 列是 $\lambda_k$，所以

$$\begin{bmatrix}\lambda_0\\\lambda_1\\\vdots\\\lambda_{N-1}\end{bmatrix}=\begin{bmatrix}c_0+c_1+\cdots+c_{N-1}\\c_0+c_2\omega+\cdots+c_{N-1}\omega^{N-1}\\\vdots\\c_0+c_1\omega^{N-1}+\cdots+c_{N-1}\omega^{(N-1)(N-1)}\end{bmatrix}=\boldsymbol{F}\begin{bmatrix}c_0\\c_1\\\vdots\\c_{N-1}\end{bmatrix}=\boldsymbol{Fc}.\tag{6.38}$$

$N=2$ 时，$\omega=\mathrm{e}^{2\pi\mathrm{i}/N}=-1$，

$$\boldsymbol{F}=\begin{bmatrix}1&1\\1&-1\end{bmatrix}\qquad\boldsymbol{C}=\begin{bmatrix}c_0&c_1\\c_1&c_0\end{bmatrix}\qquad\begin{bmatrix}\lambda_0(\boldsymbol{C})\\\lambda_1(\boldsymbol{C})\end{bmatrix}=\begin{bmatrix}c_0+c_1\\c_0-c_1\end{bmatrix}=\begin{bmatrix}1&1\\1&-1\end{bmatrix}\begin{bmatrix}c_0\\c_1\end{bmatrix}=\boldsymbol{Fc}\tag{6.39}$$

另一方面，记 $\boldsymbol{F}=\begin{bmatrix}\boldsymbol{q}_0&\cdots&\boldsymbol{q}_{N-1}\end{bmatrix}$，那么 $\boldsymbol{q}_0,\boldsymbol{q}_1,\cdots,\boldsymbol{q}_{N-1}$ 是 $\boldsymbol{C}$、$\boldsymbol{D}$ 和 $\boldsymbol{CD}$ 共同的特征向量，$\boldsymbol{CD}$ 的特征值就是 $\boldsymbol{C}$ 和 $\boldsymbol{D}$ 的特征值相乘：$\boldsymbol{CD}\boldsymbol{q}_i=\boldsymbol{C}\lambda_i(\boldsymbol{D})\boldsymbol{q}_i=\lambda_i(\boldsymbol{C})\lambda_i(\boldsymbol{D})\boldsymbol{q}_i$. 我们用 $.*$ 来表达这个事实：

$$\begin{bmatrix}\lambda_0(\boldsymbol{CD})\\\lambda_1(\boldsymbol{CD})\\\vdots\end{bmatrix}=\begin{bmatrix}\lambda_0(\boldsymbol{C})\lambda_0(\boldsymbol{D})\\\lambda_1(\boldsymbol{C})\lambda_1(\boldsymbol{D})\\\vdots\end{bmatrix}=\begin{bmatrix}\lambda_0(\boldsymbol{C})\\\lambda_1(\boldsymbol{C})\\\vdots\end{bmatrix}.*\begin{bmatrix}\lambda_0(\boldsymbol{D})\\\lambda_1(\boldsymbol{D})\\\vdots\end{bmatrix}\tag{6.40}$$

**$.*$ 被称作阿达玛乘积，它的运算法则是把两个向量的分量各自相乘.** 根据式(6.37)，$\boldsymbol{CD}$ 也是循环矩阵，其第一行是 $\boldsymbol{c}\circledast\boldsymbol{d}$. 再用式(6.38)，把 $\boldsymbol{Fc}$ 和 $\boldsymbol{Fd}$ 和 $\boldsymbol{F}(\boldsymbol{c}\circledast\boldsymbol{d})$ 代入式(6.40)，我们就得到了用以简化信号处理的极为优美的结果：

向量卷积和傅里叶变换的相容性 $\boxed{\boldsymbol{F}(\boldsymbol{c}\circledast\boldsymbol{d})=(\boldsymbol{Fc}).*(\boldsymbol{Fd})}$ (6.41)

$\boldsymbol{CD}$ 是以 $\boldsymbol{c}\circledast\boldsymbol{d}$ 为第一行的循环矩阵，特征值是 $(\boldsymbol{Fc}).*(\boldsymbol{Fd})$ 的各个分量.

## 习题 6.4

1. 设 $z=1-\mathrm{i}$，求 $\bar{z},r=|z|,1/z$ 和辐角 $\theta$.

2. 求埃米特矩阵 $\boldsymbol{S}=\begin{bmatrix}1&1+\mathrm{i}\\1-\mathrm{i}&2\end{bmatrix}$ 的特征值和特征向量.

3. 如果 $\overline{\boldsymbol{Q}}^{\mathrm{T}}\boldsymbol{Q}=\boldsymbol{I}$（即 $\boldsymbol{Q}$ 是酉矩阵，或者说复正交矩阵），$\boldsymbol{Q}\boldsymbol{x}=\lambda\boldsymbol{x}$，证明：$|\lambda|=1$.

4. 求三阶傅里叶矩阵 $\boldsymbol{F}_3$，它的列向量是 $\begin{bmatrix}0&1&0\\0&0&1\\1&0&0\end{bmatrix}$ 的两两正交的特征向量.

5.（尝试一下）按照式(6.35)，把六阶傅里叶矩阵 $\boldsymbol{F}_6$ 和三阶傅里叶矩阵 $\boldsymbol{F}_3$ 联系起来.

6. 如式(6.37)所示，将首行分别为 $1,1,1$ 和 $1,2,1$ 的两个 3 阶循环矩阵 $\boldsymbol{C}$ 和 $\boldsymbol{D}$ 相乘. 先计算 111 与 121 的乘积，然后基于 $\boldsymbol{P}^3=\boldsymbol{I}$ 将得到的 5 个数减少到 3 个数，由此求出这两个向量的循环卷积.

7. 令 $\boldsymbol{c}=\begin{bmatrix}1&1&1\end{bmatrix}^{\mathrm{T}},\boldsymbol{d}=\begin{bmatrix}1&2&1\end{bmatrix}^{\mathrm{T}}$，$\boldsymbol{F}_3$ 是 3 阶傅里叶矩阵，$\omega^3=1$. 对这些向量和矩阵，验证式(6.41)的卷积运算法则.

8. 已知 $\mathrm{e}^{\mathrm{i}\theta}\approx 1+\mathrm{i}\theta+\frac{1}{2}(\mathrm{i}\theta)^2+\frac{1}{6}(\mathrm{i}\theta)^3,\cos\theta\approx 1-\frac{1}{2}\theta^2,\sin\theta\approx\theta-\frac{1}{6}\theta^3$，验证 Euler 公式：$\mathrm{e}^{\mathrm{i}\theta}=\cos\theta+\mathrm{i}\sin\theta$.①

9. 用 Euler 公式和 $(\mathrm{e}^{\mathrm{i}\theta})(\mathrm{e}^{\mathrm{i}\theta})=\mathrm{e}^{2\mathrm{i}\theta}$，把 $\cos 2\theta$ 和 $\sin 2\theta$ 都用 $\cos\theta$、$\sin\theta$ 表示出来.②

10. 如何判断循环矩阵 $\boldsymbol{C}$ 是否可逆？如果 $\boldsymbol{C}$ 可逆，那么 $\boldsymbol{C}^{-1}$ 是否也是循环矩阵？为什么？

11. 满足什么条件时，一个循环矩阵是另一个循环矩阵的平方？

12. 循环矩阵 $\boldsymbol{C}$ 何时是埃米特矩阵（$\overline{\boldsymbol{C}}^{\mathrm{T}}=\boldsymbol{C}$）？何时是酉矩阵（$\overline{\boldsymbol{C}}^{\mathrm{T}}=\boldsymbol{C}^{-1}$）？

13. 求向量 $\boldsymbol{x}=\begin{bmatrix}1&0&1&0\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}0&1&0&1\end{bmatrix}^{\mathrm{T}}$ 的离散傅里叶变换 $\boldsymbol{F}\boldsymbol{x}$.

14. 设 $\omega=\mathrm{e}^{2\pi\mathrm{i}/64}$，那么 $\omega^2$ 和 $\sqrt{\omega}$ 分别是 1 的_____ 次和_____ 次方根.

15. 求如下 2 阶循环差分矩阵 $\boldsymbol{C}$ 的特征值：

$$\boldsymbol{C}=\begin{bmatrix}2&-1&0&-1\\-1&2&-1&0\\0&-1&2&-1\\-1&0&-1&2\end{bmatrix}=2\boldsymbol{I}-\boldsymbol{P}-\boldsymbol{P}^3.$$

## 6.5　解线性微分方程

（1）如果 $\boldsymbol{A}\boldsymbol{x}=\lambda\boldsymbol{x}$，则 $\boldsymbol{u}(t)=\mathrm{e}^{\lambda t}\boldsymbol{x}$ 是方程组 $\dfrac{\mathrm{d}\boldsymbol{u}}{\mathrm{d}t}=\boldsymbol{A}\boldsymbol{u}$ 的解. 每一组 $\lambda$ 和 $\boldsymbol{x}$ 都给出一个解 $\mathrm{e}^{\lambda t}\boldsymbol{x}$.

（2）如果 $\boldsymbol{A}=\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1}$，则方程组 $\dfrac{\mathrm{d}\boldsymbol{u}}{\mathrm{d}t}=\boldsymbol{A}\boldsymbol{u}$ 的通解是

$$\boxed{\boldsymbol{u}(t)=\mathrm{e}^{\boldsymbol{A}t}\boldsymbol{u}(0)=\boldsymbol{X}\mathrm{e}^{\boldsymbol{\Lambda}t}\boldsymbol{X}^{-1}\boldsymbol{u}(0)=c_1\mathrm{e}^{\lambda_1 t}\boldsymbol{x}_1+c_2\mathrm{e}^{\lambda_2 t}\boldsymbol{x}_2+\cdots+c_n\mathrm{e}^{\lambda_n t}\boldsymbol{x}_n.}$$

① 译者注：这里说的验证不是给严格的证明，而是验证等式两边级数的前几项相同. 在实际应用中，控制级数的项数实际上就是控制误差的精度. 只要误差远小于实际工程所需的精度，那么应用中就可以认为两者相同.

② 译者注：说白了就是用欧拉公式证明二倍角公式：$\cos 2\theta=\cos^2\theta-\sin^2\theta,\sin 2\theta=2\sin\theta\cos\theta$.

（3）矩阵的指数函数：$e^{\boldsymbol{A}t}=\boldsymbol{I}+\boldsymbol{A}t+\cdots+\dfrac{(\boldsymbol{A}t)^n}{n!}+\cdots$；当 $\boldsymbol{A}=\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1}$ 时，$e^{\boldsymbol{A}t}=\boldsymbol{X}e^{\boldsymbol{\Lambda}t}\boldsymbol{X}^{-1}$.

（4）当 $\boldsymbol{A}$ 的所有特征值的实部均小于零时，$\boldsymbol{A}$ 是稳定的，且 $u(t)\to\boldsymbol{0}, e^{\boldsymbol{A}t}\to\boldsymbol{0}$.

（5）二阶微分方程可以转化为一阶微分方程组：$u''+\boldsymbol{B}u'+\boldsymbol{C}u=\boldsymbol{0}$ 等价于 $\begin{bmatrix}u\\u'\end{bmatrix}'=\begin{bmatrix}0&1\\-C&-B\end{bmatrix}\begin{bmatrix}u\\u'\end{bmatrix}$.

特征值、特征向量以及相似对角化分解式 $\boldsymbol{A}=\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1}$ 在计算矩阵幂 $\boldsymbol{A}^k$ 时表现优异. 它们同样适用于解微分方程 $\mathrm{d}\boldsymbol{u}/\mathrm{d}t=\boldsymbol{A}\boldsymbol{u}$. 本节内容虽然主要着眼点是线性代数，但要理解它，需要掌握微积分中的一个基本事实：$e^{\lambda t}$ 的导数是 $\lambda e^{\lambda t}$. 本节的要点是：常系数微分方程可以转化为线性代数问题. 单个方程式(6.42)和式(6.43)中方程组 $\mathrm{d}\boldsymbol{u}/\mathrm{d}t=\boldsymbol{A}\boldsymbol{u}$ 均适用.

通常的微分方程 $\dfrac{\mathrm{d}u}{\mathrm{d}t}=u$ 和 $\dfrac{\mathrm{d}u}{\mathrm{d}t}=\lambda u$ 的解都是指数函数：

$$\boxed{\frac{\mathrm{d}u}{\mathrm{d}t}=u \quad \text{的解是} \quad u(t)=Ce^{t}, \qquad \frac{\mathrm{d}u}{\mathrm{d}t}=\lambda u \quad \text{的解是} \quad u(t)=Ce^{\lambda t}.} \tag{6.42}$$

其中，$C$ 是任意常数. 时间 $t=0$ 时，两个方程的解都推出 $u(0)=C$，所以我们称之为初值为 $C$ 的微分方程. 换言之，$t=0$ 时初值为 $u(0)$ 的上述两个方程的解分别是 $u(t)=u(0)e^{t}$ 和 $u(t)=u(0)e^{\lambda t}$.

我们处理了单个函数的问题，对应矩阵是 $1\times1$ 阶矩阵. 线性代数可以处理 $n\times n$ 矩阵，那么未知函数实际上应该是向量值函数 $\boldsymbol{u}(t)$——由 $n$ 个关于 $t$ 的函数构成的列向量. 根据经验，我们需要定好初值 $\boldsymbol{u}(0)$. 单个方程也变为 $n$ 个方程构成的方程组，其系数矩阵记为 $\boldsymbol{A}$. $\boldsymbol{A}$ 的 $n$ 个特征值 $\boldsymbol{A}\boldsymbol{x}=\lambda\boldsymbol{x}$ 给出方程组的 $n$ 个解：$\boldsymbol{u}(t)=\boldsymbol{u}(0)e^{\lambda t}\boldsymbol{x}$：

$n$个微分方程构成的方程组　以 $\boldsymbol{u}(0)=\begin{bmatrix}u_1(0)\\\vdots\\u_n(0)\end{bmatrix}$ 为初值的微分方程组 $\boxed{\dfrac{\mathrm{d}\boldsymbol{u}}{\mathrm{d}t}=\boldsymbol{A}\boldsymbol{u}}$ (6.43)

该微分方程是线性的. 如果 $\boldsymbol{u}(t)$ 和 $\boldsymbol{v}(t)$ 是解，那么 $C\boldsymbol{u}(t)+D\boldsymbol{v}(t)$ 也是解. 我们需要 $n$ 个像 $C$ 和 $D$ 这样的常数来匹配在初始时刻 $\boldsymbol{u}(0)$ 的 $n$ 个分量. 但是首要任务是先用 $\boldsymbol{A}\boldsymbol{x}=\lambda\boldsymbol{x}$ 求出 $n$ 个“纯指数函数解” $\boldsymbol{u}=e^{\lambda t}\boldsymbol{x}$.

请注意，此处 $\boldsymbol{A}$ 是常数矩阵. 在其他一些线性方程中，$\boldsymbol{A}$ 本身也会随着 $t$ 的变化而变化. 若 $\boldsymbol{A}$ 随着 $\boldsymbol{u}$ 的变化而变化，这样的方程组被称作非线性微分方程（组）. 我们不涉及这种困难的方程组，本节考虑的方程组 $\mathrm{d}\boldsymbol{u}/\mathrm{d}t=\boldsymbol{A}\boldsymbol{u}$ 都是“常系数线性方程”. 只有这类方程才是我们直接转换为线性代数的微分方程.

当 $\boldsymbol{A}\boldsymbol{x}=\lambda\boldsymbol{x}$ 时，通过指数函数 $\boldsymbol{u}=e^{\lambda t}\boldsymbol{x}$ 来求解常系数线性方程.

### 6.5.1 $\mathrm{d}\boldsymbol{u}/\mathrm{d}t=\boldsymbol{A}\boldsymbol{u}$ 的解

对于微分方程组，纯指数解指的是形如 $e^{\lambda t}\boldsymbol{x}$ 的解，其中 $\boldsymbol{x}$ 是向量. 很自然地，我们可以猜测

$\lambda$ 是 $\boldsymbol{A}$ 的特征值，$\boldsymbol{x}$ 是属于 $\lambda$ 的特征向量. 所谓“大胆猜想，小心求证”，把 $\boldsymbol{u}(t)=\mathrm{e}^{\lambda t}\boldsymbol{x}$ 代入方程 $\mathrm{d}\boldsymbol{u}/\mathrm{d}t=\boldsymbol{A}\boldsymbol{u}$，因子 $\mathrm{e}^{\lambda t}$ 可以被消掉，剩下的是 $\lambda\boldsymbol{x}=\boldsymbol{A}\boldsymbol{x}$，这说明上述猜测完全正确！

$$\text{当 } \boldsymbol{A}\boldsymbol{x}=\lambda\boldsymbol{x} \text{ 时}\quad \text{选取 } \boldsymbol{u}=\mathrm{e}^{\lambda t}\boldsymbol{x} \qquad \boxed{\frac{\mathrm{d}\boldsymbol{u}}{\mathrm{d}t}=\lambda\mathrm{e}^{\lambda t}\boldsymbol{x}} \quad \text{和} \quad \boxed{\boldsymbol{A}\boldsymbol{u}=\boldsymbol{A}\mathrm{e}^{\lambda t}\boldsymbol{x}} \quad \text{一致} \tag{6.44}$$

这个特殊的解 $\boldsymbol{u}=\mathrm{e}^{\lambda t}\boldsymbol{x}$ 的每个分量都有相同的 $\mathrm{e}^{\lambda t}$ 这个因子. 若 $\lambda>0$，该解随着 $t$ 的增长而增长；若 $\lambda<0$，则随着 $t$ 的增长而衰减. 如果 $\lambda$ 不是实数，复数 $\lambda$ 的实部决定了方程的解是随着时间增长的还是衰减，虚部 $\omega$ 赋予了 $\mathrm{e}^{\mathrm{i}\omega t}$ 类似于正弦波的振荡性.

**例 6.12**　设初值 $\boldsymbol{u}(0)=\begin{bmatrix}4\\2\end{bmatrix}$，解微分方程 $\dfrac{\mathrm{d}\boldsymbol{u}}{\mathrm{d}t}=\boldsymbol{A}\boldsymbol{u}=\begin{bmatrix}0&1\\1&0\end{bmatrix}\boldsymbol{u}$.

这是关于向量函数 $\boldsymbol{u}$ 的方程，由两个标量函数 $y$、$z$ 构成，于是原方程可以写成关于 $y$、$z$ 的方程组. 因为系数矩阵 $\boldsymbol{A}$ 并非对角矩阵，所以这两个函数是“耦合”在一起的：

$$\frac{\mathrm{d}\boldsymbol{u}}{\mathrm{d}t}=\boldsymbol{A}\boldsymbol{u} \qquad \frac{\mathrm{d}}{\mathrm{d}t}\begin{bmatrix}y\\z\end{bmatrix}=\begin{bmatrix}0&1\\1&0\end{bmatrix}\begin{bmatrix}y\\z\end{bmatrix} \qquad \Longrightarrow \qquad \frac{\mathrm{d}y}{\mathrm{d}t}=z,\frac{\mathrm{d}z}{\mathrm{d}t}=y.$$

特征向量的思路就是把方程进行适当的线性组合，约化为关于单个标量函数的问题. 这个例子中，$y+z$ 和 $y-z$ 就很合适；把两个方程相加和相减：

$$\frac{\mathrm{d}}{\mathrm{d}t}(y+z)=(z+y) \qquad \frac{\mathrm{d}}{\mathrm{d}t}(y-z)=-(y-z).$$

所以 $y+z$ 类似于 $\mathrm{e}^{t}$ 那样增长，因为它对应于 $\lambda=1$；组合 $y-z$ 类似于 $\mathrm{e}^{-t}$ 那样衰减，因为它对应于 $\lambda=-1$. 需要说明的是，处理问题的要点是：不必盲目地拼凑原始方程 $\mathrm{d}\boldsymbol{u}/\mathrm{d}t=\boldsymbol{A}\boldsymbol{u}$ 的特殊组合，而是利用 $\boldsymbol{A}$ 的特征向量和特征值来完成这项工作.

矩阵 $\boldsymbol{A}$ 的特征值为 $\lambda_1=1$ 和 $\lambda_2=-1$，$\boldsymbol{x}_1=\begin{bmatrix}1&1\end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{x}_2=\begin{bmatrix}1&-1\end{bmatrix}^{\mathrm{T}}$ 分别是属于这两个特征值的特征向量，从而 $\boldsymbol{u}_1=\mathrm{e}^{\lambda_1 t}\boldsymbol{x}_1,\boldsymbol{u}_2=\mathrm{e}^{\lambda_2 t}\boldsymbol{x}_2$ 是 $\mathrm{d}\boldsymbol{u}/\mathrm{d}t=\boldsymbol{A}\boldsymbol{u}$ 的两个纯指数解：

$$\boxed{\boldsymbol{u}_1=\mathrm{e}^{\lambda_1 t}\boldsymbol{x}_1=\mathrm{e}^{t}\begin{bmatrix}1\\1\end{bmatrix}} \quad \text{以及} \quad \boxed{\boldsymbol{u}_2=\mathrm{e}^{\lambda_2 t}\boldsymbol{x}_2=\mathrm{e}^{-t}\begin{bmatrix}1\\-1\end{bmatrix}} \tag{6.45}$$

完整解 $\boldsymbol{u}(t)$ 是 $\boldsymbol{u}_1(t)$ 和 $\boldsymbol{u}_2(t)$ 的线性组合：

$$\boldsymbol{u}(t)=C\mathrm{e}^{t}\begin{bmatrix}1\\1\end{bmatrix}+D\mathrm{e}^{-t}\begin{bmatrix}1\\-1\end{bmatrix}=\begin{bmatrix}C\mathrm{e}^{t}+D\mathrm{e}^{-t}\\C\mathrm{e}^{t}-D\mathrm{e}^{-t}\end{bmatrix} \tag{6.46}$$

通过取合适的常数 $C$、$D$ 使得求出的解 $\boldsymbol{u}(0)=\begin{bmatrix}u_1(0)&u_2(0)\end{bmatrix}^{\mathrm{T}}$ 和初值吻合. 例 6.12 的初值条件是 $\boldsymbol{u}(0)=\begin{bmatrix}4&2\end{bmatrix}^{\mathrm{T}}$，那么令 $t=0$，则 $\mathrm{e}^{0}=1$：

$$\text{由}\boldsymbol{u}(0)\text{确定}C\text{、}D \qquad C\begin{bmatrix}1\\1\end{bmatrix}+D\begin{bmatrix}1\\-1\end{bmatrix}=\begin{bmatrix}4\\2\end{bmatrix} \qquad \Longrightarrow \qquad C=3,D=1$$

把 $C=3,D=1$ 代入式(6.46)，这个带初值的微分方程组就完全解决了.

如果是 $n$ 阶方阵的情形，我们要找 $n$ 个特征向量，待定常数 $C,D$ 转变成 $c_1,c_2,\cdots,c_n$.

（1）把初值 $\boldsymbol{u}(0)$ 写成 $\boldsymbol{A}$ 的特征向量的线性组合 $c_1\boldsymbol{x}_1+c_2\boldsymbol{x}_2+\cdots+c_n\boldsymbol{x}_n$.
（2）每个特征向量 $\boldsymbol{x}_i$ 都乘以增长因子 $\mathrm{e}^{\lambda_i t}$.
（3）方程组 $\mathrm{d}\boldsymbol{u}/\mathrm{d}t=\boldsymbol{A}\boldsymbol{u}$ 的解是这些纯指数函数解 $\mathrm{e}^{\lambda t}\boldsymbol{x}$ 以 $c_1,c_2,\cdots,c_n$ 为系数的线性组合

$$\boxed{\boldsymbol{u}(t)=c_1\mathrm{e}^{\lambda_1 t}\boldsymbol{x}_1+c_2\mathrm{e}^{\lambda_2 t}\boldsymbol{x}_2+\cdots+c_n\mathrm{e}^{\lambda_n t}\boldsymbol{x}_n} \tag{6.47}$$

上述方法步骤不涉及重特征值，但是只有一个线性无关的特征向量的情形，这种情况下，$\mathrm{e}^{\lambda t}$ 我们还需要其他解（最终增加的解是 $t\mathrm{e}^{\lambda t}$）. 原因是上述步骤中第一步就需要由 $n$ 个特征向量组成的基，并进一步地将 $\boldsymbol{A}$ 相似对角化 $\boldsymbol{A}=\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1}$.

**例 6.13** 对如下三阶方阵 $\boldsymbol{A}$，熟知它的特征值是 1、2、3，求解带初值的微分方程组：

关于 $\boldsymbol{u}(t)$ 的微分方程组 $\mathrm{d}\boldsymbol{u}/\mathrm{d}t=\boldsymbol{A}\boldsymbol{u}$ 的典型例题 带初值条件 $\boldsymbol{u}(0)$

$$\frac{\mathrm{d}\boldsymbol{u}}{\mathrm{d}t}=\begin{bmatrix}1&1&1\\0&2&1\\0&0&3\end{bmatrix}\boldsymbol{u} \qquad \text{初值条件是 } \boldsymbol{u}(0)=\begin{bmatrix}9\\7\\4\end{bmatrix}.$$

特征向量矩阵 $\boldsymbol{X}$ 的列向量是 $\boldsymbol{x}_1=\begin{bmatrix}1&0&0\end{bmatrix}^{\mathrm{T}},\boldsymbol{x}_2=\begin{bmatrix}1&1&0\end{bmatrix}^{\mathrm{T}},\boldsymbol{x}_3=\begin{bmatrix}1&1&1\end{bmatrix}^{\mathrm{T}}$

第一步. 向量 $\boldsymbol{u}(0)=\begin{bmatrix}9&7&4\end{bmatrix}^{\mathrm{T}}=2\boldsymbol{x}_1+3\boldsymbol{x}_2+4\boldsymbol{x}_3$，所以 $(c_1,c_2,c_3)=(2,3,4)$.
第二步. 增长因子 $\mathrm{e}^{\lambda t}$ 给出纯指数解 $\boldsymbol{u}_1=\mathrm{e}^t\boldsymbol{x}_1,\boldsymbol{u}_2=\mathrm{e}^{2t}\boldsymbol{x}_2,\boldsymbol{u}_3=\mathrm{e}^{3t}\boldsymbol{x}_3$.
第三步. 符合初值 $\boldsymbol{u}(0)$ 的解是线性组合 $\boldsymbol{u}(t)=2\boldsymbol{u}_1+3\boldsymbol{u}_2+4\boldsymbol{u}_3=2\mathrm{e}^t\boldsymbol{x}_1+3\mathrm{e}^{2t}\boldsymbol{x}_2+4\mathrm{e}^{3t}\boldsymbol{x}_3$.

组合系数 2、3、4 通过初值条件和求解方程组 $c_1\boldsymbol{x}_1+c_2\boldsymbol{x}_2+c_3\boldsymbol{x}_3=\boldsymbol{u}(0)$ 得到：

$$\begin{bmatrix}\boldsymbol{x}_1&\boldsymbol{x}_2&\boldsymbol{x}_3\end{bmatrix}\begin{bmatrix}c_1\\c_2\\c_3\end{bmatrix}=\begin{bmatrix}1&1&1\\0&1&1\\0&0&1\end{bmatrix}\begin{bmatrix}2\\3\\4\end{bmatrix}=\begin{bmatrix}9\\7\\4\end{bmatrix} \qquad \text{即} \qquad \boldsymbol{X}\boldsymbol{c}=\boldsymbol{u}(0). \tag{6.48}$$

现在我们已经掌握了解微分方程组 $\mathrm{d}\boldsymbol{u}/\mathrm{d}t=\boldsymbol{A}\boldsymbol{u}$ 的基本方法. 本节的其余部分将进一步深入讨论二阶微分方程，解决包含二阶导数的方程. 这类方程在实际应用中非常常见. 我们还将判断 $\boldsymbol{u}(t)$ 是趋于零、爆炸式增长还是振荡.

最后，我们将介绍以矩阵为指数的函数 $\mathrm{e}^{\boldsymbol{A}t}$，建立了这个概念后，用 $\mathrm{e}^{\boldsymbol{A}t}\boldsymbol{u}(0)$ 就可以简短地表达出方程组 $\mathrm{d}\boldsymbol{u}/\mathrm{d}t=\boldsymbol{A}\boldsymbol{u}$ 的解，像 $\boldsymbol{A}^k\boldsymbol{u}_0$ 能解决递归方程 $\boldsymbol{u}_{k+1}=\boldsymbol{A}\boldsymbol{u}_k$ 一样. 例 6.14 将说明“差分方程”如何用来解决微分方程.

所有这些步骤都需要使用特征值 $\lambda$ 和特征向量 $\boldsymbol{x}$. 本节将讨论常系数的微分方程的问题——常微分方程组，它们可以转化为线性代数问题. 这些是最简单但最重要的微分方程——其解完全基于增长因子 $\mathrm{e}^{\lambda t}$.

### 6.5.2 二阶微分方程

力学中最重要的方程是 $my''+by'+ky=0$. 第一项是质量 $m$ 乘以加速度 $a=y''$，表示惯性力，$by'$ 表示阻尼，$ky$ 表示弹力. 未知函数 $y(t)$ 表示弹簧末端质量为 $m$ 的质点的位置. 这是包含

二阶导数 $y''=\mathrm{d}^2y/\mathrm{d}t^2$ 方程（它遵循牛顿定律 $F=ma$），但是仍然是有常数系数 $m$、$b$、$k$ 的线性方程.

在微分方程的课程中，求解方法是先代入 $y=\mathrm{e}^{\lambda t}$，寻找 $\lambda$ 必须满足的条件. $y$ 的每一阶导数都包含因子 $\mathrm{e}^{\lambda t}$，如果期望 $y=\mathrm{e}^{\lambda t}$ 是弹簧方程的解，则

$$\boxed{m\frac{\mathrm{d}^2y}{\mathrm{d}t^2}+b\frac{\mathrm{d}y}{\mathrm{d}t}+ky=0 \quad \text{转化为} \quad (m\lambda^2+b\lambda+k)\mathrm{e}^{\lambda t}=0.} \tag{6.49}$$

所以结论取决于方程 $m\lambda^2+b\lambda+k=0$. 关于 $\lambda$ 的方程式(6.49)有两个复数解 $\lambda_1$、$\lambda_2$，因此关于 $y$ 的微分方程有两个纯指数函数解 $y_1=\mathrm{e}^{\lambda_1 t}, y_2=\mathrm{e}^{\lambda_2 t}$. 它们的线性组合 $c_1y_1+c_2y_2$ 的全体给出了所有解. 但是当 $\lambda_1=\lambda_2$ 时，结论未必成立.

现在我们身处线性代数课程，我们希望特征值和特征向量发挥作用. 鉴于此，我们把方程式(6.49)（关于 $y''$）这个标量方程改写成关于 $\begin{bmatrix}y & y'\end{bmatrix}^{\mathrm{T}}$ 的向量方程：**只涉及一阶导数！** 不妨设质量 $m=1$，那么关于 $\boldsymbol{u}=\begin{bmatrix}y & y'\end{bmatrix}^{\mathrm{T}}$ 的两个方程给出方程组 $\mathrm{d}\boldsymbol{u}/\mathrm{d}t=\boldsymbol{A}\boldsymbol{u}$：

$$\begin{aligned}&\mathrm{d}y/\mathrm{d}t=y'\\&\mathrm{d}y'/\mathrm{d}t=-ky-by'\end{aligned} \quad \text{转化成} \quad \frac{\mathrm{d}}{\mathrm{d}t}\begin{bmatrix}y\\y'\end{bmatrix}=\begin{bmatrix}0&1\\-k&-b\end{bmatrix}\begin{bmatrix}y\\y'\end{bmatrix}=\boldsymbol{A}\boldsymbol{u} \tag{6.50}$$

第一个方程是平凡的方程 $\mathrm{d}y/\mathrm{d}t=y'$，第二个方程根据式(6.49)用 $y$、$y'$ 把 $y''$ 表示出来. 综上所述，我们得到了联系 $\boldsymbol{u}'$ 和 $\boldsymbol{u}$ 的方程：$\boldsymbol{u}'=\boldsymbol{A}\boldsymbol{u}$. 接下来的任务就是用 $\boldsymbol{A}$ 的特征值来求解 $\boldsymbol{u}'=\boldsymbol{A}\boldsymbol{u}$：

$$\boldsymbol{A}-\lambda\boldsymbol{I}=\begin{bmatrix}-\lambda&1\\-k&-b-\lambda\end{bmatrix} \quad \text{的行列式是} \quad \lambda^2+b\lambda+k=0.$$

该方程和式(6.49)得到的方程一致：此时我们假设了 $m=1$，两个方程都是 $\lambda^2+b\lambda+k=0$.

方程的两个根 $\lambda_1$、$\lambda_2$ 是 $\boldsymbol{A}$ 的特征值，特征向量和 $\boldsymbol{u}'=\boldsymbol{A}\boldsymbol{u}$ 的解为

$$\boldsymbol{x}_1=\begin{bmatrix}1\\\lambda_1\end{bmatrix} \quad \boldsymbol{x}_2=\begin{bmatrix}1\\\lambda_2\end{bmatrix} \quad \boldsymbol{u}(t)=c_1\mathrm{e}^{\lambda_1 t}\begin{bmatrix}1\\\lambda_1\end{bmatrix}+c_2\mathrm{e}^{\lambda_2 t}\begin{bmatrix}1\\\lambda_2\end{bmatrix}.$$

$\boldsymbol{u}(t)$ 的第一个分量是 $y=c_1\mathrm{e}^{\lambda_1 t}+c_2\mathrm{e}^{\lambda_2 t}$——和之前的答案相同. 除此之外就没有其他解了. $\boldsymbol{u}(t)$ 的第二个分量是速度 $\mathrm{d}y/\mathrm{d}t$. 式(6.50)中二阶方阵 $\boldsymbol{A}$ 被称为多项式 $\lambda^2+b\lambda+k$ 的友阵.

**例 6.14**　*无阻尼振动方程为 $y''+y=0$，且 $y=\cos t$ 是它的解.*

这是本节的主要方程中取质量 $m=1$、弹性系数 $k=1$、阻尼系数 $d=0$（意即无阻尼）的情形. 把 $y=\mathrm{e}^{\lambda t}$ 代入 $y''+y=0$ 得 $\boldsymbol{\lambda^2+1=0.}$ 该方程有一堆共轭虚根：$\lambda=\pm\mathrm{i}$. 于是 $\mathrm{e}^{\mathrm{i}t}+\mathrm{e}^{-\mathrm{i}t}$ 的一半给出了方程的一个解 $y=\cos t$.

给定初始条件 $y(0)=1, y'(0)=0$，把无阻尼振动方程 $y''+y=0$ 转化为一阶微分方程组 $\boldsymbol{u}'=\boldsymbol{A}\boldsymbol{u}$，初始条件为 $\boldsymbol{u}(0)=\begin{bmatrix}1 & 0\end{bmatrix}^{\mathrm{T}}$：

$$y''=-y \quad \text{推出} \quad \frac{\mathrm{d}\boldsymbol{u}}{\mathrm{d}t}=\frac{\mathrm{d}}{\mathrm{d}t}\begin{bmatrix}y\\y'\end{bmatrix}=\begin{bmatrix}0&1\\-1&0\end{bmatrix}\begin{bmatrix}y\\y'\end{bmatrix}=\boldsymbol{A}\boldsymbol{u} \tag{6.51}$$

不出我们所料，$\boldsymbol{A}$ 的特征值仍然是 $\lambda=\pm\mathrm{i}$. $y=\cos t$ 不断地上下振荡，向量 $\begin{bmatrix}y(t)\\y'(t)\end{bmatrix}=\begin{bmatrix}\cos t\\-\sin t\end{bmatrix}$ 实际上在单位圆上旋转.

$\boldsymbol{A}$ 是反对称矩阵，$\boldsymbol{x}_1=\begin{bmatrix}1\\\mathrm{i}\end{bmatrix}$ 和 $\boldsymbol{x}_2=\begin{bmatrix}1\\-\mathrm{i}\end{bmatrix}$ 是它的特征向量. 和初值条件 $\boldsymbol{u}(0)=\begin{bmatrix}1\\0\end{bmatrix}$ 吻合的线性组合是 $\frac{1}{2}(\boldsymbol{x}_1+\boldsymbol{x}_2)$，步骤 2 把 $\mathrm{e}^{\mathrm{i}t}$ 和 $\mathrm{e}^{-\mathrm{i}t}$ 分别和 $\boldsymbol{x}_1$、$\boldsymbol{x}_2$ 相乘，步骤 3 把纯振荡 $\mathrm{e}^{\mathrm{i}t}$ 和 $\mathrm{e}^{-\mathrm{i}t}$ 组合起来，得到预期的 $y=\cos t$. 一切都太棒了！$\boldsymbol{u}=\begin{bmatrix}\cos t\\-\sin t\end{bmatrix}$ 的轨迹是个圆周，因为 $\cos^2 t+\sin^2 t=1$，所以半径是 1，见图 6.11(a). 周期 $2\pi$ 是跑遍整个圆周一次所用的时间.

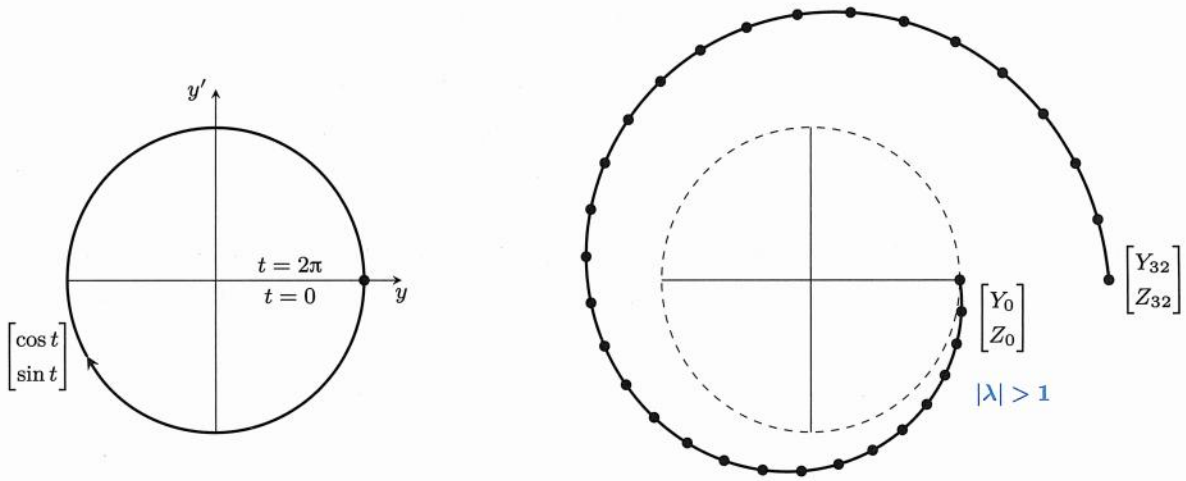


(a) 精确解　　(b) 向前差分，外旋 32 步

图 6.11　无阻尼振动方程的解

注：图 (a) 是精确解 $\boldsymbol{u}=\begin{bmatrix}\cos t & \sin t\end{bmatrix}^{\mathrm{T}}$，精确解在圆周上，时间 $t$ 从 0 到 $2\pi$ 形成完整的圆周. 图 (b) 是 (11F) 中的向前差分，外旋了 32 步，$Y_{32}$ 超出了 $y(2\pi)=1$，整体呈离心运动的状态.

### 6.5.3　差分方程

我们实际上没法画出连续的曲线，只能用充分多的离散点去逼近模拟. 例如，画一个圆，其实也没有真的画出严格意义上的圆. 具体到数值解微分方程，$y''=-y$ 被差分方程取而代之. 我们引入二阶差分 $Y(t+\Delta t)-2Y(t)+Y(t-\Delta)$ 来处理二阶导数，而等式右端的函数值我们有三个选择. $Y(t+\Delta t)-2Y(t)+Y(t-\Delta)$ 除以 $(\Delta t)^2$ 是二阶导数 $\mathrm{d}^2y/\mathrm{d}t^2$ 的近似.

F　向时刻 $n-1$ 外旋
C　以时刻 $n$ 为中心
B　向时刻 $n+1$ 内旋

$$\frac{Y(t+\Delta t)-2Y(t)+Y(t-\Delta)}{(\Delta t)^2}=\begin{cases}-Y_{n-1} & (11F)\\ -Y_n & (11C)\\ -Y_{n+1} & (11B)\end{cases}\qquad(6.52)$$

图 6.11 展示了 $y(t)=\cos t$ 在经过周期 $2\pi$ 之后精确地走出一个圆周. 然而，在间隔为 $\Delta t=2\pi/32$ 的 32 个时间步长内，这三种差分方法都没有完成一个完美的圆. 这些图中的螺旋线将通过特征值 $\lambda$ 来解释，这些特征值对应于 11F、11B 和 11C 三种情况.

**F.　$|\lambda|>1$ （外旋）　　C.　$|\lambda|=1$ （最佳）　　B.　$|\lambda|<1$ (内旋)**

上述二阶差分方程也可以约化为一阶方程组 $\boldsymbol{U}_{n+1}=\boldsymbol{A}\boldsymbol{U}_n$：把 $\boldsymbol{u}=\begin{bmatrix}y & y'\end{bmatrix}^{\mathrm{T}}$ 替换成 $\boldsymbol{U}_n=\begin{bmatrix}Y_n & Z_n\end{bmatrix}^{\mathrm{T}}$. 从 $\boldsymbol{U}_0$ 开始，取 $n$ 个间隔为 $\Delta t$ 的时间间隔：

$$\text{外旋（11F）}\quad \begin{cases} Y_{n+1}=Y_n+\Delta t Z_n \\ Z_{n+1}=Z_n-\Delta t Y_n \end{cases} \quad \text{转化为} \quad \boldsymbol{U}_{n+1}=\begin{bmatrix}1 & \Delta t\\ -\Delta t & 1\end{bmatrix}\begin{bmatrix}Y_n\\ Z_n\end{bmatrix}=\boldsymbol{A}\boldsymbol{U}_n. \tag{6.53}$$

这是 $Y'=Z, Z'=-Y$ 的近似. 该方程组是一阶求导，所以我们有矩阵形式 $\boldsymbol{U}_{n+1}=\boldsymbol{A}\boldsymbol{U}_n$. 消去 $Z$ 就可以返回关于 $Y$ 的二阶方程 (11 F).

现在就有一个简单的问题：点 $(Y_n,Z_n)$ 是否都在圆周 $Y^2+Z^2=1$ 上？很遗憾，结论是否定的；如图 6.11(b) 所示，当 $n$ 趋于无穷时，这些点也趋于无穷. 本质原因是我们在计算 $\boldsymbol{A}^n$，而不是 $\mathrm{e}^{\boldsymbol{A}t}$，所以我们需要判断式(6.53) 中 $\boldsymbol{A}$ 的特征值 $\lambda$ 的模长 $|\lambda|=\sqrt{1+(\Delta t)^2}$ 的渐进性质：

**$A$ 的特征值是$\lambda=1\pm \mathrm{i}$. 那么$|\lambda|>1$并且 $(Y_n,Z_n)$ 远离圆心向外旋转.**

而对于 (11B) 这个选项，情况恰恰相反，见图 6.12. 注意此时的矩阵

$$\text{内旋 (11B)}\quad \begin{cases} Y_{n+1}-Y_n= \Delta t Z_{n+1} \\ Z_{n+1}-Z_n= -\Delta t Y_{n+1} \end{cases} \quad \text{转化为} \quad \begin{bmatrix}1 & \Delta t\\ -\Delta t & 1\end{bmatrix}\begin{bmatrix}Y_{n+1}\\ Z_{n+1}\end{bmatrix}=\begin{bmatrix}Y_n\\ Z_n\end{bmatrix}=\boldsymbol{U}_n. \tag{6.54}$$

矩阵与上面相同，特征值 $1\pm \mathrm{i}\Delta t$. 但是方向是反的，它把 $\boldsymbol{U}_{n+1}$ 映回 $\boldsymbol{U}_n$. 所以这种情况下，正确的特征值满足 $|\lambda|=|1\pm \mathrm{i}\Delta t|^{-1}<1$，这是 $(Y_n,Z_n)$ 不断靠近圆心向内旋转的原因. 图 6.12(b) 展示了选择 (11C) 的 32 步. 如果 $\Delta t<2$，$(Y_n,Z_n)$ 一直在圆周附近（见习题 28）. 这就是常用的“蛙跳法”. 在 (11C) 中，二阶差分 $Y_{n+1}-2Y_n+Y_{n-1}$ “跳过”了 $Y_n$ 的值.

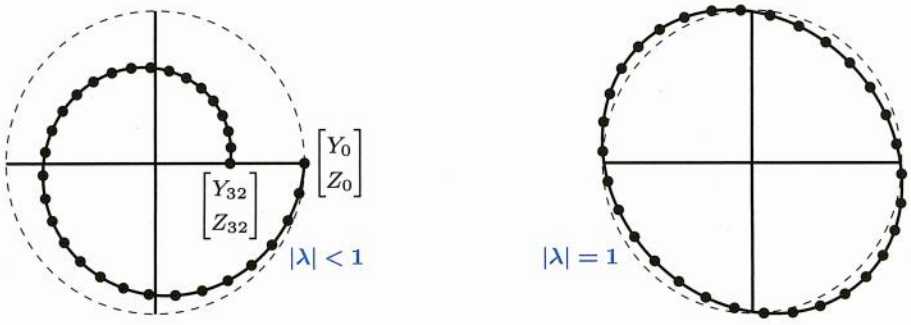


(a) 向后差分，内旋　　(b) 中心差分，“蛙跳”

**图 6.12　振动方程的向后差分和中心差分**

注：图 (a) 是（11B）中的向后差分，迭代图像靠近圆心向内旋转；图 (b) 是（11C）中的中心差分，迭代图像在圆周附近跳动.

化学家就是用这种方法来追踪分子运动的（分子动力学需要进行大量的计算）. 计算科学之所以充满活力，是因为一个微分方程可以被许多差分方程所替代——有些是不稳定的，有些是稳定的，有些是中性的. 习题 26 有第四种（非常好的）方法，可以更精确地逼近圆周.

真正的工程计算或者物理学处理的是方程组，而不仅仅是某一点上的一个单一质量. 未知量 $y$ 是一个向量，$y''$ 的系数是质量矩阵 $\boldsymbol{M}$，它的对角线元表示 $n$ 个质量. $y$ 的系数是弹性矩阵 $\boldsymbol{L}$，而不是一个单一的数值 $k$. $y'$ 的系数是阻尼矩阵，可能为零.

向量方程 $\boldsymbol{M}y''+\boldsymbol{K}y=f$ 是计算力学的重要组成部分.

### 6.5.4 二阶方阵的稳定性

求解微分方程 $\mathrm{d}\boldsymbol{u}/\mathrm{d}t=\boldsymbol{A}\boldsymbol{u}$ 有一个基本问题：当 $t\to\infty$ 时，解是否会趋于 0？这个问题是否稳定？能量是否会耗散？包含 $\mathrm{e}^t$ 的解是不稳定的，稳定性取决于矩阵 $\boldsymbol{A}$ 的特征值.

我们知道完整解 $\boldsymbol{u}(t)$ 是纯指数函数解 $\mathrm{e}^{\lambda t}\boldsymbol{x}$ 的线性组合. 如果特征值 $\lambda$ 是实数，我们可以确切地知道 $\mathrm{e}^{\lambda t}$ 何时会趋近于零：$\lambda$ 必须为负数. 如果特征值是复数 $\lambda=r+\mathrm{i}s$，则实部 $r$ 必须为负数. 当 $\mathrm{e}^{\lambda t}$ 分解为 $\mathrm{e}^{rt}\mathrm{e}^{\mathrm{i}st}$ 时，第二个因子 $\mathrm{e}^{\mathrm{i}st}$ 的模长始终是 1：

**Euler 公式** $\mathrm{e}^{\mathrm{i}st}=\cos(st)+\mathrm{i}\sin(st)$ 其模长的平方是 $|\mathrm{e}^{\mathrm{i}st}|^2=\cos^2(st)+\sin^2(st)=1$.

所以 $|\mathrm{e}^{\lambda t}|=\mathrm{e}^{rt}$，$\lambda$ 的实部决定了 $\mathrm{e}^{\lambda t}$ 是增长（$r>0$）还是衰减（$r<0$）.

那么问题来了：什么样的矩阵特征值都是负数？更准确一点，什么样的矩阵所有特征值的实部都是负数？$2\times 2$ 矩阵有如下判别方法.

如果 $\boldsymbol{A}$ 的特征值的实部都是负数，那么 $\boldsymbol{A}$ 是稳定的，且 $\boldsymbol{u}(t)\to 0(t\to\infty)$.

对于 $2\times 2$ 矩阵 $\boldsymbol{A}=\begin{bmatrix}a & b\\ c & d\end{bmatrix}$，$\boldsymbol{A}$ 的所有特征值的实部都是负数，当且仅当以下两个条件同时满足：

$\lambda_1+\lambda_2<0$ $\quad$ $\boldsymbol{A}$ 的迹 $\mathrm{Tr}(\boldsymbol{A})=a+d=\lambda_1+\lambda$ 必须小于零. (14T)

$\lambda_1\cdot\lambda_2>0$ $\quad$ $\boldsymbol{A}$ 的行列式 $\det\boldsymbol{A}=ab-bc=\lambda_1\lambda$ 必须大于零. (14D)

**理由** 如果 $\lambda_1$、$\lambda_2$ 都是负实数，那么迹 $\mathrm{Tr}(\boldsymbol{A})=a+d=\lambda_1+\lambda_2$ 也是负实数. 同时行列式 $\det(\boldsymbol{A})=ad-bc=\lambda_1\lambda_2$ 是正实数. 反之，如果 $\det(\boldsymbol{A})=\lambda_1\lambda_2$ 大于零，则 $\lambda_1$ 和 $\lambda_2$ 的正负号相同. 进一步地，若 $\mathrm{Tr}(\boldsymbol{A})=\lambda_1+\lambda_2<0$，那么 $\lambda_1$ 和 $\lambda_2$ 必须都是负实数.

如果 $\lambda_1$ 和 $\lambda_2$ 都是不是实数，因为它们是实系数多项式方程 $\lambda^2-\mathrm{Tr}(\boldsymbol{A})\lambda+\det(\boldsymbol{A})$ 的两个根，那么必须是共轭复数 $\lambda_1=r+\mathrm{i}s,\lambda_2=r-\mathrm{i}s$，此时行列式 $\det(\boldsymbol{A})=\lambda_1\lambda_2=r^2+s^2$ 自动大于 0；而迹 $\mathrm{Tr}(\boldsymbol{A})=(r+\mathrm{i}s)+(r-\mathrm{i}s)=2r$，所以 $\mathrm{Tr}(\boldsymbol{A})<0$ 和 $r<0$ 等价，此时矩阵 $\boldsymbol{A}$ 是稳定的. 这就完成了上述判别法的证明.

### 6.5.5 矩阵的指数函数

虽然我们已经讨论过了微分方程组 $\mathrm{d}\boldsymbol{u}/\mathrm{d}t=\boldsymbol{A}\boldsymbol{u}$ 的解，但是和标量方程作比较，我们还是希望能够将方程组的解写成 $\mathrm{e}^{\boldsymbol{A}t}\boldsymbol{u}(0)$ 的形式，所以需要对 $\mathrm{e}^{\boldsymbol{A}t}$ 这个以矩阵 $\boldsymbol{A}t$ 为指数的指数函数加以

定义.

矩阵指数函数 $e^{At}$　　$e^{At}=I+At+\frac{1}{2}(At)^2+\frac{1}{6}(At)^3+\cdots$　　(6.55)

关于 $t$ 求导，导数是 $Ae^{At}$　　$A+A^2t+\frac{1}{2}A^3t^2+\cdots=Ae^{At}$

特征值是 $e^{\lambda t}$　　$\left(I+At+\frac{1}{2}(At)^2+\cdots\right)x=(1+\lambda t+\frac{1}{2}(\lambda t)^2+\cdots)x$

现在我们就可以断言：$u(t)=e^{At}u(0)$ 是方程组 $du/dt=Au$ 的解：

$$\frac{du}{dt}=\frac{de^{At}u(0)}{dt}=\frac{d}{dt}e^{At}u(0)=Ae^{At}u(0)=Au(t). \tag{6.56}$$

$(At)^n$ 系数的分母被称为 “$n$ 的阶乘”：$n!=(1)(2)\cdots(n-1)(n)$. 在 1、2、6 之后，$4!=24$，$5!=120$. 阶乘的增长速度非常快，所以 $e^{At}$ 这个级数总是收敛的，且其导数是 $Ae^{At}$. 因此，$e^{At}u(0)$ 用一个简洁的表达式快速解决微分方程——即使线性无关的特征向量不够多也没问题.

本节重点介绍如何通过矩阵对角化求出 $u(t)=e^{At}u(0)$. 假设 $A$ 有 $n$ 个线性无关的特征向量，我们将 $A=X\Lambda X^{-1}$ 代入 $e^{At}$ 的级数展开式中. 每当出现 $X\Lambda X^{-1}X\Lambda X^{-1}$ 时，可以消去中间项 $X^{-1}X$：

利用级数展开　　$e^{At}=I+X\Lambda X^{-1}t+\frac{1}{2}(X\Lambda X^{-1})(X\Lambda X^{-1})t+\cdots$

消掉中间项并提取公因子　　$=X\left(I+\Lambda t+\frac{1}{2}(\Lambda t)^2+\cdots\right)X^{-1}$

$e^{At}$ 可相似对角化　　$\boxed{e^{At}=Xe^{\Lambda t}X^{-1}}$

$e^{At}$ 和 $A$ 有相同的特征向量矩阵 $X$. 那么 $\Lambda$ 是对角矩阵，若其对角元是 $\lambda_i$，则 $e^{At}$ 是以 $e^{\lambda_i t}$ 为对角元的对角矩阵. 于是从 $Xe^{\Lambda t}X^{-1}u(0)$ 可得 $u(t)$：

$$e^{At}u(0)=Xe^{\Lambda t}X^{-1}u(0)=\begin{bmatrix}x_1 & \cdots & x_n\end{bmatrix}\begin{bmatrix}e^{\lambda_1 t} & & \\ & \ddots & \\ & & e^{\lambda_n t}\end{bmatrix}\begin{bmatrix}c_1\\ \vdots\\ c_n\end{bmatrix} \tag{6.57}$$

$e^{At}u(0)$ 这个解和之前通过三个步骤求出的式(6.47)解相同.

（1）$u(0)=c_1x_1+c_2x_2+\cdots+c_nx_n=Xc$. 此处我们需要 $n$ 个线性无关的特征向量.

（2）将每个 $x_i$ 乘以其增长因子 $e^{\lambda_i t}$，研究其关于时间的变化趋势.

（3）$u(t)=e^{At}u(0)$ 的最佳表达形式是

$$u(t)=c_1e^{\lambda_1 t}x_1+c_2e^{\lambda_2 t}x_2+\cdots+c_ne^{\lambda_n t}x_n \tag{6.58}$$

**例 6.15**　设 $A=\begin{bmatrix}0 & 1\\ -1 & 0\end{bmatrix}$，用无穷级数计算 $e^{At}$. 注意到 $A^4=I$：[①]

$$A=\begin{bmatrix} & 1\\ -1 & \end{bmatrix}\qquad A^2=\begin{bmatrix}-1 & \\ & -1\end{bmatrix}\qquad A^3=\begin{bmatrix} & -1\\ 1 & \end{bmatrix}\qquad A^4=\begin{bmatrix}1 & \\ & 1\end{bmatrix}.$$

① 译者注：怎么注意到的？注意不到怎么办？前一个问题很简单，既然是用无穷级数去计算，那么前几项总要计算一下，直到计算到第四项就可以发现了，机智一点算完 $A^2$ 就可以发现了. 此时后一个问题也可以回答了，注意不到就多算算，多算几项之后总结规律.

$\boldsymbol{A}^5$、$\boldsymbol{A}^6$、$\boldsymbol{A}^7$、$\boldsymbol{A}^8$ 也就是把 $\boldsymbol{A}$、$\boldsymbol{A}^2$、$\boldsymbol{A}^3$、$\boldsymbol{A}^4$ 再重复一遍，其中右上角元素以 1、0、$-1$、0 为周期循环. 所以 $\mathrm{e}^{\boldsymbol{A}t}$ 右上角元素的前几项是 $t-\frac{1}{6}t^3$，左上角元素的前几项是 $1-\frac{1}{2}t^2$：

$$\mathrm{e}^{\boldsymbol{A}t}=\boldsymbol{I}+\boldsymbol{A}t+\frac{1}{2}(\boldsymbol{A}t)^2+\frac{1}{6}(\boldsymbol{A}t)^3+\cdots=\begin{bmatrix}1-\frac{1}{2}t^2+\cdots & t-\frac{1}{t}t^3+\cdots\\ -t+\frac{1}{t}t^3+\cdots & 1-\frac{1}{2}t^2+\cdots\end{bmatrix}$$

简直是太完美了！矩阵 $\mathrm{e}^{\boldsymbol{A}t}$ 的每个元素都是三角函数 $\cos t$ 或者 $\sin t$：

$$\boldsymbol{A}=\begin{bmatrix}0 & 1\\ -1 & 0\end{bmatrix}\qquad\qquad \mathrm{e}^{\boldsymbol{A}t}=\begin{bmatrix}\cos t & \sin t\\ -\sin t & \cos t\end{bmatrix}\tag{6.59}$$

该矩阵 $\boldsymbol{A}$ 是反对称矩阵（$\boldsymbol{A}^{\mathrm{T}}=-\boldsymbol{A}$），矩阵指数函数 $\mathrm{e}^{\boldsymbol{A}t}$ 是正交矩阵. $\boldsymbol{A}$ 的特征值是 i 和 $-\mathrm{i}$，那么 $\mathrm{e}^{\boldsymbol{A}t}$ 的特征值是 $\mathrm{e}^{\mathrm{i}t}$ 和 $\mathrm{e}^{-\mathrm{i}t}$. 对任意矩阵 $\boldsymbol{A}$，都有以下事实：

（1）对任意 $t$，$\mathrm{e}^{\boldsymbol{A}t}$ 的逆矩阵都是 $\mathrm{e}^{-\boldsymbol{A}t}$.

（2）对任意 $t$，$\mathrm{e}^{\boldsymbol{A}t}$ 的特征值都形如 $\mathrm{e}^{\lambda t}$，其中 $\lambda$ 是 $\boldsymbol{A}$ 的特征值.

（3）对任意反对称矩阵 $\boldsymbol{A}$，$\mathrm{e}^{\boldsymbol{A}t}$ 都是正交矩阵，$\mathrm{e}^{\boldsymbol{A}t}$ 的逆矩阵 = 转置 $=\mathrm{e}^{-\boldsymbol{A}t}$.

反对称和斜对称是一个意思：$\boldsymbol{A}^{\mathrm{T}}=-\boldsymbol{A}$. 反对称矩阵 $\boldsymbol{A}$ 的特征值都是形如 $\mathrm{i}s(s\in\mathbb{R})$ 的纯虚数，那么 $\mathrm{e}^{\boldsymbol{A}t}$ 的特征值 $\lambda$ 都形如 $\mathrm{e}^{\mathrm{i}st}$，模长 $|\lambda|=1$. 微分方程 $\mathrm{d}\boldsymbol{u}/\mathrm{d}t=\boldsymbol{A}\boldsymbol{u}$ 的解都是中性稳定、纯震荡、能量守恒的. 所以 $\|\boldsymbol{u}(t)\|=\|\boldsymbol{u}(0)\|$.

若 $\boldsymbol{A}$ 是可对角化的上三角矩阵，我们可以取上三角的特征向量矩阵 $\boldsymbol{X}$，于是 $\boldsymbol{X}^{-1}$、$\mathrm{e}^{\boldsymbol{A}t}$ 也是上三角矩阵. 微分方程 $\mathrm{d}\boldsymbol{u}/\mathrm{d}t=\boldsymbol{A}\boldsymbol{u}$ 的解 $\boldsymbol{u}(t)$ 是特征向量的线性组合，可以简记作 $\mathrm{e}^{\boldsymbol{A}t}\boldsymbol{u}(0)$.

**例 6.16** 解在 $t=0$ 处初值条件为 $\boldsymbol{u}(0)=\begin{bmatrix}2\\1\end{bmatrix}$ 的微分方程 $\dfrac{\mathrm{d}\boldsymbol{u}}{\mathrm{d}t}=\boldsymbol{A}\boldsymbol{u}=\begin{bmatrix}1 & 1\\0 & 2\end{bmatrix}\boldsymbol{u}=\boldsymbol{A}\boldsymbol{u}$.

**解** 因为 $\boldsymbol{A}$ 是上三角矩阵，特征值是其对角元 1 和 2；向量 $\begin{bmatrix}1\\2\end{bmatrix}$ 和 $\begin{bmatrix}1\\1\end{bmatrix}$ 是分别属于这两个特征值的特征向量. 对任意初值 $\boldsymbol{u}(0)$，都可以通过 $\mathrm{e}^{\boldsymbol{A}t}$ 求出解 $\boldsymbol{u}(t)$：

$$\boldsymbol{u}(t)=\boldsymbol{X}\mathrm{e}^{\boldsymbol{A}t}\boldsymbol{X}^{-1}\boldsymbol{u}(0)=\begin{bmatrix}1 & 1\\0 & 1\end{bmatrix}\begin{bmatrix}\mathrm{e}^{t} & \\ & \mathrm{e}^{2t}\end{bmatrix}\begin{bmatrix}1 & -1\\0 & 1\end{bmatrix}\boldsymbol{u}(0)=\begin{bmatrix}\mathrm{e}^{t} & \mathrm{e}^{2t}-\mathrm{e}^{t}\\ & \mathrm{e}^{2t}\end{bmatrix}\boldsymbol{u}(0).$$

最后那个矩阵是 $\mathrm{e}^{\boldsymbol{A}t}$，因为 $\boldsymbol{A}$ 是上三角矩阵，它的性质和形式都很好. 具体情况与求解 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 的情况类似，我们不需要先找出 $A$ 的逆矩阵 $\boldsymbol{A}^{-1}$ 然后再求解 $\boldsymbol{x}$. 同样地，我们也不需要先找出 $\mathrm{e}^{\boldsymbol{A}t}$ 再求解 $\mathrm{d}\boldsymbol{u}/\mathrm{d}t=\boldsymbol{A}\boldsymbol{u}$. 但是作为能够快速得出结果的公式，$\boldsymbol{A}^{-1}\boldsymbol{b}$ 和 $\mathrm{e}^{\boldsymbol{A}t}\boldsymbol{u}(0)$ 在理论上也有其无与伦比的优势.

**例 6.17** 先通过待定系数法：将 $\mathrm{e}^{\lambda t}$ 代入 $y''+4y'+3y=0$ 求解该方程；再通过线性代数的方法求解.

**解** 代入 $\mathrm{e}^{\lambda t}$ 得 $(\lambda^2+4\lambda+3)\mathrm{e}^{\lambda t}=0$. 对二次多项式因式分解 $\lambda^2+4\lambda+3=(\lambda+1)(\lambda+3)=0$，因此 $\lambda_1=-1,\lambda_2=-3$. 纯指数函数解为 $y_1=\mathrm{e}^{-t},y_2=\mathrm{e}^{-2t}$. $t\to\infty$ 时，任意完整解 $\boldsymbol{y}=c_1y_1+c_2y_2$ 都趋于 0.

要用线性代数方法，令 $\boldsymbol{u}=\begin{bmatrix} y \\ y' \end{bmatrix}$，那么原二阶微分方程可以转化为关于 $\boldsymbol{u}$ 的一阶微分方程：

$$\begin{aligned} &\mathrm{d}y/\mathrm{d}t = y' \\ &\mathrm{d}y'/\mathrm{d}t = -3y - 4y' \end{aligned} \qquad \text{转化成} \frac{\mathrm{d}\boldsymbol{u}}{\mathrm{d}t} = \begin{bmatrix} 0 & 1 \\ -3 & -4 \end{bmatrix} \boldsymbol{u} = \boldsymbol{A}\boldsymbol{u}.$$

$\boldsymbol{A}$ 是 $\lambda^2+4\lambda+3$ 的友阵，特征值是 $\lambda_1=-1, \lambda_2=-3$.

同一个二次方程　$$\det(\boldsymbol{A}-\lambda\boldsymbol{I}) = \begin{vmatrix} -\lambda & 1 \\ -3 & -4-\lambda \end{vmatrix} = \lambda^2+4\lambda+3=0$$

$\begin{bmatrix} 1 \\ \lambda_1 \end{bmatrix}$ 和 $\begin{bmatrix} 1 \\ \lambda_2 \end{bmatrix}$ 是 $\boldsymbol{A}$ 的特征向量. 无论哪种方法，$y(t)$ 的衰减性都来源于 $\mathrm{e}^{-t}$ 和 $\mathrm{e}^{-3t}$. 这个例子也提示我们，常微分方程都可以导向线性代数：$\boldsymbol{A}\boldsymbol{x}=\lambda\boldsymbol{x}$.

**例 6.18**　把 $y=\mathrm{e}^{\lambda t}$ 代入方程 $y''-2y'+y=0$ 可得有重根的方程 $\lambda^2-2\lambda+1=0$，该方程即 $(\lambda-1)^2=0$，有二重根 $\lambda=1,1$. 微分方程课上，老师会告诉你：$\mathrm{e}^t$ 和 $t\mathrm{e}^t$ 是微分方程两个线性无关的解. 知其然也要知其所以然，此处我们分析一下其中的原因.

使用相同的线性代数的方法，把微分方程 $y''=2y'-y$ 改写成关于向量 $\boldsymbol{u}=\begin{bmatrix} y \\ y' \end{bmatrix}$ 的微分方程：

$$\frac{\mathrm{d}}{\mathrm{d}t}\begin{bmatrix} y \\ y' \end{bmatrix} = \begin{bmatrix} y' \\ 2y'-y \end{bmatrix} \qquad \text{即} \qquad \frac{\mathrm{d}\boldsymbol{u}}{\mathrm{d}t} = \boldsymbol{A}\boldsymbol{u} = \begin{bmatrix} 0 & 1 \\ -1 & 2 \end{bmatrix}\boldsymbol{u} \tag{6.60}$$

$\boldsymbol{A}$ 有重特征值 $\lambda=1,1$，迹是 2，行列式是 1. $\boldsymbol{A}$ 的特征向量只分布在一条直线上，只有一个线性无关的特征向量，可以取作 $\boldsymbol{x}=\begin{bmatrix} 1 \\ 1 \end{bmatrix}$，所以 $\boldsymbol{A}$ 不可对角化. 那么计算 $\mathrm{e}^{\boldsymbol{A}t}$ 只能返回到无穷级数的定义：

有限级数　$$\mathrm{e}^{\boldsymbol{A}t} = \mathrm{e}^{\boldsymbol{I}t}\mathrm{e}^{(\boldsymbol{A}-\boldsymbol{I})t} = \mathrm{e}^t[\boldsymbol{I}+(\boldsymbol{A}-\boldsymbol{I})t] \tag{6.61}$$

$\mathrm{e}^{(\boldsymbol{A}-\boldsymbol{I})t}$ 的无穷级数实际只有两项，因为 $(\boldsymbol{A}-\boldsymbol{I})^2=\boldsymbol{0}$，所以从这一项往后全都没有贡献. 我们从式(6.61)中就发现了 $t\mathrm{e}^t$ 的栖身之所. $\mathrm{e}^{\boldsymbol{A}t}\boldsymbol{u}(0)$ 的第一个分量即我们要求的 $\boldsymbol{y}(t)$：

$$\begin{bmatrix} y \\ y' \end{bmatrix} = \mathrm{e}^t\left(\boldsymbol{I}+\begin{bmatrix} -1 & 1 \\ -1 & 1 \end{bmatrix}t\right)\begin{bmatrix} y(0) \\ y'(0) \end{bmatrix} \qquad \Longrightarrow \qquad \boldsymbol{y(t)=\mathrm{e}^t y(0)-t\mathrm{e}^t y(0)+t\mathrm{e}^t y'(0).}$$

最后一个例子真就是在挑战线性代数课程的极限！从常微分方程 $\mathrm{d}\boldsymbol{u}/\mathrm{d}t=\boldsymbol{A}\boldsymbol{u}$ 转向热方程和波动方程，即偏微分方程 $\partial u/\partial t=\partial^2 u/\partial x^2$ 和 $\partial^2 u/\partial t^2=\partial^2 u/\partial x^2$.

热方程　在图 6.13(a) 中，中心的温度初始值为 $2\sqrt{2}$. 热量向周围的盒子扩散：$\mathrm{d}\boldsymbol{u}/\mathrm{d}t=\boldsymbol{A}\boldsymbol{u}$（外部格子初始温度固定在 0°）. 盒子间热量流动的速度取决于温差，从 0 处的盒子出发，热量以 $u_1-u_0$ 和 $u_{-1}-u_0$ 的速率向右和向左流动. 因此，在 $\boldsymbol{A}\boldsymbol{u}$ 的第二行中，流出的热量表示为 $u_1-2u_0+u_{-1}$.

波动方程 $\mathrm{d}^2\boldsymbol{u}/\mathrm{d}t^2=\boldsymbol{A}\boldsymbol{u}$ 有相同的特征向量 $\boldsymbol{x}$. 但是特征值 $\lambda<0$ 导致了振荡解 $\mathrm{e}^{\mathrm{i}\omega t}$ 和 $\mathrm{e}^{-\mathrm{i}\omega t}$. 频率 $\omega$ 满足 $\omega^2=-\lambda$:

$$\frac{\mathrm{d}^2}{\mathrm{d}t^2}(\mathrm{e}^{\mathrm{i}\omega t}\boldsymbol{x}) = \boldsymbol{A}(\mathrm{e}^{\mathrm{i}\omega t}\boldsymbol{x}) \qquad \text{转化成} \qquad (\mathrm{i}\omega)^2\mathrm{e}^{\mathrm{i}\omega t}\boldsymbol{x} = \lambda\mathrm{e}^{\mathrm{i}\omega t}\boldsymbol{x} \quad \text{以及} \quad \omega^2=-\lambda$$

由于 $-\lambda$ 有两个平方根，因此我们有两个振荡解 $e^{i\omega t}\boldsymbol{x}$ 和 $e^{-i\omega t}\boldsymbol{x}$；同时 $\boldsymbol{A}$ 有三个特征向量，结合起来，方程 $\boldsymbol{u}''=\boldsymbol{A}\boldsymbol{u}$ 有六个解. 给定初值条件 $\boldsymbol{u}(0)$ 和 $\boldsymbol{u}'(0)$，就需要找出这六个解的一个线性组合，使其符合初值条件. 比如说，如果要求 $\boldsymbol{u}'(0)=0$，从 $e^{i\omega t}\boldsymbol{x}$ 和 $e^{-i\omega t}\boldsymbol{x}$ 出发可以组合出 $2\cos(\omega t)\boldsymbol{x}$ 是满足条件的.

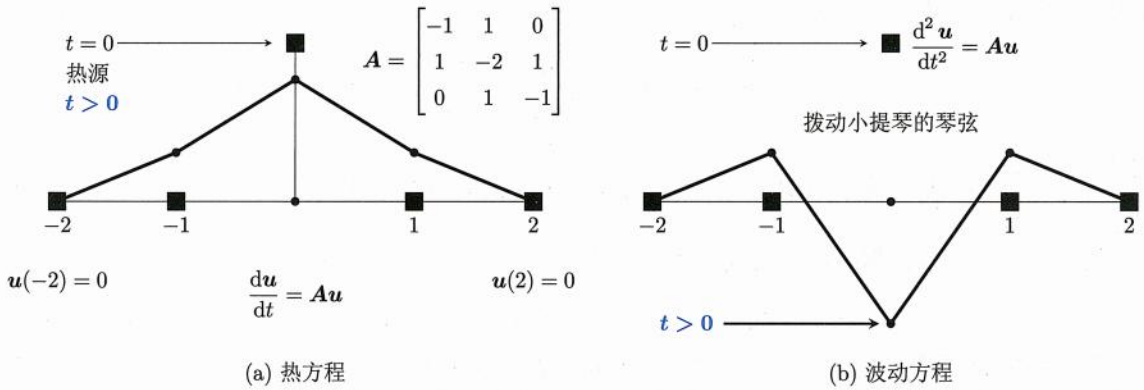


(a) 热方程　　(b) 波动方程

图 6.13　热方程和波动方程

注：图 (a) 中热方程在 $t=0$ 时是最高峰，逐渐消散；图 (b) 是波动方程，显示了弦上的波的振动.

## 习题 6.5

1. 求两组 $(\lambda,\boldsymbol{x})$，使得 $\boldsymbol{u}=e^{\lambda t}\boldsymbol{x}$ 是方程组 $\dfrac{d\boldsymbol{u}}{dt}=\begin{bmatrix}4&3\\0&1\end{bmatrix}\boldsymbol{u}$ 的解.

求符合初值条件 $\boldsymbol{u}(0)=\begin{bmatrix}5\\-2\end{bmatrix}$ 的线性组合 $\boldsymbol{u}=c_1e^{\lambda_1 t}\boldsymbol{x}_1+c_2e^{\lambda_2 t}\boldsymbol{x}_2$.

2. 考虑习题 1 中的微分方程，记 $\boldsymbol{u}=\begin{bmatrix}y&z\end{bmatrix}^{\mathrm{T}}$，先求 $z$，再求 $y$，通过回代法解该方程组：

解带初值条件 $z(0)=-2$ 的微分方程 $\dfrac{dz}{dt}=z$. 解带初值条件 $y(0)=5$ 的微分方程 $\dfrac{dy}{dt}=4y+3z$.

$y$ 的解是 $e^{4t}$ 和 $e^{t}$ 的线性组合. $\boldsymbol{A}$ 的特征值是 4 和 1.

3.（1）若 $\boldsymbol{A}$ 的每一个列向量各分量之和都是 0，为什么 $\lambda=0$ 是它的特征值？

（2）当矩阵 $\boldsymbol{A}$ 对角线上元素为负、非对角线元素都是正数且列向量各分量相加和都为零时，方程 $\boldsymbol{u}'=\boldsymbol{A}\boldsymbol{u}$ 称作一个“连续”的马尔可夫方程. 对下面的马尔可夫方程，求其特征值和特征向量，以及当 $t\to\infty$ 时的稳态.

$$\text{解方程组 } \frac{d\boldsymbol{u}}{dt}=\begin{bmatrix}-2&3\\2&-3\end{bmatrix}\boldsymbol{u},\ \text{初值条件为 } \boldsymbol{u}(0)=\begin{bmatrix}4\\1\end{bmatrix}.\ \boldsymbol{u}(+\infty)\ \text{是什么？}$$

4. 有两个房间之间开着门，开始人数分别是 $v(0)=30$ 和 $w(0)=10$. 两个房间的人员转移速率和人数差成正比，我们假设：

$$\frac{\mathrm{d}v}{\mathrm{d}t}=w-v \qquad\qquad \frac{\mathrm{d}w}{\mathrm{d}t}=v-w.$$

证明：总人数 $v+w$ 等于常数（保持 40 人不变）[①]，记 $\boldsymbol{u}=\begin{bmatrix}v\\w\end{bmatrix}$，请将方程组写成矩阵形式：$\mathrm{d}\boldsymbol{u}/\mathrm{d}t=\boldsymbol{A}\boldsymbol{u}$，求 $\boldsymbol{A}$ 的特征值和特征向量. 当时间 $t=1$ 和 $t=\infty$ 时，$v$、$w$ 分别取值多少？

5. 习题 4 中的人口扩散模型在列方程时其实有一个隐含的假设：人总是从高人口房间向低人口房间转移. 如果我们取相反的假设，则可以列出方程 $\mathrm{d}\boldsymbol{u}/\mathrm{d}t=\boldsymbol{A}\boldsymbol{u}$：

$$\frac{\mathrm{d}v}{\mathrm{d}t}=v-w \qquad\qquad \frac{\mathrm{d}w}{\mathrm{d}t}=w-v.$$

证明：总人数仍然保持不变. 但是系数矩阵从 $\boldsymbol{A}$ 变到 $-\boldsymbol{A}$ 时，特征值 $\lambda$ 是如何变化的？证明：当 $t\to\infty$ 时，$v(t)$ 将从 $v(0)=30$ 增长到无穷.[②]

6. $a$、$b$ 都是实数，证明：$\boldsymbol{A}=\begin{bmatrix}a & 1\\1 & a\end{bmatrix}$ 有两个实数特征值，$\boldsymbol{B}=\begin{bmatrix}b & -1\\1 & b\end{bmatrix}$ 有两个复数（非实数）特征值. $a$、$b$ 满足什么条件，$\mathrm{d}\boldsymbol{u}/\mathrm{d}t=\boldsymbol{A}\boldsymbol{u}$ 和 $\mathrm{d}\boldsymbol{v}/\mathrm{d}t=\boldsymbol{B}\boldsymbol{v}$ 的所有解在 $t\to\infty$ 时都趋于 0？（提示：非实数特征值的实部都小于 0.）

7. 设 $\boldsymbol{P}$ 是 $\mathbb{R}^2$ 到直线 $y=x$ 的正交投影矩阵. 它的特征值是什么？考虑微分方程 $\mathrm{d}\boldsymbol{u}/\mathrm{d}t=-\boldsymbol{P}\boldsymbol{u}$（注意其中的负号），初值条件为 $\boldsymbol{u}(0)=\begin{bmatrix}3 & 1\end{bmatrix}^{\mathrm{T}}$，求 $\lim_{t\to\infty}\boldsymbol{u}(t)$.

8. 设兔子数量为 $r$，狼数量是 $w$，微分方程组

$$\frac{\mathrm{d}r}{\mathrm{d}t}=6r-2w \qquad\qquad \frac{\mathrm{d}w}{\mathrm{d}t}=2r+w$$

给出了兔子和狼的一个繁衍数量模型：兔子以正比于自身数量的速度（6 倍）迅速增长，同时因为被狼捕猎，以正比于狼的数量的速度（2 倍）相对缓慢减少；而狼由于缺少天敌，其数量的增长取决于自身种群的总数（$w$）（若将这一项改成 $-w^2$，意思是狼的种群对于繁衍有限制作用）和食物的丰富程度（$2r$）. 把方程组写成矩阵形式，并求系数矩阵的特征值和特征向量. 假设 $r(0)=w(0)=30$，那么时间 $t$ 之后，兔子和狼数量各是多少？充分长时间后，兔子和狼的数量比例是多少？

9.（1）设 $\boldsymbol{A}=\begin{bmatrix}0 & 1\\-1 & 0\end{bmatrix}$，已知

$$\boldsymbol{A}\boldsymbol{x}_1=\begin{bmatrix}0 & 1\\-1 & 0\end{bmatrix}\begin{bmatrix}1\\\mathrm{i}\end{bmatrix}=\mathrm{i}\begin{bmatrix}1\\\mathrm{i}\end{bmatrix}=\mathrm{i}\boldsymbol{x}_1 \qquad \boldsymbol{A}\boldsymbol{x}_2\begin{bmatrix}0 & 1\\-1 & 0\end{bmatrix}\begin{bmatrix}1\\-\mathrm{i}\end{bmatrix}=-\mathrm{i}\begin{bmatrix}1\\-\mathrm{i}\end{bmatrix}=-\mathrm{i}\boldsymbol{x}_2$$

把 $\begin{bmatrix}4 & 0\end{bmatrix}^{\mathrm{T}}$ 写成线性组合 $c_1\boldsymbol{x}_1+c_2\boldsymbol{x}_2$.

（2）方程组 $\mathrm{d}\boldsymbol{u}/\mathrm{d}t=\boldsymbol{A}\boldsymbol{u}$ 以 $\begin{bmatrix}4 & 0\end{bmatrix}^{\mathrm{T}}$ 为初值的解是 $c_1\mathrm{e}^{\mathrm{i}t}\boldsymbol{x}_1+c_2\mathrm{e}^{-\mathrm{i}t}\boldsymbol{x}_2$. 利用 Euler 公式，把 $\mathrm{e}^{\mathrm{i}t}=\cos t+\mathrm{i}\sin t$ 和 $\mathrm{e}^{-\mathrm{i}t}=\cos t-\mathrm{i}\sin t$ 代入，求出 $\boldsymbol{u}(t)$.

---

① 译者注：由于人员只在两个房间之间转移，所以看起来这个要证明的结论是平凡的. 此处作者的意图是借助微积分给出纯数学的证明.

② 译者注：此处不必较真实际情况，可以假定人数可以是负数.

10. 把二阶微分方程 $y''=5y'+4y$ 写成关于 $\boldsymbol{u}=\begin{bmatrix}y\\y'\end{bmatrix}$ 的一阶方程组：

$$\frac{\mathrm{d}\boldsymbol{u}}{\mathrm{d}t}=\begin{bmatrix}y'\\y''\end{bmatrix}=\begin{bmatrix}\ &\ \\\ &\ \end{bmatrix}\begin{bmatrix}y\\y'\end{bmatrix}=\boldsymbol{A}\boldsymbol{u},$$

请求出 $\boldsymbol{A}$ 和 $\boldsymbol{A}$ 的特征值. 再用待定系数法，把 $y=\mathrm{e}^{\lambda t}$ 代入方程 $y''+5y'+4y=0$，求解此方程.

11. 方程 $y''=0$ 的解是直线 $y=C+Dt$. 把它转化成矩阵形式：

$$\frac{\mathrm{d}}{\mathrm{d}t}\begin{bmatrix}y\\y'\end{bmatrix}=\begin{bmatrix}0&1\\0&0\end{bmatrix}\begin{bmatrix}y\\y'\end{bmatrix}\qquad\text{的解是}\qquad\begin{bmatrix}y\\y'\end{bmatrix}=\mathrm{e}^{\boldsymbol{A}t}\begin{bmatrix}y(0)\\y'(0)\end{bmatrix}.$$

矩阵 $\boldsymbol{A}$ 的特征值是 $\lambda=0,0$ 且不可对角化，请计算 $\boldsymbol{A}^2$ 和级数 $\mathrm{e}^{\boldsymbol{A}t}=\boldsymbol{I}+\boldsymbol{A}t+\frac{1}{2}\boldsymbol{A}^2t^2+\cdots$. 再计算 $\mathrm{e}^{\boldsymbol{A}t}$ 和 $\begin{bmatrix}y(0)\\y'(0)\end{bmatrix}$ 的乘积验证原微分方程的解是直线 $y(t)=y(0)+y'(0)t$.

12. 把 $y=\mathrm{e}^{\lambda t}$ 代入 $y''=6y'-9y$，证明：$\lambda=3$ 是重根. 这对求解该二阶微分方程带来了困难，除了 $\mathrm{e}^{3t}$ 我们还需要找出另一个线性无关的解. 把方程改写成一阶微分方程组：

$$\frac{\mathrm{d}}{\mathrm{d}t}\begin{bmatrix}y\\y'\end{bmatrix}=\begin{bmatrix}0&1\\-9&6\end{bmatrix}\begin{bmatrix}y\\y'\end{bmatrix}$$

证明：系数矩阵的特征值是 $\lambda=3,3$，但是特征向量只在一条直线上. 还是有麻烦. 验证：$y=t\mathrm{e}^{3t}$ 是 $y''=6y'-9y$ 的解.

注释：在线性代数中，方阵对相似对角化的障碍是线性无关的特征向量不够多. 当 $\lambda_1=\lambda_2$ 时，特征向量 $\begin{bmatrix}1\\\lambda_1\end{bmatrix}$ 和 $\begin{bmatrix}1\\\lambda_2\end{bmatrix}$ 相同，那么就无法将矩阵 $\boldsymbol{A}$ 相似对角化. 在这种情况下，我们还没有找到 $\mathrm{d}\boldsymbol{u}/\mathrm{d}t=\boldsymbol{A}\boldsymbol{u}$ 的两个线性无关的解.

在微分方程中，难点同样来自重复的特征值 $\lambda$. 在 $y=\mathrm{e}^{\lambda t}$ 之外，还需要找一个与之线性无关的解. 当然我们已经知道了结果：这个解是 $y=t\mathrm{e}^{\lambda t}$. 这个“不纯”的解（带有额外的 $t$）会出现在矩阵指数 $\mathrm{e}^{\boldsymbol{A}t}$ 中. 例 6.18 展示了如何找出后一个解的.

13.（1）写下方程 $\mathrm{d}^2y/\mathrm{d}t^2=-9y$ 两个熟知的解. 哪个解符合初值条件 $\begin{bmatrix}y(0)&y'(0)\end{bmatrix}^{\mathrm{T}}=\begin{bmatrix}3&0\end{bmatrix}^{\mathrm{T}}$?

（2）二阶微分方程 $y''=-9y$ 等价于向量函数的一阶方程组 $\boldsymbol{u}'=\boldsymbol{A}\boldsymbol{u}$：

$$\boldsymbol{u}=\begin{bmatrix}y\\y'\end{bmatrix}\qquad\frac{\mathrm{d}\boldsymbol{u}}{\mathrm{d}t}=\begin{bmatrix}y'\\y''\end{bmatrix}=\begin{bmatrix}0&1\\-9&0\end{bmatrix}\begin{bmatrix}y\\y'\end{bmatrix}=\boldsymbol{A}\boldsymbol{u}.$$

利用 $\boldsymbol{A}$ 的特征值和特征向量求符合初值条件 $\boldsymbol{u}(0)=\begin{bmatrix}3&0\end{bmatrix}^{\mathrm{T}}$ 的解 $\boldsymbol{u}(t)$.

14. 本题中的矩阵 $\boldsymbol{A}$ 是反对称矩阵（$\boldsymbol{A}^{\mathrm{T}}=-\boldsymbol{A}$）：

$$\frac{\mathrm{d}\boldsymbol{u}}{\mathrm{d}t}=\begin{bmatrix}0 & c & -b\\ -c & 0 & a\\ b & -a & 0\end{bmatrix}\boldsymbol{u}\qquad\text{或者等价地}\qquad\begin{cases}u_1'=au_2-bu_3\\ u_2'=au_3-cu_1\\ u_3'=bu_1-au_2.\end{cases}$$

（1）$\|\boldsymbol{u}(t)\|^2=u_1^2+u_2^2+u_3^2$ 的导数是 $2u_1u_1'+2u_2u_2'+2u_3u_3'$. 将上述 $u_1'$、$u_2'$、$u_3'$ 满足的方程代入该导数，证明：结果为零. 再由此证明：对任意 $t$，$\|\boldsymbol{u}(t)\|^2=\|\boldsymbol{u}(0)\|^2$.

（2）反对称性 $\boldsymbol{A}^{\mathrm{T}}=-\boldsymbol{A}$ 保证了 $\boldsymbol{Q}=\mathrm{e}^{\boldsymbol{A}t}$ 是正交矩阵. 根据 $\boldsymbol{Q}$ 的无穷级数的定义式，证明：$\boldsymbol{Q}^{\mathrm{T}}=\mathrm{e}^{-\boldsymbol{A}t}$.

15. 如果 $\boldsymbol{A}$ 是可逆矩阵，那么 $\mathrm{d}u/\mathrm{d}t=\boldsymbol{A}\boldsymbol{u}-\boldsymbol{b}$（这是非齐次微分方程组）的一个特解是常值：$\boldsymbol{u}_p=\boldsymbol{A}^{-1}\boldsymbol{b}$. $\mathrm{d}\boldsymbol{u}/\mathrm{d}t=\boldsymbol{A}\boldsymbol{u}$（这是齐次微分方程组）的解记作 $\boldsymbol{u}_n$. 求下列非齐次方程组的完整解 $\boldsymbol{u}=\boldsymbol{u}_p+\boldsymbol{u}_n$:

（1）$\dfrac{\mathrm{d}u}{\mathrm{d}t}=u-4$　　（2）$\dfrac{\mathrm{d}\boldsymbol{u}}{\mathrm{d}t}=\begin{bmatrix}1 & 0\\ 1 & 1\end{bmatrix}\boldsymbol{u}-\begin{bmatrix}4\\ 6\end{bmatrix}$

习题 16 ~ 22 关于矩阵的指数函数 $\mathrm{e}^{\boldsymbol{A}t}$.

16. 写出 $\mathrm{e}^{\boldsymbol{A}t}$ 的无穷级数定义式的前五项. 逐项关于 $t$ 求导，证明：你得到了 $\boldsymbol{A}\mathrm{e}^{\boldsymbol{A}t}$ 的前四项. 结论：$\mathrm{e}^{\boldsymbol{A}t}\boldsymbol{u}_0$ 是方程 $\boldsymbol{u}'=\boldsymbol{A}\boldsymbol{u}$ 的解.

17. 矩阵 $\boldsymbol{B}=\begin{bmatrix}0 & -4\\ 0 & 0\end{bmatrix}$ 满足 $\boldsymbol{B}^2=0$. 通过无穷级数定义求 $\mathrm{e}^{\boldsymbol{B}t}$（提示：此时级数只有有限项有贡献）. 验证：$\mathrm{e}^{\boldsymbol{B}t}$ 的导数为 $\boldsymbol{B}\mathrm{e}^{\boldsymbol{B}t}$.

18. 带初值条件 $\boldsymbol{u}(0)$ 的微分方程 $\boldsymbol{u}'=\boldsymbol{A}\boldsymbol{u}$ 在 $T$ 时刻的取值是 $\mathrm{e}^{\boldsymbol{A}T}\boldsymbol{u}(0)$. 再经过时间 $t$ 后，取值为 $\mathrm{e}^{\boldsymbol{A}t}\mathrm{e}^{\boldsymbol{A}T}\boldsymbol{u}_0$.[①]该微分方程的解在 $t+T$ 时刻的取值也可以写作_____. 由此我们断言：$\mathrm{e}^{\boldsymbol{A}t}\mathrm{e}^{\boldsymbol{A}T}=$_____.

19. 如果 $\boldsymbol{A}^2=\boldsymbol{A}$，根据 $\mathrm{e}^{\boldsymbol{A}t}$ 的无穷级数定义证明：$\mathrm{e}^{\boldsymbol{A}t}=\boldsymbol{I}+(\mathrm{e}^t-1)\boldsymbol{A}$.

20. 一般来说，$\mathrm{e}^{\boldsymbol{A}}\mathrm{e}^{\boldsymbol{B}}$、$\mathrm{e}^{\boldsymbol{B}}\mathrm{e}^{\boldsymbol{A}}$、$\mathrm{e}^{\boldsymbol{A}+\boldsymbol{B}}$ 三者互不相等. 以下面的矩阵为例验证这个事实：

$$\boldsymbol{A}=\begin{bmatrix}1 & 4\\ 0 & 0\end{bmatrix}\qquad\boldsymbol{B}=\begin{bmatrix}0 & -4\\ 0 & 0\end{bmatrix}\qquad\boldsymbol{A}+\boldsymbol{B}=\begin{bmatrix}1 & 0\\ 0 & 0\end{bmatrix}$$

21. 把 $\boldsymbol{A}=\begin{bmatrix}1 & 3\\ 0 & 0\end{bmatrix}$ 代入无穷级数求 $\mathrm{e}^{\boldsymbol{A}t}$. 提示：首先计算 $\boldsymbol{A}^2,\boldsymbol{A}^3,\cdots$，找出 $\boldsymbol{A}^n$ 的规律：

$$\mathrm{e}^{\boldsymbol{A}t}=\begin{bmatrix}1 & 0\\ 0 & 1\end{bmatrix}+\begin{bmatrix}t & 3t\\ 0 & 0\end{bmatrix}+\frac{1}{2}\begin{bmatrix}\ & \ \\ \ & \ \end{bmatrix}+\cdots=\begin{bmatrix}\mathrm{e}^t & \ \\ 0 & \ \end{bmatrix}$$

22.（推荐）从以下两个角度说明矩阵指数 $\mathrm{e}^{\boldsymbol{A}t}$ 一定不是奇异矩阵：

（1）写下 $\mathrm{e}^{\boldsymbol{A}t}$ 的逆矩阵　　（2）说明 $\mathrm{e}^{\boldsymbol{A}t}$ 的特征值都非零

① 译者注：相当于把时间零点定在 $T$，那么该取值就是同一个微分方程，初值是 $\mathrm{e}^{\boldsymbol{A}t}\boldsymbol{u}(0)$ 在时刻 $T$ 处的取值.

23. 二阶差分 $Y_{n+1-2Y_n+Y_{n-1}} = -(\Delta t)^2 Y_n$ 可以写成向量的一阶差分方程：

$$\begin{aligned} Y_{n+1} &= Y_n + \Delta t Z_n \\ Z_{n+2} &= Z_n - \Delta Y_{n+1} \end{aligned} \qquad \begin{bmatrix} 1 & 0 \\ \Delta t & 1 \end{bmatrix} \begin{bmatrix} Y_{n+1} \\ Z_{n+1} \end{bmatrix} = \begin{bmatrix} 1 & \Delta t \\ 0 & 1 \end{bmatrix} \begin{bmatrix} Y_n \\ Z_n \end{bmatrix}$$

对等式左边的矩阵取逆矩阵，把差分方程写成 $\boldsymbol{U}_{n+1} = \boldsymbol{A}\boldsymbol{U}_n$ 的形式. 证明：$\det \boldsymbol{A} = 1$. 取较大的时间间隔 $\Delta t = 1$，求 $\boldsymbol{A}$ 的特征值 $\lambda_1$ 和 $\lambda_2 = \overline{\lambda_1}$：

$$\boldsymbol{A} = \begin{bmatrix} 1 & 1 \\ -1 & 0 \end{bmatrix} \quad \text{满足} \quad |\lambda_1| = |\lambda_2| = 1. \text{ 证明：} \boldsymbol{A}^6 = \boldsymbol{I}, \text{ 所以 } u_6 = u_0.$$

24. 习题 23 中的蛙跳法对于小时间间隔 $\Delta t$ 相当成功，但是对于大时间间隔就未必了. 当 $\Delta t = \sqrt{2}$ 和 2 时，求 $\boldsymbol{A}$ 的特征值. 证明：如果 $\Delta t > 2$，则特征值的模长 $|\lambda| > 1$，因此 $\boldsymbol{U}_n \boldsymbol{A}^n \boldsymbol{U}_0$ 中的矩阵幂就迅速爆炸了.

$$\Delta t = \sqrt{2} \text{ 时，} \boldsymbol{A} = \begin{bmatrix} 1 & \sqrt{2} \\ -\sqrt{2} & 1 \end{bmatrix} \qquad \Delta t = 2 \text{ 时，} \boldsymbol{A} = \begin{bmatrix} 1 & 2 \\ -2 & -3 \end{bmatrix}, \text{ 处于不稳定的临界状态}$$

25. 梯形法（半前向/半后向）是数值求解 $y'' = -y$ 非常好的方法. 这可能是使 $(Y_n, Z_n)$ 精确位于圆上的最佳方法.

$$\text{梯形法} \qquad \begin{bmatrix} 1 & -\Delta t/2 \\ \Delta t/2 & 1 \end{bmatrix} \begin{bmatrix} Y_{n+1} \\ Z_{n+1} \end{bmatrix} = \begin{bmatrix} 1 & \Delta t/2 \\ -\Delta t/2 & 1 \end{bmatrix} \begin{bmatrix} Y_n \\ Z_n \end{bmatrix}$$

（1）对等式左边的矩阵取逆，把方程写成 $\boldsymbol{U}_{n+1} = \boldsymbol{A}\boldsymbol{U}_n$. 证明：$\boldsymbol{A}$ 是正交矩，或者等价地，$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A} = \boldsymbol{I}$. 所以点 $\boldsymbol{U}_n$ 始终在圆周上. 进一步证明：若 $\boldsymbol{B}$ 是反对称矩阵 $\boldsymbol{B}^{\mathrm{T}} = -\boldsymbol{B}$，则 $\boldsymbol{C} = (\boldsymbol{I} - \boldsymbol{B})^{-1}(\boldsymbol{I} + \boldsymbol{B})$ 是正交矩阵.

（2）（选做，关于 MATLAB）从 $\boldsymbol{U}_0 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$ 开始，以时间间隔 $\Delta t = 2\pi/32$ 迭代 32 次，请问 $\boldsymbol{U}_{32}$ 是否和 $\boldsymbol{U}_0$ 重合？其中可能会有一点点误差.

26. 按照以下三种思路中的一种，证明：$(\mathrm{e}^{\boldsymbol{A}})^2 = \mathrm{e}^{2\boldsymbol{A}}$.

（1）解线性方程组 $\mathrm{d}\boldsymbol{u}/\mathrm{d}t = \boldsymbol{A}\boldsymbol{u}$，从时刻 $t = 0$ 到时刻 $t = 1$、再到时刻 $t = 2$，等效于从时刻 $t = 0$ 直接到时刻 $t = 2$.

（2）验证无穷级数 $\left(\boldsymbol{I} + \boldsymbol{A} + \dfrac{\boldsymbol{A}^2}{2} + \cdots\right)^2$ 和无穷级数 $\boldsymbol{I} + 2\boldsymbol{A} + \dfrac{(2\boldsymbol{A})}{2} + \cdots = \mathrm{e}^{2\boldsymbol{A}}$ 吻合.

（3）如果 $\boldsymbol{A}$ 可相似对角化，则 $(\boldsymbol{X}\mathrm{e}^{\boldsymbol{\Lambda}}\boldsymbol{X}^{-1})(\boldsymbol{X}\mathrm{e}^{\boldsymbol{\Lambda}}\boldsymbol{X}^{-1}) = \boldsymbol{X}\mathrm{e}^{2\boldsymbol{\Lambda}}\boldsymbol{X}^{-1}$.

## 6.6 用 $QR$ 计算特征值

本节要介绍的是用于求解矩阵 $\boldsymbol{A}$ 特征值的一种非常出色的算法，其步骤也非常容易理解. 从矩阵 $\boldsymbol{A}$ 开始，做一个相似变换得到矩阵 $\boldsymbol{A}_0 = \boldsymbol{B}^{-1}\boldsymbol{A}\boldsymbol{B}$（记住，相似矩阵具有相同的特征值）. 如果 $\boldsymbol{A}_0$ 已经是上三角矩阵，那么其特征值就是对角元，问题也就解决了.

第一步变换要求 $\boldsymbol{A}_0$ 比 $\boldsymbol{A}$ 更接近上三角矩阵，但必须允许有一个额外的非零对角线. 此处我们省略了关于 $\boldsymbol{B}$ 的详细信息：

$$\boldsymbol{A}_0 = \boldsymbol{B}^{-1}\boldsymbol{A}\boldsymbol{B} = \begin{bmatrix} a_{11} & a_{12} & \cdots & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & \cdots & a_{2n} \\ 0 & a_{32} & \ddots & \cdots & a_{3n} \\ \vdots & \vdots & \ddots & \cdots & \vdots \\ 0 & 0 & \cdots & a_{n,n-1} & a_{nn} \end{bmatrix}$$

$\boldsymbol{A}_0$ 是 Hessenberg 矩阵：它有一个非零下次对角线. 从 $\boldsymbol{A}_0$ 到 $\boldsymbol{A}_1$、$\boldsymbol{A}_2\cdots$ 的所有步骤都会产生 Hessenberg 矩阵. 神奇之处在于每一步都能使下次对角线越来越小；结果当然就是矩阵 $\boldsymbol{A}_1$、$\boldsymbol{A}_2\cdots$ 的对角线元素趋近于 $\boldsymbol{A}$ 的特征值. 每一步都是 $\boldsymbol{A}_{k+1} = \boldsymbol{B}_k^{-1}\boldsymbol{A}_k\boldsymbol{B}_k$ 的形式，因此所有的 $\boldsymbol{A}_i$ 都是相似矩阵——这保证了特征值不会发生变化.

最优美、最重要的矩阵是对称矩阵. 在这种情况下，如果 $\boldsymbol{B}$ 是正交矩阵 $\boldsymbol{Q}$（$\boldsymbol{Q}^{-1} = \boldsymbol{Q}^{\mathrm{T}}$），那么对称性在每一步都得到了保持：

$$\text{若}\boldsymbol{A}^{\mathrm{T}} = \boldsymbol{A}，\text{则}\boldsymbol{A}_0^{\mathrm{T}} = (\boldsymbol{Q}^{-1}\boldsymbol{A}\boldsymbol{Q})^{\mathrm{T}} = (\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{Q})^{\mathrm{T}} = \boldsymbol{Q}^{\mathrm{T}}\boldsymbol{Q}\boldsymbol{Q} = \boldsymbol{Q}^{-1}\boldsymbol{A}\boldsymbol{Q} = \boldsymbol{Q}_0 \tag{6.62}$$

对称性告诉我们：若矩阵只有唯一的下次对角线，那它也只有唯一的上次对角线. 换句话说，之前的步骤中，每一个 $\boldsymbol{A}_{k+1} = \boldsymbol{B}_k^{-1}\boldsymbol{A}_k\boldsymbol{B}_k = \boldsymbol{Q}_k^{-1}\boldsymbol{A}_k\boldsymbol{Q}_k$ 只有三条非零对角线. 这个计算速度非常快，收敛速度也非常快.

准备工作做完了，该介绍如何从 $\boldsymbol{A}_k$ 得到 $\boldsymbol{A}_{k+1} = \boldsymbol{B}_k^{-1}\boldsymbol{A}_k\boldsymbol{B}_k$ 了. 首先做 Gram-Schmnidt 正交化：$\boldsymbol{A}_k = \boldsymbol{Q}_k\boldsymbol{R}_k$. 记住：由 4.4 节可知，$\boldsymbol{Q}_k$ 是正交矩阵，$\boldsymbol{R}_k$ 是上三角矩阵. 于是需要的正交矩阵已经摆在面前了，其实际效果是交换 $\boldsymbol{QR}$ 分解中两个因子的位置：

$$\boldsymbol{QR}\text{ 算法}\qquad \boxed{\boldsymbol{A}_{k+1} = \boldsymbol{R}_k\boldsymbol{Q}_k = \boldsymbol{Q}_k^{-1}\boldsymbol{A}_k\boldsymbol{Q}_k} \tag{6.63}$$

$\boldsymbol{A}_{k+1}$ 和 $\boldsymbol{A}_k$ 相似，所以它和 $\boldsymbol{A}_k$ 有相同的特征值. 由式(6.62)，因为 $\boldsymbol{Q}_k$ 是正交矩阵，若 $\boldsymbol{A}_k$ 对称则 $\boldsymbol{A}_{k+1}$ 也对称. 神奇之处（我们通过一个例子来说明）在于，$\boldsymbol{A}_1, \boldsymbol{A}_2, \cdots$ 的下对角线元素的确越来越小！所有矩阵 $\boldsymbol{A}_i$ 都有相同的特征值，这些特征值迅速出现在对角线上.[①]

**例 6.19**　$\boldsymbol{A}_0 = \begin{bmatrix} \cos\theta & \sin\theta \\ \sin\theta & 0 \end{bmatrix} = \boldsymbol{QR} = \begin{bmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{bmatrix}\begin{bmatrix} 1 & \cos\theta\sin\theta \\ 0 & -\sin^2\theta \end{bmatrix}$. 交换 $\boldsymbol{Q}$ 和 $\boldsymbol{R}$ 得 $\boldsymbol{A}_1$，它和 $\boldsymbol{A}_0$ 有相同的特征值. 但是观察其下对角线元素，该元素从 $\sin\theta$ 降到了 $-\sin^3\theta$:

$$\boldsymbol{A}_1 = \boldsymbol{RQ} = \begin{bmatrix} 1 & \cos\theta \\ 0 & -\sin^2\theta \end{bmatrix}\begin{bmatrix} \cos\theta & \sin\theta \\ \sin\theta & 0 \end{bmatrix} = \begin{bmatrix} \cos\theta(1+\sin^2\theta) & -\sin^3\theta \\ -\sin^3\theta & -\sin^2\theta\cos\theta \end{bmatrix}$$

校验计算过程可知：迹仍然是 $\cos\theta$，行列式仍然是 $-\sin^2\theta$，一切都和 $\boldsymbol{A}_0$ 一样. 但是下三角线元素从 $\sin\theta$ 变成了 $-\sin^3\theta$，也就是说我们观察到了三次方收敛（非常罕见）! 新的矩阵 $\boldsymbol{A}_1$ 几乎是对角矩阵，其最后一个元素 $-\sin^2\theta\cos\theta$ 非常接近 $\boldsymbol{A}_0$ 和 $\boldsymbol{A}_1$ 的一个真正的特征值.

---

① 译者注：读者阅读这一部分内容可能有脱节感，因为在 $\boldsymbol{QR}$ 算法中，我们只是不断交换正交矩阵和上三角矩阵的乘法顺序，并没有将矩阵化成 Hessenberg 这一步；所以前面关于把 $\boldsymbol{A}$ 转化成 Hessenberg 矩阵 $\boldsymbol{A}_0$ 再进行后面步骤的做法不知道有什么用. 对此，我们作两点说明. 首先对于对称矩阵，不经过把 $\boldsymbol{A}$ 转化成 $\boldsymbol{A}_0$ 这一步，使用 $\boldsymbol{QR}$ 算法本身是有效的，不断迭代之后，$\boldsymbol{A}_k$ 的对角线元素的极限的确是 $\boldsymbol{A}$ 的特征值；另一方面，如果加上把 $\boldsymbol{A}$ 转化成 $\boldsymbol{A}_0$ 这一步能使 $\boldsymbol{QR}$ 算法更有效，计算复杂度从 $O(n^3)$ 降到 $O(n^2)$.

$\boldsymbol{A}_0$ 的 $(2,2)$ 元素为零是有帮助的；如果不是 0，我们总可以通过平移单位阵的适当的常数倍来使 $(\boldsymbol{A}_0)_{22}=0$，然后在该步骤结束时平移回来. “带平移的 $\boldsymbol{QR}$ 算法”在数值计算上非常成功——最初计算特征多项式 $\det(\boldsymbol{A}-\lambda\boldsymbol{I})$ 再求根的想法与之大相径庭，相比而言，实在是一种失败透顶的方法.

计算线性代数是一个发展成熟且拥有丰富的优秀教材的学科. 在这里我们提及两本书，同时在网络上你可以找到更多书籍. 一本是《数值线性代数》（*Numerical Linear Algebra*），由 SIAM 于 1997 年出版，作者是 L. N. Trefethen 和 David Bau. 还有一本是内容丰富、长达 756 页的教材——《矩阵计算》（*Matrix Computations*），第 4 版，由 Gene Golub 和 Charles van Loan 合著，由约翰斯·霍普金斯大学出版社出版.

## 6.7 谈谈微分方程

常系数线性方程是最容易求解的，6.5节简要地讲述了微分方程课程的一部分内容，但还有更多内容. 以下是两个重要的对象.

（1）二阶方程 $mu''+bu'+ku=0$ 在应用中相当重要. 解 $u=\mathrm{e}^{\lambda t}$ 中的指数 $\lambda$ 满足方程 $m\lambda^2+b\lambda+k=0$. 根据阻尼情况，可以分为以下三种：

欠阻尼：$b^2<4mk$　　临界阻尼：$b^2=4mk$　　过阻尼：$b^2>4mk$

这决定了特征值 $\lambda_1$ 和 $\lambda_2$ 是实根、重根还是复根. 当 $\lambda$ 为复数 $a+\mathrm{i}\omega$，解 $u(t)$ 像 $\mathrm{e}^{\mathrm{i}\omega t}$ 那样振荡，同时振幅以 $\mathrm{e}^{at}$ 的速度变化.

（2）方程中没有强迫项 $f(t)$，我们找到的是“零空间解”. 为了得到完整解，我们需要在 $u_n(t)$ 上加一个特解 $u_p(t)$，以平衡外力 $f(t)$. 这个解也可以通过**Laplace 变换**来构造和研究：

在时刻 $s$ 输入 $f(s)$
增长因子 $\mathrm{e}^{\boldsymbol{A}(t-s)}$
将截止到时刻 $t$ 的输出累计起来

$$u_p=\int_0^t \mathrm{e}^{\boldsymbol{A}(t-s)}f(s)\,\mathrm{d}s.$$

在实际应用中，非线性微分方程一般用数值方法求解，其中一种精度较高的方法是 Runge-Kutta 方法. 对于微分方程 $\mathrm{d}u/\mathrm{d}t=f(u)$，其常数解为 $u(t)=Y$，其中 $Y$ 是 $f$ 的零点：$f(Y)=0$. 此时 $\mathrm{d}u/\mathrm{d}t=0$，即没有运动. 偏离 $Y$ 时，只能让计算机进行计算了.

这些基础对象是我另一本教科书《微分方程与线性代数》（与本书配套）的主题.

# 第 7 章

CHAPTER 7

# 奇异值分解

本章阐述了奇异值和奇异向量. 它们适用于任意矩阵，正方形的或者长方形的. 奇异向量是特征向量的一种推广. 但是我们需要两族正交的向量：输入向量 $\boldsymbol{v}_1, \boldsymbol{v}_2, \cdots, \boldsymbol{v}_n$ 以及输出向量 $\boldsymbol{u}_1, \boldsymbol{u}_2, \cdots, \boldsymbol{u}_m$. 这对于 $m \times n$ 矩阵来说完全是自然的. 向量 $\boldsymbol{v}_1, \boldsymbol{v}_2, \cdots, \boldsymbol{v}_r$ 是行空间的一组基，$\boldsymbol{u}_1, \boldsymbol{u}_2, \cdots, \boldsymbol{u}_r$ 是列空间的一组基. 然后我们可以通过 $r$ 个秩为 1 的矩阵以及对角矩阵 $\boldsymbol{\Sigma}$ 中的正的奇异值 $\sigma_1 \geqslant \sigma_2 \geqslant \cdots \geqslant \sigma_r > 0$ 来表示 $\boldsymbol{A}$，其中 $r = \operatorname{rank}(\boldsymbol{A})$.

奇异值分解　　$\boldsymbol{A} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\mathrm{T}} = \sigma_1 \boldsymbol{u}_1 \boldsymbol{v}_1^{\mathrm{T}} + \sigma_2 \boldsymbol{u}_2 \boldsymbol{v}_2^{\mathrm{T}} + \cdots + \sigma_r \boldsymbol{u}_r \boldsymbol{v}_r^{\mathrm{T}}.$

右奇异向量 $\boldsymbol{v}_i$ 是 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 的特征向量. 它们给出了 $\boldsymbol{A}$ 的行空间和零空间的基. 左奇异向量 $\boldsymbol{u}_i$ 是 $\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 的特征向量. 它们给出了 $\boldsymbol{A}$ 的列空间和左零空间的基. 那么对于 $i \leqslant r$，$\boldsymbol{A}\boldsymbol{v}_i$ 等于 $\sigma_i \boldsymbol{u}_i$. 矩阵 $\boldsymbol{A}$ 可以通过这两组正交基进行对角化：$\boldsymbol{A}\boldsymbol{V} = \boldsymbol{U}\boldsymbol{\Sigma}$.

注意到 $\boldsymbol{U}\boldsymbol{\Sigma}$ 的非零列就是 $\sigma_1 \boldsymbol{u}_1, \sigma_2 \boldsymbol{u}_2, \cdots, \sigma_r \boldsymbol{u}_r$. 那么 $\boldsymbol{U}\boldsymbol{\Sigma}$ 乘以 $\boldsymbol{V}^{\mathrm{T}}$ 可以看作列和行做乘法——类似于对称矩阵的谱分解 $\boldsymbol{S} = \boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\mathrm{T}}$.

当 $\boldsymbol{A}$ 是对称正定矩阵 $\boldsymbol{S}$ 时，$\boldsymbol{u}_i = \boldsymbol{v}_i$. 奇异向量就是特征向量 $\boldsymbol{q}_i$. 奇异值 $\sigma_i$ 就是 $\boldsymbol{S}$ 的特征值. 如果 $\boldsymbol{A}$ 不是方阵或者不对称，那么需要 $\boldsymbol{A} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\mathrm{T}}$ 而不是 $\boldsymbol{S} = \boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\mathrm{T}}$. 图 7.1会给出如何从 $\boldsymbol{x}$ 通过 $\boldsymbol{V}^{\mathrm{T}}\boldsymbol{x}$、$\boldsymbol{\Sigma}\boldsymbol{V}^{\mathrm{T}}\boldsymbol{x}$ 逐步变成 $\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\mathrm{T}}\boldsymbol{x} = \boldsymbol{A}\boldsymbol{x}$. 这一过程就是将圆上的单位向量变换为椭圆上的向量 $\boldsymbol{A}\boldsymbol{x}$.

奇异值分解（Singular Value Decomposition，SVD）可以帮助我们更好地理解矩阵中的数据. 在将数据单位化以及除以 $n-1$（7.3 节）后，$\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 可看作样本协方差矩阵. 它的特征值是 $\sigma_1^2, \sigma_2^2, \cdots, \sigma_r^2$. 它们的特征向量就是奇异值分解中的 $\boldsymbol{u}$. 主成分分析 (Principal Component Analysis，PCA) 就是在考虑矩阵 $\boldsymbol{A}$ 的奇异特征向量.

奇异值分解在图像处理中有重要应用. 可以将图片或是像素组成的矩阵分解为一些秩 1 矩阵的和. 每次加入一个 $\sigma_i \boldsymbol{u}_i \boldsymbol{v}_i^{\mathrm{T}}$，图片会更加清晰. 7.2 节给出了一些例子以及一个非常好的网站. 7.3 节描述了 PCA 以及它和统计中的协方差矩阵之间的联系.

## 7.1　奇异值和奇异向量

（1）矩阵 $\boldsymbol{A}$ 的奇异值分解为 $\boldsymbol{A} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\mathrm{T}}$ 或者 $\boldsymbol{A}\boldsymbol{V} = \boldsymbol{U}\boldsymbol{\Sigma}$.

（2）$\boldsymbol{A}\boldsymbol{v}_i = \sigma_i \boldsymbol{u}_i$ 中的奇异向量 $\boldsymbol{v}_i$、$\boldsymbol{u}_i$ 各自均是正交的：$\boldsymbol{V}^{\mathrm{T}}\boldsymbol{V} = \boldsymbol{I}$ 以及 $\boldsymbol{U}^{\mathrm{T}}\boldsymbol{U} = \boldsymbol{I}$.

（3）对角阵 $\boldsymbol{\Sigma}$ 包括了所有的奇异值 $\sigma_1 \geqslant \sigma_2 \geqslant \cdots \geqslant \sigma_r > 0$.
（4）奇异值的平方 $\sigma_i^2$ 是 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 和 $\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 的特征值 $\lambda_i$.

对称矩阵的特征向量是正交的. 我们希望进一步讨论所有的矩阵，但是仍然保留正交性. 为了对任意的 $m \times n$ 矩阵进行讨论，我们需要 $\mathbb{R}^n$ 中的 $n$ 个正交向量 $\boldsymbol{v}_1, \boldsymbol{v}_2, \cdots, \boldsymbol{v}_n$ 和第二个 $\mathbb{R}^m$ 中的正交向量集 $\boldsymbol{u}_1, \boldsymbol{u}_2, \cdots, \boldsymbol{u}_m$. 和对称阵中的 $\boldsymbol{S}\boldsymbol{x} = \lambda\boldsymbol{x}$ 类似，不过我们希望得到 $\boldsymbol{A}\boldsymbol{v} = \sigma\boldsymbol{u}$.

下面这个非对称矩阵 $\boldsymbol{A}$ 有两个正交的输入向量 $\boldsymbol{v}_1 = \begin{bmatrix}1 & 1\end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{v}_2 = \begin{bmatrix}-1 & 1\end{bmatrix}^{\mathrm{T}}$：

$$\begin{bmatrix}5 & 4\\ 0 & 3\end{bmatrix}\begin{bmatrix}1\\1\end{bmatrix} = \begin{bmatrix}9\\3\end{bmatrix} \qquad \begin{bmatrix}5 & 4\\ 0 & 3\end{bmatrix}\begin{bmatrix}-1\\1\end{bmatrix} = \begin{bmatrix}-1\\3\end{bmatrix}$$

输出向量 $\begin{bmatrix}9 & 3\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}-1 & 3\end{bmatrix}^{\mathrm{T}}$ 也是正交的！$\boldsymbol{v}_1$、$\boldsymbol{v}_2$ 和 $\boldsymbol{u}_1$、$\boldsymbol{u}_2$ 不是单位向量，但是很容易进行修正. $\begin{bmatrix}1 & 1\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}-1 & 1\end{bmatrix}^{\mathrm{T}}$ 除以 $\sqrt{2}$，$\begin{bmatrix}3 & 1\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}-1 & 3\end{bmatrix}^{\mathrm{T}}$ 除以 $\sqrt{10}$，就将这些向量都单位化了. 奇异值 $\sigma_1 = 3\sqrt{5}, \sigma_2 = \sqrt{5}$：

$$\boxed{\boldsymbol{A}\boldsymbol{v} = \sigma\boldsymbol{u}} \qquad \begin{bmatrix}5 & 4\\ 0 & 3\end{bmatrix}\boldsymbol{v}_1 = 3\sqrt{5}\boldsymbol{u}_1 \qquad \begin{bmatrix}5 & 4\\ 0 & 3\end{bmatrix}\boldsymbol{v}_2 = \sqrt{5}\boldsymbol{u}_2. \tag{7.1}$$

我们可以将这两个向量公式写为一个矩阵公式 $\boldsymbol{A}\boldsymbol{V} = \boldsymbol{U}\boldsymbol{\Sigma}$. 输入向量 $\boldsymbol{v}_1$、$\boldsymbol{v}_2$ 构成了 $\boldsymbol{V}$. 输出向量 $\sigma_1\boldsymbol{u}_1$、$\sigma_2\boldsymbol{u}_2$ 构成 $\boldsymbol{U}\boldsymbol{\Sigma}$，其中 $\dfrac{\sqrt{5}}{\sqrt{10}} = \dfrac{1}{\sqrt{2}}$.

$$\boldsymbol{A}\boldsymbol{V} = \begin{bmatrix}5 & 4\\ 0 & 3\end{bmatrix}\underbrace{\begin{bmatrix}1 & -1\\ 1 & 1\end{bmatrix}}_{\sqrt{2}} = \underbrace{\begin{bmatrix}3 & -1\\ 1 & 3\end{bmatrix}}_{\sqrt{10}}\begin{bmatrix}3\sqrt{5} & 0\\ 0 & \sqrt{5}\end{bmatrix} = \boldsymbol{U}\boldsymbol{\Sigma} \tag{7.2}$$

$\boldsymbol{V}$ 和 $\boldsymbol{U}$ 都是正交矩阵！如果我们将 $\boldsymbol{A}\boldsymbol{V} = \boldsymbol{U}\boldsymbol{\Sigma}$ 右乘 $\boldsymbol{V}^{\mathrm{T}}$，式子左边将只有 $\boldsymbol{A}$：

$$\boxed{\boldsymbol{A}\boldsymbol{V} = \boldsymbol{U}\boldsymbol{\Sigma} \quad \text{转化为} \quad \boldsymbol{A} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\mathrm{T}}. \quad \text{也可以写成} \boldsymbol{A} = \sigma_1\boldsymbol{u}_1\boldsymbol{v}_1^{\mathrm{T}} + \sigma_2\boldsymbol{u}_2\boldsymbol{v}_2^{\mathrm{T}}.} \tag{7.3}$$

这些奇异值分解包含了所有的信息. 剩下的问题是如何找到正交矩阵 $\boldsymbol{V}$ 和 $\boldsymbol{U}$.

任意矩阵 $\boldsymbol{A}$ 都可以被两组奇异向量对角化，而不是一组特征向量.

在上面这个 $2 \times 2$ 矩阵的例子中，$\sigma_1\boldsymbol{u}_1\boldsymbol{v}_1^{\mathrm{T}}$ 比 $\sigma_2\boldsymbol{u}_2\boldsymbol{v}_2^{\mathrm{T}}$ 更重要，原因就是 $\sigma_1 = 3\sqrt{5}$ 比 $\sigma_2 = \sqrt{5}$ 大. 要反解 $\boldsymbol{A}$，把这两部分相加即可：

$$\frac{3\sqrt{5}}{\sqrt{10}\sqrt{2}}\begin{bmatrix}3\\1\end{bmatrix}\begin{bmatrix}1 & 1\end{bmatrix} + \frac{\sqrt{5}}{\sqrt{10}\sqrt{2}}\begin{bmatrix}-1\\3\end{bmatrix}\begin{bmatrix}-1 & 1\end{bmatrix} = \frac{3}{2}\begin{bmatrix}3 & 3\\1 & 1\end{bmatrix} + \frac{1}{2}\begin{bmatrix}1 & -1\\-3 & 3\end{bmatrix} = \begin{bmatrix}5 & 4\\0 & 3\end{bmatrix}. \tag{7.4}$$

### 7.1.1 奇异值分解的几何意义

奇异值分解将矩阵 $\boldsymbol{A}$ 分解为 $\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\mathrm{T}}$：(正交阵) × (对角阵) × (正交阵). 在二维空间我们可以画出这些步骤. 正交矩阵 $\boldsymbol{U}$ 和 $\boldsymbol{V}$ 将平面进行了旋转. 对角矩阵 $\boldsymbol{\Sigma}$ 沿着坐标轴伸展. 图 7.1 表示**旋转**乘**伸缩**乘**旋转**. **圆上的向量 $\boldsymbol{v}$ 通过 $\boldsymbol{A}\boldsymbol{v} = \sigma\boldsymbol{u}$ 化为椭圆上的向量.**

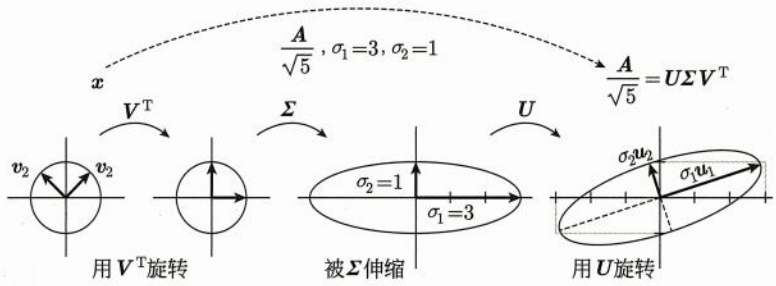


图 7.1　二阶正交矩阵和对角矩阵的几何表现

图 7.1 讨论了以 $\sigma_1>0$ 和 $\sigma_2>0$ 为奇异值的一个 $2\times 2$ 可逆矩阵如何作用到向量上. 首先是旋转变换将 $\boldsymbol{x}$ 变为 $\boldsymbol{V}^{\mathrm{T}}\boldsymbol{x}$，然后伸缩变换 $\boldsymbol{\Sigma}$ 将其变为 $\boldsymbol{\Sigma V}^{\mathrm{T}}\boldsymbol{x}$，最后再通过旋转得到 $\boldsymbol{U\Sigma V}^{\mathrm{T}}\boldsymbol{x}$. 我们假定所有的行列式都为正来避免反射. 矩阵的四个元素 $a$、$b$、$c$、$d$ 与旋转的两个角度 $\theta$、$\phi$ 以及 $\boldsymbol{\Sigma}$ 中的两个对角元 $\sigma_1$、$\sigma_2$ 紧密相连.

$$\boldsymbol{A}=\begin{bmatrix}a & b\\ c & d\end{bmatrix}=\begin{bmatrix}\cos\theta & -\sin\theta\\ \sin\theta & \cos\theta\end{bmatrix}\begin{bmatrix}\sigma_1 & \\ & \sigma_2\end{bmatrix}\begin{bmatrix}\cos\phi & \sin\phi\\ -\sin\phi & \cos\phi\end{bmatrix}. \tag{7.5}$$

**问题 1**　如果 $\boldsymbol{A}$ 是对称矩阵，那么 $b=c$. 于是 $A$ 只有 3 个（不是 4 个）参数. 那么对于对称矩阵，奇异值分解中的 $\theta$、$\phi$、$\sigma_1$、$\sigma_2$ 这 4 个参数是怎么约化为 3 个的?

**问题 2**　如果 $\theta=30°$，$\sigma_1=2$，$\sigma_2=1$ 以及 $\phi=60°$，$\boldsymbol{A}$ 等于什么? 验证 $\det\boldsymbol{A}=2$.

$$\boldsymbol{A}=\begin{bmatrix}\sqrt{3}/2 & -1/2\\ 1/2 & \sqrt{3}/2\end{bmatrix}\begin{bmatrix}2 & \\ & 1\end{bmatrix}\begin{bmatrix}1/2 & \sqrt{3}/2\\ -\sqrt{3}/2 & 1/2\end{bmatrix}=\frac{1}{4}\begin{bmatrix}3\sqrt{3} & 5\\ -1 & 3\sqrt{3}\end{bmatrix}. \tag{7.6}$$

**问题 3**　如果 $\boldsymbol{A}$ 是 $3\times 3$ 矩阵（9 个参数），那么 $\boldsymbol{\Sigma}$ 有 3 个奇异值. $\boldsymbol{U}$ 和 $\boldsymbol{V}$ 具有 3 个旋转，包含 3+3+3=9 个数. 对一个飞行员来说这三个旋转是什么?

答案：一架飞机可以俯仰、旋转、横滚（参考欧拉角）.

**问题 4**　如果 $\boldsymbol{S}=\boldsymbol{Q\Lambda Q}^{\mathrm{T}}$ 是对称正定矩阵，它的奇异值分解是什么?

答案：奇异值分解是 $\boldsymbol{U\Sigma V}^{\mathrm{T}}=\boldsymbol{Q\Lambda Q}^{\mathrm{T}}$. 矩阵 $\boldsymbol{U}=\boldsymbol{V}=\boldsymbol{Q}$ 是正交的. 对角特征值矩阵 $\boldsymbol{\Lambda}$ 就是奇异值矩阵 $\boldsymbol{\Sigma}$.

**问题 5**　如果 $\boldsymbol{S}=\boldsymbol{Q\Lambda Q}^{\mathrm{T}}$ 有负的特征值（$\boldsymbol{Sx}=-\alpha\boldsymbol{x}$），奇异值 $\sigma$ 和相应的奇异向量 $\boldsymbol{v}$ 和 $\boldsymbol{u}$ 是什么?

答案：奇异值是 $\sigma=+\alpha$（正的）. 一个奇异向量（$\boldsymbol{v}$ 或 $\boldsymbol{u}$）必须是 $-\boldsymbol{x}$（符号取反），那么 $\boldsymbol{Sx}=-\alpha\boldsymbol{x}$ 就变为 $\boldsymbol{Sv}=\sigma\boldsymbol{u}$，两个符号变化抵消了.

### 7.1.2　奇异值分解的完整型

奇异值分解的完整形式包括了 $\boldsymbol{A}$ 和 $\boldsymbol{A}^{\mathrm{T}}$ 的零空间的基. 向量 $\boldsymbol{v}_{r+1},\boldsymbol{v}_{r+2},\cdots,\boldsymbol{v}_n$ 以及 $\boldsymbol{u}_{r+1},\boldsymbol{u}_{r+2},\cdots,\boldsymbol{u}_m$ 补全了正交矩阵 $\boldsymbol{V}$（$n\times n$）和 $\boldsymbol{U}$（$m\times m$）. 那么矩阵 $\boldsymbol{\Sigma}$ 和 $\boldsymbol{A}$ 行列数相等，都是 $m\times n$ 矩阵. 但是 $\boldsymbol{\Sigma}$ 在除了主对角线上的 $r$ 个奇异值 $\sigma_1\geqslant\sigma_2\geqslant\cdots\geqslant\sigma_r>0$ 之外的元素都为 0. 这些 $\sigma_i$ 就是向量 $\boldsymbol{u}_1,\boldsymbol{u}_2,\cdots,\boldsymbol{u}_r$ 的系数.

### 奇异值分解的完整型

完整的奇异值分解

$$\boldsymbol{AV}=\boldsymbol{U\Sigma}$$

$$(m\times n)(n\times n)=\quad \boldsymbol{A}\left[\boldsymbol{v}_1\cdots\boldsymbol{v}_r\quad \boldsymbol{v}_{r+1}\cdots\boldsymbol{v}_n\right]=\left[\boldsymbol{u}_1\cdots\boldsymbol{u}_r\quad \boldsymbol{u}_{r+1}\cdots\boldsymbol{u}_m\right]\begin{bmatrix}\sigma_1 & & & 0\\ & \ddots & & \\ & & \sigma_r & 0\\ 0 & \cdots & 0 & 0\end{bmatrix}$$

$$(m\times m)(m\times n)$$

$$\boldsymbol{V}^{\mathrm{T}}=\boldsymbol{V}^{-1}\quad \boldsymbol{U}^{\mathrm{T}}=\boldsymbol{U}^{-1}$$

等式两边右乘 $\boldsymbol{V}^{\mathrm{T}}=\boldsymbol{V}^{-1}$ 时，方程 $\boldsymbol{AV}=\boldsymbol{U\Sigma}$ 就化为了奇异值分解 $\boldsymbol{A}=\boldsymbol{U\Sigma V}^{\mathrm{T}}$. 矩阵 $\boldsymbol{V}$ 和 $\boldsymbol{U}$ 是方阵，$\boldsymbol{V}$ 的列向量包含 $\boldsymbol{A}$ 的行空间的基和零空间的一组基，$\boldsymbol{U}$ 的列向量包含 $\boldsymbol{A}$ 的列空间的左零空间的一组基.

### 7.1.3 奇异值分解的简化型

若 $\boldsymbol{A}$ 的秩很小，则其零空间很大，完整的奇异值分解 $\boldsymbol{AV}=\boldsymbol{U\Sigma}$ 中，$\boldsymbol{\Sigma}$ 有很多零. 这些零在矩阵乘法中并不会发挥作用. 奇异值分解的核心是前 $r$ 个（左，右）奇异向量和奇异值. 那 $\boldsymbol{AV}=\boldsymbol{U\Sigma}$ 中的全零部分删去，化简为 $\boldsymbol{AV}_r=\boldsymbol{U}_r\boldsymbol{\Sigma}_r$. 这样将得到奇异值分解的简化型，其中 $\boldsymbol{\Sigma}_r$ 是方阵，整个分解式中矩阵的行数列数为：$(m\times n)(n\times r)=(m\times r)(r\times r)$.

奇异值分解的简化型

$$\boldsymbol{AV}_r=\boldsymbol{U}_r\boldsymbol{\Sigma}_r \qquad \boldsymbol{A}\begin{bmatrix}\\ \boldsymbol{v}_1\cdots\boldsymbol{v}_r\\ \text{行空间}\end{bmatrix}=\begin{bmatrix}\\ \boldsymbol{u}_1\cdots\boldsymbol{u}_r\\ \text{列空间}\end{bmatrix}\begin{bmatrix}\sigma_1 & & \\ & \ddots & \\ & & \sigma_r\end{bmatrix}$$

$$\boldsymbol{Av}_i=\sigma_i\boldsymbol{u}_i \tag{7.7}$$

尽管 $\boldsymbol{V}_r$ 和 $\boldsymbol{U}_r$ 不是方阵，由 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_r$ 和 $\boldsymbol{u}_1,\boldsymbol{u}_2,\cdots,\boldsymbol{u}_r$ 的正交性，我们仍然有 $\boldsymbol{V}_r^{\mathrm{T}}\boldsymbol{V}_r=\boldsymbol{I}_r$ 和 $\boldsymbol{U}_r^{\mathrm{T}}\boldsymbol{U}_r=\boldsymbol{I}_r$. 只不过当 $\boldsymbol{V}_r$ 和 $\boldsymbol{U}_r$ 不是方阵时，它们没有逆：$\boldsymbol{V}_r\boldsymbol{V}_r^{\mathrm{T}}\neq\boldsymbol{I},\boldsymbol{U}_r\boldsymbol{U}_r^{\mathrm{T}}\neq\boldsymbol{I}$. 同时，$\boldsymbol{A}=\boldsymbol{U}_r\boldsymbol{\Sigma}_r\boldsymbol{V}_r^{\mathrm{T}}=\boldsymbol{u}_1\sigma_1\boldsymbol{v}_1^{\mathrm{T}}+\boldsymbol{u}_2\sigma_2\boldsymbol{v}_2^{\mathrm{T}}+\cdots+\boldsymbol{u}_r\sigma_r\boldsymbol{v}_r^{\mathrm{T}}$仍然成立. 我个人认为简化型更方便，完整型 $\boldsymbol{AV}=\boldsymbol{U\Sigma}$ 中的其他运算都是 0，没有必要留着.

**例 7.1** 先前例子中 $2\times 2$ 矩阵满足 $r=m=n=2$，因此简化型就是完整型.

**例 7.2** $\boldsymbol{A}=\begin{bmatrix}1 & 2 & 2\end{bmatrix}=\begin{bmatrix}1\end{bmatrix}\begin{bmatrix}3\end{bmatrix}\left(\frac{1}{3}\begin{bmatrix}1 & 2 & 2\end{bmatrix}\right)=\boldsymbol{U}_r\boldsymbol{\Sigma}_r\boldsymbol{V}_r^{\mathrm{T}}$，则有 $r=1,\sigma_1=3$.

$\boldsymbol{U\Sigma V}^{\mathrm{T}}$ 的其余部分对 $\boldsymbol{A}$ 没有贡献，因为 $\boldsymbol{\Sigma}$ 的其余部分都是 0. 因为秩为 1，所以 $\boldsymbol{A}$ 的分解 $\sigma_1\boldsymbol{u}_1\boldsymbol{v}_1^{\mathrm{T}}+\sigma_2\boldsymbol{u}_2\boldsymbol{v}_2^{\mathrm{T}}+\cdots+\sigma_r\boldsymbol{u}_r\boldsymbol{v}_r^{\mathrm{T}}$ 的有效部分只有 $\sigma_1\boldsymbol{u}_1\boldsymbol{v}_1^{\mathrm{T}}$.

### 7.1.4 奇异值分解的证明

我们的目标是得到分解式 $\boldsymbol{A}=\boldsymbol{U\Sigma V}^{\mathrm{T}}$，也就是说需要确定两个奇异向量集 $\boldsymbol{u}_1,\boldsymbol{u}_2,\cdots,\boldsymbol{u}_m$ 和 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_n$. 一种方法是通过对称矩阵 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 和 $\boldsymbol{AA}^{\mathrm{T}}$ 的谱分解来寻找这些向量：

$$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}=\left(\boldsymbol{V\Sigma}^{\mathrm{T}}\boldsymbol{U}^{\mathrm{T}}\right)\left(\boldsymbol{U\Sigma V}^{\mathrm{T}}\right)=\boldsymbol{V\Sigma}^{\mathrm{T}}\boldsymbol{\Sigma V}^{\mathrm{T}}\quad \text{因为}\quad \boldsymbol{U}^{\mathrm{T}}\boldsymbol{U}=\boldsymbol{I} \tag{7.8}$$

$$\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}=\left(\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\mathrm{T}}\right)\left(\boldsymbol{V}\boldsymbol{\Sigma}^{\mathrm{T}}\boldsymbol{U}^{\mathrm{T}}\right)=\boldsymbol{U}\boldsymbol{\Sigma}^{\mathrm{T}}\boldsymbol{\Sigma}\boldsymbol{U}^{\mathrm{T}}\quad\text{因为}\quad\boldsymbol{V}^{\mathrm{T}}\boldsymbol{V}=\boldsymbol{I}\tag{7.9}$$

式(7.8)和式(7.9)都是对称矩阵. 通常 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 和 $\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 不一样，但是两者的谱分解都是特殊形式 $\boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\mathrm{T}}$. $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 和 $\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 的特征向量构成了 $\boldsymbol{V}$ 和 $\boldsymbol{U}$ 的列向量，也即 $\boldsymbol{A}$ 的奇异向量. 所以从式(7.8)和式(7.9)可以看到 $\boldsymbol{A}=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\mathrm{T}}$ 的三部分是如何通过对称矩阵 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 和 $\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 生成的.

> $\boldsymbol{V}$ 包含了 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 的正交特征向量
> $\boldsymbol{U}$ 包含了 $\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 的正交特征向量
> $\sigma_1^2$ 到 $\sigma_r^2$ 为 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 和 $\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 的非零特征值

到目前为止证明还没有结束， 奇异值分解还要求 $\boldsymbol{A}\boldsymbol{v}_k=\sigma_k\boldsymbol{u}_k$. 当 $k=1,2,\cdots,r$ 时，该等式将右奇异向量 $\boldsymbol{v}_k$ 和左奇异向量 $\boldsymbol{u}_k$ 联系起来，一旦选择了 $\boldsymbol{v}$，实际上也就确定了 $\boldsymbol{u}$ 的符号. 如果 $\boldsymbol{S}\boldsymbol{u}=\lambda\boldsymbol{u}$，那么 $\boldsymbol{S}(-\boldsymbol{u})=\lambda(-\boldsymbol{u})$，所以我们需要知道该选择什么符号. 此外，当 $\lambda$ 是二重特征值时，特征向量将组成整个平面；因此选择两个 $\boldsymbol{v}$ 时，$\boldsymbol{A}\boldsymbol{v}=\sigma\boldsymbol{u}$ 将给出两个 $\boldsymbol{u}$.

我们先从 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 开始，选择它正交的特征向量 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_r$，然后令 $\sigma_k=\sqrt{\lambda_k}$，通过 $\boldsymbol{A}\boldsymbol{v}=\sigma\boldsymbol{u}$ 来确定 $\boldsymbol{u}$:

$$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{v}_k=\sigma_k^2\boldsymbol{v}_k\quad\text{则}\quad\boldsymbol{u}_k=\frac{\boldsymbol{A}\boldsymbol{v}_k}{\sigma_k},\quad k=1,2,\cdots,r.\tag{7.10}$$

这样我们就得到了奇异值分解! 我们来检验一下这样得到的 $\boldsymbol{u}_1,\boldsymbol{u}_2,\cdots,\boldsymbol{u}_r$ 是 $\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 的特征向量.

$$\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}\boldsymbol{u}_k=\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}\left(\frac{\boldsymbol{A}\boldsymbol{v}_k}{\sigma_k}\right)=\boldsymbol{A}\left(\frac{\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{v}_k}{\sigma_k}\right)=\boldsymbol{A}\frac{\sigma_k^2\boldsymbol{v}_k}{\sigma_k}=\sigma_k^2\boldsymbol{u}_k\tag{7.11}$$

注意，我们在对对称矩阵作谱分解时，$\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_n$ 是单位正交的. 接下来验证 $\boldsymbol{u}_1,\boldsymbol{u}_2,\cdots,\boldsymbol{u}_r$ 是单位正交的：

$$\boldsymbol{u}_j^{\mathrm{T}}\boldsymbol{u}_k=\left(\frac{\boldsymbol{A}\boldsymbol{v}_j}{\sigma_j}\right)^{\mathrm{T}}\frac{\boldsymbol{A}\boldsymbol{v}_k}{\sigma_k}=\frac{\boldsymbol{v}_j^{\mathrm{T}}\left(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{v}_k\right)}{\sigma_j\sigma_k}=\frac{\sigma_k}{\sigma_j}\boldsymbol{v}_j^{\mathrm{T}}\boldsymbol{v}_k=\begin{cases}1, & j=k\\ 0, & j\neq k\end{cases}\tag{7.12}$$

式(7.11)的关键是 $\left(\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}\right)\boldsymbol{A}=\boldsymbol{A}\left(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\right)$. 结合律 $(\boldsymbol{A}\boldsymbol{B})\boldsymbol{C}=\boldsymbol{A}(\boldsymbol{B}\boldsymbol{C})$ 是线性代数很多证明的关键. 这样我们就完成了证明.

**例 7.3 (完整解决)**　对 $\boldsymbol{A}=\begin{bmatrix}5 & 4\\ 0 & 3\end{bmatrix}$，求出 $\boldsymbol{U}$、$\boldsymbol{\Sigma}$ 和 $\boldsymbol{V}$，从而写出其奇异值分解.

$\boldsymbol{A}$ 的秩为 2，有两个正的奇异值 $\sigma_1$ 和 $\sigma_2$. 我们可以看到 $\sigma_1$ 比 $\lambda_{\max}=5$ 大，而 $\sigma_2$ 比 $\lambda_{\min}=3$ 小. 我们从 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 和 $\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 开始:

$$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}=\begin{bmatrix}25 & 20\\ 20 & 25\end{bmatrix}\qquad\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}=\begin{bmatrix}41 & 12\\ 12 & 9\end{bmatrix}$$

这两个矩阵有相同的迹 $\lambda_1+\lambda_2=50$ 和相同的特征值 $\lambda_1=\sigma_1^2=45$ 和 $\lambda_2=\sigma_2^2=5$. 特征值的平方根为 $\sigma_1=\sqrt{45}=3\sqrt{5}$ 和 $\sigma_2=\sqrt{5}$. 那么 $\sigma_1$ 和 $\sigma_2$ 的乘积是 15, 也就是 $\boldsymbol{A}$ 的行列式. 下一步是确定 $\boldsymbol{V}$. 找出 $\boldsymbol{V}$ 的关键是确定 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 的特征向量（特征值为 45 和 5）:

$$\begin{bmatrix}25 & 20\\ 20 & 25\end{bmatrix}\begin{bmatrix}1\\ 1\end{bmatrix}=45\begin{bmatrix}1\\ 1\end{bmatrix}\qquad\begin{bmatrix}25 & 20\\ 20 & 25\end{bmatrix}\begin{bmatrix}-1\\ 1\end{bmatrix}=5\begin{bmatrix}-1\\ 1\end{bmatrix}$$

由于 $\boldsymbol{v}_1$ 和 $\boldsymbol{v}_2$ 是单位化的正交的特征向量，因此除以模长可得

右奇异特征向量 $$\boldsymbol{v}_1=\frac{1}{\sqrt{2}}\begin{bmatrix}1\\1\end{bmatrix},\qquad \boldsymbol{v}_2=\frac{1}{\sqrt{2}}\begin{bmatrix}-1\\1\end{bmatrix}$$

那么左奇异特征向量为 $\boldsymbol{u}_1=\boldsymbol{A}\boldsymbol{v}_1/\sigma_1,\boldsymbol{u}_2=\boldsymbol{A}\boldsymbol{v}_2/\sigma_2$. 将 $\boldsymbol{A}$ 乘以 $\boldsymbol{v}_1$、$\boldsymbol{v}_2$ 得到：

$$\begin{aligned}\boldsymbol{A}\boldsymbol{v}_1&=\frac{3}{\sqrt{2}}\begin{bmatrix}3\\1\end{bmatrix}=\sqrt{45}\frac{1}{\sqrt{10}}\begin{bmatrix}3\\1\end{bmatrix}=\sigma_1\boldsymbol{u}_1\\ \boldsymbol{A}\boldsymbol{v}_2&=\frac{1}{\sqrt{2}}\begin{bmatrix}-1\\3\end{bmatrix}=\sqrt{5}\frac{1}{\sqrt{10}}\begin{bmatrix}-1\\3\end{bmatrix}=\sigma_2\boldsymbol{u}_2\end{aligned}$$

除以 $\sqrt{10}$ 使 $\boldsymbol{u}_1$ 和 $\boldsymbol{u}_2$ 成为单位向量. 然后和我们预想的一样，$\sigma_1=\sqrt{45},\sigma_2=\sqrt{5}$. 矩阵 $\boldsymbol{A}$ 的奇异值分解为 $\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\mathrm{T}}$（并不是 $\boldsymbol{V}$）.

$$\boldsymbol{U}=\frac{1}{\sqrt{10}}\begin{bmatrix}3&-1\\1&3\end{bmatrix}\qquad \boldsymbol{\Sigma}=\begin{bmatrix}\sqrt{45}&0\\0&\sqrt{5}\end{bmatrix}\qquad \boldsymbol{V}^{\mathrm{T}}=\frac{1}{\sqrt{2}}\begin{bmatrix}1&1\\-1&1\end{bmatrix}\tag{7.13}$$

最后我们还需要选择 $n-r$ 个向量 $\boldsymbol{v}_{r+1},\boldsymbol{v}_{r+2},\cdots,\boldsymbol{v}_n$ 和 $m-r$ 个向量 $\boldsymbol{u}_{r+1},\boldsymbol{u}_{r+2},\cdots,\boldsymbol{u}_m$. 这一步相对简单，因为它们分别都在 $\boldsymbol{A}$ 和 $\boldsymbol{A}^{\mathrm{T}}$ 的零空间里，$\mathcal{N}(\boldsymbol{A})\perp\mathcal{C}(\boldsymbol{A}^{\mathrm{T}}),\mathcal{N}\left(\boldsymbol{A}^{\mathrm{T}}\right)\perp\mathcal{C}(\boldsymbol{A})$. 选择这两个零空间中的任意一组标准正交基，那么分别自动和 $\boldsymbol{A}$ 的行空间中向量以及 $\boldsymbol{A}$ 的列空间中的向量正交. 根据线性代数的基本定理，奇异值分解就得到了完整的证明.

再次强调：SVD 的好的算法并不是从 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 和 $\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 出发. 事实上，我们第一步先用旋转变换使 $\boldsymbol{A}$ 只有两个对角线非零 (并不影响 $\sigma$)，然后再处理这种特殊的矩阵. 本节的最后会介绍计算奇异值分解的一个有效的方法.

现在我们得到了完整的奇异值分解所需的 $\boldsymbol{U}$、$\boldsymbol{\Sigma}$ 和 $\boldsymbol{V}$：$\boldsymbol{u}_1,\boldsymbol{u}_2,\cdots,\boldsymbol{u}_n$ 和 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_n$. 可以看到 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 的特征值也是 $\boldsymbol{\Sigma}^{\mathrm{T}}\boldsymbol{\Sigma}$ 的特征值. 同样地，$\sigma_1^2,\sigma_2^2,\cdots,\sigma_r^2$ 也是 $\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 和 $\boldsymbol{\Sigma}\boldsymbol{\Sigma}^{\mathrm{T}}$ 的特征值. 更一般地，有一个神奇的现象：若 $\boldsymbol{A}$ 是 $m\times n$ 矩阵，$\boldsymbol{B}$ 是 $n\times m$ 矩阵，那么$n\times n$ 矩阵 $\boldsymbol{B}\boldsymbol{A}$ 和 $m\times m$ 矩阵 $\boldsymbol{A}\boldsymbol{B}$ 总有相同的非零特征值.[①]

### 7.1.5 $AB$ 和 $BA$：相同的非零特征值

**如果 $\boldsymbol{A}$ 是 $m\times n$ 矩阵而 $\boldsymbol{B}$ 是 $n\times m$ 矩阵，那么 $\boldsymbol{A}\boldsymbol{B}$ 和 $\boldsymbol{B}\boldsymbol{A}$ 总有同样的非零特征值.**

令 $\boldsymbol{A}\boldsymbol{B}\boldsymbol{x}=\lambda\boldsymbol{x},\lambda\neq0$. 左乘 $\boldsymbol{B}$ 可得 $\boldsymbol{B}\boldsymbol{A}\boldsymbol{B}\boldsymbol{x}=\lambda\boldsymbol{B}\boldsymbol{x}$，所以 $\boldsymbol{B}\boldsymbol{x}$ 是 $\boldsymbol{B}\boldsymbol{A}$ 的属于同样的 $\lambda$ 的特征向量——这正是我们想要的. $\lambda\neq0$ 是为了保证 $\boldsymbol{B}\boldsymbol{x}$ 是 $\boldsymbol{B}\boldsymbol{A}$ 的非零特征向量.

注意到：如果 $\boldsymbol{B}$ 是方阵而且可逆，那么 $\boldsymbol{B}^{-1}(\boldsymbol{B}\boldsymbol{A})\boldsymbol{B}=\boldsymbol{A}\boldsymbol{B}$. 这说明 $\boldsymbol{B}\boldsymbol{A}$ 与 $\boldsymbol{A}\boldsymbol{B}$ 相似，进而有相同的特征值. 但上面的证明允许 $\boldsymbol{A}$ 是 $m\times n$ 矩阵而 $\boldsymbol{B}$ 是 $n\times m$ 矩阵，也包括当 $\boldsymbol{B}=\boldsymbol{A}^{\mathrm{T}}$ 时的奇异值分解的重要例子，此时，$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 和 $\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 都说明 $\boldsymbol{A}$ 有 $r$ 个非零的奇异值.

如果 $m>n$，那么和 $\boldsymbol{B}\boldsymbol{A}$ 相比，$\boldsymbol{A}\boldsymbol{B}$ 有 $m-n$ 个额外的零特征值.

① 译者注：“相同的特征值”包括每个特征值的重数也都一样.

### 7.1.6　$2\times 2$ 矩阵的奇异向量

图 7.2 是关于 $2\times 2$ 矩阵的奇异值分解的图像证明. 我们希望寻找互相垂直的向量 $\boldsymbol{v}$ 和 $\boldsymbol{w}$ 使得 $\boldsymbol{Av}$ 和 $\boldsymbol{Aw}$ 仍然是垂直的. 一开始我们猜测 $\boldsymbol{V}=\begin{bmatrix}1 & 0\end{bmatrix}^{\mathrm{T}}$，$\boldsymbol{W}=\begin{bmatrix}0 & 1\end{bmatrix}^{\mathrm{T}}$，但这时从 $\boldsymbol{AV}$ 和 $\boldsymbol{AW}$ 的夹角 $\theta$ 太小（在第一个图中，小于 90°），而从 $\boldsymbol{AW}$ 到 $-\boldsymbol{AV}$ 的角度 $180°-\theta$ 又太大（在第二个图中，大于 90°）. 所以我们需要在 $\boldsymbol{V}$ 到 $\boldsymbol{W}$ 寻找一个合适的 $\boldsymbol{v}$，使得 $\boldsymbol{Av}$ 到 $\boldsymbol{Aw}$ 的角度恰好是 90°，这也正是奇异值分解所证明的：正交的输入 $\boldsymbol{v}\perp\boldsymbol{w}$，输出 $\boldsymbol{Av}\perp\boldsymbol{Aw}$ 仍是正交的.

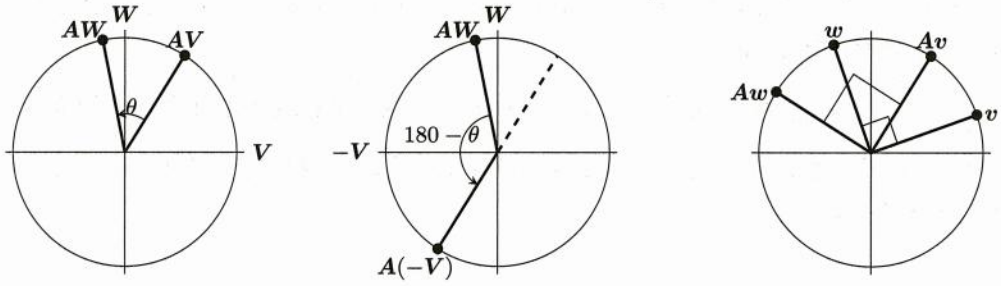


图 7.2　奇异向量的动态演示

注：$\boldsymbol{AV}$ 和 $\boldsymbol{AW}$ 的夹角 $\theta$ 小于 90°. $\boldsymbol{AW}$ 和 $-\boldsymbol{AV}$ 的夹角 $180°-\theta$ 大于 90°. 在两者之间，在 $\boldsymbol{v}$ 从 $\boldsymbol{V}$ 移动到 $\boldsymbol{W}$ 的过程中，$\boldsymbol{Av}$ 和 $\boldsymbol{Aw}$ 的夹角恰好等于 90°. 图中并没有体现向量的长度.

下面将用一种新的方法来得到 $\boldsymbol{v}_1$. 前面通过 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 的特征向量来得到右奇异向量 $\boldsymbol{v}_i$，当然这仍然是正确的，但是有一种（计算上）更有价值的方法来一个个得到这些奇异向量，而不是一次求出全部特征向量.

### 7.1.7　第一个奇异向量 $\boldsymbol{v}_1$

$$\boxed{\text{求比值 } \frac{\|\boldsymbol{Ax}\|}{\|\boldsymbol{x}\|} \text{ 的最大值，设该比值在 } \boldsymbol{x}=\boldsymbol{v}_1 \text{ 处取最大值 } \sigma_1.} \tag{7.14}$$

图 7.1中的椭圆说明了为什么在 $\boldsymbol{x}=\boldsymbol{v}_1$ 时取最大值. 考虑 $\boldsymbol{v}_1$ 在该图中的变化可以得到 $\boldsymbol{Av}_1=\sigma_1\boldsymbol{u}_1$. 椭圆长轴的长度即为 $\|\boldsymbol{Av}_1\|=\sigma_1$.

但我们的目标是直接得到奇异值分解！我们并未假设 $\boldsymbol{U}$、$\boldsymbol{\Sigma}$ 或 $\boldsymbol{V}$ 已知. 如何发现 $\dfrac{\|\boldsymbol{Ax}\|}{\|\boldsymbol{x}\|}$ 当 $\boldsymbol{x}=\boldsymbol{v}_1$ 时取最大值？一个简单的方法是将目标函数平方，考虑 $\boldsymbol{S}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$：

$$\text{问题：求 } \frac{\|\boldsymbol{Ax}\|^2}{\|\boldsymbol{x}\|^2}=\frac{\boldsymbol{x}^{\mathrm{T}}\boldsymbol{A}^{\mathrm{T}}\boldsymbol{Ax}}{\boldsymbol{x}^{\mathrm{T}}\boldsymbol{x}}=\frac{\boldsymbol{x}^{\mathrm{T}}\boldsymbol{Sx}}{\boldsymbol{x}^{\mathrm{T}}\boldsymbol{x}} \text{ 的最大值 } \lambda. \tag{7.15}$$

为了求这个“Rayleigh 商”的最大值，记 $\boldsymbol{x}=c_1\boldsymbol{x}_1+c_2\boldsymbol{x}_2+\cdots+c_n\boldsymbol{x}_n$，其中 $\boldsymbol{Sx}_i=\lambda_i\boldsymbol{x}_i$，则

$$\frac{\boldsymbol{x}^{\mathrm{T}}\boldsymbol{Sx}}{\boldsymbol{x}^{\mathrm{T}}\boldsymbol{x}}=\frac{c_1^2\lambda_1+c_2^2\lambda_2+\cdots+c_n^2\lambda_n}{c_1^2+c_2^2+\cdots+c_n^2}\leqslant\lambda_1=\boldsymbol{S}\text{的最大特征值}. \tag{7.16}$$

所以使得式(7.15)取最大值的 $\boldsymbol{x}$ 就是 $\boldsymbol{S}$ 的一个特征向量！

$$\boxed{\boldsymbol{S}\boldsymbol{x}=\lambda\boldsymbol{x}，\text{而且}\ \frac{\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}}{\boldsymbol{x}^{\mathrm{T}}\boldsymbol{x}}=\frac{\|\boldsymbol{A}\boldsymbol{x}\|^2}{\|\boldsymbol{x}\|^2}\ \text{的最大值是}\ \lambda_1(\boldsymbol{S})=\sigma_1^2(\boldsymbol{A}).}$$

对于完整的奇异值分解，我们需要求出所有的奇异向量和奇异值. 为了找到 $\boldsymbol{v}_2$ 和 $\sigma_2$，我们需要修改一下上述最值问题使得解满足与 $\boldsymbol{v}_1$ 正交这个限制条件:

$$\boxed{\text{在}\ \boldsymbol{v}_1^{\mathrm{T}}\boldsymbol{x}=0\ \text{的限制条件下，求}\ \frac{\|\boldsymbol{A}\boldsymbol{x}\|}{\|\boldsymbol{x}\|}\ \text{的最大值. 事实上，该比值在}\ \boldsymbol{x}=\boldsymbol{v}_2\ \text{时取到最大值}\ \sigma_2.}$$

“拉格朗日”乘子最先被引入求解带有约束 $\boldsymbol{v}_1^{\mathrm{T}}\boldsymbol{x}=0$ 的最值问题. 课后习题 9 给出了一个简单而直接的方法来处理条件 $\boldsymbol{v}_1^{\mathrm{T}}\boldsymbol{x}=0$.

每一个奇异向量 $\boldsymbol{v}_{k+1}$ 都是 $\dfrac{\|\boldsymbol{A}\boldsymbol{x}\|}{\|\boldsymbol{x}\|}$ 在 $\boldsymbol{x}$ 与 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_k$ 垂直这个条件之下的最大值. 总而言之，求奇异向量，其实也是在寻找一个椭球坐标系以及对称矩阵 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 或 $\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 的特征向量：同时找出来或者挨个找出来.

问题：为什么方阵 $\boldsymbol{A}$ 的所有特征值都小于或等于 $\sigma_1$?

答：对矩阵 $\boldsymbol{A}$ 左乘正交矩阵 $\boldsymbol{U}$ 或右乘正交矩阵 $\boldsymbol{V}^{\mathrm{T}}$ 不会改变向量的长度：对任意 $\boldsymbol{x}$

$$\|\boldsymbol{A}\boldsymbol{x}\|=\left\|\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\mathrm{T}}\boldsymbol{x}\right\|=\left\|\boldsymbol{\Sigma}\boldsymbol{V}^{\mathrm{T}}\boldsymbol{x}\right\|\leqslant\sigma_1\left\|\boldsymbol{V}^{\mathrm{T}}\boldsymbol{x}\right\|=\sigma_1\|\boldsymbol{x}\|.\tag{7.17}$$

对特征向量有 $\|\boldsymbol{A}\boldsymbol{x}\|=|\lambda|\,\|\boldsymbol{x}\|$. 由式(7.17)得 $|\lambda|\,\|\boldsymbol{x}\|\leqslant\sigma_1\|\boldsymbol{x}\|$，所以 $|\lambda|\leqslant\sigma_1$.

问题：如果 $\boldsymbol{A}=\boldsymbol{x}\boldsymbol{y}^{\mathrm{T}}$ 秩为 1，如何求 $\boldsymbol{u}_1$、$\boldsymbol{v}_1$ 和 $\sigma_1$? 验证 $|\lambda_1|\leqslant\sigma_1$.

答：奇异向量 $\boldsymbol{u}_1=\boldsymbol{x}/\|\boldsymbol{x}\|$，$\boldsymbol{v}_1=\boldsymbol{y}/\|\boldsymbol{y}\|$ 长度为 1. 那么 $\sigma_1=\|\boldsymbol{x}\|\,\|\boldsymbol{y}\|$ 是奇异值矩阵 $\boldsymbol{\Sigma}$ 的唯一非零元. 奇异值分解为

秩 1 矩阵
$$\boldsymbol{A}=\boldsymbol{x}\boldsymbol{y}^{\mathrm{T}}=\frac{\boldsymbol{x}}{\|\boldsymbol{x}\|}\left(\|\boldsymbol{x}\|\,\|\boldsymbol{y}\|\right)\frac{\boldsymbol{y}^{\mathrm{T}}}{\|\boldsymbol{y}\|}=\boldsymbol{u}_1\sigma_1\boldsymbol{v}_1^{\mathrm{T}}.\tag{7.18}$$

观察 $\boldsymbol{A}=\boldsymbol{x}\boldsymbol{y}^{\mathrm{T}}$ 的唯一非零特征值为 $\lambda_1=\boldsymbol{y}^{\mathrm{T}}\boldsymbol{x}$，因为 $\boldsymbol{A}\boldsymbol{x}=\left(\boldsymbol{x}\boldsymbol{y}^{\mathrm{T}}\right)\boldsymbol{x}=\boldsymbol{x}\left(\boldsymbol{y}^{\mathrm{T}}\boldsymbol{x}\right)=\lambda_1\boldsymbol{x}$，所以对应的特征向量为 $\boldsymbol{x}$. 那么不等式 $|\lambda_1|\leqslant\sigma_1$ 即为施瓦尔茨不等式 $\left|\boldsymbol{y}^{\mathrm{T}}\boldsymbol{x}\right|\leqslant\|\boldsymbol{x}\|\,\|\boldsymbol{y}\|$.

### 7.1.8 计算特征值和奇异值

对称矩阵特征值问题 $\boldsymbol{S}\boldsymbol{x}=\lambda\boldsymbol{x}$ 与奇异值问题 $\boldsymbol{A}\boldsymbol{v}=\sigma\boldsymbol{u}$ 的主要区别是什么？我们可以如何简化 $\boldsymbol{S}$ 和 $\boldsymbol{A}$ 来计算 $\lambda$ 和 $\sigma$?

若 $\boldsymbol{Q}$ 是正交矩阵，则 $\boldsymbol{S}$ 和 $\boldsymbol{Q}^{-1}\boldsymbol{S}\boldsymbol{Q}=\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{Q}$ 有相同的特征值.

所以我们在对 $\boldsymbol{Q}^{-1}\boldsymbol{S}\boldsymbol{Q}$ 简化使之出现零元时是有限制的：需要保证对称性. 如果在 $\boldsymbol{Q}^{-1}\boldsymbol{S}$ 中有过多的 0，那么右乘 $\boldsymbol{Q}$ 会重新出现非零元. $\boldsymbol{Q}^{-1}\boldsymbol{S}\boldsymbol{Q}$ 的最佳状态应该是三对角矩阵，我们可以将 $\boldsymbol{S}$ 简化为 3 个非零的对角线.

即使 $\boldsymbol{Q}_1$ 和 $\boldsymbol{Q}_2$ 不相等，$\boldsymbol{A}$ 和 $\boldsymbol{Q}_1^{-1}\boldsymbol{A}\boldsymbol{Q}_2$ 仍然有相同的奇异值.

通过 $\boldsymbol{Q}_1^{-1}\boldsymbol{A}\boldsymbol{Q}_2$ 我们有更大的自由度来得到 0. 因此我们期望有合适的 $\boldsymbol{Q}_1$、$\boldsymbol{Q}_2$，使得 $\boldsymbol{Q}_1^{-1}\boldsymbol{A}\boldsymbol{Q}_2$ 是二对角矩阵（两个非零的对角线）. 我们可以快速找到 $\boldsymbol{Q}$、$\boldsymbol{Q}_1$ 和 $\boldsymbol{Q}_2$ 使得

$$\boldsymbol{Q}^{-1}\boldsymbol{S}\boldsymbol{Q}=\begin{bmatrix} a_1 & b_1 & & \\ b_1 & a_2 & b_2 & \\ & b_2 & \ddots & \ddots \\ & & \ddots & a_n \end{bmatrix} \qquad \boldsymbol{Q}_1^{-1}\boldsymbol{A}\boldsymbol{Q}_2=\begin{bmatrix} c_1 & d_1 & & \\ 0 & c_2 & d_2 & \\ & 0 & \ddots & \ddots \\ & & 0 & c_n \end{bmatrix} \tag{7.19}$$

读者可以看到 $\boldsymbol{A}$ 的奇异值是 $\boldsymbol{S}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 的特征值的平方根. $\boldsymbol{Q}_1^{-1}\boldsymbol{A}\boldsymbol{Q}_2$ 的奇异值和 $\boldsymbol{A}$ 的奇异值相同. (二对角型)$^{\mathrm{T}}$(二对角型) 将得到三对角型.

但是我们不应该使用这个性质，不要计算 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 并得到其特征值. 这是不必要的工作，而且我们不一定需要方阵这个条件. Golub-Kahan 算法直接对 $\boldsymbol{A}$ 进行操作，而且仅需要两步.

（1）找到 $\boldsymbol{Q}_1$ 和 $\boldsymbol{Q}_2$ 使得 $\boldsymbol{A}^*=\boldsymbol{Q}_1^{-1}\boldsymbol{A}\boldsymbol{Q}_2$ 是二对角矩阵. 像式(7.19)那样它和 $\boldsymbol{A}$ 的奇异值相同.

（2）调整带平移的 $\boldsymbol{QR}$ 算法（见 6.6 节）来得到 $\boldsymbol{A}^*$ 的奇异值.

步骤（1）需要 $O(mn^2)$ 次乘法来将 $\boldsymbol{A}$ 化为二对角型矩阵. 接下来的步骤只针对二对角型矩阵. 通常还需要 $O(n^2)$ 次乘法来得到奇异值（校正到接近机器精度）. 整个算法可查阅 *Golub-Van Loan: the bible*（第 4 版，489-492）.

当 $A$ 非常大时，我们使用随机样本法. 随机线性代数有很大的概率会给出非常精确的结果. 多数赌徒都认为通过随机样本可以稳定获得很好的收益.

## 习题7.1

1. 设 $\boldsymbol{A}=\begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 8 \\ 0 & 0 & 0 \end{bmatrix}$，它的秩为 2. 特征值为 0、0、0. 求 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$、$\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 和 $\boldsymbol{A}$ 的奇异向量 $\boldsymbol{v}_1$、$\boldsymbol{v}_2$、$\boldsymbol{u}_1$、$\boldsymbol{u}_2$. 验证 $\boldsymbol{A}\boldsymbol{v}_1=\sigma_1\boldsymbol{u}_1$、$\boldsymbol{A}\boldsymbol{v}_2=\sigma_2\boldsymbol{u}_2$ 以及 $\boldsymbol{A}=\sigma_1\boldsymbol{u}_1\boldsymbol{v}_1^{\mathrm{T}}+\sigma_2\boldsymbol{u}_2\boldsymbol{v}_2^{\mathrm{T}}$. 如果去掉 $\boldsymbol{A}$ 的第 3 行（全零行），证明 $\sigma_1$ 和 $\sigma_2$ 没有变化.

2. 设 $\boldsymbol{B}=\begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 8 \\ \dfrac{1}{1000} & 0 & 0 \end{bmatrix}$，它的秩为 3，行列式为 $\dfrac{8}{1000}$. 求 $\boldsymbol{B}$ 的奇异值和特征值.

与上面的 $\boldsymbol{A}$ 相比较，可以看到特征值的变化比奇异值的变化大得多.

3. 奇异值分解建立了行空间中的向量 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_r$ 和列空间中的向量 $\boldsymbol{u}_1,\boldsymbol{u}_2,\cdots,\boldsymbol{u}_r$ 之间的联系. 将 $\boldsymbol{A}=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\mathrm{T}}$ 转置可得 $\boldsymbol{A}^{\mathrm{T}}=\boldsymbol{V}\boldsymbol{\Sigma}^{\mathrm{T}}\boldsymbol{U}^{\mathrm{T}}$，它给出了相反的从 $\boldsymbol{u}$ 到 $\boldsymbol{v}$ 的方式：

$$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{u}_k=\sigma_k\boldsymbol{v}_k,\quad k=1,2,\cdots,r; \qquad \boldsymbol{A}^{\mathrm{T}}\boldsymbol{u}_k=\boldsymbol{0},k=r+1,r+2,\cdots,m$$

对我们的例子，转置矩阵 $\boldsymbol{A}^{\mathrm{T}}=\begin{bmatrix} 5 & 0 \\ 4 & 3 \end{bmatrix}$，它的左奇异向量 $\boldsymbol{u}$ 和右奇异向量 $\boldsymbol{v}$ 分别是什么？

4. 当 $\boldsymbol{A}\boldsymbol{v}_k=\sigma_k\boldsymbol{u}_k,\boldsymbol{A}^{\mathrm{T}}\boldsymbol{u}_k=\sigma_k\boldsymbol{v}_k$ 时，证明：$\sigma_k$ 和 $-\sigma_k$ 是矩阵 $\boldsymbol{S}=\begin{bmatrix} 0 & \boldsymbol{A} \\ \boldsymbol{A}^{\mathrm{T}} & 0 \end{bmatrix}$ 的特征值，$\begin{bmatrix} u_k \\ v_k \end{bmatrix}$ 和 $\begin{bmatrix} -u_k \\ v_k \end{bmatrix}$ 是 $\boldsymbol{S}$ 的特征向量，迹为 0. 对称矩阵 $\boldsymbol{S}$ 的特征向量给出了 $\boldsymbol{A}$ 的奇异向量.

5. 求 $2\times 2$ 矩阵 $\boldsymbol{A}=\begin{bmatrix}2 & 1\\ 4 & 2\end{bmatrix}$ 的特征值和奇异值.

$$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}=\begin{bmatrix}20 & 10\\ 10 & 5\end{bmatrix},\quad \boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}=\begin{bmatrix}5 & 10\\ 10 & 20\end{bmatrix}$$

$\boldsymbol{A}$ 的特征向量 $\begin{bmatrix}1 & 2\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}1 & -2\end{bmatrix}^{\mathrm{T}}$ 不是正交的. 为什么 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 的特征向量 $\boldsymbol{v}_1$、$\boldsymbol{v}_2$ 是正交的？注意：$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 和 $\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 有相同的特征值 $\lambda_1=25$ 和 $\lambda_2=0$.

6. 求 $\boldsymbol{A}_1=\begin{bmatrix}1 & 0\\ 1 & 1\end{bmatrix}$ 和 $\boldsymbol{A}_2=\begin{bmatrix}1 & 0 & 1 & 0\\ 1 & 1 & 1 & 1\end{bmatrix}$ 的奇异值分解式.

7. MATLAB 命令 $\boldsymbol{A}=\mathrm{rand}(20,\ 40)$ 和 $\boldsymbol{B}=\mathrm{randn}(20,40)$ 可以生成 $20\times 40$ 的随机矩阵. $\boldsymbol{A}$ 中的元素满足从 0 到 1 的正态分布. $\boldsymbol{B}$ 中元素满足正态的“钟型”分布. 利用 svd 命令，求出并画出它们的奇异值 $\sigma_1,\sigma_2,\cdots,\sigma_{20}$. 为什么它们有 20 个 $\sigma$？

8. 为什么不能直接利用 $\boldsymbol{\Sigma}+\boldsymbol{I}$ 对 $\boldsymbol{A}+\boldsymbol{I}$ 做奇异值分解？如果 $\boldsymbol{A}=\sum_i \sigma_i\boldsymbol{u}_i\boldsymbol{v}_i^{\mathrm{T}}$，为什么 $\boldsymbol{A}^{+}=\sum_i \dfrac{1}{\sigma_i}\boldsymbol{v}_i\boldsymbol{u}_i^{\mathrm{T}}$？

9. 如果 $\boldsymbol{A}=\boldsymbol{Q}$ 是正交矩阵，为什么 $\boldsymbol{Q}$ 的奇异值都是 1？

10. 一个对称矩阵 $\boldsymbol{S}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 有特征值 $\lambda_1\geqslant 0,\lambda_2\geqslant 0,\cdots,\lambda_n\geqslant 0$. 特征向量 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_n$ 都是正交的. 那么任意向量 $\boldsymbol{x}=c_1\boldsymbol{v}_1+c_2\boldsymbol{v}_2+\cdots+c_n\boldsymbol{v}_n$，有

$$R(\boldsymbol{x})=\frac{\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}}{\boldsymbol{x}^{\mathrm{T}}\boldsymbol{x}}=\frac{\lambda_1c_1^2+\lambda_2c_2^2+\cdots+\lambda_nc_n^2}{c_1^2+c_2^2+\cdots+c_n^2}$$

$R$ 在哪个向量 $\boldsymbol{x}$ 处取得最大值？这个 $\boldsymbol{x}$ 的系数 $c_1,c_2,\cdots,c_n$ 是多少？$R$ 又在哪个向量 $\boldsymbol{x}$ 处取得最小值？

11. 为了从 $R(\boldsymbol{x})$ 中求得 $\sigma_2$ 和 $\boldsymbol{v}_2$，我们需要给出限制条件 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{v}_1=0$. 这对 $c_1$ 有什么要求？什么样的 $c$ 使得 $R(\boldsymbol{x})$ 在第二个特征向量 $\boldsymbol{x}=\boldsymbol{v}_2$ 取得最大值 $\sigma_2$？

12. 对以下两个矩阵 $\boldsymbol{A}$，分别求 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 以及奇异向量使得 $\boldsymbol{A}\boldsymbol{v}_1=\sigma_1\boldsymbol{u}_1,\boldsymbol{A}\boldsymbol{v}_2=\sigma_2\boldsymbol{u}_2$：

$$\boldsymbol{A}=\begin{bmatrix}2 & 2\\ -1 & 1\end{bmatrix}\qquad \boldsymbol{A}=\begin{bmatrix}3 & 3\\ 4 & 4\end{bmatrix}$$

13. 设 $\boldsymbol{A}=\begin{bmatrix}1 & 1 & 0\\ 0 & 1 & 1\end{bmatrix}$，求 $\boldsymbol{v}_1$、$\boldsymbol{v}_2$、$\boldsymbol{v}_3$，$\boldsymbol{u}_1$、$\boldsymbol{u}_2$，以及 $\sigma_1$、$\sigma_2$. 给出 $\boldsymbol{A}$ 的奇异值分解 $\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\mathrm{T}}=(2\times 2)(2\times 3)(3\times 3)$.

14. 如果 $\left(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\right)\boldsymbol{v}=\sigma^2\boldsymbol{v}$，左乘 $\boldsymbol{A}$ 将得到 $\left(\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}\right)\boldsymbol{A}\boldsymbol{v}=\sigma^2(\boldsymbol{A}\boldsymbol{v})$. 如果 $\boldsymbol{v}$ 是 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 的特征向量，那么_____是 $\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 的特征向量.

15. 对下面的 $\boldsymbol{A}$，求 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 的特征值与特征向量 $\boldsymbol{v}_1$、$\boldsymbol{v}_2$，然后求 $\boldsymbol{u}_1=\dfrac{\boldsymbol{A}\boldsymbol{v}_1}{\sigma_1}$：

$$\boldsymbol{A}=\begin{bmatrix}1 & 2\\ 3 & 6\end{bmatrix},\quad \boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}=\begin{bmatrix}10 & 20\\ 20 & 40\end{bmatrix},\quad \boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}=\begin{bmatrix}5 & 15\\ 15 & 45\end{bmatrix}$$

验证 $\boldsymbol{u}_1$ 是 $\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 的单位特征向量. 求矩阵 $\boldsymbol{U}$、$\boldsymbol{\Sigma}$、$\boldsymbol{V}$，完成奇异值分解

$$\begin{bmatrix} 1 & 2 \\ 3 & 6 \end{bmatrix} = \begin{bmatrix} \boldsymbol{u}_1 & \boldsymbol{u}_2 \end{bmatrix} \begin{bmatrix} \sigma_1 & \\ & 0 \end{bmatrix} \begin{bmatrix} \boldsymbol{v}_1 & \boldsymbol{v}_2 \end{bmatrix}^{\mathrm{T}}$$

16. （1）证明：$\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 的迹等于所有 $a_{ij}^2$ 的和.

（2）对秩 1 矩阵，证明：$\sigma_1$ 等于所有 $a_{ij}^2$ 的和.

17. 如果 $\boldsymbol{A} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\mathrm{T}}$ 是可逆方阵，那么 $\boldsymbol{A}^{-1} =$ _____. $\boldsymbol{A}^{-1}$ 的最大的奇异值为 $1/\sigma_{\min}(\boldsymbol{A})$，最大特征值为 $1/|\lambda(A)|_{\min}$. 式(7.17)告诉我们 $\sigma_{\min}(\boldsymbol{A}) \leqslant |\lambda(\boldsymbol{A})|_{\min}$.

18. 假设 $\boldsymbol{A} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\mathrm{T}}$ 是 $2 \times 2$ 矩阵，$\sigma_1 > \sigma_2 > 0$. 请对 $\boldsymbol{A}$ 做一个尽量小的扰动以得到一个不可逆矩阵 $\boldsymbol{A}_0$. 提示：$\boldsymbol{U}$ 和 $\boldsymbol{V}$ 是不变的.

## 7.2　通过线性代数来做图像处理

（1）图像是一个由灰度值构成的大型矩阵，每个像素和颜色都对应一个灰度值.

（2）当相邻像素具有相关性（非随机）时，图像可以被压缩.

（3）旗帜图像通常较为简单. 照片可以通过奇异值分解进行压缩.

图像处理和压缩是线性代数的主要应用领域. 图像识别在深度学习中经常使用卷积神经网络. 第 7~8 章中的这些主题体现了计算工程与数学的大量交叉内容.

本节将从旗帜这类有特点的图像开始讲解：这类图像通常复杂度较低. 然后我们会讨论像素更多的照片. 在所有情况下，我们都在寻找高效的信号处理和传输方法. 图像实际上是一个大型矩阵，它可以为每个小像素表示明/暗以及红/绿/蓝信息.

奇异值分解提供了一种矩阵近似的方法：用 $\boldsymbol{A}_k$ 替换 $\boldsymbol{A}$. $r$ 个秩为 1 的矩阵 $\sigma_j \boldsymbol{u}_j \boldsymbol{v}_j^{\mathrm{T}}$ 的和构成的 $\boldsymbol{A}$ 可以简化为前 $k$ 项的和 $\boldsymbol{A}_k$. 本节（以及在线帮助内容）将研究奇异值分解对旗帜或照片等图像的影响. 7.3 节将探讨更多需要对数据矩阵进行近似和理解的例子.

以各国国旗为例. 超过 30 个国家选择了三色条纹的国旗. 这些国旗有特别简单的形式，易于压缩. 我找到了一本名为《世界各国国旗》的书，书中的图像范围从单一纯色（在卡扎菲执政期间，利比亚国旗全是绿色）到非常复杂的图像. 如何以最小的损失压缩这些图像呢？

线性代数的答案是：用奇异值分解. 注意，三色条纹的国旗矩阵秩仍为 1. 法国国旗是蓝-白-红垂直条纹，其矩阵列中是 $b$（蓝色）、$w$（白色）、$r$（红色）. 巧合的是，德国国旗几乎是它的转置，颜色为黑-红-黄：

$$\text{法国：} \begin{bmatrix} b & b & w & w & r & r \\ b & b & w & w & r & r \\ b & b & w & w & r & r \\ b & b & w & w & r & r \\ b & b & w & w & r & r \\ b & b & w & w & r & r \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \\ 1 \\ 1 \end{bmatrix} \begin{bmatrix} b & b & w & w & r & r \end{bmatrix}$$

$$\text{德国：}\begin{bmatrix} B & B & B & B & B & B \\ B & B & B & B & B & B \\ R & R & R & R & R & R \\ R & R & R & R & R & R \\ Y & Y & Y & Y & Y & Y \\ Y & Y & Y & Y & Y & Y \end{bmatrix} = \begin{bmatrix} B \\ B \\ R \\ R \\ Y \\ Y \end{bmatrix} \begin{bmatrix} 1 & 1 & 1 & 1 & 1 & 1 \end{bmatrix}$$

每个矩阵都可化简为两个向量. 为了传输这些图像，我们可以只用 $2N$ 个像素，无须 $N^2$ 个. 同样，意大利国旗是绿-白-红，爱尔兰国旗是绿-白-橙. 但是很多国家让这个问题变得无比困难，因为它们在这些条纹之上添加了一个小徽章. 日本国旗是白色背景上有一个红色太阳，马尔代夫国旗是在白色矩形上的绿色矩形中有一个优雅的白色新月. 这些曲线图像的秩是无穷大——压缩仍然是可能且必要的，但秩不再是 1.

有一些国旗仍然保持了有限的秩但是它们添加了十字来增加秩. 比如希腊和汤加两国的国旗的秩分别为 3 和 4.

希腊国旗有四行不同的图案，但只有三列. 我曾错误地认为其秩为 4. 但现在发现第 2 行加上第 3 行等于第 1 行，所以希腊国旗（矩阵表示）的秩是 3.

另一方面，汤加国旗似乎秩为 4. 左半部分有四行：全白-短红-长红-全红. 我们无法通过其他行的线性组合得到其中任何一行. 汤加拥有（矩阵表示下）有限秩的“冠军”国旗！

### 7.2.1 对角矩阵的奇异值

有三个国家的国旗只有两条对角线：巴哈马、捷克共和国和科威特. 许多国家在国旗中加入了星星和多条对角线. 从我的书中，我无法确定加拿大国旗是否也有小的曲线图案. 找出这个下三角为 1（包括主对角线）且上三角为 0 的矩阵的奇异值分解是很有趣的.

带三角形的国旗 $\quad \boldsymbol{A} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 1 & 0 \\ 1 & 1 & 1 & 1 \end{bmatrix}$ 逆矩阵为 $\boldsymbol{A}^{-1} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ -1 & 1 & 0 & 0 \\ 0 & -1 & 1 & 0 \\ 0 & 0 & -1 & 1 \end{bmatrix}$

$\boldsymbol{A}$ 是满秩的，$r = n$. 所有特征值在主对角线上且都为 1. 那么 $\boldsymbol{A}$ 有 $n$ 个奇异值（均为正，但不等于 1）. 奇异值分解会产生 $n$ 个秩为 1 的部分 $\sigma_i \boldsymbol{u}_i \boldsymbol{v}_i^{\mathrm{T}}$. 完美重现需要所有 $n$ 部分.

在压缩过程中，较小的 $\sigma$ 值可以被舍弃，且不会对图像质量造成严重损失. 我们想要了解 $n = 4$ 时的奇异值，也想要绘制出 $n$ 较大时所有 $\sigma$ 值的图像. 图 7.3 将判断 $\boldsymbol{A}$ 是否能通过奇异值分解得到大幅压缩（不能）.

手动计算时，我们从 $\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 开始（计算机的计算过程会有所不同）：

$$\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}} = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & 2 & 2 & 2 \\ 1 & 2 & 3 & 3 \\ 1 & 2 & 3 & 4 \end{bmatrix} \qquad \left(\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}\right)^{-1} = \left(\boldsymbol{A}^{-1}\right)^{\mathrm{T}} \boldsymbol{A}^{-1} = \begin{bmatrix} 2 & -1 & 0 & 0 \\ -1 & 2 & -1 & 0 \\ 0 & -1 & 2 & -1 \\ 0 & 0 & -1 & 2 \end{bmatrix} \tag{7.20}$$

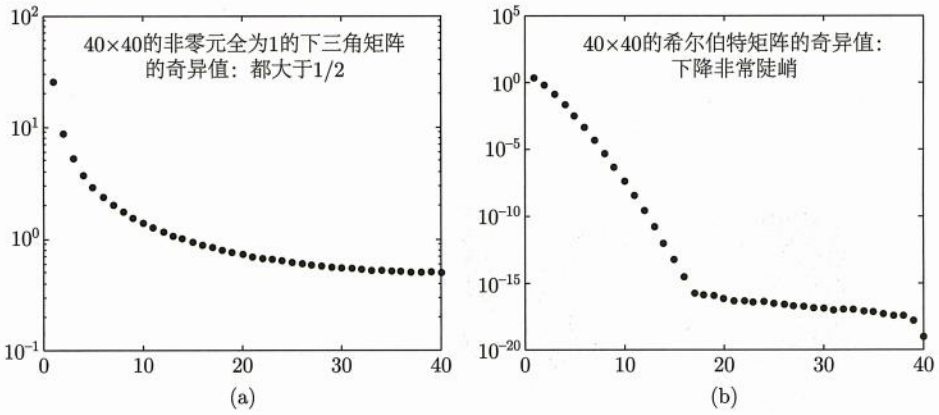


图 7.3　不同矩阵的奇异值示例

注：图 (a) 是 $40 \times 40$ 的下三角且非零元全为 1 的矩阵的奇异值，它不可压缩，都大于 1/2. 图 (b) 表示邪恶的希尔伯特矩阵 $H(i,j)=(i+j-1)^{-1}$ 有效秩较低，我们必须对其进行压缩.

这个以 $-1$、2、$-1$ 为三条对角线的逆矩阵我们非常熟悉，特征值都形如 $2-2\cos\theta$. 我们知道所有的特征值！也就知道了矩阵 $\boldsymbol{A}$ 的奇异值.

$$\lambda\left(\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}\right)=\frac{1}{2-2\cos\theta}=\frac{1}{4\sin^2\theta/2},\quad \text{给出}\quad \sigma(\boldsymbol{A})=\sqrt{\lambda}=\frac{1}{2\sin\theta/2} \tag{7.21}$$

这个例子非常特殊，因为特征值蕴含的 $n$ 个不同的等间距的角度 $\theta$ 是

$$\theta=\frac{\pi}{2n+1},\ \frac{3\pi}{2n+1},\ \cdots,\ \frac{(2n-1)\pi}{2n+1}\qquad (n=4\text{ 时，包括了 }\theta=\frac{3\pi}{9},\text{ 此时 }2\sin\frac{\theta}{2}=1).$$

绘制矩阵 $\boldsymbol{A}$ 的 $n$ 个奇异值的图像对于理解矩阵有很重要的作用. 这些数值会下降（与矩阵 $\boldsymbol{A}$ 的所有特征值都为 1 不同），但下降并不陡峭. 所以奇异值分解对这个下三角矩阵的压缩效果有限，而对于希尔伯特矩阵则能实现很好的压缩.

图 7.3 令人惊讶的一点是，非零元都是 1 的下三角矩阵的奇异值从未低于 $\frac{1}{2}$. 与亚历克斯·汤森合作时，我们在其他形状（如圆形）的 0-1 矩阵（其中 1 具有特定形状分布）中也看到了这种现象. 出现这种现象的原因目前尚不清楚.

### 7.2.2　利用奇异值分解进行图像压缩

压缩照片和图像是观察奇异值分解实际应用的一种绝佳方式. 其原理是通过改变显示中秩为 1 的分量 $\sigma\boldsymbol{u}\boldsymbol{v}^{\mathrm{T}}$ 的数量来实现. 保留的项越多，图像质量就越好.

我们曾希望找到一个能展示这种效果提升的网站. 幸运的是，蒂姆·鲍曼恰好做到了我们所期望的. 他已允许我们所有人使用他的成果.

图 7.4 是网站提供的五张图像之一. 滑块的位置决定压缩比. 最佳比例取决于图像的复杂程度——与城市、树木或猫咪的图像相比，女孩的图像和蒙德里安画作的复杂程度较低，能实现更高的压缩比. 若滑块设置为 80，则有 80 项 $\sigma\boldsymbol{u}\boldsymbol{v}^{\mathrm{T}}$ 相加，其中向量 $\boldsymbol{u}$ 和 $\boldsymbol{v}$ 的维度为 600. 可以用算式 $600\times 80+80+80\times 600$ 来计算压缩尺寸.

可以使用网站提供的五张示例图像下方的“file picker”按钮来压缩自己的图像，也可以直接将图像拖放到页面上.

蒂姆·鲍曼的网站一个突出的特点是它在浏览器中运行，可即时得出结果. 本书的网站可以收录读者的想法. 如有问题、评论和建议，请访问该网站留言.

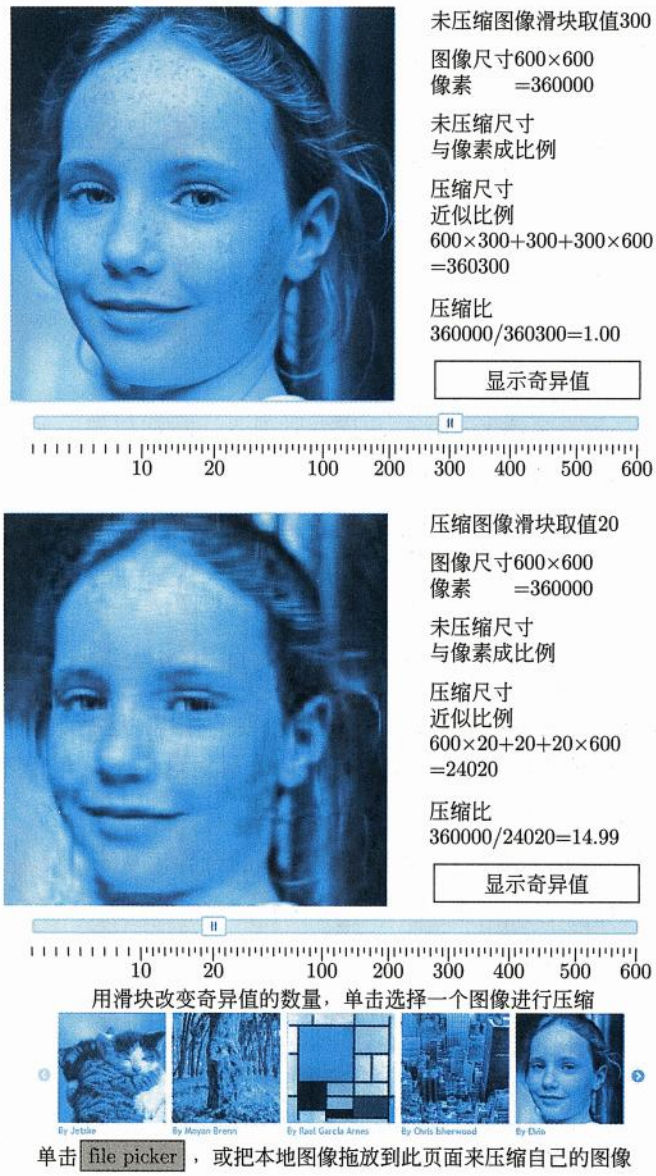


图 7.4 网站提供的五张图像之一

## 习题 7.2

1. 我们通常认为单位矩阵 $\boldsymbol{I}$ 已经尽可能简单了. 但为什么 $\boldsymbol{I}$ 难以压缩呢？构造一个有水平和竖直两条交叉线的秩为 2 的旗帜对应的矩阵. 这个矩阵是高度可压缩的.

2. 瑞典、芬兰和贝宁的国旗对应的矩阵 $\boldsymbol{A}_{\text{瑞典}}=\boldsymbol{A}_{\text{芬兰}}$ 和 $\boldsymbol{B}_{\text{贝宁}}$ 的秩是 2，把它们写成 $\boldsymbol{u}_1\boldsymbol{v}_1^{\mathrm{T}}$ 和 $\boldsymbol{u}_2\boldsymbol{v}_2^{\mathrm{T}}$ 的形式.

$$\boldsymbol{A}_{\text{瑞典}}=\boldsymbol{A}_{\text{芬兰}}=\begin{bmatrix}1&2&1&1\\2&2&2&2\\1&2&1&1\end{bmatrix},\qquad B_{\text{贝宁}}=\begin{bmatrix}1&2&2\\1&3&3\end{bmatrix}$$

3. 求习题 2 中 $\boldsymbol{B}\boldsymbol{B}^{\mathrm{T}}$ 和 $\boldsymbol{B}^{\mathrm{T}}\boldsymbol{B}$ 的迹与行列式. $\boldsymbol{B}$ 的奇异值近似为 $\sigma_1^2=28-\dfrac{1}{14}$ 和 $\sigma_2^2=\dfrac{1}{14}$. $\boldsymbol{B}$ 是否可压缩?

4. 利用 $[\boldsymbol{U},\boldsymbol{S},\boldsymbol{V}]=\mathrm{svd}(\boldsymbol{A})$ 来求 $\boldsymbol{A}_{\text{瑞典}}$ 的两个正交部分 $\sigma\boldsymbol{u}\boldsymbol{v}^{\mathrm{T}}$.

5. 日本国旗对应的矩阵是一个由 1 组成的圆，周围全是 0. 假设圆的直径上有 $2N$ 个 1，那么这个圆大约会包含 $\pi N^2$ 个 1. 我们将该国旗视为一个 0-1 矩阵. 它的秩大约为 $CN$，与 $N$ 成正比. 这个数 $C$ 是多少?

提示：去掉一个由 1 组成的大正方形子矩阵，其角在 $\pm45°$ 和 $\pm135°$ 处. 正方形上方的行和正方形右侧的列是相互独立的. 画一张图并估计这些行的数量 $cN$，则 $C=2c$.

6. 这里有一种从函数 $F(x,y)$ 出发构造矩阵 $\boldsymbol{A}$ 的方法. 设 $\boldsymbol{A}_{ij}=F(i/N,j/N)$，（指标 $i$ 和 $j$ 的取值范围是从 0 到 $N$，或者从 $-N$ 到 $N$.）随着 $N$ 增大，$\boldsymbol{A}$ 的秩应反映 $F$ 的简单程度或复杂程度. 求出函数 $F_1=xy$、$F_2=x+y$ 和 $F_3=x+y$ 所对应矩阵的秩，然后求出 $F_3$ 对应矩阵的三个奇异值和奇异向量.

7. 在习题 6 中，$F(x,y)$ 分别满足什么条件时，可以得到如下各种矩阵？对称矩阵 $\boldsymbol{S}$、反对称矩阵 $\boldsymbol{A}$、一个奇异矩阵 $\boldsymbol{M}$、秩为 2 的矩阵.

## 7.3　主成分分析

矩阵 $\boldsymbol{A}$ 的“主成分”是其奇异向量，即矩阵 $\boldsymbol{U}$ 和 $\boldsymbol{V}$ 的正交列向量 $\boldsymbol{u}_j$ 和 $\boldsymbol{v}_j$. 本节旨在应用奇异值分解 $\boldsymbol{A}=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\mathrm{T}}$. 主成分分析使用与首个 $\boldsymbol{u}$ 向量和 $\boldsymbol{v}$ 向量相关联的最大的 $\sigma$ 值来理解数据矩阵中的信息. 给定一个矩阵 $\boldsymbol{A}$，我们提取其最重要的部分 $\boldsymbol{A}_k$（最大的 $\sigma$ 值对应的部分）：

$$\boldsymbol{A}_k=\sigma_1\boldsymbol{u}_1\boldsymbol{v}_1^{\mathrm{T}}+\sigma_2\boldsymbol{u}_2\boldsymbol{v}_2^{\mathrm{T}}+\cdots+\sigma_k\boldsymbol{u}_k\boldsymbol{v}_k^{\mathrm{T}},\quad \mathrm{rank}\,(\boldsymbol{A}_k)=k$$

$\boldsymbol{A}_k$ 解决了一个矩阵优化问题——我们从这里开始讲起. 与 $\boldsymbol{A}$ 最接近的秩为 $k$ 的矩阵是 $\boldsymbol{A}_k$. 在统计学中，我们需要识别 $\boldsymbol{A}$ 中具有最大方差的秩为 1 的部分. 这使得奇异值分解成为数据科学的核心.

在数据科学领域中，主成分分析是“无监督”学习. 我们唯一的指导是线性代数——奇异值分解告诉我们选择 $\boldsymbol{A}_k$. 在有监督学习时，我们有一大组训练数据. 深度学习构建一个（非线性的!）函数 $F$ 来对大部分数据进行正确分类. 然后我们将这个 $F$ 应用于新数据，这将会在第 10 章中看到.

主成分分析基于 $\boldsymbol{A}_k$ 进行矩阵近似. $\boldsymbol{A}_k$ 是最佳选择的证明由施密特（1907 年）开启. 他撰写了关于函数空间中的算子的内容；他的想法可直接延伸到矩阵. 埃克哈特和扬给出了一个新的证明（使用弗罗贝尼乌斯范数来度量 $\boldsymbol{A}-\boldsymbol{A}_k$）. 然后米尔斯基允许使用仅依赖于奇异值的任何范数 $\|A\|$，如定义式(7.23)~式(7.25)所示.

以下是特殊的秩为 $k$ 的矩阵 $\boldsymbol{A}_k=\sigma_1\boldsymbol{u}_1\boldsymbol{v}_1^{\mathrm{T}}+\sigma_2\boldsymbol{u}_2\boldsymbol{v}_2^{\mathrm{T}}+\cdots+\sigma_k\boldsymbol{u}_k\boldsymbol{v}_k^{\mathrm{T}}$ 的关键性质：

$$\boxed{\boldsymbol{A}_k\text{距离}\boldsymbol{A}\text{最近：}\quad\text{对任意秩为}k\text{的矩阵}\boldsymbol{B},\text{都有}\|\boldsymbol{A}-\boldsymbol{A}_k\|\leqslant\|\boldsymbol{A}-\boldsymbol{B}\|.}\tag{7.22}$$

矩阵范数 $\|\boldsymbol{A}\|$ 有三种特别重要的选择，分别是

$$\text{谱范数}\qquad\|\boldsymbol{A}\|_2=\max\frac{\|\boldsymbol{A}\boldsymbol{x}\|}{\|\boldsymbol{x}\|}=\sigma_1\quad(\text{通常称为}\ell^2\ \text{范数})\tag{7.23}$$

$$\text{弗罗贝尼乌斯范数}\qquad\|\boldsymbol{A}\|_{\mathrm{F}}=\sqrt{\sigma_1^2+\sigma_2^2+\cdots+\sigma_r^2}\quad\text{式(7.28)也定义了}\ \|\boldsymbol{A}\|_{\mathrm{F}}\tag{7.24}$$

$$\text{核范数}\qquad\|\boldsymbol{A}\|_{\mathrm{N}}=\sigma_1+\sigma_2+\cdots+\sigma_r\quad(\text{迹范数})\tag{7.25}$$

对于 $n$ 阶单位矩阵，这三个范数已经取值不同了：

$$\|\boldsymbol{I}\|_2=1,\quad\|\boldsymbol{I}\|_{\mathrm{F}}=\sqrt{n},\quad\|\boldsymbol{I}\|_{\mathrm{N}}=n\tag{7.26}$$

用任何正交矩阵 $\boldsymbol{Q}$ 代替 $\boldsymbol{I}$，范数保持不变（因为所有 $\sigma_i=1$）：

$$\|\boldsymbol{Q}\|_2=1,\quad\|\boldsymbol{Q}\|_{\mathrm{F}}=\sqrt{n},\quad\|\boldsymbol{Q}\|_{\mathrm{N}}=n\tag{7.27}$$

不仅如此，$\boldsymbol{A}$ 乘以（任一侧）正交矩阵，矩阵的谱范数、弗罗贝尼乌斯范数和核范数保持不变. 由于 $\boldsymbol{U}$ 和 $\boldsymbol{V}$ 都是正交矩阵，所以 $\boldsymbol{A}=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\mathrm{T}}$ 的范数等于 $\boldsymbol{\Sigma}$ 的范数：$\|\boldsymbol{A}\|=\|\boldsymbol{\Sigma}\|$. 要用某种方式来度量向量或矩阵的大小；对于向量，最重要的范数是通常的长度 $\|\boldsymbol{v}\|$. 对于矩阵，弗罗贝尼乌斯将平方和的概念进行了扩展，以包含矩阵 $\boldsymbol{A}$ 中的所有元素. 这个范数 $\|\boldsymbol{A}\|_{\mathrm{F}}$ 也被称为希尔伯特-施密特范数.

$$\|\boldsymbol{v}\|^2=v_1^2+v_2^2+\cdots+v_n^2\qquad\|\boldsymbol{A}\|_{\mathrm{F}}^2=a_{11}^2+a_{12}^2+\cdots+a_{1n}^2+\cdots+a_{m1}^2+a_{m2}^2+\cdots+a_{mn}^2\tag{7.28}$$

显然，$\|\boldsymbol{v}\|\geqslant0$ 且 $\|c\boldsymbol{v}\|=|c|\,\|\boldsymbol{v}\|$. 类似地，$\|\boldsymbol{A}\|_{\mathrm{F}}\geqslant0$ 且 $\|c\boldsymbol{A}\|_{\mathrm{F}}=|c|\,\|\boldsymbol{A}\|_{\mathrm{F}}$. 同样重要的是 $\boldsymbol{v}+\boldsymbol{w}$ 和 $\boldsymbol{A}+\boldsymbol{B}$ 的三角不等式：

$$\text{三角不等式}\qquad\|\boldsymbol{v}+\boldsymbol{w}\|\leqslant\|\boldsymbol{v}\|+\|\boldsymbol{w}\|,\quad\|\boldsymbol{A}+\boldsymbol{B}\|_{\mathrm{F}}\leqslant\|\boldsymbol{A}\|_{\mathrm{F}}+\|\boldsymbol{B}\|_{\mathrm{F}}\tag{7.29}$$

当我们遇到点积 $v^{\mathrm{T}}w$ 或矩阵乘积 $AB$ 时，我们还会用到另一个事实：

$$\text{施瓦茨不等式}\qquad|\boldsymbol{v}^{\mathrm{T}}\boldsymbol{w}|\leqslant\|\boldsymbol{v}\|\,\|\boldsymbol{w}\|,\quad\|\boldsymbol{A}\boldsymbol{B}\|_{\mathrm{F}}\leqslant\|\boldsymbol{A}\|_{\mathrm{F}}\,\|\boldsymbol{B}\|_{\mathrm{F}}\tag{7.30}$$

矩阵的弗罗贝尼乌斯范数的施瓦茨不等式直接来自向量模长的施瓦茨向量不等式：

$$|(\boldsymbol{A}\boldsymbol{B})_{ij}|^2\leqslant\|\boldsymbol{A}\text{ 的行}\|^2\,\|\boldsymbol{B}\text{ 的列}\|^2$$

上式对所有 $i$、$j$ 求和可得 $\|\boldsymbol{A}\boldsymbol{B}\|_{\mathrm{F}}^2\leqslant\|\boldsymbol{A}\|^2\,\|\boldsymbol{B}\|^2$.

这表明可能存在矩阵的点积，它是 $\boldsymbol{A}\cdot\boldsymbol{B}=\operatorname{trace}\left(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{B}\right)$.

注意：矩阵 $\boldsymbol{A}$ 的特征值的最大模 $|\lambda|$ 不是范数！我们知道一个非零矩阵可能所有特征值都为零，但它的范数 $\|\boldsymbol{A}\|$ 不能为零. 在这方面，奇异值优于特征值：$\boldsymbol{\sigma_1=\|A\|_2}$.

### 7.3.1 埃克哈特-扬定理

该定理如式(7.22)所示：如果 $\boldsymbol{B}$ 的秩为 $k$，那么 $\|\boldsymbol{A}-\boldsymbol{A}_k\|\leqslant\|\boldsymbol{A}-\boldsymbol{B}\|$. 在谱范数 $\|\boldsymbol{A}\|_2$、弗罗贝尼乌斯范数 $\|\boldsymbol{A}\|_{\mathrm{F}}$ 和核范数 $\|\boldsymbol{A}\|_{\mathrm{N}}$ 这三种范数下，通过在奇异值分解中保留 $k$ 项，我们都能得到与 $\boldsymbol{A}$ 最接近的矩阵. 最接近的矩阵是 $\boldsymbol{A}_k=\sigma_1\boldsymbol{u}_1\boldsymbol{v}_1^{\mathrm{T}}+\sigma_2\boldsymbol{u}_2\boldsymbol{v}_2^{\mathrm{T}}+\cdots+\sigma_k\boldsymbol{u}_k\boldsymbol{v}_k^{\mathrm{T}}$. 这是用低秩矩阵逼近 $\boldsymbol{A}$ 的结论！

我们来看一个对角矩阵 $\boldsymbol{A}$ 的例子，它看起来极其简单：

和 $\boldsymbol{A}=\begin{bmatrix}4&0&0&0\\0&3&0&0\\0&0&2&0\\0&0&0&1\end{bmatrix}$ 最接近的秩为 2 的矩阵是 $\boldsymbol{A}_2=\begin{bmatrix}4&0&0&0\\0&3&0&0\\0&0&0&0\\0&0&0&0\end{bmatrix}$

矩阵 $\boldsymbol{A}-\boldsymbol{A}_2$ 除了 2 和 1 之外其余元素均为 0，那么 $\|\boldsymbol{A}-\boldsymbol{A}_2\|_{\mathrm{F}}=\sqrt{2^2+1^2}$. 还有哪个秩为 2 的矩阵能比这个 $\boldsymbol{A}_2$ 更接近 $\boldsymbol{A}$ 呢？

因为左乘或者右乘正交矩阵 $\boldsymbol{Q}_1$、$\boldsymbol{Q}_2$ 不改变矩阵的范数和秩. 上面这个看似简单的例子可以扩展到所有形如 $\boldsymbol{Q}_1\boldsymbol{A}\boldsymbol{Q}_2$ 的矩阵. 所以这个例子涵盖了所有奇异值为 4、3、2、1 的矩阵. 最佳近似 $\boldsymbol{A}_2$ 保留了奇异值 4 和 3.《线性代数与数据学习》（韦尔斯利-剑桥出版社）中收集了多个证明. Chi-Kwong Li 简化了 Mirsky 的证明，即对于所有仅依赖于奇异值 $\sigma$ 的范数，例如 $\|\boldsymbol{A}\|_2$ 和 $\|A\|_{\mathrm{F}}$，$\boldsymbol{A}_k$ 都是最接近 $\boldsymbol{A}$ 的秩为 $k$ 的矩阵.

### 7.3.2　通过奇异值分解进行主成分分析

现在我们开始用奇异值分解来研究数据. 我们有 $n$ 个样本. 对于每个样本，我们测量 $m$ 个变量（比如身高和体重）. 数据矩阵 $\boldsymbol{A}_0$ 有 $n$ 列和 $m$ 行. 在许多应用中，这是一个非常大的矩阵.

第一步是找出 $\boldsymbol{A}_0$ 每一行的平均值（样本均值）. 然后把该行的所有 $m$ 个元素减去这个均值，这一步称作中心化，中心化后的矩阵 $\boldsymbol{A}$ 的每行均值都是为零. $\boldsymbol{A}$ 的列是 $\mathbb{R}^m$ 中的 $n$ 个点. 由于进行了中心化操作，$n$ 个列向量的和为零. 所以列向量的平均是零向量.

通常，这 $n$ 个点聚集在一条直线、一个平面或 $\mathbb{R}^m$ 的另一个低维子空间附近. 图 7.5展示了一组典型的数据点，在将 $\boldsymbol{A}_0$ 中心化后，这些点在 $\mathbb{R}^2$ 中沿一条直线聚集（通过左右和上下移动点，使 $\boldsymbol{A}$ 中的点均值为 $(0,\,0)$）.

线性代数如何找到通过 $(0,0)$ 点的最接近的直线呢？答案是：**它是 $\boldsymbol{A}$ 的第一个奇异向量 $\boldsymbol{u}_1$ 张成的直线**. 这是主成分分析的关键！

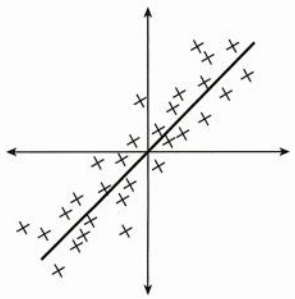

$\boldsymbol{A}$ 是 $2\times n$ 矩阵（零空间较大）
$\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 是 $2\times 2$ 矩阵（小矩阵）
$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 是 $n\times n$ 矩阵（大矩阵）
两个奇异值 $\sigma_1>\sigma_2>0$

图 7.5　$\mathbb{R}^2$ 中典型的数据分布

### 7.3.3　主成分分析背后的几何意义

图 7.5 中的最佳直线解决了一个正交最小二乘法的问题. 这也被称为正交回归. 它和对 $n$ 个数据点进行标准最小二乘拟合，或者求线性系统 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 的最小二乘解不同. 4.3节中的经典问题是

最小化 $\|\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}\|^2$. 它测量的是到最佳直线的纵向距离. 早先问题的解是线性方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\widehat{\boldsymbol{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$ 的最优解 $\widehat{\boldsymbol{x}}$. 而此时的问题则引出奇异向量 $\boldsymbol{u}_i$（$\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 的特征向量）. 这是线性代数两个不同的方面.

**数据点到 $\boldsymbol{u}_1$ 张成的直线的距离平方和是最小的.**

为了说明这一点，将 $\boldsymbol{A}$ 的每一列 $\boldsymbol{a}_j$ 分解为 $\boldsymbol{u}_1$ 和 $\boldsymbol{u}_2$ 方向的分量之和：

$$\sum_1^n \|\boldsymbol{a}_j\|^2=\sum_1^n \left|\boldsymbol{a}_j^{\mathrm{T}}\boldsymbol{u}_1\right|^2+\sum_1^n \left|\boldsymbol{a}_j^{\mathrm{T}}\boldsymbol{u}_2\right|^2$$

等号左边的求和由数据确定. 等号右边的第一个求和式包含 $\boldsymbol{u}_1^{\mathrm{T}}\boldsymbol{a}_j\boldsymbol{a}_j^{\mathrm{T}}\boldsymbol{u}_1$，其总和为 $\boldsymbol{u}_1^{\mathrm{T}}\left(\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}\right)\boldsymbol{u}_1$. 所以在主成分分析中，当我们选择 $\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 的最大特征向量 $\boldsymbol{u}_1$ 来最大化这个和时，我们就最小化了第二个和式. 从数据点到最佳直线（或最佳子空间）的第二个距离平方和就尽可能小.

### 7.3.4 埃克哈特-扬定理的几何意义

图 7.5 是二维的，它得出了最接近的直线. 现在假设我们的数据矩阵 $\boldsymbol{A}_0$ 是 $3\times n$ 矩阵，比如每一个样本，都是年龄、身高、体重这三项的测量值. 我们再次对矩阵的行向量进行中心化处理，所以 $\boldsymbol{A}$ 的各行的分量之和均为零. 并且这些点在三维空间中.

我们仍然可以寻找与样本点最接近的直线. 它依然是由 $\boldsymbol{A}$ 的第一个奇异向量 $\boldsymbol{u}_1$ 张成的直线. 最佳直线将经过 (0, 0, 0). 但是与图 7.5相比，数据点分布得更分散，因此我们实际上需要寻找的是最佳平面. “最佳”的含义仍然是：到该平面的距离平方和是最小的.

该平面由奇异向量 $\boldsymbol{u}_1$ 和 $\boldsymbol{u}_2$ 张成. 这就是埃克哈特-扬定理的推论，同时可以得出一个巧妙的结论：最佳平面包含最佳直线.

### 7.3.5 主成分分析背后的统计学原理

概率和统计学中的关键数字是均值和方差. “均值”是数据的平均值（$\boldsymbol{A}_0$ 每一行的均值）. 把 $\boldsymbol{A}_0$ 各行每一个元素减去该行的均值就得到了中心化后的 $\boldsymbol{A}$. 另外两个重要的数字是“方差”和“协方差”. 方差是距离均值的平方和——$\boldsymbol{A}$ 每一行的各元素的平方和：

**方差是矩阵 $\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 的对角元素.**

假设 $\boldsymbol{A}$ 的列对应于一个孩子的年龄（在 $x$ 轴上）以及身高（在 $y$ 轴上）. 这些年龄和身高是减去平均年龄和平均身高后的值. 我们的目标是寻找最接近图中数据点的直线. 并且我们必须考虑数据的年龄-身高联合分布.

**协方差是矩阵 $\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 的非对角元素.**

这些元素是点积 ($\boldsymbol{A}$的第 $i$ 行) · ($\boldsymbol{A}$的第 $j$ 行). 协方差大意味着身高伴随着年龄变大而增长.（负协方差意味着一个变量增加时另一个变量减少）. 我们的第一个例子只有年龄和身高这两行数据：对称矩阵 $\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 是 $2\times 2$ 矩阵. 随着儿童样本数量 $n$ 的增加，我们将 $\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 除以 $n-1$ 使其具有统计上的正确比例.

**样本协方差矩阵定义为** $\boldsymbol{S}=\dfrac{\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}}{n-1}$.

除以 $n-1$ 是因为已经有一个自由度用于使均值为 0. 下面这个有六个年龄和身高数据的例子已经进行了中心化处理，每行的和为零：

$$\boldsymbol{A}=\begin{bmatrix}3 & -4 & 7 & 1 & -4 & -3\\ 7 & -6 & 8 & -1 & -1 & -7\end{bmatrix}$$

这个例子数据很简单，样本协方差矩阵 $\boldsymbol{S}$ 很容易计算. 它是正定的：

方差和协方差

$$\boldsymbol{S}=\frac{1}{6-1}\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}=\frac{1}{5}\begin{bmatrix}20 & 25\\ 25 & 40\end{bmatrix}.$$

若 $\boldsymbol{u}_1$ 和 $\boldsymbol{u}_2$ 是 $\boldsymbol{S}$ 的两个正交的特征向量，那么它们也是 $\boldsymbol{A}$ 的左奇异向量（通常称为主成分）. 埃克哈特 -扬定理表明，向量 $\boldsymbol{u}_1$ 为图 7.5 中的最佳直线的方向向量.

第二个奇异向量 $\boldsymbol{u}_2$ 与该最佳直线垂直.

重要注记 主成分分析可以用对称矩阵 $\boldsymbol{S}=\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}/(n-1)$ 或矩形矩阵 $\boldsymbol{A}$ 来描述. 毫无疑问，$\boldsymbol{S}$ 性质更好. 但给定 $\boldsymbol{A}$ 中的数据，去计算 $\boldsymbol{S}$ 可能是一个错误. 对于大型矩阵而言，直接进行奇异值分解更快且更准确. 通过计算 $\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$，我们可得 $\sigma_1,\sigma_2,\cdots,\sigma_r$ 平方，以及条件数 $\sigma_1/\sigma_r$.[①]

在这个例子中，$\boldsymbol{S}$ 的特征值接近 57 和 3. 它们的和为 $20+40=60$，即 $\boldsymbol{S}$ 的迹. 第一个秩 1 的部分 $\sqrt{57}\boldsymbol{u}_1\boldsymbol{v}_1^{\mathrm{T}}$ 比第二部分 $\sqrt{3}\boldsymbol{u}_2\boldsymbol{v}_2^{\mathrm{T}}$ 大得多. 主特征向量 $\boldsymbol{u}_1\approx\begin{bmatrix}0.6 & 0.8\end{bmatrix}^{\mathrm{T}}$ 告诉我们，散点图中最近的直线斜率接近 8/6. 图中的方向几乎构成了一个边长是 $6-8-10$ 的直角三角形.

### 7.3.6　主成分分析背后的线性代数

主成分分析是一种理解 $m$ 维空间 $n$ 个样本点 $a_1,a_2,\cdots,a_n$（即数据）的方法. 该数据图是中心化的：矩阵 $\boldsymbol{A}$ 的每一行的各分量的和为零. 与线性代数联系最紧密的是 $\boldsymbol{A}$ 的奇异值和左奇异向量 $\boldsymbol{u}_i$. 它们来自样本协方差矩阵 $\boldsymbol{S}=\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}/(n-1)$ 的特征值 $\lambda_i=\sigma_i^2$ 和特征向量.

数据的总方差来自 $\boldsymbol{A}$ 的弗罗贝尼乌斯范数的平方：

总方差

$$T=\frac{\|\boldsymbol{A}\|_{\mathrm{F}}^2}{n-1}=\frac{\left(\|\boldsymbol{a}_1\|^2+\|\boldsymbol{a}_2\|^2+\cdots+\|\boldsymbol{a}_n\|^2\right)}{n-1}\tag{7.31}$$

这个数值也是 $\boldsymbol{S}$ 的迹——对角线元素之和. 线性代数告诉我们，迹等于样本协方差矩阵 $\boldsymbol{S}$ 的特征值之和.

奇异值分解生成正交的奇异向量 $\boldsymbol{u}_i$，这些向量将数据分离为不相关的部分（协方差为零）. 它们按方差递减的顺序排列，并且前几部分告诉我们需要知道的信息.

$\boldsymbol{S}$ 的迹将总方差与主成分 $\boldsymbol{u}_1,\boldsymbol{u}_2,\cdots,\boldsymbol{u}_r$ 的方差之和联系起来：

总方差

$$T=\sigma_1^2+\sigma_2^2+\cdots+\sigma_r^2.\tag{7.32}$$

第一主成分 $\boldsymbol{u}_1$ 占（或“解释”了）总方差的 $\sigma_1^2/T$. $\boldsymbol{A}$ 的下一个奇异向量 $\boldsymbol{u}_2$ 解释了第二大比例的方差 $\sigma_2^2/T$. 每个奇异向量都在尽力捕捉矩阵中的信息，并且最终合力取得了成功.

① 条件数的概念见附录.

埃克哈特-扬定理的要点在于，$k$ 个奇异向量（共同作用时）比任何其他 $k$ 个向量的集合能解释更多的数据. 所以我们有理由选择 $\boldsymbol{u}_1, \boldsymbol{u}_2, \cdots, \boldsymbol{u}_k$ 作为最接近 $n$ 个数据点的 $k$ 维子空间的一组基.

噪声会掩盖一部分真实信号. 而噪声无法掩盖掉的这部分真实信号所对应的奇异值的个数被称作 $\boldsymbol{A}$ 和 $\boldsymbol{S}$ 的“有效秩”. 通常，在显示奇异值或其平方 $\sigma_1^2$ 下降情况的“碎石图”上可以区分出这两部分. 读者可以在碎石图（图 7.3）中寻找真实信号结束且噪声开始占主导地位的“肘部”位置.

## 习题 7.3

1. 假设 $\boldsymbol{A}_0$ 包含 5 个样本的 2 次测量值：

$$\boldsymbol{A}_0 = \begin{bmatrix} 5 & 4 & 3 & 2 & 1 \\ -1 & 1 & 0 & 1 & -1 \end{bmatrix}$$

求出每行的平均值并把它从各行减去，得到中心化矩阵 $\boldsymbol{A}$. 计算样本协方差矩阵 $\boldsymbol{S} = \boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}/(n-1)$，并求出其特征值 $\lambda_1$ 和 $\lambda_2$. 通过原点且最接近 $\boldsymbol{A}$ 中 5 个样本的直线是哪条？

2. 对下面这个 $2 \times 6$ 矩阵 $\boldsymbol{A}_0$ 重复第 1 题的步骤：

$$\boldsymbol{A}_0 = \begin{bmatrix} 1 & 0 & 1 & 0 & 1 & 0 \\ 1 & 2 & 3 & 3 & 2 & 1 \end{bmatrix}$$

3. 样本方差 $s_1^2$、$s_2^2$ 和样本协方差 $s_{12}$ 是 $\boldsymbol{S}$ 的元素. 把 $\boldsymbol{A}_0 = \begin{bmatrix} 1 & 2 & 3 \\ 5 & 2 & 2 \end{bmatrix}$ 各行减去其平均值后求出 $\boldsymbol{S}$. $\sigma_1$ 是多少？

4. 设 $\boldsymbol{A} = \begin{bmatrix} 1 & -1 & 0 & 0 \\ 0 & 0 & 2 & -2 \\ 1 & 1 & -1 & -1 \end{bmatrix}$，从 $\boldsymbol{S} = \boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 的特征向量中，找出（过原点的、$\boldsymbol{u}_1$ 方向的）直线，然后找出在三维空间中最接近 $\boldsymbol{A}$ 的列向量所代表的四个点的（$\boldsymbol{u}_1$ 和 $\boldsymbol{u}_2$ 方向）平面.

5. 比较普通最小二乘法（4.3节）和主成分分析（垂直最小二乘法）. 对于在时刻 $t = -3$、1、2 时的对称数据 $b = -1$、0、1，它们都能给出最接近的直线 $C + Dt$.

$$\boldsymbol{A} = \begin{bmatrix} 1 & -3 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, \qquad \boldsymbol{b} = \begin{bmatrix} -1 \\ 0 \\ 1 \end{bmatrix},$$

最小二乘法：$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}} = \boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$

主成分分析：$\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$的特征向量

$\boldsymbol{A}$的奇异向量$\boldsymbol{u}_1$

6. 特征脸的概念始于尺寸相同且对齐的 $N$ 张图像. 从 $N$ 张图像中的每一张减去平均图像. 创建样本协方差矩阵 $\boldsymbol{S} = \sum \dfrac{\boldsymbol{A}_i \boldsymbol{A}_i^{\mathrm{T}}}{N-1}$ 并找出具有最大特征值的特征向量得到特征脸. 它们看起来不像人脸，但它们的组合很接近人脸. 维基百科提供了由 Turk 和 Pentland 开创的这种降维方法的代码.

7. 如果 $\boldsymbol{A}$ 的奇异值为 5、4、3、2、1 且 $\boldsymbol{A}_3$ 是最接近 $\boldsymbol{A}$ 的秩为 3 的矩阵，那么 $\boldsymbol{A} - \boldsymbol{A}_3$ 的奇异值是多少？

8. 如果 $\boldsymbol{A}$ 的 $\sigma_1 = 9$ 且 $\boldsymbol{B}$ 的 $\sigma_1 = 4$，那么 $\boldsymbol{A} + \boldsymbol{B}$ 的 $\sigma_1$ 的上下界是多少？为什么？

# 第 8 章

CHAPTER 8

# 线 性 映 射

线性代数可以从矩阵学起，也可以从线性映射学起. 我们选择了矩阵. 其他作者可能会说：“矩阵只是线性映射的一种特殊情况.” 再进一步深入：“实数只是域的一种特殊情况.” 所有这些对象以及更多内容都是数学中被称为代数学分支的合理组成部分.

我不太确定如何回应这些观点. 也许我会说：“在你全面学习语言（语言学的研究对象）之前，你至少需要了解一门语言.” 并且，研究列向量、矩阵、线性方程、逆、向量空间、正交性、线性无关性和秩是如此引人入胜且富有成效.

矩阵的多样性非常美妙. 它就像一个有着不同关系和不同工作的人群共同体. 矩阵是独特的，但矩阵分解将它们与其他矩阵联系起来. 你可以有自己最喜欢的矩阵，而且我希望你有，这体现了你的数学喜好.

8.2节讨论了函数向量空间的好的基. 从 $\mathbb{R}^n$ 到无穷维的最自然推广被称为“希尔伯特空间”. 函数 $f(x)$ 和 $g(x)$ 的长度和内积以一种自然形式定义：

$$\|f\|^2 = \int |f(x)|^2 \,\mathrm{d}x \quad \text{和} \quad (f,\, g) = \int f(x)g(x)\mathrm{d}x.$$

最好的基 $q_1(x), q_2(x), \cdots$ 一如既往地是正交的，我们将推荐三组最常用的基. 但有除了上述内积的定义，仍然有其他度量 $f(x)$ 长度的好方法.

到这个地方，我们已经在代数学的前面，开辟了通向泛函分析的道路.

## 8.1 线性映射的概念

（1）线性映射$T$ 是线性空间之间的映射，将向量 $\boldsymbol{v}$ 的像记作 $T(\boldsymbol{v})$. 线性性质要求 $\boxed{T(c\boldsymbol{v}+d\boldsymbol{w}) = cT(\boldsymbol{v}) + dT(\boldsymbol{w})}$. 注意 $T(\boldsymbol{0}) = \boldsymbol{0}$，所以 $T(\boldsymbol{v}) = \boldsymbol{v} + \boldsymbol{u}_0$ 不是线性的.

（2）输入向量 $\boldsymbol{v}$ 和输出 $T(\boldsymbol{v})$ 可以属于 $\mathbb{R}^n$、矩阵空间或函数空间.

（3）如果 $\boldsymbol{A}$ 是 $m \times n$ 矩阵，$T(\boldsymbol{v}) = \boldsymbol{A}\boldsymbol{v}$ 是从输入空间 $\mathbb{R}^n$ 到输出空间 $\mathbb{R}^m$ 的线性映射.

（4）导数 $T(f) = \dfrac{\mathrm{d}f}{\mathrm{d}x}$ 是线性的. 积分 $T^+(f) = \displaystyle\int_0^x f(t)\,\mathrm{d}t$ 是它的伪逆.

（5）两个线性映射的乘积 $ST$ 仍然是线性的：$(ST)(\boldsymbol{v}) = S(T(\boldsymbol{v}))$.

矩阵 $\boldsymbol{A}$ 与向量 $\boldsymbol{v}$ 相乘，它将 $\boldsymbol{v}$ “映射”为另一个向量 $\boldsymbol{Av}$. 输入 $\boldsymbol{v}$，输出 $T(\boldsymbol{v})=\boldsymbol{Av}$. 映射 $T$ 的思路与函数相同. 输入一个数 $x$，输出 $f(x)$. 对于单个向量 $\boldsymbol{v}$ 或单个数字 $x$，我们用矩阵与之相乘，或者对函数取值. 更深层次的目标是同时考察所有向量. 当我们用 $\boldsymbol{A}$ 乘以每一个 $\boldsymbol{v}$ 时，我们就在映射整个空间 $V$.

还是从矩阵 $\boldsymbol{A}$ 开始. 它将 $\boldsymbol{v}$ 映射为 $\boldsymbol{Av}$，将 $\boldsymbol{w}$ 映射为 $\boldsymbol{Aw}$. 那么 $\boldsymbol{A}$ 把 $\boldsymbol{u}=\boldsymbol{v}+\boldsymbol{w}$ 变成什么是我们早就已知的. 毫无疑问，$\boldsymbol{Au}$ 等于 $\boldsymbol{Av}+\boldsymbol{Aw}$. 矩阵乘法 $T(\boldsymbol{v})=\boldsymbol{Av}$ 提供了一个重要的线性映射.

**映射** $T$ 为向量空间 $V$ 中的每个输入向量 $\boldsymbol{v}$ 分配一个输出 $T(\boldsymbol{v})$. 如果对于所有的 $\boldsymbol{v}$ 和 $\boldsymbol{w}$，该映射满足以下要求，则它是线性映射：

(a) $T(\boldsymbol{v}+\boldsymbol{w})=T(\boldsymbol{v})+T(\boldsymbol{w})$　　(b) 对于所有的 $c$，$T(c\boldsymbol{v})=cT(\boldsymbol{v})$.

如果输入 $\boldsymbol{v}=\boldsymbol{0}$，输出必须是 $T(\boldsymbol{v})=\boldsymbol{0}$. 我们将规则 (a) 和 (b) 合并为一个：

**线性映射**　$T(c\boldsymbol{v}+d\boldsymbol{w})=cT(\boldsymbol{v})+dT(\boldsymbol{w})$.

再次检验矩阵乘法的线性性质是成立的：$\boldsymbol{A}(c\boldsymbol{v}+d\boldsymbol{w})=c\boldsymbol{Av}+d\boldsymbol{Aw}$.

一个线性映射受到很多限制. 假设 $T$ 给每个向量加上 $\boldsymbol{u}_0$，那么 $T(\boldsymbol{v})=\boldsymbol{v}+\boldsymbol{u}_0$，$T(\boldsymbol{w})=\boldsymbol{w}+\boldsymbol{u}_0$. 它不是线性的. $T$ 在 $\boldsymbol{v}+\boldsymbol{w}$ 上的像是 $\boldsymbol{v}+\boldsymbol{w}+\boldsymbol{u}_0$，并不等于 $T(\boldsymbol{v})+T(\boldsymbol{w})$：

**平移不是线性的**　$\boldsymbol{v}+\boldsymbol{w}+\boldsymbol{u}_0\neq T(\boldsymbol{v})+T(\boldsymbol{w})=(\boldsymbol{v}+\boldsymbol{u}_0)+(\boldsymbol{w}+\boldsymbol{u}_0)$.

唯一的例外是 $\boldsymbol{u}_0=\boldsymbol{0}$. 此时映射简化为 $T(\boldsymbol{v})=\boldsymbol{v}$，即恒等映射（没有任何变化，就像乘以单位矩阵一样）. $T$ 显然是线性的，在这种情况下，输入空间 $V$ 与输出空间 $W$ 相同.

线性映射叠加平移映射 $T(\boldsymbol{v})=\boldsymbol{Av}+\boldsymbol{u}_0$ 被称为“仿射映射”. 尽管 $T$ 不是线性的，但直线仍然保持为直线. 仿射映射在计算机图形学中广泛使用，因为能够平移图像是基本要求. 这在相关网站上有进一步阐述.

**例 8.1**　选取一个固定向量 $\boldsymbol{a}=\begin{bmatrix}1 & 3 & 4\end{bmatrix}^{\mathrm{T}}$，并令 $T(\boldsymbol{v})$ 为点积 $\boldsymbol{a}\cdot\boldsymbol{v}$：

输入是 $\boldsymbol{v}=\begin{bmatrix}v_1 & v_2 & v_3\end{bmatrix}^{\mathrm{T}}$，　　输出是 $T(\boldsymbol{v})=\boldsymbol{a}\cdot\boldsymbol{v}=v_1+3v_2+4v_3$.

点积是线性的. 输入向量 $\boldsymbol{v}$ 来自三维空间，所以 $V=\mathbb{R}^3$. 输出只是数字，所以输出空间是 $W=\mathbb{R}^1$. 如果用行向量 $\boldsymbol{A}=\begin{bmatrix}1 & 3 & 4\end{bmatrix}$ 进行乘法运算，那么 $T(\boldsymbol{v})=\boldsymbol{Av}$.

要识别哪些映射是线性的往往并不困难. 如果输出涉及平方、乘积或长度，比如 $v_1^2$ 或 $v_1v_2$ 或 $\|\boldsymbol{v}\|$，那么 $T$ 不是线性的.

**例 8.2**　长度 $T(\boldsymbol{v})=\|\boldsymbol{v}\|$ 不是线性的. 如果是线性的，那么根据要求（a），则有 $\|\boldsymbol{v}+\boldsymbol{w}\|=\|\boldsymbol{v}\|+\|\boldsymbol{w}\|$. 根据要求（b），则有 $\|c\boldsymbol{v}\|=c\|\boldsymbol{v}\|$. 这两个等式都是错误的！

（a）三角形的边满足不等式 $\|\boldsymbol{v}+\boldsymbol{w}\|\leqslant\|\boldsymbol{v}\|+\|\boldsymbol{w}\|$.

（b）长度 $\|-\boldsymbol{v}\|$ 是 $\|\boldsymbol{v}\|$ 而不是 $-\|\boldsymbol{v}\|$. 对于负数 $c$，线性不成立.

**例 8.3**　$T$ 是将平面上每个向量旋转 30° 的映射. $T$ 的“定义域”是 $xy$ 平面（所有输入向量 $\boldsymbol{v}$）. $T$ 的“值域”也是 $xy$ 平面（所有旋转后的向量 $T(\boldsymbol{v})$）. 我们在没有使用矩阵的情况下描述了 $T$: 将平面旋转 30°.

旋转是线性的吗？是的. 我们可以先旋转两个向量，然后将结果相加. 两个向量旋转之后的和 $T(\boldsymbol{v})+T(\boldsymbol{w})$ 与和的旋转 $T(\boldsymbol{v}+\boldsymbol{w})$ 相等. 在这个线性映射中，整个平面一起在转动.

线性的规则可以扩展到三个向量或 $n$ 个向量的组合：

$$\boxed{\begin{array}{ll}\text{线性} & \boldsymbol{u}=c_1\boldsymbol{v}_1+c_2\boldsymbol{v}_2+\cdots+c_n\boldsymbol{v}_n \quad \text{必须映射为} \\ & T(\boldsymbol{u})=c_1T(\boldsymbol{v}_1)+c_2T(\boldsymbol{v}_2)+\cdots+c_nT(\boldsymbol{v}_n).\end{array}} \tag{8.1}$$

比如，$n=3$ 时，上式可由 $n=2$ 的情形证明：$T(c\boldsymbol{u}+d\boldsymbol{v}+e\boldsymbol{w})=T(c\boldsymbol{u})+T(d\boldsymbol{v}+e\boldsymbol{w})$. 然后对这两部分应用线性性质：$T(c\boldsymbol{u})+T(d\boldsymbol{v}+e\boldsymbol{w})=cT(\boldsymbol{u})+dT(\boldsymbol{v})+eT(\boldsymbol{w})$.

$T$ 关于 $n$ 个向量的线性运算规则式(8.1)引出了关于线性映射的一个非常重要的事实：

**基包含所有信息**

> 假设我们知道 $T$ 在一组基 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_n$ 上的取值 $T(\boldsymbol{v}_i)$，
> 那么我们就知道 $T$ 在任意 $\boldsymbol{u}$ 上的取值 $T(\boldsymbol{u})$.

其原因是：每个 $\boldsymbol{u}$ 都是基向量 $\boldsymbol{v}_j$ 的线性组合：$\boldsymbol{u}=a_1\boldsymbol{v}_1+a_2\boldsymbol{v}_2+\cdots+a_n\boldsymbol{v}_n$，然后线性性质告诉我们，$T(\boldsymbol{u})$ 是 $T(\boldsymbol{v}_j)$ 的相同系数的线性组合：$T(\boldsymbol{u})=a_1T(\boldsymbol{v}_1)+a_2T(\boldsymbol{v}_2)+\cdots+a_nT(\boldsymbol{v}_n)$.

### 8.1.1　直线到直线，三角形到三角形

图 8.1展示了输入空间中从 $\boldsymbol{v}$ 到 $\boldsymbol{w}$ 的直线，同时也展示了输出空间中从 $T(\boldsymbol{v})$ 到 $T(\boldsymbol{w})$ 的直线. 线性性质告诉我们：输入直线上的每一个点都映射到输出直线上. 不仅如此，**共线的距离相等的点映射成的点距离也相等.** 中点 $\boldsymbol{u}=\frac{1}{2}\boldsymbol{v}+\frac{1}{2}\boldsymbol{w}$ 会映射到中点 $T(\boldsymbol{u})=\frac{1}{2}T(\boldsymbol{v})+\frac{1}{2}T(\boldsymbol{w})$.

第二幅图提升了一个维度. 现在我们有三个顶点 $\boldsymbol{v}_1$、$\boldsymbol{v}_2$、$\boldsymbol{v}_3$. 这些输入对应三个输出 $T(\boldsymbol{v}_1)$、$T(\boldsymbol{v}_2)$、$T(\boldsymbol{v}_3)$. 输入三角形映射到输出三角形. 质心 $\boldsymbol{u}=\frac{1}{3}(\boldsymbol{v}_1+\boldsymbol{v}_2+\boldsymbol{v}_3)$ 会映射到质心 $T(\boldsymbol{u})=\frac{1}{3}(T(\boldsymbol{v}_1)+T(\boldsymbol{v}_2)+T(\boldsymbol{v}_3))$.

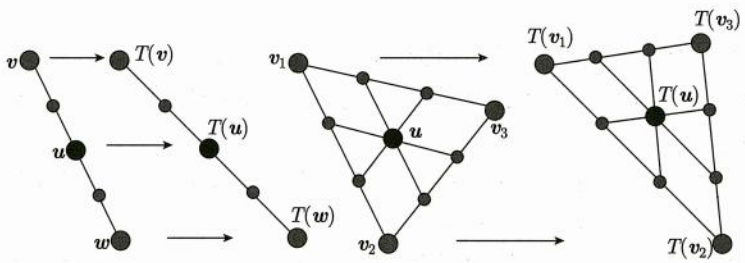


图 8.1　线性映射

注：线性映射把直线映到直线，长度相等的线段也映到长度相等的线段，$\boldsymbol{u}=\boldsymbol{0}$ 映到 $T(\boldsymbol{u})=\boldsymbol{0}$.

本书的这部分是视觉性内容，而非理论性内容. 我们将展示四座房屋以及生成它们的矩阵（见图 8.2）. 矩阵 $\boldsymbol{H}$ 的列是第一座房屋的 11 个角点（$\boldsymbol{H}$ 是 $2\times 12$ 的矩阵，所以习题 25 中的 **plot2d** 会将第 11 个角点与第一个角点连接起来）. 矩阵 $A$ 与房屋矩阵的列相乘，得到其他房屋的角点 $AH$.

房屋矩阵
$$\boldsymbol{H}=\begin{bmatrix}-6 & -6 & -7 & 0 & 7 & 6 & 6 & -3 & -3 & 0 & 0 & -6\\ -7 & 2 & 1 & 8 & 1 & 2 & 2 & -7 & -7 & -2 & -7 & -7\end{bmatrix}.$$

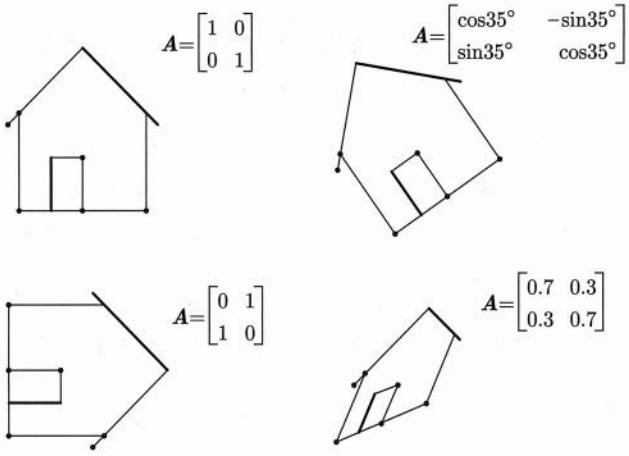


图 8.2　房屋被不同矩阵作用后的图像

注：通过 **plot2d**$(A*H)$ 得到的房屋的线性映射.

Grant Sanderson 的 3Blue1Brown YouTube 频道[①]有很棒的图形展示.

### 8.1.2　微积分中的线性映射

**例 8.4**　映射 $T$ 定义为对输入函数求导：$T(u)=\mathrm{d}u/\mathrm{d}x$. 如何求 $u=6-4x+3x^2$ 的导数呢？

可以从 1、$x$ 和 $x^2$ 的导数入手. 这些是基向量. 它们的导数分别是 0、1 和 $2x$. 然后利用线性性质求任意组合的导数：

$$\frac{\mathrm{d}u}{\mathrm{d}x}=6(1\text{ 的导数})-4(x\text{ 的导数})+3(x^2\text{ 的导数})=-4+6x.$$

整个微积分都依赖于线性性质！微积分课上求出了 $x^n$、$\sin x$、$\cos x$、$\mathrm{e}^x$ 等少数关键函数的导数. 然后线性性质适用于它们的所有线性组合. 链式法则是微积分特有的，它说的是 $f(g(x))$ 的导数是 $(\mathrm{d}f/\mathrm{d}g)(\mathrm{d}g/\mathrm{d}x)$.

$T(u)=\mathrm{d}u/\mathrm{d}x$ 的**零空间**. 为了求零空间，我们求解 $T(u)=0$. $u$ 是常数函数时导数为零. 该一维零空间是函数空间中的一条直线——特解 $u=1$ 的所有倍数.

$T(u)=\mathrm{d}u/\mathrm{d}x$ 的**列空间**. 在我们的例子中，输入空间包含所有二次函数 $a+bx+cx^2$. 输出（列空间）是所有线性函数 $b+2cx$. 注意**维数公式**仍然成立：$r+(n-r)=n$.

① 译者注：这个频道在中国国内的视频网站上也有.

（列空间）维数 + （零空间）维数 $= 2+1=3=$（输入空间）维数.

$\mathrm{d}/\mathrm{d}x$ 的矩阵是什么？在讨论导数时不得不提及矩阵. 对于线性映射 $T=\mathrm{d}/\mathrm{d}x$，$T$ 对基函数的作用：

$$\boldsymbol{v}_1,\boldsymbol{v}_2,\boldsymbol{v}_3=1,x,x^2,\qquad \frac{\mathrm{d}\boldsymbol{v}_1}{\mathrm{d}x}=0,\quad \frac{\mathrm{d}\boldsymbol{v}_2}{\mathrm{d}x}=1=\boldsymbol{v}_1,\quad \frac{\mathrm{d}\boldsymbol{v}_3}{\mathrm{d}x}=2x=2\boldsymbol{v}_2. \tag{8.2}$$

三维输入空间 $V$（二次多项式函数的全体）映射到二维输出空间 $W$（线性函数空间）. 如果 $\boldsymbol{v}_1$、$\boldsymbol{v}_2$、$\boldsymbol{v}_3$ 是向量，那么 $\mathrm{d}/\mathrm{d}x$ 的矩阵为

$$\boldsymbol{A}=\begin{bmatrix}0&1&0\\0&0&2\end{bmatrix}=\text{导数 } T=\frac{\mathrm{d}}{\mathrm{d}x}\text{ 的矩阵形式.} \tag{8.3}$$

线性映射 $\mathrm{d}u/\mathrm{d}x$ 可以完全由矩阵乘法 $\boldsymbol{Au}$ 来表示.

输入 $\boldsymbol{u}=a+bx+cx^2$　　矩阵乘法是 $\boldsymbol{Au}=\begin{bmatrix}0&1&0\\0&0&2\end{bmatrix}\begin{bmatrix}a\\b\\c\end{bmatrix}=\begin{bmatrix}b\\2c\end{bmatrix}$，　　输出 $\dfrac{\mathrm{d}u}{\mathrm{d}x}=b+2cx$.

我们将把每一个映射都与一个矩阵联系起来！从 $T$ 到 $\boldsymbol{A}$ 的联系取决于输入基 1、$x$、$x^2$ 和输出基 1、$x$ 的选取.

接下来我们看积分. 它们给出了导数的伪逆 $T^+$！因为当 $f=1$ 不是其导数 $\mathrm{d}f/\mathrm{d}x=0$ 的积分时，我们不能写 $T^{-1}$，也不能说“逆”.

**例 8.5**　积分 $T^+$ 也是线性的：$\displaystyle\int_0^x(D+Ex)\mathrm{d}x=Dx+\frac{1}{2}Ex^2$.

输入基是 1、$x$，输出基是 1、$x$、$x^2$. $T^+$ 的矩阵 $A^+$ 是 $3\times 2$ 矩阵：

输入 $v=D+Ex$　　矩阵乘法是 $\boldsymbol{A}^+\boldsymbol{v}=\begin{bmatrix}0&0\\1&0\\0&\frac{1}{2}\end{bmatrix}\begin{bmatrix}D\\E\end{bmatrix}=\begin{bmatrix}0\\D\\\frac{1}{2}E\end{bmatrix}$　　输出 $=v$ 的积分 $T^+(\boldsymbol{v})=Dx+\dfrac{1}{2}Ex^2$.

微积分基本定理表明积分是微分的（伪）逆. 对于线性代数来说，矩阵 $\boldsymbol{A}^+$ 是矩阵 $\boldsymbol{A}$ 的（伪）逆：

$$\boldsymbol{A}^+\boldsymbol{A}=\begin{bmatrix}0&0\\1&0\\0&\frac{1}{2}\end{bmatrix}\begin{bmatrix}0&1&0\\0&0&2\end{bmatrix}=\begin{bmatrix}0&0&0\\0&1&0\\0&0&1\end{bmatrix},\quad \text{且}\boldsymbol{AA}^+=\begin{bmatrix}1&0\\0&1\end{bmatrix}. \tag{8.4}$$

常数函数的导数为零. 该零值出现在 $\boldsymbol{A}^+\boldsymbol{A}$ 的对角线上. 如果没有 $T=\mathrm{d}/\mathrm{d}x$ 的一维零空间，微积分就不是微积分了.

### 8.1.3　映射的例子（多数是线性的）

**例 8.6**　将每个三维向量投影到 $z=1$ 的水平平面上. 向量 $\boldsymbol{v}=\begin{bmatrix}x&y&z\end{bmatrix}^{\mathrm{T}}$ 被映射成 $T(\boldsymbol{v})=\begin{bmatrix}x&y&1\end{bmatrix}^{\mathrm{T}}$. 这个映射不是线性的. 为什么呢？它甚至没有将 $\boldsymbol{v}=\boldsymbol{0}$ 映射为 $T(\boldsymbol{v})=\boldsymbol{0}$.

**例 8.7** 假设 $\boldsymbol{A}$ 是可逆矩阵，显然 $T(\boldsymbol{v}+\boldsymbol{w})=\boldsymbol{A}\boldsymbol{v}+\boldsymbol{A}\boldsymbol{w}=T(\boldsymbol{v})+T(\boldsymbol{w})$. 另一个线性映射是用 $\boldsymbol{A}^{-1}$ 进行乘法运算. 这给出了逆映射 $T^{-1}$, 它将每个向量 $T(\boldsymbol{v})$ 映回 $\boldsymbol{v}$:

| |
|---|
| $T^{-1}(T(\boldsymbol{v}))=\boldsymbol{v}$ 与矩阵乘法 $\boldsymbol{A}^{-1}(\boldsymbol{A}\boldsymbol{v})=\boldsymbol{v}$ 相符. |
| 如果 $T(\boldsymbol{v})=\boldsymbol{A}\boldsymbol{v}$ 且 $S(\boldsymbol{u})=\boldsymbol{B}\boldsymbol{u}$, 那么 $T(S(\boldsymbol{u}))$ 与 $\boldsymbol{A}\boldsymbol{B}\boldsymbol{u}$ 相符. |

我们面临一个无法回避的问题. 从 $V=\mathbb{R}^n$ 到 $W=\mathbb{R}^m$ 的所有线性映射都是由矩阵产生的吗? 当一个线性映射 $T$ 被描述为“旋转”、“投影”或其他称呼时, 在 $T$ 背后总是存在一个矩阵 $\boldsymbol{A}$ 吗? $T(\boldsymbol{v})$ 总是等于 $\boldsymbol{A}\boldsymbol{v}$ 吗?

答案是肯定的! 这是一种不从研究矩阵开始的线性代数研究方法. 在我们选择了输入基和输出基之后，最终仍然会得到矩阵.

**注记** 映射有它自己的一套术语. 对于一个矩阵，列空间包含所有的输出 $\boldsymbol{A}\boldsymbol{v}$. 零空间包含所有使得 $\boldsymbol{A}\boldsymbol{v}=\boldsymbol{0}$ 的输入. 将这些术语翻译成“值域”和“核”:

- $T$ 的值域 = 所有输出 $T(\boldsymbol{v})$ 的全体. 值域对应于列空间.
- $T$ 的核 = 所有使得 $T(\boldsymbol{v})=\boldsymbol{0}$ 的输入 $\boldsymbol{v}$ 的全体. 核对应于零空间.

值域在输出空间 $W$ 中. 核在输入空间 $V$ 中. 当 $T$ 是用矩阵进行乘法运算，即 $T(\boldsymbol{v})=\boldsymbol{A}\boldsymbol{v}$ 时, 值域就是列空间, 核就是零空间.

## 要点回顾

1. 映射 $T$ 将输入空间中的每个 $\boldsymbol{v}$ 映射到输出空间中的 $T(\boldsymbol{v})$.
2. 如果 $T(\boldsymbol{v}+\boldsymbol{w})=T(\boldsymbol{v})+T(\boldsymbol{w})$ 且 $T(c\boldsymbol{v})=cT(\boldsymbol{v})$, 则 $T$ 是线性的: 直线映射为直线.
3. 线性组合的像是像的线性组合:

$$T(c_1\boldsymbol{v}_1+c_2\boldsymbol{v}_2+\cdots+c_n\boldsymbol{v}_n)=c_1T(\boldsymbol{v}_1)+c_2T(\boldsymbol{v}_2)+\cdots+c_nT(\boldsymbol{v}_n).$$

4. $T=$ 求导运算和 $T^+=$ 积分运算是线性的. 从 $\mathbb{R}^n$ 到 $\mathbb{R}^m$ 的映射 $T(\boldsymbol{v})=\boldsymbol{A}\boldsymbol{v}$ 也是线性的.

观察一个映射比定义它更有趣. 当一个 $2\times 2$ 矩阵 $\boldsymbol{A}$ 与 $\mathbb{R}^2$ 中的所有向量相乘时, 我们可以观察它的作用方式. 11 个房屋向量 $\boldsymbol{v}$ 被映射为 11 个向量 $\boldsymbol{A}\boldsymbol{v}$. $\boldsymbol{v}$ 之间的直线变成了映射后的向量 $\boldsymbol{A}\boldsymbol{v}$ 之间的直线.（从一个房屋到另一个房屋的映射是线性的!）将 $\boldsymbol{A}$ 应用于一个标准房屋会产生一个新房屋——可能被拉伸、旋转或变得不适宜居住.

## 例题总结

8.1 A. 倍加矩阵 $\begin{bmatrix}1&0\\1&1\end{bmatrix}$ 给出了一个从 $\begin{bmatrix}x&y\end{bmatrix}^{\mathrm{T}}$ 到 $T(x,y)=\begin{bmatrix}x&x+y\end{bmatrix}^{\mathrm{T}}$ 的剪切映射（见图 8.3）. 如果输入填满一个正方形, 画出映射后的图形.

**解** $x$ 轴上的点 $\begin{bmatrix}1&0\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}2&0\end{bmatrix}^{\mathrm{T}}$ 通过 $T$ 映射为 45° 直线上的 $\begin{bmatrix}1&1\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}2&2\end{bmatrix}^{\mathrm{T}}$. $y$ 轴上的点保持不变: $T\left(\begin{bmatrix}0&y\end{bmatrix}^{\mathrm{T}}\right)=\begin{bmatrix}0&y\end{bmatrix}^{\mathrm{T}}$, 是特征值 $\lambda=1$ 对应的特征向量.

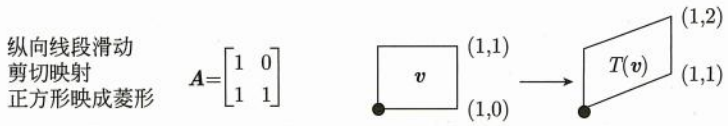


图 8.3　正方形被剪切映射

8.1 B. 一个非线性映射 $T$ 是可逆的，当且仅当输出空间中的每一个 $\boldsymbol{b}$ 都恰好来自输入空间中唯一一个 $\boldsymbol{x}$: $T(\boldsymbol{x})=\boldsymbol{b}$ 总是恰好有唯一解. 在下列 (关于实数 $x$ 的) 映射中, 哪些是可逆的，以及 $T^{-1}$ 是什么？没有一个是线性的，甚至 $T_3$ 也不是. 当求解 $T(\boldsymbol{x})=\boldsymbol{b}$ 时，是在对 $T$ 求逆以找到 $\boldsymbol{x}$.

$$T_1(x)=x^2 \quad T_2(x)=x^3 \quad T_3(x)=x+9 \quad T_4(x)=e^x \quad T_5(x)=\frac{1}{x}\ (\text{对于非零的 } x)$$

解　$T_1$ 不可逆: $x^2=1$ 有两个解, $x^2=-1$ 无解.

$T_4$ 不可逆, 因为 $e^x=-1$ 无解（如果输出空间变为正的 $b$ 值, 那么 $e^x=b$ 的逆是 $x=\ln b$）.

注意 $T_5^2=$ 恒等映射，但 $T_3^2=x+18$. $T_2^2(x)$ 和 $T_4^2(x)$ 是什么呢？

$T_2$、$T_3$、$T_5$ 是可逆的：$x^3=b$, $x+9=b$ 和 $\dfrac{1}{x}=b$ 都有唯一解 $x$.

$$x=T_2^{-1}(b)=b^{1/3} \quad x=T_3^{-1}(b)=b-9 \quad x=T_5^{-1}(b)=1/b$$

## 习题 8.1

1. 线性映射必须使零向量保持不变: $T(\mathbf{0})=\mathbf{0}$. 根据 $T(\boldsymbol{v}+\boldsymbol{w})=T(\boldsymbol{v})+T(\boldsymbol{w})$，令 $\boldsymbol{w}=$_____，即可证明这一点 (并完成证明). 也可以根据 $T(c\boldsymbol{v})=cT(\boldsymbol{v})$，令 $c=$_____ 来证明.

2. 要求 (b) 给出 $T(c\boldsymbol{v})=cT(\boldsymbol{v})$, 同时 $T(d\boldsymbol{w})=dT(\boldsymbol{w})$. 把两者相加，要求 (a) 给出 $T($　　$)=$_____. $T(c\boldsymbol{v}+d\boldsymbol{w}+e\boldsymbol{u})$ 等于什么？

3. 以下这些映射哪些不是线性的？输入是 $\boldsymbol{v}=\begin{bmatrix}v_1 & v_2\end{bmatrix}^{\mathrm{T}}$:

(1) $T(\boldsymbol{v})=\begin{bmatrix}v_2 & v_1\end{bmatrix}^{\mathrm{T}}$;

(2) $T(\boldsymbol{v})=\begin{bmatrix}v_1 & v_1\end{bmatrix}^{\mathrm{T}}$;

(3) $T(\boldsymbol{v})=\begin{bmatrix}0 & v_1\end{bmatrix}^{\mathrm{T}}$;

(4) $T(\boldsymbol{v})=\begin{bmatrix}0 & 1\end{bmatrix}^{\mathrm{T}}$;

(5) $T(\boldsymbol{v})=v_1-v_2$;

(6) $T(\boldsymbol{v})=v_1v_2$.

4. 如果 $S$ 和 $T$ 是线性映射, $T(S(\boldsymbol{v}))$ 是线性的还是二次的？

(1)（特殊情况）如果 $S(\boldsymbol{v})=\boldsymbol{v}$ 且 $T(\boldsymbol{v})=\boldsymbol{v}$，那么 $T(S(\boldsymbol{v}))=\boldsymbol{v}$ 还是 $\boldsymbol{v}^2$？

(2)（一般情况）$S(\boldsymbol{v}_1+\boldsymbol{v}_2)=S(\boldsymbol{v}_1)+S(\boldsymbol{v}_2)$ 且 $T(\boldsymbol{v}_1+\boldsymbol{v}_2)=T(\boldsymbol{v}_1)+T(\boldsymbol{v}_2)$，那么

$$T(S(\boldsymbol{v}_1+\boldsymbol{v}_2))=T(_____)=_____+_____.$$

5. 假设除了 $T(0,\ v_2)=(0,\ 0)$ 之外，$T(\boldsymbol{v})=\boldsymbol{v}$. 证明这个映射满足 $T(c\boldsymbol{v})=c\boldsymbol{v}$，但不满足 $T(\boldsymbol{v}+\boldsymbol{w})=T(\boldsymbol{v})+T(\boldsymbol{w})$.

6. 下列哪些映射满足 $T(\boldsymbol{v}+\boldsymbol{w})=T(\boldsymbol{v})+T(\boldsymbol{w})$，以及哪些满足 $T(c\boldsymbol{v})=cT(\boldsymbol{v})$？

（1）$T(\boldsymbol{v})=\dfrac{\boldsymbol{v}}{\|\boldsymbol{v}\|}$；

（2）$T(\boldsymbol{v})=v_1+v_2+v_3$；

（3）$T(\boldsymbol{v})=(v_1,\ 2v_2,\ 3v_3)$；

（4）$T(\boldsymbol{v})=\boldsymbol{v}$ 的最大分量.

7. 对下列从 $V=\mathbb{R}^2$ 到 $W=\mathbb{R}^2$ 的映射，求 $T(T(\boldsymbol{v}))$. 证明：当 $T(\boldsymbol{v})$ 是线性的时，$T(T(\boldsymbol{v}))$ 也是线性的.

（1）$T(\boldsymbol{v})=-\boldsymbol{v}$；

（2）$T(\boldsymbol{v})=\boldsymbol{v}+\begin{bmatrix}1 & 1\end{bmatrix}^{\mathrm{T}}$；

（3）$T(\boldsymbol{v})=$ 旋转$90^\circ=(-v_2,\ v_1)$；

（4）$T(\boldsymbol{v})=$ 投影$=\dfrac{1}{2}\begin{bmatrix}v_1+v_2 & v_1+v_2\end{bmatrix}^{\mathrm{T}}$.

8. 求 $T$ 的像空间和核空间 (类似于列空间和零空间)：$\boldsymbol{v}=\begin{bmatrix}v_1 & v_2\end{bmatrix}^{\mathrm{T}}\in\mathbb{R}^2$.

（1）$T(\boldsymbol{v})=\begin{bmatrix}v_1-v_2 & 0\end{bmatrix}^{\mathrm{T}}$；

（2）$T\left(\begin{bmatrix}v_1 & v_2 & v_3\end{bmatrix}^{\mathrm{T}}\right)=\begin{bmatrix}v_1 & v_2\end{bmatrix}^{\mathrm{T}}$；

（3）$T(\boldsymbol{v})=\begin{bmatrix}0 & 0\end{bmatrix}^{\mathrm{T}}$；

（4）$T(\boldsymbol{v})=\begin{bmatrix}v_1 & v_1\end{bmatrix}^{\mathrm{T}}$.

9. 映射 $T\left(\begin{bmatrix}v_1 & v_2 & v_3\end{bmatrix}^{\mathrm{T}}\right)=\begin{bmatrix}v_2 & v_3 & v_1\end{bmatrix}^{\mathrm{T}}$ 是“循环的”. $T(T(\boldsymbol{v}))$ 等于什么？$T^3(\boldsymbol{v})$ 等于什么？$T^{100}(\boldsymbol{v})$ 等于什么？将 $T$ 作用于 $\begin{bmatrix}v_1 & v_2 & v_3\end{bmatrix}^{\mathrm{T}}$ 一百次.

10. 假设线性映射 $T$ 将 $\begin{bmatrix}1 & 1\end{bmatrix}^{\mathrm{T}}$ 映射为 $\begin{bmatrix}2 & 2\end{bmatrix}^{\mathrm{T}}$，将 $\begin{bmatrix}2 & 0\end{bmatrix}^{\mathrm{T}}$ 映射为 $\begin{bmatrix}0 & 0\end{bmatrix}^{\mathrm{T}}$. 对下面各 $\boldsymbol{v}$，求 $T(\boldsymbol{v})$：

（1）$\boldsymbol{v}=\begin{bmatrix}2 & 2\end{bmatrix}^{\mathrm{T}}$；

（2）$\boldsymbol{v}=\begin{bmatrix}3 & 1\end{bmatrix}^{\mathrm{T}}$；

（3）$\boldsymbol{v}=\begin{bmatrix}-1 & 1\end{bmatrix}^{\mathrm{T}}$；

（4）$\boldsymbol{v}=\begin{bmatrix}a & b\end{bmatrix}^{\mathrm{T}}$.

11. 设 $T$ 是从 $V$ 到 $W$ 的线性映射. 当像空间是整个 $W$ 且核空间 (零空间) 仅包含 $\mathbf{0}$ 时，存在从 $W$ 到 $V$ 的线性逆映射. 那么对于 $W$ 中的每个 $\boldsymbol{w}$，$T(\boldsymbol{v})=\boldsymbol{w}$ 有唯一解. 为什么以下这些 $T$ 不可逆？

(1) $T\left(\begin{bmatrix} v_1 & v_2 \end{bmatrix}^{\mathrm{T}}\right) = \begin{bmatrix} v_2 & v_2 \end{bmatrix}^{\mathrm{T}}$, $W = \mathbb{R}^2$;

(2) $T\left(\begin{bmatrix} v_1 & v_2 \end{bmatrix}^{\mathrm{T}}\right) = \begin{bmatrix} v_1 & v_2 & v_1 + v_2 \end{bmatrix}^{\mathrm{T}}$, $W = \mathbb{R}^3$;

(3) $T\left(\begin{bmatrix} v_1 & v_2 \end{bmatrix}^{\mathrm{T}}\right) = v_1$, $W = \mathbb{R}^1$.

12. 若 $T(\boldsymbol{v}) = \boldsymbol{A}\boldsymbol{v}$ 且 $\boldsymbol{A}$ 是 $m \times n$ 矩阵, 那么 $T$ 是“用 $\boldsymbol{A}$ 进行乘法运算”.

(1) 输入空间 $V$ 和输出空间 $W$ 分别是什么?

(2) 为什么 $T$ 的像空间 $= \boldsymbol{A}$ 的列空间?

(3) 为什么 $T$ 的核空间 $= \boldsymbol{A}$ 的零空间?

**问题 13~19 可能更难. 输入空间 $V$ 包含所有的 $2 \times 2$ 矩阵 $\boldsymbol{M}$.**

13. $\boldsymbol{M}$ 是任意的 $2 \times 2$ 矩阵, 且 $\boldsymbol{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$. 映射 $T$ 定义为 $T(\boldsymbol{M}) = \boldsymbol{A}\boldsymbol{M}$. 矩阵乘法的哪些规则表明 $T$ 是线性的?

14. 假设 $\boldsymbol{A} = \begin{bmatrix} 1 & 2 \\ 3 & 5 \end{bmatrix}$, 证明 $T$ 的像空间是整个矩阵空间 $V$ 且核空间是零矩阵:

(1) 若 $\boldsymbol{A}\boldsymbol{M} = \boldsymbol{0}$, 证明: $\boldsymbol{M}$ 一定是零矩阵.

(2) 对于任意的 $2 \times 2$ 矩阵 $\boldsymbol{B}$, 求 $\boldsymbol{A}\boldsymbol{M} = \boldsymbol{B}$ 的一个解.

15. 假设 $\boldsymbol{A} = \begin{bmatrix} 1 & 2 \\ 3 & 6 \end{bmatrix}$, 证明单位矩阵 $\boldsymbol{I}$ 不在 $T$ 的像空间中. 找一个非零矩阵 $\boldsymbol{M}$, 使得 $T(\boldsymbol{M}) = \boldsymbol{A}\boldsymbol{M}$ 为零矩阵.

16. 假设 $T$ 对每个 $2 \times 2$ 矩阵 $\boldsymbol{M}$ 进行转置, 尝试找一个矩阵 $\boldsymbol{A}$, 使得 $\boldsymbol{A}\boldsymbol{M} = \boldsymbol{M}^{\mathrm{T}}$. 证明不存在这样的矩阵 $\boldsymbol{A}$. 给教授们的问题: 这是一个无法由矩阵定义的线性映射吗? 这个矩阵应该是 $4 \times 4$ 的!

17. 对每个 $2 \times 2$ 矩阵进行转置的映射 $T$ 显然是线性的. 以下这些额外性质中哪些是正确的?

(1) $T^2 =$ 恒等映射.

(2) $T$ 的核空间是零矩阵.

(3) 每个 $2 \times 2$ 矩阵都在 $T$ 的像空间中.

(4) $T(\boldsymbol{M}) = -\boldsymbol{M}$ 是不可能的.

18. 假设 $T(\boldsymbol{M}) = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} \boldsymbol{M} \begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix}$, 请找出一个矩阵 $\boldsymbol{M}$ 使得 $T(\boldsymbol{M}) \neq \boldsymbol{0}$. 描述所有使得 $T(\boldsymbol{M}) = 0$ 的矩阵 (核空间) 以及所有的输出矩阵 $T(\boldsymbol{M})$ (像空间).

19. 为什么从 $\mathbb{R}^2$ 到 $\mathbb{R}^2$ 的每个线性映射 $T$ 都将正方形映射为平行四边形? 矩形也会被映射为平行四边形 (如果 $T$ 不可逆则会被压缩).

**问题 20~26 是关于房屋映射的. 输出为 $T(\boldsymbol{H}) = \boldsymbol{A}\boldsymbol{H}$.**

20. 如何从 $T$(房屋) 的图像判断 $\boldsymbol{A}$ 是:

(1) 对角矩阵;

（2）秩为 1 的矩阵；

（3）下三角矩阵.

21. 针对以下矩阵绘制 $T$(房屋) 的图像: $\boldsymbol{D}=\begin{bmatrix}2&0\\0&1\end{bmatrix}$ $\boldsymbol{A}=\begin{bmatrix}7&7\\3&3\end{bmatrix}$ $\boldsymbol{U}=\begin{bmatrix}1&1\\0&1\end{bmatrix}$.

22. $\boldsymbol{A}=\begin{bmatrix}a&b\\c&d\end{bmatrix}$ 需满足什么条件以确保 $T$（房屋）：

（1）直立；

（2）旋转房屋且形状不变.

23. 当 $T(\boldsymbol{v})=-\boldsymbol{v}+\begin{bmatrix}1&0\end{bmatrix}^{\mathrm{T}}$ 时，描述 $T$（房屋）. 此 $T$ 是“仿射的”.

24. 更改房屋矩阵 $\boldsymbol{H}$ 以添加一个烟囱.

25. 标准房屋由 plot2d($\boldsymbol{H}$) 绘制. 圆形用 o 表示, 线条用 − 表示：

$$x=H(1,\ :)';\quad y=H(2,\ :)'$$
$$\text{axis}\left([-1010-1010]\right),\quad \text{axis}('\text{square}')$$
$$\text{plot}(x,y,'o',\ x,\ y,\ '-');$$

用图 8.2中的矩阵测试 plot2d($A'*\boldsymbol{H}$) 和 plot2d($A'*A*H$).

26. 不用计算机, 画出对于矩阵 $\boldsymbol{A}$、$\boldsymbol{A}*\boldsymbol{H}$ 所表示的房屋图形：

$$\begin{bmatrix}1&0\\0&0.1\end{bmatrix}\quad\begin{bmatrix}0.5&0.5\\0.5&0.5\end{bmatrix}\quad\begin{bmatrix}0.5&0.5\\-0.5&0.5\end{bmatrix}\quad\begin{bmatrix}1&1\\1&0\end{bmatrix}.$$

27. 此代码创建了一个由 50 个角度组成的向量 $\theta$. 它绘制单位圆，然后绘制 $T$(圆) = (椭圆). $T(\boldsymbol{v})=\boldsymbol{A}\boldsymbol{v}$将圆映射为椭圆.

```
A = [2 1; 1 2] % 可以更改A
theta = [0:2*pi/50:2*pi];
circle = [cos(theta); sin(theta)];
ellipse = A * circle;
axis([-4 4 -4 4]); axis('square')
plot(circle(1, :), circle(2, :), ellipse(1, :), ellipse(2, :))
```

28. 对于 $\det\boldsymbol{A}=ad-bc$，需满足什么条件才能确保输出的房屋 $\boldsymbol{AH}$：

（1）被压缩到一条直线上；

（2）端点保持顺时针顺序（不被反射）；

（3）与原始房屋面积相同.

## 8.2 线性映射的矩阵

（1）如果我们知道线性映射 $T$ 在输入基 $v_1,v_2,\cdots,v_n$ 上的取值 $T(\boldsymbol{v}_1),T(\boldsymbol{v}_2),\cdots,T(\boldsymbol{v}_n)$，那么线性性质就能告诉我们所有的 $T(\boldsymbol{v})$.

（2）“$T$ 的矩阵”的第 $j$ 列，是将 $T$ 作用于输入基向量 $\boldsymbol{v}_j$ 得到的.
（3）在输出基 $\boldsymbol{w}$ 下，将 $T(\boldsymbol{v}_j)$ 写成 $T(\boldsymbol{v}_j)=a_{1j}\boldsymbol{w}_1+a_{2j}\boldsymbol{w}_2+\cdots+a_{mj}\boldsymbol{w}_m$ 的形式. 这些 $a_{ij}$ 构成第 $j$ 列.
（4）如果输入基和输出基分别是 $I_{n\times n}$ 和 $I_{m\times m}$ 的列向量，那么 $T(\boldsymbol{x})=\boldsymbol{A}\boldsymbol{x}$ 的矩阵就是 $\boldsymbol{A}$.
（5）当基变为 $\boldsymbol{v}$ 和 $\boldsymbol{w}$ 时，同一个 $T$ 的矩阵从 $\boldsymbol{A}$ 变为 $\boldsymbol{W}^{-1}\boldsymbol{A}\boldsymbol{V}$.
（6）最好的基：$\boldsymbol{V}=\boldsymbol{W}=$（特征向量），或者 $\boldsymbol{V},\boldsymbol{W}=$（奇异向量），分别将 $\boldsymbol{A}$ 变为 $\boldsymbol{\Lambda}$ 和 $\boldsymbol{\Sigma}$.

接下来为每个线性映射 $T$ 指定一个矩阵 $\boldsymbol{A}$. 对于普通的列向量，输入 $\boldsymbol{v}$ 属于 $V=\mathbb{R}^n$，输出 $T(\boldsymbol{v})$ 属于 $W=\mathbb{R}^m$. 这个映射的矩阵 $\boldsymbol{A}$ 将是 $m\times n$ 矩阵. 对 $V$ 和 $W$ 的基的选择将决定 $\boldsymbol{A}$.

$\mathbb{R}^n$ 和 $\mathbb{R}^m$ 的标准基向量是单位矩阵的列向量. 这种选择会得到一个标准矩阵，然后通常有 $T(\boldsymbol{v})=\boldsymbol{A}\boldsymbol{v}$. 但这些空间也有其他基，所以同一个映射 $T$ 可以由其他矩阵来表示. 线性代数的一个主要主题是选择能给出最佳矩阵（对角矩阵）的基.

所有向量空间 $V$ 和 $W$ 都有基. 对这些基的每一种选择都会得到一个表示线性映射 $T$ 的矩阵. 当输入基与输出基不同时，$T(\boldsymbol{v})=\boldsymbol{v}$ 的矩阵将不是单位矩阵 $I$，它将是“基变换矩阵”. 这里的关键思想是：

> 假设我们知道 $T$ 在输入基向量 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots\boldsymbol{v}_n$ 上的取值.
> 矩阵的第 1 列到第 $n$ 列将包含这些输出 $T(\boldsymbol{v}_1),T(\boldsymbol{v}_2),\cdots,T(\boldsymbol{v}_n)$.
> $\boldsymbol{A}$ 乘以 $\boldsymbol{c}=$ 矩阵乘以向量 $=$ 这 $n$ 列的线性组合.
> $\boldsymbol{A}\boldsymbol{c}$ 给出正确的线性组合 $c_1T(\boldsymbol{v}_1)+c_2T(\boldsymbol{v}_2)+\cdots+c_nT(\boldsymbol{v}_n)=T(\boldsymbol{v})$.

**原因**　每个 $\boldsymbol{v}$ 都是基向量 $\boldsymbol{v}_j$ 的唯一线性组合 $c_1\boldsymbol{v}_1+c_2\boldsymbol{v}_2+\cdots+c_n\boldsymbol{v}_n$. 由于 $T$ 是线性映射（这里用到线性性质），$T(\boldsymbol{v})$ 一定是各列中输出 $T(\boldsymbol{v}_j)$ 的相同线性组合 $c_1T(\boldsymbol{v}_1)+c_2T(\boldsymbol{v}_2)+\cdots+c_nT(\boldsymbol{v}_n)$.

第一个例子给出了 $\mathbb{R}^2$ 和 $\mathbb{R}^3$ 中标准基向量对应的矩阵 $\boldsymbol{A}$. $\boldsymbol{A}$ 的两列是 $\boldsymbol{v}_1=\begin{bmatrix}1 & 0\end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{v}_2=\begin{bmatrix}0 & 1\end{bmatrix}^{\mathrm{T}}$ 的输出.

**例 8.8**　假设 $T$ 将 $\boldsymbol{v}_1=\begin{bmatrix}1 & 0\end{bmatrix}^{\mathrm{T}}$ 映射为 $T(\boldsymbol{v}_1)=\begin{bmatrix}2 & 3 & 4\end{bmatrix}^{\mathrm{T}}$，将第二个基向量 $\boldsymbol{v}_2=\begin{bmatrix}0 & 1\end{bmatrix}^{\mathrm{T}}$ 映射为 $T(\boldsymbol{v}_2)=\begin{bmatrix}5 & 5 & 5\end{bmatrix}$. 如果 $T$ 是从 $\mathbb{R}^2$ 到 $\mathbb{R}^3$ 的线性映射，那么它的“标准矩阵”是 $3\times 2$ 矩阵. 这些输出 $T(\boldsymbol{v}_1)$ 和 $T(\boldsymbol{v}_2)$ 构成 $\boldsymbol{A}$ 的列：

$$\boldsymbol{A}=\begin{bmatrix}2 & 5\\ 3 & 5\\ 4 & 5\end{bmatrix},\quad c_1=1\text{且}c_2=1\text{时，有}T(\boldsymbol{v}_1+\boldsymbol{v}_2)=\begin{bmatrix}2 & 5\\ 3 & 5\\ 4 & 5\end{bmatrix}\begin{bmatrix}1\\ 1\end{bmatrix}=\begin{bmatrix}7\\ 8\\ 9\end{bmatrix}.$$

### 8.2.1　基变换：矩阵 $B$

**例 8.9**　假设输入空间 $V=\mathbb{R}^2$ 也是输出空间 $W=\mathbb{R}^2$. 假设 $T(\boldsymbol{v})=\boldsymbol{v}$ 是恒等映射. 你可能期望它的矩阵是单位矩阵 $\boldsymbol{I}$，但这只有在输入基和输出基相同时才会发生. 我将选择不同的基，以

了解矩阵是如何构造的.

对于这个特殊情况 $T(\boldsymbol{v})=\boldsymbol{v}$，我将把矩阵称为 $\boldsymbol{B}$ 而不是 $\boldsymbol{A}$. 我们只是在做从基 $\boldsymbol{v}_1$、$\boldsymbol{v}_2$ 到 $\boldsymbol{w}_1$、$\boldsymbol{w}_2$ 的基变换. 每个 $\boldsymbol{v}$ 都是 $\boldsymbol{w}_1$ 和 $\boldsymbol{w}_2$ 的线性组合.

$$\text{输入基 } \begin{bmatrix}\boldsymbol{v}_1 & \boldsymbol{v}_2\end{bmatrix}=\begin{bmatrix}3 & 6\\ 3 & 8\end{bmatrix},\quad \text{输出基 } \begin{bmatrix}\boldsymbol{w}_1 & \boldsymbol{w}_2\end{bmatrix}=\begin{bmatrix}3 & 0\\ 1 & 2\end{bmatrix},\quad \boxed{\begin{array}{l}\text{基变换}\\ \\ \end{array}\begin{array}{l}\boldsymbol{v}_1=\mathbf{1}\cdot\boldsymbol{w}_1+\mathbf{1}\cdot\boldsymbol{w}_2\\ \boldsymbol{v}_2=\mathbf{2}\cdot\boldsymbol{w}_1+\mathbf{3}\cdot\boldsymbol{w}_2\end{array}}$$

请注意！用输出基 $\boldsymbol{w}_1$、$\boldsymbol{w}_2$ 来表示输入基 $\boldsymbol{v}_1$、$\boldsymbol{v}_2$. 因为这是我们的关键规则. 我们对每个输入基向量应用恒等映射 $T:T(\boldsymbol{v}_1)=\boldsymbol{v}_1$ 且 $T(\boldsymbol{v}_2)=\boldsymbol{v}_2$. 然后我们用输出基 $\boldsymbol{w}_1$ 和 $\boldsymbol{w}_2$ 来表示这些输出 $\boldsymbol{v}_1$ 和 $\boldsymbol{v}_2$. 那些数字 1、1 和 2、3 告诉我们矩阵 $\boldsymbol{B}$（基变换矩阵）的第一列和第二列：$\boldsymbol{WB}=\boldsymbol{V}$，所以 $\boldsymbol{B}=\boldsymbol{W}^{-1}\boldsymbol{V}$.

$$\begin{array}{l}\text{基变换}\\ \text{矩阵}\boldsymbol{B}\end{array}\quad \begin{bmatrix}\boldsymbol{w}_1 & \boldsymbol{w}_2\end{bmatrix}\boxed{\begin{bmatrix}\boldsymbol{B}\end{bmatrix}}=\begin{bmatrix}\boldsymbol{v}_1 & \boldsymbol{v}_2\end{bmatrix}\quad \text{即}\quad \begin{bmatrix}3 & 0\\ 1 & 2\end{bmatrix}\boxed{\begin{bmatrix}\mathbf{1} & \mathbf{2}\\ \mathbf{1} & \mathbf{3}\end{bmatrix}}=\begin{bmatrix}3 & 6\\ 3 & 8\end{bmatrix}. \tag{8.5}$$

当输入基排成矩阵 $\boldsymbol{V}$，输出基排成矩阵 $\boldsymbol{W}$ 时，$T=\boldsymbol{I}$（恒等映射）的基变换矩阵为 $\boldsymbol{B}=\boldsymbol{W}^{-1}\boldsymbol{V}$.

**关键** 我们有一种清晰的方式来理解 $\boldsymbol{B}=\boldsymbol{W}^{-1}\boldsymbol{V}$. 假设同一个向量 $\boldsymbol{u}$ 分别用输入基和输出基来表示，我们将用三种方式来表示：

$$\begin{cases}\boldsymbol{u}=c_1\boldsymbol{v}_1+\cdots+c_n\boldsymbol{v}_n\\ \boldsymbol{u}=d_1\boldsymbol{w}_1+\cdots+d_n\boldsymbol{w}_n\end{cases}\quad \text{即}\quad \begin{bmatrix}\boldsymbol{v}_1 & \cdots & \boldsymbol{v}_n\end{bmatrix}\begin{bmatrix}c_1\\ \vdots\\ c_n\end{bmatrix}=\begin{bmatrix}\boldsymbol{w}_1 & \cdots & \boldsymbol{w}_n\end{bmatrix}\begin{bmatrix}d_1\\ \vdots\\ d_n\end{bmatrix},\quad \text{也即}\boldsymbol{Vc}=\boldsymbol{Wd}.$$

以 $\boldsymbol{w}_1,\boldsymbol{w}_2,\cdots,\boldsymbol{w}_n$ 为基，则线性组合的系数 $\boldsymbol{d}$ 为 $\boldsymbol{W}^{-1}\boldsymbol{Vc}$. 那么 $\boldsymbol{B}$ 就是 $\boldsymbol{W}^{-1}\boldsymbol{V}$. (8.6)

公式 $\boldsymbol{B}=\boldsymbol{W}^{-1}\boldsymbol{V}$ 引出了一个奇妙的问题：当标准基 $\boldsymbol{V}=\boldsymbol{I}$ 映射为不同的基 $W$ 时，**基变换矩阵不是 $\boldsymbol{W}$，而是 $\boldsymbol{B}=\boldsymbol{W}^{-1}$.** 更大的基向量对应的系数更小！

$$\text{在标准基下的 }\begin{bmatrix}x\\ y\end{bmatrix}\text{ 在基 }\boldsymbol{w}_1\text{、}\boldsymbol{w}_2\text{ 下的系数为 }\begin{bmatrix}\boldsymbol{w}_1 & \boldsymbol{w}_2\end{bmatrix}^{-1}\begin{bmatrix}x\\ y\end{bmatrix}.$$

### 8.2.2 构造线性映射 $T$ 的矩阵

现在我们为任意线性映射构造一个矩阵. 假设 $T$ 将空间 $V$（$n$ 维）映射到空间 $W$（$m$ 维）. 我们为 $V$ 选择一组基 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_n$，为 $W$ 选择一组基 $\boldsymbol{w}_1,\boldsymbol{w}_2,\cdots,\boldsymbol{w}_m$. 矩阵 $\boldsymbol{A}$ 将是 $m\times n$ 矩阵. 为了找到 $\boldsymbol{A}$ 的第一列，将 $T$ 应用于第一个基向量 $\boldsymbol{v}_1$. 输出 $T(\boldsymbol{v}_1)$ 属于 $W$.

$$\boxed{T(\boldsymbol{v}_1)\text{ 是 }W\text{ 的基的线性组合 }a_{11}\boldsymbol{w}_1+a_{21}\boldsymbol{w}_2+\cdots+a_{m1}\boldsymbol{w}_m.}$$

数 $a_{11},a_{21},\cdots,a_{m1}$ 构成了 $\boldsymbol{A}$ 的第一列. 将 $\boldsymbol{v}_1$ 映射为 $T(\boldsymbol{v}_1)$ 相当于用 $\boldsymbol{A}$ 乘以 $\begin{bmatrix}1 & 0 & \cdots & 0\end{bmatrix}^{\mathrm{T}}$，得到矩阵的第一列. 当 $T$ 是求导运算且第一个基向量是 1 时，它的导数是 $T(\boldsymbol{v}_1)=0$. 所以对于下面的求导矩阵，$\boldsymbol{A}$ 的第一列全为零.

**例 8.10**　设输入基是 1、$x$、$x^2$、$x^3$. 输出基是 1、$x$、$x^2$. 那么 $T$ 进行求导运算: $T(\boldsymbol{v})=\dfrac{\mathrm{d}\boldsymbol{v}}{\mathrm{d}x}$, 并且 $\boldsymbol{A}$ 是 "求导矩阵".

$$\text{如果 } \boldsymbol{v}=c_1+c_2x+c_3x^2+c_4x^3 \quad \text{那么 } \frac{\mathrm{d}\boldsymbol{v}}{\mathrm{d}x}=1c_2+2c_3x+3c_4x^2$$

$$\boldsymbol{Ac}=\begin{bmatrix}0&1&0&0\\0&0&2&0\\0&0&0&3\end{bmatrix}\begin{bmatrix}c_1\\c_2\\c_3\\c_4\end{bmatrix}=\begin{bmatrix}c_2\\2c_3\\3c_4\end{bmatrix}$$

> 关键规则: 通过将 $T$ 应用于第 $j$ 个基向量来得到 $\boldsymbol{A}$ 的第 $j$ 列
>
> $$T(\boldsymbol{v}_j)=\text{输出基向量的组合}=a_{1j}\boldsymbol{w}_1+a_{2j}\boldsymbol{w}_2+\cdots+a_{mj}\boldsymbol{w}_m \tag{8.7}$$

这些数 $a_{ij}$ 构成矩阵 $\boldsymbol{A}$. 构造这个矩阵是为了正确处理基向量，然后利用线性性质可以处理所有其他向量. 每个 $\boldsymbol{v}$ 都可以写成线性组合 $c_1\boldsymbol{v}_1+c_2\boldsymbol{v}_2+\cdots+c_n\boldsymbol{v}_n$，并且 $T(\boldsymbol{v})$ 是 $\boldsymbol{w}_1,\boldsymbol{w}_2,\cdots,\boldsymbol{w}_m$ 的组合. 当 $\boldsymbol{A}$ 乘以 $\boldsymbol{v}$ 组合中的向量 $\boldsymbol{c}=\begin{bmatrix}c_1&\cdots&c_n\end{bmatrix}$ 时，得到 $T(\boldsymbol{v})$ 组合中的系数. 这是因为矩阵乘法 (组合列向量) 和 $T$ 一样具有线性性质.

**取定基，从 $V$ 到 $W$ 的任意线性映射都对应于唯一一个矩阵.**

**例 8.11**　对于积分 $T^+(\boldsymbol{v})$，第一个基函数同样是 1，它的积分是第二个基函数 $x$，所以 "积分矩阵" $\boldsymbol{A}^+$ 的第一列是 $\begin{bmatrix}0&1&0&0\end{bmatrix}^{\mathrm{T}}$.

$$d_1+d_2x+d_3x^2\text{的积分是}d_1x+\frac{1}{2}d_2x^2+\frac{1}{3}d_3x^3$$

$$\boldsymbol{A}^+\boldsymbol{d}=\begin{bmatrix}0&0&0\\1&0&0\\0&\frac{1}{2}&0\\0&0&\frac{1}{3}\end{bmatrix}\begin{bmatrix}d_1\\d_2\\d_3\end{bmatrix}=\begin{bmatrix}0\\d_1\\\frac{1}{2}d_2\\\frac{1}{3}d_3\end{bmatrix}$$

对一个函数先积分然后求导，就回到起始状态，所以 $\boldsymbol{AA}^+=\boldsymbol{I}$. 但是如果先求导然后积分，常数项就会丢失，所以 $\boldsymbol{A}^+\boldsymbol{A}\neq\boldsymbol{I}$.

1 的导数的积分是 0:

$$T^+T(1)=\text{零函数的积分}=0.$$

这与 $\boldsymbol{A}^+\boldsymbol{A}$ 吻合，$\boldsymbol{A}^+\boldsymbol{A}$ 的第一列全为 0. 导数映射 $T$ 有一个核 (即常数函数). 它的矩阵 $\boldsymbol{A}$ 有一个零空间. 再次强调一下最核心的思想: $\boldsymbol{Av}$ 对应 $T(\boldsymbol{v})$.

导数和积分的例子说明了三点. 第一，线性映射 $T$ 在微积分、微分方程和线性代数中无处不在. 第二，除 $\mathbb{R}^n$ 之外的空间也很重要，例如函数空间. 第三，如果先求导然后积分，可以将它们的矩阵 $\boldsymbol{A}^+\boldsymbol{A}$ 相乘.

### 8.2.3 矩阵乘积 $AB$ 与映射复合 $TS$ 相对应

这一段内容很重要——我们终于发现了矩阵乘法规则的真正原因. 两个线性映射 $T$ 和 $S$ 由两个矩阵 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 表示. 现在将 $TS$ 与乘法 $\boldsymbol{AB}$ 进行比较.

（1）当我们将映射 $T$ 应用于 $S$ 的输出时，根据以下规则得到 $TS$：$(TS)(\boldsymbol{u})$ 定义为 $T(S(\boldsymbol{u}))$，输出 $S(\boldsymbol{u})$ 成为 $T$ 的输入.

（2）当我们将矩阵 $\boldsymbol{A}$ 应用于 $\boldsymbol{B}$ 的输出时，根据以下规则计算 $\boldsymbol{AB}$：$(\boldsymbol{AB})(\boldsymbol{x})$ 定义为 $\boldsymbol{A}(\boldsymbol{Bx})$，输出 $\boldsymbol{Bx}$ 成为 $\boldsymbol{A}$ 的输入. 矩阵乘法给出了表示 $TS$ 的正确矩阵 $\boldsymbol{AB}$.

$S$ 把空间 $U$ 映到 $V$. 选取 $U$ 的一组基 $\boldsymbol{u}_1, \boldsymbol{u}_2, \cdots, \boldsymbol{u}_p$ 和 $V$ 的一组基 $\boldsymbol{v}_1, \boldsymbol{v}_2, \cdots, \boldsymbol{v}_n$，那么它的矩阵 $\boldsymbol{B}$ 是 $n \times p$ 矩阵. $T$ 把 $V$ 映到 $W$. 要求它的矩阵 $\boldsymbol{A}$，选取 $V$ 的基时，必须取 $\boldsymbol{v}_1, \boldsymbol{v}_2, \cdots, \boldsymbol{v}_n$——这是 $S$ 的输出空间和 $T$ 的输入空间. 那么矩阵 $\boldsymbol{AB}$ 与 $TS$ 相对应.

**乘法** 线性映射 $TS$ 把 $U$ 中的任意向量 $\boldsymbol{u}$ 映到 $V$ 中的 $S(\boldsymbol{u})$，最后映到 $W$ 中的 $T(S(\boldsymbol{u}))$. 矩阵 $\boldsymbol{AB}$ 把 $\mathbb{R}^p$ 中的任意向量 $\boldsymbol{x}$ 映到 $\mathbb{R}^n$ 中的 $\boldsymbol{Bx}$，最后到 $\mathbb{R}^m$ 中的 $\boldsymbol{ABx}$. **矩阵 $AB$ 对应于线性映射 $TS$：**

$$TS: U \to V \to W \qquad \boldsymbol{AB}: (m \times n)(n \times p) = (m \times p).$$

**映射的复合 $TS$ 与矩阵的乘积 $AB$ 相对应.** 一个重要的情况是当空间 $U$、$V$、$W$ 相同，并且它们的基也相同时，那么相关的矩阵都是**方阵.**

**例 8.12** $S$ 将平面旋转角度 $\theta$，$T$ 也将平面旋转角度 $\theta$. 那么 $TS$ 将平面旋转角度 $2\theta$. 这个映射 $T^2$ 对应于旋转角度 $2\theta$ 的旋转矩阵 $\boldsymbol{A}^2$：

$$T = S \quad \boldsymbol{A} = \boldsymbol{B} \quad T^2 = \text{旋转 角度 } 2\theta \quad \boldsymbol{A}^2 = \begin{bmatrix} \cos 2\theta & -\sin 2\theta \\ \sin 2\theta & \cos 2\theta \end{bmatrix}. \tag{8.8}$$

$$\boldsymbol{A}^2 = \begin{bmatrix} \cos\theta & \sin\theta \\ -\sin\theta & \cos\theta \end{bmatrix} \begin{bmatrix} \cos\theta & \sin\theta \\ -\sin\theta & \cos\theta \end{bmatrix} = \begin{bmatrix} \cos^2\theta - \sin^2\theta & -2\sin\theta\cos\theta \\ 2\sin\theta\cos\theta & \cos^2\theta - \sin^2\theta \end{bmatrix}. \tag{8.9}$$

比较式(8.8)和式(8.9)可得 $\cos 2\theta = \cos^2\theta - \sin^2\theta$ 以及 $\sin 2\theta = 2\sin\theta\cos\theta$.

**例 8.13** $S$ 旋转角度 $\theta$，$T$ 旋转角度 $-\theta$. 那么 $TS = I$，从而 $\boldsymbol{AB} = \boldsymbol{I}$. 在这种情况下，$T(S(\boldsymbol{u})) = \boldsymbol{u}$. 我们先逆时针旋转再顺时针旋转. 为了使映射与矩阵相对应，$\boldsymbol{ABx}$ 必须是 $\boldsymbol{x}$. 角度为 $\theta$ 和 $-\theta$ 的矩阵是互逆的.

$$\boldsymbol{AB} = \begin{bmatrix} \cos\theta & \sin\theta \\ -\sin\theta & \cos\theta \end{bmatrix} \begin{bmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{bmatrix} = \begin{bmatrix} \cos^2\theta + \sin^2\theta & 0 \\ 0 & \cos^2\theta + \sin^2\theta \end{bmatrix} = I.$$

### 8.2.4 选择最好的基

现在到了本书这部分内容的最后一步. **选择能使矩阵对角化的基.** 使用标准基 (单位矩阵的列向量) 时，映射 $T$ 对应于某个矩阵 $\boldsymbol{A}$——很可能不是对角矩阵. 当我们选择不同的基时，同一个映射 $T$ 会由不同的矩阵来表示. 基的两种很好的选择是特征向量和奇异向量.

**特征向量**　如果 $T$ 将 $\mathbb{R}^n$ 映射到 $\mathbb{R}^n$, 它的矩阵 $\boldsymbol{A}$ 是方阵. 如果 $\boldsymbol{A}$ 有 $n$ 个线性无关的特征向量, 选择它们作为输入和输出基. 在这个选择之下，$T$ 的矩阵是对角特征值矩阵 $\boldsymbol{\Lambda}$.

**例 8.14**　**投影矩阵**$T$ 将 $\mathbb{R}^2$ 中的每个向量 $\boldsymbol{v}=\begin{bmatrix}x & y\end{bmatrix}^{\mathrm{T}}$ 投影到直线 $y=-x$ 上. 使用标准基, $\boldsymbol{v}_1=\begin{bmatrix}1 & 0\end{bmatrix}^{\mathrm{T}}$ 投影到 $T(\boldsymbol{v}_1)=\begin{bmatrix}\frac{1}{2} & -\frac{1}{2}\end{bmatrix}^{\mathrm{T}}$. 对于 $\boldsymbol{v}_2=\begin{bmatrix}0 & 1\end{bmatrix}^{\mathrm{T}}$, 其投影是 $T(\boldsymbol{v}_2)=\begin{bmatrix}-\frac{1}{2} & \frac{1}{2}\end{bmatrix}^{\mathrm{T}}$. 这些构成了矩阵 $\boldsymbol{A}$ 的列向量:

$$\begin{matrix}\text{标准基下的}\\ \text{投影矩阵}\\ \text{不是对角矩阵}\end{matrix}\qquad \boldsymbol{A}=\begin{bmatrix}\frac{1}{2} & -\frac{1}{2}\\ -\frac{1}{2} & \frac{1}{2}\end{bmatrix}\quad \text{满足}\quad \boldsymbol{A}^{\mathrm{T}}=\boldsymbol{A}\quad \text{且}\quad \boldsymbol{A}^2=\boldsymbol{A}.$$

现在的重点是特征向量. 把它们当作基向量! 进行对角化!

当基向量是特征向量时, 矩阵就变成对角矩阵:

$$\boldsymbol{v}_1=\boldsymbol{w}_1=\begin{bmatrix}1 & -1\end{bmatrix}^{\mathrm{T}}\text{ 投影到自身 }T(\boldsymbol{v}_1)=\boldsymbol{v}_1\text{ 且 }\lambda_1=1$$

$$\boldsymbol{v}_2=\boldsymbol{w}_2=\begin{bmatrix}1 & 1\end{bmatrix}^{\mathrm{T}}\text{ 投影到零向量 }T(\boldsymbol{v}_2)=0\text{ 且 }\lambda_2=0$$

$$\begin{matrix}\text{特征向量为基}\\ \text{对角矩阵}\end{matrix}\qquad \text{新矩阵是}\quad \begin{bmatrix}1 & 0\\ 0 & 0\end{bmatrix}=\begin{bmatrix}\lambda_1 & 0\\ 0 & \lambda_2\end{bmatrix}=\boldsymbol{\Lambda}\tag{8.10}$$

特征向量构成一组完美的基，它使得 $T$ 的矩阵是特征值矩阵 $\boldsymbol{\Lambda}$.

那么其他的输入基等于输出基的情况下会发生什么？将这些基向量排成矩阵 $\boldsymbol{B}$. 我们在上面看到 (标准基和新基之间的) 基变换矩阵是 $\boldsymbol{B}_{\text{in}}=\boldsymbol{B}$ 且 $\boldsymbol{B}_{\text{out}}=\boldsymbol{B}^{-1}$. 变换 $T$ 的新矩阵与 $\boldsymbol{A}$ 相似.

在新的基下，新的矩阵 $\boldsymbol{A}_{\text{new}}=\boldsymbol{B}^{-1}\boldsymbol{A}\boldsymbol{B}$，与标准基下的矩阵 $\boldsymbol{A}$ 相似:

$$\boldsymbol{A}_{\boldsymbol{b}\text{ 到 }\boldsymbol{b}}=\boldsymbol{B}^{-1}_{\text{标准到 }\boldsymbol{b}}\boldsymbol{A}_{\text{标准}}B_{\boldsymbol{b}\text{到标准}}\tag{8.11}$$

这个等式实际上对映射复合 $ITI$ 和矩阵乘法 $\boldsymbol{B}^{-1}\boldsymbol{A}\boldsymbol{B}$ 的对应规则.

最后, 我们考虑不同的空间 $V$ 和 $W$, 以及两者各自的基. 选取好基之后，线性映射 $T$ 会对应一个矩阵 $\boldsymbol{A}$. $\boldsymbol{A}$ 可能不是对称的, 甚至不是方阵. 但我们总能选择合适的基，使之得到一个对角矩阵. 这就是奇异值分解 $\boldsymbol{A}=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\mathrm{T}}$ 中的奇异值矩阵 $\boldsymbol{\Sigma}=\operatorname{diag}(\sigma_1,\cdots,\sigma_r)$.

**奇异向量**　奇异值分解 (SVD) 表明 $\boldsymbol{U}^{-1}\boldsymbol{A}\boldsymbol{V}=\boldsymbol{\Sigma}$. 右奇异向量 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_n$ 将作为输入基. 左奇异向量 $\boldsymbol{u}_1,\boldsymbol{u}_2,\cdots,\boldsymbol{u}_m$ 将作为输出基. 根据矩阵乘法规则, 在这两组新基下, 同一个变换的矩阵是 $\boldsymbol{B}_{\text{out}}^{-1}\boldsymbol{A}\boldsymbol{B}_{\text{in}}=\boldsymbol{U}^{-1}\boldsymbol{A}\boldsymbol{V}=\boldsymbol{\Sigma}$. $\boldsymbol{\Sigma}$ 是对角矩阵!

我不能说 $\boldsymbol{\Sigma}$ 与 $\boldsymbol{A}$ “相似”. 我们现在处理的是两个基，输入基和输出基. 但这些是标准正交基，它们保持向量的长度. 按照大卫 • 沃根的一个好建议, 我提议说: $\boldsymbol{\Sigma}$ 与 $\boldsymbol{A}$ “等距”.

**定义.**　如果 $\boldsymbol{Q}_1$ 和 $\boldsymbol{Q}_2$ 是正交矩阵, 那么 $\boldsymbol{C}=\boldsymbol{Q}_1^{-1}\boldsymbol{A}\boldsymbol{Q}_2$ 与 $\boldsymbol{A}$ 等距.

**例 8.15** 为了构造变换 $T=\dfrac{\mathrm{d}}{\mathrm{d}x}$(求导映射) 的矩阵 $\boldsymbol{A}$, 我们选择输入基为 1、$x$、$x^2$、$x^3$, 输出基为 1、$x$、$x^2$. 矩阵 $\boldsymbol{A}$ 很简单, 但遗憾的是它不是对角矩阵. 不过我们可以将每个基按相反顺序选取.

现在输入基是 $x^3$、$x^2$、$x$、1, 输出基是 $x^2$、$x$、1. 基变换矩阵 $\boldsymbol{B}_{\text{in}}$ 和 $\boldsymbol{B}_{\text{out}}$ 是置换矩阵. 在新基下 $T(u)=\mathrm{d}u/\mathrm{d}x$ 的矩阵是对角奇异值矩阵 $\boldsymbol{B}_{\text{out}}^{-1}\boldsymbol{A}\boldsymbol{B}_{\text{in}}=\boldsymbol{\Sigma}$, 奇异值为 3、2、1:

$$\boldsymbol{B}_{\text{out}}^{-1}\boldsymbol{A}\boldsymbol{B}_{\text{in}}=\begin{bmatrix} & & 1\\ & 1 & \\ 1 & & \end{bmatrix}\begin{bmatrix} 0 & \mathbf{1} & 0 & 0\\ 0 & 0 & \mathbf{2} & 0\\ 0 & 0 & 0 & \mathbf{3}\end{bmatrix}\begin{bmatrix} & & & 1\\ & & 1 & \\ & 1 & & \\ 1 & & & \end{bmatrix}=\begin{bmatrix} \mathbf{3} & 0 & 0 & 0\\ 0 & \mathbf{2} & 0 & 0\\ 0 & 0 & \mathbf{1} & 0\end{bmatrix}. \tag{8.12}$$

这部分内容有些难. 即使是同一组基, 它的向量顺序不一样, 线性映射对应的矩阵也不同. $x^3$、$x^2$、$x$ 的导数分别是 $3x^2$、$2x$、1.

## 要点回顾

1. 如果我们知道 $T$ 在一组基向量 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_n$ 上的取值 $T(\boldsymbol{v}_1),T(\boldsymbol{v}_2),\cdots,T(\boldsymbol{v}_n)$, 那么线性性质将决定所有其他的 $T(\boldsymbol{v})$.

2. $\left\{\begin{array}{c}\text{线性变换}T\\ \text{输入基}\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_n\\ \text{输出基}\boldsymbol{w}_1,\boldsymbol{w}_2,\cdots,\boldsymbol{w}_m\end{array}\right\}\longrightarrow\begin{array}{c}\text{在这两组基下}\\ m\times n\text{ 矩阵 }\boldsymbol{A}\\ \text{表示 }T\end{array}\quad\begin{array}{c}\boldsymbol{A}\text{ 的第 }j\text{ 列 }a_{1j},a_{2j},\cdots,a_{mj}\\ \text{对应于}\\ T(\boldsymbol{v}_j)=a_{1j}\boldsymbol{w}_1+a_{2j}\boldsymbol{w}_2+\cdots+a_{mj}\boldsymbol{w}_m\end{array}$

3. 基变换矩阵 $\boldsymbol{B}=\boldsymbol{W}^{-1}\boldsymbol{V}=\boldsymbol{B}_{\text{out}}^{-1}\boldsymbol{B}_{\text{in}}$ 表示恒等变换 $T(\boldsymbol{v})=\boldsymbol{v}$ 在两组基下的矩阵.

4. 如果 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 分别表示 $T$ 和 $S$, 且 $S$ 的输出基是 $T$ 的输入基, 那么矩阵 $\boldsymbol{A}\boldsymbol{B}$ 表示线性映射 $T(S(\boldsymbol{u}))$.

5. 最好的输入-输出基是 $\boldsymbol{A}$ 的特征向量或奇异向量. 此时 $\boldsymbol{B}^{-1}\boldsymbol{A}\boldsymbol{B}=\boldsymbol{\Lambda}$ ($\boldsymbol{\Lambda}$ 为特征值对角矩阵), 或 $\boldsymbol{B}_{\text{out}}^{-1}\boldsymbol{A}\boldsymbol{B}_{\text{in}}=\boldsymbol{\Sigma}$（$\boldsymbol{\Sigma}$ 为奇异值对角矩阵）.

## 习题 8.2

习题 1 ~ 4 将一阶导数的例子扩展到高阶导数.

1. 映射 $S$ 为求二阶导数. 将 1、$x$、$x^2$、$x^3$ 作为输入基向量 $\boldsymbol{v}_1$、$\boldsymbol{v}_2$、$\boldsymbol{v}_3$、$\boldsymbol{v}_4$, 同时也作为输出基向量 $\boldsymbol{w}_1$、$\boldsymbol{w}_2$、$\boldsymbol{w}_3$、$\boldsymbol{w}_4$. 用 $\boldsymbol{w}_1$、$\boldsymbol{w}_2$、$\boldsymbol{w}_3$、$\boldsymbol{w}_4$ 线性表出 $S(\boldsymbol{v}_1)$、$S(\boldsymbol{v}_2)$、$S(\boldsymbol{v}_3)$、$S(\boldsymbol{v}_4)$. 求 $S$ 对应的 $4\times 4$ 矩阵 $\boldsymbol{A}_2$.

2. 哪些函数满足 $S(\boldsymbol{v})=0$? 它们在二阶导数 $S$ 的核中. 在习题 1 中，其矩阵 $\boldsymbol{A}_2$ 的零空间中的向量是什么?

3. 二阶导数矩阵 $\boldsymbol{A}_2$ 不是一阶导数矩阵 $\boldsymbol{A}_1$ 的平方:

$$\boldsymbol{A}_1=\begin{bmatrix} 0 & 1 & 0 & 0\\ 0 & 0 & 2 & 0\\ 0 & 0 & 0 & 3\end{bmatrix}\qquad \text{并不满足}\boldsymbol{A}_1^2=\boldsymbol{A}_2.$$

给 $\boldsymbol{A}_1$ 添加一个零行, 使得输出空间 = 输入空间. 比较 $\boldsymbol{A}_1^2$ 和 $\boldsymbol{A}_2$. 结论: 我们希望输出基 =_____ 基. 这样有 $m=n$.

4. (1) 一阶导数和二阶导数的乘积 $TS$ 产生三阶导数. 添加零元素使其成为 $4\times 4$ 矩阵, 然后计算 $\boldsymbol{A}_1\boldsymbol{A}_2=\boldsymbol{A}_3$.

(2) 矩阵 $\boldsymbol{A}_2^2$ 对应于 $S^2$ = 四阶导数. 为什么它等于零?

习题 5 ~ 9 都是关于第 5 题中的线性映射 $T$ 及其矩阵 $\boldsymbol{A}$.

5. 对于基向量 $\boldsymbol{v}_1$、$\boldsymbol{v}_2$、$\boldsymbol{v}_3$ 和 $\boldsymbol{w}_1$、$\boldsymbol{w}_2$、$\boldsymbol{w}_3$, 假设 $T(\boldsymbol{v}_1)=\boldsymbol{w}_2$ 且 $T(\boldsymbol{v}_2)=T(\boldsymbol{v}_3)=\boldsymbol{w}_1+\boldsymbol{w}_3$. $T$ 是一个线性变换. 求矩阵 $\boldsymbol{A}$, 并将其与向量 $\begin{bmatrix}1 & 1 & 1\end{bmatrix}^{\mathrm{T}}$ 相乘. 当输入为 $\boldsymbol{v}_1+\boldsymbol{v}_2+\boldsymbol{v}_3$ 时, $T$ 的输出是什么?

6. 因为 $T(\boldsymbol{v}_2)=T(\boldsymbol{v}_3)$, 则 $T(\boldsymbol{v})=0$ 的解为 $\boldsymbol{v}=$_____. $\boldsymbol{A}$ 的零空间是什么? 求 $T(\boldsymbol{v})=\boldsymbol{w}_2$ 的所有解.

7. 求一个不在 $\boldsymbol{A}$ 的列空间中的向量. 求一个不在线性映射 $T$ 的值域中向量, 用 $\boldsymbol{w}_1$、$\boldsymbol{w}_2$、$\boldsymbol{w}_3$ 的线性组合表示.

8. 你没有足够的信息来确定 $T^2$. 为什么它的矩阵不一定是 $\boldsymbol{A}^2$? 你还需要什么信息?

9. 求 $\boldsymbol{A}$ 的秩. 秩不是整个输出空间 $\boldsymbol{W}$ 的维数, 它是 $T$ 的_____ 的维数.

习题 10 ~ 13 关于可逆线性映射.

10. 假设 $T(\boldsymbol{v}_1)=\boldsymbol{w}_1+\boldsymbol{w}_2+\boldsymbol{w}_3$, $T(\boldsymbol{v}_2)=\boldsymbol{w}_2+\boldsymbol{w}_3$, $T(\boldsymbol{v}_3)=\boldsymbol{w}_3$. 利用这些基向量求 $T$ 的矩阵 $\boldsymbol{A}$. 什么样的输入向量 $\boldsymbol{v}$ 能使 $T(\boldsymbol{v})=\boldsymbol{w}_1$?

11. 求习题 10 中矩阵 $\boldsymbol{A}$ 的逆. 同时求变换 $T$ 的逆——$T^{-1}(\boldsymbol{w}_1)$、$T^{-1}(\boldsymbol{w}_2)$ 和 $T^{-1}(\boldsymbol{w}_3)$.

12. 以下哪些是正确的, 为什么其他的是荒谬的?

(1) $T^{-1}T=\boldsymbol{I}$;

(2) $T^{-1}(T(\boldsymbol{v}_1))=\boldsymbol{v}_1$;

(3) $T^{-1}(T(\boldsymbol{w}_1))=\boldsymbol{w}_1$.

13. 假设空间 $V$ 和 $W$ 有相同的基 $\boldsymbol{v}_1$、$\boldsymbol{v}_2$.

(1) 构造一个线性映射 $T$(不是恒等映射 $\boldsymbol{I}$), 逆映射是它自身.

(2) 构造一个线性映射 $T$(不是恒等映射 $\boldsymbol{I}$), 它满足 $T=T^2$.

(3) 为什么不会有一个 $T$ 同时满足 (1) 和 (2)?

习题 14 ~ 19 关于基变换.

14. (1) 什么样的矩阵 $\boldsymbol{B}$ 将 $\begin{bmatrix}1 & 0\end{bmatrix}^{\mathrm{T}}$ 映为 $\begin{bmatrix}2 & 5\end{bmatrix}^{\mathrm{T}}$, 并将 $\begin{bmatrix}0 & 1\end{bmatrix}^{\mathrm{T}}$ 映为 $\begin{bmatrix}1 & 3\end{bmatrix}^{\mathrm{T}}$?

(2) 什么样的矩阵 $\boldsymbol{C}$ 将 $\begin{bmatrix}2 & 5\end{bmatrix}^{\mathrm{T}}$ 映为 $\begin{bmatrix}1 & 0\end{bmatrix}^{\mathrm{T}}$, 并将 $\begin{bmatrix}1 & 3\end{bmatrix}^{\mathrm{T}}$ 映为 $\begin{bmatrix}0 & 1\end{bmatrix}^{\mathrm{T}}$?

(3) 为什么不存在矩阵将 $\begin{bmatrix}2 & 6\end{bmatrix}^{\mathrm{T}}$ 映为 $\begin{bmatrix}1 & 0\end{bmatrix}^{\mathrm{T}}$, 并将 $\begin{bmatrix}1 & 3\end{bmatrix}^{\mathrm{T}}$ 映为 $\begin{bmatrix}0 & 1\end{bmatrix}^{\mathrm{T}}$?

15. (1) 什么样的矩阵 $\boldsymbol{M}$ 将 $\begin{bmatrix}1 & 0\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}0 & 1\end{bmatrix}^{\mathrm{T}}$ 映为 $\begin{bmatrix}r & t\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}s & u\end{bmatrix}^{\mathrm{T}}$?

(2) 什么样的矩阵 $\boldsymbol{N}$ 将 $\begin{bmatrix}a & c\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}b & d\end{bmatrix}^{\mathrm{T}}$ 映为 $\begin{bmatrix}1 & 0\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}0 & 1\end{bmatrix}^{\mathrm{T}}$?

(3) $a$、$b$、$c$、$d$ 满足什么条件会使 (2) 中的矩阵 $N$ 不存在?

16.（1）习题 15 中的 $\boldsymbol{M}$ 和 $\boldsymbol{N}$ 如何得出将 $\begin{bmatrix}a & c\end{bmatrix}^{\mathrm{T}}$ 映为 $\begin{bmatrix}r & t\end{bmatrix}^{\mathrm{T}}$ 且将 $\begin{bmatrix}b & d\end{bmatrix}^{\mathrm{T}}$ 映为 $\begin{bmatrix}s & u\end{bmatrix}^{\mathrm{T}}$ 的矩阵？

（2）什么样的矩阵将 $\begin{bmatrix}2 & 5\end{bmatrix}^{\mathrm{T}}$ 映为 $\begin{bmatrix}1 & 1\end{bmatrix}^{\mathrm{T}}$，并将 $\begin{bmatrix}1 & 3\end{bmatrix}^{\mathrm{T}}$ 映为 $\begin{bmatrix}0 & 2\end{bmatrix}^{\mathrm{T}}$？

17. 如果保持相同的基向量但改变它们的顺序，基变换矩阵 $\boldsymbol{B}$ 是一个_____矩阵. 如果保持基向量的顺序但改变它们的长度，$\boldsymbol{B}$ 是一个_____矩阵.

18. 将轴向量 $\begin{bmatrix}1 & 0\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}0 & 1\end{bmatrix}^{\mathrm{T}}$ 逆时针旋转角度 $\theta$ 的矩阵是 $\boldsymbol{Q}$. 使用新的（旋转后的）轴，原来 $\begin{bmatrix}1 & 0\end{bmatrix}^{\mathrm{T}}$ 的坐标 $\begin{bmatrix}a & b\end{bmatrix}^{\mathrm{T}}$ 是什么？这个逆问题可能有点棘手. 可以画一个图或求解 $a$ 和 $b$：

$$\boldsymbol{Q}=\begin{bmatrix}\cos\theta & -\sin\theta\\ \sin\theta & \cos\theta\end{bmatrix},\quad \begin{bmatrix}1\\0\end{bmatrix}=a\begin{bmatrix}\cos\theta\\ \sin\theta\end{bmatrix}+b\begin{bmatrix}-\sin\theta\\ \cos\theta\end{bmatrix}.$$

19. 将 $\begin{bmatrix}1 & 0\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}0 & 1\end{bmatrix}^{\mathrm{T}}$ 变换为 $\begin{bmatrix}1 & 4\end{bmatrix}^{\mathrm{T}}$ 和 $\begin{bmatrix}1 & 5\end{bmatrix}^{\mathrm{T}}$ 的矩阵 $\boldsymbol{B}=$_____. 在使得 $a\begin{bmatrix}1 & 4\end{bmatrix}^{\mathrm{T}}+b\begin{bmatrix}1 & 5\end{bmatrix}^{\mathrm{T}}$ 等于 $\begin{bmatrix}1 & 0\end{bmatrix}^{\mathrm{T}}$ 的组合中，$\begin{bmatrix}a & b\end{bmatrix}^{\mathrm{T}}=$_____. $\begin{bmatrix}1 & 0\end{bmatrix}^{\mathrm{T}}$ 的这些新坐标与 $\boldsymbol{B}$ 或 $\boldsymbol{B}^{-1}$ 有何关系？

习题 20 ~ 23 是关于二次多项式空间 $y=A+Bx+Cx^2$ 的.

20. 抛物线 $w_1=\frac{1}{2}(x^2+x)$ 在 $x=1$ 处取值为 1，在 $x=0$ 和 $x=-1$ 处取值为 0. 求满足以下条件的抛物线 $w_2$、$w_3$，然后通过线性组合求出 $y(x)$.

（1）$w_2$ 在 $x=0$ 处取值为 1，在 $x=1$ 和 $x=-1$ 处取值为 0.

（2）$w_3$ 在 $x=-1$ 处取值为 1，在 $x=0$ 和 $x=1$ 处取值为 0.

（3）$y(x)$ 在 $x=1$ 处取值为 4，在 $x=0$ 处取值为 5，在 $x=-1$ 处取值为 6. 使用 $w_1$、$w_2$、$w_3$ 来表示 $y(x)$.

21. 二次多项式的一个基是 $\boldsymbol{v}_1=1$、$\boldsymbol{v}_2=x$、$\boldsymbol{v}_3=x^2$. 另一个基是习题 20 中的 $w_1$、$w_2$、$w_3$. 求两个基变换矩阵，一个是从基 $w_1$、$w_2$、$w_3$ 到基 $\boldsymbol{v}_1$、$\boldsymbol{v}_2$、$\boldsymbol{v}_3$ 的，另一个是从基 $\boldsymbol{v}_1$、$\boldsymbol{v}_2$、$\boldsymbol{v}_3$ 到基 $w_1$、$w_2$、$w_3$ 的.

22. 如果抛物线 $y=A+Bx+Cx^2$ 在 $x=a$ 处取值为 4，在 $x=b$ 处取值为 5，在 $x=c$ 处取值为 6，那么关于 $A$、$B$、$C$ 的三个方程是什么？求这个 $3\times 3$ 矩阵的行列式. 这个矩阵是将像 4、5、6 这样的值变换为抛物线 $y$，还是反过来呢？

23. 对于数 $m_1,\ m_2,\ \cdots,\ m_9$，在什么条件下这三条抛物线能构成所有抛物线 $a+bx+cx^2$ 空间的一个基？

$$\boldsymbol{v}_1=m_1+m_2x+m_3x^2,\quad \boldsymbol{v}_2=m_4+m_5x+m_6x^2,\quad \boldsymbol{v}_3=m_7+m_8x+m_9x^2.$$

24. 格拉姆-施密特 (Gram-Schmidt) 正交化将基 $\boldsymbol{a}_1$、$\boldsymbol{a}_2$、$\boldsymbol{a}_3$ 变换为标准正交基 $\boldsymbol{q}_1$、$\boldsymbol{q}_2$、$\boldsymbol{q}_3$. 这些是分解式 $\boldsymbol{A}=\boldsymbol{QR}$ 中 $\boldsymbol{Q}$ 的列向量. 证明：$\boldsymbol{R}$ 是从基 $\boldsymbol{a}_1$、$\boldsymbol{a}_2$、$\boldsymbol{a}_3$ 到基 $\boldsymbol{q}_1$、$\boldsymbol{q}_2$、$\boldsymbol{q}_3$ 的基变换矩阵.（当 $\boldsymbol{A}=\boldsymbol{QR}$ 时，$\boldsymbol{a}_2$ 如何用 $\boldsymbol{q}_1$、$\boldsymbol{q}_2$、$\boldsymbol{q}_3$ 线性表出？）

25. 消元法将矩阵 $\boldsymbol{A}$ 的行变换为矩阵 $\boldsymbol{U}$ 的行，其中 $\boldsymbol{A}=\boldsymbol{LU}$. $\boldsymbol{A}$ 的第二行如何用 $\boldsymbol{U}$ 的行线性表出？通过写出 $\boldsymbol{A}^T=\boldsymbol{U}^{\mathrm{T}}\boldsymbol{L}^{\mathrm{T}}$ 来处理列，基变换矩阵为 $\boldsymbol{B}=\boldsymbol{L}^{\mathrm{T}}$. 当这些矩阵是_____时，我们得到空间的基.

26. 假设 $\boldsymbol{v}_1$、$\boldsymbol{v}_2$、$\boldsymbol{v}_3$ 是 $T$ 的特征向量. 这意味着对于 $i=1,\ 2,\ 3$，有 $T(\boldsymbol{v}_i)=\lambda_i\boldsymbol{v}_i$. 当输入基和输出基都是 $\boldsymbol{v}$ 时，$T$ 的矩阵是什么？

27. 每一个可逆线性变换都可以以 $\boldsymbol{I}$ 作为其矩阵! 选择任意输入基 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_n$. 对于输出基，选择 $\boldsymbol{w}_i=T(\boldsymbol{v}_i)$. 为什么上述论断中，$T$ 必须是可逆的？

28. 令 $\boldsymbol{v}_1=\boldsymbol{w}_1$ 且 $\boldsymbol{v}_2=\boldsymbol{w}_2$，求下列 $T$ 的矩阵：

（1）$T(\boldsymbol{v}_1)=0$ 且 $T(\boldsymbol{v}_2)=3\boldsymbol{v}_1$；

（2）$T(\boldsymbol{v}_1)=\boldsymbol{v}_1$ 且 $T(\boldsymbol{v}_1+\boldsymbol{v}_2)=\boldsymbol{v}_1$.

29. 假设 $T$ 是将 $xy$ 平面关于 $x$ 轴进行反射，$S$ 是关于 $y$ 轴进行反射. 如果 $\boldsymbol{v}=\begin{bmatrix}x & y\end{bmatrix}^{\mathrm{T}}$，那么 $S(T(\boldsymbol{v}))$ 是什么？求乘积 $ST$ 的更简单描述.

30. 假设 $T$ 是关于直线 $y=x$ 线的反射，$S$ 是关于 $y$ 轴的反射. 如果 $\boldsymbol{v}=\begin{bmatrix}2 & 1\end{bmatrix}^{\mathrm{T}}$，那么 $T(\boldsymbol{v})=\begin{bmatrix}1 & 2\end{bmatrix}^{\mathrm{T}}$. 求 $S(T(\boldsymbol{v}))$ 和 $T(S(\boldsymbol{v}))$. 通常 $ST\neq TS$.

31. 两次反射的乘积是一个旋转. 将这些反射矩阵相乘以求出旋转角度:

$$\begin{bmatrix}\cos 2\theta & \sin 2\theta\\ \sin 2\theta & -\cos 2\theta\end{bmatrix}\begin{bmatrix}\cos 2\alpha & \sin 2\alpha\\ \sin 2\alpha & -\cos 2\alpha\end{bmatrix}.$$

32. 假设 $\boldsymbol{A}$ 是一个秩 $r=2$ 的 $3\times 4$ 矩阵，且 $T(\boldsymbol{v})=\boldsymbol{A}\boldsymbol{v}$. 从 $\boldsymbol{A}$ 的行空间中选取输入基向量 $\boldsymbol{v}_1$、$\boldsymbol{v}_2$，从零空间中选取 $\boldsymbol{v}_3$、$\boldsymbol{v}_4$. 在列空间中选取输出基向量 $\boldsymbol{w}_1=\boldsymbol{A}\boldsymbol{v}_1,\boldsymbol{w}_2=\boldsymbol{A}\boldsymbol{v}_2$，并从 $\boldsymbol{A}^{\mathrm{T}}$ 的零空间中选取 $\boldsymbol{w}_3$. 在这些特殊基下，什么样的特别简单的矩阵表示 $T$？

33. $2\times 2$ 矩阵的空间 $\boldsymbol{M}$ 有基 $\boldsymbol{v}_1=\begin{bmatrix}1 & 0\\ 0 & 0\end{bmatrix},\boldsymbol{v}_2=\begin{bmatrix}0 & 1\\ 0 & 0\end{bmatrix},\boldsymbol{v}_3=\begin{bmatrix}0 & 0\\ 1 & 0\end{bmatrix},\boldsymbol{v}_4=\begin{bmatrix}0 & 0\\ 0 & 1\end{bmatrix}$. 假设 $T$ 将每个矩阵乘以 $\begin{bmatrix}a & b\\ c & d\end{bmatrix}$. 当 $\boldsymbol{w}$ 等于 $\boldsymbol{v}$ 时，什么样的 $4\times 4$ 矩阵 $\boldsymbol{A}$ 表示矩阵空间上的这个变换 $T$？

34. 判断对错: 如果已知线性映射 $T$ 在 $\mathbb{R}^n$ 中 $n$ 个不同的非零向量的取值，那么我们就知道 $T$ 在 $\mathbb{R}^n$ 中所有向量的取值.

## 8.3　寻找好的基

（1）对于新的输入基 $\boldsymbol{B}_{\text{in}}$ 和输出基 $\boldsymbol{B}_{\text{out}}$，每个矩阵 $\boldsymbol{A}$ 都会变为 $\boldsymbol{B}_{\text{out}}^{-1}\boldsymbol{A}\boldsymbol{B}_{\text{in}}$.

（2）$\boldsymbol{B}_{\text{in}}=\boldsymbol{B}_{\text{out}}=$“$\boldsymbol{A}$ 的广义特征向量”会产生若尔当标准形 $\boldsymbol{J}=\boldsymbol{B}^{-1}\boldsymbol{A}\boldsymbol{B}$.

（3）傅里叶矩阵 $\boldsymbol{F}=\boldsymbol{B}_{\text{in}}=\boldsymbol{B}_{\text{out}}$ 可将每个循环矩阵对角化（使用快速傅里叶变换）.

（4）正弦函数、余弦函数、$\mathrm{e}^{ikx}$、勒让德多项式和切比雪夫多项式，这些都是函数空间中优秀的基.

这是本书的重要章节. 前面的章节通过解释基的概念做了铺垫. 第 6章介绍了特征向量 $\boldsymbol{x}$，第 7 章找到了奇异向量 $\boldsymbol{v}$ 和 $\boldsymbol{u}$. 这些基向量是两个成功的例子，但还有许多其他选择也非常有价值. 许多计算都是从选择基开始的.

输入基向量将是矩阵 $\boldsymbol{B}_{\text{in}}$ 的列，输出基向量将是 $\boldsymbol{B}_{\text{out}}$ 的列. $\boldsymbol{B}_{\text{in}}$ 和 $\boldsymbol{B}_{\text{out}}$ 始终是可逆的——因为基向量是线性无关的！

**纯代数** 如果 $\boldsymbol{A}$ 是标准基下变换 $T$ 的矩阵，那么

$$\boldsymbol{B}_{\text{out}}^{-1}\boldsymbol{A}\boldsymbol{B}_{\text{in}} \text{ 就是新基下的矩阵.} \tag{8.13}$$

标准基向量是单位矩阵的列向量：$\boldsymbol{B}_{\text{in}}=\boldsymbol{I}_{n\times n}$ 且 $\boldsymbol{B}_{\text{out}}=\boldsymbol{I}_{m\times m}$. 现在我们选择特殊的基，以使矩阵比 $\boldsymbol{A}$ 更清晰简单. 当 $\boldsymbol{B}_{\text{in}}=\boldsymbol{B}_{\text{out}}=\boldsymbol{B}$ 时，方阵 $\boldsymbol{B}^{-1}\boldsymbol{A}\boldsymbol{B}$ 与 $\boldsymbol{A}$ 相似，两者有相同的特征值.

**应用代数** 好的应用主要在于选择合适的基. 这里有针对向量的四个重要选择以及针对函数的三个重要选择. 在 8.1.3 节中我们引出了特征值矩阵 $\boldsymbol{\Lambda}$ 和奇异值矩阵 $\boldsymbol{\Sigma}$. 若尔当标准形是新内容.

（1）$\boldsymbol{B}_{\text{in}}=\boldsymbol{B}_{\text{out}}=$ 特征向量矩阵 $\boldsymbol{X}$. 那么 $\boldsymbol{X}^{-1}\boldsymbol{A}\boldsymbol{X}=\boldsymbol{\Lambda}$（特征值矩阵）. 这种选择要求 $\boldsymbol{A}$ 是一个有 $n$ 个线性无关特征向量的方阵. “$\boldsymbol{A}$ 必须是可对角化的.”当 $\boldsymbol{B}_{\text{in}}=\boldsymbol{B}_{\text{out}}$ 为特征向量矩阵 $\boldsymbol{X}$ 时，我们得到 $\boldsymbol{\Lambda}$.

（2）$\boldsymbol{B}_{\text{in}}=\boldsymbol{V}$ 且 $\boldsymbol{B}_{\text{out}}=\boldsymbol{U}$：$\boldsymbol{A}$ 的奇异向量. 那么 $\boldsymbol{U}^{-1}\boldsymbol{A}\boldsymbol{V}=$ 对角矩阵 $\boldsymbol{\Sigma}$. 当 $\boldsymbol{B}_{\text{in}}$ 和 $\boldsymbol{B}_{\text{out}}$ 是奇异向量矩阵 $\boldsymbol{V}$ 和 $\boldsymbol{U}$ 时，$\boldsymbol{\Sigma}$ 是奇异值矩阵（其对角线上是 $\sigma_1,\sigma_2,\cdots,\sigma_r$）. 回想一下，$\boldsymbol{B}_{\text{in}}$ 和 $\boldsymbol{B}_{\text{out}}$ 的列向量是 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 和 $\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 的标准正交特征向量. 那么 $\boldsymbol{A}=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\mathrm{T}}$ 可得 $\boldsymbol{\Sigma}=\boldsymbol{U}^{-1}\boldsymbol{A}\boldsymbol{V}$.

（3）$\boldsymbol{B}_{\text{in}}=\boldsymbol{B}_{\text{out}}=\boldsymbol{A}$ 的广义特征向量. 那么 $\boldsymbol{B}^{-1}\boldsymbol{A}\boldsymbol{B}=$ 若尔当标准形 $\boldsymbol{J}$. $\boldsymbol{A}$ 是方阵，但它可能只有 $s$ 个线性无关的特征向量.（如果 $s=n$，那么 $\boldsymbol{B}$ 就是 $\boldsymbol{X}$ 且 $\boldsymbol{J}$ 就是 $\boldsymbol{\Lambda}$.）在所有情况下，若尔当构造了 $n-s$ 个额外的“广义”特征向量，目的是使若尔当标准形 $\boldsymbol{J}$ 尽可能接近对角矩阵：①$\boldsymbol{J}$ 的对角线上有 $s$ 个子方阵；②每个子方阵有唯一的特征值 $\lambda$，一个线性无关的特征向量，且在对角线上方的次对角线为 1.

最好的情况是 $\boldsymbol{J}$ 有 $n$ 个 $1\times 1$ 的块，每个块包含一个特征值，此时 $\boldsymbol{J}=\boldsymbol{\Lambda}$（对角矩阵）.

**例 8.16** 这个若尔当矩阵 $\boldsymbol{J}$ 的特征值为 $\lambda=2,2,3,3$（两个二重特征值）. 因为 $\boldsymbol{J}$ 是上三角矩阵，这些特征值位于对角线上. 特征值 $\lambda=2$ 有两个线性无关的特征向量，但 $\lambda=3$ 只有一个. 对于每个与 $\boldsymbol{J}$ 相似的矩阵 $\boldsymbol{C}=\boldsymbol{B}\boldsymbol{J}\boldsymbol{B}^{-1}$，情况都是如此.

**若尔当矩阵** $\boldsymbol{J}=\begin{bmatrix}2 & & & \\ & 2 & & \\ & & 3 & 1 \\ & & 0 & 3\end{bmatrix}$

两个$1\times 1$子块
一个$2\times 2$子块
$J$有 3 个线性无关的特征向量
特征值为2, 2, 3, 3

$\boldsymbol{x}_1=\begin{bmatrix}1 & 0 & 0 & 0\end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{x}_2=\begin{bmatrix}0 & 1 & 0 & 0\end{bmatrix}^{\mathrm{T}}$ 是 $\lambda=2$ 的两个线性无关的特征向量. $\boldsymbol{x}_3=\begin{bmatrix}0 & 0 & 1 & 0\end{bmatrix}^{\mathrm{T}}$ 是 $\lambda=3$ 的特征向量. 这个若尔当矩阵的“广义特征向量”是第四个标准基向量 $\boldsymbol{x}_4=\begin{bmatrix}0 & 0 & 0 & 1\end{bmatrix}^{\mathrm{T}}$. $\boldsymbol{J}$ 的特征向量（普通的和广义的）恰好是单位矩阵 $\boldsymbol{I}$ 的列向量 $\boldsymbol{x}_1$、$\boldsymbol{x}_2$、$\boldsymbol{x}_3$、$\boldsymbol{x}_4$.

注意 $(\boldsymbol{J}-3\boldsymbol{I})\boldsymbol{x}_4=\boldsymbol{x}_3$. 广义特征向量 $\boldsymbol{x}_4$ 与真正的特征向量 $\boldsymbol{x}_3$ 相关联. 真正的 $\boldsymbol{x}_4$ 应该满足 $(\boldsymbol{J}-3\boldsymbol{I})\boldsymbol{x}_4=\boldsymbol{0}$，但这里并非如此！

每个与 $\boldsymbol{J}$ 相似的矩阵 $\boldsymbol{C}=\boldsymbol{B}\boldsymbol{J}\boldsymbol{B}^{-1}$ 在 $\boldsymbol{B}$ 的前三列中会有真正的特征向量 $\boldsymbol{b}_1$、$\boldsymbol{b}_2$、$\boldsymbol{b}_3$. $\boldsymbol{B}$ 的第四列将是 $\boldsymbol{C}$ 的一个广义特征向量 $\boldsymbol{b}_4$，与真正的 $\boldsymbol{b}_3$ 相关联. 证明其实很快，令 $\boldsymbol{B}\boldsymbol{x}_3=\boldsymbol{b}_3$ 和

$\boldsymbol{B}\boldsymbol{x}_4=\boldsymbol{b}_4$ 可发现：$\boldsymbol{B}$ 的第四列 $\boldsymbol{b}_4$ 通过 $(\boldsymbol{C}-3\boldsymbol{I})\boldsymbol{b}_4=\boldsymbol{b}_3$ 与 $\boldsymbol{b}_3$ 相关联.

$$\left(\boldsymbol{B}\boldsymbol{J}\boldsymbol{B}^{-1}-3\boldsymbol{I}\right)\boldsymbol{b}_4=\boldsymbol{B}\boldsymbol{J}\boldsymbol{x}_4-3\boldsymbol{B}\boldsymbol{x}_4=\boldsymbol{B}(\boldsymbol{J}-3\boldsymbol{I})\boldsymbol{x}_4=\boldsymbol{B}\boldsymbol{x}_3=\boldsymbol{b}_3. \tag{8.14}$$

若尔当定理的要点在于，每个方阵 $\boldsymbol{A}$ 都有一组完备的特征向量和广义特征向量. 当把这些向量放入 $\boldsymbol{B}$ 的列中时，矩阵 $\boldsymbol{B}^{-1}\boldsymbol{A}\boldsymbol{B}=\boldsymbol{J}$ 就成为若尔当标准形. 基于例 8.16，以下是对 $\boldsymbol{J}$ 的描述.

### 8.3.1　若尔当标准形

对于每个方阵 $\boldsymbol{A}$，我们希望选择 $\boldsymbol{B}$，使得 $\boldsymbol{B}^{-1}\boldsymbol{A}\boldsymbol{B}$ 尽可能接近对角矩阵. 当 $\boldsymbol{A}$ 有 $n$ 个线性无关的特征向量时，将它们放入 $\boldsymbol{B}$ 的列中. 此时 $\boldsymbol{B}=\boldsymbol{X}$，矩阵 $\boldsymbol{X}^{-1}\boldsymbol{A}\boldsymbol{X}$ 是对角矩阵. 这就是 $\boldsymbol{A}$ 的若尔当标准形——$\boldsymbol{A}$ 可对角化时的情况. 在一般情况下，特征向量缺失，无法得到 $\boldsymbol{\Lambda}$.

假设 $\boldsymbol{A}$ 有 $s$ 个线性无关的特征向量. 那么它与一个有 $s$ 个子块的若尔当矩阵相似. 每个子块在对角线上有一个特征值，其上方紧邻的元素为 1. 这个子块恰好对应 $\boldsymbol{A}$ 的一个特征向量. 这时 $\boldsymbol{B}$ 既包含广义特征向量，也包含普通特征向量.

当有 $n$ 个特征向量时，所有 $n$ 个子块都将是 $1\times 1$ 的. 在这种情况下，$\boldsymbol{J}=\boldsymbol{\Lambda}$.

若尔当标准形可以求解任意方阵 $\boldsymbol{A}=\boldsymbol{B}\boldsymbol{J}\boldsymbol{B}^{-1}$ 对应的微分方程 $\mathrm{d}\boldsymbol{u}/\mathrm{d}t=\boldsymbol{A}\boldsymbol{u}$. 解 $\mathrm{e}^{\boldsymbol{A}t}\boldsymbol{u}(0)$ 变为 $\boldsymbol{u}(t)=\boldsymbol{B}\mathrm{e}^{\boldsymbol{J}t}\boldsymbol{B}^{-1}\boldsymbol{u}(0)$. $\boldsymbol{J}$ 是上三角矩阵，其矩阵指数 $\mathrm{e}^{\boldsymbol{J}t}$ 涉及 $\mathrm{e}^{\lambda t}$ 乘以幂次 $1,\ t,\ \cdots,\ t^{s-1}$. 总体而言，若尔当标准形能最优地处理重特征值问题.

（若尔当标准形）　如果 $\boldsymbol{A}$ 有 $s$ 个线性无关的特征向量，那么它与一个矩阵 $\boldsymbol{J}$ 相似，其中 $\boldsymbol{J}$ 的对角线上有 $s$ 个若尔当块 $\boldsymbol{J}_1,\boldsymbol{J}_2,\cdots,\boldsymbol{J}_s$. $\boldsymbol{B}$ 包含“广义特征向量”.

$A$ 的若尔当标准形

$$\boldsymbol{B}^{-1}\boldsymbol{A}\boldsymbol{B}=\begin{bmatrix}\boldsymbol{J}_1 & & \\ & \ddots & \\ & & \boldsymbol{J}_s\end{bmatrix}=\boldsymbol{J} \tag{8.15}$$

每个块 $\boldsymbol{J}_i$ 有一个特征值 $\lambda_i$，一个线性无关的特征向量，且在对角线上方紧邻的元素为 1：

$J$ 中的若尔当块

$$\boldsymbol{J}_i=\begin{bmatrix}\lambda_i & 1 & & \\ & \ddots & \ddots & \\ & & \ddots & 1\\ & & & \lambda_i\end{bmatrix}. \tag{8.16}$$

如果两个矩阵有相同的若尔当标准形，则它们相似，否则不相似.

若尔当标准形 $\boldsymbol{J}$ 对于每个缺失的特征向量都有一个非对角线上的 1（并且这些 1 位于特征值旁边）. 在每一族相似矩阵中，我们选取一个突出的成员，称为 $\boldsymbol{J}$. 它接近对角矩阵（或者如果可能的话是完全对角矩阵）. 我们可以快速求解 $\mathrm{d}\boldsymbol{u}/\mathrm{d}t=\boldsymbol{J}\boldsymbol{u}$ 并计算 $\boldsymbol{J}^k$. 这组相似矩阵中的其他每个矩阵都具有 $\boldsymbol{B}\boldsymbol{J}\boldsymbol{B}^{-1}$ 的形式.

若尔当定理在我的教科书《线性代数及其应用》中有证明. 如果需要证明，请参考那本书（或更高级的图书）. 推理相当复杂，并且在实际计算中，若尔当标准形一点也不受欢迎——它的计算不稳定. $\boldsymbol{A}$ 的微小变化会使重特征值分离，并消除非对角线上的 1——将约当标准型转变为对角矩阵 $\boldsymbol{\Lambda}$.

无论是否被证明，相似性的核心思想——在保留 $\boldsymbol{A}$ 的本质属性的同时，使其尽可能简单. 最好的基 $\boldsymbol{B}$ 使得 $\boldsymbol{B}^{-1}\boldsymbol{A}\boldsymbol{B}=\boldsymbol{J}$.

**问题** 如果$\boldsymbol{A}^2=$零矩阵，$\boldsymbol{A}$ 的特征值是什么？所有可能的若尔当标准形有哪些？

**答案** 特征值必定全为零，因为 $\boldsymbol{A}\boldsymbol{x}=\lambda\boldsymbol{x}$ 会推出 $\boldsymbol{A}^2\boldsymbol{x}=\lambda^2\boldsymbol{x}=0\boldsymbol{x}$. $\boldsymbol{A}$ 的若尔当标准形 $\boldsymbol{J}$ 满足 $\boldsymbol{J}^2=0$，这是因为 $\boldsymbol{J}^2=(\boldsymbol{B}^{-1}\boldsymbol{A}\boldsymbol{B})(\boldsymbol{B}^{-1}\boldsymbol{A}\boldsymbol{B})=\boldsymbol{B}^{-1}\boldsymbol{A}^2\boldsymbol{B}=\boldsymbol{0}$. $\boldsymbol{J}$ 中的每个块对角元素都是 $\lambda=0$. 当 $k=1,2,3$ 时，若尔当块 $\boldsymbol{J}_k$ 的平方 $\boldsymbol{J}_k^2$：

$$\begin{bmatrix}0\end{bmatrix}^2=\begin{bmatrix}0\end{bmatrix}\qquad\begin{bmatrix}0&1\\0&0\end{bmatrix}^2=\begin{bmatrix}0&0\\0&0\end{bmatrix}\qquad\begin{bmatrix}0&1&0\\0&0&1\\0&0&0\end{bmatrix}^2=\begin{bmatrix}0&0&\mathbf{1}\\0&0&0\\0&0&0\end{bmatrix}$$

**结论** 如果 $\boldsymbol{J}^2=0$，那么所有若尔当块的大小必定为 1 或 2. 对于 $3\times3$ 的若尔当块，其平方不为零. $\boldsymbol{J}$ 的秩最多为 $n/2$，此时有 $n/2$ 个若尔当块，每个块大小为 2、秩为 1.

$\boldsymbol{B}_{\text{in}}=\boldsymbol{B}_{\text{out}}=$ 傅里叶矩阵 $\boldsymbol{F}$. 那么 $\boldsymbol{F}\boldsymbol{x}$ 是 $\boldsymbol{x}$ 的离散傅里叶变换. 言下之意：傅里叶矩阵的列向量为式(8.18)中 $\boldsymbol{P}$ 的特征向量. 这些是很好的基向量.

哪些矩阵能被 $\boldsymbol{F}$ 对角化？这次我们从特征向量 $\begin{bmatrix}1&\lambda&\lambda^2&\lambda^3\end{bmatrix}^{\mathrm{T}}$ 开始，找出以这些向量为特征向量的矩阵：

$$\text{如果 }\lambda^4=1\text{，那么}\qquad\boldsymbol{P}\boldsymbol{x}=\begin{bmatrix}0&1&0&0\\0&0&1&0\\0&0&0&1\\1&0&0&0\end{bmatrix}\begin{bmatrix}1\\\lambda\\\lambda^2\\\lambda^3\end{bmatrix}=\lambda\begin{bmatrix}1\\\lambda\\\lambda^2\\\lambda^3\end{bmatrix}=\lambda\boldsymbol{x}.\tag{8.17}$$

$\boldsymbol{P}$ 是置换矩阵. 方程 $\boldsymbol{P}\boldsymbol{x}=\lambda\boldsymbol{x}$ 表明 $\boldsymbol{x}$ 是 $\boldsymbol{P}$ 的特征向量，$\lambda$ 是 $\boldsymbol{P}$ 的特征值. 注意这个向量方程的第四行是 $1=\lambda^4$，事实上该条件也是上述论证的充分条件.

这会给出四个不同的特征值 $\lambda$ 吗？是的. 四个数 $\lambda=1,\ \mathrm{i},\ -1,\ -\mathrm{i}$ 都满足 $\lambda^4=1$. （我们知道 $\mathrm{i}^2=-1$. 两边同时平方可得 $\lambda^4=1$.）所以这四个数是 $\boldsymbol{P}$ 的特征值，每个特征值都有其特征向量 $\boldsymbol{x}=\begin{bmatrix}1&\lambda&\lambda^2&\lambda^3\end{bmatrix}^{\mathrm{T}}$.

特征向量矩阵 $\boldsymbol{F}$ 将上述置换矩阵 $\boldsymbol{P}$ 对角化：

$$\boldsymbol{P}\text{ 的特征值矩阵 }\boldsymbol{\Lambda}\quad\begin{bmatrix}1&&&\\&\mathrm{i}&&\\&&-1&\\&&&-\mathrm{i}\end{bmatrix}\qquad\begin{matrix}\text{特征向量矩阵为}\\\text{傅里叶矩阵}\boldsymbol{F}\end{matrix}\quad\begin{bmatrix}1&1&1&1\\1&\mathrm{i}&-1&-\mathrm{i}\\1&\mathrm{i}^2&1&(-\mathrm{i})^2\\1&\mathrm{i}^3&-1&(-\mathrm{i})^3\end{bmatrix}\tag{8.18}$$

$\boldsymbol{F}$ 的列向量两两正交，它们是 $\boldsymbol{P}$ 以及每个循环矩阵 $\boldsymbol{C}=c_0\boldsymbol{I}+c_1\boldsymbol{P}+c_2\boldsymbol{P}^2+c_3\boldsymbol{P}^3$ 的特征向量. 不幸的是，这个傅里叶矩阵 $\boldsymbol{F}$ 是复矩阵（它是世界上最重要的复矩阵）. 通过快速傅里叶变换，$\boldsymbol{F}\boldsymbol{x}$ 的乘法运算可以在极短时间内进行数百万次.

$$\text{循环矩阵}\quad\boldsymbol{C}=\begin{bmatrix}c_0&c_1&c_2&c_3\\c_3&c_0&c_1&c_2\\c_2&c_3&c_0&c_1\\c_1&c_2&c_3&c_0\end{bmatrix}$$

傅里叶矩阵$\boldsymbol{F}$四个列向量是它的特征向量

向量$\boldsymbol{F}\boldsymbol{c}$的分量是它的四个特征值

特征向量 $\begin{bmatrix}1&1&1&1\end{bmatrix}^{\mathrm{T}}$ 属于特征值$\lambda=c_0+c_1+c_2+c_3$

若想了解更多关于循环矩阵的内容，请见 6.4 节.

**循环矩阵的对角元都相同.** $c_0$ 从左上角沿着主对角线绵延到右下角，$c_1$ 在对角线上方，最后绕回左下角. 这反映了“循环性”，其含义包括某种周期性，比方说，$\lambda$ 的方幂就是周期的，因为 $\lambda^4=1$，这就导致 $\lambda^5=\lambda,\lambda^6=\lambda^2,\lambda^7=\lambda^3,\lambda^8=\lambda^4$.

循环矩阵的主对角线是常数这一点也是重要的性质. 在微分方程中，这对应于常系数微分方程. 这正是傅里叶的工作的完美之处!

$$\text{方程 } \frac{\mathrm{d}^2u}{\mathrm{d}t^2}=-u \text{ 的解是 } u=c_0\cos t+c_1\sin t$$

$$\text{方程 } \frac{\mathrm{d}^2u}{\mathrm{d}t^2}=tu \text{ 不能用初等函数求解}$$

这些方程都是线性的. 第一个方程描述了一个简单的弹簧振动，它基于牛顿第二定律 $f=ma$，其中质量 $m$ 设为 1，加速度 $a$ 即 $\mathrm{d}^2u/\mathrm{d}t^2$，而力 $f$ 则等于 $-u$. 当微分方程中的系数为常数时，我们就能找到它的解.

但是，在方程 $u''=tu$ 中，系数 $t$ 是一个变量. 这就是物理学和光学中著名的艾里方程（最初用于解释彩虹）. 当 $t$ 经过零点时，这个方程的解会完全改变，此时需要使用无限级数来表示这些解. 不过我们在这里不深入讨论这个问题.

关键在于，常数系数的方程通常有简单的解，比如 $\mathrm{e}^{\lambda t}$. 我们可以通过将 $\mathrm{e}^{\lambda t}$ 代入微分方程来求出 $\lambda$ 的值. 这个 $\lambda$ 就像是一个特征值. 对于 $u=\cos t$ 和 $u=\sin t$，$\lambda$ 的值是 i. 伟大的欧拉公式 $\mathrm{e}^{\mathrm{i}t}=\cos t+\mathrm{i}\sin t$ 完美地把复数放进整个框架，这一点我们在讨论 $\boldsymbol{P}$ 和 $\boldsymbol{C}$ 的特征值时已经了解了.

### 8.3.2　函数空间的基

对于 $x$ 的函数，我首先想到的基包含单项式 $1,x,x^2,\cdots$. 不幸的是，这是一组很糟糕的基. 那些函数 $x^n$ 几乎不是线性无关的. $x^{10}$ 几乎是基向量 $1,x,\cdots,x^9$ 的组合. 用这个“病态”基进行计算几乎是不可能的.

如果处理的是向量而不是函数，判断一个基好不好，我们的方法是研究 $\boldsymbol{B}^{\mathrm{T}}\boldsymbol{B}$. 这个矩阵包含了基向量（$\boldsymbol{B}$ 的列）之间的所有内积. 当 $\boldsymbol{B}^{\mathrm{T}}\boldsymbol{B}=\boldsymbol{I}$ 时，这组基是标准正交基. 这是最理想的情况. 但是基 $1,x,x^2,\cdots$ 会产生糟糕的希尔伯特矩阵：$\boldsymbol{B}^{\mathrm{T}}\boldsymbol{B}$ 的最大特征值和最小特征值之间的比值极大. 较大的条件数表明基的选择不佳.

从 0 到 1 积分，$x^i$ 与 $x^j$ 的内积为

$$\int_0^1 x^ix^j\mathrm{d}x=\frac{x^{i+j+1}}{i+j+1}\bigg|_{x=0}^{x=1}=\frac{1}{i+j+1}=\text{希尔伯特矩阵}\boldsymbol{B}^{\mathrm{T}}\boldsymbol{B}\text{的元素}$$

注：此处 $\boldsymbol{B}$ 的列是函数而不是向量. 我们仍然使用 $\boldsymbol{B}^{\mathrm{T}}\boldsymbol{B}$ 来检验线性无关性. 所以我们需要知道两个函数的点积（内积是更好的叫法）——这些就是 $\boldsymbol{B}^{\mathrm{T}}\boldsymbol{B}$ 中的数值.

向量的点积为 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{y}=x_1y_1+x_2y_2+\cdots+x_ny_n$. 函数的内积不是做加法，而是进行积分，但思想是完全类似的：

$$\text{内积}\quad (f,g)=\int f(x)g(x)\,\mathrm{d}x$$

$$\text{复内积}\quad (f,g)=\int \overline{f(x)}g(x)\,\mathrm{d}x,\ \overline{f}\text{表示复共轭}$$

$$\text{加权内积}\quad (f,g)_w=\int w(x)\overline{f(x)}g(x)\,\mathrm{d}x,\ w\text{为权函数}$$

### 8.3.3 函数空间的正交基

以下是理论和数值计算中常用的三组奇 -偶 (函数) 基：

（1）傅里叶基：$1,\ \sin x,\ \cos x,\ \sin 2x,\ \cos 2x,\ \cdots$

（2）勒让德基：$1,\ x,\ x^2-\dfrac{1}{3},\ x^3-\dfrac{3}{5}x,\ \cdots$

（3）切比雪夫基：$1,\ x,\ 2x^2-1,\ 4x^3-3x,\ \cdots$

傅里叶基函数（正弦函数和余弦函数）都是周期函数，因为 $\cos(x+2\pi)=\cos x$ 且 $\sin(x+2\pi)=\sin x$，$2\pi$ 是它们的公共周期. 所以这个基特别适用于本身是周期函数的 $f(x)$ : $f(x+2\pi)=f(x)$.

这个基也是正交的. 正弦函数和余弦函数相互正交.

最重要的是，正弦-余弦基在函数逼近方面也非常出色. 如果我们有一个光滑的周期函数 $f(x)$，那么少量的正弦和余弦函数（低频部分）就足够了. $f(x)$ 中的跳跃以及信号中的噪声会在更高频率（更大的 $n$）中体现出来. 我们希望并期待信号不会被噪声淹没.

傅里叶变换将 $f(x)$ 与它的傅里叶级数中的系数 $a_k$ 和 $b_k$ 联系起来.

傅里叶级数：

$$f(x)=a_0+b_1\sin x+a_1\cos x+b_2\sin 2x+a_2\cos 2x+\cdots$$

函数空间是无穷维的. 要完美地表示一个典型的 $f(x)$ 需要无穷多个基函数. 求每个系数（例如 $a_3$）的公式就类似于将向量 $\boldsymbol{b}$ 投影到过 $\boldsymbol{a}$ 的直线上的投影公式 $\boldsymbol{b}^{\mathrm{T}}\boldsymbol{a}/\boldsymbol{a}^{\mathrm{T}}\boldsymbol{a}$.

比如我们将函数 $f(x)$ 投影到函数空间中过 $\cos 3x$ 的直线上：

$$\text{傅里叶系数：}\qquad a_3=\frac{(f(x),\cos 3x)}{(\cos 3x,\cos 3x)}=\frac{\displaystyle\int f(x)\cos 3x\,\mathrm{d}x}{\displaystyle\int \cos 3x\cos 3x\,\mathrm{d}x}. \tag{8.19}$$

注意：如果函数 $f(x)$ 有跳跃（比如 $0-1$ 函数），正弦-余弦基就不那么出色了. 傅里叶逼近会在跳跃处产生过冲. 这种吉布斯现象不会因为在逼近中加入更多的正弦和余弦函数而得到改善.

### 8.3.4 勒让德多项式和切比雪夫多项式

勒让德多项式是应用格拉姆-施密特方法（4.4节）的结果. 其思路是将幂函数 $1,\ x,\ x^2,\cdots$ 正交化. 首先，奇函数 $x$ 在区间 $[-1,1]$ 上已经与偶函数 $1$ 正交. 它们的乘积 $(x)(1)=x$ 的积分值为零，但是 $x^2$ 与 $1$ 的内积是 $\displaystyle\int x^2\,\mathrm{d}x=2/3$：

$$\frac{(x^2,\ 1)}{(1,\ 1)}=\frac{\int x^2\,\mathrm{d}x}{\int 1\,\mathrm{d}x}=\frac{2/3}{2}=\frac{1}{3}$$　　格拉姆-施密特方法选取 $\boldsymbol{x^2-\frac{1}{3}}$　作为勒让德多项式

类似地，奇次幂 $x^3$ 在奇函数 $x$ 方向上有一个 $3x/5$ 的分量：

$$\frac{(x^3,\ x)}{(x,\ x)}=\frac{\int x^4\,\mathrm{d}x}{\int x^2\,\mathrm{d}x}=\frac{2/5}{2/3}=\frac{3}{5}$$　　格拉姆-施密特方法选取 $\boldsymbol{x^3-\frac{3}{5}x}$　作为勒让德多项式

对 $x^4$、$x^5$ 继续应用格拉姆-施密特方法就得到了正交的勒让德函数.

最后我们来看切比雪夫多项式 1、$x$、$2x^2-1$、$4x^3-3x$. 它们并非来自格拉姆 -施密特方法. 相反，它们与 1、$\cos\theta$、$\cos(2\theta)$、$\cos(3\theta)$ 相关. 这带来了巨大的计算优势——我们可以使用快速傅里叶变换. 令 $x=\cos\theta$，切比雪夫多项式与傅里叶的联系就显现出来了：

| 切比雪夫到傅里叶 | $\boldsymbol{2x^2-1=2(\cos\theta)^2-1=\cos 2\theta}$<br>$\boldsymbol{4x^3-3x=4(\cos\theta)^3-3\cos\theta=\cos(3\theta)}$ |
|---|---|

$n$ 次切比雪夫多项式 $T_n(x)$ 把 $\cos(n\theta)$ 转化为 $T_n(\cos\theta)$.

注：这些多项式是一个名为 chebfun 的大型软件项目的基础. 每个函数 $f(x)$ 都被一个超高精度的切比雪夫逼近所替代. 然后可以对 $f(x)$ 进行积分，求解 $f(x)=0$，并找出它的最大值或最小值. 不仅如此，还可以快速且高精度地求解涉及 $f(x)$ 的微分方程.

当 chebfun 用一个多项式来替代 $f(x)$ 时，就可以着手解决问题了.

## 要 点 回 顾

1. 如果基向量构成的矩阵 $\boldsymbol{B}$ 条件数良好，那么这个基就很好. 正交基是最好的.
2. 如果 $\boldsymbol{\Lambda=B^{-1}AB}$ 是对角矩阵，这样的基也很好，但若尔当标准形 $\boldsymbol{J}$ 非常不稳定.
3. 傅里叶矩阵可将常系数周期方程对角化：堪称完美.
4. 函数空间的基 1，$x$，$x^2,\cdots$ 会导致 $\boldsymbol{B^{\mathrm{T}}B}$ 成为希尔伯特矩阵，对计算而言非常糟糕.
5. 勒让德多项式和切比雪夫多项式是函数空间的优秀的基.

## 习题 8.3

1. 在例 8.16中，$\boldsymbol{J-3I}$ 的秩是多少？它的零空间的维数是多少？这个维数给出了特征值 $\lambda=3$ 线性无关特征向量的个数.

$\lambda=3$ 的代数重数为 2，因为 $\det(\boldsymbol{J}-\lambda\boldsymbol{I})$ 有重因子 $(\lambda-3)^2$. 几何重数为 1，因为只有 1 个线性无关的特征向量.

2. 下面的两个矩阵 $\boldsymbol{A}_1$ 和 $\boldsymbol{A}_2$ 与 $\boldsymbol{J}$ 相似. 通过求解 $\boldsymbol{A_1B_1=B_1J}$ 和 $\boldsymbol{A_2B_2=B_2J}$ 来找出矩阵 $\boldsymbol{B}_1$ 和 $\boldsymbol{B}_2$，使得 $\boldsymbol{J=B_1^{-1}A_1B_1}$ 且 $\boldsymbol{J=B_2^{-1}A_2B_2}$.

$$\boldsymbol{J}=\begin{bmatrix}0&1\\0&0\end{bmatrix},\qquad \boldsymbol{A}_1=\begin{bmatrix}0&4\\0&0\end{bmatrix},\qquad \boldsymbol{A}_2=\begin{bmatrix}4&-8\\2&-4\end{bmatrix}$$　　迹为 0，行列式为 0

3. 若尔当块的转置 $\boldsymbol{J}^{\mathrm{T}}$ 与 $\boldsymbol{J}$ 有相同的三重特征值 2（且只有一个特征向量），求基变换矩阵 $\boldsymbol{B}$，使得 $\boldsymbol{J}=\boldsymbol{B}^{-1}\boldsymbol{J}^{\mathrm{T}}\boldsymbol{B}$（这意味着 $\boldsymbol{B}\boldsymbol{J}=\boldsymbol{J}^{\mathrm{T}}\boldsymbol{B}$）：

$$\boldsymbol{J}=\begin{bmatrix}2&1&0\\0&2&1\\0&0&2\end{bmatrix},\qquad \boldsymbol{J}^{\mathrm{T}}=\begin{bmatrix}2&0&0\\1&2&0\\0&1&2\end{bmatrix}$$

4. $\boldsymbol{J}$ 和 $\boldsymbol{K}$ 是若尔当标准形，它们有相同的零特征值且秩都为 2. 证明：不存在可逆矩阵 $\boldsymbol{B}$ 使得 $\boldsymbol{B}\boldsymbol{K}=\boldsymbol{J}\boldsymbol{B}$，所以 $\boldsymbol{K}$ 与 $\boldsymbol{J}$ 不相似：

$$\boldsymbol{J}=\begin{bmatrix}0&1&0&0\\&0&0&0\\&&0&1\\&&&0\end{bmatrix},\qquad \boldsymbol{K}=\begin{bmatrix}0&1&0&0\\&0&1&0\\&&0&0\\&&&0\end{bmatrix}$$ 分块大小不同!

5. 若 $\boldsymbol{A}^3=\boldsymbol{0}$，证明：对所有的 $\lambda=0$，并且所有满足 $\boldsymbol{J}^3=0$ 的若尔当块的大小为 1、2 或 3. 进一步可得 $\operatorname{rank}(\boldsymbol{A})\leqslant 2n/3$. 若 $\boldsymbol{A}^n=\boldsymbol{0}$，为什么 $\operatorname{rank}(\boldsymbol{A})<n$?

6. 证明：$\boldsymbol{u}(t)=\begin{bmatrix}te^{\lambda t}\\e^{\lambda t}\end{bmatrix}$ 是 $\dfrac{\mathrm{d}\boldsymbol{u}}{\mathrm{d}t}=\boldsymbol{J}\boldsymbol{u}$ 的解，其中 $\boldsymbol{J}=\begin{bmatrix}\lambda&1\\0&\lambda\end{bmatrix}$，$\boldsymbol{u}(0)=\begin{bmatrix}0\\1\end{bmatrix}$. $\boldsymbol{J}$ 不可对角化所以 $te^{\lambda t}$ 出现在 $\mathrm{d}\boldsymbol{u}/\mathrm{d}t=\boldsymbol{J}\boldsymbol{u}$ 的解中.

7. 证明：差分方程 $v_{k+2}-2\lambda v_{k+1}+\lambda^2 v_k=0$ 的解为 $v_k=\lambda^k$ 和 $v_k=k\lambda^k$，对应于习题 6 中的 $e^{\lambda t}$ 和 $te^{\lambda t}$.

8. $\lambda^3=1$ 的三个解是什么？它们是复数 $\lambda=\cos\theta+\mathrm{i}\sin\theta=e^{\mathrm{i}\theta}$. 当角度 $3\theta$ 为 0 或 $2\pi$ 或 $4\pi$ 时，$\lambda^3=e^{3\mathrm{i}\theta}=1$. 写出包含列向量 $\begin{bmatrix}1&\lambda&\lambda^2\end{bmatrix}^{\mathrm{T}}$ 的 $3\times 3$ 傅里叶矩阵 $\boldsymbol{F}$.

9. 验证：习题 8 中的向量 $\begin{bmatrix}1&\lambda&\lambda^2\end{bmatrix}^{\mathrm{T}}$ 是任意 $3\times 3$ 循环矩阵 $\boldsymbol{C}$ 的特征向量. 若矩阵 $\boldsymbol{C}$ 的首行为 $\boldsymbol{c}=\begin{bmatrix}c_0&c_1&c_2\end{bmatrix}$，那么 $\boldsymbol{F}\boldsymbol{c}$ 的三个分量是 $\boldsymbol{C}$ 的特征值.

10. 对于 $f(x)=\begin{cases}1, & -L\leqslant x\leqslant L\\ 0, & L\leqslant|x|\leqslant 2\pi\end{cases}$，用式(8.19)确定其傅里叶级数中的 $a_3\cos 3x$.

# 第 9 章

CHAPTER 9

# 最优化中的线性代数

本章将微积分与线性代数相结合. 总体问题是求解关于多变元 $\boldsymbol{x}=(x_1,x_2,\cdots,x_n)$ 的函数 $F(\boldsymbol{x})$ 的最小化问题. 假设已知 $F$ 的一阶导数——这里指 $F$ 的全体偏导数，它们构成梯度向量 $\nabla F=\begin{bmatrix}\partial F/\partial x_1 & \cdots & \partial F/\partial x_n\end{bmatrix}^{\mathrm{T}}$. 那么由微积分的知识得，在 $F(\boldsymbol{x})$ 的“光滑”最小值点 $\boldsymbol{x}^*$ 处，有 $\nabla F(\boldsymbol{x}^*)=\boldsymbol{0}$. 此处的基本问题是：求解含有 $n$ 个未知数 $x_1,x_2,\cdots,x_n$ 的 $n$ 个方程 $\nabla F(\boldsymbol{x})=\boldsymbol{0}$.

一个重要的代表性问题是二次函数 $Q(\boldsymbol{x})=\frac{1}{2}\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}-\boldsymbol{b}^{\mathrm{T}}\boldsymbol{x}$. 此时，梯度向量为 $\nabla Q(\boldsymbol{x})=\boldsymbol{S}\boldsymbol{x}-\boldsymbol{b}$. 于是 $\nabla Q=\boldsymbol{0}$ 是一个包含 $n$ 个方程的线性方程组 $\boldsymbol{S}\boldsymbol{x}=\boldsymbol{b}$. 当 $\boldsymbol{S}$ 是（常值）对称正定矩阵时，上述方程组的解 $\boldsymbol{x}^*$ 就是 $Q(\boldsymbol{x})$ 的最小值点.

当 $F$ 不是二次函数时，其梯度 $\nabla F$ 不是线性的，其二阶导数矩阵（Hessian 矩阵）$\boldsymbol{S}(\boldsymbol{x})$ 不是常数矩阵. 但如果 $\boldsymbol{S}(\boldsymbol{x})$ 处处正定，则 $F$ 为凸函数，其图形仍然大致呈碗状. 9.1 节讨论用负梯度 $-\nabla F$ 向下逼近 $\boldsymbol{x}^*$. 9.2 节展示如何用“反向传播”法计算该梯度 $\nabla F$.

在 9.3 节和 9.4节中，将处理另一类型的可能性——对 $\boldsymbol{x}$ 有一些限制（约束）条件. 一个典型问题是在约束条件 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 和 $\boldsymbol{x}\geqslant 0$（即每个 $x_i\geqslant 0$）下最小化二次函数 $Q(\boldsymbol{x})$ 或线性成本 $\boldsymbol{c}^{\mathrm{T}}\boldsymbol{x}$. 此时 $Q(\boldsymbol{x})$ 的（碗状）图像会被 $m$ 个互相垂直的平面 $x_i=0$ 切割. 关键问题是确定最小值点是在 $x_i>0$ 还是 $x_i=0$ 处取到.

处理形如 $x_1\geqslant 0$ 的约束条件的方法，是引入拉格朗日乘子. 在此之前，9.1 节和 9.2 节将解释梯度下降和随机梯度下降方法. 这些方法是第 10 章中讨论深度学习的主力，其中 $\boldsymbol{x}$ 包含大量的变量.

## 9.1 多变量函数的最小化问题

假设 $F(x_1,x_2,\cdots,x_n)$ 是关于 $n$ 个变量的函数. 我们需要了解 $F$ 的一阶和二阶导数的基本信息. 当 $n>1$ 时，这些导数均是“偏导数”.

式(9.1) 和式(9.2) 是最重要的最基本的事实. 不需要了解整个微积分课程（太多关于微积分的内容），就可以使用这些事实讨论函数 $F(\boldsymbol{x})$ 的最小化问题.

| | |
|---|---|
| 一个函数<br>一个自变量：$x$ | $F(x+\Delta x)\approx F(x)+\Delta x\dfrac{\mathrm{d}F}{\mathrm{d}x}(x)+\dfrac{1}{2}(\Delta x)^2\dfrac{\mathrm{d}^2F}{\mathrm{d}x^2}(x)$ (9.1) |

这是泰勒级数的前面几项——通常我们不会展开超过二阶项. 首项 $F(x)+(\Delta x)(\mathrm{d}F/\mathrm{d}x)$ 用 $F$

在点 $x$ 及其附近的信息，给出了 $F(x+\Delta x)$ 的一阶近似. 接下来，$\frac{1}{2}(\Delta x)^2F''$ 给出了二阶近似.

$\Delta x$ 项给出了 $F(x)$ 的函数图像在一点处的切线，而 $(\Delta x)^2$ 项将切线移动得到“切抛物线”. 当二阶导数为正时，即 $\mathrm{d}^2F/\mathrm{d}x^2>0$时，函数 $F$ 是下凸的——其切线斜率递增，图像向上弯曲，如 $y=x^2$. 式(9.2)是式(9.1)在 $n$ 维情形的推广.

$$\boxed{\begin{array}{l}\text{一个函数}\\ n\text{个自变量：}x_1,x_2,\cdots,x_n\end{array}\qquad F(\boldsymbol{x}+\Delta\boldsymbol{x})\approx F(\boldsymbol{x})+(\Delta\boldsymbol{x})^{\mathrm{T}}\nabla F+\frac{1}{2}(\Delta\boldsymbol{x})^{\mathrm{T}}\boldsymbol{S}(\Delta\boldsymbol{x})} \tag{9.2}$$

这个公式至关重要！向量 $\nabla F$ 是 $F$ 的梯度——由 $n$ 个偏导数 $\frac{\partial F}{\partial x_1},\frac{\partial F}{\partial x_2},\cdots,\frac{\partial F}{\partial x_n}$ 组成的列向量. $\boldsymbol{S}$ 是由二阶偏导数构成的对称矩阵（Hessian 矩阵），其中 $\boldsymbol{S}_{ij}=\partial^2F/\partial x_i\partial x_j=\partial^2F/\partial x_j\partial x_i$.

函数 $y=F(x_1,x_2,\cdots,x_n)$ 的图像为 $n+1$ 维空间中的曲面. 一维情形时的切线现在也变成了在点 $\boldsymbol{x}$ 处的切平面. 当海森矩阵 $\boldsymbol{S}$ 正定时，$F$ 是严格下凸函数，也即函数图像保持在切平面的上方. 如果 $\nabla F(\boldsymbol{x}^*)=\boldsymbol{0}$，则下凸函数 $F$ 在 $\boldsymbol{x}^*$ 处有极小值，$\nabla F(\boldsymbol{x}^*)=\boldsymbol{0}$ 是关于 $\boldsymbol{x}^*$ 的 $n$ 个方程构成的线性方程组.

下述来自微积分的式(9.3)给出了直接求解向量方程 $\nabla F(\boldsymbol{x})=\boldsymbol{0}$ 的方法. 从 $\boldsymbol{x}$ 点出发，做一个位移 $\Delta\boldsymbol{x}$ 修正，使之更为接近精确解.

$$\boxed{\nabla F(\boldsymbol{x}+\Delta\boldsymbol{x})\approx\nabla F(\boldsymbol{x})+\boldsymbol{S}(\boldsymbol{x})\Delta\boldsymbol{x}=\boldsymbol{0}\quad\Rightarrow\quad\Delta\boldsymbol{x}=-\boldsymbol{S}^{-1}(\boldsymbol{x})\nabla F(\boldsymbol{x})} \tag{9.3}$$

这里关于 $\Delta\boldsymbol{x}$ 的公式实际上是牛顿方法中的一步：设此时位于点 $\boldsymbol{x}_k$，下一步移动到点 $\boldsymbol{x}_{k+1}=\boldsymbol{x}_k+\Delta\boldsymbol{x}$. 点列 $\boldsymbol{x}_0,\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots$ 通常会快速收敛到极小值点 $\boldsymbol{x}^*$，使得 $\nabla F(\boldsymbol{x}^*)=\boldsymbol{0}$. 但快速收敛的代价可能很大，每一步都需要计算矩阵 $\boldsymbol{S}(\boldsymbol{x})$ 中的所有二阶偏导数 $\partial^2F/\partial x_i\partial x_j$.

**例 9.1** 设函数 $F(\boldsymbol{x})=\frac{1}{2}\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}-\boldsymbol{x}^{\mathrm{T}}\boldsymbol{b}$，则有 $\nabla F=\boldsymbol{S}\boldsymbol{x}-\boldsymbol{b}$. 使用式(9.3)中的牛顿方法，一步即可解出方程组 $\nabla F(\boldsymbol{x}^*)=\boldsymbol{S}\boldsymbol{x}^*-\boldsymbol{b}=\boldsymbol{0}$！具体如下：

$$\boldsymbol{x}_1-\boldsymbol{x}_0=\Delta\boldsymbol{x}=-\boldsymbol{S}^{-1}\nabla F(\boldsymbol{x}_0)=-\boldsymbol{S}^{-1}(\boldsymbol{S}\boldsymbol{x}_0-\boldsymbol{b})=-\boldsymbol{x}_0+\boldsymbol{S}^{-1}\boldsymbol{b}$$

两边消去 $-\boldsymbol{x}_0$，得到使得 $\nabla F=\boldsymbol{0}$ 的点 $\boldsymbol{x}_1$，即 $\boldsymbol{x}_1=\boldsymbol{S}^{-1}\boldsymbol{b}=\boldsymbol{x}^*$.

**例 9.2** 使用牛顿法求解方程 $\nabla F=x^2-4=0$. 其导数为 $S(x)=2x$. 第 $k$ 步的迭代公式为 $\Delta x=-(1/S(x_k))\nabla F(x_k)$，于是

$$x_{k+1}-x_k=(-1/2x_k)(x_k^2-4)\quad\text{或}\quad x_{k+1}=\frac{1}{2}\left(x_k+\frac{4}{x_k}\right) \tag{9.4}$$

原方程移项开方，可知 $x^*=\sqrt{4}=2=\frac{1}{2}\left(2+\frac{4}{2}\right)$. 牛顿方法的要点在于快速收敛至 $x^*$. 我们从 $x_0=4$ 开始：

$$x_1=\frac{1}{2}\left(x_0+\frac{4}{x_0}\right)=\frac{1}{2}\left(4+\frac{4}{4}\right)=2.5$$

$$x_2=\frac{1}{2}\left(x_1+\frac{4}{x_1}\right)=\frac{1}{2}\left(2.5+\frac{4}{2.5}\right)=\frac{1}{2}(2.5+1.6)=2.05$$

若再进行两步迭代，便可观察到误差（与 $\sqrt{4}=2$ 的距离）会迅速趋于零. $x_k-2$ 的小数点后零的数量每步都会翻倍:

$$x_0=4,\quad x_1=2.5,\quad x_2=2.05,\quad x_3=2.0006,\quad x_4=2.000000009$$

每完成一步，误差的小数位数向后移动两倍. 实际上相邻两步的误差 $x_k-2$ 有近似平方的关系:

$$x_{k+1}-2=\frac{1}{2}\left(x_k+\frac{4}{x_k}\right)-2=\frac{1}{2x_k}\left(x_k-2\right)^2,\quad \left\|x_{k+1}-x^*\right\|\approx\frac{1}{4}\left\|x_k-x^*\right\|^2$$

误差的平方解释了牛顿法的快速收敛性——前提是 $x_k$ 相对接近 $x^*$.

总结：牛顿法在真实解 $\boldsymbol{x}^*$ 附近会收敛迅速，因为它利用了 $F(\boldsymbol{x})$ 的二阶导数. 但计算这些二阶导数可能需要较大计算量（尤其是高维情形）. 通常，神经网络规模都很大，从而无法计算 $F(\boldsymbol{x})$ 的所有二阶导数. 梯度下降法是深度学习的首选算法.

### 9.1.1　梯度下降 = 最速下降

本节讨论一个基本问题：最小化函数 $F\left(x_1,x_2,\cdots,x_n\right)$. 由微积分知识，在最小值处（当 $F$ 光滑时），所有一阶偏导数 $\partial F/\partial x_i$ 都为零. 如果函数有 $n=20$ 个未知数（在深度学习中这只是一个小数目），那么为了最小化一个函数 $F$，就会产生 20 个方程 $\partial F/\partial x_i=0$. “梯度下降法”使用偏导数 $\partial F/\partial x_i$ 寻找到一个使得函数值 $F(\boldsymbol{x})$ 快速下降的方向. 在 $\boldsymbol{x}_k$ 处，$F(\boldsymbol{x})$ 下降最快的最速方向由负梯度 $-\nabla F\left(\boldsymbol{x}_k\right)$ 给出:

最速方向　　梯度下降法　$\boldsymbol{x}_{k+1}=\boldsymbol{x}_k-s_k\nabla F\left(\boldsymbol{x}_k\right)$　　(9.5)

对每一步的 $k=1,2,3,\cdots$，式(9.5)均为关于向量的方程，其中 $s_k$ 是步长或学习率. 我们希望朝着 $F(\boldsymbol{x})$ 图像底部的点 $\boldsymbol{x}^*$ 移动.

假设这 20 个一阶偏导数存在且可以计算. 但我们不愿意假设这 20 个偏导函数各自还有 20 个方便计算的导数 $\partial/\partial x_j\left(\partial F/\partial x_i\right)$，也即 $F$ 的 210 个二阶偏导数——它们构成一个 20 阶对称矩阵 $\boldsymbol{S}$.（对称性将二阶偏导的个数从 $n^2=400$ 减少到 $\frac{1}{2}\left(n^2+n\right)=210$. ）二阶偏导数提供了非常有用的额外信息，但在许多问题中我们不得不放弃它们.

20 个一阶偏导数和 210 个二阶偏导数并不会使计算量分别乘以 20 和 210. 自动微分这一巧妙想法，作为机器学习中的反向传播法被人们重新发现和扩展，使得计算量大大降低.

暂且回到式(9.5)，位移项“$-s_k\nabla F\left(\boldsymbol{x}_k\right)$”中包括一个负号（确保函数值下降）、一个因子 $s_k$（控制步长）和下降向量 $\nabla F$（包含在当前点 $\boldsymbol{x}_k$ 处 $F$ 的一阶偏导数）. 关于步长和搜索方向的选择问题，前人有大量的思考与探索.

### 9.1.2　$n=1$ 时一元函数 $f(x)$ 的一阶导数

一元函数 $f(x)$ 的导数涉及极限运算，这是微积分与代数之间的关键区别. 随着 $\Delta x$ 趋近于零，我们比较函数在两个邻近点 $x$ 和 $x+\Delta x$ 处的值. 更准确地说，我们观察 $f(x)$ 图像上两点之间连线的斜率 $\Delta f/\Delta x$:

$$\frac{\mathrm{d}f}{\mathrm{d}x}=\lim_{\Delta x\to 0}\frac{f(x+\Delta x)-f(x)}{\Delta x}\qquad(9.6)$$

当 $\Delta x > 0$ 时，这是一个前向差分；当 $\Delta x < 0$ 时，这是一个后向差分. 当我们从两侧得到相同的极限时，该极限就是图像在 $x$ 处的斜率.

在深度学习中，斜坡函数 $\mathrm{ReLU}(x) = f(x) = \max(0, x)$ 有广泛的应用. ReLU 在 $x = 0$ 右侧的斜率为 1，左侧的斜率为 0. 因此，ReLU 在其图像的尖点处不存在导数.

对光滑函数 $f(x) = x^2$，比值 $\Delta f/\Delta x$ 会从两侧安全地趋近导数 $\mathrm{d}f/\mathrm{d}x$. 但趋近的速度可能较慢（仅为一阶）. 再次观察点 $x = 0$，该点的导数 $\mathrm{d}f/\mathrm{d}x = 2x$ 为零：

$$\text{在 } x = 0 \text{ 处比值 } \frac{\Delta f}{\Delta x} \text{ 为 } \frac{f(\Delta x) - f(0)}{\Delta x} = \frac{(\Delta x)^2 - 0}{\Delta x} = \Delta x, \text{ 极限为 } \frac{\mathrm{d}f}{\mathrm{d}x} = 0.$$

正如 2.5 节所说明的，通过前向差分（对 $\Delta x > 0$）和后向差分（对 $\Delta x < 0$）的平均值，可得到一个更好的比值（更接近极限斜率 $\mathrm{d}f/\mathrm{d}x$）. 它们的平均值是一个更精确的中心差分.

$$\frac{1}{2}\left[\frac{f(x+\Delta x) - f(x)}{\Delta x} + \frac{f(x-\Delta x) - f(x)}{-\Delta x}\right] = \frac{f(x+\Delta x) - f(x-\Delta x)}{2\Delta x} \tag{9.7}$$

对于函数 $f(x) = x^2$，使用上述中心化的方法可得到精确的导数 $\mathrm{d}f/\mathrm{d}x = 2x$. 在函数图像中，我们通过平均正负斜率来得到 $x = 0$ 时正确的斜率 0.

对于所有光滑函数，中心差分可将误差减小到 $(\Delta x)^2$ 的量级. 这相比于未做中心化差分 $f(x + \Delta x) - f(x)$ 的误差（$\Delta x$ 量级），是一个巨大的改进.

斜坡函数 ReLU 和 $f = x^2$ 的中心斜率如图 9.1 所示.

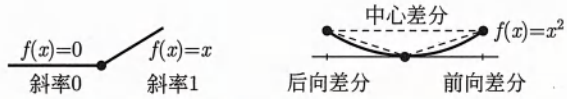


图 9.1 斜坡函数 ReLU 和 $f = x^2$ 的中心斜率

为了获得更高的精度，大多数有限差分近似方法都是中心化的. 但我们仍然要除以一个小数 $2\Delta x$. 对于多变量函数 $F(x_1, x_2, \cdots, x_n)$，我们需要计算 $n$ 个不同方向上的比值 $\Delta F/\Delta x_i$（此处的 $n$ 可能会非常大）. 这些比值近似于 $F$ 的梯度向量 $\nabla F$ 中的 $n$ 个偏导数.

多元函数 $F(x_1, x_2, \cdots, x_n)$ 的梯度是列向量 $\nabla F = \begin{bmatrix} \dfrac{\partial F}{\partial x_1} & \cdots & \dfrac{\partial F}{\partial x_n} \end{bmatrix}^{\mathrm{T}}$

梯度向量的分量是 $F$ 的 $n$ 个偏导数. $\Delta F$ 给出了函数图像在该点的最陡方向. 例 9.3～例 9.5将展示向量语言的优势（注：$\Delta F$ 始终是一个列向量）.

**例 9.3** 对常数向量 $\boldsymbol{a}$，函数 $F(\boldsymbol{x}) = \boldsymbol{a}^{\mathrm{T}}\boldsymbol{x}$ 的梯度是 $\nabla F = \boldsymbol{a}$. 函数 $F = a_1x_1 + a_2x_2 + \cdots + a_nx_n$ 的偏导数是 $\partial F/\partial x_k = a_k$.

**例 9.4** 对于对称矩阵 $\boldsymbol{S}$，函数 $F = \dfrac{1}{2}\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}$ 的梯度是 $\nabla F = \boldsymbol{S}\boldsymbol{x}$. 为了看清这一点，取 $n = 2$，则函数形如 $F(x_1, x_2)$，$\boldsymbol{S}$ 是 2 阶对称阵：

$$F=\frac{1}{2}\begin{bmatrix}x_1 & x_2\end{bmatrix}\begin{bmatrix}a & b\\ b & c\end{bmatrix}\begin{bmatrix}x_1\\ x_2\end{bmatrix}=\frac{1}{2}ax_1^2+\frac{1}{2}cx_2^2+bx_1x_2$$

梯度为

$$\begin{bmatrix}\partial F/\partial x_1\\ \partial F/\partial x_2\end{bmatrix}=\begin{bmatrix}ax_1+bx_2\\ bx_1+cx_2\end{bmatrix}=\boldsymbol{S}\begin{bmatrix}x_1\\ x_2\end{bmatrix}$$

**例 9.5**　设 $\boldsymbol{S}$ 为对称正定矩阵，则二次函数 $F(\boldsymbol{x})=\frac{1}{2}\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}-\boldsymbol{a}^{\mathrm{T}}\boldsymbol{x}$ 的最小值为 $F_{\min}=-\frac{1}{2}\boldsymbol{a}^{\mathrm{T}}\boldsymbol{S}^{-1}\boldsymbol{a}$（必为一个负数）.

这是一个重要的例子！梯度是 $\nabla F=\boldsymbol{S}\boldsymbol{x}-\boldsymbol{a}$. 最小值出现在 $\boldsymbol{x}^*=\boldsymbol{S}^{-1}\boldsymbol{a}$ 处，此时 $F$ 的一阶导数为零：

$$\text{在 }\boldsymbol{x}^*=\boldsymbol{S}^{-1}\boldsymbol{a}=\arg\min F\text{ 处，}\nabla F=\begin{bmatrix}\partial F/\partial x_1\\ \vdots\\ \partial F/\partial x_n\end{bmatrix}=\boldsymbol{S}\boldsymbol{x}-\boldsymbol{a}=\boldsymbol{0}. \tag{9.8}$$

其中符号 $\arg\min F$ 表示使得 $F(\boldsymbol{x})$ 取到最小值的点 $\boldsymbol{x}^*$. 通常，我们更感兴趣的是该函数的最小值点 $\boldsymbol{x}^*$，而不是该点处的实际最小值 $F_{\min}=F(\boldsymbol{x}^*)$.

$$F_{\min}=\frac{1}{2}\left(\boldsymbol{S}^{-1}\boldsymbol{a}\right)^{\mathrm{T}}\boldsymbol{S}\left(\boldsymbol{S}^{-1}\boldsymbol{a}\right)-\boldsymbol{a}^{\mathrm{T}}\left(\boldsymbol{S}^{-1}\boldsymbol{a}\right)=\frac{1}{2}\boldsymbol{a}^{\mathrm{T}}\boldsymbol{S}^{-1}\boldsymbol{a}-\boldsymbol{a}^{\mathrm{T}}\boldsymbol{S}^{-1}\boldsymbol{a}=-\frac{1}{2}\boldsymbol{a}^{\mathrm{T}}\boldsymbol{S}^{-1}\boldsymbol{a}$$

$F$ 的图像是一个通过原点 $\boldsymbol{x}=\boldsymbol{0}$ 的碗形曲面，并在 $\boldsymbol{x}^*$ 处下降取到 $F_{\min}$.

**例 9.6**　行列式函数 $F(\boldsymbol{x})=\det\boldsymbol{x}$ 是关于 $n^2$ 个变量 $x_{ij}$ 的多元函数. 在 $\det\boldsymbol{x}$ 的公式中，每一行中的元素 $x_{ij}$ 乘以对应的“代数余子式” $C_{ij}$. 第 5章讨论过代数余子式，它是由 $\boldsymbol{x}$ 中除了第 $i$ 行与第 $j$ 列之外的所有元素组成的 $n-1$ 的行列式，并且 $C_{ij}$ 还包括正负号 $(-1)^{i+j}$：

偏导数 $\dfrac{\partial(\det\boldsymbol{x})}{\partial x_{ij}}=C_{ij}$（其中全体代数余子式组成一个与 $\boldsymbol{x}$ 有关的矩阵 $\boldsymbol{C}=(C_{ij})_{n\times n}$）.

**例 9.7**　行列式的对数函数是一个极为重要的函数：

$$L(\boldsymbol{x})=\log(\det\boldsymbol{x})\text{ 的偏导数为 }\frac{\partial L}{\partial x_{ij}}=\frac{C_{ij}}{\det\boldsymbol{x}}=\boldsymbol{X}^{-1}\text{ 的 }(j,i)\text{ 分量.}$$

其中，对 $L=\log F$ 求偏导的链式法则为 $\left(\dfrac{\mathrm{d}L}{\mathrm{d}F}\right)\left(\dfrac{\partial F}{\partial x_{ij}}\right)=(1/F)\left(\dfrac{\partial F}{\partial x_{ij}}\right)=(1/\det\boldsymbol{X})C_{ij}$. 而代数余子式 $C_{ij}$ 与 $\det\boldsymbol{X}$ 的比值恰为逆矩阵 $\boldsymbol{X}^{-1}$ 的 $(j,i)$ 位置上的元素.

非常有趣且简洁的是 $\boldsymbol{X}^{-1}$ 包含了 $L=\log\det\boldsymbol{X}$ 的 $n^2$ 个一阶偏导数，而 $L$ 的二阶偏导数也同样值得关注. 行列式函数有 $n^2$ 个变量 $x_{ij}$，以及 $\nabla L=(\boldsymbol{X}^{-1})^{\mathrm{T}}$ 中的 $n^2$ 个一阶导数，这意味着共有 $n^4$ 个二阶偏导数！令人惊奇的是：当 $\boldsymbol{X}=\boldsymbol{S}$ 为对称正定时，该二阶导数矩阵是负定的. 因此，若我们改变 $L$ 的符号，则它就有正定的二阶导数矩阵（海森矩阵），从而 $L$ 为凸函数，即

$$-\log(\det\boldsymbol{S})\text{ 是下凸函数（对任一正定矩阵 }\boldsymbol{S}\text{ 成立）.}$$

### 9.1.3 梯度向量 $\nabla F$ 的几何意义

设 $F(x,y)$ 为 $n=2$ 元函数，其梯度为 $\nabla F=\begin{bmatrix}\partial F/\partial x & \partial F/\partial y\end{bmatrix}^{\mathrm{T}}$. 梯度向量的长度会随着点 $(x,y)$ 的移动而变化，具体计算公式为

$$\nabla F=\left(\frac{\partial F}{\partial x},\frac{\partial F}{\partial y}\right),\quad \text{长度}=\|\nabla F\|=\sqrt{\left(\frac{\partial F}{\partial x}\right)^2+\left(\frac{\partial F}{\partial y}\right)^2}=F\text{的最大斜率}$$

梯度向量的长度 $\|\nabla F\|$ 告诉我们函数图像 $z=F(x,y)$ 的陡峭程度. 该图像通常是一个曲面——类似于 $xyz$ 空间中的山谷. 在图像上的每个点，都存在 $x$ 方向的斜率 $\partial F/\partial x$ 和 $y$ 方向的斜率 $\partial F/\partial y$. **最大的斜率位于 $\nabla F=\mathbf{grad}F$ 的方向，即最快增长方向，而该最大斜率的大小为 $\|\nabla F\|$.**

**例 9.8** 线性函数 $F(x,y)=ax+by$ 的图像是平面 $z=ax+by$，其梯度是偏导数构成的向量 $\nabla F=\begin{bmatrix}a\\b\end{bmatrix}$. 该向量的长度为 $\|\nabla F\|=\sqrt{a^2+b^2}=$ **“屋顶”的坡度.** 斜率在 $\nabla F$ 的方向上最大.

**上述最快增长方向与水平方向是正交的.** 在水平方向上 $z=$ 常数，从而 $ax+by=$ 常数，这是行走的安全方向，且垂直于 $\nabla F$，也即 $\nabla F$ 在该平坦方向上的投影为零. 图 9.2展示了平面 $z=F(x,y)=x+2y$ 上的两个垂直方向（水平方向和最快增长方向）.

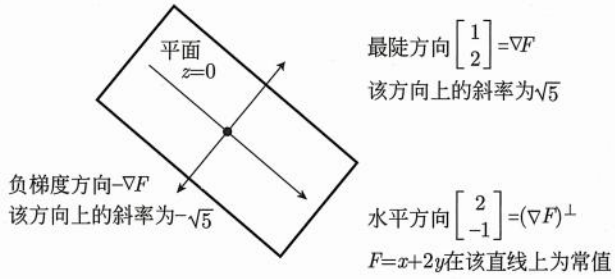


图 9.2 负梯度 $-\nabla F$ 给出最速下降方向

**例 9.9** 设 $F(x,y)=ax^2+by^2$，其梯度为 $\nabla F=\begin{bmatrix}2ax\\2by\end{bmatrix}$. $\nabla F$ 给出了最快增长方向，且随自变量的移动而变化. 最快增长方向的斜率为 $\|\nabla F\|$. 函数图像是一个开口向上的碗状曲面（见图 9.3）. 碗底位于 $x=y=0$ 处，此处的梯度向量为零，即在最小值点处，$\nabla F=(2ax,2by)=(0,0)$，且斜率为零. 此外，如果 $a=b$，则这个碗是圆形的.

在水平方向上，满足 $z=ax^2+by^2=$ 固定高度. 用平面 $z=c$（常数）截割碗形得到一条水平曲线：$ax^2+by^2=c$，这是一个椭圆. 但对于最速下降问题存在一些困难：变化最快的方向在下降过程中会不断变化！而且梯度并不指向碗底！

重述一遍，在点 $(x_0,y_0)$ 处，函数 $F=ax^2+by^2$ 的梯度方向为 $\nabla F=\begin{bmatrix}2ax_0 & 2by_0\end{bmatrix}^{\mathrm{T}}$. 最速变化方向所在的直线为 $(x,y)=(x_0,y_0)-s\,(2ax_0,2by_0)$，$\forall s\in\mathbb{R}$. 但如果 $a\neq b$ 且 $x_0y_0\neq 0$，则无论 $s$ 为何值，最小值点 $(x,y)=(0,0)$ 均**不位于该直线上**.

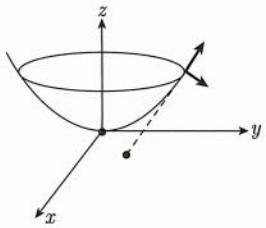


最速变化方向 $\nabla F$
水平方向 $(\nabla F)^{\perp}$ 沿着椭圆 $ax^2+by^2=$常值
最速变化方向与水平方向是垂直的
但最速变化方向并未指向最小值点

图 9.3　沿着负梯度方向 $\begin{bmatrix}-2ax\\-2by\end{bmatrix}$ 形成最速下降切线

**我们无法通过一次“梯度下降”就找到最小值点 $(0,0)$，最速变化方向并不一定指向碗底**——除非 $b=a$，即碗口为圆形时.

水流在流淌下山的过程中会改变方向. 同样，我们也迟早会改变方向. 在实践中，我们继续沿着负梯度方向前进，直到成本函数 $F$ 的下降速度不再那么快速. 此时步骤 1 结束，并且我们重新计算梯度 $\nabla F$，从而为步骤 2 提供快速下降的新方向.

### 9.1.4　一个重要的“之字形”示例

这是一个很有用的重要示例. 设 $F(x,y)=\dfrac{1}{2}\left(x^2+by^2\right)$ 且 $0<b\leqslant 1$. 其梯度 $\nabla F$ 向量有两个分量：$\partial F/\partial x=x$ 和 $\partial F/\partial y=by$. $F$ 的最小值为零，并在最小值点 $(x^*,y^*)=(0,0)$ 处达到. 最好的是，通过选择最佳的步长 $s$ 而搜索得精确路线，在逐步向下移动到碗底 $(0,0)$ 的过程中，每一步的 $(x_k,y_k)$ 给出相对简单的公式. 设初始点 $(x_0,y_0)=(b,1)$，我们搜寻可得如下方案：

$$\boxed{x_k=b\left(\frac{b-1}{b+1}\right)^k,\quad y_k=\left(\frac{1-b}{1+b}\right)^k,\quad F\left(x_k,y_k\right)=\left(\frac{1-b}{1+b}\right)^{2k}F\left(x_0,y_0\right)} \tag{9.9}$$

如果 $b=1$，只需移动一步即可成功，即 $(x_1,y_1)=(0,0)$. 因为函数 $F=\dfrac{1}{2}\left(x^2+y^2\right)$ 图像是一个具有完美的圆形的碗，其负梯度方向正好穿过 $(0,0)$. 从而，梯度下降法的第一步抵达了准确的最小值点.

然而，当 $b$ 非常小时，这个示例的真正目的就显现出来了. 式(9.9)中的关键比率是 $r=(1-b)/(1+b)$. 若 $b=\dfrac{1}{10}$，则比率 $r=\dfrac{9}{11}$；若 $b=\dfrac{1}{100}$，则比率 $r=\dfrac{99}{101}$. 可见当 $b$ 非常小时，比率 $r$ 趋近于 1，故向 $(0,0)$ 的移动几乎停止了.

在图 9.4 中，我们看到了向 $(0,0)$ 逐步移动之字形线路，到后来的进展是令人沮丧的：每一步都很短，进展非常缓慢. 虽然每一步移动 $\boldsymbol{x}_{k+1}=\boldsymbol{x}_k-s_k\nabla F\left(\boldsymbol{x}_k\right)$ 中的步长 $s_k$ 都是为了最小化 $F$ 而精确搜索得到的，也就是说，负梯度 $-\nabla F$ 方向虽然在每个 $(x_k,y_k)$ 处都是最陡的，但是每次移动后距离最终的最小值点 $(x^*,y^*)=(0,0)$ 仍然很远.

当 $b$ 很小时，碗变成了一个狭窄的山谷. 我们正在徒劳地穿越山谷，而不是沿着山谷向下移动到最底部的 $(0,0)$ 点.

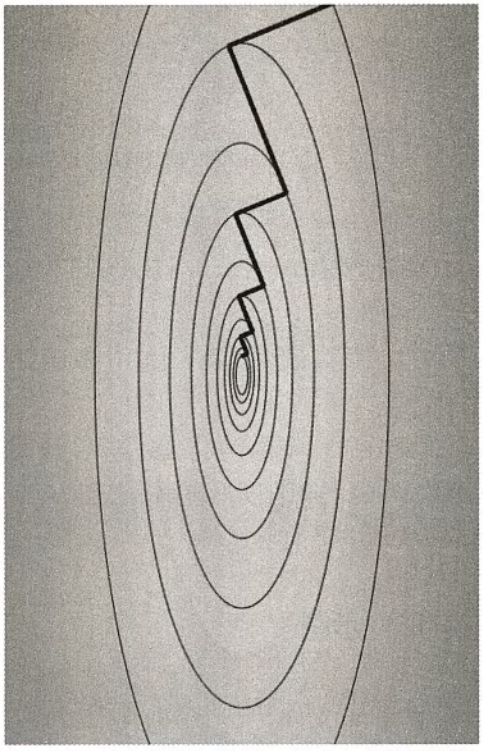

图 9.4　之字形路径缓慢收敛到函数 $F = x^2 + by^2$ 的最小值

### 9.1.5　动量与重球的路径

最陡下降的缓慢之字形路径确实是一个问题，我们必须做出改进. 上述示例中的函数 $F = \frac{1}{2}\left(x^2 + by^2\right)$ 仅包含两个变量 $x$、$y$，其二阶导数矩阵是对角矩阵，且对角元为常值 $F_{xx} = 1$ 和 $F_{yy} = b$. 但当 $b = \lambda_{\min}/\lambda_{\max}$ 很小时，就会发生明显的之字形问题.

**关键思想：**对于滚下山坡的重球而言，不会发生之字形运动. 动量使它快速滚下狭窄的山谷——虽然会碰撞两侧，但总体是向下滚动. 因此，我们**向梯度添加动量系数 $\beta$**（Polyak 的重要思想）. 这便是深度学习中最为方便且有用的思想之一.

下降过程的第一步，是沿着垂直于等高线（水平集）的方向移动. 穿越更低的等高线时，意味着函数 $F(x, y)$ 的值在减小. 最终，当移动方向与某条等高线相切时，下降过程停止. 而如果继续前进，$F$ 值将会增加，这是因为此步结束后，下一步将垂直于 $L$ 移动，从而之字形路径转了 90°.

**读者注意：**第 10 章介绍的深度学习将涉及许多函数 $F(x, v_i)$ 之和——训练集中每个向量 $v_i$ 都有一个对应函数. 于是，总的梯度就等于上述许多函数的梯度之和，这将导致每一步的计算量过大. 在 9.2 节中，我们给出的解决方案是下降过程中的每步只随机地选择一个或几个函数.

**关键思想：**新步骤的方向 $\boldsymbol{z}_k$ 与上一步的方向 $\boldsymbol{z}_{k-1}$ 有关.

**考虑动量的下降法：**

$$\boxed{\boldsymbol{x}_{k+1} = \boldsymbol{x}_k - s\boldsymbol{z}_k, \quad \text{其中} \quad \boldsymbol{z}_k = \nabla F(\boldsymbol{x}_k) + \beta \boldsymbol{z}_{k-1}} \tag{9.10}$$

现在，我们需要选择两个系数：步长 $s$ 和 $\beta$. 重要的是：式 (9.10) 中，移动到 $\boldsymbol{x}_{k+1}$ 的跨步还与 $\boldsymbol{z}_{k-1}$ 有关. 动量法将梯度下降法的一阶递归（一步法），转变为二阶递归（两步法）. 实际上，如

果我们把式 (9.10) 重写为两个等式，即 $k+1$ 时刻关于 $(\boldsymbol{x},\boldsymbol{z})$ 的一个向量等式：

$$\text{考虑动量的下降法：}\quad \boxed{\begin{cases}\boldsymbol{x}_{k+1}=\boldsymbol{x}_k-s\boldsymbol{z}_k\\ \boldsymbol{z}_{k+1}-\nabla F\left(\boldsymbol{x}_{k+1}\right)=\beta\boldsymbol{z}_k\end{cases}} \tag{9.11}$$

由上述两个等式，我们又恢复了一阶递归的方法. 这类似于将单个二阶微分方程转化为两个一阶微分方程的方法.

### 9.1.6　二次模型

当 $F(\boldsymbol{x})=\dfrac{1}{2}\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}$ 为二次函数时，其梯度 $\nabla F=\boldsymbol{S}\boldsymbol{x}$ 是线性的. 在本节讨论的模型中，要求 $\boldsymbol{S}$ 是对称正定矩阵. 于是在式 (9.11) 中，$\nabla F\left(\boldsymbol{x}_{k+1}\right)$ 等于 $\boldsymbol{S}\boldsymbol{x}_{k+1}$. 前面之字形的典型示例，也包含在内，其对应矩阵 $\boldsymbol{S}$ 是（以 1、$b$ 为对角元的）对角矩阵. 对每个矩阵 $\boldsymbol{S}$，不难发现其最大和最小特征值决定了 $\beta$ 和步长 $s$ 的最佳选择. 因此，$2\times 2$ 的情况实际上已经足以说明整个问题的本质了.

为了加速下降的步骤，我们考察 $\boldsymbol{S}$ 的每个特征向量 $\boldsymbol{q}$. 假设 $\boldsymbol{S}\boldsymbol{q}=\lambda\boldsymbol{q}$，$\boldsymbol{x}_k=c_k\boldsymbol{q}$，$\boldsymbol{z}_k=d_k\boldsymbol{q}$，且 $\nabla F_k=\boldsymbol{S}\boldsymbol{x}_k=\lambda c_k\boldsymbol{q}$. 于是，等式 (9.11) 将第 $k$ 步中的数 $c_k$、$d_k$ 与第 $k+1$ 步中的下一组数 $c_{k+1}$、$d_{k+1}$ 联系起来：

$$\text{对特征向量 } \boldsymbol{q}\text{：}\quad \begin{cases}c_{k+1}=c_k-sd_k\\ -\lambda c_{k+1}+d_{k+1}=\beta d_k\end{cases}\quad\Rightarrow\quad \begin{bmatrix}1 & 0\\ -\lambda & 1\end{bmatrix}\begin{bmatrix}c_{k+1}\\ d_{k+1}\end{bmatrix}=\begin{bmatrix}1 & -s\\ 0 & \beta\end{bmatrix}\begin{bmatrix}c_k\\ d_k\end{bmatrix} \tag{9.12}$$

进一步，对上式第一个矩阵求逆（$-\lambda$ 变为 $+\lambda$），即可看清下降过程中每一步的变化规律：

$$\boxed{\begin{bmatrix}c_{k+1}\\ d_{k+1}\end{bmatrix}=\begin{bmatrix}1 & 0\\ \lambda & 1\end{bmatrix}\begin{bmatrix}1 & -s\\ 0 & \beta\end{bmatrix}\begin{bmatrix}c_k\\ d_k\end{bmatrix}=\begin{bmatrix}1 & -s\\ \lambda & \beta-\lambda s\end{bmatrix}\begin{bmatrix}c_k\\ d_k\end{bmatrix}=\boldsymbol{R}\begin{bmatrix}c_k\\ d_k\end{bmatrix}} \tag{9.13}$$

经过 $k$ 步后，起始向量乘以 $\boldsymbol{R}^k$. 为了快速收敛到零（达到 $F(\boldsymbol{x})=\dfrac{1}{2}\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}$ 的最小值点），我们希望 $\boldsymbol{R}$ 的两个特征值 $e_1$ 和 $e_2$ 都尽可能小. 显然，$\boldsymbol{R}$ 的特征值依赖于 $\boldsymbol{S}$ 的特征值 $\lambda$. 该特征值 $\lambda$ 可能为介于 $\lambda_{\min}(\boldsymbol{S})$ 和 $\lambda_{\max}(\boldsymbol{S})$ 之间的任何数. 接下来的问题是：对于 $\lambda\in\left[\lambda_{\min}\left(\boldsymbol{S}\right),\lambda_{\max}\left(\boldsymbol{S}\right)\right]$，选择合适的 $s$ 与 $\beta$，使得 $\max\left[\left|e_1(\lambda)\right|,\left|e_2(\lambda)\right|\right]$ 取到最小值.

令人惊喜的是，上述问题得到了漂亮的解决方案：最优的 $s$ 和 $\beta$ 是

$$\boxed{s=\left(\frac{2}{\sqrt{\lambda_{\max}}+\sqrt{\lambda_{\min}}}\right)^2,\quad \beta=\left(\frac{\sqrt{\lambda_{\max}}-\sqrt{\lambda_{\min}}}{\sqrt{\lambda_{\max}}+\sqrt{\lambda_{\min}}}\right)^2} \tag{9.14}$$

考虑之字形的典型示例，$\boldsymbol{S}$ 的特征值为 $\lambda_{\max}=1$，$\lambda_{\min}=b$，于是

$$s=\left(\frac{2}{1+\sqrt{b}}\right)^2,\quad \beta=\left(\frac{1-\sqrt{b}}{1+\sqrt{b}}\right)^2 \tag{9.15}$$

上述步长和动量因子的选择给出了一个收敛速率，形式上看起来与式(9.9)用普通最速下降（无动量）法所给出的收敛速率接近. 但有一个关键区别：式(9.9) 中的数字 $b$，在式(9.15)中变成了 $\sqrt{b}$，即

$$\boxed{\text{普通下降因子：}\quad \left(\frac{1-b}{1+b}\right)^2 \qquad \text{加速下降因子：}\quad \left(\frac{1-\sqrt{b}}{1+\sqrt{b}}\right)^2.} \tag{9.16}$$

可谓既相似又不同. 真正的考验是在 $b$ 非常小时，此时普通下降因子约为 $1-4b$，这非常接近于 1；而加速下降因子约为 $1-4\sqrt{b}$，这远低于 1.

为了说明动量法的改进效果，设 $b=1/100$，则 $\sqrt{b}=1/10$（是 $b$ 的 10 倍）. 式(9.16) 中的收敛因子是

$$\text{普通下降}\left(\frac{0.99}{1.01}\right)^2 \approx 0.96,\ \text{加速下降}\left(\frac{0.9}{1.1}\right)^2 \approx 0.67.$$

普通下降法十步后，将初始误差下降到 0.67. 这相当于动量法做一步的效果. 而动量法做十步后，可以将误差下降为初始误差的 0.018.

也可以说，$\boldsymbol{S}$ 的条件数 $\lambda_{\max}/\lambda_{\min}=1/b$ 决定了一切.

**注释 1** Nesterov 对梯度下降法做了与动量法不同的改进.

**注释 2** 自适应方法利用所有先前的步长方向选择，对当前步长方向 $\nabla L_k$ 做修正，从而得到 $x_{k+1}$. 当前方向的公式变为 $D_k=\delta D_{k-1}+(1-\delta)\nabla L_k$. 可以证实使用早先方向（进入 $D_{k-1}$ 的方向）的确可以带来加速效果.

在随机梯度下降中，批处理大小 $B$ 在后续步骤中可以增加.

## 习题 9.1

1. 什么函数 $F(x)$ 代入式(9.1) 和式(9.2) 后，对所有 $x$ 成立？

2. 写出方程 $x^2+1=0$ 的牛顿法. 它并不收敛（没有实数解）. 如果 $x_n=\cos\theta/\sin\theta$，证明：$x_{n+1}=\cos 2\theta/\sin 2\theta$. 这是《大学数学杂志》（College Math J.）22 卷（1991 年）第 3~12 页中“混沌”的一个例子.

3. $1\times 1$ 矩阵的行列式就是 $\det \boldsymbol{x}=x_{11}$. 对于 $x_{11}>0$，计算一元函数 $F(X)=-\log(\det X)=-\log x_{11}$ 的一阶和二阶导数. 画出 $F=-\log x$ 的图像，说明 $F$ 是凸函数.

4. 二阶对称阵 $\boldsymbol{A}$ 的行列式为 $\det(\boldsymbol{A})=ac-b^2$. 利用二阶导数矩阵（海森矩阵），证明关于 $a$、$b$、$c$ 的三元函数 $F=-\log(ac-b^2)$ 是凸函数.

5. 对于最小二乘问题中的待最小化目标函数 $F(\boldsymbol{x})=\frac{1}{2}\|\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}\|^2$，具体写出其梯度下降方程 $\boldsymbol{x}_{k+1}=\boldsymbol{x}_k-s_k\nabla F(\boldsymbol{x}_k)$.

6. 求出函数 $F(x,y)=\frac{1}{2}\left(x^2+\frac{1}{4}y^2\right)$ 的梯度和梯度下降方程. 若初始点为 $(x_0,y_0)=\left(\frac{1}{4},1\right)$，验证或改进式(9.9)以得到 $(x_1,y_1)$.

7. 在习题 6 的基础上添加动量因素，并利用式(9.10)和式(9.11)进行一次“加速”步骤.

8. 证明下述非二次函数的最小值点为 $(x,y)=(0,+\infty)$：

$$F(x,y)=\frac{1}{2}x^2+\mathrm{e}^{-y},\quad \nabla F=\begin{bmatrix}x\\-\mathrm{e}^{-y}\end{bmatrix},\quad \boldsymbol{S}=\begin{bmatrix}1&0\\0&\mathrm{e}^{-y}\end{bmatrix}$$

并以 $(x_0,y_0)=(1,1)$ 为初始点，进行一步梯度下降法操作.

## 9.2　反向传播和随机梯度下降

本节将解释深度学习中的一个关键计算步骤，即优化学习函数 $F(\boldsymbol{x},\boldsymbol{v})$ 中的**权重集合** $\boldsymbol{x}$. 我们有“训练数据”——一组包含大量输入向量 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_N$ 的集合. 对于每个输入向量 $\boldsymbol{v}_i$，我们都清楚其对应的正确输出向量 $\boldsymbol{w}_i$. 我们的目标是找到合适的权重 $\boldsymbol{x}$，使得误差向量 $\boldsymbol{e}_i=F(\boldsymbol{x},\boldsymbol{v}_i)\boldsymbol{w}_i$ 尽可能小. 换句话说，我们希望通过选择合适的权重 $\boldsymbol{x}$，将学习函数 $F$ 拟合到这 $N$ 个训练数据点上，以**最小化总损失** $L(\boldsymbol{x})$:

$$\text{最小化}\qquad L(\boldsymbol{x})=\frac{1}{N}\sum_{i=1}^{N}\ell(\boldsymbol{e}_i)=\frac{1}{N}\sum_{i=1}^{N}\ell(F(\boldsymbol{x},\boldsymbol{v}_i)-\boldsymbol{w}_i). \tag{9.17}$$

最佳的权重 $\boldsymbol{x}$ 取决于选择的学习函数 $F(\boldsymbol{x},\boldsymbol{v})$ 的形式. 同时，权重也取决于选择的用于衡量误差 $\boldsymbol{e}_i$ 的损失函数 $\ell$. 如果选择“平方损失” $\ell(\boldsymbol{e})=\|\boldsymbol{e}\|^2$ 作为损失函数，那么我们的任务就是找到训练数据 $(\boldsymbol{v}_1,\boldsymbol{w}_1),(\boldsymbol{v}_2,\boldsymbol{w}_2),\cdots,(\boldsymbol{v}_N,\boldsymbol{w}_N)$ 的最小二乘拟合.

这个问题整体概述如下. 我们正在构建一个函数 $F$，它能够近似甚至“插值”训练数据：对于 $i=1,2,\cdots,N$，有 $F(\boldsymbol{v}_i)\approx\boldsymbol{w}_i$. 然后，当我们有新的**测试数据** $\boldsymbol{V}$ 时，将通过函数 $F(\boldsymbol{V})$ 来估计未知的输出 $\boldsymbol{W}$. 比如说，我们正在尝试识别一个手写数字 $\boldsymbol{W}$. 我们有 $N$ 张图片 $\boldsymbol{v}_1,\boldsymbol{v}_2,\cdots,\boldsymbol{v}_N$，对应已知的数字 $\boldsymbol{w}_1,\boldsymbol{w}_2,\cdots,\boldsymbol{w}_N$. 基于这些训练数据，我们如何对新的图片 $\boldsymbol{V}$ 中的像素进行加权，以识别出那张图片中的数字 $\boldsymbol{W}$?

插值是一个历史悠久的问题. 深度学习是一种全新的方法，其成功程度远超以往. 最差的方法之一是通过一个次数非常高的多项式 $F$ 来拟合数据，这种方法极其不稳定. 输入 $\boldsymbol{V}$ 的微小变化会导致输出 $\boldsymbol{W}=F(\boldsymbol{V})$ 的巨大波动. 这说明我们选择了错误的学习函数 $F$（即多项式）. 第 10 章将介绍 $F$ 的一个更好选择. 本节讨论的是如何**“将函数 $F$ 拟合到训练数据”**.

构建和使用学习函数 $F$ 包括三个主要步骤.

（1）选择 $F(\boldsymbol{x},\boldsymbol{v})$ 的形式. 它包含一个非线性函数，通常是 ReLU.

（2）计算 $F$ 能拟合训练数据的最佳权重 $\boldsymbol{x}$，即 $F(\boldsymbol{x},\boldsymbol{v}_i)\approx\boldsymbol{w}_i$.

（3）用这些权重，评估新测试数据 $\boldsymbol{V}$ 的输出 $\boldsymbol{W}=F(\boldsymbol{x},\boldsymbol{V})$.

步骤（1）是本书第 10 章的目标. 我们将创建一个神经网络来描述 $F$ 的形式. 其关键在于 $F$ 是由一系列更简单的函数 $F_1$ 到 $F_L$ 按顺序复合产生的：

$$F(\boldsymbol{x},\boldsymbol{v})=F_L(F_{L-1}(\cdots(F_2(F_1(\boldsymbol{v}))))) \tag{9.18}$$

函数链中的每个函数 $F_k$ 都有自己的权重 $\boldsymbol{x}_k$. 第 10 章将会介绍，这些单个函数 $F_k$ 都具有一种简单的分段线性的形式. 正是这个从 $F_1$ 到 $F_L$ 的函数链组合起来，产生了一个强大的学习函数 $F$.

10.1 节将计算由 ReLU 构造的 $F$ 所含有的（大量的）线性片段的数量.

本节描述**反向传播算法**，它能有效地找到 $F$ 在函数 $F_1$ 到 $F_L$ 中关于权重矩阵 $\boldsymbol{x}_1$ 到 $\boldsymbol{x}_L$ 的导数. 通过这些导数 $\partial F_k/\partial x_k$，我们可以用**梯度下降（或随机梯度下降）**来优化权重. 因此，一旦确定了 $F$ 的形式，深度学习的核心任务就是计算权重 $\boldsymbol{x}$，以最小化损失之和 $\ell(\boldsymbol{x},\boldsymbol{v}_i)$:

$$\text{损失函数} \qquad \ell(\boldsymbol{x},\boldsymbol{v}_i)=F(\boldsymbol{x},\boldsymbol{v}_i)-\boldsymbol{w}_i=\text{近似值}-\text{真实值}.$$

作者注记. 在此，我要特别感谢两位朋友，他们为我详细解释了梯度 $\nabla F$ 和 $\nabla\ell$（损失函数关于权重的导数）的计算方法. 其中一位是亚历山大·克雷格 (Alexander Craig)，他是我在麻省理工学院数学课 (编号 18.065) 的学生. 他的课程研究项目就是反向传播，而且他的报告写得非常精彩. 亚历山大也参与了本章 9.2节的撰写. 我的另一位重要支持者是安德烈亚斯·格里旺克 (Andreas Griewank)，他是“自动微分”技术的主要创造者之一. 这个算法能够以惊人的速度计算出 $F$ 和 $\ell$ 关于每个权重的导数. 当我们将其递归地应用于 $L$ 个函数的复合 $F=F_L(F_{L-1}(\cdots F_1))$ 时，这就是我们所熟知的反向传播.

基于这个计算引擎，深度学习已经取得了巨大的成功.

### 9.2.1 多变量链式法则

我们从复合函数 $h(x)=f(g(x))$ 的链式法则开始，其中输入变量为 $x_1,x_2,\cdots,x_m$. 函数 $g(x)$ 输出 $n$ 个分量 $g_1,g_2,\cdots,g_n$，函数 $h(x)=f(g(x))$ 输出 $p$ 个分量 $h_1,h_2,\cdots,h_p$. 雅可比矩阵 $\partial f/\partial g$ 和 $\partial g/\partial x$ 分别包含 $f$ 和 $g$ 的偏导数:

$$\frac{\partial \boldsymbol{f}}{\partial \boldsymbol{g}}=\begin{bmatrix}\dfrac{\partial f_1}{\partial g_1} & \cdots & \dfrac{\partial f_1}{\partial g_n}\\ \vdots & \ddots & \vdots\\ \dfrac{\partial f_p}{\partial g_1} & \cdots & \dfrac{\partial f_p}{\partial g_n}\end{bmatrix},\quad \frac{\partial \boldsymbol{g}}{\partial \boldsymbol{x}}=\begin{bmatrix}\dfrac{\partial g_1}{\partial x_1} & \cdots & \dfrac{\partial g_1}{\partial x_m}\\ \vdots & \ddots & \vdots\\ \dfrac{\partial g_n}{\partial x_1} & \cdots & \dfrac{\partial g_n}{\partial x_m}\end{bmatrix} \tag{9.19}$$

每个 $h_i$ 都依赖于 $g$，而每个 $g_j$ 都依赖于 $\boldsymbol{x}$，因此 $h_i$ 最终依赖于 $x_1,x_2,\cdots,x_m$. 链式法则的目标是计算所有的偏导数 $\partial h_i/\partial x_k$. 标量形式的链式法可以写成点积：$\partial f/\partial g$ 的第 $i$ 行与 $\partial g/\partial x$ 的第 $k$ 列的乘积. 多变量链式法则的矩阵形式即为矩阵乘积:

$$\frac{\partial \boldsymbol{h_i}}{\partial \boldsymbol{x_k}}=\frac{\partial h_i}{\partial g_1}\frac{\partial g_1}{\partial x_k}+\frac{\partial h_i}{\partial g_2}\frac{\partial g_2}{\partial x_k}+\cdots+\frac{\partial h_i}{\partial g_n}\frac{\partial g_n}{\partial x_k}=\left(\frac{\partial \boldsymbol{f}}{\partial \boldsymbol{g}}\text{的第 }i\text{行}\right)\left(\frac{\partial \boldsymbol{g}}{\partial \boldsymbol{x}}\text{的第 }k\text{列}\right) \tag{9.20}$$

对于由 $F_1$ 至 $F_L$ 复合而成的函数链 $F$，其关于 $\boldsymbol{x}$ 的偏导数矩阵链式法则为 $L$ 个矩阵的乘积:

$$\boxed{\text{矩阵链式法则} \qquad \frac{\partial F}{\partial x}=\frac{\partial F_L}{\partial F_{L-1}}\frac{\partial F_{L-1}}{\partial F_{L-2}}\cdots\frac{\partial F_1}{\partial x}} \tag{9.21}$$

### 9.2.2 随机梯度下降

在用反向传播计算导数之前，我们需要先做一个重要的决策. 待最小化的损失函数 $L(\boldsymbol{x})$ 是训练集中每个样本 $\boldsymbol{v}_i$ 的误差 $\ell(F(\boldsymbol{x},\boldsymbol{v}_i)-\boldsymbol{w}_i)$ 之和. 单个样本的导数已足够复杂！若在每次最速下降迭代中为每个样本计算所有权重的导数，计算量将巨大！为此，必须想办法减少计算量.

随机梯度下降（Stochastic Gradient Descent，SGD）随机选择一个样本或小批量样本（$B$ 个）来更新权重 $\boldsymbol{x}_k \to \boldsymbol{x}_{k+1}$. 此方法效果显著：初始迭代步骤通常能大幅改进权重 $\boldsymbol{x}$. 接近最优权重时，迭代可能变得不稳定，收敛速度也放缓，但此时通常不需要也不期望高精度. 通常我们可提前终止迭代. SGD 将每次梯度更新的计算成本降至可接受水平.

### 9.2.3　普通最小二乘的 SGD

最小二乘法为“随机”思想提供了绝佳验证. 目标是最小化 $\|\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}\|^2$. 每次迭代随机选择矩阵 $\boldsymbol{A}$ 的一行 $\boldsymbol{a}_i$，并通过下式把 $\boldsymbol{x}_k$ 更新为 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 的另一个近似解 $\boldsymbol{x}_{k+1}$：

$$\boldsymbol{x}_{k+1}=\boldsymbol{x}_k+\frac{\boldsymbol{b}_i-\boldsymbol{a}_i\boldsymbol{x}_k}{\|\boldsymbol{a}_i\|^2}\boldsymbol{a}_i^{\mathrm{T}},\quad \text{其满足}\boldsymbol{a}_i\boldsymbol{x}_{k+1}=b_i. \tag{9.22}$$

Kaczmarz 提出此方法时，考虑从 $\boldsymbol{A}$ 的第一行到最后一行采用逐行循环遍历. Strohmer 与 Vershynin 改进为随机选择行（随机梯度下降），并证明了其向最小二乘解 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\hat{\boldsymbol{x}}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$ 的指数收敛性. 图 9.5展示了收敛的关键形态：*初期快速逼近最优解 $\boldsymbol{x}^*$，后期振荡*. 正因为后期的震荡性，我们建议提前终止迭代.

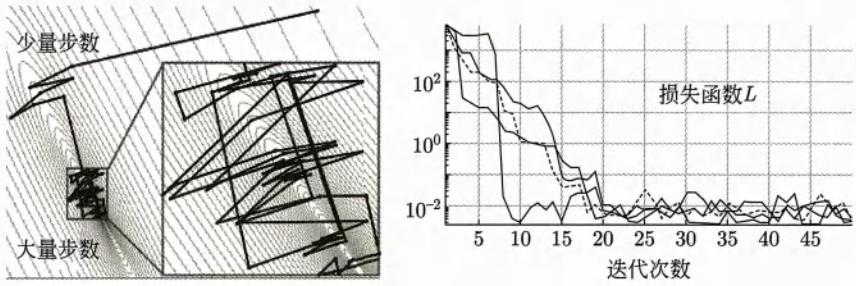


(a)含两个未知数的SGD轨迹　　(b)损失函数

图 9.5　两个未知数的随机梯度下降和二次损失函数

注：图 9.5(a) 初期迭代成功，后期振荡；图 9.5(b) 二次损失函数初期快速下降，随后波动而非收敛；图 9.5(b) 中四条路径起点相同.

### 9.2.4　反向传播的核心思想

为简化思路与符号，假设学习函数 $F$ 取决于权重 $\boldsymbol{x}$（矩阵 $\boldsymbol{A}_1$ 至 $\boldsymbol{A}_L$ 与向量 $\boldsymbol{b}_1$ 至 $\boldsymbol{b}_L$ 属于相应的层）. 最特殊的简化特征是，每一个权重仅出现在函数链 $F_1$ 至 $F_L$ 的一层. 设 $\boldsymbol{x}_j$ 表示第 $j$ 层的矩阵 $\boldsymbol{A}_j$ 和向量 $\boldsymbol{b}_j$，即 $F_j=\mathrm{ReLU}(\boldsymbol{A}_jF_{j-1}+\boldsymbol{b}_j)$（ReLU 是一个广为人知的简单函数，见图 10.1）. 损失函数 $\ell$ 对 $F_j$ 的权重 $\boldsymbol{x}_j$ 的链式法则为

$$\frac{\partial \ell}{\partial \boldsymbol{x}_j}=\frac{\partial \ell}{\partial F_L}\cdot\frac{\partial F_L}{\partial F_{L-1}}\cdot\frac{\partial F_{L-1}}{\partial F_{L-2}}\cdots\frac{\partial F_{j+1}}{\partial F_j}\cdot\frac{\partial F_j}{\partial \boldsymbol{x}_j} \tag{9.23}$$

此处，关键的不同点在于，此计算仅涉及权重 $\boldsymbol{x}_j$ 至 $\boldsymbol{x}_L$，而不涉及早期权重. 因此效率更高的计算方法是从 $\partial\ell/\partial F_L\cdot\partial F_L/\partial F_{L-1}$（涉及 $\boldsymbol{A}_L$ 和 $\boldsymbol{b}_L$）开始，逐步引入权重 $\boldsymbol{x}_{L-1}$ 中的 $\boldsymbol{A}_{L-1}$ 和 $\boldsymbol{b}_{L-1}$. 这很自然地促使我们选择从后往前作微分：

$\partial F/\partial \boldsymbol{x}_j$ 的计算仅涉及权重 $\boldsymbol{x}_j$ 到 $\boldsymbol{x}_L$.

注意，权重 $\boldsymbol{x}_j$ 包含矩阵 $\boldsymbol{A}_j$ 和向量 $\boldsymbol{b}_j$. $F_j$ 对 $\boldsymbol{A}_j$ 的导数需要三个分量（这让它构成一个张量），后续将详细计算. 此处我们先完成从 $F$ 的梯度到损失函数 $\ell$ 的梯度这最后一步，这一步体现了反向计算导数的第二个优势.

第二个关键点是：损失函数 $\ell(\boldsymbol{x},\boldsymbol{v})$ 是输出向量 $F(\boldsymbol{x},\boldsymbol{v})$ 的标量函数. 以“平方损失”为例：

损失函数
$$\ell(x)=(\boldsymbol{w}-F(\boldsymbol{x},\boldsymbol{v}))^{\mathrm{T}}(\boldsymbol{w}-F(\boldsymbol{x},\boldsymbol{v}))\quad 且\quad \frac{\partial \ell}{\partial F}=2(\boldsymbol{w}-F(\boldsymbol{x},\boldsymbol{v})) \tag{9.24}$$

其中，$\boldsymbol{w}$ 为训练样本 $\boldsymbol{v}$ 的真实输出，$F(\boldsymbol{x},\boldsymbol{v})$ 为使用权重计算得到的第 $L$ 层输出. 无论损失函数形式如何，$\partial\ell/\partial F$ 都是向量. 然后将矩阵 $\boldsymbol{M}_k=\partial F_k/\partial F_{k-1}$ 构成的反向链与该向量相乘，每一步均为向量与矩阵的乘积：

(向量)(矩阵)
而不是(矩阵)(矩阵)
$$\frac{\partial \ell}{\partial x_j}=\left(\left(\left(\frac{\partial \ell}{\partial F}\boldsymbol{M}_L\right)\boldsymbol{M}_{L-1}\right)\cdots\boldsymbol{M}_{j+1}\right) \tag{9.25}$$

假设每个矩阵 $\boldsymbol{M}_i$ 都是 $n\times n$ 矩阵，则每次向量-矩阵相乘需 $n^2$ 次乘法. 若采用正向模式（矩阵-矩阵相乘），则需 $n^3$ 次. 反向模式的计算效率显著更高.

反向计算微分的高效性源于两点：

（1）主要操作为向量-矩阵乘法（或向量-张量）；

（2）计算结果可复用于后续导数计算.

反向模式计算微分通过从左到右重新排列链式法则中的括号来实现高效计算——从输出端的损失函数回溯到第 $j$ 层：

反向传播
$$\frac{\partial \ell}{\partial b_j}=\left(\left(\left(\frac{\partial \ell}{\partial F_L}\cdot\frac{\partial F_L}{\partial F_{L-1}}\right)\cdot\frac{\partial F_{L-1}}{\partial F_{L-2}}\right)\cdots\frac{\partial F_{j+1}}{\partial F_j}\right)\cdot\frac{\partial F_j}{\partial b_j} \tag{9.26}$$

由于 $\partial\ell/\partial F_L$ 是向量，中间结果大多都是向量，因此我们执行向量-矩阵乘法. 当计算 $\partial\ell/\partial\boldsymbol{A}_j$ 时，我们无法避免最后的单个向量-张量缩并——因为 $\boldsymbol{A}$ 是矩阵. 10.2 节将计算该矩阵 $\partial F_j/\partial\boldsymbol{A}_j$.

除了每一步的速度提升，反向计算模式还通过复用中间结果这一“优雅”的方式减少总计算量. 关键点是：对于每一层 $j\leqslant k$，其链式法则表达式共享相同的前缀 $\partial\ell/\partial F_k$. 由于反向计算模式从左到右地把项组合起来，它可以调用 $\partial\ell/\partial F_k$ 的结果来计算所有 $j\leqslant k$ 的层. 反向传播在每一层都应用这一优化，算法如下：

初始化时，使用输入 $\boldsymbol{v}$ 执行向前传播并存储所有中间结果 $F_j$，同时计算 $\partial\ell/\partial F_L$. 随后：

for $j=L\to 1$ do

计算并存储：

$$\frac{\partial \ell}{\partial b_j}=\frac{\partial \ell}{\partial F_j}\cdot\frac{\partial F_j}{\partial b_j}\quad 和\quad \frac{\partial \ell}{\partial A_j}=\frac{\partial \ell}{\partial F_j}\cdot\frac{\partial F_j}{\partial A_j}$$

if $j\neq 1$ then

计算下一轮递归要用的 $\partial\ell/\partial F_{j-1}$：

$$\frac{\partial \ell}{\partial F_{j-1}}=\frac{\partial \ell}{\partial F_j}\cdot\frac{\partial F_j}{\partial F_{j-1}}$$

end if

end for

所以反向传播通过一次反向遍历网络即可计算所有导数，仅需 $2L$ 次向量-矩阵乘法和 $L$ 次向量-张量缩并. 而前向模式需要 $O(L^2)$ 次矩阵-张量缩并和矩阵-矩阵乘法. 反向传播的效率高出多个数量级.

### 9.2.5　Keras 与 TensorFlow 中的反向传播

Keras 是目前最流行的机器学习库之一. 它提供了简单的 Python 神经网络接口，并通过 TensorFlow 库内部执行反向传播.

TensorFlow 对反向传播算法的实现是对上述算法的一个显著升级，它不仅更为复杂，也更为强大. TensorFlow 旨在处理任意复杂函数链的求导问题. 为此，它首先构建一个计算图，用以表示需要求导的函数. 接着，在这个图中添加代表导数的操作，通常是从函数的输出端开始，逆向追溯到输入端. 这样，TensorFlow 就能为网络中任何给定的输入计算导数. 当网络结构符合我们之前的描述时，TensorFlow 的计算图及其中的导数操作将与我们的伪代码示例产生相同的结果.

### 9.2.6　$Av+b$ 的导数

我们现在要计算每一层的学习函数 $F_j$ 对该层引入的权重 $\boldsymbol{A}_j$ 和偏置向量 $\boldsymbol{b}_j$ 的偏导数. 每一层的计算过程是这样的：首先计算向量 $\boldsymbol{w}_j=\boldsymbol{A}_j\boldsymbol{v}_{j-1}+\boldsymbol{b}_j$，然后应用 ReLU 函数得到 $\boldsymbol{v}_j=\mathrm{ReLU}(\boldsymbol{w}_j)$. 为了简化问题，我们首先考虑最简单的情况，暂时不考虑具体的层指标 $j$. 那么我们的函数是 $\boldsymbol{w}(\boldsymbol{A},\boldsymbol{b})=\boldsymbol{A}\boldsymbol{v}+\boldsymbol{b}$.

我们需要明确的是，函数 $\boldsymbol{w}(\boldsymbol{A},\boldsymbol{b})=\boldsymbol{A}\boldsymbol{v}+\boldsymbol{b}$ 第 $i$ 个分量（也是第 $i$ 个输出）$w_i=(\boldsymbol{A}\boldsymbol{v}+\boldsymbol{b})_i$ 对第 $j$ 个输入元素 $b_j$ 的导数是多少？虽然这个问题看起来有些特殊，但答案其实非常简单：

$$\text{若 } i=j,\ \text{则}\quad \frac{\partial w_i}{\partial b_j}=1;\quad \text{若 } i\neq j,\ \text{则}\frac{\partial w_i}{\partial b_j}=0. \tag{9.27}$$

这种 $0-1$ 二选一取值的现象在数学中非常常见，所以专门给它一个记号，即克罗内克函数 $\delta_{ij}$.

$$\delta_{ij}=\begin{cases}1, & i=j\\ 0, & i\neq j\end{cases}=\text{单位阵 }\boldsymbol{I}\text{ 的元素}$$

接下来，我们需要计算第 $i$ 个输出元素 $w_i$ 对第 $(j,k)$ 个输入元素 $\boldsymbol{A}_{jk}$ 的偏导数. 在这个过程中，我们涉及三个指标 $i$、$j$、$k$，这意味着我们正在处理的是一个张量（更准确地说，是一个三阶张量）. 张量可以看作矩阵的推广，不过就是指标多了点，就像矩阵是两个指标的数字组成二维矩形，而三个指标的张量则是三个指标的数字组成的三维长方体.

注记　张量在理论和计算上都扮演着重要的角色（由此进入了多重线性代数的领域）. 然而，张量并不是矩阵概念的简单扩展. 例如，张量的秩就不是那么容易定义的，而且像 SVD 这样的矩阵分解方法也不能直接应用于张量. 不过，秩为 1 的张量相对容易理解：它的元素 $T_{ijk}$ 可以用三个向量 $\boldsymbol{a}$、$\boldsymbol{b}$、$\boldsymbol{c}$ 的分量的乘积形式 $a_ib_jc_k$ 来表示，这与秩为 1 的矩阵中的元素 $a_ib_j$ 类似.

以下是 $\boldsymbol{w}=\boldsymbol{A}\boldsymbol{v}+\boldsymbol{b}$ 的张量导数的公式：

$$T_{ijk}=\frac{\partial w_i}{\partial A_{jk}}=v_k\delta_{ij} \tag{9.28}$$

例如，$T_{111}=\boldsymbol{v}_1, T_{122}=0$. 这说明，只有当 $i=j$ 时，$\boldsymbol{A}$ 的第 $j$ 行才对 $\boldsymbol{w}=\boldsymbol{A}\boldsymbol{v}+\boldsymbol{b}$ 的第 $i$ 个分量有影响. 在这个前提下，该行中的元素 $A_{jk}$ 和 $v_k$ 相乘，所以输出 $w_i$ 关于矩阵元素 $A_{jk}$ 的偏导数即 $v_k$.

**例 9.10** 设 $\begin{bmatrix}w_1\\w_2\end{bmatrix}=\begin{bmatrix}b_1\\b_2\end{bmatrix}+\begin{bmatrix}a_{11}v_1+a_{12}v_2\\a_{21}v_1+a_{22}v_2\end{bmatrix}$，其中共有 6 个变量，$w_1$ 关于这 6 个变量的偏导数分别是

$$\frac{\partial w_1}{\partial b_1}=\mathbf{1},\quad \frac{\partial w_1}{\partial b_2}=\mathbf{0},\quad \frac{\partial w_1}{\partial a_{11}}=\boldsymbol{v}_1\quad \frac{\partial w_1}{\partial a_{12}}=\boldsymbol{v}_2\quad \frac{\partial w_1}{\partial a_{21}}=\frac{\partial w_1}{\partial a_{22}}=\mathbf{0}.$$

### 9.2.7 隐藏层的偏导数

现在考虑含一个隐藏层（$L=2$）的网络，输出 $\boldsymbol{w}=\boldsymbol{v}_L=\boldsymbol{v}_2$，隐藏层包含 $\boldsymbol{v}_1$，输入是 $\boldsymbol{v}_0=\boldsymbol{v}$.

$$\boldsymbol{v}_1=\mathrm{ReLU}(\boldsymbol{A}_1\boldsymbol{v}_0+\boldsymbol{b}_1),\quad \boldsymbol{w}=\boldsymbol{A}_2\boldsymbol{v}_1+\boldsymbol{b}_2=\boldsymbol{b}_2+\boldsymbol{A}_2\mathrm{ReLU}(\boldsymbol{b}_1+\boldsymbol{A}_1\boldsymbol{v}_0).$$

式(9.27)和式(9.28)给出了 $\boldsymbol{w}$ 关于最后一个权重 $\boldsymbol{A}_2$ 和 $\boldsymbol{b}_2$ 的偏导数. 函数 ReLU 在这一步是不涉及的，同时上两式中 $\boldsymbol{v}$ 应是 $\boldsymbol{v}_1$. 但是 $\boldsymbol{w}$ 关于 $\boldsymbol{A}_1$ 和 $\boldsymbol{b}_1$ 的偏导数的确是涉及非线性函数 ReLU 在 $\boldsymbol{b}_1+\boldsymbol{A}_1\boldsymbol{v}_0$ 上的作用的.

所以偏导数 $\partial\boldsymbol{w}/\partial\boldsymbol{A}_1$ 需要链式法则：

**链式法则**
$$\frac{\partial \boldsymbol{w}}{\partial \boldsymbol{A}_1}=\frac{[\boldsymbol{A}_2\mathrm{ReLU}(\boldsymbol{b}_1+\boldsymbol{A}_1\boldsymbol{v}_0)]}{\partial \boldsymbol{A}_1}=\boldsymbol{A}_2\mathrm{ReLU}'(\boldsymbol{b}_1+\boldsymbol{A}_1\boldsymbol{v}_0)\frac{\partial(\boldsymbol{b}_1+A_1\boldsymbol{v}_0)}{\partial \boldsymbol{A}_1}. \tag{9.29}$$

这个公式包含三部分. 首先是第 $L2=0$ 层的初始值 $\boldsymbol{v}_0$，通过权重 $\boldsymbol{b}_1$ 和 $\boldsymbol{A}_1$ 进入第 $L1=1$ 层. 这一步的导数计算与式(9.27)和式(9.28)相同. 但这一步的输出并不是 $\boldsymbol{v}_{L1}$. 为了得到隐藏层的输出，我们需要先使用 ReLU 函数. 因此，链式法则中包含了 ReLU 函数的导数 ReLU′. 最后一步，我们将结果与最后的权重矩阵 $\boldsymbol{A}_2$ 相乘，得到 $\boldsymbol{w}$.

课后题将这些公式进一步扩展到了 $L$ 层的网络. 这些公式非常有用. 但在涉及池化和批量归一化的情况时，自动微分似乎比硬编码更为有效.

还有非常重要的一点，像式(9.29)这样的表达式是从输出 $\boldsymbol{w}$反向计算到输入 $\boldsymbol{v}$ 的. 自动反向传播也是按照这种方式进行的，即从输出开始，逐层反向计算.

### 9.2.8 偏导数 $\partial\boldsymbol{w}/\partial\boldsymbol{A}_1$ 的细节

下面更详细地介绍式(9.29). 非线性部分 ReLU′ 来源于非线性激活函数的导数. 通常取斜坡函数作激活函数

$$\mathrm{ReLU}=\max\{x,0\}=\begin{cases}0, & x\leqslant 0\\ x, & x\geqslant 0\end{cases}$$

ReLU 的函数图像如图 9.6(a) 所示，图 9.6(b) 与之对比.

所以

$$\frac{\mathrm{dReLU}}{\mathrm{d}x}=\begin{cases}0, & x<0\\ 1, & x>0\end{cases}\qquad \mathrm{ReLU}'(\boldsymbol{A}_1\boldsymbol{v}_0+\boldsymbol{b}_1)=\begin{cases}0, & (\boldsymbol{A}_1\boldsymbol{v}_0+\boldsymbol{b}_1)_i<0\\ 1, & (\boldsymbol{A}_1\boldsymbol{v}_0+\boldsymbol{b}_1)_i>0\end{cases}.$$

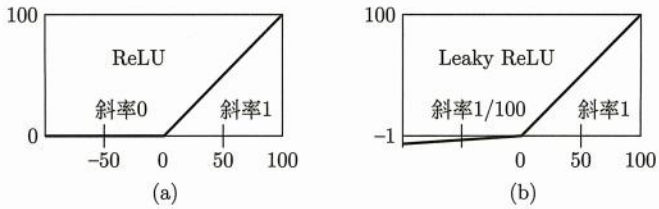


图 9.6　ReLU 和 Leaky ReLU 的函数图像

回到式(9.29)，用 $\boldsymbol{A}$ 和 $\boldsymbol{b}$ 表示生成最后一层隐藏层的矩阵 $\boldsymbol{A}_{L-1}$ 和向量 $\boldsymbol{b}_{L-1}$. ReLU 与 $\boldsymbol{A}_L$、$\boldsymbol{b}_L$ 共同生成最终输出 $\boldsymbol{w}=\boldsymbol{v}_L$. 我们关注的是 $\partial \boldsymbol{w}/\partial A$，即 $\boldsymbol{w}$ 对倒数第二层权重矩阵的依赖关系：

$$\boxed{\boldsymbol{w}=\boldsymbol{A}_L(\mathrm{ReLU}(\boldsymbol{A}\boldsymbol{v}+\boldsymbol{b}))+\boldsymbol{b}_L \qquad \frac{\partial \boldsymbol{w}}{\partial \boldsymbol{A}}=\boldsymbol{A}_L\mathrm{ReLU}'(\boldsymbol{A}\boldsymbol{v}+\boldsymbol{b})\frac{\partial(\boldsymbol{A}\boldsymbol{v}+\boldsymbol{b})}{\partial \boldsymbol{A}}} \tag{9.30}$$

我们将 ReLU 视为对角矩阵作用于 $\boldsymbol{A}\boldsymbol{v}+\boldsymbol{b}$ 的每个元素，则雅可比矩阵 $\boldsymbol{J}=\mathrm{ReLU}'(\boldsymbol{A}\boldsymbol{v}+\boldsymbol{b})$ 为对角矩阵：正分量为 1，负分量为 0（ReLU 在 0 处的导数暂不讨论）：

$$\boldsymbol{w}=\boldsymbol{A}_L\mathrm{ReLU}(\boldsymbol{A}\boldsymbol{v}+\boldsymbol{b}) \qquad \frac{\partial \boldsymbol{w}}{\partial \boldsymbol{A}}=\boldsymbol{A}_L\boldsymbol{J}\frac{\partial(\boldsymbol{A}\boldsymbol{v}+\boldsymbol{b})}{\partial \boldsymbol{A}} \tag{9.31}$$

$\dfrac{\partial(\boldsymbol{A}\boldsymbol{v}+\boldsymbol{b})}{\partial \boldsymbol{A}}$ 的分量（$v_k$ 或 0）可由式(9.27)和式(9.28)得出.

若用平滑的 sigmoid 函数 $\mathrm{ReLU}_a$ 替代 ReLU，雅可比矩阵 $\boldsymbol{J}=\mathrm{ReLU}_a'(\boldsymbol{A}\boldsymbol{v}+\boldsymbol{b})$ 不再仅含 0 和 1. 此时需计算每个分量的导数 $\mathrm{dReLU}_a/\,\mathrm{d}x$.

实践中，反向传播自动且高效地生成任意权重矩阵和偏置向量的导数.

## 习题 9.2

1. 对线性方程组 $x+2y=3$ 和 $2x+3y=5$，测试式(9.22)的 Kaczmarz 迭代，初值为 $(x_0,y_0)=(0,0)$. 比较循环顺序（方程 1、2、1、2……）与随机顺序的收敛速度.

2. 写出最小化损失函数 $\ell(x)=(1-F(x))^2$ 的第一步反向传播过程，其中 $F(x)=F_2(F_1(x))$、$F_2=\cos(\sin x)$、$x_0=0$. 此单变量问题无法体现反向传播的优势.

3. 假设用平滑非线性激活函数 tanh 替代 ReLU：

双曲正切函数　　$\tanh(x)=\dfrac{\mathrm{e}^x-\mathrm{e}^{-x}}{\mathrm{e}^x+\mathrm{e}^{-x}}$

（1）当 $x\to 0$、$x\to+\infty$、$x\to-\infty$ 时，$\tanh(x)$ 的极限值分别是多少？

（2）绘制 $y=\tanh(x)$ 在 $x\in(-\infty,+\infty)$ 的函数图像.

（3）求导 $\mathrm{d}y/\,\mathrm{d}x$，证明 tanh 是单调递增函数.

4. 在 ReLU 之前，tanh 曾是深度学习中常用的非线性“激活函数”. 因其平滑性，其导数对所有输入均有效（与 ReLU 不同）. 输入 $\boldsymbol{b}$ 可以是标量或向量. 求 $\tanh(\boldsymbol{A}\boldsymbol{x}+\boldsymbol{b})$ 对 $\boldsymbol{b}$ 的梯度.

5. 设 $F=F_2(x,F_1(y))$ 为 $x$ 和 $y$ 的函数，求偏导数 $\partial F/\partial x$ 和 $\partial F/\partial y$. 应优先计算哪个偏导数？

## 9.3 约束条件、拉格朗日乘子与最小范数

考虑 $xy$ 平面上的约束直线 $3x+4y=1$，需在此线上找到范数最小的点 $(x^*,y^*)$. 问题的解取决于范数的定义. 设 $\boldsymbol{v}=\begin{bmatrix}x & y\end{bmatrix}^{\mathrm{T}}$，以下是三种常用向量范数：

| | |
|---|---|
| $\ell^1$ 范数： | $\|\boldsymbol{v}\|_1=\|x\|+\|y\|$ |
| $\ell^2$ 范数： | $\|\boldsymbol{v}\|_2=\sqrt{x^2+y^2}$ |
| $\ell^\infty$ 范数： | $\|\boldsymbol{v}\|_\infty=\max\{\|x\|,\|y\|\}$ |

范数都应该满足：$\|c\boldsymbol{v}\|=|c|\,\|\boldsymbol{v}\|$

三角不等式 $\|\boldsymbol{v}+\boldsymbol{w}\|\leqslant\|\boldsymbol{v}\|+\|\boldsymbol{w}\|$.

对 $p>1$，有 $\ell^p$ 范数：$\|\boldsymbol{v}\|_p=(|x|^p+|y|^p)^{1/p}$

对向量 $\boldsymbol{v}=\begin{bmatrix}1 & 1\end{bmatrix}^{\mathrm{T}}$，三种范数分别为 2、$\sqrt{2}$ 和 1. 绘制区域 $\|\boldsymbol{v}\|_1\leqslant1$、$\|\boldsymbol{v}\|_2\leqslant1$、$\|\boldsymbol{v}\|_\infty\leqslant1$ 是直观理解范数差异的最好的方法. 在 $\ell^1$、$\ell^2$、$\ell^\infty$ 三种范数下，对应的区域分别是菱形、圆形和正方形（见图 9.7(a)~(c)）. 当 $p\to\infty$ 时，$\ell^p$ 范数的区域形状逐渐趋近正方形.

若 $p<1$，例如 $p=\dfrac{1}{2}$，则 $\|\boldsymbol{v}\|_p=(x^p+y^p)^{1/p}$ 不构成范数：向量 $\boldsymbol{v}=(1,0)$ 和 $\boldsymbol{w}=(0,1)$ 的范数均为 1，但 $\boldsymbol{v}+\boldsymbol{w}$ 的范数为 $(1+1)^2=4$，这和三角不等式 $\|\boldsymbol{v}+\boldsymbol{w}\|\leqslant\|\boldsymbol{v}\|+\|\boldsymbol{w}\|$ 的要求矛盾. 因此 $\|\cdot\|_p$ 不是良定义的范数（见图 9.7(d)）.

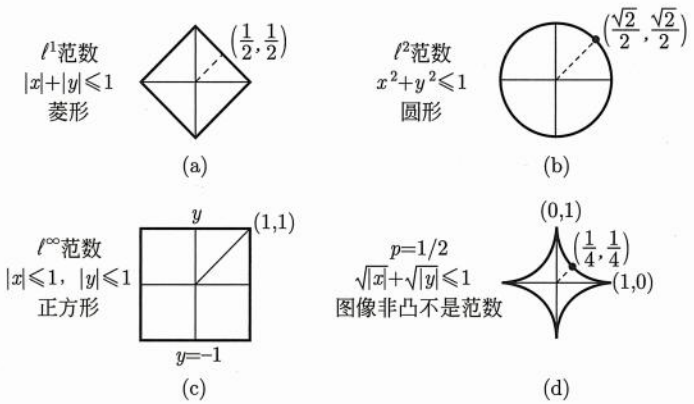


图 9.7 三种重要的向量范数以及 $p<1$ 时的反例

对于三维向量 $\boldsymbol{v}=\begin{bmatrix}x & y & z\end{bmatrix}^{\mathrm{T}}$，圆形变为球体 $x^2+y^2+z^2\leqslant1$，正方形 $\|\boldsymbol{v}\|_\infty\leqslant1$ 变为立方体 $-1\leqslant x,y,z\leqslant1$，菱形 $\|\boldsymbol{v}\|_1\leqslant1$ 变为 $|x|+|y|+|z|\leqslant1$ 定义的六个顶点的多面体. 当菱形扩大时，其尖角仍会首先接触三维空间中的直线或平面. 图 9.8 展示了这三种重要范数对应的最优向量 $\boldsymbol{v}^*$.

现在我们已经准备好在约束条件 $3x+4y=1$ 下最小化范数 $\|\boldsymbol{v}\|_1$、$\|\boldsymbol{v}\|_2$ 和 $\|\boldsymbol{v}\|_\infty$. 图 9.8 展示了这条约束线和三个最小值点，这些点的位置取决于所选择的范数. 我们将 $\|\boldsymbol{v}\|=r$ 的图形逐渐缩小（即不断减小 $r$），直到它们刚好与约束直线相接触. 这些接触点 $\boldsymbol{v}^*$ 就是 $\ell^1$、$\ell^2$ 和 $\ell^\infty$ 范数下对应的极小值点.

图 9.8(a) 展示了 $\ell^1$ 范数下最小化问题解决方案的一个重要特性：**最小值点 $\boldsymbol{v}^*=\begin{bmatrix}0 & \frac{1}{4}\end{bmatrix}^{\mathrm{T}}$ 仅包含一个非零分量.** 因此，向量 $\boldsymbol{v}^*$ 是**稀疏**的. 这种稀疏性源于**菱形和直线相交于尖点.** 直线（或三

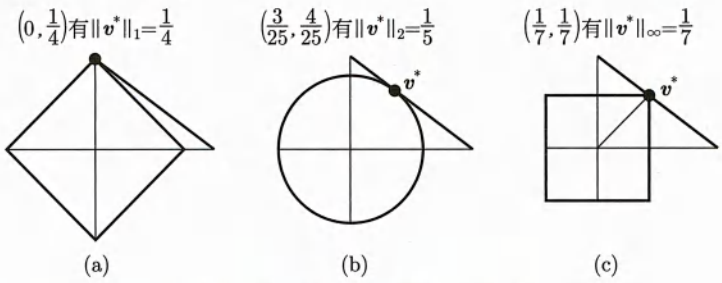


图 9.8　三种范数下的最小化问题

注：$\boldsymbol{v}^*$ 对应于 $\ell^1$、$\ell^2$ 以及 $\ell^\infty$ 的最小化问题. 第一种情形是稀疏的.

维空间中的平面，比如说 $3x+4y+5z=1$）包含了约束方程组 $\boldsymbol{Av}=\boldsymbol{b}$ 的解集. 三维空间中，多面体和该平面相交于角落的尖点 $(x,y,z)=\left(0,0,\dfrac{1}{5}\right)$！因此，最小值点 $\boldsymbol{v}=\begin{bmatrix}0 & 0 & \dfrac{1}{5}\end{bmatrix}^{\mathrm{T}}$ 有两个零元素.

这种稀疏性的关键在于，$\ell^1$ 问题的最优解通常只有少数非零元素，而这些非零元素通常具有实际的物理或数学意义. 相比之下，使用 $\ell^2$ 范数的最小二乘法之下的最优解在 $n$ 维空间中通常包含许多小的、无实际意义的元素. 由于这些小元素在计算 $\ell^2$ 距离时被平方，因此它们对总距离的贡献非常小.

考虑向量的$\ell^0$ 范数 ——其非零元素的数量，但这并不构成一个真正的数学意义上的范数. 只有当向量在 $x$ 轴或 $y$ 轴上，即只有一个非零元素时，其 $\ell^0$ 范数才等于 1. 如果令 $p=\dfrac{1}{2}$，那么图形将变得更加极端，仅在 $x$ 轴和 $y$ 轴上形成交叉或骨架形状.

显然，这种骨架形状并不是凸的. $\ell^0$ 范数实际上违反了范数的基本性质，例如 $\|2\boldsymbol{v}\|$ 应等于 $2\|\boldsymbol{v}\|$. 实际上，对于任何向量 $\boldsymbol{v}$，$2\boldsymbol{v}$ 的 $\ell^0$ 范数与 $\boldsymbol{v}$ 的 $\ell^0$ 范数相同，都等于 $\boldsymbol{v}$ 中非零元素的数量.

有趣的是，我们可以通过使用 $\ell^1$ 范数来找到一个满足 $\boldsymbol{Av}=\boldsymbol{b}$ 的稀疏解. 在这个过程中，我们实际上是将原本非凸的 $\ell^0$ 骨架（仅沿着坐标轴）转化为一个凸形状，即 $\ell^1$ 范数形成的菱形.

总而言之，这些向量问题突显了选择适当范数的重要性. 在第 10 章中，我们将讨论矩阵问题，并面临选择合适矩阵范数的问题. 届时，凸性将再次成为关键性质，它与矩阵范数的三角不等式 $\|\boldsymbol{A}+\boldsymbol{B}\|\leqslant\|\boldsymbol{A}\|+\|\boldsymbol{B}\|$ 密切相关.

### 9.3.1　拉格朗日乘数法——成本函数的偏导数

我们用拉格朗日乘数法重新解决 $\ell^2$ 范数下的最优化问题，因为该方法可推广至所有“二次规划”问题甚至“凸规划”问题. 拉格朗日乘数用于处理约束条件，其意义在于揭示乘数 $\lambda_1,\lambda_2,\cdots,\lambda_m$ 的含义. 引入并使用这些乘数后，弃之不用将是很愚蠢的.

以二维问题为例，设目标函数 $F$ 为二次函数，约束集 $K$ 是线性的.

问题：在直线 $K(a_1x_1+a_2x_2=b)$ 上最小化 $F(x)=x_1^2+x_2^2$.

在直线 $K$ 上，我们寻找距离原点 $(0,0)$ 最近的点. 成本函数 $F(x)$ 为距离平方. 图 9.9中，约束线与圆在点 $\boldsymbol{x}^*=(x_1^*,x_2^*)$ 处相切. 将约束方程 $a_1x_1+a_2x_2=b$ 代入 $F=x_1^2+x_2^2$ 之后，简单的

微积分即可求解.

$F(x)$ 减去未知乘数 $\lambda$ 和 $a_1x_1+a_2x_2-b$ 的乘积.
拉格朗日函数：$L(x,\lambda)=F(x)-\lambda(a_1x_1+a_2x_2-b)=x_1^2+x_2^2-\lambda(a_1x_1+a_2x_2-b)$.
令偏导数 $\partial L/\partial x_1,\partial L/\partial x_2$ 和 $\partial L/\partial\lambda$ 都等于 0.
解这个关于 $x_1$、$x_2$、$\lambda$ 的方程组. (9.32)

$$\partial L/\partial x_1=2x_1-\lambda a_1=0 \tag{9.33a}$$

$$\partial L/\partial x_2=2x_2-\lambda a_2=0 \tag{9.33b}$$

$$\partial L/\partial\lambda=-(a_1x_1+a_2x_2-b)=0 \quad (\text{约束条件}) \tag{9.33c}$$

由前两个方程得 $x_1=\frac{1}{2}\lambda a_1, x_2=\frac{1}{2}\lambda a_2$. 代入约束条件 $a_1x_1+a_2x_2=b$：

$$\frac{1}{2}\lambda a_1^2+\frac{1}{2}\lambda a_2^2=b \implies \lambda=\frac{2b}{a_1^2+a_2^2} \tag{9.34}$$

将 $\lambda$ 代入式(9.33a)和式(9.33b)，得到最近点 $(x_1^*,x_2^*)$ 及最小成本：

$$x_1^*=\frac{1}{2}\lambda a_1=\frac{a_1b}{a_1^2+a_2^2},\quad x_2^*=\frac{1}{2}\lambda a_2=\frac{a_2b}{a_1^2+a_2^2},\quad (x_1^*)^2+(x_2^*)^2=\frac{b^2}{a_1^2+a_2^2}$$

最小成本对约束水平 $b$ 的偏导数为拉格朗日乘数 $\lambda$：

$$\frac{\mathrm{d}}{\mathrm{d}b}\left(\frac{b^2}{a_1^2+a_2^2}\right)=\frac{2b}{a_1^2+a_2^2}=\lambda \tag{9.35}$$

接下来介绍对应于正定矩阵 $\boldsymbol{S}$ 的二次规划问题.

将上述问题从二维推广到 $n$ 维空间 $\mathbb{R}^n$. 约束条件从单个扩展为 $m$ 个：$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{x}=\boldsymbol{b}$，其中 $\boldsymbol{A}^{\mathrm{T}}$ 为 $m\times n$ 矩阵. 对应地，引入 $m$ 个拉格朗日乘数 $\lambda_1,\lambda_2,\cdots,\lambda_m$. 目标函数为 $F(x)=\frac{1}{2}\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}$，其中 $\boldsymbol{S}$ 为对称正定矩阵.

问题：在约束条件 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{x}=\boldsymbol{b}$ 下最小化 $\boldsymbol{F}=\frac{1}{2}\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}$. (9.36)

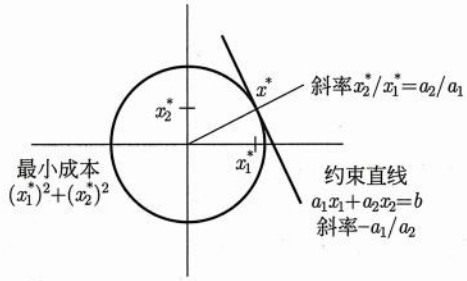


图 9.9 约束直线和最小成本圆在最优解处相切

$m$ 个约束条件导致 $m$ 个拉格朗日乘数：$\boldsymbol{\lambda}=\begin{bmatrix}\lambda_1 & \cdots & \lambda_m\end{bmatrix}$ 把约束条件 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{x}=\boldsymbol{b}$ 插入拉格朗

日函数 $L(\boldsymbol{x},\boldsymbol{\lambda})=\frac{1}{2}\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}-\boldsymbol{\lambda}^{\mathrm{T}}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{x}-\boldsymbol{b})$. 对 $\boldsymbol{x}$ 和 $\boldsymbol{\lambda}$ 的 $n+m$ 个变元求偏导，得到 $n+m$ 个方程：

$$\boxed{\begin{aligned}&\frac{\partial L}{\partial \boldsymbol{x}}=0 \qquad && \boldsymbol{S}\boldsymbol{x}-\boldsymbol{A}\boldsymbol{\lambda}=0\\ &\frac{\partial L}{\partial \boldsymbol{\lambda}}=0 && \boldsymbol{A}^{\mathrm{T}}\boldsymbol{x}=\boldsymbol{b}\end{aligned}} \tag{9.37}$$

由第一个方程得 $\boldsymbol{x}=\boldsymbol{S}^{-1}\boldsymbol{A}\boldsymbol{\lambda}$，代入第二个方程得 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}^{-1}\boldsymbol{A}\boldsymbol{\lambda}=\boldsymbol{b}$，解得最优乘数 $\boldsymbol{\lambda}^*$ 和最优解 $\boldsymbol{x}^*$：

$$\boldsymbol{\lambda}^*=(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}^{-1}\boldsymbol{A})^{-1}\boldsymbol{b},\quad \boldsymbol{x}^*=\boldsymbol{S}^{-1}\boldsymbol{A}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}^{-1}\boldsymbol{A})^{-1}\boldsymbol{b} \tag{9.38}$$

最小成本为 $F^*=\frac{1}{2}(\boldsymbol{x}^*)^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}^*=\frac{1}{2}\boldsymbol{b}^{\mathrm{T}}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}^{-1}\boldsymbol{A})^{-1}\boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}^{-1}\boldsymbol{S}\boldsymbol{S}^{-1}\boldsymbol{A}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}^{-1}\boldsymbol{A})^{-1}\boldsymbol{b}$. 千万不要被它吓坏了，其实可以极大地简化：

$$\boxed{\begin{aligned}&\text{最小成本} && F^*=\frac{1}{2}\boldsymbol{b}^{\mathrm{T}}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}^{-1}\boldsymbol{A})^{-1}\boldsymbol{b}\\ &\text{成本梯度} && \frac{\partial F^*}{\partial \boldsymbol{b}}=(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}^{-1}\boldsymbol{A})^{-1}\boldsymbol{b}=\boldsymbol{\lambda}^*\end{aligned}} \tag{9.39}$$

这是一类典型问题的数学模型. 需要注意，目标函数 $F(\boldsymbol{x})=\frac{1}{2}\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}-\boldsymbol{c}^{\mathrm{T}}\boldsymbol{x}$ 可以包含线性项，且部分文献会将 $\lambda$ 改为 $-\lambda$. 当约束变为 $m$ 个不等式 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{x}\leqslant\boldsymbol{b}$ 时，乘数需满足 $\lambda_i\geqslant 0$，并且问题难度陡然提高！若最优解中出现 $\lambda_i^*=0$，则表明第 $i$ 个约束条件 $\boldsymbol{a}_i^{\mathrm{T}}\boldsymbol{x}\leqslant b_i$ 未激活，移除该约束后最小值不变.

式(9.37) 可以用“鞍点矩阵”Karush-Kuhn-Tucker 矩阵改写：

$$\text{KKT 矩阵}\quad \boldsymbol{K}\begin{bmatrix}\boldsymbol{x}\\-\boldsymbol{\lambda}\end{bmatrix}=\begin{bmatrix}\boldsymbol{S}&\boldsymbol{A}\\\boldsymbol{A}^{\mathrm{T}}&\boldsymbol{0}\end{bmatrix}\begin{bmatrix}\boldsymbol{x}\\-\boldsymbol{\lambda}\end{bmatrix}=\begin{bmatrix}\boldsymbol{0}\\\boldsymbol{b}\end{bmatrix}. \tag{9.40}$$

此对称矩阵 $\boldsymbol{K}$ 未必正定或负定. 若用 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}^{-1}$ 左乘第一行 $\begin{bmatrix}\boldsymbol{S}&\boldsymbol{A}\end{bmatrix}$，得到 $\begin{bmatrix}\boldsymbol{A}^{\mathrm{T}}&\boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}^{-1}\boldsymbol{A}\end{bmatrix}$，再与第二块行相减：

$$\begin{bmatrix}\boldsymbol{S}&\boldsymbol{A}\\\boldsymbol{0}&-\boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}^{-1}\boldsymbol{A}\end{bmatrix}\begin{bmatrix}\boldsymbol{x}\\-\boldsymbol{\lambda}\end{bmatrix}=\begin{bmatrix}\boldsymbol{0}\\\boldsymbol{b}\end{bmatrix}. \tag{9.41}$$

这一过程别无其他，仅仅是对 $2\times 2$ 分块矩阵 $\boldsymbol{K}$ 的消元，(2,2) 位置的新块称为 Schur 补（以史上最伟大的线性代数学者命名）.

消元得到了相同方程 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}^{-1}\boldsymbol{A}\boldsymbol{\lambda}=\boldsymbol{b}$. 消元法无非是系统地解线性方程组的方法. 前 $n$ 个主元因 $\boldsymbol{S}$ 正定而大于 0，后 $m$ 个主元因 $-\boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}^{-1}\boldsymbol{A}$ 负定而小于 0. 此即**拉格朗日函数 $L(\boldsymbol{x},\boldsymbol{\lambda})$ 鞍点的明确标志.**

函数 $L=\frac{1}{2}\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}-\boldsymbol{\lambda}^{\mathrm{T}}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{x}-\boldsymbol{b})$ 关于 $\boldsymbol{x}$ 下凸，关于 $\boldsymbol{\lambda}$ 上凸.

### 9.3.2　极大值的极小值 = 极小值的极大值

关于这个问题，我们还能研究出更多的内容. 方程组式(9.37) 令 $L$ 关于 $\boldsymbol{x}$ 和 $\boldsymbol{\lambda}$ 的偏导数为零，此方程的解 $(\boldsymbol{x}^*,\boldsymbol{\lambda}^*)$ 是 $L=\frac{1}{2}\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}-\boldsymbol{\lambda}^{\mathrm{T}}(\boldsymbol{A}^{\mathrm{T}}-\boldsymbol{b})$ 的鞍点. 通过解方程组式 (9.37)，我们求出了成

本函数的极小值，并且在式(9.39)中得到了它的偏导数.

假设我们从两方面去思考这个问题：一个极大值问题和一个极小值问题. 首先对任意固定的 $\boldsymbol{\lambda}$，求 $L(\boldsymbol{x},\boldsymbol{\lambda})$ 的最小值；最小值点 $\boldsymbol{x}^*$ 取决于 $\boldsymbol{\lambda}$，所以记作 $\boldsymbol{x}^*(\boldsymbol{\lambda})$. 然后求 $L(\boldsymbol{x}^*(\boldsymbol{\lambda}),\boldsymbol{\lambda})$ 的极大值和极大值点 $\boldsymbol{\lambda}^*$.

（1）固定 $\boldsymbol{\lambda}$，$L$ 在 $\boldsymbol{x}^*=\boldsymbol{S}^{-1}\boldsymbol{A}\boldsymbol{\lambda}$ 处取得极小值，此时 $\min L=-\frac{1}{2}\boldsymbol{\lambda}^{\mathrm{T}}\boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}^{-1}\boldsymbol{A}\boldsymbol{\lambda}+\boldsymbol{\lambda}^{\mathrm{T}}\boldsymbol{b}$；

（2）$\min L$ 在 $\boldsymbol{\lambda}^*=(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}^{-1}\boldsymbol{A})^{-1}\boldsymbol{b}$ 处取得极大值 $L=\frac{1}{2}\boldsymbol{b}^{\mathrm{T}}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}^{-1}\boldsymbol{A})^{-1}\boldsymbol{b}$.

$$\boxed{\overset{\max}{\boldsymbol{\lambda}}\overset{\min}{\boldsymbol{x}}L=\frac{1}{2}\boldsymbol{b}^{\mathrm{T}}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}^{-1}\boldsymbol{A})^{-1}\boldsymbol{b}}$$

我们也可以反过来，先对任意固定的 $\boldsymbol{x}$，求 $L(\boldsymbol{x},\boldsymbol{\lambda})$ 的极大值和极大值点 $\boldsymbol{\lambda}^*(\boldsymbol{x})$，再求 $L(\boldsymbol{x},\boldsymbol{\lambda}^*(\boldsymbol{x}))$ 的极小值和极小值点. 事实上，关于 $\boldsymbol{\lambda}$ 的函数 $L(\boldsymbol{x},\boldsymbol{\lambda})$ 的极大值是

$$\begin{cases}+\infty, & \boldsymbol{A}^{\mathrm{T}}\boldsymbol{x}\neq\boldsymbol{b}\\ \frac{1}{2}\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}, & \boldsymbol{A}^{\mathrm{T}}\boldsymbol{x}=\boldsymbol{b}\end{cases}$$

从而该极大值的极小值也是 $\frac{1}{2}\boldsymbol{b}^{\mathrm{T}}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}^{-1}\boldsymbol{A})^{-1}\boldsymbol{b}$

$$\boxed{\overset{\min}{\boldsymbol{x}}\overset{\max}{\boldsymbol{\lambda}}L=\frac{1}{2}\boldsymbol{b}^{\mathrm{T}}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}^{-1}\boldsymbol{A})^{-1}\boldsymbol{b}}$$

总而言之，在鞍点 $(\boldsymbol{x}^*,\boldsymbol{\lambda}^*)$ 处，我们有 $\frac{\partial L}{\partial \boldsymbol{x}}=\frac{\partial L}{\partial \boldsymbol{\lambda}}=0$，而且 $\overset{\max}{\boldsymbol{\lambda}}\overset{\min}{\boldsymbol{x}}L=\overset{\min}{\boldsymbol{x}}\overset{\max}{\boldsymbol{\lambda}}L$.

### 9.3.3 二次规划：一般情形

接下来我们探讨应用和计算优化中的一个主要问题. 需要最小化的量仍然是一个以 $\frac{1}{2}\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}$ 为首的二次项. 约束条件仍然是线性的，不同之处在于，$\boldsymbol{S}$ 可能仅是半正定的，并且有些或所有的约束条件可能是不等式.

在这种情况下，拉格朗日乘子也遵循线性不等式！通常，要么是对 $\boldsymbol{x}$ 的约束，要么是对 $\boldsymbol{\lambda}$ 的约束，总有其一是紧的（意味着等式成立）. 而难点在于：我们不知道哪个不等式是紧约束. 哪怕是仅仅 10 对约束，我们也将面临 $2^{10}$ 种 $(\lambda=0)$ 或 $(\lambda>0)$ 的选择. 我们完全不想去挨个尝试这 1024 种可能性，事实上，如果我们正确地使用线性代数，也不必去尝试.

这个课题的参考书是 Wright 和 Nocedal 的优秀教科书《数值优化》. 最基本的二次规划问题是这样的：

| | | | |
|---|---|---|---|
| 最小化 | $q(x)=\frac{1}{2}\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}+\boldsymbol{x}^{\mathrm{T}}\boldsymbol{c}$ | | |
| 约束条件 | $\boldsymbol{a}_i^{\mathrm{T}}\boldsymbol{x}=\boldsymbol{b}_i$ | $i=1,2,\cdots,m$ | （方程） |
| | $\boldsymbol{a}_j^{\mathrm{T}}\boldsymbol{x}\geqslant\boldsymbol{c}_j$ | $j=1,2,\cdots,p$ | （不等式） |

当 $\boldsymbol{S}=\boldsymbol{S}^{\mathrm{T}}$ 半正定时，该问题是凸问题. 如果不是凸问题，那么可能有不止一个局部最小值.

如果只有 $\boldsymbol{Ax}=\boldsymbol{b}$ 一个等式约束，没有不等式约束，对 $\boldsymbol{x}$ 的 $m$ 个约束等式，引入拉格朗日乘数 $\lambda_1,\lambda_2,\cdots,\lambda_m$.

（1）拉格朗日函数为：$L=\dfrac{1}{2}\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}+\boldsymbol{x}^{\mathrm{T}}\boldsymbol{c}-\boldsymbol{\lambda}^{\mathrm{T}}(\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b})$.

（2）关于 $\boldsymbol{x}$ 偏导数给出方程 $\boldsymbol{S}\boldsymbol{x}^*-\boldsymbol{c}-\boldsymbol{A}^{\mathrm{T}}\boldsymbol{\lambda}^*=\boldsymbol{0}$.

（3）关于 $\boldsymbol{\lambda}$ 的偏导数给出方程组 $\boldsymbol{A}\boldsymbol{x}^*=\boldsymbol{b}$（即约束条件）.

构造和先前一样，这些方程组组合起来得到 KKT 矩阵——带约束条件的最优化问题的核心矩阵：

$$\boldsymbol{K}\begin{bmatrix}\boldsymbol{x}^*\\-\boldsymbol{\lambda}^*\end{bmatrix}=\begin{bmatrix}\boldsymbol{S}&\boldsymbol{A}^{\mathrm{T}}\\\boldsymbol{A}&\boldsymbol{0}\end{bmatrix}\begin{bmatrix}\boldsymbol{x}^*\\-\boldsymbol{\lambda}^*\end{bmatrix}=\begin{bmatrix}-\boldsymbol{c}\\\boldsymbol{b}\end{bmatrix}\tag{9.42}$$

许多读者在定义该问题时，会用 $-\boldsymbol{A}^{\mathrm{T}}$ 代替矩阵方程中的 $\boldsymbol{A}^{\mathrm{T}}$. Wright 和 Nocedal 指出，通过简单地重新表述问题，就可以得到式(9.42) 中的对称 KKT 矩阵，但这种矩阵并不是正定的，甚至不是半正定的.

至关重要的问题是：**何时 KKT 矩阵是可逆的？** 假设 $\boldsymbol{A}$ 秩为 $m$（行满秩，其含义是各约束是独立的），则

**当 $\boldsymbol{S}$ 正定时，$\boldsymbol{K}$ 可逆.**

然而，此时的 $\boldsymbol{S}$ 仅仅是半正定的，所以还需要用 $\boldsymbol{A}$ 保证 $\boldsymbol{K}$ 的前 $n$ 列线性无关. $\boldsymbol{A}$ 可以给 $\boldsymbol{S}$ 提供充分的援助，以确保 $\boldsymbol{S}$ 不可逆时 $\boldsymbol{K}$ 仍然可逆，关键的条件是：

**若矩阵 $\boldsymbol{N}$ 的列向量是 $\mathcal{N}(\boldsymbol{A})$ 的一组基，诱导矩阵 $\boldsymbol{N}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{N}$ 正定，则 $\boldsymbol{K}$ 可逆.**

因为 $\boldsymbol{N}$ 有 $n-m$ 列，所以 $\boldsymbol{N}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{N}$ 是 $n-m$ 阶方阵. 这一条件使得哪怕 $\boldsymbol{S}$ 列相关，$\boldsymbol{K}$ 的前 $n$ 列也线性无关. 证明如下：

假设 KKT 矩阵 $\boldsymbol{K}$**不可逆**，则存在非零向量 $\begin{bmatrix}\boldsymbol{w}\\\boldsymbol{v}\end{bmatrix}$ 使得：

$$\begin{bmatrix}\boldsymbol{S}&\boldsymbol{A}^{\mathrm{T}}\\\boldsymbol{A}&\boldsymbol{0}\end{bmatrix}\begin{bmatrix}\boldsymbol{w}\\\boldsymbol{v}\end{bmatrix}=\begin{bmatrix}\boldsymbol{0}\\\boldsymbol{0}\end{bmatrix}$$

那么 $\boldsymbol{A}\boldsymbol{w}=\boldsymbol{0}$，即 $\boldsymbol{w}\in\mathcal{N}(\boldsymbol{A})$，所以存在 $\boldsymbol{y}$ 使得 $\boldsymbol{w}=\boldsymbol{N}\boldsymbol{y}$，从而

$$0=\begin{bmatrix}\boldsymbol{w}\\\boldsymbol{v}\end{bmatrix}^{\mathrm{T}}\begin{bmatrix}\boldsymbol{S}&\boldsymbol{A}^{\mathrm{T}}\\\boldsymbol{A}&\boldsymbol{0}\end{bmatrix}\begin{bmatrix}\boldsymbol{w}\\\boldsymbol{v}\end{bmatrix}=\boldsymbol{w}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{w}=\boldsymbol{y}^{\mathrm{T}}\boldsymbol{N}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{N}\boldsymbol{y}.$$

由于我们假设矩阵 $\boldsymbol{N}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{N}$ 正定，所以 $\boldsymbol{y}=\boldsymbol{0}$，从而 $\boldsymbol{w}=\boldsymbol{0}$. 此外，由 $\boldsymbol{S}\boldsymbol{w}+\boldsymbol{A}^{\mathrm{T}}\boldsymbol{v}=\boldsymbol{0}$ 得 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{v}=\boldsymbol{0}$，我们又假设了 $\boldsymbol{A}$ 行满秩，所以 $\boldsymbol{v}=\boldsymbol{0}$. 总之，$\begin{bmatrix}\boldsymbol{w}\\\boldsymbol{v}\end{bmatrix}=\boldsymbol{0}$，矛盾.

### 9.3.4　不等式约束

我们最后来探讨既包含 $m$ 个等式约束 $\boldsymbol{a}_i^{\mathrm{T}}\boldsymbol{x}=\boldsymbol{b}_i$ 又包含 $p$ 个不等式约束 $\boldsymbol{a}_j^{\mathrm{T}}\boldsymbol{x}\leqslant\boldsymbol{c}_j$ 的问题. 在这个阶段，一个致命的问题浮现出来：**在问题的最优解 $\boldsymbol{x}^*$ 中，哪些不等式是起作用的（即“活跃”**

的)? 如果我们能预先知道这些“活跃”的约束，就可以将它们转换为等式，从而忽略那些“不活跃”的不等式. 但遗憾的是，在问题得到解决之前，我们无法分辨哪些是活跃约束，哪些不是.

下面是对一种在实践中比较成功的*活跃集方法*的简要描述：

在解题过程中，每一步我们都会维护一个包含当前的等式约束的“工作集”. 如果当前解 $\boldsymbol{x}_k$ 不能最小化这个工作集对应的二次函数，我们就会暂时忽略所有不在工作集中的约束，只解决这个简化后的子问题. 然后，我们尽可能地朝着这个子问题的解移动，直到遇到某个“阻塞约束”. 接着，我们将这个“阻塞约束”添加到新的工作集中，再次求解.

Wright 和 Nocedal 将这个简略的想法转化为一个高效的活跃集算法. 最终的工作集准确地识别出了那些在最优解处成为等式的活跃约束. 在线性规划的单纯形方法中，也会遇到类似的思想，即**每一步都沿着成本降低的方向前进，直到触碰到新的约束.**

### 9.3.5 科学与工程中的对偶问题

在物理和应用数学中，最小化满足线性约束 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{x}=\boldsymbol{b}$ 的二次函数 $\frac{1}{2}\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}$ 是一个核心问题，尤其是将线性微分方程离散化之后. 以下是工程领域的两个典型案例.

（1）**电路网络方程**.

**未知量**：节点电压、支路电流.

**方程**：基尔霍夫定律（节点电流平衡）.

**约束**：欧姆定律（电流与电压降成正比）.

**矩阵**：$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}^{-1}\boldsymbol{A}$ 为**电导矩阵**.

（2）**结构有限元方法**.

**未知量**：节点位移、结构应力.

**方程**：节点力平衡.

**约束**：应力-应变关系（弹簧的胡克定律）.

**矩阵**：$\boldsymbol{A}^{\mathrm{T}}S^{-1}A$ 为**刚度矩阵**.

在工程学的各个领域，我们都会遇到这类问题. 对于稳定的问题，刚度矩阵和电导矩阵通常都是对称正定矩阵. 而且，在大多数情况下，我们面临的约束条件是等式，而不是不等式. 针对这类物理问题的建模，数学领域提供了三种主要的方法：①蕴含刚度矩阵或电导矩阵 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}^{-1}\boldsymbol{A}$ 的线性方程组；②以电流或应力为未知量 $\boldsymbol{x}$ 的最小化问题；③以电压或位移为未知量 $\boldsymbol{\lambda}$ 的最大化问题.

最终，第①种方案——线性方程组——成为广泛采用的选择. 我们将方程组式(9.40)转化为方程组式(9.41). 电路网络方程综合了基尔霍夫定律和欧姆定律；结构方程则考虑了力的平衡以及材料的弹性特征；所有的电气和机械法则整合到被表示为 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}^{-1}\boldsymbol{A}$ 的最终系统中.

在处理流体流动问题时，我们经常会遇到方程组以鞍点形式出现的情况. 方程组中的未知数 $\boldsymbol{x}$ 和 $\boldsymbol{\lambda}$ 分别代表速度和压力. 关于其中的数值分析方法，Elman、Silvester 和 Wathen 的《有限元和快速迭代求解器》一书中有详细的介绍.

在处理电路网络方程和有限元方程时，我们通常会遇到电导矩阵和刚度矩阵 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{C}\boldsymbol{A}$. 关于这方面的内容，可以参考我的教科书《计算科学与工程》.

在统计学和线性回归中，我们通常会用到矩阵 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}\boldsymbol{A}$，其中 $\boldsymbol{\Sigma}$ 是协方差矩阵. 通过除以方差 $\sigma^2$，我们可以对噪声进行白化处理.

对于非线性问题，能量的表达式不再是二次型 $\frac{1}{2}\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}$. 在这种情况下，几何非线性会体现在矩阵 $\boldsymbol{A}$ 中，而材料非线性（通常较为简单）则会体现在矩阵 $\boldsymbol{S}$ 中. 大位移和大应力通常是导致非线性的主要原因.

## 习题 9.3

1. 对于约束线 $3x+4y=1$ 上的点 $\boldsymbol{v}=(x,y)$，找到最小化 $\|\boldsymbol{v}\|_p^p=|x|^p+|y|^p$ 的点 $\boldsymbol{v}_p^*=(x_p^*,y_p^*)$. 当 $p$ 从 1 增加到 $\infty$ 时，该点从 $\boldsymbol{v}_1^*=\left(0,\frac{1}{4}\right)$ 变化到 $\boldsymbol{v}_\infty^*=\left(\frac{1}{7},\frac{1}{7}\right)$.

2. 三角不等式 $\|\boldsymbol{v}+\boldsymbol{w}\|\leqslant\|\boldsymbol{v}\|+\|\boldsymbol{w}\|$ 成立的充要条件是单位球$\{\boldsymbol{v}:\|\boldsymbol{v}\|\leqslant 1\}$ 是凸集. 凸性的意思是，在球体内，对于任意两点 $\boldsymbol{v}_1$ 和 $\boldsymbol{v}_2$（它们的模长都不超过 1），连接这两点的直线段必须完全位于球体内. 凸性条件与三角不等式有直接的关联. 请证明此结论.

3. 设约束条件为 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{x}=\boldsymbol{x}_1+3\boldsymbol{x}_2=\boldsymbol{b}$. 最小化 $F(x)=\frac{1}{2}\boldsymbol{x}^{\mathrm{T}}\boldsymbol{S}\boldsymbol{x}=\frac{1}{2}x_1^2+2x_2^2$.

（1）写出拉格朗日函数 $L(\boldsymbol{x},\boldsymbol{\lambda})$；

（2）求解 $\boldsymbol{x}^*$ 与 $\boldsymbol{\lambda}^*$；

（3）参照图 9.8，绘制约束直线与成本圆相切的示意图；

（4）验证最小成本对 $b$ 的导数为 $\partial F^*/\partial b=\boldsymbol{\lambda}^*$.

4. 设约束条件为 $2x_1+x_2=5$. 最小化 $F(x)=\frac{1}{2}(x_1^2+4x_2^2)$，写出并求解三个方程 $\partial L/\partial x_1=0$、$\partial L/\partial x_2=0$ 与 $\partial L/\partial\lambda=0$，绘制约束直线与椭圆 $\frac{1}{2}(x_1^2+4x_2^2)=F_{\min}$ 在极小值点 $(x_1^*,x_2^*)$ 相切的示意图.

5. 通过消元法，式(9.40) 中的鞍点矩阵 $\boldsymbol{K}$ 可以被化为矩阵 $\boldsymbol{U}$. 下面的鞍点矩阵 $\boldsymbol{K}$ 有几个正的主元？有几个正特征值？

$$\boldsymbol{K}=\begin{bmatrix}\boldsymbol{S} & \boldsymbol{A}\\ \boldsymbol{A}^{\mathrm{T}} & \boldsymbol{0}\end{bmatrix}=\begin{bmatrix}1 & 0 & 1\\ 0 & 4 & 3\\ 1 & 3 & 0\end{bmatrix}\longrightarrow\boldsymbol{U}=\begin{bmatrix}\boldsymbol{S} & \boldsymbol{A}\\ \boldsymbol{0} & -\boldsymbol{A}^{\mathrm{T}}\boldsymbol{S}^{-1}\boldsymbol{A}\end{bmatrix}.$$

6. 对任何可逆的对称矩阵 $\boldsymbol{S}$，正的主元个数等于正特征值的个数. 这些主元出现在分解式 $\boldsymbol{S}=\boldsymbol{L}\boldsymbol{D}\boldsymbol{L}^{\mathrm{T}}$（其中 $\boldsymbol{L}$ 是上三角矩阵）中，而特征值则出现在分解式 $\boldsymbol{S}=\boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\mathrm{T}}$（其中 $\boldsymbol{Q}$ 是正交矩阵）中. 有一个巧妙的证明将 $\boldsymbol{L}$ 和 $\boldsymbol{D}$ 映射到 $\boldsymbol{Q}$ 和 $\boldsymbol{\Lambda}$. 特征值不会跨越零点：$\boldsymbol{D}$ 和 $\boldsymbol{\Lambda}$ 中的元素有相同的正负号.

对 $2\times 2$ 可逆对称矩阵 $\boldsymbol{S}$ 证明这个“惯性定律”：对任何 $2\times 2$ 可逆对称矩阵 $\boldsymbol{S}$，当 $\boldsymbol{S}$ 有 0 个、1 个或 2 个正的主元时，它也有 0 个、1 个或 2 个正的特征值.

（1）计算 $\boldsymbol{L}\boldsymbol{D}\boldsymbol{L}^{\mathrm{T}}=\boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\mathrm{T}}$ 的行列式，说明 $\det\boldsymbol{D}$ 和 $\det\boldsymbol{\Lambda}$ 有相同的正负号. 如果行列式为负，则 $\boldsymbol{S}$ 有_____ 个正特征值，有_____ 个正的主元.

（2）如果行列式是正的，那么 $\boldsymbol{S}$ 要么正定，要么负定. 证明：当 $\boldsymbol{S}$ 的特征值都是正数时，$\boldsymbol{S}$ 的主元也都是正数.

7. 先求 $F(\boldsymbol{x})=\frac{1}{2}(x_1^2+x_2^2+x_3^2)$ 在约束条件 $x_1+x_2+x_3=3$ 下的最小值，再求它在约束条件 $x_1+2x_2+3x_3=12$ 下的最小值. 解释为何第二个最小值更大. 这两个问题在 $\mathbb{R}^3$ 中有和球面相切的_____和_____.

8. 用线性不等式组 $\boldsymbol{Ax}\leqslant\boldsymbol{b}$ 描述正方形区域 $\{(x_1,x_2):|x_1|\leqslant 1,|x_2|\leqslant 1\}$，即求矩阵 $\boldsymbol{A}$ 和向量 $\boldsymbol{b}$.

## 9.4 线性规划、博弈论和对偶

本节讨论分段线性优化问题——不是二次问题. 标准线性规划问题的目标是最小化线性成本 $\boldsymbol{c}^{\mathrm{T}}\boldsymbol{x}$，约束条件为线性方程组 $\boldsymbol{Ax}=\boldsymbol{b}$，并要求 $\boldsymbol{x}\geqslant\boldsymbol{0}$（每个分量都大于或等于 0）. 正是这些不等式使得问题变得有趣. 我最喜欢的例子是后面将提到的最大流/最小割问题.

不等式约束 $x_k\geqslant 0$ 有两种状态——激活与非激活. 若最优解满足 $x_k^*>0$，则该约束条件未激活——它未改变结果，其拉格朗日乘数 $\lambda_k^*=0$. 此时最小成本不受该约束条件的影响. 但若约束条件 $x_k\geqslant 0$ 强制最优解为 $x_k^*=0$，则乘数 $\lambda_k^*>0$. 因此最优条件为：对每个 $k$，$x_k^*\lambda_k^*=0$.

此处我们将通过“对偶”视角，观察最小化问题与最大化问题——两个同时求解的线性规划. Dantzig 发明了单纯形算法来寻找最优解.

关于线性规划的另一点是：它可以解决所有的二人零和博弈. 一方的收益即另一方的损失. 博弈初始有一个支付矩阵 $\boldsymbol{A}$，规则非常简单：每一步，玩家 $R$ 选择 $\boldsymbol{A}$ 的一行，玩家 $C$ 选择一列（通常不会每轮选择相同策略——混合策略更优）. 随后 $R$ 向 $C$ 支付该行列交叉处的数值.

最优策略 $\boldsymbol{x}$ 和 $\boldsymbol{y}$（$R$ 的最小化策略，$C$ 的最大化策略）给出 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{Ay}$ 的鞍点. 三人博弈则完全不同，复杂得多.

### 9.4.1 线性规划

线性规划从成本向量 $\boldsymbol{c}=\begin{bmatrix}c_1 & \cdots & c_n\end{bmatrix}^{\mathrm{T}}$ 开始，目标是最小化成本函数 $F(\boldsymbol{x})=c_1x_1+c_2x_2+\cdots+c_nx_n=\boldsymbol{c}^{\mathrm{T}}\boldsymbol{x}$. 约束条件为 $m$ 个线性方程 $\boldsymbol{Ax}=\boldsymbol{b}$ 和 $n$ 个不等式 $x_1\geqslant 0,x_2\geqslant 0,\cdots,x_n\geqslant 0$. 简记为 $\boldsymbol{x}\geqslant\boldsymbol{0}$：

$$\text{线性规划问题}\qquad \boxed{\text{在约束条件}\quad \boldsymbol{Ax}=\boldsymbol{b}\quad\text{和}\quad \boldsymbol{x}\geqslant\boldsymbol{0}\quad\text{之下最小化}\quad \boldsymbol{c}^{\mathrm{T}}\boldsymbol{x}} \tag{9.43}$$

若 $\boldsymbol{A}$ 是 $1\times 3$ 矩阵，$\boldsymbol{Ax}=\boldsymbol{b}$ 给出三维空间中的平面，如 $x_1+x_2+2x_3=4$. 该平面被约束条件 $x_1\geqslant 0,x_2\geqslant 0,x_3\geqslant 0$ 截断，形成一个三角形区域，顶点为 $(4,0,0)$、$(0,4,0)$ 和 $(0,0,2)$. 问题是在此三角形区域 $K$ 中找到使成本 $\boldsymbol{c}^{\mathrm{T}}\boldsymbol{x}$ 最小的点 $\boldsymbol{x}^*$.

由于成本函数是线性的，其最小值出现在 $K$ 的顶点. 线性规划需找到该最小成本顶点 $\boldsymbol{x}^*$. 当 $m$ 和 $n$ 较大时，穷举所有顶点在计算上不可行. 因此，Dantzig 的单纯形法从一个满足 $\boldsymbol{Ax}=\boldsymbol{b}$ 和 $\boldsymbol{x}\geqslant\boldsymbol{0}$ 的初始顶点出发，沿三角形 $K$ 的边移动到另一（成本更低）顶点. 每一步成本 $\boldsymbol{c}^{\mathrm{T}}\boldsymbol{x}$ 均降低.

寻找最速下降边及下一顶点（边的终点）是线性代数问题. 单纯形法从一个顶点到另一顶点不断重复此步骤.

单纯形法步骤：初始顶点 $\longrightarrow$ 新最速边 $\longrightarrow$ 新低成本顶点. 每步都让成本 $\boldsymbol{c}^{\mathrm{T}}\boldsymbol{x}$ 降低，当顶点达到最小成本时即停止.

我们首先关注对偶问题——以 $\mathbb{R}^m$ 中的向量 $\boldsymbol{y}$ 为变量的最大化问题. 通常用 $\boldsymbol{y}$ 而非 $\boldsymbol{\lambda}$ 表示对偶变量（拉格朗日乘数）：

$$\text{对偶问题} \qquad \boxed{\text{在约束条件}\quad \boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}\leqslant\boldsymbol{c}\quad\text{之下最大化}\quad \boldsymbol{y}^{\mathrm{T}}\boldsymbol{b}} \tag{9.44}$$

这是单纯形法需解决的另一个线性规划，输入同为 $\boldsymbol{A}$、$\boldsymbol{b}$、$\boldsymbol{c}$. 当 $\boldsymbol{A}$ 为 $m\times n$ 矩阵时，$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}\leqslant\boldsymbol{c}$ 包含 $n$ 个约束不等式. 一个奇妙的事实是：最大化问题中的 $\boldsymbol{y}^{\mathrm{T}}\boldsymbol{b}$ 永不超过最小化问题中的 $\boldsymbol{c}^{\mathrm{T}}\boldsymbol{x}$:式(9.44) 中 $\boldsymbol{y}^{\mathrm{T}}\boldsymbol{b}$ 的最大值 $\leqslant$ 式(9.43) 中 $\boldsymbol{c}^{\mathrm{T}}\boldsymbol{x}$ 的最小值

$$\text{弱对偶性} \qquad \boldsymbol{y}^{\mathrm{T}}\boldsymbol{b}=\boldsymbol{y}^{\mathrm{T}}(\boldsymbol{A}\boldsymbol{x})=(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y})^{\mathrm{T}}\boldsymbol{x}\leqslant\boldsymbol{c}^{\mathrm{T}}\boldsymbol{x} \tag{9.45}$$

最大化推动 $\boldsymbol{y}^{\mathrm{T}}\boldsymbol{b}$ 增长，最小化推动 $\boldsymbol{c}^{\mathrm{T}}\boldsymbol{x}$ 减小. 对偶定理（极小极大定理）表明它们在最优解 $\boldsymbol{x}^*$ 和 $\boldsymbol{y}^*$ 处相等.

$$\boxed{\text{对偶性定理}\qquad \text{式(9.44) 中的 } \boldsymbol{y}^{\mathrm{T}}\boldsymbol{b}\text{ 的最大值}\leqslant\text{式(9.43) 中的 } \boldsymbol{c}^{\mathrm{T}}\boldsymbol{x}\text{ 的最小值}}$$

单纯形法可同时求解这两个问题. 多年来该方法无可匹敌，但如今新算法通过直接穿越可行区域内部（而非沿边移动）与之竞争. 内点法因为可以使用微积分实现最速下降而具有竞争力.

现状是两种方法（沿边或内部）的比拼非常焦灼，都有可能胜出.

线性规划与单纯形法的关键点如下：

（1）满足 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$ 的向量集被平面 $x_i\geqslant 0$ 截断；

（2）最小成本 $\boldsymbol{c}^{\mathrm{T}}\boldsymbol{x}$ 出现在可行集 $K$ 的顶点；

（3）单纯形法沿 $K$ 的边界从顶点移动到顶点；

（4）当所有边均使 $\boldsymbol{c}^{\mathrm{T}}\boldsymbol{x}$ 增加时，算法停止，该点即最优顶点.

### 9.4.2　在线示例

本书外版网站提供了一个示例：要解决 4 个难题，某博士、朋友和计算机每小时分别收费 \$5、\$3、\$8，他们工作 $x_1$、$x_2$、$x_3$ 小时，每小时分别解决 1、1、2 个问题.

约束条件为：$\boldsymbol{A}\boldsymbol{x}=x_1+x_2+2x_3=4$ 和 $\boldsymbol{x}\geqslant\boldsymbol{0}$，目标是：最小化成本 $\boldsymbol{c}^{\mathrm{T}}\boldsymbol{x}=5x_1+3x_2+8x_3$.

平面 $\boldsymbol{A}\boldsymbol{x}=4$ 在坐标轴上的截点为 $(4,0,0)$、$(0,4,0)$ 和 $(0,0,2)$，即全由博士、朋友或计算机解决的三种极端情况. 其中一个顶点即最优解！

此例中可计算三个顶点的成本. 在实际问题中，单纯形法通过让某个 $x_i$ 降为 0 而另一 $x_i$ 从 0 增加，移动到更低成本顶点. 对偶性在最终获胜顶点处成立.

### 9.4.3　最大流-最小割

这是一个特殊的线性规划问题. 矩阵 $\boldsymbol{A}$ 是某个图的关联矩阵. 方程组 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}=\boldsymbol{0}$ 意味着每个节点的流入等于流出. 图的每条边有容量约束 $M_j$——该边上的流量 $y_j$ 不可超过此限制.

最大化问题要求从源节点 $s$ 到汇节点 $t$ 输送可能的最大流量. 此流量通过一条无限容量的特殊边从 $t$ 返回到 $s$（见图 9.10）. 对 $\boldsymbol{y}$ 的约束包括基尔霍夫电流定律 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}=\boldsymbol{0}$ 和图 9.10 上每条边的

容量限制 $|y_j| \leqslant M_j$. 此例的妙处在于（对于小型图）可通过直觉求解，在此过程中发现并求解对偶的最小割问题——寻找**容量最小的“最小割”**.

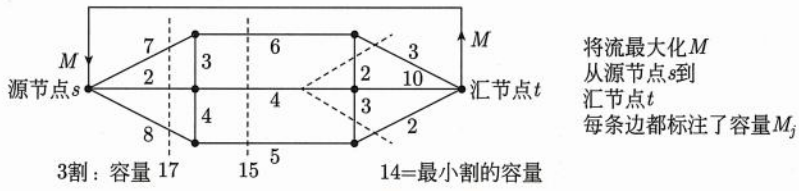


图 9.10 最大流和最小割

注：最大流 $M$ 被所有割 (虚线的分割线) 的容量所限制. 根据对偶原理，**最小割的容量等于最大流的容量**. 对于此例，$M = 14$.

首先从源节点发送流量. 从 $s$ 出发的三条边容量为 $7+2+8=\mathbf{17}$. 是否存在比 $M \leqslant 17$ 更严格的限制?

存在！仅通过三条中间边的割容量为 $6+4+5=\mathbf{15}$，因此 17 无法到达汇节点. 是否存在比 $M \leqslant 15$ 更严格的限制?

存在！通过后续五条边的割容量为 $\mathbf{3+2+4+3+2=14}$，总流量 $M$ 不能超过 14. 此流量 14 是否可达汇节点？此割是否最紧?

**是的，14 即为最小割**（这是一个 $\ell^1$ 范数的问题！）. 根据对偶性，**14 也是最大流.**

维基百科列出了解决此重要问题的快速算法. 该问题有许多应用. 若容量 $M_j$ 为整数，最优流量 $y_j$ 也为整数. 通常整数规划更为困难，但此处例外.

特殊最大流问题中所有容量 $M_j = 1$ 或 0. 对应的图为**二分图**（见图 9.11）（顶点可以分成两部分，各部分内部没有边，所有边从第一部分的节点指向第二部分）. 我们将第一部分的人与第二部分的职位匹配（每人至多一个职位，每职位至多一人）. 此时最大匹配 $M$ 即为图 9.11中的最大流 = 最大匹配数.

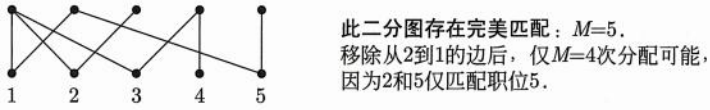


图 9.11 二分图

对于二分图，最大流 = 最小割这个结论即柯尼格定理与霍尔婚姻定理.

### 9.4.4 二人博弈

三人及以上博弈极难求解. 玩家群体可能结盟对抗他人，新团队经常会形成，且联盟不稳定. 约翰·纳什在此取得突破性进展并获诺贝尔经济学奖. 而二人零和博弈早已被冯·诺依曼完全解决. 我们将看到其与线性规划及对偶性的紧密联系. **博弈规则如下：**

玩家为 $R$ 和 $C$，给定支付矩阵 $\boldsymbol{A}$. 每轮 $R$ 选择一行，$C$ 选择一列. 该行列交叉处的数值即为 $R$ 支付给 $C$ 的金额. 随后双方进行下一轮.

$R$ 希望将支付最小化，$C$ 希望将之最大化. 以下是一个小型支付矩阵，$R$ 可选两行，$C$ 可选三列：

支付矩阵

| | $y_1$ | $y_2$ | $y_3$ |
|---|---|---|---|
| $x_1$ | 1 | 0 | 2 |
| $x_2$ | 3 | −1 | 4 |

$C$ 偏好第三列的大数值. $R$ 则发现该列最小数为 2（第一行）. 双方没有理由放弃这个简单策略：$C$ 选第三列，$R$ 选第一行. 每轮支付金额恒为 2.

2在其列中最小，在其行中最大.

这个位置就是鞍点. $C$ 无法期望收益超过 2，$R$ 无法期望损失低于 2. 最优策略 $x^*$ 和 $y^*$ 非常明确：$R$ 选第一行，$C$ 选第三列.

但若修改第三列的数值，双方则需重新思考策略.

新支付矩阵

| | $y_1$ | $y_2$ | $y_3$ |
|---|---|---|---|
| $x_1$ | 1 | 0 | 4 |
| $x_2$ | 3 | −1 | 2 |

$R$ 偏好第二列的小额有利数值，但 $C$ 绝不会选此列. 第三列对 $C$ 最有利（数值最大），而 $R$ 应选择第二行以避免支付 4. 此时对 $C$ 而言，第一列收益 3 优于第三列收益 2.

可见 $C$ 仍倾向于第三列，但必须偶尔选择第一列. $R$ 需采用混合策略：以概率 $x_1$ 和 $x_2$ 选择第一行和第二行. 每次选择需不可预测，否则对方将利用此规律. 故 $R$ 的决策为满足 $x_1 + x_2 = 1$ 的概率分布：

| | | | |
|---|---|---|---|
| 第一行 | 1 | 0 | 4 |
| 第二行 | 3 | −1 | 2 |
| $x_1 \cdot$第一行 $+ x_2 \cdot$第二行 | $x_1 + 3x_2$ | $-x_2$ | $4x_1 + 2x_2$ |

$R$ 将选择比例 $x_1$ 和 $x_2$ 使得最坏（最大）支付尽量小. 考虑到 $x_2 = 1 - x_1$，当两个最大支付相等时达到最优：

$$x_1 + 3x_2 = 4x_1 + 2x_2 \quad \Rightarrow \quad x_1 + 3(1 - x_1) = 4x_1 + 2(1 - x_1)$$

解得 $x_1^* = \dfrac{1}{4}$，$x_2^* = \dfrac{3}{4}$. 新混合行策略的支付为 2.5、−0.75、2.5.

类似地，$C$ 将以概率 $y_1$、$y_2$、$y_3$ 选择三列，且 $y_1 + y_2 + y_3 = 1$. 混合策略将三列组合为新列：

| 第一列 | 第二列 | 第三列 | 混合 |
|---|---|---|---|
| 1 | 0 | 4 | $y_1 + 4y_3$ |
| 3 | −1 | 2 | $3y_1 - y_2 + 2y_3$ |

$C$ 将选择比例 $y_1+y_2+y_3=1$ 使得最坏（最小）支付尽量大. 当 $y_2=0$ 且 $y_3=1-y_1$ 时，两个混合支付相等：

$$y_1+4(1-y_1)=3y_1+2(1-y_1) \quad \Rightarrow \quad -3y_1+4=y_1+2 \quad \Rightarrow \quad y_1^*=y_3^*=\frac{1}{2}$$

**新混合列策略的支付均为 2.5. 此最优策略确定博弈值为 2.5.** 采用混合策略 $x_1^*=\frac{1}{4}$，$x_2^*=\frac{3}{4}$，玩家 $R$ 确保支付不超过 2.5；玩家 $C$ 可确保收益不低于 2.5. 我们找到了鞍点（最优混合策略），双方支付均为 2.5.

冯·诺依曼的**极大值最小化定理**给出了所有支付矩阵的解，它也等价于线性规划中的对偶定理 $\min \boldsymbol{c}^{\mathrm{T}}\boldsymbol{x}=\max \boldsymbol{y}^{\mathrm{T}}\boldsymbol{b}$.

### 9.4.5 半定规划

仍然考虑（线性）成本函数 $\boldsymbol{c}^{\mathrm{T}}\boldsymbol{x}$ 最小化的问题. 但对 $\boldsymbol{x}$ 的约束涉及对称矩阵 $\boldsymbol{S}$. 给定 $\boldsymbol{S}_0,\boldsymbol{S}_1,\cdots,\boldsymbol{S}_n$，要求 $\boldsymbol{S}(\boldsymbol{x})=\boldsymbol{S}_0+x_1\boldsymbol{S}_1+\cdots+x_n\boldsymbol{S}_n$ 半正定（或正定）. 幸运的是，$\boldsymbol{x}$ 的约束集仍是凸集——两个半定矩阵的平均值仍半定（因为能量也是两个半正定矩阵的平均值）.

此时 $\boldsymbol{x}$ 的约束集的边界可能是曲面边而非平面：

$$\text{当 } x_1\geqslant 0 \text{ 且 } x_1x_2\geqslant 1 \text{ 时，矩阵} \boldsymbol{S}_0+x_1\boldsymbol{S}_1+x_2\boldsymbol{S}_2=\begin{bmatrix} x_1 & 1 \\ 1 & x_2 \end{bmatrix} \text{ 半正定.}$$

可通过引入变量 $t$ 找出 $\boldsymbol{S}(\boldsymbol{x})$ 的最大特征值的最小值：

$$\text{求最小的} t \text{ 使得} t\boldsymbol{I}-\boldsymbol{S}(\boldsymbol{x}) \text{ 半正定}$$

对此类及多数半定问题，内点法是最好的. 本质上，每次迭代都在求解最小二乘问题——通常需 $5\sim 50$ 次迭代.

与线性规划类似，半定规划（Semidefinite Programming，SDP）也有**对偶问题**（最大化）. 对偶问题的值永不超过原问题的值 $\boldsymbol{c}^{\mathrm{T}}\boldsymbol{x}$. 我们也希望对偶问题中的最大值与在原问题中的最小化值这两者相等. 但对于含矩阵不等式的半定规划，可能做不到.

SDP 为先前看似困难的矩阵问题提供了解决方法.

## 习题 9.4

1. 在弱对偶方程式(9.45)中，约束条件 $\boldsymbol{x}\geqslant \boldsymbol{0}$ 是必要的吗？不等式 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}\leqslant \boldsymbol{c}$ 是否已经足以证明 $\left(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{y}\right)^{\mathrm{T}}\boldsymbol{x}\leqslant \boldsymbol{c}^{\mathrm{T}}\boldsymbol{x}$？（提示：答案为否.）

2. 假设约束条件为 $x_1+2x_2+2x_3=4$ 且 $x_1\geqslant 0,x_2\geqslant 0,x_3\geqslant 0$，该约束区域形成一个三角形，请在 $\boldsymbol{R}^3$ 中确定该三角形的三个顶点. 成本函数 $\boldsymbol{c}^{\mathrm{T}}\boldsymbol{x}=5x_1+3x_2+8x_3$ 在哪个顶点取到最小值？

3. 在习题 2 的对偶问题中，关于 $\boldsymbol{y}$ 的最大问题是什么？原问题中的一个约束条件对应于对偶问题中的一个未知数 $\boldsymbol{y}$. 请求解该对偶问题.

4. 假设约束条件为 $\boldsymbol{x}\geqslant 0$，$x_1+2x_3+x_4=4$，以及 $x_2+x_3-x_4=2$. 四个未知数由两个等式约束，所以像 $\boldsymbol{x}=(0,6,0,4)$ 这样的顶点有 $4-2=2$ 个分量为零. 请决定另一个顶点 $\boldsymbol{x}=(x_1,x_2,0,0)$，并说明此点处的成本高于第一个顶点.

5. 对下述两个支付矩阵，确定 $R$ 的行最优（最小化）策略，以及 $C$ 的列最优（最大化）策略. 在极大值取最小值的点 $(\boldsymbol{x}^*, \boldsymbol{y}^*)$，每一局游戏 $R$ 支付给 $C$ 多少钱：

支付矩阵　$\begin{bmatrix} 1 & 2 \\ 4 & 8 \end{bmatrix}$　　$\begin{bmatrix} 1 & 4 \\ 8 & 1 \end{bmatrix}$

6. 对反对称支付矩阵（满足 $\boldsymbol{A}^{\mathrm{T}} = -\boldsymbol{A}$），当极大支付的极小值等于零时，为什么博弈对 $R$ 和 $C$ 是公平的？

7. 设支付矩阵为对角矩阵 $\boldsymbol{\Sigma}$，且其对角元满足 $\sigma_1 > \sigma_2 > \cdots > \sigma_n$. 对于玩家 $R$ 和玩家 $C$ 来说，什么策略是最佳的？

8. 将 $\ell^1$-范数下的约束条件 $\left\| \begin{bmatrix} x_1 & x_2 & x_3 \end{bmatrix}^{\mathrm{T}} \right\|_1 \leqslant 2$ 转化为八个线性不等式 $\boldsymbol{A}\boldsymbol{x} \leqslant \boldsymbol{b}$. 同理 $\ell^\infty$-范数下的约束条件 $\|\boldsymbol{x}\| \leqslant 2$ 同样也可转化为八个线性不等式.

9. 在 $\ell^2$-范数下，$\|\boldsymbol{x}\| \leqslant 2$ 是一个二次不等式 $x_1^2 + x_2^2 + x_3^2 \leqslant 4$. 但在半定规划中，这变成了一个矩阵不等式 $\boldsymbol{X}\boldsymbol{X}^{\mathrm{T}} \leqslant 4\boldsymbol{I}$. 为什么约束条件 $\boldsymbol{X}\boldsymbol{X}^{\mathrm{T}} \leqslant 4\boldsymbol{I}$ 等价于 $\boldsymbol{x}^{\mathrm{T}}\boldsymbol{x} \leqslant 4$？

10. 设关于 $x_1, x_2, \cdots, x_n$ 的约束条件为 $\boldsymbol{A}\boldsymbol{x} \leqslant \boldsymbol{b}$，且 $\boldsymbol{x} \geqslant \boldsymbol{0}$（即每个 $x_i \geqslant 0$）. 如果两个向量 $\boldsymbol{x}$ 和 $\boldsymbol{X}$ 满足上述条件，证明：它们的平均 $\boldsymbol{M} = \frac{1}{2}\boldsymbol{x} + \frac{1}{2}\boldsymbol{X}$ 也满足该条件，即约束集 K 是凸的.

注记：对偶性给我们提供了一个重要备选方案——求解原问题，也可求解对偶问题. 这样的思路适用于机器学习中的优化.

# 第 10 章

CHAPTER 10

# 数 据 学 习

深度学习的训练集是一系列输入 $\boldsymbol{v}$ 及其对应的输出 $\boldsymbol{w}$ 的集合. 每个输入都是以 $v_1, v_2, \cdots, v_p$ 为分量的向量（即该输入的“表征”[①]）. 每个输出都是以 $w_1, w_2, \cdots, w_q$ 为分量的向量（即该输出的“类型”）. 学习函数 $F(\boldsymbol{x}, \boldsymbol{v})$ 的自变量包含“权重” $\boldsymbol{x}$，它的形式是预先选定的，要求 $F(\boldsymbol{x}, \boldsymbol{v})$ 非常接近（或等于）$\boldsymbol{w}$.

选取优秀的训练方式和合适的权重，将函数 $F$ 应用于来自统计的相似数据，但是并未出现于原始数据集的**测试数据** $\boldsymbol{V}$. 如果 $F(\boldsymbol{x}, \boldsymbol{V})$ 接近于该测试数据的正确输出 $\boldsymbol{W}$——学习函数 $F$ 未曾见过的情况，那么该学习模型就取得了成功.

10.1 节描述了 $L$ 个函数 $F_L(F_{L-1}(\cdots(F_2(F_1))))$ 的复合构成的学习函数 $F(\boldsymbol{x}, \boldsymbol{v})$. 每个函数 $F_k$ 都有自己的权重 $\boldsymbol{x}_k$. 这些权重包括一个矩阵 $\boldsymbol{A}_k$ 和一个向量 $\boldsymbol{b}_k$. $F_k$ 的输入是 $F_{k-1}$ 的输出 $\boldsymbol{v}_{k-1}$. $F_k$ 的线性分块使用权重来构建 $\boldsymbol{A}_k\boldsymbol{v}_{k-1} + \boldsymbol{b}_k$. 我们对这个向量的每个分量引入一个非线性的“激活函数”. 一个简单且成功的选择是

$$\mathrm{ReLU}(y) = \max(y, 0) = \begin{cases} y, & y \geqslant 0 \\ 0, & y \leqslant 0 \end{cases}$$

对 $\boldsymbol{A}_k\boldsymbol{v}_{k-1} + \boldsymbol{b}_k$ 的每个分量都使用 ReLU，则有 $\boldsymbol{v}_k = F_k(\boldsymbol{v}_{k-1})$. $\boldsymbol{v}_k$ 处于第 $k$ 层，是函数链中下一个函数 $F_{k+1}$ 的输入（当然还有其自身的权重 $\boldsymbol{A}_{k+1}$ 和 $\boldsymbol{b}_{k+1}$）.

请注意，ReLU 是分段线性函数（两段），$\boldsymbol{v}_k$ 的每个分量也是分段线性函数. 10.1 节将尝试计算第一个函数 $\boldsymbol{v}_1 = F_1(\boldsymbol{v}_0)$ 和函数链中的函数 $\boldsymbol{v}_L = F(\boldsymbol{v}_0)$. 10.2 节描述了一个用于实验的神奇网站.

### 1. 泛化：深度学习在新数据上有效的原因

深度学习的一个核心问题是**泛化**. 泛化指的是神经网络在未见过的测试数据上的表现. 如果我们构造了一个函数 $F(\boldsymbol{x}, \boldsymbol{v})$，能够成功地分类已知的训练数据，那么当输入不属于训练集时，$F$ 是否还能给出正确的结果？

答案依赖于选择权重的随机梯度下降算法（第 9 章）. 这些权重 $\boldsymbol{x}$ 最小化了训练数据上的损失函数 $L(\boldsymbol{x}, \boldsymbol{v})$. 但问题是：**来自计算的权重为何在测试数据上表现如此优秀？**

通常情况下，$\boldsymbol{x}$ 中的自由参数比 $\boldsymbol{v}$ 中的数据点多. 在这种情况下，我们可以预期有很多权重集

① 译者注：此处“表征”是 feature 的翻译，包括 feature vector 也被翻译为表征向量. 单纯从中文来说，feature 翻译成“特征”可能更合适，但是“feature vector”如果翻译成“特征向量”明显就太有歧义了，尽管它的确表示的是“表达数据特征点的向量”. 这是我们折中选择翻译为“表征”的原因.

合（很多向量 $\boldsymbol{x}$）在训练集上同样准确. 这些权重可能好也可能坏. 泛化的表现可能很好，也可能很差. 我们的算法选择了一个特定的 $\boldsymbol{x}$，并将这些权重应用于新的测试数据 $\boldsymbol{V}$.

一项不同寻常的实验产生了意想不到的正面效果. 每个输入向量 $\boldsymbol{v}$ 的分量随机打乱，那么 $\boldsymbol{v}$ 所代表的个体表征突然之间失去了意义. 尽管如此，深度神经网络还是学会了这些随机化的样本.

### 2. 数据中的模式

本书的这一部分是一个很大的冒险——对读者来说可能是，但对作者来说绝对是极大的挑战；它涉及整个思维和智能的科学. 你可以称之为机器学习（ML）或人工智能（AI）. 是人类智能创造了它（尽管我们并不完全理解我们做了什么事情）. 我们尝试模仿大脑中的神经元，在经历过一些想法和失败之后，一种成功的方法已经浮现出来，用于寻找数据中的模式.

理解深度学习的重点是对数据进行拟合计算. 由于其规模之大几乎史无前例，所以一般来说拟合有极大的困难. 训练数据中有许多关键点，但在深度网络中要计算的权重可能更多. 深度学习的艺术在于在许多可能的解决方案中找到一种能够在新的数据上泛化的方案.

一个显著的观察是，具有许多权重的深度神经网络上的学习取得了非常成功的结果：$F$ 在训练集和未见测试集上都是准确的. 而学习函数 $F(\boldsymbol{x},\boldsymbol{v})$ 中的良好的权重 $\boldsymbol{x}$ 的计算则依赖于第 9章的关键算法——随机梯度下降.

## 10.1　分段线性学习函数

假设一个正方形内画着数字 $0\sim9$ 中的一个. 人如何识别出这个数字呢？这个神经科学问题此处无法回答. 计算机如何识别出这个数字呢？这是一个机器学习问题. 但也许两个问题都始于同一个想法：从例子中学习.

我们从 $M$ 个不同的图片（训练集）开始. 每个图片都是 $p$ 个一组的小像素——或者说是一个向量 $\boldsymbol{v}=\begin{bmatrix}v_1 & v_2 & \cdots & v_p\end{bmatrix}^{\mathrm{T}}$. 分量 $v_i$ 代表图片中第 $i$ 个像素的“灰度”：该像素多暗或多亮（或者对于彩色图像来说是红色 -绿色 -蓝色）. 所以我们有 $M$ 个图片，每个都有 $p$ 个表征，于是就得到了 $p$ 维空间中的 $M$ 个向量 $\boldsymbol{v}$. 对于训练集中的每个 $\boldsymbol{v}$，我们都知道它每个分量的数字.

在某种程度上，我们得到了一个函数：给定 $\mathbb{R}^p$ 中的 $M$ 个输入，每个输入对应 $0\sim9$ 中的一个输出；但我们没有“规则”.[①]面对新的输入，我们束手无策. 机器学习试图创建一个在（大多数）训练图片上成功的规则. 但是“成功”的意义远不止于此：该规则应该为更广泛的、来自同一采样群体的测试图片集给出正确的数字. 这个基本要求被称为泛化.

规则应该采取什么形式？这是我们面临的第一个基本问题. 第一个可行的回答可能是：$F(\boldsymbol{v})$ 是从 $\mathbb{R}^p$ 到 $\mathbb{R}^{10}$ 的线性函数（即一个 $10\times p$ 矩阵）. $M$ 个输入 $\boldsymbol{v}$ 是来自训练集样本的、代表 $p$ 个表征的 $p$ 维向量. 10 个输出是数字 $0\sim9$ 的概率.

这样做的困难在于：线性的局限性太大了. 比如说，两个 0 可以组成一个 8，而图片不会相加. 在识别面孔而不是数字时，我们将需要更多的像素——从 $F$ 的输入-输出规则来看，这远远不是线性的.

① 译者注：所以我们只能说“某种程度上得到一个函数”，函数的本质就是要设定规则.

人工智能停滞了一代，等待新想法的涌现. 没有任何人可以声称现在已经找到了最好的函数类. 这样的类需要大量的参数（称为权重），并且它必须在合理的时间内从训练集的知识中计算出所有这些权重.

超出大家预期并大获成功的选择是连续的分段线性（CPL）函数，它将浅层学习转变为深度学习. **线性**是为了简单，**连续**是为了模拟一个未知但合理的规则，**分段**是为了实现对于真实图像和数据来说是绝对必要的非线性.

这接下来就是可计算性的关键问题. 哪些参数能够快速地描述大量 CPL 函数？在估计微分方程时，有限元方法从三角形网格开始. 但是在 $\mathbb{R}^p$ 中指定许多单个节点代价太大. 如果这些节点是更少数量的线（或超平面）的交点那就好一些，但是规则的网格太简单了.

以下是数据向量 $\boldsymbol{v}$ 的分段线性函数的第一种构造方式. 选定矩阵 $\boldsymbol{A}_1$ 和向量 $\boldsymbol{b}_1$，然后令 $\boldsymbol{A}_1\boldsymbol{v}+\boldsymbol{b}_1$ 的所有负的分量为零（这是非线性的 ReLU 的步骤）. 然后乘以一个矩阵 $\boldsymbol{A}_2$ 以产出 $\boldsymbol{w}=F(\boldsymbol{v})=\boldsymbol{A}_2(\mathrm{ReLU}(\boldsymbol{A}_1\boldsymbol{v}+\boldsymbol{b}))$ 的 10 个输出. 向量 $\mathrm{ReLU}(\boldsymbol{A}_1\boldsymbol{v}+\boldsymbol{b})$ 在图 10.1中的输入 $\boldsymbol{v}$ 和输出 $\boldsymbol{w}$ 之间形成了一个“隐藏层”.

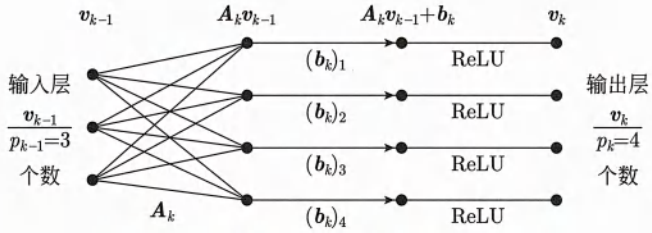


图 10.1　从第 $k-1$ 层到第 $k$ 层的步骤

注：从第 $k-1$ 层到第 $k$ 层的 $\boldsymbol{v}_k$ 有三步：$\boldsymbol{v}_k=F_k(\boldsymbol{v}_{k-1})=\mathrm{ReLU}(\boldsymbol{A}_k\boldsymbol{v}_{k-1}+\boldsymbol{b}_k)$：①矩阵乘法 $\boldsymbol{A}_k\boldsymbol{v}_{k-1}$（共 $p_k$ 行）；②加上向量 $\boldsymbol{b}_k$；③每个分量都用 ReLU 作用.

ReLU 函数产出了 2 个线性分块：要么输出 = 输入（当输入 $\geqslant 0$ 时），要么输出 $=0$（当输入 $\leqslant 0$ 时）. 起初，我们希望像 $\dfrac{1}{1+\mathrm{e}^{-x}}$ 这样的光滑曲线对优化权重 $\boldsymbol{A}_1$、$\boldsymbol{b}_1$、$\boldsymbol{A}_2$ 会有帮助；但现实是无情的，这种想法终究是“镜花水月”.

$\mathrm{ReLU}(\boldsymbol{A}_1\boldsymbol{v}+\boldsymbol{b}_1)$ 的每个分量的图像都分成两部分，其中一个是平的，即 $\boldsymbol{A}_1\boldsymbol{v}+\boldsymbol{b}_1$ 非正的部分. 如果 $\boldsymbol{A}_1$ 是 $p_1\times p_0$ 矩阵，那么输入空间将被 $p_1$ 个超平面分割成 $r$ 块. 这些块的数量是可以计算的，它衡量了函数 $F_1$ 的“表现力”. 此数量实际上是一些二项式系数之和：

$$r(p_1,p_0)=\binom{p_1}{0}+\binom{p_1}{1}+\cdots+\binom{p_1}{p_0}=F_1(\boldsymbol{v}_0)\text{的线性分支个数}$$

这个数字给出了 $F_1$ 图形的基本印象——像是有 $r$ 个平坦组件的马赛克. 但是 $F_1$ 的表达能力还不够充分，此时另一个想法就出现了：**增加更多层.**

学习函数 $F$ 一个不可或缺的要点是从简单函数构建复杂函数，最佳方式是函数复合. 每个 $F_k$ 都使用了 $\boldsymbol{A}_k$ 和 $\boldsymbol{b}_k$，还有非线性的 ReLU：$F_k(\boldsymbol{v})=\mathrm{ReLU}(\boldsymbol{A}_k\boldsymbol{v}+\boldsymbol{b}_k)$，$L$ 个函数依次复合得 $F(\boldsymbol{v})=F_L(F_{L-1}(\cdots F_2(F_1(\boldsymbol{v}))))$. 那么在最终的输出层之前隐藏了 $L-1$ 个中间层. 当 $L$ 增加时，整个学习网络就更“深”.

深度学习最重大的优化问题是计算权重 $\boldsymbol{A}_k$ 和 $\boldsymbol{b}_k$，要求输出 $F(\boldsymbol{v})$ 几乎是完全正确的——尽量接近 $\boldsymbol{v}$ 的像所代表的数字 $\boldsymbol{w}(\boldsymbol{v})$. 最小化 $F(\boldsymbol{v})-\boldsymbol{w}$ 的问题是通过梯度下降法解决的. 而这个复杂函数的梯度又通过*反向传播*（深度学习中执行链式法则的核心工具）来计算.

2012 年有一项历史性比赛——识别 ImageNet 收集的 120 万张图像. AlexNet 的突破性神经网络有 6000 万个权重，其错误率（经过 5 天的随机梯度下降）只有第二名的一半. 这预示着深度学习已经到来.

我们的目标是要意识到连续的分段线性函数可以做到非常强的近似. 该函数族本身性质也很好——在加法 $F+G$、取最大值 $\max(F,G)$ 和函数复合 $F(G)$ 下都是封闭的. 其神奇之处在于学习函数在从未见过的输入 $\boldsymbol{v}$ 上的像 $F(\boldsymbol{v})$ 是相当准确的结果.

### 10.1.1　深度神经网络的构建

深度神经网络已经发展成为机器学习领域的一股重要力量. 随着网络的结构逐步稳健和强大，它也更容易适用于新的应用场景. 首先要介绍的是网络结构的本质组件，这些组件可以组合成一个**学习函数** $F(\boldsymbol{x},\boldsymbol{v})$，其中权重 $\boldsymbol{x}$ 从训练数据 $\boldsymbol{v}$ 中捕获信息，以便于测试新的数据.

这里说明构造函数 $F$ 的重要步骤.

（1）关键操作：函数复合 $F(\boldsymbol{x},\boldsymbol{v})=F_3(F_2(F_1(\boldsymbol{v})))$；

（2）关键规则：$F$ 对 $\boldsymbol{x}$ 求偏导数的链式法则；

（3）关键算法：寻找最佳权重 $\boldsymbol{x}$ 的随机梯度下降法；

（4）关键子程序：执行链式法则的反向传播；

（5）关键非线性：$\mathrm{ReLU}(\boldsymbol{y})=\max(\boldsymbol{y},\boldsymbol{0})=$ 斜坡函数.

第（1）步是逐层描述神经元层的各部分 $F_1,F_2,F_3,\cdots$. 在构造 $F$ 的过程中，连接层 $\boldsymbol{v}$ 的权重 $\boldsymbol{x}$ 被优化. 向量 $\boldsymbol{v}=\boldsymbol{v}_0$ 来自训练集，而函数 $F_k$ 在第 $k$ 层产生向量 $\boldsymbol{v}_k$. 整个过程成功的关键在于式(10.1)中由 $F_k$ 构造的函数 $F$ 的强大威力.

### 10.1.2　$F_k$ 是 $v_{k-1}$ 的分段线性函数

函数 $F_k$ 的输入是 $p_{k-1}$ 维向量 $\boldsymbol{v}_{k-1}$，输出是 $p_k$ 维向量 $\boldsymbol{v}_k$，$\boldsymbol{v}_k$ 也是函数 $F_{k+1}$ 的输入. 函数 $F_k$ 有线性和非线性两部分：

（1）$F_k$ 的线性分块是 $\boldsymbol{A}_k\boldsymbol{v}_{k-1}+\boldsymbol{b}_k$（偏置向量 $\boldsymbol{b}_k$ 使得输入是“仿射”的）；

（2）作用于 $\boldsymbol{A}_k\boldsymbol{v}_{k-1}+\boldsymbol{b}_k$ 每个分量、类似于 ReLU 那样的固定的非线性函数：

$$\boxed{\boldsymbol{v}_k=F_k(\boldsymbol{v}_{k-1})=\mathrm{ReLU}(\boldsymbol{A}_k\boldsymbol{v}_{k-1}+\boldsymbol{b}_k)} \tag{10.1}$$

每个样本的训练数据都位于表征向量中，矩阵 $\boldsymbol{A}_k$ 是 $p_k\times p_{k-1}$ 矩阵，列向量 $\boldsymbol{b}_k$ 有 $p_k$ 个分量. **这些 $\boldsymbol{A}_k$ 和 $\boldsymbol{b}_k$ 是由优化算法构建的权重.** 通常，随机梯度下降在深度学习的主要计算中计算出最优权重 $\boldsymbol{x}=(\boldsymbol{A}_1,\boldsymbol{b}_1,\cdots,\boldsymbol{A}_L,\boldsymbol{b}_L)$. 它依赖反向传播来找到 $F$ 的 $\boldsymbol{x}$-偏导数，以求解 $\nabla F=\boldsymbol{0}$.

线性函数过于局限，最终它们并不成功. 激活函数 $\mathrm{ReLU}(\boldsymbol{y})=\max(\boldsymbol{y},\boldsymbol{0})$ 则提供了一定的灵活性和适应性.

ReLU 作用于每个中间层的每个“神经元”. 第 $k$ 层有 $p_k$ 个神经元，包含了来自 $\boldsymbol{A}_k\boldsymbol{v}_{k-1}+\boldsymbol{b}_k$ 的 $p_k$ 个输出. 请注意，ReLU 正如其图像所示，本身是连续的且分段线性的（图形只是斜率为 0 和 1 的斜坡在原点相接，其导数是通常的跳跃函数）. 当我们选择 ReLU 时，复合函数 $F=F_L\cdots(F_2(F_1(\boldsymbol{v})))$ 具有一个重要的性质：

学习函数 $F$ 关于 $v$ 是连续且分段线性的.

### 10.1.3 一个中间层（$L=2$）的情况

假设我们在训练集中测量了一个样本的 3 个表征，这些表征构成了输入向量 $\boldsymbol{v}=\boldsymbol{v}_0$. 在神经网络的第一层，函数 $F_1$ 将 $\boldsymbol{v}_0$ 与一个 $4\times 3$ 矩阵 $\boldsymbol{A}_1$ 相乘，并加一个四维的偏置向量 $\boldsymbol{b}_1$. 这样，我们就得到了一个包含 4 个分量的新向量 $\boldsymbol{A}_1\boldsymbol{v}_0+\boldsymbol{b}_1$.

这一过程实际上是从原始的 3 个表征中提取出了 4 种新的组合. 在训练过程中，这些权重（矩阵 $\boldsymbol{A}_1$ 和偏置向量 $\boldsymbol{b}_1$）会不断更新，以便找到最有意义的表征组合. 最后，为了得到 $\boldsymbol{v}_1$，我们需要对 $\boldsymbol{A}_1\boldsymbol{v}_0+\boldsymbol{b}_1$ 的每个分量用一个非线性“激活函数”进行作用. 在早期的神经网络中，这个激活函数通常是一个平滑的“S 曲线”. 图 10.2 展示了一些常见的激活函数.

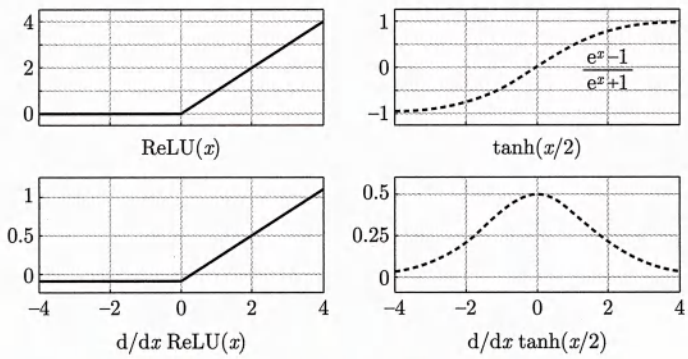


图 10.2 非线性的两种选择：ReLU 和双曲正切 tanh

过去，人们认为函数斜率的突然变化可能会导致不稳定和风险. 然而，通过大量的数值实验，我们发现情况并非如此. 使用斜坡函数，即 $\mathrm{ReLU}(\boldsymbol{y})=\max(\boldsymbol{y},\boldsymbol{0})$，可以获得更优的结果. 我们将采用 ReLU 函数进行操作：

将 ReLU 作用于 $\boldsymbol{A}_1\boldsymbol{v}_0+\boldsymbol{b}_1$，求得 $\boldsymbol{v}_1$ $\qquad (\boldsymbol{v}_1)_k=\max((\boldsymbol{A}_1\boldsymbol{v}_0+\boldsymbol{b}_1)_k,0).$ (10.2)

现在，我们在神经网络第一层的四个节点（或称“神经元”）中得到了 $\boldsymbol{v}_1$ 的各个分量. 输入层包含了这个特定训练样本的三个表征. 在实际应用中，我们可能处理的是成千上万个或数以百万计的这样的样本. 通过随机梯度下降法，并利用反向传播技术来计算损失函数的梯度，优化算法成功地找到了最佳的权重矩阵 $\boldsymbol{A}_1$ 和偏置向量 $\boldsymbol{b}_1$.

假设神经网络结构较为简单，只有一层，这一层包含 4 个神经元. 在这种情况下，网络的最终输出通过将四维向量 $\boldsymbol{v}_1$ 与 $1\times 4$ 的矩阵 $\boldsymbol{A}_2$（即一个行向量）相乘，并加上一个偏置向量 $\boldsymbol{b}_2$（即一个数）来得到，即 $\boldsymbol{v}_2=\boldsymbol{A}_2\boldsymbol{v}_1+\boldsymbol{b}_2$. 值得注意的是，在这个简化的神经网络结构中，最后一步并没有涉及非线性函数 ReLU.

总的来说，我们对训练集中的每个表征向量 $\boldsymbol{v}_0$ 应用神经网络模型 $F$，计算出对应的输出 $\boldsymbol{v}_2 = F(\boldsymbol{x}, \boldsymbol{v}_0)$. 具体步骤是：

$$\boldsymbol{v}_2 = \boldsymbol{A}_2\boldsymbol{v}_1 + \boldsymbol{b}_2 = \boldsymbol{A}_2(\mathrm{ReLU}(\boldsymbol{A}\boldsymbol{v}_0 + \boldsymbol{b})) + \boldsymbol{b}_2 = F(\boldsymbol{x}, \boldsymbol{v}_0). \tag{10.3}$$

在优化神经网络参数 $\boldsymbol{x} = (\boldsymbol{A}_1, \boldsymbol{b}_1, \boldsymbol{A}_2, \boldsymbol{b}_2)$ 的过程中，我们的目标是确保网络最后一层（第二层）的输出 $\boldsymbol{v}_2$ 能够准确地捕捉到训练数据 $\boldsymbol{v}_0$ 的关键特征.

对于分类任务，每个训练样本 $\boldsymbol{v}_0$ 都标记了 1 或 $-1$，我们希望输出 $\boldsymbol{v}_2$（在大多数情况下）能够正确地反映这个标签. 对于回归任务，我们关注的是 $\boldsymbol{v}_2$ 的具体数值，而不仅仅是正负. 我们并不会使用大量参数 $\boldsymbol{A}_k$ 和 $\boldsymbol{b}_k$ 以图完美拟合每个训练样本，因为这样可能会导致过拟合，即模型过度地学习训练数据中的特定细节和噪声，从而在新数据上表现不佳.

我们选择一个损失函数 $L(\boldsymbol{x}, \boldsymbol{v}_2)$ 并努力将其最小化来训练模型，这个损失函数可以是平方损失（用于回归问题）或交叉熵损失（用于分类问题）.

我们希望函数 $F$ 可以从数据中学习，这是机器学习的本质. 我们需要模型能够在识别狗和猫或者区分直行车辆和转弯车辆等任务中，捕捉到关键的特征.

机器学习并不是要模型记住每个数字（如 $0, 1, \cdots, 9$）的每个细节，而是能够提取出足够的信息，以便能够准确地区分这些数字. 机器学习的核心目标就是让模型通过学习数据来提取有用的信息.

### 10.1.4　学习函数 $F(v)$ 的图像

函数 $F(\boldsymbol{v})$ 的图像是一个由许许多多平坦分块组成的曲面，这些部分是平面或超平面，它们在 ReLU 函数斜率有变化的地方拼接在一起. 这有点像折纸，但是不同的是，这个图形的平坦分块延伸至无穷远处. 此外，这个图形也可能不是三维空间 $\mathbb{R}^3$ 的子集——因为表征向量 $\boldsymbol{v} = \boldsymbol{v}_0$ 有 $p_0$ 个分量.

深度学习的一部分数学上的挑战在于估计这些平坦分块的数目，并理解它们如何组合成一个分段线性的表面. 这个估计通常是在研究具有一个内部层的神经网络实例后得出的. 每个表征向量 $\boldsymbol{v}_0$ 包含了 $p_0$ 个测量值，比如训练集中样本的高度、重量和年龄.

在该示例中，函数 $F$ 有 3 个输入（$\boldsymbol{v}_0$ 的 3 个分量）和 1 个输出 $\boldsymbol{v}_2$. 其图像是四维空间中的一个分段平坦曲面. 该图像中，高度 $\boldsymbol{v}_2 = F(\boldsymbol{v}_0)$ 表示函数 $F$ 在三维空间中的点 $\boldsymbol{v}_0$ 上的取值. 由于篇幅的限制（以及作者在四维空间想象力上的局限），我们无法绘制 $\mathbb{R}^4$ 中的这个图形. 尽管如此，我们仍然可以根据输入的数量（3 个）、神经元的数量（4 个）和输出的数量（1 个）来尝试估算这些平坦分块的数目.

注：当只有两个输入（$m = 2$）时，函数 $F$ 的图像是三维空间中的曲面. 我们可以尝试画出这个图像.

**重要说明：全连接层与卷积层**

我们不想误导读者. “全连接”网络并非总是最有效的选择. 在处理图像时，如果一个像素点的权重可以在图像的其他像素点重复使用（这是可行的），那么我们只需要 $\boldsymbol{A}$ 的一个行向

量. 这一行权重为图像中远离该像素点的区域分配零权重. 这种利用局部区域权重的网络被称为**卷积神经网络（CNN）**，将在 10.2 节中详细介绍.

### 10.1.5 计算学习函数图像的平坦分块个数：一个中间层的情形

计算权重矩阵 $\boldsymbol{A}_k$ 和偏置向量 $\boldsymbol{b}_k$ 中的参数数量是简单的，这些参数决定了神经网络的学习函数 $F$. 更有趣的是计算函数 $F$ 的图像中分段线性分块的数目，这个数字反映了神经网络的复杂度和**表达能力**. $F(\boldsymbol{x},\boldsymbol{v})$ 是一个我们目前还没有完全理解的复杂函数. 这个函数能够自主地做出决策和行动，而无须明确的指导. 例如，在无人驾驶汽车的应用中，我们将很快看到这种自主决策的能力的结果.

假设输入向量 $\boldsymbol{v}_0$ 有 $p_0$ 个分量，而经过第一层变换后的向量 $\boldsymbol{A}_1\boldsymbol{v}_0+\boldsymbol{b}_1$ 有 $p_1$ 个分量. 这意味着我们有 $p_1$ 个关于 $\boldsymbol{v}_0$ 的线性函数. 每个这样的线性函数在一个超平面上（$p_0-1$ 维线性子空间）取值为零. 当我们应用 ReLU 函数时，线性函数变为分段线性函数，函数图像沿着超平面形成折痕. 在折痕的一侧，函数图形有斜率，而在另一侧，函数从负值变为零.

矩阵 $\boldsymbol{A}_2$ 将这些关于 $\boldsymbol{v}_0$ 的 $p_1$ 个分段线性函数组合起来，从而在 $p_1$ 个不同的超平面上形成折痕. 这描述了下一层 $\boldsymbol{A}_2(\mathrm{ReLU}(\boldsymbol{A}_1\boldsymbol{v}_0+\boldsymbol{b}_1))$ 中的每个分段线性分块.

我们可以将这个过程想象为在平面上形成 $p_1$ 个直的折痕（实际上是在 $p_0$ 维空间中的 $p_1$ 个超平面上）. 第一个折痕将平面分为两部分，接下来的 ReLU 将折痕形成 4 部分，而第三个折痕则更难可视化，但如图 10.3所示，会有 7 部分而不是 8 部分.

在组合理论中，我们研究的是**超平面排列**，Tom Zaslavsky 的一个定理能够计算这些片段的数量. 这个证明可以在 Richard Stanley 的 *Enumerative Combinatorics* 这本经典教材（2001 年）中找到. 但这个定理比我们的实际需求更复杂，因为它考虑了折痕线以所有可能的方式相交；而我们的任务相对简单，因为我们假设这些折痕线处于“一般位置”. 在这种情况下，我们可以采用 Raghu、Poole、Kleinberg、Gangul 和 Dickstein 在他们的论文“On the Expressive Power of Deep Neural Networks”中提出的简洁计数方法.

**定理 10.1** 假设 $F(\boldsymbol{v})$ 的图像在 $p_1$ 个超平面 $\boldsymbol{a}_i^{\mathrm{T}}\boldsymbol{v}+\boldsymbol{b}_i=0$ 上有折痕；换言之，这些超平面来自 ReLU 在 $p_1$ 个神经元上的转折. 如果 $\boldsymbol{v}$ 有 $p_0$ 个分量，那么这 $p_1$ 个折痕在 $F(\boldsymbol{v})$ 的定义域中会形成 $r$ 个线性区域：

$$r(p_1,p_0)=\binom{p_1}{0}+\binom{p_1}{1}+\cdots+\binom{p_1}{p_0} \tag{10.4}$$

其中组合系数为

$$\binom{p_1}{i}=\frac{p_1!}{i!(p_1-i)!},\quad 0!=1,\quad \binom{p_1}{0}=1,\quad \text{以及当 } i>p_1 \text{ 时，}\quad \binom{p_1}{i}.$$

例如，函数 $F(x,y,z)=\mathrm{ReLU}(x)+\mathrm{ReLU}(y)+\mathrm{ReLU}(z)$ 在 3 个平面 $x=0,y=0,z=0$ 有 3 个折痕. 这些平面将 $\mathbb{R}^3$ 分割成 $r(3,3)=8$ 部分，其中 $F$ 的表达形式包括 $x+y+z$、$x+z$、$x$ 和 0（还有其他 4 种形式）. 再添加 $\mathrm{ReLU}(x+y+z-1)$ 会产生第四个折痕，并且在三维空间中形成 $r(4,3)=15$ 部分，而不是 16 部分，因为新的折痕平面 $x+y+z=1$ 无法和第 8 部分（$x<0,y<0,z<0$）相交.

George Polya 在他著名的 YouTube 视频《让我们教猜想》中用 5 个平面切割蛋糕. 他帮助学生切出 $r(5,3)=26$ 块. 我们的蛋糕可以维数更高.

$m$ 维空间 $\mathbb{R}^m$ 中的一个超平面会产生 $\binom{1}{0}+\binom{1}{1}=2$ 个区域. 如果有 2 个超平面，在 $p_0>1$ 的前提下，将会产生 $r(2,p_0)=1+2+1=4$ 个区域. 当 $p_0=1$ 时，线上有两个折痕，它将线只分割成 $r(2,1)=3$ 部分.

---

平坦分块的数目 $r$ 满足递推公式

式(10.4)的证明

$$\boxed{r(p_1,p_0)=r(p_1-1,p_0)+r(p_1-1,p_0-1)} \tag{10.5}$$

为了理解这个递归关系，我们从 $p_1-1$ 个超平面和它们分割出的 $r(p_1-1,p_0)$ 个区域开始考虑. 接着，我们添加一个 $p_0-1$ 维超平面 $H$. 已有的 $p_1-1$ 个超平面会将这个新超平面 $H$ 分割成 $r(p_1-1,p_0-1)$ 个区域，而 $H$ 的每个这样的部分都会将一个原有的区域分隔成两个，从而在最初的 $r(p_1-1,p_0)$ 个区域的基础上增加 $r(p_1-1,p_0-1)$ 个新的区域；具体可见 10.3 节. 因此，这个递归关系是正确的，我们现在可以使用式(10.5)来计算 $r(p_1,p_0)$. 从计算 $r(1,0)=r(0,1)=1$ 开始. 接着，我们可以通过对 $p_1+p_0$ 用归纳法来证明式(10.4)：

$$\begin{aligned} r(p_1-1,p_0)+r(p_1-1,p_0-1) &= \sum_{i=0}^{p_0}\binom{p_1-1}{i}+\sum_{i=0}^{p_0-1}\binom{p_1-1}{i} \\ &= \binom{p_1-1}{0}+\sum_{i=0}^{p_0-1}\left[\binom{p_1-1}{i}+\binom{p_1-1}{i+1}\right] \\ &= \binom{p_1}{0}+\sum_{i=0}^{p_0-1}\binom{p_1}{i+1}=\sum_{i=0}^{p_0}\binom{p_1}{i} \end{aligned} \tag{10.6}$$

第二行中括号内的两项根据组合数的公式

$$\binom{p_1-1}{i}+\binom{p_1-1}{i+1}=\binom{p_1}{i+1} \tag{10.7}$$

缩并成一项，由此完成归纳.

Mike Giles 建议用图 10.3来展现最后一个超平面 $H$ 的作用.

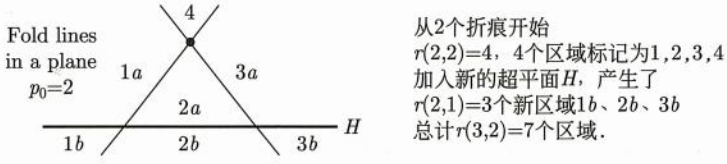


**图 10.3　平面的分块示意图**

注：$H$ 的 $r(2,1)=3$ 部分产生 3 个新的区域. 因此 $\boldsymbol{v}_2=F(\boldsymbol{v}_0)$ 的分段线性的平坦分块总是总数为 $r(3,2)=4+3=7$. 第四个折痕将和 3 个现有的折痕都交叉，并由此产生 4 个新区域，因此 $r(4,2)=11$.

### 10.1.6　计算学习函数图像的平坦分块个数：更多中间层的情形

当神经网络包含两个中间层时，函数 $F(\boldsymbol{v})$ 的线性片段数量的计算变得非常复杂. 同样假设 $\boldsymbol{v}_0$ 和 $\boldsymbol{v}_1$ 分别有 $p_0$ 和 $p_1$ 个分量. 在使用 ReLU 之前，$\boldsymbol{A}_2\boldsymbol{v}_1+\boldsymbol{b}_2$ 将产生 $p_2$ 个分量. 每个分量都类似

于上面描述的单层函数 $F$. 接着，ReLU 将在其图像中产生新的折痕，这些折痕即 $\boldsymbol{A}_2\boldsymbol{v}_1+\boldsymbol{b}_2$ 中某个分量取零值的线.

需要注意的是，$\boldsymbol{A}_2\boldsymbol{v}_1+\boldsymbol{b}_2$ 的每个分量都是分段线性的，而不是线性的，因此它们沿着一个分段线性的表面穿过零点（如果穿过），而不是一个超平面. 图 10.3中 $\boldsymbol{v}_1$ 的折痕直线对于 $\boldsymbol{v}_2$ 的折痕来说，只是分段直的. 因此，计数依赖于 $\boldsymbol{v}_0$、$\boldsymbol{A}_1$、$\boldsymbol{b}_1$、$\boldsymbol{A}_2$ 和 $\boldsymbol{b}_2$ 的细节.

我们仍然可以估算线性片段的数量. 在第二个中间层，我们有来自 $p_2$ 个 ReLU 函数的 $p_2$ 个分段直线（或分段超平面）. 如果这些线实际上是直的，那么在 $\boldsymbol{v}_3=F(\boldsymbol{v}_0)$ 的每个分量中，我们将总共有 $p_1+p_2$ 个折痕. 于是，用式(10.4) 计数时，要用 $p_1+p_2$ 代替 $p_1$. 这个估计被 Hanin 和 Rolnick 的研究所证实. 因此，决定 $F(\boldsymbol{x},\boldsymbol{v})$ 中线性片段数量的是神经元的数量，而不是层数和深度.

Boris-Hanin 证明了，深度-广度比 $L/W$ 是神经网络最关键的数值.

如果所有函数都是线性的，那么 $F_k$ 都可以简单地表示为矩阵乘法 $F_k(\boldsymbol{v})=\boldsymbol{A}_k\boldsymbol{v}$，例如，$F_3(\boldsymbol{v}_0)=\boldsymbol{A}_3\boldsymbol{A}_2\boldsymbol{A}_1\boldsymbol{v}_0$. 对于非线性的 $F_k$，其含义也类似：首先计算 $\boldsymbol{v}_1=F_1(\boldsymbol{v}_0)$，然后计算 $\boldsymbol{v}_2=F_2(\boldsymbol{v}_1)$，最后计算 $\boldsymbol{v}_3=F_3(\boldsymbol{v}_2)$. 这种函数复合 $F_3(F_2(F_1(\boldsymbol{v}_0)))$ 在构造函数方面比加法或乘法强大得多.

### 10.1.7 移除

**移除是指在神经网络中随机选择并移除神经元.** 这些神经元是输入层 $\boldsymbol{v}_0$ 的分量或（在输出层 $\boldsymbol{v}_L$ 之前的）中间层 $\boldsymbol{v}_n$ 的分量. 与那些被移除的神经元相连的、在 $\boldsymbol{A}$ 和 $\boldsymbol{b}$ 中的所有权重都会从网络中消失. 通常，中间层的神经元可能被赋予 $p=0.5$ 的存活概率，而输入层的分量存活概率可能是 $p\geqslant 0.8$. 随机移除的主要目的是避免过拟合. 与许多网络中的组合预测相比，这是一种物美价廉的平均方法.

## 习题 10.1

1. 在例子 $F=\mathrm{ReLU}(x)+\mathrm{ReLU}(y)+\mathrm{ReLU}(z)$ 中，根据式(10.4)计算 $r$，假设第四个折痕来自 $\mathrm{ReLU}(x+y+z)$. 它的折痕平面是 $x+y+z=0$ 和 3 个初始平面 $x=0$、$y=0$、$z=0$ 均相交于原点 $(0,0,0)$——这是一个特殊情况. 请描述 $G$（这四个 ReLU 函数之和）的 12（不是 15）个线性分块.

2. 假设有 $m=2$ 个输入和一个有 $N$ 个神经元的中间层，因此 $F(x,y)$ 是 $N$ 个 ReLU 函数的线性组合. 写出 $r(N,2)$ 的公式，并说明 $F$ 的线性分块的数量的首项是 $\frac{1}{2}N^2$.

3. 假设平面内有 $N=18$ 条线，如果其中 9 条是垂直的，9 条是水平的，那么这个平面将被分割成多少部分？将这个结果与处于一般位置且没有三条线共点时的 $r(18,2)$ 比较.

4. 哪个权重矩阵 $\boldsymbol{A}_1$ 和偏置向量 $\boldsymbol{b}_1$ 产生的第一隐藏层的 $N=3$ 个分量是 $\mathrm{ReLU}(x+2y-4)$、$\mathrm{ReLU}(3x-y+1)$ 和 $\mathrm{ReLU}(2x+5y-6)$（输入层的分量是 $x$ 和 $y$）. 如果输出 $w$ 是那三个 ReLU 的和，那么 $w(x,y)$ 中有多少个线性分块？

5. 将一条线折叠四次会产生 $r(4,1)=5$ 个线性分块，将一个平面折叠四次会产生 $r(4,2)=11$ 个线性分块. 根据式(10.4)，将 $\mathbb{R}^3$ 折叠四次会产生多少个线性分块？$\mathbb{R}^3$ 的平坦子集相交成 2 维子

集，类似于一个门框的结构.

6. 二项式展开 $(a+b)^N=\sum_{k=0}^{N}\binom{N}{k}a^kb^{N-k}$ 的系数是组合数 $\binom{N}{k}$. 令 $a=b=1$，可以得到关于组合数和 $r(N,m)(m\geqslant N)$ 的什么结论？

7. 在图 10.3中，再增加一个折痕将在 $z=F(x,y)$ 的函数图像中产生 11 个平坦分块. 请验证式(10.4)是否确实得出 $r(4,2)=11$. 那么，五次折叠后会有多少个平坦分块呢？

8. 请解释为什么下面关于连续分段线性函数（CPL 函数）的陈述都是正确的？可以用文字或者图像描述.

> （1）两个 CPL 函数 $F_1(x,y)$ 和 $F_2(x,y)$ 的极大值 $M(x,y)$ 也是 CPL.
> （2）两个 CPL 函数 $F_1(x,y)$ 和 $F_2(x,y)$ 之和 $S(x,y)$ 也是 CPL.
> （3）若两个一元函数 $y=F_1(x)$ 和 $z=F_2(y)$ 都是 CPL，那么它们的复合函数 $C(x)=z=F_2(F_1(x))$ 也是 CPL.

9. 在某神经网络中，每个输入的表征向量 $\boldsymbol{v}_0$ 有 $p_0=4$ 分量，3 个中间层，每个中间层有 $N=6$ 个神经元. 这个网络中有多少个权重？偏置向量有几个分量？此外，在最终输出之前，这个网络中有多少个激活函数（ReLU）?

10. 平面上的 20 条直线最少可以将这个平面分割成多少部分？

11. 10 条竖直的线和 10 条水平线将平面分割成多少部分？

12. 平面上的 20 条直线最多可以将这个平面分割成多少部分？

## 10.2 发明和实验

本节从一个精美的展示深度学习的网站（网页说明见图 10.4）开始. 用户可以添加或移除层以及每个层上的节点（神经元）. 该网站提供了四个例子用以实验，其中三个相对容易，第四个则更具挑战性. 这个教育性质的网站由谷歌的 Daniel Smilkov 创建，因其简洁明了而备受推崇.

以下是访问网站时出现的图片. 我们为用户需要做的选项添加了加粗的名称，包括：

（1）层数和每层的节点（神经元）数——这些并没有隐藏；

（2）用于控制梯度下降中的步长的“学习率”（建议尝试使用 0.003）；

（3）在每个节点上应用的非线性激活函数（推荐使用 ReLU）；

（4）随机梯度下降中的批处理数目（1 个或更多）以及正则化方法；

（5）从四组训练数据集中进行选择（其中三组较简单，一组包含复杂的螺旋形状）.

当选择一个示例并单击“开始”时，系统会开始遍历蓝色和橙色的数据点——致力于创建学习函数 $F$ 中的权重，以正确地对这些点进行分类. 节点之间更粗的曲线表示更大的权重.

每个循环称为一个周期（epoch）. 可以从前两个表征 $x_1$ 和 $x_2$（每个数据点的位置）开始，右侧的输出显示了损失函数正在接近一个最小值（希望能接近零）. 可以看到 $F$ 如何或多或少正确地将蓝色和橙色点分开. 分隔线是 $F=0$ 的白色线条.

本节的习题建议进行更多实验. 数据集 4 需要更多的神经元！

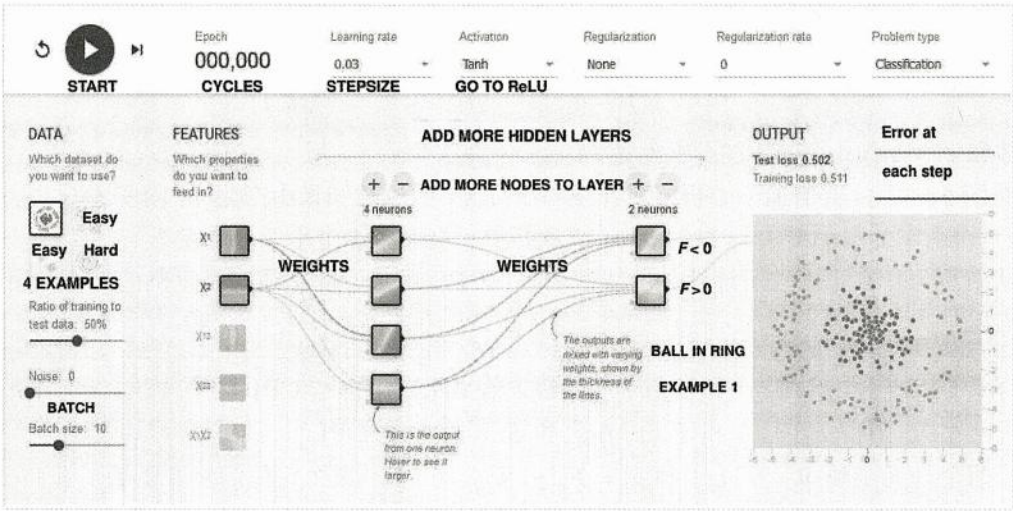


图 10.4 网页说明

### 10.2.1 泛化与双重下降

深度学习领域有一个重要问题：为什么它如此成功？为什么有时它会失败（就像在 playground 网站上那样）？我们通过计算矩阵权重 $\boldsymbol{x}$ 来衡量成功与否，以确保函数 $F(\boldsymbol{x}, \boldsymbol{v})$ 对训练数据 $\boldsymbol{v}$ 是准确的，然后将 $F$ 应用到新的测试数据 $V$. 通常（但并不总是）结果都很好. 虽然权重是针对 $\boldsymbol{v}$ 选择的，但输出 $F(x, \boldsymbol{V})$ 是准确的. 这表明，尽管没有外部帮助，系统已经泛化至新数据.

我们需要解释为什么成功，并且合理的解释已经开始有眉目了. 对于线性问题，经典的测试是逼近的稳定性. 输入的微小变化只会导致输出的微小变化. 但是当我们添加新数据时，$F$ 明显是非线性的.

统计学已经对过拟合数据作出强烈的警报. 在最小二乘法的典型例子中，随着拟合参数的数量 $n$ 接近拟合数据的数量 $m$，结果已经变得不那么稳定了. 但 $F$ 是关于数据的非线性函数，所以需要充足的实验来指明选取的方向. 测试误差曲线如图 10.5 所示.

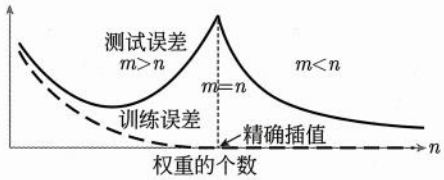


图 10.5 测试误差曲线

注：这是 Belkin 的双重下降曲线. 它显示了测试误差随着 $n$ 的增加而下降，然后由于过度拟合而上升. 令人惊讶的是，对于 $n > m$，误差再次下降. 在众多可能的解决方案中，选择了一个较好的方案.

最小二乘误差曲线表现出双重下降现象. 随着 $n$ 接近 $m$，误差增加，符合预期. 在 $n = m$ 时，我们过于紧密地拟合了 $m$ 个数据点，导致小误差被放大. 但是当 $n$ 超过 $m$ 时，误差再次减小. 尽

管看起来过拟合了，但是当我们选择最小范数解，即在 $\boldsymbol{A}$ 的零空间中的分支是零向量时，准确性得以提高，误差曲线重新开始下降.

Belkin 引领了对这一现象的分析，该分析仍在不断发展中.

### 10.2.2　卷积神经网络：权重共享

神经网络各层之间的权重矩阵 $\boldsymbol{A}_k$ 通常是“稠密”的，即 $\boldsymbol{A}_k$ 中的每个元素都是一个独立的参数. 我们的目标是用 $\boldsymbol{A}_k$ 中的每个元素作为参数，尽可能地拟合数据.

然而，对于某些类型的输入数据，例如图像，这种方法计算成本过高. 图像包含大量的像素，而且这些像素之间的相互关系并不随机，相邻的像素高度相关，而距离较远的像素则相关性较弱. 对权重矩阵 $\boldsymbol{A}_k$ 加以限制，可以加快训练速度并提高效率. 卷积神经网络就是这样一种重要的方法.

在许多问题中，采用局部卷积矩阵的方法是相当成功的. 卷积操作在每个图像点周围应用相同的权重，它是平移不变的. 当远距离像素的权重为零时，这种卷积被称为*局部卷积*. 在信号处理中，这些卷积矩阵通常是有常数对角线的三对角矩阵，也被称为“滤波器”或“Toeplitz 矩阵”. 在图像处理（二维空间，用列向量 $\boldsymbol{A}$、$\boldsymbol{B}$、$\boldsymbol{C}$ 来表示）中，局部卷积在 $\boldsymbol{A}$、$\boldsymbol{B}$、$\boldsymbol{C}$ 中可能只有 $3^2=9$ 个自由参数，这些参数需要在每个点周围重复使用. 局部卷积矩阵如图 10.6所示.

$$\begin{matrix}\text{一维滤子}\\=\\\text{Toeplitz 矩阵}\end{matrix}\begin{bmatrix} a & b & c & & & \\ & a & b & c & & \\ & & a & b & c & \\ & & & a & b & c \end{bmatrix}\qquad \begin{matrix}\text{二维滤子}\\=\\\text{分块Toeplitz 矩阵}\end{matrix}\begin{bmatrix} A & B & C & & & \\ & A & B & C & & \\ & & A & B & C & \\ & & & A & B & C \end{bmatrix}$$

图 10.6　局部卷积矩阵

注：二维卷积用包含 9 个权重的方阵 $\boldsymbol{ABC}$ 来替换原来的一个行向量中的 3 个权重.

### 10.2.3　最大池化

像往常一样，将前一层 $\boldsymbol{v}$ 与矩阵 $\boldsymbol{A}$ 相乘. 然后，从每个相邻的输出对（例如 $\boldsymbol{Av}+\boldsymbol{b}$ 中的第 2 和第 3 个分量）中保留最大值. 请注意，最大池化（max-pooling）是一种简单且快速的运算，**但它并不是线性操作.** 这种方法可以迅速降低数据的维数，并可能降低过拟合的风险.

对于图像（一种二维信号），我们通常会在 $2\times 2$ 像素块上应用最大池化的操作. 这样做会使每个维度都减少 2，因此图像的整体维度会减少 4. 这种操作可以加快训练速度，特别是当隐藏层上的神经元数量是 4 的整数倍时.

在神经网络的整体架构中，最大池化步骤通常有自己的独立位置. 神经网络架构的一部分可能如图 10.7所示.

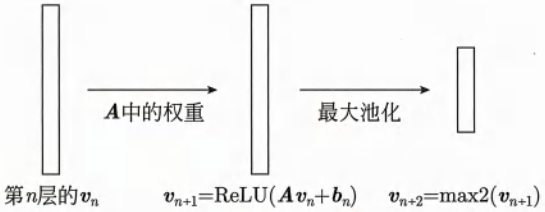


图 10.7　最大池化

### 10.2.4 深度学习领域的四大重要成就

总有一天，这个领域会有一个完整的历史，记录下它的起伏、成功与失败，以及那些将失败转化为成功的想法. 在这里，我将报告伦敦 DeepMind 团队的两大重要成就，以及一个在语言翻译方面的成功案例. 此外，还有一个新的代码，它对学生的影响巨大：它能帮助你解决所有的习题！

（1）**AlphaGo Zero**的神经网络是利用 TensorFlow 进行训练的. 起初，它对围棋的了解仅限于规则，只能识别棋盘上的棋子. 它的训练核心在于强化学习，与自己进行了 490 万局对弈. 通过评估每个位置的优势，它逐渐具备了击败顶尖人类棋手的能力. 相比之下，早期的 AlphaGo 需要数月的训练才能达到同样的水平.

（2）**AlphaFold**被评选为 2021 年度的科学突破. 它能够预测数百万种蛋白质的三维结构，而对这些结构了解的匮乏一直是研制药物的严重瓶颈. AlphaFold 以惊人的准确性揭示了蛋白质的细微结构. 这项由 DeepMind 多位作者完成的工作，毫无疑问是诺贝尔奖的有力竞争者.[①] Demis Hassabis 于 2010 年创立了 DeepMind，并一直担任首席执行官. 他在 2022 年对理解智能这一大问题，以及蛋白质结构这一具体问题作了公开演讲.

（3）**Google 翻译**是机器学习黄金法则的完美例证：*不要对每个语法规则和例外情况编码*，而是让计算机去发现这些规则. 如果你正在教朋友玩游戏，那就直接开始玩. 某种程度上这就是机器学习的核心原理：从训练集开始，而不是从学习函数开始，是例子确定了函数. 语言翻译和国际象棋、围棋一样，系统会自动学习所需的知识.

（4）**一个神经网络能够解决、解释并生成大学数学问题.** 这个网络能够理解和解决数学作业中的典型问题，并且能够涵盖从基础到高级的广泛课程. 那么，*传统的习题集将如何变化呢？* 代码是用 OpenAI 的 Codex transformer 以一种高度创新的方式自动写成的. Iddo Drori 领导的一个大型团队成功开发出了一款远超竞争对手的代码. 它能准确识别出问题并找出解答. 这篇重要的论文可以在`arXiv:2112.15594` 上找到，并且已经发表在《美国国家科学院院刊》（PNAS，2022 年）上. 碰巧的是，最初的测试例子正来自你正在阅读的这本教材的第五版. 线性代数是第一个被测试的领域！现在已经涵盖整个大学数学课程. 目前，作者们还不知道这对数学教学会有什么最终影响. 我也无法预测，但可以肯定的是，习题将会发生巨大的变化！

## 习题 10.2

**问题 1-2 使用了在网页（网页链接详见本书数字资源）上的蓝色球和橙色环的示例. 当学习过程成功时，一个白色的多边形会出现在图中，将蓝色和橙色区域明确分隔开来.**

1. 若有 $N=4$ 个神经元，学习能成功吗？在 $F(\boldsymbol{v})$ 图像平坦分块的数目 $r(N,2)$ 是多少？白色多边形显示了在 $F(\boldsymbol{v})$ 的图像中，平坦分块在越过基平面 $z=0$ 时符号改变的位置. 该多边形有多少条边？

2. 考虑一个中间层、$N=3$ 个中间层，$F$ 还能把蓝色球从橙色环分离开吗？$F(\boldsymbol{v})$ 的图像的平坦分块数 $r(3,2)$ 是多少？$N=2$ 时答案如何？

---

① 译者注：2024 年诺贝尔化学奖已经授予 DeepMind 的创始人之一的 Demis Hassabis，以及 ALphaFold 项目的关键贡献者 John M. Jumper.

3. 在示例 2 中，蓝色和橙色分别占据了两个象限. 当使用单层网络时，$N=3$ 个神经元甚至 $N=2$ 个神经元能否正确分类该训练数据？成功分类需要多少个平坦分块？描述 $N=2$ 时，$F(\boldsymbol{v})$ 的异常图像.

4. 示例 4 中的蓝色和橙色螺旋形状要难得多！神经网络只用一个中间层能成功学习这个训练数据吗？随着 $N$ 的增加，会发生什么情况？两个隐藏层需要多少神经元才能完全分离这些螺旋？

我发现对于那个螺旋图，$4+4+2$ 和 $4+4+4$ 个神经元的迭代非常不稳定. 训练损失出现了尖峰，直到算法停止运行.

---

**Python 和 Julia 代码：识别手写数字**

本书网站上的代码是由 Ruochen Li 提供的，他在 2022 年学习了《从数据中学习》课程（课程编号 18.065）. 对此我非常感激！图像识别是一个优秀的示例，它基于测量来自 MNIST 的训练集中（训练集的典型大小为 60,000 张图像）每个像素的灰度值. 由于不规则的书写和未居中的放置，这个问题变得更加困难.

你可以尝试用不同大小的训练集进行实验. 除了 ReLU，还可以尝试使用像 tanh 这样的激活函数. 批量大小、周期数（epoch）和学习率（步长）决定了训练的准确性和速度. 当输出数字有 $0\sim9$ 共 10 个类别时，一个合适的要最小化的损失函数是分类交叉熵 (categorical crossentropy). 如果将 10 个数字 $w_0\sim w_9$ 转换为 10 个相加等于 1 的概率 $p_0\sim p_9$，柔性最大值（softmax）是最终步骤：

$$\text{柔性最大值}\qquad \text{概率}p_j=\frac{1}{S}e^{w_j},\quad \text{其中}\quad S=\sum_{k=0}^{9}e^{w_k}.$$

## 10.3　均值、方差和协方差

（1）输出结果 $x_1\sim x_n$ 的概率加起来等于正数 $p_1,p_2,\cdots,p_n$.

（2）**均值** $m$ 是结果的平均值或期望值，计算公式为 $m=\sum p_ix_i$.

（3）**方差** $\sigma^2$ 是平均值标准差的平方，即从均值到各个结果的平均平方距离：$\sum p_i(x_i-m)^2$.

（4）若随机变量 $x_i$ 和 $y_j$ 的均值分别为 $m_x$ 和 $m_y$，则其**协方差**为 $\sum p_{ij}(x_i-m_x)(y_j-m_y)$.

均值很简单，我们就从均值开始. 我们面临两种不同的情况：一个已完成试验的结果（**样本值**），或者未来试验的预期结果（**期望值**）. 我们具体说明这两种情况的差异：

**样本值**　五个随机选取的新生年龄是 $18,17,18,19,17$

**样本均值**　基于采样数据，平均年龄是 $\frac{1}{5}(18+17+18+19+17)=17.8$

**概率**　新生班级的年龄分布是 17(20%)、18(50%) 和 19(30%).

随机新生的**年龄期望值** $E[x]=(0.2)\cdot17+(0.5)\cdot18+(0.3)\cdot19=18.1$.

17.8 和 18.1 都是正确的平均值. 样本均值基于已完成试验的 $N$ 个样本 $x_1\sim x_N$，它们的均值就是 $N$ 个观察样本的平均数：

$$\boxed{\text{样本均值} \qquad m = \mu = \frac{1}{N}(x_1 + x_2 + \cdots + x_N)} \tag{10.8}$$

$x$ 的期望值基于 $n$ 个年龄 $x_1, x_2, \cdots, x_n$ 的概率 $p_1, p_2, \cdots, p_n$：

$$\boxed{\text{期望值} \qquad m = E[x] = p_1 x_1 + p_2 x_2 + \cdots + p_n x_n} \tag{10.9}$$

所以期望值也是向量点积 $\boldsymbol{p} \cdot \boldsymbol{x}$. 期望值 $E[x]$ 告诉我们应该期待什么，而均值 $m = \mu$ 告诉我们实际上得到了什么.

一个均匀的硬币反面和正面的概率为 $p_0 = p_1 = \frac{1}{2}$. 因此，期望值 $E[x] = \frac{1}{2} \cdot 0 + \frac{1}{2} \cdot 1$. 投掷 $N$ 次硬币，正面的比例是样本均值，大数定律断言，随着样本量 $N$ 的增加，样本均值将以概率 1 收敛到其期望值 $E[x] = \frac{1}{2}$. 但这并不意味着，如果我们看到的反面比正面多，下一个样本更有可能是正面；正反面的概率仍然是 50% 对 50%.

前 1000 次投掷硬币，其结果影响样本矩阵，但是不影响样本均值的极限——因为最终要把 $N$ 除以 $\infty$.

注意，概率论和统计学对于现代应用数学至关重要. 在多次实验中，均值 $\boldsymbol{m}$ 表示为一个向量，方差/协方差组成一个矩阵. 利用线性代数的方法，对协方差矩阵进行对角化，那样我们就能更好地理解它了.

### 10.3.1 方差

方差 $\sigma^2$ 衡量了到期望均值 $E[x]$ 的期望距离的平方. 样本方差 $S^2$ 衡量了到实际样本均值的实际距离的平方. 它们的平方根称作标准差 $\sigma$ 或 $S$. 在期末考试后，我把均值 $\mu$ 和样本标准差 $S$ 发邮件给所有同学. 我并不知道期望均值 $m$ 和期望方差 $\sigma^2$，因为我们不知道 $0 \sim 100$ 每个分数的概率 $p_0, p_1, \cdots, p_{100}$.

距离永远是指到均值——样本均值或者期望均值——的距离. 我们也在寻找围绕着均值 $x = m$ 的“扩散”程度. 从 $N$ 个样本的例子开始：

$$\text{样本方差} \qquad S^2 = \frac{1}{N-1}\left[(x_1 - m)^2 + (x_2 - m)^2 + \cdots + (x_N - m)^2\right] \tag{10.10}$$

例如，年龄样本为 $x = 18, 17, 18, 19, 17$ 的均值是 $m = 17.8$，该样本的方差是 0.7:

$$S^2 = \frac{1}{4}\left[(0.2)^2 + (-0.8)^2 + (0.2)^2 + (1.2)^2 + (-0.8)^2\right] = \frac{1}{4} \cdot 2.8 = 0.7.$$

在计算平方时，负号消失了. 请注意！统计学家用 $N - 1 = 4$（而不是 $N = 5$）来除，以使 $S^2$ 是无偏估计量 $\sigma^2$. 其中一个自由度已经在样本均值中考虑了.

把每一项 $(x - m)^2$ 展开成 $x^2 - 2mx + m^2$，就得到一个重要的等式：

$$\begin{aligned} \sum (x_i - m)^2 &= \sum (x_i^2) - 2m \sum x_i + \sum m^2 \\ &= \sum x_i^2 - 2m(Nm) + Nm^2 \\ &= \boldsymbol{\sum x_i^2 - Nm^2} \end{aligned} \tag{10.11}$$

换言之，通过对 $x_i^2$ 求和也能计算出 $(x_1 - m)^2 + (x_2 - m)^2 + \cdots + (x_N - m)^2$.

现在再考虑各个样本的概率 $p_i$（一定是非负的!）. 那么，不仅仅是样本值，我们还可以求出期望值. **在统计中，方差 $\sigma^2$ 是关键数值.**

$$\boxed{\text{方差}\qquad \sigma^2 = E[(x-m)^2] = p_1(x_1-m)^2 + p_2(x_2-m)^2 + \cdots + p_n(x_n-m)^2.} \tag{10.12}$$

我们把到期望值 $m = E[x]$ 的距离平方求和；我们只有期望值，而没有样本值. 我们知道概率，但是不知道实验结果. 关于样本方差 $S^2$ 的式(10.10)可以直接拓展到关于方差 $\sigma^2$ 的式(10.13)：

$$\sum p_i(x_i-m)^2 = \sum p_i x_i^2 - \left(\sum p_i x_i\right)^2 \quad \text{或者} \quad \boxed{\sigma^2 = E[x^2] - (E[x])^2} \tag{10.13}$$

**例 10.1**　投掷硬币有两个输出 $x=0$ 和 $x=1$，其概率是 $p_0 = p_1 = \dfrac{1}{2}$.

**均值 $m$**　$= \dfrac{1}{2}\cdot 0 + \dfrac{1}{2}\cdot 1 = \dfrac{1}{2}$ = 输出结果的平均数 $= E[x]$

**方差 $\sigma^2$**　$= \dfrac{1}{2}\cdot\left(0-\dfrac{1}{2}\right)^2 + \dfrac{1}{2}\cdot\left(0-\dfrac{1}{2}\right)^2 = \dfrac{1}{8}+\dfrac{1}{8} = \dfrac{1}{4}$ = 到 $m$ 的距离的平方的均值

对于到 $m$ 的平均距离（不是距离的平方），你有什么猜测？$E[x-m] = 0$!

**例 10.2**　求一个学院新生年龄的方差 $\sigma^2$.

**解**　年龄 $x = 17$，18，19 的概率依次是 $p = 0.2$，0.5，0.3，那么期望值是 $m = \sum p_i x_i = 18.1$. 方差的计算用了同样的概率：

$$\begin{aligned}\sigma^2 &= (0.2)(17-18.1)^2 + (0.5)(18-18.1)^2 + (0.3)(19-18.1)^2 \\ &= (0.2)(1.21) + (0.5)(0.01) + (0.3)(0.81) = 0.49\end{aligned}$$

因此 $\sigma = 0.7$. 这衡量了 17、18、19，以概率 0.2、0.5、0.3 为权重，围绕 $E[x]$ 的扩散程度.

### 10.3.2　连续概率分布

到目前为止，我们讨论的年龄仅限于 17 岁、18 岁和 19 岁这三种情况. 如果我们改用天数来衡量年龄，那么可能的年龄将变得非常多. 因此，更合理的方法是考虑 17 ~ 20 岁的每一个实数，形成一个连续的年龄范围. 这样，原先年龄 $x_1$、$x_2$、$x_3$ 对应的概率 $p_1$、$p_2$、$p_3$ 就转变成了一个年龄 $x$ 在 $17 \leqslant x \leqslant 19$ 的概率分布 $p(x)$.

为了更好地解释概率分布，我将给出两个示例：**均匀分布**和**正态分布**. 首先是均匀分布，它相对简单. 而正态分布则是非常重要的一个概念.

**均匀分布**　假设年龄在 17.0 ~ 20.0 呈均匀分布. 这意味着每个年龄出现的可能性是相等的. 当然，具体到某一个确切的年龄，比如 17.1 岁或 $17+\sqrt{2}$ 岁，其出现的概率实际上是零. 但是我们能够计算出**一个随机的新生年龄小于某个值 $x$ 的概率**，这个概率用 $F(x)$ 来表示.

| | |
|---|---|
| 年龄小于 $x = 17$ 的概率是 $F(17) = 0$ | $x \leqslant 17$ 不可能发生 |
| 年龄小于 $x = 20$ 的概率是 $F(20) = 1$ | $x \leqslant 20$ 一定发生 |
| 年龄小于 $x$ 的概率是 $F(x) = \dfrac{1}{3}(x-17)$ | 从 17 到 20，$F$ 取值从 0 到 1 |

在 17 岁到 20 岁这个区间内，累积分布函数 $F(x)$ 线性递增，这是因为概率密度函数 $p(x)$ 是常值函数.

当然可以说 $p(x)\,\mathrm{d}x$ 是样本在 $x$ 和 $x+\mathrm{d}x$ 之间的概率之差. 在无穷小意义上，这是正确的：$p(x)\,\mathrm{d}x$ 即 $F(x+\mathrm{d}x)-F(x)$. 用微积分来叙述即

$$p(x) \text{ 是} F(x) \text{ 的导数，} F(x) \text{ 是} p(x) \text{ 的积分.}$$

$$\boxed{a \leqslant x \leqslant b\text{的概率}=\int_a^b p(x)\,\mathrm{d}x = F(b)-F(a)} \tag{10.14}$$

$F(b)$ 是 $x \leqslant b$ 的概率，减去 $F(a)$ 保证了 $x \geqslant a$，差值即 $\mathrm{Prob}\{a \leqslant x \leqslant b\}$.

### 10.3.3 $p(x)$ 的均值和方差

概率分布函数和概率密度函数如图 10.8 所示.

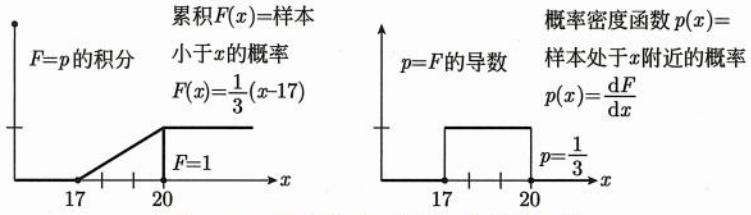


图 10.8 概率分布函数和概率密度函数

注：$F(x)$ 是**累积分布函数**，其导数 $p(x)=\mathrm{d}F/\mathrm{d}x$ 是**概率密度函数**（简称**pdf**）. 横坐标到 $x$ 的 $p(x)$ 的图像下方部分面积等于 $F(x)$.

那么一个概率分布的均值 $m$ 和方差 $\sigma^2$ 是什么呢？先前在离散情形，我们把 $p_i x_i$ 相加得到均值（期望值）；对于连续分布，我们对 $xp(x)$**积分**：

$$\boxed{\begin{aligned} &\text{均值}\quad m=E[x]=\int xp(x)\,\mathrm{d}x \\ &\text{方差}\quad \sigma^2=E[(x-m)^2]=\int p(x)(x-m)^2\,\mathrm{d}x \end{aligned}}$$

当年龄在 $17\sim20$ 岁均匀分布时，均值是 $m=18.5$，方差是 $\sigma^2=\dfrac{3}{4}$：

$$\sigma^2=\int_{17}^{20}\frac{1}{3}(x-18.5)^2\,\mathrm{d}x=\int_0^3\frac{1}{3}(x-1.5)^2\,\mathrm{d}x=\frac{1}{9}(x-1.5)^3\Big|_{x=0}^{x=3}=\frac{2}{9}(1.5)^3=\frac{3}{4}.$$

这是典型的例子. 下表是 $0\sim a$ 均匀分布 $p(x)$ 的完整的参数表：

$0 \leqslant x \leqslant a$ 的均匀分布

| | |
|---|---|
| 概率密度函数 $p(x)=\dfrac{1}{a}$ | 累积分布函数 $F(x)=\dfrac{x}{a}$ |
| 均值 $m=\displaystyle\int xp(x)\,\mathrm{d}x=\frac{a}{2}$ | 方差 $\sigma^2=\displaystyle\int_0^a\frac{1}{a}\left(x-\frac{a}{2}\right)^2\mathrm{d}x=\frac{a^2}{12}$ |

对于在 0 到 1 的一个随机数，其均值为 $\frac{1}{2}$，方差为 $\sigma^2 = \frac{1}{12}$.

### 10.3.4　正态分布：钟形曲线

正态分布也被称为高斯分布，是所有概率密度函数中最重要的. 其之所以有极度的重要性，是因为当我们多次重复某一实验并计算其结果的平均值时，这些平均值会趋向于形成一个正态分布. 每个实验都有其独特的分布特征（例如，抛硬币时出现的正面和反面）. 随着实验次数的增加，这些平均值的分布会越来越接近于正态分布. 标准正态分布如图 10.9 所示.

> 中心极限定理（非正式表述）：对任何概率分布，取 $N$ 个样本并计算这些样本的平均值，那么当 $N$ 趋于无穷时，这些平均值的分布趋于一个正态分布.

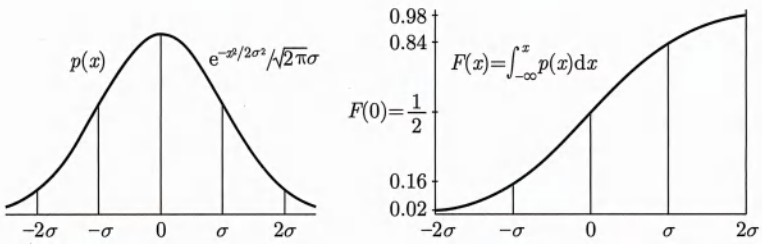


(a) $\mathbf{N}(0,\sigma^2)$的概率密度函数图像　　(b) 密度函数$F(x)$的图像

图 10.9　标准正态分布（均值 $m=0$，标准差 $\sigma=1$）

标准正态分布 $p(x)$ 关于 $x=0$ 对称，所以均值 $\boldsymbol{m=0}$，标准方差 $\sigma^2=1$. 我们也用 $\mathbf{N}(0,1)$ 来记标准正态分布.

$$p(x)=\frac{1}{\sqrt{2\pi}}\mathrm{e}^{-x^2/2} \text{ 的图像是钟形曲线，方差 } \sigma^2=1.$$

用积分计算出 $\sigma^2=1$ 可以借助习题 11 中的想法. 图 10.9(a) 是 $\mathbf{N}(0,\sigma^2)$ 的概率密度函数的图像，图 10.9(b) 是密度函数 $F(x)$（也即 $p(x)$ 的变上限定积分）的图像. 通过观察 $F(x)$，或者说 $p(x)$ 下方面积，我们可以发现一个非常重要的统计规律：随机抽取的样本值落在区间 $[-\sigma,\sigma]$ 内的概率 $F(\sigma)-F(-\sigma)$ 大约是 2/3. 这一点对于统计的应用，比如说民意调查来说，都非常重要.

同样地，随机变量 $x$ 落在区间 $[-2\sigma,2\sigma]$ 内的概率（即“在平均值左右两个标准差之内”）大约是 0.95. 因此，如果实验结果偏离平均值超过两个标准差，我们有理由相信这并非偶然. 任意给定平均值 $m$ 和标准差 $\sigma$ 的正态分布，可以通过对标准正态分布 $\mathrm{e}^{-x^2/2}/\sqrt{2\pi}$ 进行水平和垂直方向的平移和伸缩变换来得到. 把 $x$ 替换成 $x-m$，再把 $x-m$ 替换成 $(x-m)/\sigma$.

$$\text{正态分布}\mathbf{N}(m,\sigma^2)\text{的高斯密度}p(x)=\frac{1}{\sigma\sqrt{2\pi}}\mathrm{e}^{-(x-m)^2/2\sigma^2} \tag{10.15}$$

$p(x)$ 的积分是 $F(x)$，它表示随机样本落在 $x$ 以下的概率. 由于 $\mathrm{e}^{-x^2/2}$ 没有简单的积分公式，因此计算 $F(x)$ 要非常谨慎.

### 10.3.5 均值和方差：投掷 $N$ 次硬币，以及 $N \to \infty$ 的渐进行为

**例 10.3** 设 $x$ 取值 1 和 $-1$ 的概率相等：$p_1 = p_{-1} = \dfrac{1}{2}$.

均值 $\boldsymbol{m = \frac{1}{2}(1) + \frac{1}{2}(-1) = 0}$，方差 $\boldsymbol{\sigma^2 = \frac{1}{2}(1)^2 + \frac{1}{2}(-1)^2 = 1}$.

关键问题是计算平均值$A_N = (x_1 + x_2 + \cdots + x_N)/N$；其中，独立变量 $x_i$ 均取值于 $\pm 1$，我们将它们的和除以 $N$.$A_N$ 的预期均值仍然是 0. 大数定律断言：样本平均 $A_N =$ (正面朝上的次数 $-$ 反面朝上的次数)$/N$ 以概率 1 趋于 0. 那么，$A_N$ 趋于零的速度是怎样的？其方差$\sigma_N^2$是多少？

由线性性：

$$\boldsymbol{\sigma_N^2 = \frac{\sigma^2}{N^2} + \frac{\sigma^2}{N^2} + \cdots + \frac{\sigma^2}{N^2} = N\frac{\sigma^2}{N^2} = \frac{1}{N}}.$$

这里我提供三个我本人的数值验证：随机在 0、1 中取值 $N$ 次.

[$N = 100$ 时，有 48 次取 1]　　[$N = 10000$ 时，有 5035 次取 1]　　[$N = 40000$ 时，有 19967 次取 1]

将变量标准化 $\boldsymbol{X = (x - m)/\sigma} = (A_N - \frac{1}{2}) \times 2\sqrt{N}$，值是 [−0.40]、[0.70]、[−0.33].

中心极限定理指出，当进行许多次硬币投掷时，投掷结果的平均值会趋近于正态分布. 让我们来看看这是怎样发生的：**二项分布会趋于正态分布，而二项概率 $p_0, p_1, \cdots, p_N$ 就是 $N$ 次硬币投掷中得到正面的次数的概率.**

对于每次公平的投掷，得到正面的概率是 1/2. 因此，当 $N = 3$ 时，三次都得到正面的概率是 $(1/2)^3 = 1/8$. 而得到两次正面和一次反面的概率是 3/8，因为有三种可能的序列：HHT、HTH 和 THH.[①]

1/8 和 3/8 这两个概率是 $(1/2 + 1/2)^3 = \boldsymbol{\frac{1}{8} + \frac{3}{8} + \frac{3}{8} + \frac{1}{8}} = 1$ 展开式的组成部分. 3 次投掷，正面的平均次数是 1.5.

$$\boldsymbol{\text{均值}} = (3\text{次正面})\frac{\boldsymbol{1}}{\boldsymbol{8}} + (2\text{次正面})\frac{\boldsymbol{3}}{\boldsymbol{8}} + (1\text{次正面})\frac{\boldsymbol{3}}{\boldsymbol{8}} + (0\text{次正面})\frac{\boldsymbol{1}}{\boldsymbol{8}} = \frac{3}{8} + \frac{6}{8} + \frac{3}{8} = \boldsymbol{1.5}\text{次正面}$$

投掷 $N$ 次硬币，无论是例 10.3还是直觉都告诉我们均值是 $\boldsymbol{m = \sum x_i p_i = \frac{N}{2}}$ 次正面.

方差 $\sigma^2$ 基于变量到均值 $N/2$ 的距离的平方. 例如，$N = 3$ 时，方差 $\sigma^2 = \boldsymbol{\frac{3}{4}}$（即 $N/4$），我们对 $p_i(x_i - m)^2$ 求和来计算 $\sigma^2$，其中 $m = 1.5$：

$$\boldsymbol{\sigma^2} = (3 - 1.5)^2\frac{1}{8} + (2 - 1.5)^2\frac{3}{8} + (1 - 1.5)^2\frac{3}{8} + (0 - 1.5)^2\frac{1}{8} = \frac{9 + 3 + 3 + 9}{32} = \boldsymbol{\frac{3}{4}}$$

① 译者注：H 是 head 的首字母，是指正面；T 是 tail 的首字母，是指反面.

对任意 $N$，二项分布的方差 $\boldsymbol{\sigma_N^2 = N/4}$，从而 $\sigma_N = \sqrt{N}/2$.

图 10.10将展示投 $N = 4$ 次硬币，得到 0、1、2、3、4 次正面的概率是如何趋近于钟形的高斯分布的. 我们目睹了中心极限定理的强大威力. 该高斯分布以平均值 $m = N/2 = 2$ 为中心.

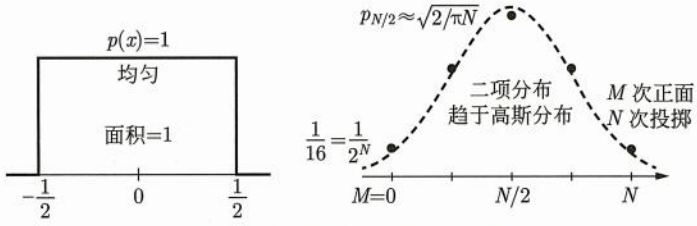


**图 10.10　中心极限定理示意图**

注：投 4 次硬币正面次数的概率 $\boldsymbol{p} = (1,4,6,4,1)/16$. $p_i$ 最终趋于中心点在 $m = N/2$、方差为 $\sigma^2 = N/4$ 的高斯分布. 中心极限定理说明 $X$ 最终收敛于正态分布 $\mathbf{N}(0,1)$.

为了将其转换为标准正态分布（平均值 0 和方差 1），我们需要进行移位和重新缩放. 如果 $x$ 是在 $N$ 次投掷中得到的正面次数，即 $N$ 个 $0-1$ 随机数的平均值，那么我们需要将 $x$ 平移其均值 $m = N/2$，并按标准差 $\sigma = \sqrt{N}/2$ 缩放，以得到标准化的 $X$.

平移和缩放：$X = \dfrac{x-m}{\sigma} = \dfrac{x - \frac{1}{2}N}{\sqrt{N}/2}$　（$N = 4$ 时，$X = x - 2$）.

减去 $m$ 是“中心化”或“去趋势化”. $X$ 的均值为零.

除以 $\sigma$ 是“正规化”或“标准化”. $X$ 的方差是 1.

观察到中心极限定理在中心点 $X = 0$ 给出正确结果是非常有趣的. 在这个点上，指数函数 $\mathrm{e}^{-X^2/2}$ 的值等于 1. 我们知道，投掷 $N$ 次硬币的方差 $\sigma^2$ 是 $N/4$. 钟形曲线的最高点，即其中心的高度是 $1/\sqrt{2\pi}\sigma = \sqrt{2/\pi N}$.

对于硬币投掷的分布（即二项分布），其中心点的高度是多少？当 $N = 4$ 时，得到 0、1、2、3、4 次正面的概率 $p_0 \sim p_4$ 可以用 $\left(\frac{1}{2}+\frac{1}{2}\right)^4$ 来计算.

$$\text{中心点概率} = \frac{\mathbf{6}}{\mathbf{16}} \qquad \left(\frac{1}{2}+\frac{1}{2}\right)^4 = \frac{1}{16}+\frac{4}{16}+\frac{6}{16}+\frac{4}{16}+\frac{1}{16} = 1. \tag{10.16}$$

将 $\left(\frac{1}{2}+\frac{1}{2}\right)^N$ 二项展开可得 $0,1,\cdots,N$ 次正面的概率；

中间项是——$\frac{N}{2}$ 次正面、$\frac{N}{2}$ 次反面的概率：$\dfrac{1}{2^N}\dfrac{N!}{(N/2)!(N/2)!}$.

若 $N = 4$，这些阶乘的结果是 $\dfrac{4!}{2!2!} = \dfrac{24}{4} = 6$. 当 $N$ 很大时，Stirling 公式 $\sqrt{2\pi N}(N/\mathrm{e})^N$ 非常接近 $N!$，用它来估计 $N!$ 和 $(N/2)!$ 得

$$\text{二项概率中心点处的极限} \qquad p_{N/2} \simeq \frac{1}{2^N}\frac{\sqrt{2\pi N}(N/\mathrm{e})^N}{\pi N(N/2\mathrm{e})^N} = \frac{\sqrt{2}}{\sqrt{\pi N}} = \frac{\mathbf{1}}{\sqrt{\mathbf{2\pi}}\boldsymbol{\sigma}} \tag{10.17}$$

最后一个等号用到了 $N$ 次投掷的方差 $\sigma^2 = N/4$. 最后结果 $1/\sqrt{2\pi}\sigma$ 和高斯分布在中心点处的取值（前文提到的 $\sqrt{2/N\pi}$）吻合. 这也说明了中心极限定理的正确性：

$$\text{中心化的二项分布区域正态分布} \quad N(0,\sigma^2).$$

### 10.3.6 协方差矩阵和联合概率

当我们同时进行 $M$ 个不同的实验时，线性代数就可以派上用场了. 例如，我们可能会同时测量 $N$ 个孩子的年龄和身高（$M=2$）. 每一项指标都有一个均值, 因此我们可以得到一个包含两个均值的向量 $\boldsymbol{m} = \begin{bmatrix} m_a & m_h \end{bmatrix}^{\mathrm{T}}$. 这两个平均值可以是年龄和身高的样本平均值. 另外，$m_1$ 和 $m_2$ 也可以是基于年龄和身高已知概率的期望值.

当我们考虑年龄和身高的方差时，矩阵就变得重要了. 每个实验都会有其样本方差 $S_i^2$ 和基于样本到均值的距离平方的期望方差 $\sigma_i^2 = E[(x_i - m)^2]$. 这两个方差 $\sigma_1^2$ 和 $\sigma_2^2$ 构成了“方差 -协方差矩阵”的主对角线. 然而，至今我们还未考虑两个平行实验之间的联系. 尽管它们测量的是不同的随机变量，但年龄和身高并非相互独立.

如果我们测量儿童的年龄和身高，会发现这两个变量之间强相关. 通常情况下，年龄较大的儿童身高也相对较高. 假设我们已知年龄和身高的均值 $m_a$ 和 $m_h$. 注意，$\sigma_a^2$ 和 $\sigma_h^2$ 分别代表年龄和身高的方差；而新的关键指标是衡量不同年龄与身高之间的关联性的协方差 $\sigma_{ah}$.

$$\boxed{\text{协方差} \qquad \sigma_{ah} = E\big[(\text{年龄} - \text{年龄均值})(\text{身高} - \text{身高均值})\big]} \tag{10.18}$$

我们需要仔细审视这个定义. 仅仅知道每个年龄和身高各自的概率是不够的，因为年龄和身高是相互关联的，我们还需要了解每一对年龄和身高的联合概率 $p_{ah}$.

$p_{ah}$ 表示随机选择的儿童同时具有年龄 $a$ 和身高 $h$ 的概率.

$p_{ij}$ 表示实验 1 得到结果 $x_i$ 且实验 2 得到结果 $y_j$ 的概率.

假设实验 1（年龄）的均值是 $m_1$，实验 2（身高）的均值是 $m_2$. 实验 1 和实验 2 之间的协方差考虑了年龄 $x_i$ 和身高 $y_j$ 所有可能的组合. 为了与式(10.18)保持一致，我们需要乘以对应的年龄-身高对的联合概率 $p_{ij}$.

$$(x - m_1)(y - m_2)\text{的期望值} \qquad \boxed{\text{协方差}\sigma_{12} = \sum_{i,j} p_{ij}(x_i - m_1)(y_j - m_2)} \tag{10.19}$$

我们从两个简单的例子入手理解“联合概率 $p_{ij}$”的概念.

**例 10.4** 分别投掷两个硬币，用 1 来记正面，0 记反面，那么结果可能是 $(1,1)$、$(1,0)$、$(0,1)$、$(0,0)$. 这四种结果的概率都是 $\left(\frac{1}{2}\right)^2 = \frac{1}{4}$. 独立实验的概率只需要把各自概率相乘：协方差等于 0.

$$p_{ij} = (i,j)\text{的概率} = (i\text{的概率}) \times (j\text{的概率}).$$

**例 10.5** 以同样的方向，把两个硬币粘一起扔. 此时结果只有两种可能性：$(1,1)$ 和 $(0,0)$，概率分别都是 $\frac{1}{2}$ 和 $\frac{1}{2}$. 因为硬币被粘在一起了，要么都是正面，要么都是反面，$(1,0)$ 和 $(0,1)$ 不可能发生，所以 $p_{01} = p_{10} = 0$.

例 10.4 和例 10.5 中的联合概率矩阵　$\boldsymbol{P}_4=\begin{bmatrix}\frac{1}{4}&\frac{1}{4}\\ \frac{1}{4}&\frac{1}{4}\end{bmatrix}$　$\boldsymbol{P}_5=\begin{bmatrix}\frac{1}{2}&0\\ 0&\frac{1}{2}\end{bmatrix}$

详细解释一下矩阵 $\boldsymbol{P}$，以便更好地用矩阵来表示. 这个矩阵蕴含了每一对 $(x_i,y_j)$ 的概率 $p_{ij}$，例如，$(x_1,y_1)=$（正面，正面）和 $(x_1,y_2)=$（正面，反面）. 另外，矩阵的每一行总和为 $p_1$ 和 $p_2$，每一列之和为 $p_1'$ 和 $p_2'$，且整个矩阵所有元素的总和等于 1.

概率矩阵　$\boldsymbol{P}=\begin{bmatrix}p_{11}&p_{12}\\ p_{21}&p_{22}\end{bmatrix}$　$p_{11}+p_{12}=p_1$　（第一个硬币）

（第二个硬币）　$p_1'$　$p_2'$　$p_{21}+p_{22}=p_2$　4 个元素总和为 1

$p_1$、$p_2$，以及 $p_1'$、$p_2'$ 是联合概率分布 $\boldsymbol{P}$ 的边缘概率.

$p_1=p_{11}+p_{12}=$ 硬币 1 是正面的概率（硬币 2 可能是正面也可能是反面）

$p_1'=p_{11}+p_{21}=$ 硬币 2 是正面的概率（硬币 1 可能是正面也可能是反面）

例 10.4中的随机变量是独立的，所以 $p_{ij}$ 都等于 $p_i\cdot p_j$（该例中所有 $p_{ij}=\frac{1}{2}\frac{1}{2}=\frac{1}{4}$）. 在这种情况下，斜方差 $\sigma_{12}=0$. 第一个硬币正面或者反面，对第二个硬币没有任何影响，无法提供任何信息.

独立测试的协方差 $\sigma_{12}=0$　$\boldsymbol{V}=\begin{bmatrix}\sigma_1^2&0\\ 0&\sigma_2^2\end{bmatrix}$　协方差矩阵是对角矩阵

因为式(10.19) 中 $p_{ij}$ 都等于 $p_ip_j$，所以 $\sigma_{12}=0$：

$$\sigma_{12}=\sum_{i,j}p_ip_j(x_i-m_1)(y_j-m_2)=\left[\sum_i(p_i)(x_i-m_1)\right]\left[\sum_j(p_j)(y_j-m_2)\right]=[0][0].$$

**例 10.6**　两枚粘在一起的硬币的正反面完全一致，一枚硬币显示正面，另一枚也会显示正面. 这是关联性很直观的体现. 而协方差 $\sigma_{12}$ 从毫无关联时的 0 变为 $\sigma_1$ 与 $\sigma_2$ 的乘积，这是 $\sigma_{12}$ 可能的最大值，其结算结果为 $\frac{1}{2}\frac{1}{2}=\frac{1}{4}$：

均值$=\frac{1}{2}$　$\sigma_{12}=\frac{1}{2}\left(1-\frac{1}{2}\right)\left(1-\frac{1}{2}\right)+0+0+\frac{1}{2}\left(0-\frac{1}{2}\right)\left(0-\frac{1}{2}\right)=\frac{1}{4}$

从第一个硬币的正反面可以完全获知第二个硬币的正反面：

硬币粘在一起时，协方差取最大值
斜方差矩阵不可逆，因为行列式 $=0$　$\boldsymbol{V}_{\text{glue}}=\begin{bmatrix}\sigma_1^2&\sigma_1\sigma_2\\ \sigma_1\sigma_2&\sigma_2^2\end{bmatrix}$

在任何情况下，不等式 $\sigma_1^2\sigma_2^2\geqslant(\sigma_{12})^2$ 始终成立. 这说明矩阵 $\boldsymbol{V}$ 一定是半正定的. 这一重要事实，对于来源于 $M$ 个实验的 $M\times M$ 的协方差矩阵 $\boldsymbol{V}$ 也成立.

由 $N$ 次测试给出的样本协方差矩阵 $S$当然也是半正定的. 比如，样本 $X=$(年龄，身高) 给出样本均值 $\overline{X}=(m_a,m_h)$. 每个秩 1 项 $(X_i-\overline{X})(X_i-\overline{X})^{\mathrm{T}}$ 都是半正定的，把它们相加即得样本

协方差矩阵 $S$. $S$ 中不包含概率，只有实际观测结果：

$$\overline{\boldsymbol{X}}=\frac{X_1+X_2+\cdots+X_N}{N},\qquad \boldsymbol{S}=\frac{(X_1-\overline{X})(X_1-\overline{X})^{\mathrm{T}}+(X_2-\overline{X})(X_2-\overline{X})^{\mathrm{T}}+\cdots+(X_N-\overline{X})(X_N-\overline{X})^{\mathrm{T}}}{N-1} \tag{10.20}$$

### 10.3.7 协方差矩阵 $V$ 的半正定性

我们重新回顾两个实验之间的期望协方差 $\sigma_{12}$:

$$\begin{aligned}&\sigma_{12}=[(\text{结果1}-\text{均值1})(\text{结果2}-\text{均值2})]\text{的期望；}\\&\boldsymbol{\sigma_{12}=\sum_{i,j}p_{ij}(x_i-m_1)(y_j-m_2).}\quad\text{其中求和包含所有 } i、j.\end{aligned} \tag{10.21}$$

$p_{ij}\geqslant 0$ 是实验 1 发生 $x_i$ 同时实验 2 发生 $y_j$ 的概率. 某些结果会成对发生，并且 $n^2$ 个联合概率 $p_{ij}$ 相加之和等于 1.

所有结果发生的概率总和是 1 $$\sum_{i,j}p_{ij}=1. \tag{10.22}$$

我们还需要另外一个事实. 固定实验 1 中的某个结果 $x_i$，考虑实验 2 的所有结果 $y_j$，那么把结果对 $(x_i,y_1),(x_2,y_2),\cdots,(x_i,y_n)$ 的概率相加：

$\boldsymbol{P}$ 的第 $i$ 行之和$\boldsymbol{p_i}$ $$\sum_{j=1}^{n}p_{ij}=\text{实验 1 中 } x_i \text{ 发生的概率 } p_i. \tag{10.23}$$

在实验 2 中，某些结果 $y_j$ 必然会出现！两枚硬币无论是分离的还是粘在一起的，我们计算得出硬币 1 正面的概率 $p_{\mathrm{H}}$（即 $p_{\mathrm{HH}}+p_{\mathrm{HT}}$）都是 1/2：

$$\text{（分离的）}\ p_{\mathrm{HH}}+p_{\mathrm{HT}}=\frac{1}{4}+\frac{1}{4}=\frac{1}{2}\qquad\text{（粘连的）}\ p_{\mathrm{HH}}+p_{\mathrm{HT}}=\frac{1}{2}+0=\frac{1}{2}$$

这个基本的事实使我们能够写出一个包含协方差 $\sigma_{12}$ 以及实验 1 和实验 2 各自的方差 $\sigma_1^2$ 和 $\sigma_2^2$ 的公式. 我们将每一对 $(i,j)$ 对应的矩阵 $\boldsymbol{V}_{ij}$ 相加得到整个协方差矩阵 $\boldsymbol{V}$：

协方差矩阵$\boldsymbol{V}$ =所有$\boldsymbol{V_{ij}}$的和 $$\boldsymbol{V}=\sum_{i,j}p_{ij}\begin{bmatrix}(x_i-m_1)^2 & (x_i-m_1)(y_j-m_2)\\(x_i-m_1)(y_j-m_2) & (y_j-m_2)^2\end{bmatrix} \tag{10.24}$$

对角线以外的项和式(10.19)协方差 $\sigma_{12}$ 的表达式一样；对角线上正是通常的方差 $\sigma_1^2$ 和 $\sigma_2^2$. 下面利用式(10.23)详细地证明 $V_{11}=\sigma_1^2$.

$$V_{11}=\sum_{i,j}p_{ij}(x_i-m_1)^2=\sum_i p_i(x_i-m_1)^2=\boldsymbol{\sigma_1^2}. \tag{10.25}$$

第二个等号是因为对每一个固定的 $i$，对 $p_{ij}$ 求和等于 $p_i$.

我们再看一遍. 这是通过式(10.24)生成整个协方差矩阵的关键. 该公式的美妙之处在于它把所有的 $2\times 2$ 矩阵 $\boldsymbol{V}_{ij}$ 组合起来了. 并且在式(10.24)中，对每一对 $i$、$j$，矩阵 $\boldsymbol{V}_{ij}$ 都是半正定的：

对角线的元素满足 $p_{ij}(x_i-m_1)^2 \geqslant 0$ 和 $p_{ij}(y_j-m_2)^2 \geqslant 0$，且其行列式 $\det(\boldsymbol{V}_{ij})=0$.

$\boldsymbol{V}_{ij}$ 都是秩 1 矩阵：

$$\begin{bmatrix} (x_i-m_1)^2 & (x_i-m_1)(y_j-m_2) \\ (x_i-m_1)(y_j-m_2) & (y_j-m_2)^2 \end{bmatrix} = \begin{bmatrix} x_i-m_1 \\ y_j-m_2 \end{bmatrix} \begin{bmatrix} x_i-m_1 & y_j-m_2 \end{bmatrix} = \boldsymbol{u}_{ij}\boldsymbol{u}_{ij}^{\mathrm{T}}$$

所以式(10.24)右端是对 $p_{ij}\boldsymbol{u}_{ij}\boldsymbol{u}_{ij}^{\mathrm{T}}$ 求和. 因为每个矩阵 $p_{ij}\boldsymbol{u}_{ij}\boldsymbol{u}_{ij}^{\mathrm{T}}$ 都是半正定的，所以 $\boldsymbol{V}$（半正定秩 1 矩阵的和）也至少是半正定的. 但是一般来说，$\boldsymbol{V}$ 是正定矩阵：

**协方差矩阵 $V$ 正定，除非实验不独立.**

现在，我们不仅仅关注两个变量 $x$ 和 $y$，而且关注 $M$ 个变量，例如 3 个变量：年龄、身高和体重. 每个孩子都有一个包含年龄、身高和体重的向量 $\boldsymbol{X}$，这个向量有 $M=3$ 个分量. 协方差矩阵 $\boldsymbol{V}$ 是 $M\times M$ 矩阵，由向量 $\boldsymbol{X}$ 和它们的均值 $\overline{\boldsymbol{X}}=E[\boldsymbol{X}]$ 构建：

$$\boxed{\text{协方差矩阵} \qquad \boldsymbol{V}=E[(\boldsymbol{X}-\overline{\boldsymbol{X}})(\boldsymbol{X}-\overline{\boldsymbol{X}})^{\mathrm{T}}] \qquad \boldsymbol{V}_{ij}=p_{ij}(X_i-m_i)(X_j-m_j)} \tag{10.26}$$

需要提醒的是，$\boldsymbol{X}\boldsymbol{X}^{\mathrm{T}}$ 和 $\overline{\boldsymbol{X}}\,\overline{\boldsymbol{X}}^{\mathrm{T}}$ 是列向量乘以行向量，所以都是 $M\times M$ 矩阵.

当 $M=1$ 时，$\overline{\boldsymbol{X}}$ 是均值，$\boldsymbol{V}$ 是方差 $\sigma^2$. 当 $M=2$ 时，$\overline{\boldsymbol{X}}=(m_1,m_2)$，并且 $\boldsymbol{V}$ 和式(10.24)一致. 期望总是将输出乘以其概率之后再相加. 以“年龄 -身高 -重量”为例，输出可以是 $\boldsymbol{X}$ =(5 岁，31 英尺，48 英镑)，它的概率记作 $p_{5,31,48}$.

---

我们现在又有了新的方法. 取这些随机变量的线性组合：$\boldsymbol{c}^{\mathrm{T}}\boldsymbol{X}=c_1X_1+c_2X_2+\cdots+c_MX_M$.

例如，取 $\boldsymbol{c}=\begin{bmatrix}6\\2\\5\end{bmatrix}^{\mathrm{T}}$，那么 $\boldsymbol{c}^{\mathrm{T}}\boldsymbol{X}=6\times$ 年龄 $+2\times$ 身高 $+5\times$ 体重. 由线性性，$\boldsymbol{c}^{\mathrm{T}}\boldsymbol{X}$ 的均值= 期望值 $E[\boldsymbol{c}^{\mathrm{T}}\boldsymbol{X}]=\boldsymbol{c}^{\mathrm{T}}E[\boldsymbol{X}]=\boldsymbol{c}^{\mathrm{T}}\overline{\boldsymbol{X}}$

$$E[\boldsymbol{c}^{\mathrm{T}}\boldsymbol{X}]=\boldsymbol{c}^{\mathrm{T}}E[\boldsymbol{X}]=6(\text{年龄期望值})+2(\text{身高期望值})+5(\text{体重期望值}).$$

不光是 $\boldsymbol{c}^{\mathrm{T}}\boldsymbol{X}$ 的均值，它的方差也可知 $\sigma^2=\boldsymbol{c}^{\mathrm{T}}\boldsymbol{V}\boldsymbol{c}$：

$$\boldsymbol{c}^{\mathrm{T}}\boldsymbol{X}\text{的方差}=\boldsymbol{c}^{\mathrm{T}}E\left[(\boldsymbol{X}-\overline{\boldsymbol{X}})(\boldsymbol{X}-\overline{\boldsymbol{X}})^{\mathrm{T}}\right]\boldsymbol{c}=\boldsymbol{c}^{\mathrm{T}}\boldsymbol{V}\boldsymbol{c}. \tag{10.27}$$

根据 $\boldsymbol{c}^{\mathrm{T}}\boldsymbol{X}$ 的方差非负这一重要事实可知，$\boldsymbol{c}^{\mathrm{T}}\boldsymbol{V}\boldsymbol{c}\geqslant 0$. 而这一结论正是 $\boldsymbol{V}$ 半正定的能量判据，所以实际上我们给出了协方差矩阵半正定的新证明.

协方差矩阵 $\boldsymbol{V}$ 揭示了概率论与线性代数之间的深刻联系：$\boldsymbol{V}$ 可以分解为 $\boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\mathrm{T}}$ 的形式，其中特征值 $\lambda_i$ 均大于或等于 0，而特征向量 $\boldsymbol{q}_1$ 到 $\boldsymbol{q}_M$ 则是彼此正交的.

对协方差矩阵 $\boldsymbol{V}$ 进行对角化，实际上意味着我们能够找到 $M$ 个独立的实验，这些实验是由最初的 $M$ 个实验以某种方式组合而成的.

### 10.3.8　$Z=AX$ 的协方差矩阵

如果随机变量 $z=x+y$，我们有一个研究 $\sigma_z^2$ 的好方式. 考虑列向量 $\boldsymbol{x}=\begin{bmatrix}x\\y\end{bmatrix}$ 以及 $1\times 2$

矩阵 $\boldsymbol{A}=\begin{bmatrix}1 & 1\end{bmatrix}^{\mathrm{T}}$，那么 $z=x+y=\boldsymbol{AX}$，于是用矩阵乘法表示 $\sigma_z^2$ 有

$$\sigma_z^2=\begin{bmatrix}1 & 1\end{bmatrix}^{\mathrm{T}}\begin{bmatrix}\sigma_x^2 & \sigma_{xy}\\ \sigma_{xy} & \sigma_y^2\end{bmatrix}\begin{bmatrix}1\\1\end{bmatrix}\quad\text{即}\quad\sigma_z^2=\boldsymbol{AV}\boldsymbol{A}^{\mathrm{T}}\tag{10.28}$$

现在来到了核心部分. 向量 $\boldsymbol{X}$ 可以包含来自 $M$ 个实验的 $M$ 个分量（而不仅仅是 2 个）. 这些实验将产生一个 $M\times M$ 协方差矩阵 $\boldsymbol{V_X}$. 矩阵 $\boldsymbol{A}$ 可能是 $K\times M$ 矩阵，因此 $\boldsymbol{AX}$ 是 $M$ 个输出（而不仅仅两个输出 $x$ 和 $y$）的 $K$ 个线性组合构成的向量.

$K$ 维向量 $\boldsymbol{Z}=\boldsymbol{AX}$ 的长度包含了 $K\times K$ 的协方差矩阵 $\boldsymbol{V_Z}$. 协方差矩阵的一个重要法则（其中式(10.28)只是 $1\times 2$ 的特例）是一个简洁的公式：$\boldsymbol{AX}$ 的协方差矩阵等于 $\boldsymbol{A}$ 乘以 $\boldsymbol{X}$ 的协方差矩阵，再乘以 $\boldsymbol{A}^{\mathrm{T}}$.

$$\boldsymbol{Z}=\boldsymbol{AX}\text{的协方差矩阵}\qquad\boxed{\boldsymbol{V_Z}=\boldsymbol{AV_X}\boldsymbol{A}^{\mathrm{T}}}\tag{10.29}$$

这个公式被广泛地应用到很多领域；它充分地体现了矩阵乘法的魅力，是那么的简洁！正可谓“可远观而不可亵玩焉”，所以我不打算证明这个公式，而是欣赏它的美妙.

### 10.3.9 相关性 $\rho$

相关性 $\rho_{xy}$ 与协方差 $\sigma_{xy}$ 密切相关，它们都用于衡量变量间的依赖程度或独立性. 首先，我们对随机变量 $x$ 和 $y$ 进行重新缩放或“标准化”处理. 经过处理的新变量 $X=x/\sigma_x$ 和 $Y=y/\sigma_y$ 方差都是 1，即 $\sigma_X^2=\sigma_Y^2=1$. 这类似于将向量 $\boldsymbol{v}$ 除以其长度，得到长度为 1 的单位向量 $\boldsymbol{v}/\|\boldsymbol{v}\|$.

$x$ 和 $y$ 的相关性等同于 $X$ 和 $Y$ 的协方差. 如果 $x$ 和 $y$ 的原始协方差为 $\sigma_{xy}$，那么在将它们重新缩放为 $X$ 和 $Y$ 后，得到的相关性 $\rho_{xy}=\sigma_{xy}/\sigma_x\sigma_y$.

$$\text{相关性}\,\rho_{xy}=\frac{\sigma_{xy}}{\sigma_x\sigma_y}=\frac{x}{\sigma_x}\text{ 和 }\frac{y}{\sigma_y}\text{的协方差，并且 }-1\leqslant\rho_{xy}\leqslant 1$$

## 习题 10.3

1. 如果来自某群体人口的 24 个样本都有相同的年龄 $x=20$，那么样本均值 $\mu$ 和样本方差 $S^2$ 是多少？如果年龄 $x=20$ 或 21，且每个年龄都出现 12 次，结论又如何？

2. 如果每个输出 $x$ 都加上 7，均值和方差会发生什么变化？新的样本均值、新的期望均值和新的方差分别是多少？

3. 我们知道，所有整数中有 $\frac{1}{3}$ 可以被 3 整除，有 $\frac{1}{7}$ 可以被 7 整除. 那么，有多少比例的整数能被 3 或 7 整除？有多少比例能同时被这两个数整除？

4. 从 1 到 1000 的数字中随机抽样，假设每个数字被抽中的概率都是 $\frac{1}{1000}$. 那么，抽中的数字最后一位是 $0\sim 9$ 的概率 $p_0\sim p_9$ 各是多少？这个最后一位数字的期望均值 $m$ 是多少？它的方差 $\sigma^2$ 又是多少？

5. 再次从 1 到 1000 中随机抽样，但这次关注的是抽样数字平方后的最后一位. 这个平方的最后一位数字可能是 0、1、4、5、6 或 9. 那么，这些数字出现的概率 $p_0$、$p_1$、$p_4$、$p_5$、$p_6$、$p_9$ 各是多少？此外，这个数字的期望均值 $m$ 和方差 $\sigma^2$ 是多少？

6.（这个问题有点棘手）再次从 1 到 1000 中随机抽样，但这次关注的是每个数字的第一位数字（例如，如果数字是 15，那么 $x$ 就是 1）. 那么，$x$ 取 $1\sim 9$ 的概率 $p_1\sim p_9$（这些概率加起来应该是 1）各是多少？这个数字的均值和方差又是多少？

7. 假设在问题 5 中有 4 个样本，分别是 157、312、696 和 602. 那么，这些数字平方后的第一位数字 $x_1\sim x_4$ 分别是什么？这 4 个样本的样本均值 $\mu$ 是多少？样本方差 $S^2$ 又是多少？别忘了，计算样本方差时要除以 $N-1=3$，而不是 $N=4$.

8. 式(10.11)给出了样本方差 $S^2$ 的一个等价形式：

$$S^2=\frac{1}{N-2}\sum(x_i-m)^2=\frac{1}{N-1}\left[\left(\sum x_i^2\right)-Nm^2\right].$$

对期望方差，利用 $m=\sum p_ix_i$，验证平行的等式：

$$\sigma^2=\sum p_i(x_i-m)^2=\left(\sum p_ix_i^2\right)-m^2.$$

9. 计算机实验：计算一百万个随机 0-1 样本的平均值 $A_{1000000}$，再计算标准化变量 $X=\left(A_N-\frac{1}{2}\right)\times 2\sqrt{N}$ 的值.

10. 对于任何函数 $f(x)$，其期望值 $E[f]$ 定义为 $\sum p_if(x_i)$（离散情况）或者 $\int p(x)f(x)\,\mathrm{d}x$（连续情况）. 这里的函数可以是 $x$、$(x-m)^2$ 或者是 $x^2$. 已知均值 $E[x]=m$，方差 $E[(x-m)^2]=\sigma^2$，求 $E[x^2]$ 的值.

11. 证明标准正态分布 $p(x)$ 的总概率是 $\int p(x)\,\mathrm{d}x=1$. 这里有一个常用的技巧：将 $\int p(x)\,\mathrm{d}x$ 与 $\int p(y)\,\mathrm{d}y$ 相乘，并计算 $x$ 和 $y$ 从 $-\infty$ 到 $\infty$ 的积分. 在这个技巧中，我们将二重积分中的 $\mathrm{d}x\,\mathrm{d}y$ 替换为极坐标下的 $r\,\mathrm{d}r\,\mathrm{d}\theta$，其中 $x^2+y^2=r^2$. 请详细解释下面等式的每一步：

$$2\pi\int_{-\infty}^{\infty}p(x)\,\mathrm{d}x\int_{-\infty}^{\infty}p(y)\,\mathrm{d}y=\iint_{-\infty}^{\infty}\mathrm{e}^{-(x^2+y^2)/2}\,\mathrm{d}x\,\mathrm{d}y=\int_{\theta=0}^{2\pi}\int_{r=0}^{+\infty}\mathrm{e}^{-r^2/2}r\,\mathrm{d}r\,\mathrm{d}\theta=2\pi.$$

## 10.4　深度学习的成功引发的思考

数学家们会很自然地问：“深度学习解决了什么问题？它的答案是否唯一且完整？未来是否会有新的理念来取代或拓展它？其成功的关键是什么？”我并没有完全令人满意的答案，但这些问题的确至关重要.

深度学习的框架似乎很清晰. 我们手头有训练数据 $\boldsymbol{v}$，并且知道它描述的是对象 $\boldsymbol{w}$. 我们的目标是构建一个函数 $\boldsymbol{F}$，使得 $\boldsymbol{F}(\boldsymbol{v})$ 能够接近或等于 $\boldsymbol{w}$. 这里的接近意味着 $\boldsymbol{F}(\boldsymbol{v})$ 是 $\boldsymbol{w}$ 的一个近似值，而等于则意味着 $\boldsymbol{F}(\boldsymbol{v})$ 是 $\boldsymbol{w}$ 的插值. 本质要求是 $\boldsymbol{F}$ 能够成功泛化到新的测试数据 $\boldsymbol{V}$. 我们假设 $\boldsymbol{v}$ 和 $\boldsymbol{V}$ 来自统计上相似甚至完全相同的群体. 如果 $\boldsymbol{F}(\boldsymbol{V})$ 能够接近测试数据 $\boldsymbol{V}$ 的实际结果 $\boldsymbol{W}$，那么就认为深度学习是成功.

简而言之，我们寻求的是一个函数，它能够（几乎）插值训练数据，并成功外推到测试数据.

难点在于：$\boldsymbol{F}$ 的最佳形式是什么？成功的泛化需要“稳定性”，即当输入 $\boldsymbol{V}$ 接近 $\boldsymbol{v}$ 时，输出 $\boldsymbol{F}(\boldsymbol{V})$ 应该接近 $\boldsymbol{F}(\boldsymbol{v})$. 同时，我们也希望这个过程简单高效，即构建和评估 $\boldsymbol{F}$ 的过程不应过于复杂或耗时.

我认为我可以肯定地说，传统的方案并不成功. 如果 $\boldsymbol{F}$ 是一个多项式，或者是预先选定的某些函数的线性组合，那么在高维空间中很难得到理想的结果. 另一种方法是“有限元方法”，它使用低阶分段多项式和预选的插值点. 这种方法在结构工程领域效果显著，但在深度学习的广泛应用中，由于这些应用通常缺乏明显的结构，因此效果并不理想.

成功的关键（尤其是出乎意料的成功）可能在于$F_L(\cdots(F_2(F_1(\boldsymbol{v}))))$ 这样的简单函数的复合. 这种复合过程迅速带来了令人惊诧的复杂性. 在本书中，我们所讨论的函数都是连续且分段线性的（例如我们选择了 ReLU 作为激活函数）.

其他研究者已经对有理函数的应用进行了探索，这些函数虽然能很好地近似许多类型的函数，但在极点附近可能会变得不稳定. 对于泛化能力的深入理解仍在不断进步.

令人印象深刻的是，这些简单函数的复合极大地提升了我们对数据进行逼近的能力，并让我们在探索新应用时更加自信大胆.

# 附录 A

## A1 矩阵 $AB$ 与 $A+B$ 的秩

由第 1~3 章，我们知道 $\boldsymbol{A}$ 的秩 $=\boldsymbol{A}^{\mathrm{T}}$ 的秩. 本附录确立关于秩的更为关键的事实：矩阵乘法不增加秩. 该结论将从矩阵的列空间与行空间的观点得到验证. 下面列出了关于秩的五个关键结论，其中结论 3 是结论 1 的特殊情形，它说明当 $\boldsymbol{B}=\boldsymbol{A}^{\mathrm{T}}$ 时，乘积的秩不变，从而可得到 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 与 $\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}$ 的秩. 而在数据科学中，当把 $\boldsymbol{A}$ 分解为 $\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\mathrm{T}}$ 或 $\boldsymbol{C}\boldsymbol{R}$ 时，结论 4 将变得尤为重要：

| | |
|---|---|
| 0. | $\operatorname{rank}(\boldsymbol{A})=\operatorname{rank}(\boldsymbol{A}^{\mathrm{T}})$ （最基本重要的结论）； |
| 1. | $\operatorname{rank}(\boldsymbol{A}\boldsymbol{B})\leqslant\operatorname{rank}(\boldsymbol{A})$；$\operatorname{rank}(\boldsymbol{A}\boldsymbol{B})\leqslant\operatorname{rank}(\boldsymbol{B})$； |
| 2. | $\operatorname{rank}(\boldsymbol{A}+\boldsymbol{B})\leqslant\operatorname{rank}(\boldsymbol{A})+\operatorname{rank}(\boldsymbol{B})$； |
| 3. | $\operatorname{rank}\left(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\right)=\operatorname{rank}\left(\boldsymbol{A}\boldsymbol{A}^{\mathrm{T}}\right)=\operatorname{rank}(\boldsymbol{A})=\operatorname{rank}\left(\boldsymbol{A}^{\mathrm{T}}\right)$； |
| 4. | 若 $\boldsymbol{A}$ 为 $m\times r$ 矩阵，$\boldsymbol{B}$ 为 $r\times n$ 矩阵，且二者秩均为 $r$，则 $\operatorname{rank}(\boldsymbol{A}\boldsymbol{B})=r$. |

**结论 1：** 讨论涉及 $\boldsymbol{A}\boldsymbol{B}$ 的列空间与行空间：

$$\mathcal{C}(\boldsymbol{A}\boldsymbol{B}) \text{ 包含于 } \mathcal{C}(\boldsymbol{A})，\text{故 } \mathcal{C}(\boldsymbol{A}\boldsymbol{B}) \text{ 的维数不能变大.}$$

① $\boldsymbol{A}\boldsymbol{B}$ 的每一列都是 $\boldsymbol{A}$ 的列的线性组合（矩阵乘法）.

② $\boldsymbol{A}\boldsymbol{B}$ 的每一行都是 $\boldsymbol{B}$ 的行的线性组合（矩阵乘法）.

由 1.4 节可知，**矩阵的行秩等于其列秩**，从而我们可以使用行或列来计算矩阵的秩. 故矩阵相乘时，秩不会增加. 结论 1 是常用结论.

**结论 2：** $\boldsymbol{A}+\boldsymbol{B}$ 的每一列均为 $\boldsymbol{A}$ 的列与 $\boldsymbol{B}$ 的列之和. 因此，

$\operatorname{rank}(\boldsymbol{A}+\boldsymbol{B})\leqslant\operatorname{rank}(\boldsymbol{A})+\operatorname{rank}(\boldsymbol{B})$ 成立，并且 $\mathcal{C}(\boldsymbol{A})$ 的基与 $\mathcal{C}(\boldsymbol{B})$ 的基可张成 $\mathcal{C}(\boldsymbol{A}+\boldsymbol{B})$.

$\operatorname{rank}(\boldsymbol{A}+\boldsymbol{B})=\operatorname{rank}(\boldsymbol{A})+\operatorname{rank}(\boldsymbol{B})$ 并不总是成立，例如，当 $\boldsymbol{A}=\boldsymbol{B}=\boldsymbol{I}$ 时，显然不成立.

**结论 3：** $\boldsymbol{A}$ 和 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 都有 $n$ 列，**且它们具有相同的零空间**（参见习题 4.10）. 因此，$n-\operatorname{rank}(\boldsymbol{A})=n-\operatorname{rank}\left(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\right)$，从而二者秩相等. 进而，有 $\operatorname{rank}\left(\boldsymbol{A}^{\mathrm{T}}\right)\geqslant\operatorname{rank}\left(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\right)=\operatorname{rank}(\boldsymbol{A})$，将 $\boldsymbol{A}$ 与 $\boldsymbol{A}^{\mathrm{T}}$ 互换即得结论 3 的等式.

**结论 4：** 已知 $\boldsymbol{A}$ 与 $\boldsymbol{B}$ 的秩均为 $r$，由结论 3 知 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 与 $\boldsymbol{B}^{\mathrm{T}}$ 的秩均为 $r$，由它们均为 $r$ 阶方阵，故它们均可逆，其乘积 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{B}^{\mathrm{T}}$ 也可逆. 故有

$$r=\operatorname{rank}(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{B}\boldsymbol{B}^{\mathrm{T}})\leqslant\operatorname{rank}(\boldsymbol{A}\boldsymbol{B})\leqslant\operatorname{rank}(\boldsymbol{A})=r$$

因此 $\boldsymbol{A}\boldsymbol{B}$ 的秩为 $r$.

注意：这并不意味着所有秩为 $r$ 的矩阵乘积的秩都为 $r$. 结论 4 中的条件是 $\boldsymbol{A}$ 恰好有 $r$ 列，而 $\boldsymbol{B}$ 恰好有 $r$ 行. 这时 $\boldsymbol{BA}$ 的秩可能不是 $r$. 例如：

$$\boldsymbol{A}=\begin{bmatrix}1\\1\\1\end{bmatrix},\boldsymbol{B}=\begin{bmatrix}1 & 2 & -3\end{bmatrix},\text{则 } \boldsymbol{AB} \text{ 秩为 1，但 } \boldsymbol{BA} \text{ 为零矩阵！}$$

## A2 矩阵分解

1. $\boldsymbol{A}=\boldsymbol{CR}$=($\boldsymbol{A}$ 的列空间的基) ($\boldsymbol{A}$ 的行空间的基) 条件：$\boldsymbol{C}$ 是 $m\times r$ 矩阵，$\boldsymbol{R}$ 是 $r\times n$ 矩阵. 其中，$\boldsymbol{C}$ 由 $\boldsymbol{A}$ 的 $r$ 个主元列组成. $\boldsymbol{R}$ 由 $\boldsymbol{A}$ 的最简行阶梯形矩阵 $\boldsymbol{R}_0=\mathbf{rref}(\boldsymbol{A})$ 的非零行组成. 于是 $\boldsymbol{R}$ 的前 $r$ 列恰为 $r\times r$ 单位矩阵，从而

$$\boldsymbol{A}=\boldsymbol{CR}=\begin{bmatrix}\boldsymbol{C} & \boldsymbol{CF}\end{bmatrix}\boldsymbol{P}=\begin{bmatrix}\text{主元列} & \text{自由列}\end{bmatrix}\text{列置换.}$$

2. $\boldsymbol{A}=\boldsymbol{CW}^{-1}\boldsymbol{B}=\begin{pmatrix}\boldsymbol{C}=\boldsymbol{A}\text{的 } r \text{ 个}\\ \text{主元列}\end{pmatrix}\begin{pmatrix}\boldsymbol{W}=\boldsymbol{A}\text{最左上角的}\\ r \text{ 阶可逆子方阵}\end{pmatrix}\begin{pmatrix}\boldsymbol{B}=\boldsymbol{A}\text{的前 } r \text{ 个}\\ \text{线性无关行.}\end{pmatrix}$.

条件：$\boldsymbol{C}$ 和 $\boldsymbol{B}$ 由 $\boldsymbol{A}$ 的某 $r$ 列和某 $r$ 行组成. 这些行与列的交叉即为 $\boldsymbol{A}$ 的可逆子方阵 $\boldsymbol{W}$（参见 3.2 节）. 因此，$\boldsymbol{W}^{-1}\boldsymbol{B}=\boldsymbol{R}$.

3. $\boldsymbol{A}=\boldsymbol{LU}=\begin{pmatrix}\boldsymbol{L}\text{为主对角元均为 1}\\ \text{的下三角矩阵}\end{pmatrix}\begin{pmatrix}\boldsymbol{U}\text{为以 }\mathbf{rref}(\boldsymbol{A})\text{ 的主元}\\ \text{为对角元的上三角矩阵.}\end{pmatrix}$.

条件：在不做行对换的情况下，用高斯消元法将方阵 $\boldsymbol{A}$ 化简得到 $\boldsymbol{U}$.

4. $\boldsymbol{A}=\boldsymbol{LDU}=\begin{pmatrix}\boldsymbol{L}\text{为主对角元均}\\ \text{为 1 的下三角矩阵}\end{pmatrix}\begin{pmatrix}\boldsymbol{D}\text{为以 }\mathbf{rref}(A)\text{ 的主}\\ \text{元为对角元的对角阵}\end{pmatrix}\begin{pmatrix}\boldsymbol{U}\text{为主对角元均}\\ \text{为 1 的上三角矩阵}\end{pmatrix}$.

条件：同上，不做行对换. 将上三角矩阵中的主元提出得到 $\boldsymbol{D}$，剩下主对角元为 1 的上三角阵 $\boldsymbol{U}$. 特别地，若 $\boldsymbol{A}$ 为对称阵，则 $\boldsymbol{U}=\boldsymbol{L}^{\mathrm{T}}$ 且 $\boldsymbol{A}=\boldsymbol{LDL}^{\mathrm{T}}$.

5. $\boldsymbol{PA}=\boldsymbol{LU}$（置换矩阵 $\boldsymbol{P}$ 的主元位置不为零）.

条件：$\boldsymbol{A}$ 可逆，从而 $\boldsymbol{P}$、$\boldsymbol{L}$、$\boldsymbol{U}$ 均可逆. 利用 $\boldsymbol{P}$ 预先对 $\boldsymbol{A}$ 进行适当行对换，之后再进行一般的 $\boldsymbol{LU}$ 分解. 另一种分解形式：$\boldsymbol{A}=\boldsymbol{L}_1\boldsymbol{P}_1\boldsymbol{U}_1$.

6. $\boldsymbol{S}=\boldsymbol{C}^{\mathrm{T}}\boldsymbol{C}=\left(\text{以 }\sqrt{\boldsymbol{D}}\text{ 为对角元的下三角阵}\right)\left(\text{以 }\sqrt{\boldsymbol{D}}\text{ 为对角元的上三角阵}\right)$.

条件：$\boldsymbol{S}$ 为对称正定阵（$\boldsymbol{D}$ 为 $n$ 个对角元均是正数的对角矩阵）. 这也称为乔莱斯基（Cholesky）分解，记 $\boldsymbol{C}=\mathrm{chol}(\boldsymbol{S})$，并满足 $\boldsymbol{C}^{\mathrm{T}}=\boldsymbol{L}\sqrt{\boldsymbol{D}}$，所以 $\boldsymbol{S}=\boldsymbol{C}^{\mathrm{T}}\boldsymbol{C}=\boldsymbol{LDL}^{\mathrm{T}}$.

7. $\boldsymbol{A}=\boldsymbol{QR}=\left(\boldsymbol{Q}\text{由单位正交列组成}\right)\left(\boldsymbol{R}\text{为上三角矩阵}\right)$.

条件：$\boldsymbol{A}$ 为列满秩矩阵. 用施密特正交化方法（Gram-Schmidt）或豪斯霍尔德（Householder）过程，将 $\boldsymbol{A}$ 的列做正交化即得 $\boldsymbol{Q}$. 若 $\boldsymbol{A}$ 为方阵，则 $\boldsymbol{Q}$ 为正交阵，即 $\boldsymbol{Q}^{-1}=\boldsymbol{Q}^{\mathrm{T}}$.

8. $\boldsymbol{A}=\boldsymbol{X\Lambda X}^{-1}=\begin{pmatrix}\boldsymbol{X}\text{由 }\boldsymbol{A}\text{ 的线性无}\\ \text{关的特征向量组成}\end{pmatrix}\begin{pmatrix}\boldsymbol{\Lambda}\text{为由 }\boldsymbol{A}\text{ 的特征}\\ \text{值构成的对角阵}\end{pmatrix}\begin{pmatrix}\boldsymbol{X}^{-1}\text{由 }\boldsymbol{A}^{\mathrm{T}}\text{ 的线性}\\ \text{无关的特征向量组成}\end{pmatrix}$ ①.

① 译者注：此处有误：由 $\boldsymbol{A}=\boldsymbol{X\Lambda X}^{-1}$ 知：$\boldsymbol{AX}=\boldsymbol{X\Lambda}$，取转置得 $\boldsymbol{X}^{\mathrm{T}}\boldsymbol{A}^{\mathrm{T}}=\boldsymbol{\Lambda X}^{\mathrm{T}}$，即 $\boldsymbol{A}^{\mathrm{T}}(\boldsymbol{X}^{-1})^{\mathrm{T}}=(\boldsymbol{X}^{-1})^{\mathrm{T}}\boldsymbol{\Lambda}$，因此 $(\boldsymbol{X}^{-1})^{\mathrm{T}}$ 由 $\boldsymbol{A}^{\mathrm{T}}$ 的线性无关的特征向量组成.

条件：$\boldsymbol{A}$ 须有 $n$ 个线性无关的特征向量（即可对角化），才能得到可逆矩阵 $\boldsymbol{X}$，使得 $\boldsymbol{AX}=\boldsymbol{X\Lambda}$.

9. $\boldsymbol{S}=\boldsymbol{Q\Lambda Q}^{\mathrm{T}}=\left(\boldsymbol{Q}\text{为正交阵}\right)\left(\boldsymbol{\Lambda}\text{为由 }\boldsymbol{A}\text{ 的实特征值构成的对角矩阵}\right)\left(\boldsymbol{Q}^{\mathrm{T}}=\boldsymbol{Q}^{-1}\right)$.

条件：$\boldsymbol{S}$ 为实对称阵，即 $\boldsymbol{S}^{\mathrm{T}}=\boldsymbol{S}$. 这称为谱分解定理.

10. $\boldsymbol{A}=\boldsymbol{BJB}^{-1}=\left(\boldsymbol{B}\text{由 }\boldsymbol{A}\text{ 的广义特征向量构成}\right)\left(\boldsymbol{J}\text{由约当块构成}\right)\left(\boldsymbol{B}^{-1}\right)$.

条件：$\boldsymbol{A}$ 为方阵. 若尔当标准形 $\boldsymbol{J}$ 中的每个子块均对应 $\boldsymbol{A}$ 的一个线性无关特征向量，且每个块仅有一个特征值（见附录 A5）.

11. $\boldsymbol{A}=\boldsymbol{U\Sigma V}^{\mathrm{T}}=\begin{pmatrix}\boldsymbol{U}\text{为 }m\times m\\ \text{正交阵}\end{pmatrix}\begin{pmatrix}\boldsymbol{\Sigma}\text{为以奇异值 }\sigma_1,\sigma_2,\cdots,\sigma_r\\ \text{为主对角元的 }m\times n\text{ 矩阵}\end{pmatrix}\begin{pmatrix}\boldsymbol{V}\text{为 }n\times n\\ \text{正交阵}\end{pmatrix}$.

条件：对任意 $\boldsymbol{A}$ 均成立，称为奇异值分解. 其中，$\boldsymbol{AA}^{\mathrm{T}}$ 的特征向量构成 $\boldsymbol{U}$，$\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$ 的特征向量构成 $\boldsymbol{V}$，奇异值 $\sigma_i=\sqrt{\lambda_i\left(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\right)}=\sqrt{\lambda_i\left(\boldsymbol{AA}^{\mathrm{T}}\right)}$，并满足 $\sigma_1\geqslant\sigma_2\geqslant\cdots\geqslant\sigma_r>0$. 进一步，由分块矩阵乘法知

$$\boldsymbol{A}=\boldsymbol{U\Sigma V}^{\mathrm{T}}=\sigma_1\boldsymbol{u}_1\boldsymbol{v}_1^{\mathrm{T}}+\sigma_2\boldsymbol{u}_2\boldsymbol{v}_2^{\mathrm{T}}+\cdots+\sigma_r\boldsymbol{u}_r\boldsymbol{v}_r^{\mathrm{T}}=r\text{个秩 }1\text{ 矩阵之和.}$$

特别地，若 $\boldsymbol{S}$ 为对称正定矩阵，则有 $\boldsymbol{U}=\boldsymbol{V}=\boldsymbol{Q},\boldsymbol{\Sigma}=\boldsymbol{\Lambda}$ 且 $\boldsymbol{S}=\boldsymbol{Q\Lambda Q}^{\mathrm{T}}$.

12. $\boldsymbol{A}^{+}=\boldsymbol{V\Sigma U}^{\mathrm{T}}=\begin{pmatrix}\boldsymbol{V}\text{为 }n\times n\\ \text{正交阵}\end{pmatrix}\begin{pmatrix}\boldsymbol{\Sigma}^{+}\text{为 }\boldsymbol{\Sigma}\text{ 的广义逆，以 }1/\sigma_1,1/\sigma_2,\cdots,\\ 1/\sigma_r\text{ 为主对角元的 }n\times m\text{ 矩阵}\end{pmatrix}\begin{pmatrix}\boldsymbol{U}\text{为 }m\times m\\ \text{正交阵}\end{pmatrix}$.

条件：对任意 $\boldsymbol{A}$ 均成立. $\boldsymbol{A}^{+}$ 称为 $\boldsymbol{A}$ 的广义逆，满足 $\boldsymbol{A}^{+}\boldsymbol{A}$ 为向 $\boldsymbol{A}$ 的列空间的投影矩阵，$\boldsymbol{AA}^{+}$ 为向 $\boldsymbol{A}$ 的行空间的投影矩阵. 若 $\boldsymbol{A}$ 可逆，则 $\boldsymbol{A}^{+}=\boldsymbol{A}^{-1}$. 此外，方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 的最优最小二乘解为 $\boldsymbol{X}^{+}=\boldsymbol{A}^{+}\boldsymbol{b}$，且满足方程 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{AX}^{+}=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$.

13. $\boldsymbol{A}=\boldsymbol{QS}=\left(\boldsymbol{Q}\text{为正交矩阵}\right)\left(\boldsymbol{S}\text{为对称正定矩阵}\right)$.

条件：$\boldsymbol{A}$ 为可逆阵，称为极分解式，从而有 $\boldsymbol{S}^2=\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}$. 其中，当 $\boldsymbol{A}$ 不可逆时，$\boldsymbol{S}$ 为半正定矩阵；类似有反向极分解式 $\boldsymbol{A}=\boldsymbol{KQ}$，从而有 $\boldsymbol{K}^2=\boldsymbol{AA}^{\mathrm{T}}$. 由奇异值分解可得，两式中的 $\boldsymbol{Q}$ 均满足 $\boldsymbol{Q}=\boldsymbol{UV}^{\mathrm{T}}$.

14. $\boldsymbol{A}=\boldsymbol{UAU}^{-1}=\left(\boldsymbol{U}\text{为酉矩阵}\right)\begin{pmatrix}\boldsymbol{\Lambda}\text{为由 }\boldsymbol{A}\text{ 的特征值}\\ \text{构成的对角阵}\end{pmatrix}\left(\boldsymbol{U}^{-1}\text{即为}\overline{\boldsymbol{U}}^{\mathrm{T}}\right)$.

条件：$\boldsymbol{A}$ 为正规矩阵，即满足 $\bar{\boldsymbol{A}}^{\mathrm{T}}\boldsymbol{A}=\boldsymbol{A}\bar{\boldsymbol{A}}^{\mathrm{T}}$. 其正交特征向量（可能在复空间）构成 $\boldsymbol{U}$ 的列. $\boldsymbol{\Lambda}$ 一般为复矩阵（除非 $\boldsymbol{A}$ 为艾米特阵，即 $\boldsymbol{A}=\bar{\boldsymbol{A}}^{\mathrm{T}}$ 时）.

15. $\boldsymbol{A}=\boldsymbol{QTQ}^{-1}=\left(\text{酉矩阵}\boldsymbol{Q}\right)\left(\text{以 }\lambda\text{ 为对角元的三角阵 T}\right)\left(\boldsymbol{Q}^{-1}=\overline{\boldsymbol{Q}}^{\mathrm{T}}\right)$.

条件：对任意方阵 $\boldsymbol{A}$ 的舒尔（Schur）三角化. 存在一个有单位正交列的矩阵 $\boldsymbol{Q}$，使得 $\boldsymbol{Q}^{-1}\boldsymbol{AQ}$ 为三角矩阵（见 6.4 节）.

16. $\boldsymbol{F}_n=\begin{bmatrix}\boldsymbol{I}&\boldsymbol{D}\\ \boldsymbol{I}&-\boldsymbol{D}\end{bmatrix}\begin{bmatrix}\boldsymbol{F}_{n/2}&\\ &\boldsymbol{F}_{n/2}\end{bmatrix}\begin{bmatrix}\text{奇偶}\\ \text{置换阵}\end{bmatrix}=\begin{array}{l}\text{快速傅里叶变换 (FFT) 中将矩阵}\\ \text{阶数从 }n\text{ 降为 }n/2=m\text{ 的一步.}\end{array}$

条件：$\boldsymbol{F}_n=$ 以 $w^{jk}$ 为分量的傅里叶（Fourier）矩阵，其中 $w^n=1$，且 $\boldsymbol{F}_n\overline{\boldsymbol{F}}_n=n\boldsymbol{I}$. 矩阵 $\boldsymbol{D}$ 的对角元为 $1,w,\cdots,w^{\frac{n}{2}-1}$. 对 $n=2^\ell$ 情形，用快速傅里叶变换中 $\boldsymbol{D}$ 的 $\ell$ 个阶段，计算 $\boldsymbol{F}_n\boldsymbol{X}$ 仅需要 $\dfrac{1}{2}n\ell=\dfrac{1}{2}n\log_2 n$ 次乘法运算. 实际上，快速傅里叶变换将两个 $\dfrac{1}{2}$ 体量的变换 $\boldsymbol{y}'=\boldsymbol{F}_m\boldsymbol{c}'$ 与 $\boldsymbol{y}''=\boldsymbol{F}_m\boldsymbol{c}''$ 合成变换 $\boldsymbol{y}=\boldsymbol{F}_n\boldsymbol{c}$，其中

$$y_j=y_j'+(w_n)^j\,y_j'',y_{j+m}=y_j'-(w_n)^j y_j'',\ j=0,1,\cdots,m-1.$$

## A3 基本矩阵分解中的参量计数问题

$$\boldsymbol{A}=\boldsymbol{LU},\quad \boldsymbol{A}=\boldsymbol{QR},\quad \boldsymbol{S}=\boldsymbol{Q\Lambda Q}^{\mathrm{T}},\quad \boldsymbol{A}=\boldsymbol{X\Lambda X}^{-1},\quad \boldsymbol{A}=\boldsymbol{QS},\quad \boldsymbol{A}=\boldsymbol{U\Sigma V}^{\mathrm{T}}$$

本附录是对线性代数中关键思想的综述. 这些思想通过矩阵乘法分解来表述. 我们的方案很简单：计算每个矩阵中分量的数量. 我们希望得到每个等式，如 $\boldsymbol{A}=\boldsymbol{LU}$，两边的分量数量均相等.

对 $\boldsymbol{A}=\boldsymbol{LU}$，由 $\frac{1}{2}n(n-1)+\frac{1}{2}n(n+1)=n^2$ 可知，等式两边都有 $n^2$ 个自由参数.

| | |
|---|---|
| $\boldsymbol{L}$：主对角元全为 1 的 $n\times n$ 下三角矩阵， | $\frac{1}{2}n(n-1)$ 个自由参数 |
| $\boldsymbol{U}$：$n\times n$ 上三角矩阵， | $\frac{1}{2}n(n+1)$ 个自由参数 |
| $\boldsymbol{Q}$：$n\times n$ 正交矩阵， | $\frac{1}{2}n(n-1)$ 个自由参数 |
| $\boldsymbol{S}$：$n\times n$ 对称矩阵， | $\frac{1}{2}n(n+1)$ 个自由参数 |
| $\boldsymbol{\Lambda}$：$n\times n$ 对角矩阵， | $n$ 个自由参数 |
| $\boldsymbol{X}$：线性无关特征向量为列的 $n\times n$ 矩阵， | $n^2-n$ 个自由参数 |

其中，对正交矩阵 $\boldsymbol{Q}$ 有如下注释：其第一列 $\boldsymbol{q}_1$ 是单位向量. 条件 $\|\boldsymbol{q}_1\|=1$ 会使 $\boldsymbol{q}_1$ 的 $n$ 个分量之中的某一个被固定，即 $\boldsymbol{q}_1$ 有 $n-1$ 个自由参数. 而对第二列 $\boldsymbol{q}_2$ 有 $n-2$ 个自由参数，这是因为它是一个单位向量并且与 $\boldsymbol{q}_1$ 正交. 以此类推，$\boldsymbol{Q}$ 中共有 $(n-1)+(n-2)+\cdots+1=n(n-1)/2$ 个自由参数. 换言之，$\boldsymbol{Q}$ 的 $n$ 个列，平均每列有 $(n-1)/2$ 个自由参数.

特征向量矩阵 $\boldsymbol{X}$ 只有 $n^2-n$ 个参数，而不是 $n^2$. 若 $\boldsymbol{x}$ 是一个特征向量，那么对任何 $c\neq 0$，$c\boldsymbol{x}$ 也是一个特征向量. 故我们可要求每个 $\boldsymbol{x}$ 的（绝对值）最大分量为 1，这为每个特征向量留下了 $n-1$ 个自由参数. 并且当 $\boldsymbol{X}$ 确定后，$\boldsymbol{X}^{-1}$ 没有自由参数. 于是，对于上述第一行中的前五个分解式，等式两边的自由参量计数就都一致了.

对于奇异值分解（第六个分解式），使用简化形式 $\boldsymbol{A}_{m\times n}=\boldsymbol{U}_{m\times r}\boldsymbol{\Sigma}_{r\times r}\boldsymbol{V}_{r\times n}^{\mathrm{T}}$（注意零不是自由参数!）假设 $m\leqslant n$，且 $\boldsymbol{A}$ 为满秩矩阵使得 $r=m$，则 $\boldsymbol{A}$ 的自由参数计数为 $mn$. 此外，$\boldsymbol{U}$、$\boldsymbol{\Sigma}$、$\boldsymbol{V}$ 的总计数也是 $mn$. $\boldsymbol{U}$ 和 $\boldsymbol{V}$ 正交列的参数计数推理与上述正交矩阵 $\boldsymbol{Q}$ 的列的推理相同，即

$\boldsymbol{U}$ 有 $\frac{1}{2}m(m-1)$ 个，$\boldsymbol{\Sigma}$ 有 $m$ 个，而 $\boldsymbol{V}$ 有 $(n-1)+(n-2)+\cdots+(n-m)=mn-\frac{m(m+1)}{2}$ 个参数.

所以，对秩为 $r$ 的矩阵 $\boldsymbol{A}$，其总参量计数为 $mr+nr-r^2=(m+n-r)r$.

我们在 1.4 节中，对于 $\boldsymbol{A}=\boldsymbol{CR}$ 也得到了相同的总数. $\boldsymbol{C}$ 的 $r$ 列直接取自 $\boldsymbol{A}$，行矩阵 $\boldsymbol{R}$ 包含一个 $r\times r$ 单位矩阵（固定非自由的!）. 当 $\boldsymbol{A}$ 的秩为 $r$ 时：

$$\boldsymbol{C}\text{ 有 }mr\text{ 个参数，}\boldsymbol{R}\text{ 有 }nr-r^2\text{ 个参数，共计 }mr+nr-r^2\text{ 个参数.}$$

因此，$\boldsymbol{A}=\boldsymbol{CR}$ 的参数计数与前述 $\boldsymbol{A}=\boldsymbol{U\Sigma V}^{\mathrm{T}}$ 的参数计数一致.

## A4 数值线性代数中相关代码与算法

| | |
|---|---|
| LAPACK | 是对线性代数问题进行密集编码的首选. |
| ScaLAPACK | 在处理大规模问题时能够实现高性能. |

COIN/OR 为运筹学中的优化问题提供高质量的代码.

以下是特定算法的来源：

| 线性系统（线性方程组）的直接求解问题: | |
|---|---|
| 基本矩阵-向量运算 | BLAS |
| 包含行交换的消元法 | LAPACK |
| 稀疏问题直接求解（UMFPACK） | SuiteSparse，SuperLU |
| Gram-Schmidt 或 Householder 方法做 QR 分解 | LAPACK |
| **特征值和奇异值问题** | |
| 移位 QR 分解法求特征值 | LAPACK |
| Golub-Kahan 方法求奇异值分解 | LAPACK |
| **迭代求解** | |
| 预处理共轭梯度法求解 $\boldsymbol{Sx}=\boldsymbol{b}$ | Trilinos |
| 预处理 GMRES 法求解 $\boldsymbol{Ax}=\boldsymbol{b}$ | Trilinos |
| Krylov-Arnoldi 方法求 $\boldsymbol{Ax}=\lambda\boldsymbol{x}$ | ARPACK, Trilinos, SLEPc |
| $\boldsymbol{S}$ 的极端特征值求解 | 另见 BLOPEX |
| **优化问题** | |
| 线性规划 | COIN/OR 中的 CLP |
| 半正定规划 | COIN/OR 中的 CSDP |
| 内点法 | COIN/OR 中的 IPOPT |
| 凸优化 | CVX, CVXR |
| **随机线性代数** | |
| 通过主元 QR 的随机分解 | `users.ices.utexas.edu/~pgm/maincodes.html` |
| $\boldsymbol{A}=\boldsymbol{CMR}$ 列/混合/行 | |
| 快速傅里叶变换 | `FFTW.org` |
| 高质量代码库 | GAMS 和`Netlib.org` |
| ACM 系列教材相关的数学软件 | TOMS |

| 深度学习软件 | |
|---|---|
| Julia 中的深度学习 | `Fluxml.ai/Flux.jl/stable` |
| MATLAB 中的深度学习 | `Mathworks.com/learn/tutorials/deep-learning-onramp.html` |
| Python 和 JavaScript 中的深度学习 | `TensorFlow.org`, `TensorFlow.js` |
| R 中的深度学习 | Keras, KerasR |

## A5 方阵的若尔当标准形

某些有重复特征值的方阵 $\boldsymbol{A}$ 并不存在 $n$ 个线性无关的特征向量. 因此，它们无法通过 $\boldsymbol{X}^{-1}\boldsymbol{A}\boldsymbol{X}=\boldsymbol{\Lambda}$ 进行相似对角化. 若尔当为每个方阵 $\boldsymbol{A}$ 给出了一种分块对角标准形 $\boldsymbol{J}=\boldsymbol{B}\boldsymbol{A}\boldsymbol{B}^{-1}$. 当 $\boldsymbol{A}$ 具有 $k$ 个线性无关的特征向量时，“若尔当标准形” $\boldsymbol{J}$ 包含 $k$ 个若尔当块 $\boldsymbol{J}_1,\boldsymbol{J}_2,\cdots,\boldsymbol{J}_k$，且 $\boldsymbol{J}$ 与 $\boldsymbol{A}$ 有相同的特征值.

$$\boldsymbol{J}=\boldsymbol{B}\boldsymbol{A}\boldsymbol{B}^{-1}=\begin{bmatrix}\boldsymbol{J}_1 & & \\ & \ddots & \\ & & \boldsymbol{J}_k\end{bmatrix},\ \text{其若尔当块形如}\ \boldsymbol{J}_i=\begin{bmatrix}\lambda_i & 1 & 0 & \cdots & 0\\ & \lambda_i & 1 & \cdots & 0\\ & & \ddots & \ddots & \vdots\\ & & & \lambda_i & 1\\ & & & & \lambda_i\end{bmatrix}$$

如果矩阵 $\boldsymbol{A}$ 可对角化，则 $k=n$ 且 $\boldsymbol{B}=\boldsymbol{X}$，此时，$\boldsymbol{J}$ 是特征值矩阵 $\boldsymbol{\Lambda}$（所有若尔当块 $\boldsymbol{J}_1,\boldsymbol{J}_2,\cdots,\boldsymbol{J}_n$ 均为 $1\times1$ 矩阵）. 如果 $\boldsymbol{A}$ 不能对角化，则一个或多个若尔当块会超过 1 阶. 每个阶数为 $n_i$ 的若尔当块 $\boldsymbol{J}_i$ 仅有一个特征值 $\lambda_i$，仅有一个线性无关的特征向量 $\boldsymbol{x}_i=(1,0,\cdots,0)$. 而矩阵 $\boldsymbol{B}$ 由 $\boldsymbol{A}$ 的特征向量和“广义特征向量”组成. 下面给出一个例子而非证明：

例 A5.1 设 $\boldsymbol{J}=\left[\begin{array}{cc|c}3&1&0\\0&3&0\\\hline0&0&3\end{array}\right]$，$\boldsymbol{J}$ 的特征值为 $\lambda=3,3,3$ 且 $\boldsymbol{J}$ 仅有两个“真正”的特征向量 $\begin{bmatrix}1\\0\\0\end{bmatrix}$ 与 $\begin{bmatrix}0\\0\\1\end{bmatrix}$. 令 $\boldsymbol{A}=\boldsymbol{B}^{-1}\boldsymbol{J}\boldsymbol{B}$，则由该标准形可得 $\boldsymbol{A}^N=\boldsymbol{B}^{-1}\boldsymbol{J}^N\boldsymbol{B}$ 与 $\mathrm{e}^{t\boldsymbol{A}}=\boldsymbol{B}^{-1}\mathrm{e}^{t\boldsymbol{J}}\boldsymbol{B}$，进而可化简计算. 而 $\boldsymbol{J}$ 的方幂的计算可归结于每个若尔当块的方幂计算：

$$\begin{bmatrix}3&1\\0&3\end{bmatrix}^N=\begin{bmatrix}3^N&N3^{N-1}\\0&3^N\end{bmatrix}\qquad \exp\left(\begin{bmatrix}3&1\\0&3\end{bmatrix}t\right)=\begin{bmatrix}\mathrm{e}^{3t}&t\mathrm{e}^{3t}\\0&\mathrm{e}^{3t}\end{bmatrix}$$

上述指数形式的公式给出了微分方程 $\mathrm{d}\boldsymbol{U}/\mathrm{d}t=\boldsymbol{J}\boldsymbol{U}$（也即 $\mathrm{d}\boldsymbol{u}/\mathrm{d}t=\boldsymbol{A}\boldsymbol{u}$）更多形式的解. 通常易知 $\mathrm{e}^{3t}$ 是一个解，但当 $\lambda=3$ 是二重特征值时，不能把 $\mathrm{e}^{3t}$ 视作二重解. 不难知“缺失”的另一个解就是 $t\mathrm{e}^{3t}$. 而当 $\lambda=3$ 是三重特征值且仅有一个特征向量（即一个约当块）时，同理可得到第三个解 $t^2\mathrm{e}^{3t}$.

接下来介绍凯莱-汉密尔顿（Cayley-Hamilton）定理：$\boldsymbol{P}(\boldsymbol{A})=\boldsymbol{0}$（零矩阵）.

“每个方阵 $\boldsymbol{A}$ 代入其特征多项式中均满足 $\boldsymbol{P}(\boldsymbol{A})=\boldsymbol{0}$.” 其中，特征多项式 $p(\lambda)=\det(\boldsymbol{A}-\lambda\boldsymbol{I})$. 方程 $p(\lambda)=0$ 的 $n$ 个（复）根恰为 $\boldsymbol{A}$ 的特征值. 对上述例子，有 $p(\lambda)=(\lambda-3)^3$，故有三重特征值

$\lambda = 3,3,3$. 凯莱-汉密尔顿定理告诉我们：$p(\boldsymbol{A}) = (\boldsymbol{A} - 3\boldsymbol{I})^3$ 等于零矩阵. 利用若尔当标准形很容易说明这一点，因为 $(\boldsymbol{A} - 3\boldsymbol{I})^3 = \boldsymbol{B}(\boldsymbol{J} - 3\boldsymbol{I})^3\boldsymbol{B}^{-1}$，而 $(\boldsymbol{J} - 3\boldsymbol{I})^3$ 必为零矩阵. 所以 $(\boldsymbol{A} - 3\boldsymbol{I})^3 = \boldsymbol{0}$.

## A6 张量

在线性代数中，**张量是一个多维数组.**（对爱因斯坦而言，张量是遵循特定变换规则的一个函数.）普通矩阵是一个二阶张量. 一个三阶张量 $\boldsymbol{T}$ 由若干矩阵堆叠而成，其元素 $T_{ijk}$ 有三个指标：行号 $i$、列号 $j$ 和“管号” $k$.

例如一张彩色图像，它有三张切片，分别对应于红-绿-蓝. 这些切片 $T_1$、$T_2$、$T_3$ 显示了每个位于 $(i,j)$ 处的像素点关于三原色 RGB（$k = 1,2,3$）的浓度.

向量

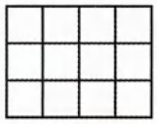
矩阵（二阶数组）

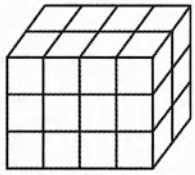
张量（三阶数组）

另一个例子是联合概率张量. 下设 $p_{ijk}$ 是一个随机样本的概率，比如 $i$ 表示年龄，$j$ 表示身高，$k$ 表示体重. 上述所有 $p_{ijk}$ 的总和为 1. 对于 $i = 9$，所有 $p_{9jk}$ 的总和为一个分数，表示年龄为 9 岁的个体所占的比例——这是张量一个切片的求和.

关于张量与矩阵的基本问题是要将张量 $T$ 分解成更简单的组分. 矩阵 $\boldsymbol{A}$ 是通过奇异值分解实现的. 求和构成 $\boldsymbol{A}$ 的组分是矩阵（现在应该说是二阶张量），每个组分具有某些特殊的性质，即每个组分为秩 1 矩阵 $\boldsymbol{u}\sigma\boldsymbol{v}^{\mathrm{T}}$. 用线性代数相关知识可说明不同组分的向量 $\boldsymbol{u}$ 是相互正交的，向量 $\boldsymbol{v}$ 也是相互正交的，并且只有 $r$ 个这样的组成部分（$r \leqslant m$ 且 $r \leqslant n$）.

遗憾的是，对于三阶张量并没有类似的奇异值分解形式. 但我们仍然可以要求 $R$ 个一阶部分相加近似得到 $T$：

$$\text{CP 分解} \qquad T \approx \boldsymbol{a}_1 \circ \boldsymbol{b}_1 \circ \boldsymbol{C}_1 + \cdots + \boldsymbol{a}_R \circ \boldsymbol{b}_R \circ \boldsymbol{C}_R \tag{A.1}$$

$\boldsymbol{a}_1, \boldsymbol{a}_2, \cdots, \boldsymbol{a}_R$ 的正交性、$\boldsymbol{b}_1, \boldsymbol{b}_2, \cdots, \boldsymbol{b}_R$ 的正交性和 $\boldsymbol{c}_1, \boldsymbol{c}_2, \cdots, \boldsymbol{c}_R$ 的正交性通常是不成立的. 组成部分的数目并不是由 $T$ 决定的（也即三阶张量的“秩”不是良好定义的）. 但是这样的近似分解在张量计算中仍然有用. 一种选择是分别求解 $\boldsymbol{a}_i$（固定 $\boldsymbol{b}_i$ 和 $\boldsymbol{c}_i$）、$\boldsymbol{b}_i$（固定 $\boldsymbol{a}_i$ 和 $\boldsymbol{c}_i$）以及 $\boldsymbol{c}_i$（固定 $\boldsymbol{a}_i$ 和 $\boldsymbol{b}_i$）. 这些子问题可以简化为最小二乘问题. $T$ 也有其他可能的近似分解.

张量分解理论（多重线性代数）是由应用驱动的. 为了能够计算 $T$，即使没有类似奇异值分解的正交性质，高阶张量的算法仍然在不断地研究与改进.

## A7 矩阵问题的条件数

条件数衡量的是“解的变化量”与“数据的变化量”之间的比率. 最常见的问题是求解 $n$ 个线性方程 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$，其中 $\boldsymbol{x}$ 是 $n$ 个未知数（组成的列向量）. 此时，数据是列向量 $\boldsymbol{b}$，解是 $\boldsymbol{x} = \boldsymbol{A}^{-1}\boldsymbol{b}$. 矩阵 $\boldsymbol{A}$ 是固定的，数据的变化是 $\Delta\boldsymbol{b}$，解的变化是 $\Delta\boldsymbol{x} = \boldsymbol{A}^{-1}\Delta\boldsymbol{b}$.

为了衡量“变化”的大小，我们是计算绝对变化量 $\|\Delta \boldsymbol{b}\|$，还是相对变化量 $\|\Delta \boldsymbol{b}\| / \|\boldsymbol{b}\|$？对于数据 $\boldsymbol{b}$ 的这个选择将决定矩阵 $\boldsymbol{A}$ 的条件数的类似选择

$$\text{绝对条件数} = \max_{\boldsymbol{b},\Delta \boldsymbol{b}} \frac{\|\Delta \boldsymbol{x}\|}{\|\Delta \boldsymbol{b}\|} = \max \frac{\|\boldsymbol{A}^{-1}\Delta \boldsymbol{b}\|}{\|\Delta \boldsymbol{b}\|} \qquad \text{相对条件数} = \max_{\boldsymbol{b},\Delta \boldsymbol{b}} \frac{\|\Delta \boldsymbol{x}\| / \|\boldsymbol{x}\|}{\|\Delta \boldsymbol{b}\| / \|\boldsymbol{b}\|} \tag{A.2}$$

绝对变化的选择看起来不错，但它存在一个问题. 如果我们把矩阵 $\boldsymbol{A}$ 倍乘 $\frac{1}{10}$，对应地就把 $\boldsymbol{A}^{-1}$ 倍乘 10，从而绝对条件数变成了原来的 10 倍. 但是方程组 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$ 的解并没有增加为 10 倍. 因此，**相对条件数是更为正确的选择.**

$$\boxed{\operatorname{cond}(A) = \max_{\boldsymbol{b},\Delta \boldsymbol{b}} \frac{\|\boldsymbol{A}^{-1}\Delta \boldsymbol{b}\|}{\|\Delta \boldsymbol{b}\|} \frac{\|\boldsymbol{A}\boldsymbol{x}\|}{\|\boldsymbol{x}\|} = \left\|\boldsymbol{A}^{-1}\right\| \|\boldsymbol{A}\| = \frac{\sigma_{\max}}{\sigma_{\min}}} \tag{A.3}$$

如果 $\boldsymbol{A}$ 是一个简单的对角矩阵 $\boldsymbol{\Sigma}$，其对角元为 $\sigma_1 \geqslant \sigma_2 \cdots \geqslant \sigma_r = \sigma_{\min}$，则其范数是 $\sigma_{\max} = \sigma_1$. 而 $\boldsymbol{A}^{-1}$ 的范数是 $1/\sigma_{\min}$，$\boldsymbol{A}$ 的奇异值分解中的正交矩阵 $\boldsymbol{U}$ 和 $\boldsymbol{v}$ 的范数保持不变，从而 $\operatorname{cond}(\boldsymbol{A}) = \sigma_{\max}/\sigma_{\min}$. 这里我们使用了通常的向量长度，即 $\|\boldsymbol{x}\|^2 = x_1^2 + x_2^2 + \cdots + x_n^2$.

注意 $\sigma_{\min}$（并非 $\lambda_{\min}$）衡量的是 $\boldsymbol{A}$ 到最近的奇异值矩阵的距离. 起初我们可能会期望看到 $\boldsymbol{A} - \lambda_{\min}\boldsymbol{I}$ 的最小特征值为 0，然而这是**错误的**！由于乘以正交矩阵 $\boldsymbol{U}$ 与 $\boldsymbol{V}$ 并不改变范数，因此与 $\boldsymbol{A} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^{\mathrm{T}}$ 最接近的奇异值矩阵为 $\boldsymbol{U}(\boldsymbol{\Sigma} - \sigma_{\min}\boldsymbol{I})\boldsymbol{V}^{\mathrm{T}}$，该矩阵的最小奇异值为零.

矩阵 $\boldsymbol{A}$ 的每个特征值也有一个条件数. 假设 $\lambda$ 是方程 $\det(\boldsymbol{A} - \lambda \boldsymbol{I}) = 0$ 的一个单根（不是重根），那么对于单位特征向量 $\|\boldsymbol{x}\| = \|\boldsymbol{y}\| = 1$，**$\lambda$ 的条件数**定义为 $1/\left|\boldsymbol{y}^{\mathrm{T}}\boldsymbol{x}\right|$. 换言之，它等于 $1/|\cos\theta|$，其中 $\theta$ 是右特征向量 $\boldsymbol{x}$ 和左特征向量 $\boldsymbol{y}$ 之间的夹角.（所谓“左”来自方程 $\boldsymbol{y}^{\mathrm{T}}\boldsymbol{A} = \lambda \boldsymbol{y}^{\mathrm{T}}$，这里 $\boldsymbol{y}^{\mathrm{T}}$ 乘在 $\boldsymbol{A}$ 的左侧.）

注意，对于对称矩阵 $\boldsymbol{A}$，有 $\boldsymbol{y} = \boldsymbol{x}$，于是 $\cos\theta = 1$. 对称矩阵的特征值问题具有完美条件，就如同由于正交矩阵 $\boldsymbol{Q}$ 满足 $\|\boldsymbol{Q}\| \|\boldsymbol{Q}^{-1}\| = 1 = \operatorname{cond}(\boldsymbol{Q})$，从而 $\boldsymbol{Q}\boldsymbol{x} = \boldsymbol{b}$ 具有完美条件.

公式 $1/\left|\boldsymbol{y}^{\mathrm{T}}\boldsymbol{x}\right|$ 来自矩阵微小变化 $\Delta \boldsymbol{A}$ 所引起的特征值变化 $\Delta\lambda$ 的近似表达式，即 $\Delta\lambda \approx (\boldsymbol{y}^{\mathrm{T}}\Delta \boldsymbol{A}\boldsymbol{x})/\boldsymbol{y}^{\mathrm{T}}\boldsymbol{x}$.

## A8 马尔可夫矩阵与佩龙-弗罗比尼斯定理

本附录讨论所谓的“正矩阵”（所有元素 $a_{ij} > 0$）以及“非负矩阵”（所有元素 $a_{ij} \geqslant 0$）. 马尔可夫（Markov）矩阵 $\boldsymbol{M}$ 即是一类重要的例子，并且其各列所有元素之和都为 1. 一组非负数字求和为 1，让我们联想到这和概率有关.

关于任意马尔可夫矩阵 $\boldsymbol{M}$ 的一个有用结论是：其最大特征值总是 $\lambda = 1$. 我们知道 $\boldsymbol{M} - \boldsymbol{I}$ 的每一列元素之和均为零，因此 $\boldsymbol{M} - \boldsymbol{I}$ 的所有行向量之和零行向量，故 $\boldsymbol{M} - \boldsymbol{I}$ 不可逆，进而 $\lambda = 1$ 是 $\boldsymbol{M}$ 的一个特征值. 以下举两个例子：

矩阵 $\boldsymbol{A} = \begin{bmatrix} 0.8 & 0.3 \\ 0.2 & 0.7 \end{bmatrix}$ 以 1 和 $\frac{1}{2}$ 为特征值；而矩阵 $\boldsymbol{b} = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$ 以 1 和 $-1$ 为特征值.

上面的矩阵 $\boldsymbol{A}$ 是马尔可夫矩阵的典型例子. 其特征向量为 $\boldsymbol{x}_1 = \begin{bmatrix} 0.6 & 0.4 \end{bmatrix}^{\mathrm{T}}$ 和 $\boldsymbol{x}_2 = \begin{bmatrix} 1 & -1 \end{bmatrix}^{\mathrm{T}}$：

$\begin{bmatrix}0.8 & 0.3\\ 0.2 & 0.7\end{bmatrix}\begin{bmatrix}0.6\\ 0.4\end{bmatrix}=1\begin{bmatrix}0.6\\ 0.4\end{bmatrix}$ $\begin{bmatrix}0.6\\ 0.4\end{bmatrix}$ 是系统长期发展的稳态，

$\boldsymbol{A}>\boldsymbol{0}, \lambda_{\max}>0,$
特征向量 $>\boldsymbol{0}$

$\begin{bmatrix}0.8 & 0.3\\ 0.2 & 0.7\end{bmatrix}\begin{bmatrix}1\\ -1\end{bmatrix}=\frac{1}{2}\begin{bmatrix}1\\ -1\end{bmatrix}$ $\begin{bmatrix}1\\ -1\end{bmatrix}$ 是系统发展的瞬态，会逐渐消失.

我们最喜欢的例子基于芝加哥和丹佛的租车情况：一开始芝加哥有 100 辆车而丹佛没有车，即初始状态向量 $\boldsymbol{y}_0=\begin{bmatrix}100 & 0\end{bmatrix}^{\mathrm{T}}$. 时间每增加一个月，就对此时的状态向量 $\boldsymbol{y}_n$ 左乘 $\boldsymbol{A}$ 得到 $\boldsymbol{y}_{n+1}$，即在第 $n+1$ 个月芝加哥和丹佛的车辆数量.

$$\boldsymbol{y}_0=\begin{bmatrix}100\\ 0\end{bmatrix}\quad \boldsymbol{y}_1=\begin{bmatrix}80\\ 20\end{bmatrix}\quad \boldsymbol{y}_3=\begin{bmatrix}70\\ 30\end{bmatrix}\quad \cdots\quad \boldsymbol{y}_\infty=\begin{bmatrix}\mathbf{60}\\ \mathbf{40}\end{bmatrix}$$

上述稳态 $\begin{bmatrix}60 & 40\end{bmatrix}^{\mathrm{T}}$ 正好是 $\boldsymbol{A}$ 的对应于 $\lambda=1$ 的特征向量. 如果我们从 $\boldsymbol{y}_0=\begin{bmatrix}60 & 40\end{bmatrix}^{\mathrm{T}}$ 开始，那么将永远停留在该状态. 从 $\begin{bmatrix}100 & 0\end{bmatrix}^{\mathrm{T}}$ 开始，我们逐步将 40 辆车转移到丹佛. 从零时刻到时刻 1，数量 40 下降到 20，到时刻 2 下降到 10，到时刻 3 下降到 5. 这是另一个特征值 $\lambda=1/2$ 的影响，每一步都减少一半：

$$\boldsymbol{y}_0=\begin{bmatrix}60\\ 40\end{bmatrix}+\begin{bmatrix}40\\ -40\end{bmatrix},\quad \boldsymbol{y}_1=\begin{bmatrix}60\\ 40\end{bmatrix}+\begin{bmatrix}20\\ -20\end{bmatrix},\quad \cdots,\quad \boldsymbol{y}_n=\begin{bmatrix}60\\ 40\end{bmatrix}+\left(\frac{1}{2}\right)^n\begin{bmatrix}40\\ -40\end{bmatrix}.$$

由递推式 $\boldsymbol{y}_{n+1}=\boldsymbol{A}\boldsymbol{y}_n$ 可推出 $\boldsymbol{y}_n=\boldsymbol{A}^n\boldsymbol{y}_0$. 用矩阵的语言来说，$\boldsymbol{A}^n$ 最终趋于一个秩 1 矩阵：

$$\boldsymbol{A}^n=(\boldsymbol{X}\boldsymbol{\Lambda}\boldsymbol{X}^{-1})^n=\boldsymbol{X}\boldsymbol{\Lambda}^n\boldsymbol{x}^{-1}=\begin{bmatrix}0.6 & 1\\ 0.4 & -1\end{bmatrix}\begin{bmatrix}1 & 1\\ 0.4 & -0.6\end{bmatrix}\begin{bmatrix}1 & 1\\ 0.4 & -0.6\end{bmatrix}\to\boldsymbol{A}^\infty=\begin{bmatrix}0.6 & 0.6\\ 0.4 & 0.4\end{bmatrix}.$$

你现在已经看到了一个典型的马尔可夫矩阵，其最大特征值 $\lambda_{\max}=1$，对应的特征向量 $\begin{bmatrix}0.6 & 0.4\end{bmatrix}^{\mathrm{T}}$ 随着时间的推移而稳定. 所有较小的特征值都有 $\lambda^n\to 0$ 的趋势. 然而，上述例子中第二个马尔可夫矩阵 $\boldsymbol{B}$，其第二个特征值 $\lambda=-1$. 此时，我们不会得到稳态：

$$\boldsymbol{B}=\begin{bmatrix}0 & 1\\ 1 & 0\end{bmatrix}$$

特征值 $\lambda_1=1$ 对应的特征向量为 $\boldsymbol{x}_1=\begin{bmatrix}1 & 1\end{bmatrix}^{\mathrm{T}}$；
特征值 $\lambda_2=-1$ 对应的特征向量为 $\boldsymbol{x}_2=\begin{bmatrix}1 & -1\end{bmatrix}^{\mathrm{T}}$.

矩阵 $\boldsymbol{B}$ 中的零元素使得第二个特征值 $\lambda_2=-1$ 与 $\lambda_1=1$ 有相同的大小（绝对值）. 所有汽车每月在两个城市之间交换（从芝加哥到丹佛，以及从丹佛到芝加哥）. 如果我们从 $\boldsymbol{y}_0=\begin{bmatrix}60 & 40\end{bmatrix}^{\mathrm{T}}$ 开始，那么下一个月将转化为 $\boldsymbol{y}_1=\boldsymbol{B}\boldsymbol{y}_0=\begin{bmatrix}40 & 60\end{bmatrix}^{\mathrm{T}}$：

$$\boldsymbol{y}_0=\begin{bmatrix}60\\ 40\end{bmatrix}=\begin{bmatrix}50\\ 50\end{bmatrix}+\begin{bmatrix}10\\ -10\end{bmatrix},\quad \boldsymbol{y}_1=\begin{bmatrix}40\\ 60\end{bmatrix}=\begin{bmatrix}50\\ 50\end{bmatrix}-\begin{bmatrix}10\\ -10\end{bmatrix},\quad \boldsymbol{y}_2=\boldsymbol{y}_0,\quad \boldsymbol{y}_3=\boldsymbol{y}_1,\quad \cdots$$

由于 $\lambda_2=-1$ 的模 $|\lambda_2|$ 同样也为 1，故不存在稳态. 当马尔可夫矩阵 $\boldsymbol{A}$ 的所有元素 $a_{ij}>0$ 时，不会发生这样的情况. 而当 $\boldsymbol{B}$ 中存在某些分量 $b_{ij}=0$ 时，就可能会出现 $|\lambda_1|=|\lambda_2|$ 的情况.

佩龙（Perron）在第一种情况即 $a_{ij}>0$ 时，给出了结论和证明. 而之后弗罗比尼斯（Frobenius）讨论了第二种情况，即允许 $b_{ij}=0$. 在这个简短的附录中，我们仅叙述和证明佩龙的结论.

定理 (Perron)　对每个正矩阵 $\boldsymbol{A}$，等式 $\boldsymbol{Ax}=\lambda_{\max}\boldsymbol{x}$ 中的每个分量均为严格正数.

**证明**　由条件 $\boldsymbol{A}>0$ 开始，关键想法考虑满足下述条件的所有数 $t$：存在非负向量 $\boldsymbol{x}\neq\boldsymbol{0}$ 使得 $\boldsymbol{Ax}\geqslant t\boldsymbol{x}$. 之所以考虑不等式 $\boldsymbol{Ax}\geqslant t\boldsymbol{x}$，是为了得到较多的满足条件的小值正数 $t$. 令 $t$ 是其中的最大值 $t_{\max}$（最大值能取到），我们要证明等式成立，即 $\boldsymbol{Ax}=t_{\max}\boldsymbol{x}$. 于是，只要 $\boldsymbol{x}$ 是正的特征向量，那么 $t_{\max}$ 即为我们寻找的特征值. 以下证明这一点.

假设不等式 $\boldsymbol{Ax}>t_{\max}\boldsymbol{x}$ 严格成立，两边同时左乘 $\boldsymbol{A}$. 因为 $\boldsymbol{A}>\boldsymbol{0}$，故得 $\boldsymbol{A}^2\boldsymbol{x}>t_{\max}\boldsymbol{Ax}$. 因此，正向量 $\boldsymbol{y}=\boldsymbol{Ax}$ 满足 $\boldsymbol{Ay}>t_{\max}\boldsymbol{y}$. 这意味着 $t_{\max}$ 可以增大，得矛盾. 故假设不成立，从而 $\boldsymbol{Ax}=t_{\max}\boldsymbol{x}$ 成立，也即得到了一个特征值，且其特征向量 $\boldsymbol{x}$ 是正的，因为等式左边 $\boldsymbol{Ax}$ 必为正的.

为了说明没有特征值大于 $t_{\max}$，假设 $\boldsymbol{Az}=\lambda\boldsymbol{z}$. 由于 $\lambda$ 和 $\boldsymbol{z}$ 可能涉及负数或复数，我们对每个分量取绝对值，并由“三角不等式”，得 $|\lambda||\boldsymbol{z}|=|\boldsymbol{Az}|\leqslant\boldsymbol{A}|\boldsymbol{z}|$. $|\boldsymbol{z}|$ 是一个非负向量，所以 $|\lambda|$ 满足开始时数 $t$ 的条件，因此 $|\lambda|$ 不会超过 $t_{\max}$. 因此，$t_{\max}$ 必为最大特征值 $\lambda_{\max}$.

许多马尔可夫示例的矩阵中开始包含零分量（弗罗比尼斯），但是 $\boldsymbol{A}^2$ 或更高次幂 $\boldsymbol{A}^m$ 就变成严格正的（佩龙）. 因此，我们可以应用佩龙的理论，说明这些“初始矩阵”仍然有一个对应于特征值 $\lambda=1$ 的稳态特征向量.

---

一个重要的例子是**谷歌矩阵** $\boldsymbol{G}$，这是页面排序（PageRank）算法的基础（一家大公司完全依靠线性代数存在）. 当页面 $j$ 有链接指向页面 $i$ 时，令 $A_{ij}=1$. 然后对 $A$ 的每列元素除以该列链出的总数：如此归一化后，每列的和均为 1. 最后，令 $G_{ij}=\alpha A_{ij}+(1-\alpha)/N$，以确保每个 $G_{ij}>0$（符合佩龙定理）. 有关更多信息，请参见维基百科，艾米·朗维尔（Amy Langville）与卡尔·迈耶（Carl Meyer）合著的书，该书可以通过谷歌快速找到.

---

**参考文献：**

Amy Langville and Carl Meyer, Google's Page Rank and Beyond: The Science of Search Engine Rankings（《谷歌的 PageRank 及其背后：搜索引擎排名的科学》），普林斯顿大学出版社，2011.

## A9　消元法与矩阵分解

如果矩阵 $\boldsymbol{A}$ 的秩为 $r$，那么它的最简行阶梯形（通过消元得到）在其前 $r$ 个主元列中包含了单位矩阵. 我们如何解释该阶梯形剩余列中包含的矩阵 $\boldsymbol{F}$？$\boldsymbol{F}$ 左乘 $\boldsymbol{A}$ 的 $r$ 个主元列构成的矩阵，可得到其 $n-r$ 个自由列. 并且 $\boldsymbol{F}$ 刻画了矩阵 $\boldsymbol{A}$ 的行空间和零空间的基. 从而，$\boldsymbol{F}$ 是列-行分解 $\boldsymbol{A}=\boldsymbol{CR}$ 的关键.

1. 消元法可以算是线性代数中最古老的算法. 通过在矩阵中系统地产生零，它简化了 $m$ 个方程联立得到的方程组 $\boldsymbol{Ax}=\boldsymbol{b}$ 的求解过程. 我们以下述 3 行 4 列的矩阵 $\boldsymbol{A}$ 为例. 不难看出，下面的 $\boldsymbol{A}$ 的第一行加第二行等于第三行，于是它的秩为 $r=2$. 我们利用大家熟悉的消元法，分步骤得

到了它的最简行阶梯形矩阵 $\boldsymbol{Z}$：

$$\boldsymbol{A}=\begin{bmatrix}1&2&11&17\\3&7&37&57\\4&9&48&74\end{bmatrix}\longrightarrow\boldsymbol{Z}=\begin{bmatrix}1&0&3&5\\0&1&4&6\\0&0&0&0\end{bmatrix}$$

此时，我们暂停算法而提出一个问题：$\boldsymbol{Z}$ 与 $\boldsymbol{A}$ 有何关系？一个答案是关于 $\boldsymbol{A}$ 的基本子空间：

（1）$\boldsymbol{Z}$ 的两个非零行（记为 $\boldsymbol{R}$）是 $\boldsymbol{A}$ 的行空间的一组基；

（2）$\boldsymbol{A}$ 的前两列（记为 $\boldsymbol{C}$）是 $\boldsymbol{A}$ 的列空间的一组基；

（3）$\boldsymbol{Z}$ 的零空间等于 $\boldsymbol{A}$ 的零空间（与相同的行空间正交）.

“简化矩阵 $\boldsymbol{A}$ 而不丢失其包含的信息”是我们最初进行消元的原因. 同时，将相同的操作应用于 $\boldsymbol{Ax}=\boldsymbol{b}$ 等号的右边，我们得到 $\boldsymbol{Zx}=\boldsymbol{d}$——该方程组和 $\boldsymbol{Ax}=\boldsymbol{b}$ 同解，而矩阵 $\boldsymbol{Z}$ 更简单.

本附录的目的是用不同的方式表达消元法的结果. 这种矩阵分解可能不是新的，但它值得再次强调.

消元法将 $\boldsymbol{A}$ 分解为 $\boldsymbol{C}_{m\times r}$ 乘以 $\boldsymbol{R}_{r\times n}$

$$\boldsymbol{A}=\begin{bmatrix}1&2&11&17\\3&7&37&57\\4&9&48&74\end{bmatrix}=\begin{bmatrix}1&2\\3&7\\4&9\end{bmatrix}\begin{bmatrix}1&0&3&5\\0&1&4&6\end{bmatrix}=\boldsymbol{CR}$$

其中，$\boldsymbol{C}$ 是秩等于 2 的列满秩矩阵，而 $\boldsymbol{R}$ 是秩为 2 的行满秩矩阵. 一旦我们证明了 $\boldsymbol{A}=\boldsymbol{CR}$ 对每个矩阵 $\boldsymbol{A}$ 都成立，该分解式就导出了线性代数第一个重要定理：列秩等于行秩.

**2.** 下面对 $\boldsymbol{C}$ 和 $\boldsymbol{R}$ 进行的描述，该描述与计算它们的算法（行变换）无关.

假设 $\boldsymbol{A}$ 的 $r$ 个主元列构成 $\boldsymbol{C}$，那么 $\boldsymbol{A}$ 的剩余 $n-r$ 列一定是 $\boldsymbol{C}$ 的列的组合，可表示为 $\boldsymbol{CF}$ 的形式. 该关键的矩阵 $\boldsymbol{F}$ 是具有 $r$ 个线性无关行的行因子矩阵 $\boldsymbol{R}=\begin{bmatrix}\boldsymbol{I}&\boldsymbol{F}\end{bmatrix}\boldsymbol{P}$ 的一部分. 于是即得 $\boldsymbol{A}=\boldsymbol{CR}$：

$$\boldsymbol{A}=\boldsymbol{CR}=\begin{bmatrix}\boldsymbol{C}&\boldsymbol{CF}\end{bmatrix}\boldsymbol{P}=\begin{bmatrix}\boldsymbol{A}\text{ 的主元列}&\boldsymbol{A}\text{ 的自由列}\end{bmatrix}\text{列置换.}\tag{A.4}$$

若 $\boldsymbol{A}$ 的 $r$ 个主元列恰好为 $\boldsymbol{A}$ 的前 $r$ 列，那么置换矩阵 $\boldsymbol{P}=\boldsymbol{I}$. 否则，我们需要用右乘 $\boldsymbol{P}$ 来将 $\boldsymbol{C}$ 和 $\boldsymbol{CF}$ 的 $n$ 个列，置换到 $\boldsymbol{A}$ 中的正确位置. 下面是一个 $\boldsymbol{A}=\boldsymbol{C}\begin{bmatrix}\boldsymbol{I}&\boldsymbol{F}\end{bmatrix}\boldsymbol{P}$ 的例子，其中 $\boldsymbol{P}$ 交换了第 2 列和第 3 列：

$$\boldsymbol{A}=\begin{bmatrix}1&2&3&4\\1&2&4&5\end{bmatrix}=\begin{bmatrix}1&3\\1&4\end{bmatrix}\begin{bmatrix}1&2&0&1\\0&0&1&1\end{bmatrix}=\begin{bmatrix}1&3\\1&4\end{bmatrix}\begin{bmatrix}1&0&2&1\\0&1&0&1\end{bmatrix}\boldsymbol{P}=\boldsymbol{CR}.\tag{A.5}$$

$\mathbf{rref}(\boldsymbol{A})$ 中的本质信息是：$\boldsymbol{A}$ 的 $r$ 个主元列的位置，以及 $r\times(n-r)$ 列矩阵 $\boldsymbol{F}$，将该主元列组合起来，而给出 $\boldsymbol{A}$ 中剩余的 $n-r$ 个自由列 $\boldsymbol{CF}$. 这些性质唯一地决定了 $\mathbf{rref}(\boldsymbol{A})$.

**3.** 矩阵分解 $\boldsymbol{A}=\boldsymbol{CR}$ 已得证，但应该如何确定 $\boldsymbol{A}$ 中前 $r$ 个线性无关列（也即主元列，进而得到 $\boldsymbol{C}$），以及剩余 $n-r$ 个自由列 $\boldsymbol{CF}$ 呢？方法也是对 $\boldsymbol{A}$ 进行初等行变换的操作. 我们允许以下三种（可逆的）操作，将 $\boldsymbol{A}$ 变为其最简行阶梯形矩阵 $\mathbf{rref}(\boldsymbol{A})$：

（1）某一行减去另一行的倍数（向上或向下均可）；

（2）交换两行位置；

（3）将一行除以其第一个非零元素.

所有线性代数教师和大部分学生都知道这些步骤及其结果 $\mathbf{rref}(\boldsymbol{A})$，其中包含一个 $r$ 行 $r$ 列的单位矩阵 $\boldsymbol{I}$（只有零可以位于那些主元 1 之前），该单位阵 $\boldsymbol{I}$ 可决定 $\boldsymbol{A}$ 的前 $r$ 个线性无关列（主元列）. 而上述分解式(A.5)表明了 $\boldsymbol{F}$ 的意义！它告诉我们 $\boldsymbol{A}$ 的 $n-r$ 个自由列 $\boldsymbol{CF}$ 是如何由 $\boldsymbol{C}$ 的线性无关的列组合而得到. 此外，$\boldsymbol{A}$ 的剩余 $m-r$ 个线性相关行在 $\boldsymbol{Z}$ 中须化为零行：

$$\text{消元法将}\quad \boldsymbol{A}\quad \text{化简为}\quad \boldsymbol{Z}=\mathbf{rref}(\boldsymbol{A})=\begin{bmatrix}\boldsymbol{I} & \boldsymbol{F}\\ \boldsymbol{0} & \boldsymbol{0}\end{bmatrix}\boldsymbol{P}. \tag{A.6}$$

这就是高斯-若尔当消元法：对主元行的上方和下方都要进行变换操作. 但是，将 $\boldsymbol{A}$ 化为其最简行阶梯形矩阵，不如式(A.5)中阐述的分解式 $\boldsymbol{A}=\boldsymbol{CR}$ 重要.

**4.** 在利用 $\boldsymbol{A}=\boldsymbol{CR}$ 求解方程组 $\boldsymbol{Ax}=\boldsymbol{0}$ 之前，我们希望由 $\boldsymbol{A}$ 从左到右逐列得到 $\mathbf{rref}(\boldsymbol{A})$. 若前 $k$ 列已完成消元，该部分就是其自身的最简行阶梯形矩阵. 假设我们对第 $k+1$ 列也展开了消元，并将所得到的新的第 $k+1$ 列分拆为靠上的部分 $\boldsymbol{u}$ 和靠下的部分 $\boldsymbol{\ell}$：

$$\text{前 } k+1 \text{ 列：}\qquad \begin{bmatrix}\boldsymbol{I}_k & \boldsymbol{F}_k\\ \boldsymbol{0} & \boldsymbol{0}\end{bmatrix}\boldsymbol{P}_k \quad \text{的右侧添加列向量} \begin{bmatrix}\boldsymbol{u}\\ \boldsymbol{\ell}\end{bmatrix}. \tag{A.7}$$

一个重要的问题是：**新得到的第 $k+1$ 列是与 $\boldsymbol{I}_k$ 相结合？还是与 $\boldsymbol{F}_k$ 相结合？**

**如果 $\boldsymbol{\ell}$ 为零向量**，则该新列与前 $k$ 列线性相关，那么将 $\boldsymbol{u}$ 与 $\boldsymbol{F}_k$ 合并得到 $\boldsymbol{F}_{k+1}$，并转到下一步处理第 $k+2$ 列.

**如果 $\boldsymbol{\ell}$ 不为零向量**，则该新列与前 $k$ 列线性无关. 选择 $\boldsymbol{\ell}$ 中的任意非零元素（最好是最大元）作为主元，将该主元所在的 $\boldsymbol{A}$ 的行移至 $\boldsymbol{\ell}$ 的顶部. 然后使用该主元行将第 $k+1$ 列的其余部分（通过标准消元法）消为零. （该操作预计会改变第 $k+1$ 列之后列.）进而将所得列与 $\boldsymbol{I}_k$ 合并得到 $\boldsymbol{I}_{k+1}$. 并据此调整置换矩阵 $\boldsymbol{P}_k$. 然后转到下一步处理第 $k+2$ 列.

在消元结束时，我们得到了一个预期的列编号子集合，这反映了 $\boldsymbol{A}$ 的前 $r$ 个线性无关列（即主元列）的位置. 这些列构成了矩阵 $\boldsymbol{C}$ 的列，在分解式 $\boldsymbol{A}=\boldsymbol{CR}$ 的行因子 $\boldsymbol{R}$ 中，这些列对应了 $r\times r$ 单位矩阵.

**5.** 将 $\boldsymbol{A}$ 化为 $\mathbf{rref}(\boldsymbol{A})$ 的目的是什么？行空间没有改变！于是它的正交补（即 $\boldsymbol{A}$ 的零空间）也没有改变. $\boldsymbol{CF}$ 的每一列说明了 $\boldsymbol{A}$ 的一个自由列是如何被 $\boldsymbol{C}$ 中的主元列组合线性表示的. 实际上，**$\boldsymbol{F}$ 的列也可以给出方程组 $\boldsymbol{AX}=\boldsymbol{0}$ 的 $n-r$ 个（线性无关的）解.**

通过以下第 1章中的例子，很容易看出这一点：

$$\begin{cases}x_1+2x_2+11x_3+17x_4=0\\ 3x_1+7x_2+37x_3+57x_4=0\end{cases}\qquad \text{化简为}\qquad \begin{cases}x_1+3x_3+5x_4=0\\ x_2+4x_3+6x_4=0\end{cases}$$

自由变量取 $x_3=1,x_4=0$，得到方程组的第一个解 $\boldsymbol{x}=\begin{bmatrix}-3 & -4 & 1 & 0\end{bmatrix}^{\mathrm{T}}$，其中 3、4 来自矩阵 $\boldsymbol{F}$. 自由变量取 $x_3=0,x_4=1$ 的，得到第二个解 $\boldsymbol{x}=\begin{bmatrix}-5 & -6 & 0 & 1\end{bmatrix}^{\mathrm{T}}$. 以这两个解为列向量，构成的矩阵 $\boldsymbol{X}$ 满足 $\boldsymbol{AX}=\boldsymbol{0}$.（此例中的置换矩阵 $\boldsymbol{P}=\boldsymbol{I}$）. 一般地，矩阵 $\boldsymbol{X}$ 的 $n-r$ 个列自然是 $\boldsymbol{A}$ 的零空间的一组基：

$$\boldsymbol{A}=\boldsymbol{C}\begin{bmatrix}\boldsymbol{I} & \boldsymbol{F}\end{bmatrix}\quad \text{乘以}\quad \boldsymbol{X}=\boldsymbol{P}^{\mathrm{T}}\begin{bmatrix}-\boldsymbol{F}\\ \boldsymbol{I}_{n-r}\end{bmatrix}\quad \text{得到}\quad \boldsymbol{AX}=-\boldsymbol{CF}+\boldsymbol{CF}=\boldsymbol{0}. \tag{A.8}$$

$\boldsymbol{X}$ 的每一列都为 $\boldsymbol{Ax}=\boldsymbol{0}$ 的一个解（注意：$\boldsymbol{PP}^{\mathrm{T}}=\boldsymbol{I}$.）$\boldsymbol{X}$ 包含的这 $n-r$ 个解告诉我们一个已知的事实：$\boldsymbol{A}$ 的每个自由列为 $\boldsymbol{C}$ 中的主元列的线性组合. 在上述例子中，第 3 列 $=3\times$（第 1 列）$+4\times$（第 2 列）.

高斯-若尔当消元法相当于利用分解式 $\boldsymbol{A}=\boldsymbol{CR}$ 来求解方程组 $\boldsymbol{Ax}=\boldsymbol{b}$，但这样做的效率低于用高斯过程直接求解. 后者在求得一个上三角阵为系数矩阵的方程组 $\boldsymbol{Ux}=\boldsymbol{c}$ 时即可停止，再用回代法求出解向量 $\boldsymbol{x}$. 而高斯 -若尔当消元法还有向上消元的额外成本. 如果我们只想求解 $n\times n$ 系数矩阵的方程组，做三角形式的矩阵分解是更快的方法.

**6. 分块消元法** 将 $\boldsymbol{A}$ 化为阶梯形矩阵的过程中，每进行一次行变换产生一个零. 最简行阶梯形矩阵中一个关键部分是 $r$ 阶单位矩阵. 如果我们从更大的尺度思考——一次不仅仅做一行的变换——**而单位阵 $\boldsymbol{I}$ 告诉我们存在某个可逆的 $r\times r$ 子方阵.** 遵循上述想法，我们有了“矩阵意义”的消除法.

假设矩阵 $\boldsymbol{A}$ 的前 $r$ 行和前 $r$ 列构成的子矩阵是 $\boldsymbol{W}$，且 $\boldsymbol{W}$ 是可逆的. 下面我们考虑利用 $\boldsymbol{W}$ 的整体结构来做消除！一次一个元素——或许可以一次性整块地消除——**而 $\boldsymbol{W}$ 可变为 $\boldsymbol{I}$.** 换言之，$\boldsymbol{A}$ 的前 $r$ 行将变化为 $\boldsymbol{I}$ 和 $\boldsymbol{F}$，其中 $\boldsymbol{F}=\boldsymbol{W}^{-1}\boldsymbol{H}$. 而后 $m-r$ 行将变成零行.

**分块消元法：**
$$\boldsymbol{A}=\begin{bmatrix}\boldsymbol{W} & \boldsymbol{H}\\ \boldsymbol{J} & \boldsymbol{K}\end{bmatrix}\text{ 化为 }\begin{bmatrix}\boldsymbol{I} & \boldsymbol{F}\\ \boldsymbol{0} & \boldsymbol{0}\end{bmatrix}=\mathbf{rref}(\boldsymbol{A}). \tag{A.9}$$

上式阐述了线性代数的一个结论：若 $\boldsymbol{A}$ 的前 $r$ 行是线性无关的，且 $\boldsymbol{A}$ 的秩为 $r$，则剩余 $m-r$ 行可表为前 $r$ 行的线性组合，即 $\begin{bmatrix}\boldsymbol{J} & \boldsymbol{K}\end{bmatrix}=\boldsymbol{JW}^{-1}\begin{bmatrix}\boldsymbol{W} & \boldsymbol{H}\end{bmatrix}$. 并且这 $m-r$ 可通过消元法化为零行.

一般地，$\boldsymbol{A}$ 的左上角 $r\times r$ 子方块不一定可逆. 但消元过程中我们将找到 $\boldsymbol{W}$，进而可通过行置换 $\boldsymbol{P}_r$ 和列置换 $\boldsymbol{P}_c$ 将 $\boldsymbol{W}$ 移到左上角的位置上.

因此，分块消元化为最简行阶梯形矩阵的完整表达式为
$$\boldsymbol{P}_r\boldsymbol{AP}_c=\begin{bmatrix}\boldsymbol{W} & \boldsymbol{H}\\ \boldsymbol{J} & \boldsymbol{K}\end{bmatrix}\longrightarrow\begin{bmatrix}\boldsymbol{I} & \boldsymbol{W}^{-1}\boldsymbol{H}\\ \boldsymbol{0} & \boldsymbol{0}\end{bmatrix}. \tag{A.10}$$

**7.** 这引发了一个有趣的观点：由于 $\boldsymbol{A}$ 的秩为 $r$，我们知道它必有 $r$ 个线性无关的行和 $r$ 个线性无关的列. 假设上述行构成子矩阵 $\boldsymbol{B}$，而上述列构成子矩阵 $\boldsymbol{C}$，那么，位于两者交叉位置上的 $r$ 阶子方阵 $\boldsymbol{W}$ 是否总是可逆？（大家都同意矩阵 $\boldsymbol{A}$ 存在某个 $r$ 阶可逆子方阵. 问题是 $\boldsymbol{B}\cap\boldsymbol{C}$ 是否能提供这样的子方阵.）也即 $\boldsymbol{W}$ 是自动满秩的吗？

回答是肯定的：$\boldsymbol{A}$ 的 $r$ 个线性无关的行和 $r$ 个线性无关的列的交集确实为一个秩为 $r$ 的子方阵 $\boldsymbol{W}$，也即 $\boldsymbol{W}$ 是可逆的.

**证明** $\boldsymbol{A}$ 的每一列都是 $\boldsymbol{C}$ 的 $r$ 个列的线性组合. $r\times n$ 矩阵 $\boldsymbol{B}$ 的每一列都是 $\boldsymbol{W}$ 的 $r$ 个列的相同线性组合. 由于 $\boldsymbol{B}$ 的秩为 $r$，其列空间是整个 $\mathbb{R}^r$，那么 $\boldsymbol{W}$ 的列空间也是 $\mathbb{R}^r$，从而子**方阵 $\boldsymbol{W}$ 的秩为 $r$.**

## A10 计算机图形学

计算机图形学处理的是图像. 图像移动、缩放，三维图形投影到二维，等等. 所有主要操作都可由矩阵来实现——但这些矩阵的形式有些出人意料.

三维空间中的变换实际上是用四阶矩阵实现的. 你可能会以为是三阶矩阵，而这里改用四阶矩阵的原因是：以下四种关键操作中的一个无法用三阶矩阵的乘法来实现. 这四种操作包括：

（1）平移：将原点移至另一点 $P_0=(x_0,y_0,z_0)$；

（2）缩放：在所有方向上按 $c$ 倍缩放，或三个方向分别按不同的因子 $c_1$、$c_2$、$c_3$ 缩放；

（3）旋转：绕经过原点（或任一点 $P_0$）的轴旋转；

（4）投影：向包含原点（或任一点 $P_0$）的平面投影.

平移的运算是最简单的，只需将每个点都加上 $(x_0,y_0,z_0)$ 即可，但这不是线性的变换！没有三阶矩阵的乘法可以移动原点. 因此，我们将原点放入四维空间中，并取其坐标为 $(0,0,0,1)$. 这就是采用四阶矩阵的原因. 我们令三维空间中点 $(x,\ y,\ z)$ 的“齐次坐标”为 $(x,\ y,\ z,\ 1)$，下面阐述这样的设定是如何生效的.

## A10.1 平移

我们将整个三维空间沿向量 $\boldsymbol{v}_0$ 做平移，其中原点移至 $(x_0,y_0,z_0)$. 运算上将该向量 $\boldsymbol{v}_0$ 与 $\mathbb{R}^3$ 中的每个点 $\boldsymbol{v}$ 做加法. 使用齐次坐标，如下四阶矩阵 $\boldsymbol{T}$ 的乘法可将整个空间平移 $\boldsymbol{v}_0$：

平移矩阵 $$\boldsymbol{T}=\begin{bmatrix}1&0&0&0\\0&1&0&0\\0&0&1&0\\x_0&y_0&z_0&1\end{bmatrix}.$$

重要提示：计算机图形学中，我们均使用行向量，即用行向量乘以矩阵，而不是矩阵乘以列向量. 你可以快速验证 $\begin{bmatrix}0&0&0&1\end{bmatrix}\boldsymbol{T}=\begin{bmatrix}x_0&y_0&z_0&1\end{bmatrix}$.

要将点 $(0,0,0)$ 和 $(x,y,z)$ 沿 $\boldsymbol{v}_0$ 做平移，先转换为齐次坐标 $(0,0,0,1)$ 和 $(x,y,z,1)$，然后右侧乘 $\boldsymbol{T}$. 行向量乘 $\boldsymbol{T}$ 得到行向量. 三维向量 $\boldsymbol{v}$ 移动到 $\boldsymbol{v}+\boldsymbol{v}_0$，可由如下齐次坐标实现：

$$\begin{bmatrix}x&y&z&1\end{bmatrix}\boldsymbol{T}=\begin{bmatrix}x+x_0&y+y_0&z+z_0&1\end{bmatrix}.$$

上述运算说明了任一 $\boldsymbol{v}$ 将移动到哪里（的确移动到 $\boldsymbol{v}+\boldsymbol{v}_0$）. 现在，平移通过（齐次坐标）的矩阵乘法实现了，而这在 $\mathbb{R}^3$ 中是不可能的.

## A10.2 缩放

为了使图片适应页面，我们会改变其宽度和高度. 例如，复印机可将图形整体按 90% 进行缩放. 在线性代数中，我们乘以 0.9 倍的单位矩阵. 通常，该矩阵为二阶单位矩阵（平面图形）或三阶单位矩阵（立体图形）. 在计算机图形学中，使用齐次坐标后，矩阵比原来大一阶：

平面缩放矩阵 $$\boldsymbol{S}=\begin{bmatrix}0.9&0&0\\0&0.9&0\\0&0&1\end{bmatrix};$$

立体缩放矩阵 $$\boldsymbol{S}=\begin{bmatrix}c&0&0&0\\0&c&0&0\\0&0&c&0\\0&0&0&1\end{bmatrix}.$$

重要提示：$\boldsymbol{S}$ 并不是 $c\boldsymbol{I}$，其最右下角的元素始终为“1”. 于是，需要在齐次坐标 $\begin{bmatrix} x & y & 1 \end{bmatrix}$ 下右乘 $\boldsymbol{S}$ 即得到正确答案. 因为 $\begin{bmatrix} 0 & 0 & 0 & 1 \end{bmatrix}\boldsymbol{S} = \begin{bmatrix} 0 & 0 & 0 & 1 \end{bmatrix}$，所以原点保持不变.

若将此“1”更改为“$c$”，结果将显得异常. 点 $\begin{bmatrix} cx & cy & cz & c \end{bmatrix}$ 实则等同于 $\begin{bmatrix} x & y & z & 1 \end{bmatrix}$，因为齐次坐标的特殊性质在于，乘以 $c\boldsymbol{I}$ 得到的是同一个点. 在 $\mathbb{R}^3$ 中，原点的齐次坐标为 $\begin{bmatrix} 0 & 0 & 0 & 1 \end{bmatrix}$ 亦为 $\begin{bmatrix} 0 & 0 & 0 & c \end{bmatrix}$（对于任意非零 $c$）. 这就是“齐次（homogeneous）”一词背后的含义.

一般地，我们也可以在不同方向缩放不同的倍数. 为了将一张全页纸的图片缩小到半页纸，只需在 $y$ 方向缩小 1/2 即可. 为了创建页边距，在 $x$ 方向缩小为 3/4. 对应的图形变换是一个对角矩阵，但并不是 $2\times 2$ 的. 一般地，平面上的缩放矩阵为 $3\times 3$ 的，而空间里的缩放矩阵是 $4\times 4$ 的，即

$$\text{缩放矩阵：}\ \boldsymbol{S} = \begin{bmatrix} \frac{3}{4} & 0 & 0 \\ 0 & \frac{1}{2} & 0 \\ 0 & 0 & 1 \end{bmatrix} \qquad \boldsymbol{S} = \begin{bmatrix} c_1 & 0 & 0 & 0 \\ 0 & c_2 & 0 & 0 \\ 0 & 0 & c_3 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}.$$

其中，后一个矩阵 $\boldsymbol{S}$ 将 $x$、$y$、$z$ 方向分别按正数 $c_1$、$c_2$、$c_3$ 倍进行缩放. 所有这些矩阵的最后一列在其末尾均保留了额外的一个“1”.

总结：缩放矩阵 $\boldsymbol{S}$ 与平移矩阵 $\boldsymbol{T}$ 尺寸相同，它们可以相乘. 若先平移后缩放，则进行运算 $\boldsymbol{vTS}$；若先缩放后平移，则进行运算 $\boldsymbol{vST}$. 两者是否有差异呢？答案是：有差异.

$\mathbb{R}^3$ 中的点 $\begin{bmatrix} x & y & z \end{bmatrix}$ 在 $\mathbb{P}^3$ 中的齐次坐标为 $\begin{bmatrix} x & y & z & 1 \end{bmatrix}$. 这里“投影空间” $\mathbb{P}^3$ 与 $\mathbb{R}^4$ 并不相同，它仍然是三维的. 为了实现这一点，我们认为 $\begin{bmatrix} x & y & z & 1 \end{bmatrix}$ 与 $\begin{bmatrix} cx & cy & cz & c \end{bmatrix}$ 表示同一个点. $\mathbb{P}^3$ 中的点实际上对应了 $\mathbb{R}^4$ 中过原点的直线.

计算机图形学中，我们采用了线性且可平移的仿射变换. 一个仿射变换 $T$ 嵌套到一个添加了特殊第四列的 $4\times 4$ 的矩阵里，并将它作用到 $\mathbb{P}^3$ 中：

$$\boldsymbol{A} = \begin{bmatrix} a_{11} & a_{12} & a_{13} & 0 \\ a_{21} & a_{22} & a_{23} & 0 \\ a_{31} & a_{32} & a_{33} & 0 \\ a_{41} & a_{42} & a_{43} & 1 \end{bmatrix} = \begin{bmatrix} T(1,0,0) & 0 \\ T(0,1,0) & 0 \\ T(0,0,1) & 0 \\ T(0,0,0) & 1 \end{bmatrix}.$$

通常的 $3\times 3$ 矩阵为我们提供三个输出，而上述矩阵提供四个输出. 常规输出来自输入向量 $\begin{bmatrix} 1 & 0 & 0 \end{bmatrix}$、$\begin{bmatrix} 0 & 1 & 0 \end{bmatrix}$ 和 $\begin{bmatrix} 0 & 0 & 1 \end{bmatrix}$. 当变换是线性时，前三个输出即可给出结果. 当变换是仿射时，矩阵还包含来自 (0, 0, 0) 的输出，于是，我们知道了位移.

## A10.3 旋转

在 $\mathbb{R}^2$ 或 $\mathbb{R}^3$ 中，旋转通过正交矩阵 $\boldsymbol{Q}$ 实现，且要求 $\boldsymbol{Q}$ 的行列式值为 $+1$（若行列式值为 $-1$，则在旋转之余还会产生一个额外的镜面反射. ）在使用齐次坐标时，请添加一个额外的第四列！

平面的旋转 $\boldsymbol{Q}=\begin{bmatrix}\cos\theta & -\sin\theta\\ \sin\theta & \cos\theta\end{bmatrix}$ 变为 $\boxed{\boldsymbol{R}=\begin{bmatrix}\cos\theta & -\sin\theta & 0\\ \sin\theta & \cos\theta & 0\\ 0 & 0 & 1\end{bmatrix}}$.

该矩阵将整个平面围绕原点进行旋转. 如何围绕另外的点如 $(4,5)$ 进行旋转？以下答案展现了齐次坐标的优美. 首先将 $(4,5)$ 平移到 $(0,0)$，然后做 $\theta$ 角度的旋转，最后再将 $(0,0)$ 平移回 $(4,5)$：

$$\boldsymbol{vT}_{-}\boldsymbol{RT}_{+}=\begin{bmatrix}x & y & 1\end{bmatrix}\begin{bmatrix}1 & 0 & 0\\ 0 & 1 & 0\\ -4 & -5 & 1\end{bmatrix}\begin{bmatrix}\cos\theta & -\sin\theta & 0\\ \sin\theta & \cos\theta & 0\\ 0 & 0 & 1\end{bmatrix}\begin{bmatrix}1 & 0 & 0\\ 0 & 1 & 0\\ 4 & 5 & 1\end{bmatrix}.$$

先不要急于计算上式中的矩阵乘法，关键在于理解每乘一个矩阵的意义：$\boldsymbol{v}$ 首先平移到 $\boldsymbol{vT}_{-}$，然后旋转到 $\boldsymbol{vT}_{-}\boldsymbol{R}$，最后平移回 $\boldsymbol{vT}_{-}\boldsymbol{RT}_{+}$. 因为每个点对应行向量 $\begin{bmatrix}x & y & 1\end{bmatrix}$，$\boldsymbol{T}_{-}$ 首先作用它，于是旋转中心 $(4,5)$（或者更应该视为 $(4,5,1)$）首先移动到 $(0,0,1)$. 旋转不改变其位置. 然后 $\boldsymbol{T}_{+}$ 将它移回 $(4,5,1)$. 一切正如预期. 而点 $(4,6,1)$ 先移动到 $(0,1,1)$，然后旋转 $\theta$ 角度再移回.

在三维空间中，每个旋转 $\boldsymbol{Q}$ 都围绕一根轴进行. 轴不随旋转而变化——它是由属于特征值 $\lambda=1$ 的特征向量构成的一条直线. 假设轴在 $z$ 轴方向. 下述 $\boldsymbol{Q}$ 中的 1 是为了保持 $z$ 轴不变，而下述 $\boldsymbol{R}$ 中额外的 1，是为了保持原点不变：

$$\boldsymbol{Q}=\begin{bmatrix}\cos\theta & -\sin\theta & 0\\ \sin\theta & \cos\theta & 0\\ 0 & 0 & 1\end{bmatrix}\qquad \boldsymbol{R}=\begin{bmatrix}\cos\theta & -\sin\theta & 0 & 0\\ \sin\theta & \cos\theta & 0 & 0\\ 0 & 0 & 1 & 0\\ 0 & 0 & 0 & 1\end{bmatrix}.$$

接下来，假设旋转是围绕单位向量 $\boldsymbol{a}=\begin{bmatrix}a_1 & a_2 & a_3\end{bmatrix}$ 进行的. 对于 $\boldsymbol{a}$ 所在的这根轴，将以下具有三个组成部分的旋转矩阵 $\boldsymbol{Q}$ 装入四阶矩阵 $\boldsymbol{R}$ 即可，其中：

$$\boldsymbol{Q}=(\cos\theta)\boldsymbol{I}+(1-\cos\theta)\begin{bmatrix}a_1^2 & a_1a_2 & a_1a_3\\ a_1a_2 & a_2^2 & a_2a_3\\ a_1a_3 & a_2a_3 & a_3^2\end{bmatrix}-\sin\theta\begin{bmatrix}0 & a_3 & -a_2\\ -a_3 & 0 & a_1\\ a_2 & -a_1 & 0\end{bmatrix}. \tag{A.11}$$

容易验证 $\boldsymbol{aQ}=\boldsymbol{a}$，故轴在旋转中是不变的. 当 $\boldsymbol{a}=\begin{bmatrix}0 & 0 & 1\end{bmatrix}$，也即为 $z$ 轴方向时，式(A.11)中的 $\boldsymbol{Q}$ 就变成了之前的 $\boldsymbol{Q}$——即绕 $z$ 轴的旋转.

线性变换 $\boldsymbol{Q}$ 总是位于 $\boldsymbol{R}$ 的左上角子块中，其下方均为零，因为旋转保持原点不动. 当该位置不是零时，变换是仿射的，原点会被变换移动.

## A10.4 投影

线性代数课程中讨论的平面大多数都通过原点. 然而在现实生活中，大多数并不是. 通过原点的平面是一个向量空间，而其他平面是仿射空间，有时称为“平片（flat）”. 仿射空间是通过向量空间平移得到的.

我们希望将三维向量投影到某个平面上. 先从通过原点的平面开始，设其单位法向量为 $\boldsymbol{n}$（我们将保持 $\boldsymbol{n}$ 为列向量）. 平面内的向量满足 $\boldsymbol{n}^{\mathrm{T}}\boldsymbol{v}=0$. 一般地，向该平面的投影矩阵为 $\boldsymbol{I}-\boldsymbol{n}\boldsymbol{n}^{\mathrm{T}}$. 列向量 $\boldsymbol{v}$ 右乘该矩阵，就可实现将 $\boldsymbol{v}$ 投影到指定平面. 向量 $\boldsymbol{n}$ 投影后变成零，而平面内的任意向量 $\boldsymbol{v}$ 投影后不变：

$$\left(\boldsymbol{I}-\boldsymbol{n}\boldsymbol{n}^{\mathrm{T}}\right)\boldsymbol{n}=\boldsymbol{n}-\boldsymbol{n}\left(\boldsymbol{n}^{\mathrm{T}}\boldsymbol{n}\right)=0 \quad \text{并且} \quad \left(\boldsymbol{I}-\boldsymbol{n}\boldsymbol{n}^{\mathrm{T}}\right)\boldsymbol{v}=\boldsymbol{v}-\boldsymbol{n}(\boldsymbol{n}^{\mathrm{T}}\boldsymbol{v})=\boldsymbol{v}.$$

在齐次坐标下，投影矩阵变为 $4\times 4$（但原点不移动）：

到平面$\boldsymbol{n}^{\mathrm{T}}\boldsymbol{v}=0$的投影矩阵为：
$$\boldsymbol{P}=\begin{bmatrix}\boldsymbol{I}-\boldsymbol{n}\boldsymbol{n}^{\mathrm{T}} & \boldsymbol{0}\\ \boldsymbol{0} & 1\end{bmatrix}.$$

下面考虑到不通过原点的平面（设其满足 $\boldsymbol{n}^{\mathrm{T}}(\boldsymbol{v}-\boldsymbol{v}_0)=0$）的投影变换，其中 $\boldsymbol{v}_0$ 为平面上的一个点. 这是一个仿射空间（或平片）. 情况类似于非齐次线性方程组 $\boldsymbol{A}\boldsymbol{v}=\boldsymbol{b}$ $(\boldsymbol{b}\neq\boldsymbol{0})$ 的解. 将一个特解 $\boldsymbol{v}_0$ 与 $\boldsymbol{a}$ 的零空间相加——以产生一个平片.

投影到平片的步骤有三步. 首先通过 $\boldsymbol{T}_-$ 将 $\boldsymbol{v}_0$ 平移到原点；然后向平面投影；最后沿行向量 $\boldsymbol{v}_0$ 平移回来：

到平片的投影矩阵为：
$$\boldsymbol{T}_-\boldsymbol{P}\boldsymbol{T}_+=\begin{bmatrix}\boldsymbol{I} & \boldsymbol{0}\\ -\boldsymbol{v}_0 & 1\end{bmatrix}\begin{bmatrix}\boldsymbol{I}-\boldsymbol{n}\boldsymbol{n}^{\mathrm{T}} & \boldsymbol{0}\\ \boldsymbol{0} & 1\end{bmatrix}\begin{bmatrix}\boldsymbol{I} & \boldsymbol{0}\\ \boldsymbol{v}_0 & 1\end{bmatrix}.$$

需要注意的是 $\boldsymbol{T}_-$ 和 $\boldsymbol{T}_+$ 互为逆矩阵：对应几何上的平移和反向平移. 它们类似于第 2 章中的初等矩阵.

下述练习中，还涉及反射矩阵，也称为镜像矩阵. 这是计算机图形学中需要的第五种类型的变换. 反射将每个点移动的距离是投影的两倍 ——穿过平面并从另一侧出来，故将投影矩阵 $\boldsymbol{I}-\boldsymbol{n}\boldsymbol{n}^{\mathrm{T}}$ 更改为 $\boldsymbol{I}-2\boldsymbol{n}\boldsymbol{n}^{\mathrm{T}}$ 即可得到镜像矩阵.

实际上，矩阵 $\boldsymbol{P}$ 对应的是所谓的“平行”投影. 所有点都沿着平行于法向量 $\boldsymbol{n}$ 的方向移动，直到它们到达平面. 计算机图形学中还有另一种投影，即所谓的“透视”投影. 这是更常见的情况，它还包括缩放. 在透视观点下，靠近时物体看起来更大. 此时，所有点并不是沿着平行于 $\boldsymbol{n}$ 的方向运动，而是沿着不同的方向，其中每条投影线都指向眼睛，即投影中心. 这就是我们如何在二维照片中感知深度的方式.

计算机图形学的基本问题从场景和观察位置开始. 理想情况下，屏幕上的图像是观察者所看到的. 最简单的图像为每个小图像元素（称为像素），每个像素分配一个比特. 它是亮（白）或暗（黑），这给出了一幅没有阴影的黑白图像. 此时，你不会满意. 实际操作中，我们为三种颜色（如红、绿、蓝）分配介于 0 和 $2^8$ 之间的一个整数值，以表示其深浅级别. 这意味着每个像素需要 $8\times 3=24$ 比特. 再乘以像素的数量，存储一张图片需要大量内存！

物理上，光栅帧缓冲区决定了电子束的方向. 正如电视机成像一样，成像质量由像素数量和每像素的位数决定. 在这一领域，标准教材是《计算机图形学：原理与实践》，由 Hughes，Van Dam，McGuire，Skylar，Foley，Feiner 和 Akeley 编著（第三版，Addison-Wesley 出版社，2014 年）. Ronald Goldman 和 Tony DeRose 的专著也是很好的参考资料.

## 要 点 回 顾

（1）计算机图形学中，同时需要线性变换 $\boldsymbol{T}(\boldsymbol{v})=\boldsymbol{A}\boldsymbol{v}$ 和平移变换 $T(\boldsymbol{v})=\boldsymbol{v}+\boldsymbol{v}_0$.

（2）$\mathbb{R}^n$ 中的图形变换可以在齐次坐标的意义下，通过 $n+1$ 阶矩阵的乘法运算实现.

（3）当所有矩阵都以 $\begin{bmatrix}0 & 0 & 0 & 1\end{bmatrix}^{\mathrm{T}}$ 为最后一列时，$\begin{bmatrix}x & y & z & 1\end{bmatrix}^{\mathrm{T}}$ 中的额外分量 1 在运算中保持不变.

## 习题 A10

1. $\mathbb{R}^3$ 中一个点的典型表示为 $x\boldsymbol{i}+y\boldsymbol{j}+z\boldsymbol{k}$，其中，$\boldsymbol{i}$、$\boldsymbol{j}$、$\boldsymbol{k}$ 的坐标分别是 (1, 0, 0)、(0, 1, 0)、(0, 0, 1)，而该点的坐标是 $(x, y, z)$.

在计算机图形学中，这个点是 $x\boldsymbol{i}+y\boldsymbol{j}+z\boldsymbol{k}+$ 原点. 则它的齐次坐标是 (___, ___, ___, ___). 同一点的其他齐次坐标是 (___, ___, ___, ___).

2. 对于线性变换 $T$ 而言，当我们知道了 $T(\boldsymbol{i})$、$T(\boldsymbol{j})$、$T(\boldsymbol{k})$ 时，$T$ 即可被确定. 对于仿射变换，我们还需要知道 $T$(_____). 输入点 $\begin{bmatrix}x & y & z & 1\end{bmatrix}$ 在该变换作用下为 $xT(\boldsymbol{i})+yT(\boldsymbol{j})+zT(\boldsymbol{k})+$_____.

3. 设右乘 4 阶方阵 $T$ 表示沿 $\begin{bmatrix}1 & 4 & 3\end{bmatrix}$ 做平移变换，右乘 4 阶方阵 $T_1$ 表示沿 $\begin{bmatrix}0 & 2 & 5\end{bmatrix}$ 做平移变换. 则乘积矩阵 $TT_1$ 表示沿 _____ 做平移变换.

4. 写出表示按 $c$ 倍进行缩放的 4 阶矩阵 $\boldsymbol{S}$. 计算 $\boldsymbol{ST}$ 和 $\boldsymbol{TS}$，其中 $\boldsymbol{T}$ 是沿 $\begin{bmatrix}1 & 4 & 3\end{bmatrix}$ 的平移变换. 若要求以 $\begin{bmatrix}1 & 4 & 3\end{bmatrix}$ 为中心不动点，对一张图片进行上述缩放，你会用算式 $\boldsymbol{vST}$ 还是 $\boldsymbol{vTS}$?

5. 要将 $8.5\times 11$ 的标准页面缩放为 $1\times 1$ 的正方形页面，相应的缩放矩阵 $\boldsymbol{S}$ 是什么？（在齐次坐标下，所以是 $3\times 3$ 矩阵.）

6. 设立方体的一个顶点初始坐标为 $\begin{bmatrix}1 & 1 & 2\end{bmatrix}$，要将立方体的该顶点平移到原点，然后所有长度都乘以 2，满足要求的 $4\times 4$ 矩阵是什么？

7. 对于本附录第 3 部分的式(A.11)，证明单位向量 $\boldsymbol{a}$ 与式(A.11)右侧的三个矩阵相乘后的结果分别为 $(\cos\theta)\boldsymbol{a}$、$(1-\cos\theta)\boldsymbol{a}$ 和 $\boldsymbol{0}$. 进一步说明 $\boldsymbol{aQ}=\boldsymbol{a}$，从而说明旋转轴没有移动.

8. 如果 $\boldsymbol{b}$ 与 $\boldsymbol{a}$ 垂直，乘以式(A.11)中的三个矩阵得到 $(\cos\theta)\boldsymbol{b}$、$\boldsymbol{0}$ 以及一个与 $\boldsymbol{b}$ 垂直的向量. 所以 $\boldsymbol{Qb}$ 与 $\boldsymbol{b}$ 形成角度 $\theta$. 这是旋转.

9. 到平面 $\frac{2}{3}x+\frac{2}{3}y+\frac{1}{3}z=0$ 的 $3\times 3$ 投影矩阵 $\boldsymbol{I}-\boldsymbol{nn}^{\mathrm{T}}$ 是什么？在齐次坐标下，在 $\boldsymbol{P}$ 中添加 $\begin{bmatrix}0 & 0 & 0 & 1\end{bmatrix}$ 作为额外的行和列.